BASES DE DATOS NO SQL:
TAREA FINAL



IMDb Top 5000 Movies

https://www.kaggle.com/datasets/tiagoadrianunes/imdb-top-5000-movies

JAIME DE VERA MARTÍN

1. Introducción

En este trabajo se va a detallar el análisis exploratorio y descriptivo realizado sobre el dataset “top_5000_movies”, una colección que agrupa las obras cinematográficas con mayor reconocimiento global según la base de datos de Internet Movie Database (IMDb). Este conjunto de datos ofrece una ventana única al comportamiento de la audiencia y la crítica a lo largo de más de un siglo de historia del cine, conteniendo variables críticas como puntuaciones de usuarios (averageRating), volumen de votos (numVotes), duración, dirección, clasificación por géneros…

Para el procesamiento de la información se ha utilizado el cliente NoSQLBooster de MongoDB.

El estudio no se limita a un ranking superficial, sino que busca desentrañar correlaciones profundas entre las características técnicas de las películas y su recepción por parte del público.

2. Objetivo

Se buscará identificar patrones de éxito, tendencias históricas y sesgos de valoración en la industria cinematográfica mediante el análisis estadístico de las 5.000 películas mejor valoradas en IMDb, con el fin de determinar qué factores (temporales, de autoría o de género) influyen determinantemente en la percepción de calidad de la audiencia.

Se intentará, entre otras cosas:

- Evaluar la evolución temporal y buscar una “Era Dorada”.
- Hacer un análisis de correlación duración-calidad.
- Determinar que directores mantienen la mayor consistencia cualitativa en su filmografía.
- Establecer un ranking de géneros basado en su nota media y volumen.

3. Carga del archivo .CSV

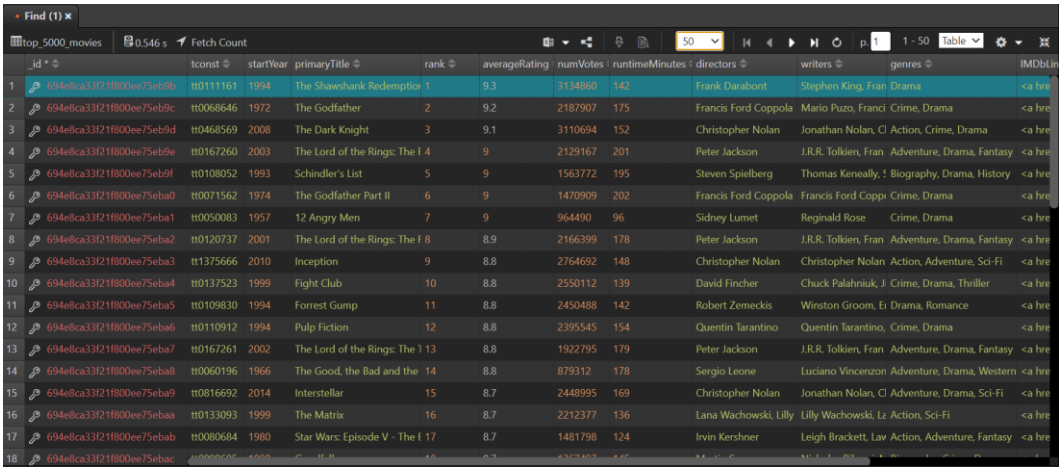
Para comenzar a trabajar con el dataset he tenido que cargarlo a MongoDB Compass: me he conectado a “Local”, he creado una nueva base de datos llamada “bases_de_datos_NoSQL”, he generado una nueva colección llamada “top_5000_movies” y he añadido el archivo “Top_5000_movies_IMDb.csv” que había descargado anteriormente de Kaggle.

Por último, he abierto el Cliente NoSQLBooster for MongoDB, me he ido a mi base de datos que ya había creado, he abierto una query y he comenzado a trabajar con el dataset.

4. Queries

En primer lugar, antes de empezar cualquier análisis es necesario visualizar la base de datos que tenemos:

```
// Vemos la estructura del dataset:
db.top_5000_movies.find()
```



	_id	tconst	startYear	primaryTitle	rank	averageRating	numVotes	runtimeMinutes	directors	writers	genres	IMDbLi
1	694e8ca33f21f800ee75eb9b	tt0111161	1994	The Shawshank Redemptio	1	9.3	3134860	142	Frank Darabont	Stephen King, Fran	Drama	<a hre
2	694e8ca33f21f800ee75eb9c	tt0068646	1972	The Godfather	2	9.2	2187907	175	Francis Ford Coppola	Mario Puzo, Franci	Crime, Drama	<a hre
3	694e8ca33f21f800ee75eb9d	tt0468569	2008	The Dark Knight	3	9.1	3110694	152	Christopher Nolan	Jonathan Nolan, Cl	Action, Crime, Drama	<a hre
4	694e8ca33f21f800ee75eb9e	tt0167260	2003	The Lord of the Rings: The I	4	9	2129167	201	Peter Jackson	J.R.R. Tolkien, Fran	Adventure, Drama, Fantasy	<a hre
5	694e8ca33f21f800ee75eb9f	tt0108052	1993	Schindler's List	5	9	1563772	195	Steven Spielberg	Thomas Keneally, S	Biography, Drama, History	<a hre
6	694e8ca33f21f800ee75eba0	tt0071562	1974	The Godfather Part II	6	9	1470909	202	Francis Ford Coppola	Francis Ford Coppo	Crime, Drama	<a hre
7	694e8ca33f21f800ee75eba1	tt0050083	1957	12 Angry Men	7	9	964490	96	Sidney Lumet	Reginald Rose	Crime, Drama	<a hre
8	694e8ca33f21f800ee75eba2	tt0120737	2001	The Lord of the Rings: The F	8	8.9	2166399	178	Peter Jackson	J.R.R. Tolkien, Fran	Adventure, Drama, Fantasy	<a hre
9	694e8ca33f21f800ee75eba3	tt1375666	2010	Inception	9	8.8	2764692	148	Christopher Nolan	Christopher Nolan	Action, Adventure, Sci-Fi	<a hre
10	694e8ca33f21f800ee75eba4	tt0137523	1999	Fight Club	10	8.8	2550112	139	David Fincher	Chuck Palahniuk, J	Crime, Drama, Thriller	<a hre
11	694e8ca33f21f800ee75eba5	tt0109830	1994	Forrest Gump	11	8.8	2450488	142	Robert Zemeckis	Winston Groom, Er	Drama, Romance	<a hre
12	694e8ca33f21f800ee75eba6	tt0110912	1994	Pulp Fiction	12	8.8	2395545	154	Quentin Tarantino	Quentin Tarantino,	Crime, Drama	<a hre
13	694e8ca33f21f800ee75eba7	tt0167261	2002	The Lord of the Rings: The T	13	8.8	1922795	179	Peter Jackson	J.R.R. Tolkien, Fran	Adventure, Drama, Fantasy	<a hre
14	694e8ca33f21f800ee75eba8	tt0060196	1966	The Good, the Bad and the	14	8.8	879312	178	Sergio Leone	Luciano Vincenzon	Adventure, Drama, Western	<a hre
15	694e8ca33f21f800ee75eba9	tt0816692	2014	Interstellar	15	8.7	2448995	169	Christopher Nolan	Jonathan Nolan, Cl	Adventure, Drama, Sci-Fi	<a hre
16	694e8ca33f21f800ee75ebaa	tt0133093	1999	The Matrix	16	8.7	2212377	136	Lana Wachowski, Lilly	Lilly Wachowski, La	Action, Sci-Fi	<a hre
17	694e8ca33f21f800ee75ebab	tt0080684	1980	Star Wars: Episode V - The E	17	8.7	1481798	124	Irvin Kershner	Leigh Brackett, Lav	Action, Adventure, Fantasy	<a hre
18	694e8ca33f21f800ee75ebac											

En segundo lugar, era importante saber en qué rango de tiempo se situaban estas películas:

```
// ¿Desde qué año parten las películas?
var proyection_oldest_movie = {"_id": 0, "startYear": 1}
var order_oldest_movie = { "startYear": 1 }
db.top_5000_movies.find({}, proyection_oldest_movie).sort(order_oldest_movie).limit(1)

// ¿De qué año son las películas más modernas?
var proyection_newest_movie = {"_id": 0, "startYear": -1}
var order_newest_movie = { "startYear": -1 }
db.top_5000_movies.find({}, proyection_newest_movie).sort(order_newest_movie).limit(1)
```

	startYear
1	1915

	startYear
1	2025

El análisis continúa respondiendo cuáles son las 10 mejores y peores películas según el ranking de la propia web de IMDb:

```
// ¿Cuáles son las 10 películas mejor valoradas según el ranking de IMDb?
var proyection_top_IMDb_movies = {"_id": 0, "primaryTitle": 1, "startYear": 1, "rank": 1}
var order_top_IMDb_movies = {"rank": 1}
db.top_5000_movies.find({}, proyection_top_IMDb_movies).sort(order_top_IMDb_movies).limit(10)

// ¿Cuáles son las 10 películas peor valoradas según el ranking de IMDb?
var proyection_bottom_IMDb_movies = {"_id": 0, "primaryTitle": 1, "startYear": 1, "rank": 1}
var order_bottom_IMDb_movies = {"rank": -1}
db.top_5000_movies.find({}, proyection_bottom_IMDb_movies).sort(order_bottom_IMDb_movies).limit(10)
```

	primaryTitle	startYear	rank
1	The Shawshank Redemption	1994	1
2	The Godfather	1972	2
3	The Dark Knight	2008	3
4	The Lord of the Rings: The Return of the King	2003	4
5	Schindler's List	1993	5
6	The Godfather Part II	1974	6
7	12 Angry Men	1957	7
8	The Lord of the Rings: The Fellowship of the Ring	2001	8
9	Inception	2010	9
10	Fight Club	1999	10

	primaryTitle	startYear	rank
1	Tomorrowland	2015	5000
2	The Woman in Black	2012	4999
3	Valerian and the City of a Thousand Planets	2017	4998
4	The Longest Yard	2005	4997
5	Happy Feet	2006	4996
6	The Taking of Pelham 123	2009	4995
7	The World Is Not Enough	1999	4994
8	The Number 23	2007	4993
9	Death Race	2008	4992
10	17 Again	2009	4991

El número 1 en 'rank', es decir la mejor película según IMDb, es The Shawshank Redemption de 1994 (Cadena Perpetua), seguida de The Godfather de 1972 (El Padrino) y de The Dark Knight de 2008 (El Caballero Oscuro).

En el otro extremo están las películas peor valoradas de este top: Tomorrowland de 2015 (El Mundo del Mañana), seguida de The Woman in Black de 2012 (La Mujer de Negro) y de Valerian and the City of a Thousand Planets de 2017 (Valerian y la Ciudad de los Mil Planetas).

Se debe recalcar que esto no quiere decir que estas películas peor valoradas sean "malas", ya que estamos analizando un dataset que registra las 5000 mejores obras cinematográficas según IMDb.

Con las siguientes queries también se quería buscar las mejores y peores 10 películas, sin embargo, esta vez quería que se tuviera en cuenta el voto de los usuarios en vez del ranking de IMDb.

Primero hice esta consulta:

```
// ¿Cuáles son las 10 películas mejor valoradas por los usuarios? Ante empate, se muestra la más antigua primero:
var proyection_top_users_movies = {"_id": 0, "primaryTitle": 1, "startYear": 1, "averageRating": 1}
var order_top_users_movies = {"averageRating": -1, "startYear": 1}
db.top_5000_movies.find({}, proyection_top_users_movies).sort(order_top_users_movies).limit(10)

// ¿Cuáles son las 10 películas peor valoradas por los usuarios? Ante empate, se muestra la más nueva primero:
var proyection_top_users_movies = {"_id": 0, "primaryTitle": 1, "startYear": 1, "averageRating": 1}
var order_top_users_movies = {"averageRating": 1, "startYear": -1}
db.top_5000_movies.find({}, proyection_top_users_movies).sort(order_top_users_movies).limit(10)
```

	primaryTitle	startYear	averageRating
1	The Shawshank Redemption	1994	9.3
2	The Godfather	1972	9.2
3	The Chaos Class	1975	9.2
4	The Dark Knight	2008	9.1
5	12 Angry Men	1957	9
6	The Godfather Part II	1974	9
7	Schindler's List	1993	9
8	The Lord of the Rings: The Return of the King	2003	9
9	Tosun Pasha	1976	8.9
10	The Lord of the Rings: The Fellowship of the Ring	2001	8.9

	primaryTitle	startYear	averageRating
1	iBoy	2017	5.9
2	Jane Got a Gun	2015	5.9
3	Sikandar Ka Muqaddar	2024	6
4	Ulajh	2024	6
5	Fast Charlie	2023	6
6	The Blackening	2022	6
7	Vesper	2022	6
8	Werewolves Within	2021	6
9	Super Troopers 2	2018	6
10	2.0	2018	6

Sin embargo, me di cuenta de que el resultado podía no ser representativo ya que no se tenía en cuenta el número de votos como segundo parámetro, sino que se tenía en cuenta la antigüedad…

Por esto mismo, decidí sacar unas estadísticas rápidas del número de votos:

```
// Estadísticas rápidas del número de votos de los usuarios
db.top_5000_movies.aggregate([
    {
        $group: {
            _id: null,
            "min_votos": {$min: "$numVotes"},
            "max_votos": {$max: "$numVotes"},
            "avg_votos": {$avg: "$numVotes"}
        }
    }
])
```

	_id *	min_votos	max_votos	avg_votos
1	null	25004	3134860	166456.785

En este momento decidí volver a calcular las 10 mejores y peores películas según el voto de los usuarios usando la media del número de votos (‘avg_votos’) para filtrar y solo tener en cuenta las películas con 166.456,785 votos o más:

```
// Teniendo en cuenta el nº de votos, ¿cuáles son las 10 películas mejor valoradas por los usuarios?
var umbral_votos = 166456.785
var filter_top_users_movies = {"numVotes": {"$gte": umbral_votos}}
var proyection_top_users_movies = {"_id": 0, "primaryTitle": 1, "startYear": 1, "averageRating": 1, "numVotes": 1}
var order_top_users_movies = {"averageRating": -1, "numVotes": -1}
db.top_5000_movies.find(filter_top_users_movies, proyection_top_users_movies).sort(order_top_users_movies).limit(10)

// Teniendo en cuenta el nº de votos, ¿cuáles son las 10 películas peor valoradas por los usuarios?
var umbral_votos = 166456.785
var filter_bottom_users_movies = {"numVotes": {"$gte": umbral_votos}}
var proyection_bottom_users_movies = {"_id": 0, "primaryTitle": 1, "startYear": 1, "averageRating": 1, "numVotes": 1}
var order_bottom_users_movies = {"averageRating": 1, "numVotes": -1}
db.top_5000_movies.find(filter_bottom_users_movies, proyection_bottom_users_movies).sort(order_bottom_users_movies).limit(10)
```

	primaryTitle	startYear	averageRating	numVotes
1	The Shawshank Redemption	1994	9.3	3134860
2	The Godfather	1972	9.2	2187907
3	The Dark Knight	2008	9.1	3110694
4	The Lord of the Rings: The Return of the King	2003	9	2129167
5	Schindler's List	1993	9	1563772
6	The Godfather Part II	1974	9	1470909
7	12 Angry Men	1957	9	964490
8	The Lord of the Rings: The Fellowship of the Ring	2001	8.9	2166399
9	Inception	2010	8.8	2764692
10	Fight Club	1999	8.8	2550112

	primaryTitle	startYear	averageRating	numVotes
1	The Expendables	2010	6.4	377463
2	The Mummy Returns	2001	6.4	363467
3	Now You See Me 2	2016	6.4	353759
4	Alien³	1992	6.4	348614
5	Alien: Covenant	2017	6.4	340200
6	How the Grinch Stole Christmas	2000	6.4	325629
7	Meet the Fockers	2004	6.4	299686
8	Just Go with It	2011	6.4	284831
9	Minions	2015	6.4	279662
10	Predators	2010	6.4	259394

Con esta consulta encontramos algo muy curioso ya que podemos afirmar que la mayoría de los 10 mejores títulos según el voto de los usuarios son los mismos que en el propio ranking de IMDb.

Sin embargo, al comparar los 10 peores títulos nos damos cuenta de que son totalmente distintos. Esto se debe a que, al haber utilizado el filtro 'avg_votos', las películas que nos encontramos aquí son "blockbusters". Es decir, son éxitos rotundos en taquillas que han acabado decepcionando al público.

En la siguiente query quería saber cuáles eran las mejores y peores décadas del cine:

```
// ¿Cuál es la mejor y peor década teniendo en cuenta las votaciones de las 50 mejores películas de cada década?
var pipeline_top_50_decade = [
    {
        $project: {
            "decada": {$subtract: ["$startYear", {$mod: ["$startYear", 10]}]},
            "averageRating": 1,
            "originalTitle": 1
        }
    },
    {
        $setWindowFields: {
            partitionBy: "$decada",
            sortBy: {"averageRating": -1}
            output: {
                "rank_en_decada": {
                    $rank: {}
                }
            }
        }
    },
    {
        $match: {"rank_en_decada": {$lte: 50}}
    },
    {
        $group: {
            "_id": "$decada",
            "calidad_top_50": {$avg: "$averageRating"}
        }
    },
    { $sort: {"calidad_top_50": -1}}
]
db.top_5000_movies.aggregate(pipeline_top_50_decade)
```

	_id *	calidad_top_50
1	1990	8.350980392156861
2	2010	8.319354838709677
3	2000	8.296825396825398
4	2020	8.27818181818182
5	1980	8.132727272727273
6	1950	8.109803921568627
7	1960	8.1
8	1970	8.098275862068965
9	1920	8.083333333333334
10	1940	7.909433962264151
11	1930	7.8566666666666665
12	1910	6.1

Sin duda esta fue de las consultas que más me costaron, ya que al principio la hice de todas las 5000 películas del dataset, sin embargo, me di cuenta de que había décadas en las que se habían hecho muchísimas más películas que en otras. Por ello, decidí filtrar el resultado y tener en cuenta solo los mejores 50 títulos de cada década.

Lo que obtuve fue que la "Década Dorada" del cine fue en 1990, aunque muy seguida de la del 2010, la del 2000 y la del 2020. También podemos observar que la década de 1910 fue la peor de todas por mucha diferencia, algo totalmente normal teniendo en cuenta que el cine se inventó oficialmente con la primera exhibición pública de los hermanos Lumière en París el 28 de diciembre de 1895.

La siguiente consulta trata de si existe una relación directa entre la duración de una película y la votación que obtiene:

```
// ¿Hay relación entre la duración de una película y su votación? Rango en minutos: 0-90, 90-120, 120-150, 150-300, 300-400.
var pipeline_time = [
    {
        $bucket: {
            groupBy: "$runtimeMinutes",
            boundaries: [0, 90, 120, 150, 300, 400],
            output: {
                "total_pelis": {$sum: 1},
                "nota_media": {$avg: "$averageRating"}
            }
        }
    }
]
db.top_5000_movies.aggregate(pipeline_time)
```

	_id *	total_pelis	nota_media
1	0	389	7.139331619537274
2	90	2860	7.038811188811189
3	120	1365	7.292893772893772
4	150	382	7.651832460732984
5	300	4	7.8

Pese a que, comercialmente, sean más populares las películas de entre una hora y media y 2 horas (2860 títulos en este rango), esto no quiere decir que tengan mejores valoraciones. De hecho, según los resultados obtenidos, podemos afirmar que la duración tiene una relación directa con la valoración de la película: cuanto más larga es la obra cinematográfica, mejor valoración tiene. Las mejores medias de valoraciones están en el rango de películas de más de cinco horas (7,8) y en el rango de entre dos horas y media y cinco horas (7,65).

El siguiente análisis fue sobre los mejores y peores directores de este dataset:

```
// ¿Quiénes son los 10 mejores directores teniendo en cuenta que tengan al menos 5 películas en este TOP?
var pipeline_top_10_directors = [
    {$sort: {"startYear": 1}},
    {
    |   $group: {
    |   |   "_id": "$directors",
    |   |   "nota_media": {$avg: "$averageRating"},
    |   |   "cantidad_peliculas_dirigidas": {$sum: 1},
    |   |   "peliculas": {$push: "$primaryTitle"}
    |   }
    },
    {
    |   $match: {
    |   |   "cantidad_peliculas_dirigidas": {$gte: 5}
    |   }
    },
    {$sort: {"nota_media": -1}},
    { $limit: 5 }
]
db.top_5000_movies.aggregate(pipeline_top_10_directors)

// ¿Quiénes son los 10 peores directores teniendo en cuenta que tengan al menos 5 películas en este TOP?
var pipeline_bottom_10_directors = [
    {$sort: {"startYear": 1}},
    {
    |   $group: {
    |   |   "_id": "$directors",
    |   |   "nota_media": {$avg: "$averageRating"},
    |   |   "cantidad_peliculas_dirigidas": {$sum: 1},
    |   |   "peliculas": {$push: "$primaryTitle"}
    |   }
    },
    {
    |   $match: {
    |   |   "cantidad_peliculas_dirigidas": {$gte: 5}
    |   }
    },
    {$sort: {"nota_media": 1}},
    { $limit: 5 }
]
db.top_5000_movies.aggregate(pipeline_bottom_10_directors)
```

_id	Charles Chaplin	Sergio Leone	Akira Kurosawa	Christopher Nolan	Frank Capra
nota_media	8,3	8,2	8,172727273	8,166666667	8,1
cantidad_peliculas_dirigidas	6	6	11	12	5
peliculas	["The Kid","The Gold Rush","The Circus","City Lights","Modern Times","The Great Dictator"]	["A Fistful of Dollars","For a Few Dollars More","The Good, the Bad and the Ugly","Once Upon a Time in the West","Duck, You Sucker!","Once Upon a Time in America"]	["Rashomon","Ikiru","Seven Samurai","Throne of Blood","The Hidden Fortress","Yojimbo","Sanjuro","High and Low","Dersu Uzala","Kagemusha: The Shadow Warrior","Ran"]	["Following","Memento","Insomnia","Batman Begins","The Prestige","The Dark Knight","Inception","The Dark Knight Rises","Interstellar","Dunkirk","Tenet","Oppenheimer"]	["It Happened One Night","You Can't Take It with You","Mr. Smith Goes to Washington","Arsenic and Old Lace","It's a Wonderful Life"]

_id	David Twohy	Gary Fleder	John Badham	Peter Segal	Danny DeVito
nota_media	6,48	6,566666667	6,571428571	6,585714286	6,62
cantidad_peliculas_dirigidas	5	6	7	7	5
peliculas	["The Arrival","Pitch Black","Below","The Chronicles of Riddick","A Perfect Getaway"]	["Things to Do in Denver When You're Dead","Kiss the Girls","Don't Say a Word","Impostor","Runaway Jury","Homefront"]	["Saturday Night Fever","WarGames","Blue Thunder","Short Circuit","Stakeout","Point of No Return","Nick of Time"]	["Naked Gun 33 1/3: The Final Insult","Tommy Boy","50 First Dates","The Longest Yard","Get Smart","Grudge Match","My Spy"]	["Throw Momma from the Train","The War of the Roses","Hoffa","Matilda","Death to Smoochy"]

He trasladado los resultados a Excel para poder hacer una captura de pantalla más eficiente.

Aquí podemos ver quiénes son los directores mejor valorados, siempre y cuando tengan 5 películas o más en este dataset. Observamos que sus medias están muy emparejadas siendo Charles Chaplin el mejor con un 8,3 de media.

Además, también nos encontramos con el número de películas del dataset que son de estos directores; siendo, en este top 5, Christopher Nolan el que más tiene con 12 filmes, seguido de Akira Kurosawa con 11.

Por otro lado, vemos los 5 directores peor valorados del dataset, liderando la cola David Twohy con una media de 6,48 y 5 películas dirigidas.

Por último, quise hacer un último análisis teniendo en cuenta los diferentes géneros de las películas. Dado que una película puede pertenecer a múltiples géneros, necesitaba separarlos para evaluar cada categoría individualmente, por ello usé '$project' + '$split' y luego '$unwind' para expandir el array en varios documentos si fuera necesario. Además, también filtré los resultados para descartar los géneros que estuvieran en menos de 50 películas y así evitar "outlayers":

```
// ¿Cuáles son los mejores géneros (> 50 pelis)? ¿Cúantas películas hay de ese género? ¿Cuál es la mejor y su not? ¿Cuál es la nota media del género?
var pipeline_final_genres = [
    {
        $project:
        {
            "primaryTitle": 1,
            "averageRating": 1,
            "genres_array": { $split: ["$genres", ", "] }
        }
    },
    { $unwind: "$genres_array" },
    { $sort: { "averageRating": -1 } },
    {
        $group: {
            "_id": "$genres_array",
            "nota_media_genero": { $avg: "$averageRating" },
            "total_peliculas": { $sum: 1 },
            "mejor_pelicula": { $first: "$primaryTitle" },
            "nota_maxima": { $first: "$averageRating" }
        }
    },
    {
        $match: {
            "total_peliculas": { $gte: 50 }
        }
    },
    {
        $project: {
            "genero": "$_id",
            "nota_media": { $round: ["$nota_media_genero", 2] },
            "total_peliculas": 1,
            "mejor_pelicula": 1,
            "nota_maxima": 1,
            "_id": 0
        }
    },
    { $sort: { "nota_media": -1 } }
]
db.top_5000_movies.aggregate(pipeline_final_genres)
```

	total_peliculas	mejor_pelicula	nota_maxima	genero	nota_media
1	82	David Attenborough: A Life on Our Planet	8.9	Documentary	7.79
2	128	Saving Private Ryan	8.6	War	7.52
3	60	The Good, the Bad and the Ugly	8.8	Western	7.46
4	71	Sita Ramam	8.5	Musical	7.33
5	222	Schindler's List	9	History	7.32
6	512	Schindler's List	9	Biography	7.3
7	323	Spirited Away	8.6	Animation	7.28
8	144	Whiplash	8.5	Music	7.24
9	3176	The Shawshank Redemption	9.3	Drama	7.24
10	126	Senna	8.5	Sport	7.2
11	203	Spirited Away	8.6	Family	7.18
12	915	The Lord of the Rings: The Return of the King	9	Adventure	7.16
13	1111	The Godfather	9.2	Crime	7.14
14	336	The Lord of the Rings: The Return of the King	9	Fantasy	7.09
15	539	Mirror Game	8.9	Mystery	7.09
16	773	Forrest Gump	8.8	Romance	7.09
17	1135	The Dark Knight	9.1	Action	7.07
18	784	Mirror Game	8.9	Thriller	7.06
19	335	Inception	8.8	Sci-Fi	7.06
20	1627	The Chaos Class	9.2	Comedy	7.03
21	449	The Silence of the Lambs	8.6	Horror	6.87

Aquí podemos ver los 21 géneros principales ordenados de mayor a menor valoración media, la película mejor valorada de cada uno junto a su nota y la cantidad de películas que pertenecen a este género.

Un detalle curioso que ocurre con este último análisis es que algunas de las mejores películas se repiten en diferentes géneros, algo totalmente normal teniendo en cuenta que hemos separado explotado el array de 'genres' en distintos documentos.

Según esta consulta, los tres líderes son los géneros Documentary (Documental), War (Guerra) y Western (Oeste) con una nota media de 7,79, 7,52 y 7,46 respectivamente; mientras que los peores son Horror (Terror), Comedy (Comedia) y Sci-Fi (Ciencia Ficción) con una nota media de 6,87, 7,03 y 7,06.

5. Conclusión

Tras el procesamiento y análisis exhaustivo del dataset "Top_5000_movies_IMDb" utilizando el framework de agregación de MongoDB, se han extraído evidencias estadísticas significativas que permiten modelar el comportamiento de la calidad cinematográfica y su percepción por parte de la audiencia.

La comparación entre el ranking oficial de IMDb y la valoración por voto de usuario reveló una distinción en la "cola" de la distribución. Mientras que las mejores películas coinciden en ambos sistemas, las peores películas son totalmente distintas. El público castiga a los blockbusters decepcionantes mientras que el ranking oficial lo suaviza mediante sus algoritmos de ponderación, ya que, según su propia web, IMDb utiliza la fórmula bayesiana o Teorema de Bayes.

Continuando el análisis, podemos afirmar que existe una Era Dorada Moderna (1990-2010). Al aislar el "Top 50" de cada década para realizar una comparación justa (evitando el ruido de las miles de producciones mediocres recientes), identificamos que las décadas de 1990 y 2000 representan el pico de calidad en este dataset. Esto puede interpretarse como el punto de madurez del cine moderno, produciendo clásicos universales (como The Shawshank Redemption, The Dark Knight, The Lord of the Rings, Schindler's List, Fight Club, Forrest Gump…) que dominan los rankings.

Contrario a la creencia popular de que el cine tiende a ser breve para maximizar sesiones, los datos revelan una correlación directa entre duración y calidad percibida. Las películas de más de 150 minutos (y especialmente las de >5 horas) obtienen las medias más altas. Esto sugiere que las producciones de larga duración suelen asociarse a proyectos de mayor ambición artística, épicas históricas o versiones extendidas dedicadas a un nicho de fans muy comprometido, mientras que las películas estándar (90-120 min) sufren mayor variabilidad en su calidad.

Además, el análisis de los directores revela que la excelencia en este dataset no es fruto de la casualidad. Los directores mejor valorados (como Christopher Nolan o Akira Kurosawa) muestran una consistencia estadística notable: son capaces de mantener medias superiores a 8,1 con filmografías extensas (>10 películas en el ranking).

Por otro lado, el análisis desglosado por género demuestra que la popularidad masiva penaliza la nota media. Los géneros mejor valorados (Documental, Guerra, Western) se caracterizan por tener un público específico y exigente, o por un "filtro de supervivencia" histórico (en el caso del Western, solo perduran las obras maestras). Por el contrario, los géneros más prolíficos (Comedia, Terror) ocupan los puestos más bajos. Esto valida la hipótesis de que el cine de género masivo tiende a producir una gran cantidad de títulos de consumo rápido que bajan la media general, además de ser géneros altamente subjetivos (lo que da miedo o risa a uno, puede aburrir a otro).

En resumen, el análisis confirma que la "calidad" en el cine, aunque subjetiva, obedece a patrones medibles relacionados con la ambición del proyecto (duración), la especialización temática (género) y la consistencia autoral (directores), proporcionando una guía objetiva sobre qué factores maximizan la probabilidad de éxito ante la audiencia de IMDb.