ntic master

UNIVERSIDAD COMPLUTENSE MADRID

Fundamentos de Estadística

Francisco José LLuna

1

Introducción a la estadística

“Algún día el pensamiento estadístico será tan necesario como la habilidad para leer y escribir” (Wells, hace un siglo)

En este capítulo estudiaremos qué es la estadística y los orígenes del término. Describiremos cuáles son las fases de un estudio estadístico y terminaremos el capítulo estudiando qué tipos de datos nos podemos encontrar.

Como ya sabes, hablar de Big Data es referirse a conjuntos de datos extremadamente grandes y complejos que son difíciles de procesar utilizando las herramientas tradicionales. Estos datos pueden ser de distintos tipos: texto, imágenes, audios, videos….

El Big Data se basa en tres puntos fundamentales:
•**Volumen**. Es la cantidad de datos que se generan y almacenan.
•**Velocidad**. Hace referencia a la velocidad a la que se generan y recopilan todos los datos en tiempo real.
•**Variedad**. Es la diversidad de fuentes de las que se obtiene la información, tanto datos estructurados como no estructurados.

Con esto es necesario que se usen distintas herramientas y técnicas para el **procesamiento y análisis de toda la información**. En este contexto es donde entra en juego la aplicación de métodos de estadística dentro de Big Data.
Como decimos, **la estadística desempeña un papel importante en el trabajo de Big Data ya que da las herramientas y las técnicas necesarias para extraer la información relevante de conjuntos de datos grandes y densos. Sin la estadística, el Big Data sería simplemente un mar de datos sin sentido.**

QUÉ ES LA ESTADÍSTICA

La Estadística es la ciencia que trata de:

- **Recoger, organizar, resumir, presentar, interpretar y procesar datos para convertir los datos en información. (Estadística descriptiva)**

- **Hacer predicciones y pronósticos de poblaciones usando el cálculo de probabilidades. Toma de decisiones (Estadística inferencial)**

Se trata de una ciencia multidisciplinar que puede ser aplicada más allá de las ciencias, ya que la estadística también es aplicada en diversos estudios en las áreas de las ciencias sociales, ciencias de la salud, economía, negocios y en diversos estudios de tipo gubernamental.
La estadística es una de las más poderosas herramientas para evaluar aspectos del comportamiento de poblaciones.

Es muy importante ser crítico con los resultados estadísticos debido a la falta de información del proceso seguido para la obtención de los mismos en muchos estudios. De ahí la importancia de un conocimiento de estadística por parte del investigador.

.

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

¿Cuándo empezó la Estadística?

La Estadística actual es el resultado de la unión de dos disciplinas que evolucionaron de forma independiente hasta confluir en el siglo XIX:

1. El Cálculo de Probabilidades, que nació en el siglo XVII como la teoría matemática de los juegos de azar
2. la “Estadística”, o ciencia del Estado, que estudia la descripción de datos, y que tiene unas raíces más antiguas, de hecho, tan antiguas como la humanida. Surge de la necesidad de registrar datos para la administración, el gobierno y la economía (censos de población).

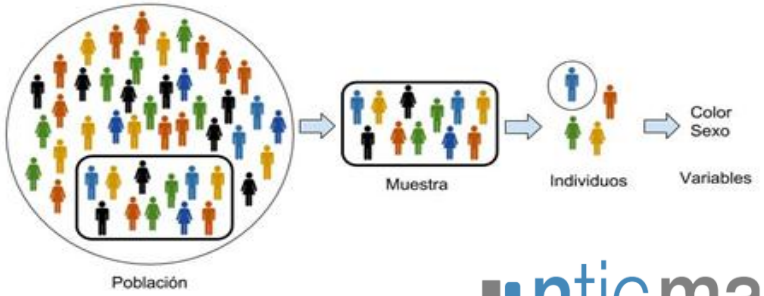
La interacción de ambas líneas de pensamiento da lugar a la ciencia que estudia cómo obtener conclusiones de la investigación empírica mediante el uso de modelos matemáticos.

TERMINOLOGÍA ESTADÍSTICA

POBLACIÓN O UNIVERSO. Conjunto de elementos, personas o cosas, objeto de estudio

INDIVIDUO. Cada uno de los elementos de la población.

MUESTRA. Subconjunto de elementos representativo de la población. Al procedimiento de escoger una muestra en la población se le llama MUESTREO



ntic master

UNIVERSIDAD COMPLUTENSE MADRID

FASES DEL ANÁLISIS ESTADÍSTICO

Cada experiencia particular de un fenómeno aleatorio no proporciona ninguna información relevante. Es necesario analizar grupos numerosos de experiencias: grandes masas de datos que es necesario organizar e interpretar . Cualquier estudio estadístico tiene dos fases:

1. ESTADÍSTICA DESCRIPTIVA

Comprende la recogida, organización, resumen, representación y análisis de los datos de la muestra. Es la fase de análisis de datos.

2. ESTADÍSTICA INFERENCIAL

Es el conjunto de técnicas que permiten “inferir” o trasladar a la población completa los resultados obtenidos para una muestra, así como el cálculo de la fiabilidad que puede otorgarse a dichos resultados para la población. Es muy importante ser críticos con las conclusiones obtenidas en muchos informes debido a la falta de información de los procedimientos seguidos. Tendríamos dentro de esta fase las técnicas de estimación de parámetros desconocidos de la población y los contrastes de hipótesis sobre el valor de un parámetro desconocido.

FASES DEL ANÁLISIS ESTADÍSTICO

En esta fase se pasa de lo particular, la muestra, a lo general, la población. Es por tanto una fase inductiva.Se trata de hacer generalizaciones de toda la población a partir de información limitada.

La estadística inferencial se utiliza en situaciones en las que no es posible o práctico medir o analizar toda la población, ya sea porque la población es muy grande, el costo de medición es prohibitivo, o simplemente porque es imposible recopilar información sobre toda la población.

La inferencia estadística usa el **cálculo de probabilidades** para saber como una cierta medida se distribuye bajo unos ciertas condiciones. De ahí la importancia de conocer el concepto de probabilidad y las distribuciones de probabilidad más importantes.

ESTADÍSTICA DESCRIPTIVA VS ESTADÍSTICA INFERENCIAL

Supongamos que tenemos una clase con 25 alumnos de un instituto de secundaria y en esa clase se quieren estudiar la notas de un examen de Matemáticas en el que se ha puntuado a los alumnos con una calificación que va del 0 al 10.

A partir de las notas de todos los alumnos podremos obtener medidas de resumen y realizar gráficos. Podremos calcular fácilmente la media obtenida por los estudiantes en el examen, calcular la proporción de los alumnos que han obtenido notable o sobresaliente e incluso podemos dibujar gráficos como un diagrama de sectores o un histograma para observar la distribución de las calificaciones obtenidas.

Las conclusiones obtenidas nos dan una imagen perfecta de lo que ocurre en esa clase en concreto. **No hay incertidumbre alrededor de estas medidas,** porque hemos recogido datos para cada uno de los estudiantes de la clase. Sin embargo, estos resultados no pueden extrapolarse a todos los estudiantes de los centros educativos españoles, ya que corresponden a los resultados de esa clase en concreto



ntic master

UNIVERSIDAD COMPLUTENSE MADRID

ESTADÍSTICA DESCRIPTIVA VS ESTADÍSTICA INFERENCIAL

En cambio, en **estadística inferencial** nosotros necesitamos definir la población con la que vamos a trabajar y a partir de ahí seleccionaremos una muestra. Por ejemplo, consideramos todos los estudiantes de 4º de la ESO de España que estudian en institutos públicos. Después de elegir adecuadamente la técnica que se usará para seleccionar los individuos de mi muestra y decidir el tamaño de la misma tendremos una muestra de un tamaño determinado, por ejemplo de 200 alumnos. Estos alumnos no estarán en una única clase , perteneceran a diferentes clases del territorio español. En inferencia estadística nosotros podremos calcular la estimación puntual de la media, desviación típica, proporción….a partir de mi muestra concreta. Sin embargo, sería muy extraño que estas estimaciones puntuales correspondan a los valores reales de estos parámetros y no hay forma de conocer el error que cometemos ya que nosotros no podemos medir a todos los individuos de la población y por lo tanto hay **incertidumbre, por ello expresaremos el posible rango de valores usando los intervalos de confianza**

.



ntic master

UNIVERSIDAD COMPLUTENSE MADRID

Ejemplo 2 : Vamos a suponer que queremos estudiar el gasto energético de un grupo de 40 viviendas de una ciudad. Nosotros recogeríamos los datos, calcularíamos las medidas de resumen junto con los gráficos estadísticos adecuados. Podríamos estar interesados en la media de energía que consumen estas viviendas o la proporción de viviendas que supera una cierta cantidad. Las conclusiones obtenidas serían un fiel reflejo de lo que pasa en ese grupo de 40 viviendas y no hay ningún tipo de incertidumbre porque los cálculos se realizan tomando el valor consumido de cada una de las viviendas .Sin embargo, nosotros no podemos extrapolar estos resultados a todas las viviendas de la ciudad. Esto sería estadística descriptiva.



Sin embargo, en estadística inferencial, tomamos una muestra aleatoria de la población mediante alguna técnica de muestreo probabilística para inferir valores poblacionales desconocidos. Imaginemos que tomamos de esa muestra la media o la proporción de viviendas que cumplen alguna condición. Sin embargo, es muy improbable que alguno de esos valores sea el exacto de la población y no hay forma de saberlo. Esto es debido a que no podemos evaluar todos los individuos de la población, por lo tanto habrá un margen de error.



nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

Muestreo probabilístico: Nos permiten conocer la probabilidad que cada individuo a estudio tiene de ser incluido en la muestra.

Destacamos los más importantes:

Muestro aleatorio simple (MAS): Cada miembro de la población tiene la misma probabilidad de ser seleccionado para la muestra y cualquier grupo de n individuos es igual de probable de ser elegido que otro grupo de n individuos.
Este sistema funciona a través de un método de «sorteo» entre un universo de individuos, en el que se le asigna a cada integrante un número para ser escogido.

Las ventajas de este tipo de muestreo es que es sencillo para armar muestras y se trata de un buen método para explicar resultados ya que la selección de los individuos es aleatoria e imparcial. En cambio como se requiere una lista completa de los individuos de la población, este muestreo se desaconseja para poblaciones grandes.

Los DataFrames de Pandas incluyen el método sample que nos permite implementar el muestreo aleatorio en Python. Así para obtener n muestras aleatorias de un DataFrame solamente se tiene que escribir lo siguiente: sample_df =df.sample(n)

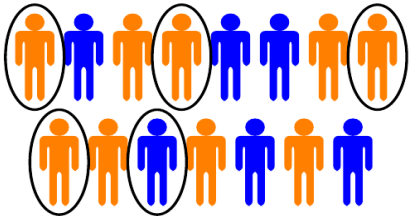
Muestreo sistemático: Supongamos que de una población de N individuos, se quiere hacer una selección de n elementos, entonces calculamos N/n = k (será el período) , se selecciona el primer elemento de forma aleatoria y a partir de ahí cada k individuos se tomarán el resto de los n-1 representantes para mi muestra.

Es un método con el que se obtienen muestras representativas y es bastante sencillo. Existe tan solo una desventaja o inconveniente al utilizar esta técnica: el orden en el que se coloca a la población seleccionada puede llegar a tener un tipo de periodicidad oculta, la cual puede coincidir con el intervalo seleccionado, ocasionando una muestra sesgada.

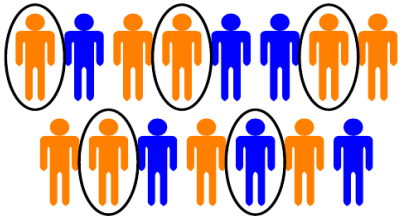
Muestreo estratificado (muestreo de cuota aleatoria) : La población es primeramente dividida en dos subgrupos o estratos , mutuamente excluyentes, exhaustivos y de forma que cada uno de los subgrupos comparten una característica común. Entonces seleccionamos una muestra aleatoria de cada uno de los subgrupos. Es usado cuando a nosotros nos interesa estudiar una característica de cada uno de los grupos que componen una población y nos queremos asegurar que contamos con representación de cada grupo de interés.

Muestreo por conglomerados: El muestreo por conglomerados es un método de muestreo en el que la población objetivo se divide en múltiples conglomerados o grupos. Algunos de estos grupos se seleccionan de manera aleatoria e incluso algunas veces, se lleva a cabo una segunda etapa o un muestreo de etapas múltiples para formar la muestra objetivo. Este método de muestreo es extremadamente rentable ya que requiere de un esfuerzo mínimo en cuanto a la creación de las muestras y también es conveniente para en cuanto a su ejecución.

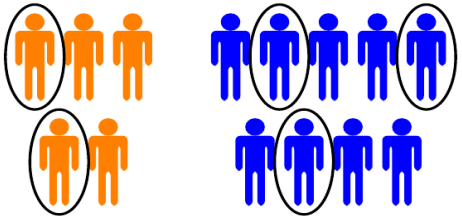
Muestreo aleatorio



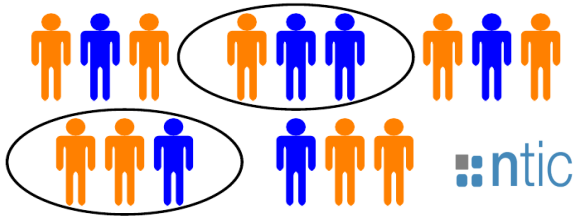
Muestreo sistemático



Muestreo estratificado



Muestreo por conglomerados



ntic master
UNIVERSIDAD COMPLUTENSE MADRID

Muestreo no probabilístico:

La selección de los individuos a estudio dependerá de ciertas características, criterios …. que el investigador pueda considerar, por lo que pueden dar pie a resultados poco válidos, lo que da lugar a **muestras no representativas de la población**. Sin embargo, en los estudios en los que no es posible un muestreo probabilístico o rentable/asequible usaremos este tipo de muestreo.

Algunos ejemplos de este tipo de muestreo son:

Muestreo por conveniencia: Los miembros de la muestra son seleccionados teniendo en cuenta su disponibilidad o voluntad de tomar parte en la misma. Podemos obtener resultados útiles, sin embargo los mismos son proclives a tener sesgo (es el término usado en estadística para indicar cómo de alejados nos encontramos del verdadero valor del parámetro que queremos estimar) ya que los voluntarios que toman parte en la muestra pueden ser diferentes de aquellos que no lo eligen y la muestra puede no ser representativa de otras características tales como edad, sexo….

Muestreo por cuota: Parecido al estratificado, pero no es aleatorio. Este método es usado por estudios de mercado. A los investigadores se les da una cuota de sujetos de un tipo específico para ser encuestados.

Muestreo bola de nieve: Este método es comúnmente usado en ciencias sociales cuando se trata de estudiar grupos de díficil dificultad o acceso. Se pide a los individuos seleccionados que vayan nombrando gente conocida por ellos para incorporarse en el muestreo, de esta forma la muestra va aumentando como si fuese una bola de nieve.



ntic master

UNIVERSIDAD COMPLUTENSE MADRID

Tipos de datos

Los **datos** son los resultados observados de una cierta característica en estudio en cada uno de los individuos que forman parte de la muestra. A esa característica la llamamos **VARIABLE**

Estableceremos tres niveles de clasificación:

1)Escala o nivel de medida (Stevens, 1951) :

A)Cualitativas (No métricas o categóricas) : Valores de la variable categorías o etiquetas

a. **Nominales**

b. **Ordinales**

B)Cuantitativas (Métricas o numéricas): Valores de la variable cantidades numéricas

I. **Intervalo**

II. **Razón**

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

Tipos de datos

➢**Escala nominal. Variables categóricas tales que sus valores no admiten ordenación**.

Destino de los últimos 5 viajes

1. España
2. Europa
3. Estados Unidos
4. Asia
5. Otros

Variable **categórica** (varias categorías de respuesta)

¿Viaja habitualmente con un paquete turístico?

0. No
1. Si

Variable **dicotómica** (dos categorías de respuesta)

Los números son sólo identificadores de las distintas categorías de respuesta y no podemos realizar ninguna operación con ellos. La característica objeto de estudio no es susceptible de ser medida: sexo, nacionalidad, estado civil, destino turístico**. (variable cualitativa). Ejemplos: raza, religión, estado civil, sexo**

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

Tipos de datos

- **Escala ordinal. Variables categóricas tales que sus valores si admiten ordenación**

Nivel de satisfacción con un paquete turístico

1. nada satisfecho
2. satisfecho
3. muy satisfecho

En este caso los números asignados a cada categoría se pueden ordenar. Las categorías 1 y 3 no sólo reflejan una diferencia en el nivel de satisfacción sino que además introducen un orden, de manera que los individuos de la categoría 3 están más satisfechos que los de la 1 aunque no podamos saber cuanto más, porque no podemos medir el grado de satisfacción. **(variable cualitativa). Otro ejemplo: nivel socioeconómico**

Tipos de datos

➢**Variables de escala (variables cuantitativas)**

➢La característica objeto de estudio es susceptible de ser medida. Edad, temperatura, ingresos…. También se llaman variables métricas. Pueden a su vez clasificarse en variables de intervalo y variables de razón. Las variables de intervalo son aquéllas que carecen de un 0 absoluto que represente la ausencia total de la característica que estamos estudiando, por ejemplo el coeficiente intelectual o la temperatura. En las variables de razón el 0 representa la ausencia total: ingresos, peso, edad…. En ocasiones se confunde esta idea. No se trata de que la variable tenga o no el valor 0 para clasificarla de una u otra forma, sino del significado que tiene este valor

Tipos de datos

2). **Según la naturaleza de la variable :**

a. **Discretas**
b. **Continuas**

3) Papel que desempeñan en la investigación

a. **Dependientes**
b. **Independientes**

4) Según el momento del tiempo en que se han tomado los datos

A)Transversales : Se toman los datos a una muestra en un momento fijo del tiempo. *Encuestas de opinión, nº de viajes en un año, etc*.

Tipos de datos

B)Longitudinales : Las observaciones se realizan en distintos momentos del tiempo

i. Series temporales: una observación para cada valor del tiempo. *Entrada de turistas en 10 años*
ii. Panel: *Se observa una muestra fija para cada valor del tiempo. Índices de audiencia*

individuo	*periodo*	*ingresos*	*edad*	*sexo*
1	2003	1500	27	1
1	2004	1700	28	1
1	2005	2000	29	1
2	2003	2100	41	2
2	2004	2100	42	2
2	2005	2200	43	2

Fuentes de datos

Externas

1. Organismos oficiales
2. Empresas suministradoras de datos

Internas

1. Datos recogidos por la propia organización
2. Datos procedentes de encuestas realizadas o encargadas por la propia organización

Organismos oficiales de ámbito internacional

•Organización Mundial del Turismo OMT www.world-tourism.org
•Eurostat www.epp.eurostat.ec.europa.eu
Organismos oficiales de ámbito nacional
•Instituto Nacional de Estadística www.ine.es
•Banco de España www.bde.es
•Organismos oficiales de ámbito autonómico

nticmaster



UNIVERSIDAD
COMPLUTENSE
MADRID