2

Organización de datos y medidas de resumen

En este capítulo estudiaremos cómo organizar los datos una vez que los hemos recogido. Una vez organizados los datos, hay que resumir los mismos en una serie de parámetros. Estudiaremos en esta unidad los parámetros de centralización, de dispersión y de posición, así como los conceptos de simetría de una distribución de datos y curtosis.

ORGANIZACIÓN DE DATOS

Cuando sobre una población hemos realizado una encuesta o cualquier registro para conocer los valores que toma una determinada variable, nos encontramos ante una gran cantidad de datos que debemos organizar. La mejor forma de organizar esta información es mediante tablas que llamaremos **tablas de frecuencias.** Aparte de las tablas de frecuencias, veremos después diferentes gráficos que nos permitirán también representar los datos

Al resumir grandes colecciones de datos, es útil distribuirlos en clases o categorías, y determinar el número de individuos que pertenecen a cada clase, este número lo llamaremos *frecuencia de clase*. La disposición tabular de los datos por clases junto con las correspondientes frecuencias de cada clase, se llama TABLA DE FRECUENCIAS o distribución de frecuencias.

TIPOS DE FRECUENCIAS:

Vamos a estudiar las diferentes frecuencias que aparecen en las tablas de frecuencia convencionales

FRECUENCIA ABSOLUTA

La frecuencia absoluta es el número de veces que aparece un determinado valor x_i en un estudio estadístico. Se representa por f_i .

Supongamos una variable estadística X , constituida por N valores, x_1 ,x_2 ,x_3 , , ...,x_n procedentes de la observación de una determinada característica sobre una población o muestra compuesta por N individuos. La **frecuencia absoluta** correspondiente al dato x_i es el número de veces que se repite el valor en la muestra y la representaremos como hemos dicho por f_i . Estas frecuencias se disponen en forma de tabla, con la siguiente estructura:

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

Valores	Frecuencia absoluta
x_1	f_1
x_2	f_2
...	
x_k	f_k
TOTAL	**N=**

Como observamos la suma de todas las frecuencias absolutas ha de coincidir con N, es decir, con el total de los datos que disponemos para realizar el estudio de la característica de estudio.

La **suma de las frecuencias absolutas** es igual al número total de datos, que se representa por **N**.

$f_1 + f_2 + f_3 + ... + f_k = N$

Para indicar de manera resumida estas sumas se utiliza la letra griega **Σ** (sigma mayúscula) que se lee suma o sumatorio

$$\sum_{I=1}^{k} fk = \mathrm{N}$$

k

nticmaster

UNIVERSIDAD COMPLUTENSE MADRID

FRECUENCIA RELATIVA:

La **frecuencia relativa** es el cociente entre la frecuencia absoluta de un determinado valor de la variable y el número total de datos N. Se suele representar por h_i

Es decir $h_i = \frac{f_i}{N}$ **La suma de todas las frecuencias relativas ha de ser igual a 1**

En muchas ocasiones, se suele expresar la frecuencia relativa en términos porcentuales, la llamaremos frecuencia porcentual. La **frecuencia porcentual** se representa por pi .

Por lo tanto, $p_i = h_i * 100$. Esta frecuencia es realmente útil para el cálculo de los percentiles

FRECUENCIA ABSOLUTA ACUMULADA:

La frecuencia absoluta acumulada es la suma de las frecuencias absolutas de todos los valores inferiores o iguales al valor considerado. Se representará por F_i

nticmaster UNIVERSIDAD COMPLUTENSE MADRID

Por lo tanto $F_1 = f_1$, $F_2 = f_1 + f_2$ $F_3 = f_1 + f_2 + f_3$……. y la última de todas las frecuencias absolutas acumuladas coincidirá con el valor de N

De la misma forma, se puede definir la frecuencia relativa acumulada. Se representará con la letra H_i

La suma de todas las frecuencias relativas acumuladas es igual a 1.

Vamos a ver dos ejemplos, uno que refleja una tabla de frecuencias con una variable discreta y otro para una variable continua.

Ejemplo (**caso discreto**):

A 100 alumnos de un colegio se les pregunta la edad, obteniendo los siguientes valores:

12 13 12 12 13 14 13 13 13 12 13 14 13 15 14 13 13 13 14 14
14 15 12 15 14 15 15 16 14 16 12 14 14 14 18 15 16 16 13 15
16 14 15 17 15 16 18 16 16 16 12 14 13 13 16 13 12 13 13 13
14 15 15 13 14 17 17 13 14 14 14 14 17 15 13 14 13 14 15 17
13 14 13 14 14 14 16 17 14 14 15 15 18 13 16 15 13 12 17 17

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

Completamos la tabla de frecuencias del ejemplo anterior correspondiente al recuento de las edades de los 100 alumnos de un centro con los valores de las frecuencias relativas, porcentuales y acumuladas.
Vamos a hacer el recuento de los datos y presentarlos en una tabla de frecuencias:

Valores	**F.Absoluta(f_i)**	**F.Relativa (h_i)**	**Porcentajes (p_i)**	**Frecuencias acumuladas (F_i)**	**Frecuencias acumuladas relativas (H_i)**
12	9	$9/100 = 0{,}09$	9%	9	0,09= 9%
13	25	$25/100 = 0{,}25$	25%	34	0,34=34%
14	27	$27/100 = 0{,}27$	27%	61	0,61=61%
15	16	$16/100 = 0{,}16$	16%	77	0,77=77%
16	12	$12/100 = 0{,}12$	12%	89	0,89=89%
17	8	$8/100 = 0{,}08$	8%	97	0,97=97%
18	3	$3/100 = 0{,}03$	3%	100	1=100%
TOTAL	**N=**100	1	100		

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

B) **VARIABLE CONTINUA (Tambíen se usa caso discreto con muchos valores)**

En el caso que estemos trabajando con una variable continua, los valores de la variable se agrupan en intervalos. De cada uno de estos intervalos tomaremos **la marca de clase** (media aritmética del intervalo) , que será el valor que represente a la clase. El resto de columnas es idéntico al caso discreto.

Ejemplo: salario de 465 trabajadores del sector turístico

$L_{i-1} - L_i$	x_i	n_i	N_i	f_i	F_i	p_i	P_i
Intervalos	Marca de clase	Frecuencia absoluta	Frecuencia absoluta acumulada	Frecuencia relativa	Frecuencia relativa acumulada	Frecuencia porcentual	Frecuencia porcentual acumulada
4000-8000	6000	33	53	0,07	0,07	7,10	7,10
8000-12000	10000	230	263	0,49	0,57	49,46	56,56
12000-16000	14000	107	370	0,23	0,80	23,01	79,57
16000-20000	18000	33	403	0,07	0,87	7,10	86,67
20000-24000	22000	26	429	0,06	0,92	5,59	92,26
24000-28000	26000	22	451	0,05	0,97	4,73	96,99
28000-32000	30000	10	461	0,02	0,99	2,15	99,14
32000-36000	34000	4	465	0,01	1,00	0,86	100,00
Total		**465**		**1**		**100,00**	

Marca de clase:

Intervalos	Valores de la variable	Frecuencia absoluta	Frecuencia absoluta acumulada	Frecuencia relativa	Frecuencia relativa acumulada	Frecuencia porcentual	Frecuencia porcentual acumulada
<= 8000	6000	33	53	0,07	0,07	7,10	7,10
8000-12000	10000	230	263	0,49	0,57	49,46	56,56
12000-16000	14000	107	370	0,23	0,80	23,01	79,57
16000-20000	18000	33	403	0,07	0,87	7,10	86,67
20000-24000	22000	26	429	0,06	0,92	5,59	92,26
24000-28000	26000	22	451	0,05	0,97	4,73	96,99
28000-32000	30000	10	461	0,02	0,99	2,15	99,14
>= 32000	34000	4	465	0,01	1,00	0,86	100,00
Total		465		1		100,00	

Intervalos abiertos

Una de las cuestiones que se plantean es decidir el número de clases k, podemos decidir el número de clases de acuerdo a criterios subjetivos, o recurrir a procedimientos más objetivos para orientar la elección. Los más populares son:

- **Regla de Nordcliffe o de la raíz cuadrada** $k = \sqrt{N}$ siendo N el total de datos
- **Regla de Sturges** $k = 1 + \log_2 N$
- **Regla de Scott** : Se determina primero la amplitud teórica A_s de las clases mediante la fórmula

$$As = 3{,}5 * s * N^{-1/3}$$ s desviación típica de los datos

y a partir de este cálculo se calcula el valor de k como $k = \frac{\max(x_i) - \min(x_i)}{As}$

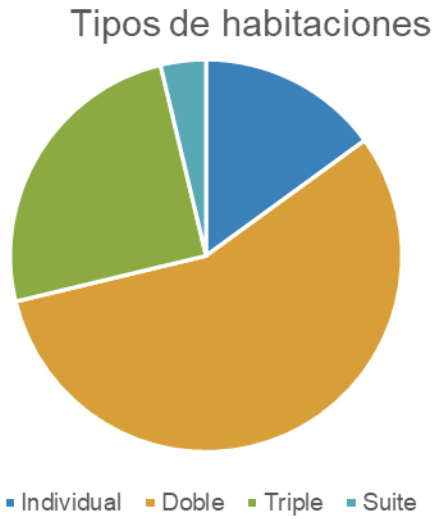
Las dos primeras solo dependen del número total de datos n, sin embargo, la última tiene en cuenta también la dispersión. No hay una regla mejor que otra,
Una vez decidido el número de intervalos k, podemos obtener su amplitud. Lógicamente realizaremos la resta del máximo de la distribución de datos con el mínimo de la distribución y el resultado lo dividiremos entre el número de intervalos k.

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

REPRESENTACIONES GRÁFICAS

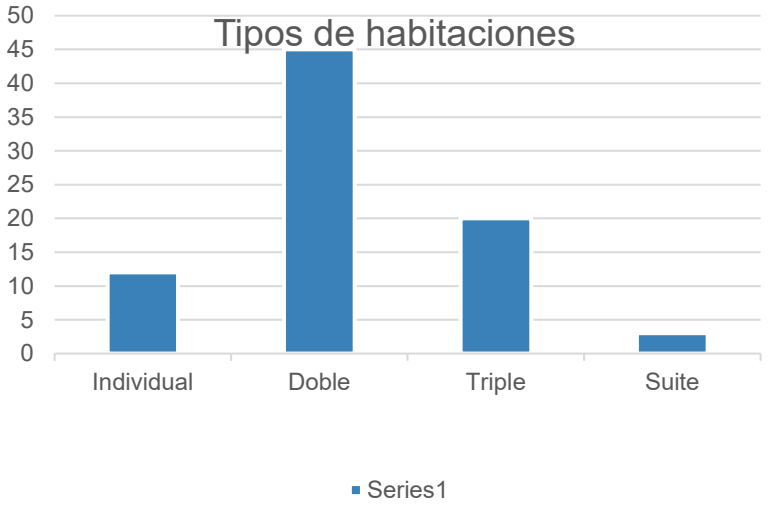
Para representar variables cualitativas o variables cuantitativas con pocos valores distintos se usa el DÍAGRAMA DE SECTORES O CIRCULAR. En el dividimos el área del círculo de forma proporcional a la frecuencia de los datos. El ángulo de cada sector es proporcional a la frecuencia absoluta correspondiente

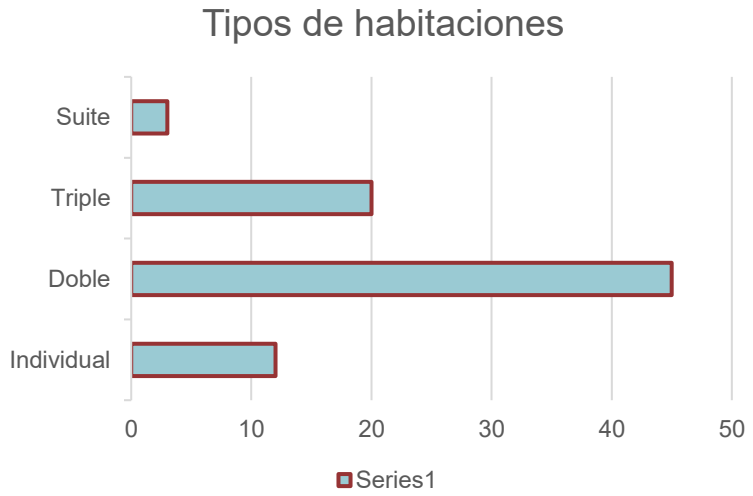
Individual	12
Doble	45
Triple	20
Suite	3



nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

Otra forma de representar las variables cualitativas o también las variables cuantitativas discretas es haciendo uso del DIAGRAMA DE BARRAS (bar plot) . En el eje de abscisas se colocan los diferentes datos de la variable y para cada uno de ellos se levanta una barra (una columna) de altura igual a la frecuencia absoluta del dato.



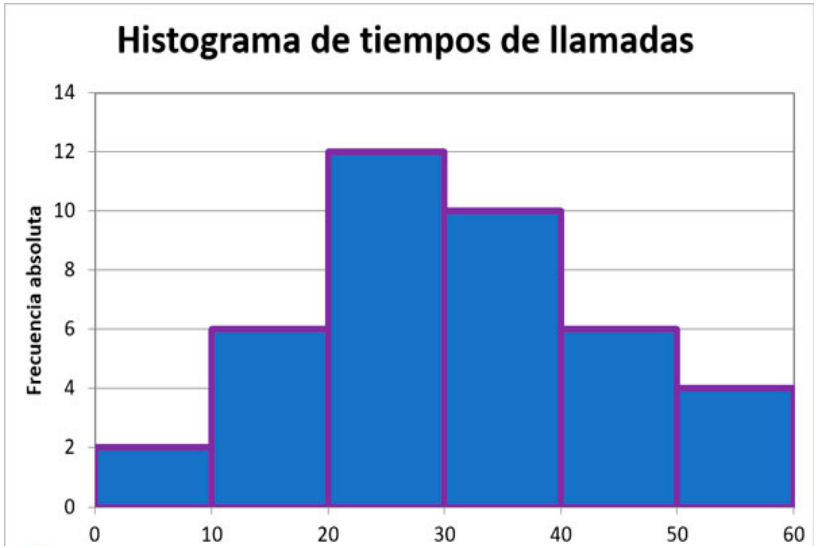


ntic master

UNIVERSIDAD COMPLUTENSE MADRID

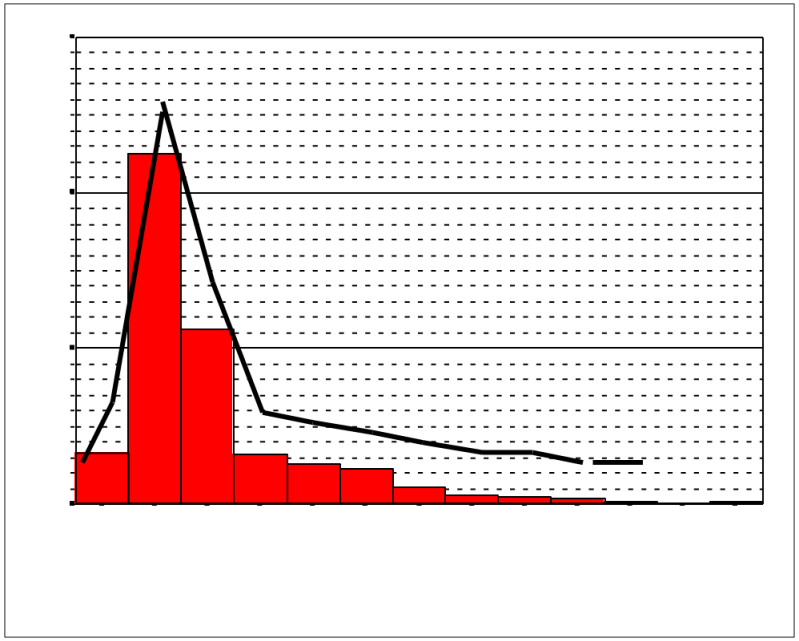
Para representar variables cuantitativas continuas o con variables discretas con una gran cantidad de valores hacemos uso del **HISTOGRAMA**. Es un diagrama en forma de barras, teniendo en cuenta que la superficie de cada barra es proporcional a la frecuencia de los valores representados. En la base se representa el intervalo de la clase (o la marca de clase) y en la altura se representa la frecuencia del intervalo/ amplitud. Si todas las amplitudes de los intervalos coinciden la altura de las barras coincide con la frecuencia.

Tiempo de llamadas	Marcas de clase	Frecuencia absoluta	Frecuencia acumulada	Frecuencia porcentual
[0 - 10)	5	2	2	5%
[10 - 20)	15	6	8	15%
[20 - 30)	25	12	20	30%
[30 - 40)	35	10	30	25%
[40 - 50)	45	6	36	15%
[50 - 60]	55	4	40	10%
Total		**40**		**100%**



nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

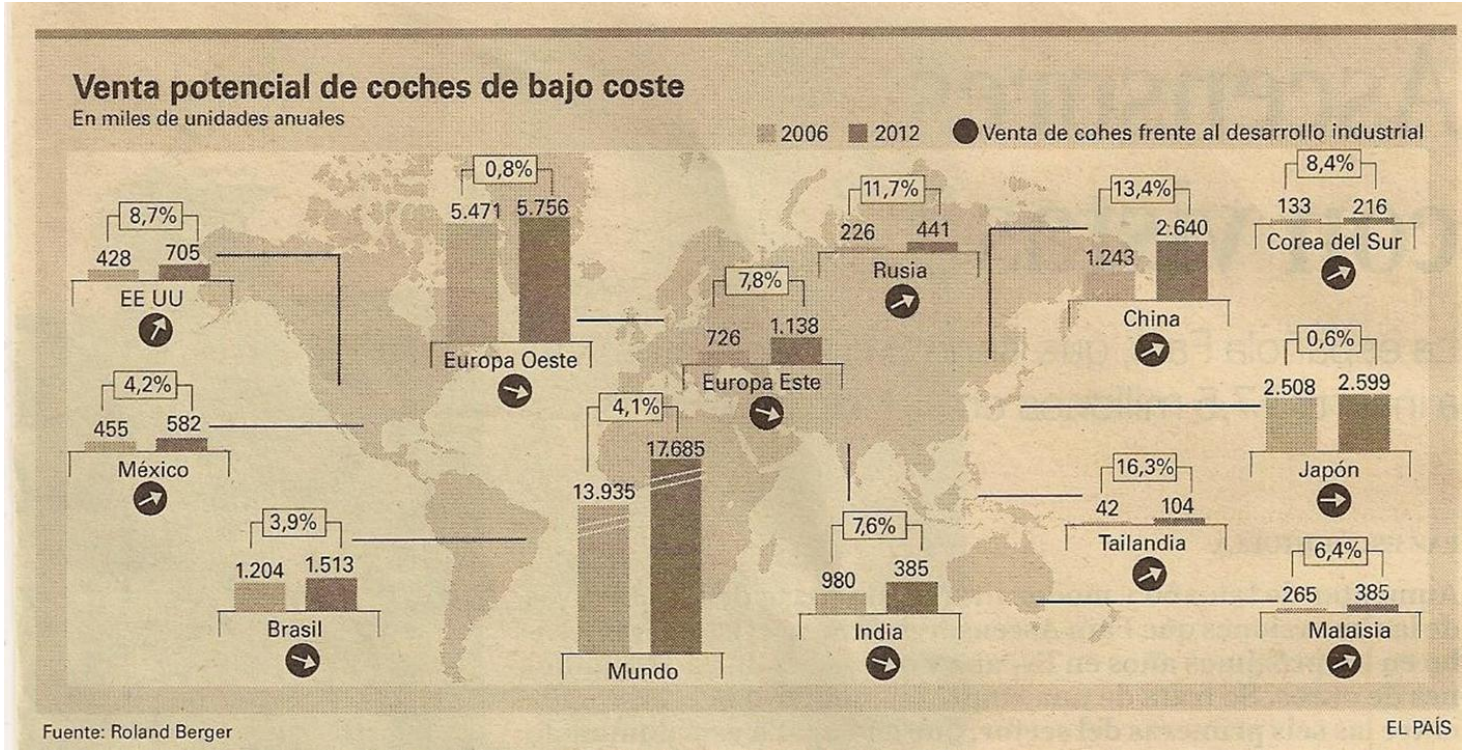
A partir del histograma muchas veces se representa el POLÍGONO DE FRECUENCIAS que consiste en unir los puntos medios de las barras mediante una LINEA POLIGONAL.



nticmaster

UNIVERSIDAD COMPLUTENSE MADRID

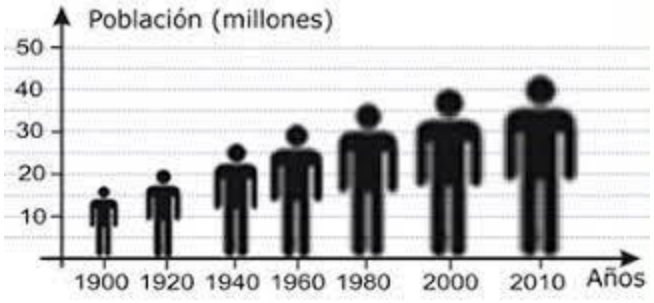
CARTOGRAMA Y PICTOGRAMAS

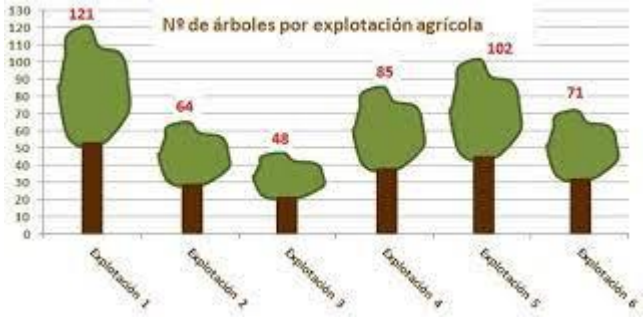


nticmaster

UNIVERSIDAD COMPLUTENSE MADRID

En el caso de los PICTOGRAMA se suele usar para variables cualitativas y en lugar de barras para representar las frecuencias, utilizan dibujos o gráficos alusivos a cada atributo y cuya dimensión es proporcional a la frecuencia absoluta





ntic master

UNIVERSIDAD COMPLUTENSE MADRID







ntic master

UNIVERSIDAD COMPLUTENSE MADRID

Parámetros de centralización

Un promedio es un valor típico o representativo de un conjunto de datos. Como tales valores suelen situarse hacia el centro del conjunto de datos ordenados por magnitud, los promedios se conocen como medidas de tendencia central. Las más conocidas y usadas son **la media aritmética, la mediana , la moda**, y otras medias como la media geométrica y la media armónica. Cada una presenta ventajas y desventajas , según los datos y el objetivo perseguido.

Media aritmética: Es el valor que se obtiene al sumar todos los datos y dividir por el número total de datos. Se representa $\overline{x}$ y su cálculo viene dado por la siguiente expresión :

$$\overline{x} = \frac{\sum_{i=1}^{n} x_i}{N} = \frac{\sum_{I=1}^{n} x_i f_i}{N}$$

Los x_i representan los datos, f_i las frecuencias absolutas y N el total de datos.

ntic master
revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE MADRID

En el caso de los datos agrupados en intervalos , los x_i que consideramos son los puntos medios (centros) de los intervalos. En este caso a las x_i se les llama **marcas de clase**

Veamos un ejemplo:

Alturas	Nº alumnos (fi)
[150,155)	3
[155,160)	7
[160,165)	6
[165,170)	4
[170,175)	5

En esta tabla aparecen las estaturas de 25 estudiantes. Como se ve los datos aparecen agrupados en intervalos. Para calcular el valor representativo de cada intervalo tomamos los puntos medios de cada intervalo y a partir de ahí calculamos la media:

$$\bar{x} = \frac{152{,}5*3+157{,}5*7+162{,}5*6+167{,}5*4+172{,}5*5}{25} = 162{,}7$$

ntic master
revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE MADRID

La media aritmética es una medida de resumen adecuada para variables de escala que presenta como ventajas el tener un significado claro y sencillo (promedio), tiene en cuenta todos los valores de la variable y además es única para cada muestra. Sin embargo presenta como **inconvenientes** que está muy afectada por la presencia de valores atípicos (outliers). Observemos cómo afecta la presencia de un valor atípico al cálculo de la media :

x_i
2
4
6
8
10

En este caso la media es 6,
$\bar{x} = 6$

x_i
2
4
6
8
100

En este caso la media es 24

ntic master
UNIVERSIDAD COMPLUTENSE MADRID

Propiedades de la media aritmética

1. La suma de las desviaciones de todas las puntuaciones de una distribución respecto a la media de la misma igual a cero. Por lo tanto, la media aritmética actúa como centro geométrico o centro de gravedad para el conjunto de daros

Ejemplo : La suma de las desviaciones de los números 8, 3, 5, 12, 10 de su media aritmética 7.6 es igual a 0:

$$(8 - 7.6) + (3 - 7.6) + (5 - 7.6) + (12 - 7.6) + (10 - 7.6) = 0.4 - 4.6 - 2.6 + 4.4 + 2.4 = 0$$

2. La suma de los cuadrados de las desviaciones de los valores de la variable con respecto a un número cualquiera se hace mínima cuando dicho número coincide con la media aritmética.

3. Si a todos los valores de la variable se les suma un mismo número, la media aritmética queda aumentada en dicho número.

ntic master
UNIVERSIDAD COMPLUTENSE MADRID

Propiedades de la media aritmética

4. Si todos los valores de la variable se multiplican por un mismo número la media aritmética queda multiplicada por dicho número

Vamos a ver con ejemplos, las dos últimas propiedades. Consideramos la distribución de datos que habíamos considerado en una anterior diapositiva

x_i
2
4
6
8
10

La media aritmética de esta distribución de datos es 6. Si sumamos 1 a todos los valores tendríamos la serie 3,5,7,9, 11, si calculo la nueva media aritmética sería $\bar{x} = 7$. Por lo tanto habríamos comprobado la propiedad.

Si multiplicamos todos los datos por 2 , la nueva serie sería 4,8,12,16,20 . La media aritmética de esta nueva serie es 12. Por lo tanto habríamos comprobado también esta propiedad.

nticmaster UNIVERSIDAD COMPLUTENSE MADRID

Mediana:

La mediana de un conjunto de números ordenados de menor a mayor es el valor que divide a la muestra en dos partes iguales, es decir es el valor central o la media de los dos valores centrales.

Ejemplos:

- En el conjunto de números 3,4,4,5,6,8,8,8,10 el valor de la mediana sería el 6. Me=6
- En el conjunto de números 5,5,7,9,11,12,15 y 18, observamos que hay dos valores centrales el 9 y el 11. Por lo tanto la mediana sería la media aritmética de ambos (9+11)/2 = 10. Me= 10

nticmaster UNIVERSIDAD COMPLUTENSE MADRID

En la tabla de frecuencias, es muy sencillo obtener la mediana si los datos no están agrupados. Hemos de calcular el cociente N/2 y buscar el dato que contiene ese valor en la columna de las frecuencias absolutas acumuladas.
En el caso de tablas agrupadas en intervalos, para el calculo de la mediana se usa una fórmula más compleja que indicamos aquí:

$$M_e = L_i + \frac{\frac{N}{2} - F_{i-1}}{f_i} \cdot a_i$$

donde:

L_i :es el límite inferior de la clase donde se encuentra la mediana (clase mediana)

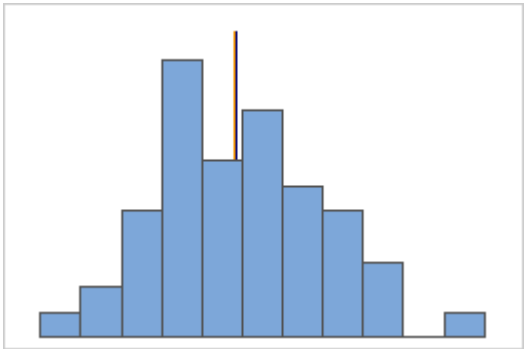
N: total de datos

f_i : es la frecuencia absoluta de la clase mediana

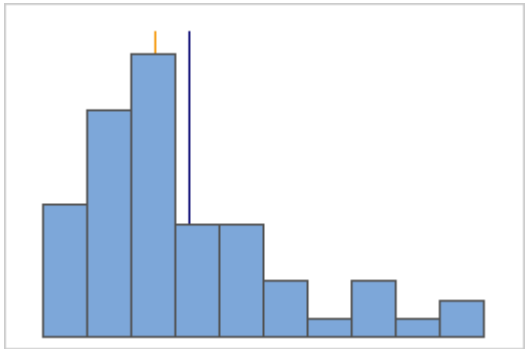
F_i :es la frecuencia acumulada anterior a la clase mediana

a_i: Amplitud intervalo clase mediana

Geométricamente la mediana es el valor de la abscisa que corresponde a la recta vertical que divide un histograma (representación variables agrupadas de escala) en dos partes de igual área.



En este gráfico la media (línea azul) y la mediana (línea naranja) no se distinguen porque están muy próximas. La distribución es simétrica



En este caso la mediana es mucho menor que la media. Distribución asimétrica

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

- La mediana es una medida muy sencilla de calcular, tiene además un significado estadístico claro.

- Presenta como inconveniente que no usa todos los datos de la muestra.

- Es importante comentar que la mediana es la medida de tendencia central adecuada para datos en escala ordinal, para las que no tiene sentido el cálculo de promedios. En este caso será la medida de tendencia central representativa de la muestra

- Además se trata de una medida con mayor estabilidad que la media aritmética ya que no está afectada por la presencia de valores atípicos. Por lo tanto para conjuntos de datos numéricos con valores atípicos o muy asimétricos puede ser más representativa que la media aritmética.

x_i
2
4
6
8
10

En este caso la mediana es 6

x_i
2
4
6
8
100

Al añadir un valor atípico, vemos que la mediana continua siendo 6

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

Moda

- Es el valor de la variable de mayor frecuencia
- Es la medida de tendencia central adecuada para datos en escala nominal y variables cualitativas
- Las ventajas e inconvenientes son los mismos que la mediana. Hay que tener en cuenta que en las distribuciones de datos la moda no tiene porque existir, e incluso no ser única en caso de no existir. Una distribución con moda única recibe el nombre de unimodal.
- Ejemplo 1: En la distribución de datos 2,2,5,7,9,9,9,10,10,11,12 y 18 la moda sería 9
- Ejemplo 2: En la distribución de datos 3,5,8, 10,12,15 y 16 no hay moda ya que todos los datos tienen la misma frecuencia.
- Ejemplo 3: En la distribución de datos 2,3, 4, 4, 4 , 5, 5 , 7, 7, 7 hay dos modas, 4 y 7 . Se llama bimodal

En el caso de datos agrupados, la moda puede deducirse de una distribución de frecuencias o de un histograma a partir de la siguiente fórmula:

$$M_o = L_i + \left(\frac{f_i - f_{i-1}}{(f_i - f_{i-1}) + (f_i - f_{i+1})} \right) \cdot A$$

donde: L_i; Límite inferior de la clase modal (clase donde se encuentra la moda)
f_i: Frecuencia absoluta del intervalo modal
f_{i-1}: Frecuencia absoluta del intervalo anterior al modal
A: amplitud del intervalo modal

Ejemplo:

	Intervalos	Marca de clase x	Frecuencia absoluta f	Frecuencia acumulada F
1	[0 - 4)	2	3	3
2	[4 - 8)	6	5	8
3	**[8 - 12)**	**10**	**6**	**14**
4	[12 - 16)	14	4	18
5	[16 - 20)	18	3	21
	Total		21	

$$M_o = L_i + \frac{f_i - f_{i-1}}{f_i - f_{i-1} + f_i - f_{i+1}} . A_i = 8 + \frac{6-5}{6-5+6-4} . 4$$

$$M_o = 8 + \frac{1}{1+2} . 4 = 8 + \frac{1}{3} . 4$$

$$M_o = 9{,}333$$

ntic master

UNIVERSIDAD COMPLUTENSE MADRID

En conclusión, las medidas de tendencia central, nos permiten identificar los valores más representativos de los datos, de acuerdo a la manera como se tienden a concentrar. La media nos indica el promedio de los datos; es decir, nos informa el valor que obtendría cada uno de los individuos si se distribuyeran los valores en partes iguales. La mediana por el contrario nos informa el valor que separa los datos en dos partes iguales, cada una de las cuales cuenta con el cincuenta por ciento de los datos. Por último la moda nos indica el valor que más se repite dentro de los datos.

Aunque desde un punto de vista puramente descriptivo las tres medidas proporcionan información complementaria, sus propiedades son muy distintas: la media utiliza todos los datos, y es por tanto, preferible si los datos son homogéneos; tiene el inconveniente de que es muy sensible a observaciones atípicas, y un error de datos o un valor anormal puede modificarla totalmente. Por el contrario, la mediana utiliza menos información que la media ya que solo tiene en cuenta el orden de los datos y no de su magnitud, pero en contrapartida , no se ve alterada si una o más observaciones contiene errores grandes de medida. En consecuencia , es siempre recomendable calcular la media y la mediana: ambas medidas diferirán mucho cuando la distribución sea muy asimétrica, lo que sugiere heterogeneidad en los datos.(Peña, 1996)

Otros promedios que son usados en otros contextos son:

1.La media geométrica: Se utiliza para promediar porcentajes, tasas , índices. En general para promediar variables que presenten variaciones acumulativas.

$$G = \sqrt[N]{X1 * X2 * X3 * \cdots \ldots \ldots . . XN}$$

2.Media armónica: Se utiliza para promediar velocidades, tiempos y rendimientos. En general para promediar variables que vienen expresadas en términos relativos como tipos de cambio, rendimientos…. Se representa con la letra H. Es el recíproco de la media aritmética de los recíprocos de esos números , es decir:

$$\frac{1}{H} = \frac{1}{N} * \sum \frac{1}{X}$$

Se cumple siempre que $H \leq G \leq \bar{X}$. La igualdad ocurre sí y solo si todos los números de la muestra son idénticos

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

Ejemplo

Determínese el tipo de cambio medio del euro respecto al dólar para una empresa que durante un año realizó las siguientes operaciones:

Operaciones	A	B	C	D
Tipo de cambio (1 dólar)	0,85	0,81	0,88	0,84
Volumen negociado (millones de euros)	2	1	3	2

$$\text{tipomedio} = \frac{\text{total de €}}{\text{total de \$}} = \frac{2+1+3+2}{\frac{2}{0.85}+\frac{1}{0.81}+\frac{3}{0.88}+\frac{2}{0.84}} = 0.8531 €/\$$$

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

Medidas de dispersión

La dispersión de los datos nos intenta dar una idea de cuán esparcidos se encuentran éstos. Estas medidas nos indican la mayor o menor separación entre los valores que toma la variable. Hay varias medidas de dispersión, siendo las más comunes las que vamos a ver en este apartado, :

1. A)RANGO O RECORRIDO.

Se define el rango de un conjunto de números a la diferencia entre el mayor y el menor valor de todos ellos. Es decir , la diferencia entre el valor máximo y mínimo de la distribución de datos
Es una medida que si bien su cálculo es inmediato, nos proporciona muy poca información, ya que no nos informa cómo se distribuyen los datos entre los extremos. Puede adolecer de graves defectos de representatividad.
Ejemplo : En la distribución 2,4,6,8 y 10 el rango sería 10-2 = 8

B)RANGO INTERCUARTÍLICO: $RIC= Q_3-Q_1$

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

Valores	Frecuencia	Frecuencia acumulada
18	5	5
19	30	35
20	15	50

$$\text{Recorrido} = 20 - 18 = 2$$

$$Q_1 = 19 \quad Q_3 = 20$$

$$RIQ = 1$$

Valores	Frecuencia	Frecuencia acumulada
18	7	7
29	10	17
35	10	27
41	13	40
50	5	45
55	5	50

$$\text{Recorrido} = 55 - 18 = 37$$

$$Q_1 = 29 \quad Q_3 = 41$$

$$RIQ = 12$$

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

2.Varianza

Entendemos por varianza a la media aritmética del cuadrado de las desviaciones de los valores de la variable respecto de la media aritmética. Esta medida de dispersión posee un gran interés y, como veremos, es la más aconsejable cuando se ha empleado como medida de la tendencia central a la media aritmética. Nos permite cuantificar las distancias de los valores de la variable a la media.

$$s_x^2 = \frac{\sum_{i=1}^{i=n} (x_i - \bar{x})^2}{n} = \frac{\sum_{i=1}^{i=n} x_i^2}{n} - \bar{x}^2$$

Tiene un significado estadístico muy claro: **lo que se separan por término medio los valores de la variable de la media**. La media será tanto más representativa del colectivo cuanto más se acerque a cero la varianza. En este caso diremos que la distribución es muy homogénea o poco dispersa.

El problema que presenta la varianza es la unidad de medida.

ntic master
revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE MADRID

La varianza se mide en la unidad que viene expresada la variable elevada al cuadrado. Sin embargo, el problema de la unidad de medida tiene muy fácil solución, ya que se puede resolver sacando la raíz cuadrada de este valor. A la raíz cuadrada de la varianza se le llama **desviación típica.**

$$s_x = \sqrt{s_x^2}$$

Al sacar la raíz cuadrada la medida resultante tendrá las mismas dimensiones que los datos originales**.**

3. Coeficiente de variación

Si tuviéramos dos distribuciones con la misma media pero diferente desviación típica, evidentemente sería mas representativa la media con menor desviación típica. Pero, ¿Qué ocurre si tenemos que comparar dos medias distintas o dos distribuciones de datos expresadas en distintas medidas?

Un problema que plantean las medidas de dispersión vistas es que vienen expresadas en las unidades en que se ha medido la variable. Es decir, son medidas absolutas y con el único dato de su valor no es posible decir si tenemos una dispersión importante o no.

Para solucionar esto, se define una medida de dispersión relativa, independiente de la unidad usada. Esta medida relativa va a permitir además comparar la dispersión entre diferentes muestras (con unidades diferentes). Entre estas medidas hay que destacar el coeficiente de variación de Pearson, definido como el cociente entre la desviación típica y la media aritmética.

$$CV = \frac{S_X}{\bar{X}}$$

- Notemos que se trata de un coeficiente adimensional
- El coeficiente de variación CV representa el número de veces que la desviación típica. A mayor coeficiente de variación menor representatividad de la media. Se suele considerar que la media es representativa si el coeficiente de variación es menor que 0,3
- Se puede expresar este CV en forma de porcentaje
- No tiene sentido si la media fuera 0, el CV tendería a infinito. Su resultado nos podría conducir a conclusiones estadísticas equivocadas.

Pongamos un ejemplo para ilustrar el uso del coeficiente de variación:
Los pesos de los toros de lidia de una ganaderia se distribuyen con una media de 500 Kg y una desviación típica de 40 kg.
Los pesos de los perros de una exposición canina tienen una media de 20 Kg y una desviación típica de 10 Kg





Como se ve la desviación típica de los pesos de la manada de toros es superior a la de los perros. Sin embargo, los 40 kg son poca cosa para el enorme peso tamaño de los toros (es decir, los toros de esa manada son muy parecidos en peso) mientras 10 kg es mucho para el peso de un perro. En casos como este, la desviación típica no es una buena medida para comparar dispersiones. Por ello, usamos el coeficiente de variación

Si calculamos el coeficiente de variación de ambos grupos de animales tenemos:

CV(toros) = 40/500 = 0,08 Es decir la variación sería del 8%

CV(perros)= 10/20 = 0,5 Es decir la variación sería del 50%

De esta forma sí que se aprecia que la variación de los pesos de los perros (50%) es mucho mayor que el peso de los toros (8%)

En suma, cuando se quieren comparar conjuntos de datos con medias aritméticas diferentes o con medidas diferentes necesitamos calcular el coeficiente de variación ya que la desviación Estándar o típica resulta insuficiente para realizar un análisis de los datos dispersos de una muestra o una población con diferentes enfoques de una situación determinada.

El coeficiente de variación es útil en la vida cotidiana, por ejemplo: saber la variación del costo del hospedaje entre dos cadenas de hoteles diferentes en una temporada determinada del año y en diferentes lugares turísticos para decidir cual paquete vacacional contratar.

El coeficiente de Variación es de gran ayuda para la toma de decisiones acerca de sucesos que se quieren comparar y tiene la ventaja de que se puede representar en porcentaje y sin unidades.

VARIABLE TIPIFICADA

Llamamos valor tipificado al resultado de realizar la siguiente transformación sobre los valores originales:

$$z_i = \frac{x_i - \bar{x}}{S_x}$$

Un valor tipificado no es más que el número de unidades de desviación típica que un valor queda por encima o por debajo de la media del grupo.

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

•Son independientes de las unidades originales de medida y facilitan enormemente la comparación de valores entre diferentes muestras ya que reduce todas las muestras a una escala común: el 0 de la escala es la media aritmética . La unidad de medida la desviación típica

•Permiten determinar la puntuación relativa de un valor dentro de la distribución e incluso comparar posiciones relativas entre distintos grupos.

•Se consideran atípicos todos aquellos valores que están a más de tres desviaciones típicas de la media.

Ejemplo:

Una persona ha realizado dos pruebas en una empresa para optar a dos puestos de trabajo diferentes A y B. En la prueba para el puesto A ha obtenido una calificación de 18 puntos sobre 20 y en la prueba para el puesto B 16 puntos sobre 20. La media en la prueba para el puesto A para el conjunto de candidatos que opta al puesto ha sido de 15 puntos con una desviación típica de 7 puntos, mientras que en la prueba para el puesto B la media ha sido también de 15 puntos pero con una desviación típica de 3 puntos. ¿Para cuál de los dos puestos tiene más posibilidades esta persona?

$$\text{Puesto A} \begin{cases} \text{media}=15 \\ \text{desviacion tipica}=7 \end{cases}$$

$$\frac{18-15}{7}=0.42$$

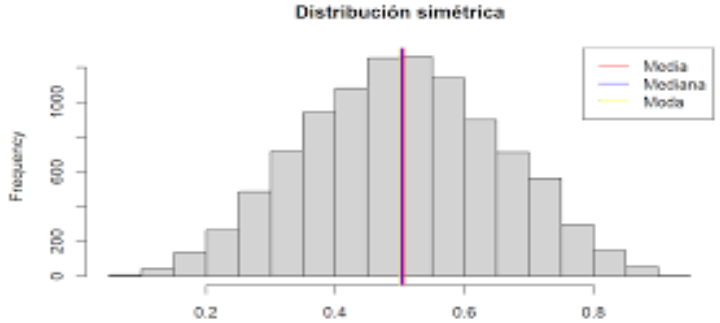
$$\text{Puesto B} \begin{cases} \text{media}=15 \\ \text{desviacion tipica}=3 \end{cases}$$

$$\frac{16-15}{3}=0.33$$

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

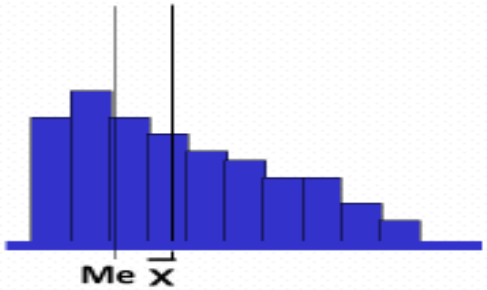
ASIMETRÍA

Supongamos que hemos representado gráficamente una distribución de frecuencias y trazamos una perpendicular al eje de abscisas por la media. Si tomamos esta perpendicular como eje de simetría, diremos que una distribución es simétrica si existe el mismo número de valores a ambos lados de dicho eje, equidistantes de la media dos a dos y tales que cada par de valores equidistantes a la media tengan la misma frecuencia. En caso contrario diremos que la distribución es **asimétrica**.



nticmaster

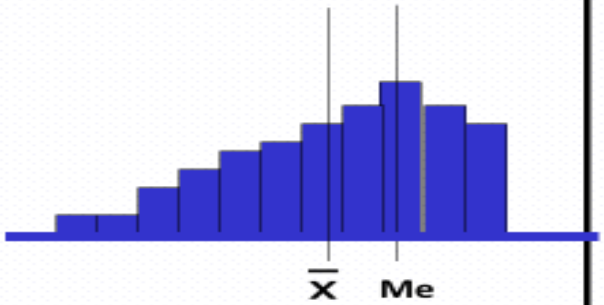
UNIVERSIDAD COMPLUTENSE MADRID



Asimetría positiva

$$\bar{x} > Me$$

Una asimetría positiva grande puede deberse a la presencia de valores atípicos por la derecha que desplazan la media hacia ese lado



Asimetría negativa

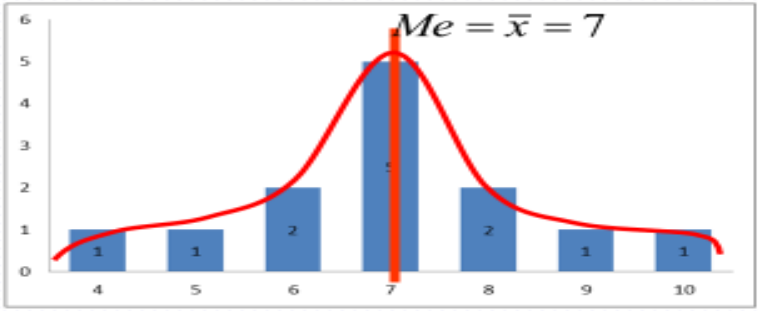
$$\bar{x} < Me$$

Una asimetría negativa grande puede deberse a la presencia de valores atípicos por la izquierda que desplazan la media hacia ese lado

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

Distribución simétrica

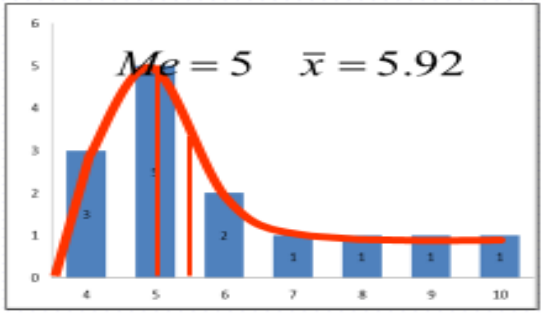
xi	ni
4	1
5	1
6	2
7	5
8	2
9	1
10	1



nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

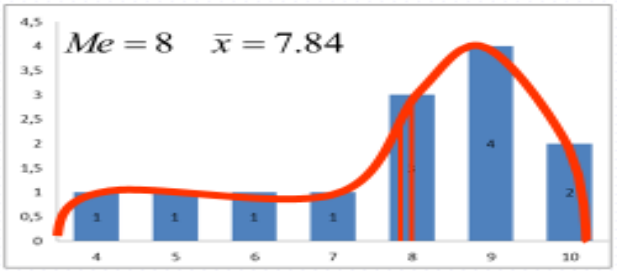
Asimetría positiva

xi	ni
4	3
5	5
6	2
7	1
8	1
9	1
10	1



Asimetría negativa

xi	ni
4	1
5	1
6	1
7	1
8	3
9	4
10	2



nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

Las medidas de asimetría se dirigen a elaborar un indicador que permita establecer el grado de simetría (o asimetría) que presenta la distribución, sin necesidad de llevar a cabo su representación gráfica. Ya hemos visto en las anteriores diapositivas cuando diremos que una distribución es simétrica y cuando una distribución es asimétrica.

EXCEL $$\frac{n}{(n-1)(n-2)}\sum\left(\frac{x_i-\bar{x}}{S_x}\right)^3$$

FISHER $$g_1=\frac{\frac{1}{n}\sum\left(x_i-\bar{x}\right)^3}{S_x^{\,3}}$$

Las medidas de asimetría (skewness measure) nos proporcionan la diferencia en horizontal del tamaño de nuestra distribución con el de la normal

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

- Si el coeficiente es 0, la distribución es simétrica
- Si el coeficiente es mayor que 0, la distribución es asimétrica positiva o asimétrica a la derecha
- Si el coeficiente es menor que 0, la distribución es asimétrica negativa o asimétrica a la izquierda
- Para distribuciones campaniformes, unimodales y moderamente asimétricas Karl Pearson propuso el siguiente coeficiente:

- PEARSON $g_p = \frac{\bar{x} - Mo}{s_x} = \frac{3(\bar{x} - Me)}{s_x}$

En el caso de las distribuciones simétricas media=mediana=moda y el coeficiente de Pearson es 0

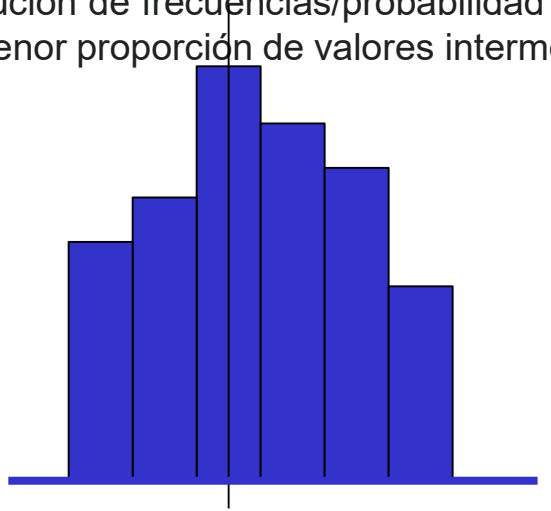
En el caso de las distribuciones asimétricas positivas media > mediana y el coeficiente es positivo

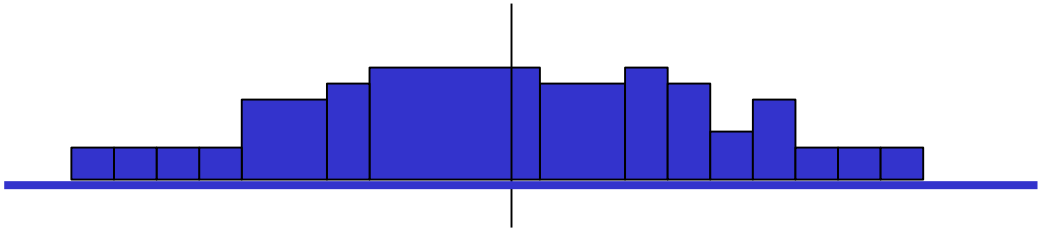
En el caso de las distribuciones asimétricas negativas media < mediana y el coeficiente es negativo

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

CURTOSIS

La **curtosis** de una variable estadística/aleatoria es una característica de forma de su distribución de frecuencias/probabilidad. La curtosis o apuntamiento, desde el punto de vista clásico , es la mayor o menor concentración de frecuencias alrededor de la media aritmética.
Nos permite comparar en vertical nuestra distribución de datos con la distribución normal,
Una curtosis grande implica una mayor concentración de valores de la variable tanto muy cerca de la media de la distribución (pico) como muy lejos de ella (colas), al tiempo que existe una relativamente menor frecuencia de valores intermedios. Esto explica una forma de la distribución de frecuencias/probabilidad con colas más gruesas, con un centro más apuntado y una menor proporción de valores intermedios entre el pico y colas.

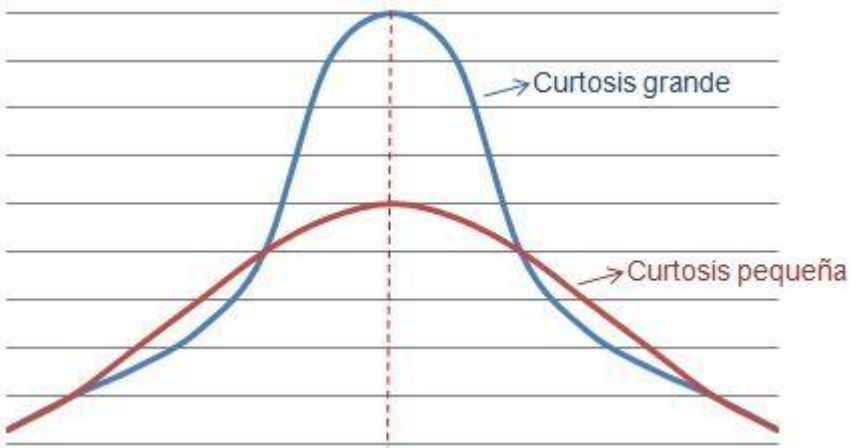




- No se puede medir de forma directa.

Se compara la curtosis de todas muestras con una cantidad fija: la curtosis de la distribución **Normal (Campana de Gauss)**

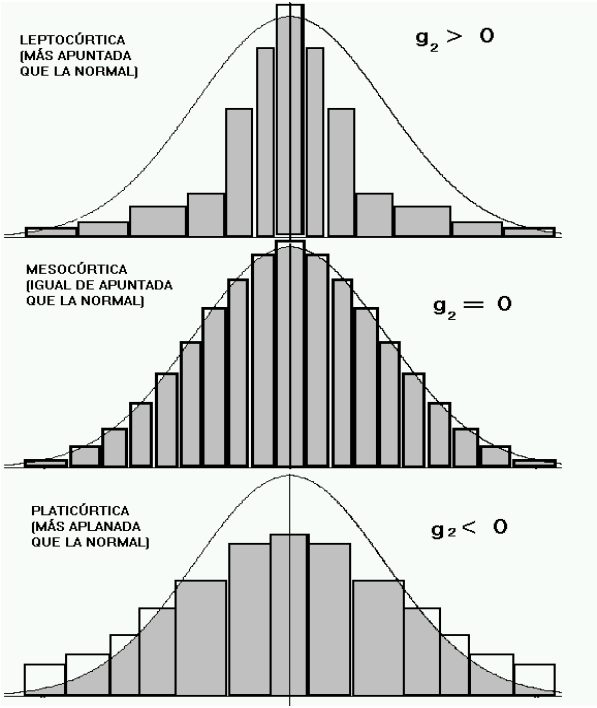
El coeficiente de curtosis de excel es una expresión complicada (ver coeficiente en la ayuda de excel). Lo importante del coeficiente es el signo:



$$g_2 = \frac{\sum_{i=1}^{N}(X_i - \overline{x})^4 \cdot n_i}{N S_x^4}$$

n_i la frecuencia absoluta de x_i

- Si el coeficiente es 0, la distribución es MESOCÚRTICA
- Si el coeficiente es mayor que 0, la distribución es LEPTOCÚRTICA
- Si el coeficiente es menor que 0, la distribución es PLATICÚRTICA



nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

MEDIDAS DE POSICIÓN

- Las medidas de posición son **valores que permiten dividir el conjunto de datos en partes porcentuales iguales y se usan para clasificar una observación dentro de una población o muestra**. Las medidas de posición más usuales son los cuartiles, los deciles y los percentiles.

- Los cuartiles son los valores que dividen a la distribución en cuatro partes iguales. La mediana que estudiamos anteriormente era el segundo cuartil. El resto de cuartiles se calcula de la misma manera sustituyendo n/2 por la frecuencia correspondiente.

	Frecuencia acumulada
Primer cuartil	n/4
Mediana	n/2
Tercer cuartil	3n/4

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

K=10 DECILES

Frecuencia acumulada	
Primer decil	n/10
Segundo decil	2n/10
……..	…….
Noveno decil	9n/10

K=100 PERCENTILES

Percentil 1	n/100
Percentil 2	2n/100
……..	…….
Percentil 99	99n/100

- Percentil de orden k N*K/100

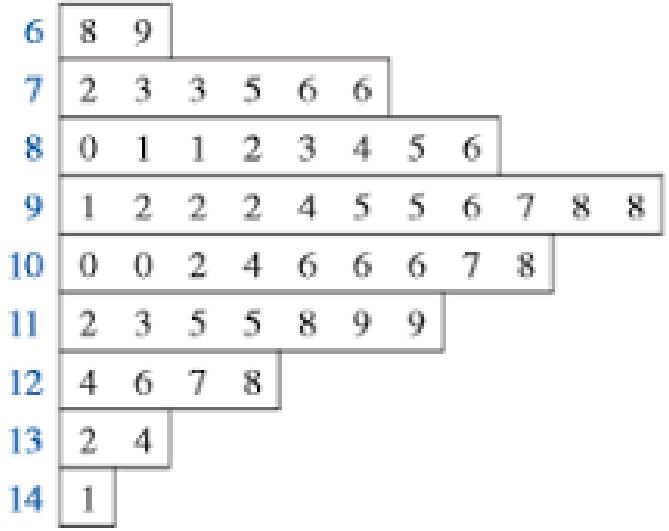
nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

ANÁLISIS EXPLORATORIO DE DATOS

Los estadísticos descriptivos más habitualmente utilizados son la media y la desviación típica. Sin embargo la media y la desviación típica son índices convenientes solo en el caso que la distribución de los datos es aproximadamente normal o, al menos simétrica y unimodal. Esto evidente no será siempre así. Por lo tanto es necesario examinar minuciosamente la estructura de los datos.
Actualmente se utilizan novedosas técnicas del análisis exploratorio de datos, mediante las cuales se pueden analizar los datos de forma exhaustiva y detectar las posibles anomalías que presentan las observaciones. Se recomienda iniciar un análisis con gráficos que permitan visualizar su estructura.

Para variables cuantitativas es aconsejable comenzar con el diagrama de tallo y hojas o histograma digital. El siguiente paso suele ser examinar la posible presencia de valores atípicos (outliers) en el conjunto de datos. Para ello suelen utilizarse los gráficos de caja y bigote. No obstante, los diagramas de caja siempre deben de ir acompañados de los histogramas digitales, ya que los primeros no detectan la presencia de distribuciones multimodales

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID




```
altura Stem-and-Leaf Plot for
GENERO= mujer

 Frequency     Stem &  Leaf

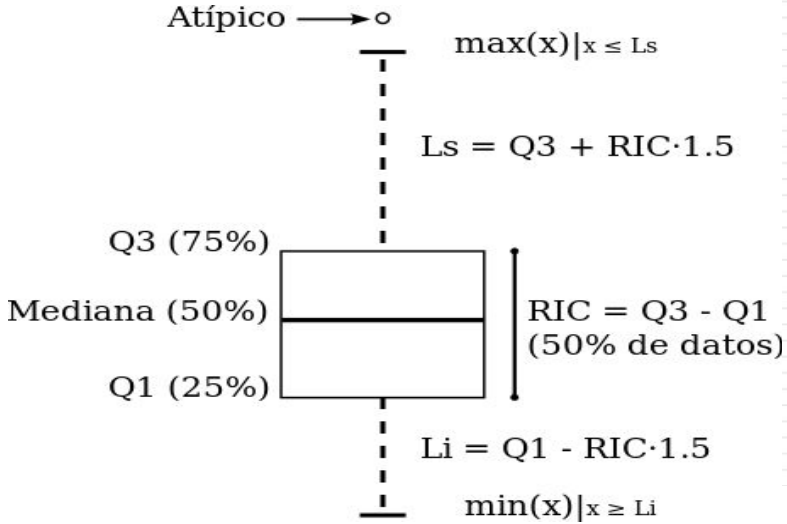
      .00        15 .
     4.00        15 .  5799
    16.00        16 .  0000122233334444
    20.00        16 .  55556667778888888999
    12.00        17 .  000000000134
     6.00        17 .  588889
     2.00 Extremes     (>=182)

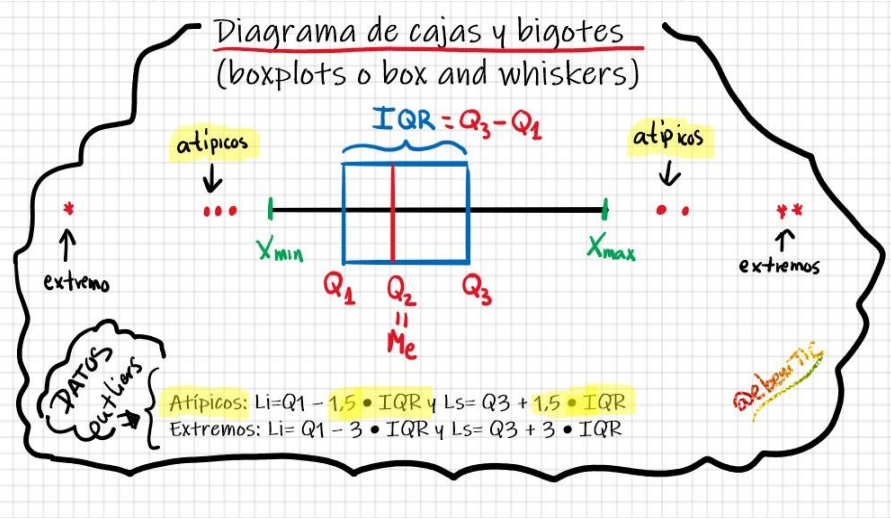
 Stem width:    10
 Each leaf:        1 case(s)
```

ntic master
UNIVERSIDAD COMPLUTENSE MADRID

Valores atípicos o outliers

Un valor atípico es un valor “raro” respecto del conjunto de datos. Para detectar valores atípicos suele recurrirse al **DIAGRAMA DE CAJA**





ntic master

UNIVERSIDAD COMPLUTENSE MADRID

- CAJA
  - Raya central : la mediana
  - Bordes inferior y superior : los cuartiles Q_1 y Q_3 respectivamente

- BIGOTES
  - Limite inferior : Q1- 1,5* (Q3-Q1)
  - Límite superior: Q3+ 1,5 *(Q3-Q1)

  Se consideran valores atípicos leves los que quedan fuera de esos límites. Si en las expresiones anteriores sustituimos 1,5 por 3 , todos los valores que queden fuera de ese rango hablaríamos de valor atípico extremo. Si no hay valores atípicos se hacen coincidir los bigotes con los valores máximo y mínimo de la muestra.

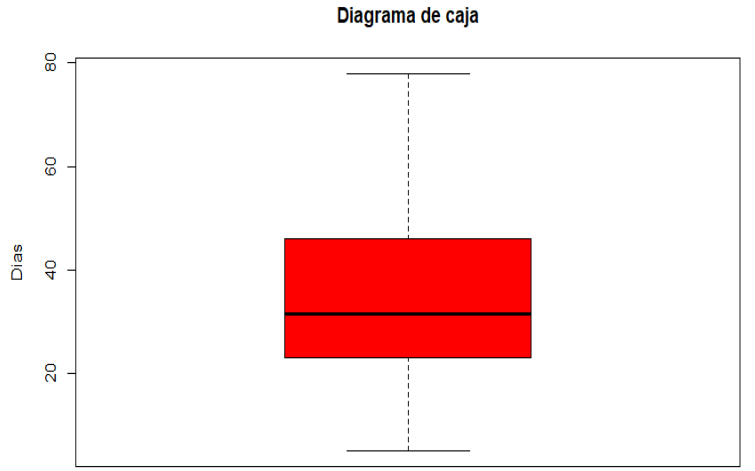
Los **outliers** o valores atípicos son puntos de datos que se alejan significativamente del resto de observaciones en un conjunto de datos, ya sea por ser inusualmente grandes o pequeños en comparación con el resto. Pueden surgir por la propia variabilidad del conjunto de datos o por errores de medición o de entrada.

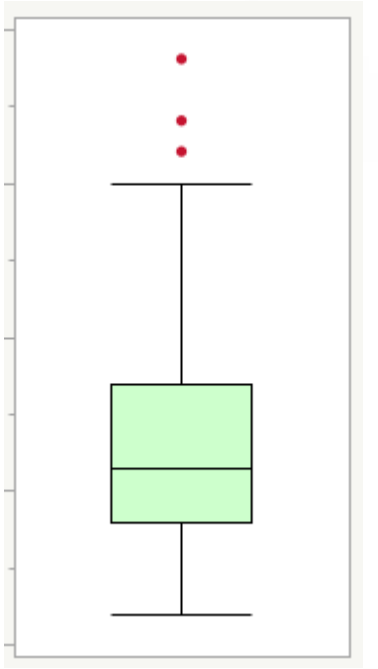
Dependiendo de sus características, los outliers pueden clasificarse en varios tipos, destacando los siguientes:

- **Valores atípicos univariados —** Son puntos de datos inusuales en base a una sola variable.
- **Valores atípicos multivariados —** Se basan en la relación entre al menos dos variables. Son puntos de datos que pueden no ser considerados atípicos cuando se analizan individualmente, pero su combinación o relación con otras variables los hace inusuales.

Nos centraremos en el tratamiento de valores atípicos univariados.
Independientemente de cómo hayan surgido, los outliers pueden tener un gran impacto sobre los resultados de los análisis estadísticos al afectar medidas sensibles a los valores extremos, como la media y la desviación estándar. Además, pueden introducir sesgo en la distribución de los datos, rompiendo las suposiciones de normalidad en las que se basan muchos modelos estadísticos como la regresión lineal o los test de hipótesis,

.


Diagrama de caja
Dias
20
40
60
80



Por otra parte, los outliers tienen una gran relevancia en la detección de anomalías, como la detección de fraudes financieros donde las transacciones fraudulentas tienen comportamientos muy diferentes a los de las transacciones normales

Para el caso de valores atípicos univariados podemos utilizar los enfoques estadísticos y la inspección visual debido a su simplicidad y eficacia. Citamos los siguientes métodos:

1. **Histograma. (Ya tratado anteriormente)**
2. **Diagrama de caja. (Ya tratado anteriormente)**
3. **Z-score**.
4. **Z-score modificada.**
5. **Rango Intercuartílico (IQR**).

Como paso previo a cualquiera de estas técnicas, es recomendable utilizar el método **'describe()' en Python** para obtener una visión general rápida de la distribución y detectar la presencia de outliers en el conjunto de datos. Para ello, buscaremos diferencias notables entre los valores mínimo, medio y máximo de cada variable.

.

La elección del 3 como umbral en la técnica de z-score proviene de la regla empírica, según la cual los datos dentro de 3 veces la desviación estándar respecto a la media representan el 99.7% de los datos de la distribución. Sabiendo esto, podemos concluir con bastante seguridad que los datos que caen más allá de este umbral son atípicos, pues son distintos al 99.7% de los datos .
Cuando los datos son asimétricos o no se distribuyen de forma normal podemos utilizar el z-score modificado, también conocido como MAD-Z-Score. Este, a diferencia del z-score, utiliza la mediana y la desviación absoluta mediana (MAD en inglés) en lugar de la media y la desviación estándar con el fin de evitar el efecto de los outliers sobre estas dos últimas medidas.
Por lo tanto, **el z-score modificado mide cuánto se aleja un valor de la mediana en términos de la desviación absoluta mediana**. Dicho de otra manera, nos indica cuántas desviaciones absolutas medianas, o MADs, se encuentra un punto de datos respecto a la mediana de la distribución.
En este contexto, se suele utilizar un umbral de 3.5 para considerar que un punto de datos es un outlier.

La fórmula para obtener el z-score modificado es:

$$M_i = \frac{0.6745 * (x_i - Mediana)}{MAD}$$

En python.La función ‘median_abs_deviation’ de scipy nos permite calcular la desviación absoluta de la mediana (MAD), la cual podemos insertar luego en la fórmula para obtener la puntuación z modificada de cada dato.

Cómo tratar los outliers

Una vez identificados, debemos decidir qué hacer con ellos. Existen diferentes métodos para gestionarlos. La elección entre uno u otro dependerá del contexto y de los objetivos del análisis. Algunos de estos métodos son:

•**Mantenerlos —** Podemos mantener los outliers si consideramos que pueden ser representativos de un subconjunto de nuestros datos.

•**Eliminarlos** — Si estamos seguros de que los outliers provienen de un error en la entrada de los datos, como un error humano o de medida, y no podemos solucionarlo, podemos eliminarlos del conjunto de datos.

Para ello, podemos filtrar el dataset. Por ejemplo, en el caso del z-score modificado podemos usar las etiquetas para obtener los registros sin outliers.

Imputar — La imputación implica reemplazar los valores atípicos con otros valores como la mediana o la media. Esto se suele hacer cuando queremos conservar la mayor cantidad de datos, pero eliminando el efecto de los outliers.

•**Winzorizar —** La winsorización es una técnica que reemplaza los valores atípicos por el valor más cercano que no se considera un outlier según ciertos criterios.

Por ejemplo, podemos reemplazar los valores atípicos por el valor del percentil 95 o 5 más cercano, reduciendo el efecto de los outliers sin eliminarlos por completo.

Librerias Python para trabajar con probabilidad y estadística

En este caso, los principales módulos que Python nos ofrece para trabajar con estadística son :

- **numpy**: El popular paquete matemático de Python, se utiliza tanto que mucha gente ya lo considera parte integral del lenguaje. Nos proporciona algunas funciones estadísticas que podemos aplicar fácilmente sobre los arrays de Numpy.
- **scipy.stats**: Este submodulo del paquete científico Scipy es el complemento perfecto para Numpy, las funciones estadisticas que no encontremos en uno, las podemos encontrar en el otro.
- **statsmodels**: Esta librería nos brinda un gran número de herramientas para explorar *datos*, estimar modelos estadísticos, realizar pruebas estadísticas y muchas cosas más.
- **matplotlib**: Es la librería más popular en Python para visualizaciones y gráficos. Ella nos va a permitir realizar los gráficos de las distintas distribuciones de datos.
- **seaborn**: Esta librería es un complemento ideal de matplotlib para realizar gráficos estadísticos.
- **pandas**: Esta es la librería más popular para análisis de *datos* y financieros. Posee algunas funciones muy útiles para realizar *estadística descriptiva* sobre nuestros datos y nos facilita sobremanera el trabajar con series de tiempo.

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

Comandos python para trabajar con probabilidad y estadística

Comando	Operación
Mean()	Devuelve la media aritmética
Fmean()	Media ponderada
Median()	mediana
Mode()	Moda única (valor más común) de datos discretos o nominales.
Multimode()	Lista de modas de datos discretos o nominales.
Quantiles()	Cálculo de los cuantiles
Stdev()	Desviación típica de una muestra
Variance ()	Varianza de una muestra
Kurtosis()	Calcula el valor de la curtosis de una serie de datos
Skew()	Calcula el coeficiente de asimetría

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

Notas finales:

La función describe de Pandas regresa estadísticas descriptivas incluyendo: media, mediana, máximo , mín, desviación típica y conteo para una columna en particular de los datos. La función describe solo regresa los valores de estas estadísticas para las columnas numéricas.
El método acepta el parámetro **percentiles** conteniendo una lista (o semejante) de los percentiles a mostrar. También acepta los parámetros **include** y **exclude** para especificar los tipos de las características a incluir o excluir del resultado.

	entradas	salidas	neto
count	12.00000	12.000000	12.000000
mean	19.50000	19.250000	0.250000
std	8.16311	7.641097	5.310795
min	9.00000	6.000000	-8.000000
25%	12.00000	14.750000	-3.750000
50%	17.00000	20.000000	1.500000
75%	28.25000	22.750000	3.000000
max	31.00000	34.000000	9.000000

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

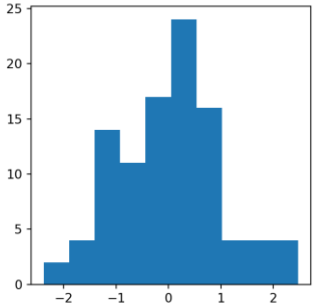
i

Gráficos con Python:

Para trabajar con gráficos en Python usaremos la librería matplotlib y el comando hist (). Como siempre en el paréntesis colocamos la variable del data frame que nos interesa. Vemos como realizar los histogramas y los diagramas de caja

```
import matplotlib.pyplot as plt

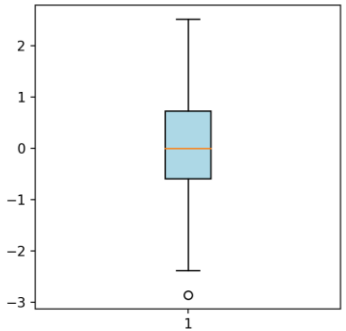
plt.hist()
```




```
import matplotlib. pyplot as plt

plt.boxplot()

plt.show()
```



nticmaster

UNIVERSIDAD COMPLUTENSE MADRID

nticmaster



UNIVERSIDAD
COMPLUTENSE
MADRID