nticmaster

UNIVERSIDAD COMPLUTENSE MADRID

“Solíamos pensar que si sabíamos lo que significaba uno, sabríamos lo que es dos, porque uno y uno son dos. Ahora descubrimos que primero debemos aprender mucho más sobre lo que significa y.”

Sir Arthur Eddington (1882-1944)

Francisco José Lluna Taverner

3 Variables bidimensionales

En el análisis estadístico es conveniente a veces contrastar los datos procedentes de dos caracteres estudiados sobre un mismo individuo. En este sentido se plantea la consideración de **variables estadísticas bidimensionales.**

Una variable estadística bidimensional es el conjunto (X,Y) de valores que pueden tomar dos caracteres diferentes X e Y medidos sobre cada uno de los individuos de una población o muestra. Los caracteres X e Y se denominan caracteres o variables marginales y pueden ser ambos cuantitativos, ambos cualitativos o uno de cada tipo; a su vez, los caracteres cuantitativos puede ser variables estadísticas tanto discretas como continuas.

Por lo tanto, llamamos **variable bidimensional** a aquélla que describe la población según dos características X e Y simultáneamente.

Ejemplos:

1) Volumen de facturación (X) y gasto en publicidad (Y) de una empresa. (en este caso las dos variables son cuantitativas continuas)
2) Sexo (X) y color de pelo (Y), en este caso las dos variables serían cualitativas.
3) Temperatura del cuerpo (X) y número de pulsaciones (Y), en este caso las dos variables serían cuantitativas discretas
4) Profesión (X) y antigüedad en la empresa (Y), en este caso X sería cualitativa y la variable Y sería cuantitativa

El objetivo final será estudiar la posible relación entre las variables. En el caso planteado en el ejemplo 1, el estudio simultáneo de ambas variables nos permitirá determinar si existe relación entre ellas. En el caso que sí que exista relación, nos plantearemos qué grado de relación tienen (correlación) y ¿Cómo podemos expresar la relación entre las variables? (regresión)

Centraremos nuestra atención en el estudio de variables bidimensionales cuyos caracteres marginales X e Y son ambos **cuantitativos**. Cada uno de los valores correspondientes a la variable bidimensional (X,Y) se representa mediante un par ordenado (xi , yj), donde x_i es el valor que mide el primer carácter e y_j es el valor que mide el segundo carácter. En consecuencia, las variables marginales X e Y toman los valores $\{x_1, x_2,..., x_r\}$, $\{y_1, y_2,..., y_s\}$ para ciertos r, s, respectivamente, y la variable bidimensional (X,Y) tomará los valores $\{(x_i , y_j)\}1 \leq i \leq r, 1 \leq j \leq s$

El número de elementos que tienen el valor x_i para el primer carácter y el valor y_j para el segundo se denomina frecuencia absoluta del par (xi , yj), y se denota $n_{i\,j}$; es decir, $n_{i\,j}$ es el número de veces que aparece repetido el par (x_i , y_j) en las observaciones. La frecuencia relativa del par (x_i , y_j) es $f_{ij} = n_{ij} /N$, donde N es el total de pares observados.

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

X Y	y_1	$\cdots$	y_j	$\cdots$	y_s	
x_1	n_{11}	$\cdots$	n_{1j}	$\cdots$	n_{1s}	$n_{1.}$
$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
x_i	n_{i1}	$\cdots$	n_{ij}	$\cdots$	n_{is}	$n_{i.}$
$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
x_r	n_{r1}	$\cdots$	n_{rj}	$\cdots$	n_{rs}	$n_{r.}$
	$n_{.1}$	$\cdots$	$n_{.j}$		$n_{.s}$	n

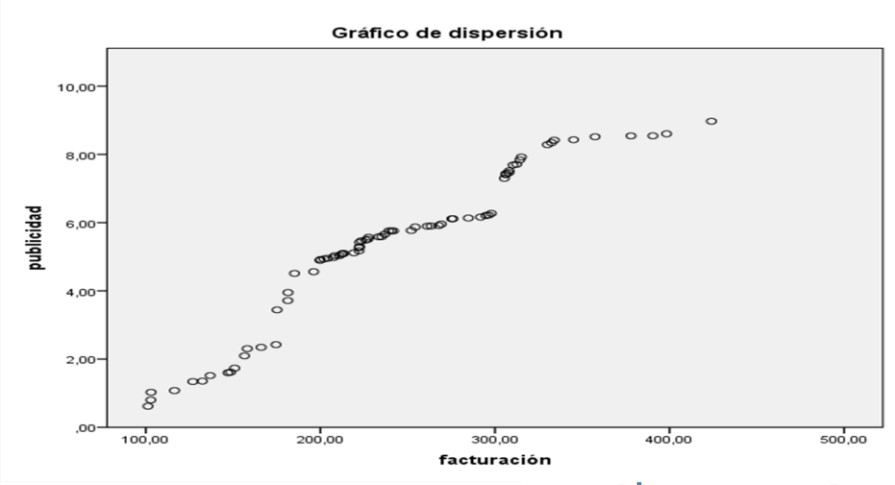
facturación (agrupado)*publicidad (agrupado) tabulación cruzada

Recuento

		publicidad (agrupado)					Total
		<= 2	2 - 4	4 - 6	6 - 8	>8	
facturación (agrupado)	< 200	10	7	3	0	0	20
	200 - 300,00	0	0	30	7	0	37
	300 - 400,00	0	0	0	9	8	17
	>400	0	0	0	0	1	1
Total		10	7	33	16	9	75

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

En el caso de las variables cuantitativas, la representación numérica es la que aparece en la diapositiva anterior y la forma gráfica de representar las variables bidimensionales cuantitativas es mediante una nube de puntos o diagrama de dispersión, en el cual se representa cada par de valores como un punto en un diagrama cartesiano. Veamos como quedaría este diagrama con el ejemplo que hemos considerado.

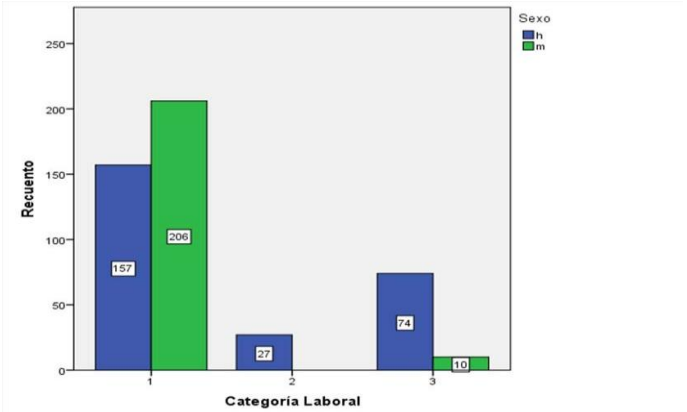


nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

En el caso de variables cualitativas, la tabla de doble entrada se denomina tabla de contingencia y la representación gráfica adecuada es un diagrama de barras.

Recuento

		Sexo		Total
		h	m	
Categoria laboral	1	157	206	363
	2	27	0	27
	3	74	10	84
Total		258	216	474



Medidas de resumen (Descriptivos)

Para cada una de las variables marginales de la variable bidimensional (X, Y) pueden obtenerse su correspondiente media, varianza o desviación típica.

Medias marginales

$$\overline{X} = \frac{\sum x_i \bullet f_i}{n}$$

$$\overline{Y} = \frac{\sum y_j \bullet f_j}{n}$$

Varianzas marginales

$$Var(X) = \frac{\sum x_i^2 \bullet f_i}{n} - \overline{X}^2$$

$$Var(Y) = \frac{\sum y_j^2 \bullet f_j}{n} - \overline{Y}^2$$

Veamos un ejemplo: Se hizo una prueba a diez estudiantes para ver la relación que había entre la expresión oral (X) y la destreza manual (Y) obteniéndose la siguiente tabla:

X	8	7	6	5	4	3	7	6	9	5
Y	5	5	6	7	8	7	4	5	3	5

Mostramos los resultados obtenidos usando SPSS:

Estadísticos descriptivos

	N	Mínimo	Máximo	Media	Desviación estándar
X	10	3,00	9,00	6,0000	1,82574
Y	10	3,00	8,00	5,5000	1,50923
N válido (por lista)	10				

Estudio de la relación entre las variables

El objetivo último del análisis conjunto de varias variables es abordar el estudio de la posible relación entre ellas .Dos variables son estadísticamente dependientes cuando el comportamiento de una de ellas influye en el comportamiento de la otra. Tenemos que aclarar dos aspectos:

- La dependencia estadística no es una dependencia funcional
- La influencia de la variable independiente en la dependiente **NO determina exactamente** sus valores, **sólo los limita**

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

En el caso en que exista relación entre las variables nos interesará:

•**Reconocer** la **presencia** de **relación** entre las variables

- Método gráfico
- Mediante valores numéricos :Covarianza y coeficiente de correlación

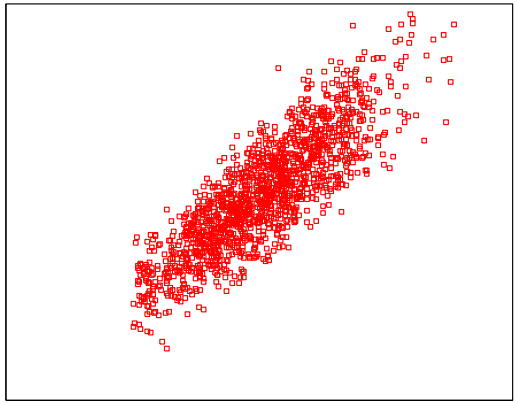
•Puesto que la relación admite grados, será necesario valorar su **intensidad** → **Estudio de la correlación**

•Cálculo del módelo de dependencia → Modelo de regresión

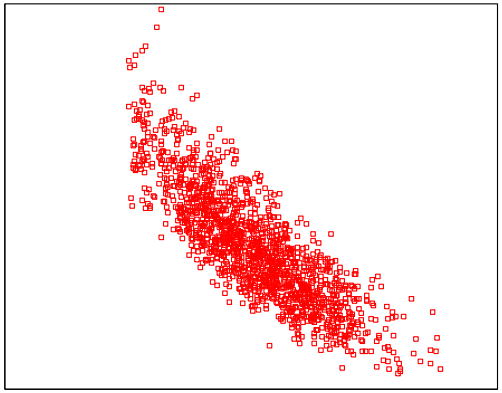
nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

RECONOCER LA PRESENCIA DE RELACIÓN ENTRE DOS VARIABLES

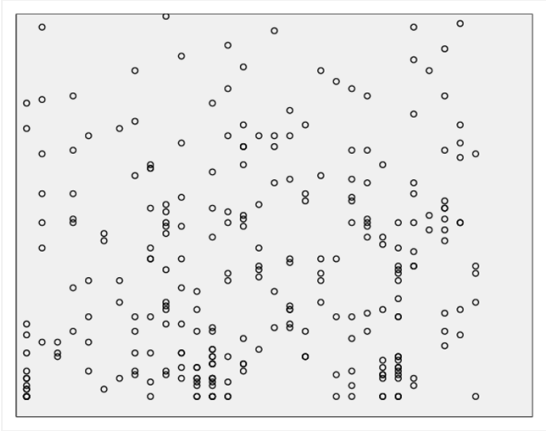
I. Método Gráfico



Relación directa o positiva



Relación inversa o negativa



Ausencia de relación.
Variables independientes

nticmaster

UNIVERSIDAD COMPLUTENSE MADRID

II. La covarianza y el coeficiente de correlación lineal

La covarianza es una medida de **asociación lineal** entre dos variables. Se llama covarianza de una variable bidimensional (X,Y) a la media aritmética de los productos de las desviaciones de cada una de las variables respecto a sus medias respectivas. La expresión de la covarianza viene dada por:

$$s_{xy} = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{n-1}$$

$$s_{xy} = \frac{\sum x_i y_i}{n-1} - \bar{x} \cdot \bar{y}$$

nticmaster

UNIVERSIDAD COMPLUTENSE MADRID

Cálculo de la covarianza $s_{XY} = \frac{1}{n-1}\sum_i (x_i - \bar{x})(y_i - \bar{y})$

	x_1	x_2	$(X_1 - \bar{X}_1)(X_2 - \bar{X}_2)$	$(X_1 - \bar{X}_1)^2$	$(X_2 - \bar{X}_2)^2$
	3	5	(3-5)(5-7.3)=4.6	$(3-5)^2$= 4	$(5-7.3)^2$= 5.29
	4	7	(4-5)(7-7.3)= 0.3	$(4-5)^2$= 1	$(7-7.3)^2$= 0.09
	8	10	(8-5)(10-7.3)=8.1	$(8-5)^2$= 9	$(10-7.3)^2$= 7.29
Suma	15	22	Suma de productos cruzados 13	Suma de cuadrados 14	Suma de cuadrados 12.67
Medias	**5**	**7.3**	$S_{x_1x_2} = \frac{13}{2} = 6.5$	$S^2_{x_1} = \frac{14}{2} = 7$	$S^2_{x_2} = \frac{12.67}{2} = 6.3$
			Covarianza	**Varianza X1**	**Varianza X2**

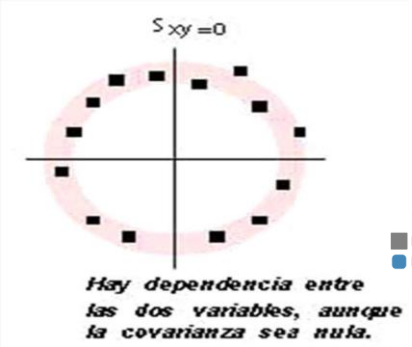
nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

PROPIEDADES DE LA COVARIANZA

•Cuanto mayor es la covarianza mayor es la relación lineal entre las variables

•Si dos variables estadísticamente dependientes crecen o decrecen en el mismo sentido la covarianza es positiva

•Si dos variables estadísticamente dependientes crecen o decrecen en sentidos contrarios la covarianza es negativa.
•La covarianza de variables independientes es cero. El recíproco no es necesariamente cierto



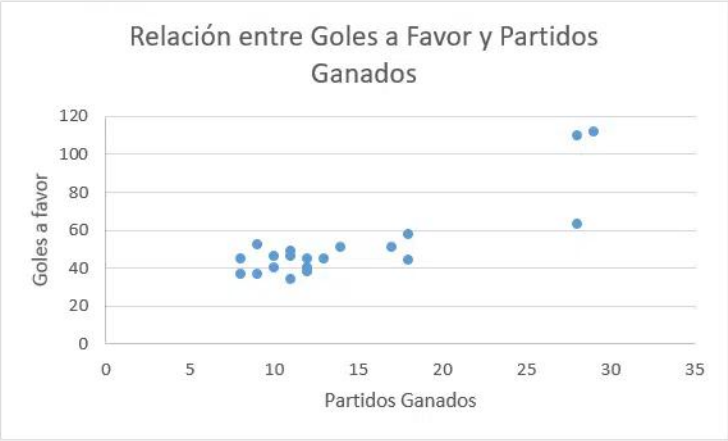
ntic master

UNIVERSIDAD COMPLUTENSE MADRID

Ejemplo: Supongamos que trabajamos con las siguientes variables.
Número de Goles a Favor marcados en toda la temporada 2021 (Y)
Número de Partidos Ganados en toda la temporada 2021 (X)
Suponemos que calculamos la covarianza: **La covarianza es 114.34**. Este valor indica que **las dos variables tienen una relación directa**. Cuando una crece la otra también.

Matriz de covarianza

	X-Partidos Ganados	Y-Goles a favor
X-Partidos Ganados	42,44	114,34
Y-Goles a favor	114,34	433,6275



Vemos, en efecto, en el diagrama de dispersión que la relación entre las variables es directa,covarianza positiva. La covarianza suele aparecer representada dentro de una matriz, la matriz de varianzas y covarianzas, matriz simétrica en la cual la diagonal corresponde a la varianza de las variables y en la diagonal secundaria aparecen los valores de la covarianza

ntic master
UNIVERSIDAD COMPLUTENSE MADRID

Limitaciones de la covarianza

•Unidad de medida. Si en el ejemplo de la tabla (diapositiva 13) multiplicamos los valores por 1000, la covarianza sería 6.500.000 sin que tenga sentido suponer que la relación entre las variables es mayor. Por lo tanto, si cambiamos la unidad de variables, la covarianza tendrá un nuevo valor, sin embargo, el signo seguirá siendo el mismo. Por lo tanto, el valor numérico de la covarianza no tiene ningún significado; sin embargo, si es positivo, ambas variables varían en la misma dirección; de lo contrario, si es negativo, varían en la dirección opuesta.

Por lo tanto la pregunta es, ¿Qué valores nos llevan a considerar la covarianza grande o pequeña?

Solución:

Coeficiente de correlación lineal (sin dimensión. No está afectado por las unidades de medida)

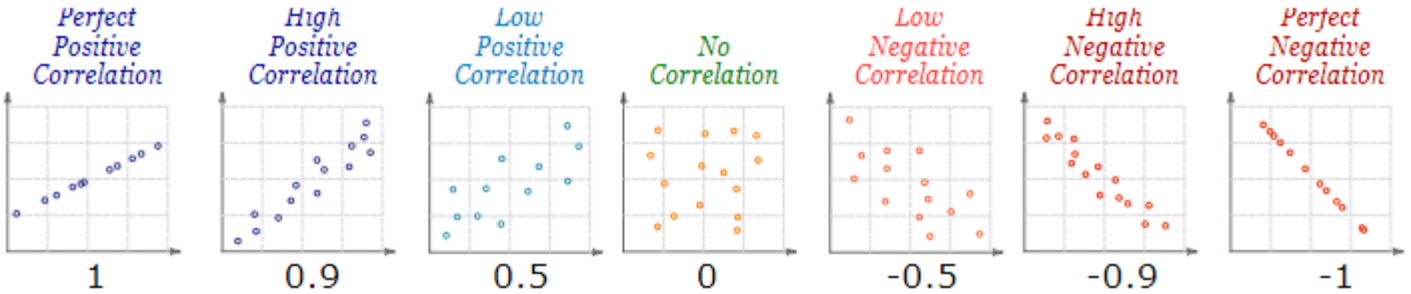
$$r = \frac{S_{XY}}{S_X S_Y}$$

Dividimos la covarianza entre las desviaciones típicas de cada variable. Este coeficiente varía entre -1 y 1 y nos permitirá valorar la intensidad de la relación lineal entre dos variables. Cuanto más próximo a 1 o -1 mayor relación. Valores próximos a 0 , nos indicarán ausencia de relación

En esta tabla vemos como interpretar el coeficiente de correlación, únicamente aparecen valores entre 0 y 1. La interpretación en valores entre -1 y 0 es análoga.

Coeficiente	Interpretación
0	Relación nula
0 – 0,2	Relación muy baja
0,2 – 0,4	Relación baja
0,4 – 0,6	Relación moderada
0,6 – 0,8	Relación alta
0,8 - 1	Relación muy alta
1	Relación perfecta





nticmaster

UNIVERSIDAD COMPLUTENSE MADRID

Características del coeficiente de correlación

•Toma valores entre [-1, +1], siendo +1 una correlación lineal positiva perfecta y -1 una correlación lineal negativa perfecta.
•Es una medida independiente de las escalas en las que se midan las variables.
•No varía si se aplican transformaciones a las variables.
•No tiene en consideración que las variables sean dependientes o independientes.
•Es sensible a *outliers*, por lo que se recomienda en caso de poder justificarlos, excluirlos del análisis.
•Si dos variables son independientes, el coeficiente de correlación entre ambas es 0 (están incorreladas, r=0), pero el recíproco no es cierto necesariamente , es decir un coeficiente de correlación próximo a 0 o nulo no implica necesariamente independencia (las variables podrían estar relacionadas de forma distinta, con otro tipo de relación)

•La existencia de un coeficiente de correlación alto entre dos variables no permite concluir que hay relación de causalidad entre ellas. En ocasiones la presencia de alta correlación entre 2 variables puede deberse a la presencia de una 3ª variable (relaciones espurias)
•http://matematicas.unex.es/wp-content/uploads/2017/09/CDE17A04_ojito_con_la_estadistica.pdf
•https://www.youtube.com/watch?v=Piz8ECyFFPk

En SPSS la matriz de varianzas/covarianzas y la matriz de correlación se muestran como sigue (mostramos salida en este paquete estadístico):

Correlaciones

		facturación	publicidad
facturación	Correlación de Pearson	1	,961**
	Sig. (bilateral)		,000
	Suma de cuadrados y productos vectoriales	399290,358	11509,998
	Covarianza	5395,816	155,541
	N	75	75
publicidad	Correlación de Pearson	,961**	1
	Sig. (bilateral)	,000	
	Suma de cuadrados y productos vectoriales	11509,998	359,554
	Covarianza	155,541	4,859
	N	75	75

**. La correlación es significativa en el nivel 0,01 (2 colas).

nticmaster UNIVERSIDAD COMPLUTENSE MADRID

REGRESIÓN

La teoría de la regresión tiene por objeto obtener la ecuación matemática , **modelo**, que mejor recoge la relación de dependencia estadística entre una variable dependiente (variable respuesta) y una o varias variables independientes (explicativas). Se tratará de :

- Medir el efecto que una o varias variables independientes tienen sobre la variable dependiente
- Hacer predicciones para la variable dependiente

Tanto la variable dependiente como la independiente han de ser variables métricas (nivel de medida:escala)

Regresión lineal simple Una variable independiente (el modelo es una recta)

$$y = \beta_1 x + \beta_0 + \mu$$

Regresión lineal múltiple Varias variables independientes (el modelo es un hiperplano)

$$y = \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \cdots \ldots \ldots + \beta_k x_k + \beta_0 + \mu$$

ntic master
UNIVERSIDAD COMPLUTENSE MADRID

En las anteriores expresiones $\beta_0, \beta_1, \beta_2, \ldots \ldots, \beta_k$ son los coeficientes del modelo.

μ: perturbación aleatoria. Este término se introduce porque el modelo en general no es determinista, es decir, la relación formulada para las variables no es exacta. Dicho término recoge aquellas variables explicativas que de manera individual se consideran irrelevantes, pero que en conjunto afectan a la variable dependiente, y en general todo lo que no explica el modelo

Objetivo: estimar los coeficientes del modelo a partir de una muestra de tamaño "n" de las variables de interés

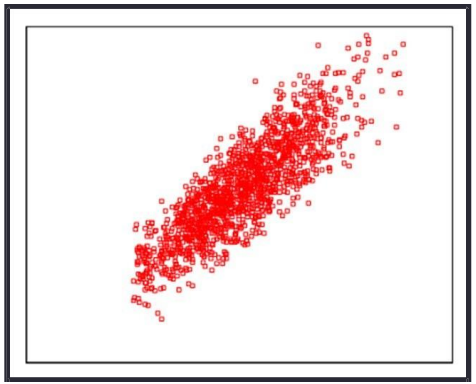
Nos centraremos únicamente en el modelo de regresión lineal simple , es decir tendremos dos variables, una variable dependiente o respuesta (Y) y una variable independiente o explicativa (X)

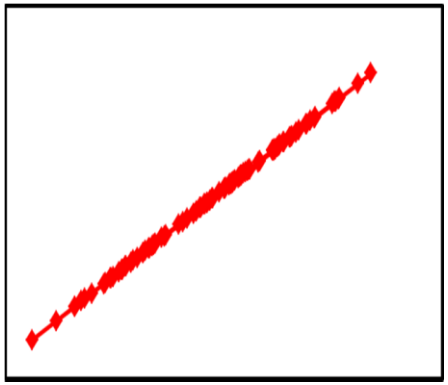
Consideraciones previas

La determinación de un **modelo de regresión lineal** tiene sentido sólo si hay **relación lineal (correlación)** entre las variables

Para detectar "**PATRONES LINEALES**" podemos:

1. **Examen visual de los diagramas de dispersión**

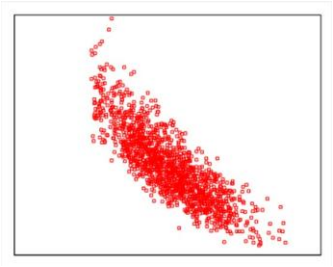




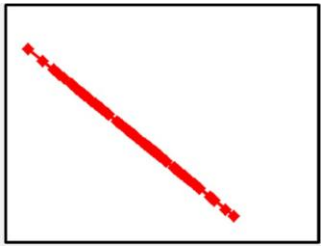
En la segunda nube, la correlación es perfecta. Cuanto más se concentre la nube de puntos entorno a una recta, más alto es el valor absoluto del coeficiente de correlación: más fuerte es la relación entre las variables

Correlación positiva r=0.8

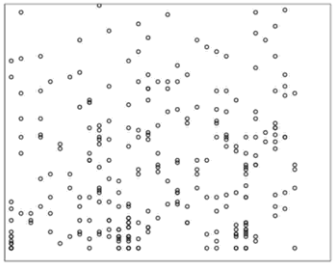
nticmaster UNIVERSIDAD COMPLUTENSE MADRID



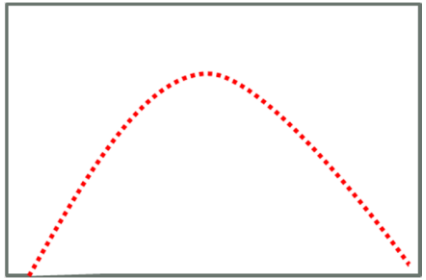
Correlación negativa r=-0.8



Correlación negativa perfecta r=-1



Ausencia de relación lineal r=0



Relación no lineal r=-0.05

En estos dos últimos casos, no tendría sentido buscar un modelo lineal .

nticmaster

UNIVERSIDAD COMPLUTENSE MADRID

2. Cálculo del coeficiente de correlación lineal "r" para los datos de la muestra.

El coeficiente de correlación lineal r , está siempre comprendido entre -1 y 1

$$-1 \leq r \leq 1$$

Cuanto más próximo sea este coeficiente de -1 o de 1 , será más factible emplear un modelo de regresión lineal simple. Sin embargo, aunque este coeficiente r dé distinto de 0 (ausencia de relación) para nuestra muestra, es necesario hacer un contraste de hipótesis para verificar que efectivamente podemos rechazar que el valor poblacional (ρ) es cero. Aunque trabajaremos con los contrastes de hipótesis cuando expliquemos la parte de la inferencia, lo mostramos aquí para completar de forma precisa este apartado.

3. Contraste de hipótesis sobre el parámetro ρ (correlación poblacional)

Podemos utilizar el valor de r para contrastar la hipótesis:

$H_0: \ \rho = 0$
$H_1: \rho \neq 0$

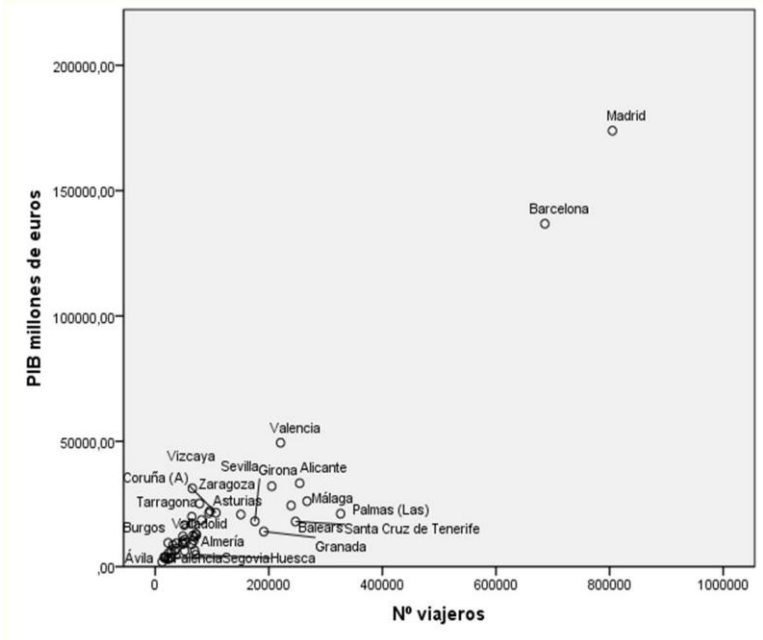
Rechazar H_0 si:
p valor < nivel de significación del contraste

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE MADRID

Ejemplo. Para el conjunto de provincias españolas (excluyendo Ceuta y Melilla) se dispone de información sobre las siguientes variables relativas al sector turístico:

- PIB (millones de euros)
- el nº de establecimientos hoteleros abiertos
- el número de plazas hoteleras
- nº de viajeros
- personal empleado

Diagrama de dispersión:
PIB/viajeros



ntic master

UNIVERSIDAD COMPLUTENSE MADRID

Contraste sobre el valor de la correlación entre PIB y viajeros

Correlaciones

		PIB millones de euros	viajeros
PIB millones de euros	Correlación de Pearson	1	,932**
	Sig. (bilateral)		,000
	N	50	50
viajeros	Correlación de Pearson	,932**	1
	Sig. (bilateral)	,000	
	N	50	50

**. La correlación es significativa en el nivel 0,01 (2 colas).

r de la muestra

Nivel de significación MENOR que 0.01.RECHAZAMOS la hipótesis nula. La correlación entre PIB y viajeros es significativa al 1%

$H_0: \rho = 0$
$H_1: \rho \neq 0$

Obtención del Modelo de Regresión Lineal Simple

Modelo poblacional $y = \beta_1 x + \beta_0 + \mu$

Modelo calculado con los datos $y = b_o + b_1 x$ *(recta de regresión)*

Tanto b_0 como b_1 son los estimadores puntuales de los coeficientes poblacionales (coeficientes de regresión)

El cálculo de los valores b_0 y b_1 se hace siguiendo el criterio de los **mínimos cuadrados** que determina los valores de forma que la recta sea la que "mejor se ajusta" a los valores observados, es decir, a los valores muestrales

Analíticamente:

Propiedad de los mínimos cuadrados: la suma de los cuadrados de los residuos es la menor suma posible, es decir, si:

$$S = \sum_{i=1}^{i=n}[y_i - (b_i x_i + b_0]^2 = \sum_{i=1}^{i=n} e_i^2 \text{ es mínima.}$$

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE MADRID

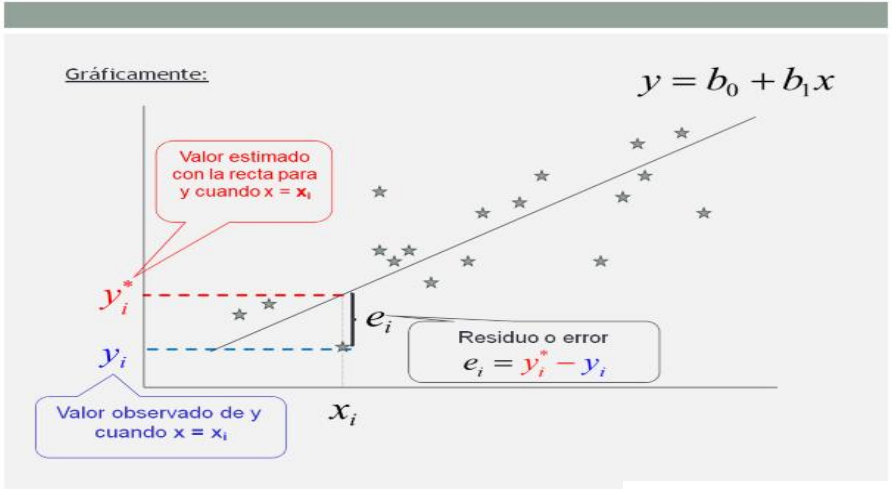
Puede demostrarse que los valores b_0 y b_1 que satisfacen la condición de los mínimos cuadrados son:

$$b_0 = \bar{y} - \frac{s_{xy}}{s_x^2}\bar{x}$$

Ordenada en el origen de la recta: valor medio estimado de Y cuando la variable independiente X toma el valor 0

$$b_1 = \frac{s_{xy}}{s_x^2}$$

Pendiente de la recta: mide la variación promedio en Y por unidad adicional de cambio de en X



ntic master
UNIVERSIDAD COMPLUTENSE MADRID

Para los datos del ejemplo “datos turísticos” estimar el modelo que explica el PIB en función del número de viajeros,

Modelo a estimar : $PIB = \beta_1 * viajeros + \beta_0 + error$

Salida obtenida con el SPSS : $PIB = 0.183 * n^o viajeros - 1319.169$

Model		Unstandardized Coefficients		Standardized Coefficients	t	Sig.
		B	Std. Error	Beta		
1	(Constant)	-1319,169	1940,630		-,680	,500
	viajeros	,183	,010	,932	17,814	,000

El valor de la pendiente es 0,183, este valor nos indica que por cada viajero adicional el PIB aumentaría 0,183 u.m. Este modelo obtenido nos permitirá realizar estimaciones del PIB conociendo un número de viajeros concreto. El sig es el contraste de hipótesis sobre si la variable es significativa o no lo es (estudiaremos este contraste al final del módulo). La cuestión a plantearse es si el modelo obtenido es bueno o no lo es.

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

Bondad de ajuste del modelo

Como hemos indicado, es necesario crear un indicador de la bondad de ajuste del modelo considerado Este indicador es el **coeficiente de determinación R^2. Indica el porcentaje de variación de la variable dependiente Y que se explica por la relación lineal con la variable independiente X.**

Hay que tener en cuenta que este coeficiente está comprendido entre 0 y 1 $0 \leq R^2 \leq 1$

Por lo tanto si quiero calcular el porcentaje de variación de Y **NO** explicado por el modelo de regresión. (% DE ERROR DEL MODELO) tendremos que usar la expresión (1- R^2)*100

Si consideramos todos los valores (x,y) y sumamos los cuadrados de las desviaciones, obtenemos "**cantidades de variación**" y podemos descomponer la variación total como suma de variación explicada y variación sin explicar:

variacion total = variacion explicada + variacion no explicada

$$\sum (y_i - \bar{y})^2 = \sum (y_i^* - \bar{y})^2 + \sum_i (y_i - y^*)^2$$

Suma de cuadrados total (SCT) | **Suma de cuadrados de regresión (SCR)** | **Suma de cuadrados del error (SCE)**

Variación de y que se debe a la relación lineal con x

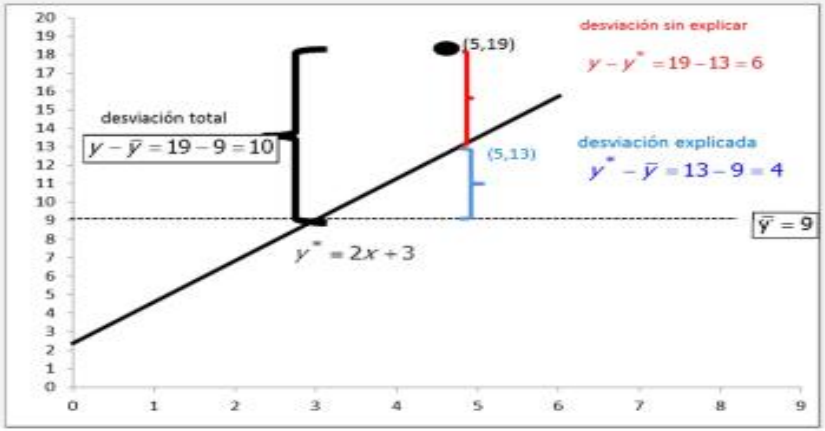
$$R^2 = \frac{\text{variación explicada}}{\text{variación total}} = \frac{\text{suma cuadrados regresión}}{\text{suma de cuadrados total}}$$

En el caso de regresión lineal simple, puede demostrarse que el coeficiente de determinación es el cuadrado del coeficiente de correlación lineal

¿Variación explicada, variación NO explicada? *Ejemplo del libro "Estadística" Mario F Triola*

Imaginemos una muestra de datos (x,y) para la que hemos obtenido:

- Alta correlación lineal entre x e y
- La ecuación de la recta de regresión es $y^* = 2x + 3$
- La media de y es $\bar{y} = 9$
- Uno de los pares de datos muestrales es (5,19)



nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

Para los datos del ejemplo:
(Tabla ANOVA)

ANOVA[b]

Model		Sum of Squares	df	Mean Square	F	Sig.
1	Regression	3,792E10	1	3,792E10	317,341	,000[a]
	Residual	5,736E9	48	1,195E8		
	Total	4,366E10	49			

a. Predictors: (Constant), viajeros

b. Dependent Variable: pib

Variación explicada por el modelo de regresión

Variación No explicada por el modelo de regresión

Model Summary

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	,932[a]	,869	,866	10931,96468

a. Predictors: (Constant), viajeros

$$R^2 = \frac{3.792E+010}{4.366E+010} = 0.869$$

nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

Ejemplo : Un investigador tiene interés de estudiar la elasticidad de cierto plástico (en grados) como una función de la temperatura (ºF) a la que se produce. Se preparan diez piezas de plástico utilizando distintas temperaturas y los valores observados de la elasticidad fueron:

Temperatura 100 110 120 135 140 150 160 175 180 200

Elasticidad 113 118 127 132 136 144 138 146 156 150

a)Determine la ecuación de regresión e interprete los coeficientes de regresión y de correlación.

b) Calcule la bondad de ajuste del modelo de regresión lineal.

c) ¿Qué cantidad de elasticidad se puede predecir cuando se aplica una temperatura de 115ºF?

Correlaciones

		Elasticidad	Temperatura
Correlación de Pearson	Elasticidad	1,000	,941
	Temperatura	,941	1,000
Sig. (unilateral)	Elasticidad	.	<,001
	Temperatura	,000	.
N	Elasticidad	10	10
	Temperatura	10	10

Como se observa el coeficiente de correlación es 0,941, por lo tanto tiene sentido plantearse un modelo lineal. Ver gráfico de dispersión final del ejercicio.

ntic master
UNIVERSIDAD COMPLUTENSE MADRID

Coeficientes[a]

Modelo		Coeficientes no estandarizados		Coeficientes estandarizados		
		B	Desv. Error	Beta	t	Sig.
1	(Constante)	76,792	7,673		10,008	<,001
	Temperatura	,403	,051	,941	7,882	<,001

a. Variable dependiente: Elasticidad

$$Elasticidad = 76{,}792 + 0{,}403 * Temperatura$$

El valor 0,403 nos indica que cada unidad que aumenta la temperatura aumenta 0,403 grados la elasticidad

ANOVA[a]

Modelo		Suma de cuadrados	gl	Media cuadrática	F	Sig.
1	Regresión	1518,472	1	1518,472	62,128	<,001[b]
	Residuo	195,528	8	24,441		
	Total	1714,000	9			

a. Variable dependiente: Elasticidad

b. Predictores: (Constante), Temperatura

Como se ve, la variable Temperatura explica un 88,6% la elasticidad del plástico

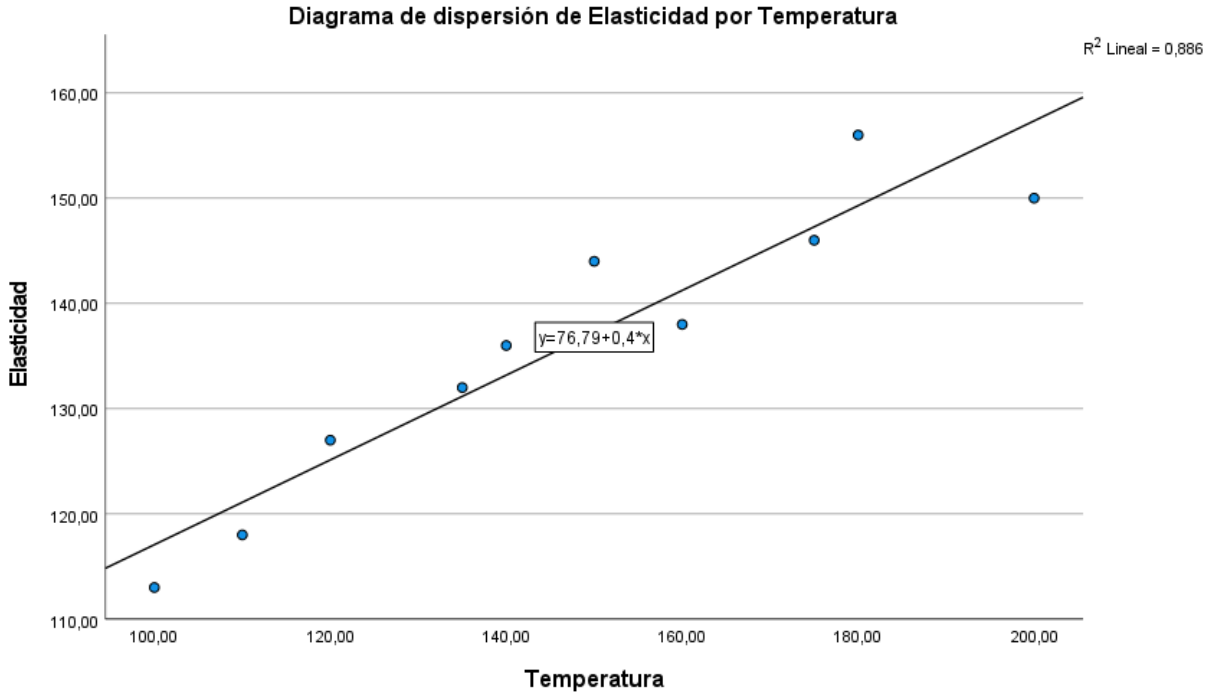
Resumen del modelo

Modelo	R	R cuadrado	R cuadrado ajustado	Error estándar de la estimación
1	,941[a]	,886	,872	4,94378

a. Predictores: (Constante), Temperatura

c) $\hat{y}(115)$ =76,792+0,403*115 =123,137

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE MADRID



nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

HIPÓTESIS DEL MODELO DE REGRESIÓN LINEAL

Hasta ahora hemos explicado cómo aproximar el modelo de regresión lineal , Y=$\beta_0 + \beta_1 x + \mu$ usando la recta de regresión $y = b_0 + b_1 x$ .Para garantizar que esta aproximación es válida, se deben cumplir las siguientes condiciones:

1. Independencia: los residuos deben ser independientes entre sí.

2. Homocedasticidad (igualdad de varianzas): para cada valor de la variable X, la varianza de los residuos debe ser la misma (es decir, que el ajuste es igual de preciso independientemente de los valores que tome X).

3. Normalidad: para cada valor de la variable X, los residuos e_i tienen distribución normal de media cero. Por lo tanto, para ver si un modelo de regresión lineal ajustado es válido, debemos comprobar que se cumplen estas tres condiciones sobre los residuos.

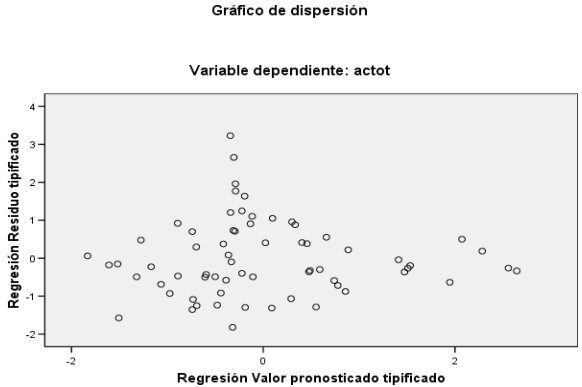
La **independencia** podemos comprobarla con el estadístico de Durbin-Watson. Si éste está entre 1.5 e 2.5, entonces podemos asumir que los residuos son independientes.

nticmaster UNIVERSIDAD COMPLUTENSE MADRID

HIPÓTESIS DEL MODELO DE REGRESIÓN LINEAL

Modelo	R	R^2	R^2corregida	Error típ. de la estimac.	Durbin-Watson
1	.960	.922	.921	2.6762	1.624

- Para comprobar la **homocedasticidad** de los residuos, haremos un procedimiento gráfico.
  Dibujaremos un diagrama de dispersión de las estimaciones (valores predichos por el modelo) tipificadas (ZPRED) frente a los residuos tipificados (ZRESID).
  Para garantizar que hay homocedasticidad, no se debe mostrar ninguna pauta de asociación (ningún patrón) en la nube de puntos.



nticmaster
UNIVERSIDAD COMPLUTENSE MADRID

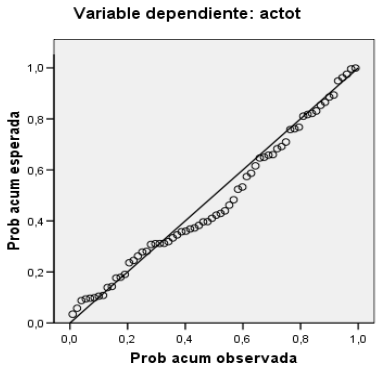
HIPÓTESIS DEL MODELO DE REGRESIÓN LINEAL

- Para comprobar la **normalidad** hacemos los gráficos de normalidad y realizamos el contraste de normalidad (test de Kolmogorov-Smirnov ó test de Shapiro-Wilks)

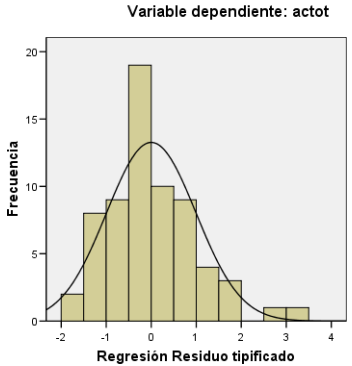
.

	Kolmogorov-Smirnov[a]			Shapiro-Wilk		
	Estadístico	gl	Sig.	Estadístico	gl	Sig.
Standardized Residual	,107	66	,061	,959	66	,027

Gráfico P-P normal de regresión Residuo tipificado



Histograma



ntic master

UNIVERSIDAD COMPLUTENSE DE MADRID

ntic master



UNIVERSIDAD
COMPLUTENSE
MADRID