5

Inferencia. Muestreo.Estimación de parámetros

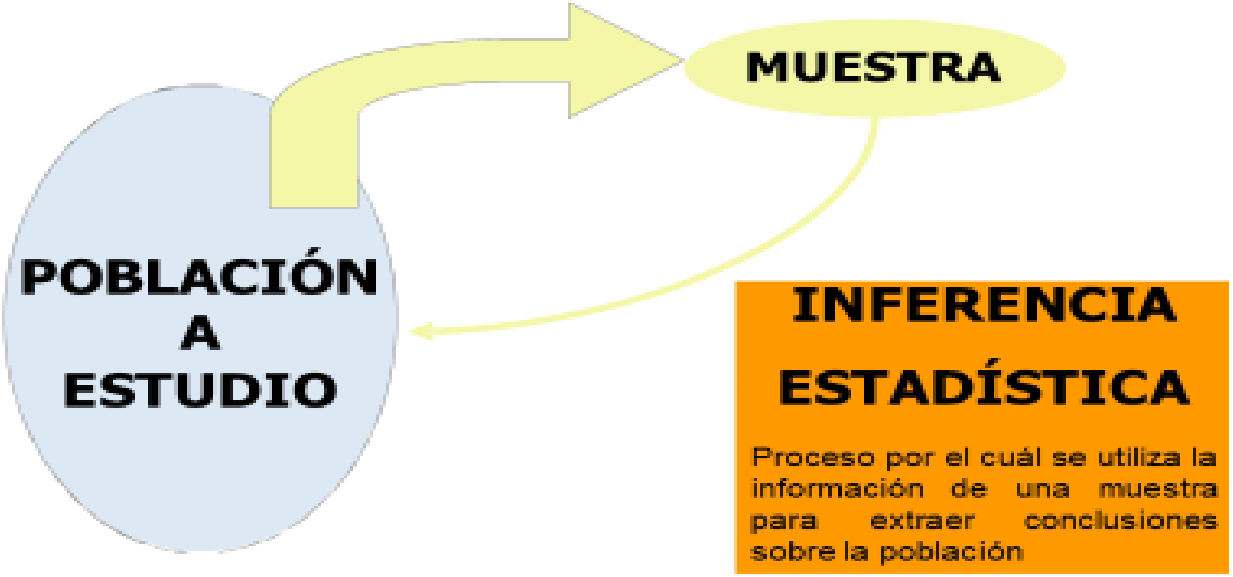
En este capítulo empezamos a trabajar con la estadística inferencial. Estudiaremos el concepto de muestreo y posteriormente presentaremos el concepto de estimación de parámetros.

INTRODUCCIÓN.CONCEPTOS FUNDAMENTALES

Uno de los objetivos principales de la estadística es extraer conclusiones e información sobre una determinada **población**. Recordemos que por POBLACIÓN se denomina al conjunto completo de elementos, con alguna característica común, objeto de nuestro estudio (personas, objetos, experimentos, etc.).

Evidentemente, la forma más directa de cumplir dicho objetivo sería estudiar todos y cada uno de los elementos de la población. Sin embargo, en numerosas ocasiones esto no es posible ya que, por ejemplo, el tamaño de la población puede ser demasiado grande (ej. Habitantes de una comunidad autónoma) o porque estudiar los elementos supone la destrucción de estos (ej. ensayos destructivos de control de calidad) o, simplemente, porque el coste económico es prohibitivo. Por todo ello, en estos casos, es necesario trabajar con un subconjunto de elementos de la población, es decir una **MUESTRA**. Al proceso de obtener muestras se le denomina **MUESTREO.**

La **inferencia estadística** se ocupa de estudiar los métodos necesarios para extraer o inferir, conclusiones válidas e información sobre una población a partir del estudio experimental de una muestra de dicha población.



INFERENCIA ESTADÍSTICA

Proceso por el cuál se utiliza la información de una muestra para extraer conclusiones sobre la población

Los métodos utilizados en la inferencia estadística dependen de la información previa que se tenga de la población a estudiar. Cuando se conoce la forma de la distribución de probabilidad que sigue la variable aleatoria a estudiar en la población, **el problema consiste en determinar los diferentes parámetros de dicha distribución (ej. media y varianza para la distribución normal**). Para ello se utilizan los métodos paramétricos, consistentes en procedimientos óptimos para encontrar dichos parámetros. Cuando la distribución de la población es desconocida, el problema principal es encontrar la forma y características de la distribución, lo cual se hace mediante los llamados métodos no paramétricos.

Para poder estudiar correctamente una población mediante la inferencia estadística es fundamental que la muestra esté bien elegida. La clave de un proceso de muestreo es que la muestra sea representativa de la población. Una forma de conseguir esto es haciendo que todos los elementos de la población tengan la misma probabilidad de ser elegidos para la muestra. Diremos en este caso que tenemos un **muestreo aleatorio simple (m.a.s)**. Para realizar estos muestreos aleatorios se utilizan a menudo tablas de números aleatorias o procedimientos con programas estadísticos. En este caso todas las muestras obtenidas tendrán la misma probabilidad de ser escogidas. Recuerda las diferentes formas de muestreo estudiadas en el tema 1.

Por otra parte, cuando cada elemento de la población pueda seleccionarse más de una vez tendremos un **muestreo con reemplazamiento**, mientras que cuando cada elemento solo se puede seleccionar una única vez será un **muestreo sin reemplazamiento**. Evidentemente, una población finita muestreada con reemplazamiento puede considerarse infinita. Si la población es infinita, o el tamaño de ´esta (N) es muy grande comparado con el tamaño de la muestra (n), es prácticamente indiferente que el muestreo sea con o sin reemplazamiento. Como veremos, normalmente **el análisis se simplifica cuando la población es infinita o el muestreo es con reemplazamiento.**

El problema se concreta entonces en calcular, o **ESTIMAR LOS PARÁMETROS POBLACIONALES**. Para ello se toma una muestra aleatoria de la población.

Para caracterizar una muestra aleatoria de tamaño n vamos a definir las variables aleatorias Xi, i = 1, 2,...,n, que representan los valores muestrales que se observen. Así , en una muestra en particular, dichas variables aleatorias tomarán los valores numéricos xi, i = 1, 2,...,n. X= (x_1,x_2,x_3…..x_n)Nótese que cada una de las variables aleatorias Xi seguirá la misma distribución de probabilidad f(x) de la población. En el caso de un muestreo con reemplazamiento las diferentes Xi serán independientes entre sí (el valor que tome una Xi particular no dependerá de los valores que se hayan obtenido anteriormente).

Por tanto, la distribución de probabilidad conjunta podrá expresarse como:

$P(X_1 = x_1, X_2 = x_2,...,X_n = x_n) = f(x_1, x_2,...,x_n) = f(x_1)f(x_2)...f(x_n)$.

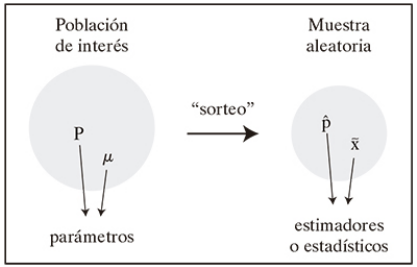
Para poder estimar los parámetros poblacionales se usan las medidas de las variables aleatorias Xi que definen la muestra.
Por ejemplo, como veremos más adelante, para estimar la media de una población normal, se calculara la media aritmética de los diferentes valores xi que se observan en la muestra. Dicha media aritmética es una función de las variables aleatorias Xi.

En general, a cualquier función $g(X_1, X_2,...,X_n)$ de las variables aleatorias que constituyen una muestra aleatoria se le llama **ESTADÍSTICO.** Es importante indicar que a cada parámetro poblacional le corresponderá un estadístico de la muestra, que constituirá una estimación del primero. (será la estimación puntual)
Por ejemplo, para estimar el parámetro poblacional media calcularemos el estadístico muestral consistente en la media aritmética de los valores x_i. Para distinguir valores de la población de los valores medidos en la muestra, se denotarán por letras griegas (μ, σ, etc.) los parámetros poblacionales y por letras romanas ($\bar{x}$, S, etc.) los estadísticos de la muestra.

ntic master
revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

MUY IMPORTANTE

Al ser una función de variables aleatorias, **un estadístico** de la muestra se podrá considerar también como una variable aleatoria, es decir, **podrá obtener diferentes valores dependiendo de la muestra en particular que se elija**. No tiene valor único. Tendrá, por lo tanto, una distribución de probabilidad asociada. A esta se le llama **distribución muestral del estadístico**. Dicho de otra forma, consideremos todas las muestras posibles que se pueden extraer de una población. Si en cada una de estas muestras se midiese un estadístico, por ejemplo la media, este tomaría valores diferentes, que se distribuirían con una determinada distribución muestral. Puesto que los estadísticos van a ser la base para la estimación de los parámetros poblacionales, es sumamente importante estudiar sus distribuciones, para así verificar su utilidad como estimadores.



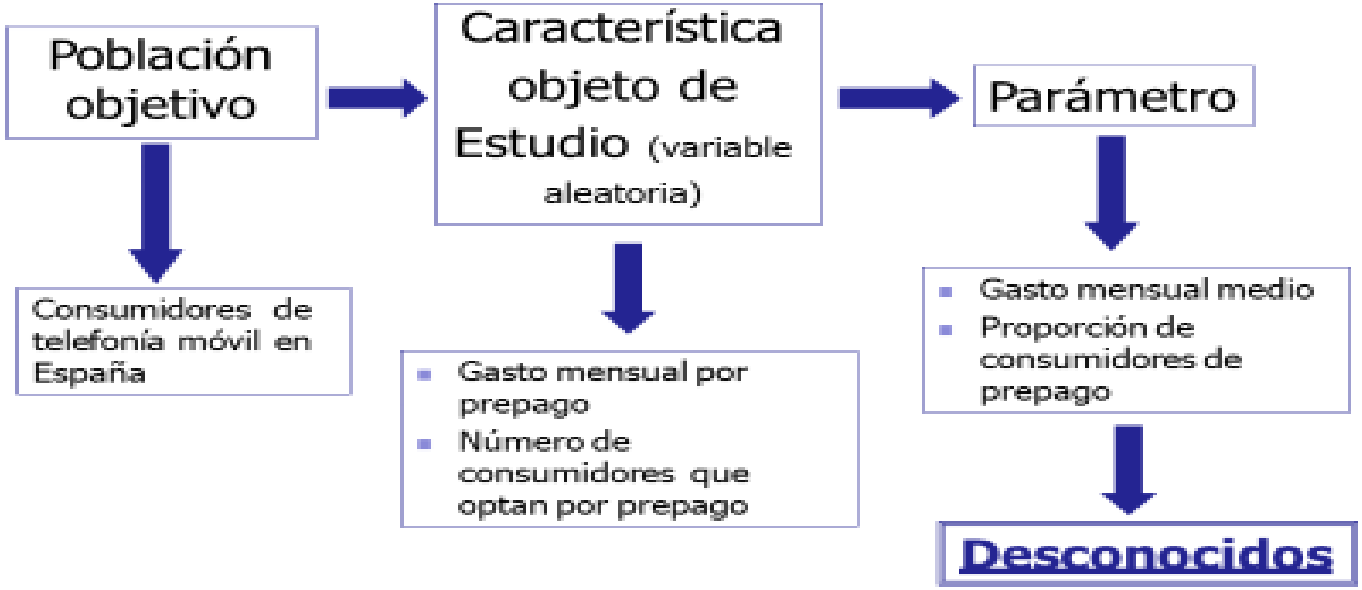
Antes de entrar en estudiar la distribución de algunos estadísticos muestrales importantes, vamos a repasar todo lo que hemos visto con un ejemplo.

Planteamiento del problema. Población y muestra

Un operador de telefonía desea comercializar un nuevo tipo de tarjeta prepago. Quiere analizar:

- El gasto de los consumidores en productos prepago, medido en gasto mensual medio.
- La proporción de clientes de telefonía que utilizan prepago.

Planteamiento del problema. Población y muestra



ntic master
revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

La teoría de la Inferencia Estadística aborda el problema de la **estimación de los parámetros desconocidos de la población** con tres metodologías distintas:

- **Estimación puntual**. Permite asignar un valor concreto al parámetro desconocido
- **Estimación por intervalo**. Proporciona un intervalo de valores, dentro del cual estamos "razonablemente seguros" de que está el parámetro desconocido
- **Contraste de Hipótesis**. Procedimiento estadístico que permite rechazar o no rechazar una hipótesis formulada sobre la población

DEFINICIÓN DE ESTADÍSTICOS Y PROPIEDADES

Un **estadístico** es un resumen de la información muestral. Es **función de la muestra** y por tanto es una variable aleatoria que puede tomar tantos valores como posibles muestras podamos seleccionar de la población. Vamos a estudiar los principales estadísticos muestrales

MEDIA MUESTRAL

El primer estadístico importante es la **media muestral**. Si tenemos una muestra aleatoria de tamaño n representada por las variables aleatorias X_i, i = 1, 2,...,n, se define la media muestral, o media de la muestra, como

$$\bar{X} = \frac{X_1+X_2+X_3+\cdots\ldots\ldots+X_n}{n}$$

Evidentemente, cuando las variables aleatorias X_i tomen, en una muestra, los valores particulares x_i, el valor que tendrá la media muestral vendrá dado por $\bar{x} = \frac{x_1+x_2+x_3+\cdots\ldots\ldots+x_n}{n}$

Al ser una combinación lineal de variables aleatorias, la media muestral es asimismo una nueva variable aleatoria y tendrá asociada una distribución de probabilidad. Es decir, consideremos una población de la que se toman diferentes muestras de tamaño n, calculando para cada muestra la media $\bar{x}$.

Si tomamos k muestras distintas, obtendremos k valores, en general diferentes, de medias muestrales x_1, x_2,..., x_k. Si hacemos que k tienda a infinito, los valores x_i tendrán una distribución llamada **distribución muestral de la media.**

Se demuestra que el valor esperado de la media muestral (media de la media muestral) es la media de la población $E[\bar{X}]=\mu$. Este resultado es sumamente importante.



De forma similar se puede calcular la varianza de la distribución muestral de la media. Puesto que la varianza de cada X_i coincide con la varianza de la población σ^2 se puede demostrar que :

$$\mathbf{Var}(\bar{X}) = \frac{\sigma^2}{n} \qquad DT(\bar{X}) = \frac{\sigma}{\sqrt{n}}$$

La varianza de la media muestral disminuye conforme aumenta el tamaño muestral. La desviación nos indica lo que varía la media muestral de una muestra a otra.

Es decir, la desviación típica de la distribución de medias será la de la población original, dividido por un factor √n que depende del tamaño de la muestra. La expresión anterior es válida solo para el caso de población infinita o muestreo con reemplazamiento. Siempre consideraremos esto.

.

ntic master
revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

Respecto a la **forma de la distribución de la media muestral**, ésta en principio dependerá de la distribución de la población de partida, pero, en virtud del **teorema del límite central** se puede establecer que $\bar{X}$ seguirá una distribución asintóticamente normal. Es decir: Si $\bar{X}$ es la media de una muestra aleatoria de tamaño n que se toma de una población con distribución cualquiera, con media μ y varianza σ^2, entonces la variable tipificada $Z = \frac{X-\mu}{\frac{\sigma}{\sqrt{n}}}$ tiende a una distribución normal estándar N(0, 1) cuando n tiende a infinito.

En resumen, $\bar{X}$ es asintóticamente normal, sea cual sea la forma de la distribución de la población de partida. Evidentemente, cuanto mayor sea el tamaño de la muestra, más se aproximará la distribución de $\bar{X}$ a la normal. En la práctica, la aproximación de distribución normal se utiliza cuando $n \geq 30$, y la bondad de esta dependerá de la forma más o menos simétrica de la distribución de la población muestreada.

Un caso particular muy importante es cuando la distribución de la población de partida es normal. En este caso, no es necesario que el tamaño de la muestra sea grande para que la distribución muestral de $\bar{X}$ sea normal y podemos establecer que:

Si la población de la cual se toman muestras está distribuida normalmente con media μ y varianza σ^2, entonces la media muestral sigue una distribución normal con media μ y varianza σ^2/n, con independencia del tamaño de la muestra.

Esto es también consecuencia del teorema del límite central.

Una combinación lineal, como $\bar{X}$, de variables aleatorias normales será también normal.

Para derivar estos últimos resultados hemos supuesto que la población era infinita o el muestreo con reemplazamiento (para que las diferentes Xi fuesen independientes). Si esto no se cumpliese y tuviésemos un muestreo sin reemplazamiento de una población finita habría que substituir $\frac{\sigma^2}{n}$por la expresión . $\mathbf{Var}(\bar{X}) = \frac{\sigma^2}{n}\frac{N-n}{N-1}$

IMPORTANTE:

En el caso que la varianza de la población no se conozca y sea una población pequeña, se puede sustituir la varianza de la población por la varianza muestral, en este caso t= $\frac{X-\mu}{\frac{s}{\sqrt{n}}} \sim t(n-1)$

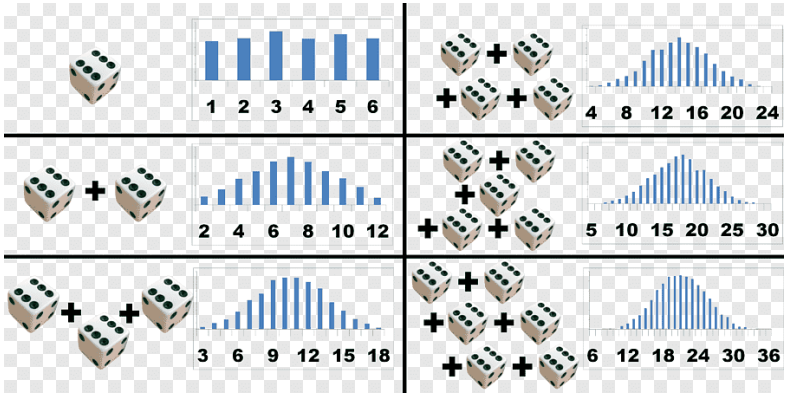
.

ntic master
revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

TEOREMA CENTRAL DEL LÍMITE

Uno de los resultados más importantes en estadística es este resultado que nos indica que independientemente de la forma de la distribución de la población, la forma de la distribución muestral de la media se aproxima a una curva normal, si el tamaño de la muestra es suficientemente grande . Este teorema se puede formular diciendo que si tenemos un grupo numeroso de variables independientes y todas ellas siguen el mismo modelo de distribución (cualquiera que éste sea), la suma de ellas sigue una distribución normal. La importancia de este teorema es que se aplica tanto a variables discretas como continuas.

Observemos esta representación gráfica que corresponde a la función de probabilidad del lanzamiento de dados equilibrados donde se aprecia el resultado que hemos enunciado

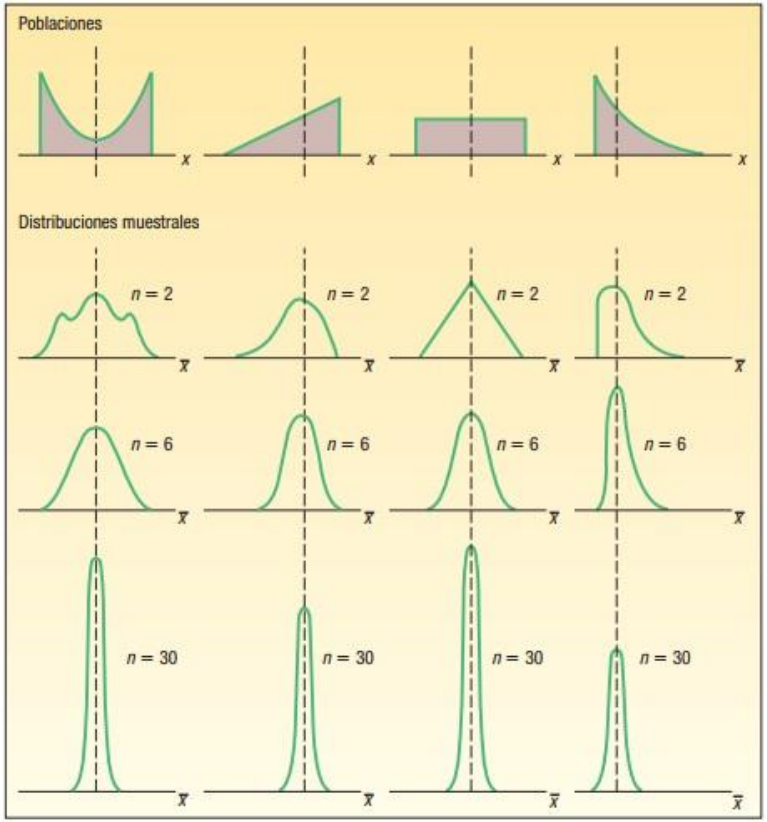


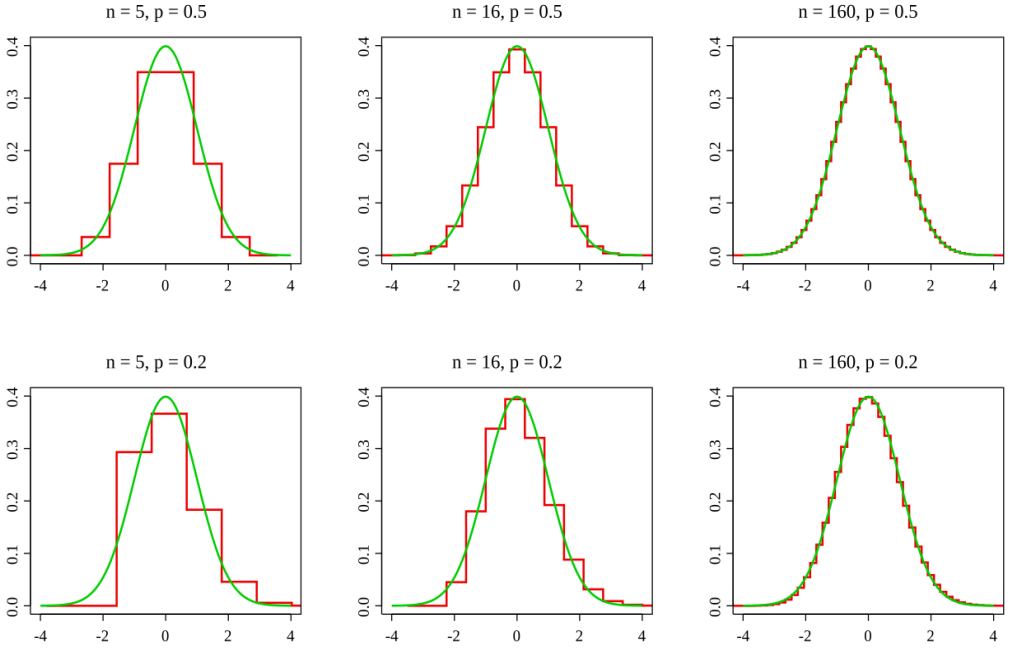
Observando el dibujo se aprecia que a medida que tenemos más dados equilibrados, la función de probabilidad se asemeja cada vez más a una normal.

El teorema del límite central es útil cuando se analizan grandes conjuntos de datos porque permite suponer que la distribución muestral de la media se distribuirá normalmente en la mayoría de los casos. Esto permite un análisis estadístico y una inferencia más fáciles.

Si la población es una distribución normal, entonces, en el caso de cualquier tamaño de muestra, la distribución muestral de las medias también será de naturaleza normal.
Si la distribución poblacional es simétrica (pero no normal), la forma normal de la distribución muestral de las medias se presenta con muestras tan pequeñas como 10.

Por otra parte, si se comienza con una distribución sesgada o con colas anchas, quizá se requieran muestras de 30 o más para registrar la característica de normalidad (Lind, Marchal, and Wathen 2015). Veamos las siguientes ilustraciones en la siguiente página





ntic master
revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

PROPORCIÓN MUESTRAL

Consideremos una población tal que sus elementos son susceptibles de poseer o no cierta característica C. La característica objeto de estudio de la población puede ser representada por una variable que toma el valor 1 si el elemento de la población posee la característica C y el valor 0 si no la posee.

Estamos interesados en conocer el número de individuos que tiene la característica C (variable X). Para cada individuo, X sólo puede tomar dos valores: 0 si el individuo no posee la característica, 1 si el individuo posee la característica.

En otras palabras, estamos suponiendo que tenemos una población sobre la que se experimenta un proceso de Bernoulli.
Es decir, se llevan a cabo n ensayos y el resultado de cada uno de ellos es un éxito o un fracaso.

Llamemos p a la probabilidad de éxito en cada ensayo y q (= 1 − p) a la probabilidad de fracaso. Es decir X es una variable Bi(1,p) donde p es la proporción de elementos que poseen la característica y que es el parámetro desconocido que deseamos estimar.

ntic master
revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

El parámetro desconocido, p, no es más que la media de la población, luego según lo visto anteriormente el estadístico apropiado para su estimación será la media de la muestra

Cada n ensayos se pueden considerar como una muestra de tamaño n. Para cada muestra vamos a definir el estadístico $\hat{p}$ como la proporción de éxitos, o número de éxitos dividido por el número de ensayos. Nótese que $\hat{p}$ puede considerarse como la media muestral de una variable de Bernoulli (o variable binomial con un ´unico ensayo). Tendremos:

$$\bar{x} = \hat{p} = \frac{\sum_{i=1}^{n} x_i}{n}$$

El estadístico $\hat{p}$ seguirá una distribución de probabilidad, **llamada distribución muestral de una proporción**, que es, entonces, un caso particular de la distribución muestral de una media. Para calcular los parámetros poblacionales de esta distribución recordemos que la media y varianza de una variable de Bernoulli vienen dadas por $\mu = p$; $\sigma^2 = p \cdot q = p(1-p)$.

Por lo tanto tenemos que la media de la proporción muestral es p $E(\hat{p}) = p$

Y la varianza de la proporción muestral vendrá dada por $Var(\hat{p}) = \frac{p(1-p)}{n}$

Al igual que antes, en el caso de un muestreo sin reemplazamiento de una muestra finita, la segunda ecuación hay que substituirla por $Var(\hat{p})=\frac{p(1-p)}{n}\frac{N-n}{N-1}$

Al ser un caso particular de la distribución muestral de la media, la distribución muestral de una proporción puede aproximarse por una distribución normal para valores grandes del número de ensayos n. En la práctica esta aproximación se hace para n ≥ 30 (Teorema central del límite)

Ejemplo: Supongamos que hemos preguntado a 500 consumidores de telefonía móvil, si son consumidores de prepago o no: 200 han contestado que SI

El parámetro p será la proporción de consumidores que usan prepago (valor desconocido)
El estadístico $\hat{p}$ será la proporción muestral para muestras de tamaño 500

En nuestro ejemplo la estimación de mi muestra será $\hat{p}$=200/500=0,4 (se le llama estimación puntual)
El estadístico $\hat{p}$ seguirá una distribución normal de media 0,4 y varianza $\frac{0,4*0,6}{500}$= 0,00048.

ntic master
revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

DISTRIBUCIÓN MUESTRAL DE LA DIFERENCIA DE MEDIAS

Supongamos que tenemos dos poblaciones, la primera caracterizada por una media μ_1 y una varianza σ_1^2, y la segunda por μ_2 y σ_2^2. Supongamos que se extraen muestras aleatorias independientes de cada población, con tamaños n_1 y n_2 respectivamente. Siguiendo la misma notación, llamemos $\overline{X_1}$ al estadístico que representa la media muestral de la primera población y $\overline{X_2}$ a la media muestral de la segunda. Vamos a estudiar un nuevo estadístico, consistente en la diferencia de las medias muestrales $\overline{X_1}$- $\overline{X_2}$. Efectivamente, al ser una combinación lineal de dos variables aleatorias, será una nueva variable aleatoria, o estadístico, que tomará diferentes valores para todas las diferentes combinaciones de muestras extraídas de cada población. Su distribución la llamaremos **distribución muestral de la diferencia de medias.**

En esta distribución la media viene dada por μ_1- μ_2 y la varianza por $\sigma_1^2 / n_1 + \sigma_2^2 / n_2$
Este último resultado solo será válido para poblaciones infinitas o en muestreos con reemplazamiento

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

Por otra parte, respecto a la forma de la distribución, por el teorema central del límite la variable tipificada definida por :

$$Z = \frac{(\overline{X_1} - \overline{X_2}) - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2 / \ n_1 + \sigma_2^2 \ / \ n_2}}$$

tenderá a la distribución normal estándar cuando tanto n_1 como n_2 tiendan a infinito. En la práctica se suele aplicar la aproximación normal si $n_1 + n_2 > 30$ (y $n1 \approx n2$). Aún cuando n_1 y n_2 sean menores de 30, la aproximación normal puede ser razonablemente buena si las distribuciones originales no son muy asimétricas. Por supuesto, si ambas poblaciones fuesen normales, entonces $\overline{X_1} - \overline{X_2}$ tiene una distribución normal sin importar los tamaños de las muestras

Ejercicio:

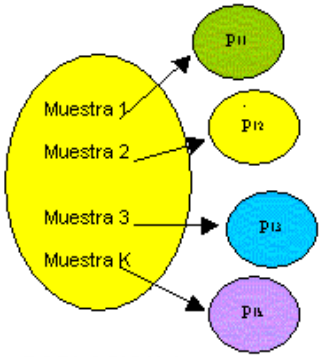
Se tienen dos poblaciones normales N(20, 5) y N(10, 6) y se extraen dos muestras de tamaños $n_1 = 25$ y $n_2 = 12$. ¿Cuál será la distribución muestral de la diferencia de medias?

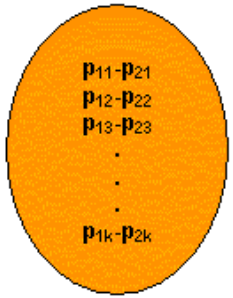
¿Cuál será la probabilidad de obtener una diferencia de medias $\overline{X_1} - \overline{X_2} > 14$?

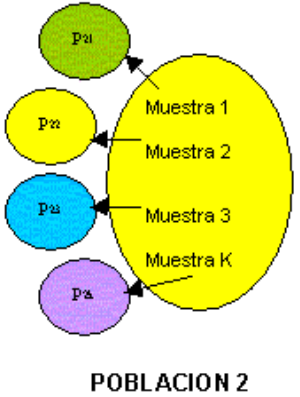
De forma similar se puede deducir la distribución muestral de la **diferencia de proporciones** para dos poblaciones con distribuciones de Bernoulli y parámetros p_1, q_1 y p_2, q_2 respectivamente. En este caso, el estadístico diferencia de proporciones de éxitos $\overline{P_1} - \overline{P_2}$ de muestras tomadas de cada población sigue una distribución con media y varianza dadas por:

Media p_1-p_2 Varianza : $p_1q_1/n_1 + p_2q_2/n_2$









ntic master revolucionamos la comunicación

UNIVERSIDAD COMPLUTENSE DE MADRID

DISTRIBUCIÓN MUESTRAL DE LA VARIANZA MUESTRAL

Otro de los estadísticos importantes es la **varianza muestral**. Si X_i, i = 1, 2,...,n, representan las variables aleatorias para una muestra de tamaño n, entonces se define la varianza muestral, o varianza de la muestra como:

$$s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$

donde los x_i son los valores particulares que toman las variables aleatorias X_i . Se sigue entonces la misma definición que para la varianza de una tabla de frecuencias.

Al igual que la media muestral, la varianza muestral es una variable aleatoria. Es decir, los valores que toma dependen de la muestra en particular que se tenga. Tiene por tanto una distribución de probabilidad asociada, llamada **distribución muestral de la varianza**. Para la media muestral vimos que la media, o esperanza matemática, de su distribución coincidía con la media poblacional. Para la varianza muestral sucede lo mismo: **El valor esperado de la varianza muestral es la varianza poblacional, es decir** $\boldsymbol{E(s^2) = \sigma^2}$

ntic master
revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

NOTA : Si en lugar de la cuasivarianza , hubiésemos optado por considerar como varianza muestral la expresión:

$$S'^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n}$$

Hubiéramos obtenido que $\boldsymbol{E(s'^2) = \frac{n-1}{n}\sigma^2}$

y la varianza muestral hubiese subestimado la varianza poblacional. Este es el motivo por el que estamos trabajando con la primera definición para la varianza. Como veremos más adelante, se dice que S^2 es un estimador insesgado de la varianza, mientras que S'^2 es un estimador sesgado. Evidentemente, cuando el tamaño n de la muestra sea grande apenas habrá diferencia de usar una definición u otra para la varianza muestral.

Los resultados anteriores son válidos si la población es infinita o el muestreo es con reemplazamiento. En el caso de tener un muestreo sin reemplazamiento de una población finita de tamaño N, la esperanza matemática de la varianza muestral estaría dada por

$$\boldsymbol{E(s^2) = \frac{N}{N-1}\sigma^2}$$

Propiedad:

Si de una población con distribución normal y parámetros μ, σ, se toman muestras aleatorias de tamaño n, entonces la siguiente variable aleatoria obedece a una distribución χ_2 con (n − 1) grados de libertad χ^2_{n-1} = (n − 1)·S² / σ²

Ejemplo: Un vendedor asegura que la pintura anticorrosiva de un automóvil dura 10 años, con una desviación típica de 3 años. Se pintan 6 coches y la pintura dura 12, 17, 3, 9, 5 y 13 años. ¿Podemos creer al vendedor cuando afirma que σ = 3?

Obtenemos la media muestral $\bar{x}$ = 9.83 (que lógicamente debe ser próxima a μ). Calculamos ahora la varianza muestral

$$s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1} = 27{,}4$$

y por tanto χ^2_{n-1} = (n − 1)S²/ σ² = 15.22, que está muy lejos de lo esperado (recordemos que una distribución χ^2_{n-1} tiene μ = (n − 1) = 5 y σ² = 2(n − 1) = 10

DISTRIBUCIÓN MUESTRAL DE LA RAZÓN DE VARIANZAS

Anteriormente hemos visto cómo para comparar dos poblaciones independientes se estudiaba la distribución muestral de la diferencia de medias. En el caso de las varianzas podría hacerse lo mismo y construir un estadístico de la diferencia de varianzas muestrales. Sin embargo, la distribución muestral de ese estadístico es demasiado complicada y, para poder comparar las varianzas de dos poblaciones, es mejor definir un estadístico basado en la razón de las varianzas muestrales, en vez de en su diferencia. Supongamos que tenemos **dos poblaciones normales** independientes con varianzas poblacionales σ_1^2, σ_2^2 respectivamente. Sean s_1^2, s_2^2 las varianzas muestrales medidas en una muestra aleatoria extraída de cada población. Se define entonces el estadístico F como :

$$F = \frac{\frac{s_1^2}{\sigma_1^2}}{\frac{s_2^2}{\sigma_2^2}} \sim F(n_1 - 1, n_2 - 1)$$

Este resultado sigue siendo válido aunque las poblaciones no sean normales pero su distribución tenga forma de campana.

ntic master
revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

ESTIMACIÓN DE PARÁMETROS

Una función de las variables aleatorias muestrales (valores muestrales) se denomina ESTADÍSTICO. Como estas variables pueden tomar distintos valores por ser variables aleatorias, un estadístico también podrá tomar distintos valores, y se constituirá de igual forma, en una variable aleatoria. Cualquier estadístico que nos permita hacernos una idea acerca del valor poblacional de un parámetro desconocido se denominara ESTIMADOR. Llamaremos **ESTIMACIÓN PUNTUAL** al valor concreto del estimador en una determinada realización muestral.

Evidentemente, el paso previo en todo proceso de estimación consistirá en definir los estadísticos que se emplearan como estimadores. En este sentido, parece lógico pensar que si la base de la inferencia radica en el estudio de la población a través de la muestra, esa misma lógica indica que un primer esbozo de determinación de un estimador será el de que se satisfaga el principio de analogía entre el parámetro a estimar y el estimador del mismo. Así , por ejemplo, si se pretende estimar la media de una población, ese principio de analogía sugiere que se emplee como estimador la media muestral. En cualquier caso, habrá que comprobar si la aplicación en cada circunstancia concreta del referido principio es correcta o no, por lo que tenemos que indicar las propiedades que deben de reunir los estimadores para que puedan ser utilizados.

Esta claro que la estimación puntual posee la ventaja de dejar especificado de forma unívoca el parámetro poblacional que se pretende estimar, pero no es menos evidente que los resultados de la estimación pueden diferir significativamente de tomar una muestra a tomar otra y además LA ESTIMACIÓN PUNTUAL NO PROPORCIONA NINGUNA INFORMACIÓN DEL ERROR que cometemos al realizar la estimación por este procedimiento.

Por ello, es vital que los estimadores gocen de determinadas propiedades deseables que citamos a continuación :

1)Los estimadores han de ser insesgados o centrados: Diremos que un estimador cumple esta propiedad si la media del estimador coincide con el parámetro poblacional a estimar. En caso contrario, al estimador se le llama sesgado , y a la desviación entre su valor probable (media) y el verdadero valor del parámetro se le denomina sesgo.

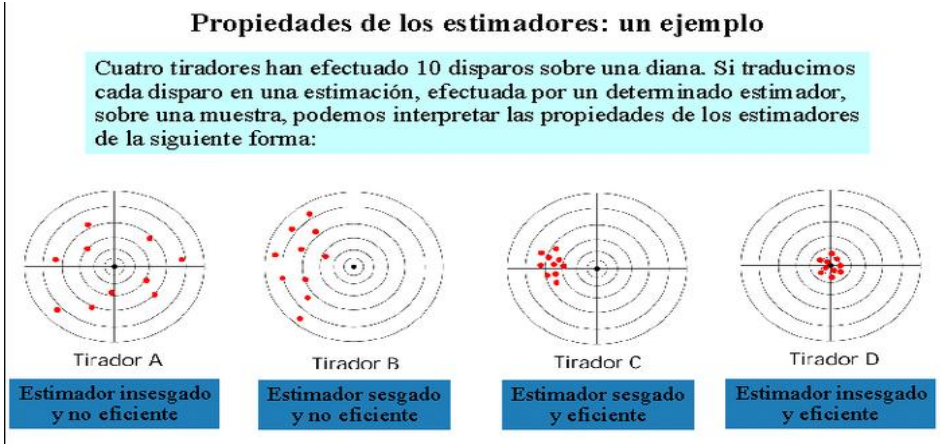
2)Consistencia: Se dice que un estimador es consistente cuando, al crecer el tamaño muestral, se aproxima asintóticamente al valor del parámetro poblacional y su varianza se hace nula.
Es decir si T es el estimador y α el parámetro poblacional a estimar $\lim_{n\to\infty} T = \alpha \;\; y \;\; \lim_{n\to\infty} \sigma^2(T) = 0$

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

3)<u>Suficiencia</u>: Se dice que un estadístico es suficiente cuando recoge toda la información que facilita la muestra. En consecuencia, parece evidente que una estimación puntual óptima de un parámetro sería la que se efectuase a través de la determinación de estadísticos suficientes.

4)Eficiencia: Se dice que un estimador es eficiente si es insesgado y tiene varianza mínima. La acotación de la varianza que permite observar la existencia de varianza mínima se realiza a través de la desigualdad de Cramer- Rao.

Un estimador ideal ha de ser insesgado y con una eficiencia máxima. Sin embargo, en la práctica, a veces no es posible calcular dichos estimadores, y, por la comodidad con que se obtienen, se trabaja con estimadores sesgados o poco eficientes. De todas formas, un requisito mínimo que ha de cumplir cualquier estimador es que sea consistente.



ntic master
revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

Una vez visto el problema que se plantea en cada proceso de estimación en relación con las condiciones que un estimador debe reunir para que se le pueda considerar como aceptable, queda por resolver la cuestión de cómo proceder a la determinación de estimadores puntuales. Existen varios métodos para realizar esta determinación.

1)**Método de la máxima verosimilitud** (EMV): los estimadores de los parámetros serán aquellos valores de estos parámetros que hacen máxima la función de verosimilitud, entendiendo por tal la función de probabilidad de la muestra.

2)**Método de los momentos**:Consiste en que si existen los k primeros momentos con relación al origen de la variable representativa de la población, como dichos momentos dependerán de los k parámetros a estimar, si se igualan sus expresiones con las de los primeros k momentos con relación al origen en la muestra, se tendrá un sistema del que pueden obtenerse, como raíces, los estimadores buscados.

3)Método de estimación por mínimos cuadrados: Calcula las estimaciones de los parámetros por minimización de la función de distancia cuadrática entre los valores estimados y los verdaderos valores del los parámetros.

En cuanto a los estimadores puntuales más comunes tenemos los siguientes:

1)La media muestral $\bar{x}$ como estimador de la media poblacional μ. Se trata de un estimador insesgado, eficiente, consistente , suficiente y de varianza mínima para el parámetro poblacional.

2)Para la varianza poblacional σ^2 hacemos uso de la cuasivarianza muestral s^2**.** Es un estimador insesgado, suficiente, consistente y de mínima varianza para el parámetro poblacional σ^2 **.**

3)Para una población binomial (n, p) , la proporción muestral del número de éxitos, es un estimador consistente, suficiente, insesgado y de varianza mínima para el parámetro poblacional p.

4)Para una población de Poisson de parámetro λ la media muestral es un estimador suficiente, insesgado, consistente, eficiente y de varianza mínima para el parámetro poblacional λ

ESTIMACIÓN POR INTERVALOS

El problema que presenta la estimación puntual de un parámetro es que a pesar de su sencillez para proceder no nos garantiza ni mide la **precisión** en que se ha hecho la estimación , es decir no nos mide el error cometido entre el verdadero valor del parámetro y la estimación. Sólo la bondad de ajuste y el tamaño de la muestra pueden proporcionar una mayor o menor confianza de la estimación obtenida.

Por esa razón es necesario dar , junto a la estimación, una medida del grado de confianza de la misma. Esto se consigue mediante un INTERVALO DE CONFIANZA que nos proporcione unos límites entre los cuales **confiamos** se encuentre el valor desconocido del parámetro. Esta confianza se expresa en tanto por ciento (porcentaje) , de tal manera que si este es del $\beta\%$ esto significa que al obtener todos los posibles intervalos como el anterior, tenemos la confianza de que el $\beta\%$ contendrán el valor exacto del parámetro desconocido.

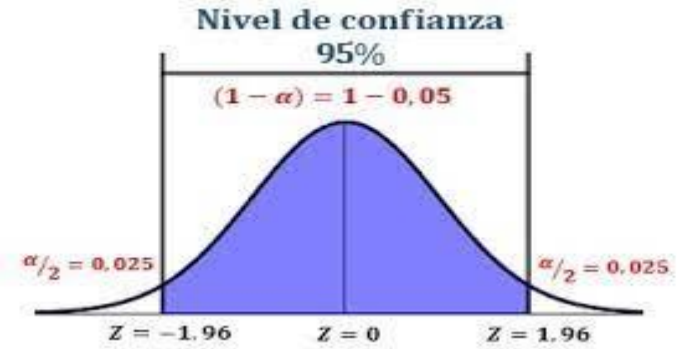
Un intervalo de confianza para el parámetro θ de una población es de la forma $L_1 \leq \theta \leq L_2$, donde θ es el valor del parámetro desconocido y L_1 y L_2 son funciones de los valores muestrales (diferentes para cada muestra), que únicamente serán números cuando hayamos obtenido una muestra y sustituido sus valores en las funciones L_1 y L_2

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

En el proceso de construcción de un intervalo de confianza por lo tanto podemos distinguir dos etapas, la primera etapa (teórica) consiste en establecer formalmente el intervalo aleatorio $[L_1, L_2]$ de manera que $P(L_1 \leq \theta \leq L_2) = \beta = 1 - \alpha$. L_1 es el límite inferior y L_2 es el límite superior. En esta etapa podemos hallar de probabilidad de que el intervalo contenga el valor del parámetro θ. En la segunda etapa, tomamos una muestra de la población a la que pertenece el parámetro y sustituimos en L_1 y L_2, de esta forma obtenemos dos números . Una vez realizada tal sustitución , no es posible hablar de la probabilidad de que el valor desconocido del parámetro se encuentre comprendido entre ambos números, ya que evidentemente , el parámetro lo estará o no. Sin embargo, como nosotros no sabemos si lo está, tenemos un coeficiente de confianza del $\beta\%$ de que lo esté.

También se dice que el **nivel de confianza** es $\beta = 1 - \alpha$ (Probabilidad de que el intervalo contenga al parámetro de la población). Los niveles de confianza típicos son del 90%, 95% y 99%.

.



ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

INTERVALOS DE CONFIANZA PARA LA MEDIA POBLACIONAL

Si X es una v.a que sigue una distribución N(μ, σ) y (x_1, x_2,……. xn) es una muestra aleatoria de tamaño n, podemos calcular intervalos de confianza para los parámetros μ y σ. Empezamos con los de la media poblacional. Vamos a suponer que tomamos como estimación puntual, la media muestral $\bar{x}$.

Distinguiremos **dos casos principales**:

1)Varianza poblacional σ^2 conocida

Es el intervalo menos usual. En este caso, como queremos determinar la media de la población μ tomamos como estimador puntual, como ya hemos dicho, la media muestral $\bar{x}$ .A partir de aquí, la construcción del intervalo de confianza se hace tomando como base este estimador y partiendo de la variable aleatoria Z de la que conocemos su distribución muestral (teorema central del límite, distribución media muestral):

$$Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0,1)$$

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

A partir de aquí tenemos que $P(-z_{\alpha/2} \leq \frac{\bar{X}-\mu}{\frac{\sigma}{\sqrt{n}}} \leq z_{\alpha/2}) = 1 - \alpha$

Si desarrollamos tenemos que

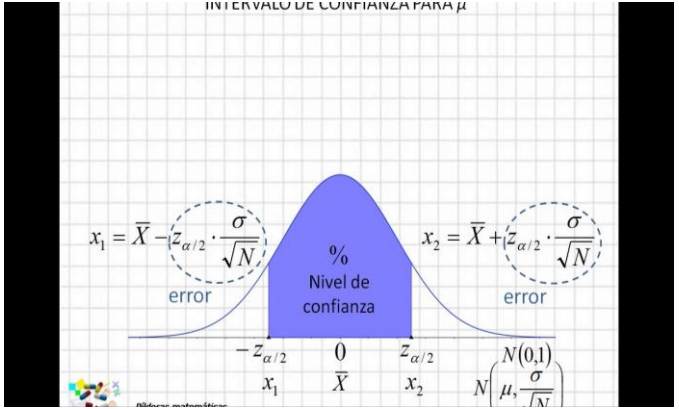
$$P(\bar{X} - z_{\alpha/2}\frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{\alpha/2}\frac{\sigma}{\sqrt{n}}) = 1 - \alpha$$

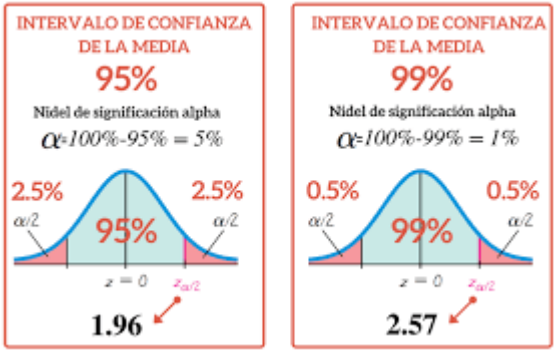
Por lo tanto la expresión del I.C que buscamos sería:

$$\boldsymbol{IC(\mu) = \left[\bar{X} - z_{\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2}\frac{\sigma}{\sqrt{n}}\right]}$$

donde $z_{\frac{\alpha}{2}}$ es el valor crítico tal que $P(X \leq z_{\frac{\alpha}{2}}) = 1 - \alpha/2$

Nótese que muestras diferentes darán lugar a valores diferentes de la media muestral $\bar{X}$ y, por lo tanto, a intervalos diferentes. Sin embargo, la longitud de los intervalos será siempre la misma y dependerá únicamente (para muestras de igual tamaño) del nivel de confianza 1 − α que se haya fijado (a menor α mayor anchura del intervalo). Evidentemente, no todos los intervalos que se construyan de diferentes muestras contendrán al parámetro μ, esto se cumplirá para el 100(1−α) % de los intervalos posibles.





ntic master
revolucionamos la comunicación

UNIVERSIDAD COMPLUTENSE DE MADRID

VALORES DE $z_{\alpha/2}$ PARA LOS NIVELES DE CONFIANZA MÁS USADOS

Nivel de confianza	α	$\alpha/2$	$z_{\alpha/2}$
90%	.10	.05	1.645
95%	.05	.025	1.960
99%	.01	.005	2.576

Resumiendo:

1 − α es la probabilidad de seleccionar una muestra concreta que conduzca a un intervalo que contenga al parámetro poblacional. En otras palabras, el 100(1 − α) % de los intervalos correspondientes a todas las muestras posibles del mismo tamaño contienen a θ y el 100α % no lo contienen. Evidentemente, al aumentar el tamaño de la muestra ha de aumentar la precisión con que se conoce el parámetro poblacional, y por lo tanto, para un nivel de confianza fijo, el intervalo de confianza ha de hacerse más pequeño. Es decir, la longitud del intervalo de confianza indica la precisión de la estimación. El valor de α es un valor comprendido entre 0 y 1(usualmente próximo a 0) que indica el riesgo que el intervalo de confianza NO contenga el valor del parámetro poblacional θ. Se le denomina a α, **nivel de significación.**

2)Varianza poblacional σ^2 desconocida

En general, la desviación típica σ de la población se desconoce a priori, de forma que, estrictamente, no se puede aplicar la expresión anterior para calcular el intervalo de confianza. Sin embargo, cuando la muestra es grande, la desviación típica muestral **s** suele ser un estimador muy preciso de σ, de forma que, en primera aproximación, el intervalo de confianza se puede construir sustituyendo σ por S en la expresión del apartado anterior, obteniéndose

$$P(-z_{\alpha/2} \leq \frac{\bar{X}-\mu}{\frac{s}{\sqrt{n}}} \leq z_{\alpha/2}) = \alpha \rightarrow \ P(\bar{X} - z_{\alpha/2}\frac{s}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{\alpha/2}\frac{s}{\sqrt{n}}) = \alpha$$

Por lo tanto el intervalo de confianza que tendríamos que calcular en este caso sería:

$$IC(\mu) = \left[\bar{X} - z_{\frac{\alpha}{2}}\frac{s}{\sqrt{n}}, \ \bar{X} + z_{\alpha/2}\frac{s}{\sqrt{n}}\right]$$

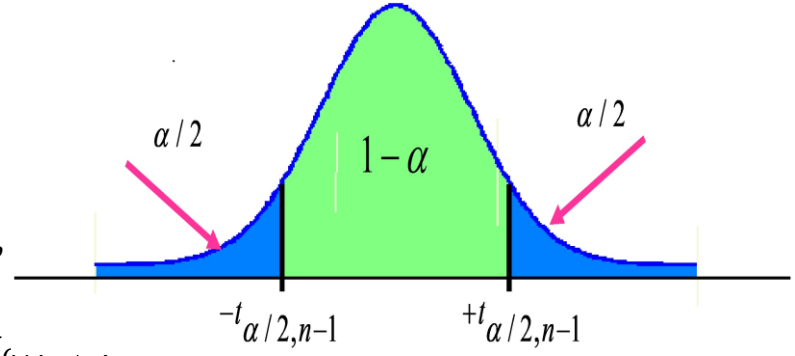
En la práctica, esta aproximación se usa cuando el tamaño de la muestra n es mayor que 30 (n>30)

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

Cuando las muestras son pequeñas la varianza muestral puede variar considerablemente de muestra a muestra, por lo que la aproximación anterior no se considera válida. En estos casos, el intervalo confianza se puede construir recordando que la variable:

$$t = \frac{\bar{X}-\mu}{\frac{s}{\sqrt{n}}} \sim t(n-1)$$

sigue una distribución t de Student con n − 1 grados de libertad.



Por lo tanto, al ser la distribución t también simétrica, se puede expresar que

$$P(-t_{\alpha/2} \leq \frac{\bar{X}-\mu}{\frac{s}{\sqrt{n}}} \leq t_{\alpha/2}) = \alpha \rightarrow \; P(\bar{X} - t_{\alpha/2}\frac{s}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{\alpha/2}\frac{s}{\sqrt{n}})$$

Por lo tanto el intervalo de confianza que tendríamos que calcular en este caso sería:

$$\boldsymbol{IC(\mu) = \left[\bar{X} - t_{\frac{\alpha}{2}}\frac{s}{\sqrt{n}}, \bar{X} + t_{\alpha/2}\frac{s}{\sqrt{n}}\right]}$$

Donde $t_{\frac{\alpha}{2}}$ es la abscisa de la distribución t que deja a su derecha un área igual a α/2.

Nota :Esta expresión será además exacta y podrá utilizarse para calcular el intervalo de confianza para muestras grandes (n > 30).

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

Sin embargo, por las propiedades de la distribución t, esta distribución tiende a la normal al aumentar los grados de libertad, por lo que la expresión del principio de este apartado es suficientemente buena si n es grande.

Nota importante : Para calcular los intervalos de confianza para la media anteriores se ha supuesto que la población de partida sigue una distribución normal. Sin embargo, en virtud del teorema del límite central y según vimos anteriormente, la distribución muestral de la media tiende asintóticamente a la normal cualquiera que sea la población de partida. Esto quiere decir que, para muestras grandes de cualquier población (n>30), el intervalo de confianza para la media es aproximadamente:

$$IC(\mu) = \left[\overline{X} - z_{\frac{\alpha}{2}} \frac{s}{\sqrt{n}}, \overline{X} + z_{\alpha/2} \frac{s}{\sqrt{n}}\right]$$

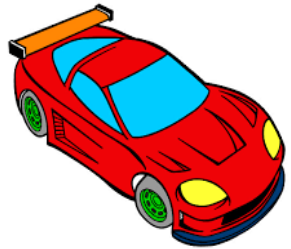
Para implementar en Python estas expresiones podemos obtenerlas manualmente calculando cada uno de los elementos que aparecen en la expresión o bien haciendo uso del módulo statsmodel. api (se importa como sm) y utilizar después la secuencia
sm. DescribeStatsW(*). tconfint_mean() o bien
sm. DescribeStatsW(*). zconfint_mean()

En * ponemos el DataFrame donde aparece la variable de la que Quiero hacer el cálculo

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

Ejemplo 1:
Se quería estimar la velocidad media en una calle con un límite teórico de 50km por hora. Con un radar oculto, se observó que la velocidad media de una muestra de 25 coches fue de 58km/hora. Si la desviación típica de la velocidad en esta calle es de 6km/hora, calcular un intervalo de 95 % de confianza para la verdadera velocidad media.

$$IC(\mu) = \left[\bar{X} - z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}},\ \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right] = [\bar{X} - error,\ \bar{X} + error]$$



Excel me permite calcular el error, que es la expresión señalada en rojo, usando la **función** INTERVALO.CONFIANZA.NORM y cumplimentando los argumentos que se piden teniendo en cuenta que 1- $\alpha = 1 - 0{,}95 = 0{,}05$ nos devuelve el valor del error obtenemos que Error= 2,352

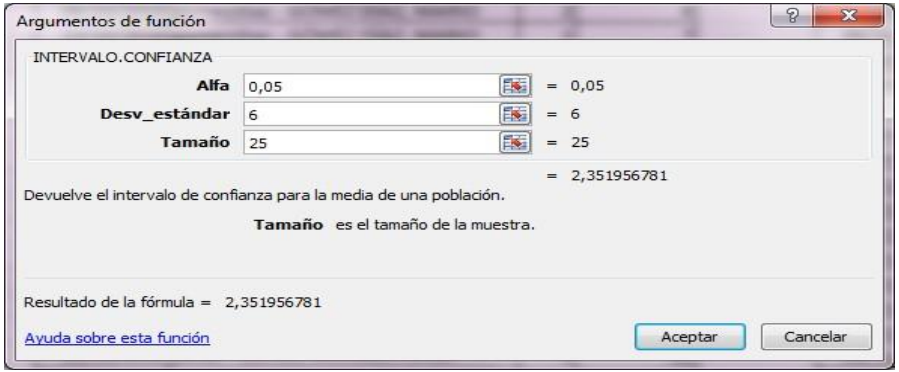
Por lo tanto el I.C pedido sería (58-2,352, 58+2,352)= (55,648 ;60,352)

Se estima que la verdadera velocidad media en esta calle es entre 55,65km/hora y 60,35km/hora.

Ejemplo 1 (continuación):

Se quería estimar la velocidad media en una calle con un límite teórico de 50km por hora. Con un radar oculto, se observó que la velocidad media de una muestra de 25 coches fue de 58km/hora. Si la desviación típica de la velocidad en esta calle es de 6km/hora, calcular un intervalo de 95 % de confianza para la verdadera velocidad media.

$$IC(\mu) = \left[\bar{X} - z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}},\ \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right] = [\bar{X} - error,\ \bar{X} + error]$$



El supuesto que se conoce la desviación típica de velocidades en la calle cuando no se conoce la media es poco realista en la práctica

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

Ejemplo 2:

Se quería estimar la velocidad media en una calle con un límite teórico de 50km por hora. Con un radar oculto, se observó que la velocidad media de una muestra de 25 coches fue de 58km/hora. Si la cuasi desviación típica de la velocidad en esta calle es de 6km/hora, calcular un intervalo de 95 % de confianza para la verdadera velocidad media.

En este caso, al desconocer la varianza poblacional usamos la desviación típica muestral. El tamaño es inferior a 30 por lo que tendremos que usar la función INTERVALO.CONFIANZA.T

$$IC(\mu) = \left[\bar{X} - t_{\frac{\alpha}{2}} \frac{s}{\sqrt{n}},\ \bar{X} + t_{\alpha/2} \frac{s}{\sqrt{n}}\right] = [\bar{X} - error,\ \bar{X} + error]$$

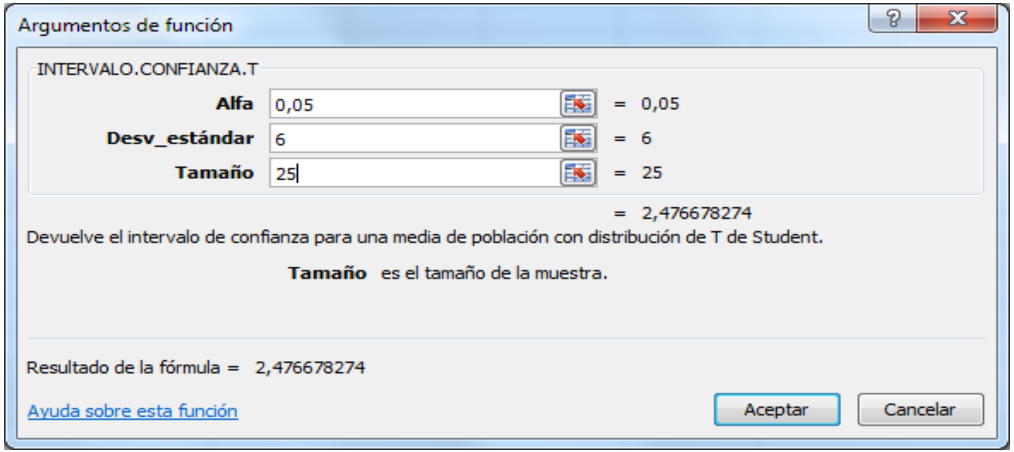
Excel me permite calcular el error, que es la expresión señalada en rojo, usando la **función** INTERVALO.CONFIANZA.T y cumplimentando los argumentos que se piden teniendo en cuenta que 1- $\alpha = 1 - 0{,}95 = 0{,}05$ nos devuelve el valor del error obtenemos que Error= 2,476

Por lo tanto el I.C pedido sería (58-2,476, 58+2,476)= (55,524 ;60,476)

.

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

De esta forma obtenemos un intervalo de confianza ligeramente más ancho que el del ejemplo 1 que el intervalo en el que conocíamos la desviación típica. En las versiones de Excel donde no aparece este comando, se realiza el cálculo a través de Análisis de datos> Estadística descriptiva.



INTERVALO DE CONFIANZA PARA LA PROPORCIÓN POBLACIONAL

Supongamos que tomamos una muestra aleatoria de tamaño n de una población y sea X la variable aleatoria que representa el número de individuos de la muestra con la característica de interés, evidentemente X seguirá una distribución binomial distribución binomial con parámetro desconocido p. Ya se ha visto como la proporción de éxitos $\hat{p}$ (número de éxitos dividido por el número de ensayos) constituye un buen estimador de p. Además, la distribución muestral del estadístico $\hat{p}$ puede aproximarse a la distribución normal cuando la muestra (o número de ensayos) es grande. Vimos que la distribución de $\hat{p}$ era un caso particular de la media y cuya media era p y cuya varianza era p(1-p)/n.

De forma análoga al apartado anterior tenemos: $P(-z_{\alpha/2} \leq \frac{\hat{p}-p}{\frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}}} \leq z_{\alpha/2}) = 1-\alpha$

Si desarrollamos tenemos que $P(\hat{p} - z_{\alpha/2}\frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}} \leq p \leq \hat{p} + z_{\alpha/2}\frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}})$=1 -α

Y por lo tanto $\boldsymbol{IC(p) = \left[\hat{p} - z_{\frac{\alpha}{2}}\frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}}, \hat{p} + z_{\alpha/2}\frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}}\right]}$

Nótese que en la varianza muestral se ha substituido p por $\hat{p}$, lo cual es una buena aproximación si la muestra es grande

Para muestras pequeñas (n < 30) la aproximación realizada de substituir la binomial por una normal es posible que no sea buena, especialmente si p se acerca a 0 o a 1. Como ya se explicó, cuando se cumpla que conjuntamente np > 5 y n(1 − p) > 5, la aproximación anterior es válida incluso para muestras pequeñas.

Nota complementaria: En control de calidad, el estadístico $\hat{p}$ corresponde a menudo a la fracción de disconformidades de un lote o proceso, siendo el número de disconformidades en el lote una variable Bi(n, p). Si se obtiene una muestra aleatoria de n observaciones y se encuentran x observaciones no conformes en tal muestra, entonces un estimador puntual insesgado de p es $\hat{p} = \mathrm{x}/\mathrm{n}$

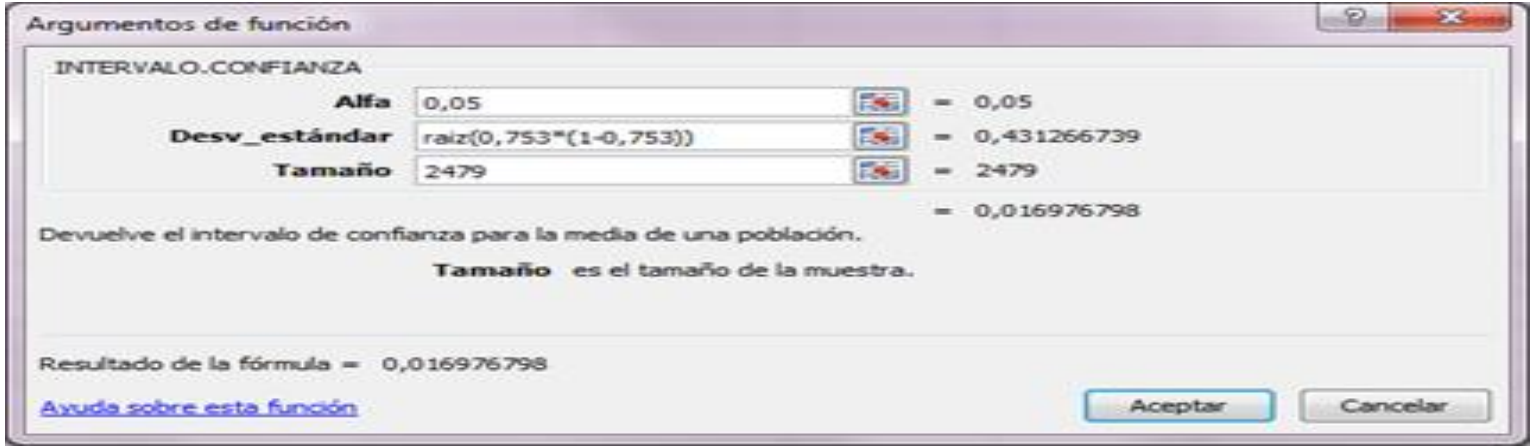
Ejemplo:

En la encuesta del CIS del abril de 2015, formulada a 2479 personas, un 75,3 % aprobaron el trabajo de la Guardia Civil. hallar un intervalo de 95 % de confianza para la verdadera proporción de españoles que aprueban el trabajo de la Guardia Civil.

En este ejercicio se desconoce la proporción p de personas que aprueban la actuación de la Guardia Civil. De las 2479 personas, un 75,3% aprobaba su gestión, por lo tanto tomamos como estimador puntual la proporción muestral $\hat{p}$=0.753. De la misma manera que usábamos el Excel para la obtener el error del intervalo de confianza de la media poblacional procedemos en este caso

El intervalo buscado será $IC(p) = \left[\hat{p} - z_{\frac{\alpha}{2}} \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}}, \hat{p} + z_{\alpha/2} \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}}\right] = [\hat{p} - error, \hat{p} + error]$

Usando la función INTERVALO.CONFIANZA.NORM y teniendo en cuenta que la varianza es p(1-p) tenemos que:



El intervalo buscado será $IC(p) = [\hat{p} - error, \hat{p} + error] = (0{,}753 - 0{,}017, 0753 + 0{,}017)$ = $(0, 736,\ 0, 770)$.

Se estima que entra un 73,6 % y un 77,0 % de la gente apoyan al trabajo de la Guardia Civil.

En Python usaremos un comando similar al de la media poblacional usando la misma librería stats sm.stats.proportion_confint(número éxitos, ensayos, nivel significación)

INTERVALO DE CONFIANZA PARA LA DIFERENCIA DE MEDIAS

Supongamos que se tienen dos poblaciones normales $N(\mu_1, \sigma_1)$ y $N(\mu_2, \sigma_2)$. Vamos a estudiar cómo se puede determinar un intervalo de confianza para la diferencia de medias $\mu_1 - \mu_2$ a partir de muestras aleatorias independientes de tamaños n_1 y n_2 extraídas de cada población respectivamente. Distinguiremos diferentes casos:

1)**Varianzas poblacionales conocidas σ_1^2, σ_2^2**

Ya se ha visto que un buen estimador puntual para la diferencia de medias es la diferencia de medias muestrales $\overline{x_1} - \overline{x_2}$. En esta distribución vimos que la media viene dada por $\mu_1 - \mu_2$ y la varianza por $\sigma_1^2 / n_1 + \sigma_2^2 / n_2$. Desarrollando de la misma manera que en los apartados anteriores llegamos a la expresión del intervalo de confianza

$$\overline{x_1} - \overline{x_2} \pm z_{\alpha/2}\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$$

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

INTERVALO DE CONFIANZA PARA LA DIFERENCIA DE MEDIAS

Supongamos que se tienen dos poblaciones normales $N(\mu_1, \sigma_1)$ y $N(\mu_2, \sigma_2)$. Vamos a estudiar cómo se puede determinar un intervalo de confianza para la diferencia de medias $\mu_1 - \mu_2$ a partir de muestras aleatorias independientes de tamaños n_1 y n_2 extraídas de cada población respectivamente. Distinguiremos diferentes casos:

1)**Varianzas poblacionales conocidas σ_1^2, σ_2^2**

Ya se ha visto que un buen estimador puntual para la diferencia de medias es la diferencia de medias muestrales $\overline{x_1} - \overline{x_2}$. En esta distribución vimos que la media viene dada por $\mu_1 - \mu_2$ y la varianza por $\sigma_1^2 / n_1 + \sigma_2^2 / n_2$. Desarrollando de la misma manera que en los apartados anteriores llegamos a la expresión del intervalo de confianza

$$\overline{x_1} - \overline{x_2} \pm z_{\alpha/2}\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$$

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

2)**Varianzas poblacionales desconocidas σ_1^2, σ_2^2 y $n_1 + n_2$>30 (con $n_1 \approx n_2$)**

Generalmente no se conocerán a priori los valores de las varianzas poblacionales. Sin embargo, cuando las muestras son grandes, ya se ha visto como las varianzas muestrales son generalmente una buena aproximación a las varianzas poblacionales. Por lo tanto, en este caso el intervalo de confianza para la diferencia de medias puede aproximarse

$$\overline{x_1} - \overline{x_2} \pm z_{\alpha/2}\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

Las aproximaciones anteriores son entonces válidas para muestras grandes. Para esto se usan diferentes criterios. **Algunos autores exigen que tanto n_1 > 30 como n_2 > 30. Aquí vamos a fijar el criterio de que $n_1 + n_2$ > 30, con la condición adicional de que ambos tamaños muestrales sean similares ($n_1 \approx n_2$)**

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

3)**Varianzas poblacionales desconocidas σ_1^2, σ_2^2 (muestras pequeñas) con $\sigma_1^2 = \sigma_2^2$**

Supongamos ahora el caso de que las muestras no son grandes, por lo que no se pueden aplicar las aproximaciones anteriores. Consideremos en primer lugar que se puede asegurar a priori que las dos varianzas poblacionales han de ser iguales $\sigma_1^2 = \sigma_2^2$, aunque con valor desconocido. En este caso se puede demostrar que el intervalo de confianza vendrá dado por

$$\overline{x_1} - \overline{x_2} \pm t_{\frac{\alpha}{2}, n1 + n2 - 2} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$$

donde $s_p = \frac{(n_1-1)s_1^2+(n_2-1)s_2^2}{n_1+n_2-1}$.

Al calcularse, s_p^2 representa una estimación puntual de la varianza común σ^2, calculándose como una media ponderada, con el número de grados de libertad, de las dos varianzas observadas. Hay que indicar que las relaciones anteriores siguen siendo una buena aproximación aun cuando existan algunas diferencias entre las varianzas poblacionales si los tamaños de las muestras son iguales.

Hay que indicar que las relaciones anteriores siguen siendo una buena aproximación aun cuando existan algunas diferencias entre las varianzas poblacionales si los tamaños de las muestras son iguales

4)**Varianzas poblacionales desconocidas σ_1^2, σ_2^2 (muestras pequeñas) con $\sigma_1^2 \neq \sigma_2^2$**

Veamos ahora el caso general en el que no se conocen las varianzas poblacionales, no se puede asumir que sean iguales y las muestras no son grandes. En este caso el intervalo de confianza vendrá dado por :

$$\overline{x_1} - \overline{x_2} \pm t_{\frac{\alpha}{2}, f} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

Como vemos la t-student que se usa en el intervalo de confianza tiene f grados de libertad, f es el entero más próximo a la aproximación de Welch

$$f = \frac{\left[\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right]^2}{\frac{\left(\frac{s_1^2}{n_1}\right)^2}{n_1 + 1} + \frac{\left(\frac{s_2^2}{n_2}\right)^2}{n_2 + 1}} - 2$$

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

Para calcular los intervalos de confianza anteriores se ha supuesto que las poblaciones de partida son normales. Como consecuencia del teorema del límite central, para cualesquiera distribuciones de partida la distribución muestral de la diferencia de medias puede aproximarse por una normal siempre que el tamaño de las muestras sea suficientemente grande. En consecuencia, las expresiones anteriores siguen siendo aplicable para distribuciones no normales y muestras grandes. Un caso particular de este resultado es el de la obtención del intervalo de confianza para la diferencia de parámetros $\widehat{p_1}$ y $\widehat{p_2}$ de dos distribuciones binomiales.

El intervalo de confianza siguiendo los apartados anteriores (por analogía) vendrá dado por :

$$\widehat{\boldsymbol{p_1}} - \widehat{\boldsymbol{p_2}} \pm \boldsymbol{z_{\alpha/2}} \sqrt{\frac{\widehat{\boldsymbol{p_1}}(\mathbf{1}-\widehat{\boldsymbol{p_1}})}{\mathbf{n_1}} + \frac{\widehat{\boldsymbol{p_2}}(\mathbf{1}-\widehat{\boldsymbol{p_2}})}{\mathbf{n_2}}}$$

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

Ejercicio:

En un proceso de control de calidad se intenta comparar la producción media de dos máquinas A y B. Para ello se realiza un seguimiento de ambas máquinas durante 100 días obteniéndose producciones medias de 12 y 9 unidades con varianzas muestrales (cuasivarianzas) de 6 y 4 respectivamente. Suponiendo normalidad en las producciones, se trata de comprobar si con una confianza del 95% se puede asegurar que las producciones medias de ambas máquinas son coincidentes o no

Para resolver este problema hallaremos un intervalo de confianza para la diferencia de producciones medias de ambas máquinas al 95% y comprobaremos si dicho intervalo contiene el valor cero. Estamos en el caso de diferencia de medias de dos distribuciones normales para varianzas desconocidas y tamaños muestrales mayores que 30

El intervalo de confianza era: $\overline{x_1} - \overline{x_2} \pm z_{\alpha/2}\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$

Sustituyendo $(12\text{-}9) \pm 1{,}96 * \sqrt{\frac{6}{100} + \frac{4}{100}} =$ [2,38 ; 3,62]

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

Como este intervalo no contiene el valor cero, no podemos aceptar con una probabilidad del 95% que las medias sean iguales. Por lo tanto tendremos que las producciones medias de las dos máquinas serán significativamente distintas. Además, como los dos extremos del intervalo son positivos, nos está indicando que la producción media es mayor en la máquina A que en la B con una probabilidad del 95%.



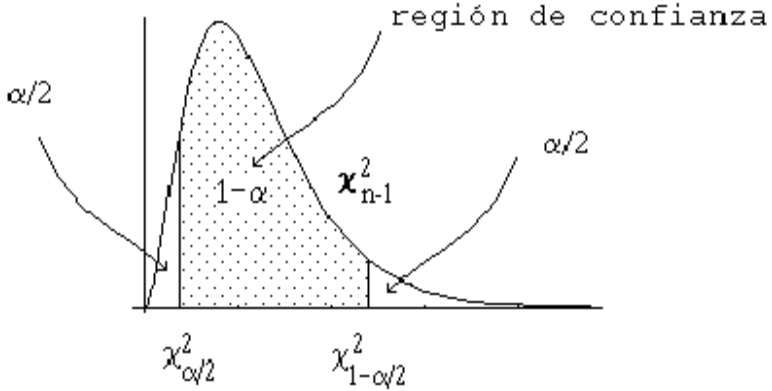
INTERVALO DE CONFIANZA PARA LA VARIANZA POBLACIONAL

A continuación se estudia cómo se puede calcular un intervalo de confianza para la varianza de una distribución normal que suponemos desconocida. Supongamos que se extrae una muestra de tamaño n sobre la que se calcula la varianza muestral S^2. Sabemos que el estadístico $(n-1)S^2/\sigma^2$ sigue una distribución χ_2 con $(n-1)$ grados de libertad.

A partir de un razonamiento teórico similar al que hemos visto en el principio del capítulo tenemos que:

$$P(\chi^2_{1-\frac{a}{2},n-1} < \frac{(n-1)s^2}{\sigma^2} < \chi^2_{\frac{a}{2},n-1}) = 1-\alpha$$

donde $\chi^2_{\frac{a}{2},n-1}$ es la abscisa de la distribución χ_2 con n−1 grados de libertad que deja a su derecha un área igual a α/2, y de manera similar para $\chi^2_{1-\frac{a}{2},n-1}$. Nótese que aunque la distribución de χ_2 no es simétrica, el intervalo se ha escogido para que el área de las dos colas sea igual a α/2.



Dividiendo cada término de la desigualdad por $(n-1)s^2$ e invirtiendo las desigualdades, se obtiene el intervalo de confianza para la varianza poblacional

$$\left[\frac{(n-1)s^2}{\chi^2_{\frac{a}{2},n-1}}, \frac{(n-1)s^2}{\chi^2_{1-\frac{a}{2},n-1}}\right].$$

Este intervalo no tiene porqué ser simétrico en torno a la varianza muestral.

De la misma manera, el intervalo de confianza para la desviación típica de una población normal puede escribirse como $\left[\sqrt{\frac{(n-1)s^2}{\chi^2_{\frac{a}{2},n-1}}}, \sqrt{\frac{(n-1)s^2}{\chi^2_{1-\frac{a}{2},n-1}}}\right]$

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

EJERCICIO:

Suponiendo que la producción de trigo por hectárea es una variable aleatoria con distribución normal, sabiendo que en 25 fincas elegidas al azar se produjeron de media 3200 kg por ha, y la desviación típica fue de 40 kg por ha, calcular un intervalo de confianza al 95% para la varianza.

Tenemos que $P(\chi^2_{1-\frac{a}{2},n-1} < \frac{(n-1)s^2}{\sigma^2} < \chi^2_{\frac{a}{2},n-1}) = 1-\alpha, \rightarrow P(\frac{(n-1)s^2}{k_1} < \sigma^2 < \frac{n-1)s^2}{k_2}) = 1-\alpha$



Buscaremos los valores de k_1 y k_2 tales que $P(\chi^2_{24} < k_1)=0.025$ y $P(\chi^2_{24} < k_2)=0.975$

Mirando las tablas tenemos que k_1=12,4011503y k_2= 39,3640771.

Estos valores pueden obtenerse con Excel con la función INV.CHICUAD (0,025;24) 12,4011503
Y INV.CHICUAD (0,975;24) 39,3640771
Sabiendo que n-1= 24 y que s^2=40²=1600 tenemos que el intervalo de confianza para la varianza poblacional será(975,508709, 3096, 48695)

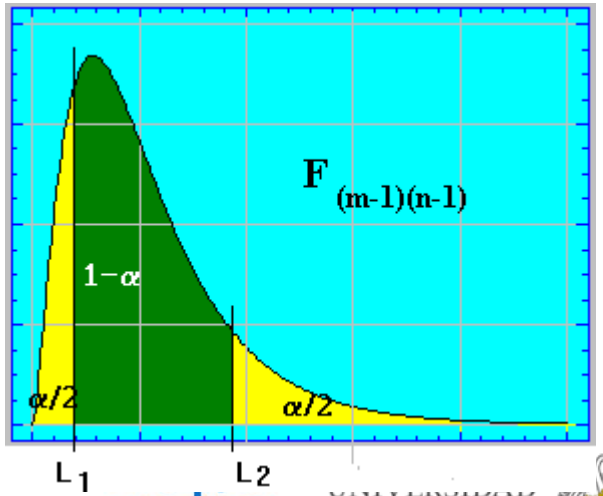
Recordad que en Python hay que utilizar el comando ppf(x) - Función inversa a cdf(x), que nos daba la función de distribución. Nos permite obtener el valor correspondiente a una probabilidad.

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

INTERVALO DE CONFIANZA PARA LA RAZÓN DE VARIANZAS

Supongamos que tenemos dos poblaciones normales independientes con varianzas poblacionales σ_1^2, σ_2^2 respectivamente. Sean s_1^2, s_2^2 las varianzas muestrales medidas en una muestra aleatoria extraída de cada población de tamaños n_1 y n_2 respectivamente. Teniendo en cuenta que $F = \frac{\frac{s_1^2}{\sigma_1^2}}{\frac{s_2^2}{\sigma_2^2}} \sim F(n_1 - 1, n_2 - 1)$ llegamos a la expresión del intervalo de confianza para la razón de varianzas.

$$\frac{S_1^2}{S_2^2} F_{\frac{\propto}{2}(n_{2-1:}n_{1-1})} < \frac{\sigma_1^2}{\sigma_2^2} < \frac{S_1^2}{S_2^2} F_{1-\frac{\propto}{2}(n_{2-1:}n_{1-1})}$$



ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

INTERVALO DE CONFIANZA PARA DATOS EMPAREJADOS

En los apartados anteriores siempre que se ha trabajado con dos poblaciones se ha supuesto que éstas eran independientes. Pero éste no es siempre el caso. Vamos a suponer ahora que se tienen dos poblaciones normales $N(\mu_1,\sigma_1^2)$ y $N(\mu_2,\sigma_2^2)$ de las que se extraen dos muestras que no son independientes. Nos vamos a restringir al caso en el cual los tamaños n de ambas muestras son iguales entre si. Típicamente consideraremos la situación en la cual las muestras no se extraen de forma independiente de cada población, sino **que cada muestra consiste en la medida de una característica en los mismos elementos de una población**. Por ejemplo, supongamos que sobre los elementos de una muestra se mide cierta variable, después se aplica un determinado tratamiento a la muestra y, sobre los mismos elementos, se vuelve a medir la misma variable (ej. temperatura antes y después de aplicar un tratamiento). A este tipo de experimentos se le llama de observaciones **pareadas o emparejadas**.

El objetivo en este caso es calcular un intervalo de confianza para la diferencia de medias $\mu_1 - \mu_2$ en dichas muestras. Para ello se consideran las diferencias $d_i = x_{1i} - x_{2i}$ (i = 1, 2,...,n) entre los valores de las variables en cada uno de los elementos de la muestra. Para plantear el problema se asume que estas diferencias son los valores de una nueva variable aleatoria D.

ntic master
revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

Si n>30 el intervalo de confianza vendrá dado por

$$\overline{D} - z_{\frac{\alpha}{2}} \frac{s_D}{\sqrt{n}}, \overline{D} + z_{\frac{\alpha}{2}} \frac{s_D}{\sqrt{n}}$$

Si la muestra es más pequeña el intervalo será $\overline{D} - t_{\frac{\alpha}{2}} \frac{s_D}{\sqrt{n}}, \overline{D} + t_{\frac{\alpha}{2}} \frac{s_D}{\sqrt{n}}$ con n-1 grados de libertad

Ejemplo:

Se aplica un proceso para aumentar el rendimiento en 10 fábricas muy diferentes (no dejar tomarse el bocadillo a media mañana). Los rendimientos (en ciertas unidades, como toneladas/día) antes y después son:

Antes	13	22	4	10	63	18	34	6	19	43
Después	15	22	2	15	65	17	30	12	20	42

Si obtenemos las diferencias tenemos la serie : Di = 2, 0, -2, 5, 2, -1, -4, 6, 1, -1

A partir de aquí se calcula la media 0.8 y la desviación típica de esta serie de datos 3,08.

Buscamos ahora el valor $t_{0.025,9} = 2{,}262$

Sustituyendo tenemos el intervalo de confianza (−1.4,3.0)

DETERMINACIÓN DEL TAMAÑO DE LA MUESTRA

Hasta ahora siempre se ha supuesto conocido el tamaño de la muestra n. Sin embargo, y fundamentalmente en el diseño de experimentos, en ocasiones el problema principal es la determinación del tamaño muestral requerido para obtener la estimación de los parámetros poblacionales con una determinada precisión. Nótese que una muestra demasiado grande puede traducirse en una perdida de tiempo y dinero, mientras que, si la muestra es demasiado pequeña, no se obtendrá la fiabilidad deseada y el experimento será un fracaso. Por lo tanto, determinar el tamaño muestral es un problema muy habitual y práctico.

La precisión de una estimación por intervalos de confianza vendrá marcada por la longitud del intervalo (en ocasiones, llamada error). Para ilustrar el problema supongamos que tenemos una distribución normal y que queremos determinar la media poblacional μ a partir de la media muestral . El intervalo de confianza vendrá entonces dado por: $\bar{X} - z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$

Y la longitud del intervalo o amplitud será A= 2* $z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$

Es decir, la longitud del intervalo es inversamente proporcional al tamaño de la muestra y la precisión aumenta, por tanto, al aumentar n.

El problema se plantea entonces en cómo calcular el tamaño de la muestra n para estimar la media poblacional con una cierta precisión, es decir, para que la diferencia entre la media poblacional y muestral sea, en valor absoluto y con un cierto nivel de confianza (1 − α).

Si llamamos error a la semiamplitud del intervalo tenemos que E= $z_{\alpha/2}\ \frac{\sigma}{\sqrt{n}}$ y de esta expresión podemos despejar la n , fijada una cierta precisión

$$\boldsymbol{n = \left(\frac{z_{\alpha/2} * \sigma}{E}\right)^2}$$

Para poder aplicar la expresión anterior es necesario conocer previamente σ. Si éste no es el caso, en la práctica se toma una muestra piloto pequeña (aunque es deseable que n > 30) para poder estimar σ mediante la desviación típica muestral S.



ntic master
revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID