7

Contrastes de hipótesis no paramétricos

En este capítulo estudiaremos diferentes tipos de contrastes en los cuales la hipótesis nula no es un parámetro. Existen muchos tipos de contrastes no paramétricos, nos centraremos en aquellos que estudian si nuestros datos se ajustan a una determinada distribución (en general a una normalidad) y los contrastes de independencia, que estudian si nuestras muestras pueden considerarse independientes.

INTRODUCCIÓN

En los temas anteriores nos hemos ocupado de los contrastes de hipótesis sobre los parámetros poblacionales. Para poderlos hacer hemos supuesto ciertas condiciones sobre la muestra, como que era aleatoria y provenía de una población que seguía una determinada distribución.

Ahora vamos a plantear algunos métodos (hay una gran variedad) para comprobar que una muestra dada cumple estas suposiciones. Contrastan hipótesis que no son afirmaciones sobre parámetros y no dependen de la forma de la distribución poblacional (por eso también se llaman de distribución libre).
En particular, se estudiarán tests de hipótesis para comprobar si la distribución supuesta es consistente con la muestra (normalmente si una muestra procede de una población normal), si diferentes muestras pueden considerarse homogéneas y si las observaciones de dos factores o parámetros de una misma población son independientes. Todos estos tests se basan en un procedimiento común consistente en la aplicación de la distribución ji- cuadrado χ^2.

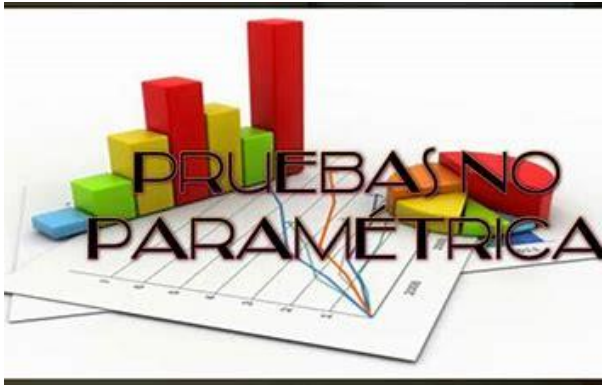
Algunas características de las técnicas no paramétricas (ventajas y desventajas)
- Son menos restrictivas sobre la población
- La distribución de determinados estadísticos es determinable independientemente de cual sea la distribución de de la población (distribuciones libres)

 Pueden no intervenir los valores muestrales de la variable, bastará conocer el orden de las observaciones, e incluso en algún contraste tan solo el número de observaciones que hay en cada categoría.

 No se estiman parámetros de una cierta familia, sino características estocásticas de una distribución general (tests no paramétricos)

 Son menos potentes que los correspondientes paramétricos si se dan las condiciones para aplicarlo

- ❑ Se pueden usar para variables en donde las mediciones se realizan de forma cualitativa (clasificando caracteres cualitativos)
- ❑ Presentan cálculos fáciles, originados por tamaños de muestra pequeños.



CONTRASTES DE LA BONDAD DE AJUSTE: TEST DE LA CHI-CUADRADO

Este tipo de tests tratan de contrastar si a partir de los datos obtenidos en una muestra puede deducirse o no que proceden de una población con una distribución determinada. Entre ellos destaca el contraste de ji-cuadrado de la bondad de ajuste que describimos a continuación.

Supongamos que de nuestra población tomamos una muestra aleatoria de tamaño n de una cierta variable y que desconocemos la función (de probabilidad o de densidad) de nuestra población, es decir el modelo de distribución de probabilidad poblacional. Puede ocurrir que los parámetros poblacionales sean o no conocidos.

Los intervalos de confianza y los contrastes de hipótesis sobre parámetros poblacionales o técnicas estadísticas se basan en suponer que la población sigue una determinada distribución de probabilidad (normal, en muchos casos). Puesto que las conclusiones de dichos contrastes dependen de la elección de la distribución teórica, es importante determinar si dicha hipótesis puede ser correcta. Evidentemente, al trabajar con una muestra de una población, siempre existirán diferencias entre la distribución teórica y la observada. Sin embargo, habrá que comprobar si dichas desviaciones pueden ser debidas al azar o, por el contrario, proporcionan evidencias de que la distribución supuesta es incorrecta.

Para elaborar el estadístico adecuado, supongamos que tenemos una muestra de tamaño n y que la variable aleatoria X puede tomar los valores X_1, X_2,...,X_k excluyentes. Esto en principio sólo sería válido para una variable discreta, sin embargo se puede aplicar también a una variable continua realizando un agrupamiento en intervalos.

Sean O_i las frecuencias observadas para cada X_i, es decir, el número de elementos de la muestra con $X = X_i$. Si se supone una distribución de probabilidad teórica, existirá una probabilidad p_i de que X tome un determinado valor X_i. Por lo tanto, las frecuencias esperadas para cada X_i serán $E_i = np_i$. Nótese que ha de cumplirse que $\sum_{i=1}^{k} O_I = \sum_{i=1}^{k} E_i$=n y además $\sum_{i=1}^{k} p_i$=1.

Podemos escribir la siguiente tabla:

X	X_1	X_2	X_3	…….	X_{K-1}	X_k
Frecuencia observada	O_1	O_2	O_3		O_{k-1}	O_k
Frecuencia teórica	E_1	E_2	E_3		E_{k-1}	E_k

A continuación se formula la hipótesis nula H_0 consistente en suponer que la muestra sigue la distribución teórica elegida y, por tanto, las desviaciones encontradas respecto a ésta son debidas al azar. La hipótesis alternativa (que puede no formularse) será que esto no ocurre.

Para poder realizar el contraste de hipótesis, una vez definidas la hipótesis nula y alternativa, definiremos el estadístico de contraste

$$\sum_{i=1}^{k} \frac{(O_i - E_i)^2}{E_i} = \sum_{i=1}^{k} \frac{O_i^2}{E_i^2} - n \quad (*)$$

Puede demostrarse que este estadístico sigue una distribución ji-cuadrado χ^2 con k-1 grados de libertad. $\sum_{i=1}^{k} \frac{(O_i - E_i)^2}{E_i} \sim \chi^2(k-1)$ siempre que Ho sea cierta (Bajo el supuesto de Ho, el estadístico seguirá esa distribución de probabilidad)

Evidentemente, si las frecuencias observadas se acercan a las esperadas se obtendrá un valor bajo de χ^2 y la hipótesis nula (la muestra sigue la distribución teórica) se debe aceptar. Por el contrario, cuando existan considerables diferencias entre las frecuencias observadas y esperadas, el valor de χ^2 será grande y el ajuste será pobre, rechazándose H_0.

Por ello, fijado el nivel de significación α buscamos en las tablas de chi-cuadrado un valor k tal que la probabilidad $P(\chi^2(k-1) > k) = \alpha$ y si el valor del estadístico (*) es mayor que k , entonces rechazaremos la hipótesis nula de que la muestra proviene de la población indicada. Si el valor del estadístico χ^2 es menor que k, entonces aceptamos Ho , y aseguramos que la muestra proviene de la población indicada.

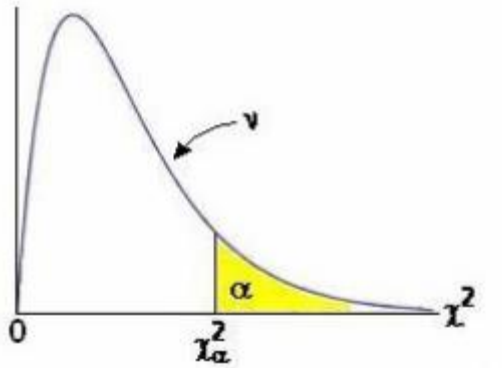
La región crítica cae entonces en la cola derecha de la distribución y, para un nivel de significación α, se rechazará Ho si

$$\sum_{i=1}^{k} \frac{(O_i - E_i)^2}{E_i} > \chi^2_{\alpha,k-1}$$

Para poder aplicar este método correctamente es necesario que el tamaño de la muestra sea suficientemente grande (típicamente n > 30). En particular, se suele poner la restricción de que las frecuencias esperadas para cada X_i (o intervalo) no sean inferiores a 5 ($e_i \geq 5$). Cuando no se cumpla esto habrá que agrupar diferentes valores de X_i (o intervalos) para que se verifique la condición. Evidentemente, ello reduce el número de grados de libertad.

Otra consideración importante es que, si para calcular las frecuencias esperadas hay que usar **parámetros poblacionales estimados a partir de la propia muestra porque son desconocidos** (ej. media y varianza para la distribución normal), el número de grados de libertad de la χ^2 hay que reducirlo a k − p − 1, donde p es el número de parámetros poblacionales que se estiman (nótese que esto no se aplica si los parámetros poblacionales se conocen, o se suponen, a priori, sin estimarlos a partir de los datos muestrales). Esta prueba de la bondad del ajuste es una herramienta muy importante debido, fundamentalmente, a que muchos procedimientos estadísticos dependen de la suposición de una determinada distribución de probabilidad.

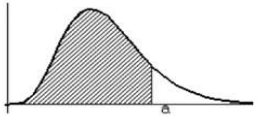
En particular, es importante para comprobar la suposición de normalidad para la población, aunque puede aplicarse en general para cualquier distribución.



Región de rechazo de Ho

La Distribución χ^2

- Cálculo de probabilidades de la X^2



PERCENTILES DE LA DISTRIBUCIÓN χ^2

F(a) = P (X ≤ a)

n	*0,995*	*0,99*	*0,975*	*0,95*	*0,9*	*0,75*	*0,5*	*0,25*	*0,05*	*0,025*	*0,01*	*0,005*
1	7,879	6,635	5,024	3,841	2,706	1,323	0,455	0,102	0,004	0,001	0,000	0,000
2	10,597	9,210	7,378	5,991	4,605	2,773	1,386	0,575	0,103	0,051	0,020	0,010
3	12,838	11,345	9,348	7,815	6,251	4,108	2,366	1,213	0,352	0,216	0,115	0,072
4	14,860	13,277	11,143	9,488	7,779	5,385	3,357	1,923	0,711	0,484	0,297	0,207
5	16,750	15,086	12,833	11,070	9,236	6,626	4,351	2,675	1,145	0,831	0,554	0,412
6	18,548	16,812	14,449	12,592	10,645	7,841	5,348	3,455	1,635	1,237	0,872	0,676
7	20,278	18,475	16,013	14,067	12,017	9,037	6,346	4,255	2,167	1,690	1,239	0,989
8	21,955	20,090	17,535	15,507	13,362	10,219	7,344	5,071	2,733	2,180	1,646	1,344
9	23,589	21,666	19,023	16,919	14,684	11,389	8,343	5,899	3,325	2,700	2,088	1,735
10	25,188	23,209	20,483	18,307	15,987	12,549	9,342	6,737	3,940	3,247	2,558	2,156
11	26,757	24,725	21,920	19,675	17,275	13,701	10,341	7,584	4,575	3,816	3,053	2,603
12	28,300	26,217	23,337	21,026	18,549	14,845	11,340	8,438	5,226	4,404	3,571	3,074

Ejemplo de aplicación:

Vamos a considerar como ejemplo el lanzamiento de un dado. Queremos saber si el dado esta equilibrado o está cargado (es decir, trucado)

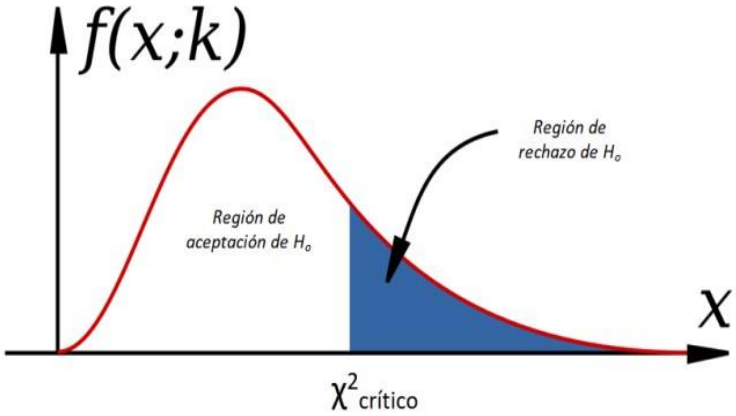
En este caso la $P(x_i)= 1/6$ siendo i= 1,2,3,4,5,6. Por lo tanto la distribución teórica sería uniforme.

Se lanza el dado 600 veces y se obtiene la siguiente tabla. Evidentemente la frecuencia teórica de cada resultado sería 100 (1/6 * 600)

X_i	1	2	3	4	5	6
F. Observada O_i	92	85	102	94	117	110
F.Teórica E_i	100	100	100	100	100	100

El número de grados de libertad será 5 (k=6-1) y el valor del estadístico será $\sum_{i=1}^{6} \frac{(O_i-E_i)^2}{E_i}$ =7,18, si tomamos como nivel de significación α de 0,05 buscamos en la tabla el valor de la $\chi^2(5)$ *y* con ese nivel de significación. Mirando en la tabla ese valor es 11.070

Mirando en la tabla ese valor es 11.070 (ver tabla diapositiva) , por lo tanto el valor observado es menor que el valor crítico , por lo tanto no rechazaremos H_0 y podremos afirmar que el dado esta equilibrado y la distribución de la tabla corresponde a una distribución uniforme (las diferencias pueden ser debidas al azar)





TEST DE KOLMOGOROV- SMIRNOV DE LA BONDAD DE AJUSTE

El contraste de Kolmogorov- Smirnov es un test para bondad de ajuste alternativo al chi-cuadrado. Con él se compara una distribución teórica de la población, representada por la variable aleatoria X que deberá ser de tipo continuo, con la distribución empírica de la muestra, extraída por un procedimiento de muestreo aleatorio simple . El contraste a estudiar será:

Ho : X se distribuye según la distribución de probabilidad continua con función de distribución F(x)
H1: Su función de distribución no es F(x)

El contraste de Kolmogorov-Smirnov se aplica **solo a variables continuas** y trata de medir el ajuste entre la función de distribución empírica de una muestra y la función de distribución teórica.

Para elaborar el estadístico de contraste se deberá, ordenar los valores muestrales de menor a mayor. A continuación se obtiene la **función de distribución empírica de la muestra** formada por las frecuencias relativas acumuladas. Esta función vendrá dada por :

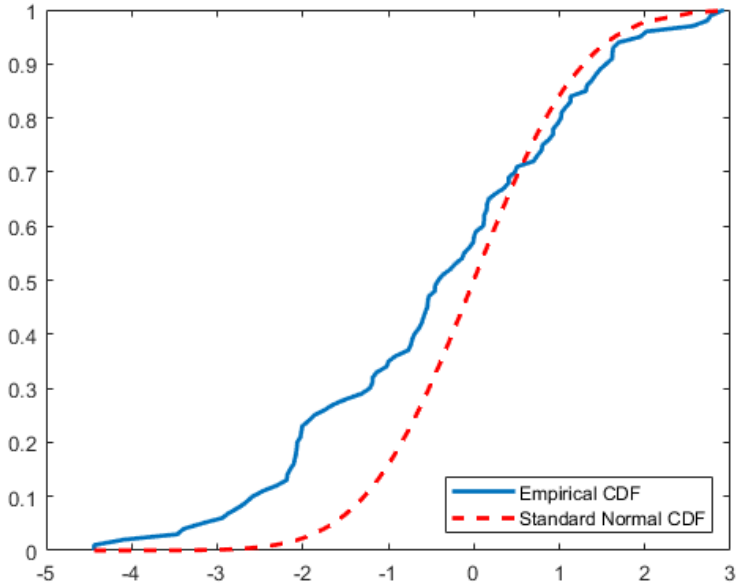
$$F_n(x) = \frac{nº\ de\ valores\ del\ conjunto\ \{x_1, x_2, \dots \dots . x_n]}{n}$$

Estos valores serán los que se compararán con los que determine la función de distribución teórica definida por F(x)= P(X<x) y que se calculará sobre cada valor de la muestra.
El estadístico del contraste Kolmogorov-Smirnov, que mide la discrepancia entre la distribución de la muestra y la teórica se define como:

$$D_n = máx|F_n(x) - F(x)|$$ F_n distribución empírica

cuya distribución es conocida y tabulada. Si la distancia D_n es mayor que la encontrada en las tablas , para un nivel de significación α, rechazamos la distribución F(x) para la muestra.

Por lo tanto para un n y un α , hallamos D(α, n) tal que P(D_n> D(α, n) = α . La región crítica del test será D_n> D(α, n)
Este contraste tiene la ventaja de que no requiere agrupar los datos y el inconveniente de que si calculamos F(x) estimando parámetros de la población, mediante la muestra, la distribución de D_n , es solo aproximada.
Normalmente se usa el estadístico $\sqrt{n}\ D_n$ en vez de D_n , lo que nos permite contrastar tablas para tamaños muestrales muy grandes.



Se puede utilizar para este contraste (como para todos) el criterio del p-valor rechazando Ho si p-valor es menor que α y aceptándola en caso contrario.

Tendremos en cuenta las siguientes consideraciones:

- Este test es más fácil de aplicar que el test ji-cuadrado
- No se ve afectado por reagrupaciones de observaciones, mientras que en χ^2, al disminuir los grupos, se pierde información, así como grados de libertad
- Es aplicable a pequeñas muestras, el χ^2 estaba diseñado para grandes muestras
- La potencia del test K-S es mayor que la del χ^2, si bien tienden a igualarse cuando el tamaño de la muestra crece
- El test χ^2 puede fácilmente ser modificado si hay parámetros desconocidos, mientras que el test K-S no tiene tal flexibilidad
- El test de χ^2 es aplicable cuando la población es discreta o continua y el test K-S requiere la continuidad de F(x)

Prueba de Kolmogorov-Smirnov para una muestra

		t
N		10
Parámetros normales[a,,b]	Media	2,30
	Desviación típica	1,494
Diferencias más extremas	Absoluta	,180
	Positiva	,180
	Negativa	-,120
Z de Kolmogorov-Smirnov		,568
Sig. asintót. (bilateral)		,904

a. La distribución de contraste es la Normal.

b. Se han calculado a partir de los datos.

Los contrastes de normalidad son un caso particular de contraste de ajuste, donde se trata de comprobar si los datos provienen de una distribución normal. Además de los contrastes que hemos visto, que sirven para hacer ajustes a cualquier distribución (incluida la normal) existen otros contrastes específicos para la normalidad como Shapiro-Wilks y los contrastes Z de asimétria y curtosis.

El contraste de Shapiro y Wilks, por ejemplo, mide el ajuste de la muestra a una recta al dibujarla en un papel probabilístico normal. Se rechaza la normalidad cuando el ajuste es bajo, que corresponde a valores pequeños del estadístico del test. x(i) el valor ordenado en la muestra que ocupa el lugar i, los coeficientes a_i

$$W = \frac{\left(\sum_{i=1}^{n} a_i x_{(i)}\right)^2}{\sum_{i=1}^{n}(x_i - \overline{x})^2}$$

La distribución de w está tabulada y se rechaza la normalidad cuando su valor calculado a partir de la muestra es menor que el correspondiente valor crítico dado en las tablas. También puede recurrirse al p-valor

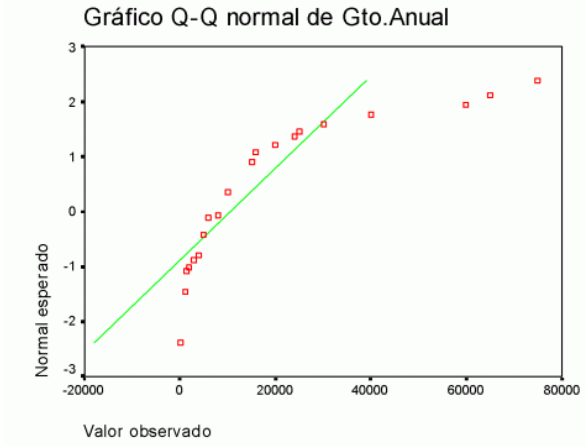
Tests of Normality[b]

	Kolmogorov-Smirnov[a]			Shapiro-Wilk		
	Statistic	df	Sig.	Statistic	df	Sig.
Int_Politics	.178	10	.200*	.944	10	.599

a. Lilliefors Significance Correction

*. This is a lower bound of the true significance.

b. Gender = Male, Edu_Level = School



ntic master
revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

CONTRASTES DE ALEATORIEDAD: CONTRASTE DE RACHAS

El contraste de rachas es un test para contrastar la aleatoriedad de una muestra basándose en el número de rachas observadas en la misma. La hipótesis nula a contrastar con este test es si la muestra es aleatoria. Que una muestra sea aleatoria tiene una gran importancia en Estadística, ya que si la muestra es aleatoria, las conclusiones pueden extenderse a toda la población (inferencia).

La prueba que vamos a ver se basa en el número de “rachas” que presenta la muestra; por lo tanto lo primero será definir que es una “racha”.

Racha: es el conjunto de elementos de la muestra, consecutivos, que presentan una determinada característica, limitados por elementos con características distintas
Por ejemplo, lanzamos un dado y anotamos 2 cuando sale par y 1 cuando sale impar.

2 2 1 1 1 2 1 1 1 1 2 2 1 2

A continuación los agrupamos en rachas, contando los elementos con características idénticas

2 2 /1 1 1/ 2 /1 1 1 1/ 2 2/ 1/ 2

Vemos que el número de rachas ***R***, es 7

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

El número total de rachas de una muestra de cualquier tamaño nos indica si la muestra es aleatoria o no es aleatoria. Un número muy bajo o por el contrario, muy alto de rachas nos pueden hacer sospechar sobre si la muestra es aleatoria o no. Por ejemplo, lanzamos una moneda 20 veces y anotamos C si es cara y + si es cruz.

C C C C C C C C C C / + + + + + + + + + +

El número de rachas es 2 lo que lleva a sospechar sobre la “legalidad” de la moneda. Ahora bien si ocurre lo siguiente:

C / + / C / + /C / + /C / +/ C / + /C / +/ C / + / C / + / C /+ / C /+

Ahora, el número de rachas es 20, que también resulta sospechoso por ser muy alto.

La distribución muestral de los valores de ***R*** que podemos esperar de muestras aleatorias es conocida. Usando esta distribución, podemos saber cuándo una muestra tiene más o menos rachas de las que probablemente ocurrirían en una muestra aleatoria

Una cuestión queda por añadir antes de pasar a ver la forma de realizar el contraste. ¿Cómo definimos las rachas cuando tenemos variables continuas como por ejemplo estatura o peso? ¿Cuál es la característica que presentan los elementos muestrales para en función de ella definir las rachas? Para contestar a esta pregunta se han propuesto distintas formas de contestar a esta cuestión. En nuestro caso haremos lo siguiente: calcularemos la MEDIANA y en función de ella veremos si los elementos muestrales, en el orden que aparecen en la muestra, es tán por encima o por debajo de la mediana. De esta manera definiremos y contaremos lasrachas.

Ejemplo: Supongamos que tomamos una muestra de 12 alumnos y a cada uno de ellos le preguntamos su altura en cm. La muestra resultante podría ser:

178, 162, 164, 188, 180, 158, 161, 159, 179, 180, 157, 160

El primer paso será calcular la mediana. En este caso la mediana es 163. Utilizando este valor definimos las rachas. **178** / 162 / **164 188 180** / 158 161 159 / **179 180** / 157 160

Como puede comprobarse tenemos 6 rachas.

Ahora ya sabemos cómo definir las rachas en cualquier caso, por tanto vamos a ver la forma de elaborar el contraste.

Contraste : Ho: La muestra es aleatoria H1: La muestra no es aleatoria

Método

Sea n_1 el número de elementos de una clase, y n_2 el número de elementos de la otra; en nuestro último ejemplo n_1 sería el número de alumnos cuya altura está por encima de la mediana, y n_2 el número de alumnos cuya altura está por debajo de la mediana. Sea N el número total de eventos observados; $N = n_1 + n_2$

Muestras Pequeñas

Si tanto n_1 como n_2 son iguales o menores que 20, utilizaremos una tabla con los valores críticos de ***R*** bajo la H_0 (suponer que la muestra es aleatoria) considerando α = 0,05. Son los valores críticos de la distribución muestral: Si el valor observado de ***R*** está entre los valores críticos, no se rechaza la hipótesis nula; esto es se acepta que **la muestra es aleatoria**. Si el valor observado de ***R*** es igual o más extremo que uno de los valores críticos, se rechaza H_0.

Muestras Grandes

Si n_1 o n_2 es mayor que 20, bajo Ho , R se aproxima una aproximación a la distribución normal, con

Media R= $\frac{2n_1n_2}{n}+1$ Desviación típica R = $\sqrt{\frac{2n_1n_2(2n_1n_2-n)}{n^2(n-1)}}$ donde n= $n_1 + n_2$

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

Por lo tanto si definimos $Z = \frac{R - \frac{2n_1n_2}{n} + 1}{\sqrt{\frac{2n_1n_2(2n_1n_2 - n)}{n^2(n-1)}}} \sim N(0,1)$

La región critica para el contraste bilateral serán los |z|> $z_{\alpha/2}$



También se puede utilizar el criterio del p-valor, rechazando la hipótesis nula al nivel α cuando el p-valor es menor que α , y aceptándola en caso contrario

Cuando existen variaciones de naturaleza cíclica en las observaciones, el test de rachas (Wald-Wolfowitz) no es eficiente y será necesario utilizar otros alternativos, como el test del cuadrado medio de diferencias sucesivas para detectar la aleatoriedad

Ejemplo:

Se trata de descubrir el carácter ordenado o aleatorio de la colocación de hombres y mujeres en la cola frente a la taquilla de un cine.
El orden actual es: H /M /H/ /M/ H H H/ M M/ H/ M/ H/ M/ H/ M/ H H H H /M /H/ M/ H /M/ H H / M M M / H / M / H / M / H / M / H H / M / H H / M / H H H H / M / H / M / H H

Hipótesis nula H_0 : la serie de hombres y mujeres están colocados en la cola al azar.
Hipótesis alternativa H_1 : la serie de hombres y mujeres no están colocados al azar.

Contraste:Se utiliza la prueba de rachas porque la hipótesis está referida a la aleatoriedad de un solo grupo de elementos. Nivel de significación 5% .La muestra es de $\boldsymbol{n_1}$ = 30 hombres y $\boldsymbol{n_2}$ = 20 mujeres. Encontramos que ***R* = 35** (númerode rachas)

Distribución muestral. Se trata de una muestra grande, por lo que podremos utilizar la aproximación a la normal que hemos visto anteriormente.
Región crítica. $\boldsymbol{H_1}$ no informa sobre la dirección de la desviación respecto al azar, por lotanto, se usa una región crítica de dos colas.

Calculamos el valor de $Z = \dfrac{R_o - \frac{2n_1n_2}{n} + 1}{\sqrt{\frac{2n_1n_2(2n_1n_2 - n)}{n^2(n-1)}}}$

Si sustiimos Ro por 35 n_1 por 30 y n_2 por 20 tenemos que Z= 2,98
Para un nivel de significación del 5% sabemos que el valor crítico en el contraste bilateral es 1,96

Como el valor del estadístico utilizado para realizar el contraste 2,98 > 1,96 que es el valor que en las tablas de la Normal (0,1) nos deja a los dos lados el 5 % de significación se **rechaza** la hipótesis nula, concluyendo que la fila frente al cine no tenía un orden aleatorio.



CONTRASTES DE INDEPENDENCIA: CONTRASTE CHI-CUADRADO

Un problema usual en las ciencias experimentales es el estudio de la dependencia o independencia entre dos caracteres o factores medidos sobre los elementos de una población (ej. entre peso y altura para una muestra de individuos). Además, a menudo hemos hecho la hipótesis de independencia para derivar expresiones simplificadas respecto a la estimación de parámetros poblacionales. Es importante contar con un método para contrastar dicha hipótesis. Para ello se puede seguir un procedimiento similar al de la prueba de la bondad del ajuste, basado en la distribución χ^2

Supongamos que sobre una muestra de tamaño n de una población se miden dos caracteres dados por las variables aleatorias X e Y , que pueden tomar los valores x_1, x_2,...,x_k e y_1, y_2,...,y_m. Estos valores particulares pueden representar a una **variable cualitativa, discreta o continua** agrupada en intervalos. Denotaremos por n_{ij} a la frecuencia o número de elementos de la muestra que tienen conjuntamente $X = x_i$ e $Y = y_j$. Las frecuencias observadas se presentan usualmente en una tabla, llamada **tabla de contingencia**. Para el caso de k valores posibles para X y m valores posibles para Y , la tabla de contingencia k × m será:

Agrupando frecuencias observadas y esperadas en la TABLA DE CONTINGENCIA k x m

X \ Y	y_1	y_2	...	y_j	...	y_m	$\sum_{i=1}^{k} n_{i\bullet}$
x_1	n_{11} (e_{11})	n_{12} (e_{12})	...	n_{1j} (e_{1j})	...	n_{1m} (e_{1m})	$n_{1\bullet}$
x_2	n_{21} (e_{21})	n_{22} (e_{22})	...	n_{2j} (e_{2j})	... ...	n_{2m} (e_{2m})	$n_{2\bullet}$
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
x_i	n_{i1} (e_{i1})	n_{i2} (e_{i2})	...	n_{ij} (e_{ij})	...	n_{im} (e_{im})	$n_{i\bullet}$
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
x_k	n_{k1} (e_{k1})	n_{k2} (e_{k2})	...	n_{kj} (e_{kj})	...	n_{km} (e_{km})	$n_{k\bullet}$
$\sum_{j=1}^{m} n_{\bullet j}$	$n_{\bullet 1}$	$n_{\bullet 2}$	...	$n_{\bullet j}$	...	$n_{\bullet m}$	n

La última columna y fila muestran las frecuencias marginales de X e Y respectivamente, es decir, el número de elementos de la muestra que tienen un cierto valor de X (o Y) sin importar los valores que tome la otra variable.

Una vez tenemos los datos de esta tabla, planteamos el contraste de hipótesis en los siguientes términos:

Ho: Los dos caracteres son independientes

H1: Los dos caracteres no son independientes (hay asociación)

El contraste de esta hipótesis se basa en comparar las frecuencias observadas con las que se esperarían si realmente los dos caracteres fuesen independientes. Las frecuencias esperadas, representadas por e_{ij} , se pueden calcular a partir de las probabilidades p_{ij} de que ambas variables tomen conjuntamente unos determinados valores, que, bajo la hipótesis de independencia, serán:

$p_{ij} = P(X = x_i, Y = y_j) = P(X = x_i) * P(Y = y_j) = \frac{n_{xi} n_{yj}}{n*n}$ Por lo tanto tendremos que $e_{ij} = n * \frac{n_{xi} n_{yj}}{n*n}$

Es decir $eij = \frac{n_{xi} n_{yj}}{n}$ Es decir, las frecuencias esperadas se calculan multiplicando los totales de la fila y columna correspondiente y dividendo por n. Estos valores se incluyen en la tabla de contingencia escribiéndolos entre paréntesis

Para el contraste de la hipótesis de independencia se utiliza, igual que en la prueba de la bondad del ajuste, el estadístico:

$$\sum_{i=1}^{k} \sum_{j=1}^{m} \frac{(n_{ij} - e_{ij})^2}{e_{ij}} = \sum_{i=1}^{k} \sum_{j=1}^{m} \frac{n_{ij}^2}{e_{ij}^2} - n$$

En el caso de ser H_0 cierta, este estadístico sigue una distribución χ^2 con ν grados de libertad. Para calcular $\nu = (k-1)(m-1)$

Al igual que ocurría en la prueba de la bondad del ajuste, el método sólo es fiable si el número de elementos es suficientemente grande. En particular, si alguna de las frecuencias esperadas es menor que 5 habrá que agrupar filas o columnas.

Por ello, fijado el nivel de significación α buscamos en las tablas de chi-cuadrado un valor k tal que la probabilidad P($\chi^2(k-1, m-1)$)>k= α y si el valor del estadístico (*) es mayor que k , entonces rechazaremos la hipótesis nula de que las variables son independientes. Si el valor del estadístico χ^2 es menor que k, entonces aceptamos Ho , y aceptaremos la independencia

Por lo tanto bajo un nivel de significación α rechazaremos la hipótesis nula si:

$$\sum_{i=1}^{k}\sum_{j=1}^{m}\frac{(n_{ij}-e_{ij})^2}{e_{ij}} > \chi^2_{\alpha,k-1,\text{m-1}}$$

y se aceptará en caso contrario. Comentar que la expresión del estadístico también se le denomina en la literatura estadística cuadrado de la contingencia.

Conviene hacer notar que el estadístico definido en toma valores discretos, ya que las frecuencias observadas son discretas. Sin embargo, en el contraste de hipótesis estamos aproximando su distribución a una distribución de probabilidad continua como la χ^2 . Para solucionar esto se suele aplicar una corrección de continuidad consistente en disminuir las diferencias entre las frecuencias observadas y esperadas en una cantidad 0.5. Es decir, si la frecuencia esperada es mayor que la observada se le resta 0.5 y al contrario. Esta corrección, llamada **corrección de continuidad de Yates** conduce a la siguiente expresión modificada para el estadístico

$$\sum_{i=1}^{k}\sum_{j=1}^{m}\frac{(n_{ij}-e_{ij}-0{,}5)^2}{e_{ij}}$$

La corrección es normalmente despreciable si el número de grados de libertad es mayor que 1. Es decir, en la práctica, sólo se aplica para tablas de contingencia 2 × 2. Lógicamente, si las frecuencias esperadas son grandes la corrección es muy pequeña. En la práctica, solo se aplica la corrección de Yates cuando las frecuencias esperadas están entre 5 y 10.

Como concepto contrario al de independencia tenemos el de **asociación**. Se dice que A y B están asociados cuando aparecen juntos en mayor número de casos que el que cabría esperar si fuesen independientes. Según que esa tendencia a coincidir o no coincidir, esté más o menos marcada, tendremos distintos grados de asociación. Para medirlos ya vimos los procedimientos del tema de regresión donde hablamos de la asociación de dos variables. Vamos a estudiar un ejemplo de aplicación de este contraste.

EJEMPLO:

Para estudiar la dependencia entre la práctica de algún deporte y la depresión, se seleccionó una muestra aleatoria simple de 100 jóvenes, con los siguientes resultados:

	Sin depresión	Con depresión
Deportista	38	9
No deportista	31	22

Determinar si existe independencia entre la actividad del sujeto y su estado de ánimo. Nivel de significación (5%)

SOLUCIÓN:

Debemos primero calcular las frecuencias esperadas bajo el supuesto de independencia. La tabla de frecuencias esperadas sería:

	Sin depresión	Con depresión	
Deportista	32.43	14.57	47
No deportista	36.57	16.43	53
	69	31	100

Calculamos ahora el estadístico del contraste:

$$\chi^2 = \frac{(38-32.43)^2}{32.43} + \frac{(9-14.57)^2}{14.57} + \frac{(31-36.57)^2}{36.57} + \frac{(22-16.43)^2}{16.43} = 5.82$$

Este valor debemos compararlo con el percentil de la distribución χ^2 con (2-1)(2-1)=1 grado de libertad. $\chi^2_{0.95}(1) = 3.84$.

Por lo tanto como el valor del estadístico es superior al valor crítico, concluimos que debemos rechazar la hipótesis de independencia y por lo tanto asumir que existe relación entre la depresión e los hábitos deportistas del individuo.

ntic master revolucionamos la comunicación
UNIVERSIDAD COMPLUTENSE DE MADRID

Ejemplo:
Una empresa dedicada a la venta de automóviles desea determinar si la edad de sus clientes potenciales, puede explicar o no la preferencia por tres modelos que va a lanzaral mercado. Consultados 200 clientes habituales, la información obtenida es la siguiente:

	Tipo de modelo		
Edad (años)	**I**	**II**	**III**
20-30	10	40	10
30-40	30	30	20
40-50	10	30	20

¿Aceptaría la empresa, a la vista de esta información, que la edad explicará la preferenciapor el modelo, al nivel de significación del 5%?

CONTRASTES DE HOMOGENEIDAD DE MUESTRAS

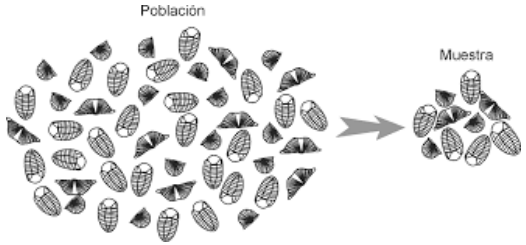
Un problema similar al anterior es el contraste de la homogeneidad de varias muestras. Mientras que en el contraste de independencia se medían dos características de una misma muestra, ahora se elijen k muestras de tamaños predeterminados (y no necesariamente iguales) y se quiere comprobar si todas ellas pueden provenir de la misma población.

Es decir, el objetivo es contrastar si la variable X se distribuye de igual manera dentro de cada muestra.

La hipótesis nula H_0 es entonces que las k muestras son homogéneas y la forma de operar es la misma que la vista para el contraste de la independencia.

Es decir se puede construir una tabla de contingencia y definir un estadístico chi-cuadrado como el visto anteriormente. Ahora k es el número de muestras y m el número de valores posibles, o intervalos, de la variable. Entonces, la hipótesis H_0 de homogeneidad se rechazará con un nivel de significación α cuando:

$$\sum_{i=1}^{k}\sum_{j=1}^{m}\frac{(n_{ij}-e_{ij})^2}{e_{ij}} > \chi^2_{\alpha,k-1\text{,m-1}}$$



ntic master
revolucionamos la comunicación

UNIVERSIDAD COMPLUTENSE DE MADRID