ntic master
revolucionamos la comunicación



UNIVERSIDAD COMPLUTENSE MADRID

Machine learning con Python

Semana 1

0. Introducción

¿Qué es machine learning?

*Rama de la inteligencia artificial que trata de crear programas capaces de **generalizar** comportamientos a partir de una información suministrada en forma de **ejemplos.***

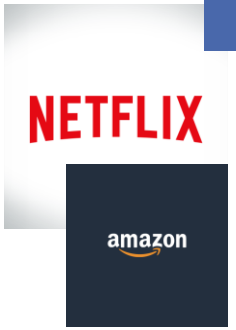
¿Qué importancia tiene?

Podemos aprovechar los datos que hay en las compañías para analizarla y realizar cosas como:

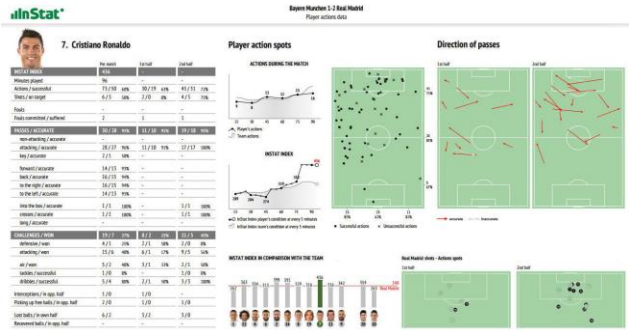
- *Hacer predicciones: ¿qué clientes se cambiarán de compañía?*
- *Buscar patrones interesantes: ¿qué productos compran juntos habitualmente mis clientes?*
- *Buscar grupos en los datos: ¿qué segmentos de clientes tengo?*

Aplicaciones de ML

















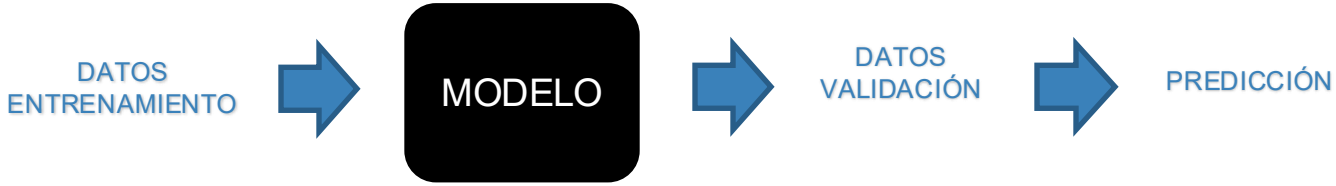




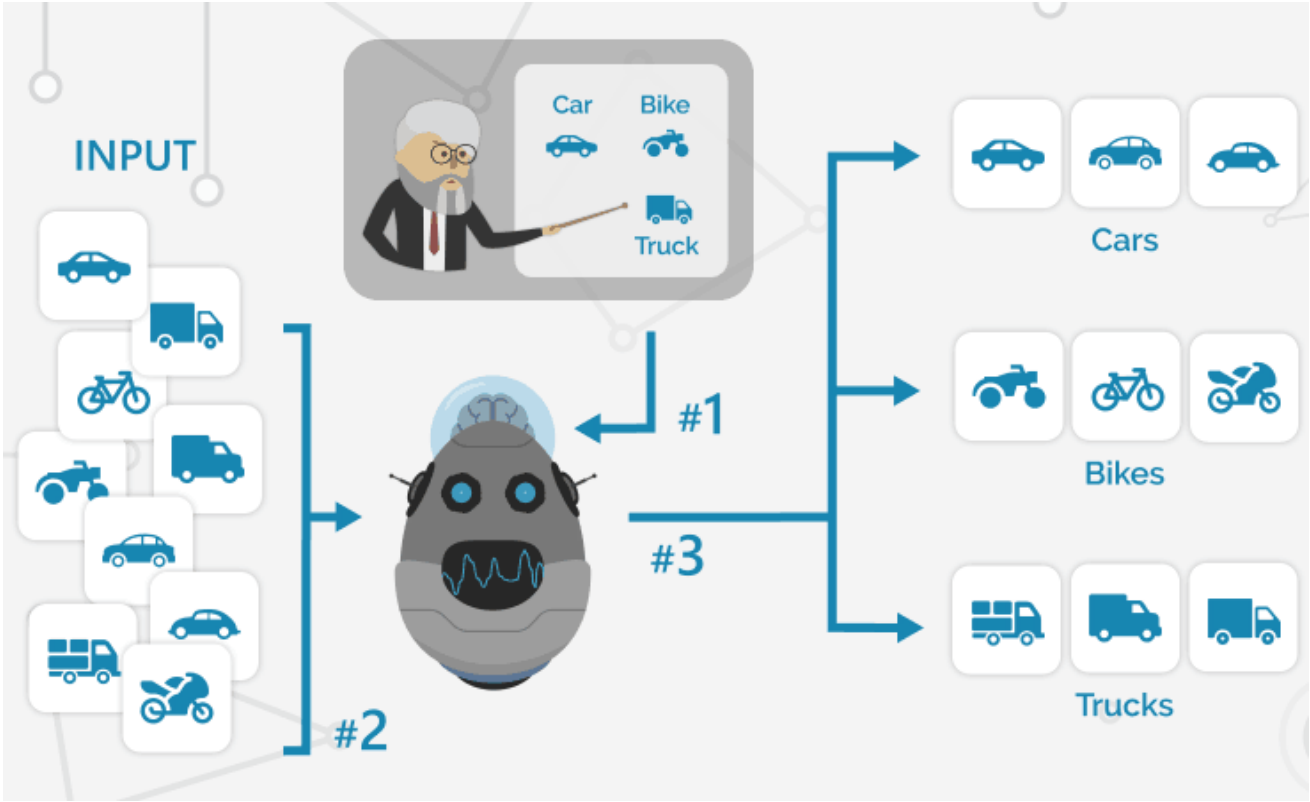
¿Qué es un modelo?

- Se trata de algoritmos utilizados para generalizar comportamientos e inferencias para un conjunto más amplio.

  - Utilizan datos de entrada para entrenarse.
  - Un modelo es una abstracción de los datos que se han utilizado.
  - Un caso particular es la memorización completa de los datos.

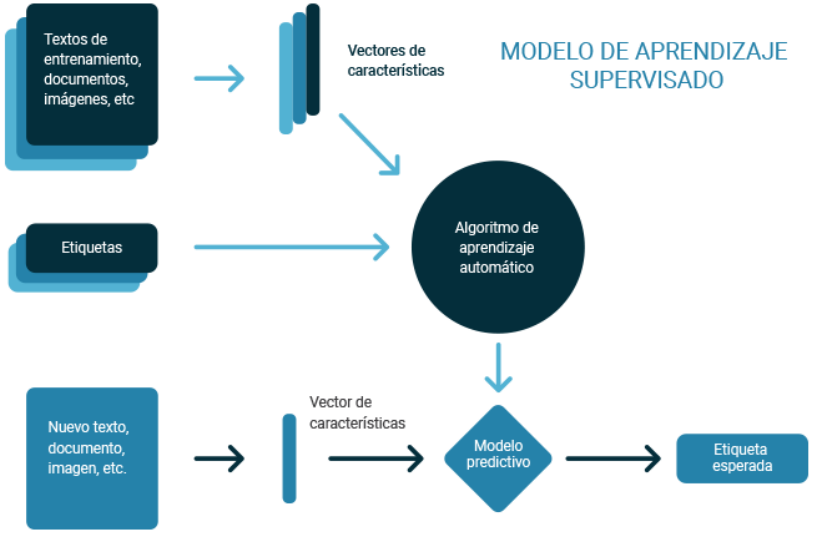


¿Qué es un modelo?



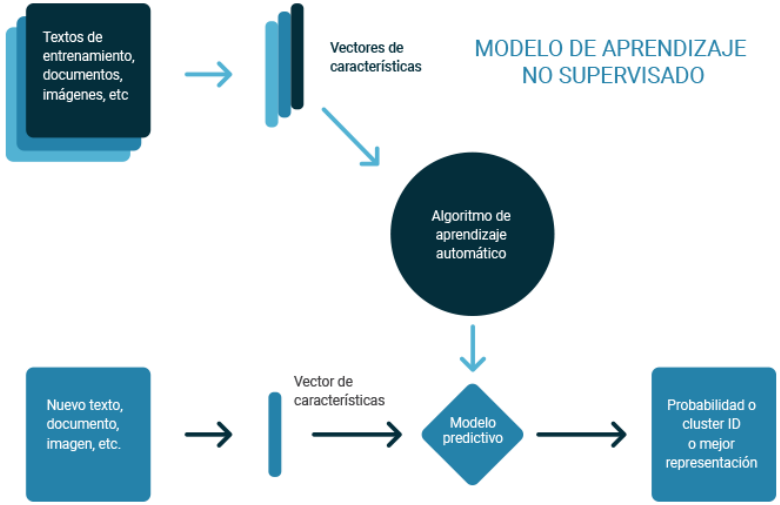
Tipos de aprendizaje

- Supervisado
  - Se genera un modelo predictivo basado en datos entrada/salida
  - Tenemos datos previamente etiquetados/clasificados (conocimiento a priori)
  - Ejemplos: SVM, decision tree, logistic regression, k-nearest…



Tipos de aprendizaje

- No supervisado
  - Ajustan su modelo predictivo únicamente con los datos de entrada
  - No tenemos datos previamente etiquetados/clasificados
  - Ejemplos: k-medias, hierarchical clustering, principal component analysis…

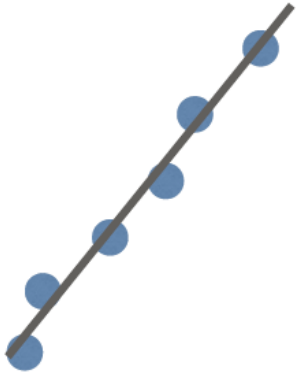


Problemas en aprendizaje automático

- Los modelos se deben seleccionar en función de los datos y el problema a resolver.

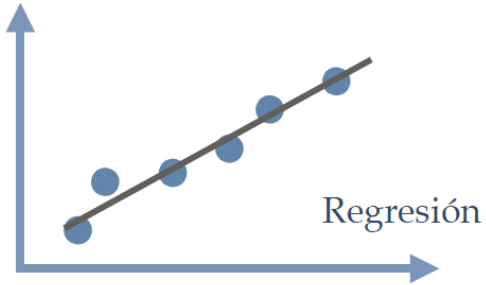






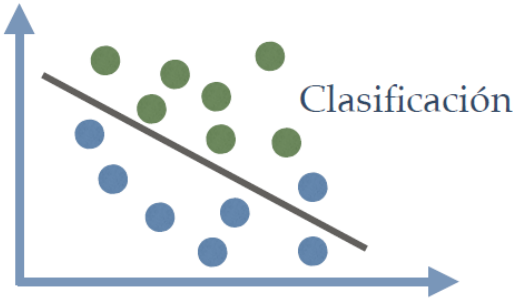
Problemas en aprendizaje automático

- **Regresión:**
  - Los algoritmos son utilizados para aprender a predecir el valor de una variable continua a partir de una o más variables explicativas.
  - El resultado es concreto y numérico.
  - Algoritmos: regresión lineal/no, random forest, SVM…
  - Ejemplos:
    - Queremos saber el precio de venta de algo (una casa).
    - Queremos saber el tiempo que se tarda en algo (empresa de mercancías).
    - Queremos saber el número de productos que venderemos.



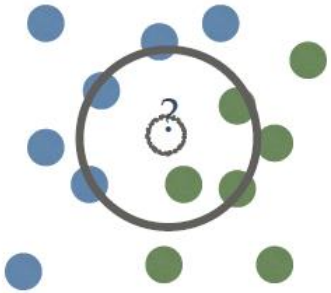
Problemas en aprendizaje automático

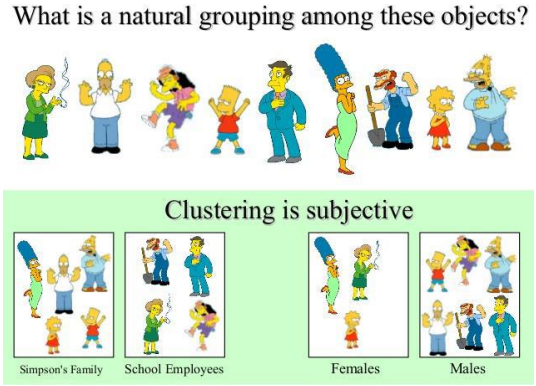
- **Clasificación**:
  - Los algoritmos son utilizados para aprender a predecir valores discretos a partir de una o más variables explicativas.
  - El resultado es una clase (a través de probabilidades…)
  - Algoritmos: igual que en regresión
  - Ejemplos:
    - ¿El cliente se irá de la compañía? SI/NO
    - ¿Tipo de enfermedad? CANCER/GRIPE
    - ¿Quién meterá el gol? DELANTERO/MEDIOCENTRO/DEFENSA



Problemas en aprendizaje automático

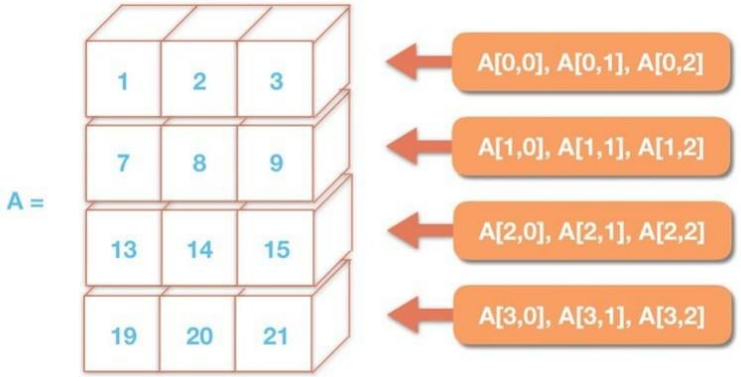
- **Clustering**:
  - Los algoritmos son utilizados para segmentar datos en grupos iguales o similares.
  - El resultado son diferentes clusters/grupos.
  - Algoritmos: kmeans, DBSCAN
  - Ejemplos:
    - ¿Qué clientes se parecen más entre ellos?
    - ¿Qué grupos de clientes tengo en mi compañía?





Inicios...

- **Numpy**: es una biblioteca de funciones matemáticas de alto nivel para operar con vectores o matrices.
  ver : **iniciación_numpy.ipynb**



- **Pandas**: pandas es una librería para el análisis de datos que cuenta con las estructuras de datos que necesitamos para limpiar los datos en bruto y que sean aptos para el análisis
  ver : **iniciación_pandas.ipynb**

	first_name	last_name	age
0	Oralie	Fidgeon	30
1	Imojean	Benet	21
2	Michele	Woodlands	29
3	Ailbert	Risdale	22
4	Stevy	MacGorman	24

1. Ingesta de datos

- Hoy en día las compañías están evolucionando y transformándose digitalmente hasta convertirse en compañías data centric.
- Las empresas más importantes lo saben y basan su estrategia en el dato: Facebook, Amazon…
- Las fuentes de datos, por tanto, aparecen desde diferentes fuentes y formatos, encontrándonos con 2 tipos de datos:

  - **ESTRUCTURADOS**: Se almacenan y comparten en forma de tabla. Cada columna es una variable y cada fila una observación. Se suelen almacenar en ficheros .xlsx, .csv, .txt, o en bases de datos como SQL.

  - **NO ESTRUCTURADOS**: Datos de navegación, imágenes, grabaciones de voz, páginas web… Se suelen almacenar en ficheros .json o en bases de datos no relacionales como MongoDB.

1. Ingesta de datos

- Podemos realizar la ingesta de datos a través de un almacenamiento en local, un clúster (cloudera) o en cloud (AWS, Azure…)

- Documentación pandas ingesta de datos:
  https://pandas.pydata.org/pandas-docs/stable/user_guide/io.html#

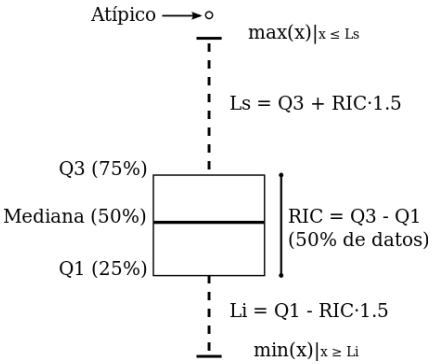
Ver: **ingesta_datos.ipynb**

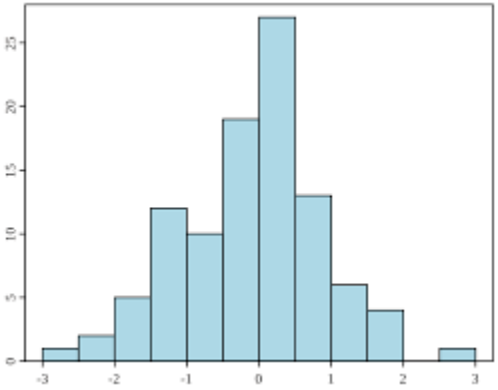
- Datos en bbdd relacionales SQL
- Datos en XML, HTML…(scraping)
- Datos en bbdd no relacionales (json)
- Datos en API,s (json)
- Datos en HDF5

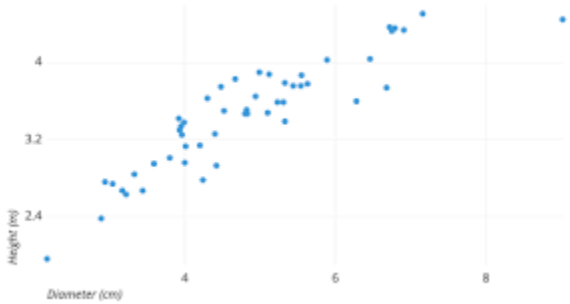
Visualización

- Hay muchas librerías para visualizar datos en Python.
  - **Matplotlib** : https://matplotlib.org/
  - **Seaborn**: https://seaborn.pydata.org/
  - **Plotly**: https://plotly.com/python/plotly-express/

- Estas librerías , nos permiten realizar análisis cuantitativos de las diferentes variables que tenemos en nuestros dataframes:
  - Boxplot, Histogramas, Scatter plot…







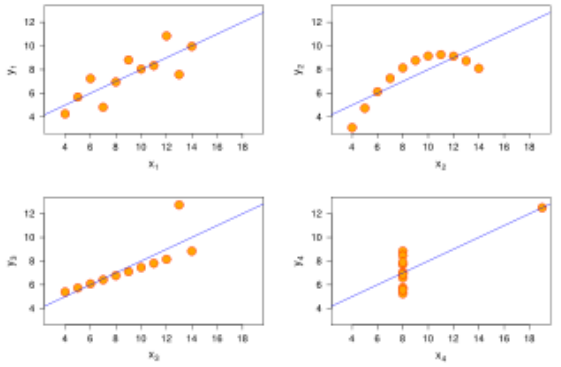
Visualización

- ¿Por qué es importante la visualización?

Cuarteto de Anscombe

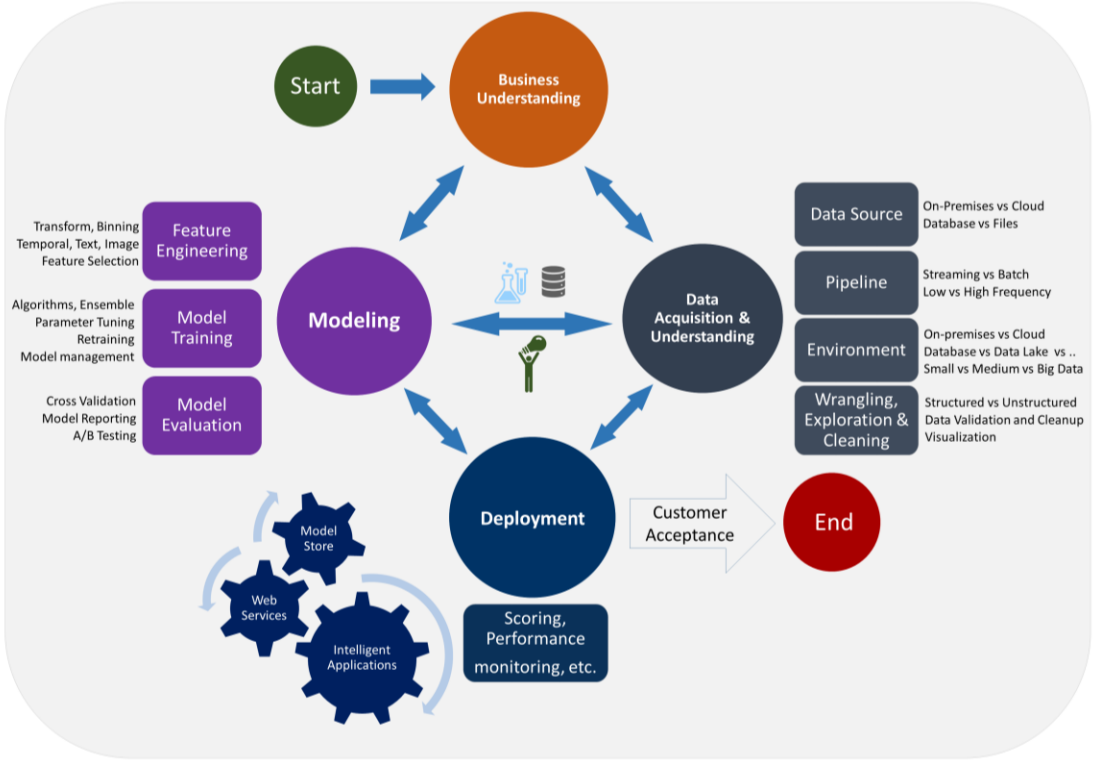
I		II		III		IV	
x	y	x	y	x	y	x	y
10.0	8.04	10.0	9.14	10.0	7.46	8.0	6.58
8.0	6.95	8.0	8.14	8.0	6.77	8.0	5.76
13.0	7.58	13.0	8.74	13.0	12.74	8.0	7.71
9.0	8.81	9.0	8.77	9.0	7.11	8.0	8.84
11.0	8.33	11.0	9.26	11.0	7.81	8.0	8.47
14.0	9.96	14.0	8.10	14.0	8.84	8.0	7.04
6.0	7.24	6.0	6.13	6.0	6.08	8.0	5.25
4.0	4.26	4.0	3.10	4.0	5.39	19.0	12.50
12.0	10.84	12.0	9.13	12.0	8.15	8.0	5.56
7.0	4.82	7.0	7.26	7.0	6.42	8.0	7.91
5.0	5.68	5.0	4.74	5.0	5.73	8.0	6.89

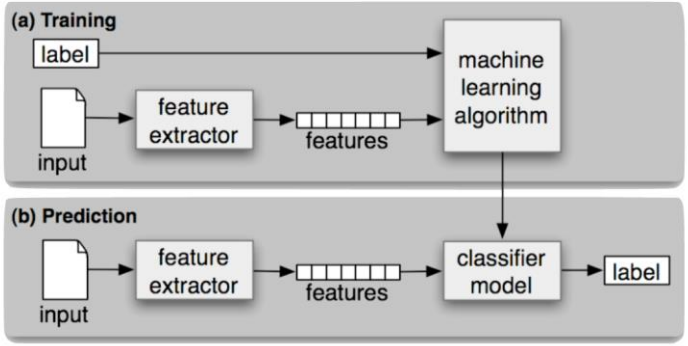
Propiedad	Valor
Media de cada una de las variables x	9.0
Varianza de cada una de las variables x	11.0
Media de cada una de las variables y	7.5
Varianza de cada una de las variables y	4.12
Correlación entre cada una de las variables x e y	0.816
Recta de regresión	$y = 3 + 0.5x$



¡PINTAR SIEMPRE LOS DATOS!

Proceso de un proyecto de ML





2. Preprocesado

Cargar: titanic_kaggle

- Analizar los datos (inconsistencia de datos…)
- Eliminar/rellenar registros nulos
- Eliminar columnas con valores únicos/no utilizables
- Transformación de variables categóricas
- Escalado de variables
- Muestreo estratificado: Conjuntos Train/Test
- Análisis variables
- Detección outliers



Material importante: https://github.com/solegalli







UNIVERSIDAD
COMPLUTENSE
MADRID