ntic master
revolucionamos la comunicación

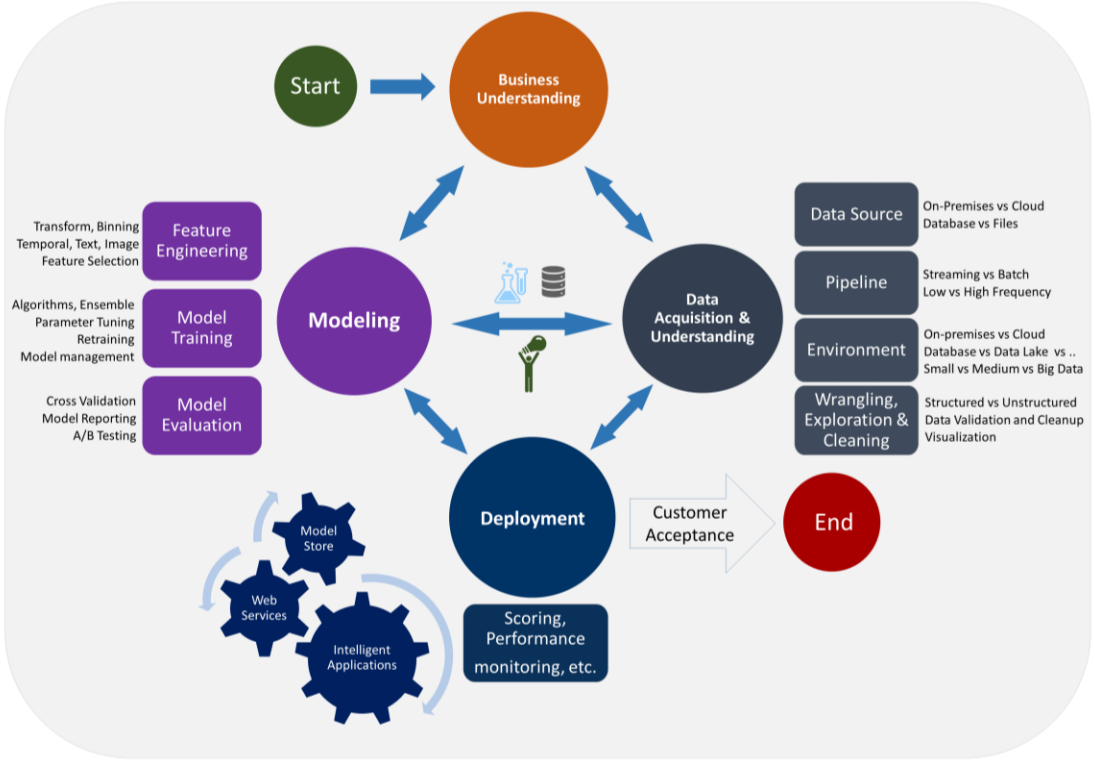


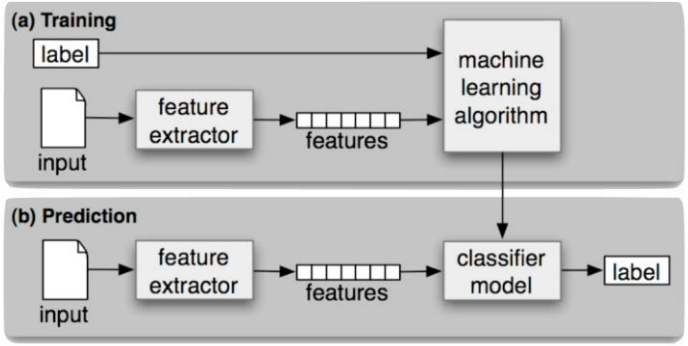
UNIVERSIDAD COMPLUTENSE MADRID

Machine learning con Python

Semana 3-4

Proceso de un proyecto de ML

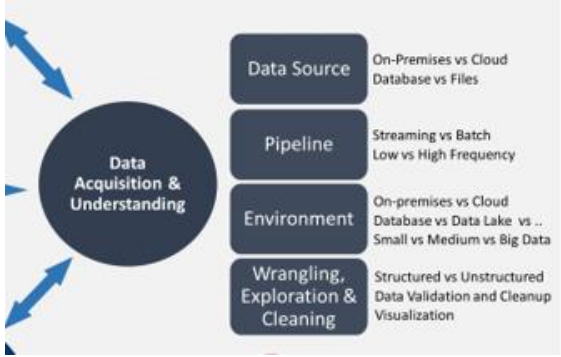




Proceso de un proyecto de ML: ejercicio

- **Bank Marketing DataSet**
  - https://archive.ics.uci.edu/ml/datasets/bank+marketing
  - bank-full.csv with all examples and 17 inputs, ordered by date





Proceso de un proyecto de ML: ejercicio

- Features:

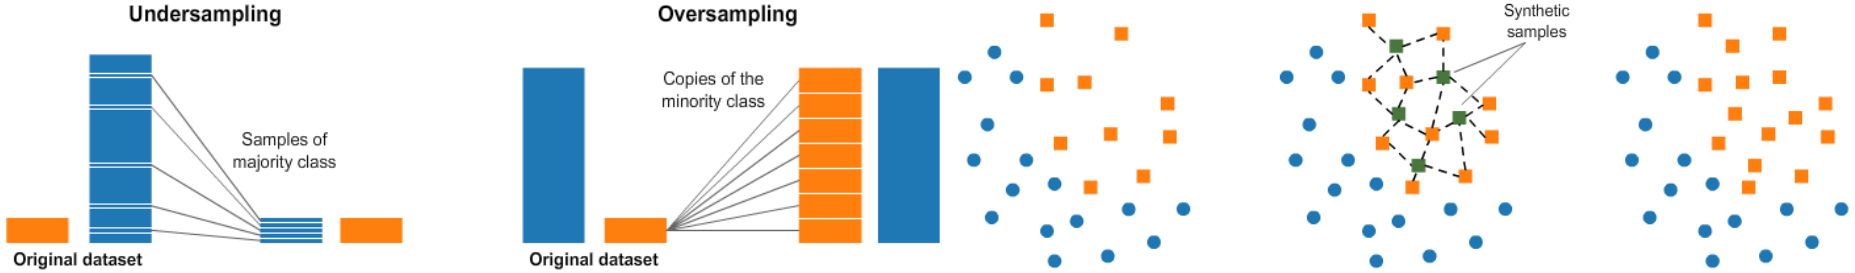
age (numeric)

job : type of job (categorical: "admin.","unknown","unemployed","management","housemaid","entrepreneur","student","blue-collar","self-employed","retired","technician","services")
marital : marital status (categorical: "married","divorced","single"; note: "divorced" means divorced or widowed)
education (categorical: "unknown","secondary","primary","tertiary")
default: has credit in default? (binary: "yes","no")
balance: average yearly balance, in euros (numeric)
housing: has housing loan? (binary: "yes","no")
loan: has personal loan? (binary: "yes","no")
related with the last contact of the current campaign:
contact: contact communication type (categorical: "unknown","telephone","cellular")
day: last contact day of the month (numeric)
month: last contact month of year (categorical: "jan", "feb", "mar", ..., "nov", "dec")
duration: last contact duration, in seconds (numeric)
other attributes:
campaign: number of contacts performed during this campaign and for this client (numeric, includes last contact)
pdays: number of days that passed by after the client was last contacted from a previous campaign (numeric, -1 means client was not previously contacted)
previous: number of contacts performed before this campaign and for this client (numeric)
poutcome: outcome of the previous marketing campaign (categorical: "unknown","other","failure","success")
Output variable (desired target):
Y: has the client subscribed a term deposit? (binary: "yes","no")

2. Preprocesado

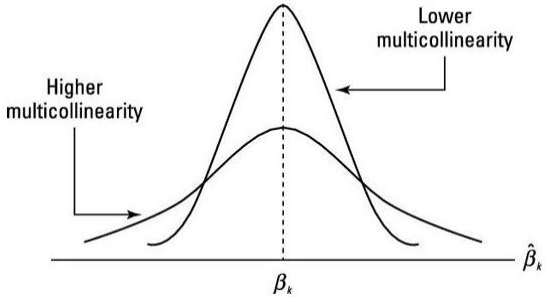
- Técnicas de balanceo de datos: cuando nuestra variable target no tiene una muestra significativa, se deben utilizar este tipo de técnicas de balanceo de datos. Entre ellas, nos encontramos con:

  - Undersampling: consiste en seleccionar un porcentaje de muestras de la clase mayoritaria.
  - Oversampling: consiste en duplicar un porcentaje de muestras de la clase minoritaria.



2. Preprocesado

- Multicolinealidad: es la dependencia lineal entre las variables independientes:



$$\beta mco = (X'X)^{-1}X'Y$$

$$Var(\beta mco) = (X'X)^{-1}\sigma^2 = \infty$$

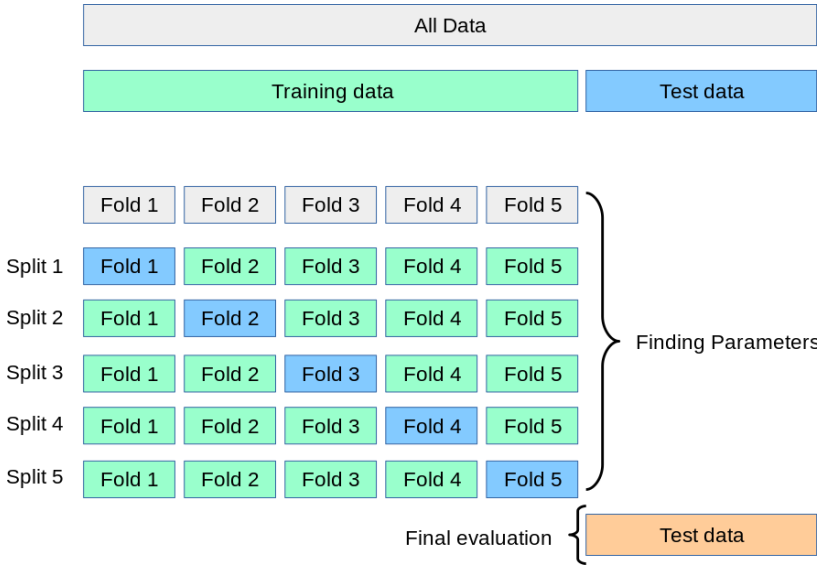
Profit	R&D Spend	Admin	Marketing	State	Dummy Variables: New York	Dummy Variables: California
192,261.83	165,349.20	136,897.80	471,784.10	New York	1	0
191,792.06	162,597.70			ia	0	1
191,050.39	153,441.51			ia	0	1
182,901.99	144,372.41			rk	1	0
166,187.94	142,107.34			ia	0	1

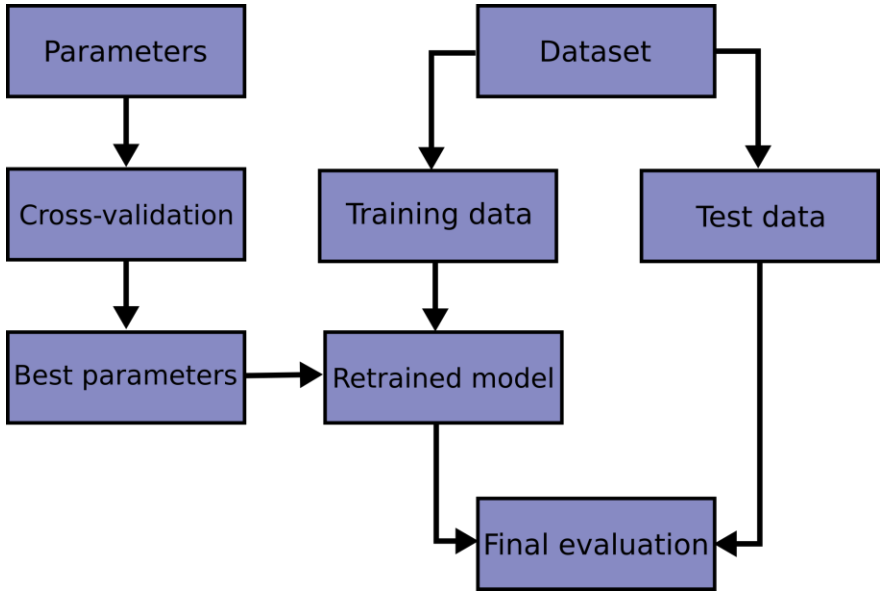
$D_2 = 1 - D_1$

$$y = b_0 + b_1*x_1 + b_2*x_2 + b_3*x_3 + b_4*D_1 + b_5*D_2$$

2. Preprocesado

- Validación cruzada: utilizada para evitar overfitting.





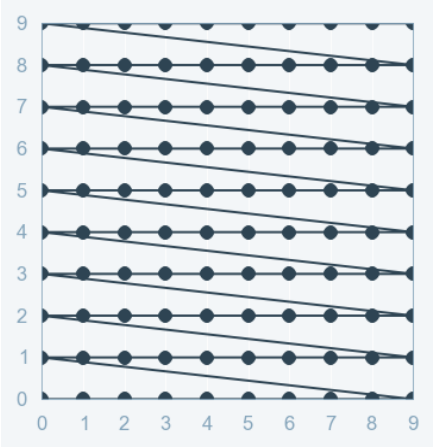
Mejora de modelos

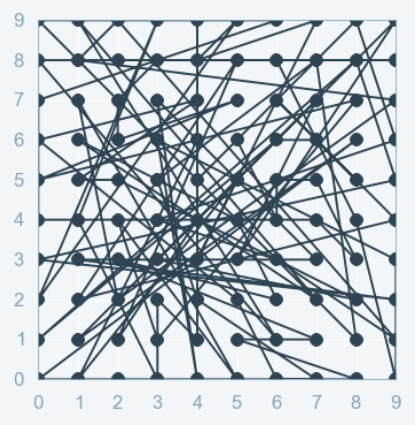
- **Feature Engineering**: en un término utilizado en proyectos de data science a la mejora de modelos a través de la creación de nuevas variables, agrupación de ellas… Este módulo, se podría incluir en el pre procesado de datos, pero normalmente se incluye después de conseguir el score de un modelo con el ánimo de realizar una mejora.

	y
y	1
duration	0.394521
poutcome_success	0.306788
poutcome	0.213476
poutcome_unknown	0.167051
contact_unknown	0.150935
housing	0.139173
contact_cellular	0.135873
month_mar	0.129456
month_oct	0.128531
month_sep	0.123185
pdays	0.103621

Mejora de modelos

- **Tuneo de hiperparámetros**: realiza una selección de hiper-parámetros



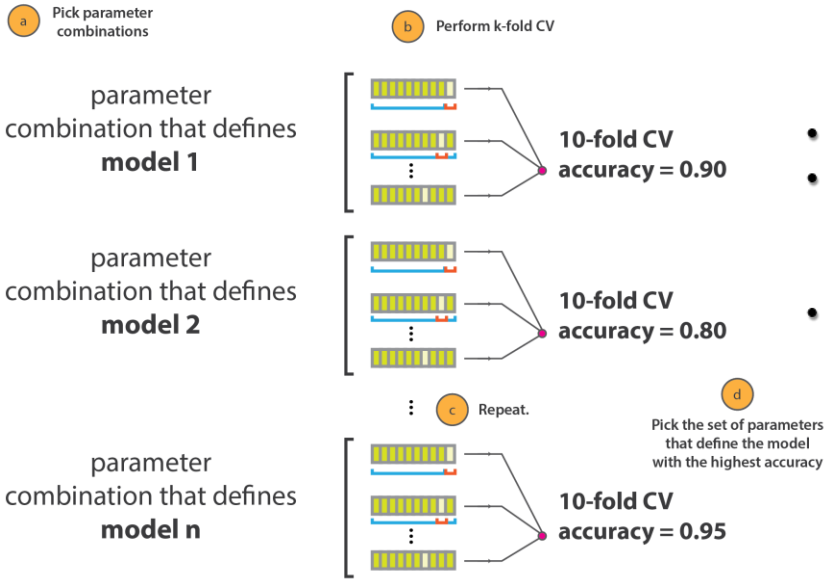


https://optuna.org/

OPTUNA

Mejora de modelos

- Grid Search: técnica usada para la selección de hiper-parámetros del entrenamiento de un modelo. Se realiza mediante los siguientes parámetros:



- **estimator**: el modelo que se ha de evaluar
- **param_grid**: un diccionario donde se indican los parámetros a evaluar como clave y el conjunto elementos como valor
- **cv**: el número de conjuntos en los que se divide los datos para la validación cruzada.

Herramientas/librerías que pueden ayudar

- **DESPLIEGUE DE MODELOS:**

Mlflow:

- MLflow es una plataforma de código abierto para gestionar el ciclo de vida de ML de principio a fin.

- MLflow se desarrolló para poder funcionar con cualquier lenguaje de programación, librerías, algoritmos y herramientas de implementación.

- Se basa en una interfaz API REST

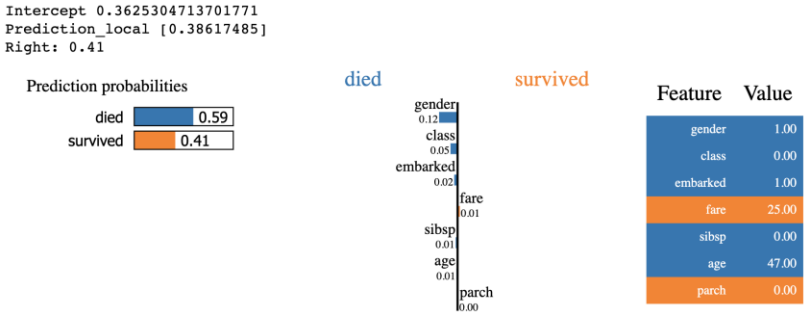


Herramientas/librerías que pueden ayudar

- **EXPLICACIÓN DE MODELOS:**

Lime/Shap:

- Conocer bien el comportamiento del modelo, así como las variables más influyentes nos ayudan a poder mejorar el mismo y saber hasta donde puede llegar.
- Además nos permite explicar al resto de personas (no técnicas) el porqué funciona de una determinada manera y respaldar su uso.
- LIME y SHAP son librerías que nos ayudan a realizar todo esto de manera sencilla y rápida.

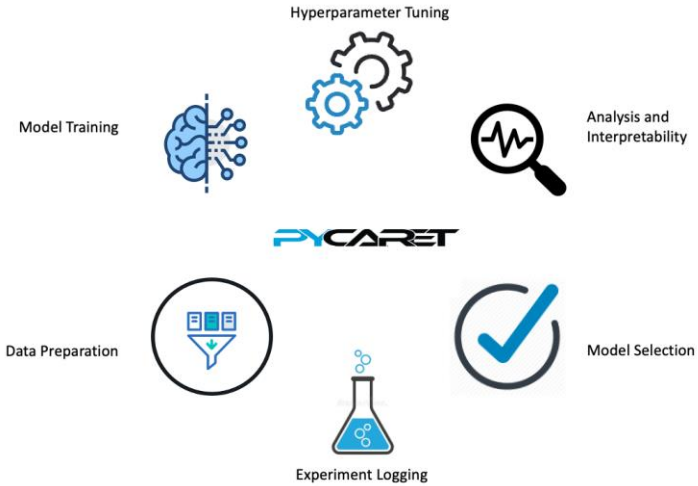


Herramientas/librerías que pueden ayudar

- **AUTOML:**

Pycaret:

- Nos ofrece una primera aproximación rápida al modelo que mejor funcionaría dentro de una amplia lista de algoritmos.
- Permite llevar a cabo desde la preparación de los datos, hasta el despliegue del modelo final en tan solo unos minutos.
- No sustituye al Data Scientist, pero nos da una primera idea del potencial de los datos, de los algoritmos que mejor se ajustan a ese dataset…
- Es compatible con jupyter notebook



Herramientas/librerías que pueden ayudar

- **AUTOML:**

  H2O.ai es una plataforma de **Machine Learning y AutoML de nivel industrial**, muy usada en empresa y producción. Su módulo más conocido es **H2O AutoML**.

- Web: https://www.h2o.ai
- Docs AutoML: https://docs.h2o.ai/h2o/latest-stable/h2o-docs/automl.html
- GitHub: https://github.com/h2oai/h2o-3
- Python API: https://docs.h2o.ai/h2o/latest-stable/h2o-py/docs/index.html

H2O.ai

- Muy robusto y estable, Excelente rendimiento, Pensado para **producción,** Maneja datasets grandes, Buen soporte empresarial, Leaderboard claro, Métricas y validación sólidas

- API menos “pythonica”, Curva de aprendizaje mayor, Arranca un **servidor Java,** Menos flexible que sklearn, Menos transparente que pipelines manuales

Herramientas/librerías que pueden ayudar

- **AUTOML:**

AutoGluon es un framework AutoML desarrollado por Amazon, orientado a **resultados rápidos y robustos**.

- Web: https://auto.gluon.ai
- GitHub: https://github.com/autogluon/autogluon
- Docs: https://auto.gluon.ai/stable/index.html



- Muy fácil de usar, funciona bien con datos reales, maneja automáticamente categóricas, missing values , ensembles

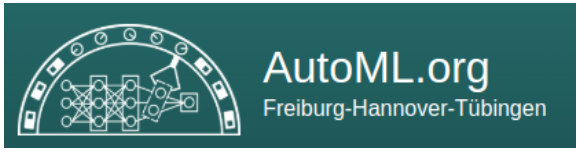
- Poco control del preprocesado, Pipelines poco transparentes, Difícil reutilizar transformaciones fuera

Herramientas/librerías que pueden ayudar

- **AUTOML:**

Auto-sklearn es un sistema AutoML basado en scikit-learn y optimización bayesiana.

- Web: https://automl.github.io/auto-sklearn
- GitHub: https://github.com/automl/auto-sklearn
- Docs: https://automl.github.io/auto-sklearn/master/



- AutoML “clásico” muy completo, Optimización de hiperparámetros, Ensembles avanzados
  Muy potente si hay tiempo

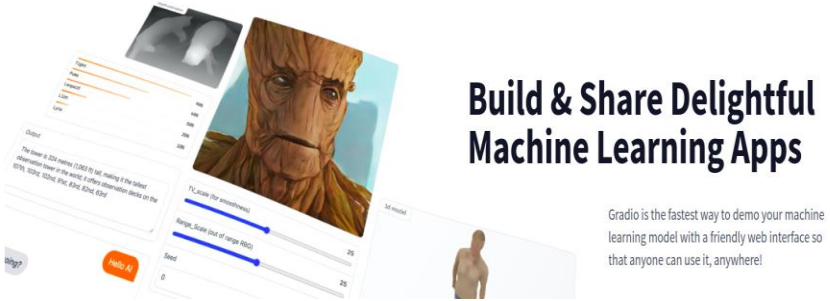
- Muy lento, Instalación complicada, Problemas con versiones modernas de Python

Herramientas/librerías que pueden ayudar

- **Mostrar resultados**

Gradio:

- Gradio es una librería de Python que permite crear demos web simplemente especificando la lista de componentes de entrada y salida que espera su modelo de Machine Learning.



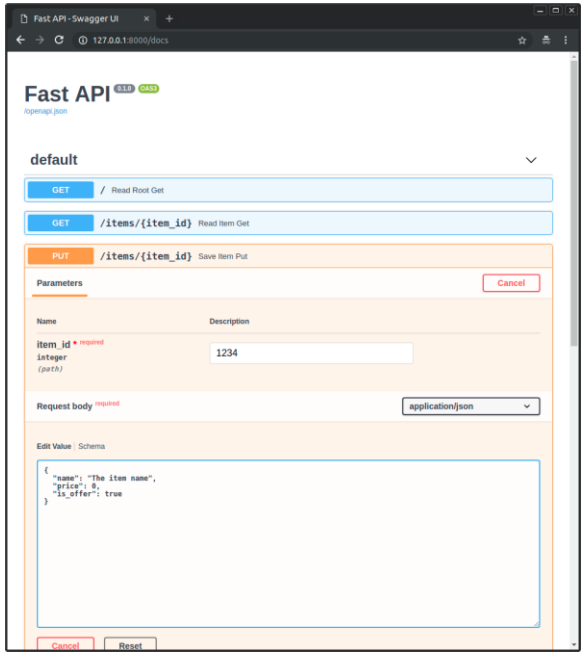
https://www.gradio.app/docs/interface

Herramientas/librerías que pueden ayudar

- **Mostrar resultados**

Fastapi:

- FastAPI es un conjunto de herramientas para los programadores que quieren construir aplicaciones web de manera eficiente y rápida. Imagina que tienes que crear una página web que se conecte con otras partes, como bases de datos o servicios en línea. FastAPI te da un atajo para hacerlo de una manera muy organizada y efectiva.



https://fastapi.tiangolo.com/es/

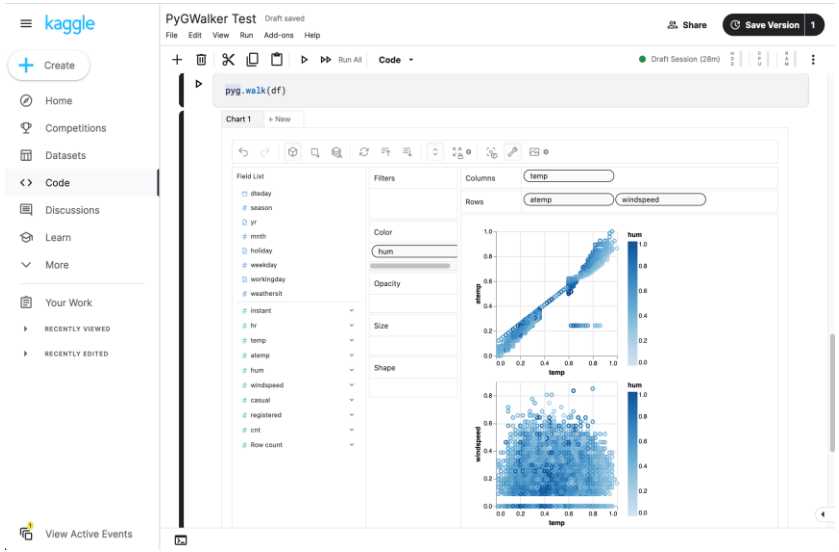
Herramientas/librerías que pueden ayudar

- **EDA:**

Pygwalker:

- Puede simplificar su flujo de trabajo de análisis de datos y visualización de datos en Jupyter Notebook, convirtiendo su DataFrame de pandas (y DataFrame de polars) en una interfaz de usuario al estilo de Tableau para exploración visual.

https://github.com/Kanaries/pygwalker/blob/main/



Herramientas/librerías que pueden ayudar

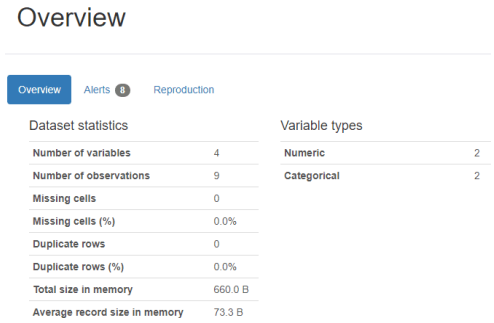
- **EDA:**

YData Profiling:

Generador automático de reportes EDA en HTML (antes *pandas-profiling*).

- Estadísticas univariadas y bivariadas, Correlaciones, outliers, valores nulos, Reporte HTML exportable, Integración directa con pandas, Muy rápido (1 línea de código), Ideal para primer vistazo, Reporte fácil de compartir

- No interactivo para explorar libremente, Puede ser pesado en datasets grandes, Poco control fino por gráfico



Herramientas/librerías que pueden ayudar

- **EDA:**

Sweetviz: EDA automático enfocado en **comparación** y **variable objetivo**.

- Comparación train vs test, Importancia exploratoria de features, Reporte HTML visual, Pensado para ML, Excelente para clasificación/regresión, Muy claro para analizar `target`, Ideal para data leakage y sesgos

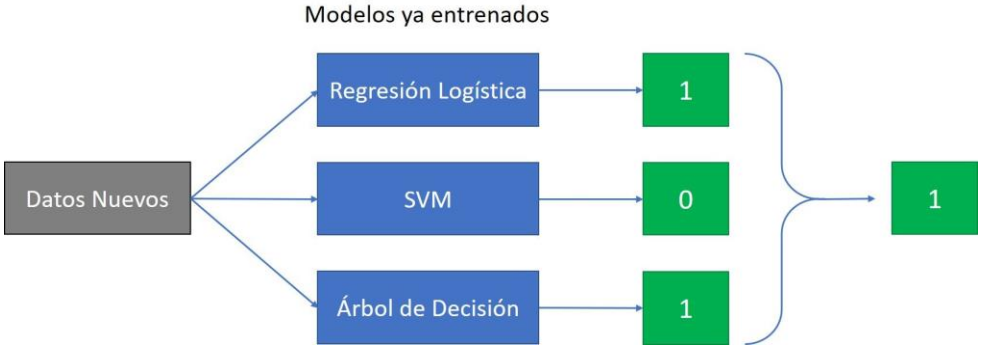
- Problemas de compatibilidad con NumPy moderno, Menos flexible que profiling, No interactivo



Ensemble models

Se tratan de métodos combinados que utilizan múltiples algoritmos de machine learning para obtener un mejor rendimiento predictivo.

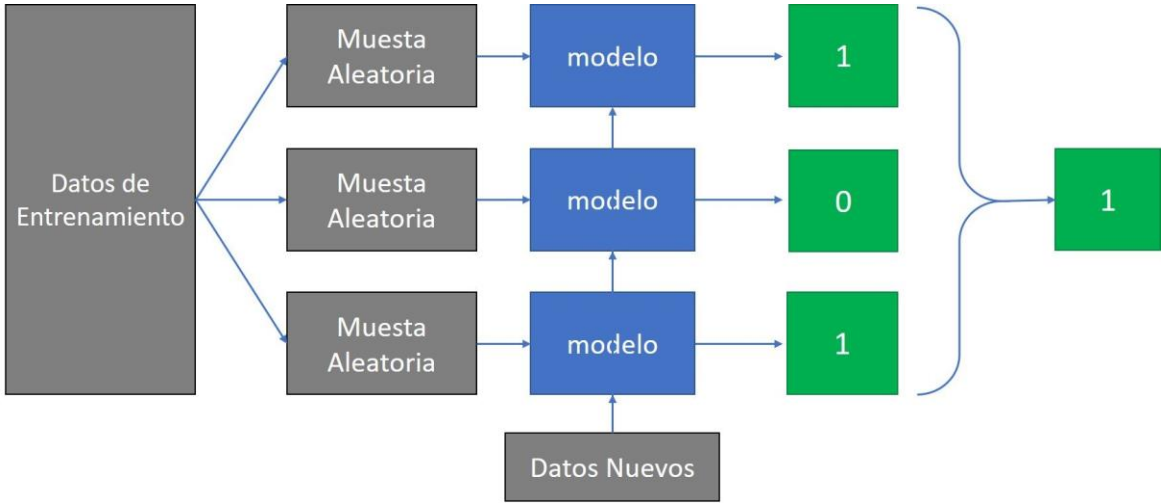
•Voting: permite entrenar varios modelos con los mismos datos. Cada modelo tiene asociado un voto. La predicción final se obtiene como la más votada.



•Stacking: se trata de apilar modelos, es decir, usar la salida de un modelo como entrada de otro.

Ensemble models

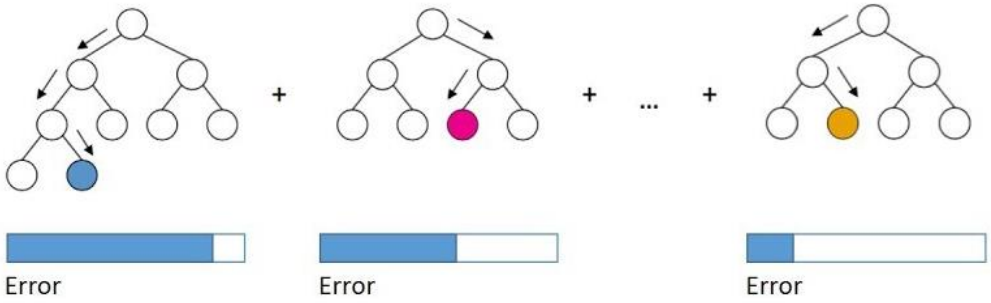
- Bagging: es un meta-algoritmo que consigue combinaciones de modelos a través de una familia inicial, provocando un menos overfitting y varianza. Consigue que los errores se compensen entre sí, entrenando cada modelo con subconjuntos del dataset original. El resultado es una combinación.
  Ejemplo: Random Forest (bagging de decission tree)



Ensemble methods

- Boosting: en este caso, cada modelo intenta arreglar los errores de los modelos anteriores. Tras la primera clasificación, se dará más peso a las muestras mal clasificadas. En el caso de regresión se da más peso al error cuadrático medio para el siguiente modelo.

- Ejemplos: Xgboost, CatBoost, Lightgbm, AdaBoost



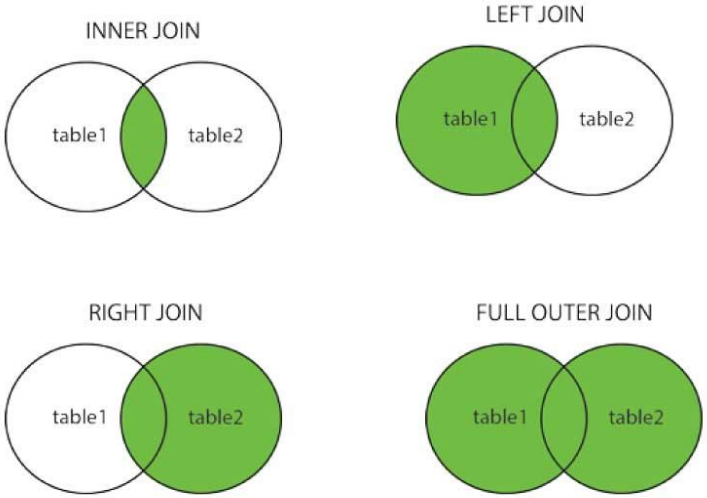
Intentar aplicar un modelo boosting a uno de los modelos realizados anteriormente (ejemplo Clasificación)

Ejercicio real

Consiste en calcular el churn (clientes que abandonan una compañía) de clientes en una operadora de telecomunicaciones. La compañía ha descubierto que entre diciembre de 2019 y enero de 2020 han tenido bastantes bajas de clientes. El objetivo de la práctica es llegar a construir un modelo analítico que sea capaz de predecir los próximos clientes que son potenciales a marcharse de la operadora para poder lanzar una campaña e intentar fidelizarles antes de su portabilidad. Además, los directivos de la compañía quieren conocer las causas por las cuales los clientes se están fugando. Para ello disponemos de varios datasets con datos que aportan información de los clientes.

Ejercicio real

1. Cargar los datasets y construir un único tablón analítico con todas las variables que consideremos necesarias para cada una de las cosechas que queremos analizar.



Ejercicio real

target: esta variable no la tenemos. Esto ocurre más a menudo de lo que pensamos en la industria. Una vez que tenemos los dos tablones analíticos construidos (diciembre y enero) hay que pensar como podemos construir esta variable.



¡¡¡ COSECHAS !!!

Ejercicio real

2. Realizar un pre procesado y una limpieza de los datos, siguiendo la metodología vista en clase.

3. Muestrear los datos, construyendo un dataset de train y test.



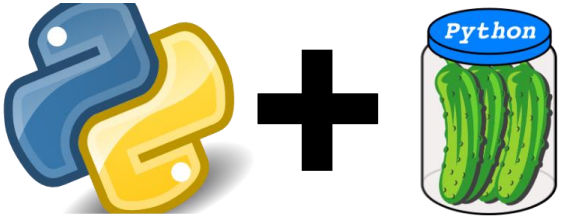
Ejercicio real

4. Construir un modelo analítico de clasificación que sea capaz de predecir cuando un cliente se fuga de la empresa, argumentando el tipo de algoritmo utilizado, las variables seleccionadas, obteniendo las métricas oportunas… Explicar lo “bueno” o “malo” que es el modelo a través de las métricas obtenidas.

5. Realizar una mejora del modelo utilizando técnicas vistas en clase (feature engineering, análisis de variables, comprobación de overfitting, validación cruzada, tuneado de hiper parámetros a través de la automatización…)

Ejercicio real

6. Predecir los clientes de la cosecha de enero que más probabilidad tienen de cambiarse de operadora.



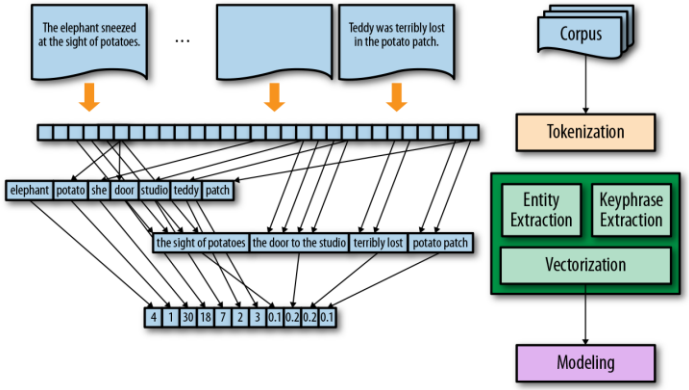
id	probabilidad
86266	0.96
98899	0.94
19111	0.93
14588	0.93
35890	0.92
...	...

7. Obtener y explicar las claves (a través de las variables…) de la marcha de los clientes en la compañía.

¿Y qué pasa si tengo texto como dataframe en vez de datos tabulados?

- Si tenemos datos que son texto (un corpus) el pre procesado será diferente. Las técnicas utilizadas serán las conocidas bajo el campo del procesamiento del lenguaje natural: Lematización, Normalización, eliminar stopwords, vectorización, tokenización...)

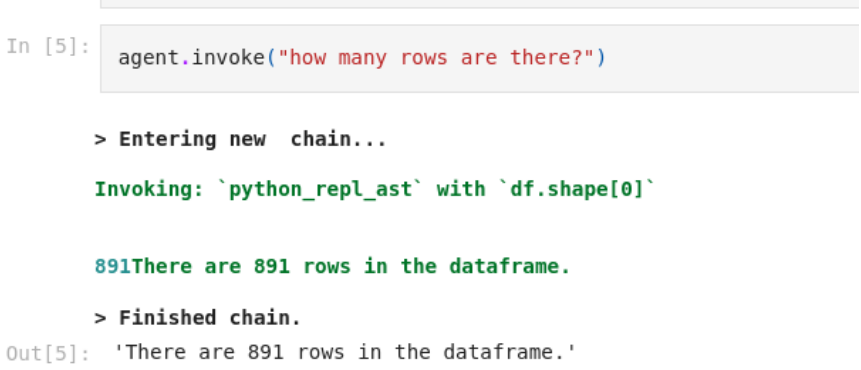
- El objetivo siempre es el mismo, convertir un dataframe en una matriz de datos numéricos para que los algoritmos (que son matemáticos) puedan trabajar con ellos.



El futuro del machine learning...

- El papel de la IA generativa está transformando todos los negocios poco a poco.
- Muchas librerías como "langchain" tiene ya agentes (con tools) para modelar datos rápidamente.

https://github.com/langchain-ai/langchain/blob/master/docs/docs/integrations/tools/pandas.ipynb







UNIVERSIDAD
COMPLUTENSE
MADRID