

ntic master School

UNIVERSIDAD COMPLUTENSE DE MADRID

Análisis de Componentes Principales

Minería de Datos y Modelización Predictiva

Máster en Big Data, Data Science & Inteligencia Artificial
Universidad Complutense de Madrid





Introducción

- Contexto **multidimensional** en la recolección de datos.
- **Necesidad** de técnicas para simplificar y **resumir** eficientemente la información.
- Resolución del problema de **multicolinealidad** o correlación alta.
- Facilita **interpretación** y análisis.
- Permite **visualización** clara en espacio de baja dimensión.
- **Versatilidad** aplicable en cualquier campo.
- Mejora de la **calidad de los datos** y eliminación de redundancias.
- **Optimización** de recursos computacionales y manejo eficiente de grandes datos.

¿En que consiste el ACP?

- ACP: **técnica matemática sofisticada** aplicada a datos con variables potencialmente correlacionadas.
- Objetivo: **Transformar** variables en **componentes principales**, que son **linealmente independientes** (no correlacionadas).
- La **transformación** se realiza mediante una combinación lineal de las variables originales.
- **Transformación** diseñada para representar la **estructura compleja** y multidimensional de los datos en dimensiones reducidas.
- Mantiene la información esencial **sin perderdidas significativas**.
- El **primer componente principal** captura la mayor parte de la variabilidad y resume la información de las variables originales.
- El **segundo componente principal** es **ortogonal** al primero y explica la siguiente mayor variabilidad.
- Proceso **secuencial**: Cada componente subsiguiente explica una proporción decreciente de variabilidad y es ortogonal a los anteriores.

A continuación, se muestra (a la izquierda) una **nube de puntos** que representa la relación entre las variables originales (X, Y), **altamente correlacionadas**.

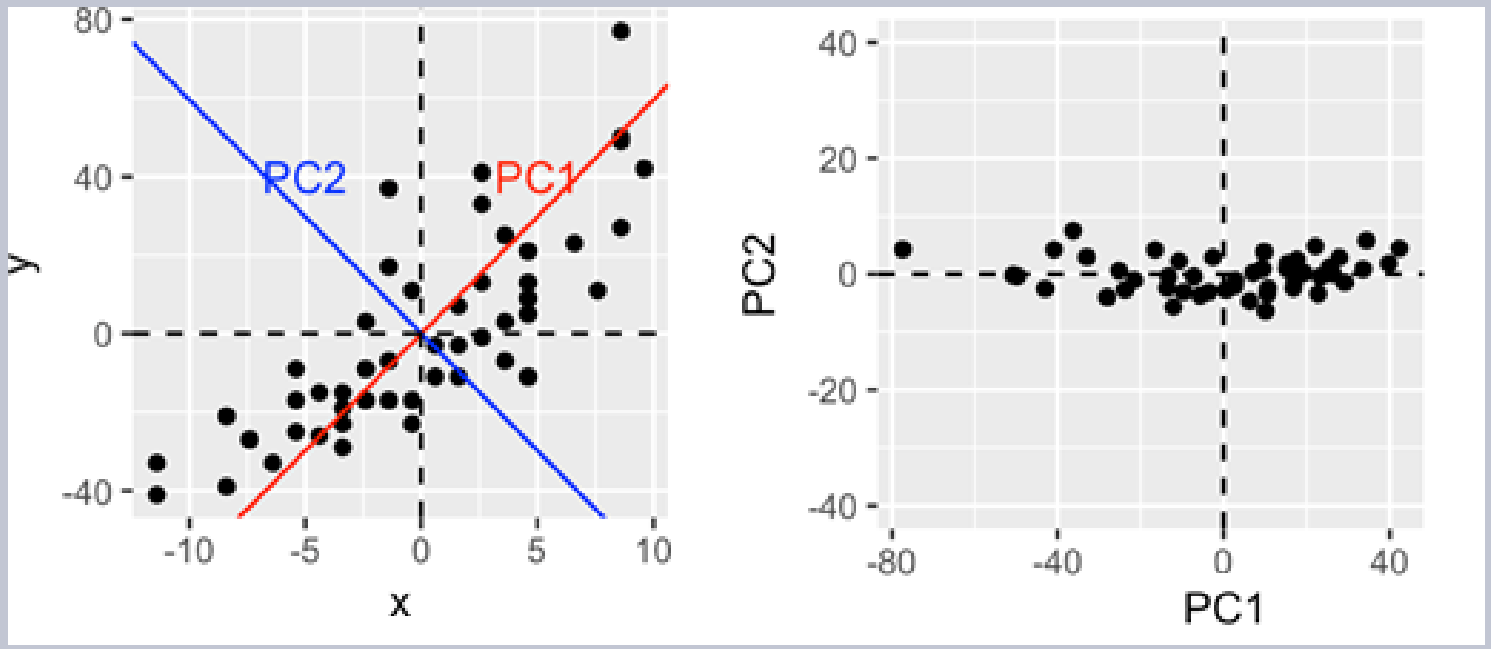


Figura: Representación de las Componentes.

Por otro lado, a la derecha se presenta el resultado del ACP: dos **variables ortogonales** que han sido derivadas de las variables originales (X, Y).

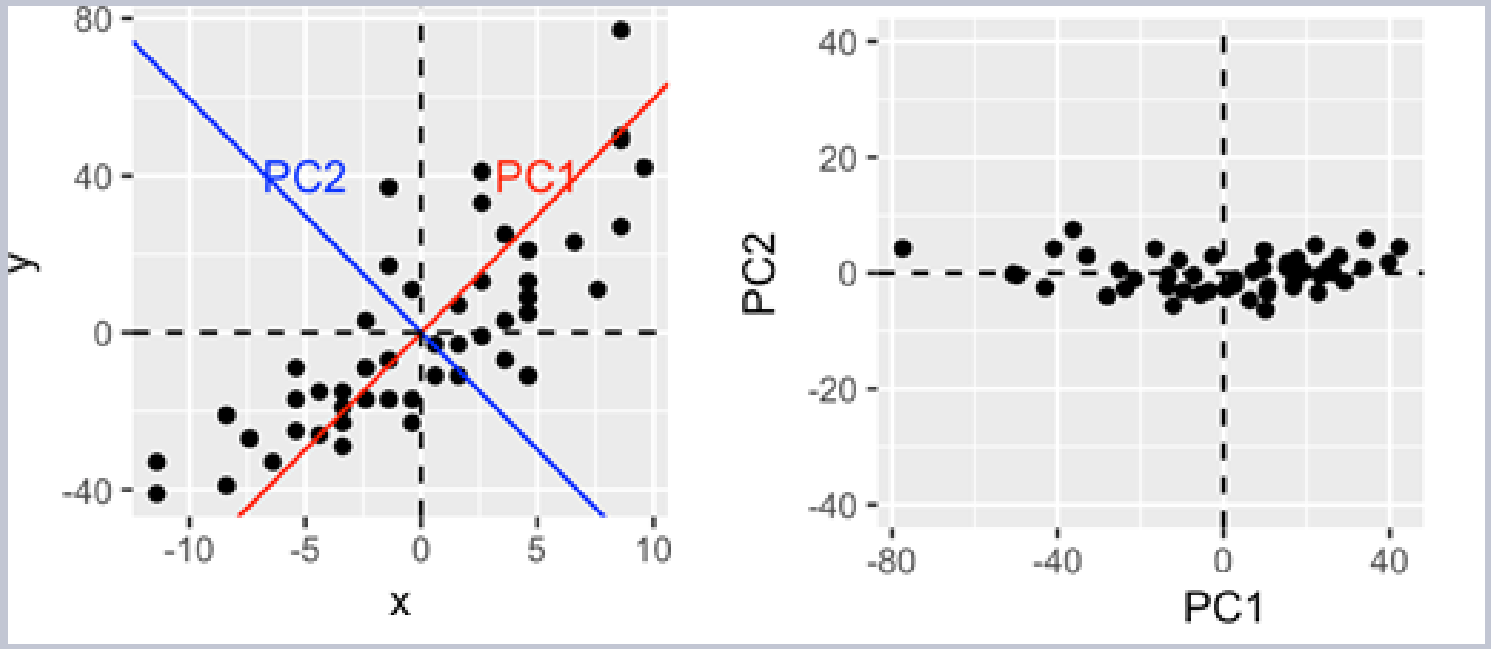


Figura: Representación de las Componentes.

Aunque la **dimensionalidad** no se ha reducido (sigue siendo un espacio bidimensional), lo notable aquí es que la correlación entre las variables originales ha sido eliminada. Las nuevas variables, ahora ortogonales entre sí, ofrecen una vista **descorrelacionada** de los datos, preservando la estructura subyacente pero en un marco donde las variables no están linealmente relacionadas.

Requisitos de los datos

Para que un conjunto de datos sea susceptible de análisis mediante el ACP, es vital cumplir con ciertos requisitos:

- **Escala de las Variables**: Las variables de entrada deben estar en la misma escala o ser estandarizadas, para que cada una contribuya de manera equitativa al análisis.
- **Ausencia de Valores Atípicos**: Los datos extremos pueden dificultar el análisis, y su manejo adecuado es fundamental.
- **Datos perdidos**: La ausencia de datos puede complicar el análisis, por lo que pueden ser necesarias técnicas de imputación.

Presuponemos Multicolinealidad

Es fundamental destacar que el ACP presupone correlaciones entre las variables originales. Aunque técnicamente es posible llevar a cabo el análisis en ausencia de correlaciones, el resultado sería trivial y no proporcionaría ninguna comprensión nueva o valiosa acerca de la estructura de los datos. En otras palabras, sin correlaciones entre las variables, el ACP no obtendría ningún resultado útil.

Supongamos que tenemos un conjunto de datos con n observaciones y p variables donde X_{ij}, es el valor de la observacion i-esima, en la variable j-esima, y queremos reducirlo a k componentes principales, entonces:

- **Estandarización de los Datos**: Si las escalas de las variables originales difieren, deben ser estandarizadas:

$$Z_{ij} = \frac{X_{ij} - \bar{X}_j}{s_j}, i \in n, j \in p,$$

donde $\bar{X}_j$ es la media de la variable j-esima, y s_j es su desviación estándar.

- **Cálculo de la Matriz de Covarianzas:** Si los datos originales están en la misma escala, (poco habitual), podremos utilizar la matriz de covarianzas, la cual, es una **matriz cuadrada** $p \times p$ que contiene las covarianzas entre cada par de variables originales. Se calcula como:

$$C = \frac{1}{n} \sum_{i=1}^{n} (X_i - \bar{X})(X_i - \bar{X})^T,$$

donde C es la matriz de covarianzas y $\bar{X}$ es el vector de medias de las variables originales.

- **Cálculo de la Matriz de Correlaciones:** Si las variables originales no están medidas en la misma escala, entonces, utilizaremos la matriz de correlaciones, la cual, se calcula a partir de los datos estandarizados y vuelve a ser una matriz cuadrada $p \times p$ que contiene las correlaciones entre cada par de variables estandarizadas. Se calcula como:

$$R = \frac{1}{n}\sum_{i=1}^{n}(Z_i - \bar{Z})(Z_i - \bar{Z})^T = \frac{1}{n}\sum_{i=1}^{n} Z_i Z_i^T,$$

donde Z_i es la i-ésima fila de la matriz estandarizada Z, y $\bar{Z}$ es el vector de las medias de Z.

- **Determinación de los Valores Propios:** A partir de la matriz de covarianza (o de correlaciones), se calculan los valores propios, resolviendo la ecuación característica $det(\Sigma - \lambda I) = 0$, donde R es la matriz de covarianzas o la matriz de correlaciones, I es la matriz identidad, matriz de dimensión $p \times p$ con unos en la diagonal y ceros en todas las demás posiciones; y λ es el vector que contiene el conjunto de valores propios

- **Determinación de los k primeros Valores Propios:** Los autovalores se ordenan en orden descendente, y se eligen los primeros k, que representarán los componentes principales. Para elegir estos k primeros, hay que tener en cuenta que el valor de cada uno de los autovalores λ_i para $i = 1, ..., p$, es proporcional a la variabilidad explicada por las componentes asociadas. Por ejemplo, estando los autovalores ordenados, tal que $\lambda 1 \geq \lambda_2 \geq ... \geq \lambda_p$, la componente asociada al primer autovalor λ_1, explica un $\frac{\lambda_1}{\sum_{i=1}^{p} \lambda_1} * 100$ por ciento de la variabilidad total de las variables originales.
- **Determinación de los vectores propios asociados:** Una vez que tenemos los valores propios λ, podemos encontrar los autovectores asociados (**w**), resolviendo la siguiente ecuación lineal para cada λ: $(R - \lambda I)x = 0$. Donde x es el vector propio que estamos buscando.

- **Construcción de la Matriz de Transformación:** Los primeros k vectores propios forman la matriz de transformación. Es decir, $W = [w_1, w_2, \ldots, w_k]$, donde w_i, para $i = 1, \ldots, k$ son los primeros k vectores propios.
- **Cálculo de los Componentes Principales:** Una vez que se ha obtenido la matriz de transformación W, las componentes principales CP se pueden calcular como la proyección de los datos originales X o los datos estandarizados Z en el espacio de las nuevas dimensiones (componentes principales). Esto se realiza mediante una multiplicación matricial entre los datos y la matriz de transformación:

$$CP = XW \quad \text{ó} \quad CP = ZW$$

donde CP es una matriz de dimensiones $n \times k$ que contiene los componentes principales de los datos. Cada columna de CP representa un componente principal, y cada fila de CP representa los componentes principales para una observación individual en el conjunto de datos original. Este paso produce las coordenadas de las observaciones en el nuevo espacio definido por los componentes principales.

Aspectos a tener en cuenta

Pese a que las variables se encuentren en la misma escala, siempre es aconsejable estandarizar los datos, por los siguientes motivos:

- **Influencia de Variables:** Si no estandarizas, las variables con mayor variabilidad tendrán más peso en la formación de componentes principales. Esto puede ser problemático si la variabilidad es alta debido a ruido o errores de medición, y no porque la variable sea particularmente importante para el fenómeno estudiado.
- **Comparabilidad:** Si planeas comparar los resultados de tu ACP con otros estudios que también utilizan ACP pero en diferentes escalas, la estandarización podría ser esencial para hacer que los resultados sean comparables.

Determinar K

Una de las **decisiones** fundamentales en el Análisis de Componentes Principales es la selección del número de componentes principales, denotado como k, que se deben retener.

La elección de k es esencial para garantizar que el ACP capture una **cantidad significativa de la variabilidad** presente en los datos originales sin incluir componentes innecesarios. Una técnica común para determinar k es utilizar el ***método del codo***, que se basa en el gráfico de la varianza explicada.

Determinar K

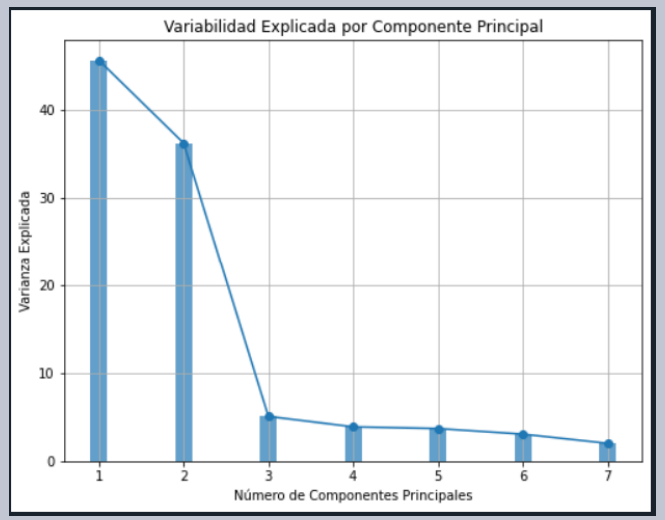


Figura: Representación de la variabilidad explicada

En este gráfico, el **eje x** representa el número de componentes y el **eje y** representa la proporción de varianza explicada. Buscamos el punto en el que agregar componentes adicionales ya no proporciona una ganancia significativa en la varianza explicada. Este punto se asemeja a la forma de un -codo- en la curva, y marca el número óptimo de componentes a retener.

Conceptos clave

En el contexto del Análisis de Componentes Principales, es fundamental comprender la **relación** entre las componentes principales y las variables originales. Esta relación se basa en conceptos clave:

- λ_i: Representa el **autovalor** asociado a la i-ésima componente principal (CP_i) obtenido durante el ACP. Los autovalores indican cuánta varianza (variabilidad) se explica por cada CP_i. Un autovalor alto (λ_i grande) implica que CP_i retiene una gran cantidad de información o variabilidad de los datos originales, mientras que un autovalor bajo (λ_i pequeño) indica que CP_i retiene menos información.

Conceptos clave

- e_{ij}: Representa el coeficiente ubicado en la posición ij del vector propio asociado a la CP_i. Este coeficiente indica la contribución relativa de la variable original X_j en la construcción de la CP_i. En otras palabras, e_{ij} **muestra cuánto peso tiene la variable X_j en la definición de los valores de CP_i**.
- $Cov(CP_i, X_j)$: La covarianza entre la i-ésima componente principal (CP_i) y la j-ésima variable original (X_j) se calcula como $\lambda_i \cdot e_{ij}$. Esta covarianza nos proporciona información sobre la relación lineal entre CP_i y X_j. Si el valor resultante es positivo, significa que ambas variables tienden a aumentar o disminuir juntas (correlación positiva). Si es negativo, indica que una variable tiende a aumentar cuando la otra disminuye (correlación negativa). Un valor cercano a cero sugiere que no hay una fuerte relación lineal entre CP_i y X_j.

Conceptos clave

- $Corr(CP_i, X_j)$: La correlación entre una componente principal CP_i y una variable X_j se calcula como

$$Corr(CP_i, X_j) = \frac{Cov(CP_i, X_j)}{\sqrt{Var(CP_i)Var(X_j)}} = \frac{\lambda_i e_{ij}}{\sqrt{\lambda_i S_j^2}} = e_{ij}\frac{\sqrt{\lambda_i}}{S_j},$$

y estandariza el valor de la covarianza anterior entre $[-1, 1]$. Esta estandarización es proporcional al coeficiente de esa variable en la definición del componente, y el coeficiente de proporcionalidad es el cociente entre la raíz cuadrada del autovalor λ_i y la desviación estándar de la variable X_j, denotada como S_j.

Para evaluar si las nuevas variables generadas por el ACP capturan eficazmente la información contenida en las variables originales (VO), y para determinar qué variables se explican mejor (o peor) mediante estas nuevas componentes, utilizamos una medida conocida como -**cosenos al cuadrado**- calculados como:

$$Cos_{ij}^2 = Corr^2(CP_i, X_j).$$

Los cosenos al cuadrado, a pesar de su nombre, no están relacionados directamente con la función coseno, sino que se derivan de la geometría subyacente del ACP. Estos valores representan las correlaciones al cuadrado entre cada variable original y las componentes principales. **Expresan la proporción de la varianza de cada variable original que se explica mediante cada componente principal.**

En otras palabras, **los cosenos al cuadrado nos indican cuánto de la variabilidad de una variable original está contenida en cada componente principal**. Un valor cercano a **1** implica que la variable se explica en gran medida por la componente, mientras que un valor cercano a **0** indica que la componente tiene poco poder para explicar la variabilidad de esa variable.

El uso de los cosenos al cuadrado es esencial para evaluar la capacidad del ACP para resumir y retener información relevante de las variables originales, lo que nos permite identificar qué variables son más influyentes en la definición de cada componente principal.

Para comprender cómo cada variable original contribuye a la construcción de las CP, podemos calcular su contribución específica, dada por:

$$Contribucion_{ji} = Cos_{ij}^2 \sqrt{\lambda_i}$$ **para todo i=1,...,k; j=1,...,p.**

Esta fórmula nos permite cuantificar la influencia de cada variable en la definición de una CP.

Estas contribuciones están en **términos relativos**, por lo que se acostumbra a **normalizar** estas contribuciones entre $[0, 1]$ o entre $[0, 100]$ para que sea más fácilmente interpretable y comparable.

En el ACP, a menudo se utiliza para resumir y comprender las relaciones entre variables en un conjunto de datos. Sin embargo, en situaciones del mundo real, es común que surjan nuevos elementos o variables que no estaban presentes en el conjunto de datos original. Estos nuevos elementos se conocen como **-individuos suplementarios-** cuando se refieren a observaciones y **-variables suplementarias-** cuando se refieren a características adicionales o medidas.

La inclusión de individuos y variables suplementarias en el ACP nos permite evaluar cómo se sitúan en relación con la estructura existente de las componentes principales.

INDIVIDUOS SUPLEMENTARIOS

Para tratar a estas nuevas observaciones, debemos **estandarizar** sus variables, utilizando la media y la desviación estándar del conjunto de datos original. Posteriormente, los añadimos a nuestra base de datos estandarizada para proceder al **cálculo de sus coordenadas en las CP**.

VARIABLES SUPLEMENTARIAS

Agregar variables categóricas al ACP enriquece la comprensión de los datos al considerar la influencia de categorías adicionales. **Representar los centroides de estas categorías en los ejes de las componentes principales** es clave. Los centroides actúan como resúmenes de la tendencia central de cada categoría, permitiendo visualizar y entender mejor las relaciones entre diferentes categorías y las CP. Esto revela patrones y relaciones sutiles, añadiendo una dimensión adicional al análisis de la estructura de datos.