

ntic master School

UNIVERSIDAD COMPLUTENSE DE MADRID

Análisis Cluster

Minería de Datos y Modelización Predictiva

Máster en Big Data, Data Science & Inteligencia Artificial
Universidad Complutense de Madrid





- **Contexto:** En la **recopilación masiva** de datos, el manejo de múltiples variables presenta un desafío. El Análisis de Clustering ofrece una manera eficiente de **simplificar y resumir esta información**.
- **Machine Learning:** A diferencia de los **algoritmos supervisados**, el Clustering opera **sin etiquetas predefinidas**, enfocándose en agrupar datos en lugar de clasificarlos en categorías fijas.
- **Técnica Estadística:** Busca organizar datos en **grupos coherentes**, agrupando elementos similares.

- **Interpretación Visual:** Reduce la complejidad a grupos para una **representación gráfica efectiva**.
- **Versatilidad:** Aplicable en múltiples campos, tan diferentes como la biología y economía, revelando patrones ocultos y avanzando en **diversas disciplinas**.
- **Conclusión:** Más que una técnica de agrupamiento, es una **herramienta multifacética** esencial para el análisis de datos, mejorando la interpretación y eficiencia en diversas áreas.

¿En que consiste el Análisis cluster?

- **Definición:** Técnica estadística para **clasificar** elementos en grupos basándose en **similitudes**. Busca máxima **homogeneidad dentro** de los grupos y máxima **heterogeneidad entre** ellos.
- **Proceso Inicial:** Comienza con la selección de una **medida de similitud** o distancia. Utiliza **algoritmos** para agrupar elementos según estas medidas.
- **Algoritmos de Clustering:**
  - ***Jerárquico:*** Forma grupos secuencialmente, ya sea fusionando (**aglomerativo**) o dividiendo (**divisivo**). No se conoce el número de grupos de antemano.
  - ***No Jerárquico:*** Se predefine un número de grupos. Las observaciones se asignan a estos grupos basándose en su cercanía o lejanía.

¿En que consiste el Análisis cluster?

- **Importancia de la Selección:** El éxito depende de la elección adecuada de la medida de distancia y del algoritmo. Diferentes elecciones pueden variar significativamente los resultados.
- **Interpretación de Grupos:** La formación de grupos revela **patrones**, tendencias y relaciones en los datos que pueden no ser evidentes sin el agrupamiento.

- **Datos a analizar:** Longitud y anchura del pico de pingüinos.

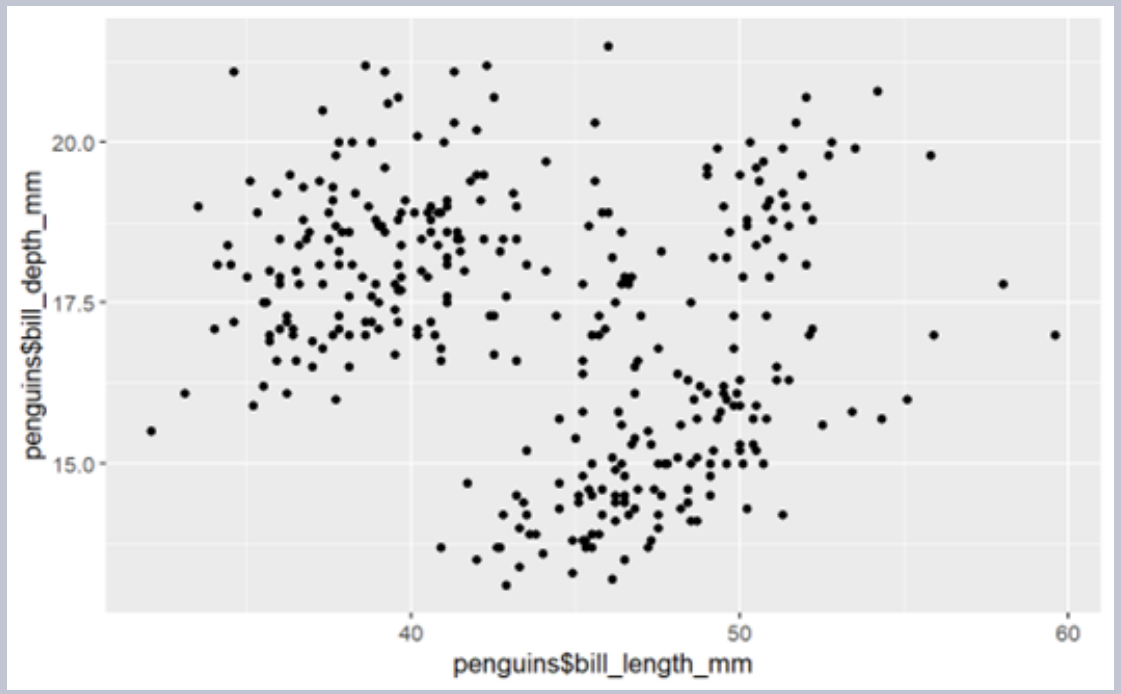


Figura: Dispersión de la nube de puntos

- **Observación Inicial:** Aparente falta de correlación en un diagrama de dispersión.

- **Clave del Análisis:** Identificar distintos grupos o subespecies de pingüinos con características únicas.
- **Ejercicio Preliminar de Clustering:** Identificación visual de posibles agrupaciones, sugiriendo la existencia de diferentes subespecies.

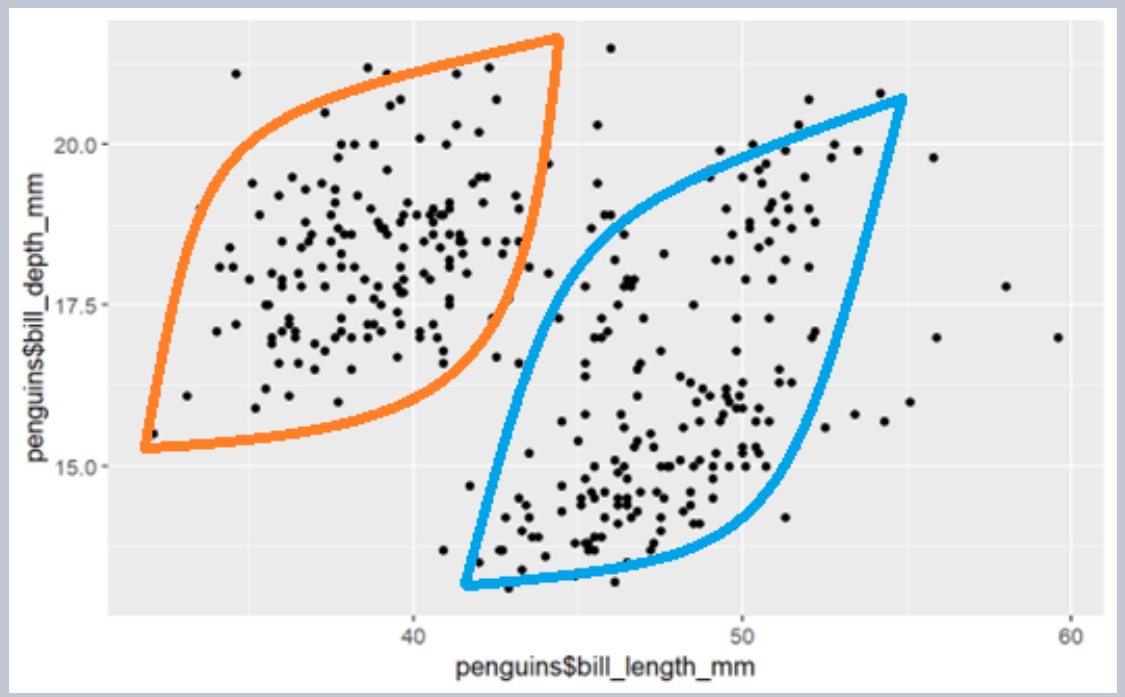


Figura: Ejemplo de posibles agrupaciones de pingüinos

Otros ejemplos podrían ser:

- **Marketing:** Agrupar potenciales clientes según sus necesidades para campañas publicitarias.
- **Banca:** Determinar perfiles de clientes para concesión de préstamos.
- **Genética:** Identificar grupos de individuos con carga genética similar.

Todos los casos propuestos tienen un **Objetivo Común:** Formar grupos de individuos con características similares basadas en determinadas variables.

Requisitos de los datos

Para realizar un análisis de clustering efectivo, es importante que el conjunto de datos cumpla con ciertos requisitos. A continuación, se detallan algunos de estos:

- **Escala de las Variables**: Las variables de entrada deben estar en la misma escala o ser estandarizadas, para que cada una contribuya de manera equitativa al análisis.
- **Ausencia de Valores Atípicos**: Los valores extremos pueden distorsionar los grupos formados en el clustering. Es importante identificar y manejar adecuadamente estos valores atípicos antes de realizar el análisis.
- **Datos perdidos**: La presencia de datos faltantes puede afectar la calidad del clustering. Puede ser necesario aplicar técnicas de imputación de datos.
- **Minimizar la Correlación entre Variables**: Es recomendable que las variables no estén fuertemente correlacionadas. Las variables correlacionadas pueden aportar información redundante, lo que podría conducir a una sobrerrepresentación de ciertas características y afectar la formación de los grupos. Considerar la reducción de dimensionalidad o la selección de variables puede ser útil en tales casos.

El análisis de clustering implica una serie de pasos estructurados para formar grupos homogéneos de datos. Estos pasos se pueden resumir de la siguiente manera:

- **Evaluación del Parecido entre Observaciones:**
  - Determinar la proximidad o similitud entre las observaciones utilizando **medidas de distancia**.
- **Evaluación del Parecido entre Variables:**
  - Evaluar la similitud o correlación entre las variables, si el enfoque del clustering es sobre las características en lugar de las observaciones.
- **Selección del Tipo de Agrupación:**
  - Decidir entre enfoques de agrupación **jerárquicos** (donde el número de clusters se determina durante el análisis) y **no jerárquicos** (donde se debe definir el número de clusters de antemano).

- **Elección del Algoritmo de Agrupación:**
  - Seleccionar un algoritmo específico de agrupación, como k-means, agrupamiento jerárquico, etc., en función del tipo de agrupación elegido.
- **Determinación del Número Óptimo de Clusters:**
  - Establecer criterios para definir el número adecuado de clusters, especialmente en métodos no jerárquicos.
- **Interpretación y Validación de los Clusters Formados:**
  - Analizar e interpretar los grupos resultantes para validar su significado y relevancia.

Consideremos dos observaciones (x, y), que constan en p variables, es decir, $(x_i, y_i) = \{(x_1, x_2, \ldots, x_p), (y_1, y_2, \ldots, y_p)\}$. Entre las medidas de distancia más utilizadas para variables numéricas, destacan las siguientes:

- **Distancia Euclídea**: Es la medida de distancia más común y se calcula como:

$$d_{\text{Euclídea}}(x, y) = \sqrt{\sum_{i=1}^{p}(x_i - y_i)^2} \tag{1}$$

- **Distancia Minkowski**: Una forma generalizada que abarca distintos tipos de distancias, incluyendo la Euclídea y la Manhattan. Se define como:

$$d_{\text{Minkowski}}(x, y) = \left(\sum_{i=1}^{p}|x_i - y_i|^k\right)^{1/k} \tag{2}$$

  Sí $k = 2$ tenemos la distancia Euclídea, y para $k = 1$, la distancia Manhattan.

NOTA

Aunque las distancias Euclídea y Manhattan son las más utilizadas en análisis de clustering, ambas son casos particulares de la distancia Minkowski.

En el análisis de clustering, además de agrupar observaciones, puede ser útil agrupar variables que exhiban comportamientos similares o estén correlacionadas entre sí. Para ello, se emplean medidas de distancia basadas en coeficientes de correlación. A continuación, describimos algunas de estas medidas:

- **Distancia de Correlación de Pearson**: Esta medida evalúa la similitud entre dos variables basándose en la correlación lineal de Pearson. Se calcula como:

$$d_{\text{Pearson}}(x, y) = 1 - \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \sum_{i=1}^{n}(y_i - \bar{y})^2}} \tag{3}$$

  donde x y y son observaciones individuales, y $\bar{x}$ y $\bar{y}$ son sus medias .

El resultado de la correlación de Pearson es un valor que varía entre -1 y 1, donde:

- Un valor de -1 indica una relación lineal perfecta negativa.
- Un valor de 1 indica una relación lineal perfecta positiva.
- Un valor de 0 sugiere que no hay relación lineal.

- **Distancia de Correlación de Spearman**: Utilizada cuando los **datos** son **ordinales** o no cumplen con los supuestos de la correlación de Pearson. La correlación de Spearman se basa en los rangos de los datos, lo que la hace menos sensible a valores atípicos y apropiada para relaciones monótonas no lineales.

$$\rho_{\text{Spearman}} = 1 - \frac{6 \sum_{i=1}^{n} d_i^2}{n(n^2 - 1)} \tag{4}$$

Donde:

- d_i representa la diferencia entre los rangos de cada par de observaciones emparejadas.
- n es el número total de pares de observaciones.

La correlación de Spearman es un valor que varía entre -1 y 1, donde:

- Un valor de -1 indica una relación monótona perfecta negativa.
- Un valor de 1 indica una relación monótona perfecta positiva.
- Un valor de 0 sugiere que no hay relación monótona.

Una relación monótona significa que las variables tienden a cambiar juntas,

- **Distancia de Correlación de Kendall**: Esta medida evalúa la concordancia entre dos conjuntos de datos basándose en la concordancia o discordancia de los pares de observaciones.

$$\tau_{\text{Kendall}} = \frac{\text{N pares concordantes} - \text{N pares discordantes}}{\text{N pares posibles}} \tag{5}$$

Un par de observaciones se considera concordante si el orden relativo de las observaciones es el mismo en ambos conjuntos de datos.

El resultado del coeficiente de asociación de Kendall es un valor que varía entre -1 y 1, donde:

- Un valor de -1 indica una falta de concordancia completa entre los conjuntos de datos.
- Un valor de 1 indica una concordancia perfecta.
- Un valor de 0 sugiere que no hay una concordancia ni discordancia sistemática.

Los métodos de **clasificación jerárquicos** organizan los datos en una **estructura arborescente**, comenzando con grupos que son observaciones individuales y agrupándolos progresivamente en clusters de niveles superiores. A diferencia de los métodos no jerárquicos, en la clasificación jerárquica **no** se conoce de antemano el número final de clusters.

Los pasos para realizar un *Clustering* Jerárquico incluyen:

1. Iniciar con tantos grupos como observaciones existan.
2. Decidir una medida de distancia entre cluster.
3. Decidir una medida de distancia entre observaciones de un mismo cluster.
4. **Crear una matriz** simétrica de dimensión $n \times n$ que represente las **distancias** entre todos los pares de observaciones.
5. **Agrupar** las dos observaciones más **cercanas**, reduciendo el número total de clusters en uno.

1. Calcular una nueva matriz de **distancias entre los clusters** formados.
2. **Repetir** el proceso de agrupación.
3. Continuar este proceso hasta que todas las observaciones estén agrupadas en un **único** cluster.

Es crucial definir claramente tanto la distancia entre observaciones individuales como la distancia entre clusters. Por lo tanto, con el mismo conjunto de datos y variando estas definiciones, se pueden obtener **diferentes clasificaciones jerárquicas**.

EVALUANDO LA DISTANCIA ENTRE CLUSTER

Supongamos que tenemos una agrupación denominada C_k y otra agrupación C_l, los algoritmos más comunes son:

- **Enlace simple o del vecino más cercano**: Se establece la siguiente distancia:

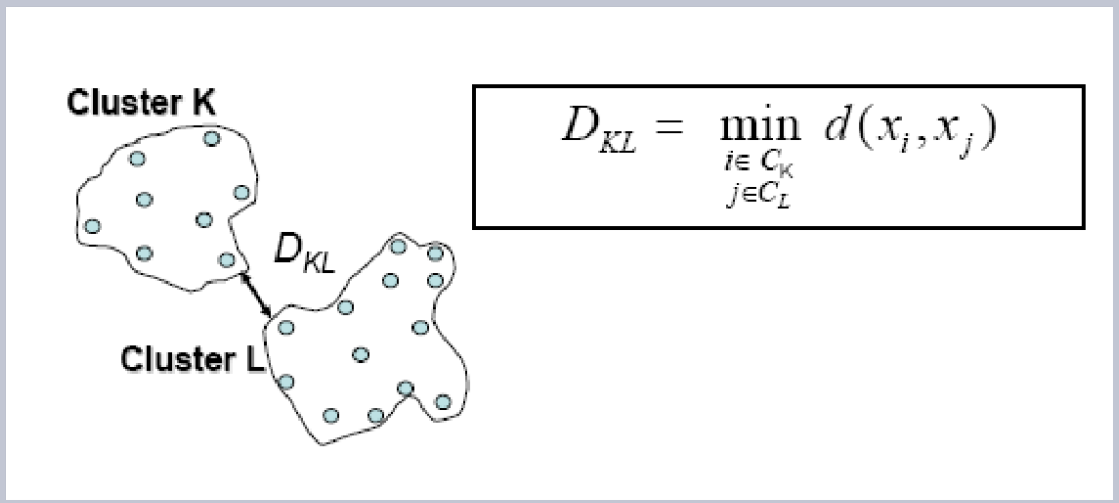


Figura: Distancia entre cluster: Vecino más cercano

Tienden a crear grupos con muchas observaciones.

EVALUANDO LA DISTANCIA ENTRE CLUSTER

- **Enlace completo o del vecino más alejado**: La distancia elegida entre dos cluster será:

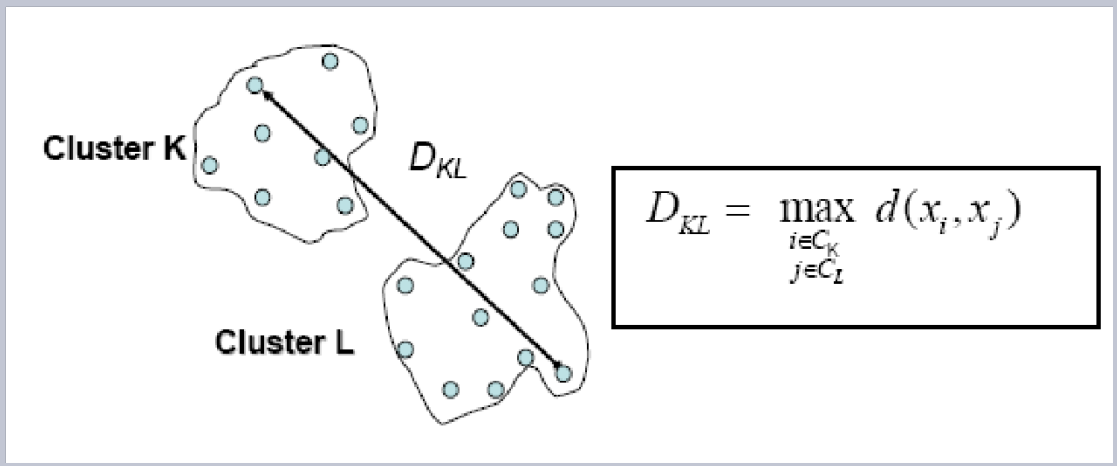


Figura: Distancia entre cluster: Vecino más lejano

Con este método, los grupos formados son más compactos que los obtenidos con el método del vecino más próximo.

EVALUANDO LA DISTANCIA ENTRE CLUSTER

- **Enlace medio**: La distancia entre dos agrupaciones es la distancia media entre una observación de la agrupación C_k y otra observación de la agrupación C_l.

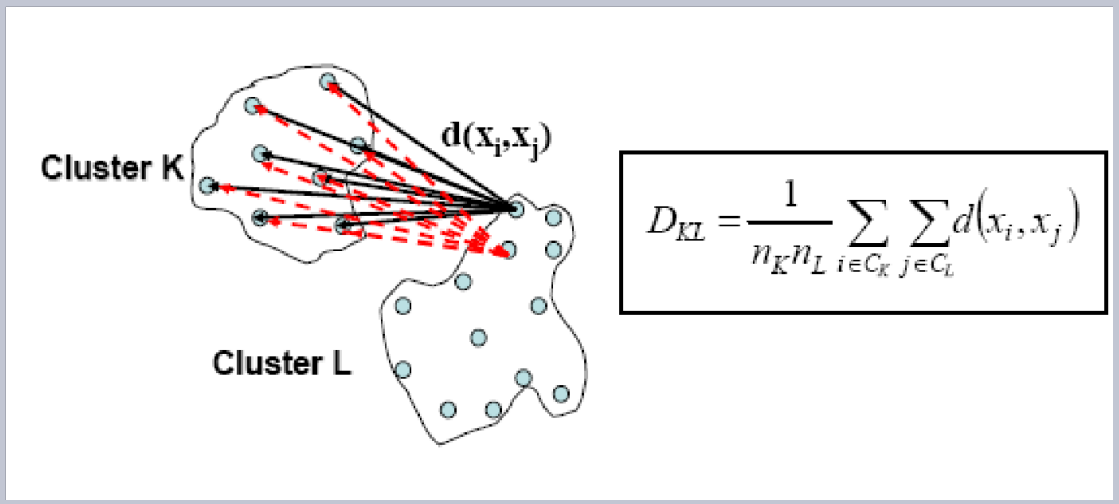


Figura: Distancia entre cluster: enlace medio

Tiende a crear grupos que son más equilibrados en términos de tamaño y forma, es decir, grupos con varianza similar.

EVALUANDO LA DISTANCIA ENTRE CLUSTER

- **Distancia entre centroides**: La distancia entre grupos será la distancia entre los centroides, que representarán el vector medio obtenido en las p variables para todos los individuos que formen parte del grupo.

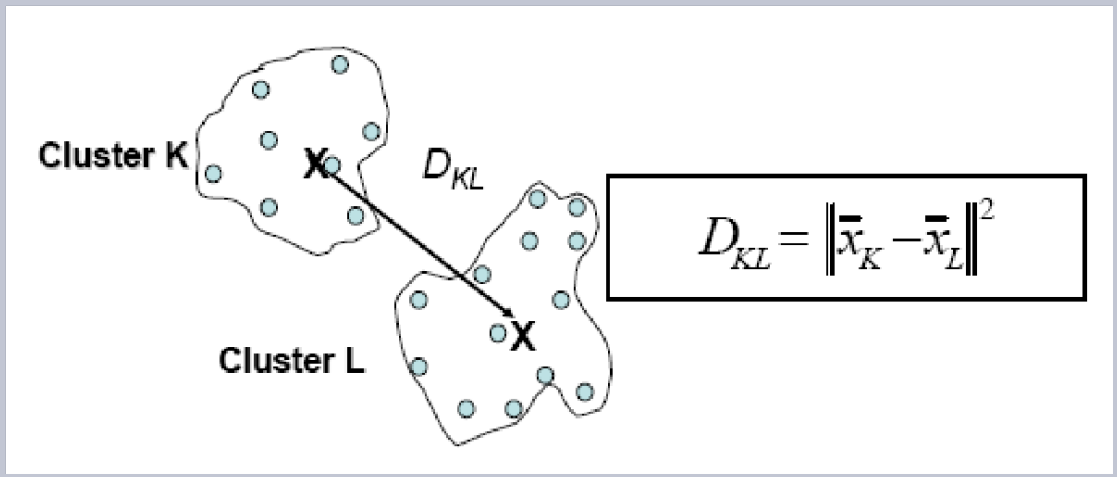


Figura: Distancia entre centroides

EVALUANDO LA DISTANCIA ENTRE CLUSTER

- **Distancia de Ward o de la Mínima Varianza**: Selecciona, en cada nivel del proceso de agrupación, la combinación de clusters que minimiza el incremento de la variabilidad total dentro de los clusters resultantes. Este enfoque se basa en la suma de cuadrados de las distancias euclidianas entre las observaciones y el centroide del grupo fusionado.

$$d_{\text{Ward}}(C_i, C_j) = \frac{n_i n_j}{n_i + n_j} \sum_{x \in C_i \cup C_j} \|x - \mu_{C_i \cup C_j}\|^2$$

  - n_i y n_j representan el número de observaciones en los grupos C_i y C_j, respectivamente.
  - x son las observaciones en la unión de los clusters C_i y C_j.
  - $\mu_{C_i \cup C_j}$ es la media de las observaciones en la unión de los conglomerados C_i y C_j.
  - La suma se realiza sobre todas las observaciones en la unión de C_i y C_j, calculando la distancia euclidiana al cuadrado entre cada observación y el centroide del grupo fusionado.

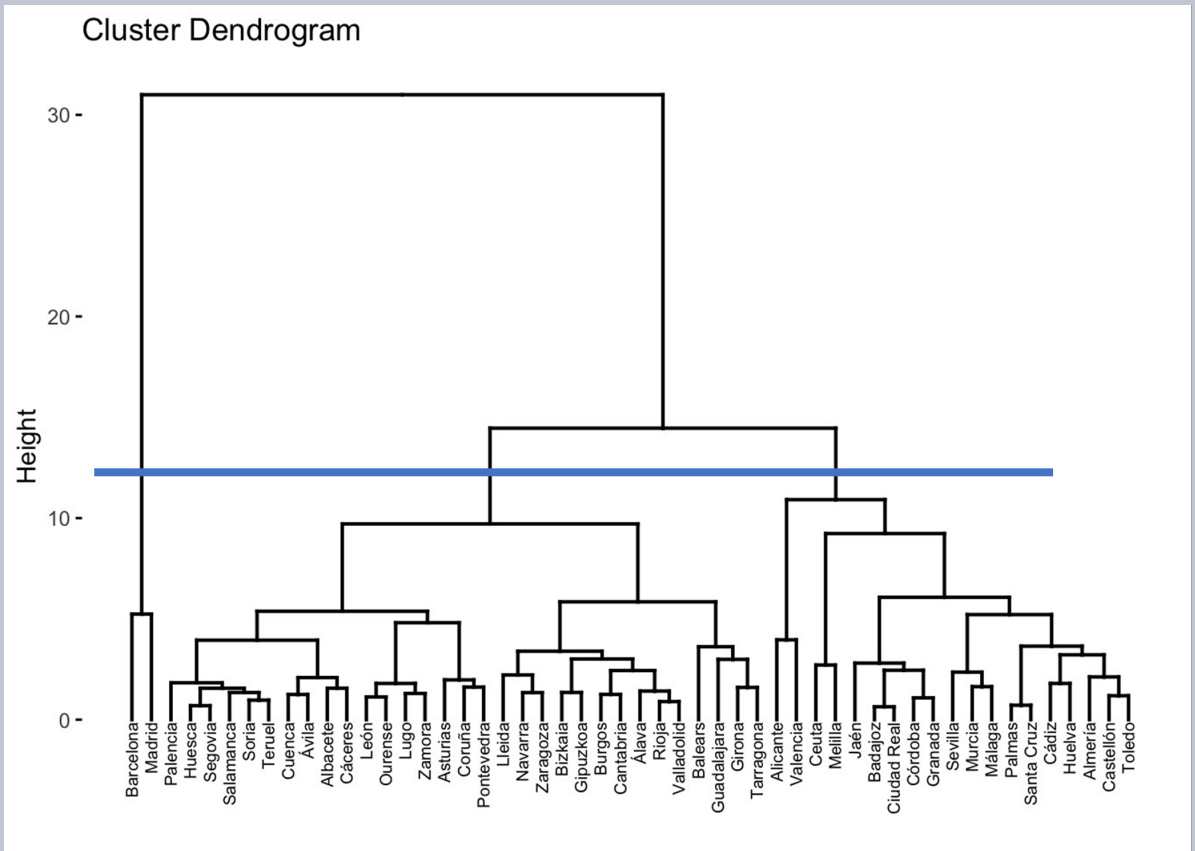
Ventajas de la distancia de Ward

Algunas de sus ventajas de la distancia de Ward son:

- **Minimización de la varianza**: Evalúa el aumento de la varianza que resulta de la fusión de conglomerados y busca minimizar este aumento. Esto puede dar lugar a **agrupaciones más compactas y homogéneas**.
- **Equilibrio de tamaños de conglomerados**: tiende a producir conglomerados de tamaños aproximadamente iguales.
- **Menos Sensible a las Condiciones Iniciales**: A diferencia de otros métodos de clustering, donde la elección inicial de algún parámetro puede afectar significativamente los resultados, el método de Ward es menos susceptible a estas condiciones iniciales.

EL DENDROGRAMA

El análisis clúster jerárquico se ilustra con frecuencia mediante un dendrograma. Este gráfico tiene la estructura de un árbol y visualiza el proceso de formación de grupos y la secuencia de fusiones entre ellos. Las alturas de las conexiones en el dendrograma representan las distancias entre los grupos que se combinan.



Los algoritmos de agrupación no jerárquicos requieren definir previamente el número de grupos (K) en los que se dividirán las observaciones. Por ello, suele preceder un análisis jerárquico para estimar el número más adecuado de clusters. Estos son los pasos típicos que se siguen en un análisis no jerárquico:

1. Elegir K observaciones como centroides iniciales, correspondientes a la cantidad de clusters deseados.
2. Asignar cada observación restante al cluster cuyo centroide sea el más cercano.
3. Reasignar las observaciones a los K clusters según una regla de parada predefinida.
4. Detener el proceso cuando no haya reasignaciones o se cumpla la regla de parada; de lo contrario, regresar al paso 2.

MÉTODOS DE SELECCIÓN DE CENTROIDES

- Tomar las K primeras observaciones sin datos faltantes.
- Escoger observaciones que maximicen una distancia predefinida entre centroides sucesivos.
- Seleccionar K observaciones al azar.
- Optar por centroides que estén lo más lejanos posible entre sí.
- Emplear centroides definidos por el investigador.

Una vez identificados los centroides, se forman los clusters iniciales asignando cada una de las $N - K$ observaciones restantes al cluster con el centroide más próximo.

REASEIGNACIÓN DE OBSERVACIONES

- Calcular el centroide de cada cluster y reasignar observaciones al cluster con el centroide más cercano. **Los centroides se recalculan tras cada reasignación y el proceso se repite hasta que el cambio en los centroides es menor que un umbral preestablecido por un criterio de convergencia**.
- Reasignar observaciones minimizando un criterio estadístico, como la suma de cuadrados dentro de los clusters.

DETERMINACIÓN DE NÚMERO DE CLUSTERS K

Uno de los desafíos más significativos es determinar el número óptimo de clusters (K), dicho desafío esta instrínsicamente relacionado con la evaluación de la calidad de nuestras agrupaciones. Ya que la bondad de ajuste de los clusters nos proporciona información valiosa sobre la adecuación del número de clusters elegido.

MEDIDAS DE BONDAD DE AJUSTE

Para evaluar una solución de agrupación, se pueden calcular varias medidas relacionadas con la variabilidad dentro de los grupos, entre grupos y la variabilidad total.

MEDIDAS DE BONDAD DE AJUSTE

1. **Variabilidad dentro de los conglomerados (suma de cuadrados dentro de los grupo, WCSS):**

   El WCSS mide la variabilidad dentro de cada grupo. Cuantifica qué tan lejos están los puntos de datos dentro de un grupo del centroide del grupo.

$$\text{WCSS} = \sum_{i=1}^{K} \sum_{j=1}^{n} d(x_{ij}, c_i)^2, \tag{6}$$

   donde

   - K es el número de conglomerados.
   - n es el número de puntos de datos en el grupo i.
   - $d(x_{ij}, c_i)$ es la distancia entre el punto de datos x_{ij} y el centroide del grupo i.

MEDIDAS DE BONDAD DE AJUSTE

1. **Variabilidad entre conglomerados (suma de cuadrados entre conglomerados, BCSS):** El BCSS mide la variabilidad entre los centroides de los conglomerados.

$$\text{BCSS} = \sum_{i=1}^{K} n_i \cdot d(c_i, c)^2, \tag{7}$$

donde

- n_i es el número de datos en el grupo i.
- $d(c_i, c)$ es la distancia entre el centroide del grupo i y el centroide general c.

MEDIDAS DE BONDAD DE AJUSTE

1. **Variabilidad total (Suma total de cuadrados, TSS):**

   El TSS mide la variabilidad total de los datos y es la suma de las distancias al cuadrado entre los puntos de datos y el centroide general.

$$\text{TSS} = \sum_{i=1}^{K} \sum_{j=1}^{n} d(x_{ij}, c)^2, \tag{8}$$

donde

- n es el número total de datos.
- $d(x_{ij}, c)$ es la distancia entre el punto de datos x_{ij} y el centroide general c.

MEDIDAS DE BONDAD DE AJUSTE

1. **Coeficiente de determinación (R-cuadrado o R^2):**

   R^2 es una medida de qué tan bien el agrupamiento explica la variabilidad de los datos. Se calcula como la relación entre BCSS y TSS.

$$R^2 = \frac{\text{BCSS}}{\text{TSS}} = 1 - \frac{\text{WCSS}}{\text{TSS}}. \tag{9}$$

Estas medidas pueden ayudarle a evaluar la calidad de su solución de clustering. Los valores de R^2 más altos indican una mejor solución de agrupación, ya que explican una mayor parte de la variabilidad total de los datos. Los valores más bajos de WCSS sugieren que los puntos de datos están más cerca de sus respectivos centroides de grupo.

MÉTODO DEL CODO

- **Objetivo**: Determinar el número óptimo de conglomerados (K) en un algoritmo de agrupamiento.
- **Proceso**:
  1. Calcular WCSS (suma de cuadrados dentro de un grupo) para diferentes valores de K.
  2. Trazar WCSS contra K. Buscar el 'punto codo', donde la curva se dobla, indicando el número óptimo de grupos.

COEFICIENTE DE SILUETA

- **Propósito**: Evaluar y graficar la calidad de los clusters.
- **Proceso**:
  1. *Calcular la distancia media* $a(i)$: Mide cuán bien se agrupa una observación i en su propio cluster.
  2. *Calcular la distancia media* $b(i)$ *al cluster más cercano*: Mide cuán bien se separa i de los clusters más cercanos.
  3. *Calcular el coeficiente de silueta* $s(i)$: $s(i) = \frac{b(i)-a(i)}{\text{máx}\{a(i),b(i)\}}$.
- **Interpretación de** $s(i)$:
  - Cerca de +1: Bien agrupada y lejos de clusters vecinos.
  - Cerca de 0: Cerca de la frontera entre dos clusters.
  - Cerca de -1: Posiblemente asignada al cluster incorrecto.
- **Aplicación**:
  - Proporciona visualización clara del puntaje promedio de silueta para cada K.
  - Ayuda a seleccionar el número de clusters que ofrece el mejor equilibrio.

- **Objetivo**: Comprender cada clúster a través de un análisis descriptivo de las variables.
- **Identificación de Miembros**: Determinar los elementos de cada clúster; listados o tablas de pertenencia.
- **Estadísticos Descriptivos**: Medidas como media, mediana, varianza y desviación estándar para cada variable dentro de los clústeres.
- **Comparación entre Clústeres**: Usar estadísticos para diferenciar clústeres en términos de variables analizadas.
- **Perfilado de Clústeres**: Crear perfiles basados en estadísticos, incluyendo gráficas o tablas resumen.
- **Análisis de Variables Significativas**: Identificar variables clave en la formación y descripción de los clústeres.
- **Visualización de Datos**: Utilizar gráficos de barras, histogramas o boxplots para ilustrar características de clústeres.