



MINERÍA DE DATOS Y MODELIZACIÓN PREDICTIVA

Ejercicio Cluster

Descripción del Conjunto de Datos 'iris'

El conjunto de datos `'iris'` es un conjunto clásico en el campo del aprendizaje automático y la estadística y contiene la siguiente información sobre diferentes especies de flores:

- **species:** Es la especie de flor. Hay tres especies en el conjunto de datos: 'setosa', 'virginica' y 'versicolor'.
- **sepal_length_cm:** Longitud del sépalo en centímetros.
- **sepal_width_cm:** Ancho del sépalo en centímetros.
- **petal_length_cm:** Longitud del pétalo en centímetros.
- **petal_width_cm:** Ancho del pétalo en centímetros.

Nos centraremos en evaluar la estructura de los grupos o clústeres existentes en el conjunto de datos. Utilizaremos técnicas de análisis de clúster, tanto jerárquicas como no jerárquicas, para identificar posibles agrupaciones basadas en las características (numéricas) de las flores. Los siguientes son los pasos y tareas a realizar:

1. **Calcular la Matriz de Distancias:** Inicialmente, calcular la matriz de distancias entre las observaciones, empleando una medida de distancia adecuada, como la distancia euclidia.
2. **Determinación del Número de Clústeres - Análisis Jerárquico:** Utilizar métodos de clustering jerárquico para explorar la estructura de los datos. Aplicar técnicas como el dendrograma para visualizar y determinar el número óptimo de clústeres. Aplicar los procemidientos que conozcas que sirvan para decidir el número de clusters. Discutir las decisiones tomadas en este proceso.
3. **Análisis de Clúster No Jerárquico:** Una vez decidido el número de clústeres, realizar un análisis de clúster no jerárquico (K-means) utilizando el número de grupos identificado en el paso anterior.
4. **Evaluación de la Calidad de las Agrupaciones:** Evaluar la calidad de los clústeres formados utilizando el índice de silueta.
5. **Caracterización de los Clústeres:** Caracterizar cada clúster basándose en estadísticos descriptivos y comparar las propiedades distintivas entre ellos.