

Competición de Modelización Predictiva

¡Cliente a la fuga!

Autor: Daniel Martín García y

Elena del Carmen Gavilán García

NUESTRO PROBLEMA

Una compañía telefónica nos ha concedido un proyecto para predecir la fuga de sus clientes antes de que ocurra, de forma que puedan llevar a cabo acciones para la retención de estos clientes en riesgo de abandono. Consideran importante el conocimiento sobre la influencia de las variables en la fuga, por lo que se niegan a utilizar modelos tipo caja negra, abogando por la interpretabilidad.

En el archivo *FugaClientes_training.csv* nos llega la información histórica de su base de clientes que contiene características de los mismos junto con la información de abandono/fuga.

INFORMACION SOBRE LAS VARIABLES

Nombre Variable	Descripción
ID	Identificador único de Cliente
Genero	Género binario (Male/Female)
Conyuge	Cliente con conyuge/compañero/compañera
Mayor65	Cliente mayor de 65 años
PersCargo	Cliente con personas a su cargo
Antigüedad	Antigüedad en meses del contrato
Telf_serv	Cliente tiene servicios de teléfono contratados
VariasLineas	Cliente tiene varias líneas de teléfono
Int_serv	Cliente tiene servicios de internet contratados
Seguridad	Cliente tiene servicio de seguridad contratado
CopiaSeguridad	Cliente tiene servicio de copia de seguridad contratado
Antivirus_disp	Cliente tiene antivirus en dispositivo
Soporte_tecnico	Cliente tiene soporte técnico contratado
TV_streaming	Cliente tiene TV en streaming contratado
Peliculas	Cliente tiene servicio de películas contratado
Contrato	Tipo de contrato de cliente
Fact_sinPapel	Factura sin papel
MetodoPago	Método de pago
FacturaMes	Importe facturado mensual
FacturaTotal	Importe facturado total
Fuga (objetivo)	Cliente abandona la compañía

Nuestro trabajo es, por tanto, ajustar el mejor modelo de predicción para esta variable objetivo **binaria** en los datos de training.

La compañía nos ha pasado los datos *FugaClientes_test.csv* que contiene información de los clientes sin la variable de abandono/fuga con el objetivo de valorar la bondad de nuestro modelo en relación a los modelos presentados por otros equipos de la competencia.

EQUIPOS DE TRABAJO

Para la participación en la competición vamos a formar **4-6 equipos de trabajo** de cara a la exploración completa de posibilidades y la colaboración para la creación del mejor modelo predictivo repartiendo el trabajo (que no es poco!).

Una sola persona representante de cada equipo subirá la entrega grupal consignando los nombres de todos los integrantes en el documento a modo de autoría y por jugar e identificar los equipos, podrías elegir un nombre de Equipo (todo lo absurdo o divertido que se os ocurra…tipo Equipo "Pico y pala" o "las depuradoras finas" o "PrediccionesFiables.com"… lo que queráis!.

ENTREGA

La entrega estará compuesta por:

1. Cuaderno de trabajo **resumen muy escueto** donde se leen los datos, y se muestran **solamente** los **cambios relevantes** por los que han pasado las variables del modelo final (imputaciones, transformaciones, tramificaciones…), el propio **modelo final con su summary** y su capacidad de predicción a un test o en CV.

2. Conjunto de datos *FugaPredict_TuEquipo.csv* que contendrá dos columnas:

    a. *ID* de cada uno de los 690 clientes de test
    b. *Fuga_pred* como variable binaria 0,1 resultado de la predicción para estos clientes dada por nuestro mejor modelo.

METODOLOGÍA TENTATIVA

Para llevar a cabo este ejercicio se podrían seguir los pasos estudiados en el módulo:

1) Lectura e inspección de datos. Tipo de variables, distribuciones, valores extraños, etc.

2) Depuración de los datos.

3) Estudio de variables y relaciones con la variable objetivo

4) Modelado manual

5) Modelado por selección de variables (clásica, aleatoria, Lasso..)

6) Comparación de modelos por validación cruzada repetida

7) Elección justificada del modelo final

8) Evaluación e interpretación de parámetros (¿Cuáles son las variables que más influyen? ¿En qué sentido lo hacen?

9) Búsqueda del punto de corte óptimo para la probabilidad estimada

10) Predicción para los datos de test (utilizando el punto de corte óptimo hallado!!)

11) Construcción del dataset de entrega con el ID y Fuga_pred

Importante: En esta ocasión, se nos presenta un conjunto de datos de Test de verdad! Es decir, sin variable respuesta recogida…Esto hace que el conjunto sea intratable hasta el final de la práctica cuando vamos a predecir con el modelo ajustado en Training. Es decir, nuestro Fuga Training es como el dataset general que utilizamos en las prácticas sobre el que generaremos la partición, validación cruzada etc. Por otro lado, cabe destacar que si el modelo elegido en Training, contiene transformaciones, habría que generarlas para el data Test…en este caso, debido a que las transformaciones se generan de forma automática con la información de la variable objetivo (aquella que maximiza la relación!) Tendremos que buscarnos un poco la vida para poder predecir de manera correcta. Simplemente tened en cuenta el pre-proceso de las variables en la función de transformación (escalado y traslación a valores positivos) para aplicarlo a la variable en test si es que eliges un modelo con transformación. Con las tramificaciones pasa lo mismo!

EVALUACIÓN

Esta prueba tiene una ponderación del 30% de la calificación del módulo.

Se valorará únicamente la capacidad predictiva del modelo con arreglo a el índice de Youden de las predicciones en relación proporcional al score máximo del grupo (los integrantes del equipo que alcance mayor índice tendrán el máximo de 3 puntos sobre la calificación del módulo, el resto un valor proporcional).

Una vez evaluada la práctica, compartiremos los resultados de la competición (sana competición por favor, sin poner zancadillas al compi).

¡¡A JUGAR!!

¿CUÁNTOS SE FUGARÁN? ¿QUIÉNES? ¿QUÉ LES CARACTERIZA EN MAYOR MEDIDA?