Tarea Minería de Datos

‘Test de Evaluación’

Autores: Daniel Martín García

Elena del Carmen Gavilán García

La entrega se realizará en la plantilla Excel adjunta indicando, para cada pregunta, la única respuesta correcta.

Test_Minería_NombreApellido.xlsx

Todas las preguntas valen un punto y las respuestas incorrectas penalizan medio punto.

Es necesario adjuntar un notebook con el código utilizado para las preguntas que lo requieran.

Codigos_Test_Minería_NombreApellido.ipynb

Esta parte de test supone el 70% de la calificación del módulo.

Pregunta 1

Para el estudio descriptivo bivariante entre dos variables de naturaleza categórica o nominal, ¿cuáles son el gráfico y el estadístico que resultan más adecuados?

a) *Boxplot paralelo y tabla de contingencia.*

b) *Gráfico de dispersión y media.*

c) *Diagrama de mosaico y valor Chi2/V de Cramer.*

d) *Gráfico de dispersión y coeficiente de correlación.*

Pregunta 2

¿Qué diferencia matemática existe entre los modelos de regresión lineal y los modelos de regresión logística en términos de estimación paramétrica?

a) *El modelo lineal estima los parámetros por máxima verosimilitud y el modelo logístico por mínimos cuadrados por lo que este último es más sencillo en términos matemáticos.*

b) *El modelo logístico es más sencillo en términos matemáticos.*

c) *La estimación paramétrica es igual en modelos lineales y logísticos.*

d) *El modelo lineal estima los parámetros por mínimos cuadrados y el modelo logístico por máxima verosimilitud por lo que este último es más complejo en términos matemáticos.*

Pregunta 3

¿Qué riesgo tiene la multicolinealidad en los modelos de regresión?

a) *Hace siempre imposible la estimación de parámetros*

b) *Provoca un aumento de la varianza de los estimadores, haciendo que sean menos robustos*

c) *Disminuye el valor estimado de los parámetros cambiando la interpretación del modelo*

d) *La multicolinealidad no es nociva para ningún modelo de regresión*

Pregunta 4

En el conjunto de datos de viviendas, la mediana de lat es:

a) *47.5*

b) *46.5*

c) *47.4*

d) *47.3*

Pregunta 5

En el conjunto de datos de Viviendas, el número de valores únicos en condition es:

a) *6*

b) *5*

c) *3*

d) *4*

Pregunta 6

En el conjunto de datos de Viviendas, la cantidad de instancias que pertenecen a la categoría 0 de la variable waterfront es:

a) *4852*

b) *106*

c) *4752*

d) *4832*

Pregunta 7

En el conjunto de datos de Viviendas, el porcentaje de filas faltantes no declaradas en la variable waterfront es:

a) *0.2*

b) *2.34*

c) *2.02*

d) 2.12

Pregunta 8

En el conjunto de datos de Viviendas (sin limpieza) el valor R^2 de un modelo con fórmula 'precio ~ lat' es:

a) 0.512

b) 0.613

c) 0.091

d) 0.453

Pregunta 9

En el conjunto de datos de viviendas (sin limpieza) el parámetro estimado para el predictor en el modelo con la fórmula 'price ~ sqft_living' es:

a) 293.3356

b) 291.3188

c) 295.3188

d) 292.3278

Pregunta 10

En el conjunto de datos de viviendas (sin limpieza) el Odds Ratio estimado para el predictor en el modelo con la fórmula 'Luxury ~ sqft_living' es:

a) 0.00196

b) 1.001866

c) 0.991286

d) 1.010886

Pregunta 11

Si el parámetro estimado para el predictor A en un modelo logístico para predecir una variable binaria y, es 0.4, entonces:

e) El odds ratio debe ser 1

f) El odds ratio debe ser de 0.4

g) El odds ratio debe ser de 1.39

h) El odds ratio debe ser de 1.49

Pregunta 12

En un modelo de regresión lineal simple que predice el precio de una vivienda (en euros) usando como variable explicativa los pies cuadrados de superficie habitable (sqft_living), se ha estimado el siguiente coeficiente para sqft_living: 205.6611

Selecciona la interpretación correcta de este coeficiente:

1. *Por cada pie cuadrado adicional de superficie habitable, se espera que el precio de la vivienda aumente, en promedio, 205.6611 miles de euros (es decir, aproximadamente 205.661 euros).*
2. *Por cada pie cuadrado adicional de superficie habitable, se espera que el precio de la vivienda aumente, en promedio, 205.6611 euros.*
3. *Por cada aumento de 1.000 euros en el precio, se espera que la superficie habitable aumente, en promedio, 205.6611 pies cuadrados.*
4. *El coeficiente 205.6611 indica el precio esperado de una vivienda con 0 pies cuadrados de superficie habitable (ordenada en el origen).*

Pregunta 13

En un modelo de regresión lineal que predice el precio de una vivienda (en euros) usando diversas variables, se incluye la variable dummy waterfront_1. Esta variable toma el valor:

- *0 si la vivienda NO tiene vistas al mar.*
- *1 si la vivienda SÍ tiene vistas al mar.*

El coeficiente estimado para waterfront_1 es: 476,400.

a) *Selecciona la interpretación correcta de este coeficiente:Por cada metro cuadrado adicional de superficie, se espera que el precio de una vivienda con vistas al mar aumente en 476,400 euros.*
b) *Por cada vivienda con vistas al mar, el precio aumenta en un 476,400% respecto al precio base.*
c) *Tener vistas al mar está asociado, en promedio, con un precio de venta 476,400 euros mayor en comparación con viviendas sin vistas al mar, manteniendo constantes las demás variables del modelo.*
d) *El coeficiente 476,400 indica el precio esperado de una vivienda que tiene vistas al mar, ignorando todas las demás características.*

Pregunta 14

En un modelo de regresión logística donde la variable dependiente es Luxury (1 = vivienda de lujo, 0 = no lujo), se ha estimado el siguiente coeficiente para la variable sqft_living (metros cuadrados de superficie habitable): 0.001183

Selecciona la interpretación correcta de este coeficiente en términos de odds:

a) *Por cada metro cuadrado adicional de superficie habitable, la probabilidad de que una vivienda sea de lujo aumenta en un 0.001183%.*
b) *Por cada metro cuadrado adicional de superficie habitable, el odds de que una vivienda sea de lujo se multiplica por* $e^{0.001183} \approx 1.00118$.
c) *Por cada metro cuadrado adicional de superficie habitable, el odds de que una vivienda sea de lujo aumenta en 0.001183 unidades.*
d) *El coeficiente 0.001183 indica la probabilidad de que una vivienda sea de lujo cuando tiene 0 metros cuadrados de superficie habitable.*

Pregunta 15

En el mismo modelo de regresión logística para predecir si una vivienda es de lujo (Luxury), se incluye la variable dummy waterfront_1 (1 = tiene vistas al mar, 0 = no). El coeficiente estimado es: 1.0839

Selecciona la interpretación correcta:

a) *Las viviendas con vistas al mar tienen una probabilidad de ser de lujo 1.0839 veces mayor que las que no tienen vistas al mar.*
b) *Por cada vivienda con vistas al mar, el log-odds de ser de lujo aumenta en 1.0839 puntos porcentuales.*
c) *Tener vistas al mar aumenta la probabilidad de ser una vivienda de lujo en un 108.39%*
d) *El odds de que una vivienda sea de lujo se multiplica por* $e^{1.0839} \approx 2.955$ *cuando tiene vistas al mar, en comparación con cuando no las tiene (manteniendo constantes las demás variables).*

Pregunta 16

En un modelo para detectar una enfermedad rara (clase positiva = tiene la enfermedad), un médico quiere minimizar los falsos negativos (no queremos dejar a un enfermo sin diagnosticar), incluso si eso significa aumentar los falsos positivos (personas sanas que haremos pruebas adicionales). ¿Qué métrica debe intentar maximizar el modelo para cumplir este objetivo?

a) *Especificidad*
b) *Valor Predictivo Positivo*
c) *Sensibilidad*
d) *Tasa de acierto*

Pregunta 17

Se quiere estudiar el salario anual (Salary) en función de los años de experiencia (Experience) y el tipo de puesto (Manager), que es una variable dummy donde:

- *Manager = 0 → Puesto base (Analista)*
- *Manager = 1 → Puesto directivo (Manager)*

Se estima el siguiente modelo de regresión con interacción:

$$Salary = \beta_0 + \beta_1 \cdot Experience + \beta_2 \cdot Manager + \beta_3 \cdot (Experience \times Manager) + \epsilon$$

Los coeficientes estimados son:

$$\widehat{\beta}_0 = 35000 \ \widehat{\beta}_1 = 2500 \ \widehat{\beta}_2 = 15000 \ \widehat{\beta}_3 = 1800$$

¿Cuál es la diferencia en el incremento salarial por un año adicional de experiencia entre un Manager y un Analista?

a) *Por cada año de experiencia, un Manager gana 1800 euros más que un Analista con la misma experiencia.*
b) *La diferencia en el incremento salarial por año de experiencia es de 1800 euros/año.*
c) *Por cada año de experiencia, el salario de un Manager aumenta un 1800% más que el de un Analista.*
d) *La interacción no modifica la pendiente, solo el intercepto. La diferencia salarial por experiencia es constante y está dada por* $\beta_2 = 15000$.

Pregunta 18

¿Cuál de los siguientes NO es un requisito previo recomendado para aplicar el PCA?

a) *Estandarización de las variables.*
b) *Ausencia de correlación entre las variables originales.*
c) *Manejo de valores atípicos.*
d) *Tratamiento de datos perdidos.*

Pregunta 19

En el PCA, ¿qué representa un autovalor (valor propio) alto?

a) *Que la componente asociada explica poca varianza.*
b) *Que la componente asociada explica mucha varianza.*
c) *Que la componente está correlacionada negativamente con todas las variables.*
d) *Que la componente es redundante y debe eliminarse.*

Pregunta 20

¿Qué matriz se utiliza generalmente cuando las variables originales no están en la misma escala?

a) *Matriz de covarianzas.*
b) *Matriz de identidad.*
c) *Matriz de correlaciones.*
d) *Matriz de distancias.*

El conjunto de datos 'penguins' contiene la siguiente información sobre diferentes especies de pingüinos:

- species: Es la especie de pingüino. Hay tres especies en el conjunto dedatos: 'Adelie', 'Chinstrap' y 'Gentoo'.

- island: Representa la isla donde se recopilaron los datos. Las islas son 'Biscoe', 'Dream' y 'Torgersen'.

- bill length mm: Longitud del pico en milímetros.

- bill depth mm: Profundidad del pico en milímetros.

- flipper length mm: Longitud de la aleta en milímetros.

- body mass g: Masa corporal del pingüino en gramos.

- sex: Género del pingüino, con las categorías 'Male' (macho), 'Female' (hembra).

Con el objetivo de reducir el número de variables numéricas y explorar relaciones entre las características físicas de los pingüinos se ha realizado un análisis PCA sobre el conjunto de datos de las variables numéricas.

Pregunta 21

Después de aplicar el PCA, obtener los autovalores asociados a las 4 componentes principales. ¿Cuál es la varianza explicada por la segunda componente principal (PC2) en porcentaje?

a) *19.45%*
a) *68.84%*
b) *29.87%*
c) *9.25%*

Pregunta 22

¿Cuántas componentes principales se necesitan para explicar al menos el 90% de la variabilidad total de los datos?

a) *1 componente*
b) *2 componentes*
c) *3 componentes*
d) *4 componentes*

Pregunta 23

En la siguiente tabla se muestra la matriz de transformación W. Indica cúal de las siguientes expresiones es correcta:

Index	Autovector 1	Autovector 2
bill_length_mm_z	0.453753	0.600195
bill_depth_mm_z	-0.399047	0.79617
flipper_length_mm_z	0.576825	0.00578817
body_mass_g_z	0.549675	0.0764637

a) *CP1 = 0.6Bill_length_mm_z + 0.796Bill_depth_mm_z + 0.005Flipper_length_mm_z + 0.076Body_mass_g_z*
b) *CP1 = 0.453Bill_length_mm_z + 0.6Bill_depth_mm_z - 0.399Flipper_length_mm_z +0.796Body_mass_g_z*
c) *CP2 = 0.453Bill_length_mm_z - 0.399Bill_depth_mm_z + 0.576Flipper_length_mm_z + 0.549Body_mass_g_z*
d) *CP2 = 0.6Bill_length_mm_z + 0.796Bill_depth_mm_z + 0.005Flipper_length_mm_z + 0.076Body_mass_g_z*

Pregunta 24

Tras realizar un PCA sobre las variables del conjunto penguins, obtienes las correlaciones entre las variables estandarizadas y las dos primeras componentes principales.

¿Cuál de las siguientes variables tiene la correlación más fuerte con la primera componente principal (PC1)?

a) *bill_length_mm_z*
b) *bill_depth_mm_z*
c) *flipper_length_mm_z*
d) *body_mass_g_z*

Pregunta 25

Según los resultados del PCA, ¿qué variable contribuye más a la segunda componente principal (PC2) en términos de correlación absoluta?

a) *bill_length_mm_z*
b) *bill_depth_mm_z*
c) *flipper_length_mm_z*
d) *body_mass_g_z*

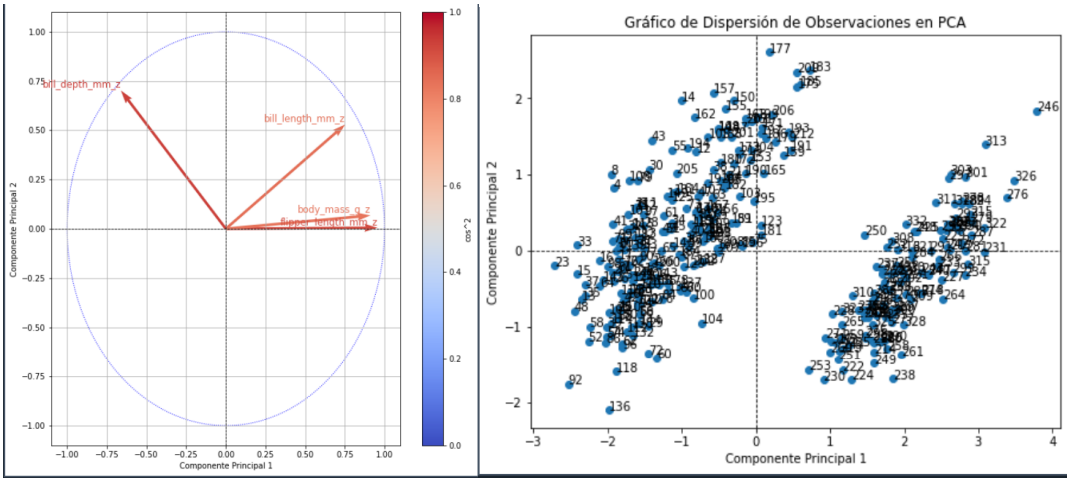
Pregunta 26

Para la variable bill_depth_mm_z, ¿qué porcentaje aproximado de su varianza es explicado por PC2?

a) *28.0%*
b) *43.7%*
c) *49.3%*
d) *70.2%*

Pregunta 27

Observa los siguientes gráficos obtenidos del PCA (plot_corr_cos y nube de puntos sobre las dos primeras componentes) aplicado al conjunto de datos penguins.



Teniendo en cuenta la interpretación de las componentes, ¿cuál de las siguientes descripciones es la más probable para el pingüino 246 (arriba a la derecha)?

a) *Tiene valores altos en longitud de aleta y masa corporal, y valores bajos en profundidad del pico.*
b) *Tiene valores por debajo de la media en longitud de aleta y masa corporal, y valores por encima de la media en profundidad del pico.*
c) *Tiene valores por encima de la media en longitud de aleta y masa corporal, y valores por debajo de la media en profundidad del pico.*
d) *Tiene valores cercanos a la media en todas las variables.*

Tras explorar las características físicas de los pingüinos mediante el Análisis de Componentes Principales (ACP), ahora nos centraremos en evaluar la estructura de los grupos o clústeres existentes en el conjunto de datos a partir de las variables numéricas.

Pregunta 28

En el clustering jerárquico, ¿qué representa un dendrograma?

a) *La evolución de los centroides en cada iteración.*
b) *La estructura de fusión o división de grupos en forma de árbol.*
c) *La distribución de las variables dentro de cada cluster.*
d) *La matriz de distancias entre todas las observaciones.*

Pregunta 29

En el método del codo para determinar el número óptimo de clusters, ¿qué se representa en el eje Y?

a) *El coeficiente de silueta promedio.*
b) *La suma de cuadrados dentro de los clusters.*
c) *La distancia entre centroides.*
d) *El número de observaciones por cluster.*

Pregunta 30

¿Qué solución de Clustering es mejor?

a) *Solución con el mayor número de grupos.*
a) *Solución con mayor variabilidad interna y menor silueta.*
b) *Solución con menor silueta y variabilidad interna.*
c) *Solución con mayor silueta y menor variabilidad interna.*

Pregunta 31

Observa los siguientes dendrogramas y selecciona una de las 4 opciones.

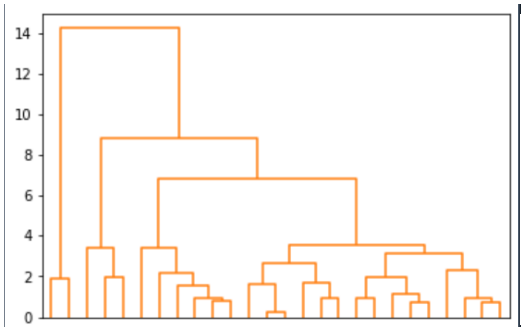


Ilustración 1 Dendrograma 1

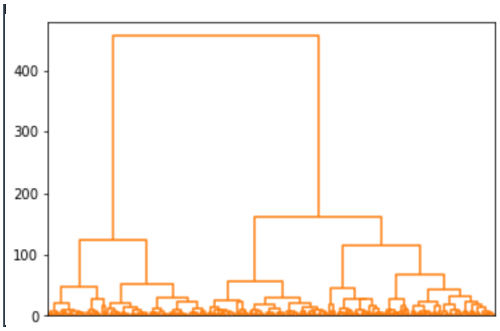


Ilustración 2 Dendrograma 2

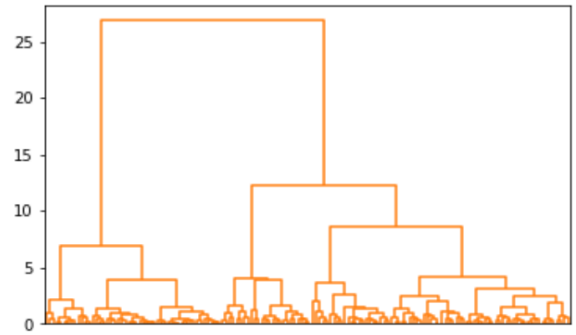


Ilustración 3 Dendrograma 3

a) *El primer dendrograma es el correspondiente a la base de datos de pingüinos.*
b) *El segundo dendrograma es el correspondiente a la base de datos de pingüinos.*
c) *El tercer dendrograma es el correspondiente a la base de datos de pingüinos.*
d) *Ninguna es correcta.*

Pregunta 32

Observa los siguientes gráficos "de codo" y selecciona una de las 4 opciones.

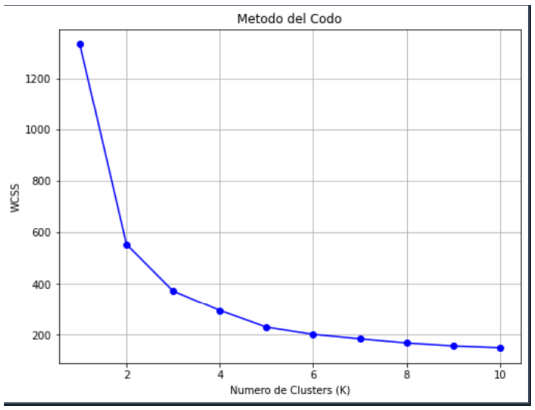


Ilustración 4 Codo 1

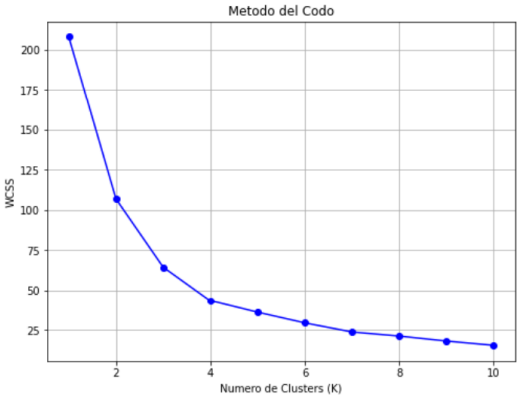


Ilustración 5 Codo 2

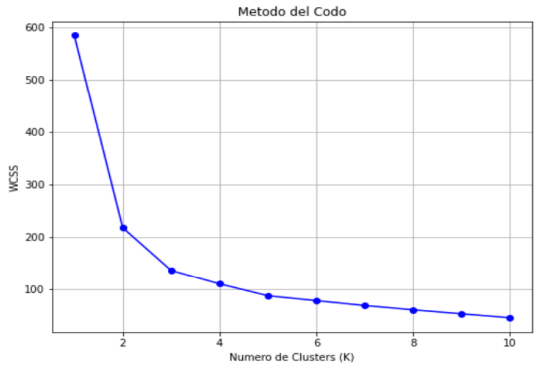


Ilustración 6 Codo 3

a) ***El primer gráfico es el correspondiente a la base de datos de pingüinos.***

b) ***El segundo gráfico es el correspondiente a la base de datos de pingüinos.***

c) ***El tercer gráfico es el correspondiente a la base de datos de pingüinos.***

d) ***Ninguna es correcta.***

Pregunta 33

Observa los siguientes gráficos “de silueta” y selecciona una de las 4 opciones.

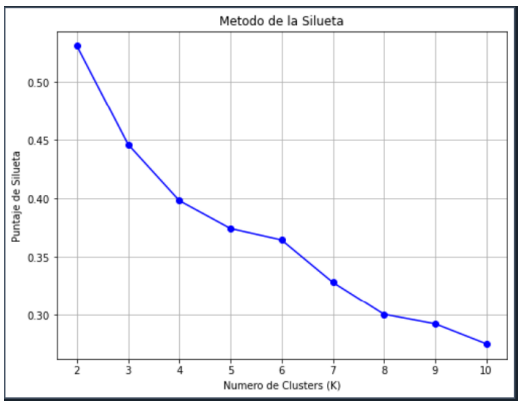


Ilustración 7 Gráfico 1

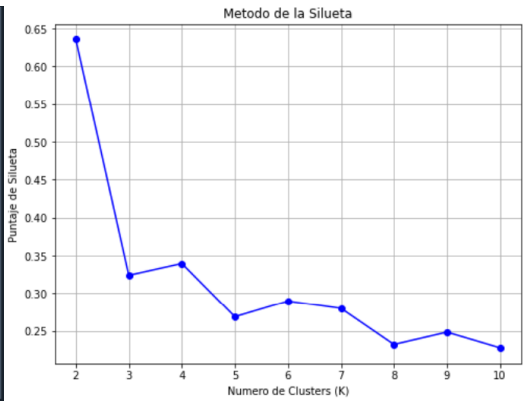


Ilustración 8 Gráfico 2

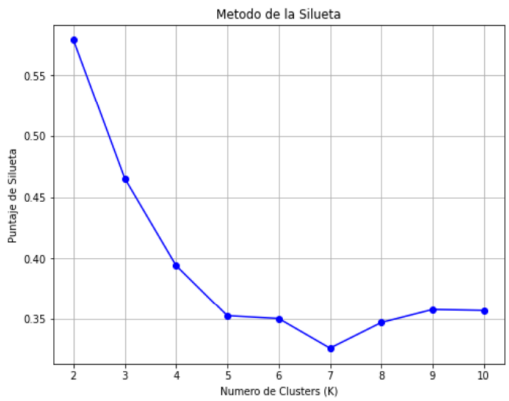


Ilustración 9 Gráfico 3

a) ***El primer gráfico es el correspondiente a la base de datos de pingüinos.***

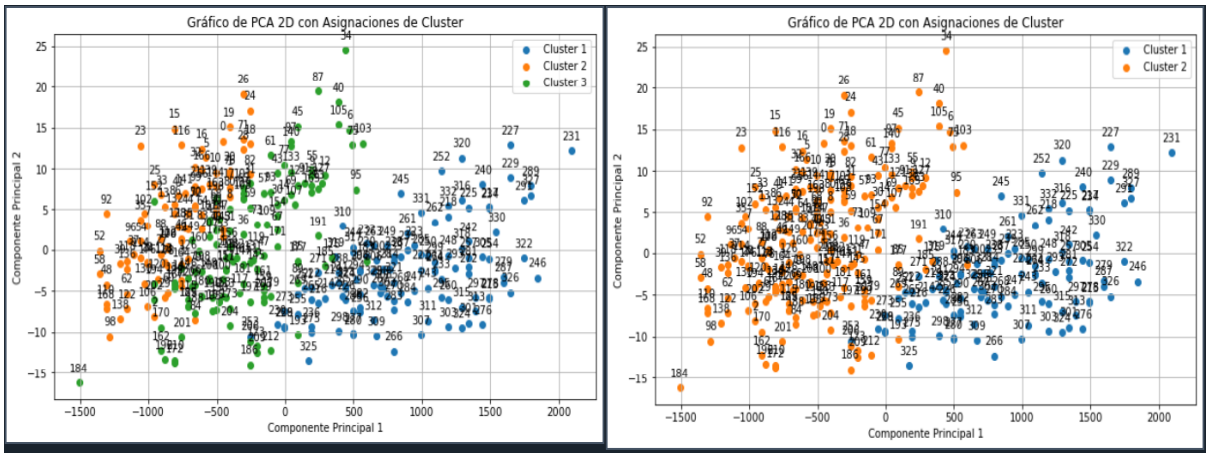
b) ***El segundo gráfico es el correspondiente a la base de datos de pingüinos.***

c) ***El tercer gráfico es el correspondiente a la base de datos de pingüinos.***

d) ***Ninguna es correcta.***

Pregunta 34

En los siguientes gráficos se muestran las nubes de puntos de los pingüinos sobre las dos primeras componentes principales, los colores representan a que clúster pertenecen, ya sea en un análisis con dos o tres clúster respectivamente. Selecciona una de las 4 opciones.



a) *Es más acertado elegir tres clúster porque originariamente existen tres especies de pingüinos.*
b) *Es más acertado elegir tres clúster porque originariamente los pingüinos proceden de tres islas diferentes.*
c) *Es más acertado elegir dos clúster porque las fronteras entre los grupos son más claras.*
d) *Las respuestas a) y b) son correctas.*

Pregunta 35

¿Cuál es la hipótesis nula del test de Ljung-Box en series temporales?

a) *La media de los residuos es nula*

b) *Los residuos se distribuyen acorde a una distribución normal*

c) *Los residuos están exentos de autocorrelaciones significativas*

d) *Los residuos están autocorrelacionados*

Pregunta 36

En una serie temporal univariante que presenta estacionalidad y tendencia con una heterocedasticidad creciente en el tiempo, ¿qué modelo de suavizado aplicarías?

a) *Modelo de suavizado doble de Holt*
b) *Modelo de suavizado de Holt-Winters aditivo*
c) *Modelo de suavizado de Holt-Winters multiplicativo*
d) *Modelo de suavizado simple*

Pregunta 37

¿Por qué es importante que una serie temporal sea estacionaria de cara las predicciones por un modelo ARIMA?

a) *En una serie estacionaria podemos calcular la media con el conjunto de observaciones y conocer la distribución de los errores*

b) *En una serie estacionaria, la media es 1 por lo que es más fácil predecir hacia delante*

c) *El método ARIMA es robusto frente a la falta de estacionariedad de la serie*

d) *En una serie estacionaria los parámetros siempre son menores que en una serie no estacionaria por lo que el modelo es más simple y funciona mejor*

Pregunta 38

En el conjunto de datos IPI (ventana de entrenamiento hasta el 31 de diciembre de 2017/ventana de prueba desde el 1 de enero de 2018), los resultados de la función eval_model() para un modelo aditivo de Hot-Winters son:

a) *Valor p de LjungBox = 7.256e-06; MAPE = 3,14*
b) *Valor p de LjungBox = 7.256e-08; MAPE = 3,14*
c) *Valor p de LjungBox = 2,543e-05; MAPE = 5,26*
d) *Valor p de LjungBox = 1,584e-05; MAPE = 5,36*

Pregunta 39

En el conjunto de datos IPI (ventana de entrenamiento hasta el 31 de diciembre de 2017/ventana de prueba desde el 1 de enero de 2018) los resultados de la función eval_model() para un SARIMAX(1,1,1)(1,1,1)12 son:

a) *Valor p de LjungBox = 0,6974; MAPE = 0,68*

b) *Valor p de LjungBox = 0,0974; MAPE = 2,68*

c) *Valor p de LjungBox = 0,0094; MAPE = 4,68*

d) *Valor p de LjungBox = 0,0994; MAPE = 2,88*

Pregunta 40

En el conjunto de datos IPI (ventana de entrenamiento hasta 2017-12-31/ventana de prueba desde 2018-01-01), los resultados de eval_model() para un modelo SARIMAX(1,1,0)(1,1,0)12 son:

a) *LjungBox pvalue = 5.153e-03; MAPE = 4.67*

b) *LjungBox pvalue = 4.613e-07; MAPE = 4.35*

c) *LjungBox pvalue = 4.153e-07; MAPE = 4.68*

d) *LjungBox pvalue = 4.653e-07; MAPE = 4.25*

Pregunta 41

En series temporales, un p-valor de la prueba de Ljung-Box de 0.8 representa que la serie residual es:

a) *Falta de autocorrelación*

b) *Altamente auto correlacionada*

c) *Estacionaria*

d) *No estacionaria*