

ntic master School

UNIVERSIDAD COMPLUTENSE MADRID

Estadística Espacial

Lorenzo Escot (escot@ucm.es)
Profesor de Métodos Econométricos en Economía y Finanzas
Dto Economía Aplicada Pública y Privada
Codirector del Grupo de Investigación Análisis de datos en Ciencias Sociales (www.ucm.es/aedipi)
Facultad de Estudios Estadísticos
Universidad Complutense de Madrid



¿Que són los datos espaciales?:

datos que tienen asociados una localización, una posición en el espacio.

Los datos espaciales tienen un **índice de posición**. Son en cierto sentido como datos de **Sección CRUZADA, pero en realidad forman un tipo especial de datos**

Tipo de estructura de Datos:

- Datos de **Sección Cruzada** (agentes, individuos, países)
  Heterocedasticidad (y endogeneidad)
- Datos de **Series Temporales** (datos de un sólo agente, pero a lo largo del tiempo)
  Estacionariedad, autocorrelación (y endogeneidad)
- **Datos de Panel**: doble dimensión sección cruzada y tiempo (muchos agentes con una serie temporal para cada uno)
  Heterocedasticidad, estacionariedad, autocorrelación pero permitían corregir endogeneidad



Estadística Espacial

Análisis de datos espaciales: datos que tienen asociados una localización, una posición en el espacio. Los datos tienen un índice de posición. Cuando la referencia de posición es geográfica serán datos geoespaciales (datos georeferenciados)

Objetivos del análisis espacial:

- Posicionar y representar en el espacio nuestras variables y entender como se distribuyen en el espacio
  - Distribución de precios en la Ciudad de Madrid
  - Distribución de la población o de la densidad de población
  - Distribución de la renta ¿hay concentración de la renta en determinadas zonas o territorios?.

- Medir áreas y distancias (por ejemplo, medir el área afectada por un incendio o una plaga, y analizar cuantas fincas y tipos de cultivo se ha visto afectada)

- Calcular ubicaciones y rutas óptimas (por ejemplo, para empresas de reparto)

Estadística Espacial

Análisis de datos espaciales: datos que tienen asociados una localización, una posición en el espacio. Los datos tienen un índice de posición. Cuando la referencia de posición es geográfica serán datos geoespaciales (datos georeferenciados)

… pero el verdader objetivo del análisis espacial es analizar la dependencia o interacción espacial entre los datos

Los datos espaciales se asemejan a los datos de sección cruzada porque **no tienen dimensión en el tiempo**. Cada dato corresponde a una localización: su un índice de identificación único es una localización en el espacio, con las dificultades que supone tener que utilizar un índice con dos elementos (longitud, latitud) o incluso tres (si consideramos la altura respecto al nivel del mar)

Pero tienen mucho, mucho, mucho que ver con los modelos de series temporales porque **permiten la interacción entre individuos** (entre localizaciones para ser más estrictos). Y de hecho el objetivo fundamental del análisis de series temporales es intentar **modelizar esa dependencia espacial**, lo que denominaremos esos patrones de comportamiento espacial en las variables.



Análisis de datos espaciales: datos que tienen asociados una localización, una posición en el espacio. Cuando la referencia de posición es geográfica serán datos geoespaciales (datos georeferenciados)

… objetivo del análisis espacial: analizar la dependencia o interacción espacial entre los datos

Los Datos espaciales, no tienen estructura temporal pero sí tienen dependencia respecto al resto de datos:

Lo que pasa en un punto depende, entre otras cosas de lo que pase al rededor. El resto de los datos ubicados en las proximidades sí influyen en nosotros (por que seguimos con memoria de pez, nos influye más lo que pasa en las proximidades muy cercanas, y menos lo que pase muy lejos nuestra)

A diferencia de las series espaciales donde la dependencia sólo va en una dirección (el pasado influye en el presente y el futuro pero el presente no influye en el pasado), con los datos espaciales la dependencia es bidireccional (mis vecinos me influyen a mi pero yo influyo en mis vecinos, lo que genera ciertos problemas de endogeneidad)

(Ojo con la validación cruzada cuando se trabaja con datos espaciales!!!!)

Los modelos de datos espaciales tratan de buscar evidencia de que existen esos **patrones de comportamiento espacial,** esa **interacción espacial**, esa **dependencia espacial**, y cuando la encuentran, intentan modelizarla para mejorar las predicciones (¿que resultados electorales habrá en un barrio o en otro de Madrid?), pera entender el porqué de las cosas (ejemplo del cólera y el mapa de Snow) o para saber por qué unas viviendas son mucho más caras que otras.

Incluso todo lo que es el análisis de datos espaciales está muy estrechamente vinculado con el **análisis de redes sociales**

¿Qué pasa si en lugar de analizar dependencia en el espacio (en función de las distancias geográficas), analizamos **otro tipo de dependencias o interconexiones**, por ejemplo, comerciales, o de flujos financieros, o de noticias, o de mensajes, de videos de tick tock?



La búsqueda de **patrones espaciales** (de dependencia o autocorrelación espacial) es uno de los grandes objetivos del análisis de datos espaciales, y al igual que con series temporales , la búsqueda de patrones espaciales se realiza **comparando la distribución de los datos con las distribuciones puramente aleatorias**:

Ruido blanco espacial

Al igual que en la modelización de series temporales donde se analizan los residuos para que ya estén incorrelacionados (temporalmente), nosotros también buscaremos la modelización que permita obtener unos residuos que estén incorrelacionados espacialmente.

Ejemplo de las viviendas y los exámenes.

Ojo!!!, también existen los **datos Espacio-Temporales**

Que serán el análogo a **los datos de panel, dimensión temporal y dimensión espacial,** y podrá modelizarse tanto la dependencia o autocorrelación temporal, como la dependencia o autocorrelación espacial

Ejemplo: El precio de una vivienda depende de sus propias características (número de habitaciones, baños, antigüedad, orientación, altura, calidad de construcción.....) pero también (y fundamentalmente) del precio de las viviendas cercanas, y también de cual haya sido el precio de la vivienda en el mes anterior.

Yo en clase hablaré, fundamentalmente, de datos que sólo tienen la dimensión espacial, aunque sobre todo al final, también hablaremos algo de los datos espacio-temporales

Análisis de datos espaciales: datos que tienen asociados una localización, una posición en el espacio. Cuando la referencia de posición es geográfica serán datos geoespaciales (datos georeferenciados)

… objetivo del análisis espacial: analizar la dependencia o interacción espacial entre los datos

En la estadística espacial estamos interesados en analizar los patrones de distribución de **los atributos** z_j (características) de los diferentes **objetos espaciales** s_i

$$\{z_j(s_i): j = 1, \dots, k; i = 1, \dots, n\} \equiv \{z_j(s_i)\}_{j,i}$$

s_i: *serán cada uno de los n objetos espaciales ubicados en el* ***dominio D del espacio eucideo*** en $\mathbb{R}^2$ (*estos objetos se localizan en el plano, no hay altitud*)

z_j: ***atributos*** *observados* (*cada objeto espacial tendrá k atributos*)

¿Qué método de análisis espacial se debe utilizar?

dominio espacial D estocástico

Análisis de Eventos Espaciales Patrones de Puntos
Se centra en identificar patrones en las ubicaciones de los eventos para determinar la distribución no aleatoria de los eventos.

dominio espacial D fijo

Análisis de Atributos Espaciales en Dominios espaciales Fijos
Se analiza la dependencia de los atributos en ubicaciones fijas, utilizando técnicas como la interpolación y la autocorrelación.

1. Dominio espacial fijo y **Continuo** (Geoestadística e Interpolación)
2. Dominio espacial fijo pero **Discreto** (Autocorrelación y modelos de regresión espacial)

… objetivo del análisis espacial: analizar la dependencia o interacción espacial entre los datos

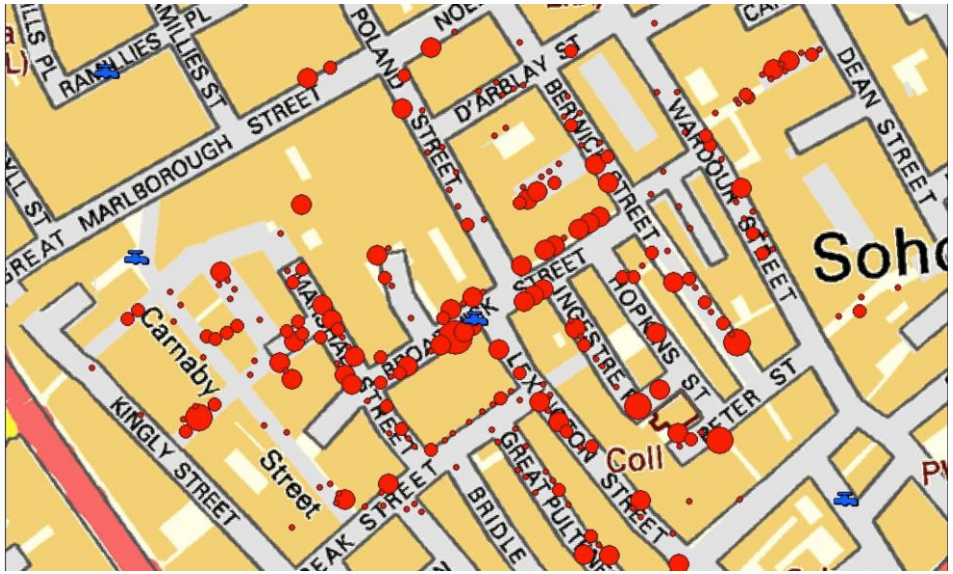
- **Localización de eventos**: buscar patrones de puntos ¿la distribución de la localización es puramente aleatoria o sigue algún patrón? (ejemplo Cólera Dr Snow). Distribución de árboles, de poblaciones de especies, de localización de casos y contagios de enfermedades (plaga de cólera, incidencia del COVID,...) recogida de clientes de úber, de ubicaciones de locales comerciales, de delitos, de accidentes. Técnicas: densidad local y global y medidas de distancia o interacción (alfabeto de Rypley)

El primer análisis de datos espaciales fue realizado por el Dr John Snow en 1854 (Snow, 1856)

En 1854 Londres sufrió un brote de cólera que supuso la muerte de más de 600 personas.

Por aquél entonces se pensaba que el contagio de esta enfermedad se producía por el aire (el miasma o aire viciado). Un médico local llamado John Snow se mostró escéptico ante la teoría imperante y empezó a recopilar datos sobre las personas que habían fallecido.

Snow dibujó puntos en un mapa para marcar los lugares donde se habían producido las muertes, y pronto se dio cuenta de que se agrupaban en torno a la bomba de agua de Broad Street.



¿Moraleja?.
La ubicación en el espacio, en el mapa, en la ciudad, en el terreno, importan.
Existen patrones de comportamiento espacial que pueden ayudarnos a entender la realidad

… objetivo del análisis espacial: analizar la dependencia o interacción espacial entre los datos

- **Localización de eventos**: buscar patrones de puntos ¿la distribución de la localización es puramente aleatoria o sigue algún patrón? (ejemplo Cólera Dr Snow). Distribución de árboles, de poblaciones de especies, de localización de casos y contagios de enfermedades (plaga de cólera, incidencia del COVID,...) recogida de clientes de úber, de ubicaciones de locales comerciales, de delitos, de accidentes. Técnicas: densidad local y global y medidas de distancia o interacción (alfabeto de Rypley)



Pointpats: Planar Point Pattern Analysis in PySAL

https://github.com/pysal/pointpats

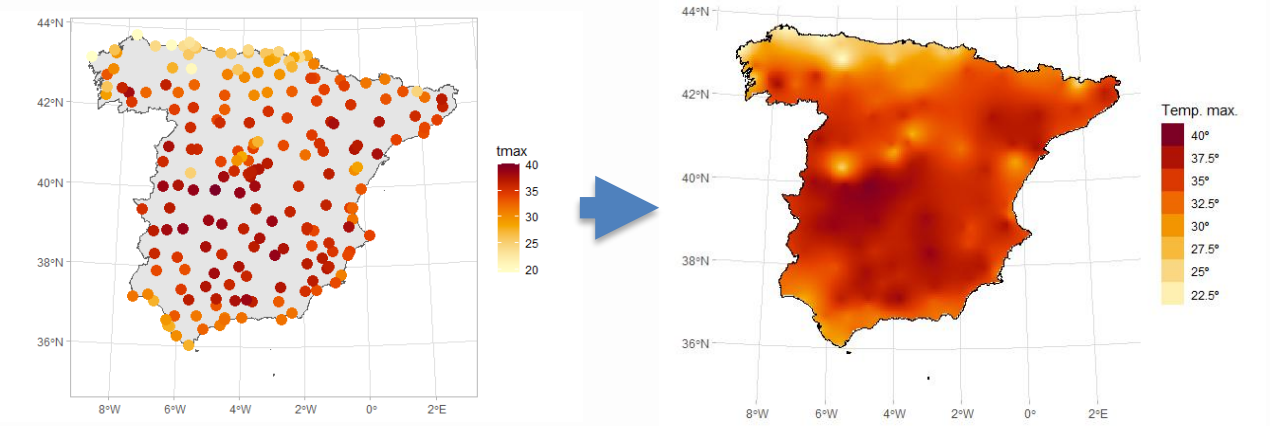
https://pysal.org/notebooks/explore/pointpats/intro.html

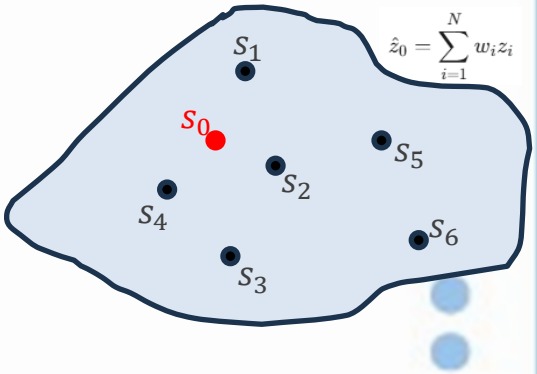
… objetivo del análisis espacial: analizar la dependencia o interacción espacial entre los datos

- **Localización de eventos**: buscar patrones de puntos (dependencia espacial de eventos)

- **Geoestadística** Análisis de la dependencia en los atributos (no de eventos) en el **Dominio Espacial (D) CONTINUO**, En cada ubicación si del Dominio espacial continuo el atributo zj tomará un valor. El problema es que no se observa el valor del atributo en todo D, sólo se observan los atributos en ciertas localizaciones puntuales, en ciertas ubicaciones (en una muestra de ubicaciones del dominio espacial).

  El objetivo de la Geoestadística es utilizar la dependencia espacial existente en los datos para realizar predicciones o **interpolaciones** del atributo en todo el dominio (Técnicas de la **Geoestadística**: Krigeado y semivariogramas). Por ejemplo, estimación de curvas de Nivel: Presión atmosférica, precipitación, temperatura o también mapas de polución atmosférica o de precio de la vivienda





… objetivo del análisis espacial: analizar la dependencia o interacción espacial entre los datos

- **Localización de eventos**: buscar patrones de puntos (dependencia espacial de eventos)

- **Geoestadística** Análisis de la dependencia en los atributos (no de eventos) en el **Dominio Espacial (D) CONTINUO**, En cada ubicación si del Dominio espacial continuo el atributo zj tomará un valor. El problema es que no se observa el valor del atributo en todo D, sólo se observan los atributos en ciertas localizaciones puntuales, en ciertas ubicaciones (en una muestra de ubicaciones del dominio espacial).

  El objetivo de la Geoestadística es utilizar la dependencia espacial existente en los datos para realizar predicciones o **interpolaciones** del atributo en todo el dominio (Técnicas de la **Geoestadística**: Krigeado y semivariogramas). Por ejemplo, estimación de curvas de Nivel: Presión atmosférica, precipitación, temperatura o también mapas de polución atmosférica o de precio de la vivienda



PyKrige: Kriging Toolkit for Python

https://geostat-framework.readthedocs.io/projects/pykrige/en/stable/

https://geostat-framework.org/

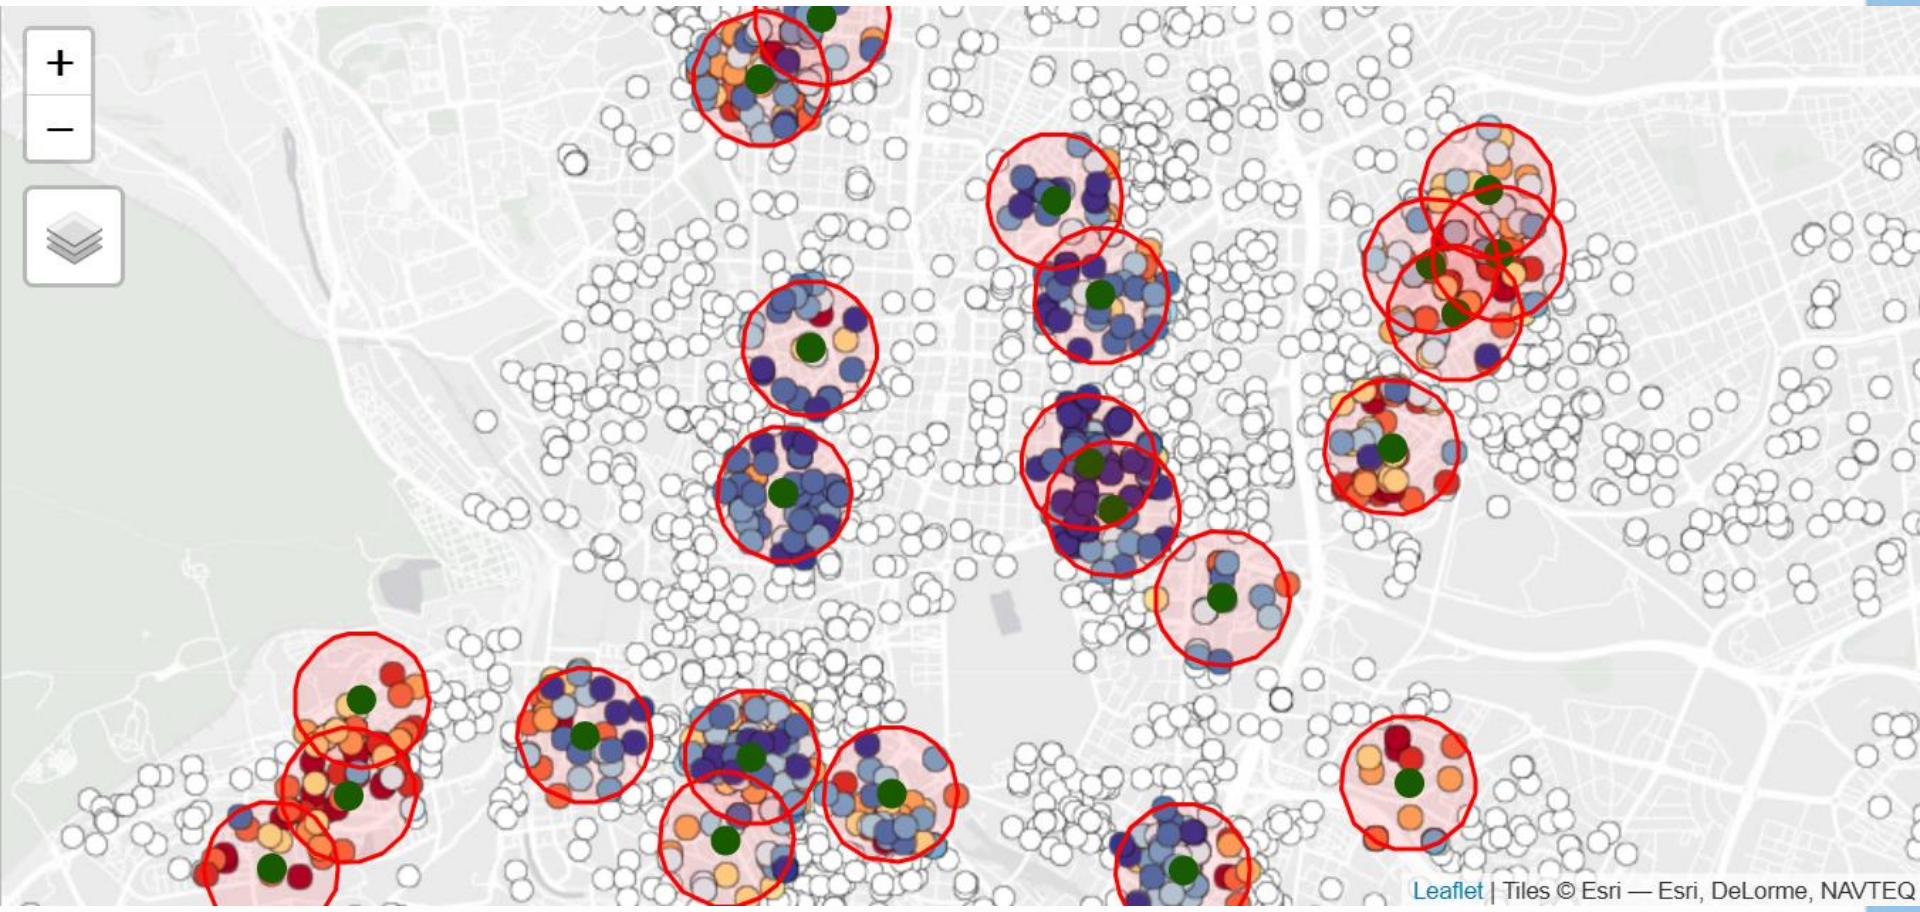
… objetivo del análisis espacial: analizar la dependencia o interacción espacial entre los datos

- **Localización de eventos**: buscar patrones de puntos (dependencia espacial de eventos)
- **Geoestadística** Análisis de la dependencia en los atributos (no de eventos) en el **Dominio Espacial (D) CONTINUO:** Realizar predicciones o **interpolaciones** de valores de una variable que sabemos que debería tomar un valor en el continuo del espacio, pero que sólo se observa en un conjunto concreto de datos
- **Modelos de correlación espacial:** Análisis de Atributos (no de eventos) en el **Dominio Espacial DISCRETO**, cada objeto espacial puede enumerarse o tiene una frontera que los separa del resto (cada objeto es un caso). El objetivo de estos modelos también es predecir el valor de un objetivo explotando la existencia de dependencia espacial





Objetivo es construir modelos predictivos de un atributo en función del resto de atributos propios de cada objeto y de los valores de los atributos del resto de objeto espaciales vecinos próximos



… objetivo del análisis espacial: analizar la dependencia o interacción espacial entre los datos

- **Localización de eventos**: buscar patrones de puntos (dependencia espacial de eventos)

- **Geoestadística** Análisis de la dependencia en los atributos (no de eventos) en el **Dominio Espacial (D) CONTINUO:** Realizar predicciones o **interpolaciones** de valores de una variable que sabemos que debería tomar un valor en el continuo del espacio, pero que sólo se observa en un conjunto concreto de datos

- **Modelos de correlación espacial:** Análisis de Atributos (no de eventos) en el **Dominio Espacial DISCRETO**, cada objeto espacial puede enumerarse o tiene una frontera que los separa del resto (cada objeto es un caso). El objetivo de estos modelos también es predecir el valor de un objetivo explotando la existencia de dependencia espacial

  Objetivo es construir modelos predictivos de un atributo en función del resto de atributos propios de cada objeto y de los valores de los atributos del resto de objeto espaciales vecinos próximos

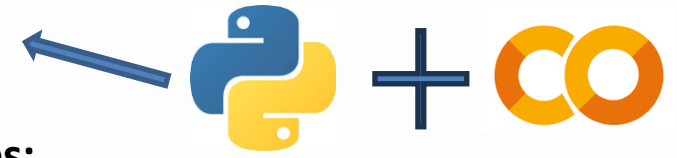
  Modelos de **regresión espacial**:
  Cuantificación de la correlación Espacial (Econometría Espacial)
  -> Extensión a Modelos de Aprendizaje automático espacial (modelos predictivos)

Software para representación y análisis GIS - Sistema Información Geográfica

- QGIS https://qgis.org/es/site/ (código abierto-software libre)
- ARGIS (se puede conectar con R)
- Carto (https://carto.com/)

Software para la estimación de modelos de econometría espacial

- Stata, SAS, SPSS, R, y …. python
- GEODA y Geoda Space



Preveedores de servicios espaciales:

- GoogleMaps o mejor Google Earth Engine (https://earthengine.google.com/)
- OpenStreetMap (https://www.openstreetmap.org/)

Bibliografía:

- Anselin, L. (1988). *Spatial Econometrics: Methods and Models. Kluwer Academic Press.*
- Anselin y Rey (2014): *Modern Spatial Econometrics in Practice,* GEODA Press
- Bonny P. McClain (2022). Python for Geospatial Data Analysis: Theory, Tools and Practice for Location Intelligence. Ed O'Reilly
- Dorman, Michael; Anita Graser, Jakub Nowosad, Robin Lovelace (2025). *Geocomputation with Python*. CRC Press https://py.geocompx.org/
- Dubé, J. y Legros, D. (2014): *Spatial Econometrics Using Microdata*. Editorial Iste Ltd John Wiley & Sons
- Elhorst, J.P. *(2010). Applied Spatial Econometrics: Raising the Bar, Spatial Economic Analysis, 5(1), 9-28.*
- Elhorst, J.P. *(2014). Spatial Econometrics: From Cross-Sectional Data to spatial Panels. Springer*
- Ignacio Alonso Fernández-Coppel (2001): Localizaciones Geográficas. Las Coordenadas Geográficas y la Proyección UTM. (Universal Transversa Mercator) Universidad de Valladolid
- James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). An introduction to statistical learning: With applications in python. Springer. https://www.statlearning.com/
- LeSage, J., & Pace, R. K. (2010). *Introduction to Spatial Econometrics*. CRC Press.
- Rey, Sergio J.; Dani Arribas-Bel; y Levi J. Wolf (2020): Geographic Data Science with Python. https://geographicdata.science/book/intro.html

Objetivo de la clase:
Búsqueda y modelización de Patrones de comportamiento espacial

Contenidos:

- **Sistemas de Información Geográfica (GIS):** cartografías, mapas...

- **Análisis Exploratorio de Datos espaciales**: representación de datos espaciales

- **Análisis Confirmatorios de Datos espaciales:** procesos de puntos, modelos de Geoestadística y de Econometría espacial

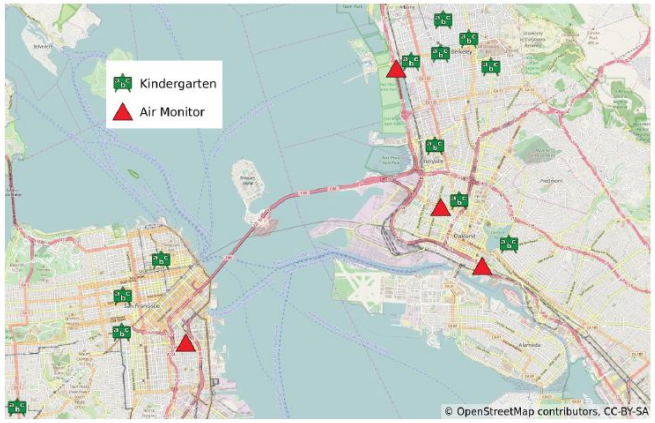
  - **Análisis de patrones (o procesos) de puntos**: ¿donde aparecen los eventos?

  - **Geoestadística**: **interpolaciones** de valores de una variable que sabemos que debería tomar un valor en el continuo del espacio, pero que sólo se observa en un conjunto concreto de datos.

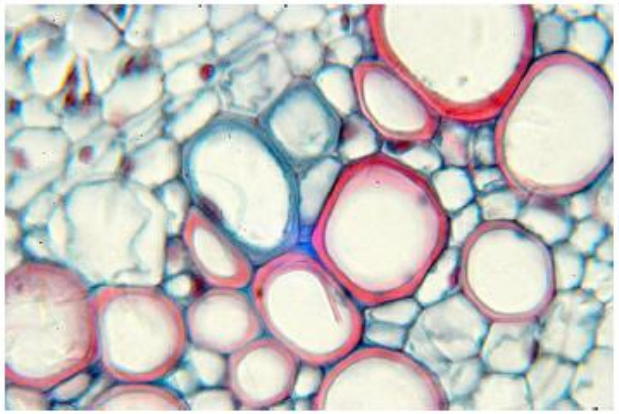
  - **Econometría Espacial : cuantificar** la Correlación Espacial mediante las matrices de pesos espaciales

Datos Espaciales

- Los datos espaciales son datos que tienen asociados una localización, una posición en el espacio.
- Los datos espaciales tienen un índice de posición en el espacio
- Cuando la referencia de posición es geográfica serán datos geoespaciales (datos georeferenciados)



Datos geostadísticos



Datos de tejidos celulares



Datos en astronomía

La posición hará referencia a un lugar **en la superficie de la Tierra**.

Necesitaremos saber a hacer mapas y a representar puntos en un mapa. Este es el objetivo de los sistemas de Información Geográfica (GIS)

Datos geoespaciales (datos georeferenciados) ¿cómo se asignan coordenadas?

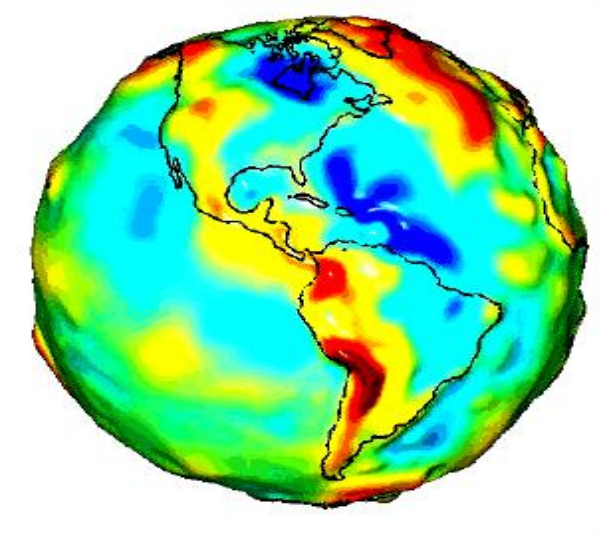
Sistemas de Información Geográfica (GIS)
Proyecciones, Coordenadas, Sistemas de Referencia Espacial, Cartografías …

- https://spatialreference.org
- https://www.ign.es/web/ign/portal/gds-area-geodesia
- Ignacio Alonso Fernández- Coppel Localizaciones geográficas.

Datos geoespaciales (datos georeferenciados):

Objetivo:
- ¿cómo se asigna una posición en el espacio?
- ¿cómo se asigna unas coordenadas a un punto?

La Geodesia es la ciencia que estudia la forma y dimensiones de la Tierra.



Geoide: superficie (de nivel) equipotencial del campo gravitatorio de la Tierra. Coincide “idealmente” con el nivel medio del mar

La Tierra NO es redonda

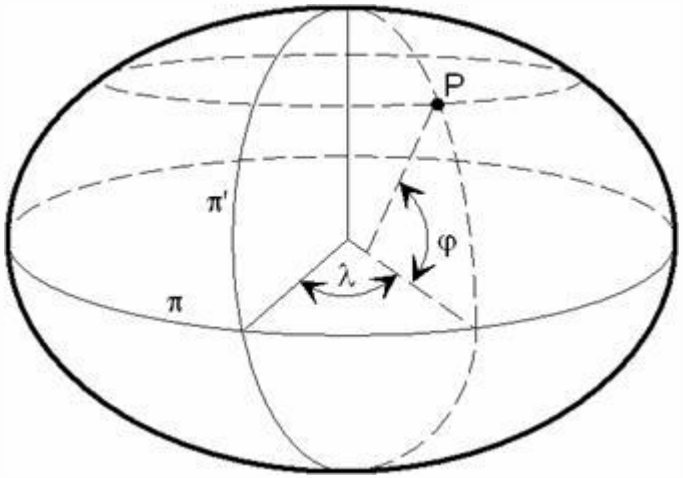
La figura "natural" de la Tierra, excluyendo la topografía o forma externa, se asemeja a la definición de **geoide**, definida como una superficie de nivel equipotencial del campo gravitatorio terrestre.

Esta superficie equipotencial o de nivel materializado por los océanos cuando se prescinde del efecto perturbador de las mareas (casi la superficie del nivel medio de los mares) es la superficie de referencia para la altitud.

Dada su forma geométrica compleja NO sabemos representar la posición de un punto sobre la Tierra.

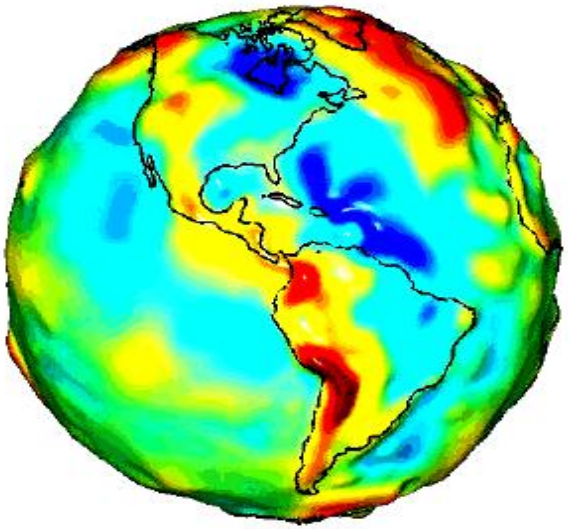
Si la Tierra tuviera una forma geométrica Euclídea sí podríamos determinar exactamente cualquier punto sobre su superficie

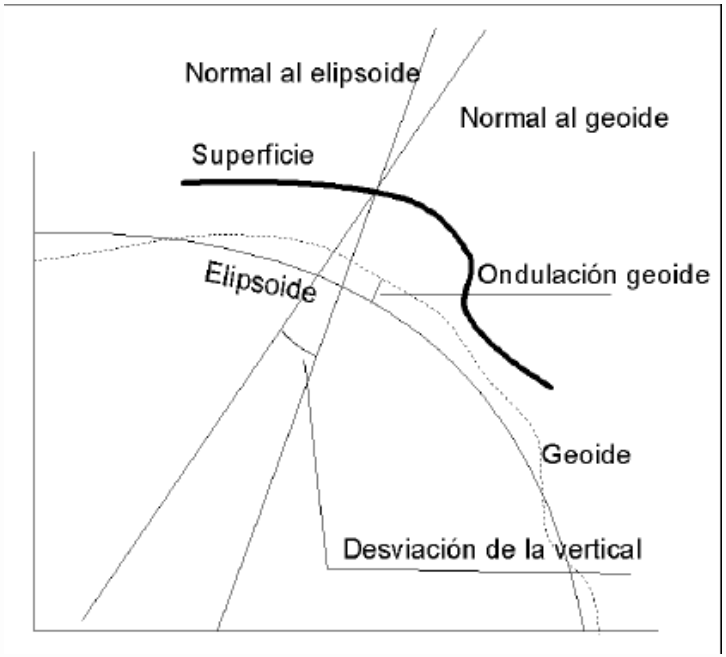
Elipsoides de revolución



Elipsoide:
- Centro
- Eje mayor
- Eje menor

Para determinar la posición de un punto en la superficie de la Tierra (geoide) se utilizas recubrimientos euclídeos (elipsoides de revolución).

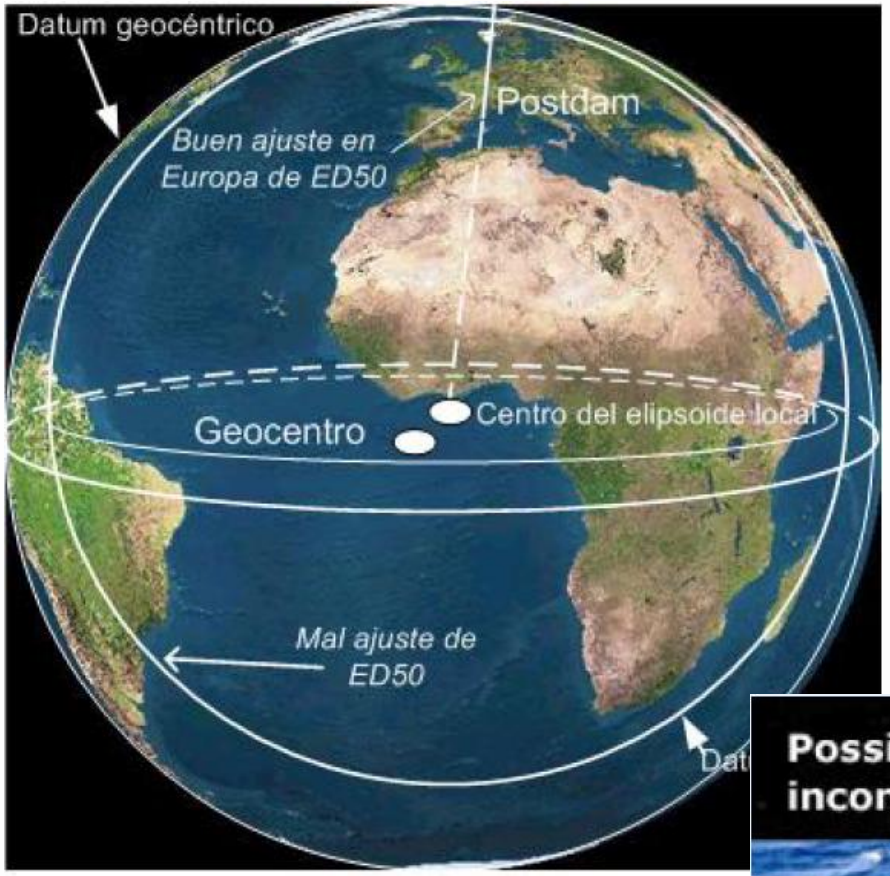




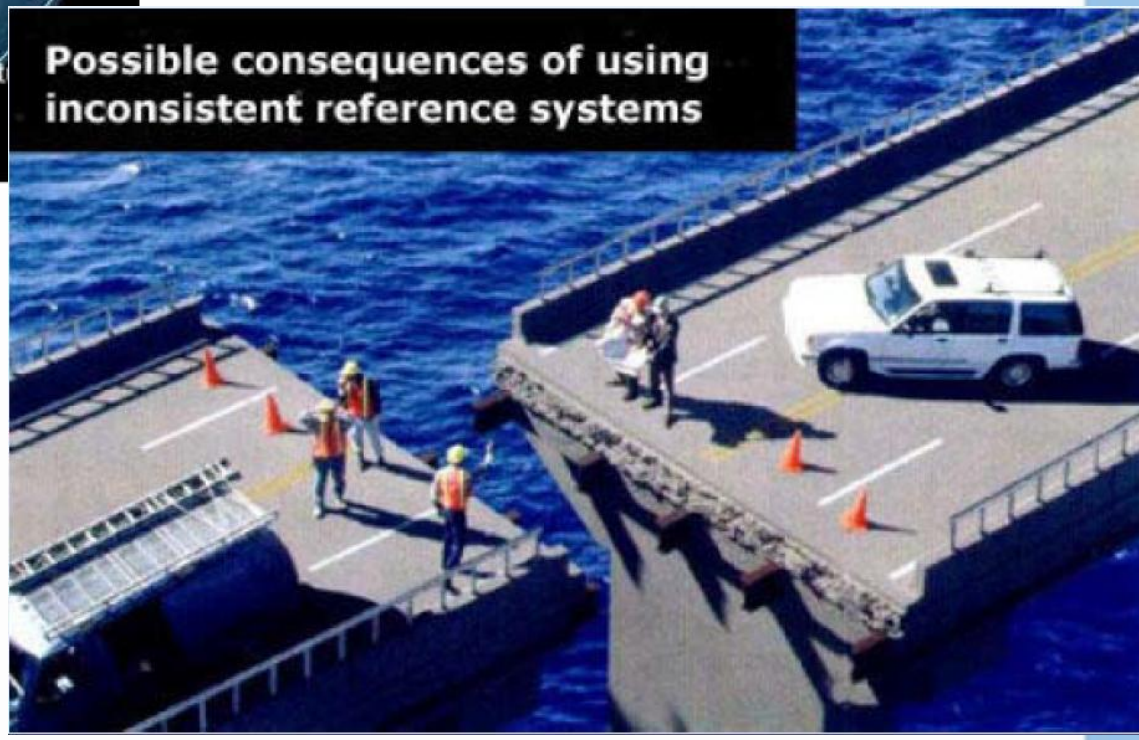


Geoide: superficie (de nivel) equipotencial del campo gravitatorio de la Tierra. Coincide "idealmente" con el nivel medio del mar

Representación de la superficie de la tierra por la revolución de un elipsoide **que mejor se adapte a la zona concreta** que se quiere representar. El **DATUM horizontal es el modelo geométrico que se utiliza para representar a la Tierra a nivel del mar (**origen y situación de un sistema de coordenadas **para una zona de la Tierra**). El Datum Vertical es el modelo que se utiliza para representar la altitud, la elevación respecto al nivel del mar

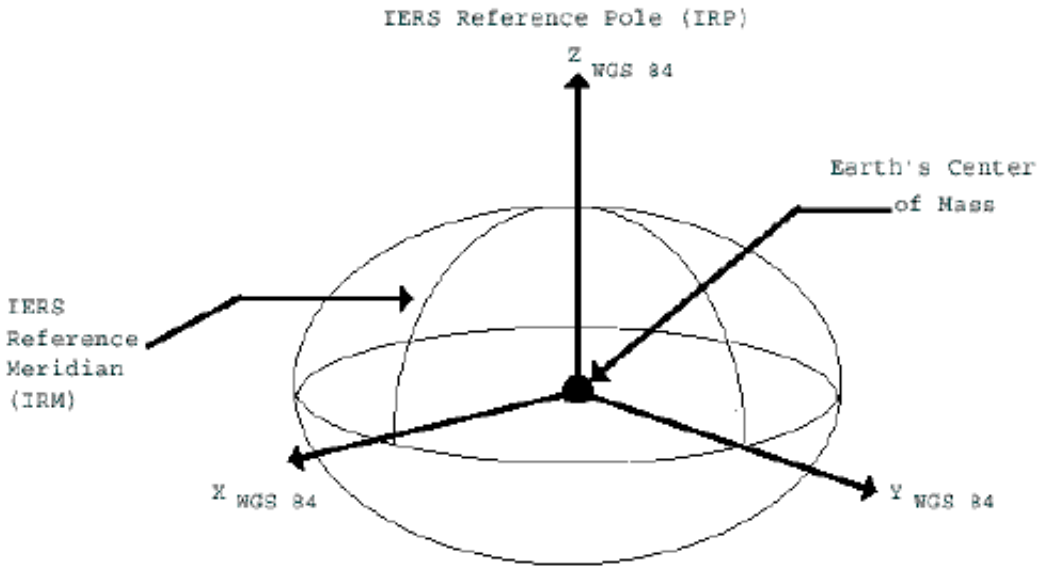


Consecuencia de trabajar con diferentes sistemas geodésicos de referencia



https://www.ign.es

Sistema geodésico de referencia en España ETRS89 (EPSG 25830) (Real Decreto 28/07/07)



EPSG:25830

ETRS89 / UTM zone 30N (Google it)

- **WGS84 Bounds**: -6.0000, 34.7500, 0.0000, 62.3300
- **Projected Bounds**: 225370.7346, 3849419.9580, 774629.265
- **Scope**: Large and medium scale topographic mapping and engir
- **Last Revised**: Oct. 19, 2000
- **Area**: Europe - 6°W to 0°W and ETRS89 by country

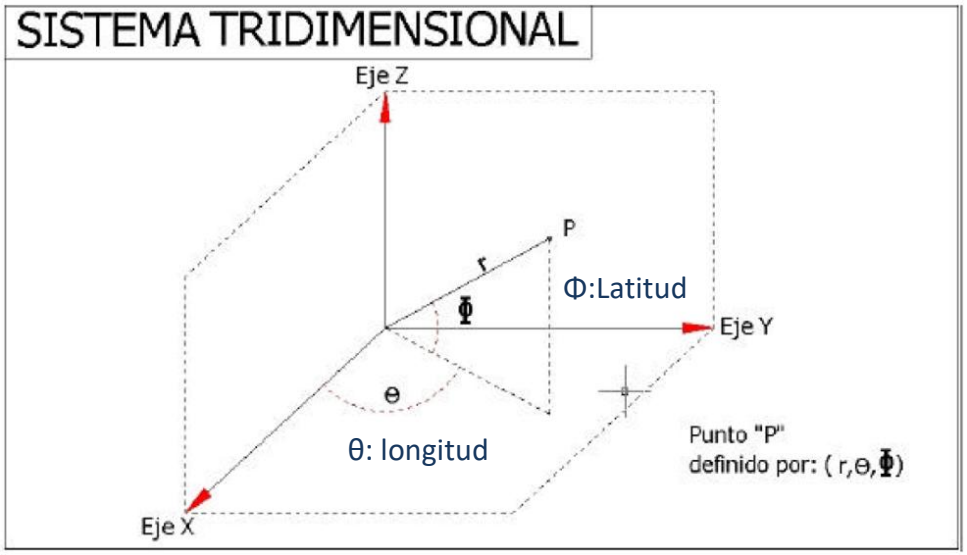
```
PROJCS["ETRS89 / UTM zone 30N",
    GEOGCS["ETRS89",
        DATUM["European_Terrestrial_Reference_System_1989",
            SPHEROID["GRS 1980",6378137,298.257222101,
                AUTHORITY["EPSG","7019"]],
            AUTHORITY["EPSG","6258"]],
        PRIMEM["Greenwich",0,
            AUTHORITY["EPSG","8901"]],
        UNIT["degree",0.01745329251994328,
            AUTHORITY["EPSG","9122"]],
        AUTHORITY["EPSG","4258"]],
    UNIT["metre",1,
        AUTHORITY["EPSG","9001"]],
    PROJECTION["Transverse_Mercator"],
    PARAMETER["latitude_of_origin",0],
    PARAMETER["central_meridian",-3],
    PARAMETER["scale_factor",0.9996],
    PARAMETER["false_easting",500000],
    PARAMETER["false_northing",0],
    AUTHORITY["EPSG","25830"],
    AXIS["Easting",EAST],
    AXIS["Northing",NORTH]]
```

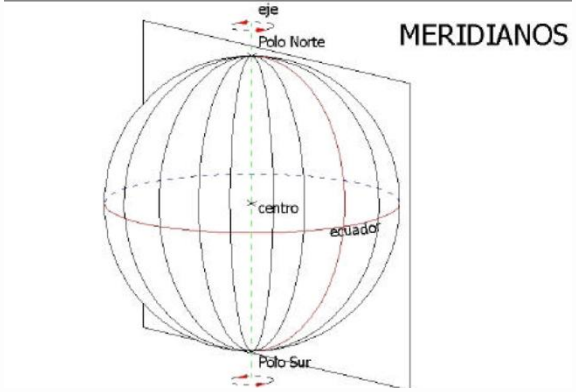


https://spatialreference.org

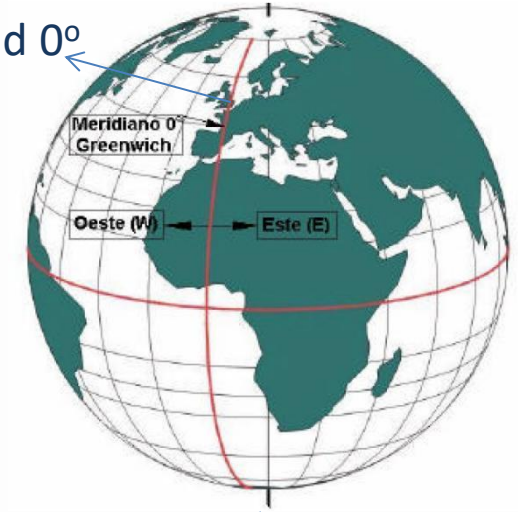
Coordenadas Geográficas

Una forma de designar un punto sobre la superficie terreste:

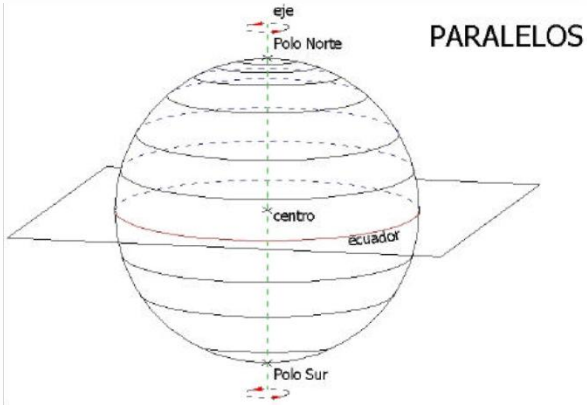


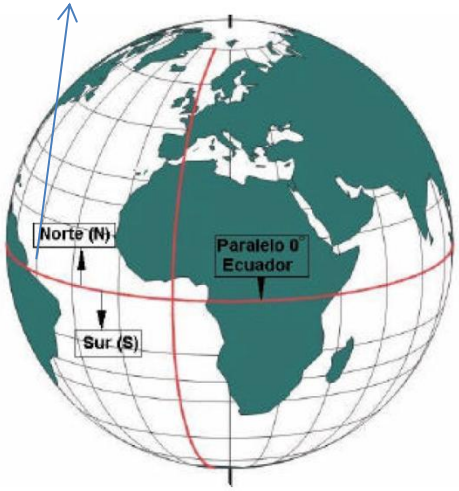


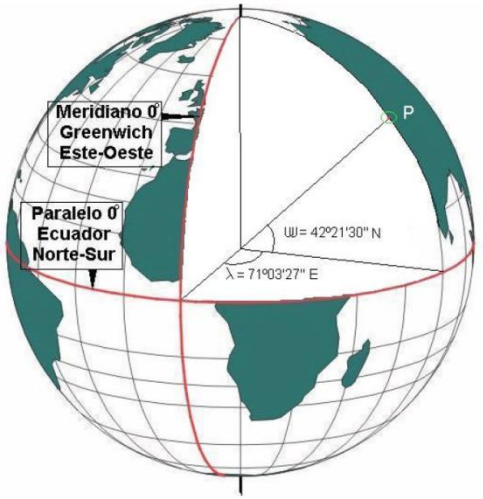
Longitud 0º



Latitud 0º







Algunas Curiosidades

1 metro es una 10^(-7) parte de un cuarto de arco de meridiano (El ecuador 40.000 kms)

Un grado de Latitud es aproximadamente 111 kilómetros

Un grado de Longitud es aproximadamente 111 kilómetros pero sólo en el ecuador

Distancia en km por grado de longitud = 111.321 km * cos(latitud)

El meridiano de Greenwich, que pasa por el Real Observatorio de Greenwich en Londres, se utiliza como el meridiano 0° y divide la Tierra en dos hemisferios:

- Hemisferio Este: Longitudes positivas (0° a 180° E)
- Hemisferio Oeste: Longitudes negativas (0° a 180° O)

Ejemplo Google Earth (tridimensional) Madrid, Latitud: 40° 25' Norte
Longitud: 3° 42' Oeste
En el hemisferio norte y al oeste del meridiano de Greenwich.

Grados decimales

Grados + minutos/60 + segundos/3600

Grados decimales a radianes

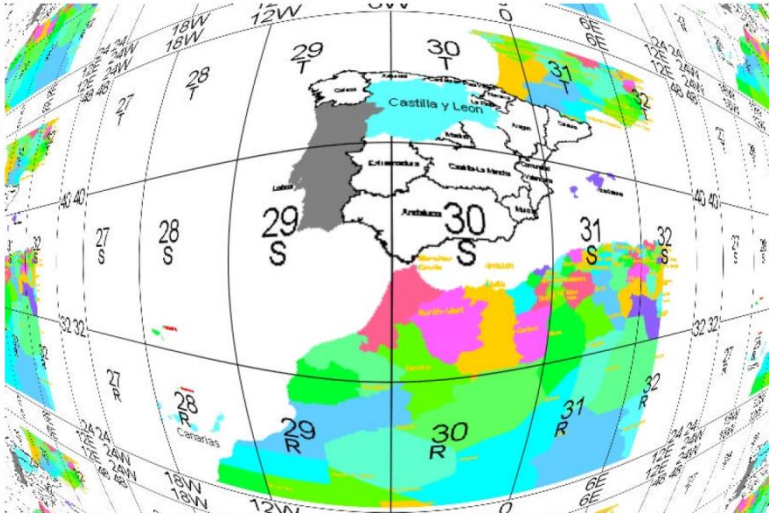
Lat radianes = (Lat grados-90) * π / 180

Lon radianes = Lon grados * π / 180

Distancias Polares o de Arco

d = R * arccos[sin(lat1) * sin(lat2) + cos(lat1) * cos(lat2) * cos(lon2 - lon1))

d es la distancia entre los dos puntos en metros. **R** es el radio medio de la Tierra, que es aproximadamente 6,371,000 metros. lat1 y lon1 son la latitud y longitud del primer punto en radianes. lat2 y lon2 son la latitud y longitud del segundo punto **en radianes**.



Proyección del elipsoide en un plano



Cartografías para la representación de mapas y datos espaciales
Ejemplo: **archivos.shape**

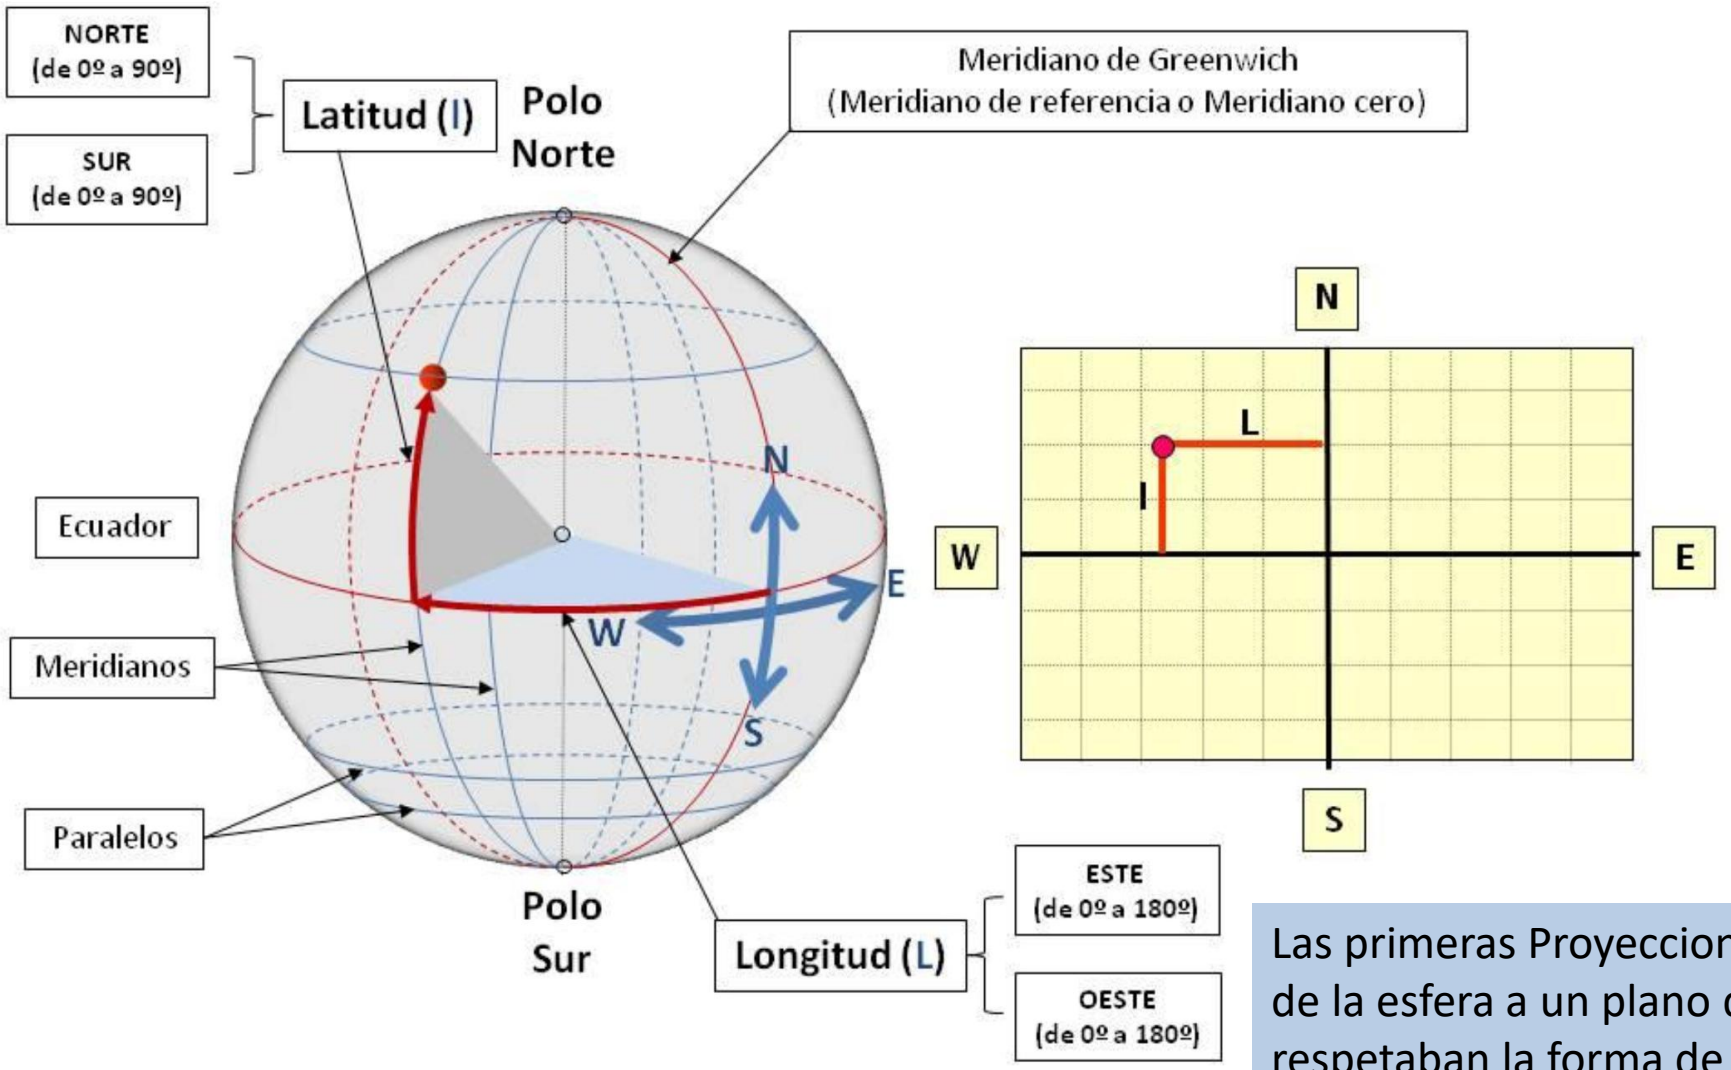


Localización geográfica (coordenadas)

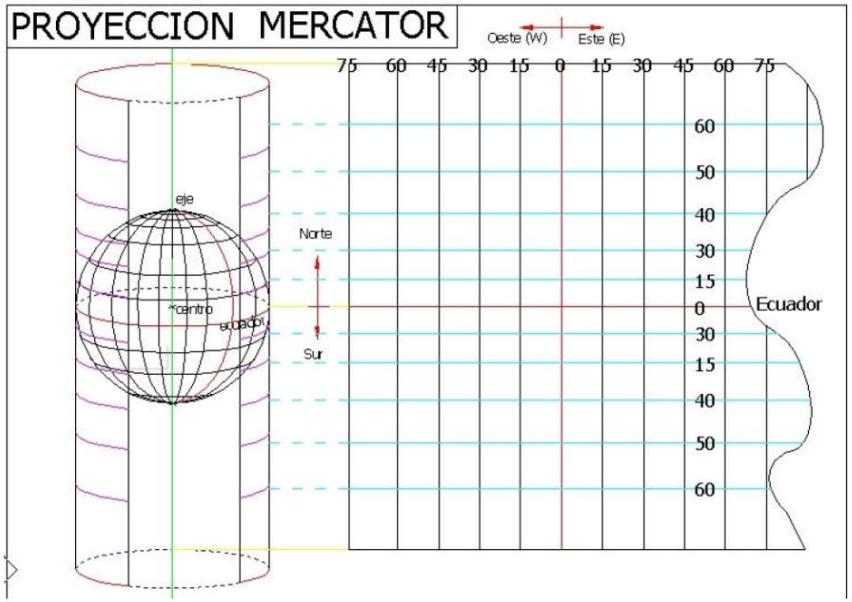
- Coordenadas geográficas en formato Longitud-Latitud
- Coordenadas (x,y) UTM: Universal Transversa Mercator

		Coordenada UTM		
Origen	Geográfica	X	y	Origen
Huso 29	42°0'0.0''N4°0'0.0''W	914143.57	4661883.98	Huso 29
Huso 30	42°0'0.0''N4°0'0.0''W	417181.93	4650259.84	Huso 30
Huso 31	42°0'0.0''N4°0'0.0''W	-79874.09	4673541.14	Huso 31

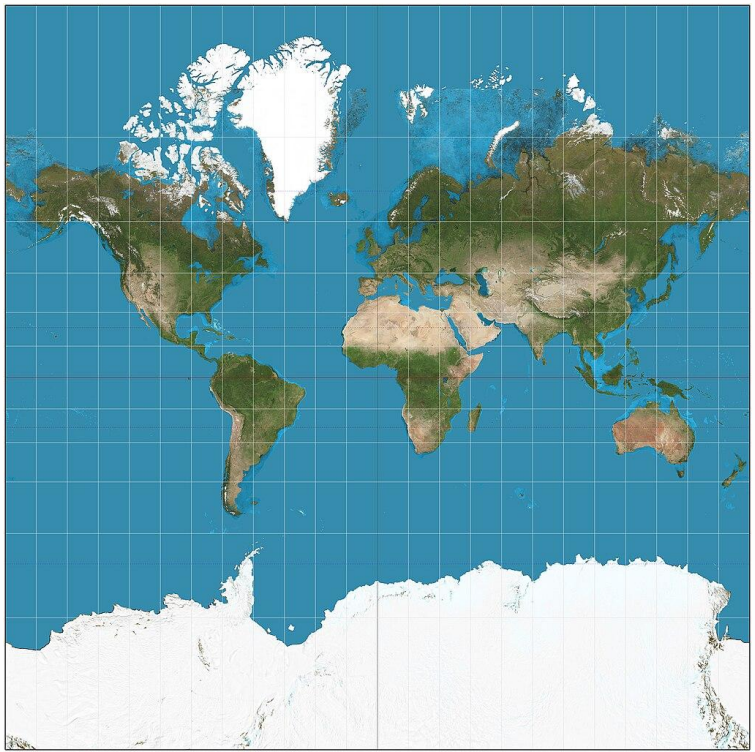
Posicionamiento de un punto en la esfera terrestre

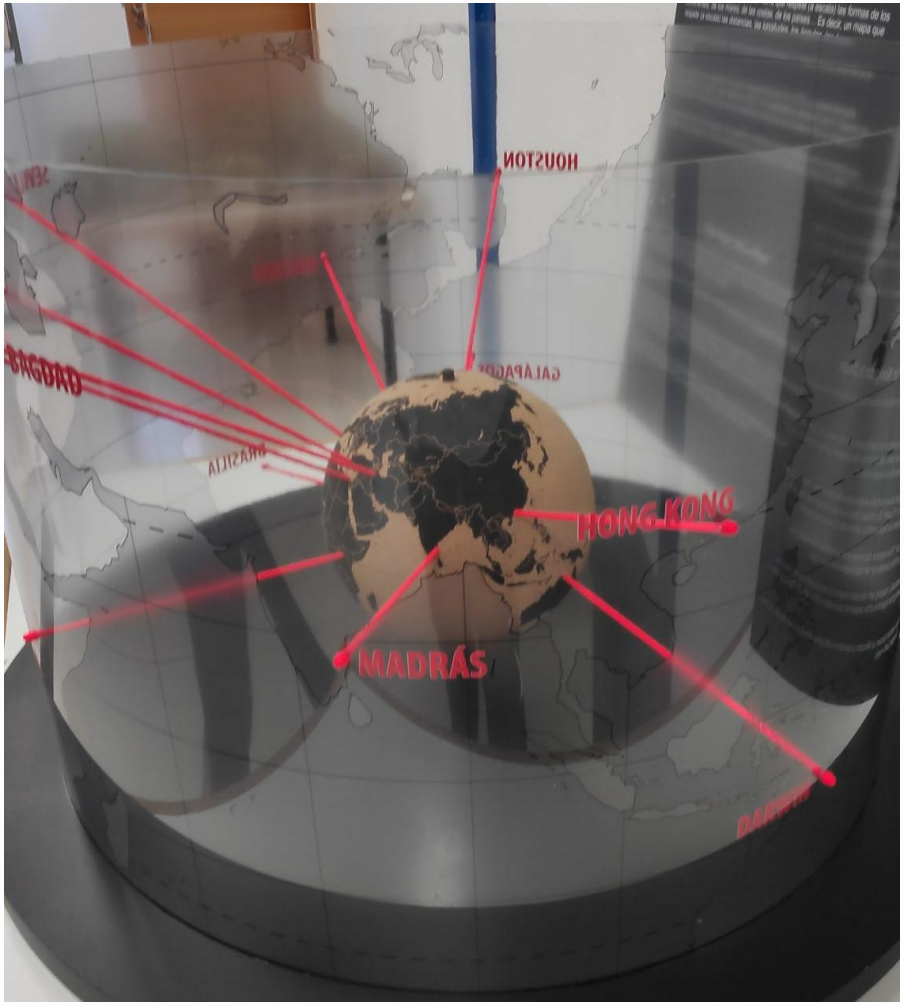


Las primeras Proyecciones de la esfera a un plano que respetaban la forma de los continentes se deben Gerardo Mercator (1569)



Ignacio Alonso Fernández- Coppel Localizaciones geográficas





$$x = \lambda - \lambda_0$$

$$y = \ln\left[\tan\left(\frac{\pi}{4} + \frac{\phi}{2}\right)\right]$$

$$= \frac{1}{2}\ln\left(\frac{1+\operatorname{sen}\phi}{1-\operatorname{sen}\phi}\right)$$

$$= \operatorname{senh}^{-1}(\tan\phi)$$

$$= \tanh^{-1}(\operatorname{sen}\phi)$$

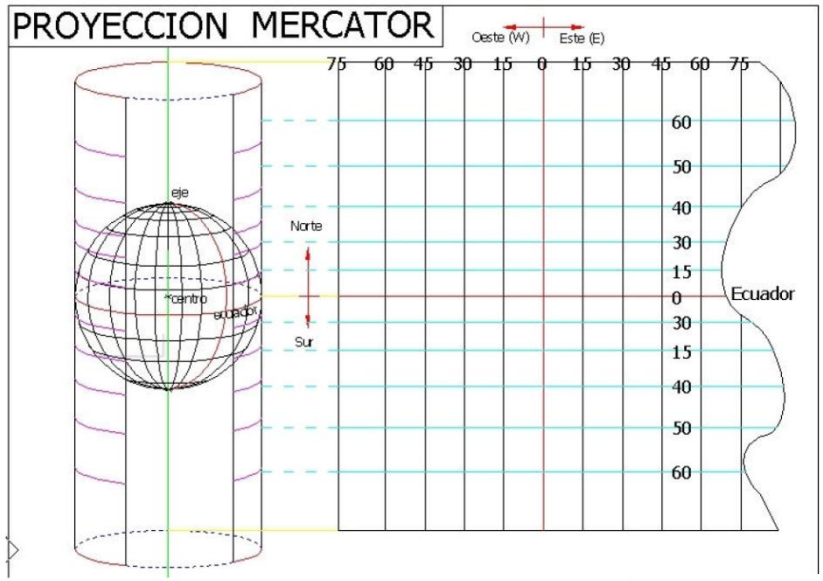
$$= \ln(\tan\phi + \sec\phi)$$

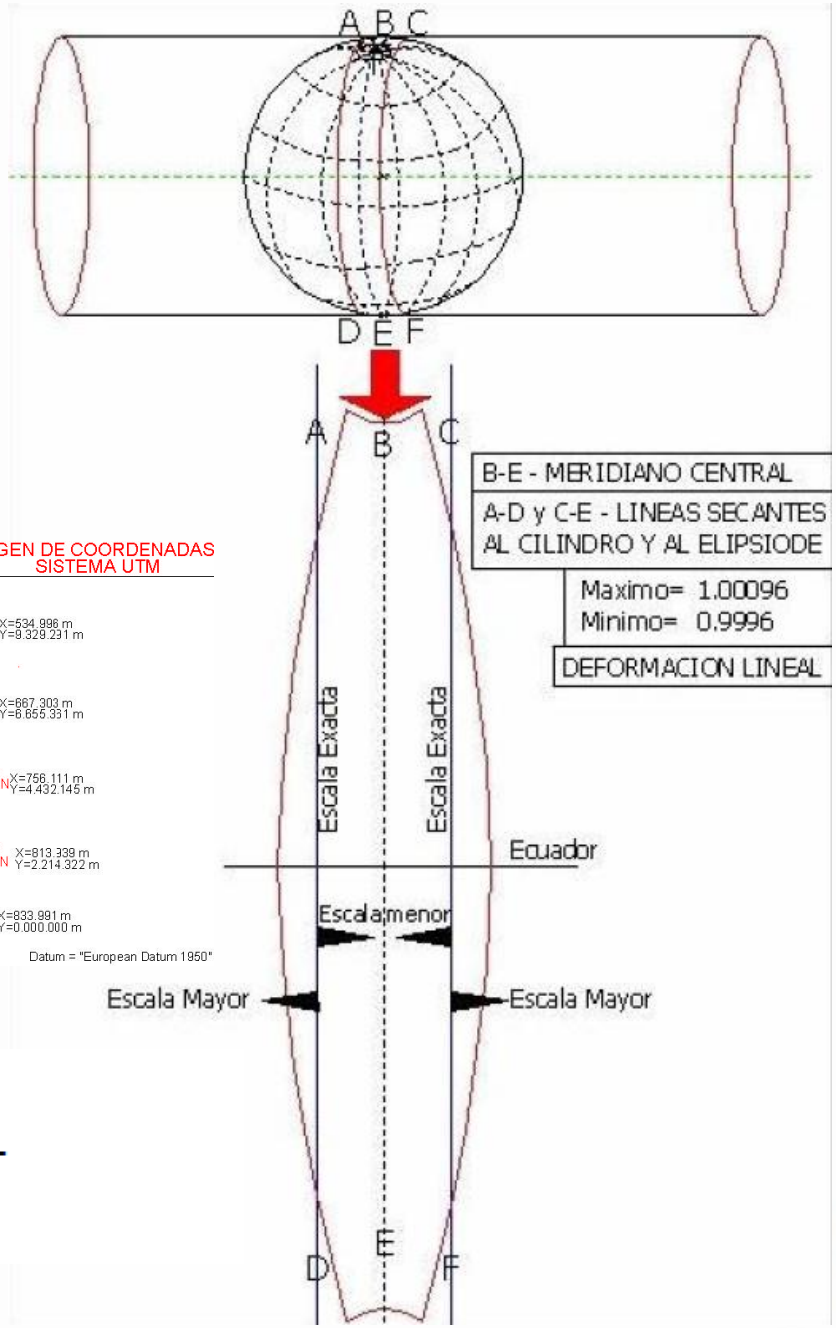
$$\phi = 2\tan^{-1}(e^y) - \frac{\pi}{2}$$

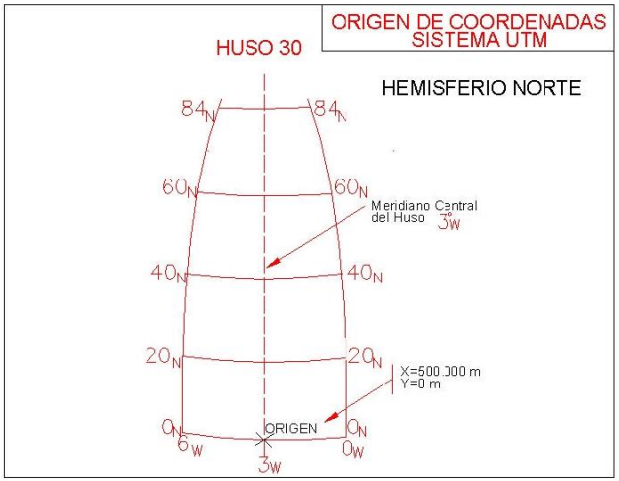
$$= \tan^{-1}(\sinh(y))$$

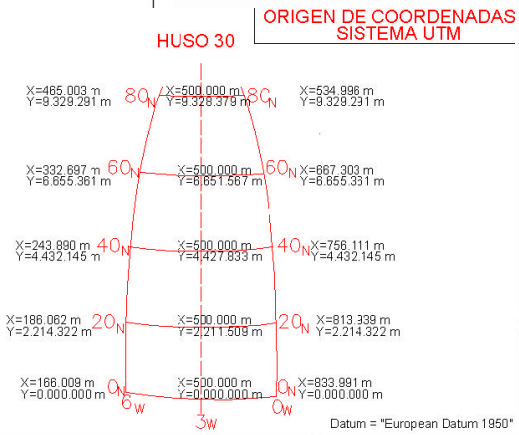
$$\lambda = x + \lambda_0$$

UTM: **Universal Transversa Mercator**



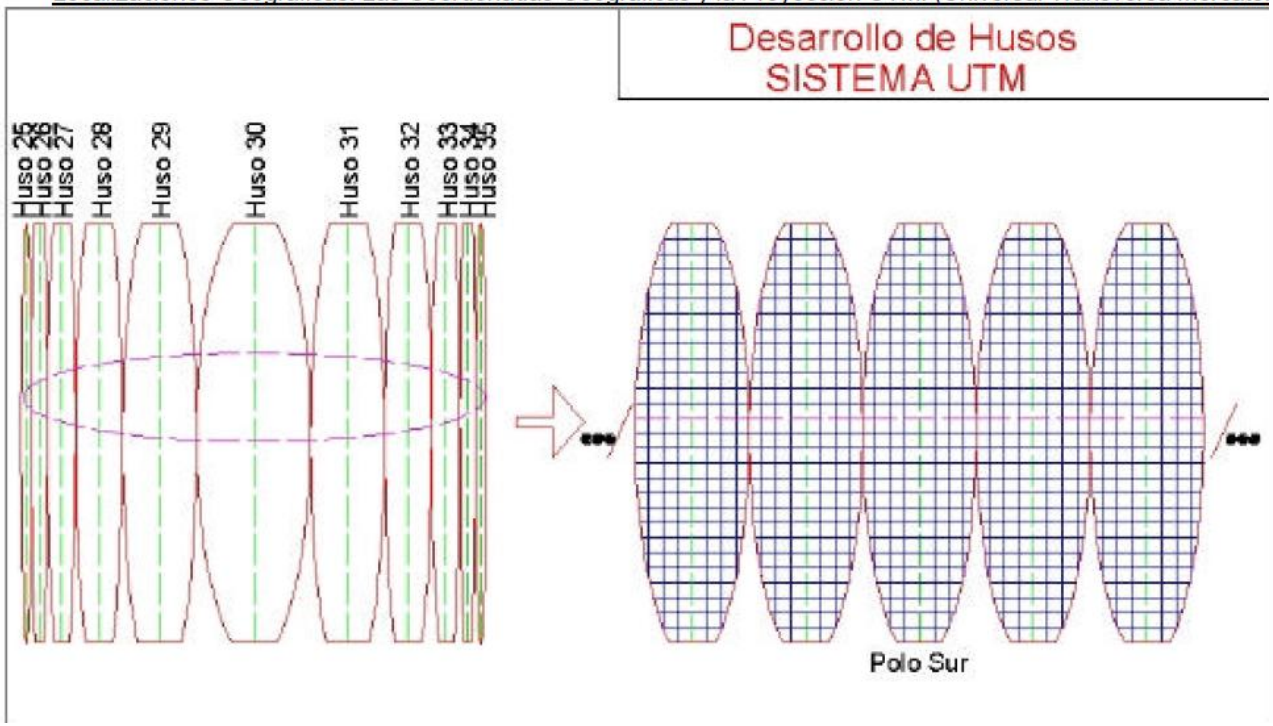


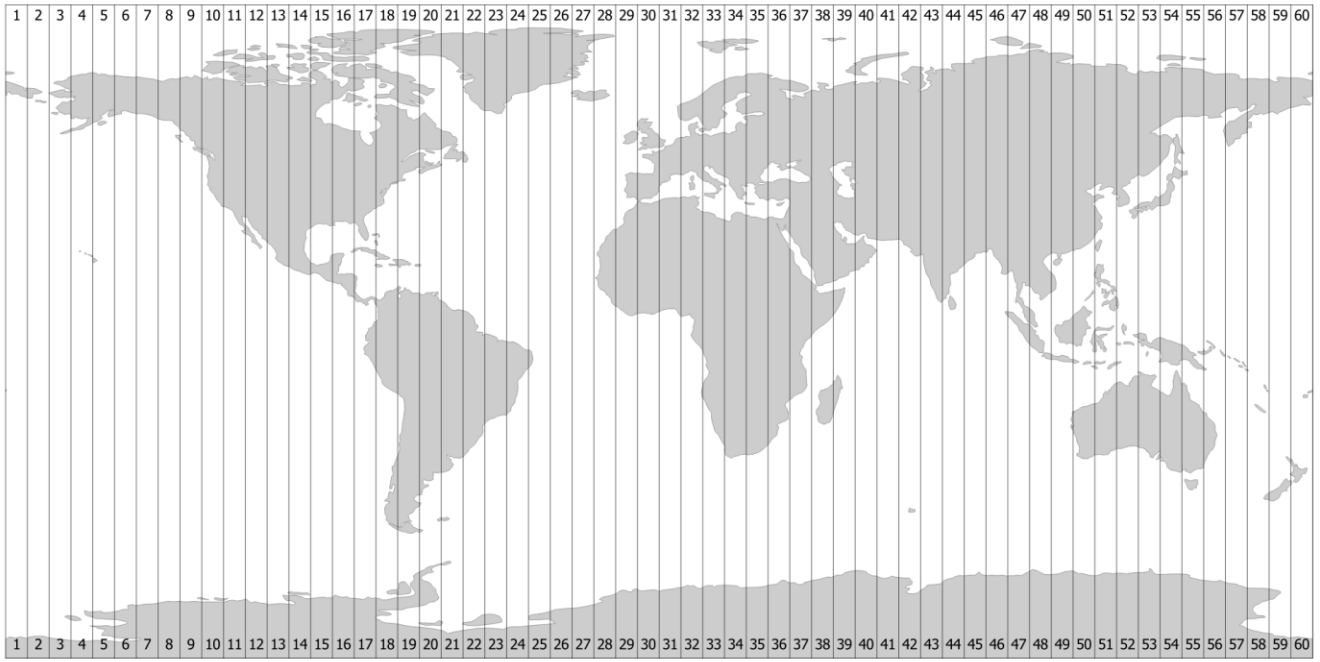




X= 462.130 m
Y= 4.634.140 m
Huso=30 Zona=T
Datum: ETRS89

Localizaciones Geográficas. Las Coordenadas Geográficas y la Proyección UTM. (Universal Transversa Mercator

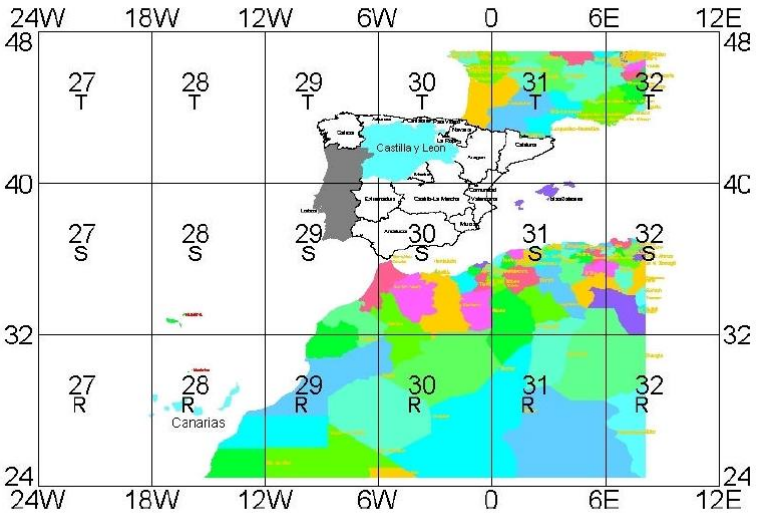




Localizaciones Geográficas. Las Coordenadas Geográficas y la Proyección UTM. (Universal Transversa Mercator)



La distribución de **Husos y zonas** para España es la siguiente:



Ignacio Alonso Fernández- Coppel Localizaciones geográficas

Sistema de Referencia de coordenadas (CRS): sistemas de referencia para localizar a un objeto en la superficie terrestre. **El CRS estará compuesto de un DATUM y una proyección**:

Datum: modelo geométrico teórico para representar la Tierra (geoide).
Se define por la situación del centro de la Tierra, eje mayor y menor del elipsoide, y otros parámetros. Suele utilizar un sistema de coordenadas geográficas o angulares (longitud-λ y latitud-ϕ)
Ejemplos de Datum geodésico espacial:

- WGS84 (World Goedesic System 1984)
- NAD83 (The North A;erican Datum of 1983)
- ETRS89 (European Terrestrial Reference System 1989)
- REGCAN95 (Red Geodésica Nacional para Canarias de 1995)

Proyección: es el método empleado para transformar el sistema tridimensional del modelo geométrico utilizado para representar la Tierra a un sistema plano de dos dimensiones ("cartesiano"). Existen diferentes métodos para realizar esas "proyecciones" a un plano: **Mercator**, **UTM**, **Robinson**, **Lambert**, **Sinusoidal**, **Albert**.... Algunas proyecciones se utilizan para representar a todo el mapa mundo (Mercator o pseudo Mercator), otras sólo para algunas regiones o áreas concretas (UTM). Debido a que cualquier proyección genera distorsiones, las proyecciones pueden corregirse para mantener el "mismo área" (escala de medida constante en todo el mapa) o "conformes" (las formas de los diferentes accidentes geográficos se representan tal y como se ven en el globo terráqueo)

Unidades: Define si las coordenadas están en grados, metros, pies. Entre otras cosas el CRS debe especificar la unidad de medida (**grados decimales** como en las cartas de navegación, o **metros** utilizados por los mapas GPS)

En [esta página pueden visualizarse las diferentes proyecciones según su notación estandarizada PROJ.4](https://proj.org/en/stable/operations/projections/index.html) (creo que va a cambiarse por una nueva notación PRϕJ)

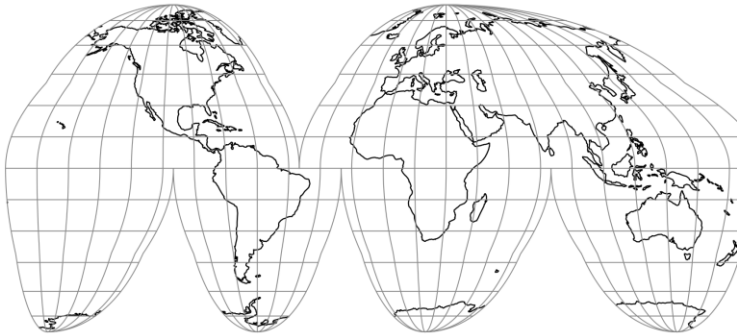
https://proj.org/en/stable/operations/projections/index.html

Chamberlin Trimetric



proj-string: +proj=chamb +lat_1=10 +lon_1=30 +lon_2=40

Interrupted Goode Homolosine



proj-string: +proj=igh

Central Conic



proj-string: +proj=ccon +lat_1=52 +lon_0=19

Albers Equal Area



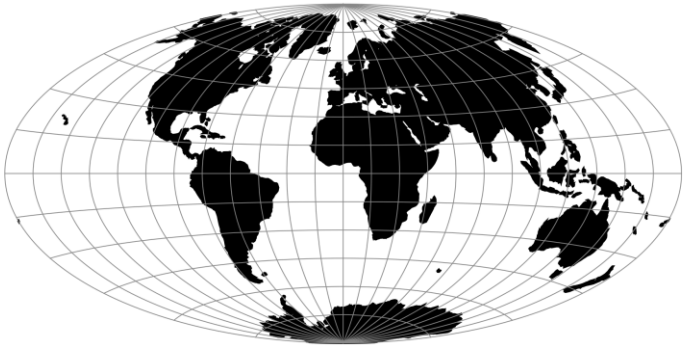
proj-string: +proj=aea +lat_1=29.5 +lat_2=42.5

Airy



proj-string: +proj=airy

Aitoff



proj-string: +proj=aitoff

Euler



+proj=euler +lat_1=67 +lat_2=75

Sistemas de Referencia de Coordenadas

Códigos de identificación de CRS: para identificar a cada CRS (Datum + proyección) se utilizan una serie de identificadores únicos denominados **códigos EPSG** (European Petroleum Survey Group)

https://spatialreference.org

Península ETRS89

EPSG:25829	UTM huso 29 en ETRS89	HUSO 29 DATUM ETRS89
EPSG:25830	UTM huso 30 en ETRS89	HUSO 30 DATUM ETRS89
EPSG:25831	UTM huso 31 en ETRS89	HUSO 31 DATUM ETRS89
EPSG:4258	Geográficas en ETRS89	HUSO 0 DATUM ETRS89

España utilizando el DATUM Internacional WGS84

EPSG:4326	Geográficas en WGS 84	HUSO 0 DATUM WGS84
EPSG:32627	UTM huso 27N en WGS 84	HUSO 27 DATUM WGS84
EPSG:32628	UTM huso 28N en WGS 84	HUSO 28 DATUM WGS84
EPSG:32629	UTM huso 29N en WGS 84	HUSO 29 DATUM WGS84
EPSG:32630	UTM huso 30N en WGS 84	HUSO 30 DATUM WGS84
EPSG:32631	UTM huso 31N en WGS 84	HUSO 31 DATUM WGS84

REGCAN95 (Red Geodésica de Canarias 1995).

¿qué sistemas de referencia hay en Canarias? (REGCAN95 (Red Geodésica de Canarias 1995).

¿cuál es el sistema de coordenadas de referencia "epsg:3857", y el "EPSG:900913"?

EPSG:4326 Utilizado por Google Earth (grados decimales)
EPSG:3857 Utilizado por Google Maps, OpenStreetMaps, Bing Maps (metros)

Objetos espaciales (o geoespaciales)

Objetos espaciales (geoespaciales)

En la estadística espacial estamos interesados en analizar los patrones de distribución de **los atributos** z_j (características) de los diferentes **objetos espaciales** s_i **en un instante de tiempo** t

$$\{z_j(s_i,t): j = 1,\dots,k; i = 1,\dots,,n; t = 1,\dots,T\} \equiv \{z_j(s_i,t)\}_{j,i,t}$$

s_i: *serán cada uno de los n objetos espaciales ubicados en el* ***espacio eucideo*** en $\mathbb{R}^2$
(*estos objetos se localizan en el plano, no hay altitud*)

z_j: *atributos observados* (*cada objeto espacial tendrá k atributos*)

t: *será el tiempo* (*habrá T periodos*). *Sirve para el tracking de movimientos de una persona*

Tipos de Datos espaciales:

Objetos espaciales discretos: objetos espaciales enumerables que tienen unas fronteras bien delimitadas (ríos, ciudades, provincias, códigos postales...), fronteras que suelen estar fijas en el tiempo. No se mueven. Presentan atributos agregados como la renta per cápita, el tamaño de la población, las tasas de Paro, etc. El **Dominio de Discreto** (áreas o polígono, líneas, redes o puntos) y **fijo**, esto es, todos los objetos espaciales tienen nivel de renta per cápita, población, densidad, tasas de paro)



Se representan como objetos vectoriales (puntos, líneas, redes o polígonos)

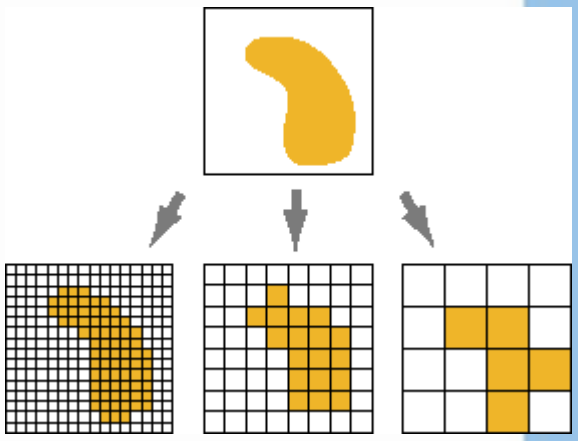
Objetos espaciales continuo: se observan en todo el espacio, no tienen fronteras naturales, en el espacio continuo, se denominan también “campos espaciales” . Presentan atributos como altitud o elevación respecto al nivel del mar, temperatura, presión atmosférica o nivel de polución calidad del aire). El **Dominio es Continuo**, y **fijo** esto es, todos los puntos del espacio tienen altitud, temperatura, niveles de contaminación, etc.



Se representan como objetos Ráster

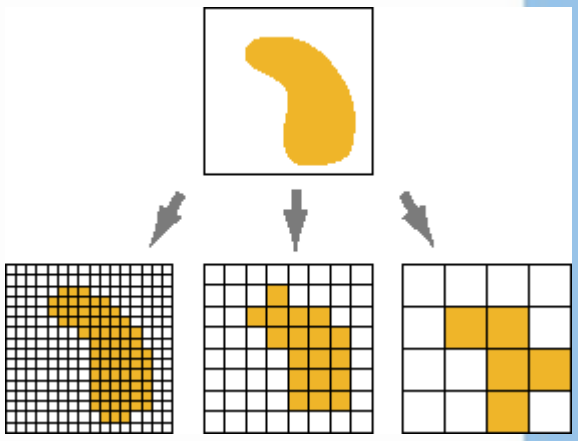
Tipos de estructura de los datos espaciales

- **Datos *raster***: registran la información espacial en una cuadrícula regular o matriz organizada en filas y columnas, de forma que cada celda contiene un número que representa una forma geográfica determinada, como un tipo de suelo, la elevación, el uso de la tierra, una pendiente, etc. Ejemplos: píxeles de fotos, mapas marinos de profundidades, etc.

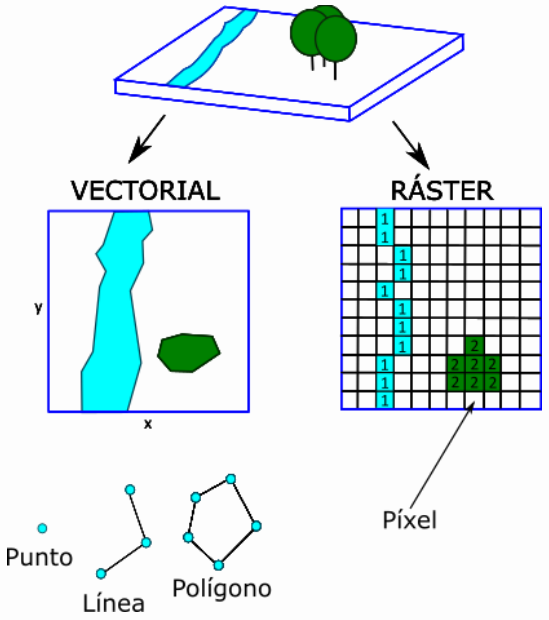


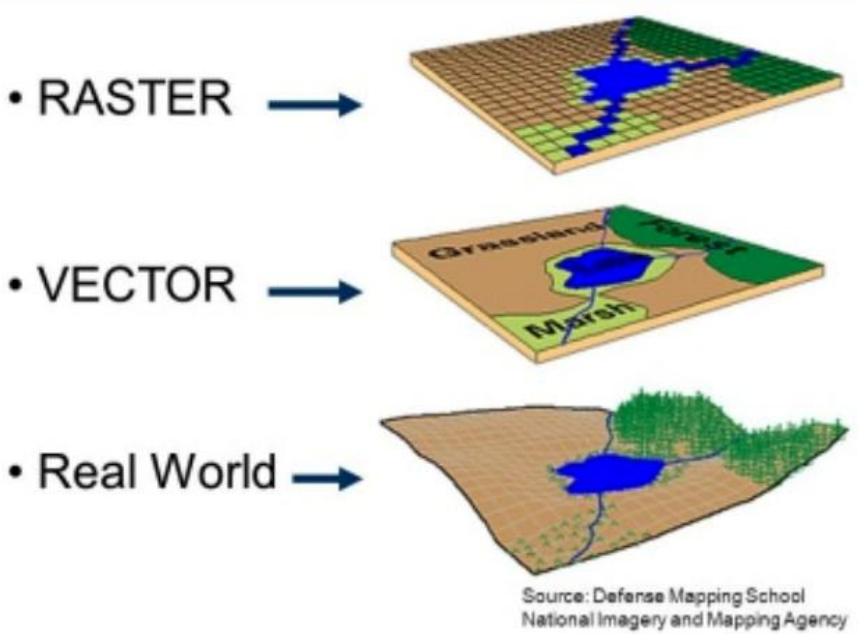
Tipos de estructura de los datos espaciales

- **Datos *raster***: registran la información espacial en una cuadrícula regular o matriz organizada en filas y columnas, de forma que cada celda contiene un número que representa una forma geográfica determinada, como un tipo de suelo, la elevación, el uso de la tierra, una pendiente, etc. Ejemplos: píxeles de fotos, mapas marinos de profundidades, etc.



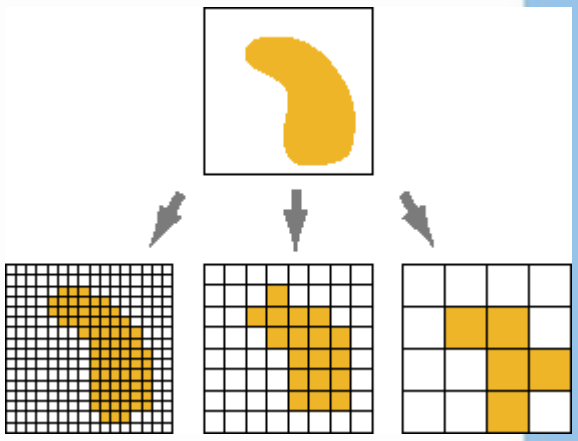
- **Datos vectoriales**: registran la información en forma de coordenadas geográficas (x,y) en un sistema plano de coordenadas. Cada **punto** se registra como una localización simple del tipo (x,y), mientras que las **formas lineales** y los contornos de los **polígonos** se recogen como series ordenadas de coordenadas (x,y).



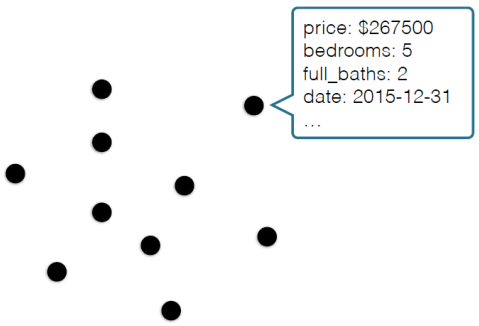


Tipos de estructura de los datos espaciales

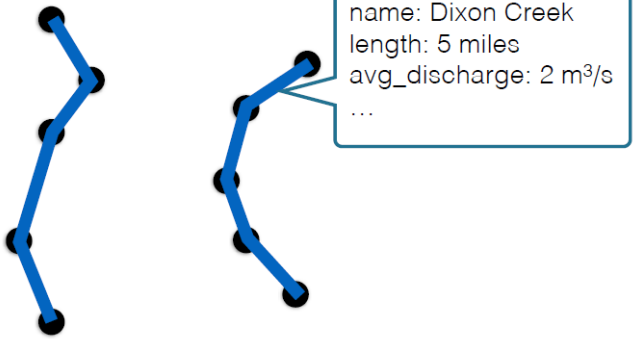
- **Datos *raster***: registran la información espacial en una cuadrícula regular o matriz organizada en filas y columnas, de forma que cada celda contiene un número que representa una forma geográfica determinada, como un tipo de suelo, la elevación, el uso de la tierra, una pendiente, etc. Ejemplos: píxeles de fotos, mapas marinos de profundidades, etc.



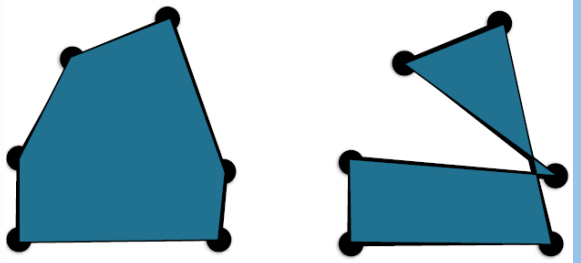
- **Datos vectoriales**: registran la información en forma de coordenadas geográficas (x,y) en un sistema plano de coordenadas. Cada **punto** se registra como una localización simple del tipo (x,y), mientras que las **formas lineales** y los contornos de los **polígonos** se recogen como series ordenadas de coordenadas (x,y).



Puntos en el espacio



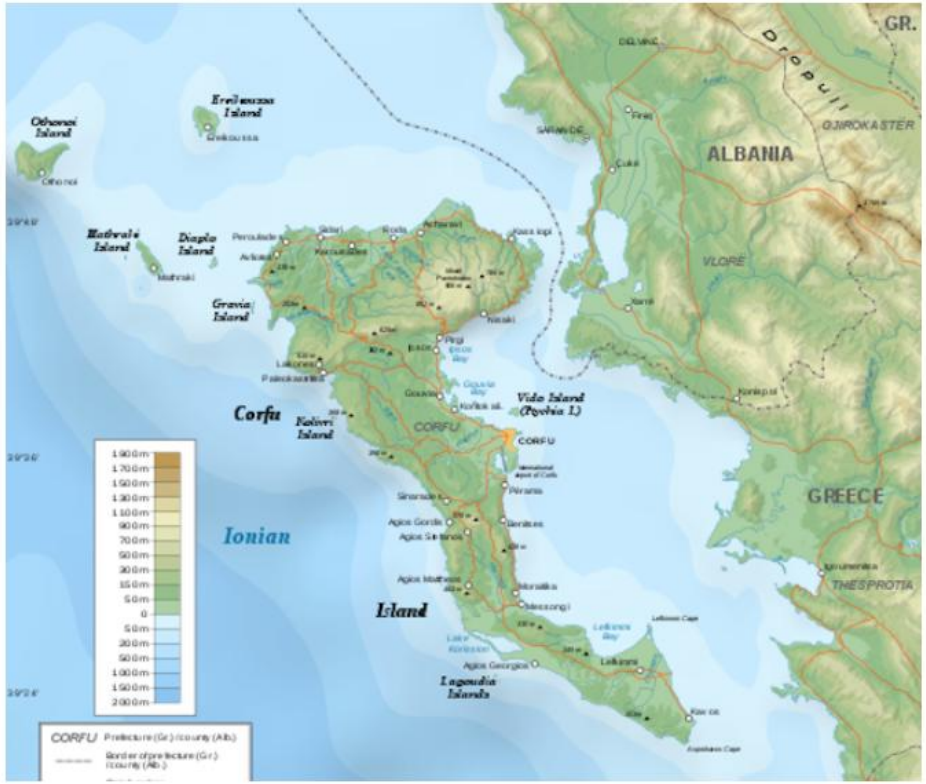
Líneas (carreteras, fronteras)



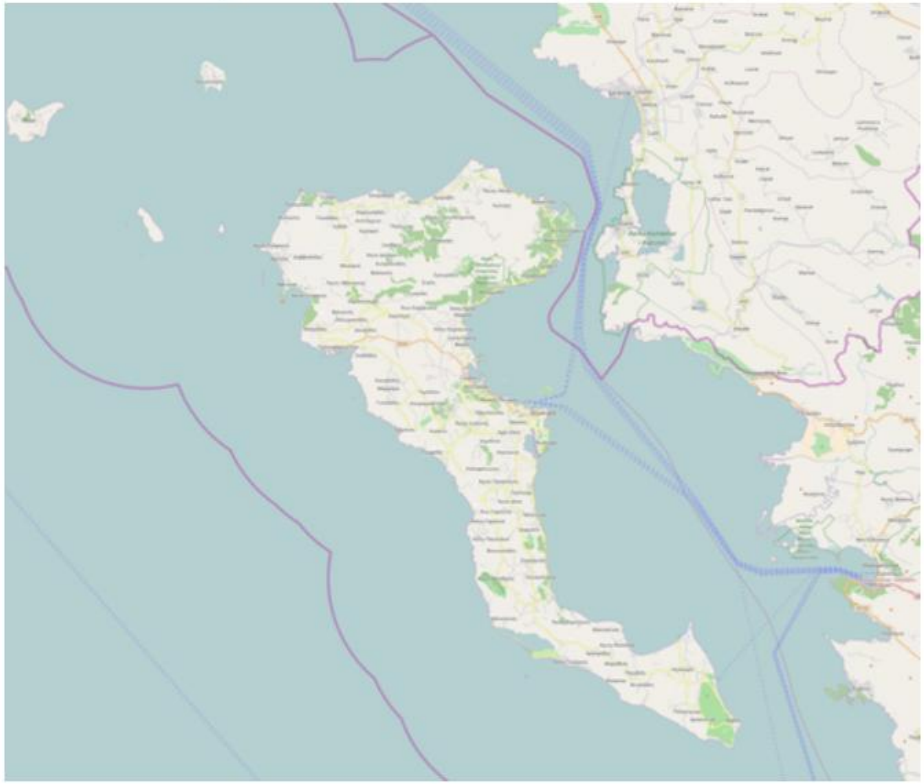
Polígonos espaciales (municipios, códigos postales, países…)

Cada dato puede llevar asociado valores de las variables correspondientes a cada punto o cada región (se suelen almacenar en una **base de datos .dbf)**

raster image of Corfu



vector image of Corfu



Fuente: Visualizing Geospatial Data in Python. DataCamp

Una Cartografía es una representación, a través de mapas, de los diferentes objetos espaciales (Raster o Vectoriales) en el territorio de

- **¿Dónde puedo encontrar cartografías?**

- **¿En que formato tengo que descargar las cartografías para poderlas leer en R o Python?**

Para representar los datos espaciales (georoferenciados) en mapas geográficos se necesita disponer de las cartografías



Cartografías en formato Vectorial

- Shapefiles
- GeoJSON
- GPS
- netCDF

Cartografías en formato Raster

- GeoTIFF
- ESRI grids
- ENVI grids
- ERDAS grids

Existen diferentes formatos de archivos de información geográfica.
El formato mas habitual en econometría espacial es el SHP.
Este tipo de formato es multiarchivo, es decir consiste en al menos tres archivos relacionados:

- .shp: archivo de formas geométricas.
- .shx: archivo índice de las formas geométricas.
- .dbf: archivo de atributos (base de datos).

El formato SHP puede ser directamente ledo por cualquier programa GIS.



El detalle y precisión de la cartografía dependerá de su escala. Dependiendo de para qué queramos la cartografía necesitaremos mayor o menor nivel de detalle. Ejemplo Eurostat

¿Dónde puedo buscar cartografías?

INE

Eurostat

https://www.naturalearthdata.com/

https://gadm.org/



Búsqueda de datos Georeferenciados:

http://opendata.esri.es/

El detalle y precisión de la cartografía dependerá de su escala. Dependiendo de para qué queramos la cartografía necesitaremos mayor o menor nivel de detalle. Ejemplo Eurostat



Lectura de Cartografías en Pyhton



- Datos vectoriales: **geopandas**



- Datos Raster: **xarray**



Cuando se trabaja con mapas geopolíticos hay que utilizar **Claves-NORMALIZADAS** para identificar a cada objeto espacial, a cada territorio de manera estandarizada

Esto es necesario para poder añadir metadatos a cada objeto espacial (a cada territorio)

Los objetos espaciales no se identifican por su nombre sino por su **nombre estandarizado o mejor aún por su código alfunumérico normalizado** según el marco estadístico nacional de cada país o el Internacional.

Por ejemplo, para España el INE:

Callejero electoral:
Código de provincia: xx
Código de Municipio: xxx
Código de distrito: XX
..... Hasta llegar a la mesa electoral

En España también los **Códigos Postales** pero con muchos problemas, ya que la Determinación de los Codigos postales atiende sólo a necesidadesde de una empresa: Correos.
Además sus cartografías no son accesibles libremente

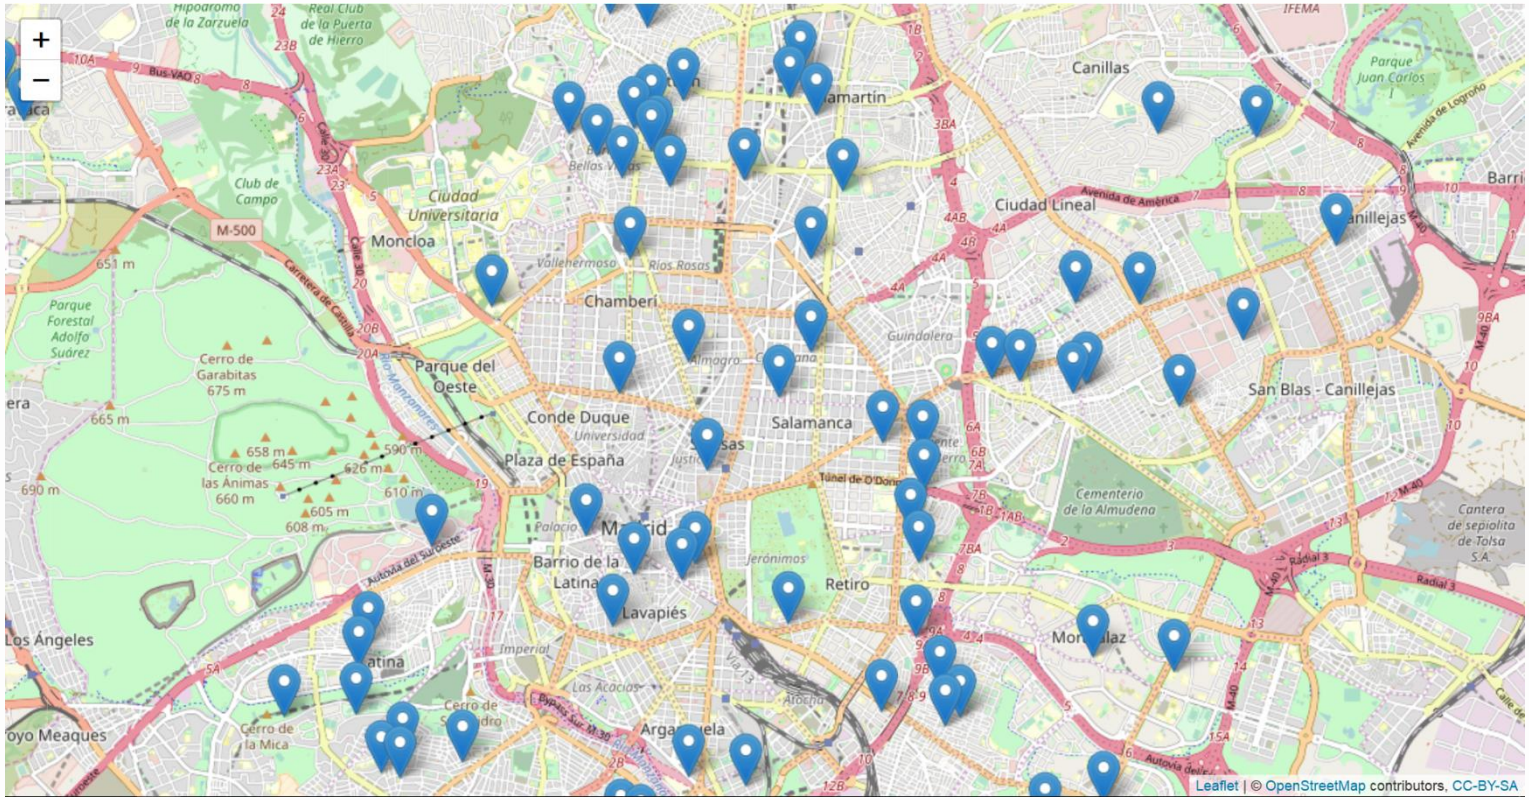
A nivel internacional Código ISO 3166 de códigos para nombre de países

México	México	MX	MEX	484	
España	España	ES	ESP	724	Códigos obtenidos del idioma nativo (español): *España*
Estados Unidos	Estados Unidos de América (los)	US	USA	840	

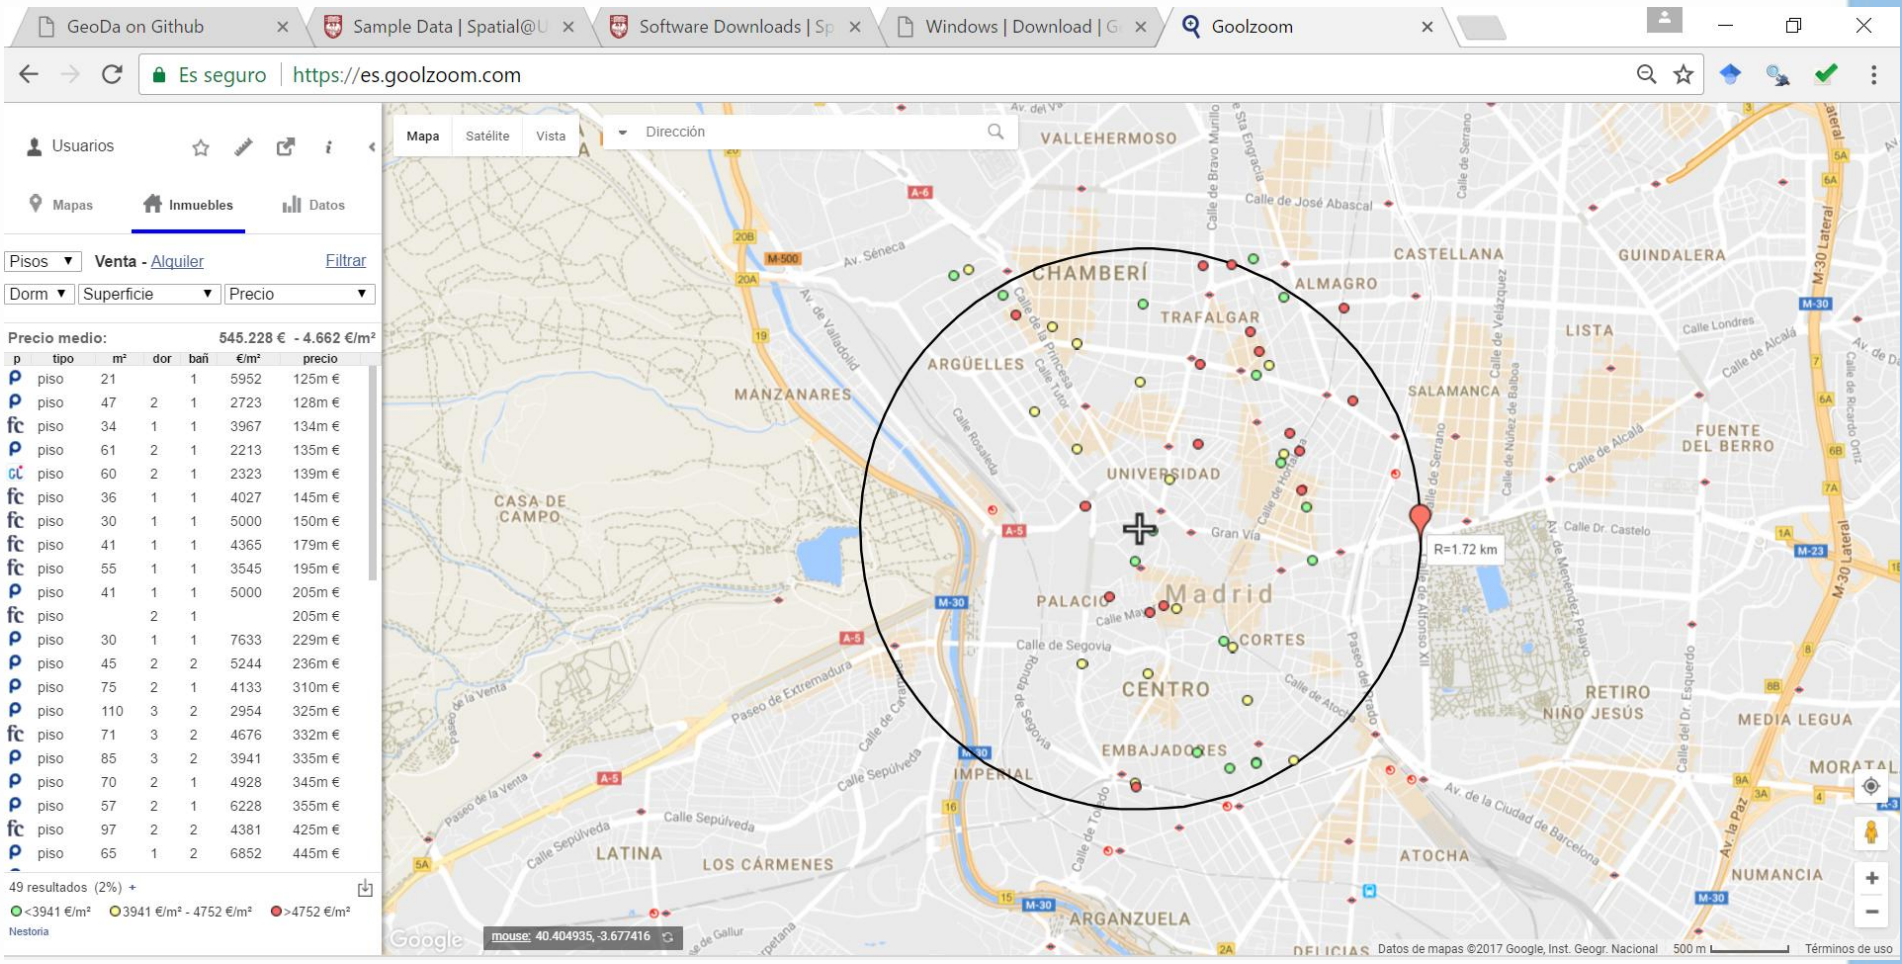
- Esta estructura de datos espaciales georeferenciados permite representar en un mapa (cartografía) los datos espaciales para analizar la distribución de determinadas variables económicas.

GoogleMaps

OpenStreetMaps



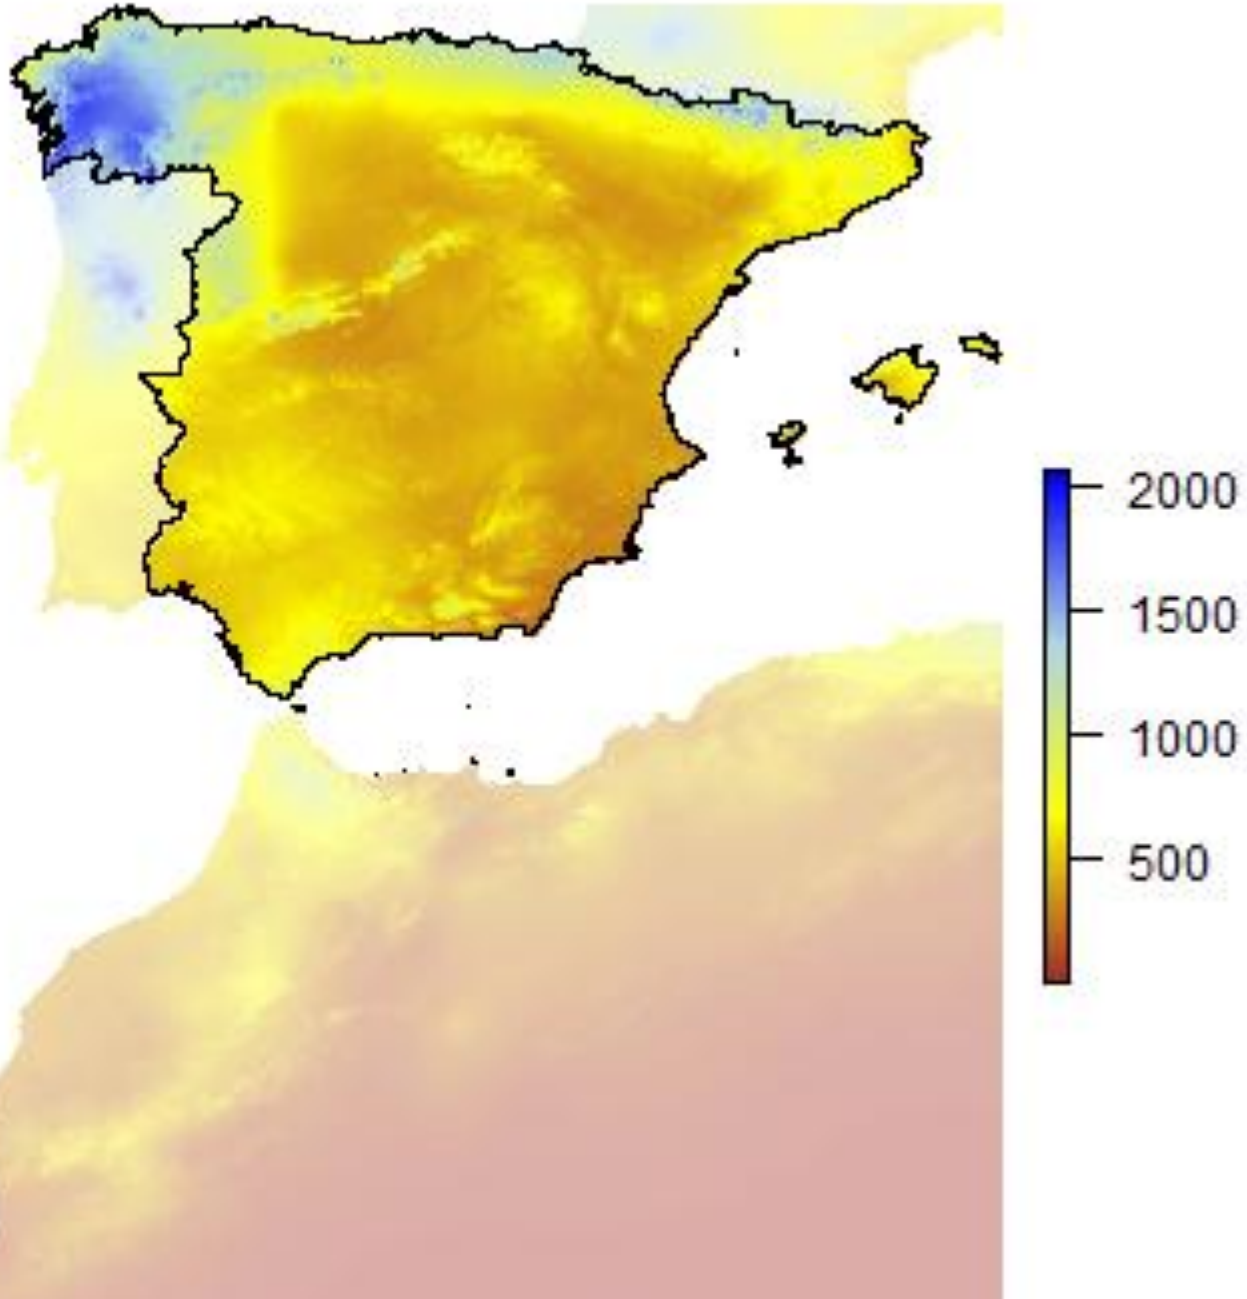
Mapa elaborado con *leaflet* + Python usando la librería ***Folium***

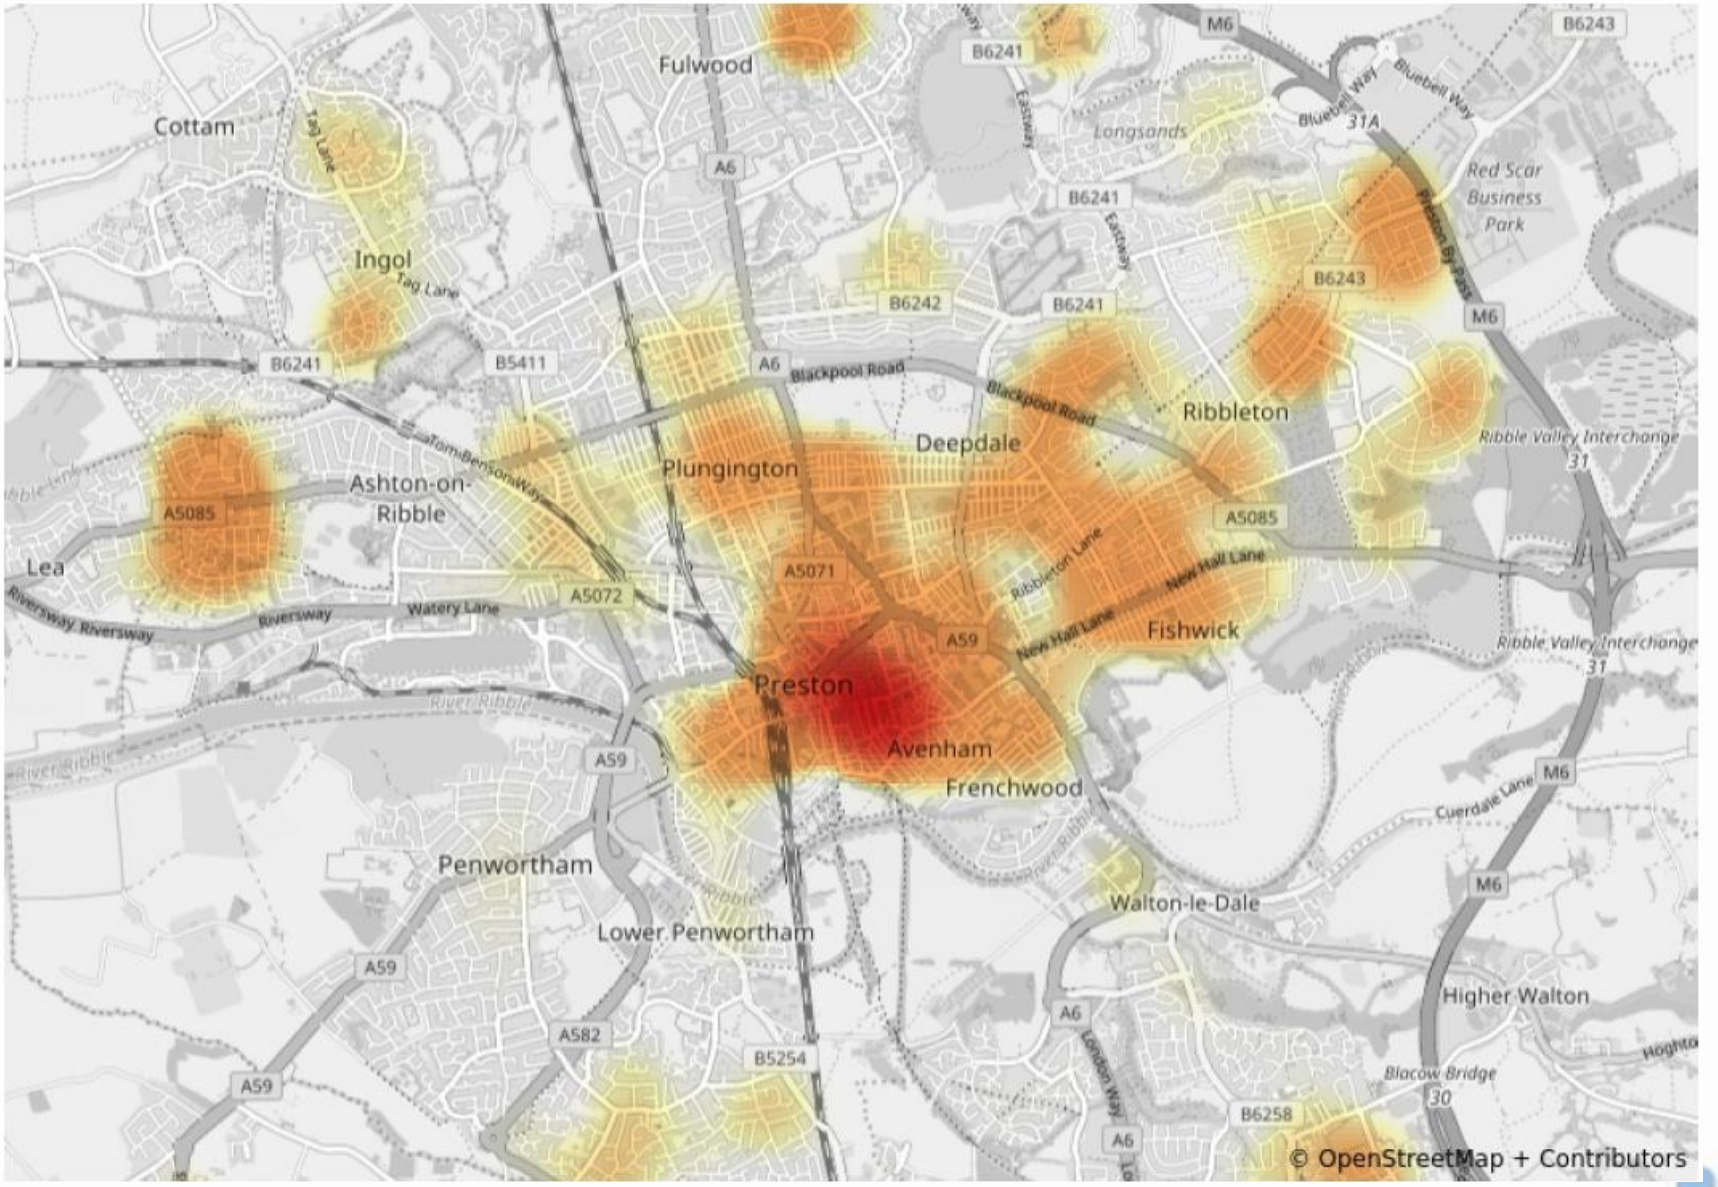


www.goolzoom.com

Los mapas raster sirven para representar objetos en el dominio del espacio continuo.

Son una cuadrícula, y no tienen demasiado interés hasta que no se les asocia el atributo que se desea representar (los dejamos para el siguiente tema)




Cottam
Fulwood
Ingol
Tag Lane
B6241
B5411
A6
B6242
Blackpool Road
Ribbleton
Deepdale
Plungington
Ashton-on-Ribble
A5085
Lea
Riversway
Watery Lane
A5072
A5071
A59
Preston
River Ribble
Avenham
Frenchwood
Penwortham
Lower Penwortham
A582
B5254
Walton-le-Dale
Higher Walton
B6258
Blacow Bridge
London Way
Longsands
Bluebell Way
M6
B6243
31A
Red Scar Business Park
Preston By Pass
Ribble Valley Interchange
31
Ribbleton Lane
New Hall Lane
Fishwick
Cuerdale Lane
30
© OpenStreetMap + Contributors

Análisis exploratorio de datos Espaciales

¿Cómo representamos una variable en un mapa?
¿Los valores de variables asociadas a objetos espaciales?

En lugar de gráfico de barras, utilizamos los llamados mapas coropléticos

Una vez cargada una cartografía puedo empezar a representar la distribución de los valores de una determinada variable en el espacio

Corepletas: TONALIDADES



Choropleth maps: representación de los valores de una variable estadística en el mapa

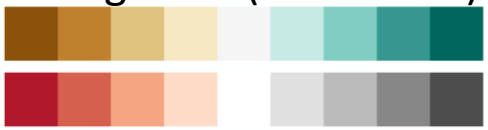
Corepletas: TONALIDADES

Paletas de Colores

Secuenciales (ordenadas)



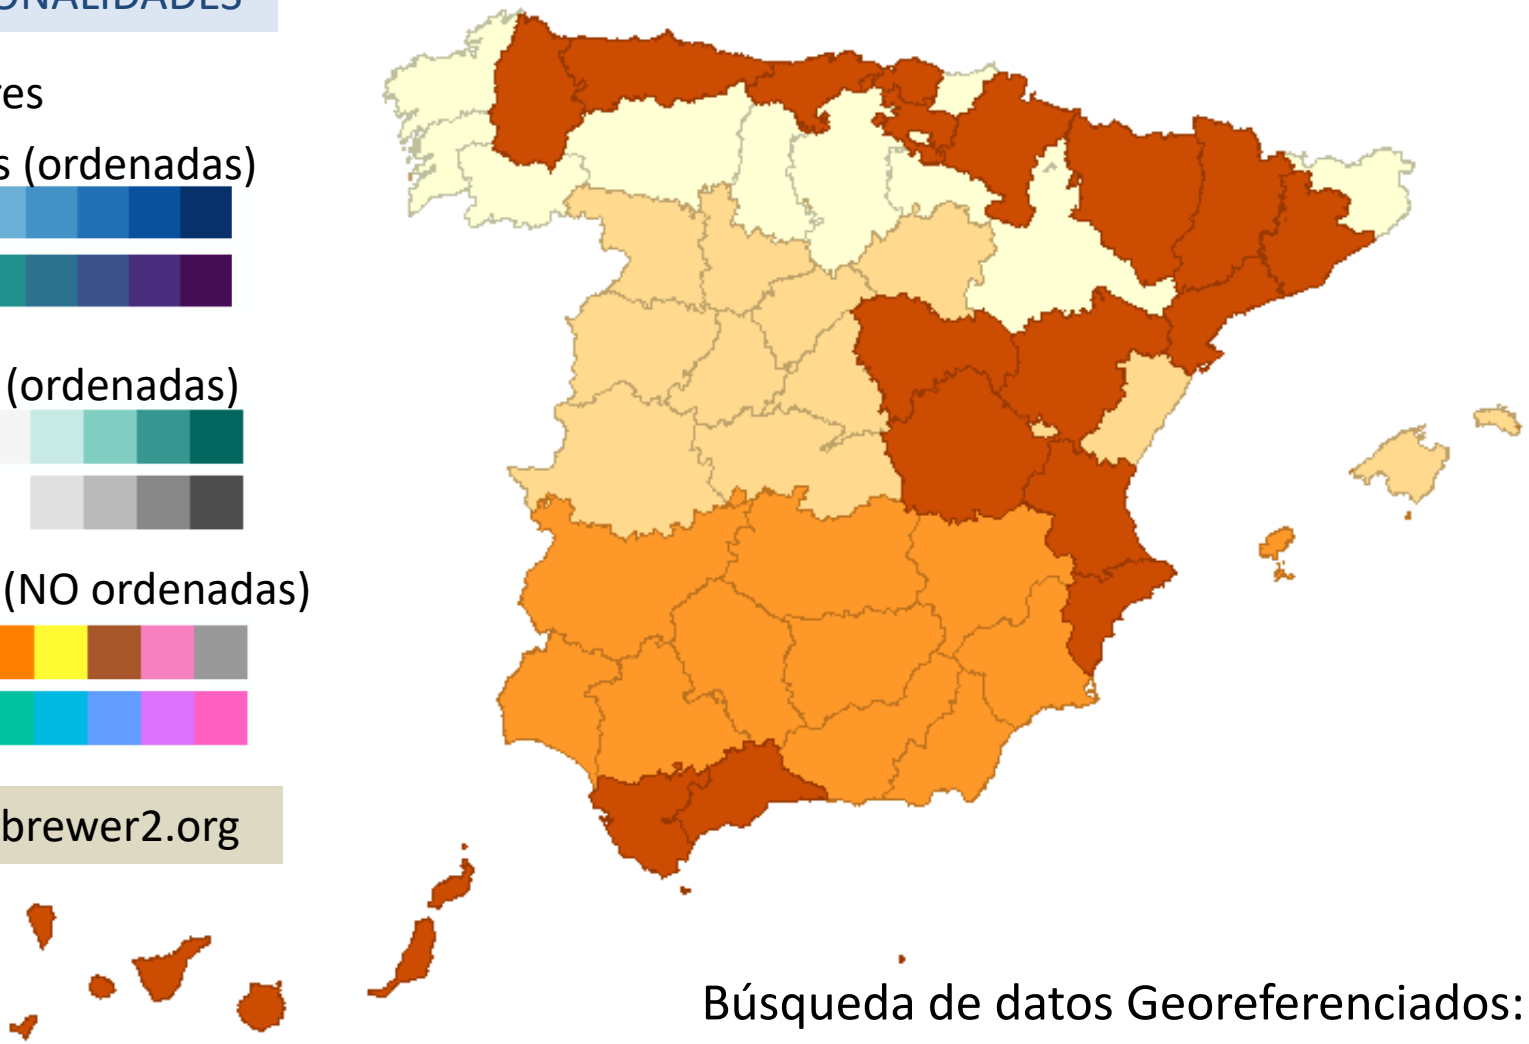
Divergentes (ordenadas)



Cualitativas (NO ordenadas)



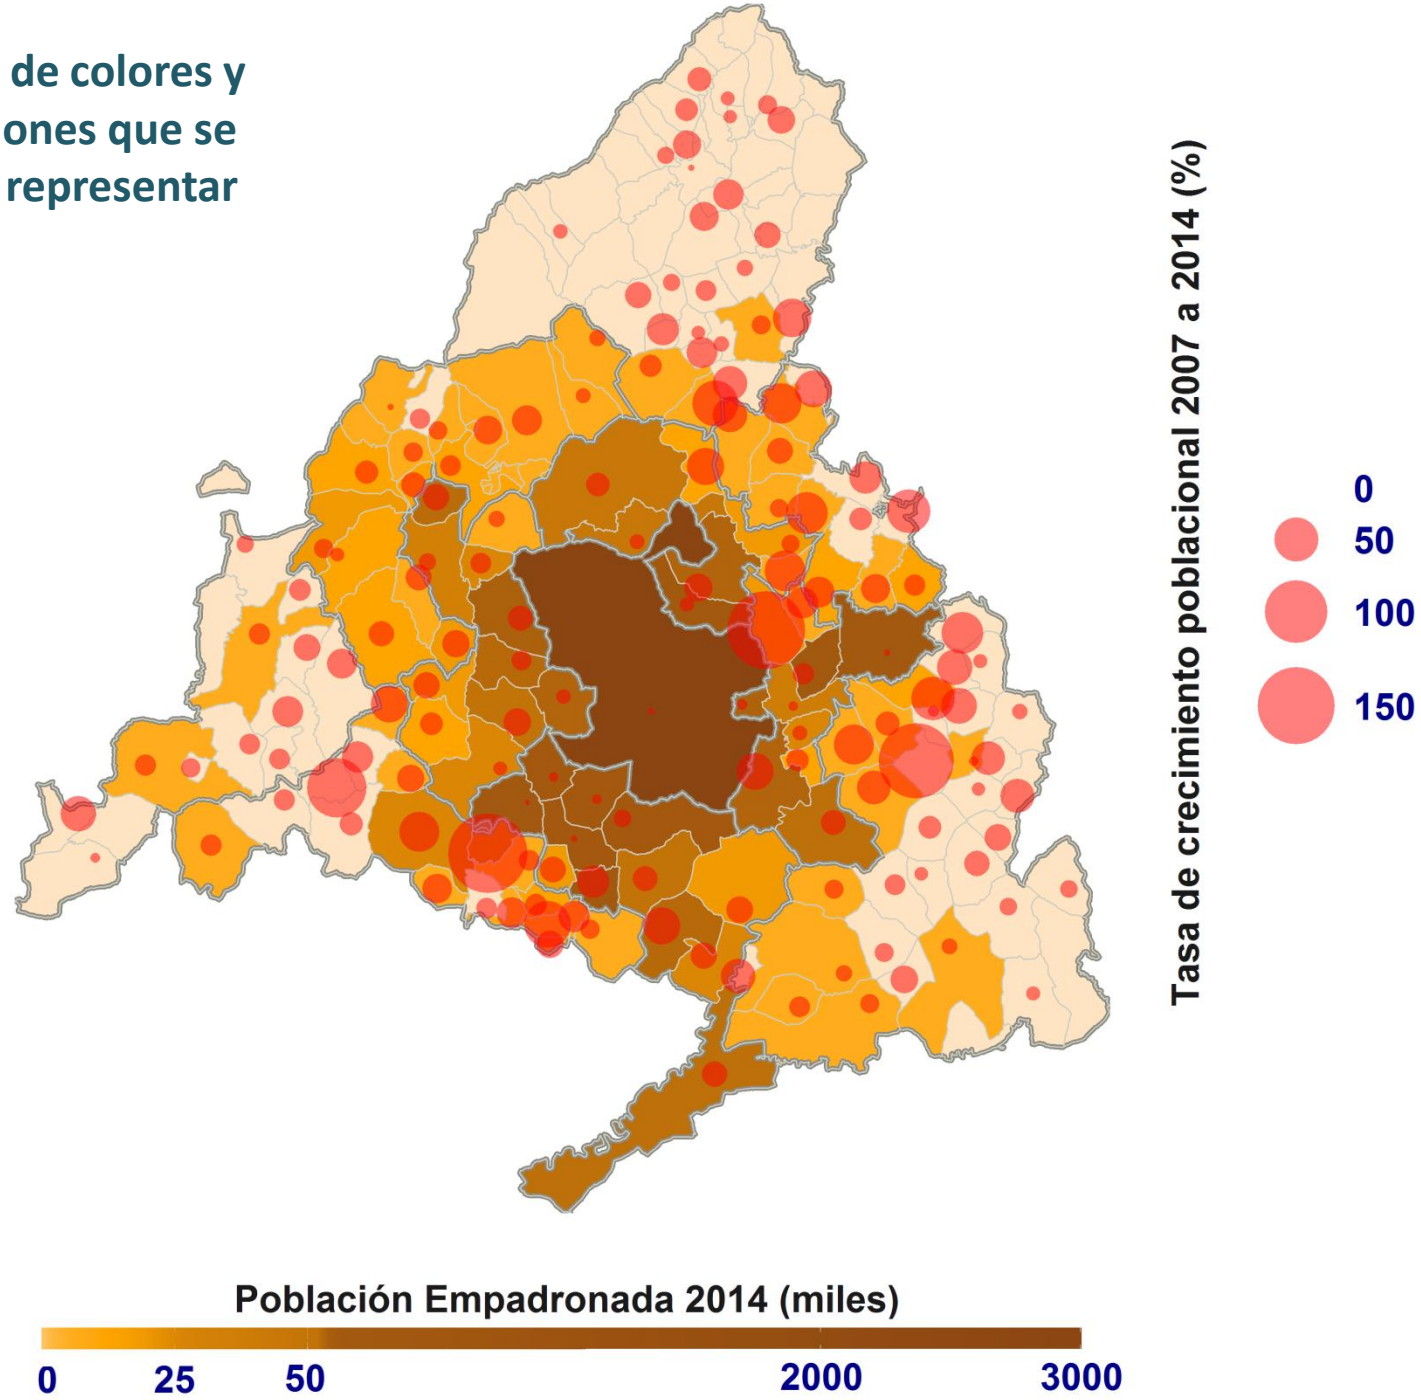
https://colorbrewer2.org

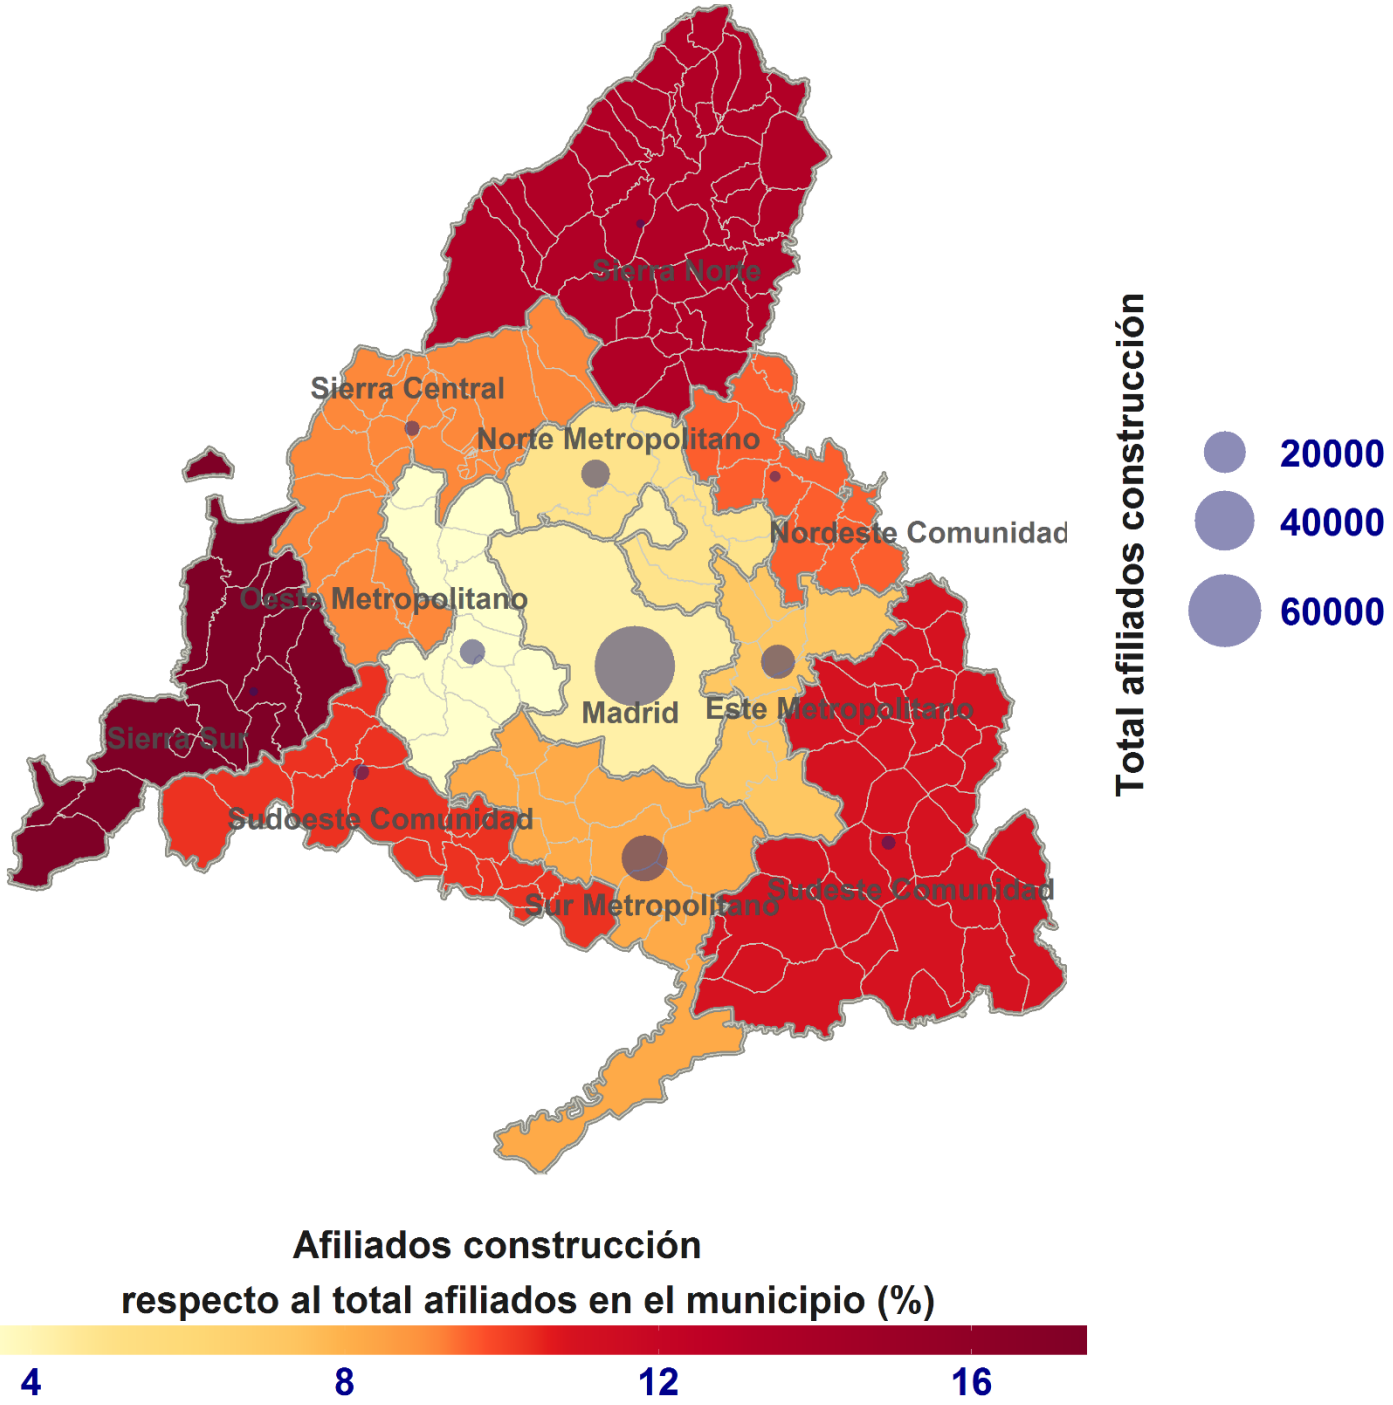


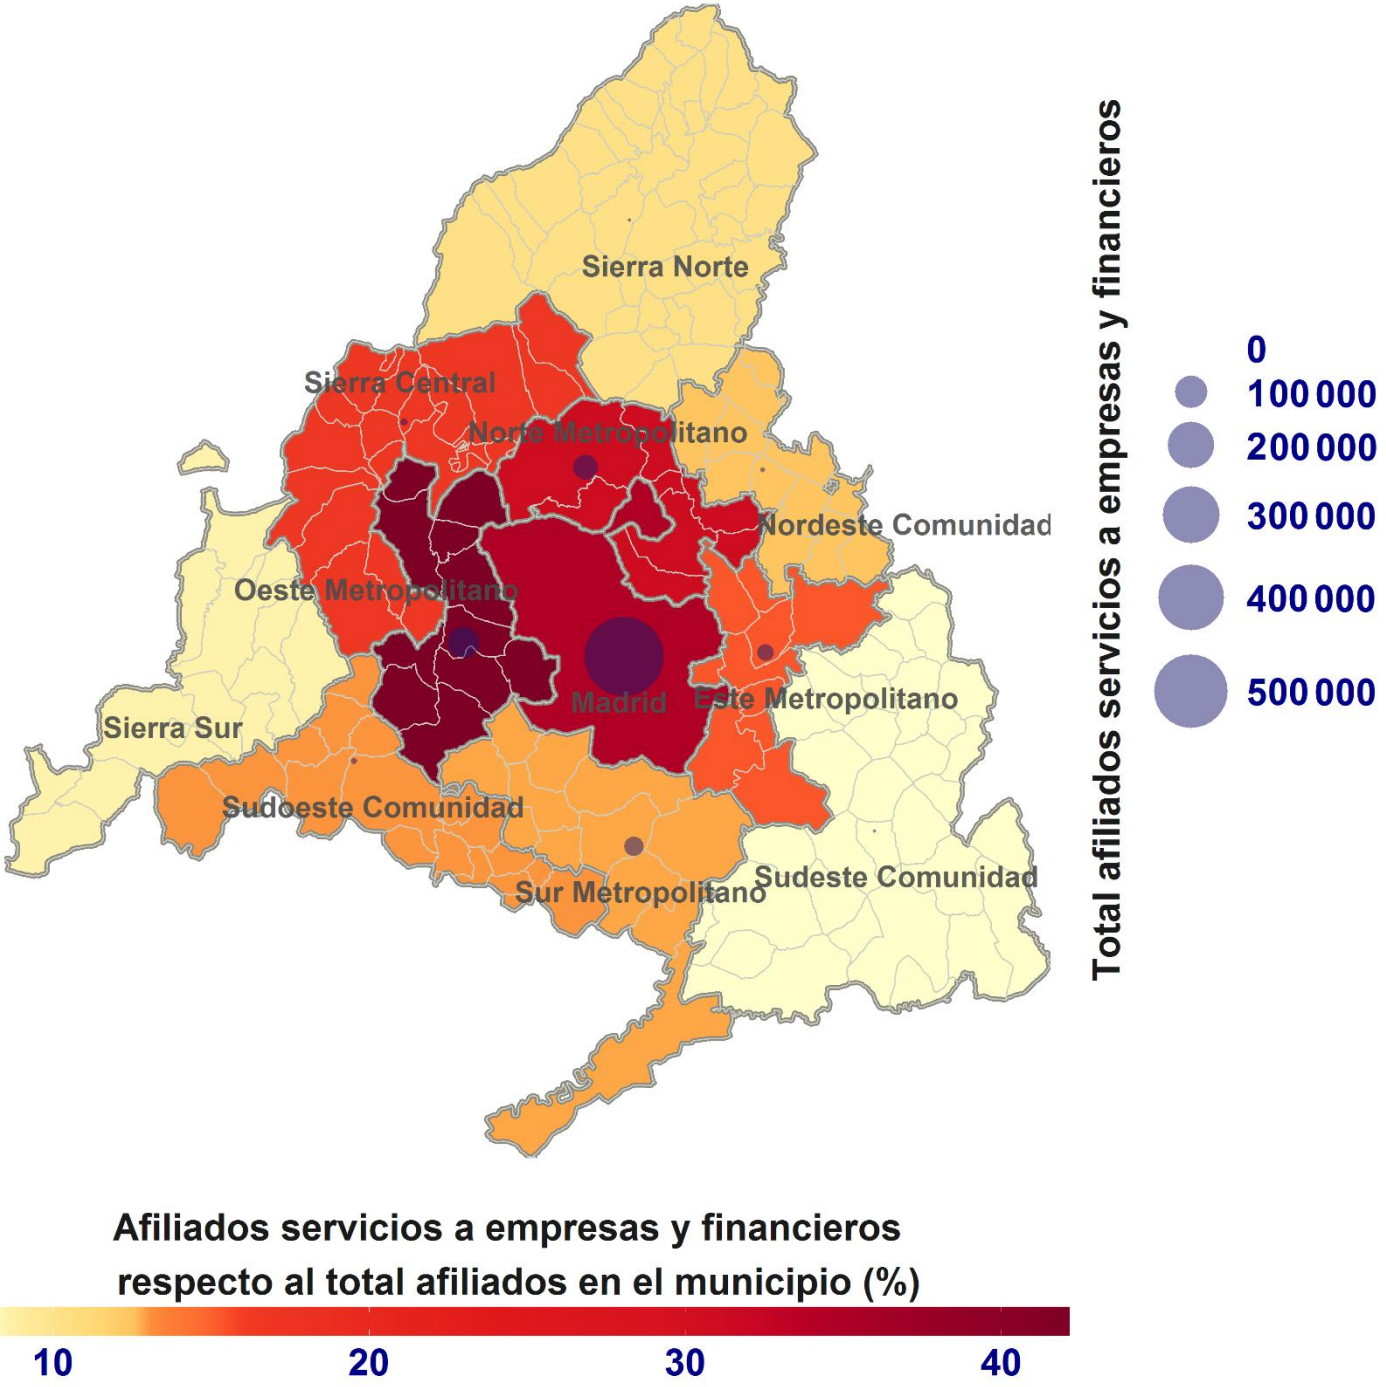
Búsqueda de datos Georeferenciados:
http://opendata.esri.es/

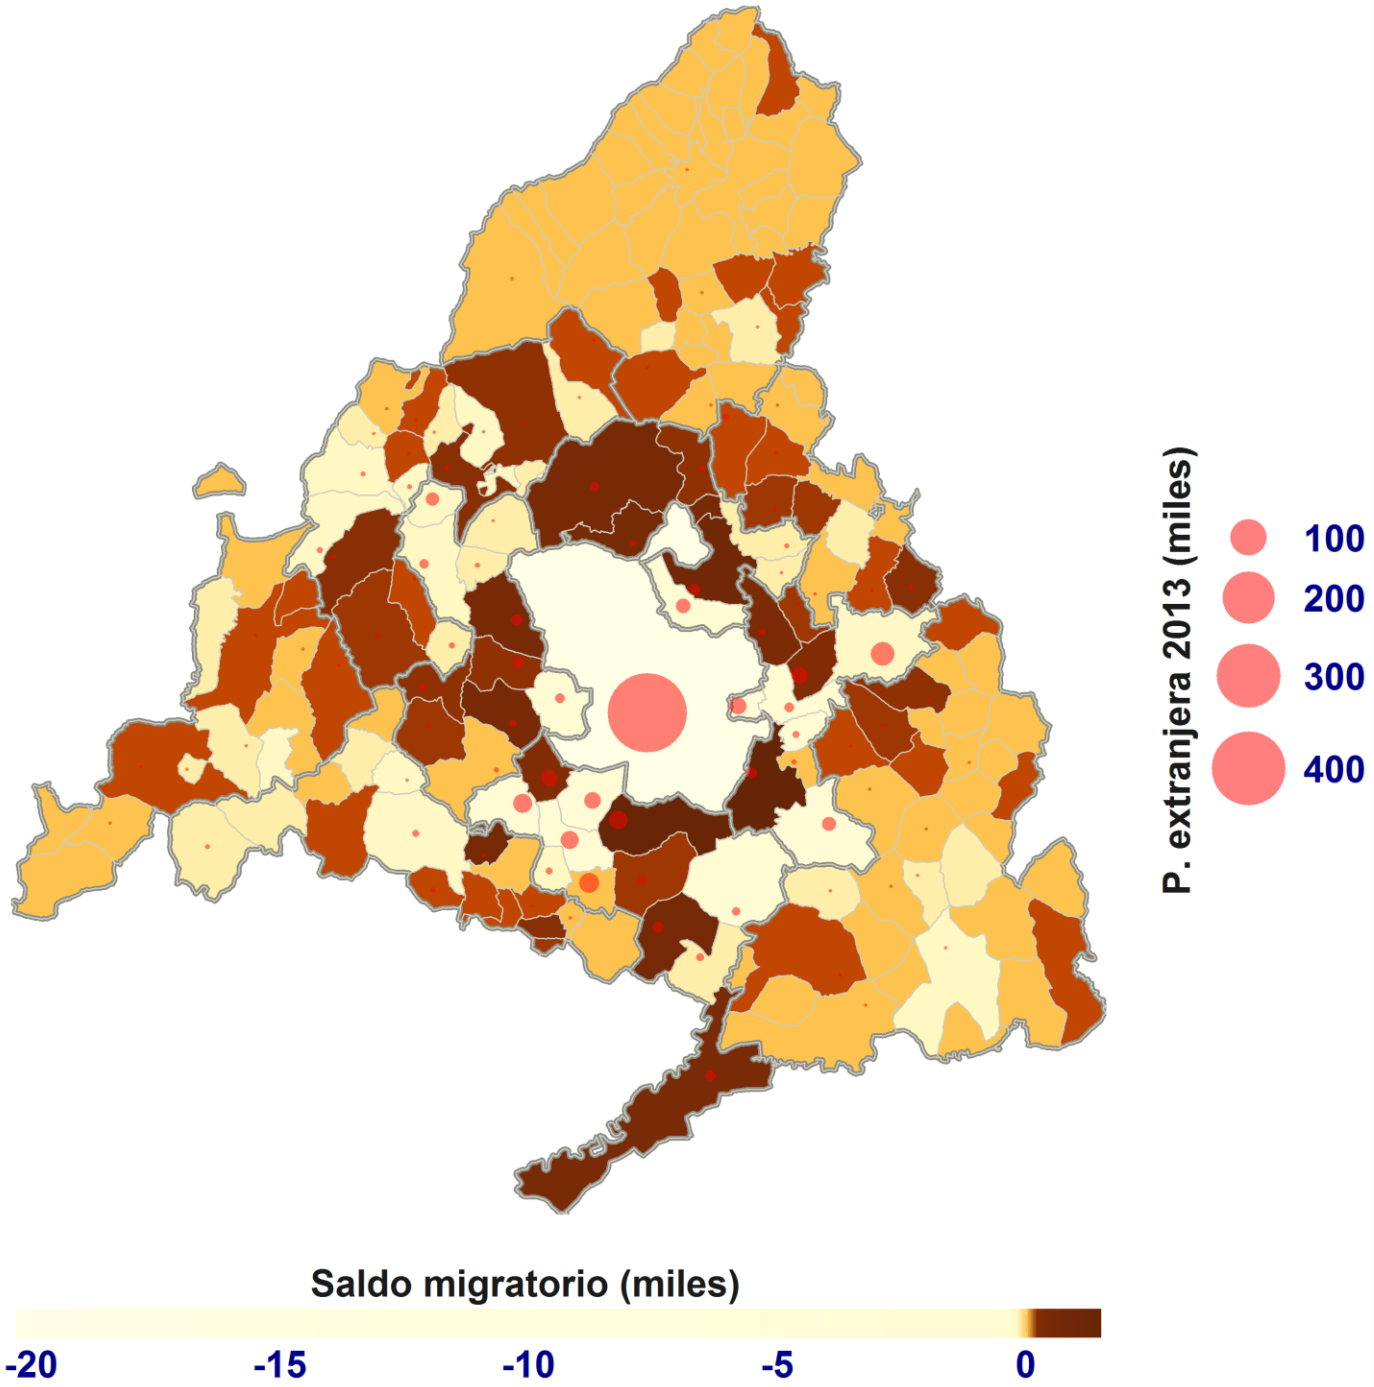
[Paletas de Colores en matplotlib]

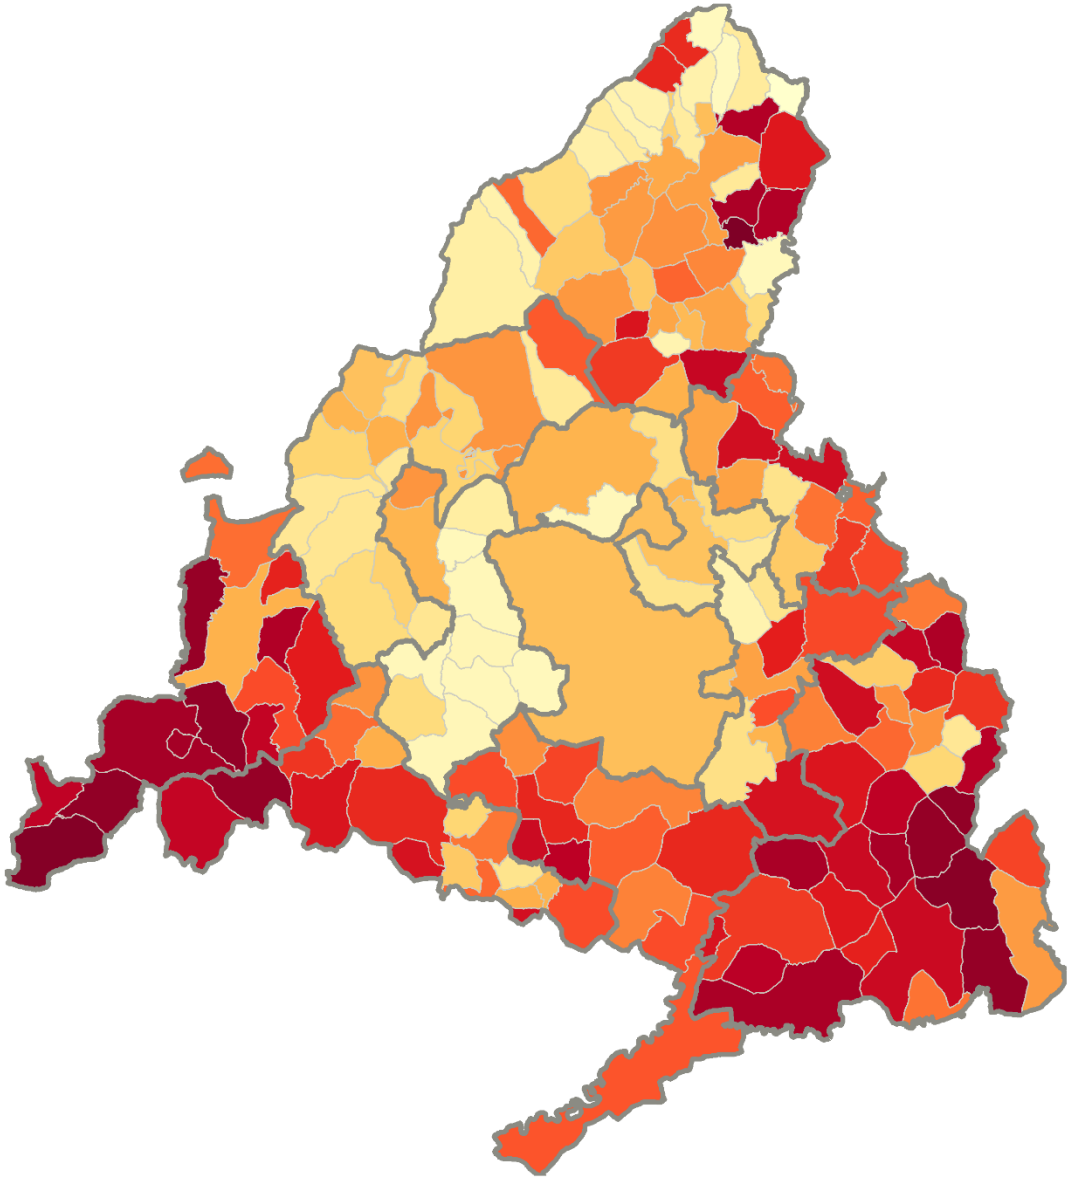
Elección de colores y dimensiones que se pueden representar




Sierra Norte
Sierra Central
Norte Metropolitano
Nordeste Comunidad
Oeste Metropolitano
Madrid
Este Metropolitano
Sierra Sur
Sudoeste Comunidad
Sur Metropolitano
Sudeste Comunidad
Total afiliados construcción
20000
40000
60000
Afiliados construcción
respecto al total afiliados en el municipio (%)
4
8
12
16

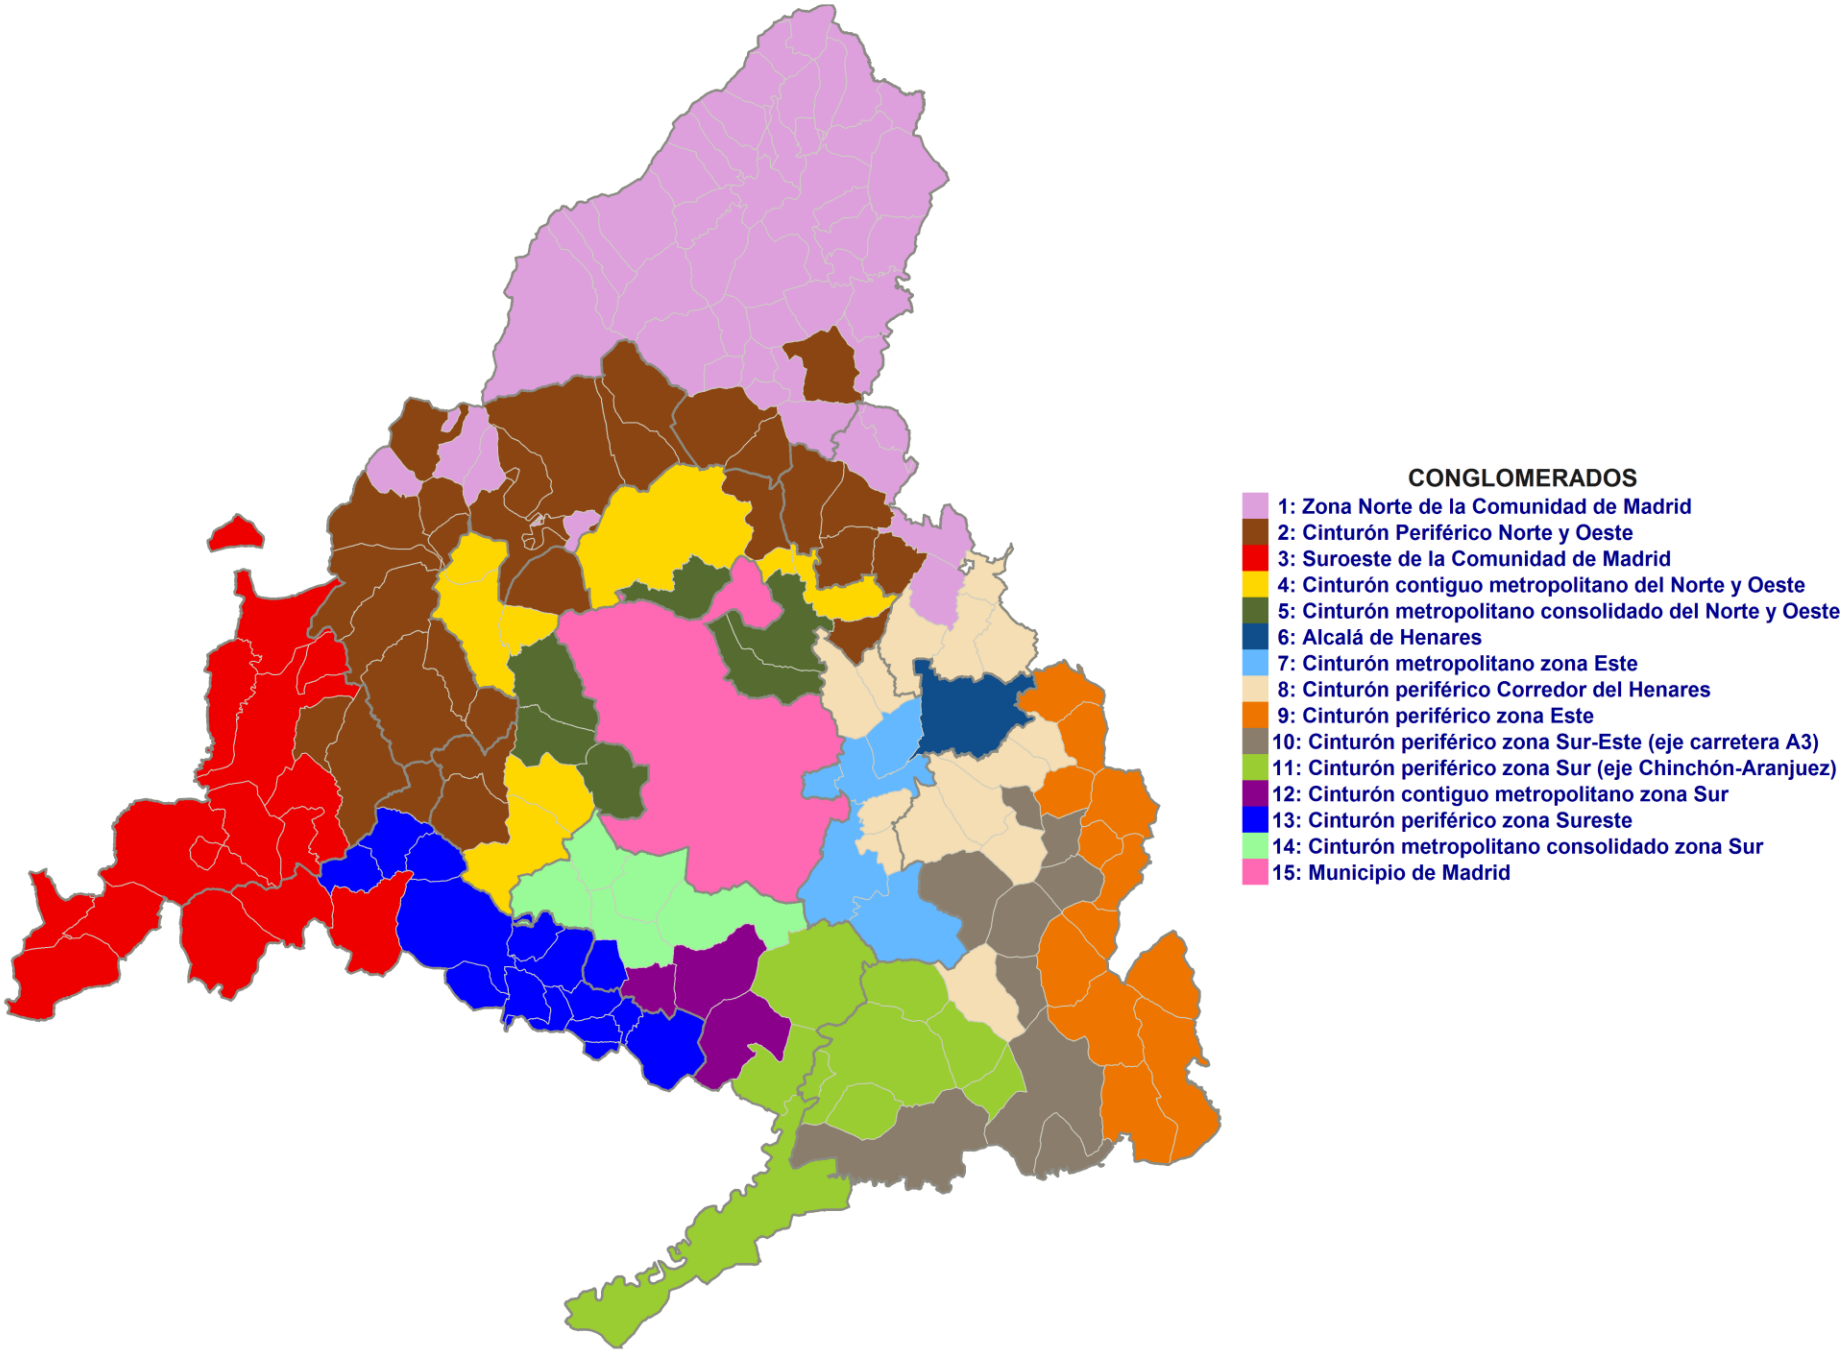

Sierra Norte
Sierra Central
Norte Metropolitano
Nordeste Comunidad
Oeste Metropolitano
Madrid
Este Metropolitano
Sierra Sur
Sudoeste Comunidad
Sur Metropolitano
Sudeste Comunidad
Total afiliados servicios a empresas y financieros
0
100 000
200 000
300 000
400 000
500 000
Afiliados servicios a empresas y financieros
respecto al total afiliados en el municipio (%)
10
20
30
40

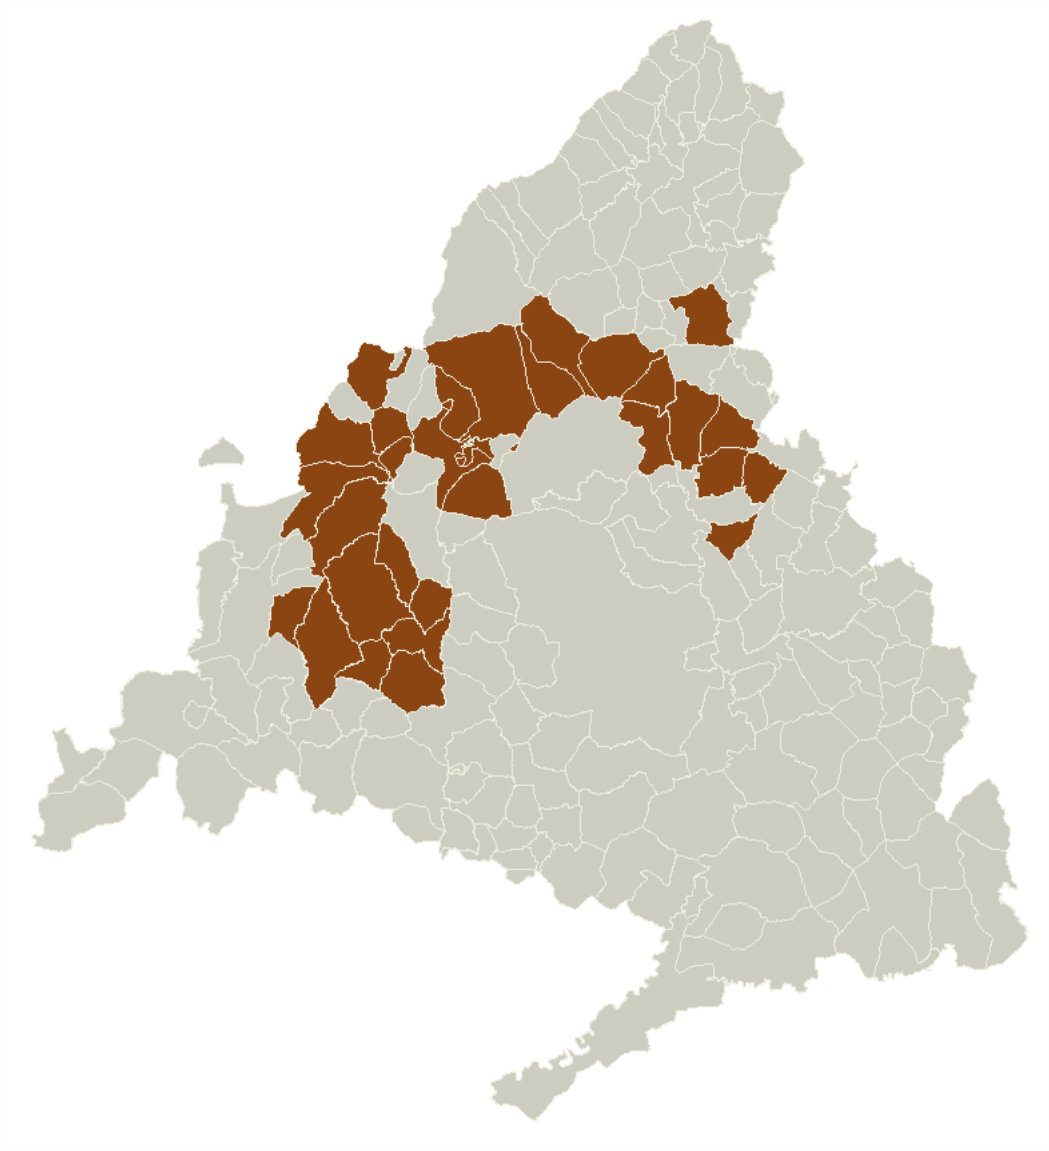

P. extranjera 2013 (miles)
100
200
300
400
Saldo migratorio (miles)
-20
-15
-10
-5
0

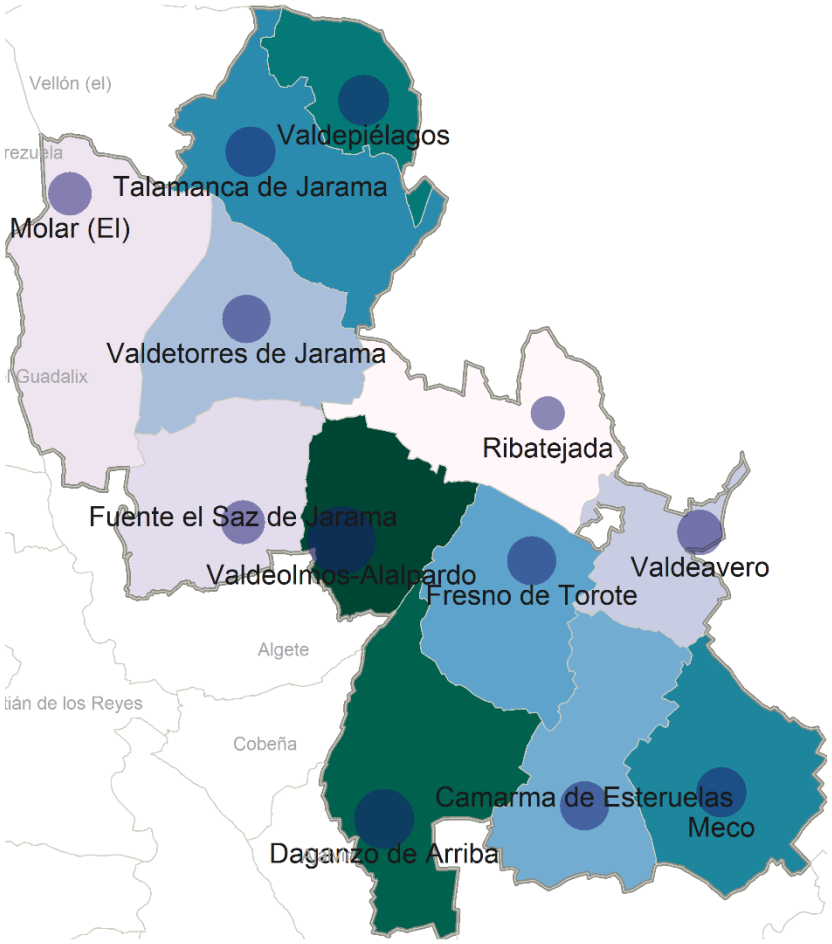


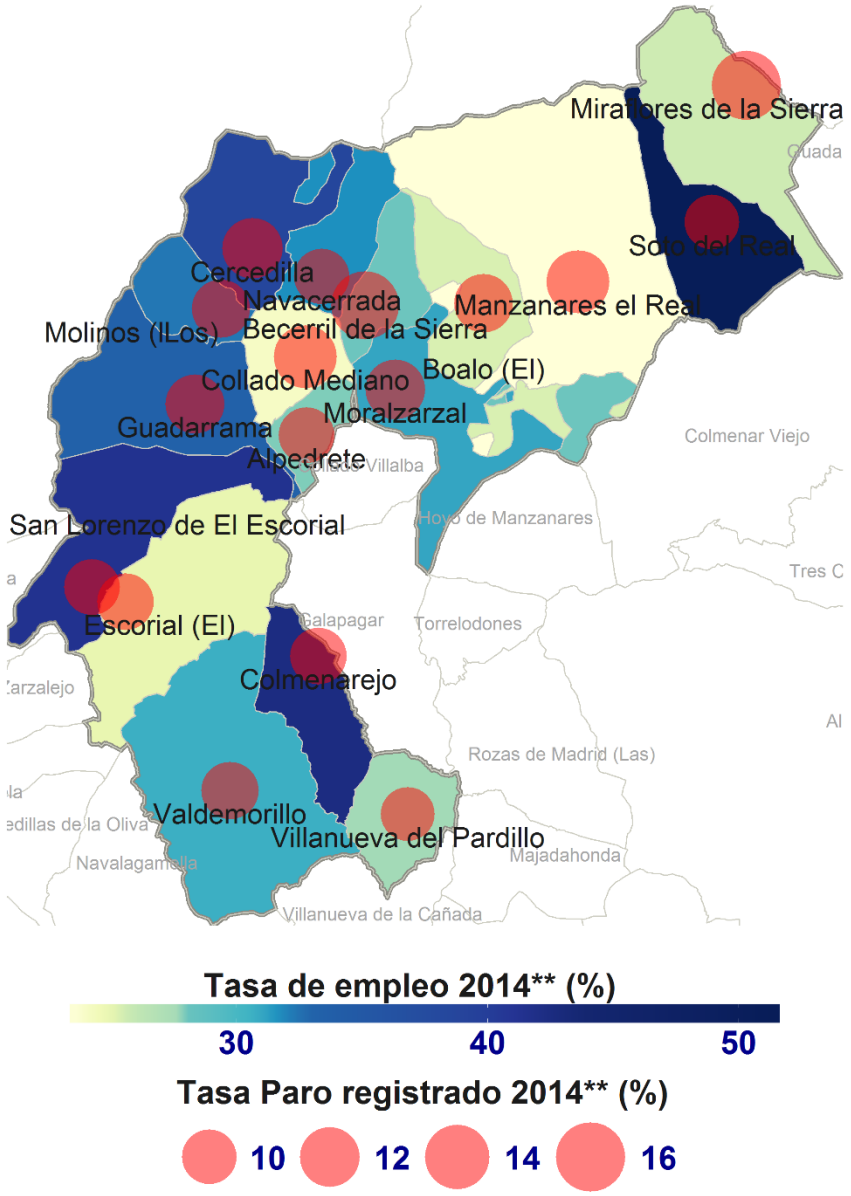
Tasa de Paro: Paro registrado respecto
a la población entre 16 a 64 años (%)

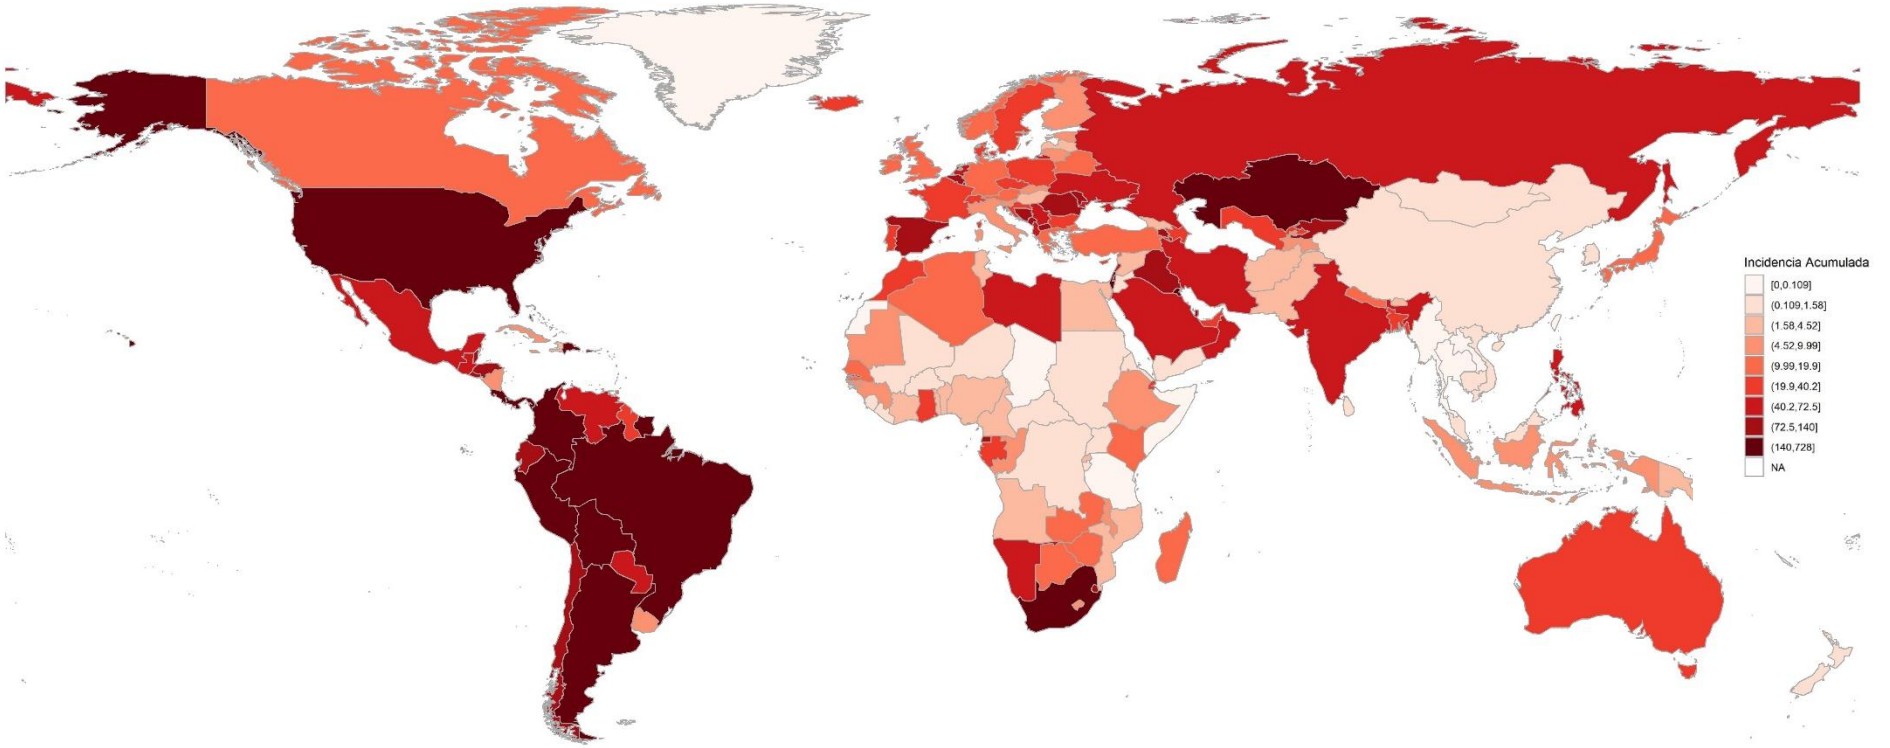
0 5 10 15 20 25


CONGLOMERADOS
1: Zona Norte de la Comunidad de Madrid
2: Cinturón Periférico Norte y Oeste
3: Suroeste de la Comunidad de Madrid
4: Cinturón contiguo metropolitano del Norte y Oeste
5: Cinturón metropolitano consolidado del Norte y Oeste
6: Alcalá de Henares
7: Cinturón metropolitano zona Este
8: Cinturón periférico Corredor del Henares
9: Cinturón periférico zona Este
10: Cinturón periférico zona Sur-Este (eje carretera A3)
11: Cinturón periférico zona Sur (eje Chinchón-Aranjuez)
12: Cinturón contiguo metropolitano zona Sur
13: Cinturón periférico zona Sureste
14: Cinturón metropolitano consolidado zona Sur
15: Municipio de Madrid

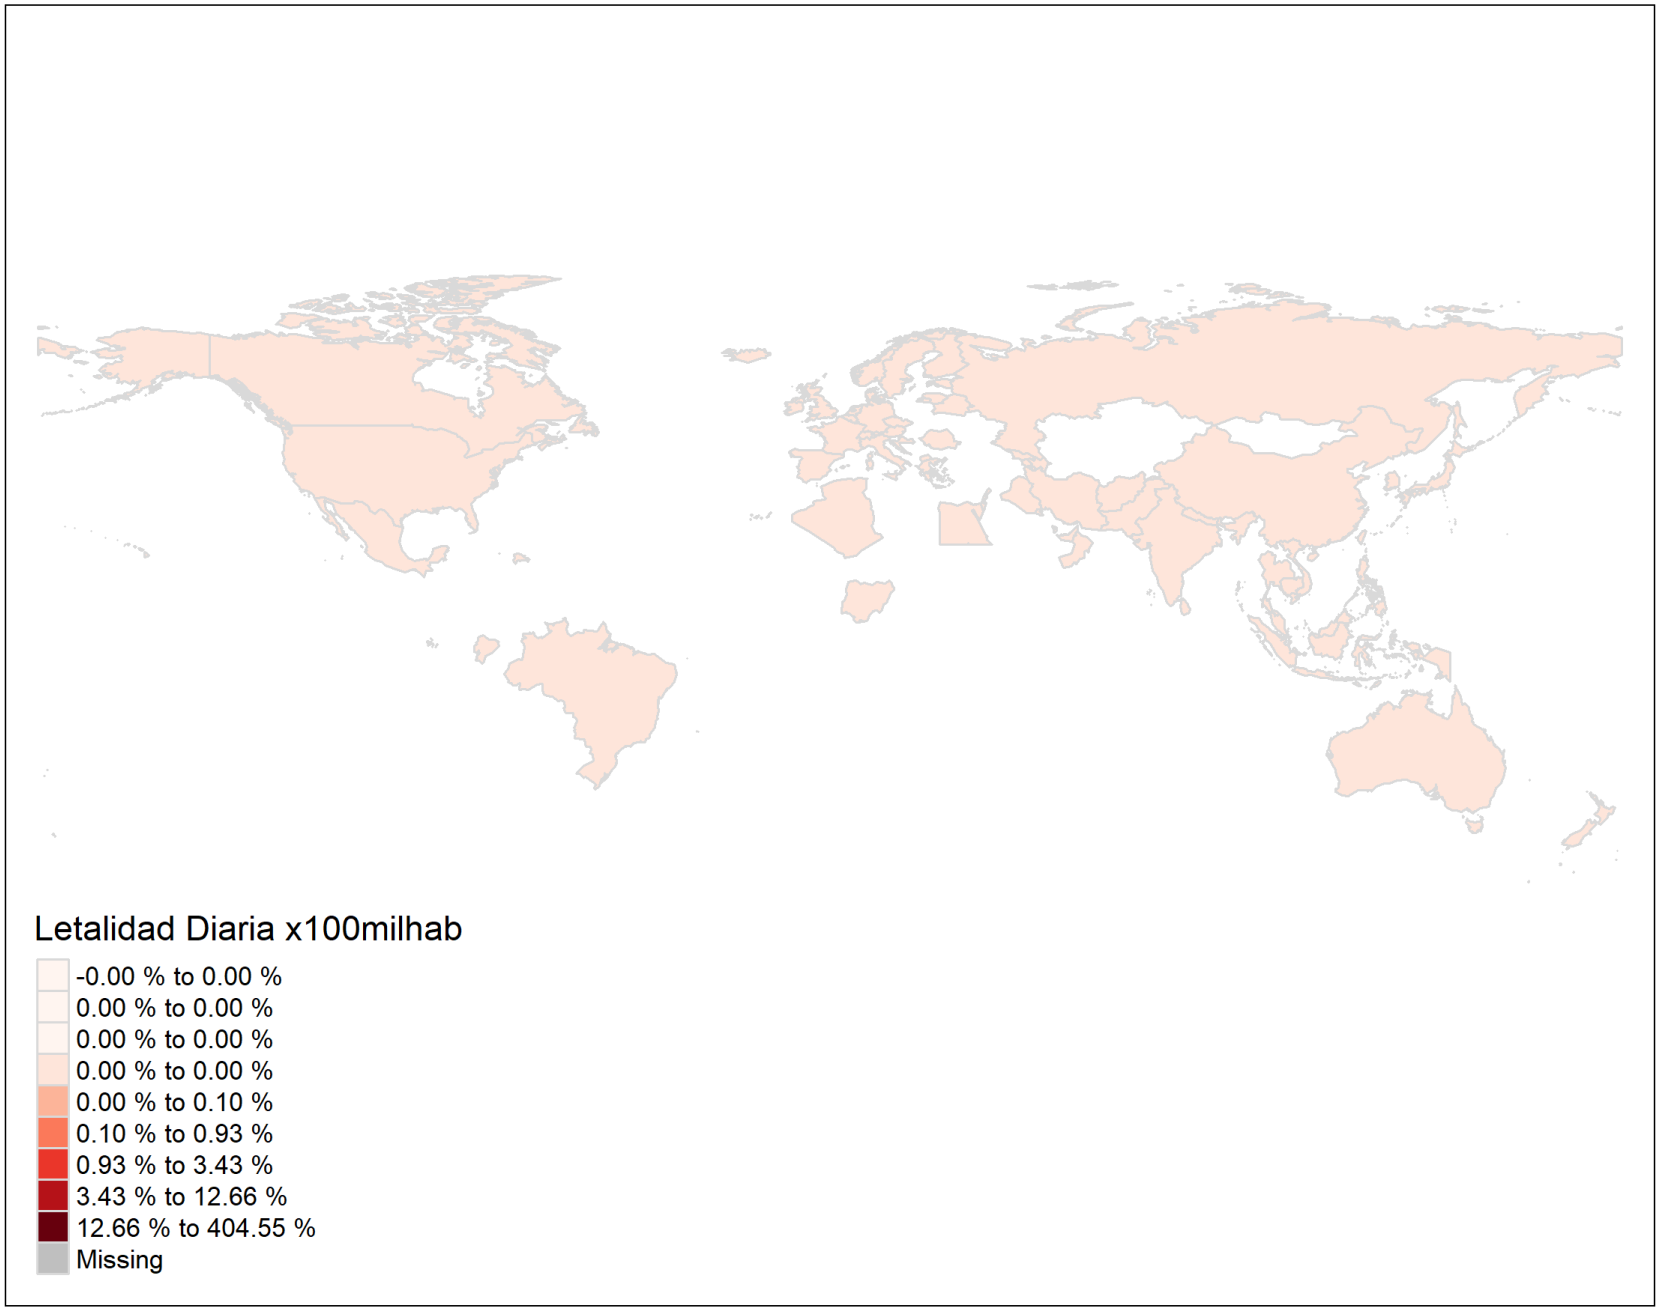



Vellón (el)
Valdepiélagos
Talamanca de Jarama
Molar (El)
Valdetorres de Jarama
Guadalix
Ribatejada
Fuente el Saz de Jarama
Valdeolmos-Alalpardo
Fresno de Torote
Valdeavero
Algete
Cobeña
Camarma de Esteruelas
Meco
Daganzo de Arriba
Afiliados Grupos 1 y 2 sobre el Total (%)
5
10
15
Afiliados Grupos 9 y 10 sobre el Total (%)
5
10
15


Miraflores de la Sierra
Soto del Real
Cercedilla
Navacerrada
Manzanares el Real
Molinos (Los)
Becerril de la Sierra
Boalo (El)
Collado Mediano
Moralzarzal
Guadarrama
Alpedrete
Colmenar Viejo
San Lorenzo de El Escorial
Tres C
Escorial (El)
Torrelodones
Colmenarejo
Rozas de Madrid (Las)
Valdemorillo
Villanueva del Pardillo
Majadahonda
Villanueva de la Cañada
Tasa de empleo 2014** (%)
30
40
50
Tasa Paro registrado 2014** (%)
10
12
14
16


Incidencia Acumulada
[0,0.109]
(0.109,1.58]
(1.58,4.52]
(4.52,9.99]
(9.99,19.9]
(19.9,40.2]
(40.2,72.5]
(72.5,140]
(140,728]
NA

2019-12-31


Letalidad Diaria x100milhab
-0.00 % to 0.00 %
0.00 % to 0.00 %
0.00 % to 0.00 %
0.00 % to 0.00 %
0.00 % to 0.10 %
0.10 % to 0.93 %
0.93 % to 3.43 %
3.43 % to 12.66 %
12.66 % to 404.55 %
Missing

Econometría Espacial

Ley de Tobler (1979) o "Primera Ley de la Geografía": "…todo tiene que ver con todo, pero las cosas cercanas están más relacionadas entre sí que las cosas lejanas".



Waldo Rudolph Tobler (1930-2018)

Modelos de Econometría Espacial, son modelos de regresión donde se tiene en cuenta de manera explícita la **dependencia espacial** o dependencia en el espacio (lo que ocurre en un área, una región o un punto determinado del **espacio está relacionado con lo que ocurre a su alrededor)**

Antecedentes:

- Moran (1948) y Geary (1954) para el cálculo de la autocorrelación espacial
- Los primeros trabajos de estadística espacial de los geógrafos **Cliff y Ord (1972, 1973)**
- **Paelinck y Klaasen (1979)** bautizaron estas técnicas con el nombre explícito de "econometría espacial". Después los trabajos de Cliff y Ord (1981), **Anselin** (1980, 1988A) y Arbia (1989) impulsan y afianzan esta rama de la econometría.

Análisis exploratorio de los datos espaciales

Objetivo: Descubrir patrones, tendencias y relaciones espaciales en los datos sin hipótesis previas. Explorar un nuevo territorio para ver si es posible que existan patrones de comportamiento espacial (básicamente es univariante)

- Visualización de datos espaciales (mapas coropléticos, mapas condicionales, cartogramas) **búsqueda visual** de autocorrelación espacial (concentración de eventos o de valores altos y bajos)
- Identificar localizaciones espaciales atípicas (*outliers* espaciales)
- Cálculo de **medidas** de autocorrelación espacial (como el estadístico I de Moran) para ver si los valores cercanos están relacionados.
- Identificación de clústeres o agrupaciones espaciales (Detección de valores atípicos espaciales....)

Análisis Confirmatorio de los datos espaciales (regresión espacial)

Modelos de regresión multivariante para **contrastar hipótesis específicas sobre las relaciones entre variables espaciales**, que puedan posteriormente para hacer predicciones o evaluación de políticas. El objetivo es conocer y cuantificar la asociación entre variables controlando por el resto de factores o covariables explicativas (análisis exploratorio es fundamentalmente univariante o bivariante)

- Modelos de regresión que tienen en cuenta los dos tipos de efectos espaciales más importantes:
  - **Heterogeneidad espacial** (los valores de la variable objetivo son diferentes en diferentes ubicaciones)
  - **la dependencia espacial** (cómo los valores en una ubicación influyen en los valores en ubicaciones cercanas).



Efectos espaciales 1

Distinguimos dos tipos de efectos espaciales: Heterogeneidad espacial y autocorrelación (dependencia) espacial

Heterogeneidad espacial (HE): no homogeneidad del mismo fenómeno analizado en distintos puntos del espacio (una relación entre variables dependientes y variables explicativas), de forma que existe HE cuando exista variación en las relaciones en el espacio

Fuentes HE: Aparece cuando en la estimación del modelo de regresión se utilizan datos de unidades espaciales muy diferentes entre sí. Esto implicará que, en los modelos espaciales, las formas funcionales y los parámetros variarán con la localización geográfica no siendo homogéneos para toda la matriz de datos.

- Inestabilidad estructural: ausencia de *estabilidad en el espacio* del comportamiento de la variable estudiada que lleva a que la forma funcional y los parámetros de una regresión varíen según su localización (no son homogéneos para toda la muestra). Las relaciones en sí pueden ser diferentes a través del espacio.

$$y_i = x_i'\beta_i + u_i$$

- Heterocedasticidad: omisión de variables relevantes que llevan a errores de medida en la especificación que se concretan en varianzas diferentes en el término de error.

$$Var(u_i) = \sigma_i^2$$

Puede tratarse con técnicas econométricas estándar.

Efectos espaciales 2

Autocorrelación (dependencia) espacial (AE): Los datos observados en un punto del espacio no son independientes de los valores observados en puntos de su alrededor.

Una variable se encontrará ***espacialmente autocorrelacionada*** cuando los valores observados en un lugar determinado dependen, no sólo de ciertos factores propios de ese lugar (otras variables), sino también de los valores observados en regiones/lugares próximos o vecinos ("Primera Ley de la Geografía").

Por ejemplo, Cox (1969) demostró que existía una *continuidad geográfica* en las intenciones de voto de los norteamericanos, es decir, que si un estado votaba mayoritariamente al partido demócrata, se producía un aumento en la probabilidad de que los estados vecinos también votaran a los demócratas. Otro ejemplo Cliff y Ord (1981): presenta el análisis espacial como forma de conocimiento de las causas y formas de propagación de epidemias y enfermedades.

Fuentes de la Autocorrelación Espacial:

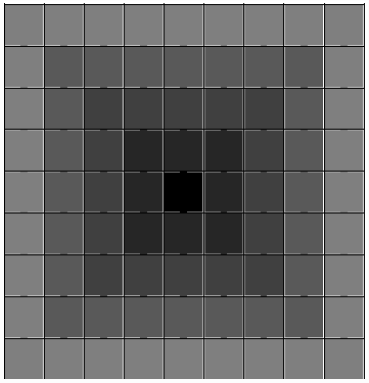
- Errores de medición para las observaciones en unidades espaciales contiguas por delimitación arbitraria de las unidades espaciales (que no recogen bien el proceso generador de datos). Errores por agregación espacial de los datos (que puede no corresponder con su proceso generador).
- Variables omitidas por efecto espacial: ejemplo influencia de un parque en el precio de la vivienda del entorno al parque, si se omite esa variable, el efecto sí se puede observar: dependencia espacial
- Interacción espacial de las unidades: externalidades en forma de *spillovers* (efectos desbordamiento) espaciales y jerarquías espaciales (**EFECTO CONTAGIO**).

Autocorrelación espacial

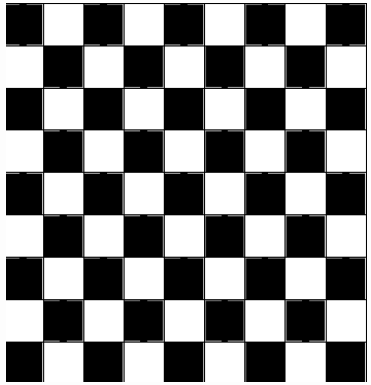
La autocorrelación espacial puede ser positiva o negativa.

- AE **positiva**: la presencia de un fenómeno en una unidad geográfica aumenta significativamente las posibilidades de que ese mismo fenómeno ocurra en la unidades colindantes. Concentración del fenómeno.
- AE **negativa:** la presencia de un fenómeno en una unidad geográfica imposibilita o disminuye significativamente las posibilidades de que ese mismo fenómeno ocurra en las unidades colindantes. Unidades geográficas cercanas son más disímiles entre ellas que entre unidades alejadas en el espacio.
- AE **nula**: la variable se distribuye de forma aleatoria (no existen patrones en la distribución espacial de los valores del fenómeno estudiado).

Podemos interpretar la AE como la **concentración** (positiva) o **dispersión** (negativa) de los valores de una variable en un mapa.



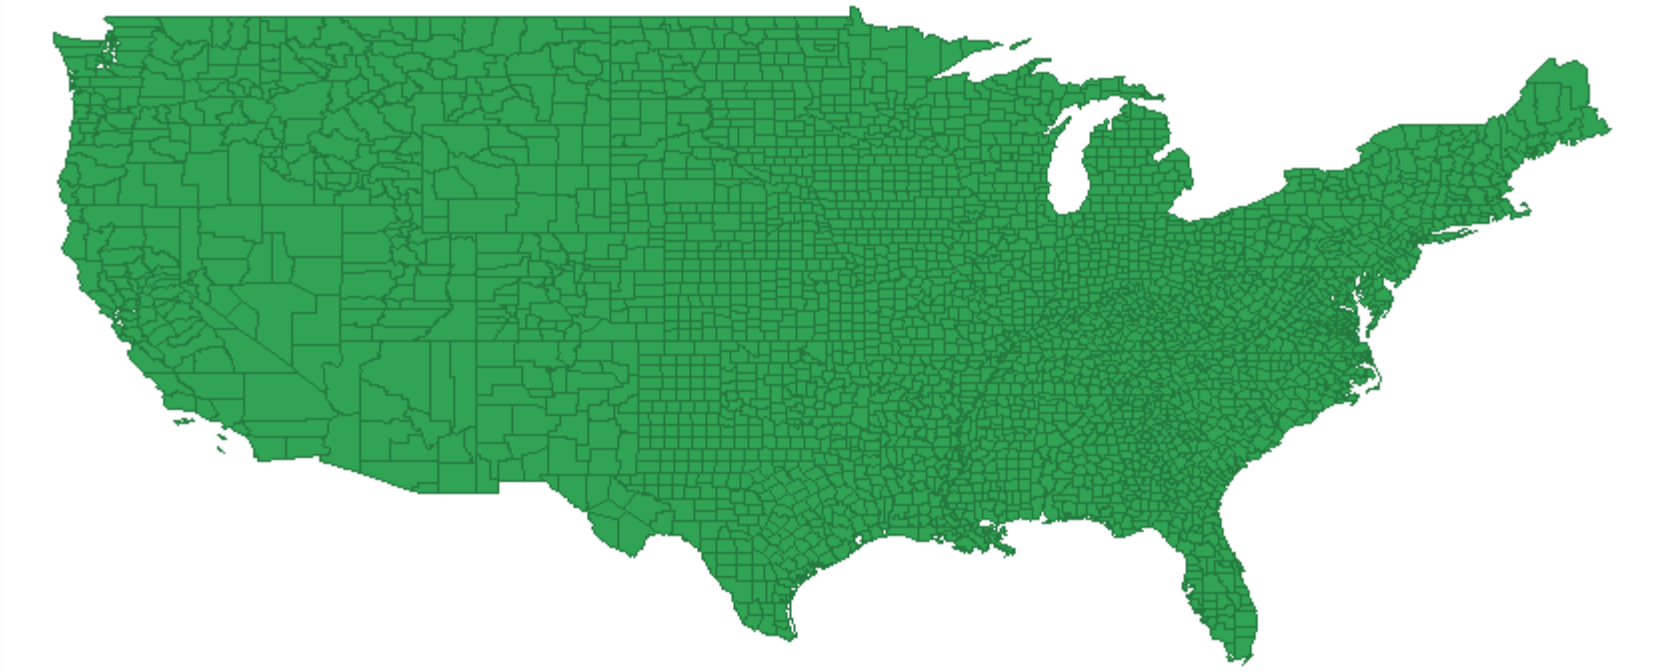
AE positiva



AE negativa

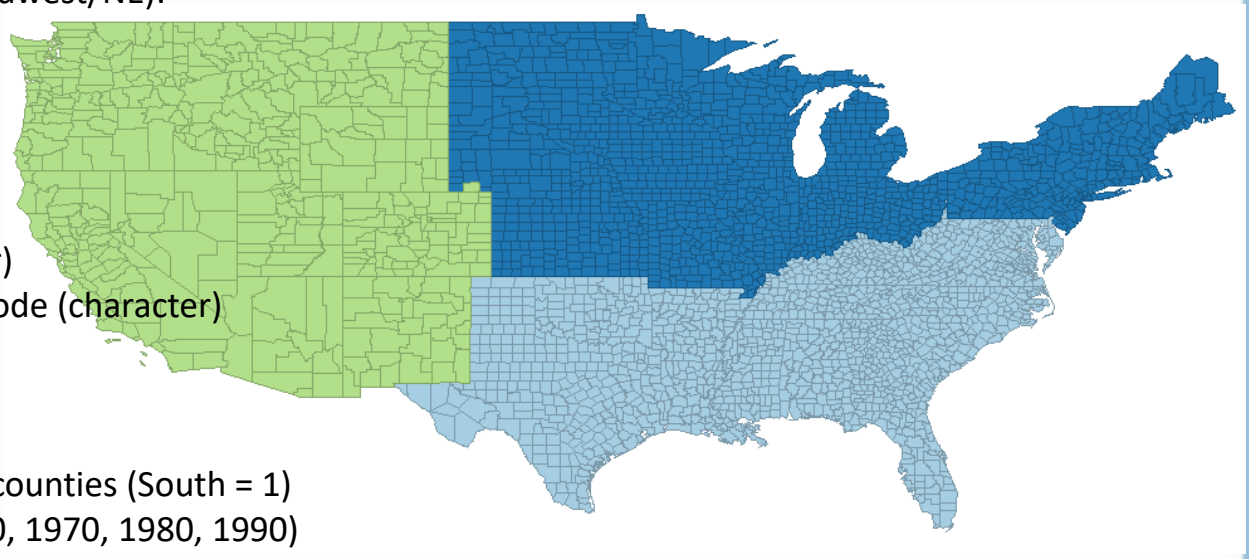
Fuente Gráficos : Baronio, A., Vianco, A. , Rabanal, C. (2012): Una introducción a la econometría espacial

Homicides and selected socio-economic characteristics for continental U.S. counties. Data for four decennial census years: 1960, 1970, 1980, 1990.
Type = polygon shape file, unprojected, lat-lon
Observations = 3085
Variables = 69



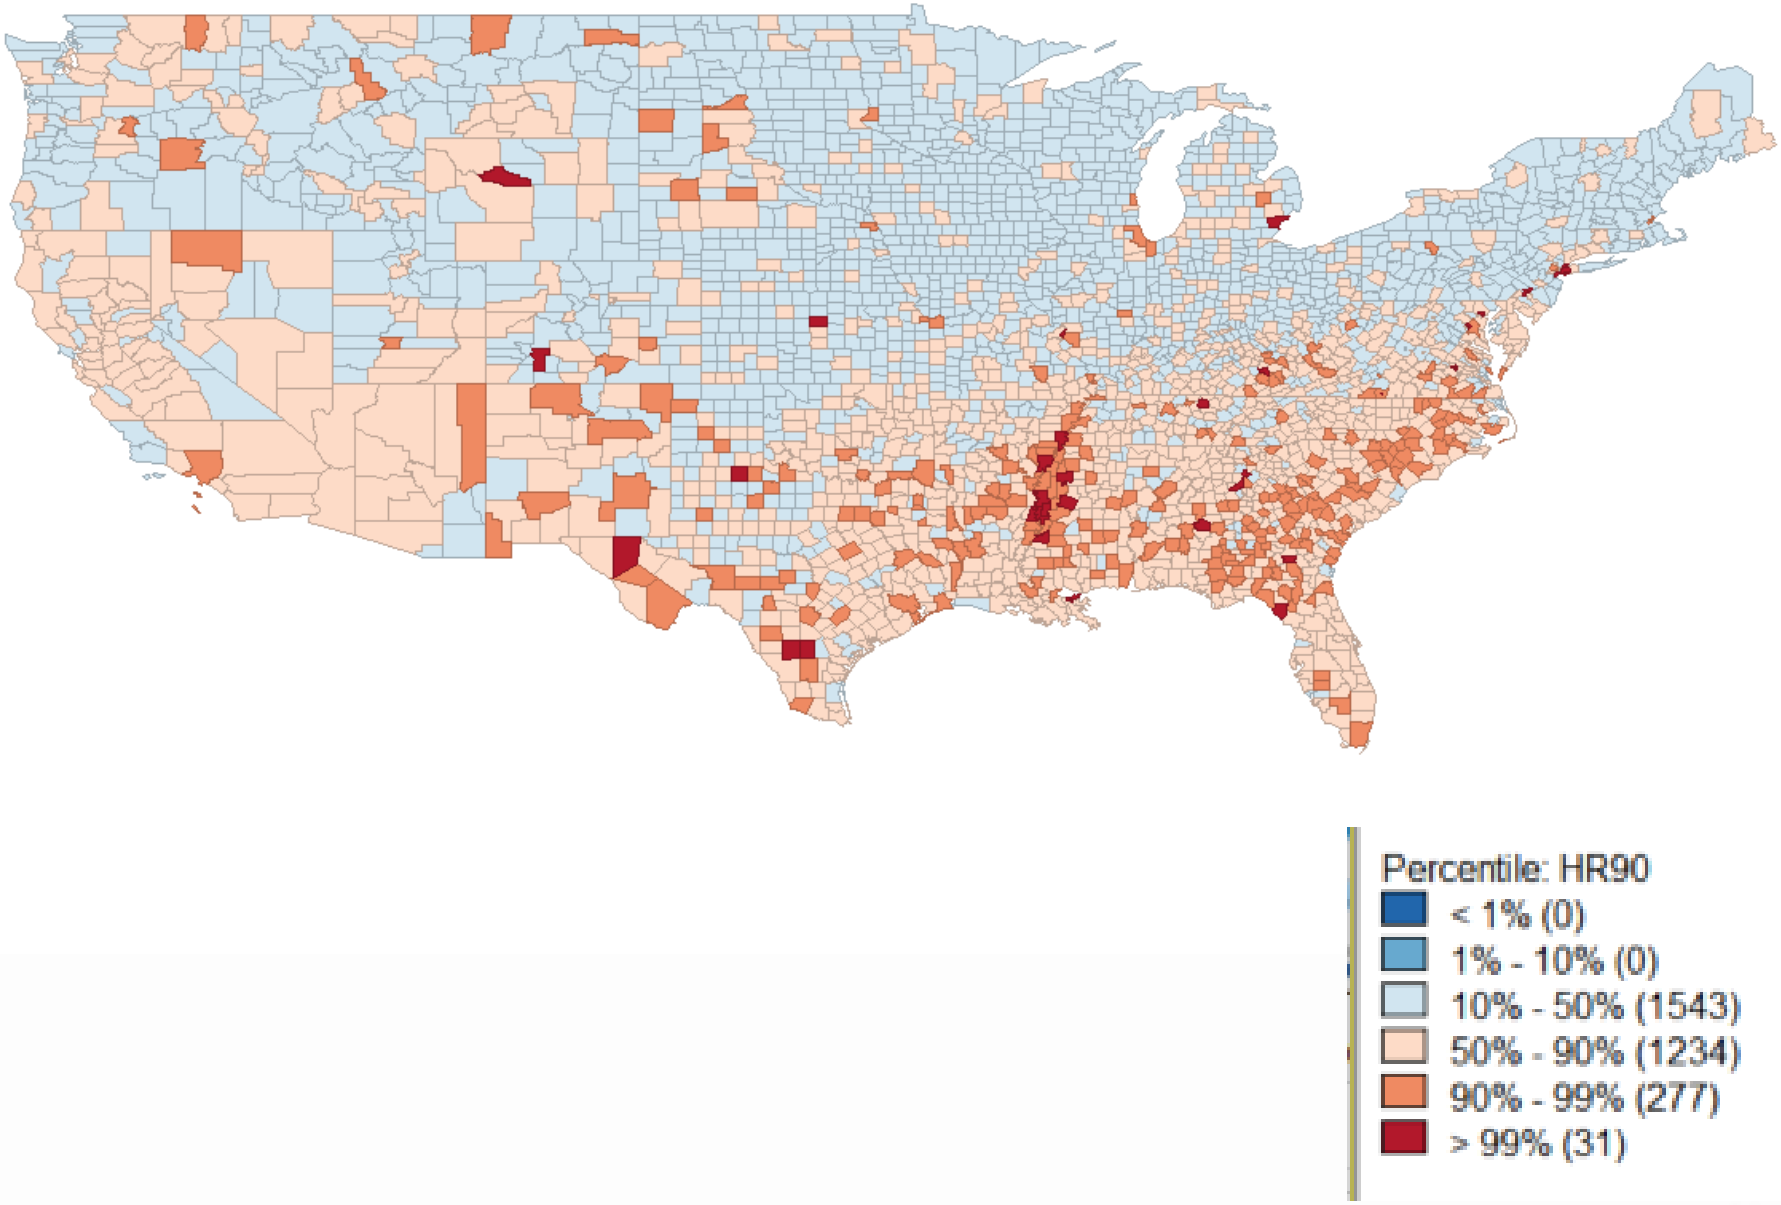
Variable: Description

REGIONS: regions (South, West and Midwest/NE):

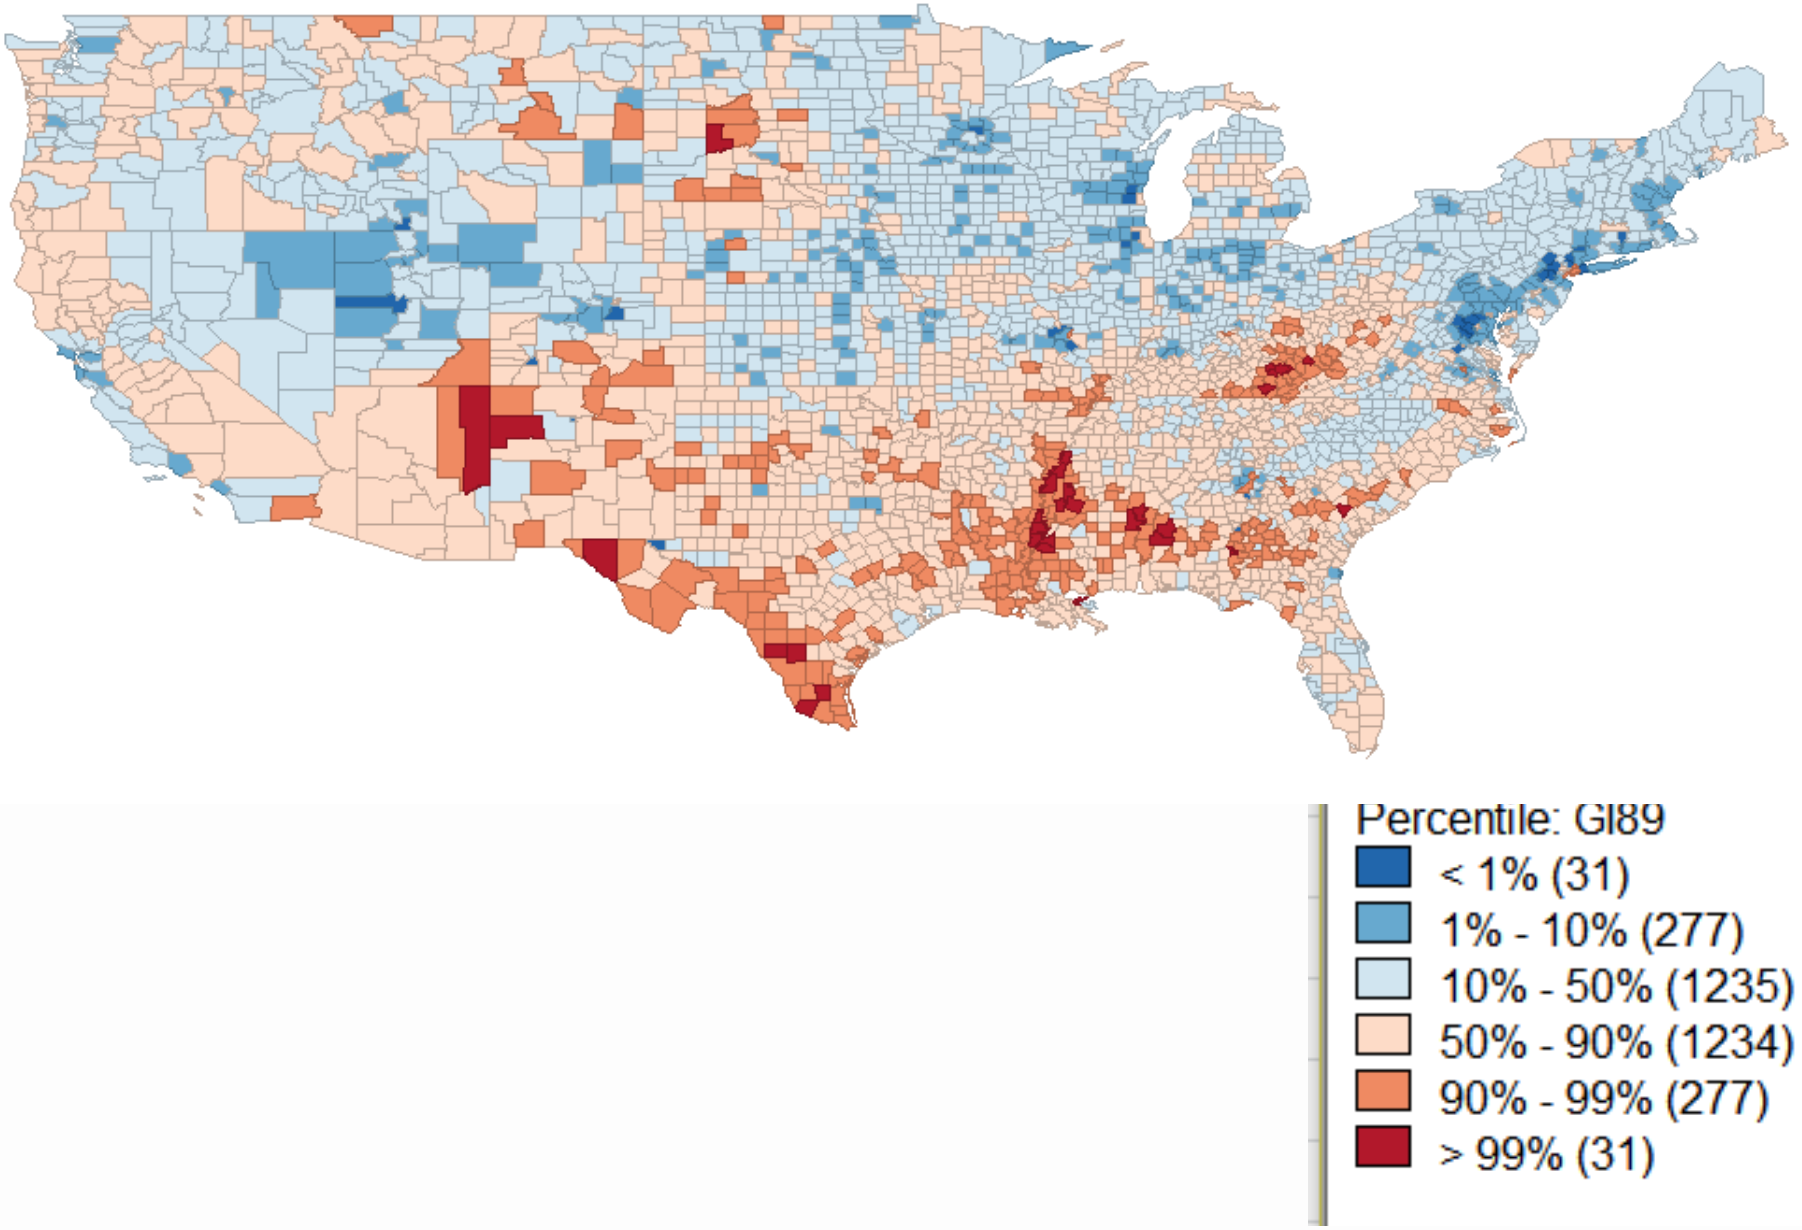


NOSOUTH: South region dummy
POLYID: unique numeric ID
NAME: county name
STATE_NAME: state name
STATE_FIPS: state fips code (character)
CNTY_FIPS: county fips code (character)
FIPS: combined state and county fips code (character)
STFIPS: state fips code (numeric)
COFIPS: county fips code (numeric)
FIPSNO: fips code as numeric variable
SOUTH: dummy variable for Southern counties (South = 1)
HR**: homicide rate per 100,000 (1960, 1970, 1980, 1990)
HC**: homicide count, three year average centered on 1960, 1970, 1980, 1990
PO**: county population, 1960, 1970, 1980, 1990
RD**: resource deprivation 1960, 1970, 1980, 1990 (principal component, see Codebook for details)
PS**: population structure 1960, 1970, 1980, 1990 (principal component, see Codebook for details)
UE**: unemployment rate 1960, 1970, 1980, 1990
DV**: divorce rate 1960, 1970, 1980, 1990 (% males over 14 divorced)
MA**: median age 1960, 1970, 1980, 1990
POL**: log of population 1960, 1970, 1980, 1990
DNL**: log of population density 1960, 1970, 1980, 1990
MFIL**: log of median family income 1960, 1970, 1980, 1990
FP**: % families below poverty 1960, 1970, 1980, 1990 (see Codebook for details)
BLK**: % black 1960, 1970, 1980, 1990
GI**: Gini index of family income inequality 1960, 1970, 1980, 1990
FH**: % female headed households 1960, 1970, 1980, 1990
WEST: West region dummy

Homicide rate per 100,000 (1990)



Gini index of family income inequality in 1990



Estimación de la Autocorrelación Espacial: Matrices de pesos Espaciales por Contigüidad o por distancia

La **dependencia espacial está determinada por una noción de espacio relativo o de localización relativa** que realza el efecto de la **distancia**.

Recordemos que una variable se encontrará *espacialmente autocorrelacionada* cuando los valores observados en un lugar determinado dependen, no sólo de ciertos factores propios de ese lugar (otras variables), sino de los valores observados en regiones/puntos vecinos. Por lo tanto, para estimar la **autocorrelación espacial** es necesario estimar la dependencia entre el **valor de una variable en de cada punto o región del espacio con el valor de esa misma variable para sus puntos** o **regiones vecinas**

En los **modelos de regresión espacial** se consideran de forma explícita las relaciones de dependencia espacial. El valor de la variable dependiente en cada punto o región dependerá del valor que tomen el resto de las variables explicativas en ese punto o región, pero también de lo que esté pasando alrededor, en puntos cercanos o **regiones vecinas**.

¿**Cómo definimos la vecindad**? Existen muchas formas de definir vecindad y distancia.

Nota: **Vecindad no implica necesariamente contigüidad física (en el espacio),** sino que existen una gran cantidad de criterios para definirla (por ejemplo, pueden definirse distancias en términos de volumen de comercio entre países, distancias económicas Case et. al, 1993)

Matriz W de pesos espaciales

Para estimar autocorrelación espacial lo primero que hay que determinar son los puntos que están cercanos o las regiones (polígonos) que son colindantes (vecinos). Esto se hace con la ayuda de las **matrices de pesos espaciales** o matriz proximidad espacial, o **matriz de contigüidad o de distancia**, y que se simboliza con **W.**

La matriz W de pesos espaciales es una matriz cuadrada (*nxn*), no estocástica y cuyos pesos w_{ij} **reflejan la intensidad de la interdependencia** en el espacio entre cada par de regiones *i* y *j* *(i, j =1, 2…. n)* .

$$W = \begin{pmatrix} w_{11} & w_{12} & \cdots & w_{1n} \\ w_{21} & w_{22} & \cdots & w_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ w_{n1} & w_{n2} & \cdots & w_{nn} \end{pmatrix}$$

¿Cómo definir los pesos espaciales?

Aunque los pesos han de ser *finitos* y *no negativos*, no existe una definición unánimemente aceptada, se recurre al concepto de *contigüidad física de primer orden*.

Tres tipos de matrices de pesos espaciales:

- Para datos de polígonos o regiones: matrices de **contigüidad** o vecindad
- Para puntos (x,y): matrices de **distancia**
- Para cualquier tipo de objeto: **matrices por bloques**

La matriz W de pesos espaciales constituye el punto débil de la econometría espacial dado que la robustez de los resultados depende de una correcta elección de la misma.

A) Matriz W de pesos espaciales: CONTIGÜIDAD

La matriz W de pesos espaciales es una matriz cuadrada, no estocástica y cuyos pesos w_{ij} reflejan la intensidad de la interdependencia en el espacio entre cada par de regiones *i* y *j*.

$$W = \begin{pmatrix} w_{11} & w_{12} & \cdots & w_{1n} \\ w_{21} & w_{22} & \cdots & w_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ w_{n1} & w_{n2} & \cdots & w_{nn} \end{pmatrix}$$

¿Cómo definir los pesos espaciales?

Aunque los pesos han de ser *finitos* y *no negativos*, no existe una definición unánimemente aceptada, se recurre al concepto de *contigüidad física de primer orden*.

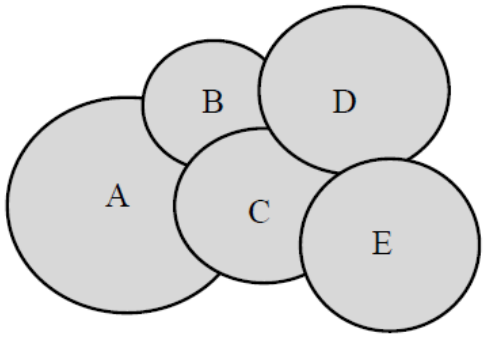
Los pesos espaciales:

$$w_{ij} = \begin{cases} 1 & cuando\ (i,j)\ S\acute{I}\ son\ vecinos\ (contig\ddot{u}os) \\ 0 & cuando\ (i,j)\ NO\ son\ vecinos\ (no\ están\ próximos)\ o\ i = j\ (w_{ii} = 0) \end{cases}$$

Además, $w_{ii} = 0$ cuando $i = j$

Los elementos de la diagonal principal serán siempre cero, queremos conocer la dependencia con el resto no con uno mismo

Matriz W de pesos espaciales: CONTIGÜIDAD



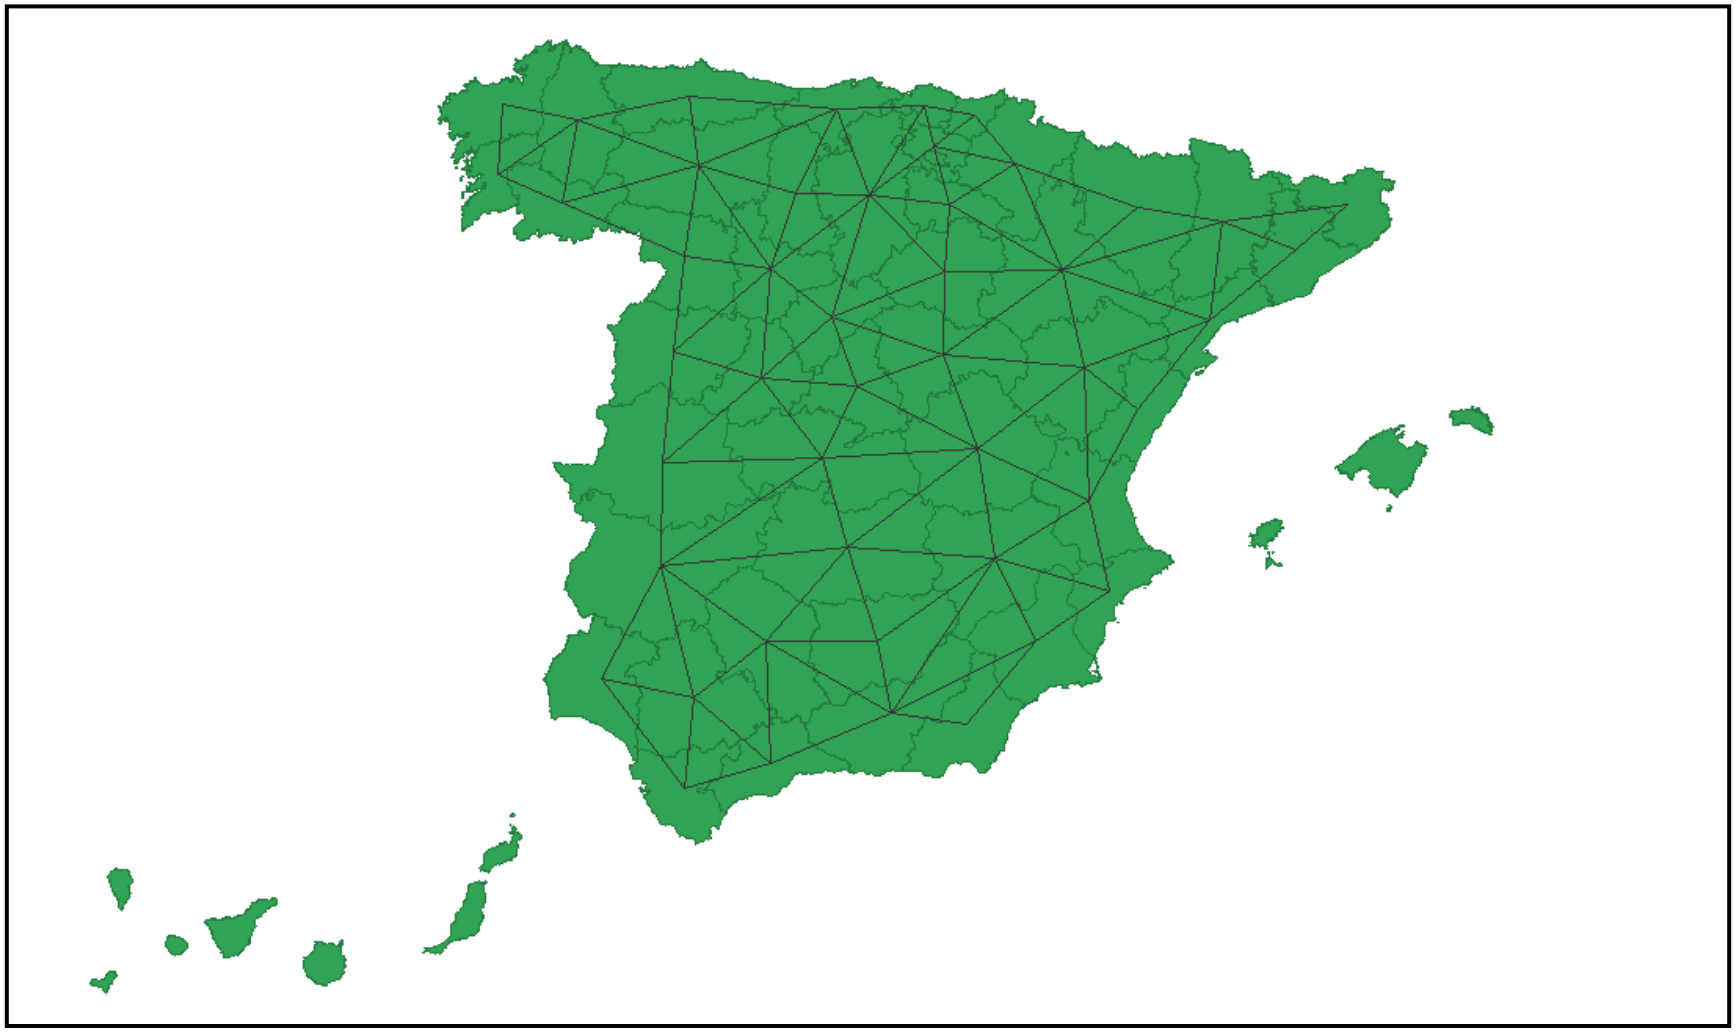
	A	B	C	D	E
A	0	1	1	0	0
B	1	0	1	1	0
C	1	1	0	1	1
D	0	1	1	0	
E	0	0	1	1	0

La forma más sencilla de construir una matriz de contigüidad es utilizando la notación binaria:

- 1 representa contigüidad espacial entre dos unidades
- 0 ausencia de contigüidad espacial entre dos unidades
- Los elementos de la diagonal principal son cero, pues ninguna región puede ser vecina de sí misma.

Una matriz construida de esta manera es **simétrica**.

Fuente Gráficos : Baronio, A., Vianco, A. , Rabanal, C. (2012): Una introducción a la econometría espacial



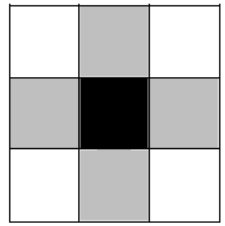
Contigúidad reina matriz de interacciones espaciales

Criterios de contigüidad de primer orden

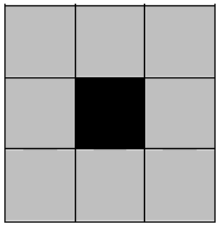
Existen muchas formas de definir la contigüidad (o vecindad) espacial:

- Contigüidad de **torre** (la más usada): w_{ij}=1 para unidades que comparten un lado común con la región de interés y 0 en caso contrario.
- Contigüidad de **alfil**: w_{ij}=1 para unidades que comparten un vértice en común con la región de interés y 0 en caso contrario.
- Contigüidad de **reina**: w_{ij}=1 para unidades que comparten un lado en común o un vértice con la región de interés y 0 en caso contrario.

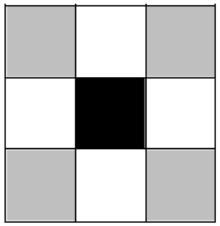
Usando alguno de estos criterios de contigüidad física se construye la matriz de pesos de **primer orden**. Solo es necesario establecer la localización de las unidades en el mapa que tienen bordes comunes con longitudes positivas.



Matriz torre (rook) de primer orden



Matriz reina (queen) de primer orden

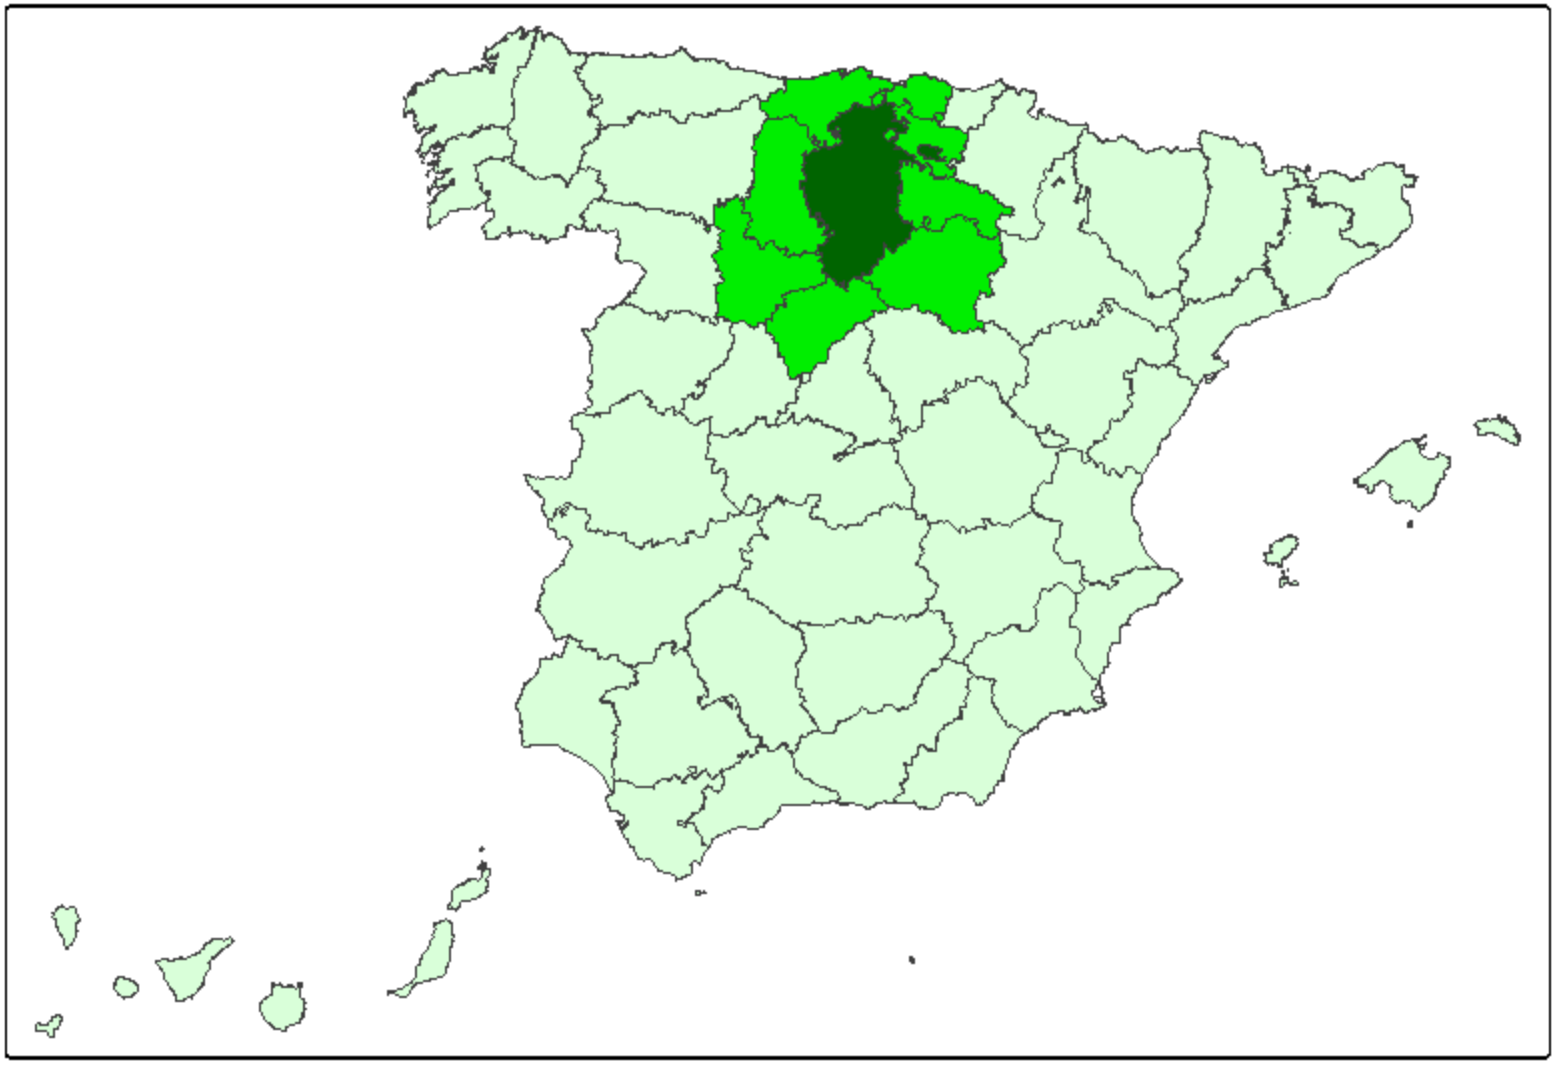


Matriz alfil (bishop) de primer orden

Fuente Gráficos : Baronio, A., Vianco, A. , Rabanal, C. (2012): Una introducción a la econometría espacial



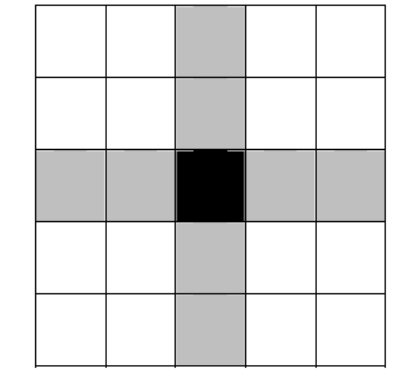
Comunidad de Madrid



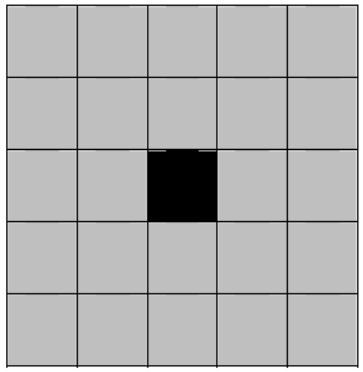
Matrices de contigüidad de órdenes superiores

Dos regiones *i* y *j* serán **contiguas de segundo orden** si ambas están separadas por una tercera región *h* que es contigua de primer orden a ambas.

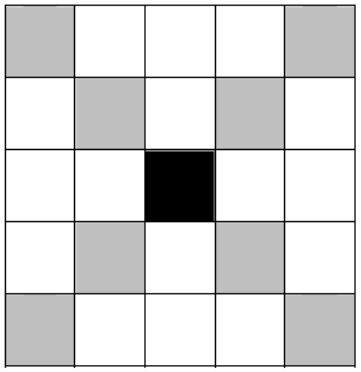
- Aunque la idea es extensible a órdenes superiores, no existen situaciones que requieran adoptar un criterio de vecindad más allá del segundo orden.



Matriz torre (rook) de primer orden



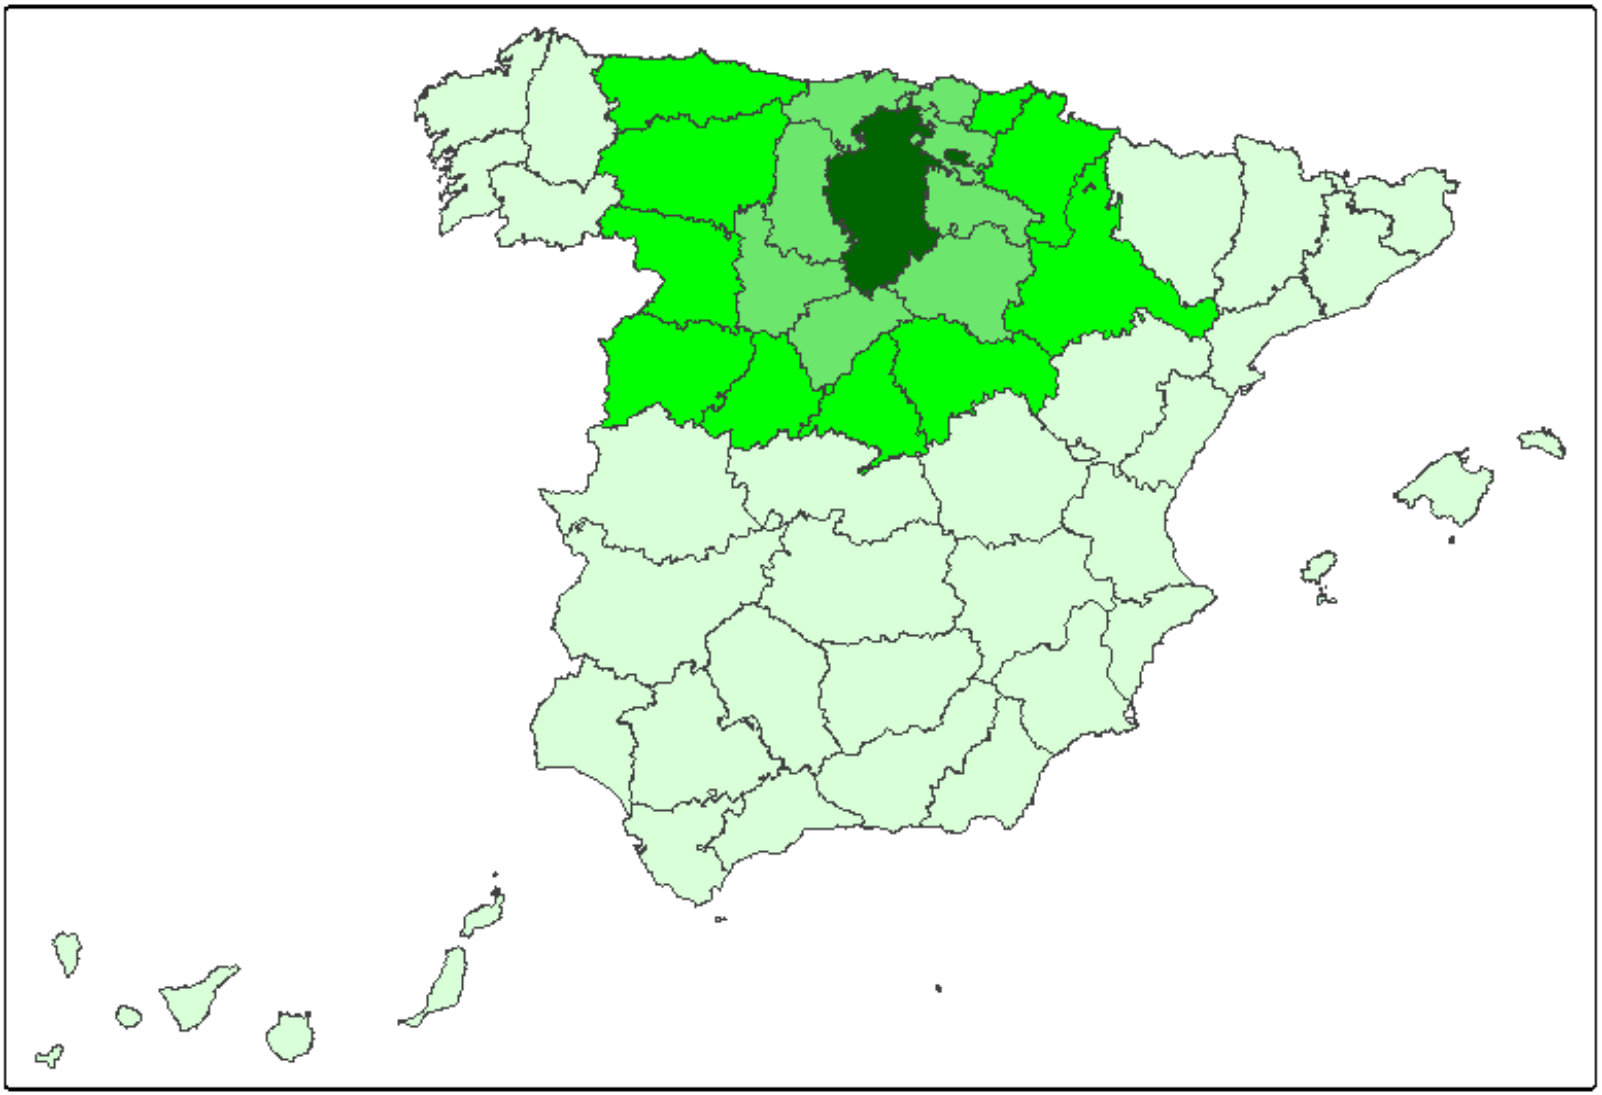
Matriz reina (queen) de primer orden



Matriz alfil (bishop) de primer orden

Otra alternativa es utilizar los k-vecinos más próximos o los situados a una distancia menor que K

Fuente Gráficos : Baronio, A., Vianco, A. , Rabanal, C. (2012): Una introducción a la econometría espacial



B) Matriz W de pesos espaciales: DISTANCIA

Otra alternativa es construir la matriz de pesos usando **distancias**:

$$w_{ij} = f(d_{ij}, \theta)$$

Por ejemplo: **pesos inversamente proporcionales a la distancia**

con $\frac{\partial w_{ij}}{\partial d_{ij}} < 0$, y siendo d_{ij} una métrica de la distancia entre dos puntos i,j

→ $w_{ij} = f(d_{ij}, \theta) = \frac{1}{d_{ij}^{\alpha}}$ Con d_{ij} la distancia Euclídea

→ $w_{ij} = f(d_{ij}, \theta) = e^{-\beta d_{ij}}$

Si α=2 (Anselin 1980), la intensidad de la interdependencia entre dos regiones disminuye con la distancia que separa sus respectivos centros.

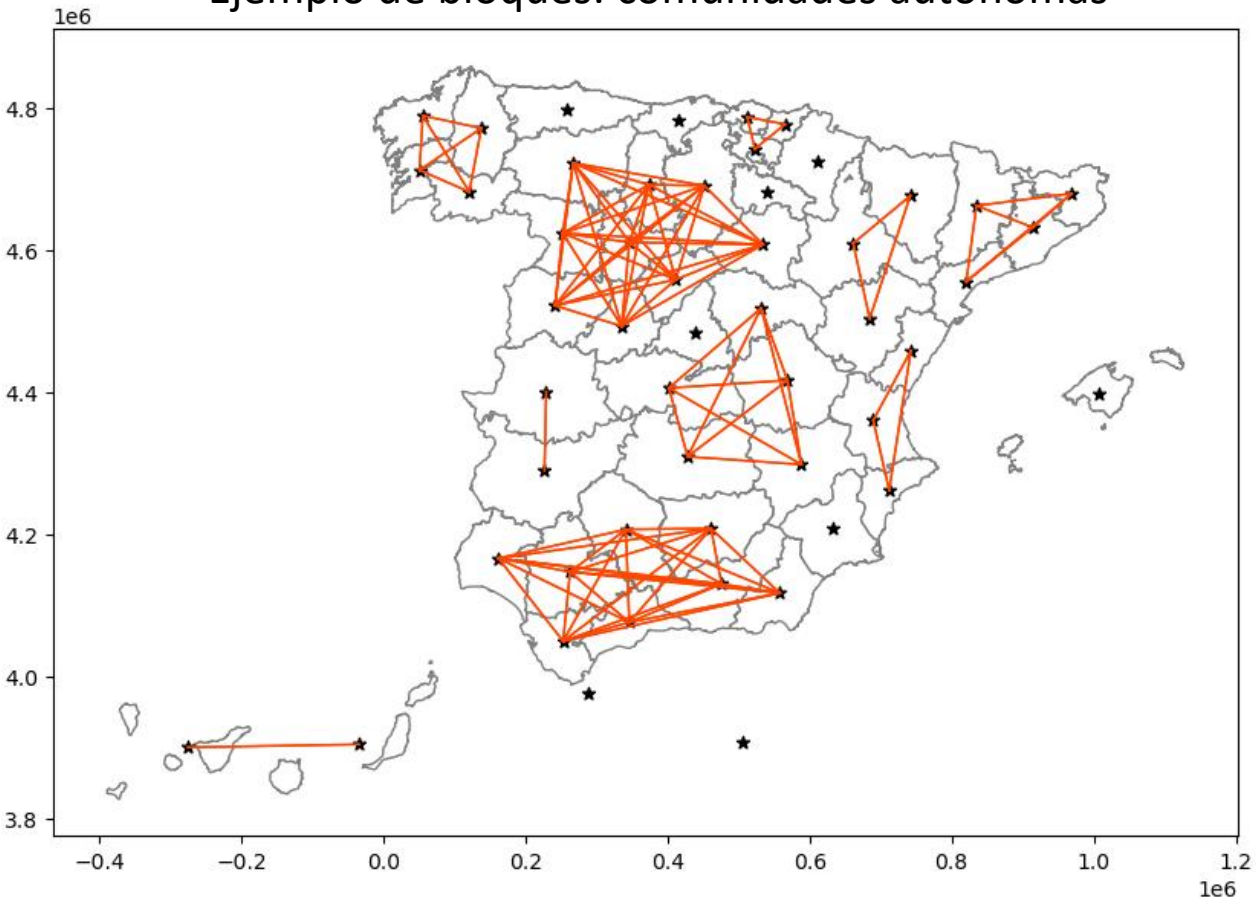
También se pueden elegir usando distancias:

- **los k-vecinos más próximos** (w_{ij}=binaria)
- o los situados a una **distancia menor que K** (w_{ij}=*binaria* o w_{ij} = *inversa a la distancia*)

C) Matriz W de pesos espaciales: por BLOQUES

$$\begin{cases} w_{ij} = 1 \quad cuando \;\; i,j \; pertenencen \; al \; mismo \; bloque \\ w_{ij} = 0 \quad cuando \;\; i,j \; pertenencen \; a \; distintos \; bloque \end{cases}$$

Ejemplo de bloques: comunidades autónomas



Matriz W de pesos espaciales: **NORMALIZACION POR FILAS**

Una vez que tenemos la matriz W con unos y ceros (por contigüidad), o con pesos inversamente proporcionales a la distancia (por distancia) , suele estandarizarse la matriz W por **filas**:

$$w_{i,j}^{s} = \frac{w_{ij}}{\sum_j w_{ij}}$$

De forma que la suma de los pesos asociados a cada área es igual a uno:

$$\sum_j w_{i,j}^{s} = 1 \qquad \sum_i \sum_j w_{i,j}^{s} = n$$

Además, para obtener estimaciones consistentes, la matriz W debe estar delimitada de manera uniforme y en valor absoluto, lo que implica que existe una constante $c<\infty$ tal que:

$$1 \le i \le n \sum_{j=1}^{n} |w_{ij}| \le c \qquad y \qquad 1 \le j \le n \sum_{i=1}^{n} |w_{ij}| \le c$$

Retardo espacial

La matriz de pesos espaciales **W** sirve para **construir las variables retardadas espacialmente** o los retardos espaciales de una variable dada ***y***. Así dada una matriz de pesos espaciales

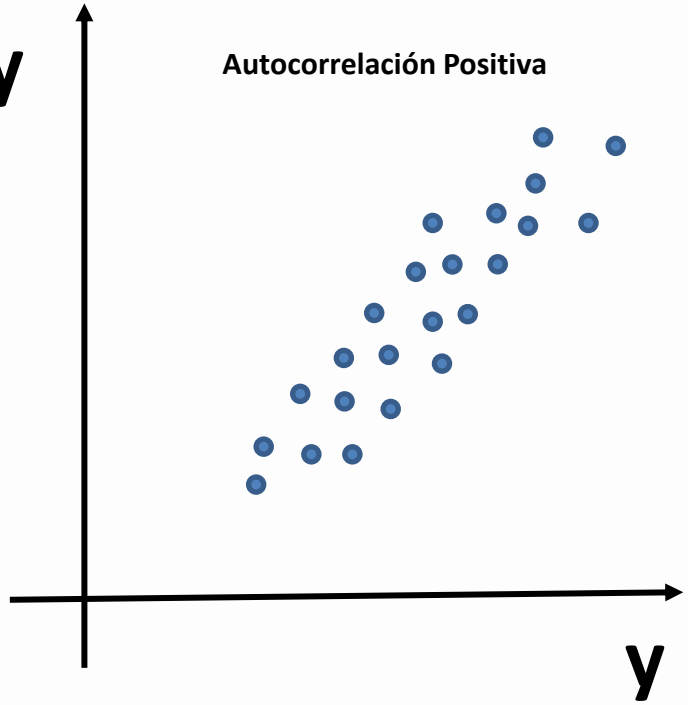
$$W = \begin{pmatrix} w_{11} & w_{12} & \dots & w_{1n} \\ w_{21} & w_{22} & \dots & w_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ w_{n1} & w_{n2} & \dots & w_{nn} \end{pmatrix} \qquad w_{i,j}^{s} = \frac{w_{ij}}{\sum_j w_{ij}} \qquad \sum_j w_{i,j}^{s} = 1$$

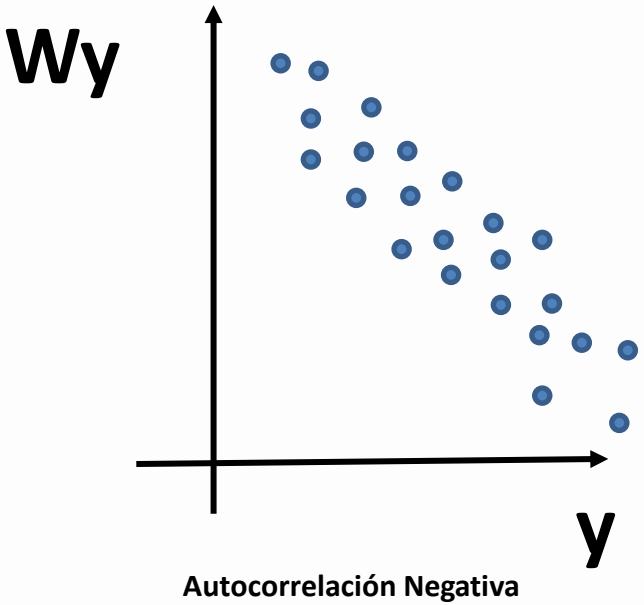
El retardo espacial de una variable dada *y* se construye premultiplicando al vector columna ***y*** (*n*x1)por la matriz pesos espaciales **W** (*n*xn)

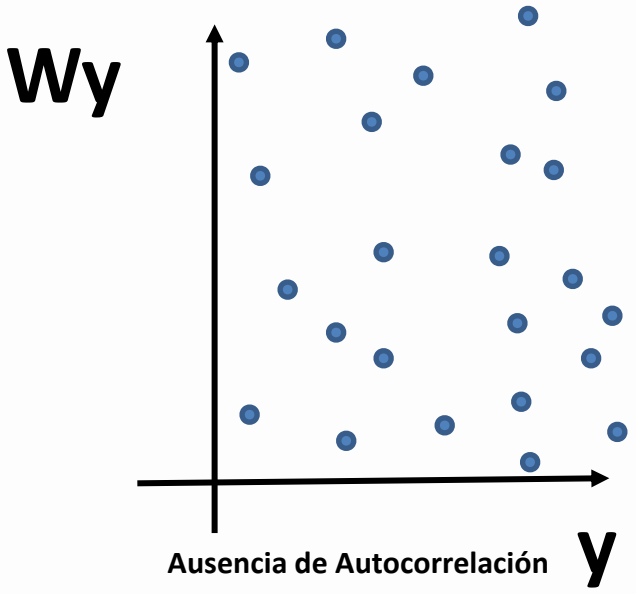
$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \xrightarrow{\text{Retardo espacial}} W \cdot y = \begin{pmatrix} \sum_j w_{1j}^{s} y_j \\ \sum_j w_{2j}^{s} y_j \\ \vdots \\ \sum_j w_{nj}^{s} y_j \end{pmatrix}$$

Cada elemento de este vector ***Wy*** es la media ponderada de los valores de la variable ***y*** en el subgrupo de las observaciones contiguas (vecinas), dado que el peso es cero si no pertenece a ese subgrupo.

Scatterplot de Moran (gráfico de dispersión de Moran)







Nota: Autocorrelación espacial y autocorrelación temporal

¿En qué se diferencia la autocorrelación espacial de la autocorrelación temporal?

- La autocorrelación temporal es **unidireccional**: el pasado explica el presente.

El instrumento utilizado para representar esta relación es el **operador de retardos L**.

- La autocorrelación espacial es multidireccional: una región puede no solo estar afectada por otra región contigua a ella sino por otras muchas que la rodean, al igual que ella puede influir sobre aquéllas.

El operador retardos espaciales será precisamente la **matriz de pesos espaciales W**.

La autorcorrelación espacial NO puede tratarse con técnicas econométricas estándar debido a esta **multidireccionalidad**. Requiere métodos para controlar por esa endogeneidad (métodos de regresión espacial)

Estadísticos de Autocorrelación Espacial

Una vez que disponemos de la matriz de pesos espaciales, podemos estimar la dependencia o autocorrelación espacial analizando la correlación entre una serie x y su **retardo espacial** Wx con **medidas de asociación o dependencia espacial local y global**

- ***I*** de Moran (1950)
- ***C*** de Geary (1954)
- ***G(d)*** de Getis y Ord (1992)

Permiten contratar la hipótesis nula de "ausencia autocorrelación espacial".

- El análisis de **Autocorrelación Espacial global** analiza todas las observaciones de la muestra de forma conjunta para determinar si existe en el conjunto de datos patrones de comportamiento espacial (dependencia espacial)
  - Permiten contrastar **si una variable se encuentra distribuida de forma totalmente aleatoria en el espacio o si, por el contrario, existe un patrón espacial determinado**

- Los **contrastes LISA (Local Indicator os Spatial Analysis)** permiten medir la **Autocorrelación Espacial Local**, esto es, si independientemente de que globalmente exista o no autocorrelación o dependencia, **si localmente, cada ubicación en particular presenta dependencia o no con sus vecinos locales**
  - Pueden detectar aglomeraciones (clústeres) en un área determinada en función de la dependencia espacial (no sólo por presentar valores similares de la variable)
  - Moran: La suma de los I_i para todas las observaciones es proporcional al indicador global ***I***. Resulta útil para medir la contribución de cada observación al contraste global

Estadísticos globales de Autocorrelación Espacial

Una vez que disponemos de la matriz de pesos espaciales, podemos estimar la dependencia o autocorrelación espacial analizando la correlación entre una serie $\boldsymbol{x}$ y su retardo espacial $\boldsymbol{Wx}$: Medidas de asociación o dependencia espacial **global**:

- El análisis de Autocorrelación Espacial global analiza todas las observaciones de la muestra de forma conjunta para determinar si una variable se encuentra distribuida de forma totalmente aleatoria en el espacio o si, por el contrario, existe un patrón espacial determinado

- Hablamos de **patrón espacial** cuando existe una asociación significativa de valores similares o disímiles entre regiones vecinas.

- Estadísticos globales:
  - ***I*** de Moran,
  - ***C*** de Geary
  - ***G(d)*** de Getis y Ord.

- Permiten contratar la hipótesis nula de “no autocorrelación espacial”.

Entre los instrumentos que permiten extraer las características de los datos georreferenciados (observación de una variable asociada a una localización del espacio geográfico) destaca el **índice I de Moran**.

El índice **I de Moran**

La I de Moran (1950) es una adaptación de una medida de correlación no-espacial al contexto espacial.

Número de zonas en consideración

Covarianza

$$I = \frac{n}{S_0}\frac{(y-\bar{y})'W(y-\bar{y})}{(y-\bar{y})'(y-\bar{y})} = \frac{n}{S_0}\frac{\sum_i \sum_j w_{ij}(y_i-\bar{y})(y_j-\bar{y})}{\sum_i (y_i-\bar{y})^2}$$

Varianza

con

$S_0 = \sum_i \sum_j w_{ij}$ → Número de relaciones (adyacencias) en el mapa

$\bar{y} = \sum_i \frac{y_i}{n}$ → Media aritmética de valores de y

La autocorrelación o dependencia espacial detectada puede ser:

- **Negativa** $\left(\textbf{Bajo la hipótesis de normalidad y aleatoriedad espacial } \boldsymbol{E(I) = -\frac{1}{n-1}}\right)$
- **Positiva**
- **Nula (test para contrastar la Hipótesis nula de Ausencia de autocorrelación Espacial)**

  Ho: *I*=0

  H1: *I* >0

La I de Moran toma valores desde **-1**, correlación espacial perfecta negativa, 0 ausencia de correlación espacial, y **1** correlación espacial perfecta positiva

El estadístico C de Geary

El estadístico C de Geary (1954), es otra medida de autocorrelación espacial que evalúa si los valores de una variable en ubicaciones cercanas tienden a ser similares (autocorrelación espacial positiva) o diferentes (autocorrelación espacial negativa).

A diferencia del índice de Moran que se basa en la covarianza, la C de Geary **se basa en las diferencias entre los valores** de las ubicaciones vecinas.

$$C = \frac{(n-1)}{2*S_0} \frac{\sum_i \sum_j w_{ij}(y_i - y_j)^2}{\sum_i (y_i - \bar{y})^2}$$

con $S_0 = \sum_i \sum_j w_{ij}$ → Número de relaciones (adyacencias) en el mapa

- **C < 1:** Indica autocorrelación espacial positiva. **Los valores cercanos tienden a ser similares**.
- **C > 1:** Indica autocorrelación espacial negativa**. Los valores cercanos tienden a ser diferentes**.
- **C ≈ 1:** Indica ausencia de autocorrelación espacial. Los valores se distribuyen aleatoriamente en el espacio (***Ho=ausencia de autocorrelación espacial***).

G de Getis y Ord

El estadístico G(d) de Getis-Ord (1992), es una medida de autocorrelación espacial que **evalúa la concentración de valores altos o bajos** de una variable dentro de una distancia o vecindad específica (d). El estadístico G global considera todas las distancias, es decir, mide de concentración de valores altos o bajos en el conjunto del espacio. Es una medida que complementa a las medidas locales: la estadístico espacial que evalúa la asociación de datos comparando promedios locales y globales. A diferencia del índice de Moran o el C de Geary, que miden la autocorrelación global, el G de Getis-Ord puede usarse para identificar "puntos calientes" (hot spots) o "puntos fríos" (cold spots) de concentración de valores.

$$G = \frac{\sum_i \sum_j w_{ij}\, y_i\, y_j}{\sum_i \sum_j y_i\, y_j}$$

La interpretación del estadístico G de Getis-Ord es la siguiente:

E[G] esperado: Bajo la hipótesis nula de aleatoriedad espacial, el valor esperado de G:

$$E[G] = \frac{\sum_i \sum_j w_{ij}}{n(n-1)} = \frac{S_0}{n(n-1)}$$

G observado > E[G]: Indica una concentración de valores altos dentro del conjunto del espacio Esto sugiere la presencia de concentración de valores altos "**puntos calientes**"

G observado < E[G]: Indica una concentración de valores bajos dentro del conjunto del espacio. Esto sugiere la presencia de valores fríos "**puntos fríos**" o clúster de valores bajos.

G observado = E[G]: Indica ausencia de concentración ni de puntos fríos ni de puntos calientes

(El estadístico G de Getis Global en una medida que complementa a las Gi locales)

G(d) de Getis y Ord

El estadístico G(d) de Getis-Ord (1992), es una medida **local** de autocorrelación espacial que **evalúa la concentración de valores altos o bajos** de una variable dentro de una distancia o vecindad específica **d**. El G(d) de Getis-Ord puede usarse para identificar "puntos calientes" (hot spots) o "puntos fríos" (cold spots) de concentración de valores en el entorno de las distancias **d**.

$$G(d)=\frac{\sum_i \sum_j w_{ij}(d)\cdot y_i \cdot y_j}{\sum_i \sum_j \cdot y_i \cdot y_j}$$

Donde $w_{ij}(d)$ es el elemento de la matriz de ponderaciones espaciales para una distancia o vecindad d:

- $w_{ij}(d)$ = 1 si la distancia entre las ubicaciones *i* y *j* es menor o igual a d,
- $w_{ij}(d)$ = 0 en caso contrario.

La interpretación del estadístico G(d) de Getis-Ord es la siguiente:

G(d) esperado: Bajo la hipótesis nula de aleatoriedad espacial, el valor esperado de G(d):

$$E[G(d)]=\frac{\sum_i \sum_j w_{ij}(d)}{n(n-1)}=\frac{S_0\,(d)}{n(n-1)}$$

G(d) observado > E[G(d)]: Indica una concentración de valores altos dentro de la distancia o vecindad d. Esto sugiere la presencia de un "**punto caliente**" o clúster de valores altos

G(d) observado < E[G(d)]: Indica una concentración de valores bajos dentro de la distancia o vecindad d. Esto sugiere la presencia de un "**punto frío**" o clúster de valores bajos.

G(d) observado = E[G(d)]: Indica ausencia de concentración ni de puntos fríos ni de puntos calientes

Estadísticos de asociación Espacial **locales**

Medidas de asociación espacial **local**:

- Los patrones de Autocorrelación Espacial detectados con contrastes globales (p.ej. ausencia Autocorrelación Espacial) pueden no mantenerse en todas las unidades del espacio analizado (procesos NO estacionarios espacialmente).

- Los **contrastes locales** permiten medir la Autocorrelación Espacial para la ubicación de cada observación:
  - Pueden detectar aglomeraciones (clústeres) en un área determinada
  - Puede detectar la presencia de localizaciones que muestren valores altos (bajos) con respecto a la media de los emplazamientos colindantes.

- LISA-*Local Indicator of Spatial Association*: Moran I_i , $New - G_i\ (d)$, $New - G_i^*(d)$
  - Proporcionan una cuantificación del grado de agrupamiento significativo de valores similares alrededor de una observación.
  - Moran: La suma de los I_i para todas las observaciones es proporcional al indicador global ***I***. Resulta útil para medir la contribución de cada observación al contraste global.

Complementariedad de la información suministrada por los índices globales y locales.

El índice **I de Moran Local**

Existe una I_i de Moran Local para cada objeto espacial i

$$I_i = \frac{(y_i - \bar{y})}{m_2} \sum_{j=1}^{n} w_{ij}(y_j - \bar{y}) \quad \text{, para } i \neq j, \quad \text{con} \quad m_2 = \frac{\sum_{i=1}^{n}(y_i - \bar{y})^2}{n}$$

además se verifica la siguiente relación entre I_i de Moran Local y la I de Moran Global

$$I = \frac{\sum_{i=1}^{n} I_i}{S_0}$$

$$S_0 = \sum_i \sum_j w_{i,j}$$

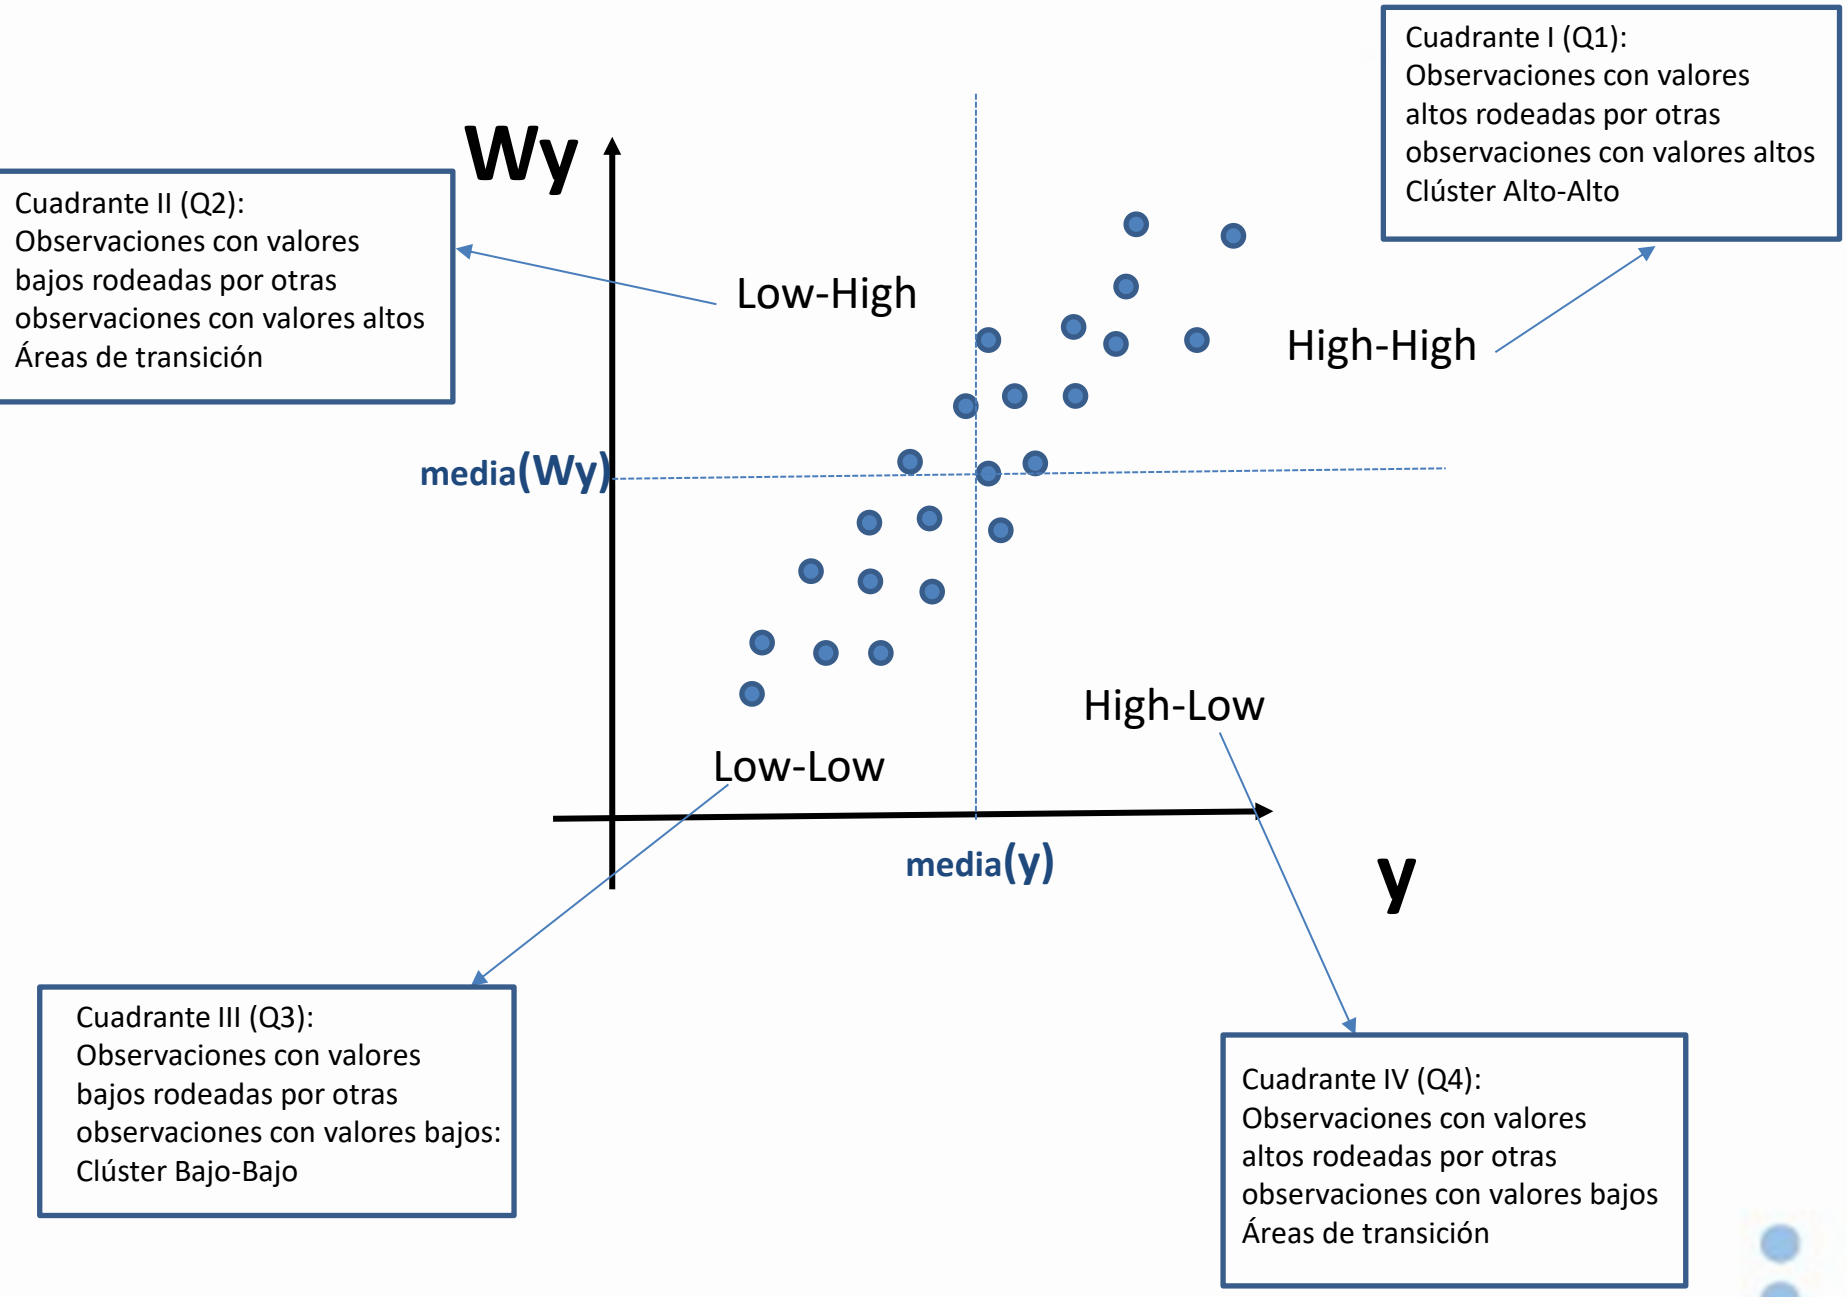
Podemos contrastar si cada uno de los objetos espaciales presenta dependencia espacial (independientemente de que exista o no dependencia global, contrastando si la I_i de Moran Local para cada objeto espacial i es estadísticamente significativa

Una vez normalizados (estandarizados) los valores de la I_i de Morán local (para que tengan media cero y desviación típica 1, puede interpretarse de la siguiente forma

- $Z(I_i) > 0$ autocorrelación positiva y significativa: cluster de valores similares alrededor de i
- $Z(I_i) < 0$ autocorrelación negativa y significativa: cluster de valores disimilares alrededor de i
- $Z(I_i) = 0$ (no significativa): ausencia de dependencia espacial local

La I de Moran puede considerarse un método de clustering alternativo a otros, como por ejemplo el DBSCAN (basado en la densidad de los puntos, iIdentificando regiones con alta densidad de observaciones separadas por regiones de baja densidad).

Local Indicator of Spatial Analisys:Clusteres mediante Scatterplot de Moran



Cuadrante I (Q1):
Observaciones con valores altos rodeadas por otras observaciones con valores altos
Clúster Alto-Alto

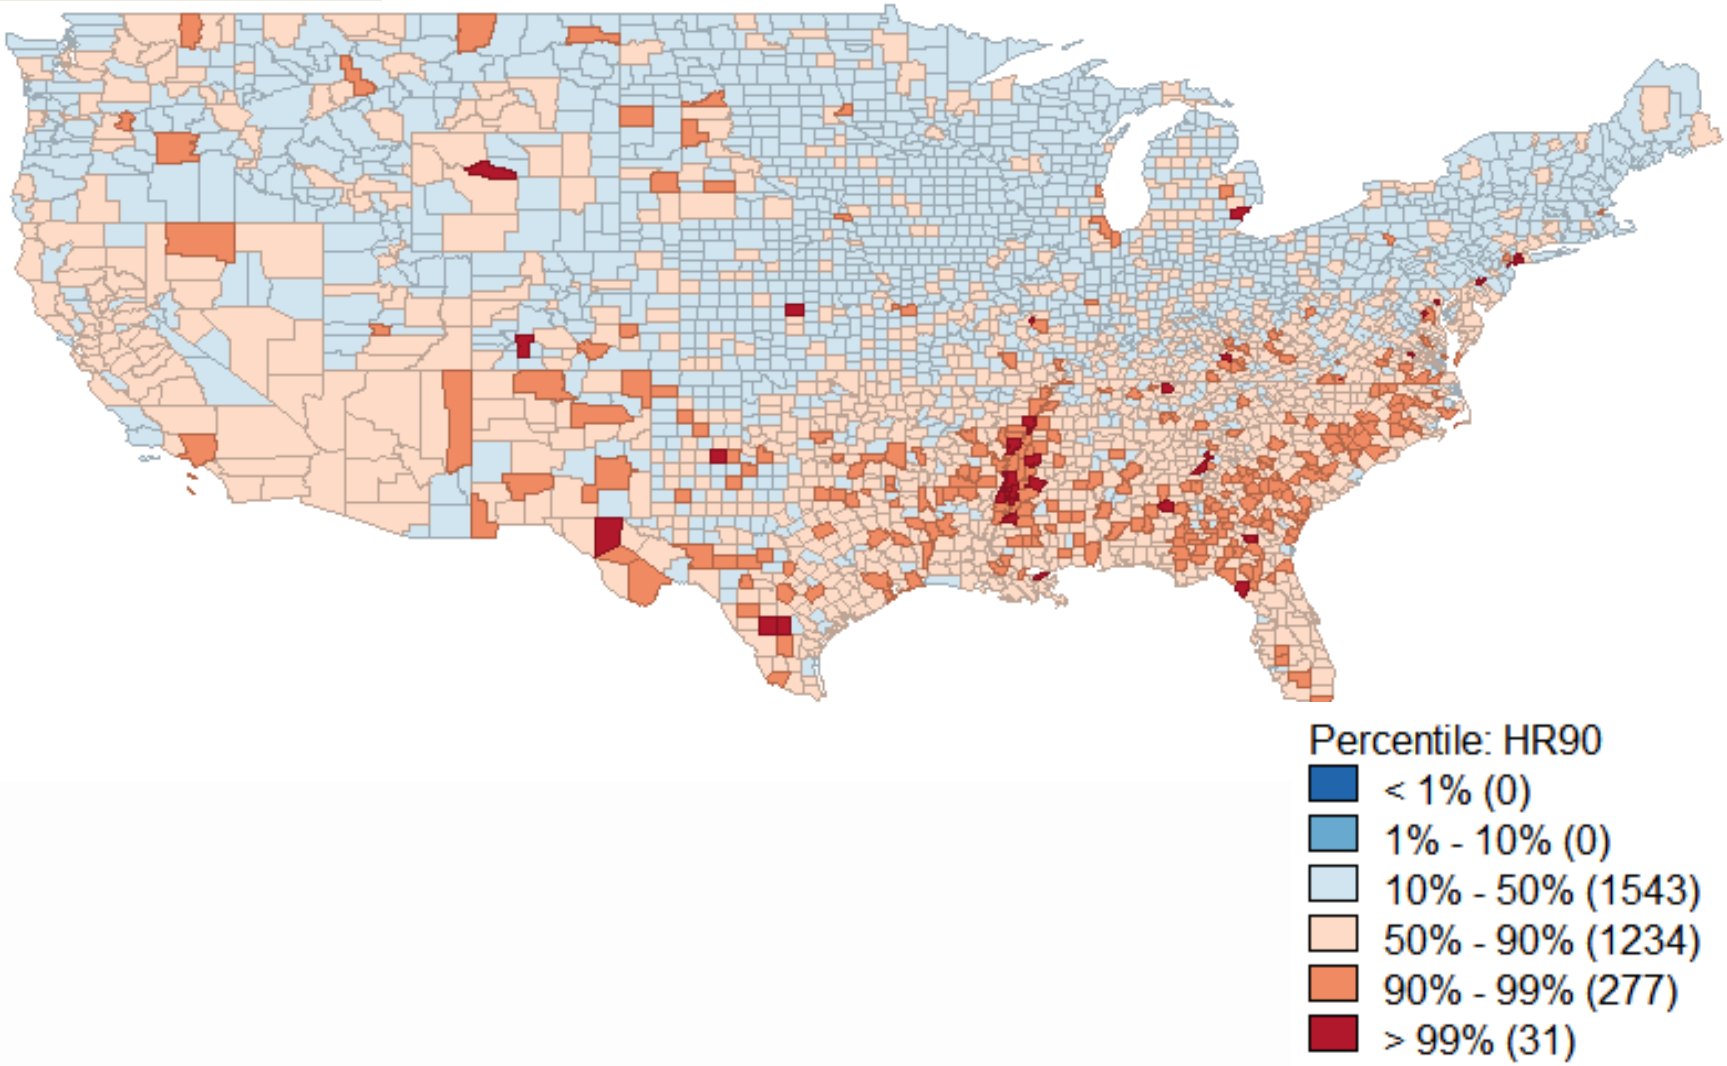
Cuadrante II (Q2):
Observaciones con valores bajos rodeadas por otras observaciones con valores altos
Áreas de transición

Cuadrante III (Q3):
Observaciones con valores bajos rodeadas por otras observaciones con valores bajos:
Clúster Bajo-Bajo

Cuadrante IV (Q4):
Observaciones con valores altos rodeadas por otras observaciones con valores bajos
Áreas de transición

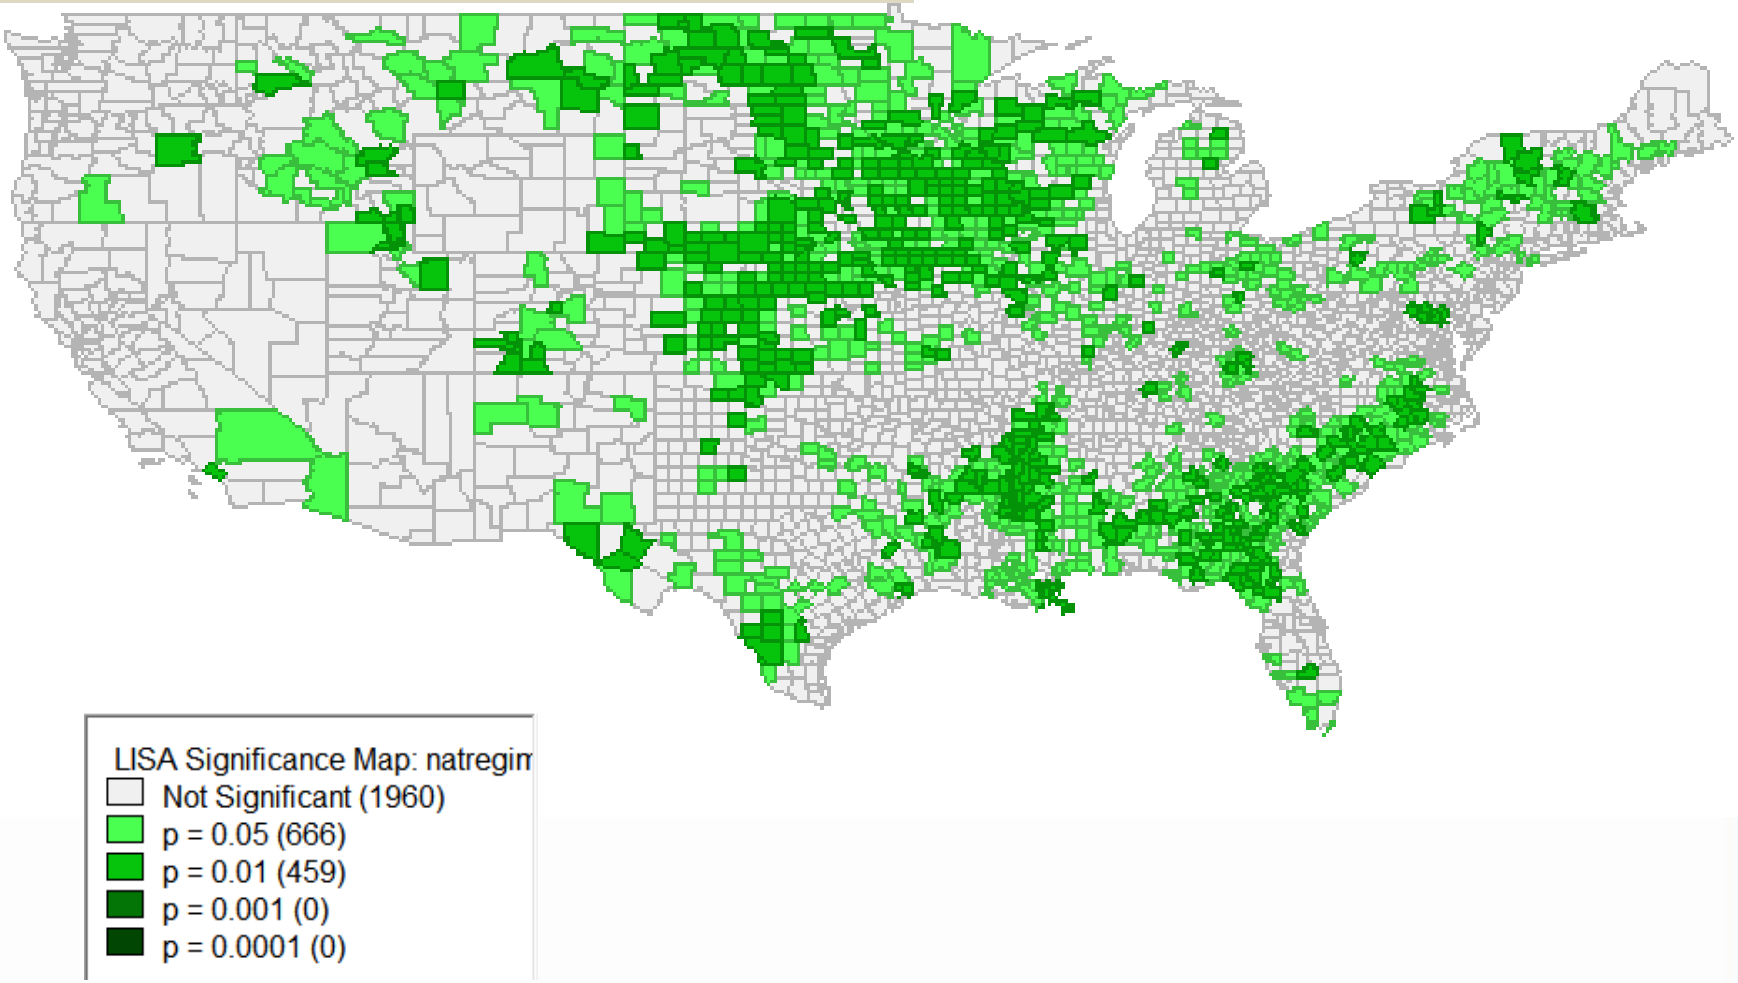
Homicidios por cada 100,000 habitantes

Mapa Coroplético



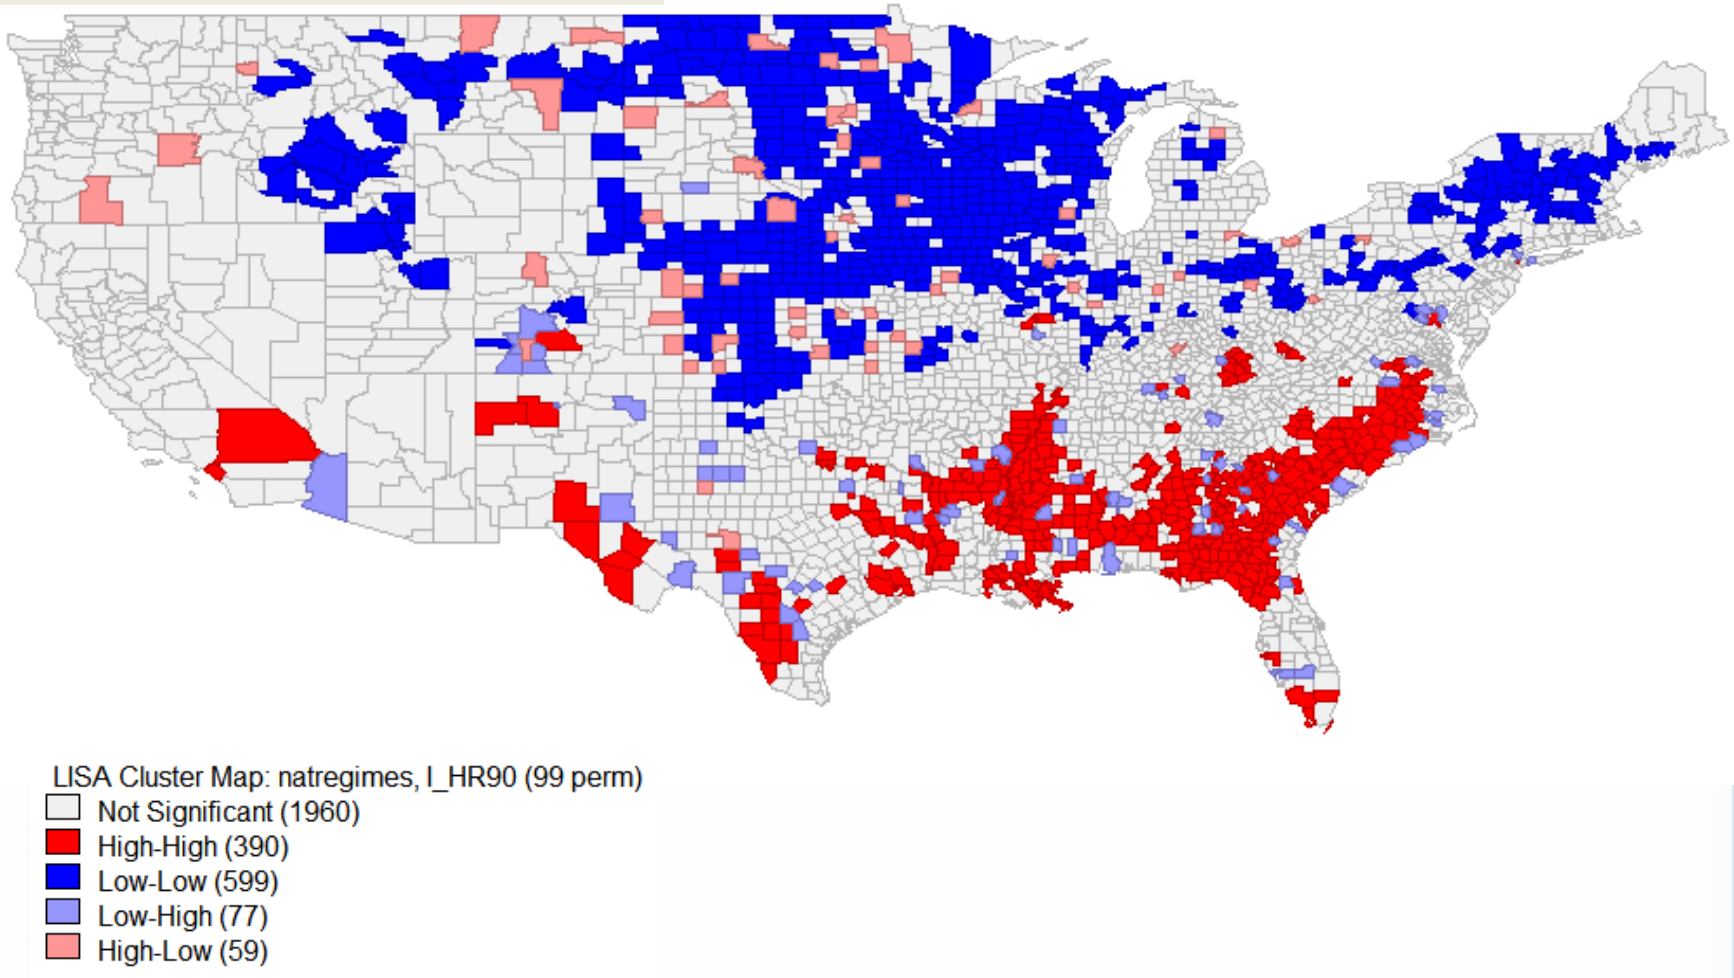
Homicidios por cada 100,000 habitantes

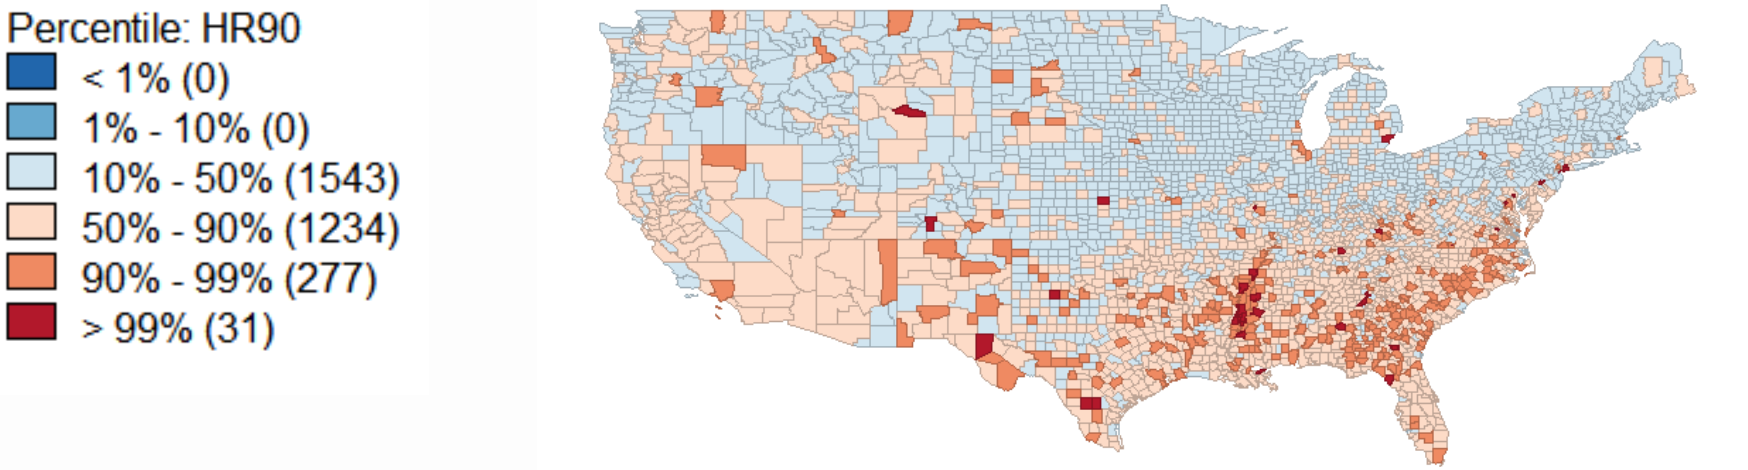
Mapa de Significación de la I de Moran Local

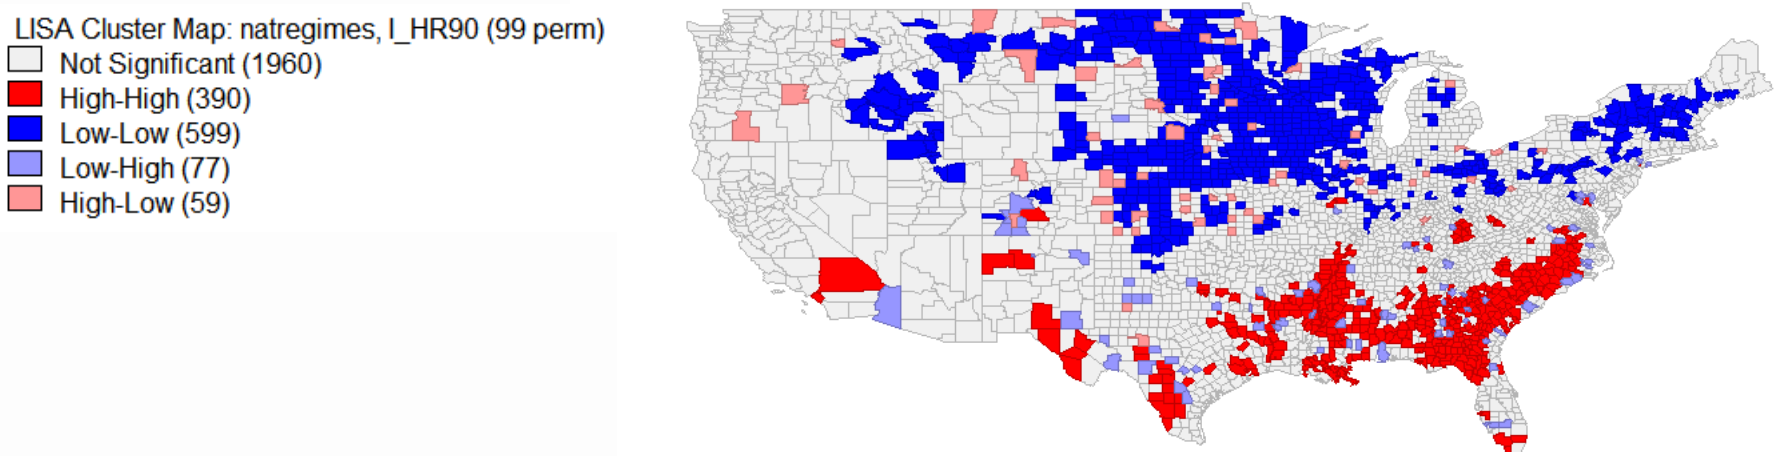


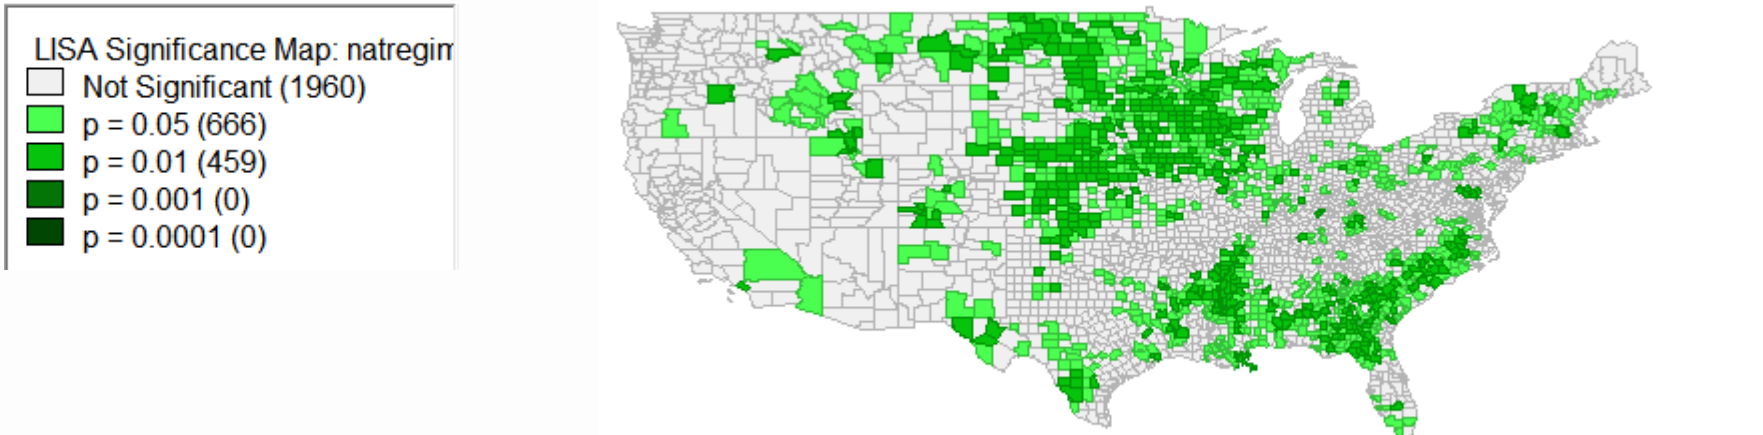
Homicidios por cada 100,000 habitantes

Cuadrante del Gráfico de Moran




Percentile: HR90
< 1% (0)
1% - 10% (0)
10% - 50% (1543)
50% - 90% (1234)
90% - 99% (277)
> 99% (31)


LISA Cluster Map: natregimes, I_HR90 (99 perm)
Not Significant (1960)
High-High (390)
Low-Low (599)
Low-High (77)
High-Low (59)


LISA Significance Map: natregim
Not Significant (1960)
p = 0.05 (666)
p = 0.01 (459)
p = 0.001 (0)
p = 0.0001 (0)

G(d) de Getis y Ord

El estadístico G(d) de Getis-Ord (1992), es una **medida local** de autocorrelación espacial que **evalúa la concentración de valores altos o bajos** de una variable dentro de una distancia o vecindad específica d. El estadístico evalúa la asociación de datos comparando promedios locales y globales. A diferencia de la I de Moran o el C de Geary, que miden la autocorrelación el G(d) de Getis-Ord **puede usarse para identificar "puntos calientes" (hot spots) o "puntos fríos" (cold spots) de concentración de valores.**

$$G(d)=\frac{\sum_i \sum_j w_{ij}(d)\cdot y_i \cdot y_j}{\sum_i \sum_j \cdot y_i \cdot y_j}$$

Donde $w_{ij}(d)$ es el elemento de la matriz de ponderaciones espaciales para una distancia o vecindad d:

- $w_{ij}(d)$ = 1 si la distancia entre las ubicaciones *i* y *j* es menor o igual a d,
- $w_{ij}(d)$ = 0 en caso contrario.

La interpretación del estadístico G(d) de Getis-Ord es la siguiente:

G(d) esperado: Bajo la hipótesis nula de aleatoriedad espacial, el valor esperado de G(d):

$$E[G(d)]=\frac{\sum_i \sum_j w_{ij}(d)}{n(n-1)}=\frac{S_0\,(d)}{n(n-1)}$$

G(d) observado > E[G(d)]: Indica una concentración de valores altos dentro de la distancia o vecindad d. Esto sugiere la presencia de un "**punto caliente**" o clúster de valores altos

G(d) observado < E[G(d)]: Indica una concentración de valores bajos dentro de la distancia o vecindad d. Esto sugiere la presencia de un "**punto frío**" o clúster de valores bajos.

G(d) observado = E[G(d)]: Indica ausencia de concentración ni de puntos fríos ni de puntos calientes

Gi y Gi* de Getis y Ord local

El estadístico Gi de Getis Ord Local (1996) se calcula para cada objeto espacial ***i*** comparando la suma local del atributo para una entidad y sus vecinos y se compara proporcionalmente con la suma de todas las entidades. Cuando la suma local es muy diferente de la esperada, y esa diferencia es demasiado grande como para ser el resultado de una opción aleatoria, se puede determinar que i es un punto caliente (y viceversa). Normalmente se representan como valores z, esto Gi – E(gi) respecto a ala desviación típica

$$Z(G_i) = \frac{\sum_{j=1}^{n} w_{ij}\, y_j \; - \bar{y}_i \sum_{j=1}^{n} w_{ij}}{\sqrt{Var(G_i)}} \quad , i \neq j$$

con

$$Var(G_i) = S_i^2 \left(\frac{(n-1)\sum_{j=1}^{n} w_{ij}^2 - \left(\sum_{j=1}^{n} w_{ij}\right)^2}{n-1} \right)$$

$$S_i^2 = \left(\frac{\sum_{j=1}^{n} y_j^2}{n-1} - \bar{y}_i^2 \right) \quad , i \neq j$$

$$\bar{y}_i = \left(\frac{\sum_{j=1}^{n} y_j}{n-1} \right) \quad , i \neq j$$

- $Z(G_i) > 0$ indica que i es un "punto caliente" de concentración
- $Z(G_i) < 0$ indica que i es un "punto frío" de concentración
- $Z(G_i) = 0$ indica que i no presenta dependencia

El estadístico G_i^* de Getis Ord Local (1996) se estima como G_i pero para todo j (i puede ser vecino de sí mismo, eliminando así el problema de aquellos objetos que no tienen vecinos, porque siempre serán vecinos de sí mismos)

A modeo de resumen:
Técnicas gráficas para detectar Autocorrelación Espacial

Entre los instrumentos gráficos destacan:

- **Visualización de distribuciones espaciales**: Mapas coropléticos en el que se representa la variable (aparecen sombreados los municipios con tonos distintos, de acuerdo con el valor que tome la variable en cada uno de ellos) y el *box map* (mapa de cuartiles) asociado.

- **Visualización de asociación espacial global**: El *scatterplot* de Moran y su *scatter map* asociado.

- **Visualización de asociación espacial local**: mapas LISA-Local Indicator of Spatial Association

- **Heterogeneidad espacial**: mapa, histograma de frecuencias, diagrama de dispersión

Análisis de Regresión espacial

La I de Morán, la C de Geary o la G de Getis-Ord son **medidas univariantes** de autocorrelación espacial. Para la **modelización multivariante** de datos espaciales necesitamos recurrir a los denominados modelos de regresión espacial, modelos predictivos espaciales o modelos de econometría espacial

El objetivo es formular un modelo multivariante capaz de modelizar o captar la heterogeneidad espacial y la dependencia espacial:

- **Heterogeneidad Espacial**: el valor de una variable y en diferentes ubicaciones del espacio (en diferentes objetos espaciales) es heterogéneo, y dependen fundamentalmente de las características propias de cada ubicación que actuarán como variables explicativas x del modelo (por eso estos modelos se asemejan a los modelos de regresión con datos de sección cruzada).

- **Dependencia Espacial**: el valor de una variable y en diferentes ubicaciones depende no sólo del valor de las variables explicativas x propias de cada ubicación, también depende del valor que tomen las variables "alrededor" de la ubicación, en sus ubicaciones vecinas o cercanas. Es decir presentan dependendencia espacial

Adicionalmente se podría añadir el **efecto de la dependencia temporal**, es decir, que el valor de una variable también dependa del valor que tomen las variables en una misma ubicación, pero en un instante anterior en el tiempo. Serían los **modelos espacio-temporales**, que cuando se consideran ubicaciones fijas en el tiempo se asemejan a los **modelos espaciales de datos de panel**

Modelos de Regresión: Análisis de la asociación entre una variable Objetivo (Y) y una o varias variables explicativas (X)

Cuando el **análisis exploratorio de la Variable Y muestra la existencia de dependencia ESPACIAL** es necesario que el modelo explique dicha dependencia espacial.

Toda la dependencia espacial de la variable Y que no sea explicada por el modelo quedará reflejada en los RESIDUOS

La diagnosis del modelo:

¿Son los residuos un Ruido Blanco?
¿se distribuyen con media cero, varianza constante?
¿ están distribuidos aleatoriamente por el espacio?, es decir, sin dependencia espacial (ruido blanco espacial).

Cuando el modelo no es capaz de explicar la dependencia espacial de la variable Y (los residuos presentan autocorrelación espacial), **será necesario incluir dicha dependencia espacial de forma explícita en el modelo econométrico hasta que los residuos sea ruido blanco** (se distribuyan de manera aleatoria por todo el territorio).

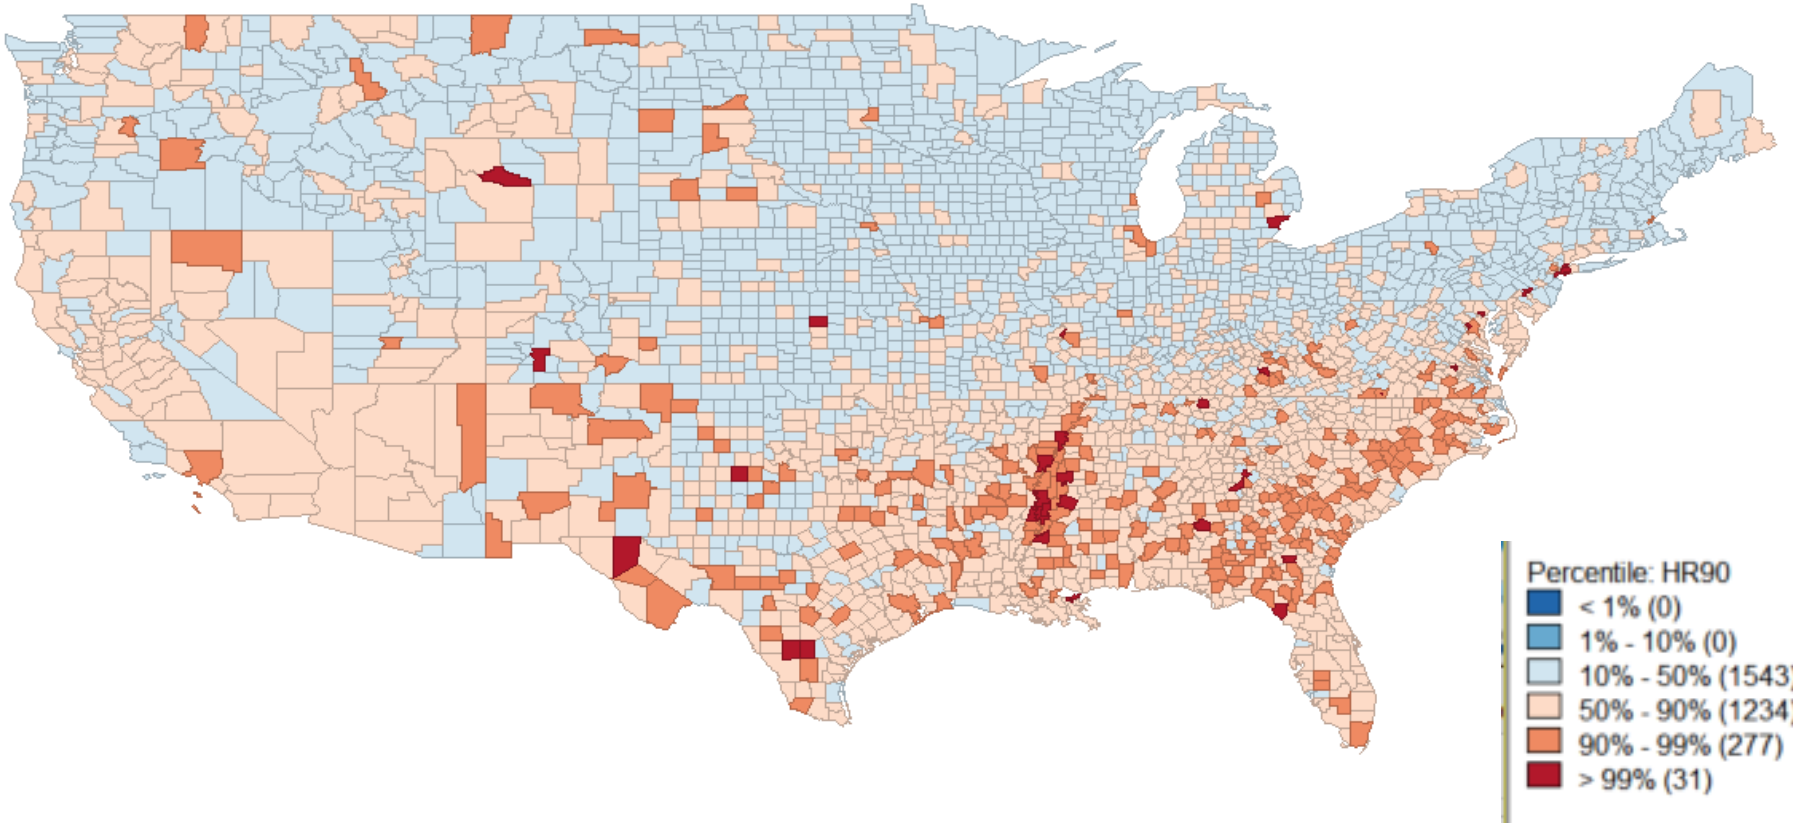
Ejemplo: Vamos a construir un modelo para intentar explicar la tasa de Homicidios, que sabemos que se encuentra autocorrelacionada espacialmente

```
        Moran I test under randomisation

data:  NAT$HR90
weights: W

Moran I statistic standard deviate = 35.703, p-value < 2.2e-16
alternative hypothesis: greater
sample estimates:
Moran I statistic       Expectation          Variance
     0.3833136112     -0.0003242542      0.0001154636
```

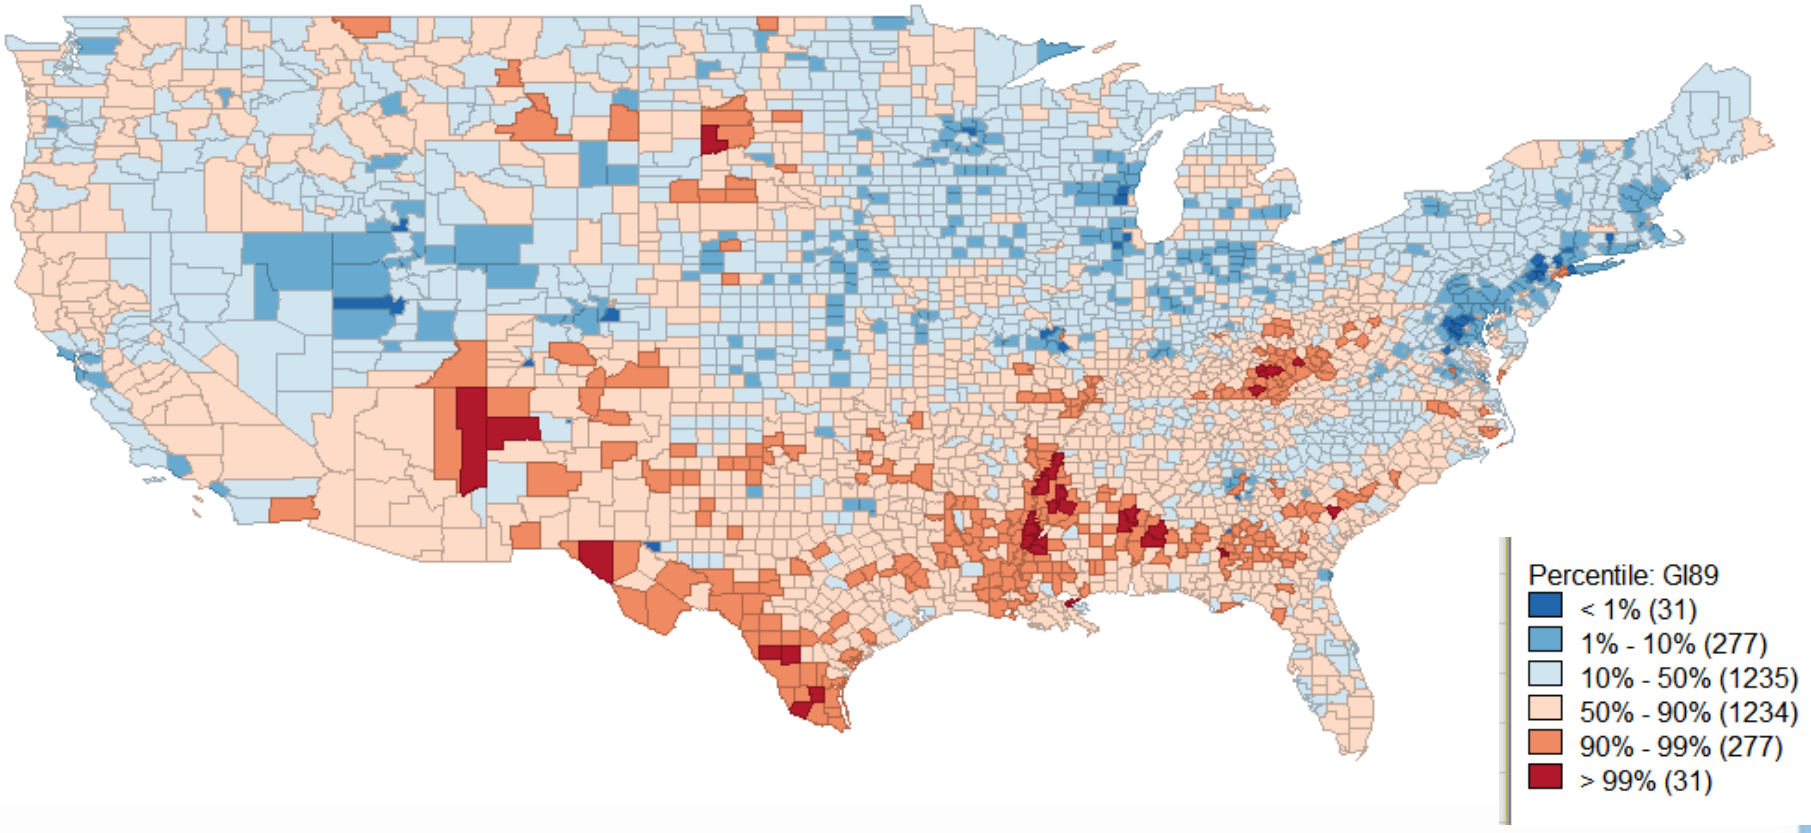
Homicide rate per 100,000 (1990)



Como Variable explicativa de los homicidios vamos a utilizar el índice de GINI

$$Homicidios_j = b0 + b1*Gini_j + u_j$$

Gini index of family income inequality in 1990



Como Variable explicativa de los homicidios vamos a utilizar el índice de GINI

$$Homicidios_j = b0 + b1*Gini_j + u_j$$

```
Call:
lm(formula = HR90 ~ GI89, data = NAT@data)

Residuals:
    Min      1Q  Median      3Q     Max
-13.936  -3.698  -0.936   2.608  65.412

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  -26.798      1.118  -23.97   <2e-16 ***
GI89          88.017      2.970   29.64   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 5.86 on 3083 degrees of freedom
Multiple R-squared:  0.2217,    Adjusted R-squared:  0.2215
F-statistic: 878.3 on 1 and 3083 DF,  p-value: < 2.2e-16
```

La diagnosis del modelo: ¿Explica el índice de Gini la tasa de Homicidios?¿Y explica también su estructura de autocorrelación espacial?¿son los residuos del modelo un ruido blanco? ¿tienen los residuos un patrón espacial?: I de moran sobre los residuos de un modelo de regresión lineal

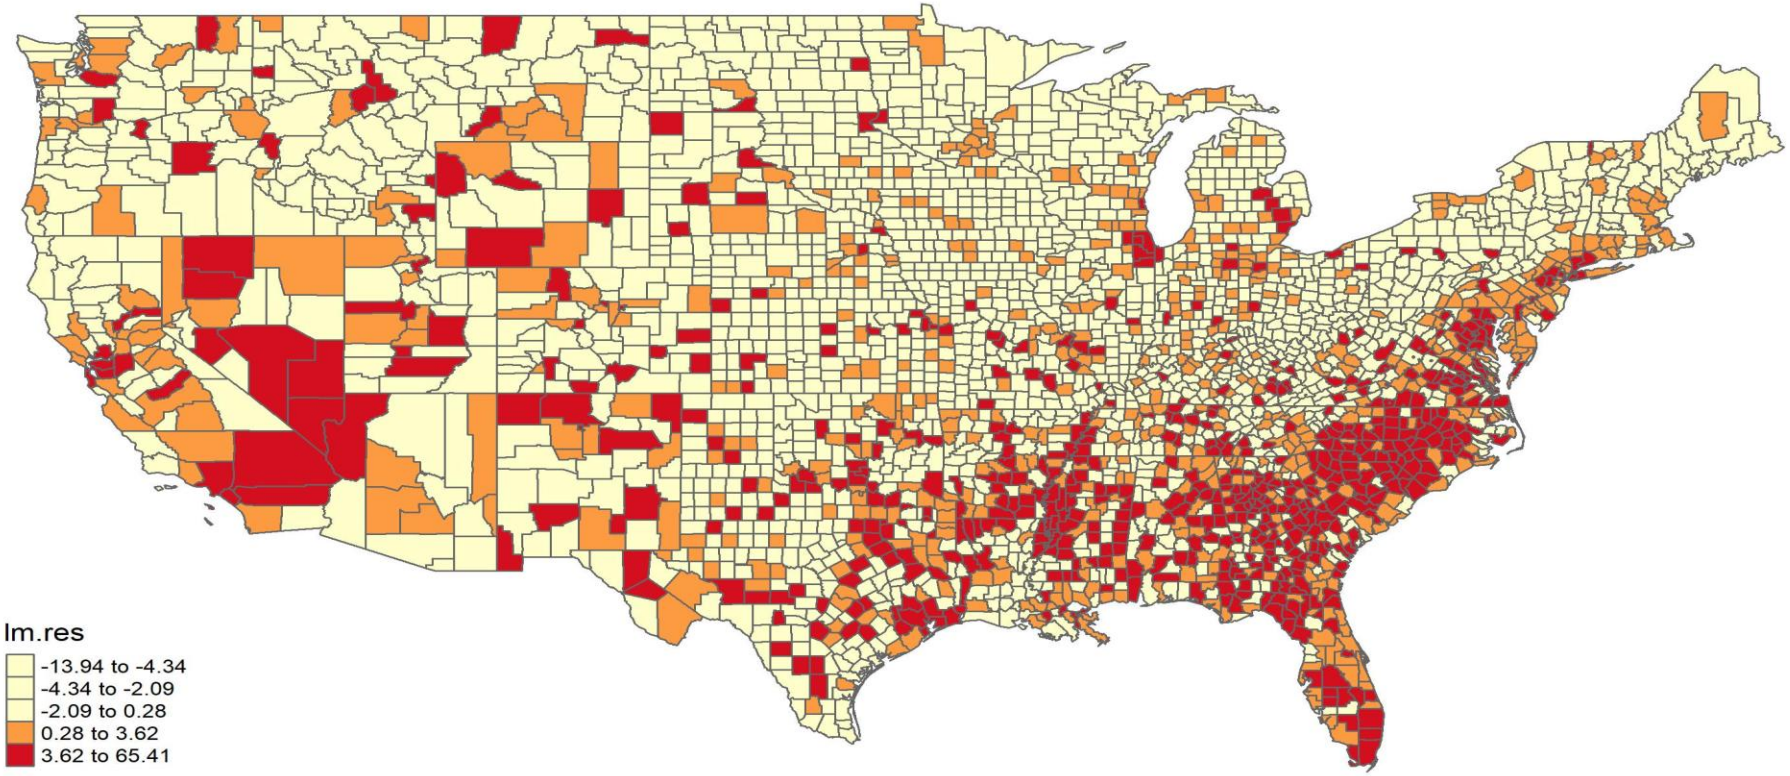
Residuos del modelo de regresión lineal

Test de I de Moran sobre los Residuos del modelo de regresión lineal

```
        Global Moran I for regression residuals

data:
model: lm(formula = HR90 ~ GI89, data = NAT@data)
weights: W

Moran I statistic standard deviate = 27.121, p-value < 2.2e-16
alternative hypothesis: two.sided
sample estimates:
Observed Moran I      Expectation         Variance
    0.2911628429    -0.0005320636     0.0001156769
```



Autocorrelación Espacial en el modelo de regresión

Primero Se analiza la dependencia espacial en la variable dependiente.

Segundo Estimamos el modelo sin tener en consideración la dependencia espacial (típicamente analizando la heterocedasticidad). Se analizan los residuos y con un test de Moran (u otra medida univariante) se contrasta la hipótesis de ausencia de dependencia espacial en los residuos del modelo. En caso de que se rechace pasamos a la siguiente fase

Tercero: modelización de la dependencia espacial... **¿y como se hace?**

La **dependencia espacial** significa que el valor de la variable dependiente en una ubicación depende de **lo que esté pasando alrededor** de dicha ubicación

¿cómo se incorpora la dependencia espacial en la modelización?:

Solución: **mediante la matriz de pesos espaciales normalizadas por filas**

$$W = \begin{pmatrix} w_{11} & w_{12} & \cdots & w_{1n} \\ w_{21} & w_{22} & \cdots & w_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ w_{n1} & w_{n2} & \cdots & w_{nn} \end{pmatrix}$$

Autocorrelación Espacial en el modelo de regresión

Una vez detectada la presencia de Autocorrelación Espacial a nivel **univariante**, comprobamos si esta **dependencia espacial está presente en el modelo de regresión**:

- **Sustantiva**: Si se omite erróneamente el **retardo espacial de la variable endógena** (Wy) y/o **exógenas** (WX), se traslada al término de error que pasaría a estar autocorrelacionado espacialmente.

Solución: incluir en el modelo un retardo espacial de la variable endógena o exógena correlacionada espacialmente.

- **Residual**: omisión de variables no relevantes que están correlacionadas espacialmente o la existencia de errores de medida.

Solución: Modelización explícita del esquema de dependencia espacial en el término de error.

En general

- Estos modelos de regresión espacial NO pueden estimarse por MCO porque los estimadores son inconsistentes.
- Hay que utilizar máxima verosimilitud, variables instrumentales (MC2E) o el método generalizado de los momentos (GMM) p ,áxima verosimilitud, utilizando como instrumentos los retardos espaciales del resto de variables explicativas.
- Además, debe estimarse consistentemente la verdadera matriz de varianzas-covarianzas de los estimadores.

Modelos de regresión espacial

- 1) **Modelo con retardo espacial** en la variable dependiente (SLM/SLAG) o **modelo espacial autorregresivo** (**SAR**):

$$\boldsymbol{y = \rho W y + X\beta + u}$$

$$\boldsymbol{u \sim N(0, \sigma^2 I)}$$

a) Parámetro autorregresivo (ρ) que recoge la intensidad de las interdependencias entre las observaciones muestrales.

b) Las estimaciones MCO serán sesgadas e inconsistentes ante la presencia de un retardo espacial en la variable endógena, aun cuando los errores no estén correlacionados espacialmente. Hay que utilizar MC2E (o métodos GM) utilizando como instrumentos los retardos espaciales del resto de variables Explicativas. Además deben estimarse siempre consistentemente la verdadera matriz de varianzas y covarianzas de los estimadores

- 2) Modelo espacial de Durbin (**SDM**) o modelo factor común:

$$\boldsymbol{y = \rho W y + X\beta + WX\gamma + u}$$

$$\boldsymbol{u \sim N(0, \sigma^2 I)}$$

- 3) Modelo espacial regresivo-cruzado (cross-reggresive) (**SCM**) o modelo con retardo espacial de X (**SLX**):

$$\boldsymbol{y = X\beta + WX\gamma + u}$$

$$\boldsymbol{u \sim N(0, \sigma^2 I)}$$

Modelos de regresión espacial

- 4) Modelo de regresión lineal con error autorregresivo espacial o **modelo de error espacial** (**SEM**):

$$\boldsymbol{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{u}$$

$$\boldsymbol{u} = \boldsymbol{\lambda}\mathbf{W}\boldsymbol{u} + \boldsymbol{\varepsilon} \qquad \boldsymbol{\varepsilon} \sim \boldsymbol{N}(\mathbf{0}, \boldsymbol{\sigma}^2\mathbf{I})$$

a) Parámetro autorregresivo (λ) que recoge la intensidad de las interdependencias.
b) Ante la presencia de errores correlacionados espacialmente, las estimaciones MCO seguirán siendo insesgadas pero ineficientes porque la matriz de varianzas-covarianzas será no esférica. Debemos estimarla consistentemente.

- 5) Modelo espacial autorregresivo combinado (**SAC**) (Kelijian-Prucha model):

$$\boldsymbol{y} = \boldsymbol{\rho}\boldsymbol{W_1}\boldsymbol{y} + \boldsymbol{X}\boldsymbol{\beta} + \boldsymbol{u}$$

$$\boldsymbol{u} = \boldsymbol{\lambda}\boldsymbol{W_2}\boldsymbol{u} + \boldsymbol{\varepsilon} \qquad \boldsymbol{\varepsilon} \sim \boldsymbol{N}(\mathbf{0}, \boldsymbol{\sigma}^2\mathbf{I})$$

Podemos suponer:

$$\mathbf{W_1} = \mathbf{W_2} = \mathbf{W}$$

- 6) Modelo de error espacial de Durbin (**SDEM**):

$$\boldsymbol{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{W_1}\mathbf{X}\boldsymbol{\gamma} + \boldsymbol{u}$$

$$\boldsymbol{u} = \boldsymbol{\lambda}\boldsymbol{W_2}\boldsymbol{u} + \boldsymbol{\varepsilon} \qquad \boldsymbol{\varepsilon} \sim \boldsymbol{N}(\mathbf{0}, \boldsymbol{\sigma}^2\mathbf{I})$$



Modelos de regresión espacial

- 7) General Nesting Spatial Model (**GNSM**) (Manski model):

$$\boldsymbol{y} = \rho \boldsymbol{W_1 y} + \mathbf{X\beta} + \boldsymbol{W_2 X\gamma} + \boldsymbol{u}$$

$$\boldsymbol{u} = \boldsymbol{\lambda W u} + \boldsymbol{\varepsilon} \qquad \boldsymbol{\varepsilon} \sim \boldsymbol{N}(\mathbf{0}, \boldsymbol{\sigma}^2 \mathbf{I})$$

Podemos suponer:

$$\mathbf{W_1} = \mathbf{W_2} = \mathbf{W}$$

a) A partir del modelo **GNSM** podemos obtener los anteriores imponiendo restricciones sobre los parámetros: λ=0, ρ=0, y θ=0.

- 8) Modelo espacial autorregresivo y media móvil (**SARMA**):

$$\boldsymbol{y} = \rho \boldsymbol{W_1 y} + \mathbf{X\beta} + \boldsymbol{u}$$

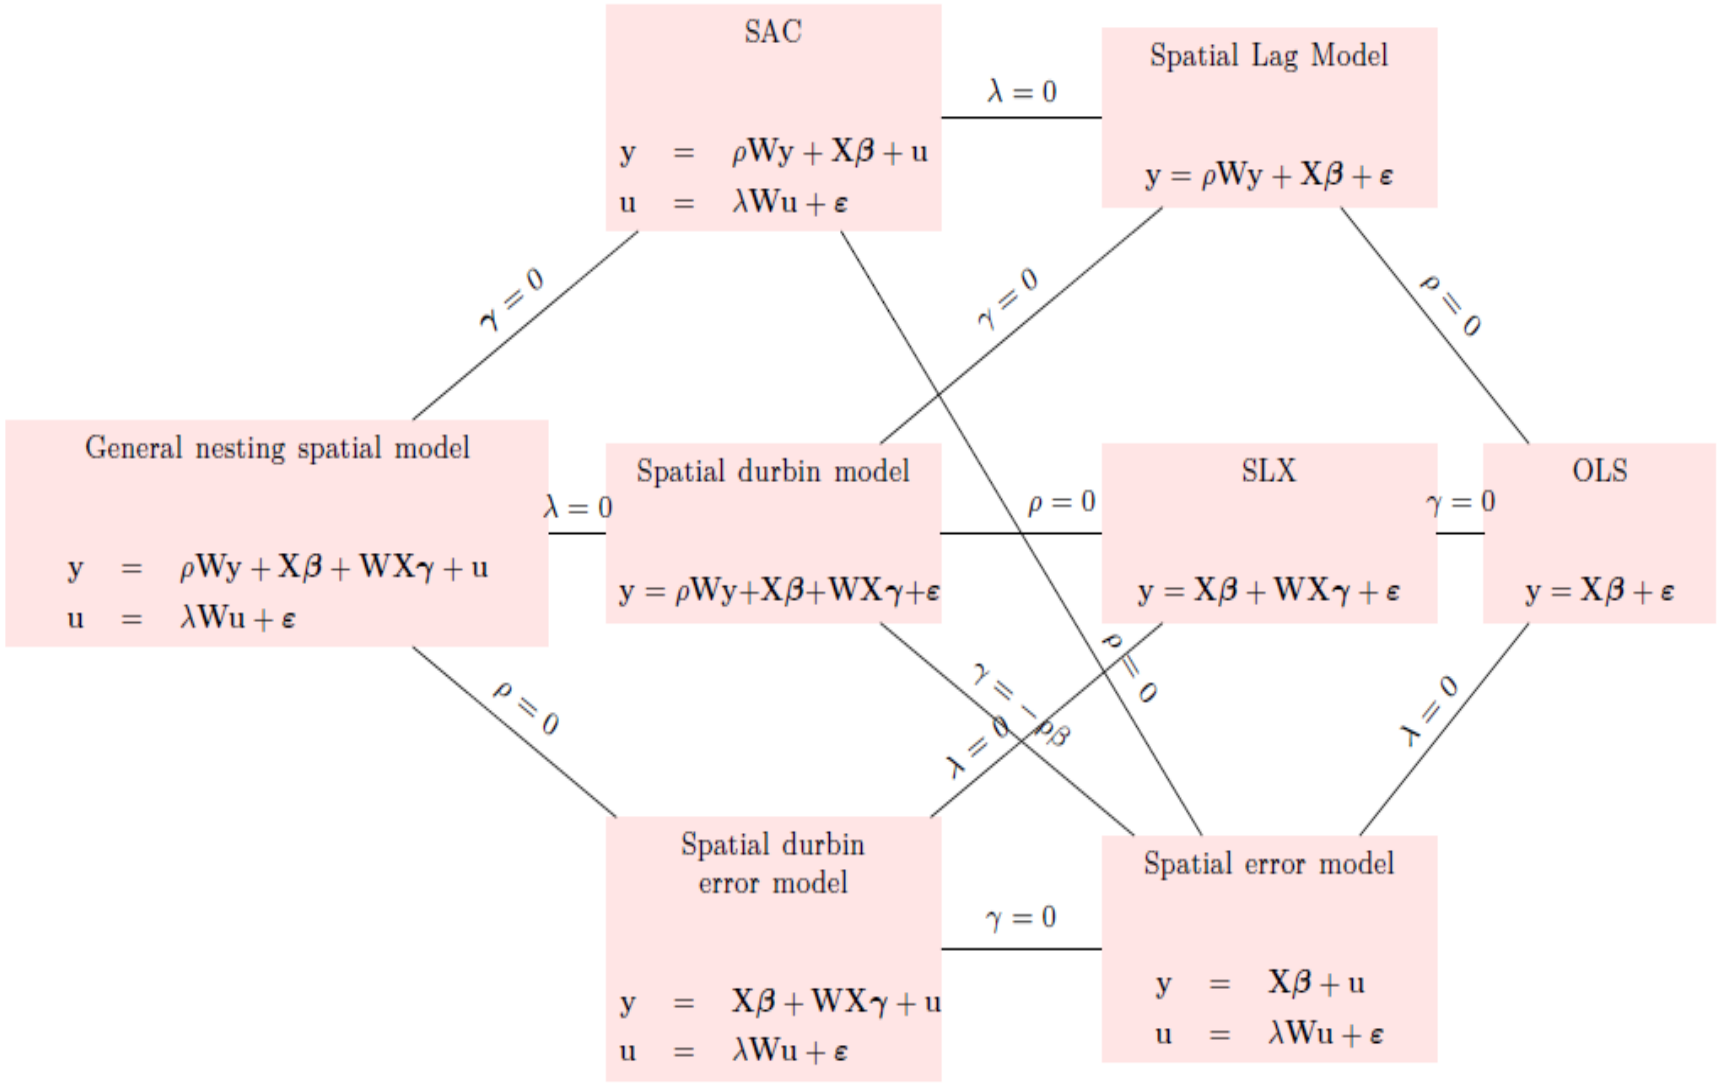
$$\boldsymbol{u} = \boldsymbol{\varepsilon} - \boldsymbol{\theta W_2 \varepsilon} + \quad \boldsymbol{\varepsilon} \sim \boldsymbol{N}(\mathbf{0}, \boldsymbol{\sigma}^2 \mathbf{I})$$

Podemos suponer:

$$\mathbf{W_1} = \mathbf{W_2} = \mathbf{W}$$

a) La diferencia entre el modelo **SAC** y el modelo **SARMA** está en la estructura del término de error: autorregresiva vs. media móvil.



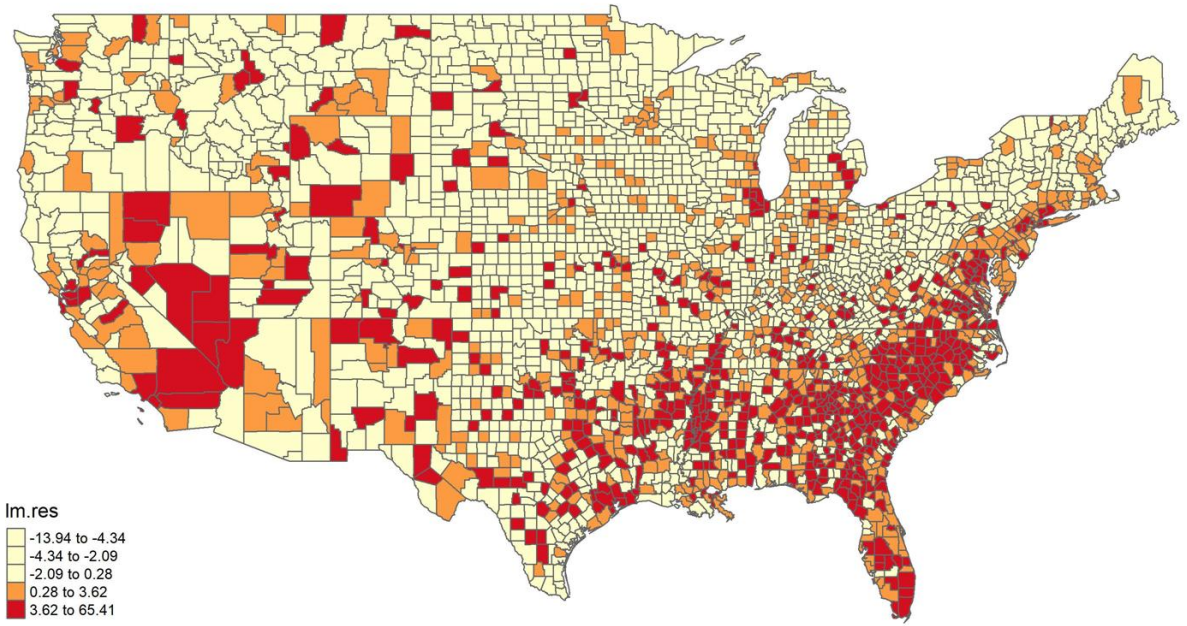

SAC
$y = \rho Wy + X\beta + u$
$u = \lambda Wu + \varepsilon$
Spatial Lag Model
$y = \rho Wy + X\beta + \varepsilon$
General nesting spatial model
$y = \rho Wy + X\beta + WX\gamma + u$
$u = \lambda Wu + \varepsilon$
Spatial durbin model
$y = \rho Wy + X\beta + WX\gamma + \varepsilon$
SLX
$y = X\beta + WX\gamma + \varepsilon$
OLS
$y = X\beta + \varepsilon$
Spatial durbin error model
$y = X\beta + WX\gamma + u$
$u = \lambda Wu + \varepsilon$
Spatial error model
$y = X\beta + u$
$u = \lambda Wu + \varepsilon$
$\lambda = 0$
$\gamma = 0$
$\gamma = 0$
$\rho = 0$
$\lambda = 0$
$\rho = 0$
$\rho = 0$
$\gamma = -\rho\beta$
$\lambda = 0$
$\rho = 0$
$\lambda = 0$
$\gamma = 0$

Residuos del Modelo Lineal

```
        Global Moran I for regression residuals

data:
model: lm(formula = HR90 ~ GI89, data = NAT@data)
weights: W

Moran I statistic standard deviate = 27.121, p-value < 2.2e-16
alternative hypothesis: two.sided
sample estimates:
Observed Moran I      Expectation         Variance
     0.2911628429     -0.0005320636      0.0001156769
```

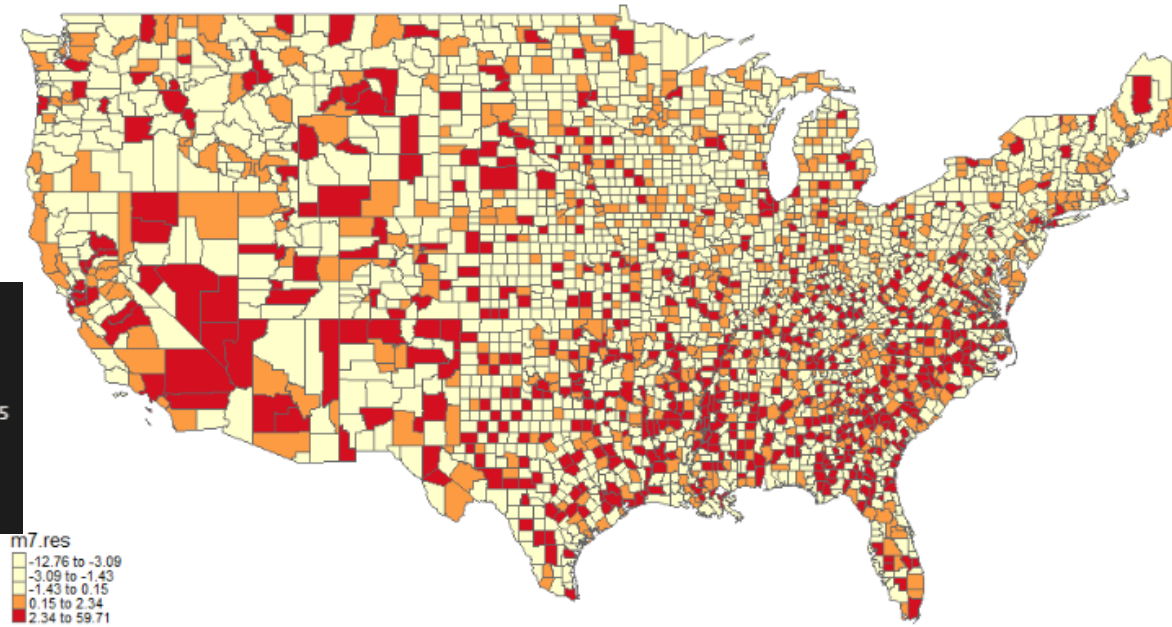


Residuos de modelo con retardo espacial

```
        Moran I test under randomisation

data:  NAT$m7.res
weights: W

Moran I statistic standard deviate = -1.4154, p-value = 0.9215
alternative hypothesis: greater
sample estimates:
Moran I statistic       Expectation          Variance
     -0.0155124064      -0.0003242542       0.0001151489
```



¿Qué especificación debemos utilizar para modelizar la dependencia espacial en un modelo de regresión?

Enfoque de LeSage & Pace: Prueba con las diferentes especificaciones y realiza siempre la diagnosis de los residuos. Quédate con el modelo para el que consigas ruido blaco espacial. Ante la duda, utiliza los Criterios de Información (BIC, AIC,...) para elegir entre diferentes especificaciones

Enfoque de L. Anselin: Una vez detectada la presencia de Autocorrelación Espacial a nivel **univariante**, comprobamos si esta **dependencia espacial está presente en el modelo de regresión de manera sustantiva o residual con una batería de test de Multiplicadores de Lagrange (LM)**:

- **Sustantiva**: Si se omite erróneamente el **retardo espacial de la variable endógena** (Wy) y/o **exógenas** (WX), se traslada al término de error que pasaría a estar autocorrelacionado espacialmente.
  Solución: incluir en el modelo un retardo espacial de la variable endógena o exógena correlacionada espacialmente.

- **Residual**: omisión de variables no relevantes que están correlacionadas espacialmente o la existencia de errores de medida.
  Solución: Modelización explícita del esquema de dependencia espacial en el término de error.

Contrastes de las diferentes especificaciones

Enfoque de L. Anselin

$$\begin{cases} \boldsymbol{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{u} \\ \boldsymbol{u} = \boldsymbol{\lambda}\mathbf{W}\boldsymbol{u} + \boldsymbol{\varepsilon} \qquad \boldsymbol{\varepsilon} \sim \boldsymbol{N}(\mathbf{0}, \boldsymbol{\sigma}^2\mathbf{I}) \end{cases}$$

$$H0\colon \lambda = 0; \quad H1\colon \lambda \neq 0$$

- **LM-ERR**:

H0: No hay AE *residual*
H1: Sí hay AE residual
con errores homocedásticos y ausencia de AE sustantiva

- **LM-ERR-HET:**

H0: No hay AE *residual*
H1: Sí hay AE residual
con errores heterocedásticos y ausencia de AE sustantiva

- **RLM-ERR (LM-EL)**:

H0: No hay AE *residual*
H1: Sí hay AE residual
con errores homocedásticos y robustos a AE sustantiva

AE: Autocorrelación Espacial

Contrastes de las diferentes especificaciones

$$\begin{cases} \boldsymbol{y = \rho W y + X\beta + u} \\ \boldsymbol{u \sim N(0, \sigma^2 I)} \end{cases}$$

$$H0\colon \rho = 0; \quad H1\colon \rho \neq 0$$

- **LM-LAG**:

H0: No hay AE *sustantiva*
H1: Sí hay AE sustantiva
con errores homocedásticos y ausencia de AE residual

- **RLM-LAG (LM-LE)**:

H0: No hay AE *sustantiva*
H1: Sí hay AE sustantiva
con errores homocedásticos y robustos AE residual

$$\begin{cases} \boldsymbol{y = \rho W_1 y + X\beta + u} \\ \boldsymbol{u = \lambda W_2 u + \varepsilon} \quad \boldsymbol{\varepsilon \sim N(0, \sigma^2 I)} \end{cases}$$

es posible que:
$\mathbf{W_1 = W_2 = W}$

- **LM-SAC/SARMA:**

H0: No hay AE
H1: Existencia conjunta de ambos tipos de dependencia espacial (sustantiva y residual)

Tests ad hoc
H0: No existe **Autocorrelación espacial residual**
H1: No especifica explícitamente el DGP del término de error

LM (multiplicadores de Lagrange): Tests basados en el Principio de Máxima Verosimilitud. Especifica H0 y H1

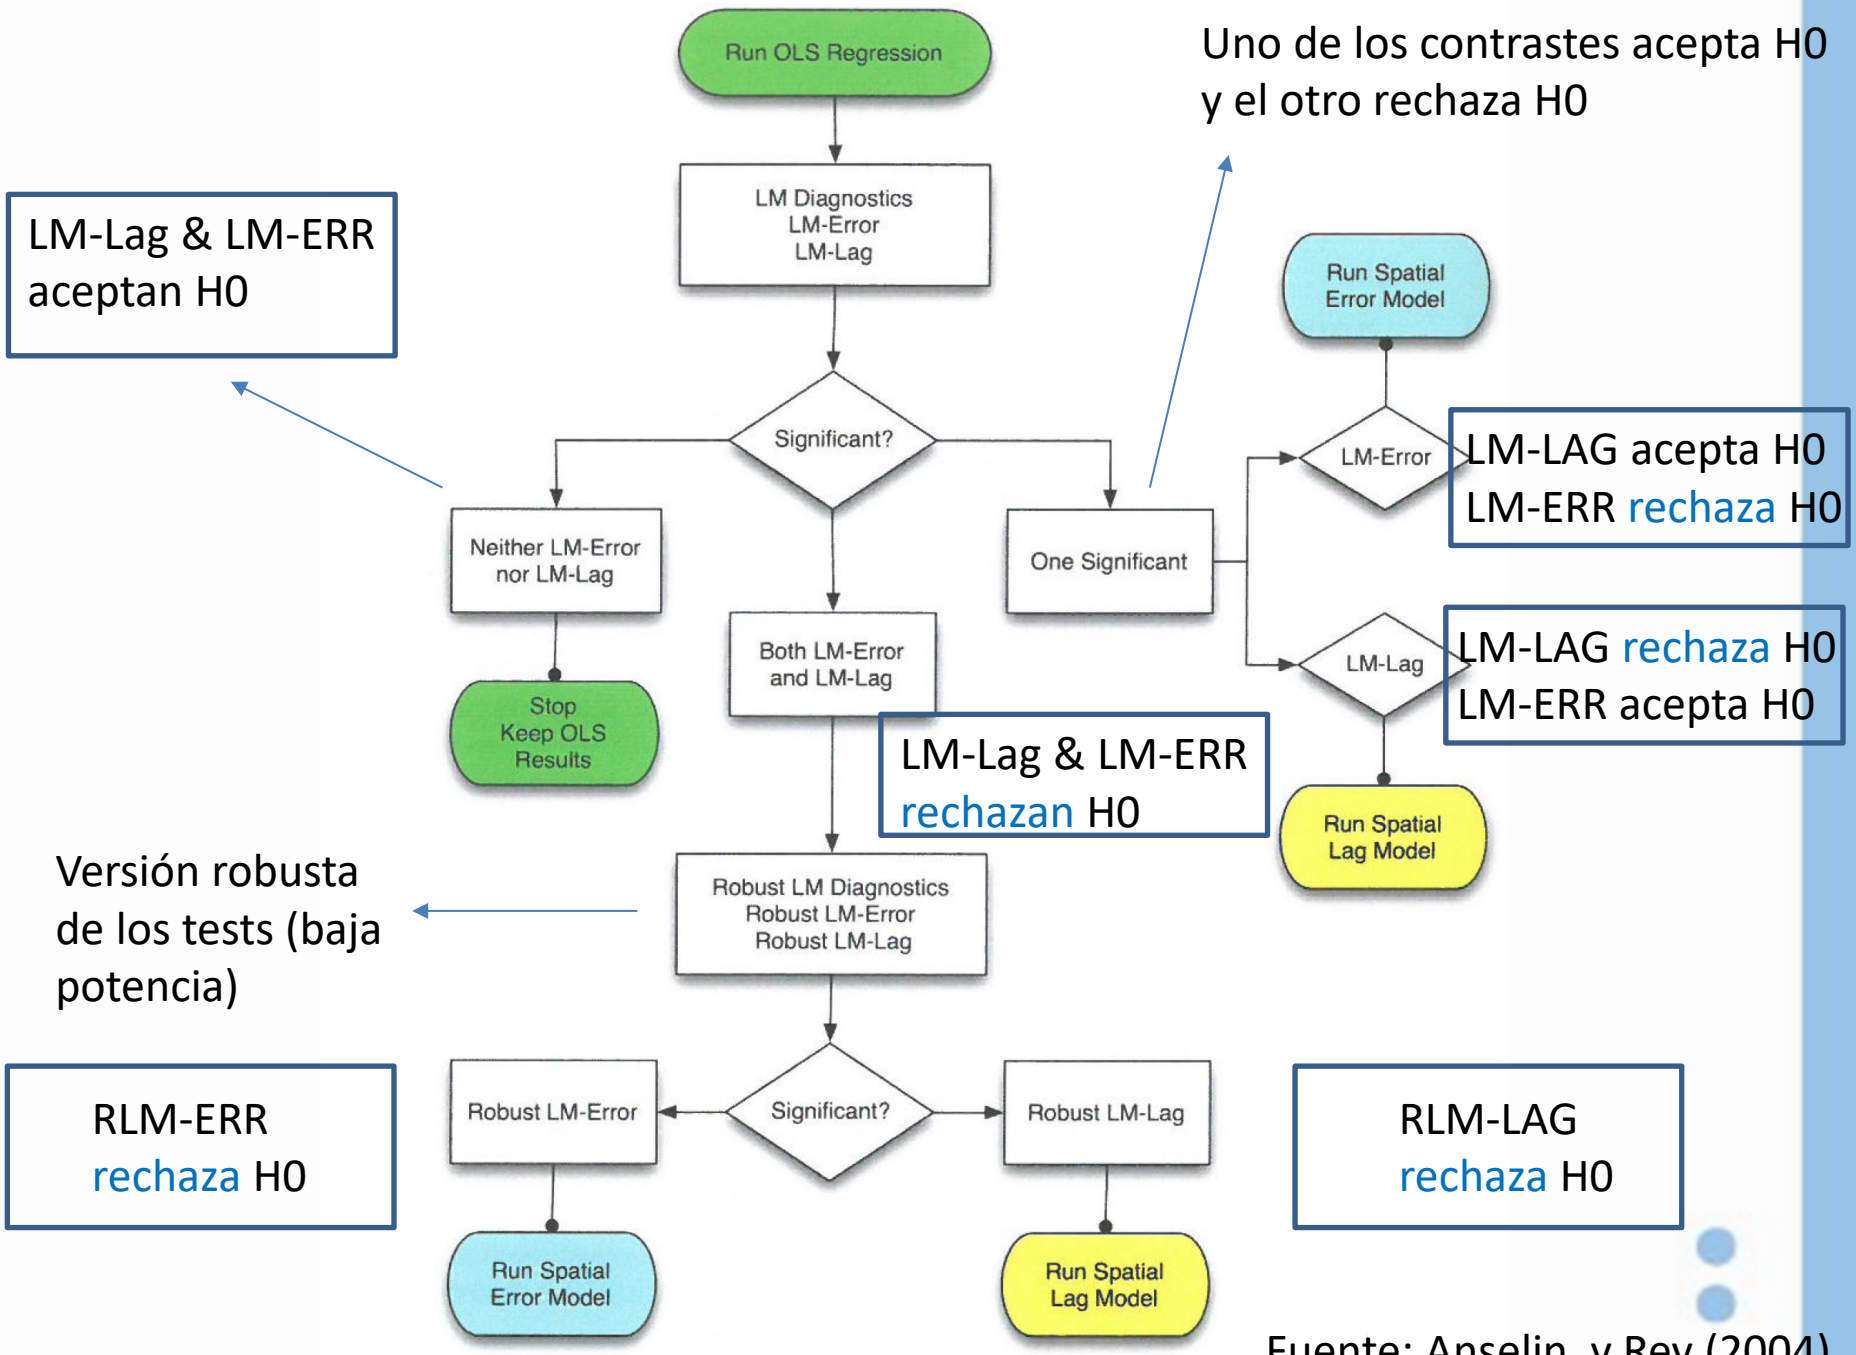
Cuadro 3. Algunos estadísticos de autocorrelación espacial en el modelo de regresión

I de Moran	$I = \frac{N}{S}\frac{e'We}{e'e}$	e: residuos MCO; N: tamaño muestral; S: suma de todos los elementos w_{ij} de la matriz W. Debe estandarizarse.
LM-ERR	$LM-ERR = \frac{\left[e'We/s^2\right]^2}{T_1} \sim \chi_1$	e: residuos MCO; s^2: estimación de la varianza residual; $T_1 = tr(W'W + W^2)$.
LM-EL	$LM-EL = \frac{\left[e'We/s^2 - T_1 (RJ_{\rho-\beta})^{-1} e'Wy/s^2\right]^2}{\left[T_1 - T_1^2 (RJ_{\rho-\beta})^{-1}\right]} \sim \chi_1$	$RJ_{\rho-\beta} = [T_1 + (WX\beta)'M(WX\beta)/s^2]$; $M = I - X(X'X)^{-1}X'$, y: var. endógena, y el resto de notación como antes.
LM-LAG	$LM-LAG = \frac{\left[e'Wy/s^2\right]^2}{RJ_{\rho-\beta}} \sim \chi_1$	Notación como antes.
LM-LE	$LM-LE = \frac{\left[e'Wy/s^2 - e'We/s^2\right]^2}{RJ_{\rho-\beta} - T_1} \sim \chi_1$	Notación como antes.

Versión LM-ERR robusta a la presencia de Wy

Versión LM-LAG robusta a la presencia de errores espaciales

Fuente Tablas: Moreno Serrano, R., Vayá Valcarce, E. (2002): Econometría espacial: nuevas técnicas para el análisis regional. Una aplicación a las regiones europeas, Investigaciones Regionales.



Fuente: Anselin y Rey (2004)

Estimación e interpretación de los parámetros

INTERPRETACION DE LOS PARAMETROS: Efectos directos e indirectos (*spillovers*)

Un cambio en una sola observación (región), asociado a cualquier variable explicativa dada, tiene:

- Un efecto en la misma región (un **impacto directo**)
- Y potencialmente, un efecto en todas las demás regiones (un **impacto indirecto**) vía el mecanismo del multiplicador espacial $(\boldsymbol{I}-\rho\boldsymbol{W})^{-1}$.

$$\begin{cases} \boldsymbol{y} = \boldsymbol{\rho W y} + \boldsymbol{X\beta} + \boldsymbol{u} \\ \boldsymbol{u} \sim \boldsymbol{N}(\boldsymbol{0}, \boldsymbol{\sigma^2 \mathrm{I}}) \end{cases}$$

$$(\boldsymbol{I}-\rho\boldsymbol{W})^{-1}\boldsymbol{y} = \boldsymbol{X\beta} + \boldsymbol{u}$$

$$\boldsymbol{y} = (\boldsymbol{I}-\rho\boldsymbol{W})^{-1}(\boldsymbol{X\beta} + \boldsymbol{u})$$

$$\frac{\boldsymbol{\partial y}}{\boldsymbol{\partial \beta}} = (\boldsymbol{I}-\rho\boldsymbol{W})^{-1}\boldsymbol{\beta}$$

Para el modelo de Durbin

$$Y = (I - \delta W)^{-1}(X\beta + WX\theta) + R$$

$$\left[\frac{\partial E(Y)}{\partial x_{1k}} \quad \cdot \quad \frac{\partial E(Y)}{\partial x_{Nk}}\right] = \begin{bmatrix} \frac{\partial E(y_1)}{\partial x_{1k}} & \cdot & \frac{\partial E(y_1)}{\partial x_{Nk}} \\ \cdot & \cdot & \cdot \\ \frac{\partial E(y_N)}{\partial x_{1k}} & \cdot & \frac{\partial E(y_N)}{\partial x_{Nk}} \end{bmatrix}$$

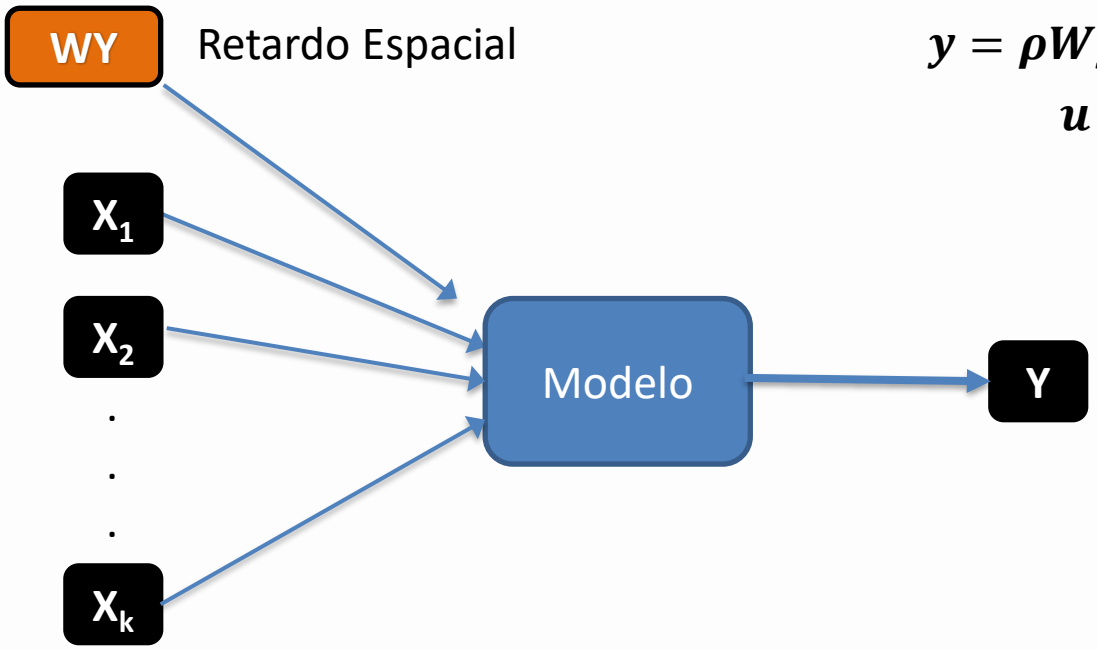
$$= (I - \delta W)^{-1} \begin{bmatrix} \beta_k & w_{12}\theta_k & \cdot & w_{1N}\theta_k \\ w_{21}\theta_k & \beta_k & \cdot & w_{2N}\theta_k \\ \cdot & \cdot & \cdot & \cdot \\ w_{N1}\theta_k & w_{N2}\theta_k & \cdot & \beta_k \end{bmatrix}$$

Table 2.1 Direct and spillover effects of different model specifications

	Direct effect	Indirect effect
OLS/SEM	β_k	0
SAR/SAC	Diagonal elements of $(I-\delta W)^{-1}\beta_k$	Off-diagonal elements of $(I-\delta W)^{-1}\beta_k$
SLX/SDEM	β_k	θ_k
SDM/GNS	Diagonal elements of $(I-\delta W)^{-1}(\beta_k + W\theta_k)$	Off-diagonal elements of $(I-\delta W)^{-1}(\beta_k + W\theta_k)$

Source Halleck Vega and Elhorst (2012)

Extensiones



¿Se podría utilizar algún otro tipo de Modelo que no sea lineal?
Modelos de machine y Deep learning espaciales
(Ojo con la validación cruzada)