ntic master School

UNIVERSIDAD COMPLUTENSE DE MADRID

cantabria labs
celebrate life

OISS
ORGANIZACIÓN IBEROAMERICANA DE SEGURIDAD SOCIAL

MRC | CONSULTANTS AND TRANSACTION ADVISERS

cecabank

BMW

AIR MILES Travel and More

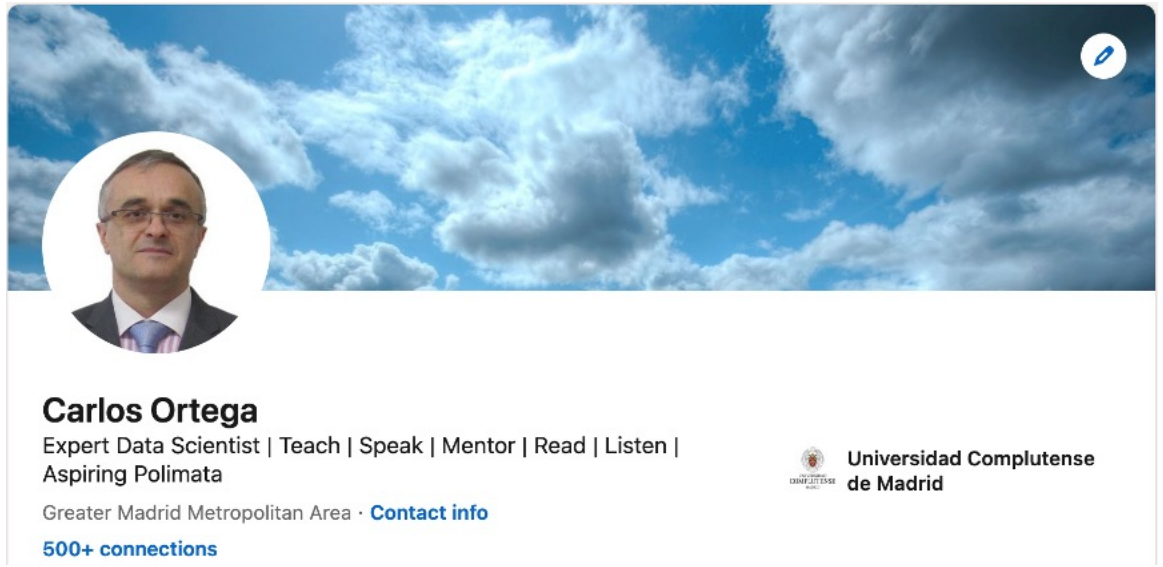

Carlos Ortega
Expert Data Scientist | Teach | Speak | Mentor | Read | Listen | Aspiring Polimata
Greater Madrid Metropolitan Area · Contact info
500+ connections
Universidad Complutense de Madrid

Santander Consumer Finance

HAVAS GROUP

Aigües de Barcelona

Santander

CaixaBank

REPSOL

Tolsa

accenture

bankinter

ENGIE

Wolters Kluwer

The Valley
Digital Business School

UNED

UNIVERSIDAD COMPLUTENSE MADRID

Afi

esic
Business & Marketing School

BANCO COOPERATIVO ESPAÑOL

MAPFRE

The Valley

ntic master
revolucionamos la comunicación

UCM
OPEN DATA

OPEN DATA

“ Making data open is not of itself a panacea for public support but it can certainly help. ”

Prof Ginny Barbour

Queensland University of Technology

Introducción

POPULARIDAD DE OPEN DATA

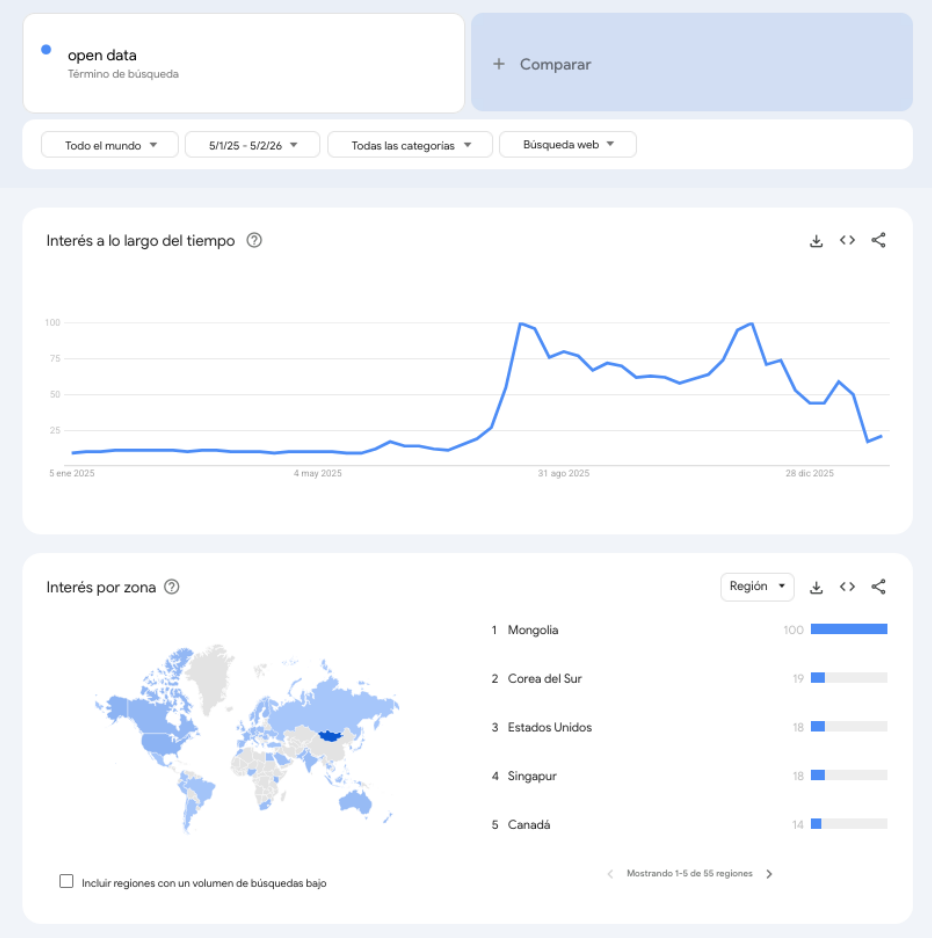

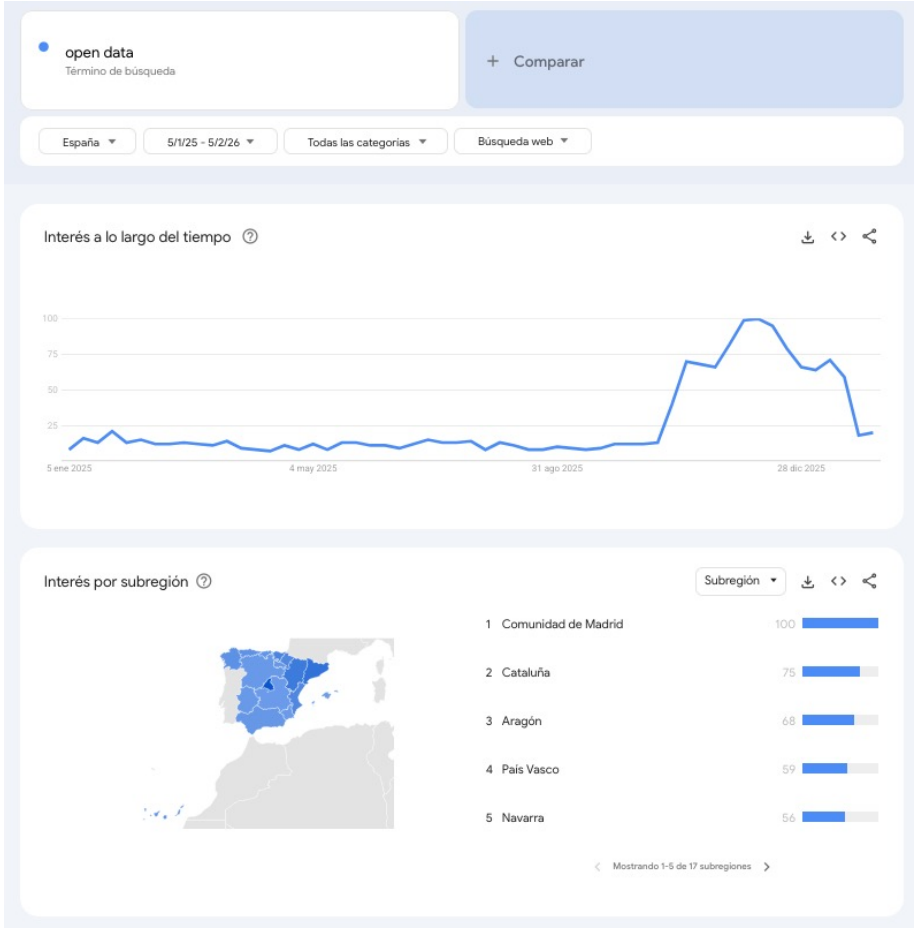

¿QUÉ ES UN DATO ABIERTO?

- Disponibilidad y Acceso: Los datos deben estar disponibles en su totalidad y no deben tener un costo de reproducción mayor al razonable, preferiblemente a través de la descarga por internet. Los datos también deben estar disponibles en una forma conveniente y modificable.
- Reutilización y Redistribución: Los datos deben ser proporcionados bajo términos que permitan la reutilización y redistribución, incluyendo su combinación con otros conjuntos de datos.
- Participación Universal: Todos deben poder utilizar, reutilizar y redistribuir los datos; no debe haber discriminación contra campos de actividad o contra personas o grupos. Por ejemplo, no se permiten restricciones "no comerciales" que impidan el uso "comercial" o restricciones de uso para ciertos fines (por ejemplo, sólo en la educación).

Fuente: Open Data Handbook Documentation, Release 1.0.0

HISTORIA DE LOS DATOS ABIERTOS

- Los orígenes de los datos abiertos se remontan al movimiento de software libre y al intercambio de información en línea en las décadas de 1980 y 1990.
- En 2003, el movimiento de datos abiertos comenzó a tomar forma con el lanzamiento del proyecto Open Archives Initiative, que estableció un estándar para la interoperabilidad de metadatos en línea.
- En 2007, el término "datos abiertos" se popularizó con el lanzamiento del Open Government Data Initiative por parte del gobierno de los Estados Unidos.

Datos Abiertos: Elementos Clave, Ventajas e Inconvenientes

Elementos Clave

- Acceso gratuito y universal
- Reutilización sin restricciones
- Legibilidad por máquina
- Formatos estándar abiertos

Ventajas

- Transparencia y rendición de cuentas
- Innovación y desarrollo económico
- Mejora de servicios públicos
- Empoderamiento ciudadano

Inconvenientes

- Riesgos de privacidad y seguridad
- Calidad y actualización variable
- Costes de mantenimiento y gestión
- Brecha digital y acceso desigual

Elementos Clave de los Datos Abiertos

1. Accesibilidad y Disponibilidad

- Descarga gratuita y directa en internet
- Sin barreras técnicas ni restricciones
- Disponibles en todo momento

2. Reutilización y Redistribución

- Bajo licencias abiertas
- Uso comercial y no comercial
- Modificación y mezcla permitidas

3. Interoperabilidad

- Formatos estándar y abiertos
- Legibles por máquina
- Integración con otros sistemas y APIs

4. Transparencia y Participación

- Rendición de cuentas
- Fomento de la participación ciudadana
- Auditoría pública y control

¿CÓMO SE GENERAN LOS DATOS ABIERTOS?

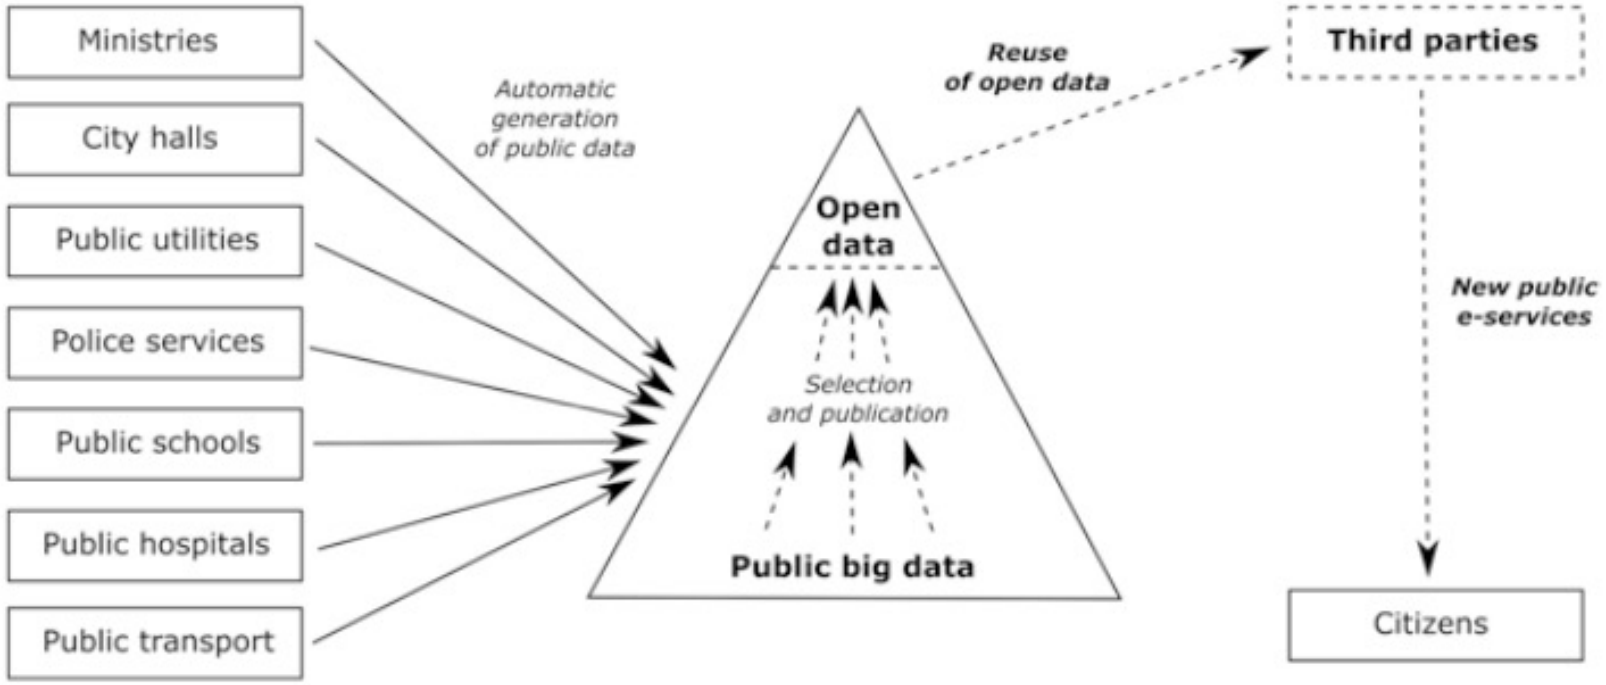

Fuente: Open Data Governance and Its Actors Theory and Practive – Maxat Kassen - 2022

DATOS ABIERTOS PERSPECTIVA GENERAL

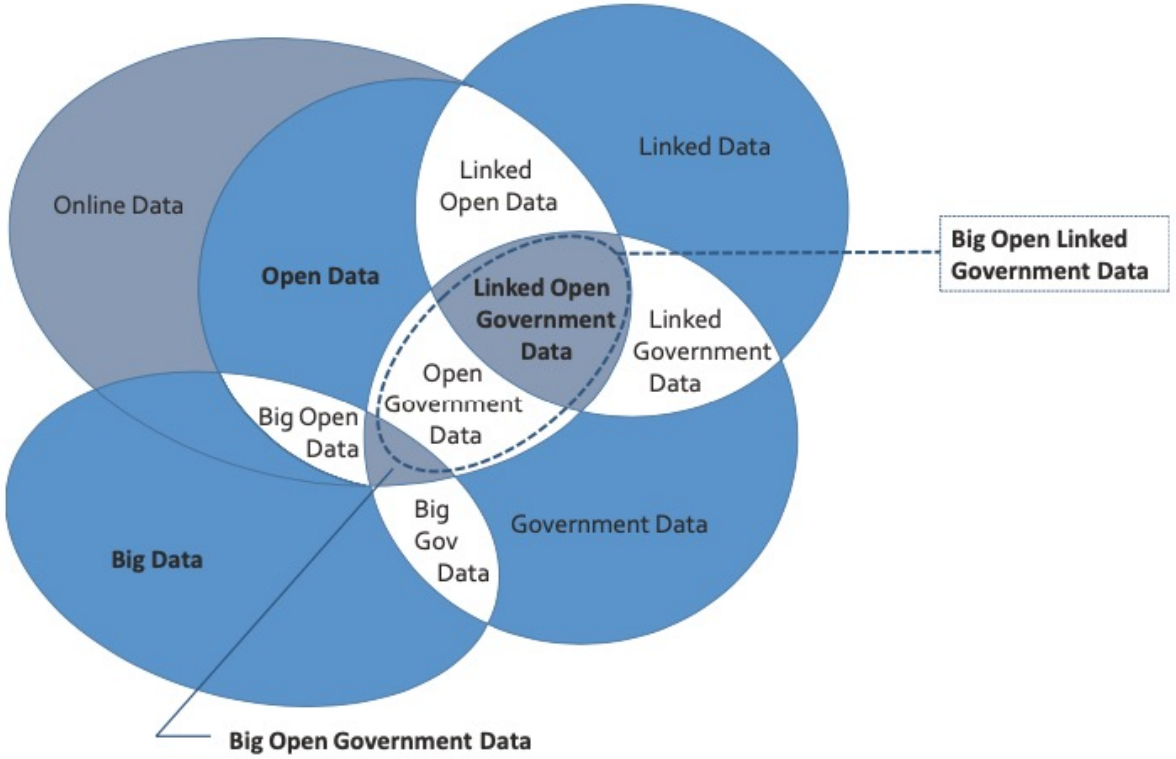

Fuente: The World of Open Data Concepts, Methods, Tools and Experiences. Springer. 2022.

Fuentes y Procedencia Habitual de los Datos Abiertos

Sector Público y Gubernamental

- Administraciones nacionales, regionales y locales
- Institutos de estadística y organismos públicos
- Servicios públicos (transporte, salud, meteorología)

Investigación y Academia

- Universidades y centros de investigación
- Organizaciones científicas (ej. CERN, NASA)
- Publicaciones y repositorios académicos

Sector Privado y Sociedad Civil

- Empresas (datos de movilidad, telecomunicaciones)
- Organizaciones sin ánimo de lucro y fundaciones
- Proyectos ciudadanos y comunidades (crowdsourcing)

¿CÓMO ASEGURAMOS QUE LOS DATOS SON ABIERTOS? (FAIR)

- (F) Encontrable - Una visión muy simplista para cumplir con este principio podría ser el simple acto de alojar los datos de investigación en una para hacerlos más fácilmente encontrables (y más accesibles, interoperables y reutilizables.
- (A) Accesible - A menudo ocurre que no se puede hacer que todos los datos de investigación estén completamente abiertos por problemas de confidencialidad.
- (I) Interoperable - Fomentar y promover el uso de vocabularios controlados comúnmente utilizados y estandarizar donde sea aplicable un enfoque estandarizado.
- (R) Reutilizable - Reutilizar estándares y técnicas de metadatos para obtener no solo eficiencias sino también una mayor claridad y calidad de (meta)datos.

¿QUÉ VENTAJAS TIENE ABRIR LOS DATOS?

- Los datos abiertos pueden aumentar la transparencia y la rendición de cuentas de las instituciones públicas.
- Los datos abiertos pueden impulsar la innovación y la creación de valor económico.
- Los datos abiertos pueden mejorar la eficiencia de los servicios públicos y la toma de decisiones informadas.

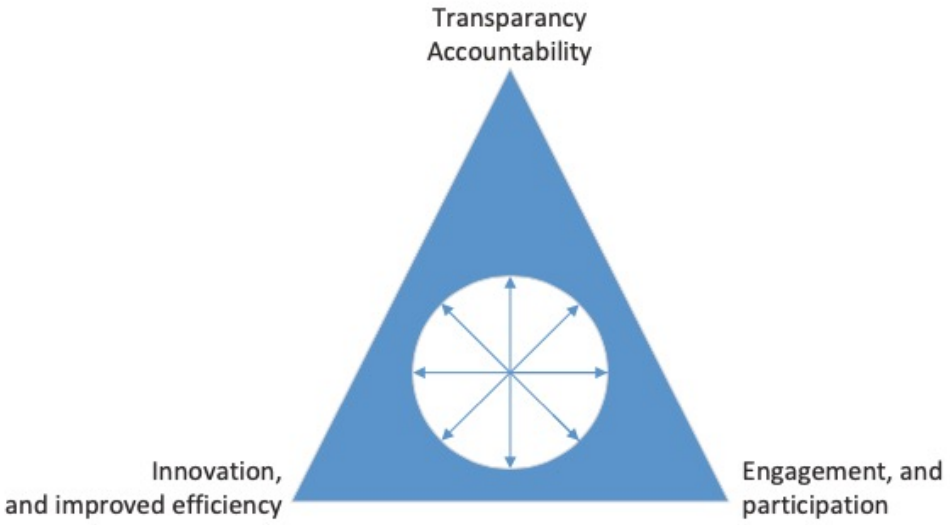

Fuente: The World of Open Data Concepts, Methods, Tools and Experiences. Springer. 2022.

¿QUÉ VENTAJAS TIENE ABRIR LOS DATOS?

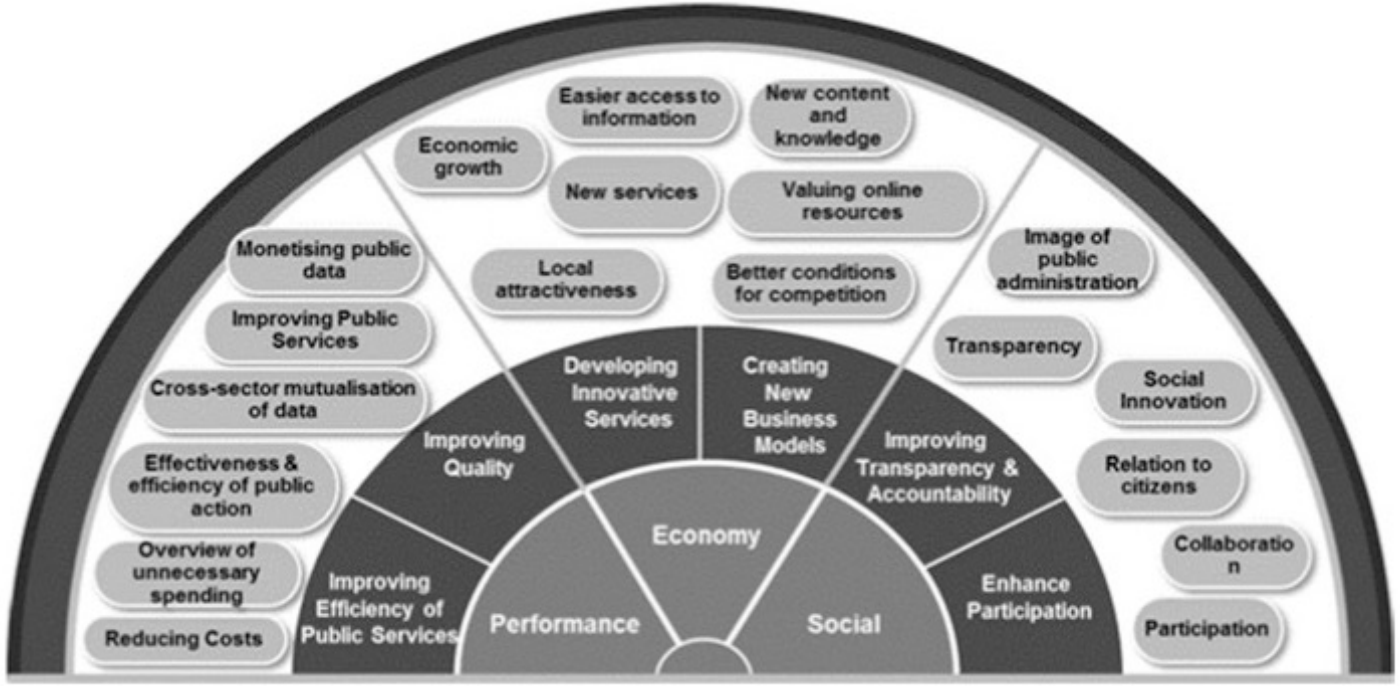

Fuente: The World of Open Data Concepts, Methods, Tools and Experiences. Springer. 2022.
Open Government Data. (https://www.europeandataportal.eu/en/ providing-data/goldbook/open-data-nutshell)

CADENA DE VALOR DE LOS DATOS ABIERTOS

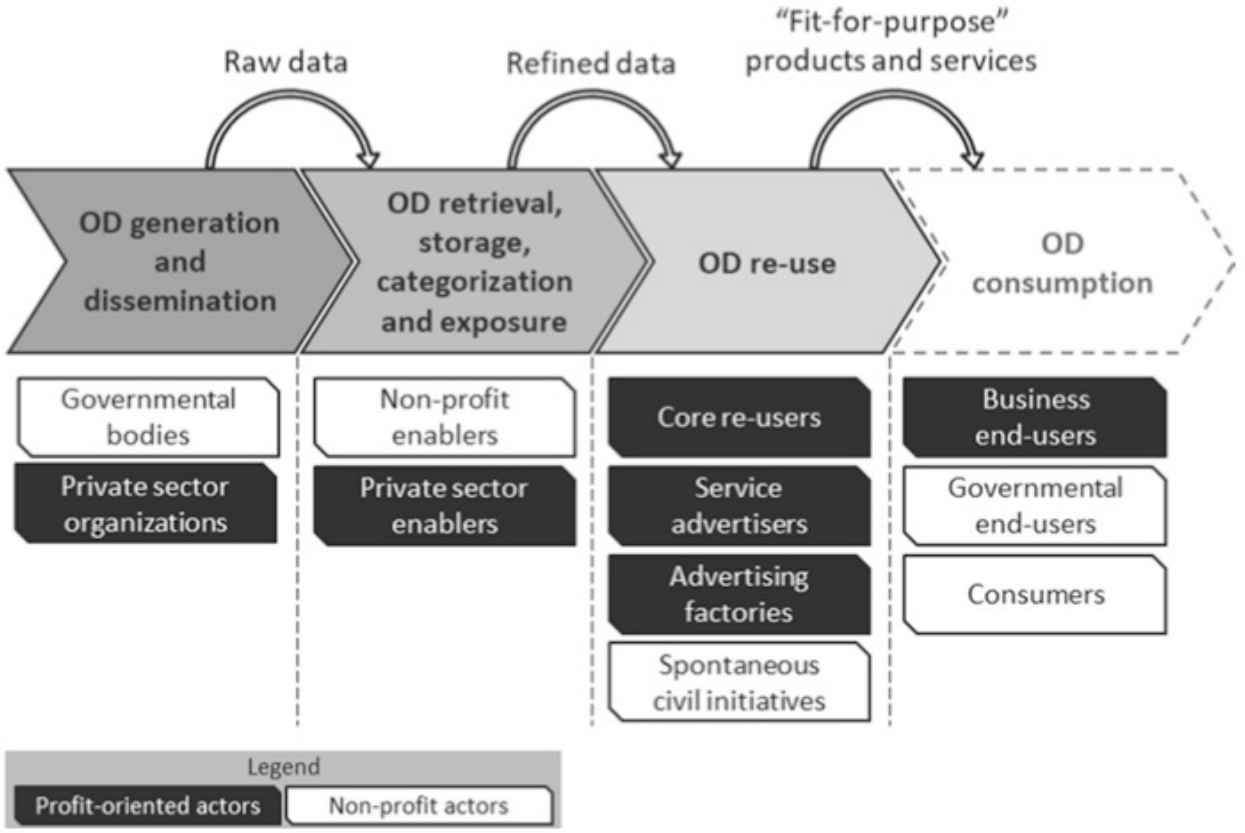

Fuente: The World of Open Data Concepts, Methods, Tools and Experiences. Springer. 2022

MERCADO DE DATOS ABIERTOS

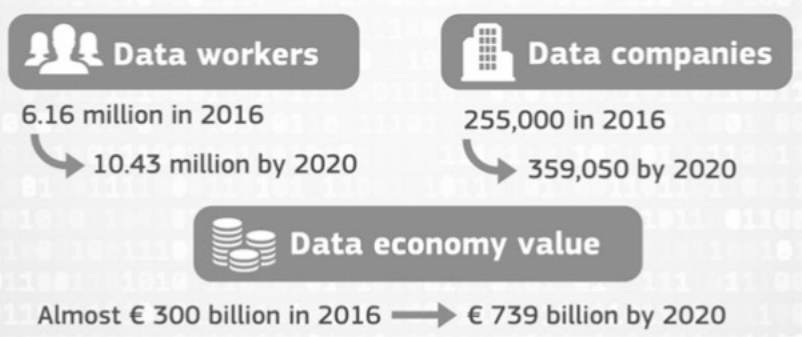

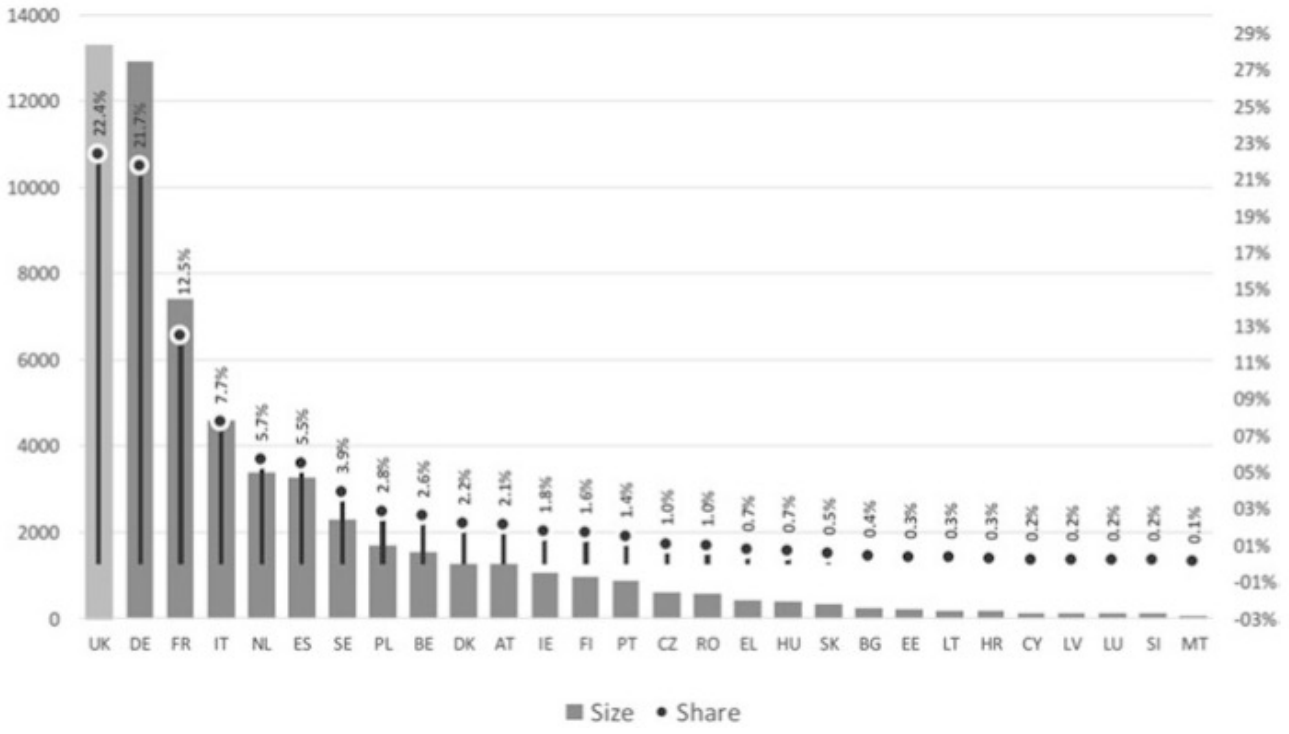

Fuente: The World of Open Data Concepts, Methods, Tools and Experiences. Springer. 2022

POTENCIAL DE REUSO POR TIPO DE DATO

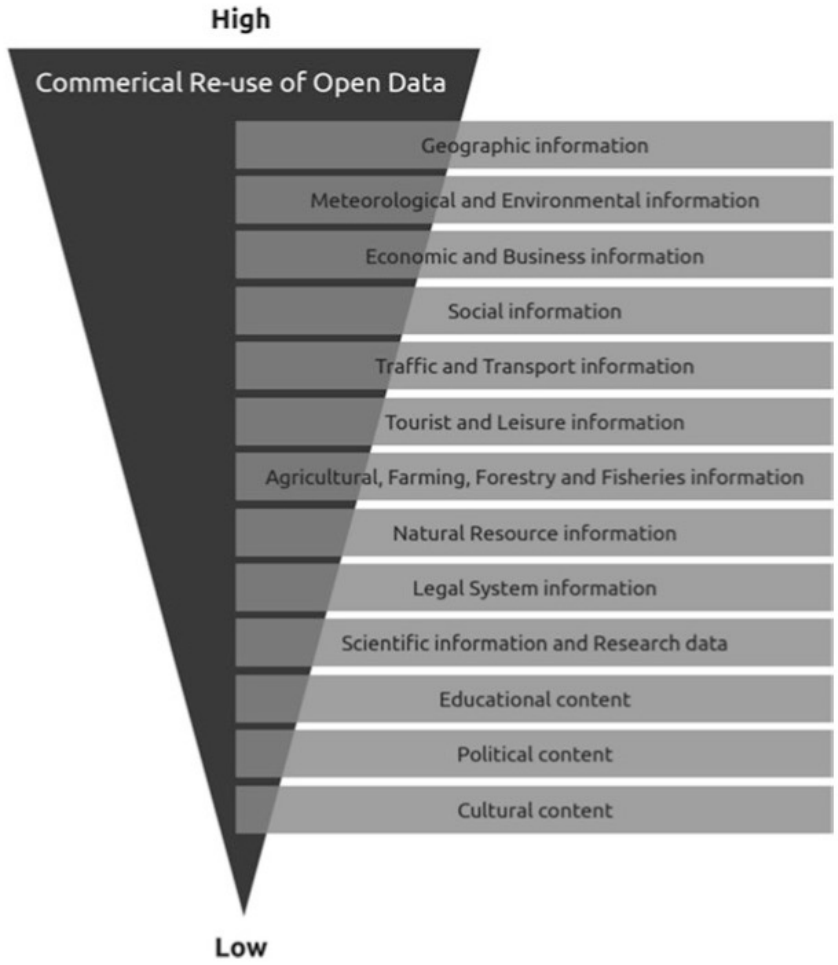

Fuente: The World of Open Data Concepts, Methods, Tools and Experiences. Springer. 2022

Jerarquía de Tipos de Datos Abiertos por Funcionalidad y Dificultad

Nivel 1: Datos Básicos y Estáticos

- Datos de referencia (Geográficos, Códigos postales)
- Estadísticas censales y demográficas históricas
- Directorios públicos de instituciones y servicios

Nivel 2: Datos Dinámicos e Intermedios

- Datos meteorológicos y ambientales en tiempo real
- Transporte público y tráfico (horarios, incidencias)
- Datos económicos y de mercado actualizados

Nivel 3: Datos Críticos y de Alto Valor

- Datos de sensores IoT y ciudades inteligentes
- Datos científicos complejos (Genómica, Física de partículas)
- Datos financieros de alta frecuencia y transaccionales

Ejemplos de empresas que usan datos abiertos en España

Empresas en España que Comercializan Valor sobre Datos Abiertos

Información Empresarial y de Crédito

- Informa D&B: Informes de riesgo y crédito basados en registros públicos
- Axesor: Inteligencia comercial a partir de datos mercantiles oficiales

Sector Inmobiliario y Geoespacial

- Idealista / Fotocasa: Enriquecimiento de anuncios con datos catastrales y cartografía pública
- Goolzoom: Herramientas de valoración usando datos abiertos del Catastro

Movilidad y Transporte Urbano

- Citymapper / Moovit: Planificación de rutas usando datos en tiempo real de operadores públicos
- Empresas de VTC/Sharing: Optimización de flotas con datos de tráfico abierto

Nuevos Ejemplos de Empresas en España y Sectores que Utilizan Datos Abiertos

Energía y Meteorología (Renovables)

- Vortex FDC: Evaluación de recurso eólico/solar con datos meteorológicos abiertos (AEMET, Copernicus)
- Uso de modelos históricos y en tiempo real para financiación de proyectos

LegalTech y Normativa (Información Jurídica)

- vLex: Plataforma jurídica que enriquece datos abiertos del BOE, DOUE y jurisprudencia (CENDOJ)
- Aplicación de IA para interconectar y añadir valor a textos legales públicos

Inteligencia de Localización y AgroTech

- CARTO: Uso de mapas base (OSM), datos censales (INE) y cartografía (IGN) para Location Intelligence
- AgriTech: Agricultura de precisión con imágenes satelitales abiertas (Copernicus) y datos climáticos

Más Ejemplos: Innovación con Datos Abiertos en Salud, Turismo y Contratación

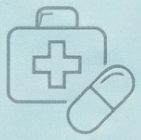

Salud Digital y Farmacia

- Vademecum: Información farmacológica basada en datos abiertos de la AEMPS (Agencia Española de Medicamentos)
- Análisis de datos abiertos sobre ensayos clínicos y epidemiología para investigación

Inteligencia en Contratación Pública (B2G)

- Gobierto / DoubleTrade: Plataformas de análisis de licitaciones y transparencia presupuestaria (PLACSP)
- Alertas y detección de oportunidades de negocio con la administración pública

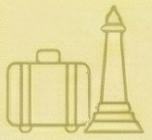

Turismo Inteligente y Cultura

- Destinos Turísticos Inteligentes (DTI): Gestión de flujos basada en datos del INE y sensores locales
- Agregadores de agendas culturales y eventos a partir de datos municipales abiertos

Tipos de Licencias

Licenciamiento de Datos Abiertos: Tipos y Consideraciones Clave

Tipos de Licencias Comunes

Permisivas (ej. CC BY, CC0)

- Uso casi sin restricciones
- Solo requiere atribución (a veces)

Copyleft / Compartir Igual (ej. CC BY-SA, ODbL)

- Requiere mismas condiciones al compartir
- Garantiza apertura futura

Elementos Clave a Considerar

- **Atribución (BY)** - Reconocer la fuente
- **Uso Comercial (NC)** - Permitido o no
- **Obras Derivadas (ND)** - Modificaciones permitidas
- **Compartir Igual (SA)** - Misma licencia

Otros Elementos Relevantes

- Compatibilidad entre licencias
- Claridad y certeza legal
- **Dominio Público** (Renuncia de derechos)
- Actualizaciones de licencia

¿QUÉ LICENCIAS SE APLICAN A LOS DATOS ABIERTOS?

- La Licencia Creative Commons es una de las licencias más populares para los datos abiertos, ya que ofrece una gran flexibilidad para permitir o restringir el uso de los datos.
- La Licencia de Dominio Público permite que los datos sean utilizados sin restricciones, pero puede no ofrecer protección legal en algunos países.
- Las licencias de código abierto, como la Licencia MIT y la Licencia Apache, pueden ser adecuadas para los datos abiertos que contienen software.

PROS Y CONS DE DIFERENTES LICENCIAS (1 / 5)

Creative Commons Zero (CC0)

- Pro: Esta licencia permite a los usuarios copiar, modificar y distribuir los datos sin restricciones, incluso con fines comerciales. La licencia garantiza que los datos están en el dominio público.
- Con: La licencia no ofrece protección legal, lo que significa que el creador original no tiene control sobre cómo se utilizan sus datos y no puede responsabilizar a los usuarios que los utilizan de manera inapropiada.

PROS Y CONS DE DIFERENTES LICENCIAS (2/ 5)

Creative Commons Attribution (CC BY)

- Pro: Esta licencia permite a los usuarios copiar, modificar y distribuir los datos siempre que se atribuya el crédito al creador original. Esto significa que los datos pueden ser utilizados de manera más amplia mientras se da reconocimiento al creador original.
- Con: La licencia no proporciona restricciones a la utilización comercial, lo que significa que los datos pueden ser utilizados con fines comerciales sin compensar al creador original.

PROS Y CONS DE DIFERENTES LICENCIAS (3/ 5)

Open Data Commons Public Domain Dedication and License (ODC PDDL)

- Pro: Esta licencia permite a los usuarios copiar, modificar y distribuir los datos sin restricciones, incluso con fines comerciales. Además, la licencia permite que el creador original renuncie a cualquier derecho de autor sobre los datos, lo que significa que los datos están en el dominio público.
- Con: La licencia no proporciona protección legal, lo que significa que el creador original no tiene control sobre cómo se utilizan sus datos y no puede responsabilizar a los usuarios que los utilizan de manera inapropiada.

PROS Y CONS DE DIFERENTES LICENCIAS (4/ 5)

Open Data Commons Attribution License (ODC BY)

- Pro: Esta licencia permite a los usuarios copiar, modificar y distribuir los datos siempre que se atribuya el crédito al creador original. Además, la licencia permite el uso comercial de los datos.
- Con: La licencia no permite a los usuarios renunciar a los derechos de autor, lo que significa que los datos siempre están sujetos a la protección legal. Esto puede restringir el uso de los datos en ciertos casos.

PROS Y CONS DE DIFERENTES LICENCIAS (5/ 5)

Open Data Commons Open Database License (ODbL)

- Pro: Esta licencia permite a los usuarios copiar, modificar y distribuir los datos siempre que se atribuya el crédito al creador original y se comparta bajo la misma licencia. Además, la licencia permite el uso comercial de los datos.
- Con: La licencia puede ser complicada de entender y aplicar, lo que puede limitar la adopción de los datos. Además, puede haber ciertas restricciones sobre cómo se pueden utilizar los datos derivados de la obra original.

Tipos de Datos
Formas de Acceso

EJEMPLOS DE DATOS ABIERTOS QUE GENERAN ALTO VALOR

- Los datos climáticos abiertos pueden ayudar a predecir y mitigar los efectos del cambio climático.
- Los datos de salud abiertos pueden mejorar la investigación médica y la atención al paciente.
- Los datos de transporte público abiertos pueden ayudar a los ciudadanos a planificar sus viajes y mejorar la movilidad urbana.

CÓMO SE PUEDEN COMBINAR LOS DATOS ABIERTOS CON DATOS PROPIETARIOS

- Los datos abiertos pueden complementar los datos propietarios, proporcionando contexto y enriqueciendo la comprensión de un problema.
- La combinación de datos abiertos y propietarios puede mejorar la eficiencia de los análisis y la toma de decisiones.
- Los datos abiertos pueden ayudar a identificar brechas o limitaciones en los datos propietarios existentes.

TIPOS DE DATOS ABIERTOS

- Los datos gubernamentales abiertos son una de las formas más comunes de datos abiertos, y pueden incluir información sobre presupuestos, elecciones, y servicios públicos.
- Los datos científicos abiertos, como los datos de investigación y las publicaciones académicas, pueden promover la colaboración y el avance del conocimiento.
- Los datos de negocios abiertos pueden incluir información financiera, de mercado y de consumo.

¿CÓMO ACCEDEMOS A DATOS ABIERTOS?

- **Portales de datos abiertos:** Muchas organizaciones gubernamentales y no gubernamentales, así como empresas, mantienen portales de datos abiertos en los que se pueden descargar conjuntos de datos en diferentes formatos. Algunos ejemplos de portales de datos abiertos son data.gov, el portal de datos abiertos del gobierno de España, y el portal de datos abiertos de la Unión Europea.

- **APIs:** Las APIs (interfaces de programación de aplicaciones) permiten el acceso a datos abiertos a través de llamadas a una interfaz de programación en lugar de descargar archivos completos. Esto puede ser útil para trabajar con conjuntos de datos grandes o en tiempo real. Muchas organizaciones gubernamentales y no gubernamentales ofrecen APIs para acceder a sus datos abiertos, como la API de clima del Servicio Nacional de Meteorología de los Estados Unidos.

- **Búsqueda en motores de búsqueda**: Los motores de búsqueda como Google también pueden ser utilizados para encontrar conjuntos de datos abiertos. Algunos sitios web especializados en datos abiertos, como data.world y Kaggle, también tienen funciones de búsqueda que permiten encontrar conjuntos de datos específicos.

Consideraciones de Uso

¿QUÉ DEBEMOS CONSIDERAR CUANDO USAMOS DATOS ABIERTOS PARA EVITAR UNA ILEGALIDAD? (1 /2)

- **Licencia:** Asegúrate de revisar la licencia bajo la cual se publican los datos abiertos. Algunas licencias, como la Creative Commons Attribution (CC BY), requieren que des crédito al creador original, mientras que otras, como la Creative Commons Zero (CC0), permiten el uso sin restricciones.

- **Uso permitido:** Revisa la información proporcionada sobre los términos y condiciones de uso del conjunto de datos. Asegúrate de que el uso que planeas darle a los datos está permitido y no infringe ningún derecho de propiedad intelectual.

- **Privacidad:** Asegúrate de que los datos no contengan información personal o confidencial que pueda comprometer la privacidad de los individuos o las organizaciones involucradas.

¿QUÉ DEBEMOS CONSIDERAR CUANDO USAMOS DATOS ABIERTOS PARA EVITAR UNA ILEGALIDAD? (2 /2)

- **Limitaciones geográficas:** Verifica si existen limitaciones geográficas que se apliquen al conjunto de datos. Algunos datos pueden estar disponibles solo para un país o región específica.

- **Actualización:** Asegúrate de que los datos estén actualizados y que la fuente de los datos sea confiable.

- **Responsabilidad:** Asegúrate de que el uso de los datos no viole ninguna ley o regulación, y que no cause daño a terceros.

Cómo abrir datos
Y su gobernanza

El Ciclo de Vida del Dato Abierto: De la Fuente al Valor

1. Generación y Captura

- Fuentes gubernamentales y sensores IoT
- Web Scraping y APIs públicas
- Datos científicos y de investigación

2. Preparación y Almacenamiento

- Limpieza, estandarización y calidad
- Catalogación y metadatos (Gobierno)
- Almacenamiento en Data Lakes/ Lakes/Warehouses

3. Análisis y Aplicación

- Analítica descriptiva y predictiva
- Entrenamiento de modelos de IA/ML
- Toma de decisiones y servicios digitales

Gobierno del Dato y Calidad: El Cimiento de la Confianza en Open Data

Fundamentos del Gobierno

- Definición de políticas, estándares y roles (Data Stewards)
- Establecer la propiedad y responsabilidad del dato
- Diccionarios de datos comunes (semántica compartida)

Procesos y Ciclo de Vida

- Catalogación exhaustiva y metadatos ricos
- Pipelines de limpieza, validación y enriquecimiento
- Gestión del ciclo de vida: creación a archivado

Valor Estratégico y Desafíos

- Confianza: Indispensable para alimentar IA fiable
- Cumplimiento Normativo: GDPR, Data Governance Act (EU)
- Desafío Cultural: Romper silos organizacionales

PASOS PARA ABRIR UN CONJUNTO DE DATOS

- Elige tu conjunto de datos. Selecciona el conjunto de datos que planeas abrir. Ten en cuenta que puedes (y puede que necesites) volver a esta etapa si encuentras problemas en una etapa posterior.
- Aplica una licencia abierta.
  - (a) Determina qué derechos de propiedad intelectual existen en los datos.
  - (b) Aplica una licencia "abierta" adecuada que otorgue licencia para todos estos derechos y que respalde la definición de apertura discutida en la sección anterior sobre "Qué son los datos abiertos".
  - (c) Nota: si no puedes hacer esto, regresa al paso 1 e intenta con un conjunto de datos diferente.
- Haz los datos disponibles - en masa y en un formato útil. También puedes considerar formas alternativas de hacerlos disponibles, como a través de una API.
- Haz que sean descubribles - publícalos en la web y quizás organiza un catálogo central para enumerar tus conjuntos de datos abiertos.

Fuente: Open Data Handbook Documentation, Release 1.0.0

PASOS PARA ABRIR UN CONJUNTO DE DATOS

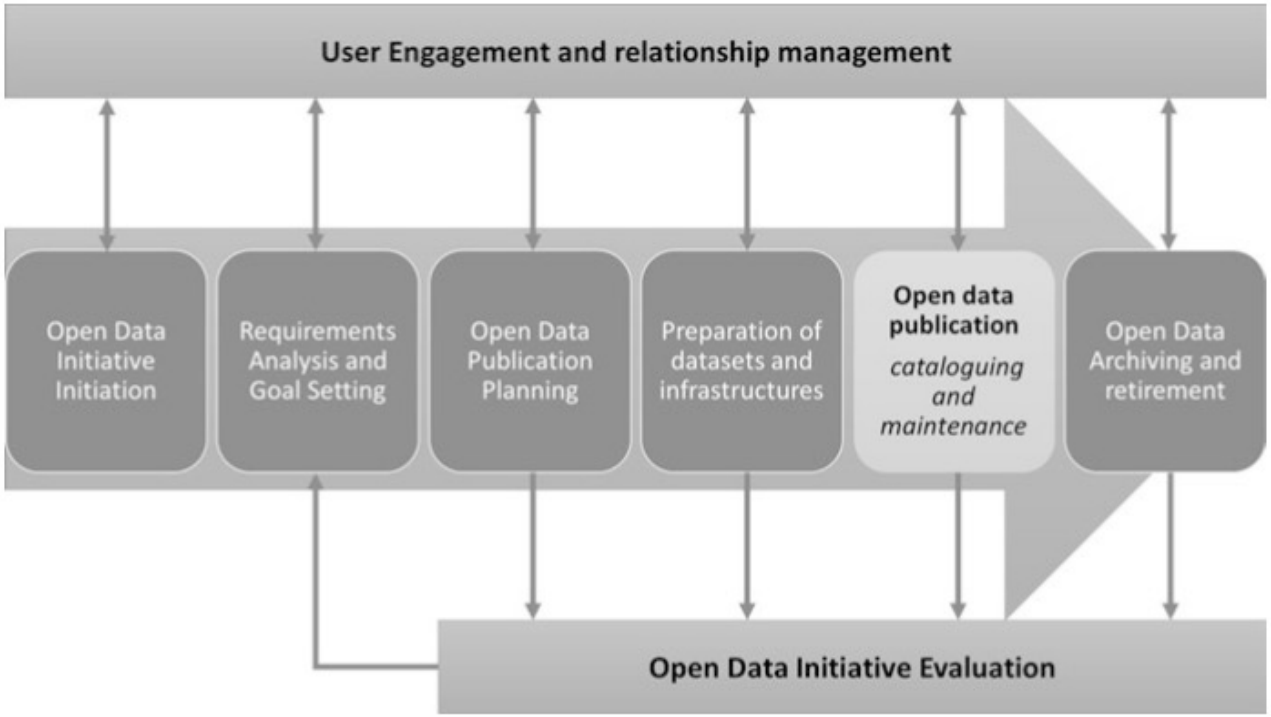

Fuente: The World of Open Data Concepts, Methods, Tools and Experiences. Springer. 2022.

PASOS PARA ABRIR UN CONJUNTO DE DATOS

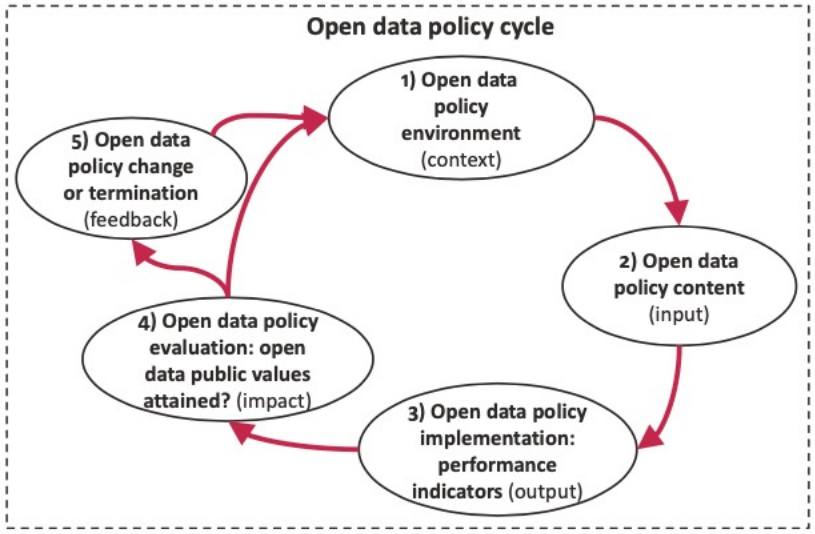

Stage 1: Policy environment (context)

- Social and demographic context
- Political context
- Economic context
- Legislation and regulatory context
- Culture and country
- Geographic level (e.g. country, region, city)
- Type of data providing organization(s)
- Mission type
- Key motivations and policy objectives
- Available resources (ICTs, human resources)
- Available open data platform
- Resource allocation

Stage 2: Policy content (input)

Data opening processes

- Policy strategy and principles for opening data
- Actors involved in opening data
- Targeted open data users
- Types of data opened and not opened
- Policy measures and instruments
- Provision of (technical) support for opening data
- Provision of (technical) support for open data use
- Type of engagement of and interaction between data providers and users
- Promotion of data and data use

Data management

- Data processing before opening
- Data quality
- Selected open data license and use conditions
- Numbers or percentages of opened datasets
- Data and metadata provision
- Data access and availability (e.g. required registration, portal)
- Way of presenting data and metadata to users (e.g. formats, standards)
- Data and metadata update frequency

Stage 4: public value (impact)

Political and social value, for example:

- Increased transparency
- Increased participation
- Increased democratic accountability
- Increased trust in government

Economic value, for example:

- Stimulated innovation
- Economic growth
- Greater efficiency of government

Technical and operational value, for example:

- Ability to reuse data
- Fair decision-making by enabling comparison of different sources
- Easier discovery of data

Stage 3: policy implementation: performance indicators (output)

Performance indicators concerning open data provision, for example:

- The number of datasets opened
- The machine-readability of data
- The metadata provided for each dataset

Performance indicators concerning open data use, for example:

- The number of data users
- The number of dataset downloads
- Type of data use

Fuente: The World of Open Data Concepts, Methods, Tools and Experiences. Springer. 2022.

Informes Observatorio Datos Abiertos - Europa

RECOMENDACIONES PARA ABRIR DATOS (GOBIERNOS)

- Pon en acción el "abrir por defecto": Desarrolla planes claros, pautas y procedimientos para divulgar datos proactivamente. Esto incluye escuchar las demandas de las personas, facilitar el intercambio de datos e invertir en los recursos financieros y humanos necesarios para una mejor gobernanza de los datos abiertos.

- Construye y consolida la infraestructura de datos abiertos: Mejora la calidad y la interoperabilidad de los datos a través de prácticas efectivas de gestión de datos y sistemas de gestión de datos que estén diseñados para manejar datos abiertos. Invierte en desarrollar capacidad y habilidades en datos.

- Publica datos con un propósito: Trabaja estrechamente con grupos cívicos y grupos de asesoramiento multi-interesados para identificar desafíos urgentes que los datos abiertos puedan ayudar a resolver. Publica los conjuntos de datos relevantes y analiza el impacto logrado.

Fuente: Open Data Barometer - Leaders Edition From Promise to Pogress - 2018

RECOMENDACIONES PARA ABRIR DATOS (CAMBIOS)

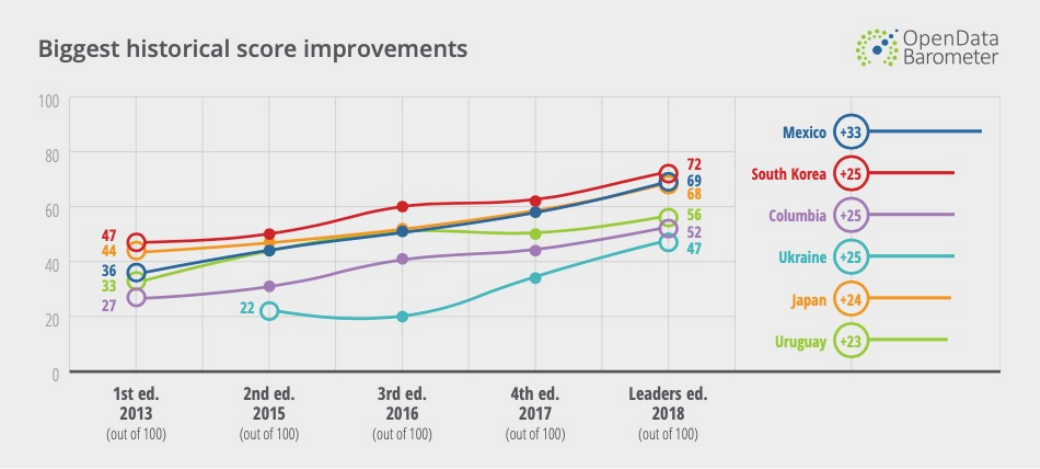

Figure 1 — Leader governments with the biggest score improvements in the Barometer historical comparison of absolute scores. Note that the older edition scores have been re-calculated using absolute values.

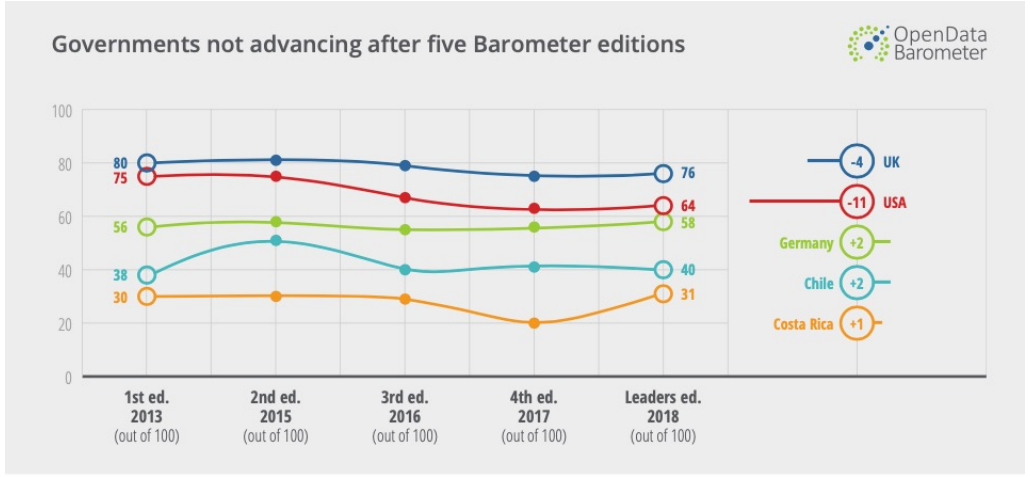

Figure 2 — Historical ODB scores comparison for *Leaders Edition* governments not advancing after five editions of the Barometer. Note that the older edition scores have been re-calculated using absolute values instead of scaled ones.

Fuente: Open Data Barometer - Leaders Edition From Promise to Pogress - 2018

SITUACIÓN DATOS ABIERTOS EN EUROPA – SITUACIÓN PAÍSES

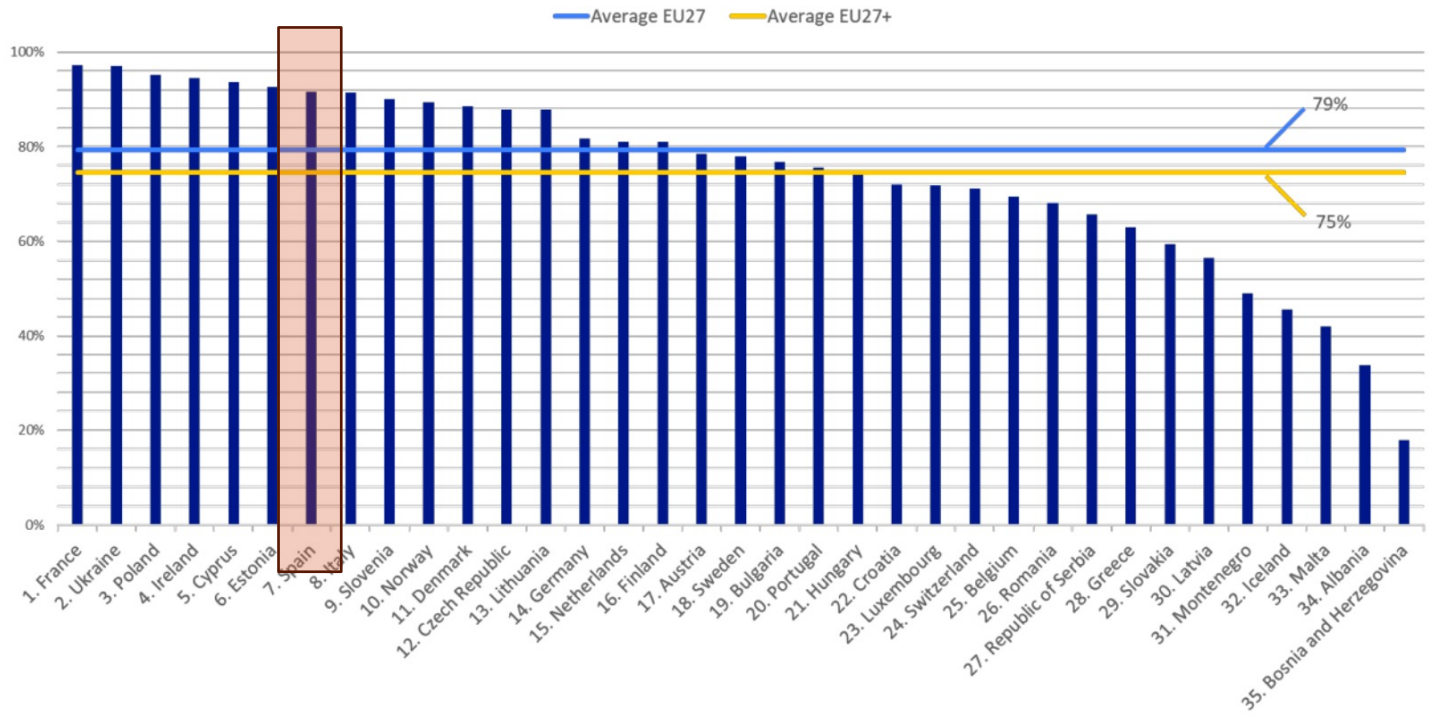

Figure 2: The overall Open Data Maturity scores of the 2022 assessment

SITUACIÓN DATOS ABIERTOS EN EUROPA - CRITERIOS

Dimension	Metrics
Open Data Policy	Policy framework
	Governance of open data
	Open data implementation
Open Data Impact	Strategic awareness
	Measuring reuse
	Created impact
Open Data Portal	Portal features
	Portal usage
	Data provision
	Portal sustainability
Open Data Quality	Currency
	Monitoring and measures
	DCAT-AP compliance
	Deployment quality and linked data

OPEN DATA MATURITY REPORT 2022 – data.europe.eu

SITUACIÓN DATOS ABIERTOS EN EUROPA - CATEGORÍAS

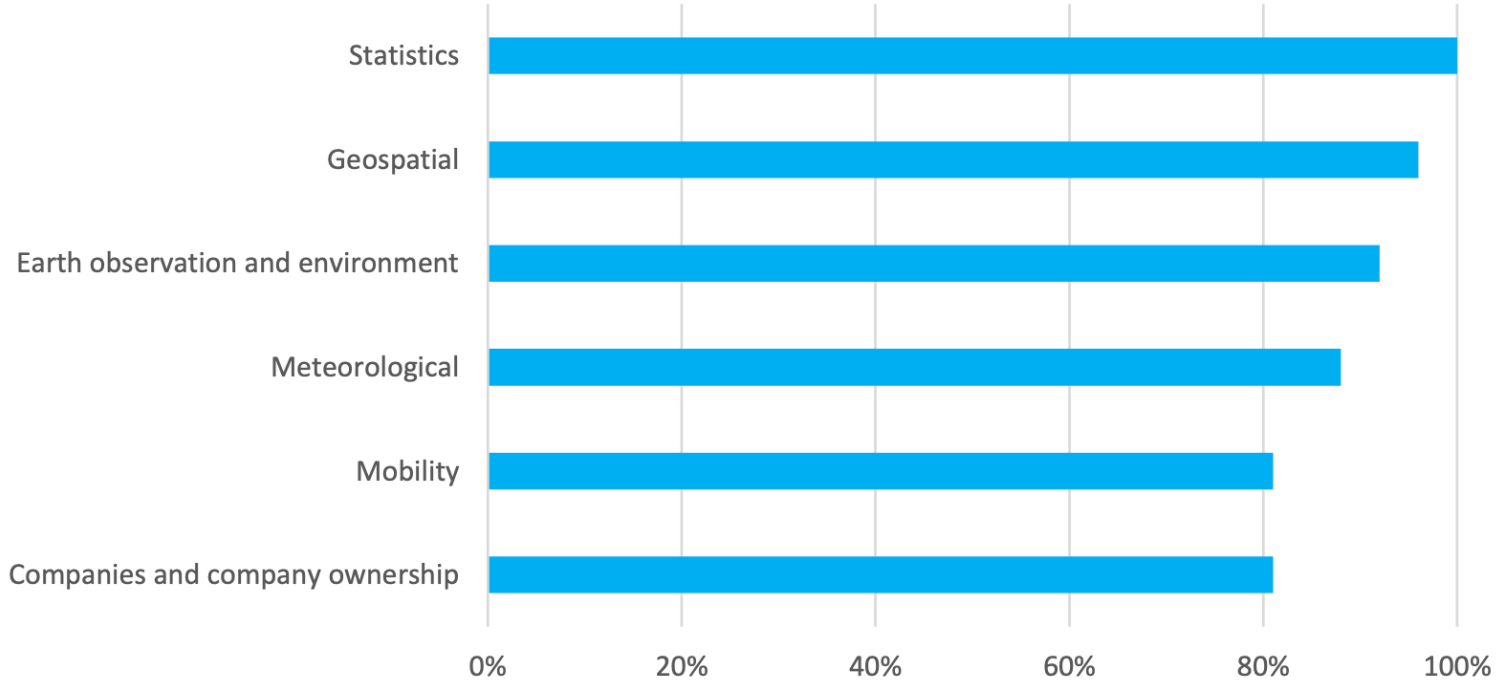

Figure 5: High-value dataset categories most prioritised by the EU27

SITUACIÓN DATOS ABIERTOS EN EUROPA – USOS PRINCIPALES

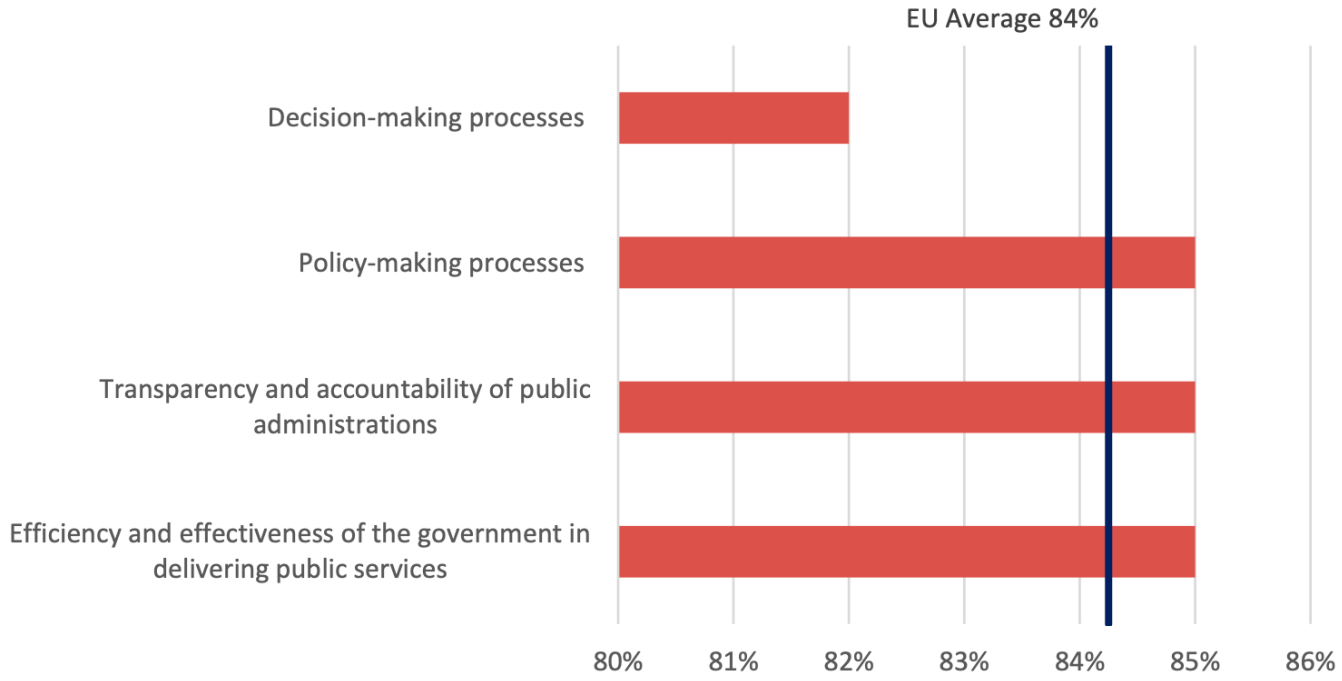

Figure 13: Impact of the use of open data on governmental challenges

SITUACIÓN DATOS ABIERTOS EN EUROPA – USOS ECONÓMICOS

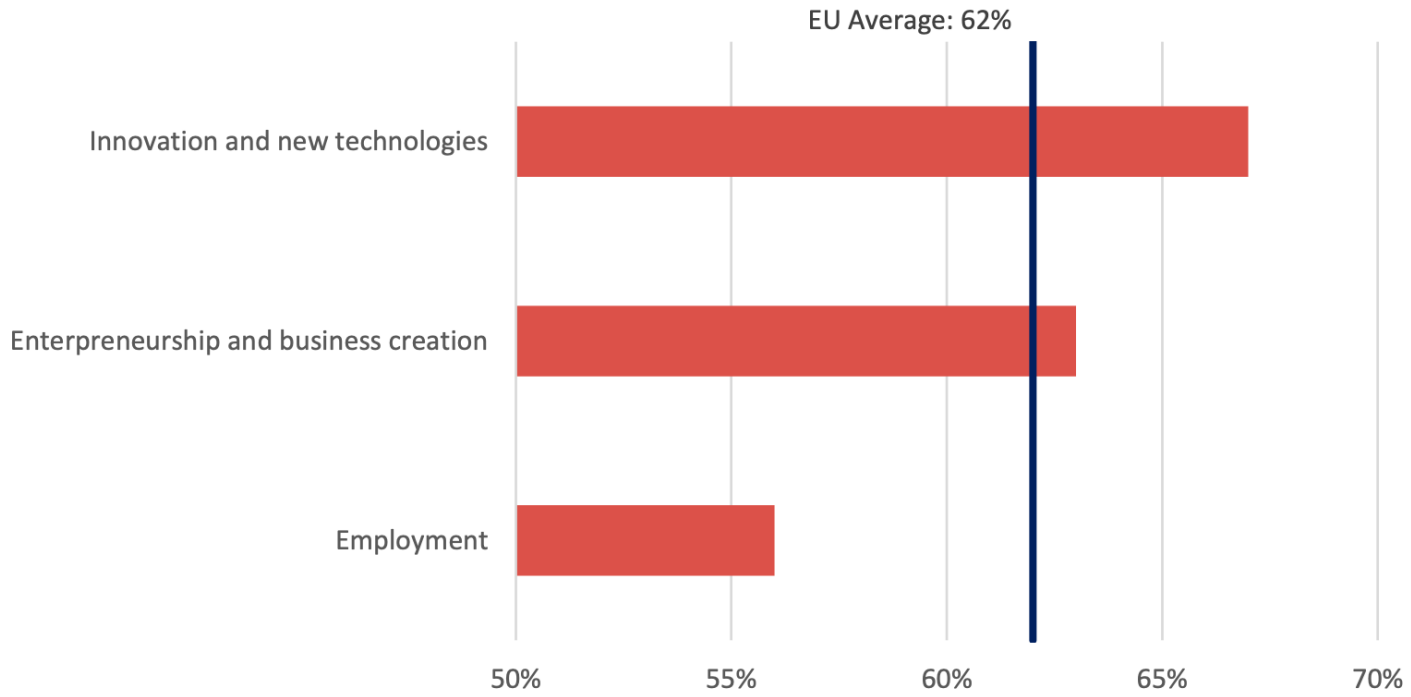

Figure 16: Impact of the use of open data on economic factors

WebScrapping

Concepto y Consideraciones del Web Scraping: Licenciamiento, Ética y Técnicas

Qué es y Técnicas Comunes

- Extracción automática de datos de webs
- APIs oficiales vs. Scraping no oficial
- Librerías: Python (Beautiful Soup, Scrapy, Selenium), Node.js (Puppeteer)

Consideraciones de Licenciamiento y Legalidad

- Revisar archivo robots.txt
- Respetar Términos de Servicio (ToS)
- Derechos de autor sobre datos extraídos

Ética y Mejores Prácticas

- No sobrecargar el servidor (Rate limiting)
- Evitar extraer datos personales sensibles
- Identificar tu scraper (User-Agent)

¿ES LEGAL EL WEBSCRAPPING?

Tribunal Supremo Español. Demanda de Ryanair contra Atráplo

Uno de los casos más sonados en España fue el de la demanda que interpuso Ryanair contra Atrápalo y que resolvió finalmente el Tribunal Supremo a favor de Atrápalo.

Ryanair, la aerolínea de vuelos low cost, demandó a Atrápalo, agencia de viajes online, por scrapear sus datos. A través del portal de Atrápalo los usuarios podían realizar una búsqueda de vuelos. Atrápalo buscaba esta información trasladando los términos de la búsqueda al buscador de Ryanair y permitía la contratación. Ryanair demandó a atrápalo calificando a las agencias online de viajes como parásitos del sector.

Sin embargo el Alto Tribunal no estuvo de acuerdo con el demandante y consideró el scraping como una técnica legal conforme dictó en la sentencia Sentencia del 9 de octubre de 2012 número 572/2012.

¿En qué casos es ilegal el scraping?

Como ya hemos comentado, el scraping no supone una ilegalidad en sí mismo. No obstante su utilización para determinados fines sí que puede suponer una ilegalidad.

Si queremos mantenernos en la legalidad **tenemos que estar atentos y utilizar el scraping de forma ética, mostrando especial interés en no utilizar propiedad intelectual o marcas registradas, no violar derechos de autor, no realizar competencia desleal y cumplir fielmente tanto la LOPD como al nuevo reglamento europeo RGPD. Y, por supuesto, no sobrecargar a los servidores de los sitios scrapeados.**

El objetivo de este post es explicar los conceptos relacionados con la legalidad del scraping a modo general y no puede utilizarse en ningún caso como un asesoramiento personalizado. Aunque este post intenta ser una ayuda, cada caso concreto tiene que estudiarse muy a fondo, ya que no hay unas leyes generales a las que acogerse.

https://datstrats.com/blog/scraping-es-legal-espana/

GDPR
LOPD

ATENCIÓN A LA LEY GDPR (REGLAMENTO GENERAL DE PROTECCIÓN DE DATOS)

El Reglamento General de Protección de Datos (GDPR) establece que las organizaciones deben cumplir con ciertas medidas para proteger la privacidad de los datos personales de los individuos en la Unión Europea.

Algunas de las limitaciones en uso que impone la ley GDPR son:

- Los datos personales solo pueden ser utilizados con fines específicos y legítimos.
- Los individuos tienen el derecho a ser informados sobre cómo se está utilizando su información personal.
- Los individuos tienen el derecho a solicitar el acceso a sus datos personales y solicitar su eliminación.
- Las organizaciones deben tomar medidas de seguridad para proteger los datos personales de los individuos.

Si una organización no cumple con las medidas establecidas por el GDPR, se pueden aplicar multas significativas. Las multas pueden llegar hasta el 4% de los ingresos globales de una organización o €20 millones, lo que sea mayor. Además de las multas, también puede haber daños a la reputación y pérdida de confianza por parte de los clientes y otros interesados.

ATENCIÓN A LA LEY GDPR - DATOS SENSIBLES

El GDPR considera los datos personales sensibles como:

- cualquier información relacionada con una persona física que revele su origen racial o étnico.
- opiniones políticas, religiosas o filosóficas, afiliación sindical,
- datos genéticos, datos biométricos para identificar a una persona de manera única,
- datos de salud
- datos relativos a la vida sexual o la orientación sexual de una persona.
- el sexo no se considera un dato sensible en sí mismo. Sin embargo, la combinación del sexo con otros datos personales, como la raza o la religión, puede hacer que esos datos sean considerados sensibles.

Estos datos son considerados sensibles porque pueden ser utilizados para discriminación o para perjudicar a los individuos de alguna manera.

ATENCIÓN A LA LEY GDPR – HISTÓRICO DE MULTAS

- La CNIL (Comisión Nacional de Informática y Libertades) de Francia impuso una multa de €50 millones a Google en enero de 2019 por falta de transparencia, información insuficiente y falta de consentimiento válido para la personalización de anuncios publicitarios.
- La autoridad de protección de datos de Austria impuso una multa de €18 millones a Österreichische Post AG en julio de 2019 por violar el GDPR al recopilar y procesar ilegalmente datos personales de sus clientes.
- La autoridad de protección de datos de Italia impuso una multa de €27,8 millones a TIM (Telecom Italia) en enero de 2020 por violar el GDPR al no obtener el consentimiento adecuado de los clientes para el procesamiento de sus datos personales.
- La autoridad de protección de datos de España impuso una multa de €9,4 millones a CaixaBank en enero de 2021 por violar el GDPR al procesar ilegalmente datos personales de sus clientes para fines de marketing.
- La autoridad de protección de datos de Alemania impuso una multa de €35,3 millones a H&M en octubre de 2020 por violar el GDPR al recopilar y procesar ilegalmente datos personales de sus empleados.

¿Y QUÉ DICE LA LOPD?

La Ley Orgánica de Protección de Datos (LOPD) en España establece un marco legal para la protección de los datos personales de los individuos. Algunos elementos destacables de la LOPD son:

- Define qué se considera como datos personales y cómo se deben proteger.
- Establece que los individuos tienen derecho a acceder a sus datos personales, rectificarlos y cancelarlos.
- Obliga a las organizaciones a obtener el consentimiento explícito de los individuos antes de recopilar, almacenar o procesar sus datos personales.
- Obliga a las organizaciones a tomar medidas de seguridad para proteger los datos personales de los individuos.
- Establece que los individuos tienen derecho a presentar una queja ante la Agencia Española de Protección de Datos si creen que sus datos personales no están siendo tratados de acuerdo con la ley.

Además, la LOPD se ha actualizado recientemente para estar en línea con el Reglamento General de Protección de Datos (GDPR) de la Unión Europea, que entró en vigor en mayo de 2018. Como resultado, las organizaciones en España también deben cumplir con las disposiciones del GDPR.

¿Y QUÉ DICE LA LOPD? - MULTAS

- En 2019, la AEPD impuso una multa de €6 millones a CaixaBank por una infracción de seguridad que permitió el acceso no autorizado a los datos personales de más de 4,4 millones de clientes.
- En 2018, la AEPD impuso una multa de €250,000 a Facebook por no informar adecuadamente a los usuarios sobre cómo se recopilaban y usaban sus datos personales.
- En 2017, la AEPD impuso una multa de €600,000 a Vodafone por violar las leyes de protección de datos en relación con el marketing directo y la retención de datos.
- En 2016, la AEPD impuso una multa de €1,2 millones a Google por una serie de infracciones relacionadas con la recopilación de datos personales sin el consentimiento adecuado de los usuarios.

Referencias de Fuentes de datos abiertos

Modelos de Negocio de Datos: Comercialización y Ejemplos Corporativos

Modelos de Comercialización de Datos

- Venta Directa de Datasets (Transaccional)
- Data-as-a-Service (DaaS) y **APIs** (Suscripción)
- Análisis y Consultoría de Datos (Valor añadido)

Ejemplos de Empresas (Finanzas y Mercado)

Bloomberg

- Bloomberg y Refinitiv (Datos financieros en tiempo real)

Nielsen

- Nielsen y Kantar (Datos de consumo y medios)

Ejemplos de Empresas (Tecnología y B2B)

Google X

- Google, Meta, X (Datos de usuario para publicidad)

salesforce ORACLE

- Salesforce y Oracle (Datos B2B y de clientes)

Conjuntos de Datos Abiertos Más Conocidos y Relevantes

OpenStreetMap (OSM) - Geografía Colaborativa

- Mapa mundial editable y libre
- Datos geoespaciales creados por comunidad
- Usado por empresas y ONGs

Wikidata - Base de Conocimiento Estructurada

- Repositorio central de datos para Wikipedia
- Datos enlazados (Linked Data)
- Legible por máquinas y humanos

NASA Open Data - Ciencia y Espacio

- Datos de misiones espaciales y observación terrestre
- Imágenes, telemetría y modelos climáticos
- Fomenta la investigación y la educación

El Ecosistema OpenData: Fundamentos, Impacto y Referencias Globales

Principios de Apertura

- Completos y Primarios (Datos brutos)
- Oportunos y Accesibles (Sin barreras)
- Procesables (Formatos abiertos: CSV, JSON)

Beneficios e Impacto

- Transparencia y Rendición de Cuentas
- Innovación Económica y Modelos IA
- Mejora de Servicios Públicos

Desafíos Clave

- Calidad, Interoperabilidad y Estandarización
- Protección de Datos Personales (Privacidad)
- Brecha Digital y Habilidades de Uso

Portales de Datos Abiertos de Referencia

Instituciones Globales

World Bank Open Data
(Desarrollo, Economía)

WHO Health Observatory
(Salud Pública Mundial)

UN Data
(Estadisticas Oficiales)

Referentes Nacionales

datos.gob.es (España)
(Líder en madurez UE)

data.gouv.fr (Francia)
(Innovación pública)

DATA.GOV (USA)
(Pionero gubernamental)

Ciencia y Especializados

NASA Open Data
(Espacio, Tierra, Clima)

CERN Open Data
(Física de partículas)

DATOS ABIERTOS EN ESPAÑA - REFERENCIAS

- **Datos.gob.es:** el portal oficial del Gobierno de España para el acceso a los datos abiertos del sector público.
- **OpenDataEuskadi:** el portal de datos abiertos del Gobierno Vasco, que ofrece datos de diferentes ámbitos como transporte, medio ambiente y estadísticas.
- **OpenDataBarcelona:** el portal de datos abiertos del Ayuntamiento de Barcelona, que ofrece información sobre la ciudad en áreas como transporte, cultura, deportes y medio ambiente.
- **OpenDataSevilla:** el portal de datos abiertos del Ayuntamiento de Sevilla, que ofrece información sobre la ciudad en áreas como transporte, urbanismo y cultura.
- **OpenDataMálaga:** el portal de datos abiertos del Ayuntamiento de Málaga, que ofrece información sobre la ciudad en áreas como transporte, turismo y medio ambiente.
- **OpenDataCanarias:** el portal de datos abiertos del Gobierno de Canarias, que ofrece información sobre las islas en áreas como turismo, medio ambiente y transporte.
- **OpenDataAlicante:** el portal de datos abiertos del Ayuntamiento de Alicante, que ofrece información sobre la ciudad en áreas como urbanismo, transporte y turismo.
- **DatosAbiertos.gob.es:** el portal de datos abiertos del Ministerio de Hacienda y Administraciones Públicas, que ofrece información sobre diferentes ámbitos como economía, industria y empleo.
- **AEMET OpenData:** el portal de datos abiertos de la Agencia Estatal de Meteorología, que ofrece información sobre el tiempo y el clima en España.
- **DatosAbiertos.jcyl.es:** el portal de datos abiertos de la Junta de Castilla y León, que ofrece información sobre la región en áreas como medio ambiente, turismo y cultura.

DATOS ABIERTOS NIVEL GLOBAL - REFERENCIAS

- **Datos abiertos del Banco Mundial**: una plataforma que ofrece datos abiertos sobre la economía, el desarrollo y el bienestar en todo el mundo.
- **Datos abiertos de la ONU:** una plataforma que ofrece datos abiertos sobre una amplia variedad de temas, como salud, medio ambiente y derechos humanos.
- **Datos abiertos del Fondo Monetario Internacional:** una plataforma que ofrece datos abiertos sobre la economía global, incluyendo información sobre el comercio, las finanzas y la deuda.
- **Datos abiertos de la Organización para la Cooperación y el Desarrollo Económico (OCDE):** una plataforma que ofrece datos abiertos sobre el desarrollo económico y social en los países miembros de la organización.
- **Datos abiertos de la Unión Europea:** una plataforma que ofrece datos abiertos sobre diversos temas, como agricultura, economía y medio ambiente, entre otros.
- **Datos abiertos de la NASA:** una plataforma que ofrece datos abiertos sobre la exploración espacial, el clima y la ciencia en general.
- **Datos abiertos de la Agencia de Protección Ambiental de EE. UU**.: una plataforma que ofrece datos abiertos sobre el medio ambiente y la salud pública en los Estados Unidos.
- **Datos abiertos de la Biblioteca del Congreso de EE. UU.:** una plataforma que ofrece datos abiertos sobre la historia y la cultura de los Estados Unidos.
- **Datos abiertos de la Comisión Europea:** una plataforma que ofrece datos abiertos sobre la política y la economía de la Unión Europea.
- **Datos abiertos de la Biblioteca Digital Mundial:** una plataforma que ofrece datos abiertos sobre la historia, la cultura y el patrimonio de todo el mundo.

Datos Kaggle

Open Data como Combustible de la IA y el Machine Learning

El Rol del Dato Abierto en la IA

- Entrenamiento de modelos fundacionales (LLMs, Visión)
- Fuente esencial para reducir sesgos (datasets diversos)
- Transparencia en benchmarks y validación de modelos

Casos de Uso Transformadores

- Ciencia y Salud: Aceleración del descubrimiento de fármacos
- Smart Cities: Optimización de tráfico y energía en tiempo real
- Clima: Modelos predictivos de alta precisión para desastres

Desafíos Éticos y Técnicos Futuros

- Privacidad en la Era IA: Riesgo de re-identificación
- 'Data Poisoning': Proteger la integridad de los datos de entrenamiento
- Sostenibilidad: Costo energético del procesamiento masivo

CUIDADO CON LOS DATOS DE KAGGLE....

- **Verificad las licencias:** asegúrate de que los datos que descarga tienen licencias abiertas o que tiene el permiso adecuado para utilizarlos. Algunos conjuntos de datos de Kaggle pueden tener restricciones de uso o licencias que limitan su uso comercial.
- **Verificad la calidad de los datos:** antes de utilizar los datos para su análisis, es importante verificar su calidad. Algunos conjuntos de datos pueden contener errores o valores atípicos, lo que puede afectar los resultados de su análisis.
- **Respetad la privacidad y los derechos de autor:** algunos conjuntos de datos de Kaggle pueden contener información personal o protegida por derechos de autor. Asegúrese de cumplir con todas las leyes y regulaciones de privacidad y derechos de autor al utilizar estos datos.
- **Prestad atención a los metadatos:** asegúrate de leer los metadatos para comprender cómo se recopilaron los datos y cómo se deben utilizar.
- **Sed consciente de los sesgos:** algunos conjuntos de datos pueden contener sesgos o prejuicios que deben tenerse en cuenta al realizar el análisis. Asegúrese de comprender las posibles fuentes de sesgo en los datos y cómo pueden afectar sus resultados.
- **No asumáis que los datos son perfectos:** recuerda que los datos pueden contener errores o sesgos, y que puede ser necesario limpiarlos o procesarlos antes de utilizarlos.

Instituciones de Referencia

INSTITUCIONES DE REFERENCIA.... (1 / 2)

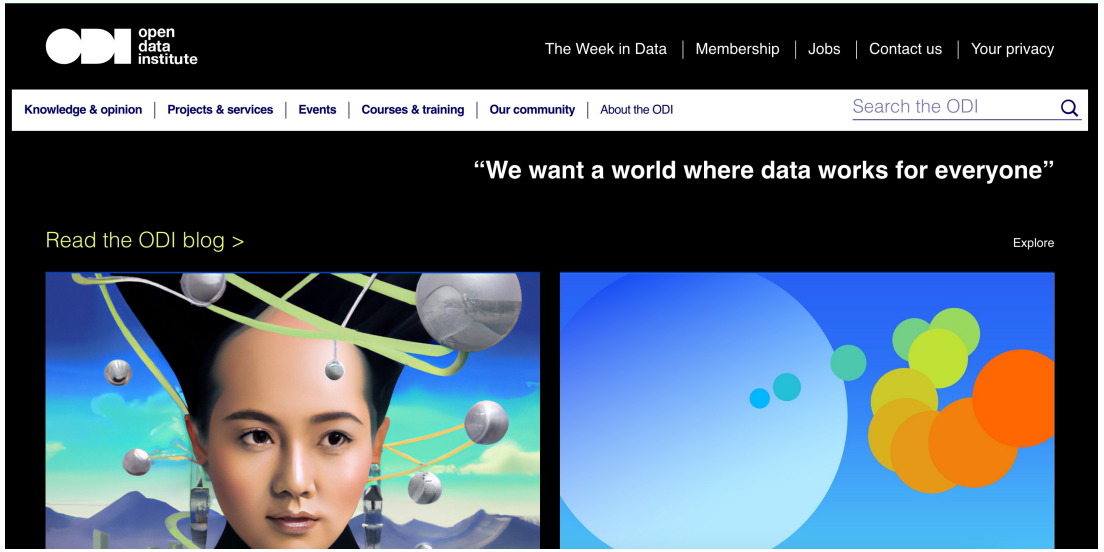

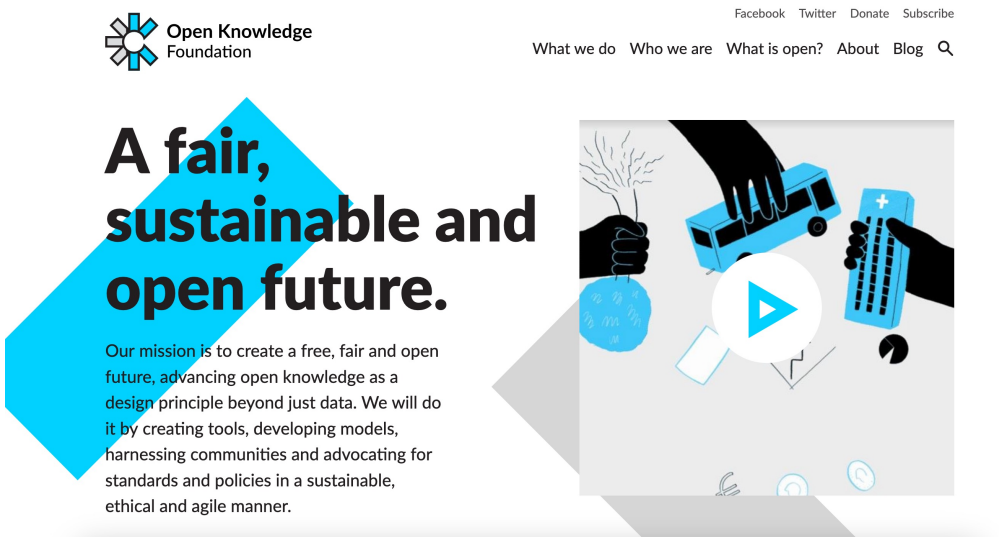

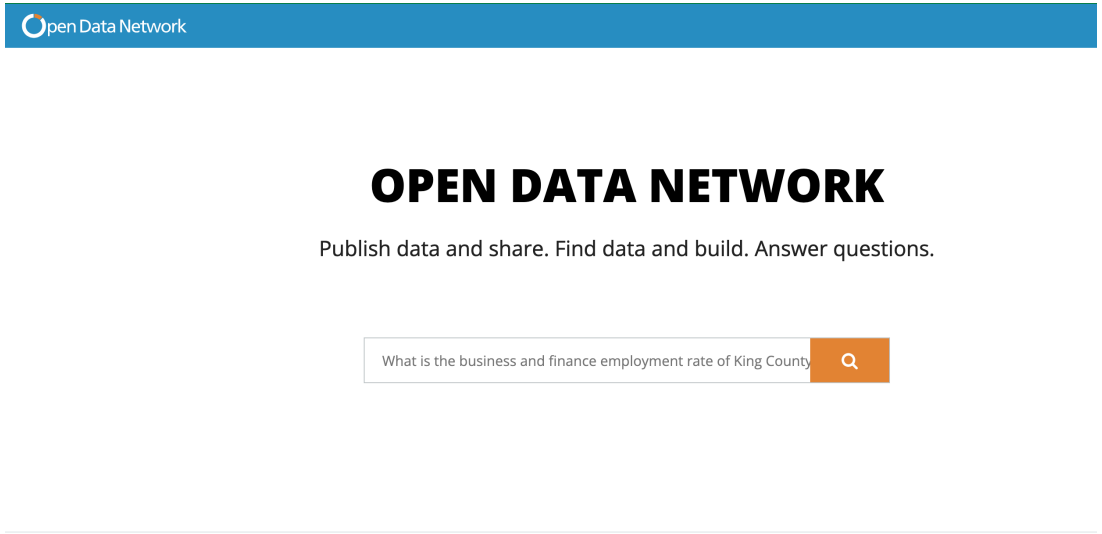

INSTITUCIONES DE REFERENCIA.... (2 / 2)

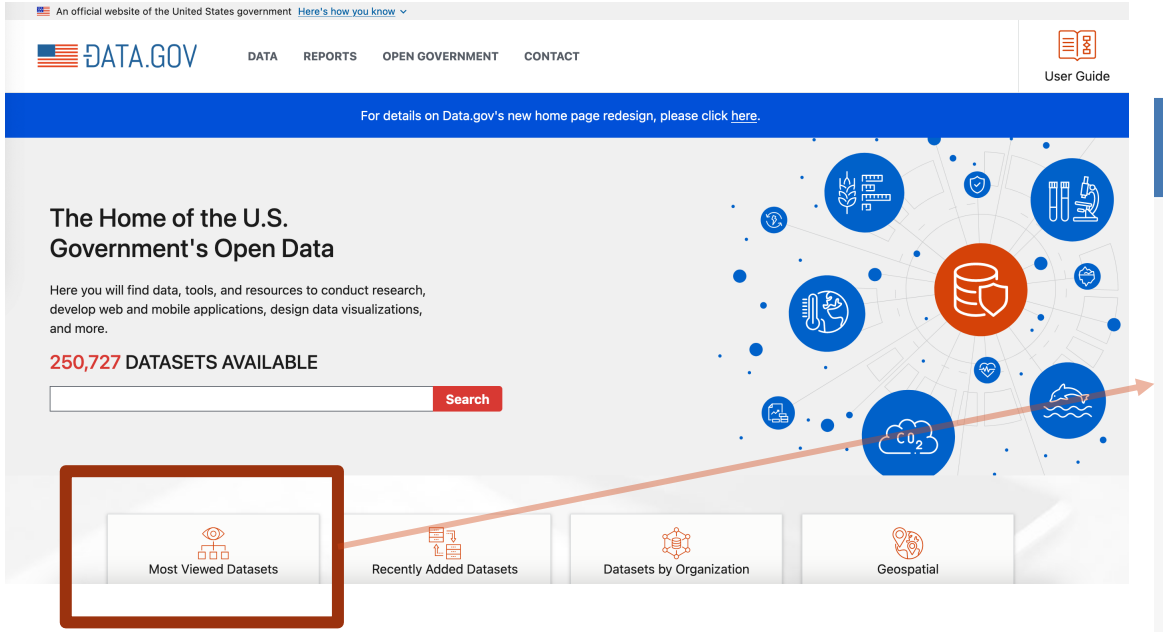

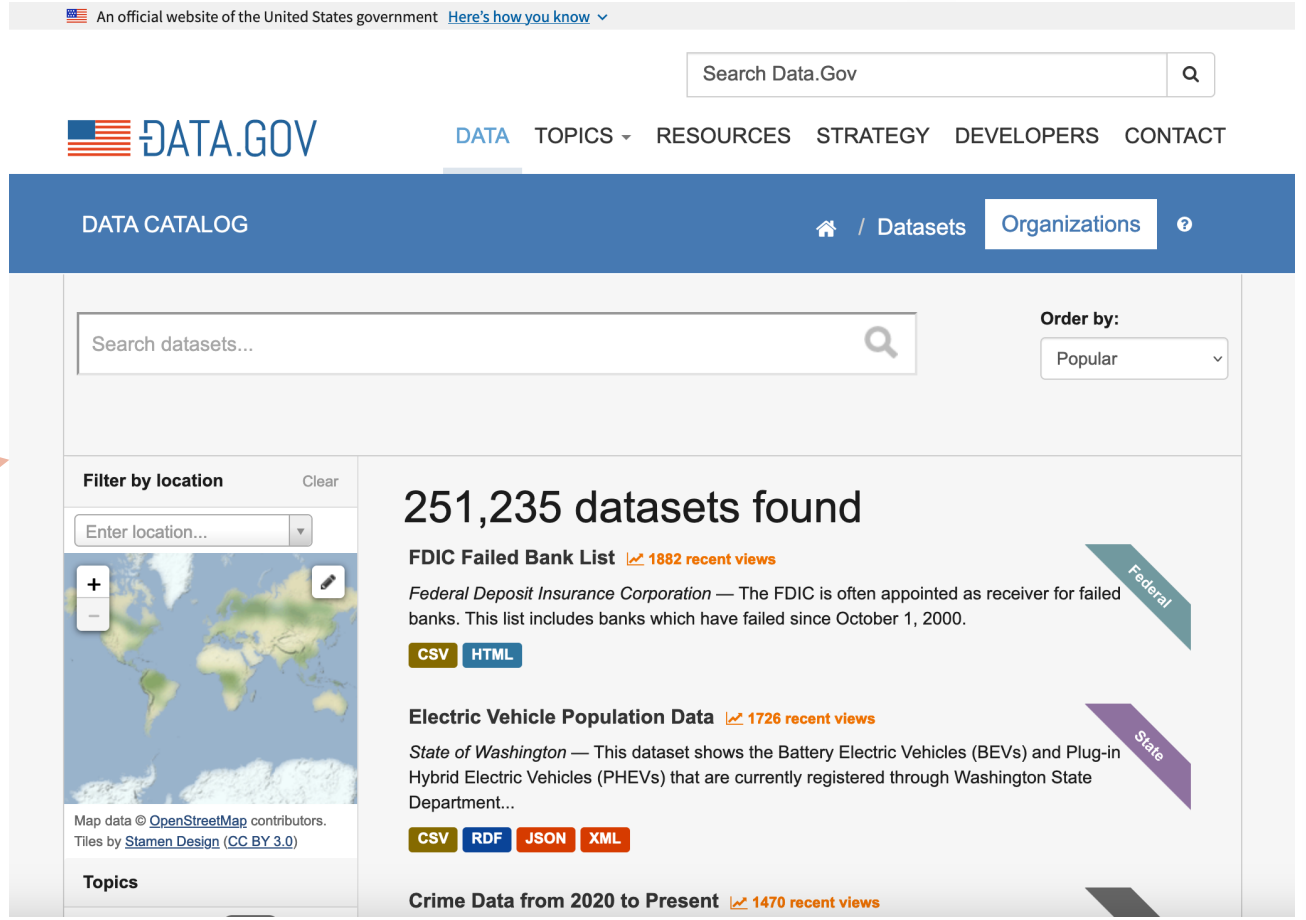

(cof@qualityexcellence.es)