

ntic master School

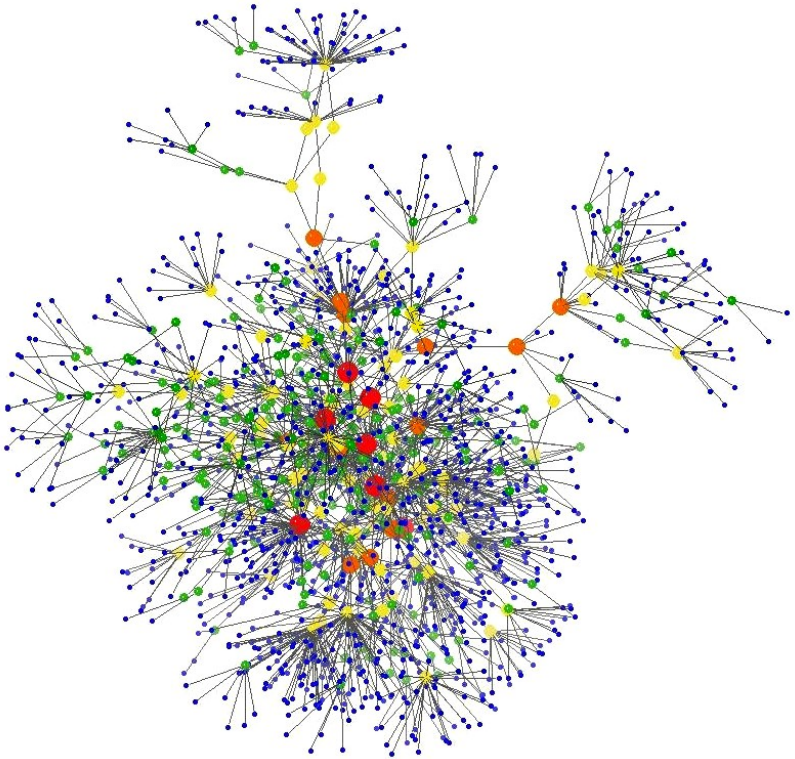
UNIVERSIDAD COMPLUTENSE DE MADRID

Introducción al Análisis de redes sociales.

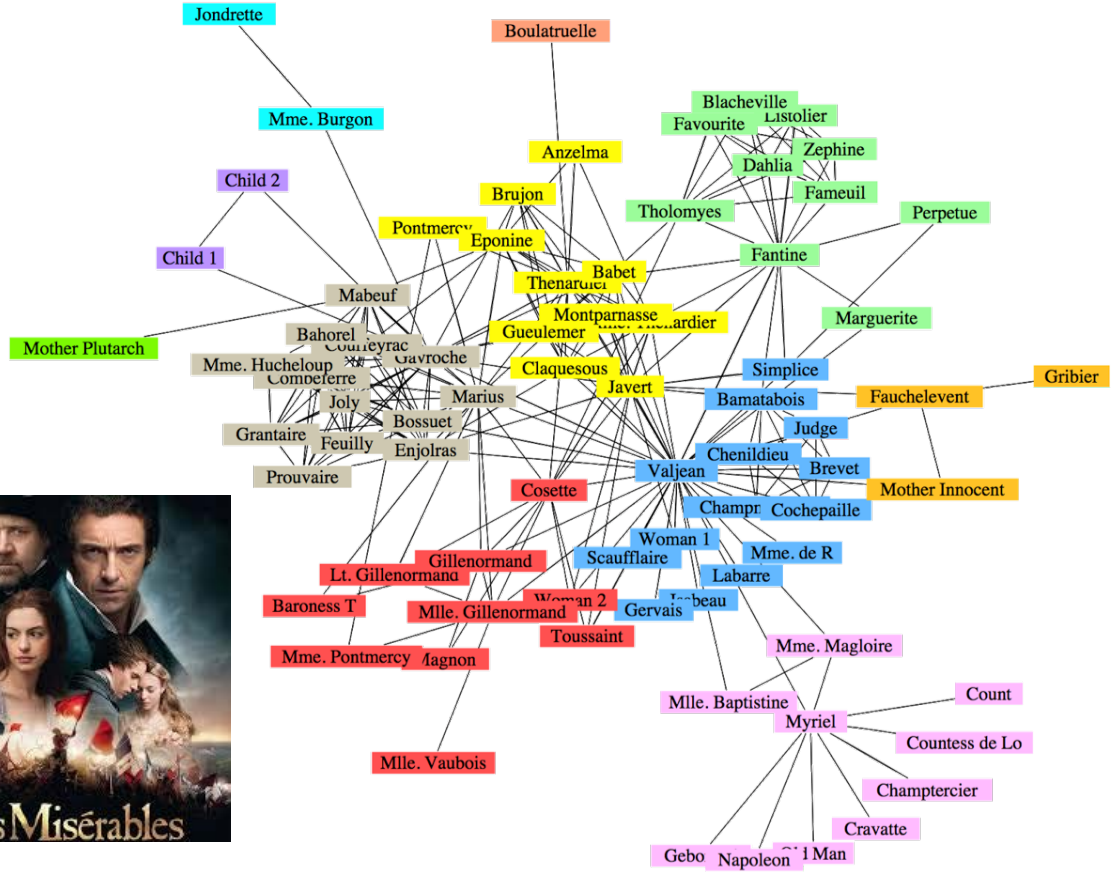
Javier Castro Cantalejo

1. Preliminares

¿Qué es una red Social?

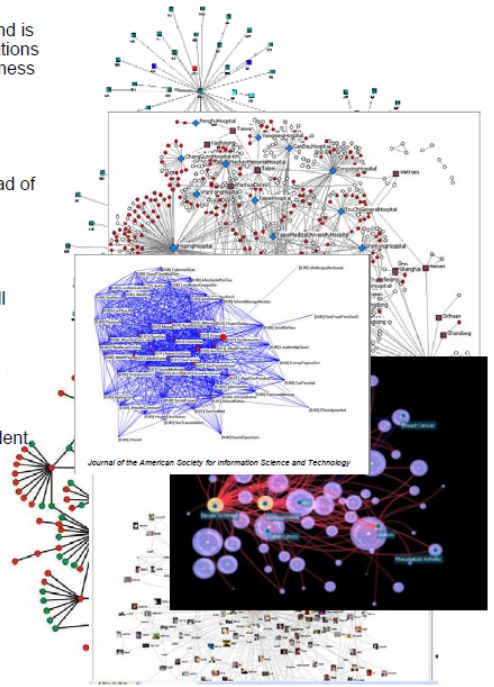



Les Misérables


Jondrette
Boulatruelle
Mme. Burgon
Blacheville
Favourite
Listolier
Zephine
Anzelma
Dahlia
Child 2
Brujon
Fameuil
Tholomyes
Perpetue
Pontmercy
Eponine
Child 1
Fantine
Babet
Mabeuf
Montparnasse
Marguerite
Mother Plutarch
Bahorel
Gueulemer
Mme. Hucheloup
Claquesous
Simplice
Gribier
Javert
Marius
Bamatabois
Fauchelevent
Joly
Judge
Grantaire
Bossuet
Feuilly
Enjolras
Chenildieu
Brevet
Prouvaire
Valjean
Cosette
Mother Innocent
Cochepaille
Woman 1
Scaufflaire
Mme. de R
Gillenormand
Labarre
Baroness T
Gervais
Mlle. Gillenormand
Toussaint
Mme. Magloire
Mme. Pontmercy
Mlle. Baptistine
Count
Myriel
Countess de Lo
Mlle. Vaubois
Champtercier
Cravatte
Napoleon

Applications of SNA

- **Terrorism and crimes**
  - Social Network analysis is an important part of a conspiracy investigation and is used as an investigative tool. Group structure may be important to investigations of racketeering enterprises, narcotics operations, illegal gambling, and business frauds.
- **Medicine – epidemiology**
  - valuable epidemiological tool for understanding the progression of the spread of an infectious disease.
- **Marketing**
  - Emarketer projected that Social Network Marketing spending in the USA will reach approximately $1.3 billion in 2009. http://www.emarketer.com/Reports/All/Emarketer_2000541.aspx
- **Product Recommendation**
  - Current recommendation models assume all users' opinions to be independent. Use of SNA relaxes the iid assumption.
- **Bio-informatics (protein interaction)**
- **Relevance Ranking**
- **Information and Library Science**

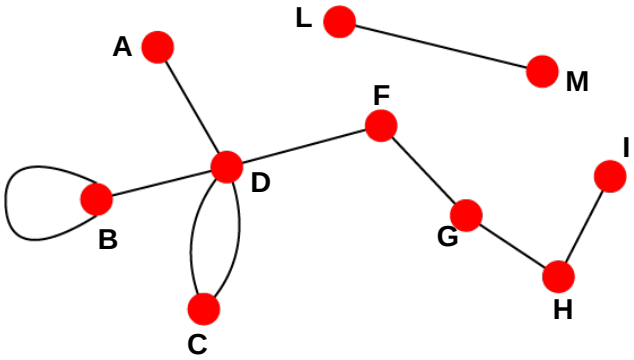


UNDIRECTED VS. DIRECTED NETWORKS

Undirected

Links: undirected (*symmetrical*)

Graph:

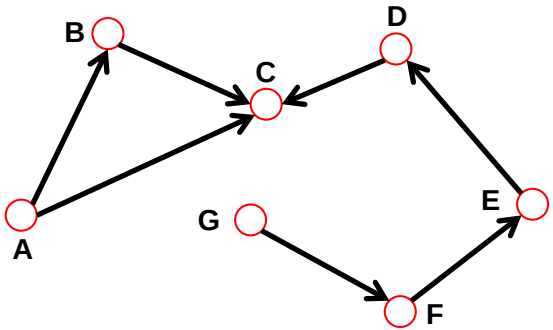


Undirected links :
coauthorship links
Actor network
protein interactions

Directed

Links: directed (*arcs*).

Digraph = directed graph:

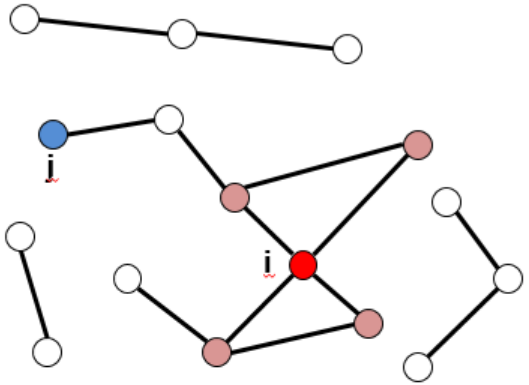


An undirected link is the superposition of two opposite directed links.

Directed links :
URLs on the www
phone calls
metabolic reactions

AVERAGE DEGREE

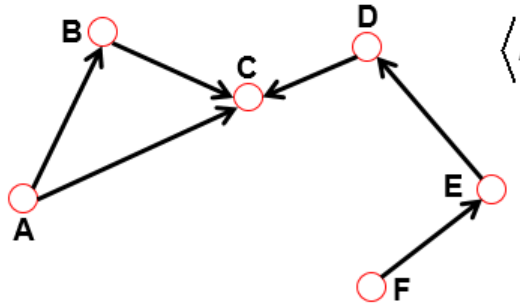
Undirected



$$\langle k \rangle \equiv \frac{1}{N}\sum_{i=1}^{N} k_i \qquad \langle k \rangle \equiv \frac{2L}{N}$$

N – the number of nodes in the graph

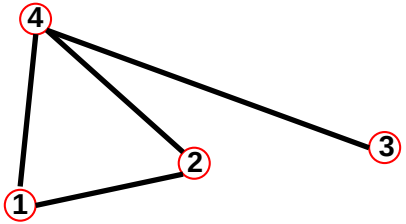
Directed

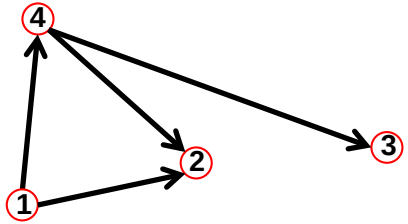


$$\langle k^{in} \rangle \equiv \frac{1}{N}\sum_{i=1}^{N} k_i^{in}, \quad \langle k^{out} \rangle \equiv \frac{1}{N}\sum_{i=1}^{N} k_i^{out}, \quad \langle k^{in} \rangle = \langle k^{out} \rangle$$

$$\langle k \rangle \equiv \frac{L}{N}$$

ADJACENCY MATRIX





A_{ij}=1 if there is a link between node *i* and *j*

A_{ij}=0 if nodes *i* and *j* are not connected to each other.

$$A_{ij} = \begin{pmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{pmatrix} \qquad A_{ij} = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \end{pmatrix}$$

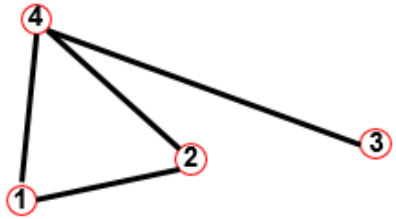
Note that for a directed graph (right) the matrix is not symmetric.

$A_{ij} = 1$ if there is a link pointing from node *j* and *i*

$A_{ij} = 0$ if there is no link pointing from *j* to *i*.

ADJACENCY MATRIX AND NODE DEGREES

Undirected



$$A_{ij} = \begin{pmatrix} 0 & 1 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{pmatrix}$$

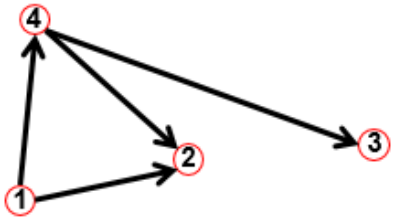
$$A_{ij} = A_{ji}$$
$$A_{ii} = 0$$

$$k_i = \sum_{j=1}^{N} A_{ij}$$

$$k_j = \sum_{i=1}^{N} A_{ij}$$

$$L = \frac{1}{2}\sum_{i=1}^{N} k_i = \frac{1}{2}\sum_{ij}^{N} A_{ij}$$

Directed



$$A_{ij} = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \end{pmatrix}$$

$$A_{ij} \neq A_{ji}$$
$$A_{ii} = 0$$

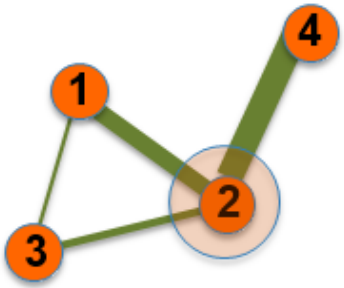
$$k_i^{in} = \sum_{j=1}^{N} A_{ij}$$

$$k_j^{out} = \sum_{i=1}^{N} A_{ij}$$

$$L = \sum_{i=1}^{N} k_i^{in} = \sum_{j=1}^{N} k_j^{out} = \sum_{i,j}^{N} A_{ij}$$

a_{ij} and w_{ij}

In the literature we often use a double notation: A_{ij} and w_{ij} (somewhat redundant)



Adjacency Matrix (A_{ij})

$$A_{ij} = \begin{pmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{pmatrix}$$

Weight Matrix (W_{ij})

$$W_{ij} = \begin{pmatrix} 0 & 2 & 0.5 & 0 \\ 2 & 0 & 1 & 4 \\ 0.5 & 1 & 0 & 0 \\ 0 & 4 & 0 & 0 \end{pmatrix}$$

Node Strength (*weighted degree*) s:

$$s_i = \sum_{j=1}^{N} a_{ij} w_{ij}$$

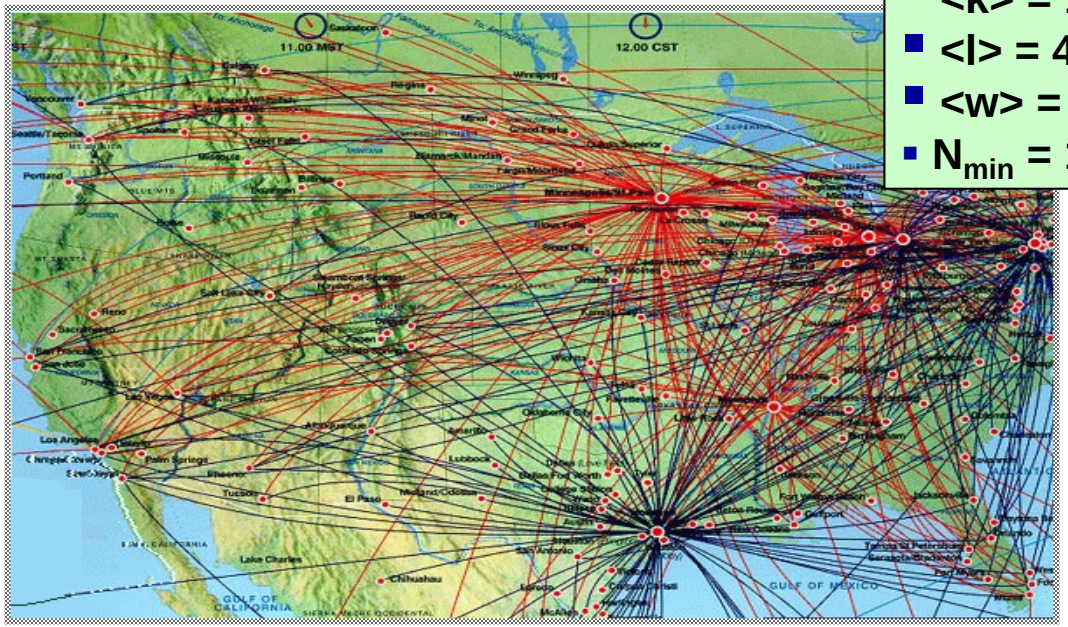
$$s_2 = \sum_{j=1}^{N} a_{ij} w_{ij} = w_{21} + w_{23} + w_{24}$$

EXAMPLE 1: AIRLINE TRAFFIC

Nodes: airports

Links: direct flights

Weights: Number of seats



- **2002 IATA database**
  - **V = 3880 airports**
  - **E = 18810 direct flights**

- **$\langle k \rangle = 10$ $k_{max} = 318$**
- **$\langle l \rangle = 4$ $l_{max} = 16$**
- **$\langle w \rangle = 10^5$ $w_{max} = 10^7$**
- **$N_{min} = 10^3$ $N_{max} = 10^7$**

EXAMPLE 2: SCIENCE COLLABORATION NETWORK

- Nodes: scientists
- Links: joint publications
- Weights: number of joint pubs.

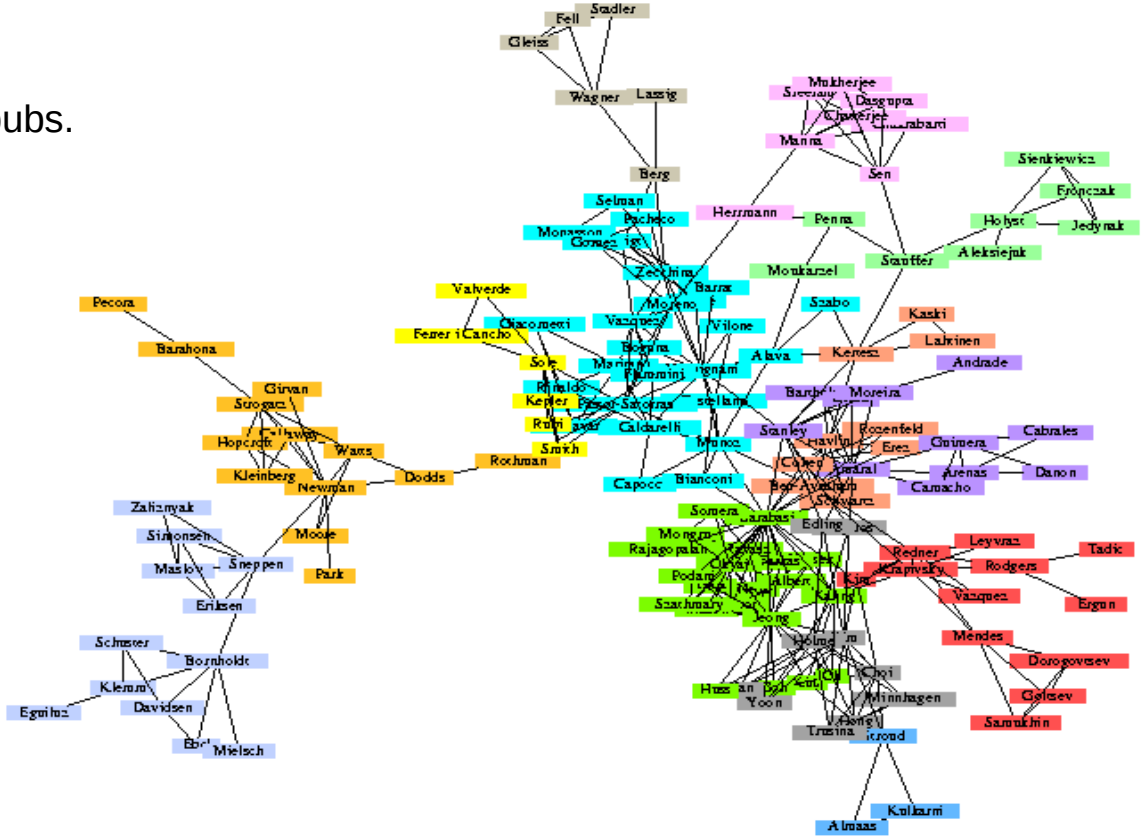
$$w_{ij} = \Sigma_k \frac{\delta_i^k \delta_j^k}{n_k - 1}$$

i, j: authors

k: paper

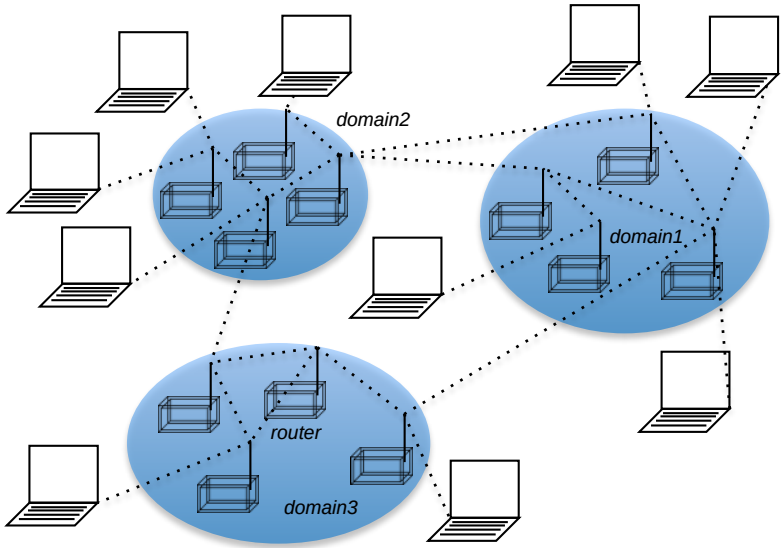
n_k: number of authors

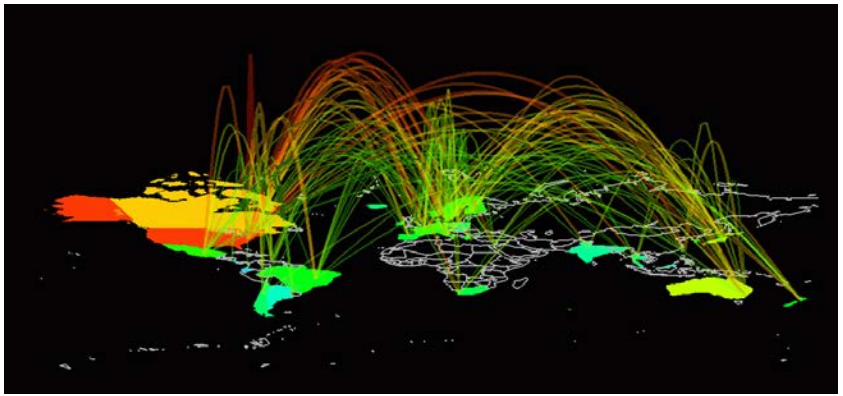
δ_i^k=1 if author i contributed to paper k

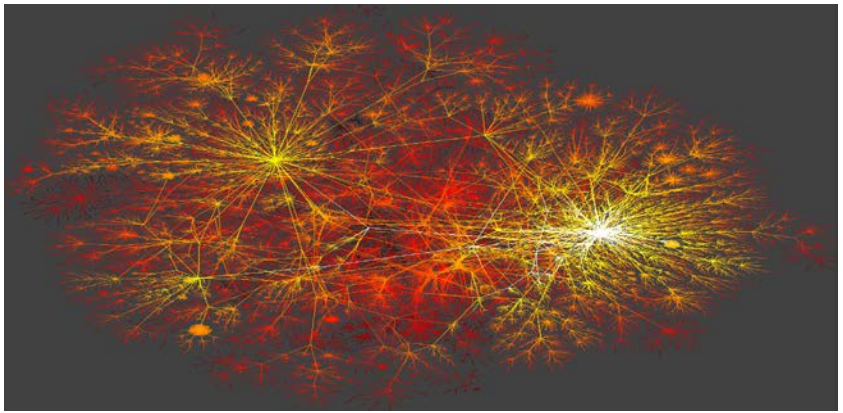


Newman and Girvan, cond-mat/0308217 (2003)

EXAMPLE 3: INTERNET

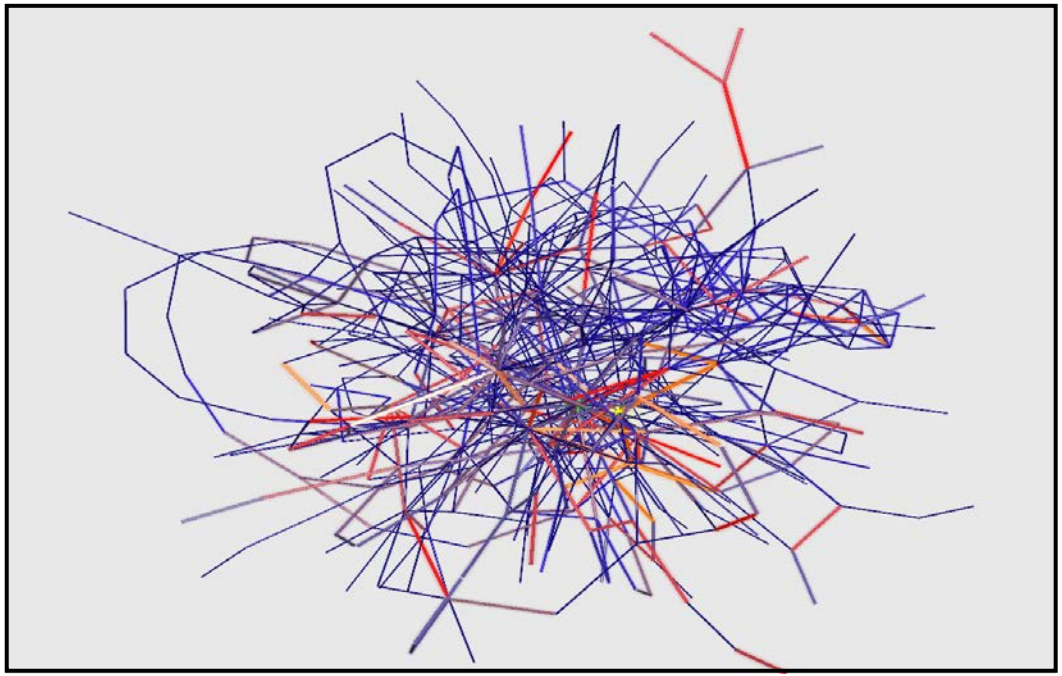






- Nodes: routers
- Links: physical lines
- Link Weights: bandwidth or traffic

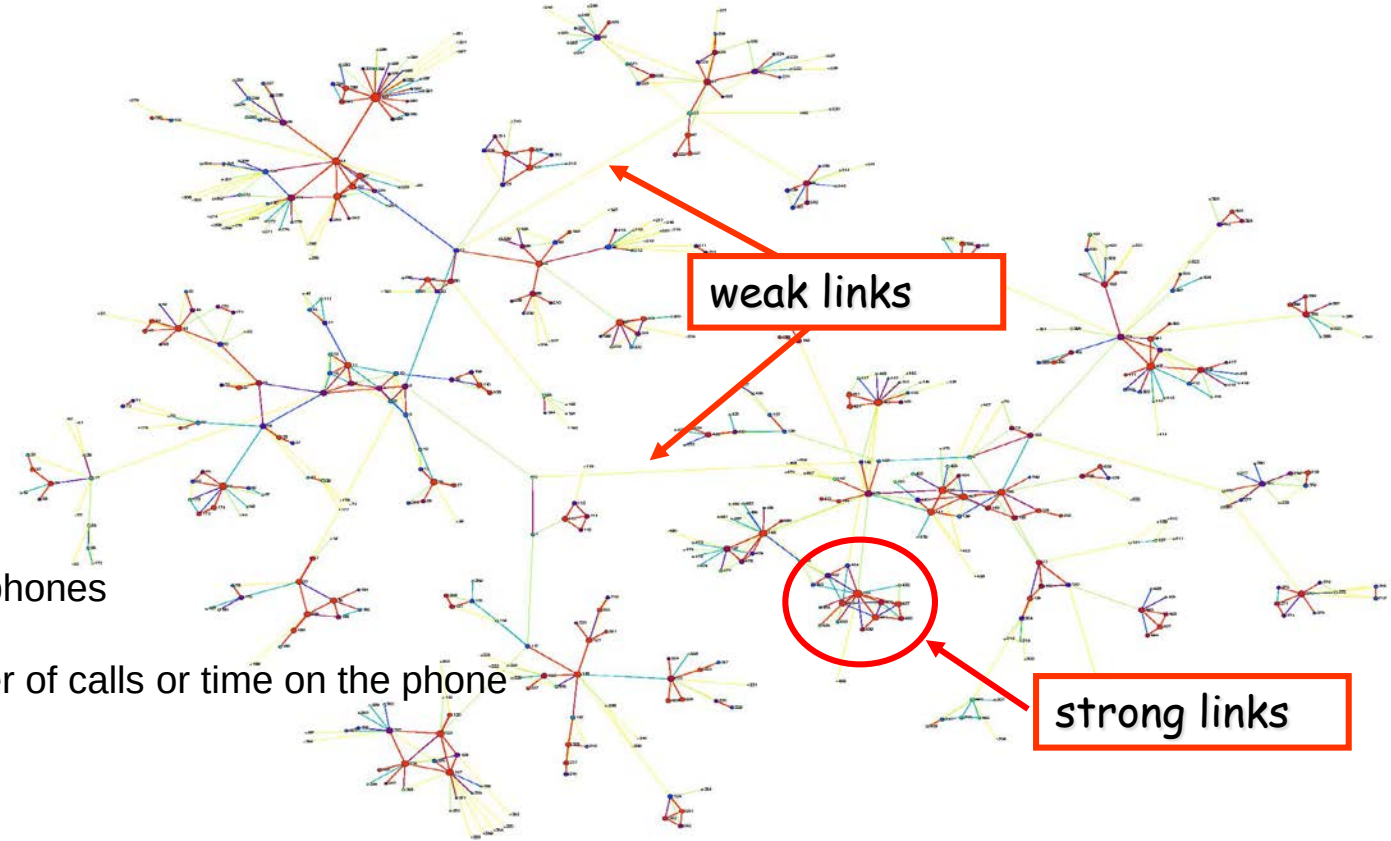
EXAMPLE 4: METABOLIC NETWORK



- Nodes: metabolites
- Links: reactions
- Link Weights: reaction flux

E. Almaas, B. Kovács, T. Vicsek, Z. N. Oltvai, A.-L. B. Nature, 2004; Goh et al, PRL 2002.

EXAMPLE 5: MOBILE CALL GRAPH



- Nodes: mobile phones
- Links: calls
- Weights: number of calls or time on the phone

Onella et al, PNAS 2007

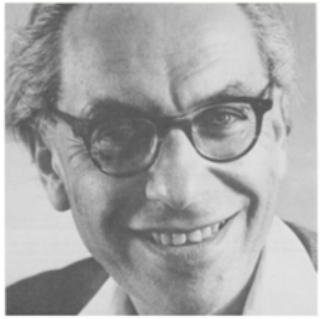
2. ¿Cómo es una red Social? ¿Cómo cambia con el tiempo?

- ¿Es posible simular redes que sigan un comportamiento real?
- ¿De esta manera podríamos entender como evoluciona la red?
- Dada una red real, ¿es posible identificar como se ha llegado hasta allí?
- Y quizás lo mas importante, ¿como evolucionará?

✓ Modelos de redes aleatorias.
✓ Simulación de redes.
✓ Análisis de la distribución del grado,
✓ Análisis de las Distancias entre nodos en una red.

MODELO DE RED ALEATORIA

Pál Erdös
(1913-1996)

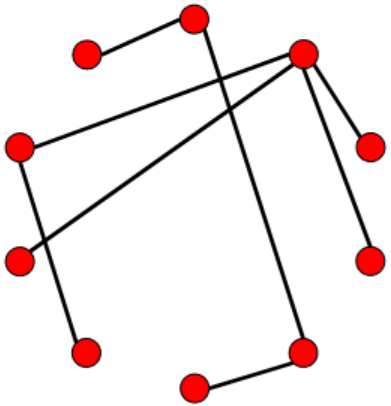




Alfréd Rényi
(1921-1970)

N=10 p=1/6

$\langle k \rangle$ ~ 1.5



Modelo Erdös-Rényi (1960):

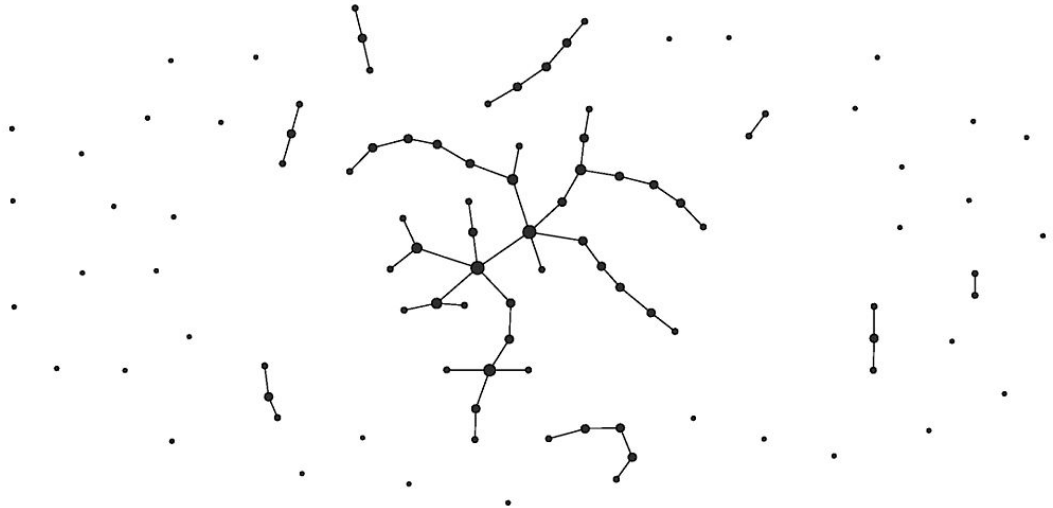
Un **grafo aleatorio** $G(N,p)$ es un grafo no dirigido con N nodos donde cada par de nodos está conectado aleatoriamente con una probabilidad prefijada ***p***

A primera vista, muchas redes reales parecen aleatorias

Este primer modelo de red compleja se basa en modelar esa aparente aleatoriedad mediante redes realmente aleatorias

Modelo Erdos-Renyi

En teoría de grafos el modelo Erdős–Rényi, nombrado así por ser un estudio que realizaron los matemáticos Paul Erdős y Alfréd Rényi, es uno de los métodos empleados en la generación de grafos aleatorios. En este modelo se tiene que un nuevo nodo se enlaza con igual probabilidad con el resto de la red, es decir posee una independencia estadística con el resto de nodos de la red. Hoy en día se emplea como base teórica para la generación de otras redes



Modelo Erdos-Renyi (Algoritmo 1)

Si consideramos N nodos de una red sin conectar y distribuidos de forma aleatoria, podemos imaginar que en un instante inicial enlazamos dos cualesquiera, de esta forma en pasos sucesivos vamos enlazando aleatoriamente de dos a dos nodos. Los nodos que se encuentren enlazados se descarta.

Si repetimos el proceso M veces eligiendo un par de nodos en cada turno al final habremos establecido como máximo M enlaces entre parejas de nodos. Si M es un valor pequeño con respecto al valor total de nodos muchos de los nodos estarán desconectados, mientras que por el contrario otros nodos estarán formando pequeñas islas.

Por el contrario si M es grande en comparación con N el número total de nodos, es muy posible que casi todos los nodos estén enlazados entre sí. Cuando se enlazan los nodos de esta forma aparecen propiedades específicas en la distribución de grado P(k) ya que posee propiedades de distribución de Poisson. Durante muchas décadas a partir de los años 1950 se pensó que las redes con esta característica eran las más adecuadas para describir ciertas redes complejas y pronto se vio que no era del todo cierto.

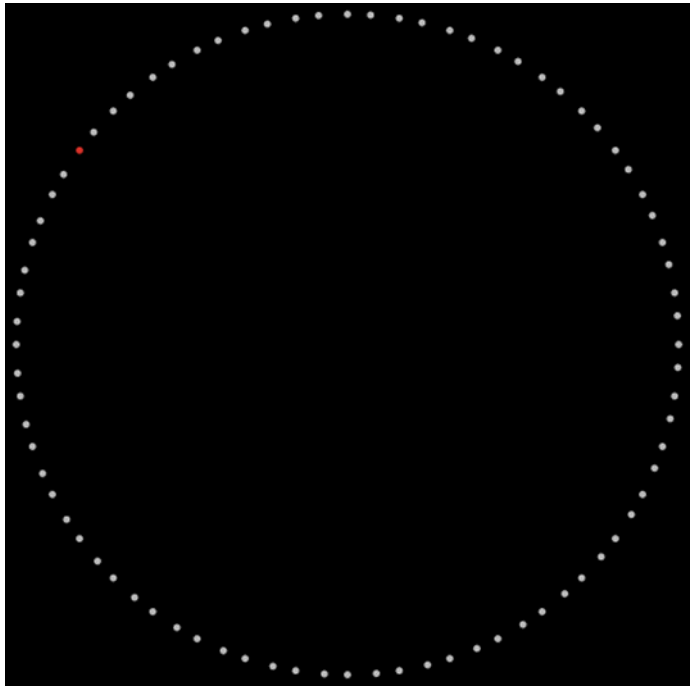
Modelo Erdos-Renyi (Algoritmo 2)

- Elija una probabilidad p para la creación de aristas. El valor de p determinará cuán densamente conectada está la gráfica.
- Comience con un conjunto de nodos (que se muestran distribuidos uniformemente alrededor del círculo en la primera imagen, aunque el diseño no es importante) pero sin conexiones entre ellos.
- Elija dos nodos al azar y agregue una arista entre ellos con probabilidad p.

Este procedimiento es similar al anterior

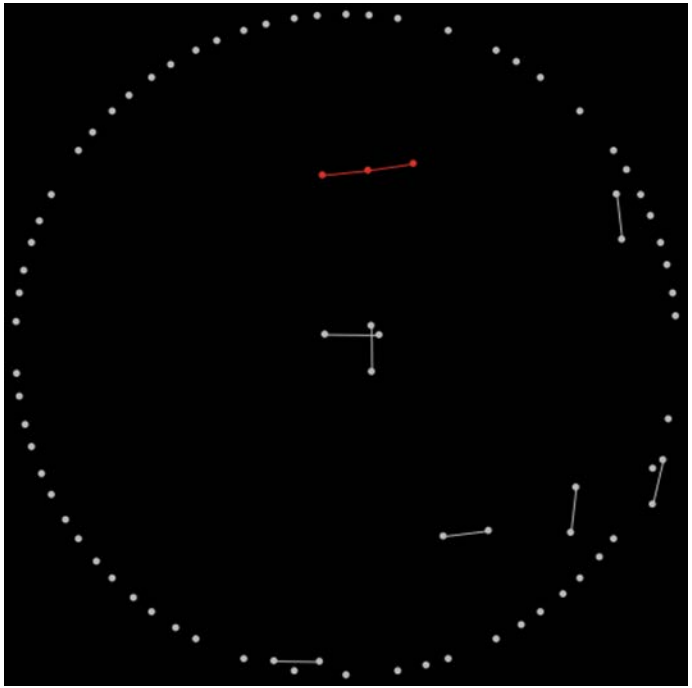
Modelo Erdos-Renyi

Situación inicial: Determinación del numero de nodos de la red



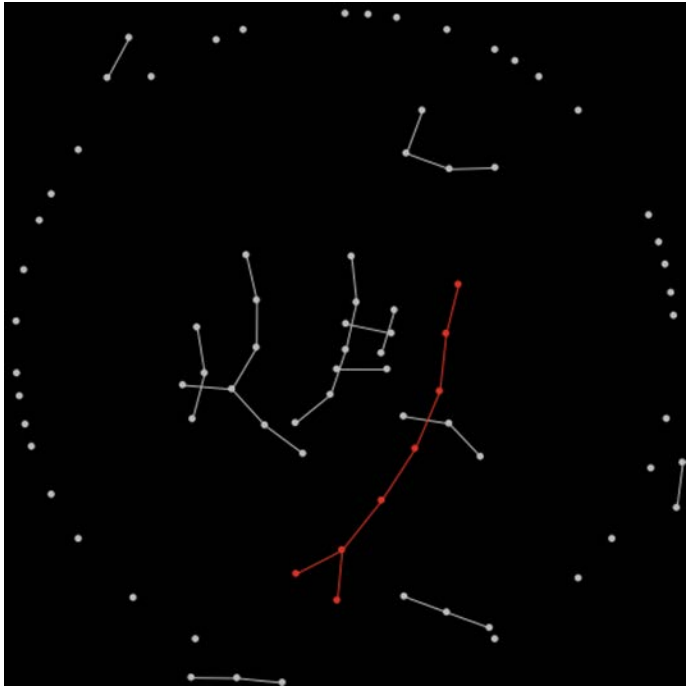
Modelo Erdos-Renyi

Situación intermedia: Primeras conexiones



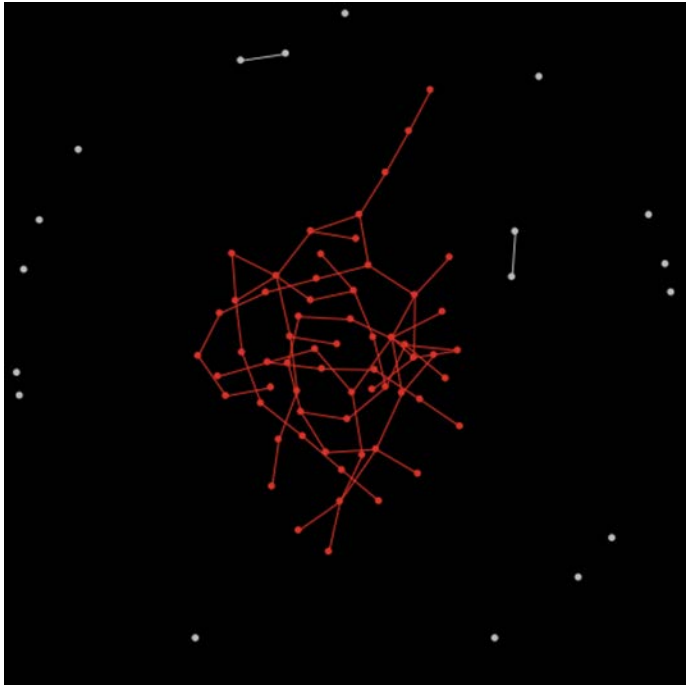
Modelo Erdos-Renyi

Situación intermedia: Emergen conexiones más largas



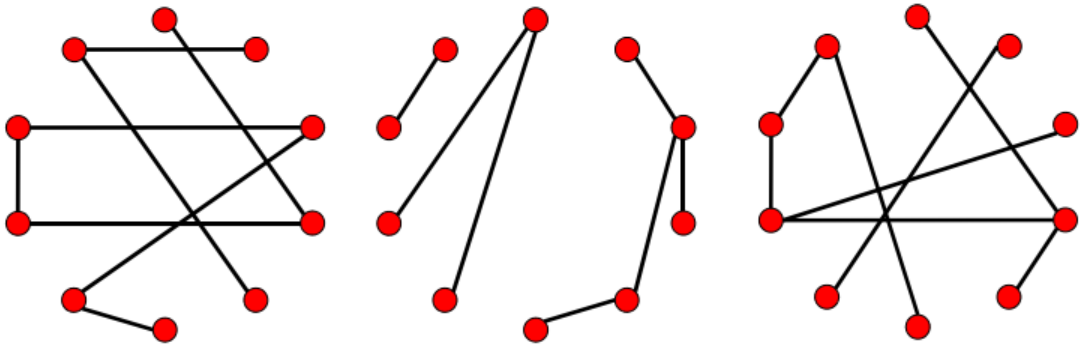
Modelo Erdos-Renyi

Situación final: Se termina generando una gran componente conexa



MODELO DE RED ALEATORIA: Variabilidad de los grafos aleatorios

N y ***p*** no definen unívocamente la red– puede haber muchas instanciaciones, diferentes en el número de enlaces *L* y en los enlaces concretos. **¿Cuántas?**



***N*=10**
***p*=1/6**

La probabilidad de generar un grafo aleatorio *concreto* **G(N,p)** con *L* enlaces es:

$$P(G(N,p)) = p^{L}(1-p)^{\frac{N(N-1)}{2}-L}$$

Es decir, cada grafo **G(N,p)** aparece con probabilidad **P(G(N,p))**

MODELO DE RED ALEATORIA: Grado medio

P(L): probabilidad de obtener una red con exactamente *L* enlaces (distribución binomial):

$$P(L) = \left(\binom{N}{2} \right) p^L (1-p)^{\frac{N(N-1)}{2} - L}$$

- El número esperado de enlaces <*L*> de un grafo aleatorio ***G(N,p)*** se calcula como el producto de la probabilidad de conexión y el número de enlaces (media de la distribución):

$$< L >= \sum_{L=0}^{\frac{N(N-1)}{2}} LP(L) = p\frac{N(N-1)}{2}$$

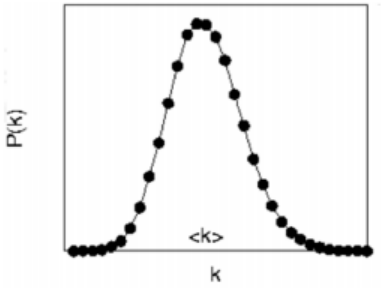
- **El grado medio es**:

$$< k >= 2L / N = p(N-1)$$

- La varianza es:

$$\sigma^2 = p(1-p)\frac{N(N-1)}{2}$$

MODELO DE RED ALEATORIA: Distribución (binomial) del grado



$$P(k) = \binom{N-1}{k} p^k (1-p)^{(N-1)-k}$$

Selección de *k* nodos de los *N*-1 a los que el nodo actual puede conectarse

Probabilidad de que *k* enlaces estén presentes

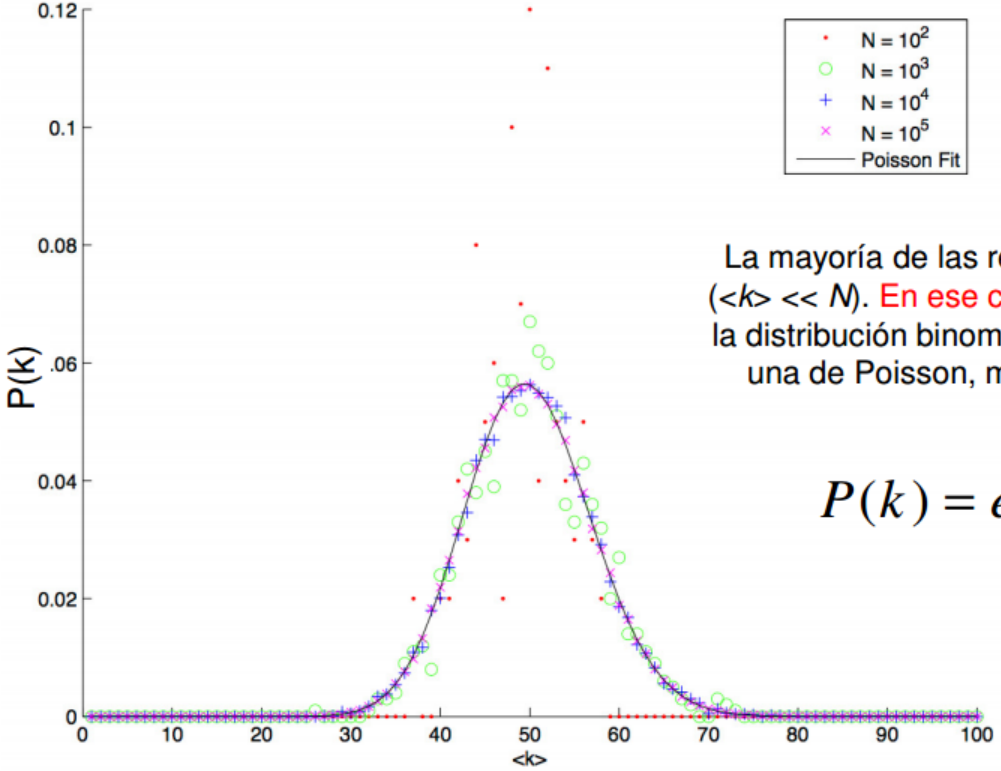
Probabilidad de que los otros *N*-1-*k* enlaces no estén presentes

$$< k >= p(N-1) \qquad \sigma_k^2 = p(1-p)(N-1)$$

$$\frac{\sigma_k}{< k >} = \left[\frac{1-p}{p}\frac{1}{(N-1)}\right]^{1/2} \approx \frac{1}{(N-1)^{1/2}}$$

Conforme aumenta el tamaño de la red, la distribución se va volviendo más estrecha, es decir, tenemos una seguridad creciente de que el grado de un nodo está en la vecindad de <*k*>

MODELO DE RED ALEATORIA: Distribución (Poisson) del grado



La mayoría de las redes reales son dispersas ($\langle k \rangle << N$). En ese caso y cuando N es grande, la distribución binomial se puede aproximar por una de Poisson, más cómoda de manejar:

$$P(k) = e^{-\langle k \rangle} \frac{\langle k \rangle^k}{k!}$$

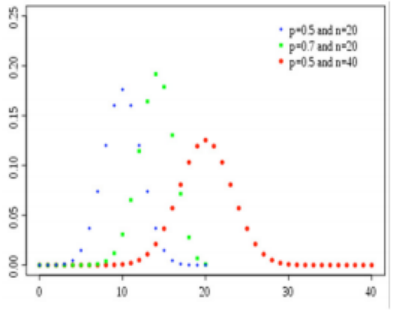
MODELO DE RED ALEATORIA:

Comparativa de distribuciónes del grado

Resultado Exacto

-distribución binomial-

$$P(k) = \binom{N-1}{k} p^k (1-p)^{(N-1)-k}$$



Función de Distribución de Probabilidad (PDF)

$$< k >= (N-1)\,p$$

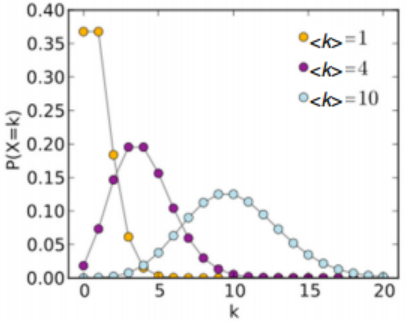
$$< k^2 >= p(1-p)(N-1) + p^2 (N-1)^2$$

$$\sigma_k = (< k^2 > - < k >^2)^{1/2} = [p(1-p)(N-1)]^{1/2}$$

Límite con <*k*> << *N* y *N* grande

-distribución de Poisson-

$$P(k) = e^{-<k>} \frac{< k >^k}{k!}$$



$$< k >=< k >$$

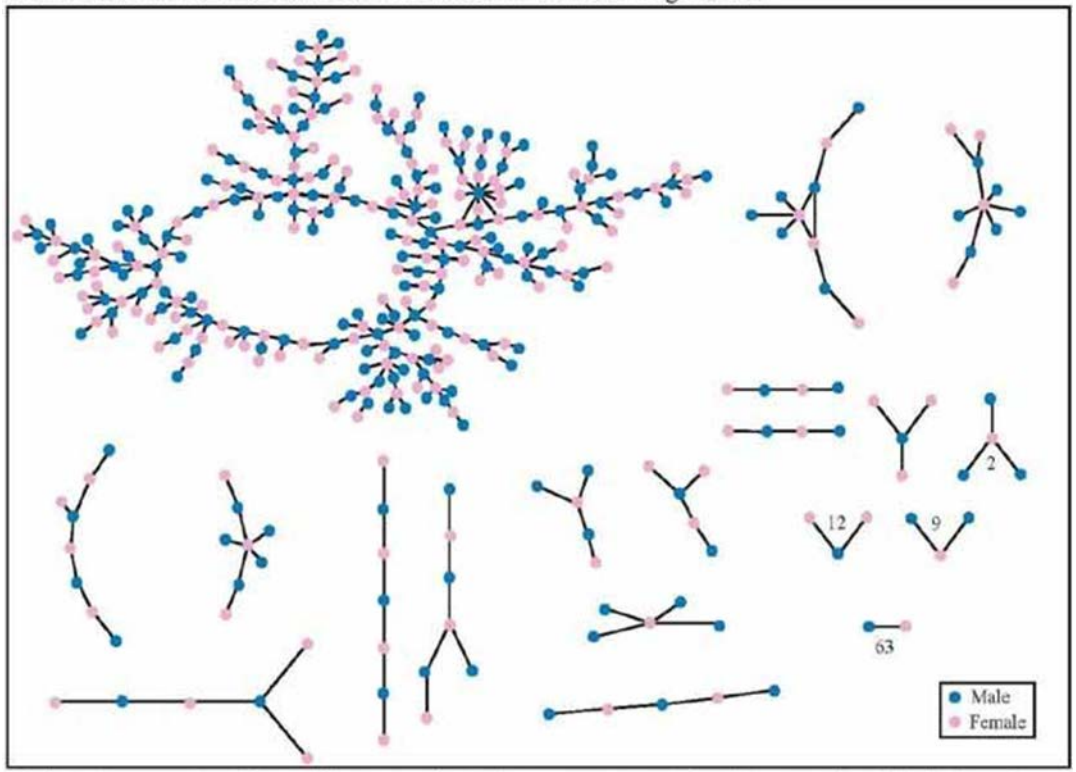
$$< k^2 >=< k > (1+ < k >)$$

$$\sigma_k = (< k^2 > - < k >^2)^{1/2} =< k >^{1/2}$$

Poisson: Todo depende de un solo parámetro <*k*> y no depende explícitamente del número de nodos *N*. Predice que la distribución del grado es la misma en redes de distintos tamaños en tanto en cuanto tengan el mismo grado medio

¿Hay redes aleatorias? ¿El amor es aleatorio?

The Structure of Romantic and Sexual Relations at "Jefferson High School"



Each circle represents a student and lines connecting students represent romantic relations occuring within the 6 months preceding the interview. Numbers under the figure count the number of times that pattern was observed (i.e. we found 63 pairs unconnected to anyone else).

MyCombedSpace.com

MODELO DE RED ALEATORIA: Utilidad del modelo de red aleatoria

Y si es erróneo e irrelevante, ¿por qué se estudia?

A pesar de todo, es un modelo de referencia. Posibilita calcular muchas medidas que pueden confrontarse con los datos reales, permitiendo entender hasta qué punto una propiedad particular es consecuencia de un proceso aleatorio

Principios organizativos: patrones que se producen en redes reales, observados en un gran número de ellas, y que se desvían de las predicciones del modelo de red aleatoria

Para identificarlos, necesitamos comprender cómo sería una propiedad particular si estuviese guiada por un proceso puramente aleatorio

Si la propiedad observada está ausente en las redes aleatorias, merece la pena estudiarla porque puede representar algún tipo de orden

¡Aunque ERRÓNEO e IRRELEVANTE, el modelo resulta ser extremadamente ÚTIL!

Modelo Barabasi-Albert

En teoría de redes se denomina Modelo de Barabási–Albert como un algoritmo empleado para generar redes aleatorias complejas libres de escala empleando una regla o mecanismo denominado conexión preferencial.

Las redes generadas por este algoritmo poseen una distribución de grado de tipo potencial y que se denominan: redes libres de escalas. Las redes de este tipo son muy frecuentes en los sistemas elaborados por el ser humano así como en la naturaleza.

Ejemplos de sistemas de este tipo son Internet, el world wide web, redes de citas, y algunas redes sociales, redes eléctricas.

El modelo toma el nombre de Albert-László Barabási y Réka Albert autores que lo popularizaron en 1999.

Modelo Barabasi-Albert

La red comienza con un conjunto de m0 nodos conectados aleatoriamente.

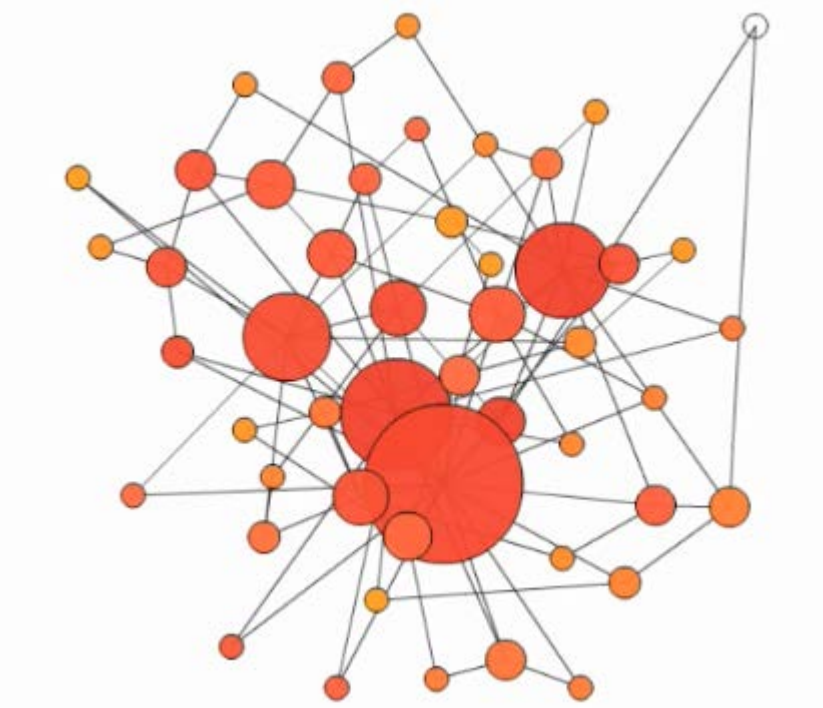
Debe notarse que m0 \ geq 2 y el grado de cada nodo en la red inicial debe ser al menos 1, de otra forma la evolución de la red, a medida que se van añadiendo nodos, haría que éstos permanecieran desconectados completamente de la red.

Los nuevos nodos se añaden a la red de uno a uno. Cada nodo es conectado a m nodos de la red con una probabilidad que es proporcional al número de enlaces que posee los nodos de la red, es decir, los nuevos nodos se enlazan preferiblemente con los nodos más conectados. Formalmente la probabilidad p_i de que un nuevo nodo se conecte con j es:

$$p_i = \frac{k_i}{\sum_j k_{j'}}$$

donde k_i es el grado del nodo i. Los nodos con gran cantidad de conexiones ("hubs") tienden a acumular rápidamente más enlaces, mientras que los que poseen pocos enlaces rara vez son el origen de nuevos enlaces. Los nuevos nodos según este algoritmo se dice que poseen una "preferencia" a ser enlazados con los nodos más solicitados. Este algoritmo se fundamenta en el concepto de "conexión prefencial" de los nuevos nodos que se incorporan a la red.

Modelo Barabasi-Albert (m=2 empezando con un triangulo)



Modelo Barabasi-Albert

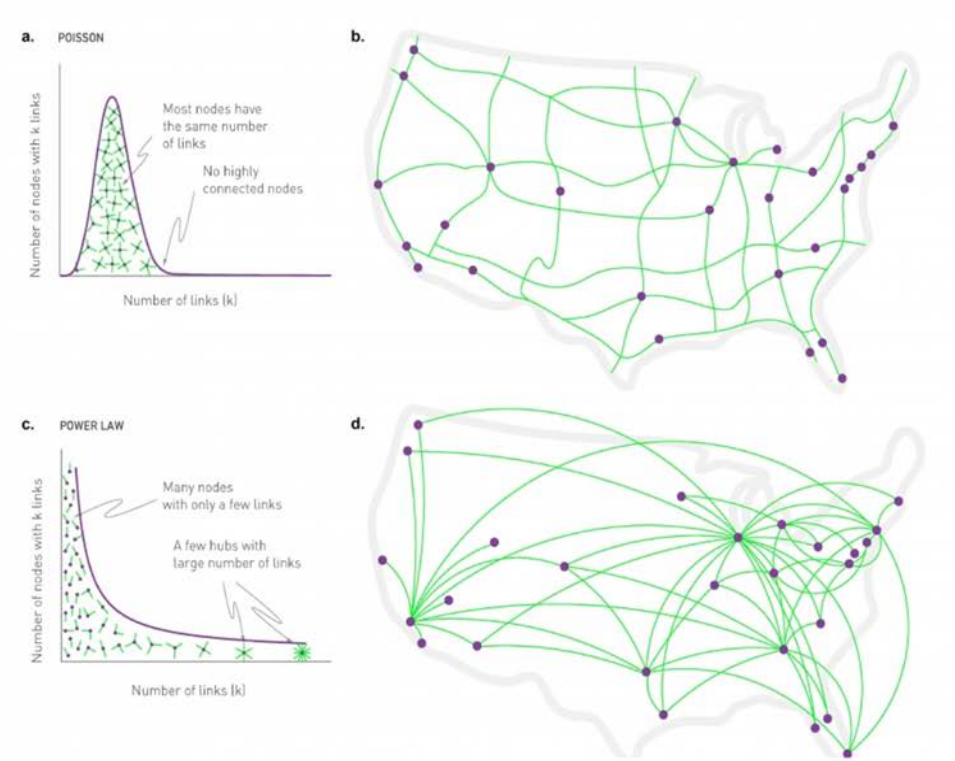
Ejercicio 3.

1. Suponiendo que se empieza con un triangulo y que en cada iteración se añaden 2 aristas. Y que el tamaño final es 23 determinar el numero de aristas y el grado medio.

Solución.
Empezamos con 3 nodos y 3 aristas. Para el resto de 20 nodos añadimos 2 aristas, por lo que el numero total de aristas será de 20*2=40 aristas nuevas a las 3 que ya teníamos.
Nodos=N=23
Aristas=L=43
<k>=1.86

Para un m genérico y un N genérico tenemos. Suponiendo No <N, Lo<L, tenemos
Nodos=N
Empezamos con No nodos y Lo aristas. Para el resto de los N-No nodos añadimos m aristas, por lo que el numero total de aristas será L=Lo+(N-No)*m.
<k>=Lo+(N-No)*m/N.

Modelo Erdos VS Barabasi-Albert



SUPONIENDO QUE EL TAMAÑO Y EL NUMERO DE ARISTAS ES EL MISMO

¿CUALES SON LAS DIFERENCIAS ENTRE REDES ALEATORIAS Y REDES LIBRES DE ESCALA?

Red de libre escala

$$k_i(t) = m\left(\frac{t}{t_i}\right)^{\beta} \qquad \beta = \frac{1}{2}$$

$$P(k) = \frac{2m^2 t}{m_o + t}\frac{1}{k^3} \sim k^{-\gamma} \qquad \boxed{\gamma = 3}$$

(i) El exponente del grado es independiente de m.

(ii) A medida que la ley de potencia describe sistemas de duraciones y tamaños bastante diferentes, se espera que un modelo correcto proporcione una distribución del grado independiente del tiempo. De hecho, asintóticamente, la distribución en grados del modelo BA es independiente del tiempo (y del tamaño del sistema N)→ La red alcanza un estado estacionario sin escala.

(iii) El coeficiente de la distribución de la ley de potencia es proporcional a m^2.

A.-L.Barabási, R. Albert and H. Jeong, *Physica* A **272,** 173 (1999)

Red de libre escala

Scale-free network

From Wikipedia, the free encyclopedia

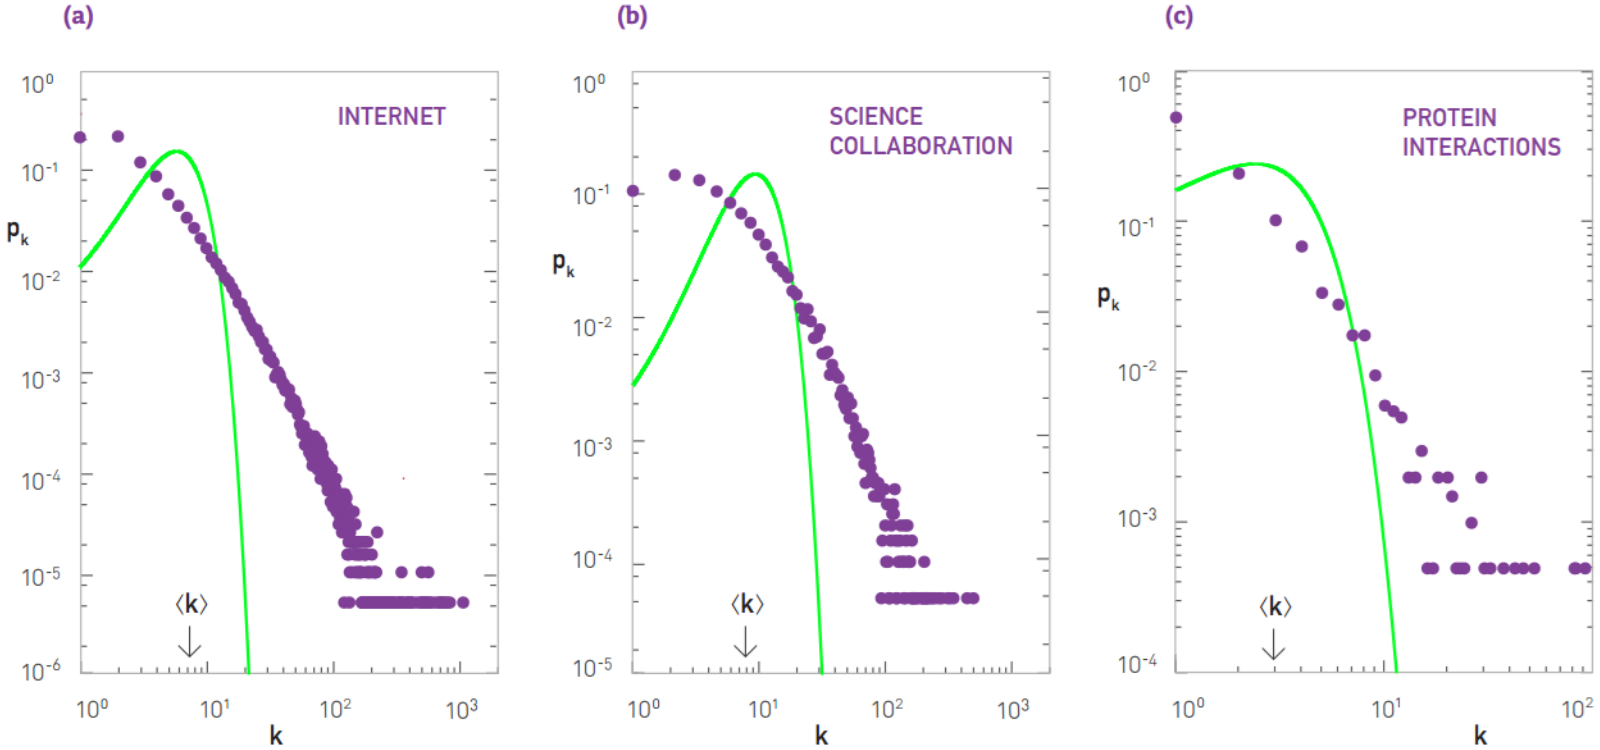
A **scale-free network** is a network whose degree distribution follows a power law, at least asymptotically. That is, the fraction $P(k)$ of nodes in the network having k connections to other nodes goes for large values of k as

$$P(k) \sim k^{-\gamma}$$

where γ is a parameter whose value is typically in the range $2 < \gamma < 3$, although occasionally it may lie outside these bounds.[1][2]

Many networks have been reported to be scale-free, although statistical analysis has refuted many of these claims and seriously questioned others.[3] Preferential attachment and the fitness model have been proposed as mechanisms to explain conjectured power law degree distributions in real networks.

Red de libre escala



Red de libre escala

Las redes sociales se suelen clasificar según la distribución que sigue el grado. A partir de ahí, se buscan diferentes algoritmos para simular como se ha llegado hasta esa distribución. Scale-Free network. El grado sigue una distribución de “power law”.

a) The Barabási–Albert model
b) Two-level network model
c) Mediation-driven attachment (MDA) model
d) Non-linear preferential attachment
e) Hierarchical network model
f) Fitness model
g) Hyperbolic geometric graphs
h) Edge dual transformation to generate scale free graphs with desired properties.

Estas redes son de distribución altamente heterogénea, que sigue una “ley de poder” (Barabasi & Albert 1999). Se denominan sin escala, ya que amplían cualquier parte de la la distribución no cambia su forma: hay pocos, pero un número significativo de nodos con mucho de conexiones y hay una cola final de nodos con muy pocas conexiones en cada nivel de ampliación. Dichas redes son típicas de la estructura de la red mundial, mapas semánticos, circuitos electrónicos.

Predicciones con solo una Red

1) Si la red es aleatoria y se prevé un crecimiento de c aristas, la mejor predicción del grado de un nodo en concreto será $k_i + (2c/n)$.

2) Si la red es libre de escala y se prevé un crecimiento de c aristas, la mejor predicción del grado de un nodo en concreto será aproximadamente $k_i + (2ck_i/\sum_{j\in N} k_j)$.

Nodo	Grado	Aleatoria (c=20)	Libre Escala (c=20)
1	5	15	10
2	5	15	10
3	10	20	20
4	20	30	40

3) Es muy importante coger la red con el corte temporal adecuado, si es muy voluble en el tiempo necesitaré una red con las conexiones más cercanas, si es poco voluble podré coger una red con las conexiones a más largo plazo.

Red de pequeño mundo

Las redes sociales se suelen clasificar según la distribución que sigue el grado. A partir de ahí, se buscan diferentes algoritmos para simular como se ha llegado hasta esa distribución.

Sin embargo, la mayoría de las redes del mundo real, especialmente las redes sociales, no tienen sistemas homogéneos en la distribución del grado y las conexiones de cada nodo. Se colocan en algún lugar entre las redes regulares y aleatorias. De hecho, Watts y Strogatz (1998) propusieron un modelo donde las conexiones entre los nodos en un gráfico regular fueron reconfigurados con cierta probabilidad. Los gráficos resultantes fueron entre los regulares y los aleatorios en su estructura y se conocen como redes de mundo pequeño (SW).

Las redes de SW están muy cerca estructuralmente de muchas redes sociales en el sentido de que tienen una agrupación más alta y casi la misma ruta promedio que las redes aleatorias con el misma número de nodos y aristas. Las redes SW suelen tener una alta modularidad (grupos de nodos que son más densos conectados entre sí que al resto de la red).

Red de pequeño mundo

Una red de mundo pequeño es un tipo de grafo para el que la mayoría de los nodos no son vecinos entre sí, y sin embargo la mayoría de los nodos pueden ser alcanzados desde cualquier nodo origen a través de un número relativamente corto de saltos entre ellos.

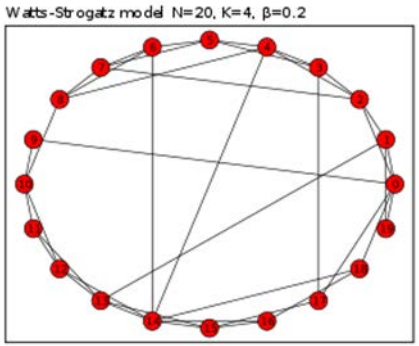
En el caso de una red social, donde los nodos son personas y los enlaces son el conocimiento/relación entre ellos se puede decir que captura muchos de los fenómenos de las redes de mundo pequeño.

Pronto se empezaría a ver que las redes de mundo pequeño son más frecuentes de lo que se presupone y pronto aparecieron otras redes bajo esta categoría: un ejemplo muy claro es la topología de Internet. Este fenómeno ha dado la posibilidad de aplicación de este tipo de redes en diferentes áreas de la ciencia como puede ser el modelado de redes sociales, física, biología, epidemiología, etc.

Este tipo de redes tienen como ejemplo “los seis grados de separación” que conectan el mundo (Stanley Milgram (1967)).

Red de pequeño mundo (algoritmo de watts y strogatz)

El algoritmo de construcción propuesto por watts y strogatz para las redes de mundo pequeño es el siguiente: se establece una red inicial unidimensional con N nodos, estos nodos se pueden disponer en forma de anillo de tal forma que cada uno de los vértices (o nodos) se una con 2k vecinos. La probabilidad de conectar un nodo con otro cualquiera es de p. Para un grafo con p=0 se puede ver que la conectividad es la misma y de valor 2k. por otro lado un valor no nulo de p introduce desorden en la red de tal forma que la conectividad no es uniforme, manteniendo todavía de media un valor de 2k.



Red de 20 nodos construida según el modelo Watts y Strogatz (N=20, k=4, β=0.2).

Red de pequeño mundo (algoritmo de watts y strogatz)

Algorithm [edit]

Given the desired number of nodes N, the mean degree K (assumed to be an even integer), and a special parameter β, satisfying $0 \leq \beta \leq 1$ and $N \gg K \gg \ln N \gg 1$, the model constructs an undirected graph with N nodes and $\frac{NK}{2}$ edges in the following way:

1. Construct a regular ring lattice, a graph with N nodes each connected to K neighbors, $K/2$ on each side. That is, if the nodes are labeled $n_0 \dots n_{N-1}$, there is an edge (n_i, n_j) if and only if $0 < |i-j| \mod \left(N - 1 - \frac{K}{2}\right) \leq \frac{K}{2}$.
2. For every node $n_i = n_0, \dots, n_{N-1}$ take every edge (n_i, n_j) with $i < j$, and rewire it with probability β. Rewiring is done by replacing (n_i, n_j) with (n_i, n_k) where k is chosen with uniform probability from all possible values that avoid self-loops ($k \neq i$) and link duplication (there is no edge $(n_i, n_{k'})$ with $k' = k$ at this point in the algorithm).

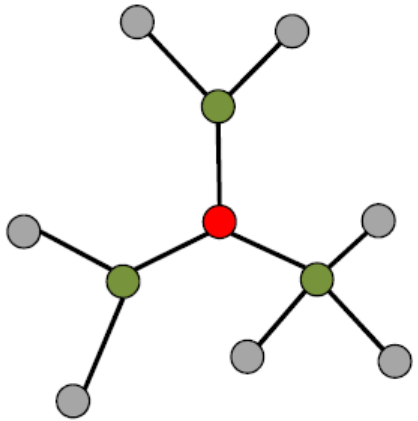
Properties [edit]

The underlying lattice structure of the model produces a locally clustered network, and the random links dramatically reduce the average path lengths. The algorithm introduces about $\beta\frac{NK}{2}$ non-lattice edges. Varying β makes it possible to interpolate between a regular lattice ($\beta = 0$) and a random graph ($\beta = 1$) approaching the Erdős–Rényi random graph $G(n,p)$ with $n = N$ and $p = \frac{NK}{2\binom{N}{2}}$.

The three properties of interest are the average path length, the clustering coefficient, and the degree distribution.

MODELO DE RED ALEATORIA: Distancias en redes aleatorias (1)

Los grafos aleatorios tienden a tener una topología en forma de árbol con nodos de grado casi constante:



- no. de vecinos a distancia 1: $N_1 \cong \langle k \rangle$
- no. de vecinos a distancia 2: $N_2 \cong \langle k \rangle^2$
- no. de vecinos a distancia *d*: $N_d \cong \langle k \rangle^d$

- Estimación de la distancia máxima (**fórmula de los mundos pequeños**):

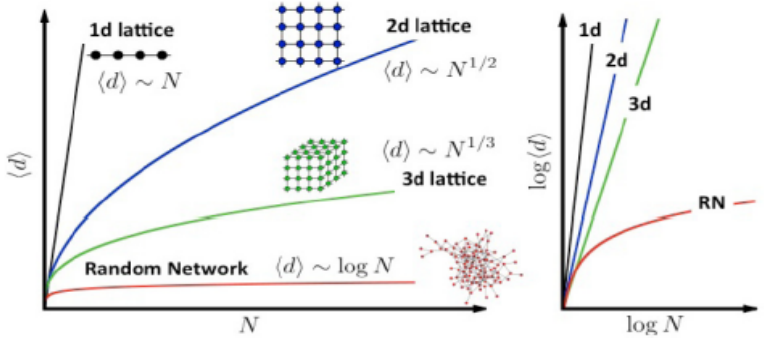
$$N = 1 + \langle k \rangle + \langle k \rangle^2 + \ldots + \langle k \rangle^d = \frac{\langle k \rangle^{d+1} - 1}{\langle k \rangle - 1} \approx \langle k \rangle^d \quad \Rightarrow \quad d_{\max} = \frac{\log N}{\log \langle k \rangle}$$

Comentarios:

- **En la mayoría de los casos, la fórmula aproxima mejor <*d*> que d_{max}**. Esto se debe a que en la práctica d_{max} está dominada por unos pocos caminos de longitud extrema mientras que <*d*> está promediada entre todos los pares de nodos

$$\langle d \rangle = \frac{\log N}{\log \langle k \rangle}$$

- En general, log *N* << *N*. Por tanto, el hecho de que <*d*> dependa de log *N* implica que **las distancias en una red aleatoria son varios órdenes de magnitud menores que el tamaño de la red**



- El término 1/log <*k*> implica que, cuanto más densa es la red, menor es la distancia entre sus nodos

MODELO DE RED ALEATORIA: Distancias en redes aleatorias (3)

En la práctica, la fórmula aproxima mejor <*d*> que d_{max}

$$\langle d \rangle = \frac{\log N}{\log \langle k \rangle}$$

Validación sobre redes reales:

Network Name	N	L	‹k›	‹d›	d_{max}	$\frac{\log N}{\log\langle k\rangle}$
Internet	192,244	609,066	6.34	6.98	26	6.59
WWW	325,729	1,497,134	4.60	11.27	93	8.32
Power Grid	4,941	6,594	2.67	18.99	46	8.66
Mobile Phone Calls	36,595	91,826	2.51	11.72	39	11.42
Email	57,194	103,731	1.81	5.88	18	18.4
Science Collaboration	23,133	186,936	8.08	5.35	15	4.81
Actor Network	212,250	3,054,278	28.78	-	-	-
Citation Network	449,673	4,707,958	10.47	11.21	42	5.55
E Coli Metabolism	1,039	5,802	5.84	2.98	8	4.04
Yeast Protein Interactions	2,018	2,930	2.90	5.61	14	7.14

Dadas las grandes diferencias en temática, tamaño y grado medio, el ajuste es bastante bueno

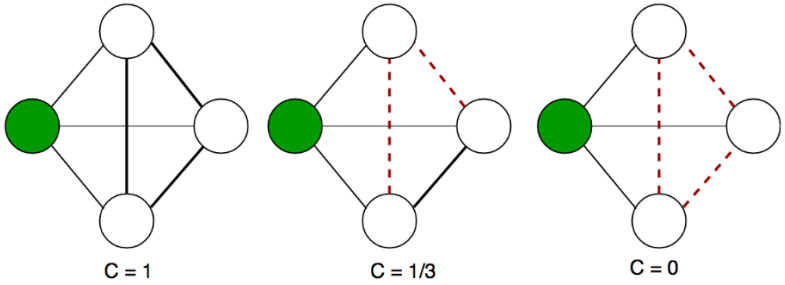
Red de pequeño mundo (Sigma y Omega)

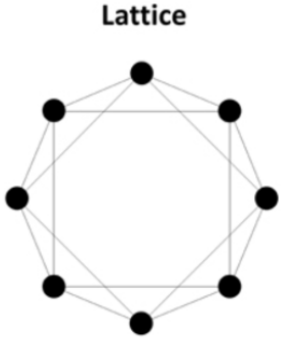
$$\sigma = \frac{\frac{C}{C_r}}{\frac{L}{L_r}} \qquad \omega = \frac{L_r}{L} - \frac{C}{C_\ell}$$

Se definen dos maneras alternativas de decidir si una red es de pequeño mundo:
1) Coeficiente sigma que es el ratio entre dos cocientes. El cociente de el coeficiente de clustering medio (C) de mi red y una red aleoria similar a mía, y el cociente de la longitud media de los caminos minimos (L) de mi red y una red aleatoria similar a la mía. Cuando toma valores mayores que 1 se dice que es de pequeño mundo.

2) Coeficiente omea que puede definirse como la resta entre los cocientes de la longitud media de los caminos minimos de mi red y una red aleoria similar a mía y el cociente de el coeficiente de clustering medio de una red enrejada (lattice) similar a mía y mi red.

El valor de C es el porcentaje de mis vecinos que son vecinos entre ellos.





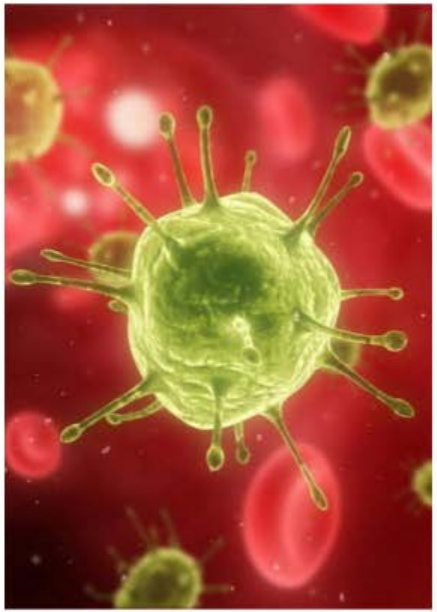
2.¿Cuál es su capacidad de difusión?

Existen diferentes modelos para estudiar como a partir de unos nodos infectados la información, virus, .. Se propaga en la red, en función de como se produce la imunidad y el contagio.

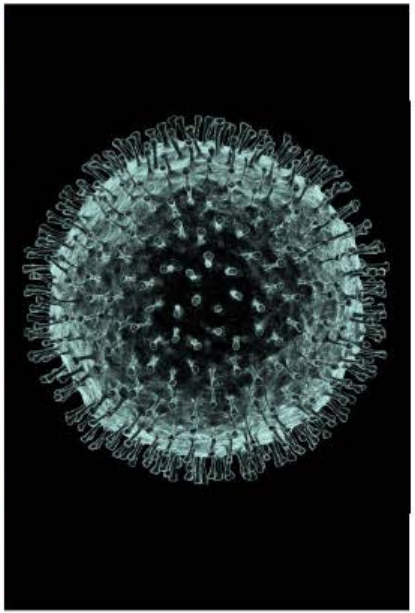
Estos modelos son complejos y en muchas ocasiones se realizan mediante simulación.

No obstante, uno de los problemas mas relevantes son a quien debo infectar/proteger para que la idea/virus se propague con mayor velocidad o para proteger a la población de una epidemia.

Este problema es un problema np-duro y se resuelve mediante distintas heurísticas.



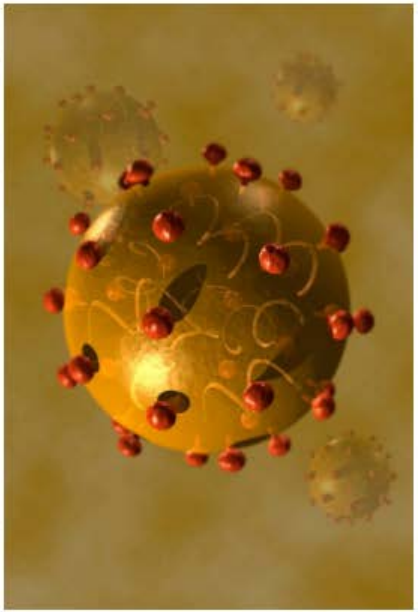
HIV



SARS

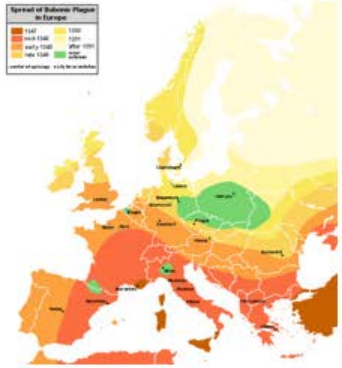


influenza

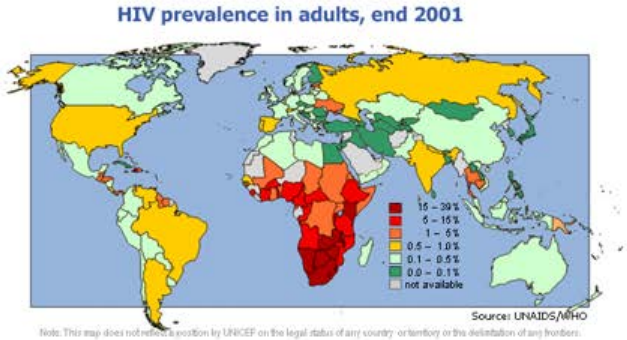


Hepatitis C

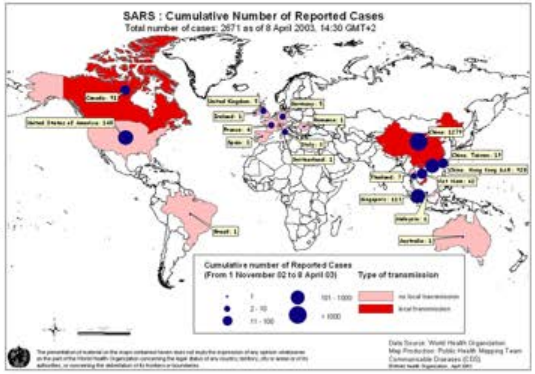
The Great Plague



HIV



SARS

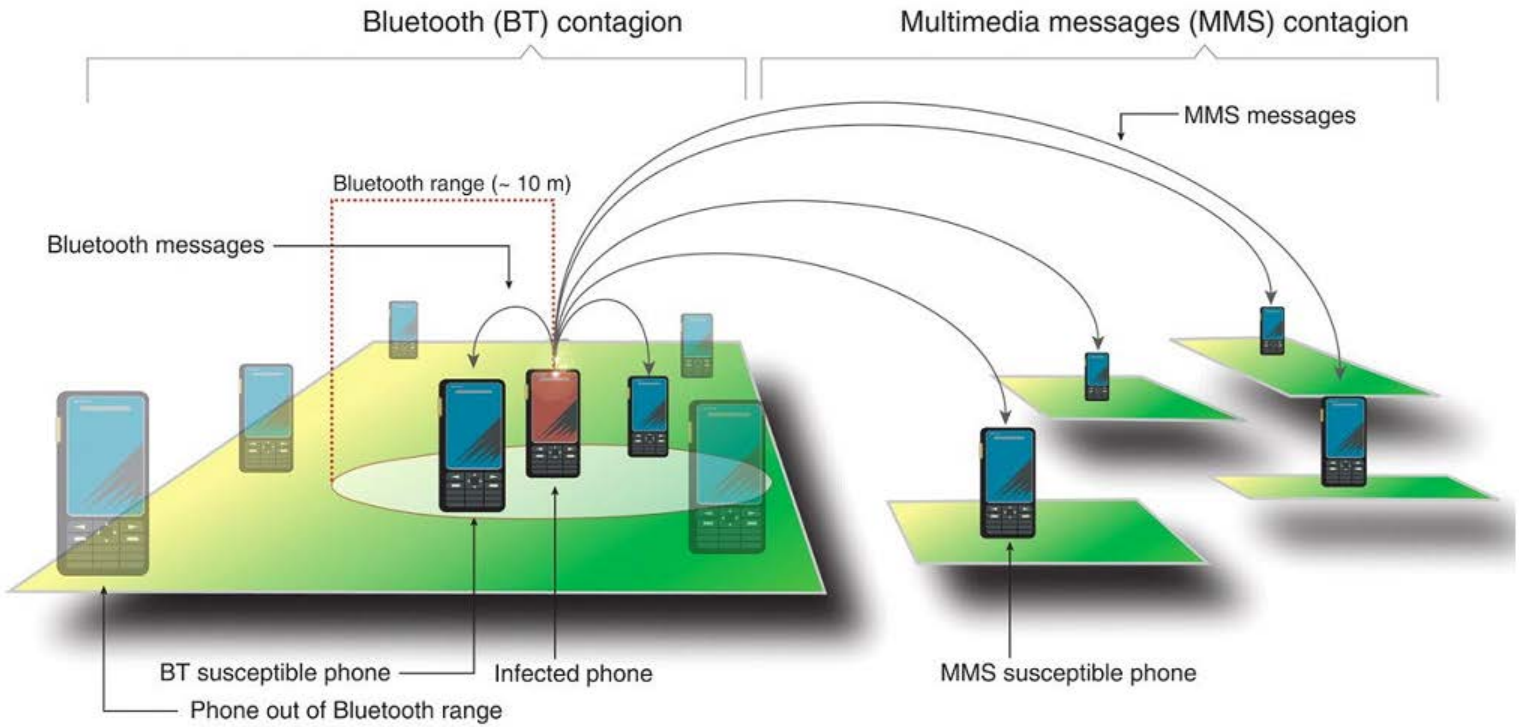




1918 Spanish flu



H1N1 flu


Bluetooth (BT) contagion
Multimedia messages (MMS) contagion
MMS messages
Bluetooth range (~ 10 m)
Bluetooth messages
BT susceptible phone
Infected phone
Phone out of Bluetooth range
MMS susceptible phone

PHENOMENA	AGENT	NETWORK
Venereal Disease	Pathogens	Sexual Network
Rumor Spreading	Information, Memes	Communication Network
Diffusion of Innovations	Ideas, Knowledge	Communication Network
Computer Viruses	Malwares, Digital viruses	Internet
Mobile Phone Virus	Mobile Viruses	Social Network/Proximity Network
Bedbugs	Bedbugs	Hotel - Traveler Network
Malaria	Plasmodium	Mosquito - Human network

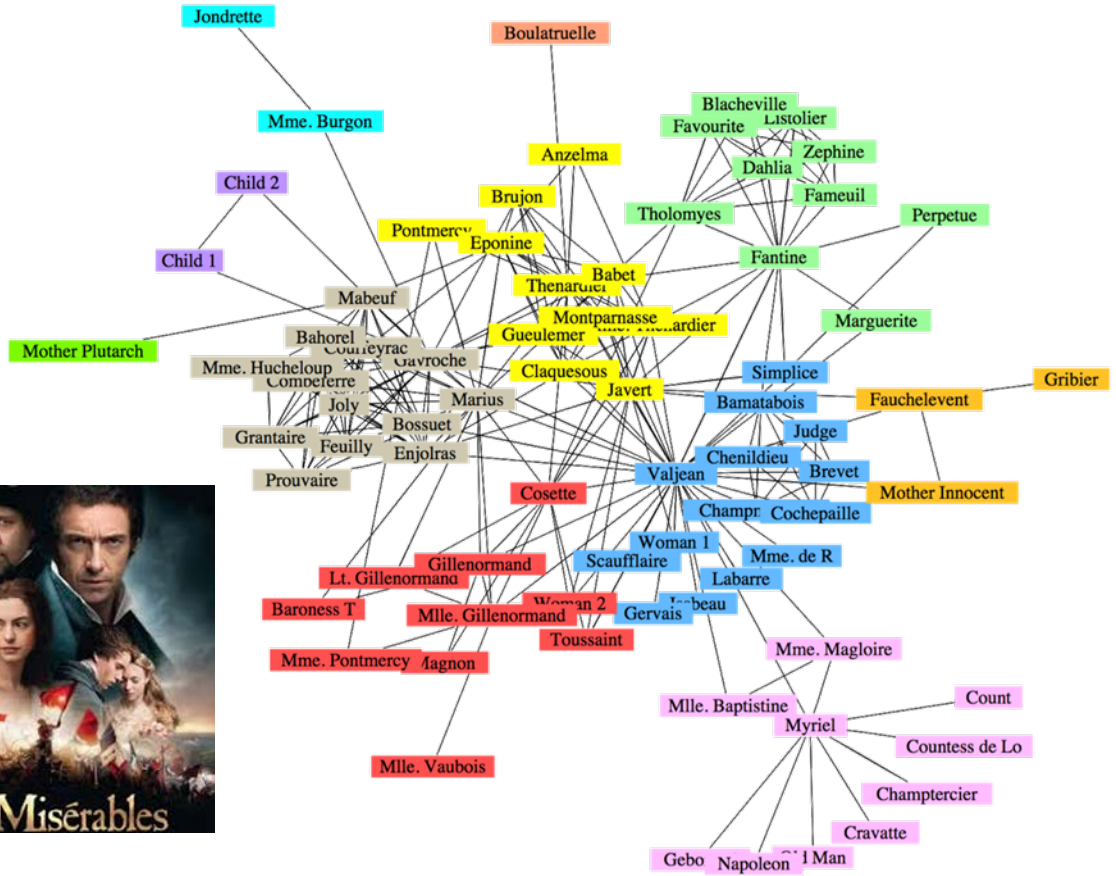
3. ¿Cuál es el poder e influencia de cada individuo-nodo en la red?

¿ Dónde medir la importancia-relevancia de la posición que ocupa un Individuo-nodo en una red ?

- Identificación de genes relevantes en para diabetes, alzeimer, enfermedades mentales, crecimiento.
- Control de epidemias (tanto a nivel global como local).
- Contagiar la red con información relevante (marketing virial?)
- Proteger una red frente ataques. Terrorismo.
- Problemas de transporte. Localización.
- Determinacion de lideres en una estructura. Blogeros mas influyentes en Twiter, Instagram, Facebook,….
- Conocer la influencia de unos nodos sobre otros (administracion, politica, empresa).
- Internet Google Page Rank.
- Agricultura, Forestales,-----

¿ Dónde medir la importancia-relevancia de la posición que ocupa un Individuo-nodo en una red ?





¿ Dónde medir la importancia-relevancia de la posición que ocupa un Individuo-nodo en una red ?

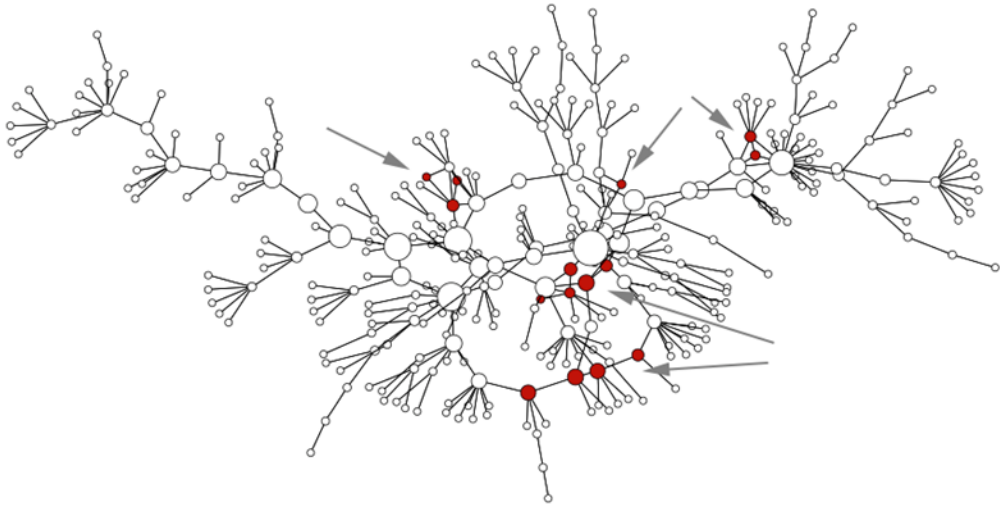
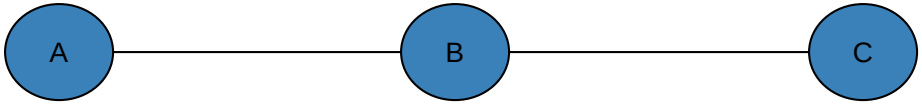


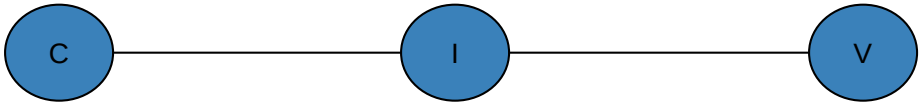
Figure 5: The largest component of a network of sexual contacts between high-risk actors in the city of Colorado Springs, CO, as reconstructed by Potterat *et al.* (2002). The size of the vertices increases linearly with their random-walk betweenness, as defined in this paper. The highlighted vertices (also indicated by the arrows) are those for which the random-walk betweenness is substantially greater than shortest-path betweenness (a factor of two or more).

¿ Dónde medir la importancia-relevancia de la posición que ocupa un Individuo-nodo en una red ?

Esquema político



Comprador-Intermediario-Vendedor



Medidas de Centralidad

Centralidad. Noción sociológica que no ha sido rigorosamente definida. Se suele definir de forma indirecta. Diremos que un nodo es central si:

- Puede comunicarse directamente con muchos nodos ó
- Es cercano a muchos nodos ó
- Existen muchos pares de nodos que le necesitan como intermediario en sus comunicaciones.

Medidas de Centralidad

- Degree centrality (Shaw, 1954, and Nieminen, 1974)
- Closeness centrality (Beauchamp, 1965 and Sabidussi, 1966)
- Betweenness centrality (Bavelas, 1948 and Freeman, 1977)
- Stephenson and Zelen (1989)
- Katz centrality
- Bonacich (1972) (autovalor).
- Flow centrality (Freeman)
- Page Rank (Google)
- Hubs and Authorities
- Game theory centrality measure (Gomez et al. 2003)
- Multicriteria centrality measure (Gomez et al. 2014)

Medidas de Centralidad (Closeness Centrality)

Closeness centrality [edit]

In connected graphs there is a natural distance metric between all pairs of nodes, defined by the length of their shortest paths. The **farness** of a node *x* is defined as the sum of its distances from all other nodes, and its closeness was defined by Bavelas as the reciprocal of the farness,[9][10] that is:

$$C(x) = \frac{1}{\sum_y d(y,x)}.$$

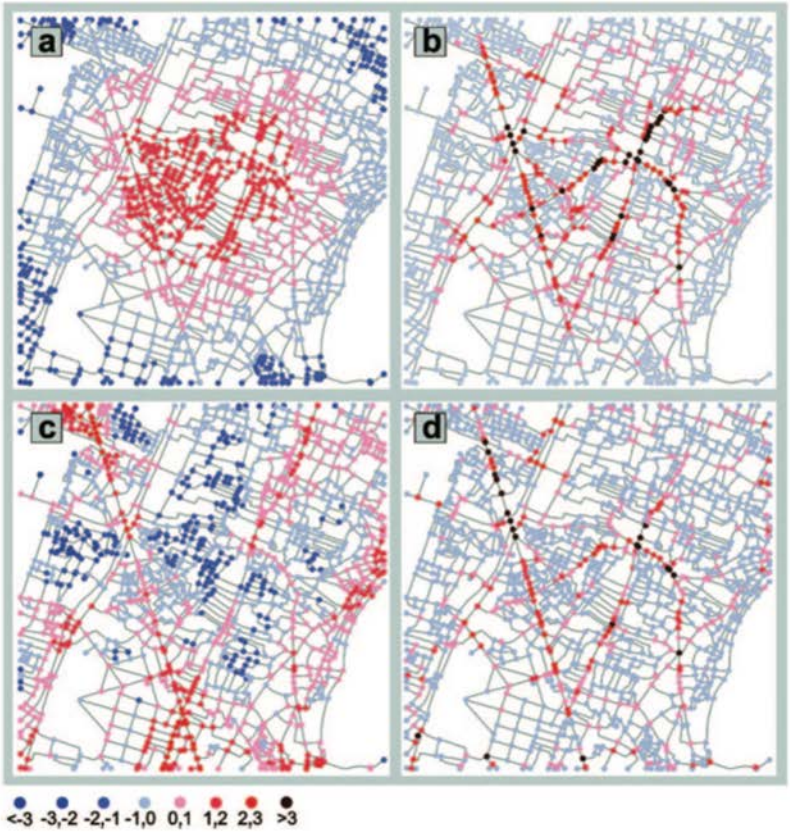
Thus, the more central a node is the lower its total distance from all other nodes. Note that taking distances *from* or *to* all other nodes is irrelevant in undirected graphs, whereas in directed graphs distances *to* a node are considered a more meaningful measure of centrality, as in general (e.g., in, the web) a node has little control over its incoming links.

When a graph is not strongly connected, a widespread idea is that of using the sum of reciprocal of distances, instead of the reciprocal of the sum of distances, with the convention $1/\infty = 0$:

$$H(x) = \sum_{y \neq x} \frac{1}{d(y,x)}.$$

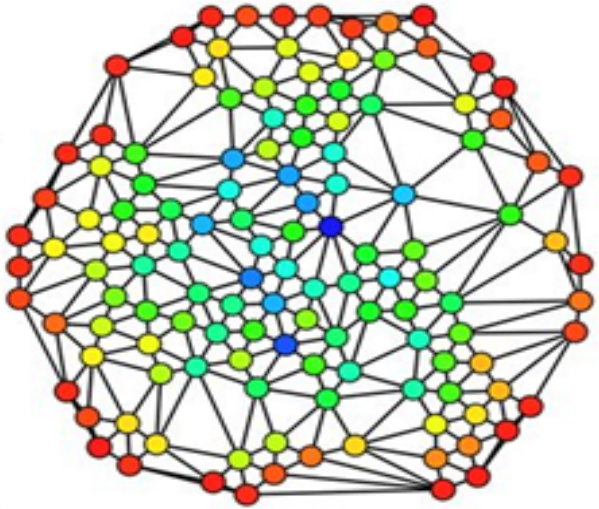
Medidas de Centralidad

Street Centralities · Centrality in a network of self-organised streets in Cairo, showing (a) closeness, (b) betweenness, (c) straightness, (d) information centralities.
Crucitti, Latora, Porta (2006)
[source]



Medidas de Centralidad (Betweenness Centrality)

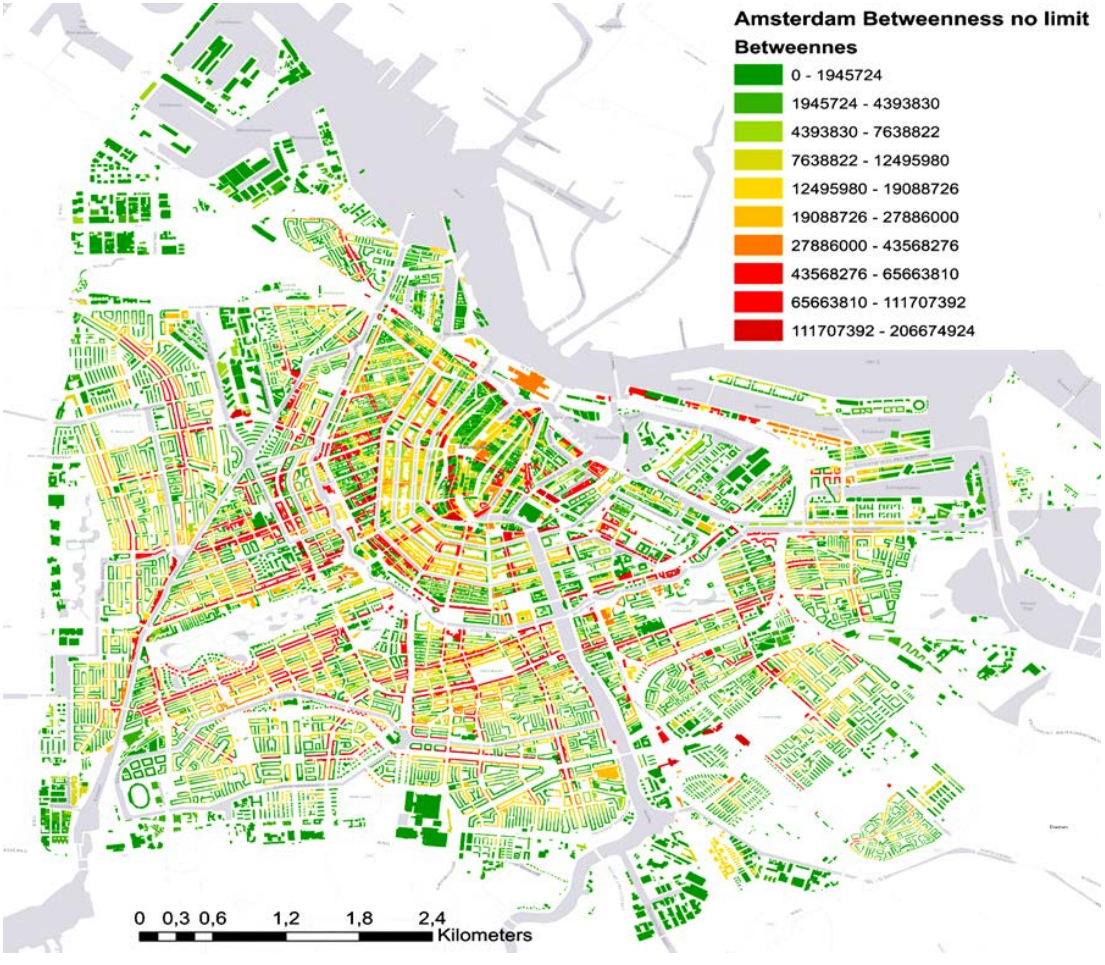
- Betweenness centrality
  - a centrality measure of a vertex within a graph
  - Vertices that occur on many shortest paths between other vertices have higher betweenness than those that do not
  - Act as “broker” or “bridge”
  - $O(V^3)$ complexity
  - $O(V^2 \log V + VE)$ for sparse network



$$C_B(v) = \sum_{\substack{s \neq v \neq t \in V \\ s \neq t}} \frac{\sigma_{st}(v)}{\sigma_{st}}$$

σ_{st} is the geodesic path between s and t. $\sigma_{st}(v)$ is the geodesic path between s and t passing through v.

Medidas de Centralidad



Medidas de Centralidad (Eigenvector Centrality)

Eigenvector centrality [edit]

Eigenvector centrality is a measure of the influence of a node in a network. It assigns relative scores to all nodes in the network based on the concept that connections to high-scoring nodes contribute more to the score of the node in question than equal connections to low-scoring nodes. Google's PageRank is a variant of the eigenvector centrality measure.[24] Another closely related centrality measure is Katz centrality.

Using the adjacency matrix to find eigenvector centrality [edit]

For a given graph $G := (V, E)$ with $|V|$ number of vertices let $A = (a_{v,t})$ be the adjacency matrix, i.e. $a_{v,t} = 1$ if vertex v is linked to vertex t, and $a_{v,t} = 0$ otherwise. The centrality score of vertex v can be defined as:

$$x_v = \frac{1}{\lambda} \sum_{t \in M(v)} x_t = \frac{1}{\lambda} \sum_{t \in G} a_{v,t} x_t$$

where $M(v)$ is a set of the neighbors of v and λ is a constant. With a small rearrangement this can be rewritten in vector notation as the eigenvector equation

$$\mathbf{Ax} = \lambda \mathbf{x}$$

In general, there will be many different eigenvalues λ for which an eigenvector solution exists. However, the additional requirement that all the entries in the eigenvector be positive implies (by the Perron–Frobenius theorem) that only the greatest eigenvalue results in the desired centrality measure.[25] The vth component of the related eigenvector then gives the centrality score of the vertex v in the network. Power iteration is one of many eigenvalue algorithms that may be used to find this dominant eigenvector.[24] Furthermore, this can be generalized so that the entries in A can be real numbers representing connection strengths, as in a stochastic matrix.

Medidas de Centralidad (Katz and PageRank Centrality)

Katz centrality and PageRank [edit]

Main article: Katz centrality

Katz centrality[26] is a generalization of degree centrality. Degree centrality measures the number of direct neighbors, and Katz centrality measures the number of all nodes that can be connected through a path, while the contributions of distant nodes are penalized. Mathematically, it is defined as $x_i = \sum_{k=1}^{\infty} \sum_{j=1}^{N} \alpha^k (A^k)_{ji}$ where α is an attenuation factor in $(0, 1)$.

Katz centrality can be viewed as a variant of eigenvector centrality. Another form of Katz centrality is $x_i = \alpha \sum_{j=1}^{N} a_{ij}(x_j + 1)$. Compared to the expression of eigenvector centrality, x_j is replaced by $x_j + 1$.

It is shown that[27] the principal eigenvector (associated with the largest eigenvalue of A, the adjacency matrix) is the limit of Katz centrality as α approaches $1/\lambda$ from below.

PageRank satisfies the following equation $x_i = \alpha \sum_j a_{ji} \frac{x_j}{L(j)} + \frac{1-\alpha}{N}$, where $L(j) = \sum_j a_{ij}$ is the number of neighbors of node j (or number of outbound links in a directed graph). Compared to eigenvector centrality and Katz centrality, one major difference is the scaling factor $L(j)$. Another difference between PageRank and eigenvector centrality is that the PageRank vector is a left hand eigenvector (note the factor a_{ji} has indices reversed).[28]

Medidas de Centralidad (Original PageRank Centrality)

Algoritmo [editar]

El algoritmo **inicial** del PageRank lo podemos encontrar en el documento original donde sus creadores presentaron el prototipo de Google: "The Anatomy of a Large-Scale Hypertextual Web Search Engine":[2]

$$\mathrm{PR}(A) = (1-d) + d\sum_{i=1}^{n}\frac{\mathrm{PR}(i)}{C(i)}$$

Donde:

- $\mathrm{PR}(A)$ es el PageRank de la página A.
- **d** es un factor de amortiguación que tiene un valor entre 0 y 1.
- $\mathrm{PR}(i)$ son los valores de PageRank que tienen cada una de las páginas **i** que enlazan a A.
- **C(i)** es el número total de enlaces salientes de la página i (sean o no hacia A).

Algunos expertos aseguran que el valor de la variable *d* suele ser 0,85. Representa la probabilidad de que un navegante continúe pulsando links al navegar por Internet en vez de escribir una url directamente en la barra de direcciones o pulsar uno de sus marcadores y es un valor establecido por Google. Por lo tanto, la probabilidad de que el usuario deje de pulsar links y navegue directamente a otra web aleatoria es *1-d*.[3] La introducción del factor de amortiguación en la fórmula resta algo de peso a todas las páginas de Internet y consigue que las páginas que no tienen enlaces a ninguna otra página no salgan especialmente beneficiadas. Si un usuario aterriza en una página sin enlaces, lo que hará será navegar a cualquier otra página aleatoriamente, lo que equivale a suponer que *una página sin enlaces salientes tiene enlaces a todas las páginas de Internet*.

La calidad de la página y el número de posiciones que ascienda se determina por una "votación" entre todas las demás páginas de la World Wide Web acerca del nivel de importancia que tiene esa página. Un hiperenlace a una página cuenta como un voto de apoyo. El PageRank de una página se define **recursivamente** y depende del número y PageRank de todas las páginas que la enlazan. Una página que está enlazada por muchas páginas con un PageRank alto consigue también un PageRank alto. Si no hay enlaces a una página web, no hay apoyo a esa página específica. El PageRank de la barra de Google va de 0 a 10. Diez es el máximo PageRank posible y son muy pocos los sitios que gozan de esta calificación, 1 es la calificación mínima que recibe un sitio normal, y cero significa que el sitio ha sido penalizado o aún no ha recibido una calificación de PageRank. Parece ser una escala logarítmica. Los detalles exactos de esta escala son desconocidos. En los últimos tiempos Google está tratando de mantener un poco "privado" su PageRank para evitar manipulaciones, pero existen sitios donde se puede comprobar el PageRank.[4]

Una alternativa al algoritmo PageRank propuesto por Jon Kleinberg, es el algoritmo HITS.

Medidas de Centralidad (hubs and authorities Centrality)

Para comenzar el ***ranking***, $\forall p$, $\mathrm{auth}(p) = 1$ y $\mathrm{hub}(p) = 1$. Consideramos dos tipos de actualizaciones: Regla de actualización de autoridad y Regla de actualización de concentrador. Para calcular las puntuaciones de concentrador / autoridad de cada nodo, se aplican iteraciones repetidas de la Regla de Actualización de Autoridades y la Regla de Actualización de Concentrador. Una aplicación en k-pasos del algoritmo HITS implica solicitar k veces primero la Regla de Actualización de Autoridades y luego la Regla de Actualización de Concentrador.

Regla de actualización de autoridad [editar]

$\forall p$, actualizamos $\mathrm{auth}(p)$ para que sea la sumatoria:

$$\mathrm{auth}(p) = \sum_{i=1}^{n} \mathrm{hub}(i)$$

donde n es el número total de páginas conectadas a p e i es una página conectada a p. Es decir, la puntuación de la Autoridad de una página es la suma de todas las puntuaciones de concentrador de las páginas que apuntan a ella.

Regla de actualización de concentrador (Hub) [editar]

$\forall p$, actualizamos $\mathrm{hub}(p)$ para que sea la sumatoria:

$$\mathrm{hub}(p) = \sum_{i=1}^{n} \mathrm{auth}(i)$$

donde n es el número total de páginas enlazadas desde p e i es una página enlazada desde p. Así, la puntuación de una página en el Concentrador es la suma de las puntuaciones de la Autoridad de todas sus páginas de enlace.

Medidas de Centralidad (Flow Centrality)

$$C_F(x_i) = \sum_{j<k}^{n} \sum^{n} m_{jk}(x_i). \qquad (1')$$

If we divide the flow that passes through x_i by the total flow between all pairs of points where x_i is neither a source nor a sink, we can determine the proportion of the flow that depends on x_i

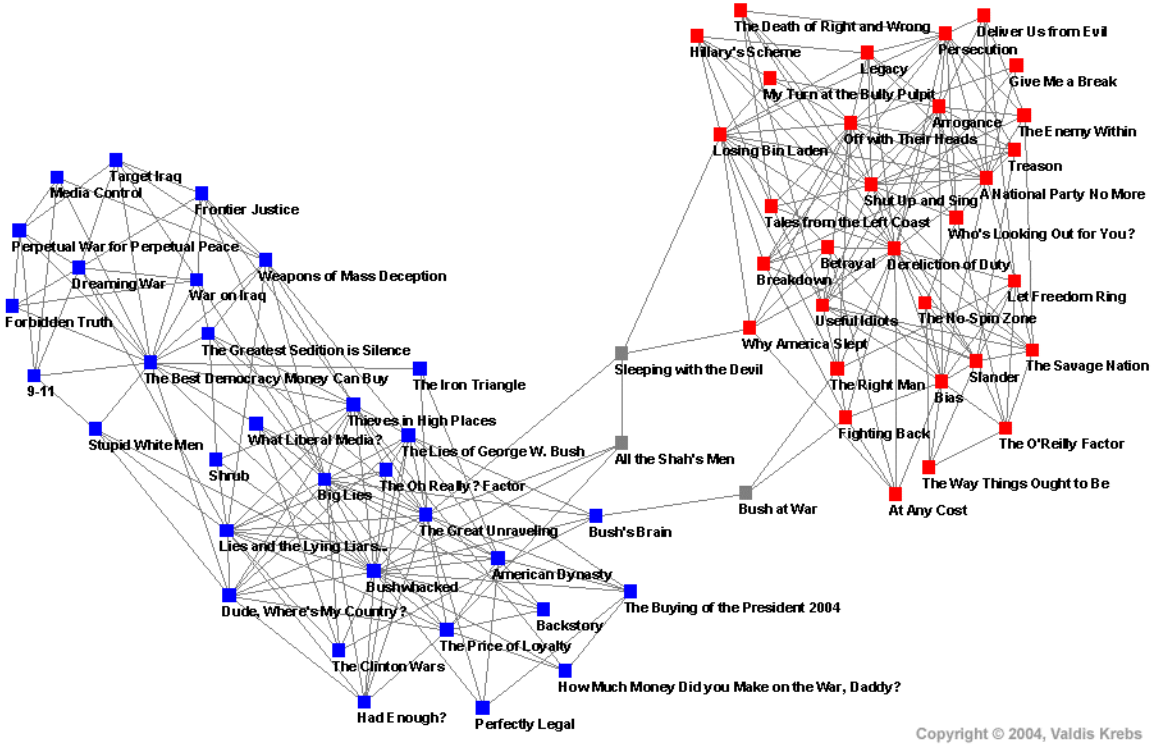
$$C'_F(p_i) = \frac{\sum_{j<k}^{n} \sum^{n} m_{jk}(x_i)}{\sum_{j<k}^{n} \sum^{n} m_{jk}}. \qquad (2')$$

4. ¿Qué individuos-nodos forman comunidades?

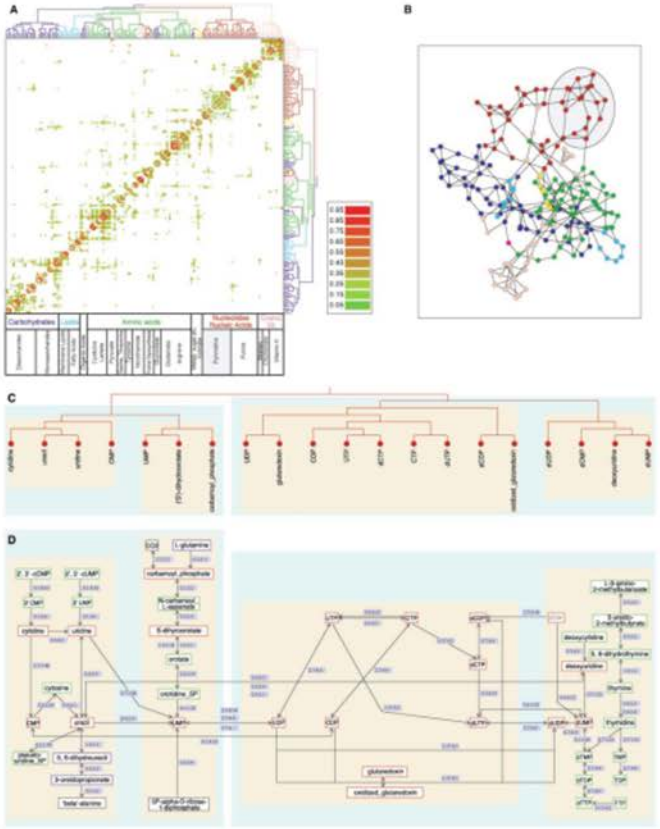
- Los problemas típicos de Clustering (sin redes) asumen que los ítem que se agrupan no están relacionados. Si lo están estos algoritmos son poco apropiados.

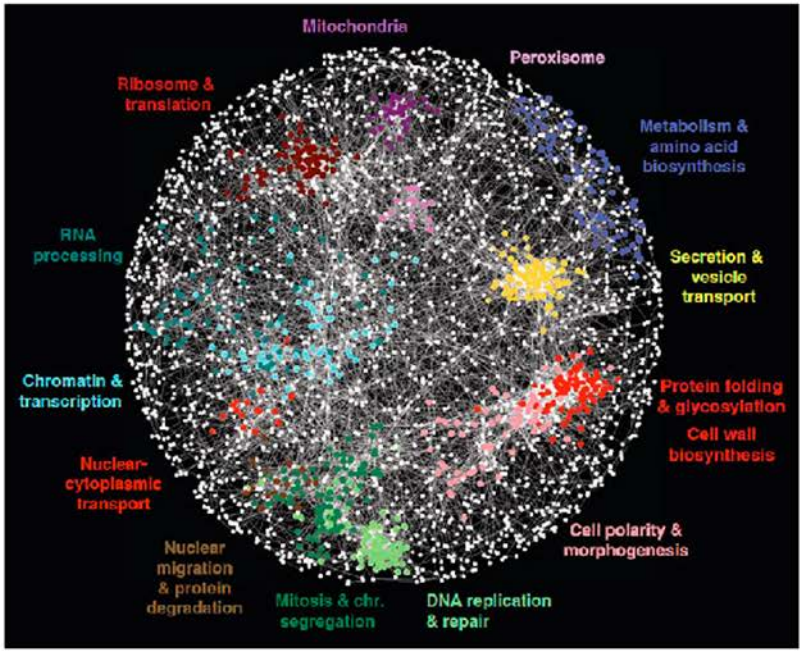
- En ocasiones la clasificación de un conjunto de objetos no se hace teniendo en cuenta sus características inherentes, si no en base a sus relaciones. Por ejemplo libros de política, votaciones a Juntas de Facultad, relaciones de amistad…

Clustering


The Death of Right and Wrong
Deliver Us from Evil
Hillary's Scheme
Persecution
Legacy
Give Me a Break
My Turn at the Bully Pulpit
Arrogance
The Enemy Within
Losing Bin Laden
Off with Their Heads
Treason
Shut Up and Sing
A National Party No More
Tales from the Left Coast
Who's Looking Out for You?
Betrayal
Dereliction of Duty
Breakdown
Let Freedom Ring
Useful Idiots
The No-Spin Zone
Why America Slept
Sleeping with the Devil
The Savage Nation
Slander
The Right Man
Bias
Fighting Back
The O'Reilly Factor
The Way Things Ought to Be
Bush at War
At Any Cost
Target Iraq
Media Control
Frontier Justice
Perpetual War for Perpetual Peace
Weapons of Mass Deception
Dreaming War
War on Iraq
Forbidden Truth
The Greatest Sedition is Silence
The Best Democracy Money Can Buy
The Iron Triangle
9-11
Thieves in High Places
What Liberal Media?
Stupid White Men
The Lies of George W. Bush
All the Shah's Men
Shrub
Big Lies
The Oh Really? Factor
The Great Unraveling
Bush's Brain
Lies and the Lying Liars...
American Dynasty
Bushwhacked
The Buying of the President 2004
Dude, Where's My Country?
Backstory
The Price of Loyalty
The Clinton Wars
How Much Money Did you Make on the War, Daddy?
Had Enough?
Perfectly Legal
Copyright © 2004, Valdis Krebs

Clustering


A
B
C
D


Mitochondria
Peroxisome
Ribosome & translation
Metabolism & amino acid biosynthesis
RNA processing
Secretion & vesicle transport
Chromatin & transcription
Protein folding & glycosylation
Cell wall biosynthesis
Nuclear-cytoplasmic transport
Cell polarity & morphogenesis
Nuclear migration & protein degradation
Mitosis & chr. segregation
DNA replication & repair

Clustering

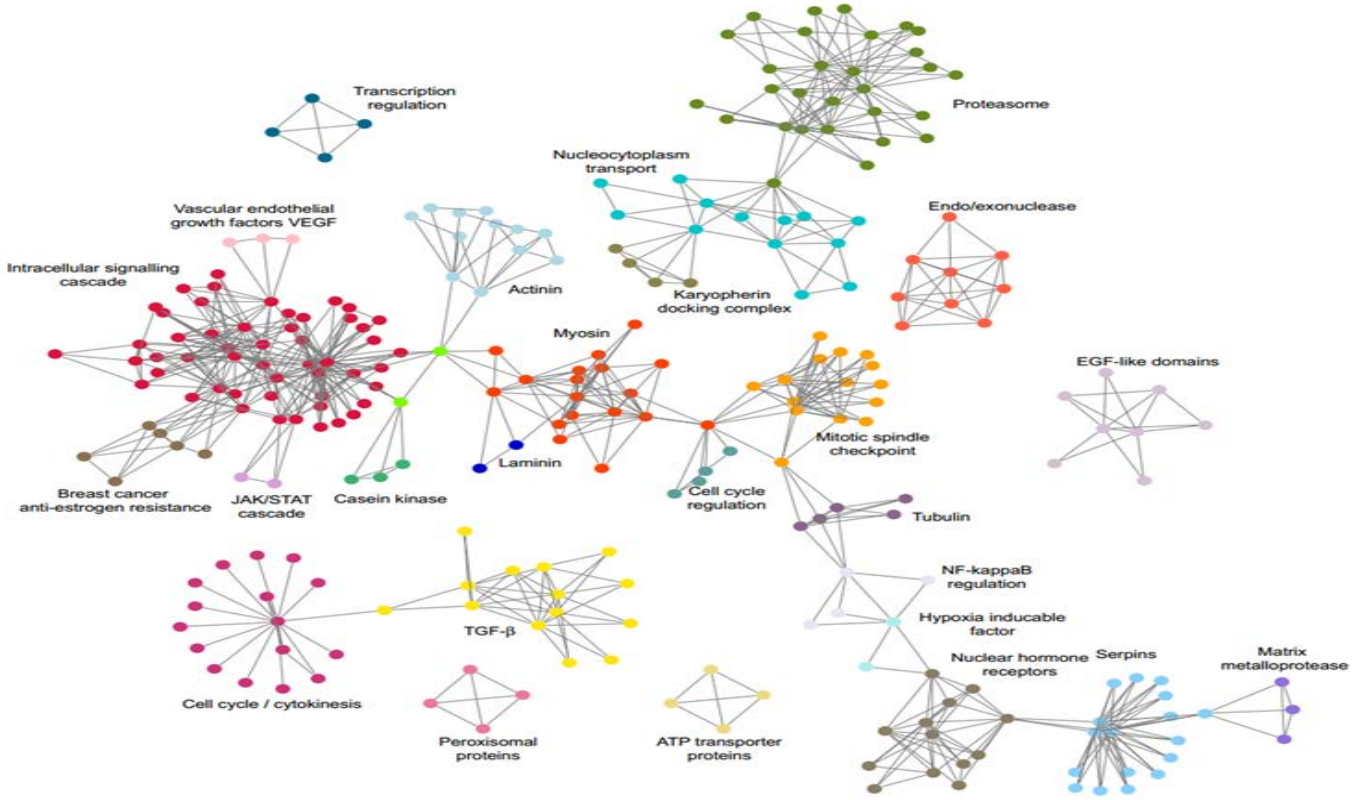
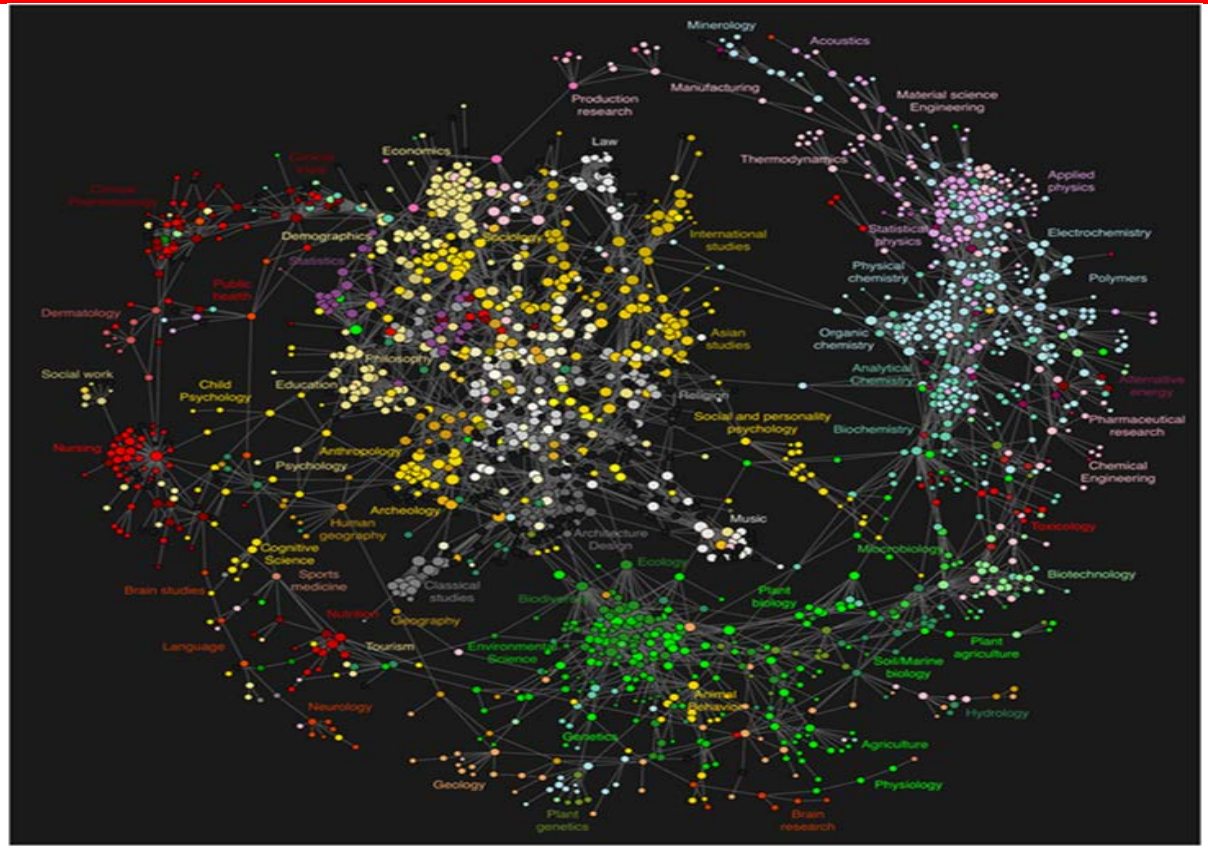


FIG. 3 Community structure in protein-protein interaction networks. The graph pictures the interactions between proteins in cancerous cells of a rat. Communities, labeled by colors, were detected with the Clique Percolation Method by Palla et al. (Section XI.A). Reprinted figure with permission from Ref. (Jonsson *et al.*, 2006). ©2006 by PubMed Central.

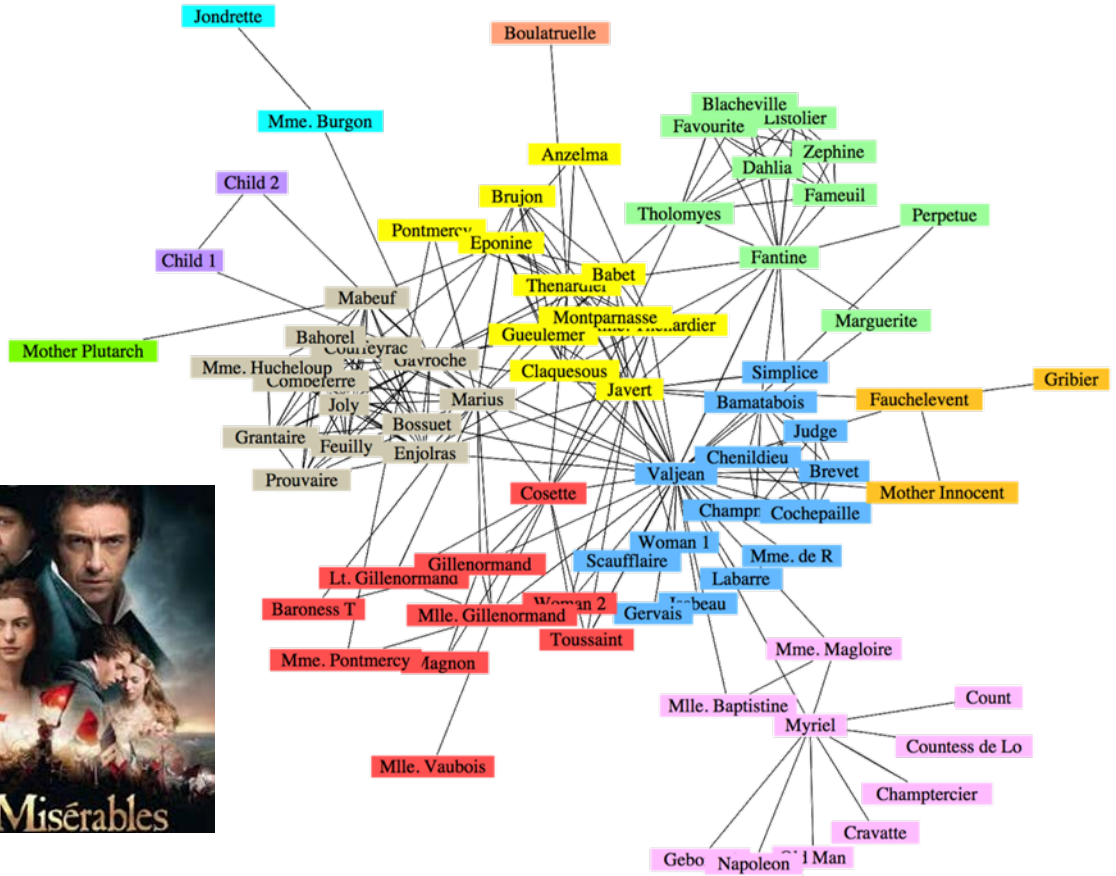
Clustering



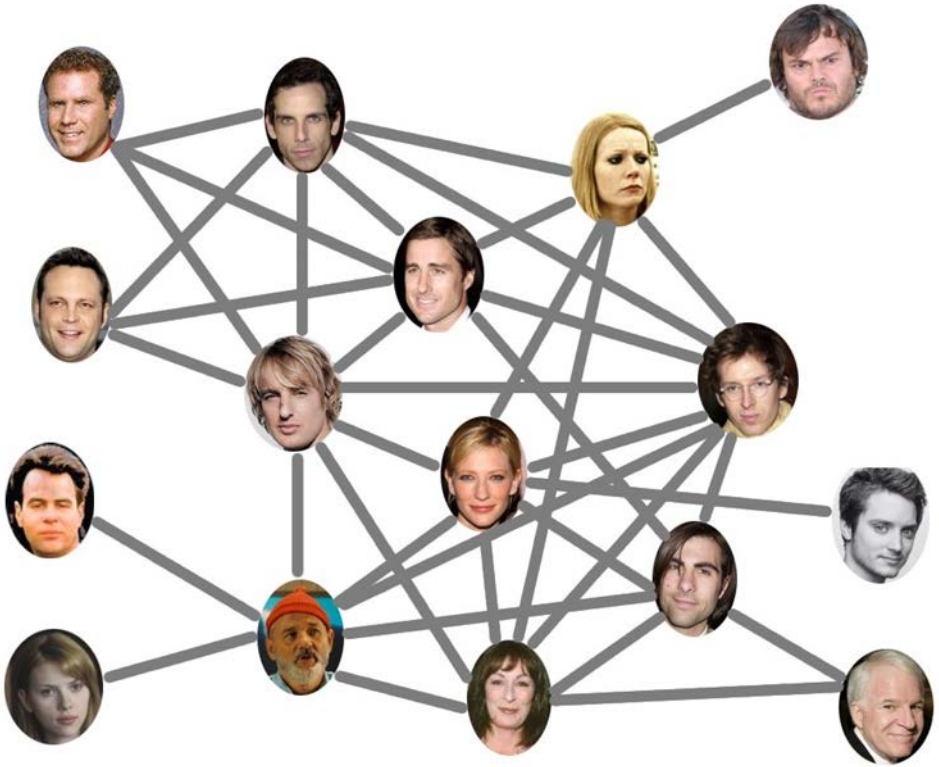
Bollen J, Van de Sompel H, Hagberg A, Bettencourt L, Chute R, et al. (2009) Clickstream Data Yields High-Resolution Maps of Science. PLoS ONE 4(3): e4803. doi:10.1371/journal.pone.0004803
http://journals.plos.org/plosone/article?id=info:doi/10.1371/journal.pone.0004803

Clustering


Les Misérables


Jondrette
Boulatruelle
Mme. Burgon
Blacheville
Favourite
Listolier
Anzelma
Zephine
Dahlia
Child 2
Brujon
Fameuil
Tholomyes
Perpetue
Pontmercy
Eponine
Child 1
Fantine
Babet
Mabeuf
Montparnasse
Marguerite
Mother Plutarch
Bahorel
Gueulemer
Mme. Hucheloup
Gavroche
Claquesous
Simplice
Gribier
Javert
Bamatabois
Fauchelevent
Joly
Marius
Judge
Grantaire
Bossuet
Feuilly
Enjolras
Chenildieu
Brevet
Prouvaire
Valjean
Cosette
Mother Innocent
Champ
Cochepaille
Woman 1
Gillenormand
Scaufflaire
Mme. de R
Lt. Gillenormand
Labarre
Baroness T
Mlle. Gillenormand
Gervais
Toussaint
Mme. Pontmercy
Mme. Magloire
Mlle. Baptistine
Count
Myriel
Countess de Lo
Mlle. Vaubois
Champtercier
Cravatte
Napoleon

Clustering



Clustering

Los problemas de Clustering en Redes Sociales consite en encontrar las comunidades, pero existen otros problemas muy relacionados como la predicción de los siguientes arcos o aristas o la clasificación de nodos dudosos

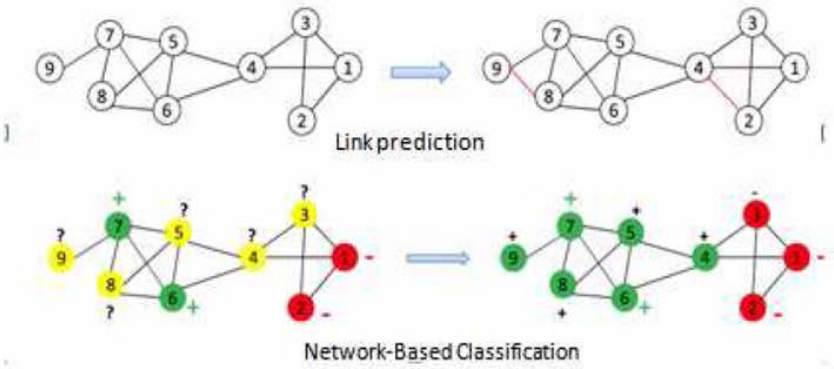


Figure: Link prediction problem and Network-Based Classification

Algoritmos de Clustering

arXiv:0906.0612v2 [physics.soc-ph] 25

Contents

I. Introduction 2

II. Communities in real-world networks 4

III. Elements of Community Detection 8
A. Computational complexity 9
B. Communities 9
1. Basics 9
2. Local definitions 10
3. Global definitions 11
4. Definitions based on vertex similarity 12
C. Partitions 13
1. Basics 13
2. Quality functions: modularity 14

IV. Traditional methods 16
A. Graph partitioning 16
B. Hierarchical clustering 19
C. Partitional clustering 19
D. Spectral clustering 20

V. Divisive algorithms 23
A. The algorithm of Girvan and Newman 23
B. Other methods 25

VI. Modularity-based methods 27
A. Modularity optimization 27
1. Greedy techniques 27
2. Simulated annealing 29
3. Extremal optimization 29
4. Spectral optimization 30
5. Other optimization strategies 33
B. Modifications of modularity 34
C. Limits of modularity 38

VII. Spectral Algorithms 41

VIII. Dynamic Algorithms 43
A. Spin models 43
B. Random walk 45
C. Synchronization 47

IX. Methods based on statistical inference 48
A. Generative models 49
B. Blockmodeling, model selection and information theory 52

X. Alternative methods 54

XI. Methods to find overlapping communities 58
A. Clique percolation 58
B. Other techniques 60

XII. Multiresolution methods and cluster hierarchy 62
A. Multiresolution methods 63
B. Hierarchical methods 65

XIII. Detection of dynamic communities 66

XIV. Significance of clustering 70

XV. Testing Algorithms 73
A. Benchmarks 74
B. Comparing partitions: measures 77
C. Comparing algorithms 79

XVI. General properties of real clusters 82

XVII. Applications on real-world networks 85
A. Biological networks 85
B. Social networks 86
C. Other networks 88

XVIII. Outlook 90

A. Elements of Graph Theory 92
1. Basic Definitions 92
2. Graph Matrices 94
3. Model graphs 94

References 96

*Electronic address: fortunato@isi.it

Algoritmos de Clustering (No Jerárquicos)

Su objetivo principal es el de obtener una partición del grafo. Como se ha llegado a esta partición no es problema suyo. La salida es solo la partición final.

Los distintos tipos son:

- ✓ Métodos Tradicionales. Clustering clásico. No funcionan bien.
- ✓ Metodos de Graph partitioning clásicos. Max-Min Flow algorithm…..
- ✓ Spectral Algorithms. Transforman los nodos de un grafo en puntos en el plano y a partir de ahí aplican técnicas clásicas de clustering.
- ✓ Algoritmos basados en la función de modularidad. Optimización.
- ✓ LOUVAIN (También conocido como BLONDEL). Es el más conocido.
- ✓ Algoritmos genéticos.
- ✓ Temple simulado.
- ✓ ……

Algoritmos de Clustering (Jerárquicos)

Muestran la evolución de como los grupos se van rompiendo (divisivos) o formando (aglomerativos) desde la primera fase hasta la ultima. La salida es un dendograma.

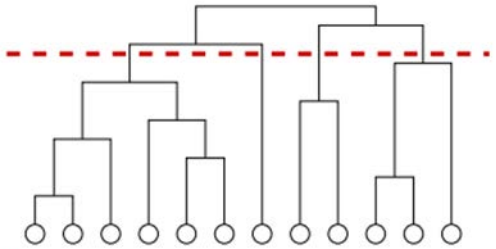


FIG. 8 A dendrogram, or hierarchical tree. Horizontal cuts correspond to partitions of the graph in communities. Reprinted figure with permission from Ref. (Newman and Girvan, 2004). ©2004 by the American Physical Society.

Algoritmos de Clustering (Jerárquicos)

Definition

Dado un grafo (V, E), *Clustering Network Problem* (CNP) busca una "buena" partición del grafo.

Definition

Dado un grafo (V, E), $P = \{H_1, \ldots, H_r\}$ es una partición del grafo si $V = \cup H_i$, $H_i \cap H_j = \emptyset$ para i distinto de j, y el grafo parcial $(H_i, E_{|_{H_i}})$ es conexo.

- Grafo modeliza una imagen: Aplicacion al campo de la Segmentación de imagenes.
- Grafo modeliza una red social. Aplicacion al campo de los Problemas de detección de comunidades.

Algoritmos de Clustering (Jerárquicos)

Definition

Dado un grafo $G = (V, E)$, the Hierarchical Clustering Network Problem (HCNP) busca una buena partición jerarquica $\mathcal{D}$ del grafo. Una partición jerarquica se suele representar por medio de un dendograma.

Partición mas fina .

Definition

Dadas dos particiones P y Q, diremos que P es mas fina que Q ($P \widetilde{\subseteq} Q$) si para toda $A \in P$, existe $B \in Q$, tal que $A \subseteq B$.

Algoritmos de Clustering (Jerárquicos)

Los distintos tipos son:

1) Divisivos.
   - ✓ Girvan-Newman (2003).
   - ✓ Gomez & Castro (2018)
   - ✓ Divide and Link (2015)
2) Aglomerativos.
   - ✓ Clauset Newman and Moore
   - ✓ Random Walk.
   - ✓ Newman 2015

***Random Hypothesis*:**
Randomly wired networks are not expected to have a community structure.

$$\{C_c,\ c = 1,\ n_c\}$$

$$M = \frac{1}{2L}\sum_{i,j=1}^{N}(A_{ij} - P_{ij})\delta(C_i - C_j)$$

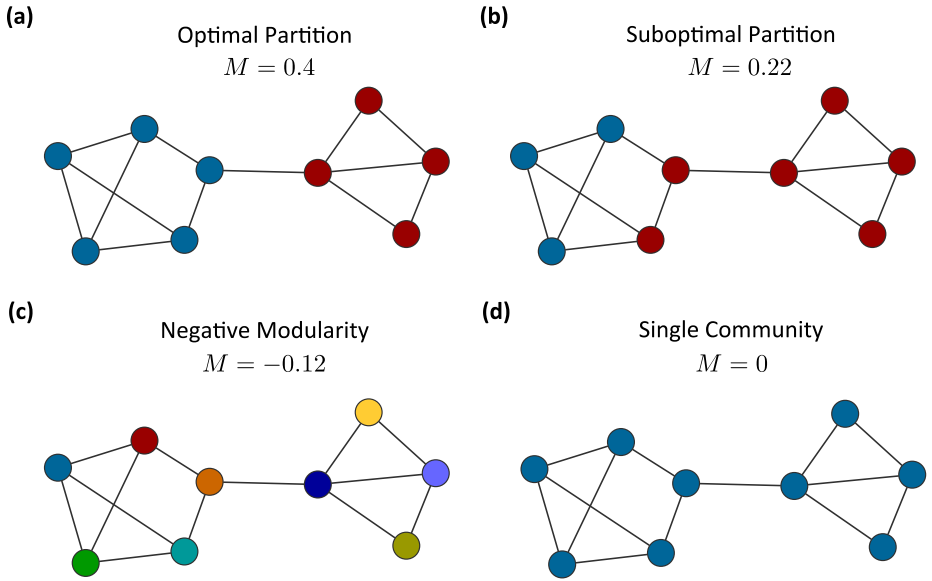
$$P_{ij} = 2Lp_ip_j = \frac{k_ik_j}{2L}$$

$$M = \sum_{c=1}^{n_c}\left[\frac{l_c}{L} - \left(\frac{k_c}{2L}\right)^2\right]$$

Clustering

Modularity

$$M = \sum_{c=1}^{n_c} \left[\frac{l_c}{L} - \left(\frac{k_c}{2L} \right)^2 \right]$$



- *Optimal partition*, that maximizes the modularity.
- *Sub-optimal* but positive modularity.
- *Negative Modularity*: If we assign each node to a different community.
- *Zero modularity:* Assigning all nodes to the same community, we obtain , independent of the network structure.
- *Modularity is size dependent.*

Algoritmos de Clustering (Louvain)

The value to be optimized is modularity, defined as a value between -1 and 1 that measures the density of links inside communities compared to links between communities.[1] For a weighted graph, modularity is defined as:

$$Q = \frac{1}{2m} \sum_{ij} \left[A_{ij} - \frac{k_i k_j}{2m} \right] \delta(c_i, c_j),$$

where

- A_{ij} represents the edge weight between nodes i and j;
- k_i and k_j are the sum of the weights of the edges attached to nodes i and j, respectively;
- $2m$ is the sum of all of the edge weights in the graph;
- c_i and c_j are the communities of the nodes; and
- δ is a simple delta function.

In order to maximize this value efficiently, the Louvain Method has two phases that are repeated iteratively.

First, each node in the network is assigned to its own community. Then for each node i, the change in modularity is calculated for removing i from its own community and moving it into the community of each neighbor j of i. This value is easily calculated by two steps: (1) removing i from its original community, and (2) inserting i to the community of j. The two equations are quite similar, and the equation for step (2) is: [1]

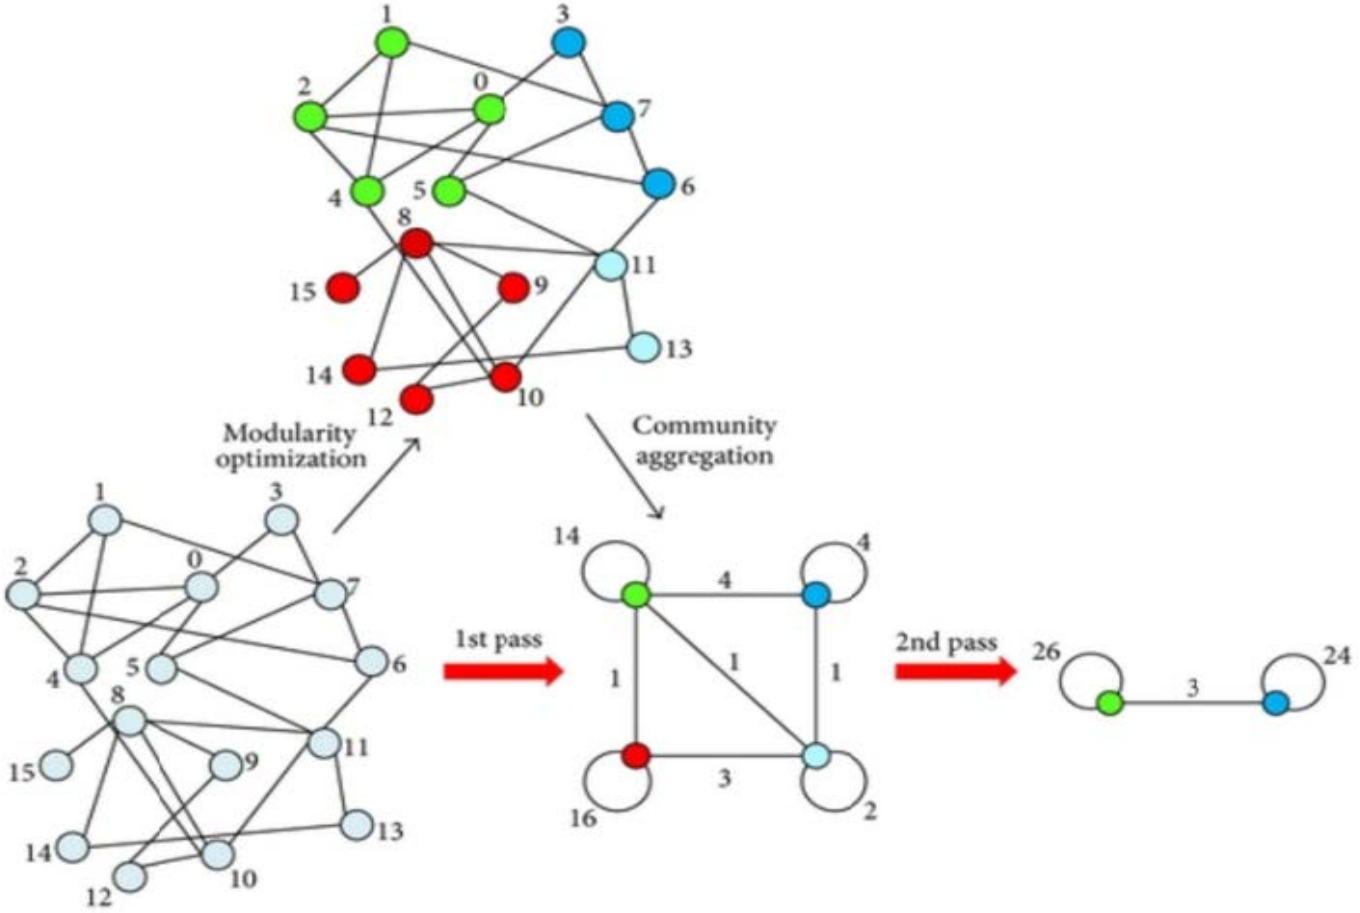
$$\Delta Q = \left[\frac{\Sigma_{in} + 2k_{i,in}}{2m} - \left(\frac{\Sigma_{tot} + k_i}{2m} \right)^2 \right] - \left[\frac{\Sigma_{in}}{2m} - \left(\frac{\Sigma_{tot}}{2m} \right)^2 - \left(\frac{k_i}{2m} \right)^2 \right]$$

Algoritmos de Clustering (Louvain)

Where Σ_{in} is sum of all the weights of the links inside the community i is moving into, Σ_{tot} is the sum of all the weights of the links to nodes in the community i is moving into, k_i is the weighted degree of i, $k_{i,in}$ is the sum of the weights of the links between i and other nodes in the community that i is moving into, and m is the sum of the weights of all links in the network. Then, once this value is calculated for all communities i is connected to, i is placed into the community that resulted in the greatest modularity increase. If no increase is possible, i remains in its original community. This process is applied repeatedly and sequentially to all nodes until no modularity increase can occur. Once this local maximum of modularity is hit, the first phase has ended.

In the second phase of the algorithm, it groups all of the nodes in the same community and builds a new network where nodes are the communities from the previous phase. Any links between nodes of the same community are now represented by self loops on the new community node and links from multiple nodes in the same community to a node in a different community are represented by weighted edges between communities. Once the new network is created, the second phase has ended and the first phase can be re-applied to the new network.

Algoritmos de Clustering (Louvain)



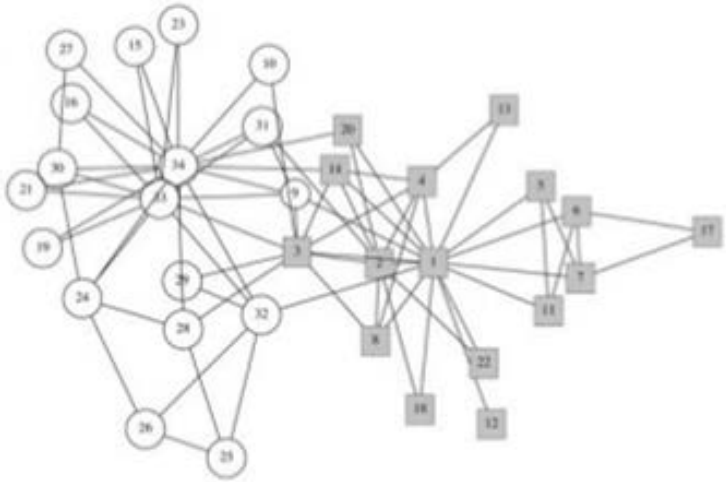
Algoritmos de Clustering (Girvan-Newman)

- GN algorithm is one of the most important algorithms stimulating a whole wave of community detection methods.
- Basic principle:
  - > Compute betweenness centrality for each edge.
  - > Remove edge with highest score.
  - > Re-compute all scores.
  - > Repeat 2nd step.
- Complexity: $O(n^3)$
- Many variations have been presented to improve precision by use of different betweenness measures or reduce complexity, e.g. by sampling or local computations.



Girvan, M., Newman, M.E.J. "Community structure in social and biological networks". In Proceedings of National Academy of Science, U. S. A. 99(12), 7821–7826, 2002

Algoritmos de Clustering (Girvan-Newman)



Optimal community structure for Zachary's karate club.



Modularity without recalculation

