Bienvenidos al curso de Spark

¡Bienvenidos al curso de Spark! En él vamos a tratar con varias herramientas Big Data que se ejecutan sobre un cluster de ordenadores. La principal que vamos a ver en detalle es Apache Spark, un framework open-source de procesamiento distribuido que permite hacer cualquier tipo de operación con datos sobre un cluster, para poder manipular y transformar datasets realmente grandes - aunque nosotros vamos a usar un cluster de juguete gratuito. Todo el trabajo lo vamos a hacer utilizando notebooks de la plataforma de la empresa Databricks (similares a los de Jupyter pero con algunas "vitaminas") que estarán enlazados con un cluster real de Spark, gracias a la infraestructura proporcionada por Databricks y Microsoft Azure. Todo se hará en la nube, por lo que no tendréis que instalar nada en vuestro ordenador, y por supuesto, es accesible desde cualquier sitio donde tengáis conexión a internet.

Para poder llevar a cabo nuestras actividades, es necesario leer detenidamente y seguir las instrucciones de la guía de la siguiente sección, para crear una cuenta en Azure, una cuenta de almacenamiento en Azure y a continuación levantar la plataforma de Databricks, y dentro de ella, un cluster sencillito (Personal compute). Estas herramientas son las mismas que habíais configurado en el curso de Tecnologías del Big Data, por lo que quienes ya hicisteis esta configuración, no es necesario que la volváis a crear, a pesar de que hayáis escogido nombres diferentes para los servicios (no supone ningún problema). El cluster de Databricks está programado por defecto para desmantelarse tras permanecer inactivo cierto tiempo, lo cual es beneficioso, aunque eso también lo podéis configurar.

El curso está estructurado de la siguiente manera:

Capítulo 1: Introducción a las Tecnologías Big Data
Capítulo 2: Apache Spark I (Core y SQL)
- Introducción
- Arquitectura de Spark
- RDD: Resilient Distributed Datasets
- DataFrames y Spark SQL
- Bibliografía recomendada

Capítulo 3: Catálogo de metadatos de Hive

Skip to main content

Capítulo 5: Structured Streaming y GraphFrames

La correspondencia entre capítulos y semanas podría ser:

- Semana 1: Introducción, Spark Core y SQL
- Semana 2: Catálogo de metadatos de Hive y Spark MLlib
- Semana 3: Spark Structured Streaming y GraphFrames