Capítulo 2: Apache Spark I (Core y SQL)

En el tema anterior vimos cómo MapReduce permite procesar los datos almacenados de manera distribuida en el sistema de archivos (por ejemplo HDFS) de un cluster de ordenadores. MapReduce permite resolver todo tipo de problemas, pese a que no siempre es sencillo pensar la solución en términos de operaciones *map* y *reduce* encadenadas. Por ello se dice que es de propósito general, a diferencia de, por ejemplo, el lenguaje SQL que está orientado específicamente a realizar consultas sobre los datos. Implementar en SQL algoritmos tales como un método de ordenación, o el algoritmo de Dijkstra para encontrar caminos mínimos en un grafo no sería posible.

Los siguientes enlaces nos llevan a cada sección.

Introducción

Arquitectura de Spark

RDD: Resilient Distributed Datasets

DataFrames y Spark SQL

Bibliografía recomendada