ntic master
revolucionamos la comunicación

TECNOLOGÍAS DEL BIG DATA

INTRODUCCIÓN

Agenda

- ¿Qué es?
  - Volumen
  - Variedad
  - Velocidad
  - Veracidad

- ¿Por qué Big Data?
  - Evolución Tecnológica
  - Evolución Analítica
  - Valor del Dato

- Casos de uso Big Data

Agenda

- Origen del Big Data
  - Hadoop

- Ecosistema Big Data
  - Ingesta
  - Procesamiento
  - Servicio

- Resumen

1.

¿QUÉ ES?

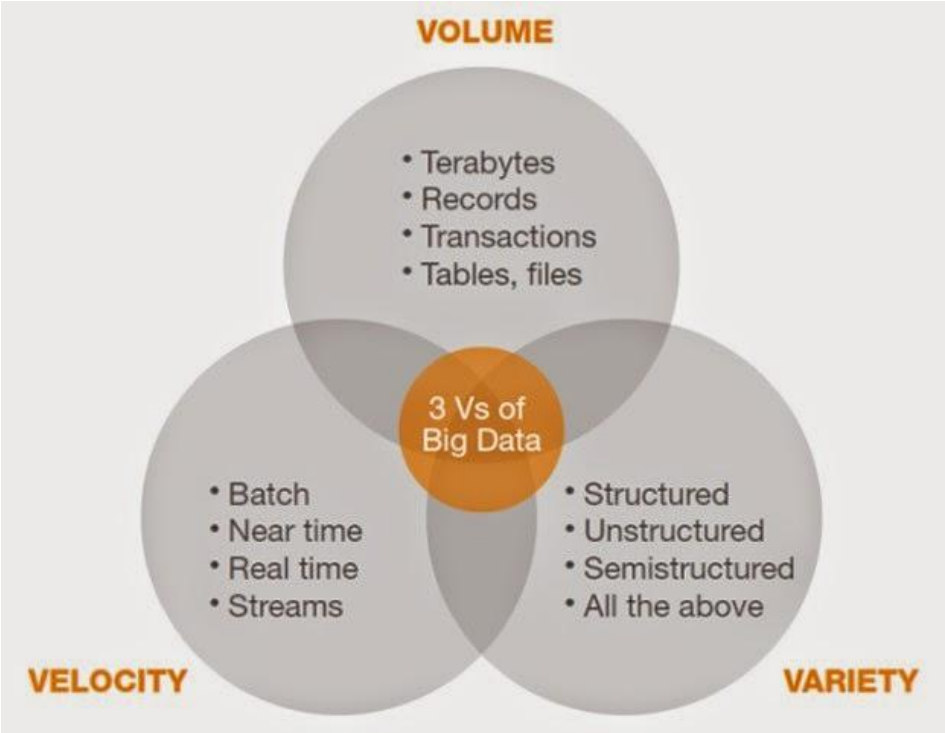
¿Qué es Big Data?

Big Data son datos de gran **variedad**, generados en **volúmenes** y una **velocidad** cada vez mayor.

Estas son conocidas como las **3 Vs**.

Gartner®

Las 3 Vs del Big Data



¿Qué es Big Data?

La evolución continua de estas características de los datos hacen que su tratamiento sea especialmente difícil para cualquier compañía.

1.1

VOLUMEN (1V)

Volumen

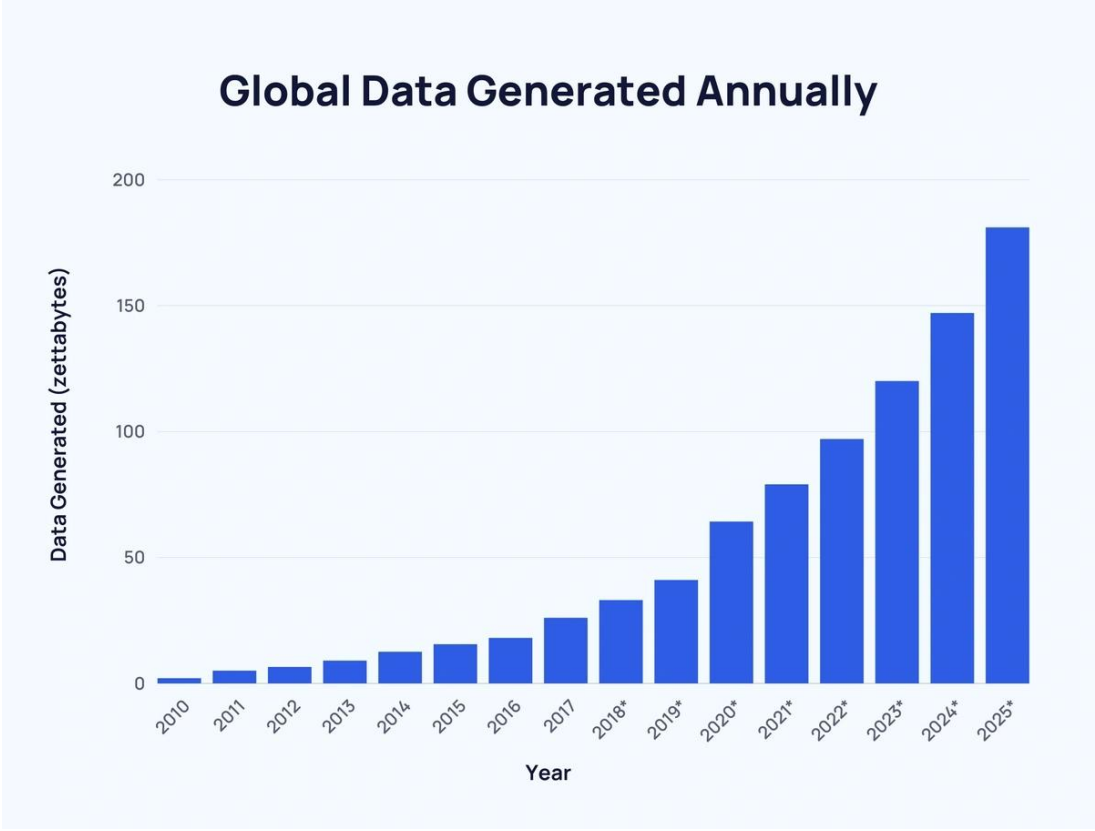
¿Cómo podemos almacenar cantidades masivas de datos?

Volumen

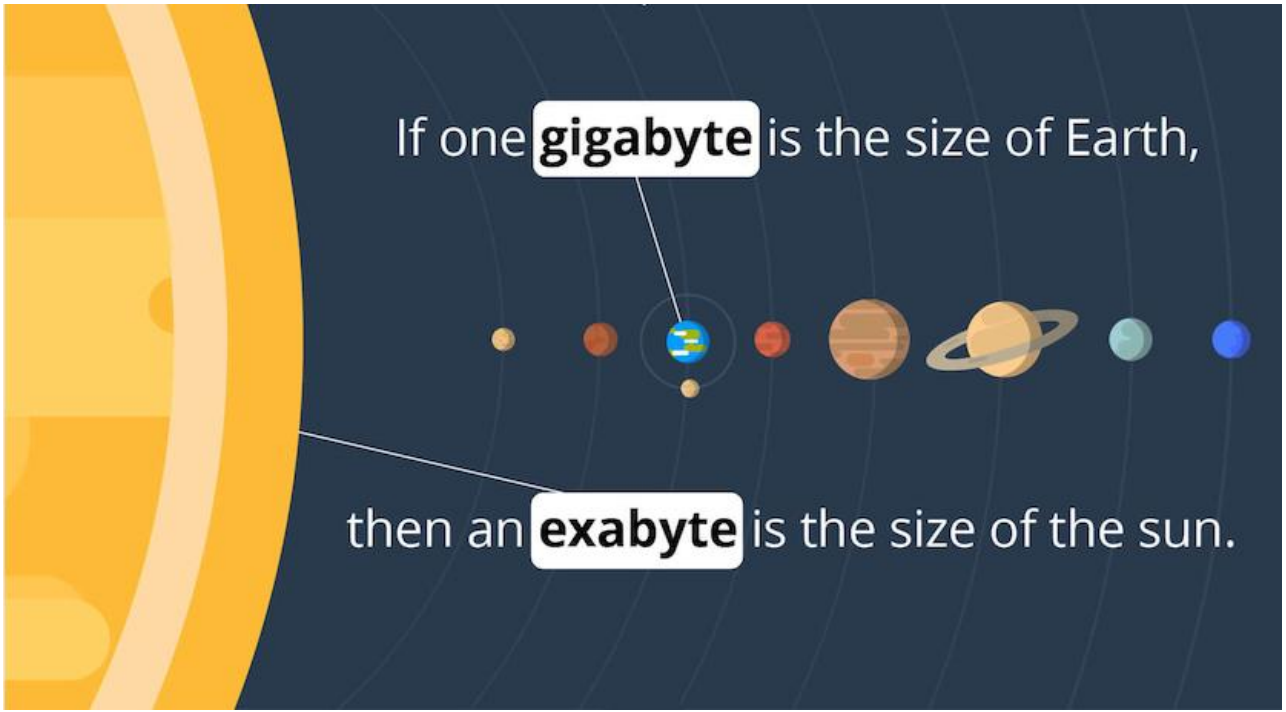
Se refiere a la cantidad de nuevos datos que se generan

Prefijo	Símbolo del prefijo	Prefijo métrico	Símbolo
Valor de referencia		*byte*	B
kilo-	k	*kilobyte*	kB
mega-	M	*megabyte*	MB
giga-	G	*gigabyte*	GB
tera-	T	*terabyte*	TB
peta-	P	*petabyte*	PB
Exa-	E	*exabyte*	EB
zetta-	Z	*zettabyte*	ZB
yotta-	Y	*yottabyte*	YB
ronna-	R	*ronnabyte*	RB
quetta-	Q	*quettabyte*	QB

Volumen


Global Data Generated Annually
Data Generated (zettabytes)
200
150
100
50
0
2010
2011
2012
2013
2014
2015
2016
2017
2018*
2019*
2020*
2021*
2022*
2023*
2024*
2025*
Year

Volumen


If one gigabyte is the size of Earth,
then an exabyte is the size of the sun.

Volumen

“We don’t have better algorithms than anyone else.
We just have more data.”



Google

Peter Norvig
Chief Scientist
Research Director

1.2

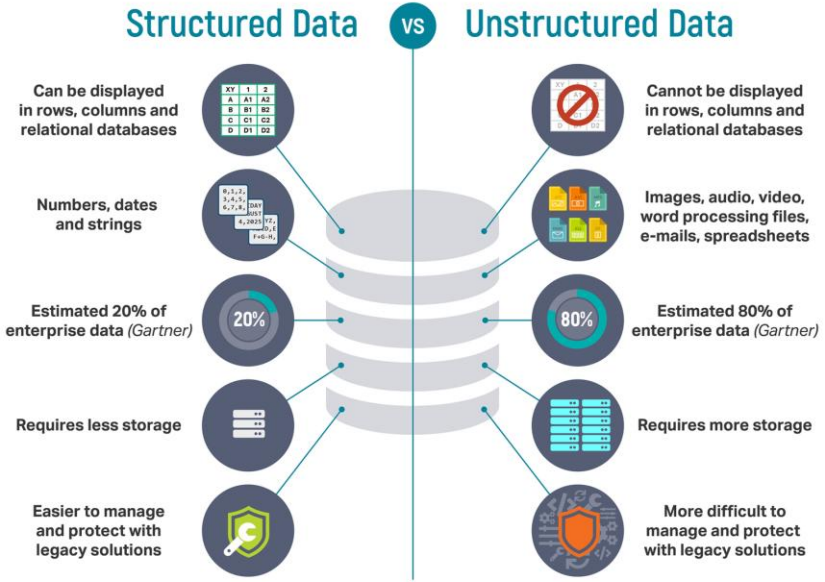
VARIEDAD (2V)

Variedad

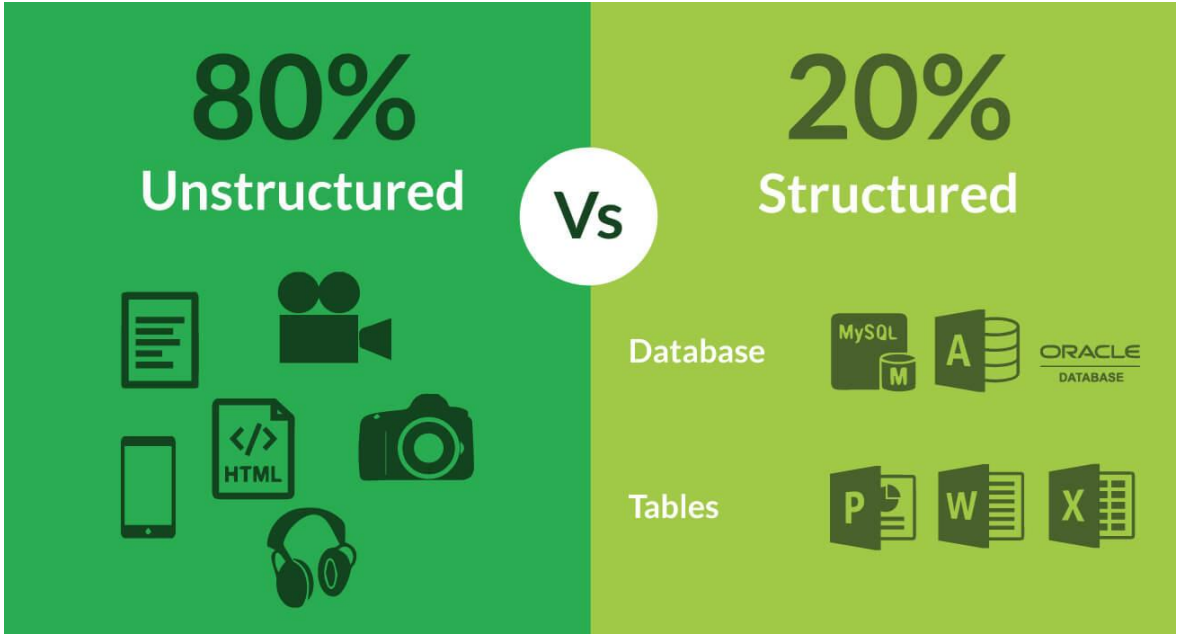
¿Cómo podemos analizar diferentes tipos de datos de forma conjunta?

Variedad

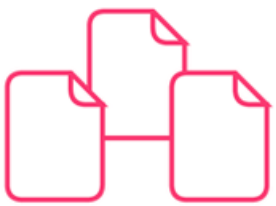
Se refiere a los distintos tipos de datos y sus orígenes



Variedad


80%
Unstructured
Vs
20%
Structured
HTML
Database
MySQL
ORACLE
DATABASE
Tables

Variedad

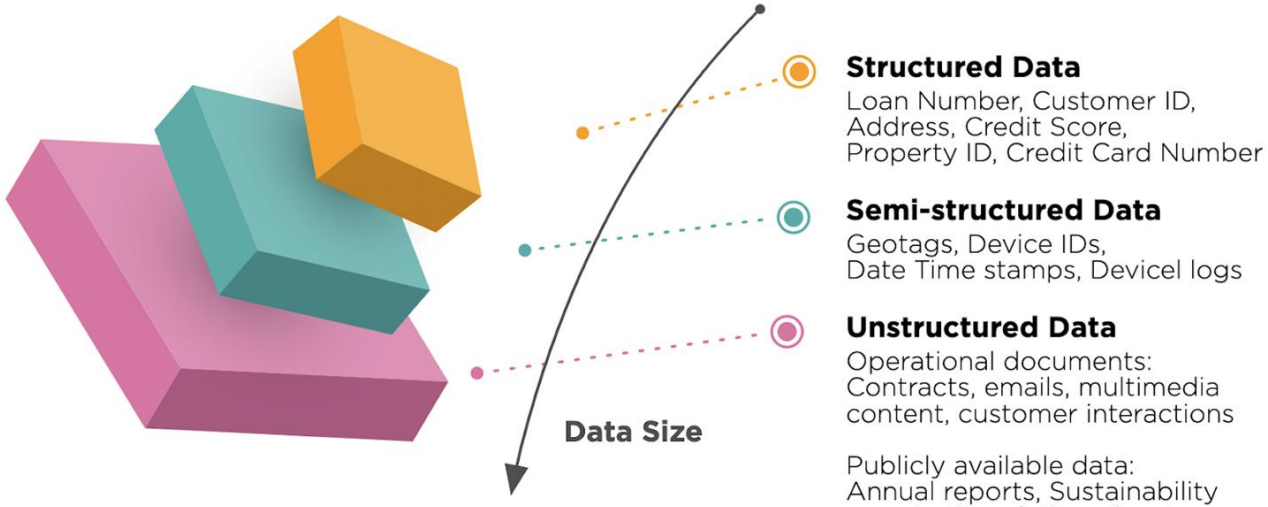






Unstructured	Semi-structured	Structured
PDFs, JPEGs, MP3, Movies, ...	CSV, JSON, XML, MongoDB, ...	Oracle, MSSQL, MySQL, DB2, ...

Variedad



Structured Data

Loan Number, Customer ID, Address, Credit Score, Property ID, Credit Card Number

Semi-structured Data

Geotags, Device IDs, Date Time stamps, Devicel logs

Unstructured Data

Operational documents: Contracts, emails, multimedia content, customer interactions

Publicly available data: Annual reports, Sustainability reports, Regulations & patents

1.3

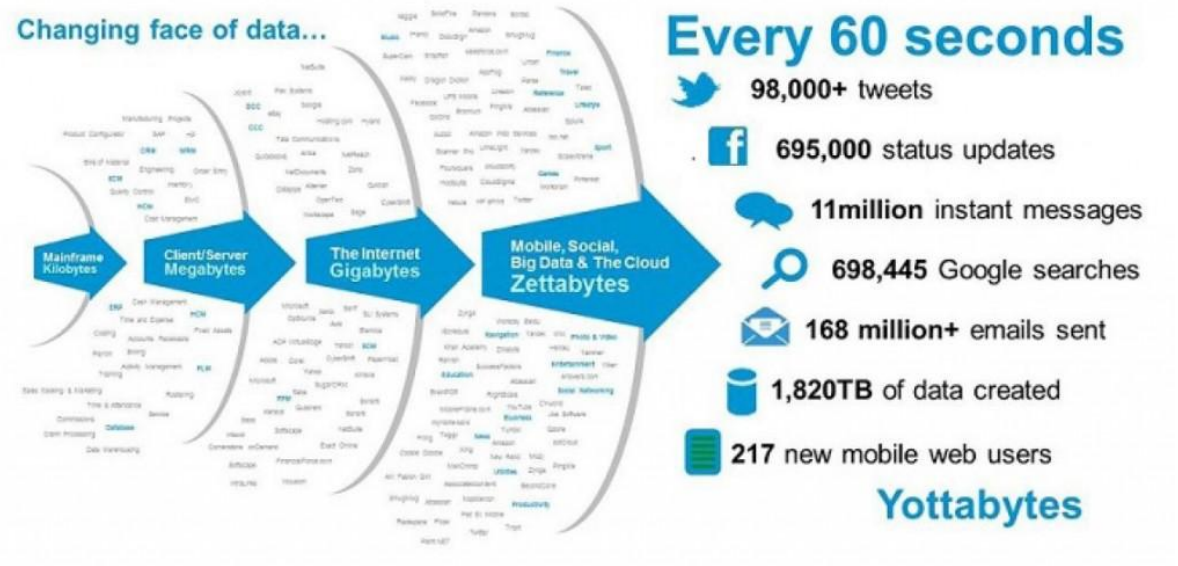
VELOCIDAD (3V)

Velocidad

¿Cómo podemos procesar y analizar datos producidos a gran velocidad?

Velocidad

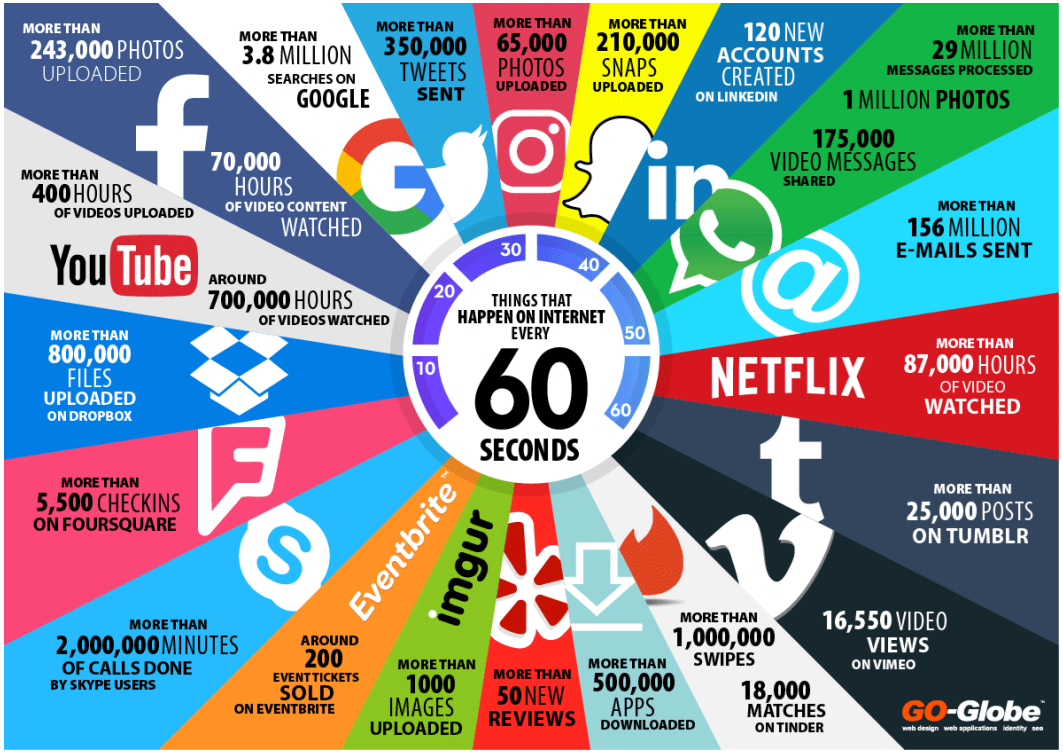
Se refiere a la velocidad a la que se están creando los datos.



Velocidad

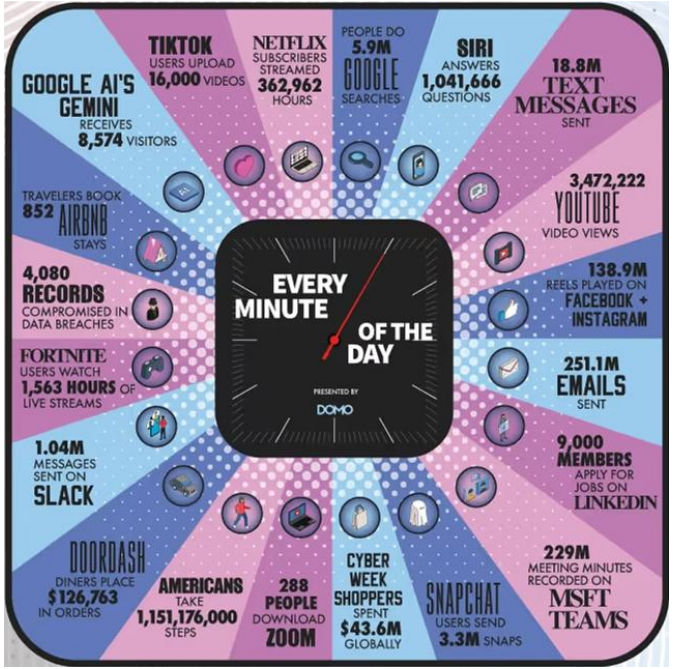
¿Cuántos datos se generan cada minuto de un día?

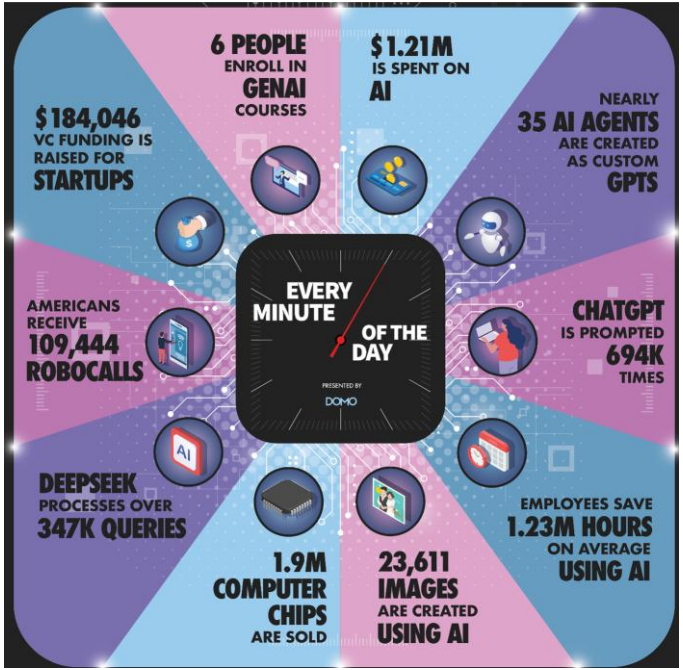
Velocidad



90% de los datos actuales se han creado en los dos últimos años

Velocidad





[Data never sleeps]

1.4

VERACIDAD (4V)

Veracidad

Además de las 3Vs, algunos expertos consideran relevante la dimensión **veracidad** o confiabilidad de los datos.

Veracidad

¿Cómo podemos garantizar que los datos sean correctos y confiables?

Veracidad

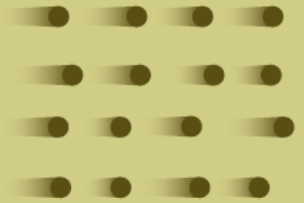
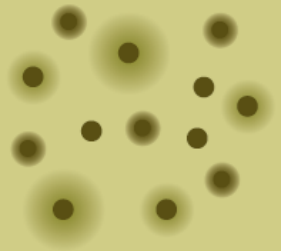
“More data beats clever algorithms, but better data beats more data.”



Google

Peter Norvig
Chief Scientist
Research Director

Las 4 V's del Big Data

Volume	Velocity	Variety	Veracity
			
Data at rest	**Data in motion**	**Data in many forms**	**Data in doubt**
Terabytes to exabytes of existing data to process	Streaming data, milliseconds to seconds to respond	Structured, unstructured, text and multimedia	Uncertainty due to data inconsistency and incompleteness, ambiguities, latency, deception and model approximations

THE 4 V'S OF BIG DATA

Volume
SCALE OF DATA

40 ZETTABYTES
of data will be created by 2020, an increase of 300 times from 2005



6 BILLION PEOPLE
have cell phones
WORLD POPULATION: 7 BILLION



2.5 QUINTILLION BYTES
of data are created each day



Most companies in the U.S. have at least
100 TERABYTES
of data stored



Variety
DIFFERENT FORMS OF DATA

As of 2011, the global size of data in healthcare was estimated to be
150 EXABYTES



30 BILLION PIECES OF CONTENT
are shared on facebook every month



4 BILLION + HOURS OF VIDEO
are watched on You Tube each month



4 MILLION TWEETS
are sent per day by about 200 million monthly active users



Velocity
ANALYSIS OF STREAMING DATA

The New York Stock Exchange captures
1TB OF TRADE INFORMATION
during each trading session

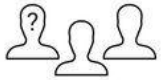


Modern cars have close to
100 SENSORS
that monitor items such as fuel level and tire pressure



Veracity
UNCERTAINITY OF DATA

1 IN 3 BUSINESS LEADERS
don't trust the information they use to make decisions



27% OF RESPONDENTS
in one survey were unsure of how much of data was inaccurate



Reference : http://www.ibmbigdatahub.com/infographic/four-vs-big-data

2.

¿POR QUÉ BIG DATA?

2.1

EVOLUCIÓN TECNOLÓGICA

Evolución Tecnológica

Pero si hemos estado usando **bases de datos** relacionales durante años...



IBM DB2

ORACLE

MySQL

PostgreSQL

Microsoft SQL Server

sas

TERADATA

Evolución Tecnológica

Las **bases de datos** tienen varios problemas:

- Escalabilidad **limitada** y **muy cara**
- **Sólo** soportan **datos estructurados**
- A veces implica **vendor-locking**



Evolución Tecnológica

Año tras año tenemos:

- Mayor capacidad en discos duros (+TB)
- Mayor velocidad en discos duros (SSD)
- Menor precio en discos duros (< € por TB)
- CPU más potentes (Cores & GPU)

Evolución Tecnológica

- Mayor capacidad de memoria (RAM)
- Mayor ancho de banda (> Gbps, 5G)
- Clouds públicas
- Democratización tecnológica

2.2

EVOLUCIÓN ANALÍTICA

Evolución Analítica

BUSINESS INTELLIGENCE



ADVANCED ANALYTICS

Evolución Analítica

Toda empresa necesita de capacidades analíticas para seguir siendo competitivas en sus nichos. Ejemplo de estas capacidades son:

- Ser capaz de tratar cualquier tipo de datos
- Ser capaz de analizar los datos y tomar acciones en tiempo real
- Ser capaz de escalar a medida que el negocio crece.
- Ser capaz de predecir el comportamiento de los clientes.
- ...

Business Intelligence (BI)

Business Intelligence (BI) es un término general que incluye las aplicaciones, la infraestructura, las herramientas y las mejores prácticas que permiten el acceso y el análisis de los datos para mejorar la toma de decisiones.

Gartner - Bi Definition



Business Intelligence (BI)

El BI tradicional se basa en el análisis de datos mirando el **pasado** para que podamos entender:

- ¿Qué ha pasado?
  - Descripción - informes.

- ¿Por qué pasó?
  - Diagnóstico - Cuadros de mando.

Analítica Avanzada (AA)

La **analítica avanzada** es el examen autónomo o semi-autónomo de datos utilizando técnicas y herramientas sofisticadas, que van más allá de del BI tradicional, para descubrir relaciones más profundas, hacer predicciones o generar recomendaciones.

Gartner - AA Definition

Gartner®

Analítica Avanzada (AA)

Ejemplos:

- Minería de datos
- Machine learning
- Minería de patrones frecuentes
- Pronóstico
- Análisis semántico,
- Análisis de sentimientos
- Análisis de grafos
- Estadísticas multivariadas
- Redes neuronales
- ...

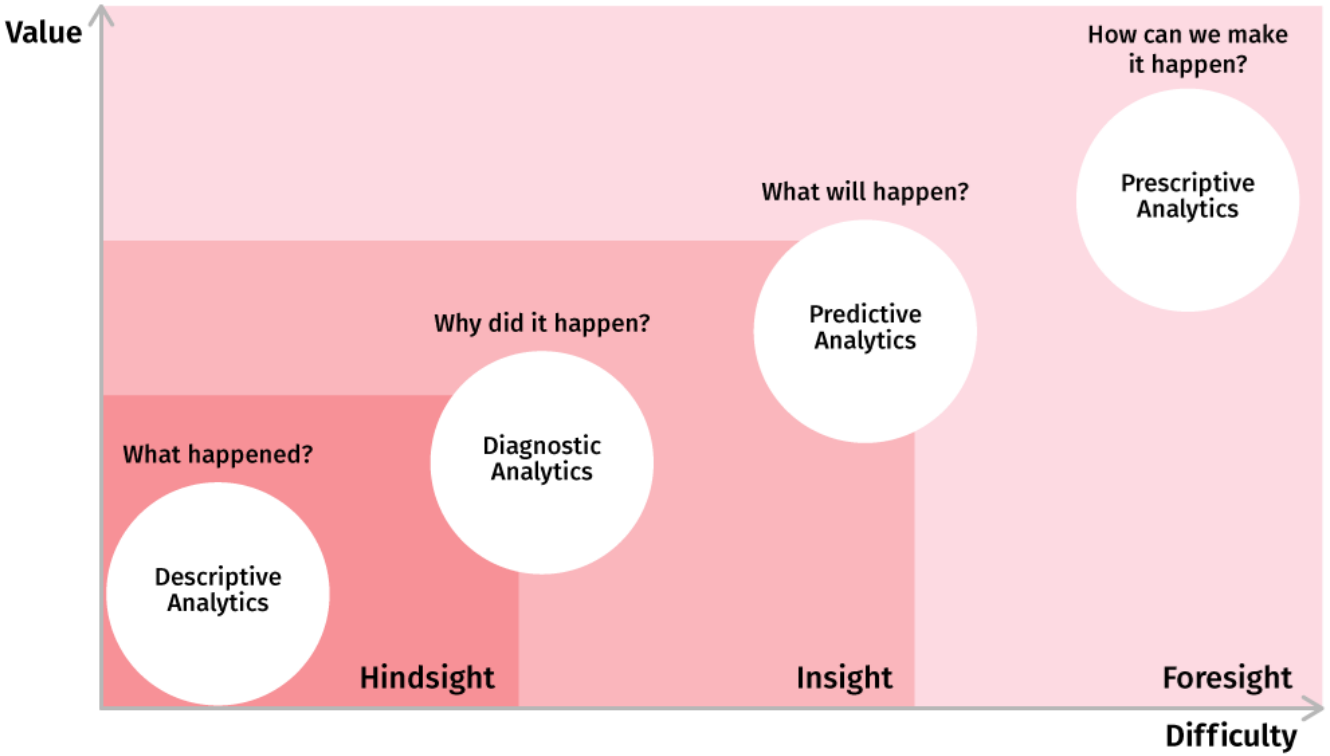
Analítica Avanzada (AA)

Aumenta las capacidades del BI tradicional mirando al **futuro** para que podamos predecir y prescribir:

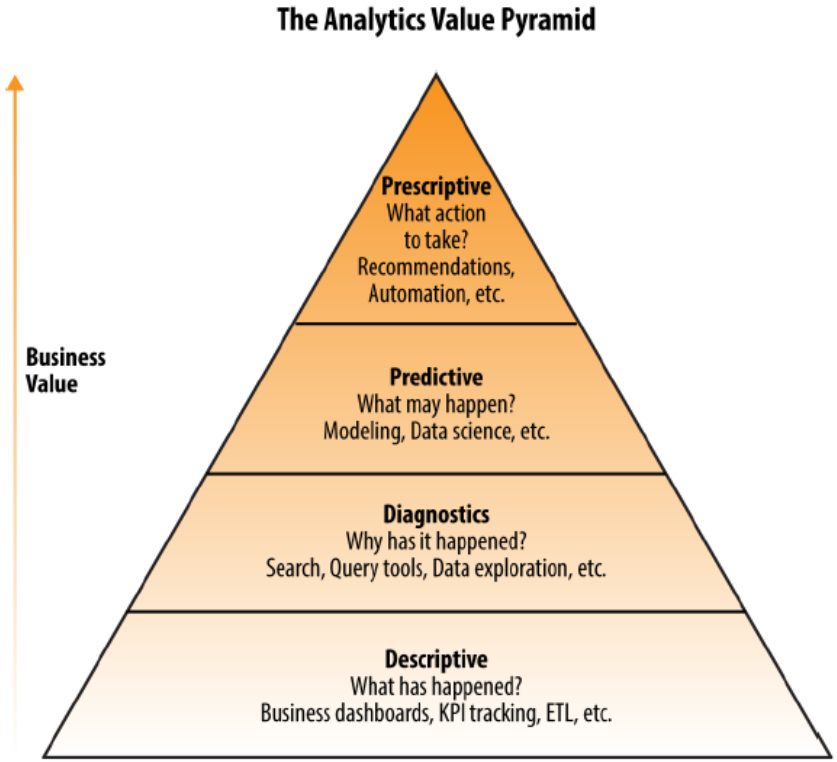
- ¿Qué ha pasado?¿Por qué pasó?
  ¿Qué puede o va a pasar?
  - Predicción - Modelos ML

- ¿Qué hay que hacer?
  - Prescripción - Recomendadores

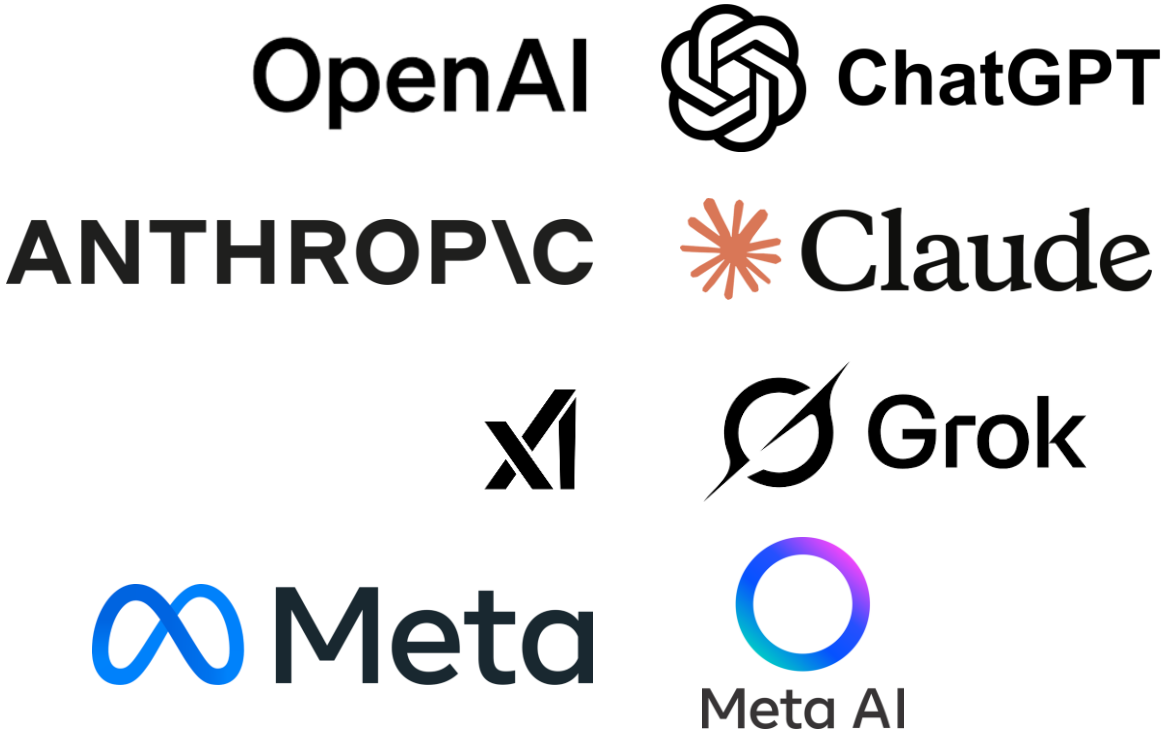
Analítica Avanzada (AA)



Analítica Avanzada (AA)



Inteligencia Artificial (IA)



Inteligencia Artificial (IA)



2.3

VALOR (5V)

Valor

¿Cómo podemos hacer que los datos aporten valor a nuestros negocios?

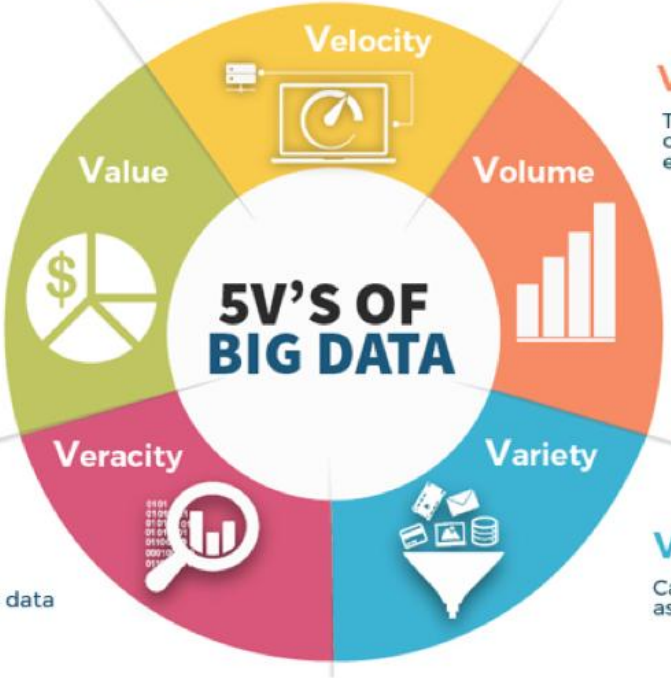
Valor

Se refiere a la importancia de los datos.

El valor de los datos guarda relación directa con lo que las empresas son capaces de hacer con ellos.

Cuando las empresas son capaces de extraer conocimiento o dar sentido a sus datos, su valor aumenta significativamente.

Las 5Vs del Big Data



Velocity
Speed at which data is emanating and changes are occurring between the diverse data sets

Volume
This refers to the sheer volume of data being generated every second.

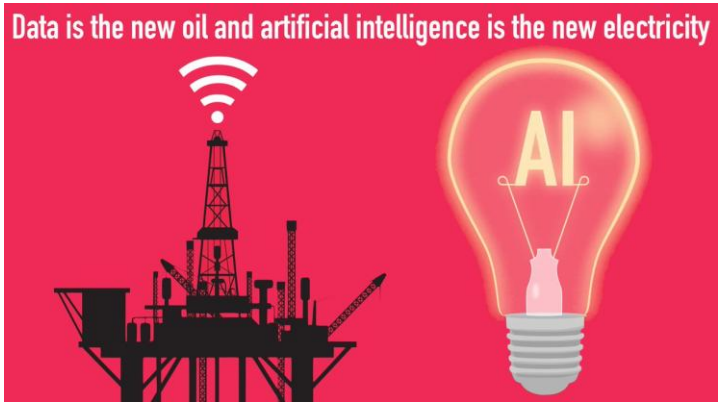
Value
Having access to big data is all well and good but that's only useful if we can turn it into a value.

Veracity
Data reliability and trust.
Verifying and validating the data

Variety
Can use structured as well as unstructured data.

Los Datos son un Activo

El recurso más valioso del mundo ya no es el petróleo sino los datos



Los Datos son un Activo

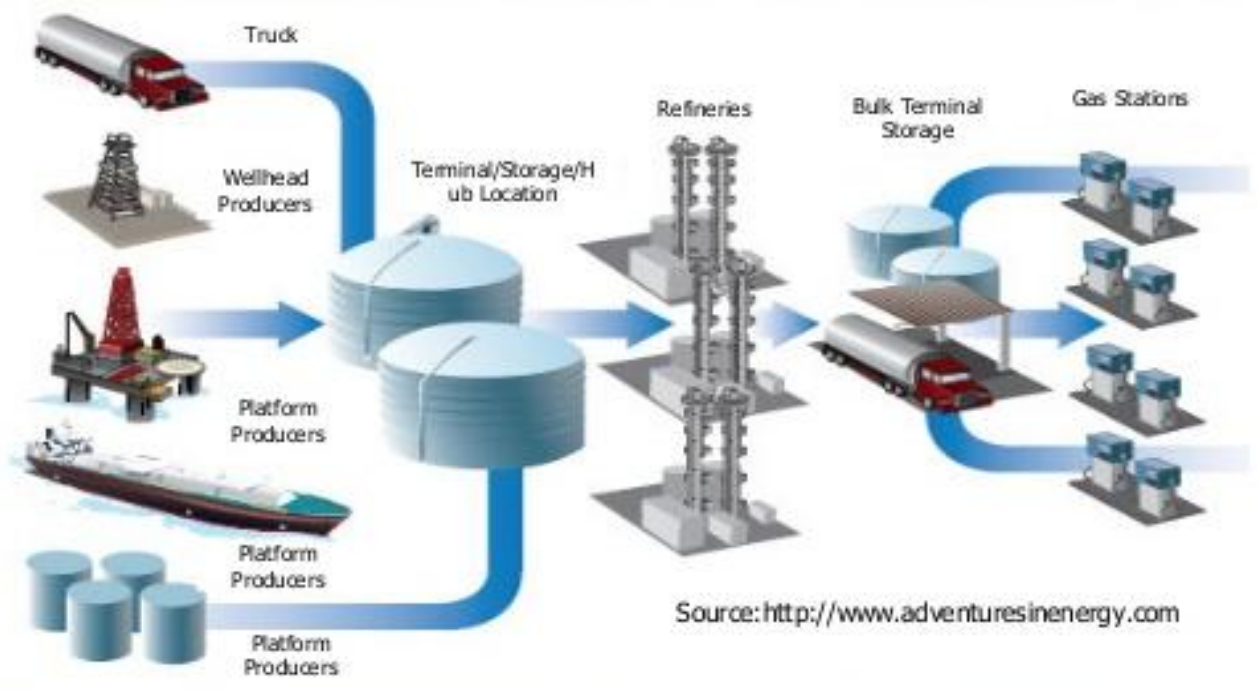
Nuevas empresas y modelos de negocio basados enteramente en Datos + IA



Los Datos son un Activo

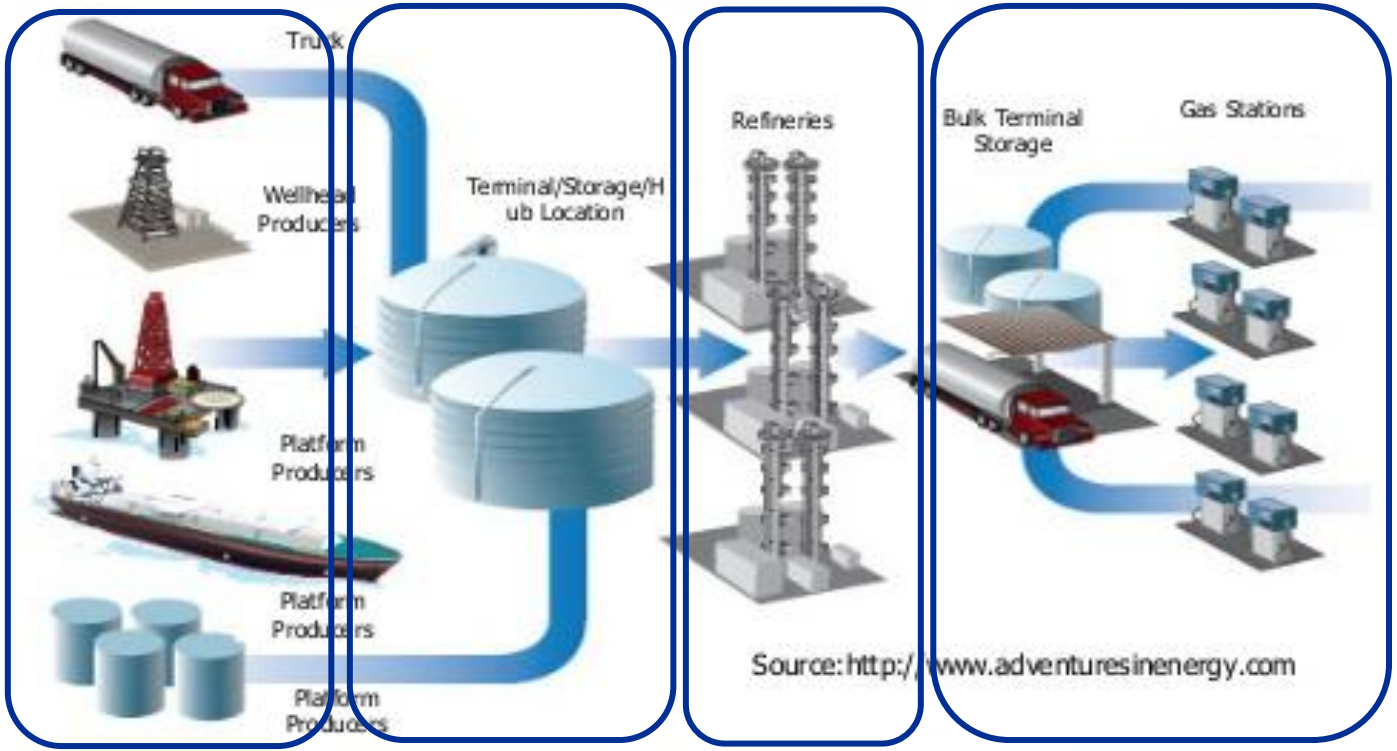


Los Datos son un Activo



CADENA DE VALOR DEL PETRÓLEO

Los Datos son un Activo



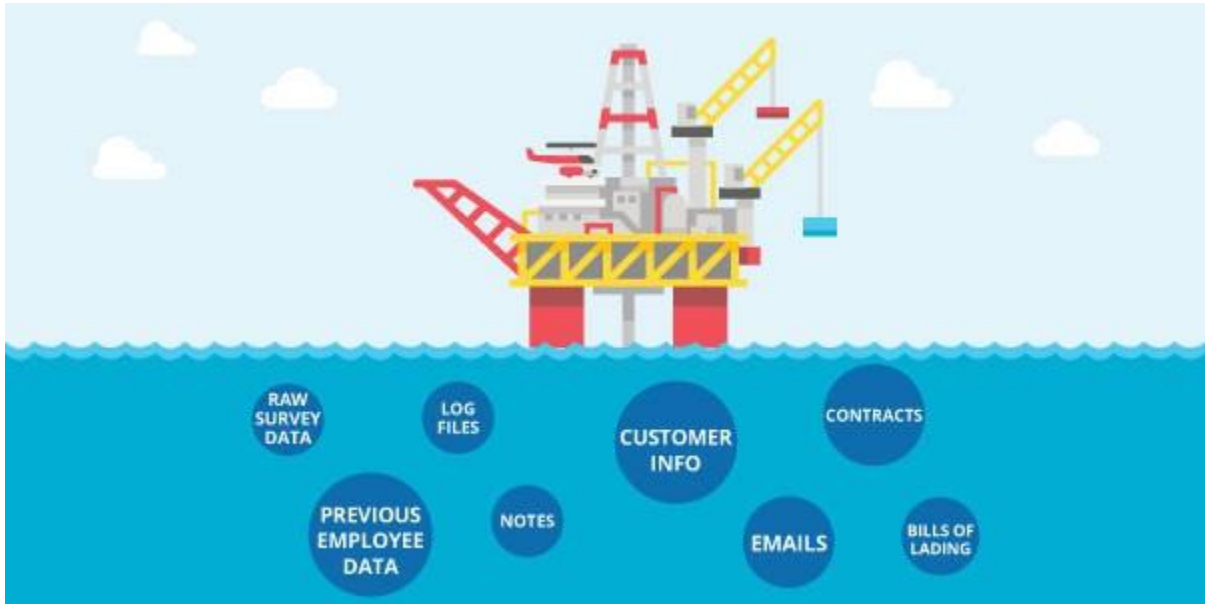
transporte almacenamiento procesado servicio

Los Datos son un Activo

La cadena de valor de los datos requiere los mismos pasos:

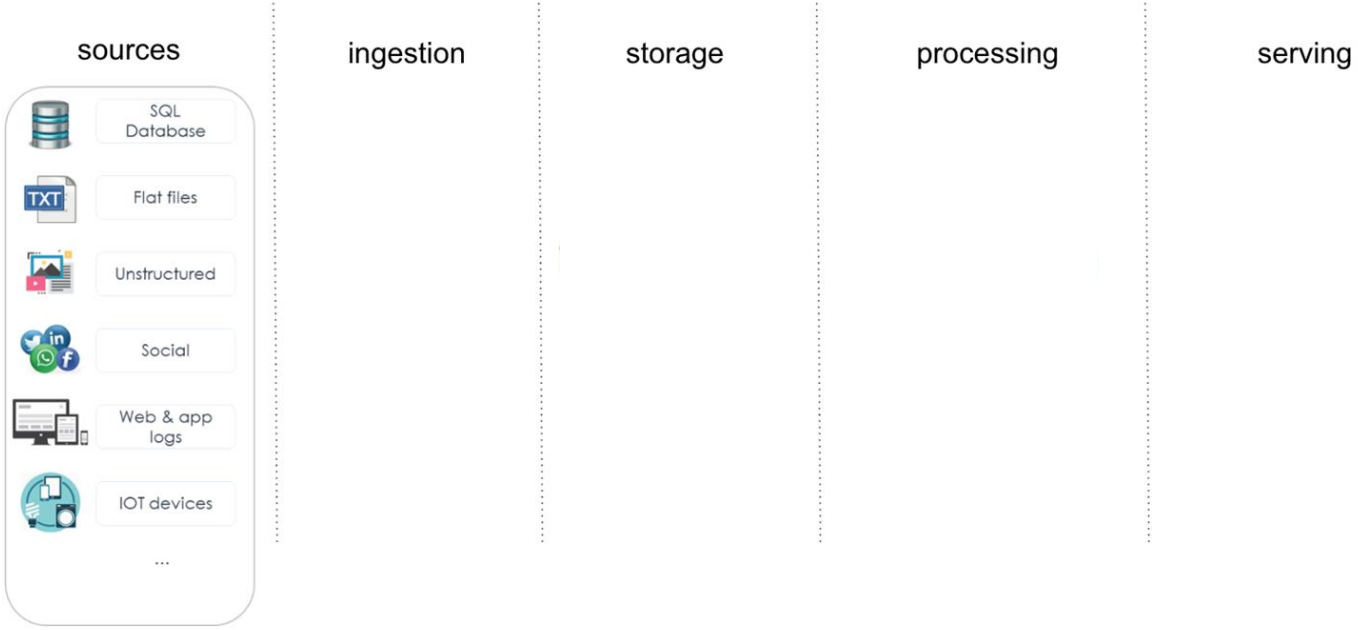
- Transporte
- Almacenamiento
- Procesamiento
- Servicio

Los Datos son un Activo



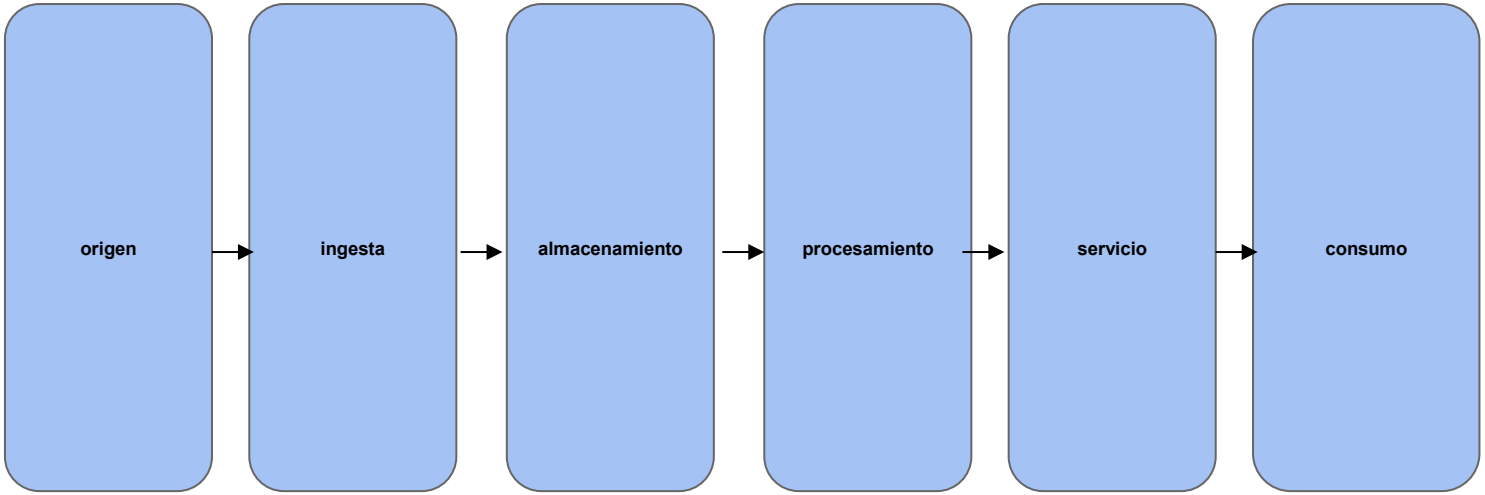
ORÍGENES DE DATOS

Los Datos son un Activo



CADENA DE VALOR DEL DATO

Los Datos son un Activo

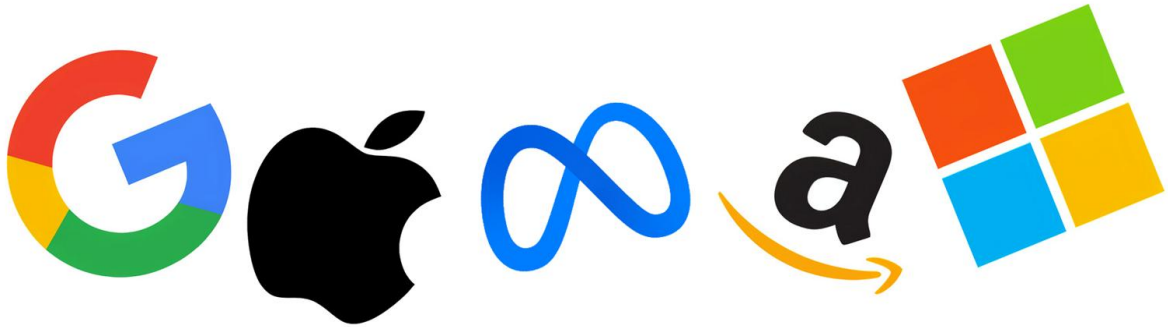


CADENA DE VALOR DEL DATO

3.

CASOS DE USO BIG DATA

¿Quién usa Big Data?



¿Quién usa Big Data?

¡TODO EL MUNDO!

Banca y Finanzas

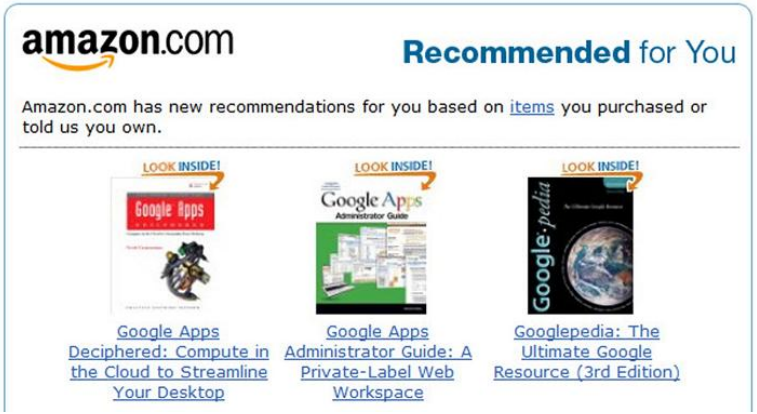
- Detección de fraude
- Detección de blanqueo de capitales
- Análisis y gestión de riesgos
- Segmentación del cliente
- Marketing personalizado





Comercio Electrónico

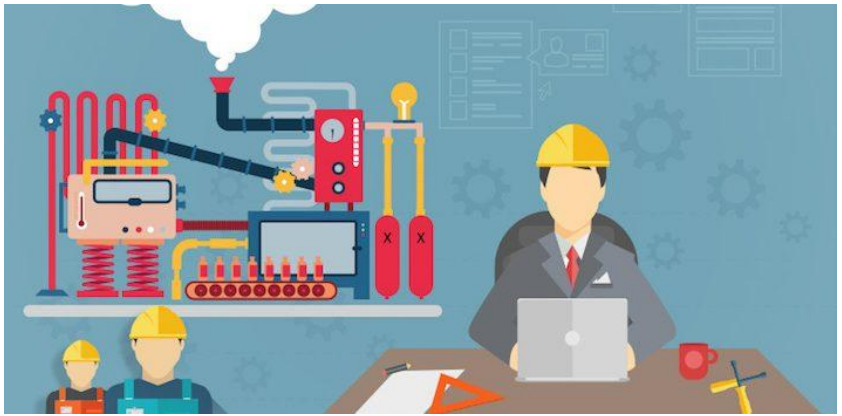
- Recomendación del producto
- Recomendación cruzada - venta
- Precios dinámicos
- Predicción de tendencias





Industria y Manufactura

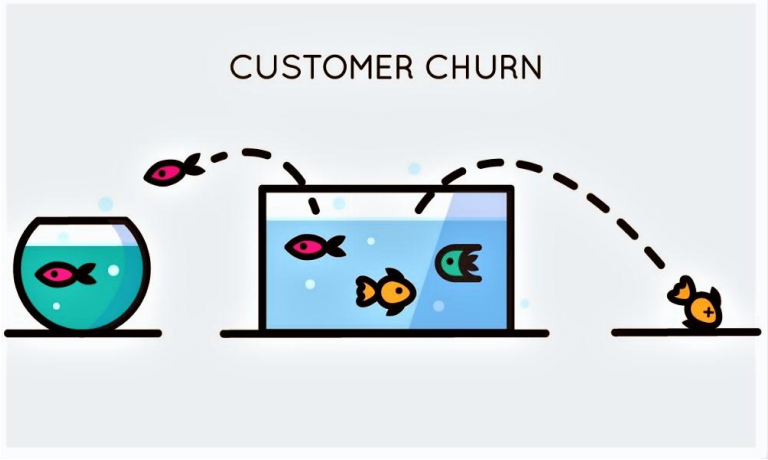
- Mantenimiento preventivo
- Pronóstico de la demanda
- Pricing
- Seguimiento de calidad de los productos





Telecomunicaciones

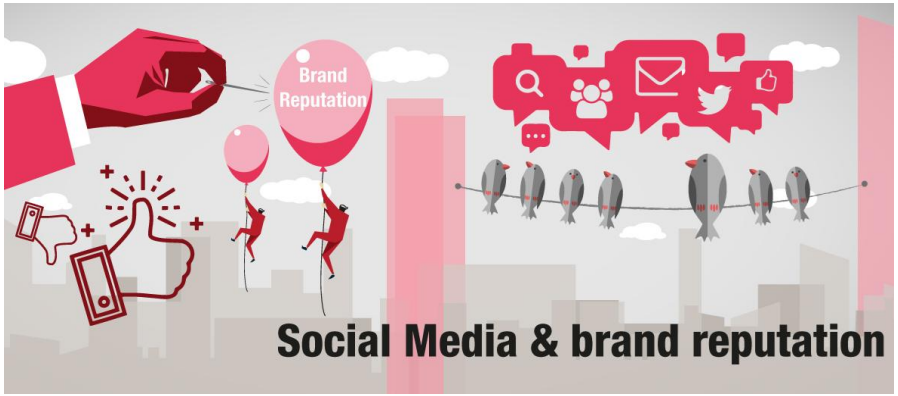
- Abandono de cliente
- Promociones de servicios personalizadas
- Inversión y localización de infraestructuras
- Desarrollo de nuevos productos





Media y Redes Sociales

- Análisis de la reputación de marca
- Marketing de campañas
- Análisis de sentimiento
- Análisis de la influencia
- Análisis de competencia

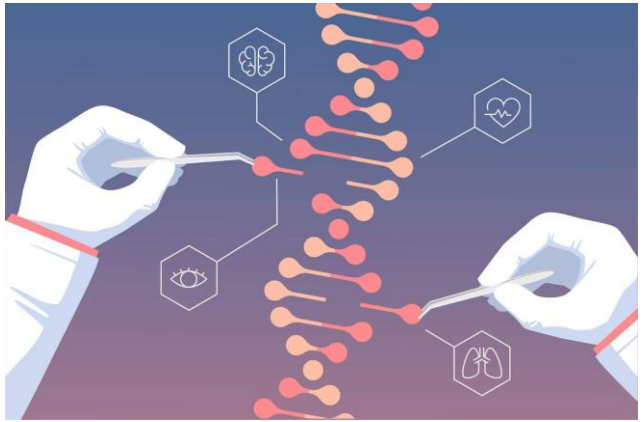




Sector Salud

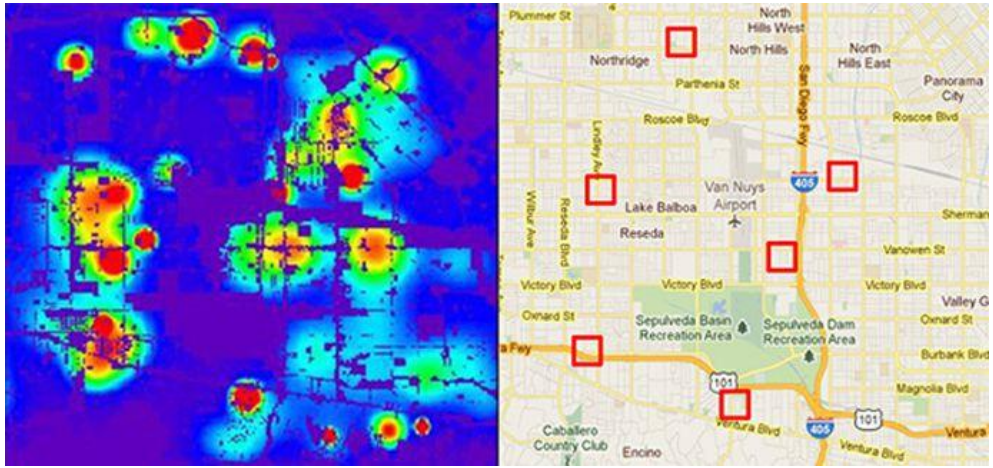
- Búsqueda nuevos tratamientos
- Diagnóstico precoz de enfermedades
- Secuenciación del ADN
- Fraude y abuso en los seguros





Seguridad y Lucha Terorrismo

- Detección de amenazas
- Predicción de crímenes y delitos
- Predicción de ataques DOS
- Respuesta a las crisis



Sector Público

- Smart Cities
- Gestión de recursos (energía, agua)
- Gestión del tráfico y el transporte
- Planificación urbana



4.

ORIGEN DEL BIG DATA

Origen del Big Data

2002

Doug Cutting y Mike Cafarella comenzaron a desarrollar un nuevo motor de búsqueda web llamado Nutch.

Pronto se dieron cuenta de que su solución no sería capaz de escalar para indexar todo Internet.



Origen del Big Data

2003



Para entonces Google ya tenía ese problema.

Los ingenieros de Google publicaron un artículo explicando cómo resolvieron sus problemas de escalabilidad de **almacenamiento** con el sistema de archivos de Google (GFS)

Google

Origen del Big Data



Google publicó un nuevo artículo explicando cómo estaban **procesando** archivos de datos GFS con un nuevo modelo de programación llamado MapReduce para lograr el nivel máximo de paralelismo.

Google

Origen del Big Data

2004

Doug Cutting y Mike Cafarella aún estaban bloqueados con su problema de escalabilidad.

Después de leer los artículos de Google pensaron que estas tecnologías serían la solución a su problema.



Origen del Big Data

2005

Nutch copió las ideas de Google y creó una solución personalizada de MapReduce y una implementación del sistema de archivos distribuido que llamaron Nutch Distributed File System (NDFs)



Origen del Big Data

2006

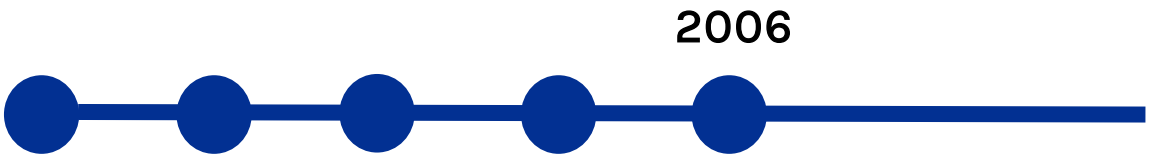
Doug Cutting y Mike Cafarella entendieron que su solución estaba extrapolable para otros problemas así que decidieron sacarla de Nutch como un proyecto separado llamado Hadoop. De esta manera, NDFS también fue renombrado como HDFS.



Origen del Big Data



Origen del Big Data



Doug Cutting se une a Yahoo! y con un equipo dedicado y recursos es capaz de evolucionar Hadoop



Origen del Big Data

2008



Hadoop es donado a la Fundación de software Apache (ASF) y se convierte en un proyecto de nivel superior



Origen del Big Data

Hadoop es una tecnología que permite a las empresas la capacidad de **almacenar** y **procesar** grandes cantidades de datos (Big Data).



Origen del Big Data

Hadoop se organiza en 2 componentes:

- Hadoop HDFS
- Hadoop MapReduce

Origen del Big Data

Hadoop HDFS:

Componente de Hadoop encargado del **almacenamiento** de los datos.

Es un sistema de archivos escalable y distribuido:

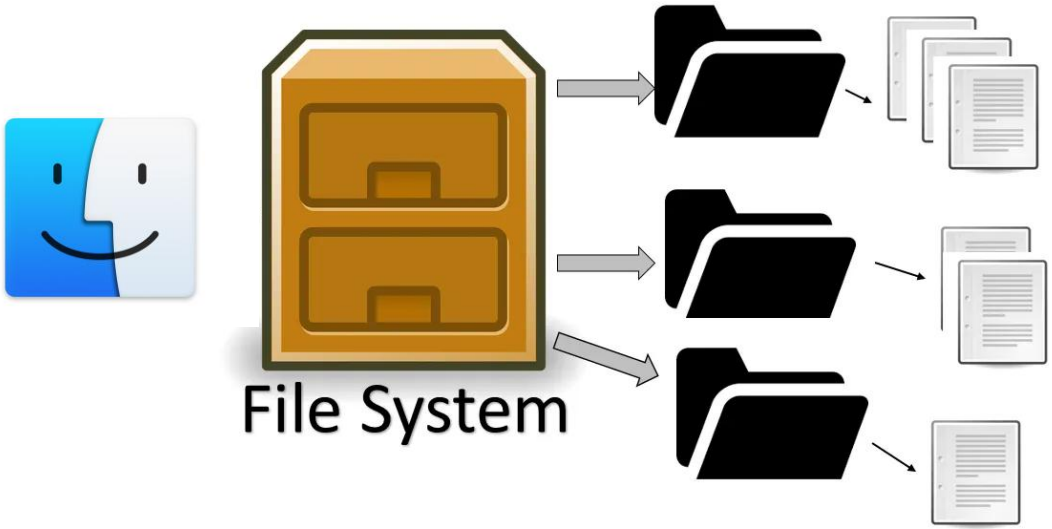
- Almacena datos en ficheros
- Organizar datos en directorios

Origen del Big Data

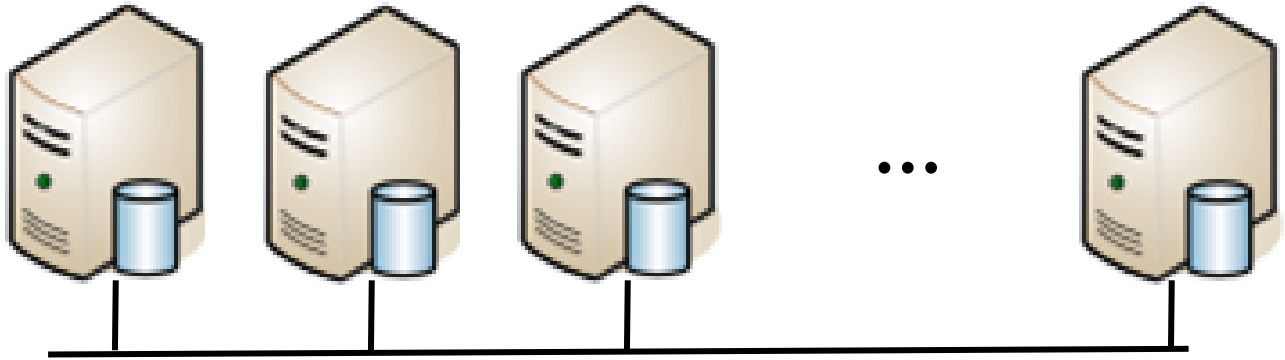


En un sistema de archivos local todos los archivos se almacenan en un solo servidor

Origen del Big Data

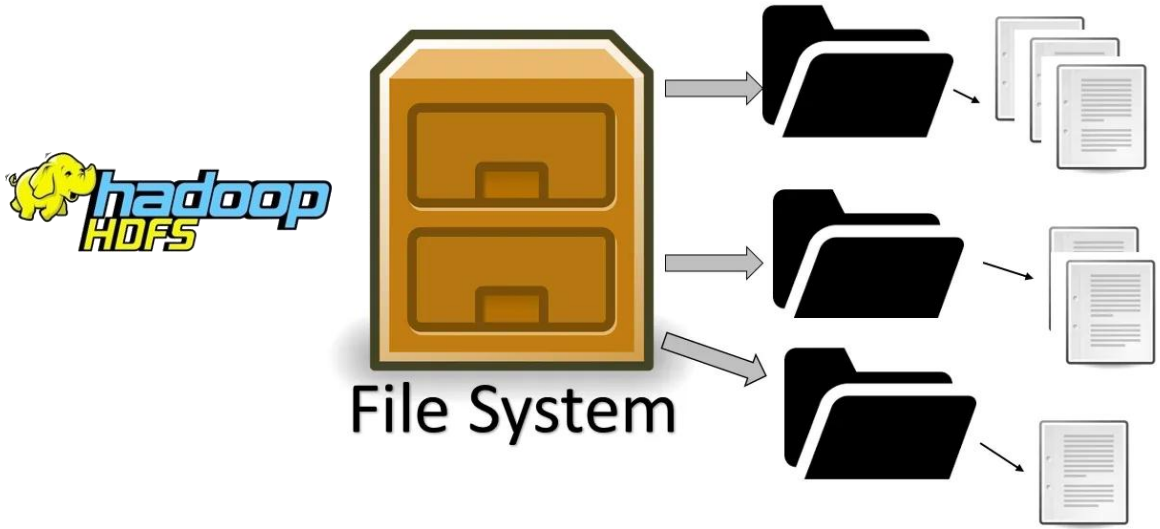


Origen del Big Data



En un sistema de ficheros distribuido los archivos se almacenan en múltiples servidores (cluster)

Origen del Big Data



Origen del Big Data

Hadoop MapReduce:

Componente de Hadoop encargado del **procesamiento** de los datos.

Solo puede **procesar** datos **almacenados en HDFS**.

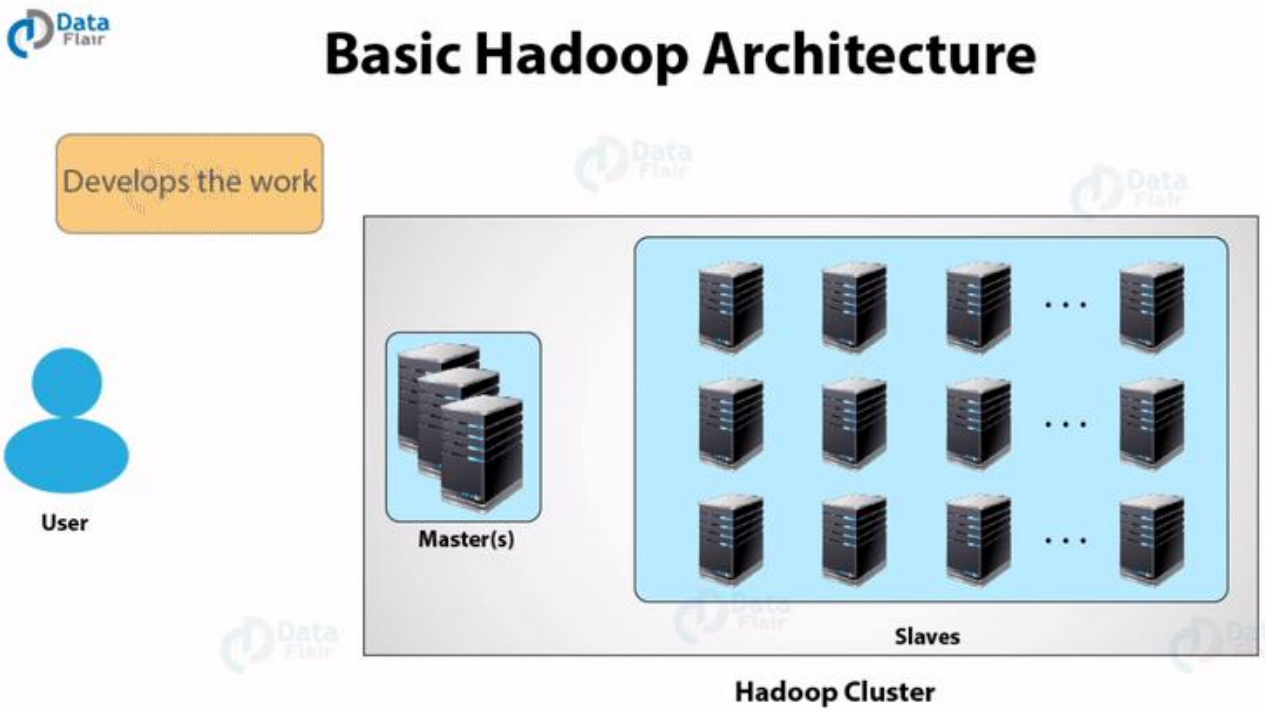
Puesto que los datos se almacenan en múltiples servidores, necesitamos una capa software que permita ejecutar aplicaciones distribuidas que ejecuten en varios servidores en paralelo.

Origen del Big Data

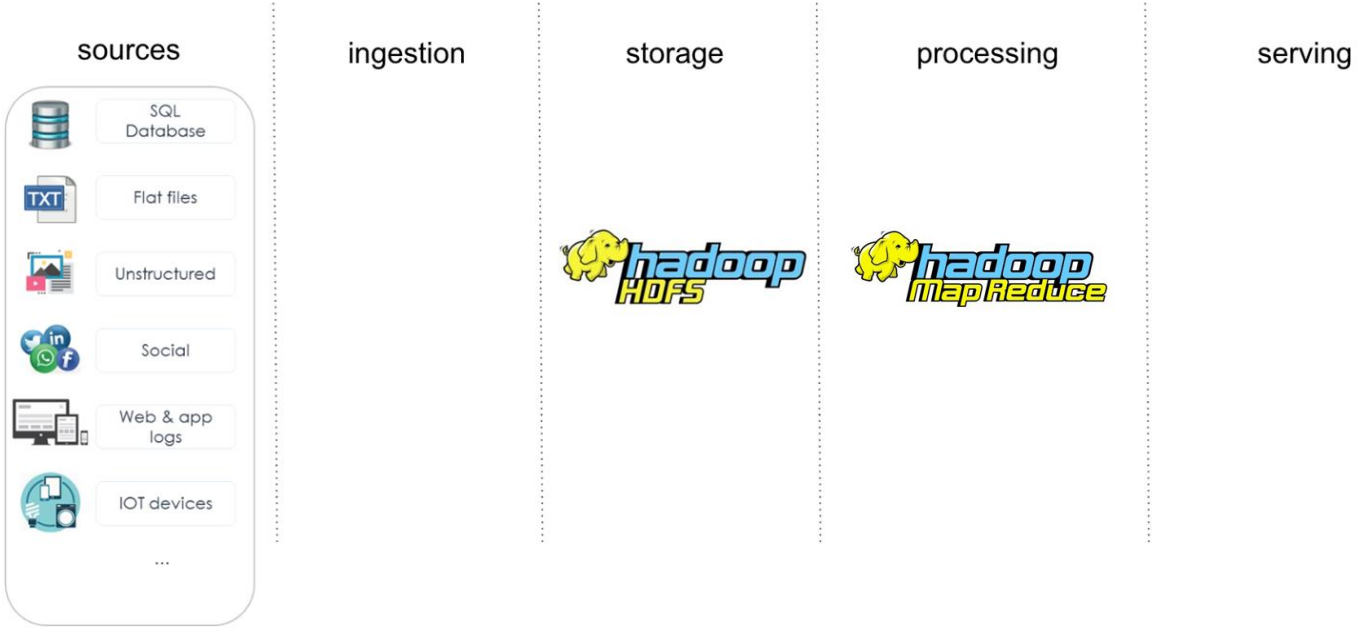
Hadoop MapReduce:

Hadoop MapReduce es un conjunto de librerías y herramientas que permiten crear aplicaciones de procesamiento distribuido

Origen del Big Data



Origen del Big Data



5.

ECOSISTEMA BIG DATA

Ecosistema

A partir de este momento (2008), la tecnología Big Data está disponible para cualquiera por primera vez.

Otras empresas comenzaron a usarlo y también a abrir su tecnología a la comunidad de código abierto. Fue el inicio de nuevos proyectos entorno a Hadoop creando un ecosistema Big Data

Ecosistema

El ecosistema **surgió de las características inexistentes** y normalmente requeridas para resolver casos de uso Big Data extremo a extremo.

Hadoop sólo proporcionaba almacenamiento y procesamiento. Sólo es capaz de lidiar con 2 Vs (volumen y variedad)

Ecosistema

Hay literalmente decenas de tecnologías en el ecosistema.

Las más comunes están relacionadas con:

- Integración e ingesta de datos
- Procesamiento de datos
- Servicio y consumo de datos

Ingesta de Datos

La ingesta de datos consiste en extraer o capturar los datos desde su origen y trasladarlos hasta la capa de almacenamiento de una manera escalable y fiable.

Hadoop carece de esta funcionalidad 😔.

Procesamiento de Datos

El procesamiento de datos se refiere a cómo se transforman/analizan los datos para destilar su valor.

Hadoop solo puede hacer procesamiento batch 😔.

Procesamiento de Datos

Hadoop MapReduce tenía varios problemas:

- Dificil de usar 🤯
  (no todos los problemas pueden resolverse con mapreduce).

- API completa sólo en Java 😩

- Sólo batch (no streaming) 😩

Procesamiento de Datos



Procesamiento de Datos

Hoy en día necesitamos:

- Procesamiento de streaming
- Procesamiento en memoria
- Procesamiento SQL
- Procesamiento ML
- Procesamiento Grafos

...

Procesamiento de Datos

Es por esto que aparecieron otras tecnologías en el ecosistema que proporcionan nuevos tipos de procesamiento

Una de estas tecnologías es Apache Spark, que destronó a Hadoop



Procesamiento de Datos



Servicio de Datos

Los datos procesados se disponibilizan para ser consumidos por usuarios o aplicaciones finales.

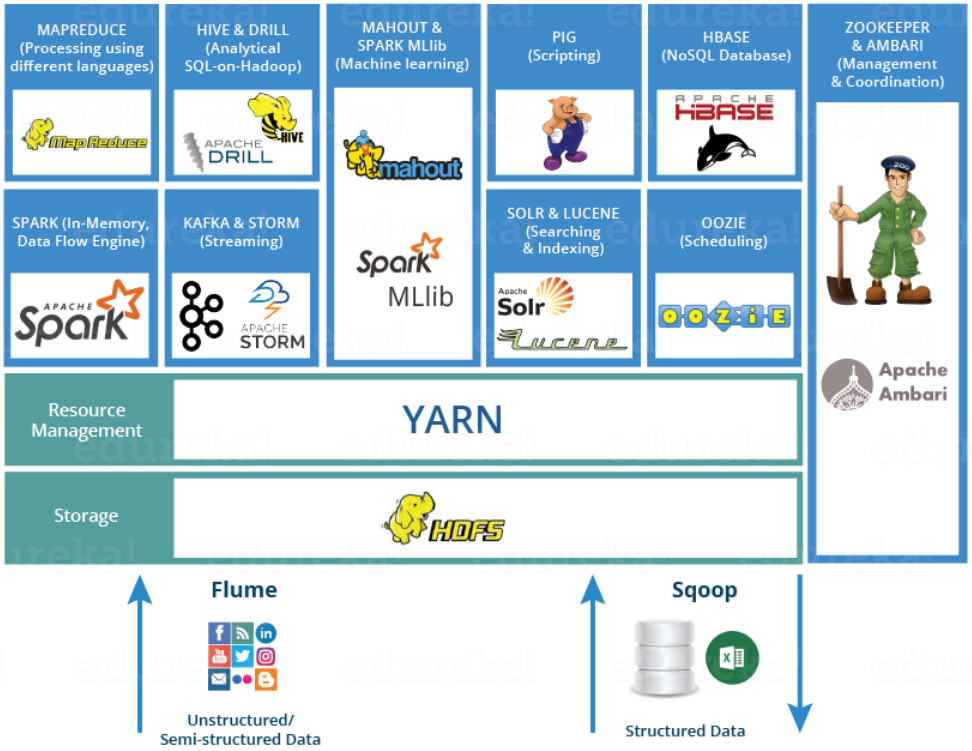
Hadoop carece de esta funcionalidad 😔.

Servicio de Datos

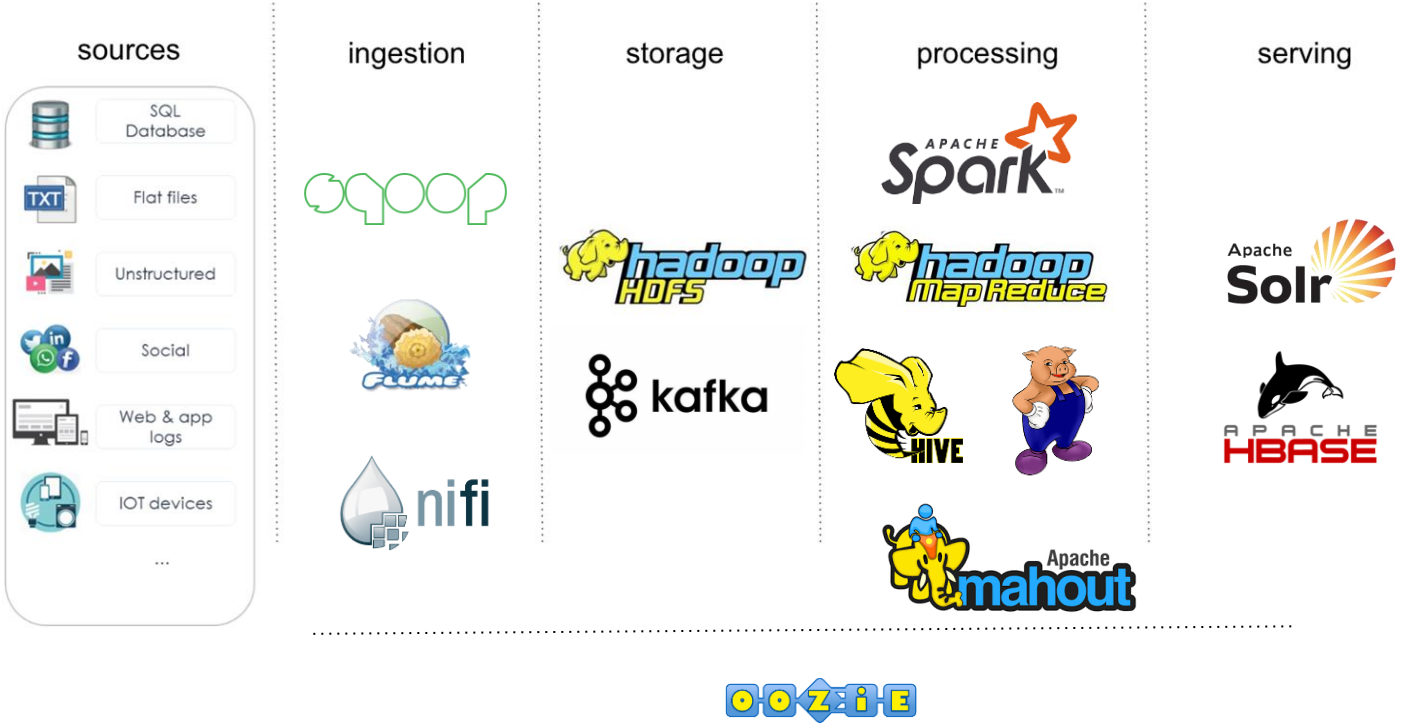
¿Y si los resultados del procesamiento son también Big Data?

Aparecieron nuevas tecnologías de almacenamiento alternativas a la bases de datos relacionales tradicionales, **NoSQL**.

Ecosistema Big Data (Legacy)



Ecosistema Big Data (Legacy)



Ecosistema Big Data (Legacy)



Ecosistema Big Data

El ecosistema de Big Data evoluciona y mejora continuamente con nuevas tecnologías



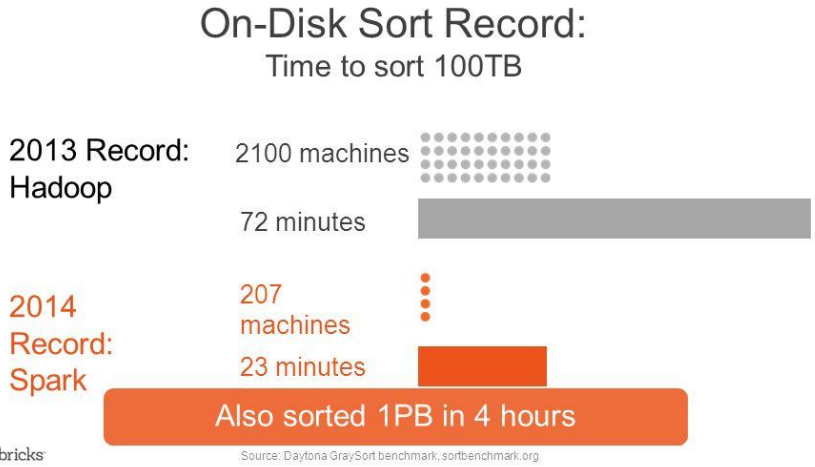
Ecosistema Big Data



VS







Source: Daytona GraySort benchmark, sortbenchmark.org

Ecosistema Big Data

El ecosistema Big Data se ha modernizado y desplazado hacia las nubes públicas.

Los proveedores cloud ofrecen todas estas tecnologías Big Data como servicios listos para usar.





