ntic master
revolucionamos la comunicación

TECNOLOGÍAS DEL BIG DATA

ARQUITECTURAS DE DATOS

Agenda

- Definición
- Importancia
- Desafíos
- Contexto
- Historia
- Tipos
- Estructura



1.

DEFINICIÓN

Definición

Una arquitectura de datos es una **solución tecnológica** que permite a las empresas recopilar, almacenar, procesar y explotar todos sus activos de datos.

Definición

Una arquitectura de datos debe:

- poder integrar cualquier tipo de dato
- tolerar errores (técnicos y humanos)
- ser escalable
- ser extensible
- ser evolucionable
- ser segura
- estar gobernada
- ofrecer multiples interfaces de consumo
- ...

Definición

La arquitectura de datos define un enfoque conceptual y un conjunto de tecnologías para gestionar todos los activos de datos dentro de la empresa.

No existe una solución única, sino que se adaptan según necesidades específicas de cada empresa o sector.

2.
IMPORTANCIA

Importancia

Invertir tiempo en diseñar una arquitectura de datos adecuada es crucial.

Sin planificación, los usuarios pueden no obtener valor y la empresa puede retrasarse frente a la competencia.

Importancia

La importancia de las arquitecturas de datos radica en su capacidad para:

- Facilitar la toma de decisiones
- Impulsar la Innovación
- Optimizar la eficiencia operativa
- Crear ventajas competitivas
- Identificación de tendencias y oportunidades
- ...

Importancia

Facilitar la toma de decisiones

Las empresas dependen de datos precisos y oportunos para tomar decisiones informadas.

Las arquitecturas de datos deben garantizar que los datos estén disponibles en el momento correcto y en el formato o sistema adecuado para su consumo.

Importancia

Impulsar la innovación

Los datos son la base de la innovación.
Las últimas tendencias como la inteligencia artificial (AI) o el aprendizaje automático (ML) solamente son posibles mediante el entrenamiento de ingentes cantidades de datos

Importancia

Optimizar la eficiencia operativa

La optimización de las operaciones empresariales requiere una gestión eficiente de datos que intervienen en la operativa diaria.
Las arquitecturas de datos permiten una gestión más eficaz de los recursos y los procesos ya que permiten entender la realidad de la empresa y por lo tanto, encontrar oportunidades de mejora.

Importancia

Crear ventajas competitivas

Las empresas que pueden aprovechar al máximo sus datos tienen una ventaja competitiva ya que pueden adaptarse rápidamente a los cambios del mercado y ofrecer mejores productos y servicios.

Importancia

Identificación de tendencias y oportunidades

Los datos permiten identificar tendencias y oportunidades que, de otro modo, pasarían desapercibidas.

La explotación de los datos y la analítica avanzada pueden revelar patrones ocultos y oportunidades en base a las tendencias.

Importancia

Un error en la arquitectura puede costar millones de euros y retrasar el progreso de la empresa.

Es esencial una arquitectura que permita a usuarios con pocos conocimientos técnicos analizar y generar informes / reportes

3.

DESAFÍOS

Desafíos

El principal desafío que enfrentan las arquitecturas de datos es el propio dato.

Desde la primera década de este siglo los datos han ido evolucionando en todas sus dimensiones principales.

Las empresas necesitan arquitecturas de datos que soporten grandes volúmenes y tipos de datos.

Desafíos

La gestión del dato actual presenta desafíos únicos, conocidos como las 5 vs del Big Data:

- Volumen
- Variedad
- Velocidad
- Veracidad
- Valor

4.

CONTEXTO

Contexto

En todas las empresas existe una separación entre los sistemas

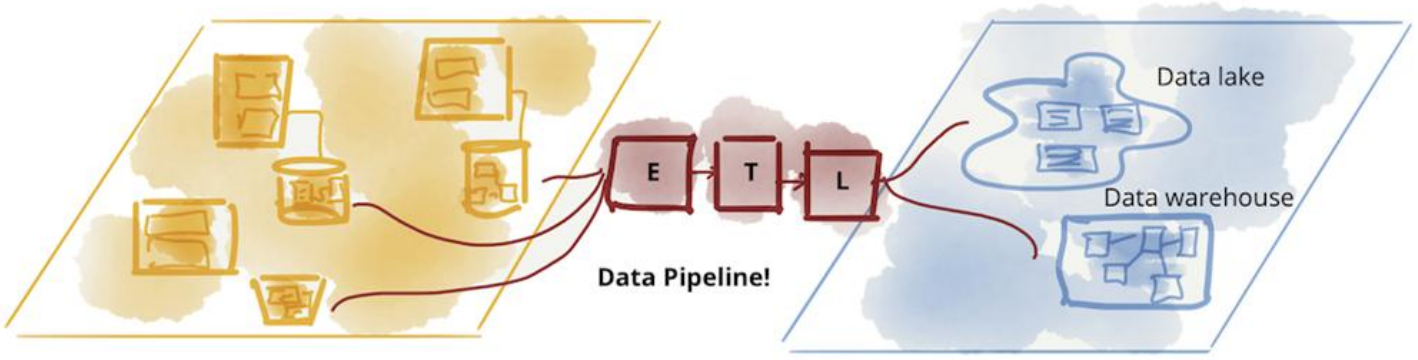
plano operacional/transaccional:
operan el propio negocio

plano informacional/analítico:
operan la analítica

Contexto

El motivo fundamental de esta separación es que ambos planos tienen **requisitos muy distintos** y por ello hacen usos de **stacks tecnológicos diferentes**.

Contexto


E
T
L
Data lake
Data warehouse
Data Pipeline!
Operational Data Plane
Running the business
Serving the users
Analytical Data Plane
Optimizing the business
Augmenting the user experience
with intelligence

Contexto

plano operacional

Lleva el peso de **soportar** todos los procesos y datos que permiten el correcto funcionamiento de **la operativa diaria** de la empresa y, por lo tanto, son críticos para el negocio.

Contexto

plano operacional

Los sistemas operacionales **no pueden ponerse en riesgo por parte de los procesos analíticos**, ya que si estos sobrecargan el sistema pueden provocar su fallo o su indisponibilidad, con el consiguiente impacto en el negocio.

Contexto

plano informacional

Para **permitir la toma de decisiones**, inteligencia de negocio (BI) y la analítica avanzada (AA), históricamente el dato se ha trasladado hasta el plano informacional mediante procesos de extracción, transformación y carga o ETLs (Extract Transform Load)

Contexto

Los **sistemas operacionales** hacen uso de sistemas **OLTP** para persistir y almacenar sus datos.

OLTP (OnLine Transaction Processing) se refiere a almacenes y bases de datos especializadas en la gestión de millones de **pequeñas transacciones**: (**insert**, **update**, **delete**, **merge**).

Contexto

Los **sistemas informacionales** por otro lado, han hecho uso de sistemas **OLAP** (OnLine Analytical Processing) especializados en el procesamiento de **grandes consultas** de datos (**select**).

Contexto


Sales operations data
CRM
ETL/ELT
BUSINESS QUESTION
How are we doing with SALES of the product?
Central repositories
Data Analyst builds report

5.

HISTORIA

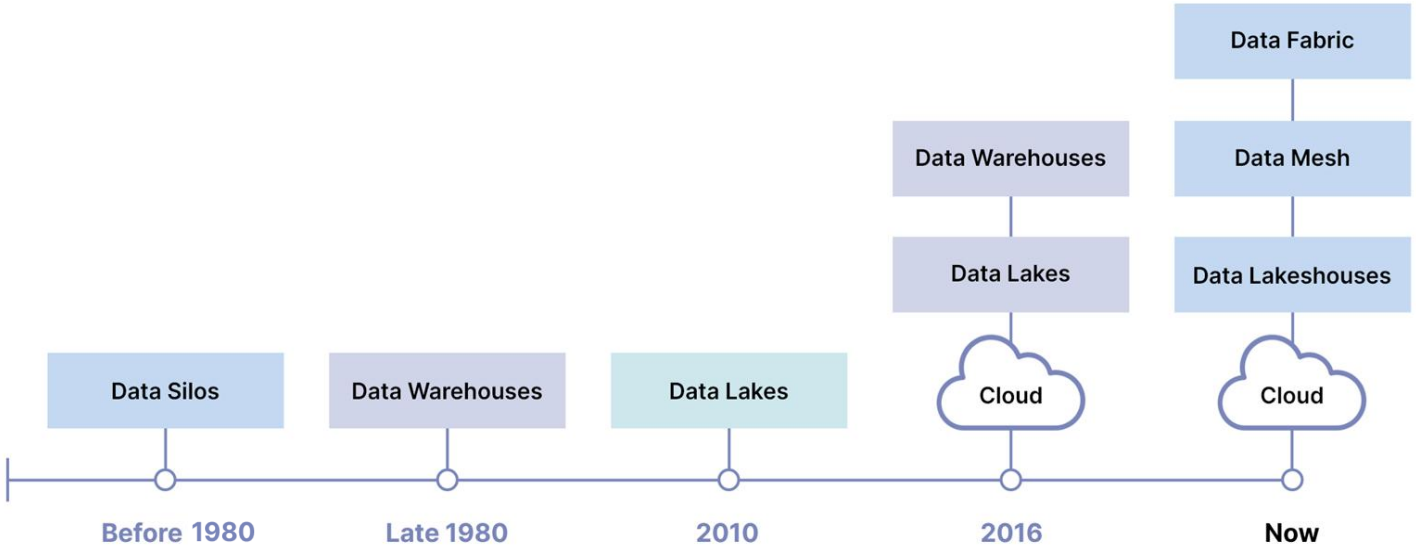
Historia

El concepto de arquitectura de datos no es nuevo, pero ha evolucionado con el tiempo, adaptándose a las cambiantes demandas tecnológicas y empresariales.

Historia

La evolución de las arquitecturas de datos muestra cómo han pasado de simples bases de datos aisladas, a sistemas altamente complejos y distribuidos.

Historia


Data Fabric
Data Warehouses
Data Mesh
Data Lakes
Data Lakeshouses
Data Silos
Data Warehouses
Data Lakes
Cloud
Cloud
Before 1980
Late 1980
2010
2016
Now

6.

TIPOS

Tipos

Las principales arquitecturas a lo largo de los últimos años:

- Data Warehouse
- Data Lake
- Modern Data Warehouse
- Data Fabric
- Data Lakehouse
- Data Mesh

DATA WAREHOUSE



Data Warehouse

Las bases de datos relaciones se especializan en dos categorías en función de su propósito:

OLTP: **O**n**L**ine **T**ransactional **P**rocessing

OLAP: **O**n**L**ine **A**nalytical **P**rocessing

Data Warehouse

OLTP

Bases de datos operacionales se caracterizan por un gran número de transacciones a gran velocidad (INSERT, UPDATE, DELETE, MERGE)

- Sobre las que desarrolla el negocio
- Optimizadas para transacciones
- Las tablas están **normalizadas** (3FN)
- Son los orígenes de los data warehouses.

Data Warehouse

OLAP

Bases de datos informacionales se caracterizan por un volumen relativamente bajo de transacciones y un volumen moderado/alto de consultas (SELECT)

- Sobre las que se analiza el negocio
- Optimizadas para consultas
- Las tablas están **desnormalizadas** (star / snowflake)
- Sobre las que se implementan los data warehouses

Data Warehouse

Las primeras bases de datos (1970s-1980s) eran sistemas operacionales aislados basadas arquitecturas OLTP.

Estas bases de datos almacenan **datos estructurados** en **tablas** y se basan en el **modelo relacional** propuesto por Codd en 1970

Data Warehouse

Problemas [1980]:

- La consulta y generación de informes a partir de estas bases de datos aisladas era tremendamente complejo.
- Además, muy intensiva y con gran impacto sobre el rendimiento de las bases de datos.
- No optimizadas para consultas pesadas

Data Warehouse

Solución:
Extraer y centralizar los datos a otra base de datos especializada (basada en sistemas OLAP), nace el **Data Warehouse**

Ventajas:
Mejora el rendimiento.
Acceso centralizado a los datos.
Reducción carga en sistemas operacionales

Data Warehouse

Un Data Warehouse (DW) es una **base de datos relacional** que centraliza todos o gran parte de los datos de una compañía.

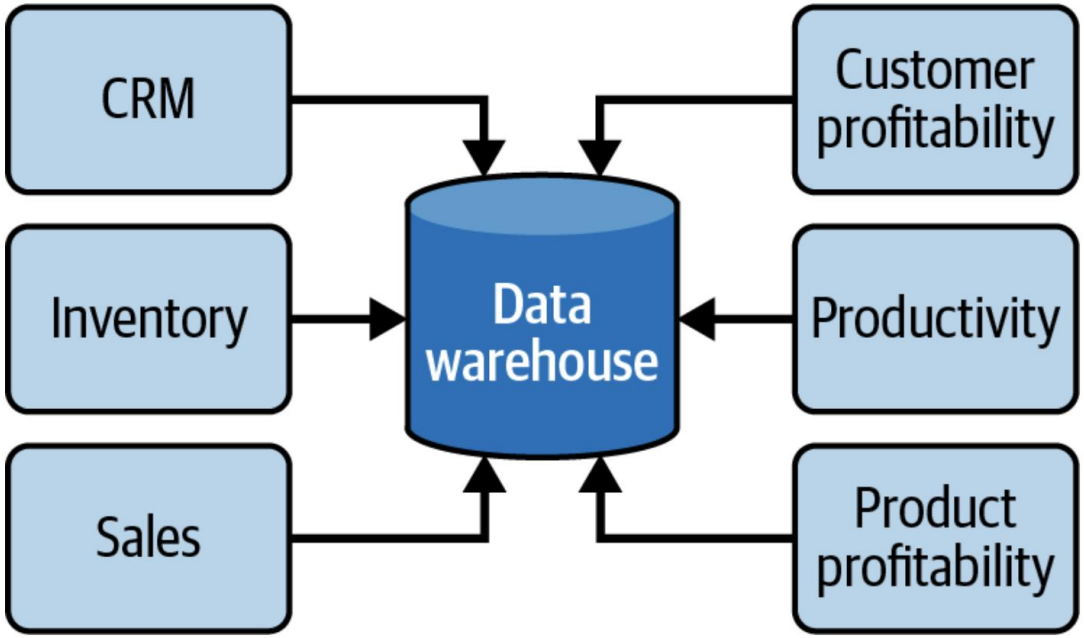
Están destinados a facilitar la toma de decisiones y por lo tanto, íntimamente relacionadas con el business intelligence (BI), cuadros de mando, reporting y visualización.

Data Warehouse

Normalmente contiene la información de varios departamentos de la empresa:

- Comercial
- Marketing
- Financiero
- Operaciones
- Tecnología
- Recursos Humanos
- ...

Data Warehouse



Data Warehouse

Sin embargo tienen ciertas **limitaciones**:

- Estructura
  solamente soportan datos estructurados
- Esquema
  necesita definirse de antemano antes de poder escribir los datos (schema-on-write)
- Granularidad
  datos normalmente agregados
- Escalabilidad
  limitada y alto coste económico

Schema-on-Write vs Schema-on-Read

Un esquema de datos (schema) define el orden, nombre y tipo de datos de las columnas o atributos, así como sus posibles restricciones.

Schema-on-Write vs Schema-on-Read

schema-on-write

el esquema se define antes de escribir los datos, asegurando consistencia.

schema-on-read

el esquema se aplica al leer los datos, ofreciendo mayor flexibilidad durante la escritura.

Schema-on-Write

Usado en bases de datos relacionales y **DW**

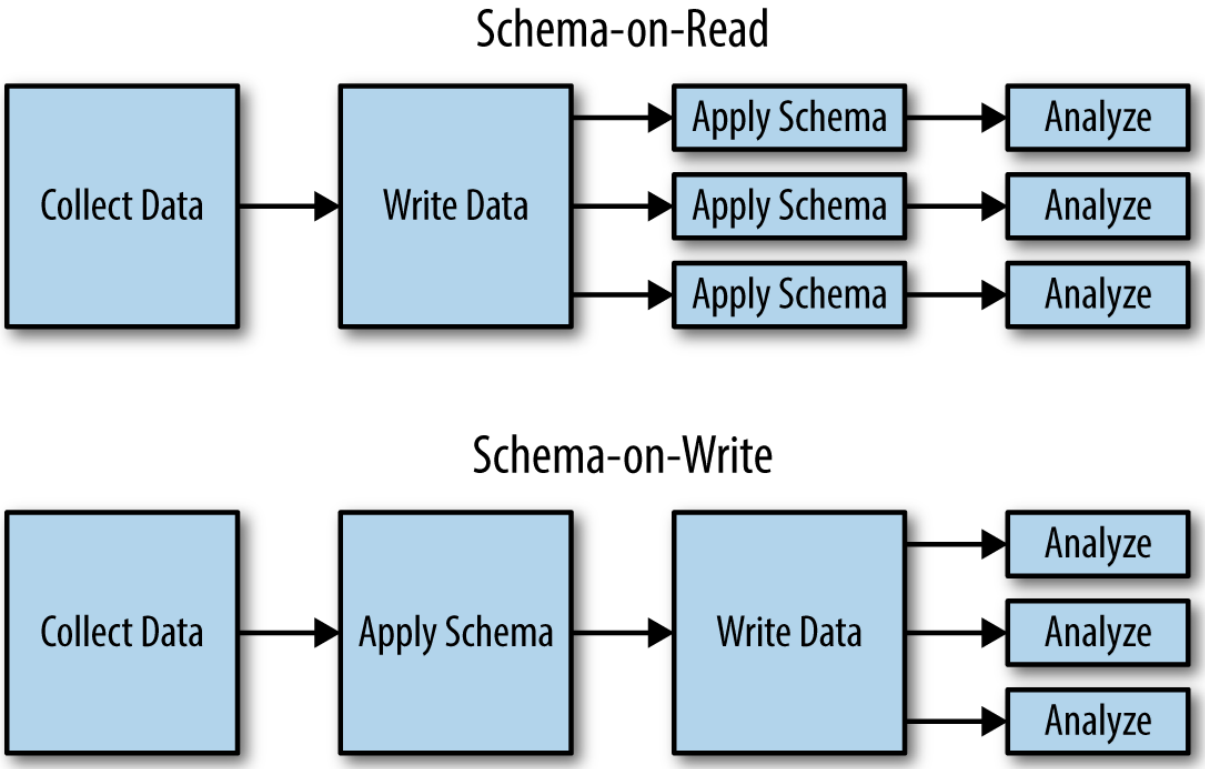
- el **esquema** de la tabla debe declararse **antes de escribir**
- escribir en una tabla implica transformar o adaptar al esquema del dato origen al que define la tabla (**ETL**)
- **Lectura** datos **rápida**.

Schema-on-Read

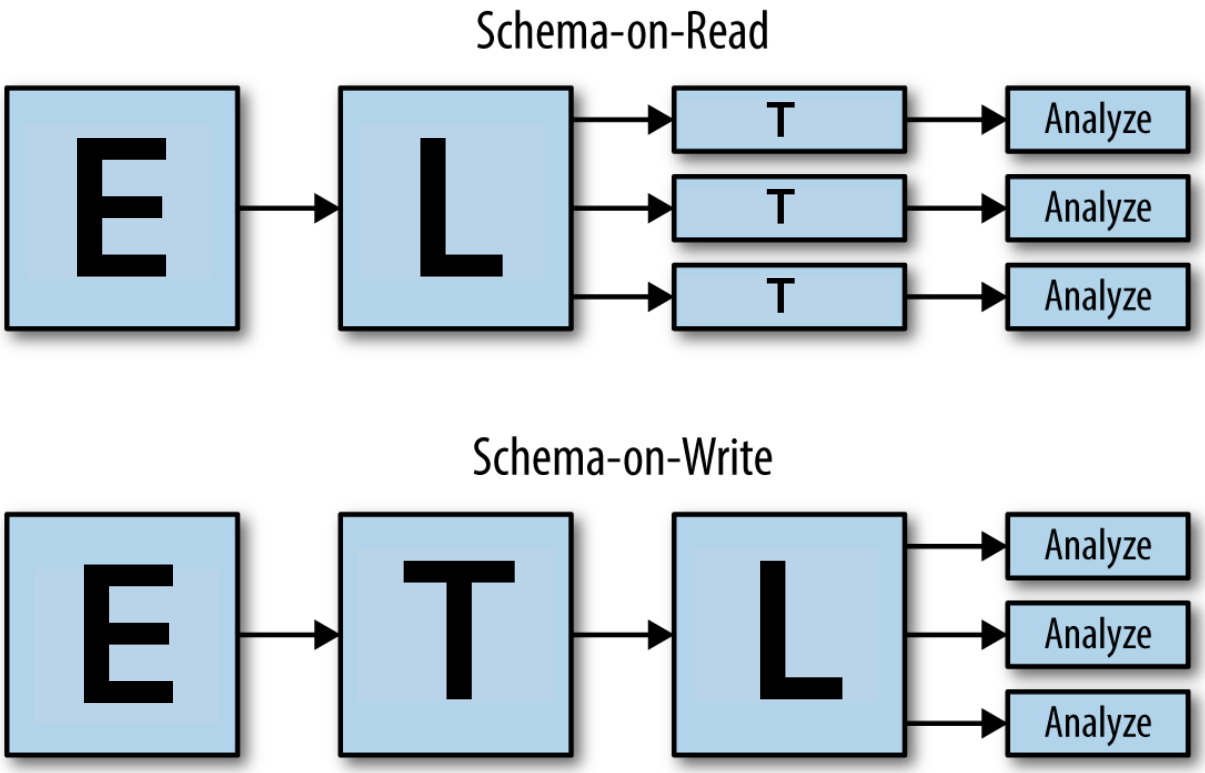
Usado en **Data Lakes** y **Data Lakehouses**

- No requieren de transformación ni de esquema a la hora de escribir (**EL, ELT**)
- El **esquema** se aplica **durante la lectura**
- **Escritura** de datos **rápida**
- Permiten evolución de esquemas

Schema-On-Read VS Schema-On-Write



Schema-On-Read VS Schema-On-Write



6.2

DATA LAKE

Data Lake

Problemas [2008]:

- Data warehouses al límite de capacidad.
- Tecnologías tremendamente caras ya que solo soportan escalado vertical
- Compañías experimentan vendor locking.
- Nuevos formatos de datos no estructurados.

Data Lake

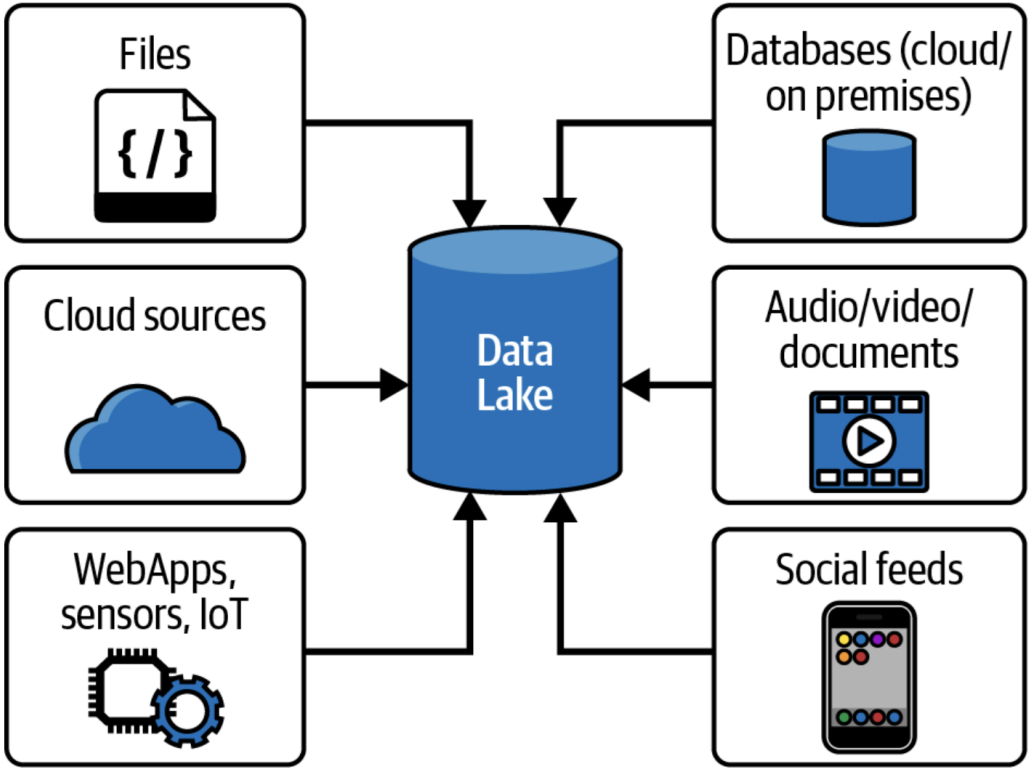
Solución:
Extraer y centralizar los datos en un sistema escalable, sin limitaciones de espacio, estructura o tipología de datos y de almacenamiento barato, nace el **Data Lake**

Ventajas:
No hay limitaciones de almacenamiento
No hay limitaciones de estructura del dato
Soporte a nuevos tipos de analítica avanzada

Data Lake

Los lagos de datos almacenan datos en su formato original (schema-on-read) y suelen utilizar almacenamiento basado en objetos o ficheros, permitiendo flexibilidad en tipos de datos.

Data Lake


Files
{/}
Databases (cloud/ on premises)
Cloud sources
Data Lake
Audio/video/ documents
WebApps, sensors, IoT
Social feeds

Data Lake

Las principales **limitaciones**

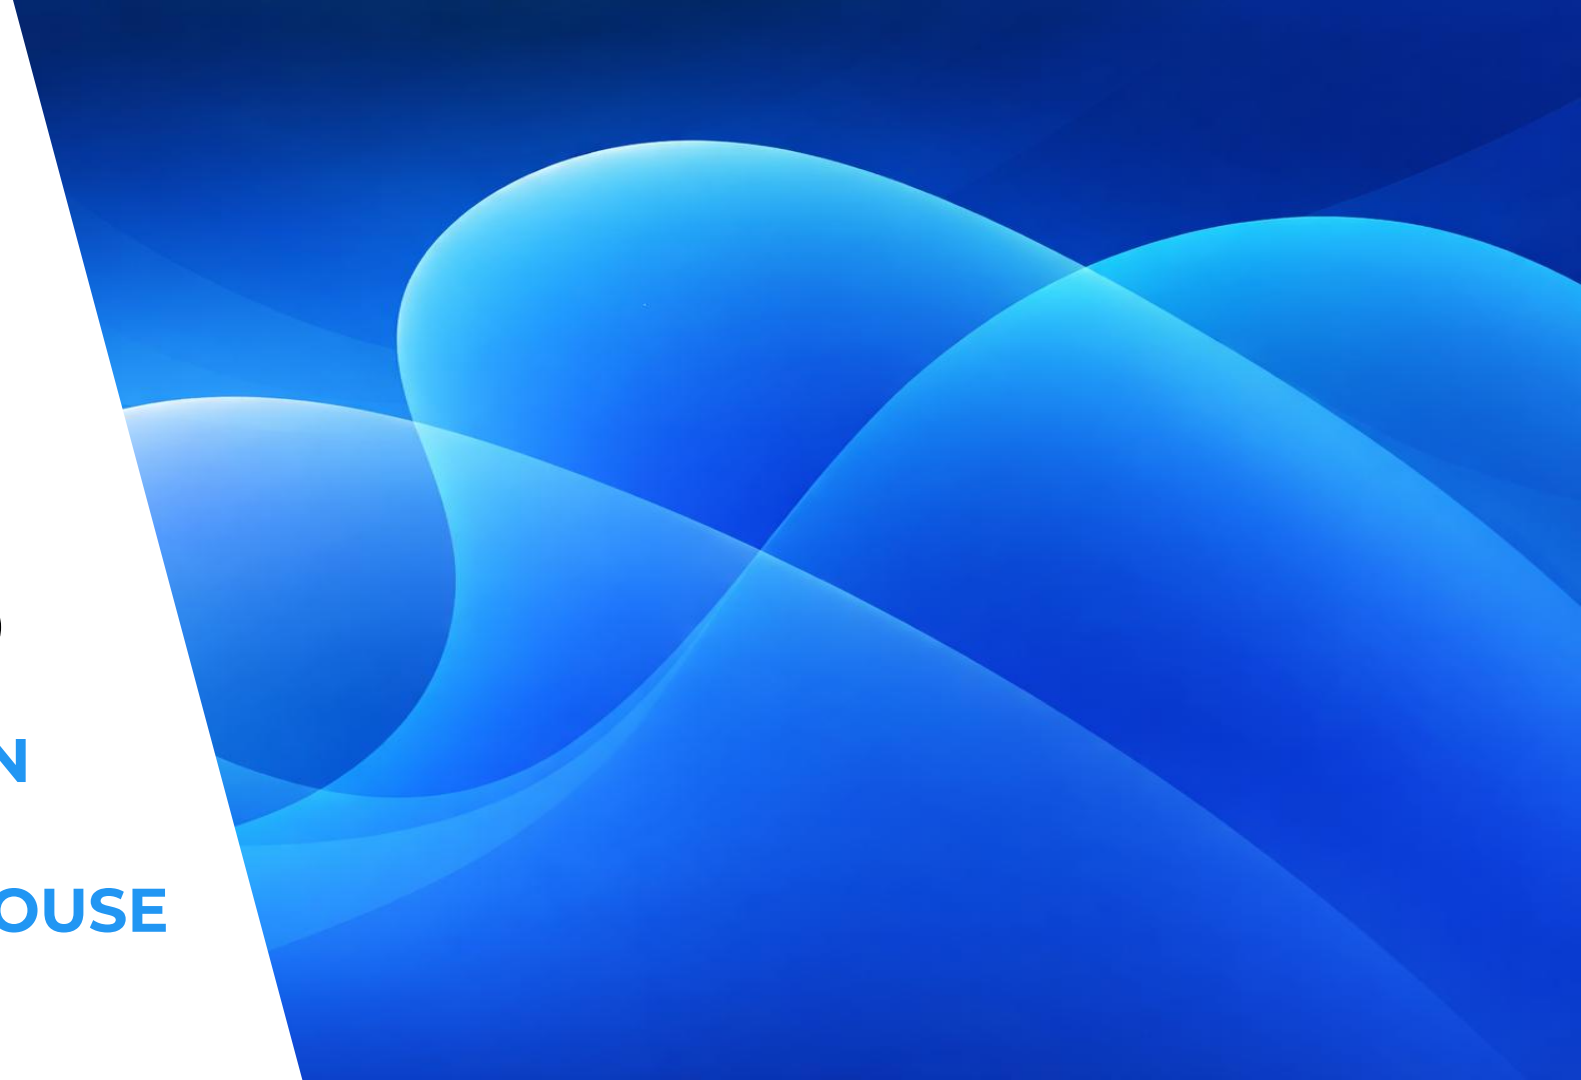
- Falta de transaccionalidad
- Gobierno de datos
- Requieren conocimientos avanzadas
- Consulta de datos lenta

Data Warehouse VS Data Lake

Data Warehouse	vs.	Data Lake
structured, processed	**Data**	structured / semi-structured / unstructured, raw
schema-on-write	**Processing**	schema-on-read
expensive for large data volumes	**Storage**	designed for low-cost storage
less agile, fixed configuration	**Agility**	highly agile, configure and reconfigure as needed
mature	**Security**	maturing
business professionals	**Users**	data scientists et al.
SQL	**Types of Queries**	Multiple types: programmatic access, machine learning, SQL, graph analysis, deep learning, etc.
mature	**Tool Integration**	maturing

6.3

MODERN DATA WAREHOUSE



Modern Data Warehouse

Problemas [2011]:
Aunque más baratos y flexibles, los lagos de datos requieren habilidades avanzadas para consultarlos, y su adopción inicial fracasó en reemplazar DW por completo.

Solución:
El **Modern Data Warehouse** (MDW) combina las ventajas de un DW y un data lake. Permite preparación de datos en el lago y consultas en el DW para seguridad y cumplimiento.

Modern Data Warehouse

Los Data Lakes no reemplazan a los DW sino que los complementan:

- Reducción almacenamiento:
  Permiten archivar datos que ya no son usados (DW offloading)
- Flexibilidad:
  Soportan cualquier tipo de dato o fichero (schema-on-read)
- Capacidad de almacenamiento masiva:
  permiten almacenar dato de granularidad fina en vez de agregada

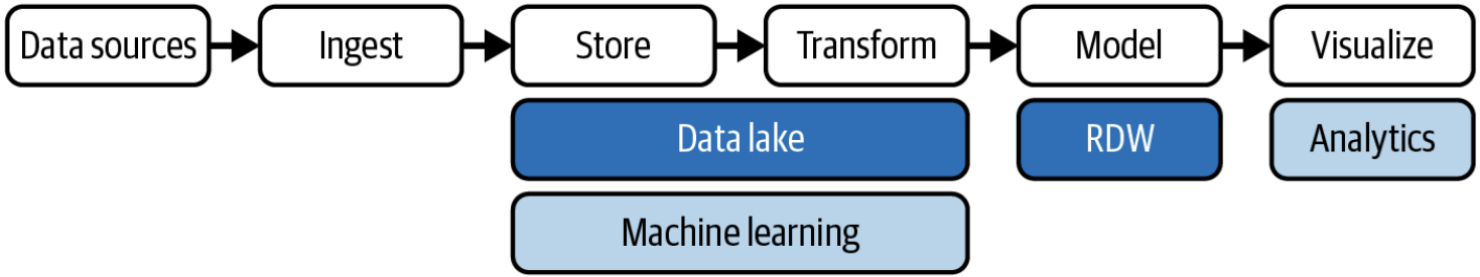
Modern Data Warehouse

Ventajas:

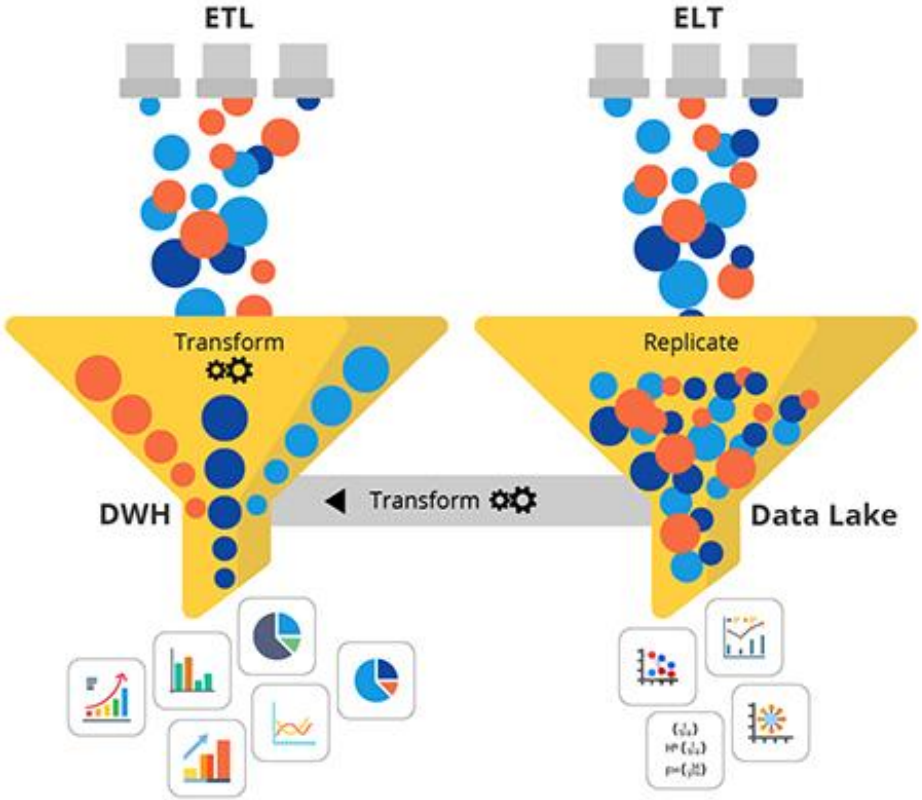
Enfoque "lo mejor de ambos mundos"

- científicos de datos utilizan data lake
- analistas de negocio utilizan el data warehouse

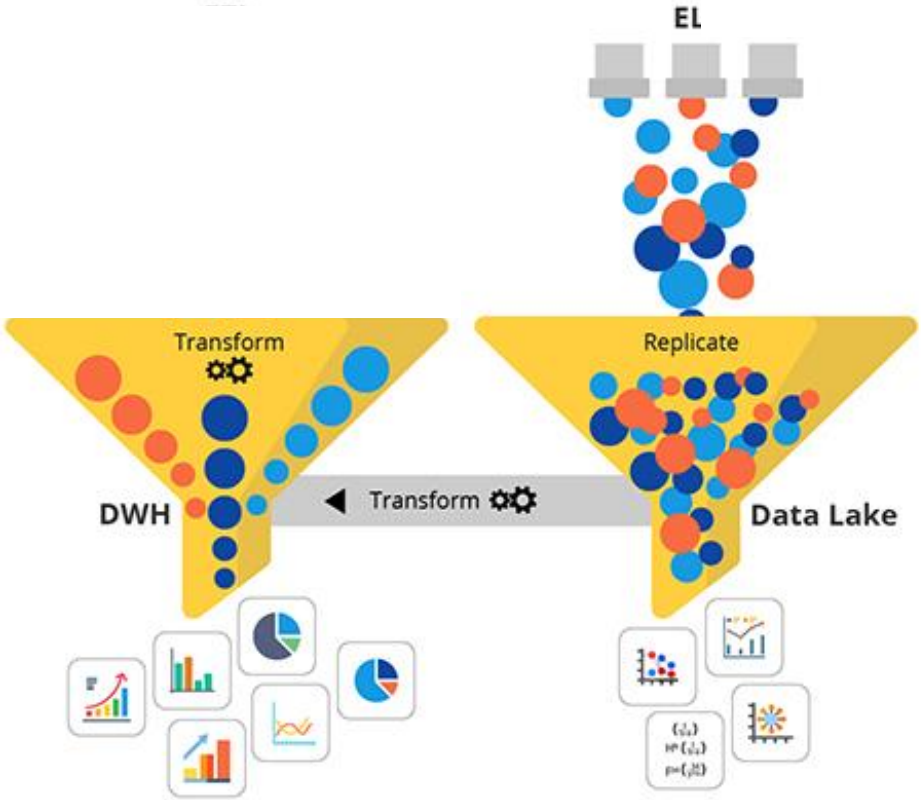
Modern Data Warehouse



Modern Data Warehouse



Modern Data Warehouse



Modern Data Warehouse

Durante 2012-2015 la velocidad de los datos empezó a cobrar inercia, las integraciones y procesamiento de datos en streaming empezó a ser indispensable.

Hubo un par de arquitecturas que se hicieron muy populares por la integración de datos en tiempo real:

Arquitectura **Lambda**

Arquitectura **Kappa**

Arquitectura Lambda

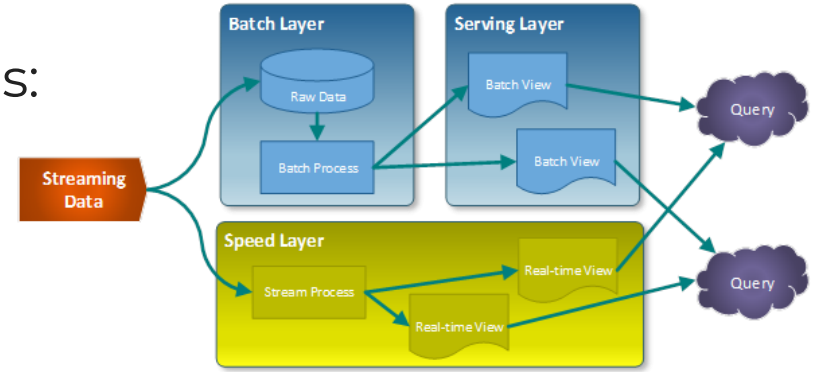
2013-2014

Propuesta por Nathan Marz (Twitter)

Separa los flujos de datos batch y streaming

Compuesta de 3 capas:

- batch layer
- speed layer
- serving layer



Arquitectura Kappa

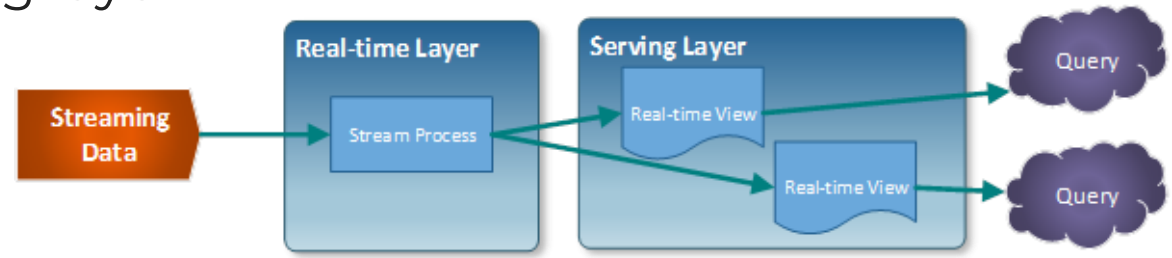
2014-2015

Propuesta por Jay Kreps (Linkedin)

Solo flujos de datos streaming

Compuesta de dos capas:

- Real-time layer
- Serving layer



6.4

DATA FABRIC

Data Fabric

Problemas [2016]:

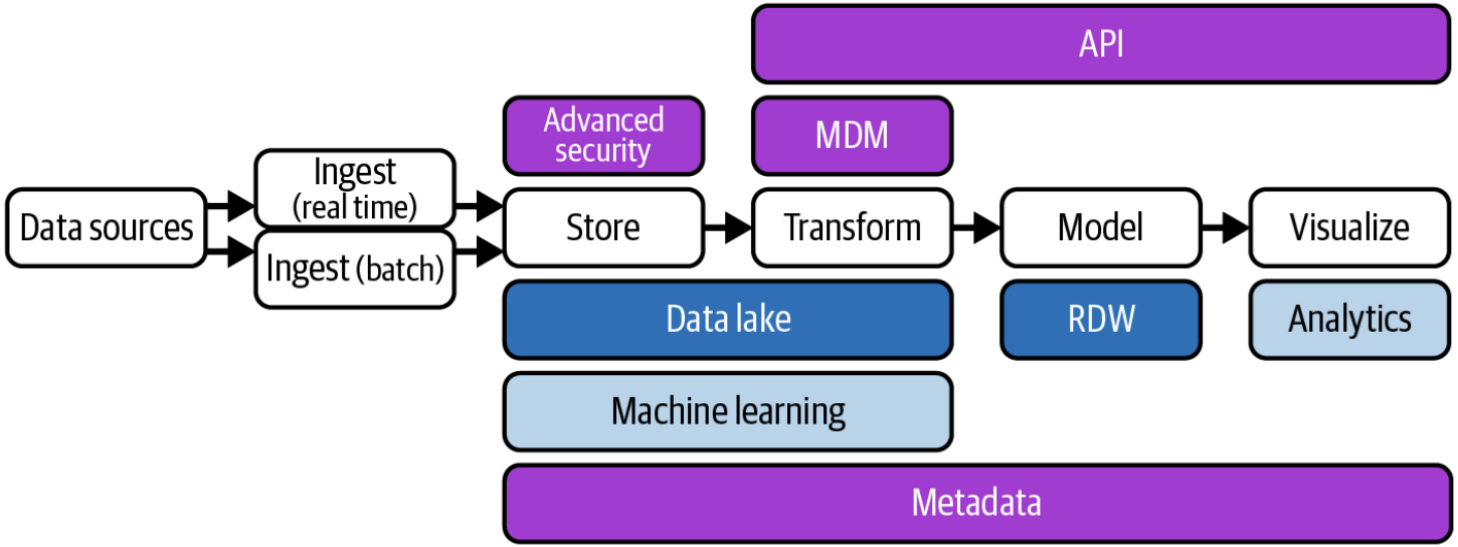
- Disponibilización de datos en tiempo real
- Apificación de datos
- Gestión de datos maestros (MDM)
- Seguridad
- Gobierno
- ...

Data Fabric

Solución:

Data Fabric extiende o aumenta el MDW con tecnologías adicionales para integrar, transformar y securizar datos, creando un arquitectura más completa.

Data Fabric


API
Advanced security
MDM
Ingest (real time)
Data sources
Ingest (batch)
Store
Transform
Model
Visualize
Data lake
RDW
Analytics
Machine learning
Metadata

Data Fabric

Ventajas:

Mejora MDW con más tecnología para:

- ingesta streaming
- MDM
- servicio
- seguridad

6.5

DATA LAKEHOUSE

Data Lakehouse

Problemas [2020]:

- Complejidad de mantenimiento (DW y Data Lake)
- Mayores costes infraestructura (DW y Data Lake)
- Gobierno más complejo (DW y Data Lake)

...

Data Lakehouse

Solución:

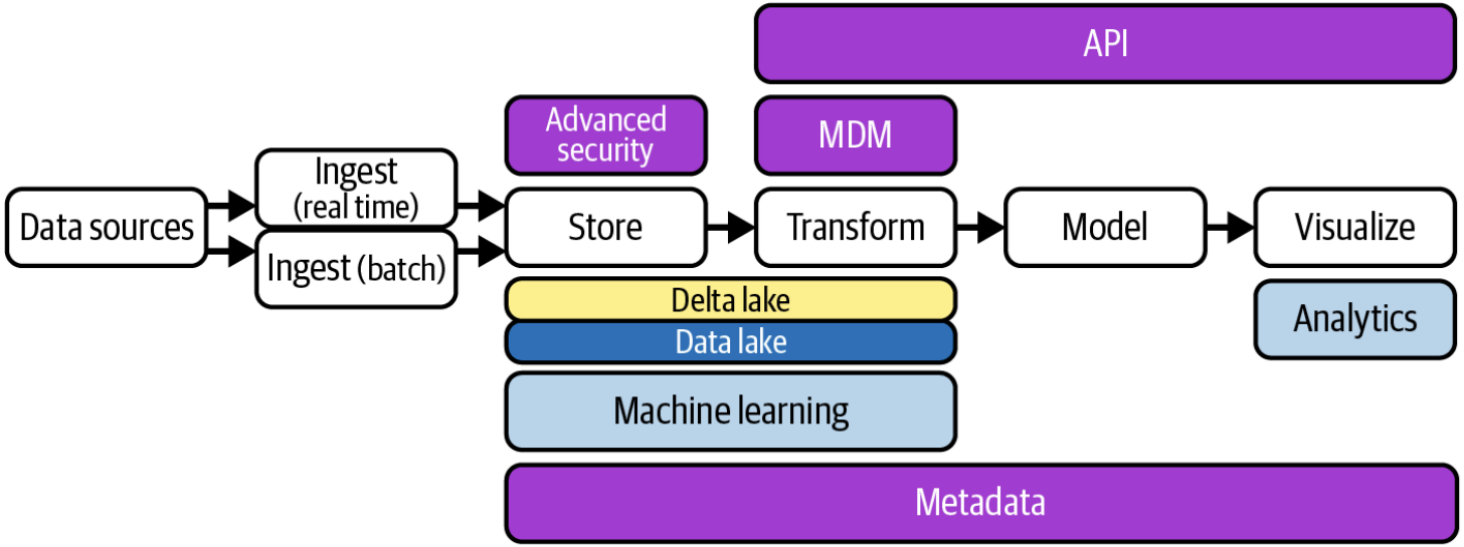
El **Data Lakehouse** integra lago y almacén de datos en un **único repositorio**, usando una capa de software transaccional para mejorar la gestión de datos sin necesidad de un DW.

Usa formatos open table (delta, iceberg, hudi) sobre un lago de datos para imitar las características de la base de datos relacionales.

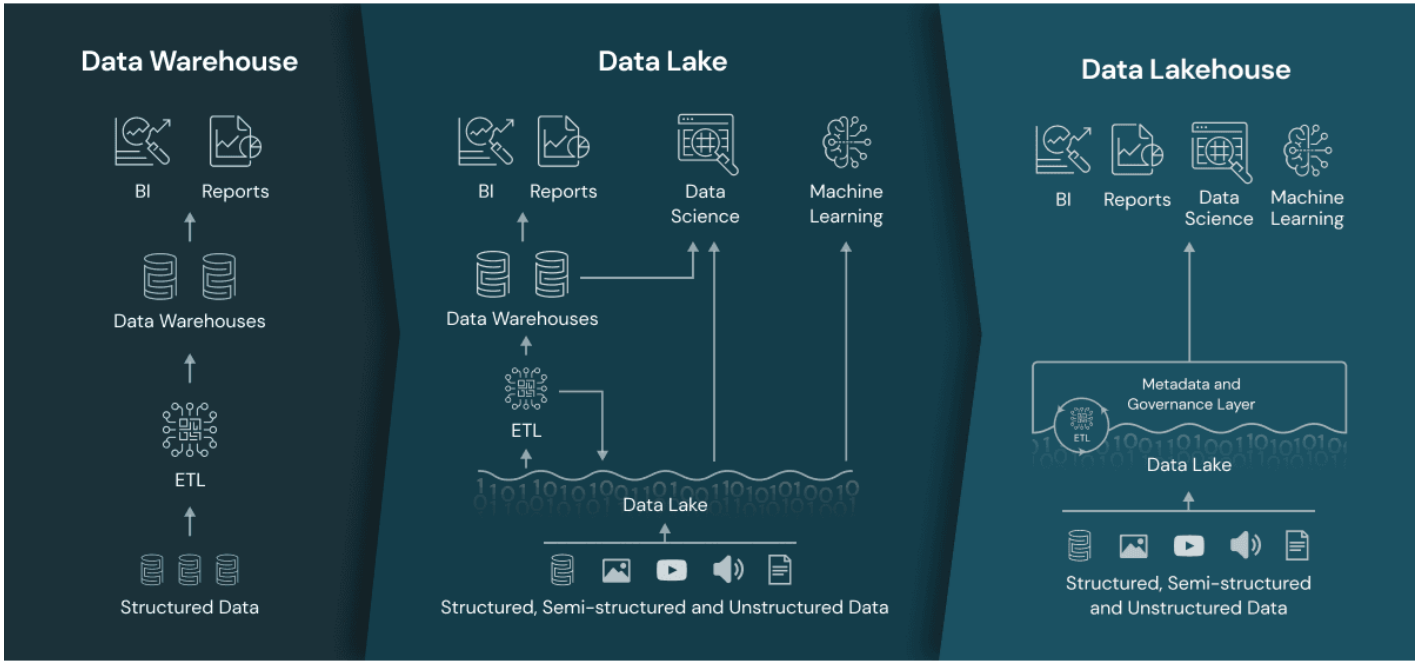
Propuesta por Databricks



Data Lakehouse



Data Lakehouse



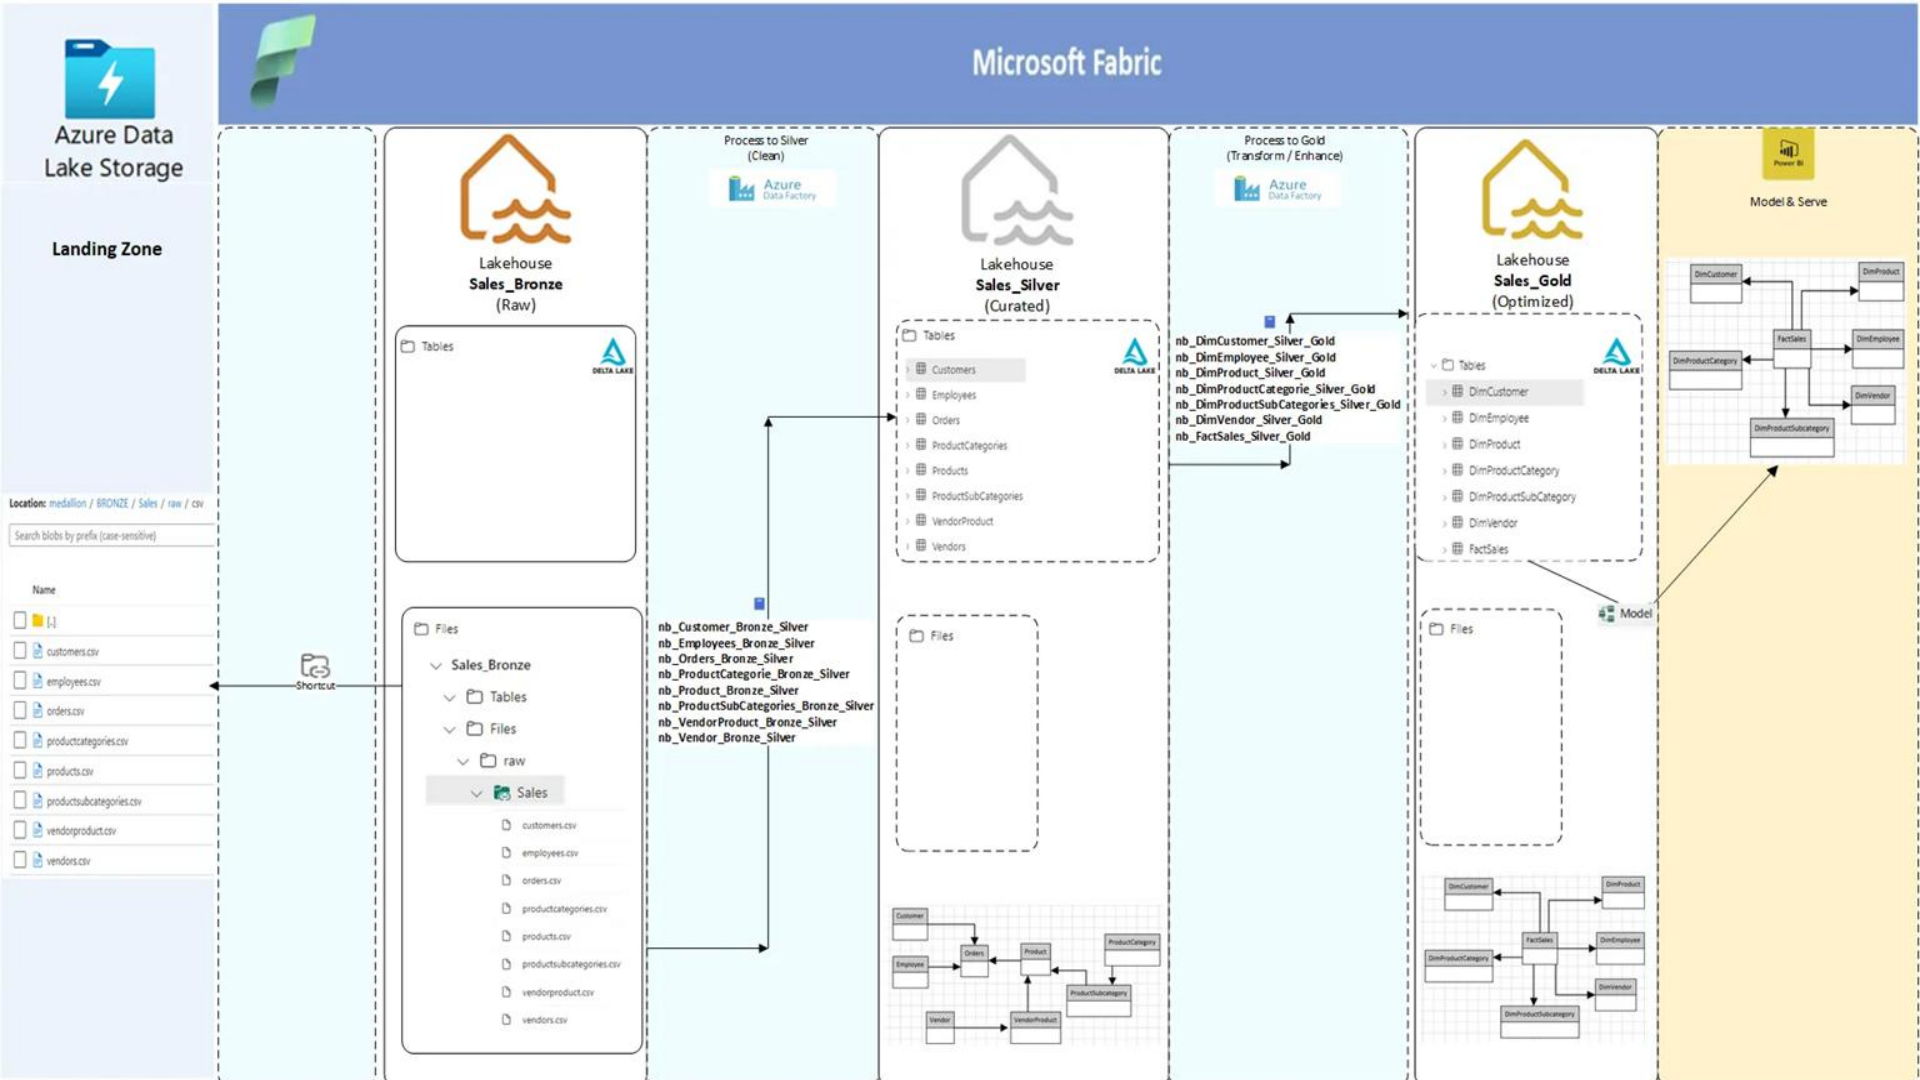
Data Lakehouse

Emerge un nuevo patrón de diseño para organizar los datos lógicamente en el data lakehouse conocido como

Medallion Architecture

Su objetivo es mejorar de forma incremental y progresiva la estructura y la calidad de los datos a medida que se promocionan a través de cada capa de la arquitectura

Bronze ⇒ Silver ⇒ Gold


Azure Data Lake Storage
Landing Zone
Microsoft Fabric
Process to Silver (Clean)
Azure Data Factory
Process to Gold (Transform / Enhance)
Azure Data Factory
Model & Serve
Lakehouse Sales_Bronze (Raw)
Lakehouse Sales_Silver (Curated)
Lakehouse Sales_Gold (Optimized)
Location: medallion / BRONZE / Sales / raw / csv
Search blobs by prefix (case-sensitive)
Name
customers.csv
employees.csv
orders.csv
productcategories.csv
products.csv
productsubcategories.csv
vendorproduct.csv
vendors.csv
Shortcut
Tables
Files
Sales_Bronze
Tables
Files
raw
Sales
customers.csv
employees.csv
orders.csv
productcategories.csv
products.csv
productsubcategories.csv
vendorproduct.csv
vendors.csv
nb_Customer_Bronze_Silver
nb_Employees_Bronze_Silver
nb_Orders_Bronze_Silver
nb_ProductCategorie_Bronze_Silver
nb_Product_Bronze_Silver
nb_ProductSubCategories_Bronze_Silver
nb_VendorProduct_Bronze_Silver
nb_Vendor_Bronze_Silver
Tables
Customers
Employees
Orders
ProductCategories
Products
ProductSubCategories
VendorProduct
Vendors
Files
nb_DimCustomer_Silver_Gold
nb_DimEmployee_Silver_Gold
nb_DimProduct_Silver_Gold
nb_DimProductCategorie_Silver_Gold
nb_DimProductSubCategories_Silver_Gold
nb_DimVendor_Silver_Gold
nb_FactSales_Silver_Gold
Tables
DimCustomer
DimEmployee
DimProduct
DimProductCategory
DimProductSubCategory
DimVendor
FactSales
Files
Model

6.6

DATA MESH

Data Mesh

Problemas [2020]:

- Arquitecturas **monolíticas** y **centralizadas**
- Equipos de ingeniería de datos centralizado se convierten en **cuello de botella** de la empresa

Data Mesh

Solución:

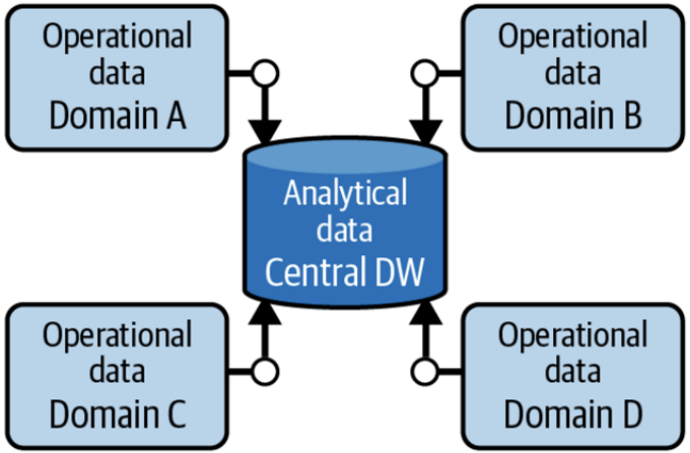
Data mesh descentraliza los datos, asignando a cada dominio de la empresa la responsabilidad de sus datos y permitiendo un escalado de personas e infraestructura.

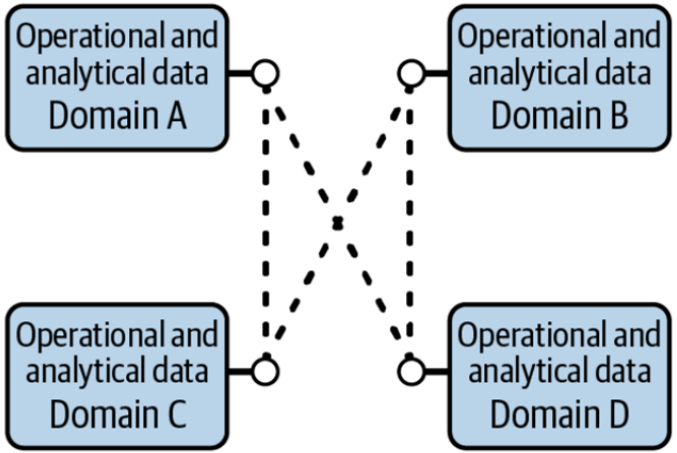
Es un **arquitectura organizativa** más que técnica. Data mesh no propone ningún stack tecnológico concreto.

Propuesta por Zhamak Dehghani

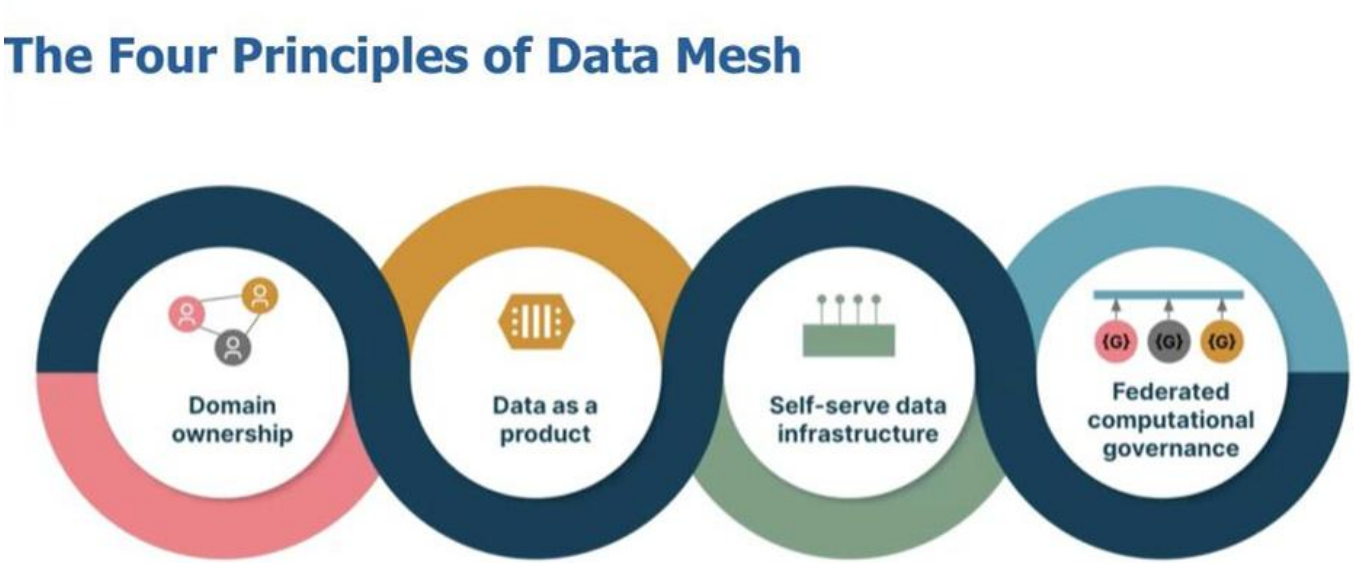
/thoughtworks

Data Mesh


Operational data Domain A
Operational data Domain B
Analytical data Central DW
Operational data Domain C
Operational data Domain D


Operational and analytical data Domain A
Operational and analytical data Domain B
Operational and analytical data Domain C
Operational and analytical data Domain D

Data Mesh



© 2021 Thoughtworks | Confidential

Data Mesh

Ventajas:

- Equipos de datos descentralizados
- Infraestructura de datos self-service
- Gobierno de datos federado
- Responsabilidad por dominio

6.7

RESUMEN

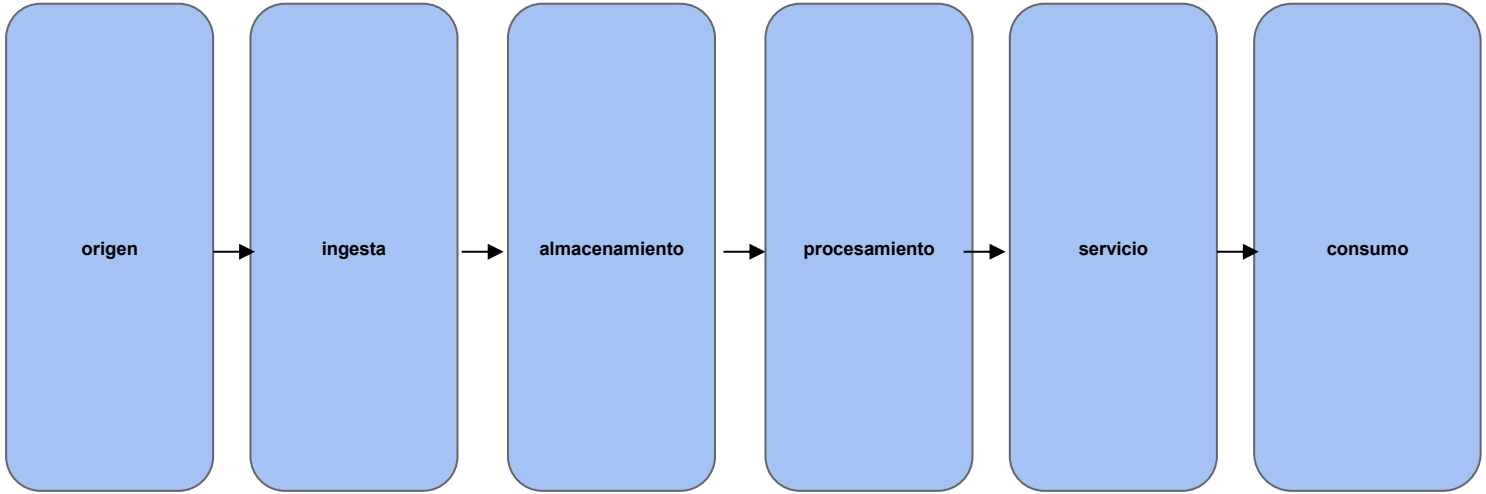
Characteristic	Relational data warehouse	Data lake	Modern data warehouse	Data fabric	Data lakehouse	Data mesh
Year introduced	1984	2010	2011	2016	2020	2019
Centralized/decentralized	Centralized	Centralized	Centralized	Centralized	Centralized	Decentralize
Storage type	Relational	Object	Relational and object	Relational and object	Object	Domain-specific
Schema type	Schema-on-write	Schema-on-read	Schema-on-read and schema-on-write	Schema-on-read and schema-on-write	Schema-on-read	Domain-specific
Data security	High	Low to medium	Medium to high	High	Medium	Domain-specific
Data latency	Low	High	Low to high	Low to high	Medium to high	Domain-specific
Time to value	Medium	Low	Low	Low	Low	High
Total cost of solution	High	Low	Medium	Medium to high	Low to medium	High
Supported use cases	Low	Low to medium	Medium	Medium to high	High	High
Difficulty of development	Low	Medium	Medium	Medium	Medium to high	High
Maturity of technology	High	Medium	Medium to high	Medium to high	Medium to high	Low
Company skill set needed	Low	Low to medium	Medium	Medium to high	Medium to high	High

7.

ESTRUCTURA

Estructura

Una arquitectura de datos puede generalizarse es las siguientes capas :



Estructura

Capa fuentes de datos (data sources)
Consiste en todos los sistemas que almacenan o producen datos.

Capa de ingesta (data ingestion)
Consiste en distintas tecnologías que nos permiten extraer y capturar el dato para transportarlo a la capa de almacenamiento.

Estructura

Capa de almacenamiento (data storage)
Esta capa consiste de las tecnologías que permiten centralizar y almacenar los datos para su posterior consumo o análisis.

Capa de procesamiento (data processing)
Consiste de las distintas tecnologías para transformar los datos en información.

Estructura

Capa de servicio (data serving)
Consiste en distintas tecnologías para disponibilizar los resultados del procesamiento para su consumo.

Capa de consumo (data consumption)
Es la capa final en la que los distintos usuarios y servicios pueden consumir los datos acorde a sus necesidades específicas.

Estructura

El dato viaja de izquierda a derecha, desde su origen hasta que es consumido.

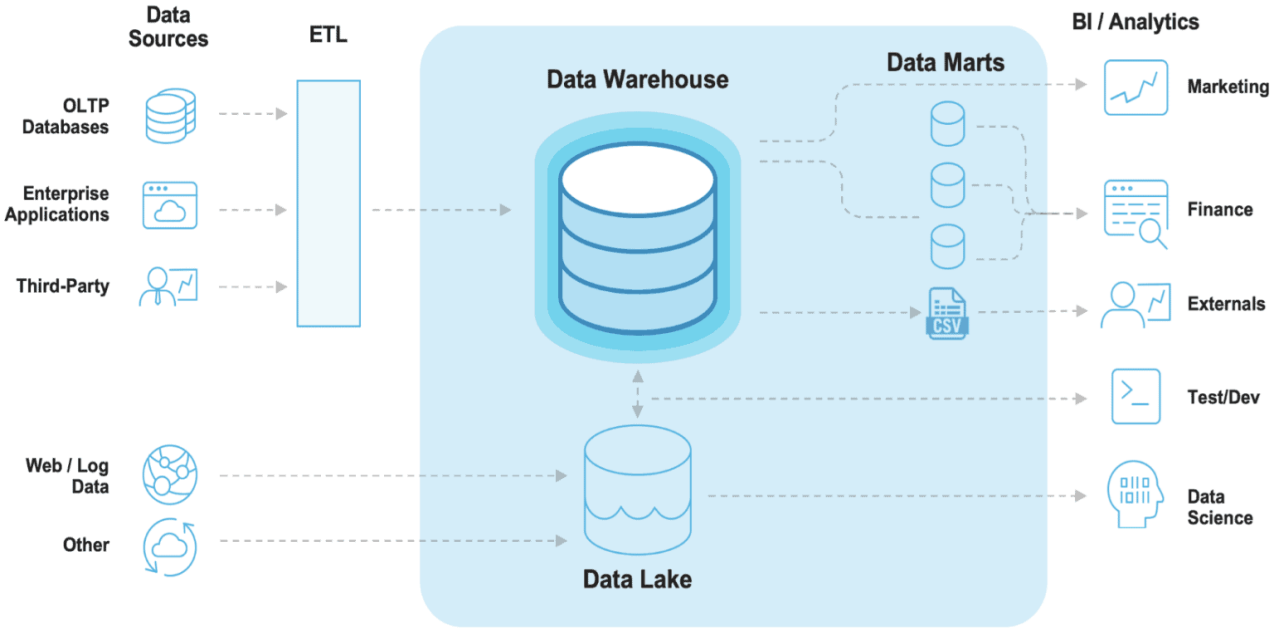
No siempre será necesario transicionar el dato por todas estas capas, por ejemplo en casos de uso en tiempo real o NRT (Near Real Time).

Hay arquitecturas en las que no existe alguna de estas capas, normalmente porque está fusionada con otra o porque se usa otra terminología.

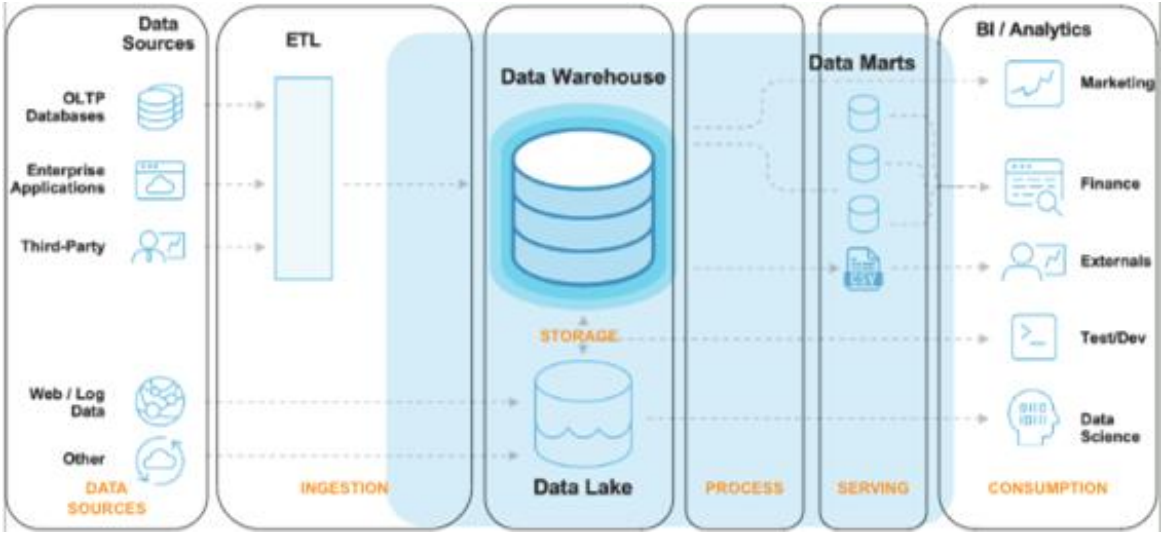
Estructura

Cada una de estas capas hace uso de tecnologías y procesos específicos.
Hay veces en que **una misma tecnología participa en distintas capas con distintos roles**, por ejemplo, podremos tener un una base datos SQL como una fuente de datos y también podrá utilizarse para servir datos.

Estructura


Data Sources
ETL
BI / Analytics
Data Warehouse
Data Marts
OLTP Databases
Enterprise Applications
Third-Party
Marketing
Finance
Externals
CSV
Test/Dev
Web / Log Data
Other
Data Science
Data Lake

Estructura


Data Sources
OLTP Databases
Enterprise Applications
Third-Party
Web / Log Data
Other
DATA SOURCES
ETL
INGESTION
Data Warehouse
STORAGE
Data Lake
PROCESS
Data Marts
SERVING
BI / Analytics
Marketing
Finance
Externals
Test/Dev
Data Science
CONSUMPTION

Estructura


sources
ingestion
storage
processing
serving
SQL Database
Flat files
Unstructured
Social
Web & app logs
IOT devices
...