ntic master
revolucionamos la comunicación

TECNOLOGÍAS DEL BIG DATA

TECNOLOGÍAS DE INGESTA

Agenda

- Capa de orígenes de datos
  - Definición
  - Tipos

- Capa de ingesta
  - Definición
  - Importancia
  - Desafíos
  - Modos integración
  - Tipos
  - Ecosistema

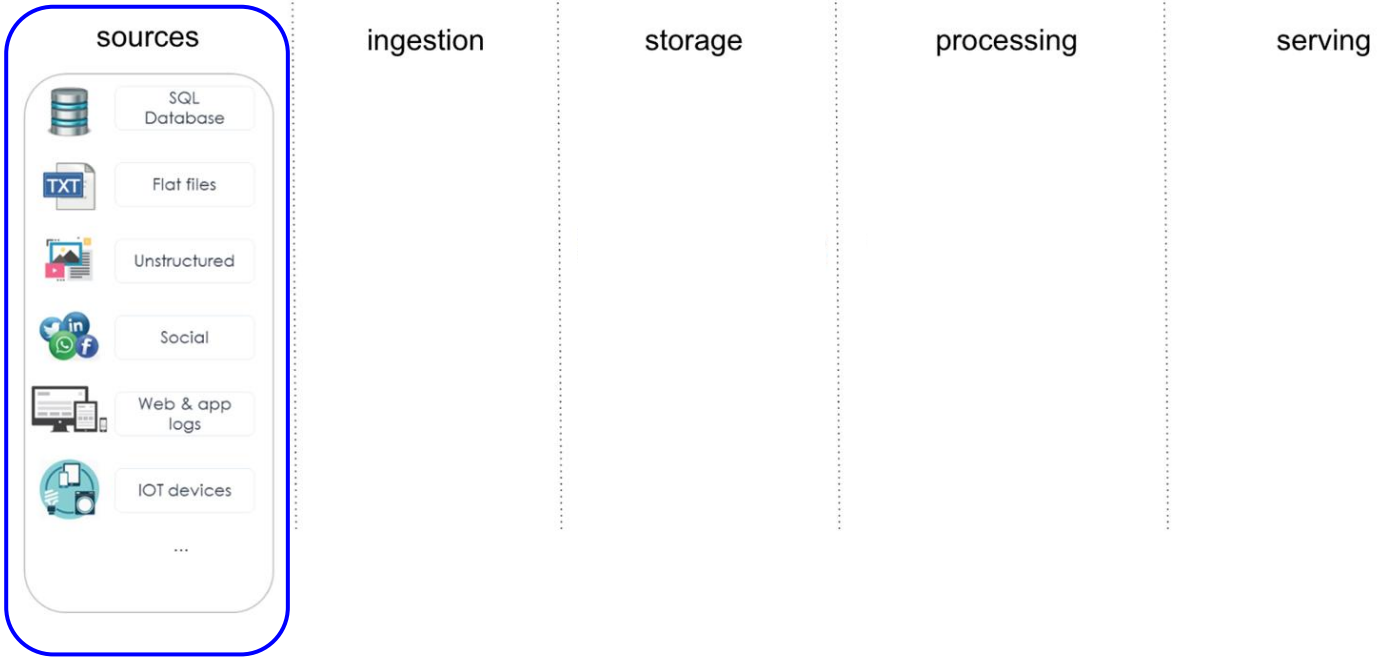
1.

CAPA DE ORÍGENES DE DATOS

1.1

DEFINICIÓN

Orígenes de Datos



Orígenes de datos

En toda empresa, los datos o **se están creando o ya están almacenados** en algún sistema.

Estos sistemas se denominan **orígenes o fuentes de datos**.

1.2

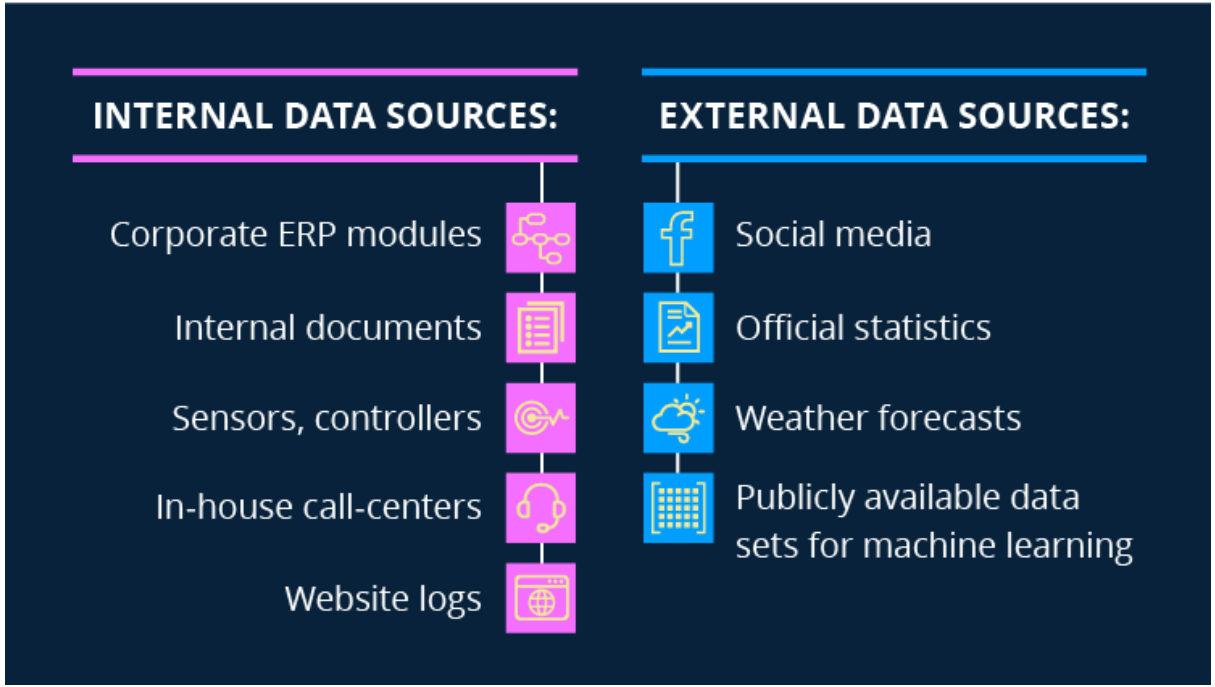
TIPOS

Tipos Orígenes de Datos

Dos categorías:

- externos vs internos
- batch vs streaming

Tipos Orígenes de Datos



Orígenes de Datos Batch

Dato en reposo (data at rest) se refiere a datos que ya están almacenados en algún tipo de almacenamiento persistente **almacenados en algún tipo de almacenamiento persistente**

Al estar ya almacenados, podemos extraerlos en lotes (batches) y **almacenarlos en ficheros**

ejemplo: datos en ficheros o bases de datos

Orígenes de Datos Batch



Bases de datos



ficheros

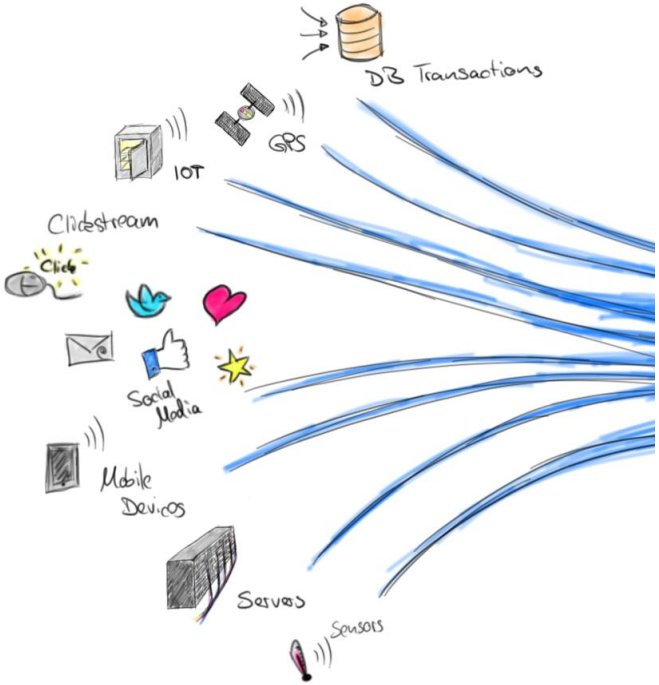
Orígenes de Datos Streaming

Dato en movimiento (data in motion), se refiere al dato en vuelo que está siendo **transportado entre dos puntos**.

Los datos en streaming consisten en un **flujo constante de eventos** / mensajes / registros

ejemplo: redes sociales, clickstreams , IoT

Orígenes de Datos Streaming



Orígenes de Datos

Esta clasificación es importante, ya que al tener el **dato** ya **almacenado en** un **origen batch siempre podremos volver a** él para **recuperarlo**

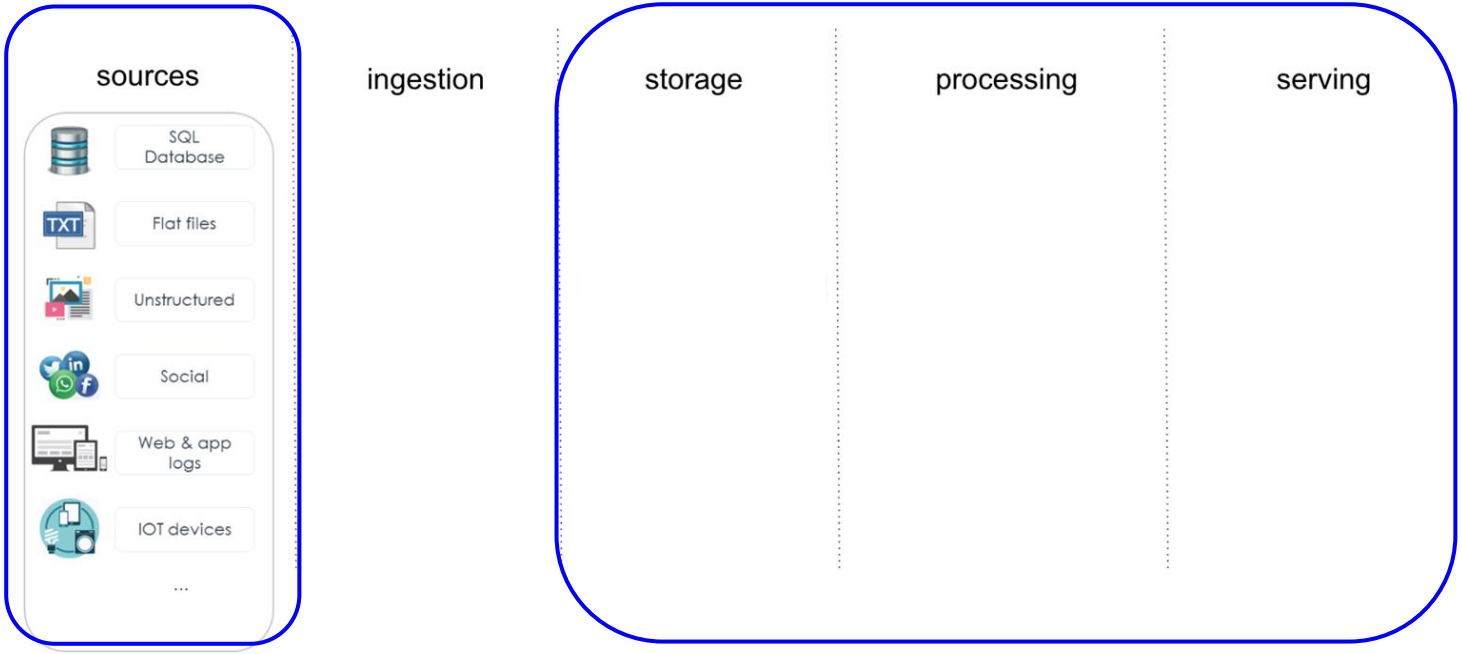
Esto no es posible en la mayoría de los casos de un **origen streaming**, en el que tenemos que capturar el dato según se produce con el consiguiente **riesgo de pérdida**.

Orígenes de Datos

Como ya explicamos, la mayoría de las veces, **los orígenes de datos** viven **en plano operacional** y **están aislados o alejados de los sistemas del plano analítico**.

Esta separación requiere por tanto, un transporte desde los sistemas origen hasta la plataforma de datos. Este movimiento de datos es el cometido de la capa de ingesta de datos.

Orígenes de Datos



plano operacional

plano informacional

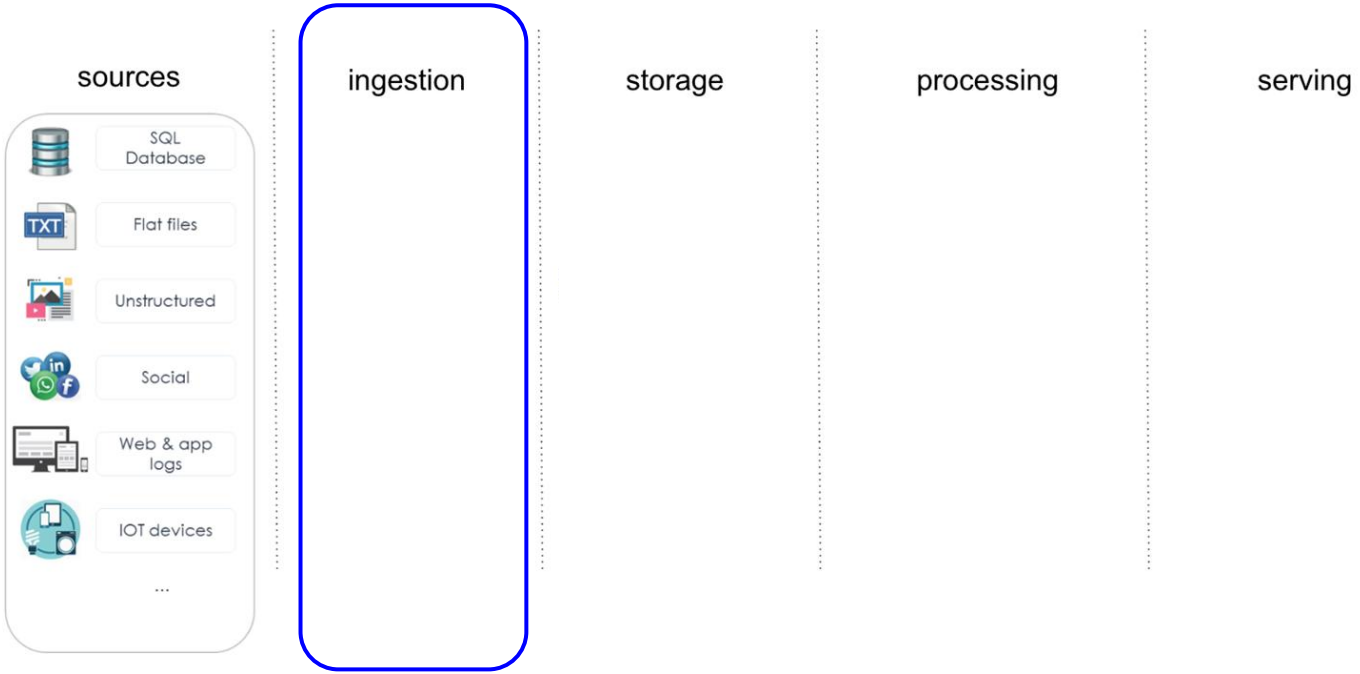
2.

CAPA DE INGESTA

2.1

DEFINICIÓN

Ingesta de Datos



Ingesta de Datos

Ingesta de datos trata sobre la **extracción y captura** de los datos desde sus orígenes y su **transporte** hasta un almacenamiento centralizado.

La forma en que los datos se integran en la arquitectura tiene un impacto significativo en la calidad y su utilidad.

Ingesta de Datos

Esta capa tiene como objetivo **integrar los datos en la capa de almacenamiento** que centraliza los datos (data warehouse, data lake, data lakehouse) y **se compone** de **procesos y tecnologías** que facilitan la integración de datos de distinta naturaleza (tipología de fuente de datos y formato).

2.2

IMPORTANCIA

Importancia

La capa de ingesta es la puerta de entrada de los datos en una arquitectura. Su importancia radica en su capacidad para:

- **Integrar orígenes diversos**
- **Garantizar la calidad de los datos**
- **Escalabilidad y rendimiento**

Importancia

Integrar orígenes diversos

Las empresas manejan una amplia variedad de datos, desde registros de servidores (logs) hasta fuentes de datos en tiempo real.

La capa de ingesta debe ser capaz de recopilar datos desde todas estas fuentes y hacerlos disponibles para su procesamiento.

Importancia

Garantizar la calidad de los datos

Es fundamental que los datos integrados sean precisos y completos. La capa de ingesta debe incluir mecanismos para verificar la integridad de los datos, asegurando que los datos sean confiables y estén listos para su uso. Es especialmente importante tener garantías que permitan no perder ni alterar los datos durante la ingesta.

Importancia

Escalabilidad y rendimiento

Las empresas actualmente manejan grandes volúmenes de datos y, a menudo, experimentan un crecimiento continuo. La capa de ingesta debe ser escalable para manejar la carga de trabajo actual y futura, sin comprometer el rendimiento.

2.3

DESAFÍOS

Desafíos

La ingesta de datos presenta desafíos significativos, que incluyen:

- **Volumen y velocidad**
- **Sincronización de datos**
- **Tolerancia fallos**
- **Seguridad y privacidad**

Desafíos

Volumen y velocidad

La gestión de grandes volúmenes de datos en tiempo real puede ser abrumadora. La capa de ingesta debe estar preparada para manejar la alta velocidad y el volumen de datos generados.

Desafíos

Sincronización de datos

En escenarios de ingestión en tiempo real, la sincronización de datos entre diversas fuentes puede ser compleja.

Asegurar que los datos lleguen en el orden correcto y se almacenen adecuadamente es un desafío importante.

Desafíos

Tolerancia a fallos

La capa de ingesta debe ser resistente a fallos. La pérdida de datos o la interrupción del proceso de ingestión pueden ser costosas y perjudiciales para las organizaciones.

Desafíos

Seguridad y Privacidad

La seguridad de los datos es crítica en la ingestión de datos. Garantizar que los datos estén protegidos y cumplan con las regulaciones de privacidad es esencial.

2.4

MODOS INTEGRACIÓN

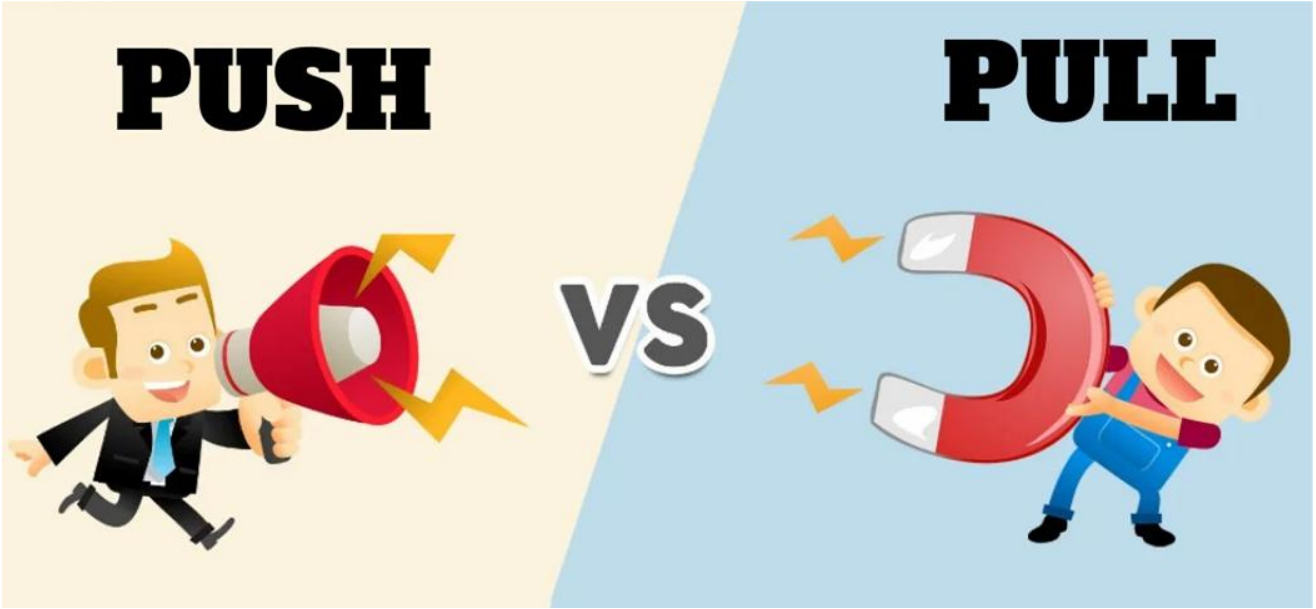
Modos de Integración

Hay dos enfoques fundamentales en función de qué parte es responsable de la integración de los datos:

Modelo Pull: los servicios de ingesta son responsables de capturar o extraer los datos directamente de las fuentes.

Modelo Push: la fuente de datos es responsable de enviar los datos hacia los servicios de ingesta.

Modos de Integración



2.4.1

MODO PULL

Modelo PULL

El modelo pull es el **método tradicional** de adquisición de datos.

En este modelo, un servicio ejecuta el proceso de extracción desde la fuente.

En general, se trata de un trabajo batch programado que se ejecuta en intervalos de tiempo (horario, diario, semanal, mensual).

Modelo PULL

Este enfoque tiene varios inconvenientes:

- **Conciencia de la integración**
- **Acceso a la fuente de datos**
- **Acoplamiento del modelo de datos**
- **Impacto operacional**

Modelo PULL

Conciencia de la integración

A menudo los propietarios de las fuentes de datos no son conscientes de que existen servicios que extraen datos de sus sistemas.

Modelo PULL

Acceso a la fuente de datos

Los servicios de ingesta necesitan acceder a las fuentes de datos de origen y por lo tanto requieren de usuarios específicos y perfilados de seguridad. Cuando el número de fuentes es muy grande complica enormemente la gestión de los mismos.

Modelo PULL

Acoplamiento del modelo de datos

Los servicios de ingesta quedan acoplados al modelo de datos físico subyacente y limitan la evolución del sistema fuente, ya que cualquier cambio en la estructura romperá la integración de los datos.

Modelo PULL

Impacto operacional

Los servicios de ingesta impactan en el rendimiento de las fuentes poniendo en riesgo la continuidad del negocio.

2.4.2

MODO
PUSH



Modelo PUSH

El modelo push es el **método moderno** de integración de datos.

En este modelo, la propia fuente o sistema productor de datos define un contrato o api de datos y es responsable de empujar los datos hacia la capa de ingesta.

Modelo PUSH

Conciencia de la integración

Los productores de datos son conscientes y responsables de qué datos están publicando y pueden decidir la mejor manera y momento para integrarlos.

Modelo PUSH

Acceso a la fuente de datos

Los servicios de ingesta no necesitan acceder a las fuentes de datos de origen.

Modelo PUSH

Acoplamiento del modelo de datos

Los productores de datos proporcionarán un contrato de datos que abstrae y desacopla su modelo de datos físicos de persistencia subyacente.

Modelo PUSH

Impacto operacional

El impacto en el sistema origen es mucho menor ya que es la propia fuente la que decide la forma y el momento en el que los datos deben emitirse.

2.5

TIPOS DE INGESTA

Tipos de Ingesta

Hay dos formas principales de realizar la ingesta de datos según el volumen o la velocidad de los datos a integrar directamente relacionados con los modelos de integración del punto anterior:

- **Ingesta batch** (por lotes)
- **Ingesta streaming** (en tiempo real)

Ingesta Batch (por lotes)

La ingesta por lotes implica la recopilación y el procesamiento de datos en grupos o lotes, en forma de intercambio de ficheros.

Los datos se acumulan durante un período de tiempo y se procesan de una sola vez. Esto es adecuado para aplicaciones que no requieren resultados en tiempo real, como informes horarios, diarios o semanales.

Ingesta Batch (por lotes)

Unidad de integración:

fichero

Latencia:

según el intervalo programado (minutos, horas).

Tamaño de datos:

no hay límites en el número de registros, ni en el tamaño ni en el formato de los datos.

Ingesta Streaming (tiempo real)

La ingesta en streaming implica la captura, recopilación y el procesamiento de datos a medida que se generan en los orígenes.

Es esencial para aplicaciones que requieren análisis en tiempo real, como la monitorización de sensores, la detección de fraudes y la optimización de la experiencia del usuario en sitios web.

Ingesta Streaming (tiempo real)

Unidad de integración:

registro o evento.

Latencia:

mínima, integración en tiempo casi real (NRT).

Tamaño de datos:

tamaño máximo de registro de datos en torno a 1 MB.

2.6

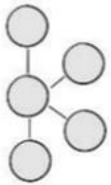
ECOSISTEMA

2.6.1

OPEN SOURCE

Tecnologías Open Source





Kafka Connect

APACHE nifi

Tecnologías Cloud



Azure IoT Hubs



Amazon IoT





Azure Data Factory



AWS Glue





Azure Event Hubs





Microsoft Azure

aws

Google Cloud

Otras Tecnologías









