ntic master
revolucionamos la comunicación

TECNOLOGÍAS DEL BIG DATA

TECNOLOGÍAS DE ALMACENAMIENTO



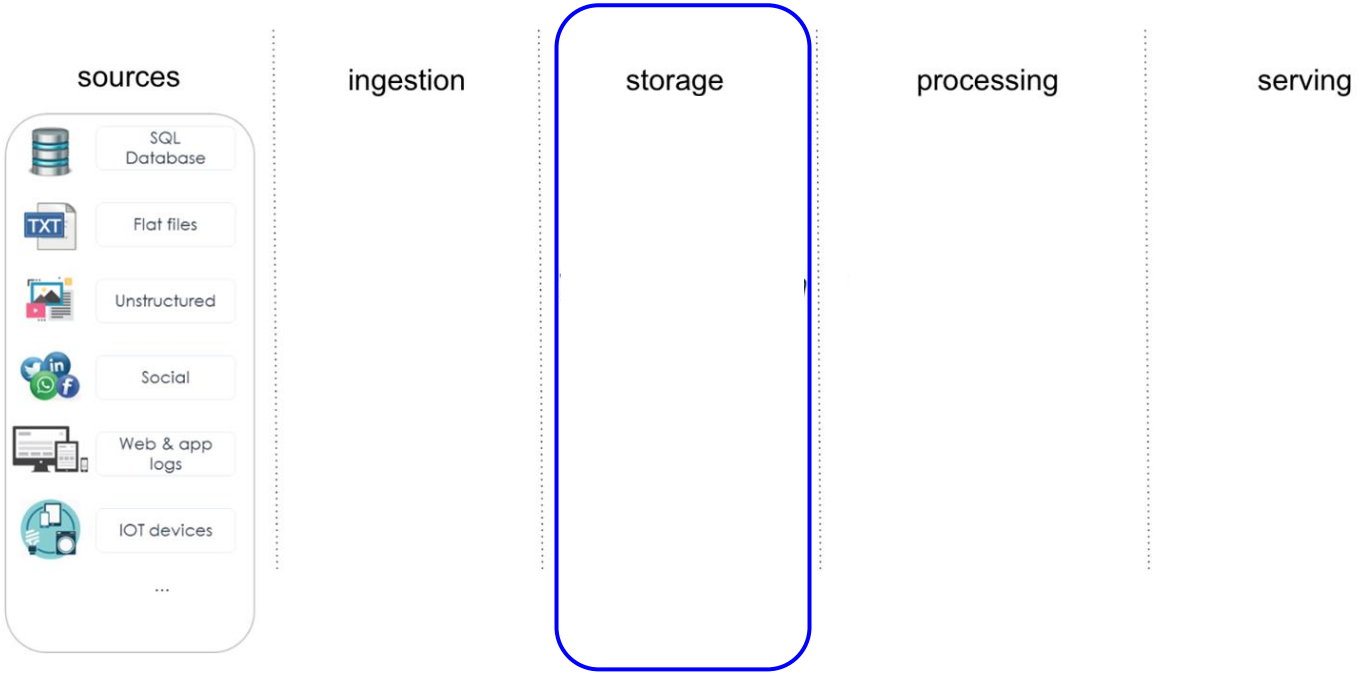
Agenda

- Definición
- Almacenamiento Batch
- Almacenamiento Streaming

1.

DEFINICIÓN

Almacenamiento de Datos



Almacenamiento de Datos

Esta capa tiene como objetivo **almacenar todos los datos** de la empresa de forma **centralizada** y **escalable**.

Almacenamiento de Datos

Su importancia radica en su capacidad para trabajar con datos batch y streaming. Hay dos tipos principales:

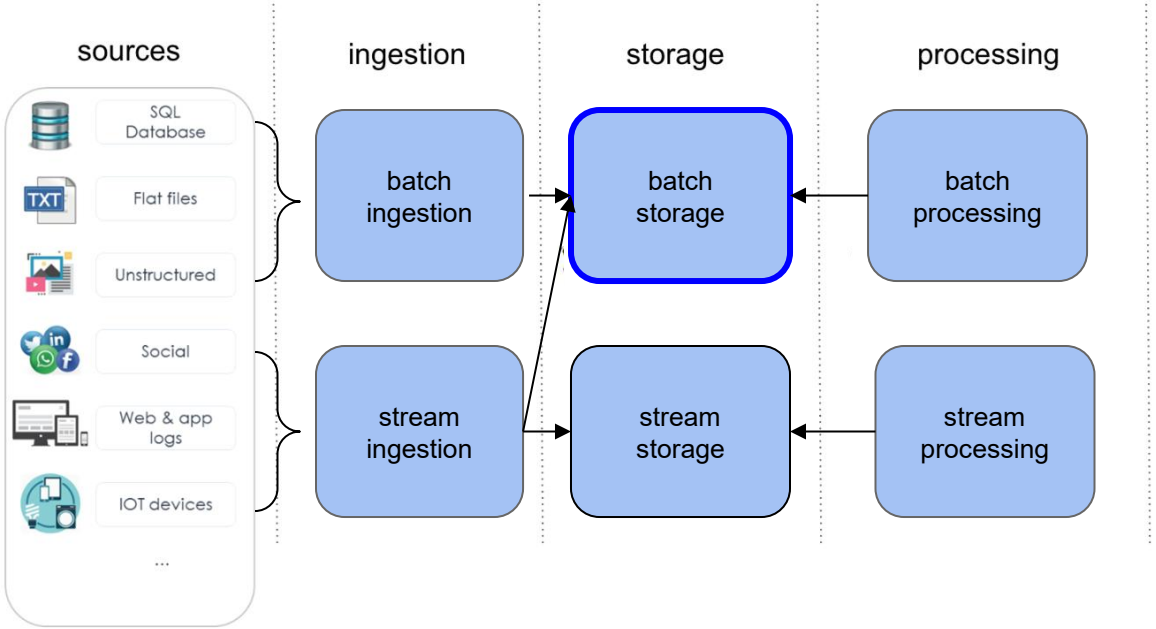
- **Almacenamiento batch** (volumen)
- **Almacenamiento streaming** (velocidad)

2.

ALMACENAMIENTO BATCH



Almacenamiento Batch



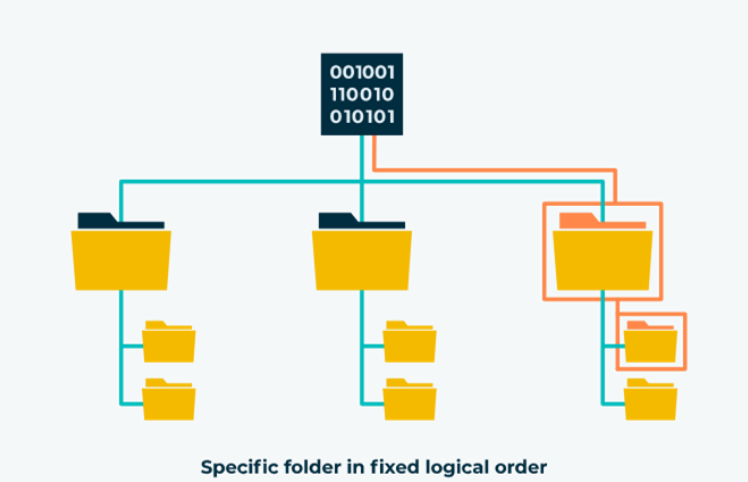
Almacenamiento Batch

Toda arquitectura de datos moderna requiere de un almacenamiento persistente, escalable y masivo que permita almacenar cualquier tipo de dato.

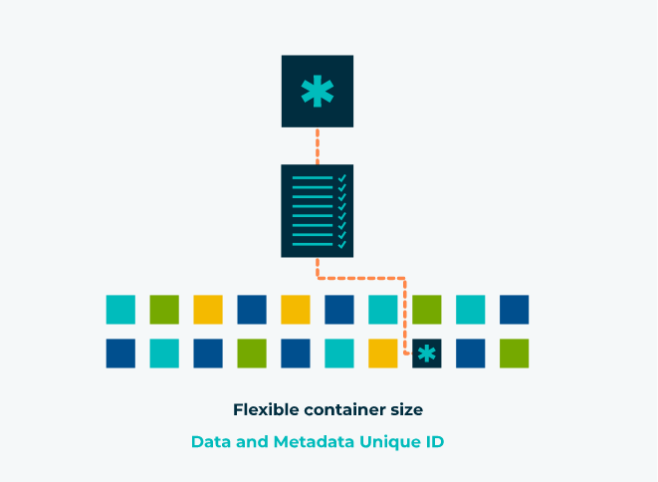
Almacenamiento persistente y de **largo plazo**

Basados en **ficheros o blobs**

Almacenamiento Batch



sistema de ficheros



blob store

Almacenamiento Batch

Los data lakes y los data lakehouses hacen uso precisamente de este tipo de almacenamiento



Almacenamiento Batch

Las principales **limitaciones** de estos sistemas

- Alta latencia lectura (interactive data access)
- Gestión de ficheros pequeños
- Escrituras arbitrarias

Almacenamiento Batch

Alta latencia lectura

El **tiempo de acceso** a estos sistemas suele ser **alta** y no están pensados para consumo directo en tiempo de respuesta por debajo del segundo

Estos sistemas han sido diseñados y **optimizados para lecturas de grandes volúmenes de datos** en paralelo, sacrificando de este modo la velocidad de acceso a los mismos.

Almacenamiento Batch

Alta latencia lectura

Solución:

Cualquier tipo de aplicación que requiera acceso a los datos de baja latencia deberá hacer uso del almacenamiento streaming o de tecnologías NoSQL.

Almacenamiento Batch

Gestión de ficheros pequeños

El **número de ficheros y el tamaño de los ficheros afecta al rendimiento** de las aplicaciones que los leen o procesan, por lo tanto, tener un dimensionamiento adecuado de los ficheros es importante.

Almacenamiento Batch

Gestión de ficheros pequeños

Solución

Los ingenieros de datos son responsables de **consolidar o fusionar ficheros pequeños en otros más grandes**.

Usan formatos especiales como **parquet, ORC**

Ficheros **muy grandes** (128MB- 256MB).

Almacenamiento Batch

Escrituras arbitrarias

Estos sistemas **no soportan escrituras arbitrarias** en los ficheros que almacenan y cualquier cambio en el dato o su contenido por pequeño que sea **requiere la reescritura completa del fichero** en el sistema

Tecnologías Open Source



Hadoop Distributed
File System
(HDFS)



MINIO
(minio)
(S3)

Tecnologías Cloud



Databricks File System
(DBFS)



Azure Data Lake Store
(ADLS)



Amazon Simple
Storage Service
(S3)

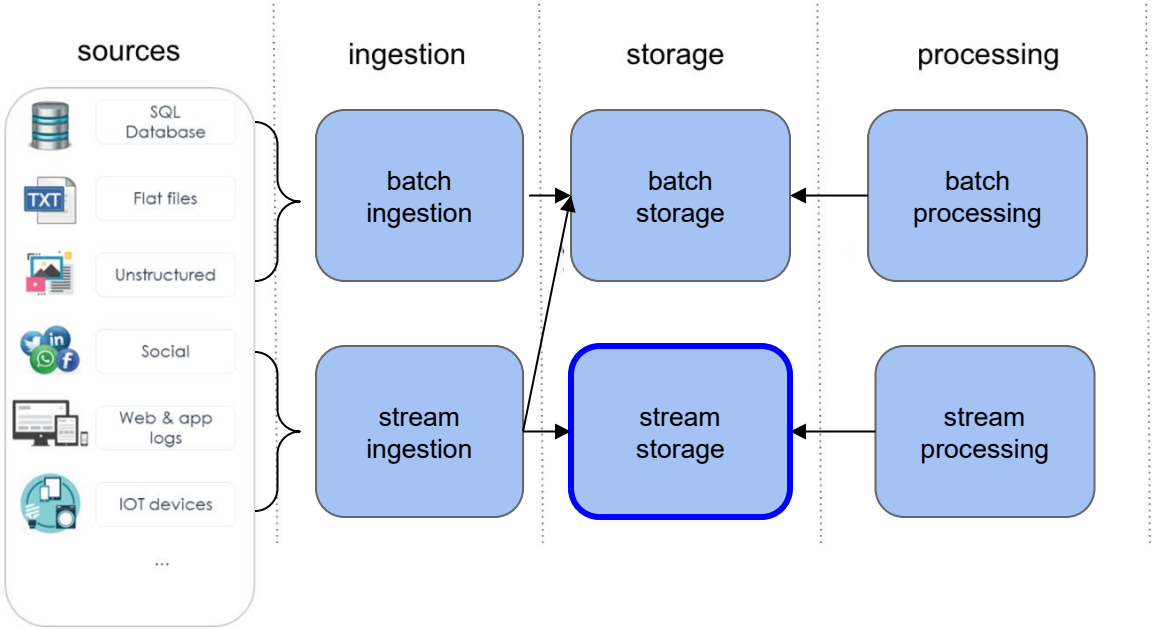


Google Cloud Storage
(GS)

3.

ALMACENAMIENTO STREAMING

Almacenamiento Streaming



Almacenamiento Streaming

Del mismo modelo, las arquitecturas de datos modernas requieren un tipo de almacenamiento especializado para poder almacenar datos en tiempo real.

El propósito de estas tecnologías **facilitar y acelerar el procesamiento de los datos en tiempo real**

Almacenamiento temporal y de corto plazo

Almacenamiento Streaming

Hadoop se diseñó teniendo en cuenta solamente 2 Vs, volumen y variedad

A medida que los datos evolucionaban en **velocidad**, la necesidad de procesarlos tan pronto como fuera posible comenzó a cobrar relevancia

Almacenamiento Streaming

Existen múltiples situaciones en las que es necesario reaccionar/analizar/procesar los datos mientras siguen en movimiento

por ejemplo la validación de una transacción de una tarjeta de débito/crédito

Para estas situaciones necesitamos una tecnología de almacenamiento streaming.

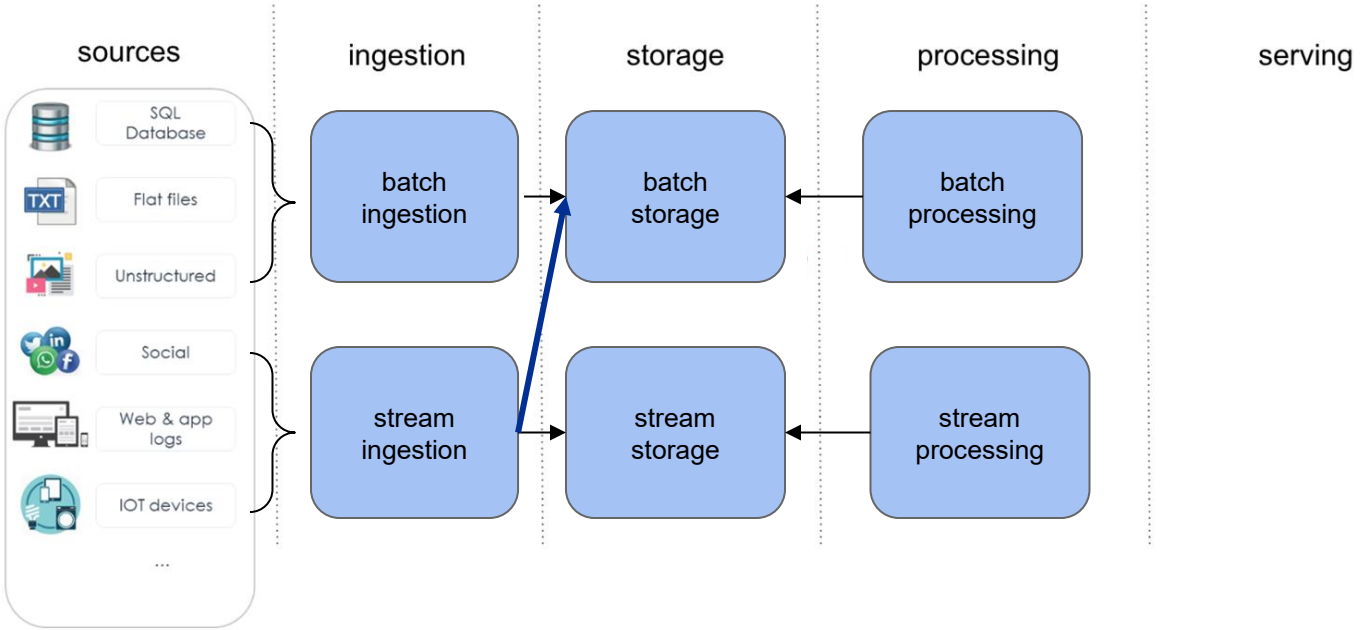
Almacenamiento Streaming

El **propósito** de este tipo de almacenamiento es por tanto **acelerar y facilitar** el acceso o **procesamiento** del dato cuanto antes.

Almacenamiento Streaming

Normalmente estas tecnologías son tecnologías en las que **el dato se almacena de forma temporal** (durante unas pocas horas o días) ya que esos datos serán persistidos de forma permanente en almacenamiento batch.

Almacenamiento Streaming



Tecnologías Open Source



Apache Kafka



Apache Pulsar

Tecnologías Cloud



Azure Event Hub



Amazon MSK



Google Cloud Pub-Sub

Tecnologías Comerciales





