ntic master
revolucionamos la comunicación

TECNOLOGÍAS DEL BIG DATA

TECNOLOGÍAS DE PROCESAMIENTO



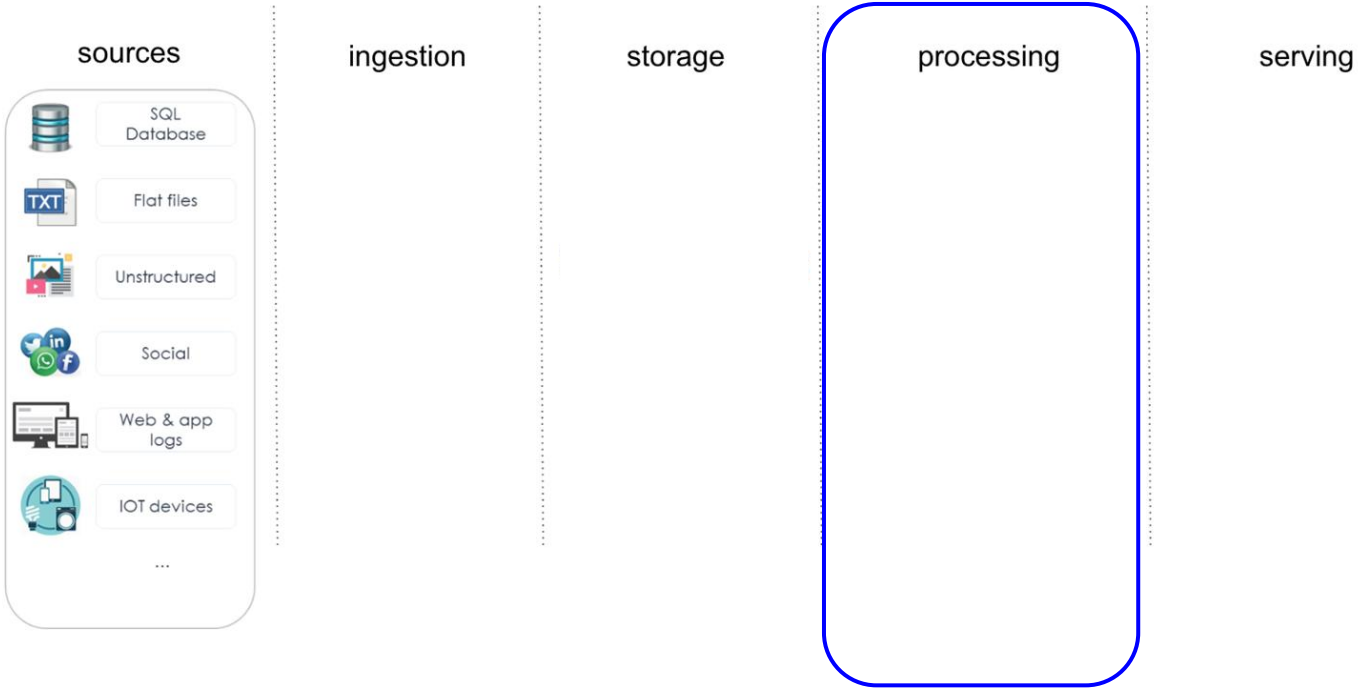
Agenda

- Definición
- Importancia
  - Procesamiento Batch
  - Procesamiento Streaming
  - Procesamiento Unificado
  - Procesamiento ETL
  - Procesamiento SQL
  - Procesamiento Grafos
  - Procesamiento ML
- Ecosistema Cloud

1.

DEFINICIÓN

Definición


sources
ingestion
storage
processing
serving
SQL Database
Flat files
Unstructured
Social
Web & app logs
IOT devices
...

Definición

Esta capa, también conocida como capa **analítica**, **transformación** o **preparación**, es responsable del procesamiento de los datos de la capa de almacenamiento y generar los resultados.

2.

IMPORTANCIA

Procesamiento de Datos

El procesamiento de datos consiste en aplicar diferentes técnicas o transformaciones sobre los datos.

Su importancia radica en su capacidad para soportar múltiples tipos de procesamiento basados en:

- Características de los datos
- Tipo de análisis

Características de los Datos

- Volumen => **procesamiento batch**
  - grandes volúmenes de datos
  - alta latencia (muy lento)
  - data at rest
  - offline

- Velocidad => **procesamiento streaming**
  - volúmenes de datos moderados
  - baja latencia (muy rápido)
  - data in motion
  - online

Tipo de Análisis

- Procesamiento ETL
- Procesamiento SQL
- Procesamiento ML
- Procesamiento Grafos
- ...

2.1

PROCESAMIENTO BATCH

Procesamiento Batch

El procesamiento batch es la forma de procesar grandes **grupos de registros** (batch) en lugar de procesarlos de forma individualmente.

Normalmente este tipo de procesamiento dura varios minutos/horas en completarse.

Tecnologías Open Source







Apache Flink

2.2

PROCESAMIENTO STREAMING

Procesamiento Streaming

El procesamiento streaming es el procesamiento en tiempo real de los datos de forma continua, concurrente y de **registro en registro**

¿Por qué es útil?

A veces es fundamental reaccionar a los datos tan pronto como sea posible.

Procesamiento Streaming

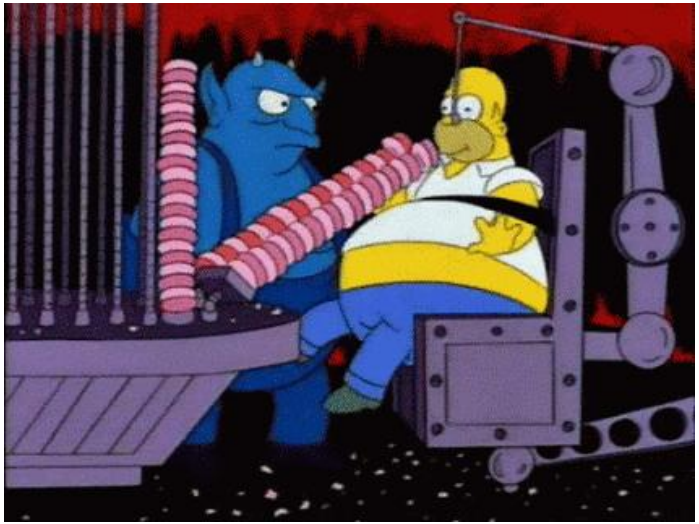
Clasificación temporal

- Batch: > 15 m
- Micro batch: [2 m, 15 m]
- Near real time (NRT) : [100 ms , 2 m]
- Real time : < 100 ms

Procesamiento Batch VS Streaming



BATCH



STREAMING

Tecnologías Open Source

Spark Streaming

kafka streams



Apache Flink

2.3

PROCESAMIENTO UNIFICADO

Procesamiento Unificado

En los primeros días de big data había que **usar diferentes tecnologías** para el procesamiento de batch y streaming.

Hoy en día las nuevas tecnologías proporcionan un modelo de procesamiento unificado para poder realizar ambos tipos de procesamiento con una sola tecnología.

Tecnologías Open Source







Apache Flink

2.4

PROCESAMIENTO ETL

Procesamiento ETL

Permiten crear ETLs usando lenguajes de alto nivel.

ETL es un acrónimo de **E**xtract, **T**ransform, **L**oad

En realidad todo procesamiento se puede generalizar como una ETL.

Tecnologías Open Source





2.5

PROCESAMIENTO SQL

Procesamiento SQL

Todas las tecnologías de **procesamiento requieren programación**

La mayoría de compañías carecen de suficientes ingenieros de datos pero cuentan con muchos empleados que saben SQL.

Procesamiento SQL

Permite el uso de un subconjunto de **SQL** para **procesar los datos.**

Solo necesitamos expresar el procesamiento en términos de consultas SQL y la tecnología de procesamiento sabrá cómo aplicarlas.

Tecnologías Open Source



SQL



presto



Apache Flink



trino

2.6

PROCESAMIENTO GRAFOS

Procesamiento de Grafos

Permiten crear y ejecutar algoritmos sobre grafos distribuidos.

Los grafos (también conocidos como redes) son estructuras de datos matemáticas utilizadas para modelar relaciones entre entidades.

Procesamiento de Grafos

Un grafo se compone de:

- **Vértices**: (nodos)

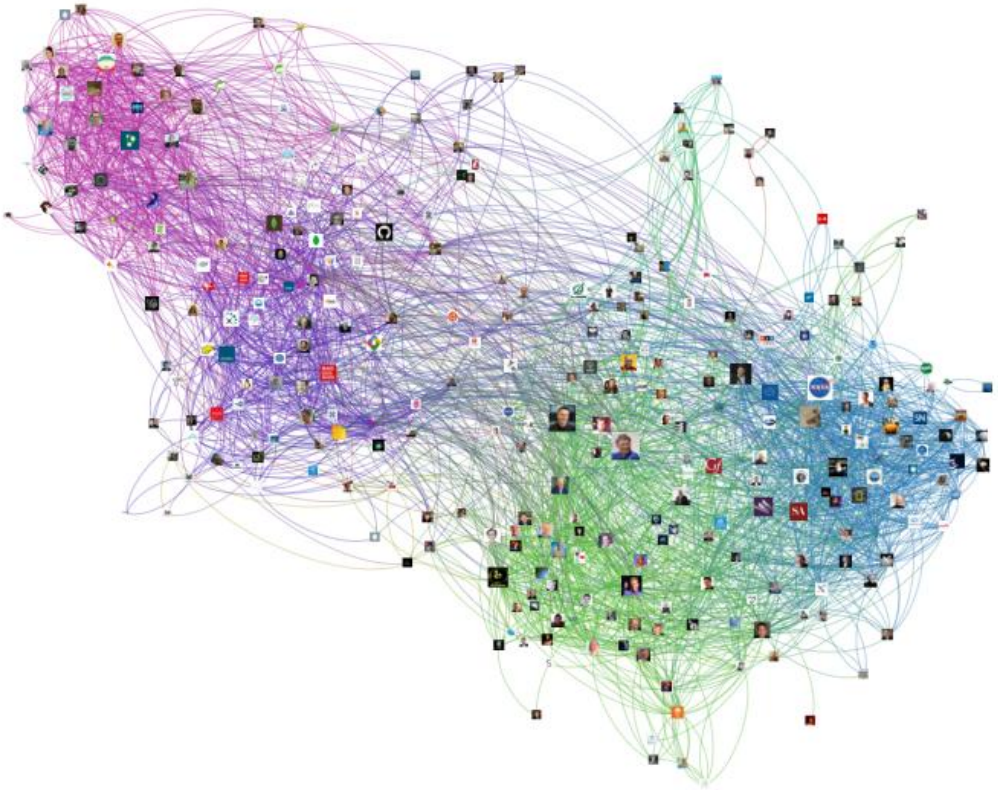
- **Aristas**: (arcos) conectan vertices.
  - Dirigidos
  - No dirigidos

Procesamiento de Grafos

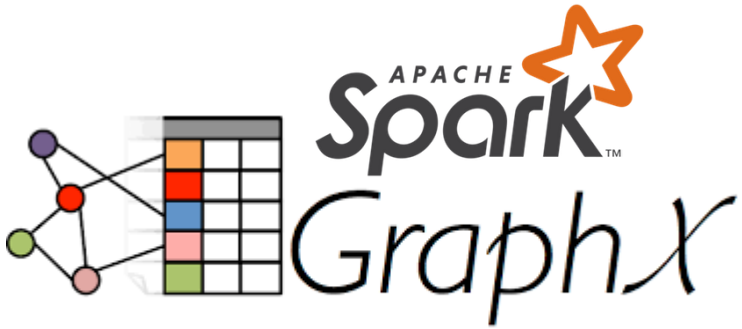
A menudo modelamos vértices representando entidades (una persona, una cuenta de un rrss) y las aristas como una relación entre vértices.

Tanto los vértices como las aristas pueden contener información.

Procesamiento de Grafos



Procesamiento de Grafos





GraphFrames

2.7

PROCESAMIENTO ML

Procesamiento ML

Permiten crear modelos y aplicar algoritmos de aprendizaje automático sobre grandes volúmenes de datos.

Tecnologías Open Source



MLlib



MAHOUT



Flink ML

3.

ECOSISTEMA CLOUD

Azure



Azure HDInsight



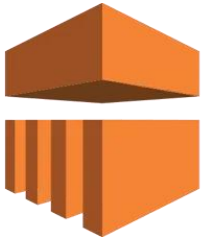
Azure Synapse



Azure Stream Analytics



AWS



amazon
EMR



Amazon Glue



amazon
KINESIS



GCP







Google Cloud

Databricks

Databricks plataforma de analítica big data e IA basada en Apache Spark.

Azure Databricks
Amazon Databricks
GCP Databricks



databricks

Microsoft Azure

aws

Google Cloud

Snowflake

Snowflake Snowflake es una plataforma de datos nativa de la nube, completamente gestionada y serverless, diseñada para unificar el almacenamiento, procesamiento y análisis de datos a escala empresarial.









