UNIVERSIDAD COMPLUTENSE MADRID

ntic master




# Ejercicios de evaluación

**MODULE / COURSE**

Máster data science, big data & business analytics

**TOPIC/UNIT**

Text Mining

**PROFESSOR**:

Luis Gascó Sánchez, PhD.

CC BY NC ND

## Ejercicio práctico (Tiempo estimado de realización: ~ 4-6 horas)

El propósito de este ejercicio es aplicar los conocimientos adquiridos sobre análisis exploratorio de datos textuales y entrenamiento de modelos supervisados, utilizando datos reales extraídos de redes sociales.

Trabajarás con datos de la **shared-task ProfNER**, específicamente con los de la Tarea 1, que se centra en la **detección de profesiones** mencionadas en textos publicados en **Twitter durante la pandemia de COVID-19**. Con esos datos, deberás desarrollar un **clasificador binario** que, dado un tweet, determine si **menciona al menos una profesión (etiqueta 1)** o **no ( etiqueta 0)**. Esta tarea permite identificar contenido relacionado con ocupaciones, con el objetivo de analizar qué profesiones podrían haber sido más vulnerables durante la crisis sanitaria.

### Recursos proporcionados

- Un **notebook de Google Colab** con la estructura básica del ejercicio. Incluye funciones y celdas predefinidas **que no deben ser modificadas**.
- Un **conjunto de datos** en formato dataset de Hugging Face, que contiene:
  - **Datos de entrenamiento**: con identificadores, texto y etiquetas.
  - **Datos de validación**: con la misma estructura que el conjunto de entrenamiento.
  - **Datos de prueba (test)**: solo incluye identificadores y texto (sin etiquetas)[1].

### Tareas a llevar a cabo:

1. **Análisis Exploratorio de Datos:**
   - Calcular estadísticas básicas: número de documentos, distribución de clases, longitud de los textos, etc.
   - Crear visualizaciones (por ejemplo, wordclouds) para entender mejor el contenido del dataset.
2. **Selección y justificación del modelo**
   - Elegir un modelo preentrenado de HuggingFace adecuado para el idioma y la naturaleza de los datos.
   - Justificar claramente por qué se ha seleccionado ese modelo.
3. **Entrenamiento del clasificador.**
   - Entrenar el modelo de forma reproducible**.**
   - Evaluar su rendimiento sobre el conjunto de validación.
4. **Generación de predicciones sobre el test**
   - Aplicar el modelo entrenado sobre el conjunto de test.
   - Guardar las predicciones en un archivo -tsv con el siguiente formato:
     - Dos columnas **id** y **label**, separadas por tabulador.
     - El archivo debe llamarse
       *APELLIDO1_APELLIDO2_NOMBRE_ejercicio1_predicciones.tsv.*

[1] El test tiene campo de etiquetas, pero todas tienen el valor -1.

## Instrucciones de entrega

Debes entregar los siguientes archivos:

1. **Notebook de Google Colab** con el desarrollo completo del ejercicio, incluyendo análisis, código y justificaciones. El nombre del archivo debe seguir esta nomenclatura**:**

   *APELLIDO1_APELLIDO2_NOMBRE_ejercicio1.ipynb*

2. **Archivo de predicciones** generado por el modelo, con el nombre:

   *APELLIDO1_APELLIDO2_NOMBRE_ejercicio1_predicciones.tsv*

Ambos archivos deben comprimirse en un archivo **.zip** con nombre:

*APELLIDO1_APELLIDO2_NOMBRE_TM_EJERCICIO.zip*

## Criterios de evaluación

| Criterio | Peso |
|---|---|
| Análisis exploratorio y preprocesamiento | 20% |
| Selección y justificación del modelo | 25% |
| Formato y validez del archivo de predicciones | 5% |
| Ejecución correcta del notebook sin intervención (sin errores) | 10% |
| Rendimiento del modelo en el conjunto de prueba | 30% |
| Claridad y calidad de las explicaciones | 10% |

**Nota importante:** El rendimiento del modelo se evaluará utilizando métricas estándar como el **F1-score** sobre el conjunto de test. Si el archivo de predicciones **no cumple con el formato requerido**, el ejercicio **no podrá ser evaluado**. El primer clasificado de la clase obtendrá la máxima calificación en este apartado, disminuyendo de forma proporcional al nivel de f1-score obtenido.

**Ejecutabilidad:** El notebook debe poder ejecutarse **de principio a fin sin intervención manual**. Si utilizas librerías no incluidas en el entorno por defecto de Google Colab, **debes instalarlas en el propio notebook**. Para que pueda ejecutarse de principio a fin

## Recomendaciones

- Trabajar directamente en el entorno de Google Colab para evitar problemas de compatibilidad o instalación de librerías.
- Sigue la estructura del notebook y **no modifiques las celdas indicadas como fijas**.
- Documentar adecuadamente cada paso realizado, incluyendo justificaciones para las decisiones tomadas.
- Realizar pruebas con subconjuntos de datos antes de entrenar el modelo completo para verificar que todo funciona correctamente.