ntic master
revolucionamos la comunicación

UNIVERSIDAD COMPLUTENSE DE MADRID



Text Mining

Luis Gascó Sánchez, Ph.D.

Sobre mi:

Formación

- Doctor en Ingeniería (Universidad Politécnica de Madrid)
- Certificado de doctorado europeo en innovación y tecnología (EIT Digital Doctoral School)
- Master en Big Data e Inteligencia de Negocio (Escuela de Organización Industrial)
- Master Universitario en Ingeniería Acústica (Universidad Politécnica de Madrid)
- Ingeniero de Imagen y Sonido (Telecomunicaciones) (Universidad Politécnica de Madrid)

Posición actual

Senior Machine Learning Research Engineer
@ Avature

Avature

Experiencia

POLITÉCNICA

NOKIA Bell Labs

TELECOM ParisTech

BSC Barcelona Supercomputing Center
Centro Nacional de Supercomputación

Atos

Cronograma

Día 1:

1. Introducción
    1. Contexto histórico
    2. ¿Qué es el Text Mining?
    3. Librerías de programación para Text Mining
2. Técnicas y conceptos básicos de NLP
3. Representación numérica del texto
4. Modelos de Lenguaje. Arquitectura Transformers

Cronograma

Día 2:

- Técnicas de Text Mining:
    1. Flujo de los datos
    2. Clasificación de textos
        - Técnica tradicional
        - Modelos de lenguaje
    3. Retrieval-based Question Answering
    4. Prompt Engineering.

Evaluación

Clases teórico prácticas

+

Ejercicio(s) prácticos


OpenAI


ANTHROP\C


MISTRAL
AI_


Google


Meta

Google

Por qué

- por qué
- por qué **o porqué**
- por qué **ronronean los gatos**
- por qué **el cielo es azul**
- por qué **no te callas**
- por qué **la sal derrite el hielo**
- por qué **se inventaron los cereales**
- por qué **la nieve es blanca**
- por qué **a los madrileños se les llama gatos**
- por qué **matan las mujeres**

Buscar con Google | Voy a tener suerte

Denunciar predicciones inadecuadas
Más información

Google

cuál es la capital de zimbabue

Todo | Noticias | Maps | Imágenes | Vídeos | Más | Configuración | Herramientas

Aproximadamente 3.170.000 resultados (1,21 segundos)

Zimbabue / Capital



Harare

Harare (denominada Salisbury hasta 1982) es la ciudad más poblada y capital de Zimbabue. Tiene una población estimada de 1.600.000 habitantes, con unas 2.800.111 personas en su área metropolitana (2006). Es el centro administrativo, comercial, y de comunicaciones de Zimbabue.

https://es.wikipedia.org › wiki › Harare

Harare - Wikipedia, la enciclopedia libre

Sugerencias

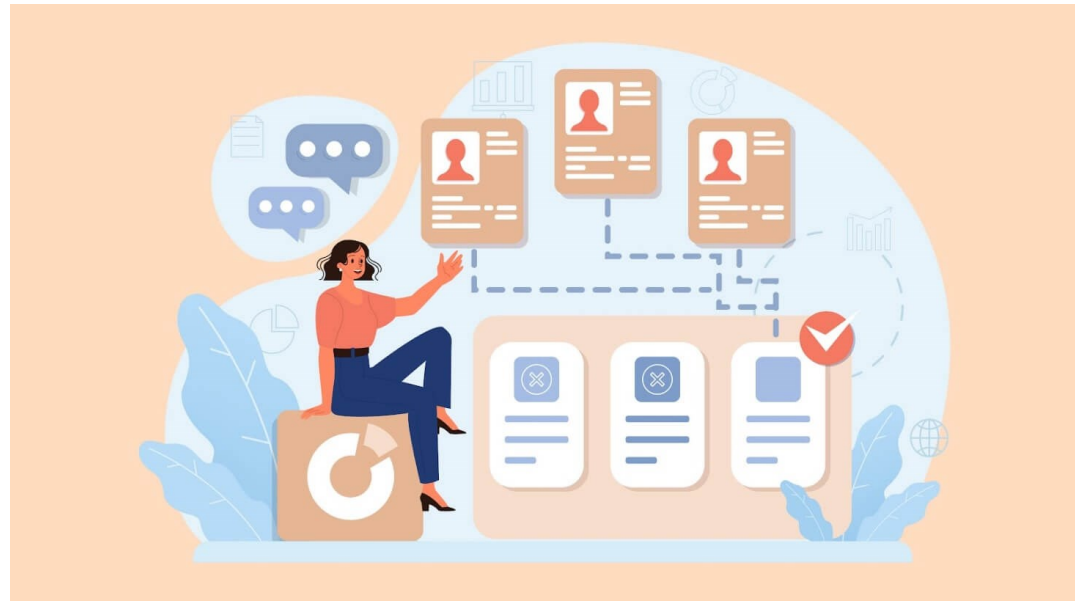
Otras preguntas de los usuarios

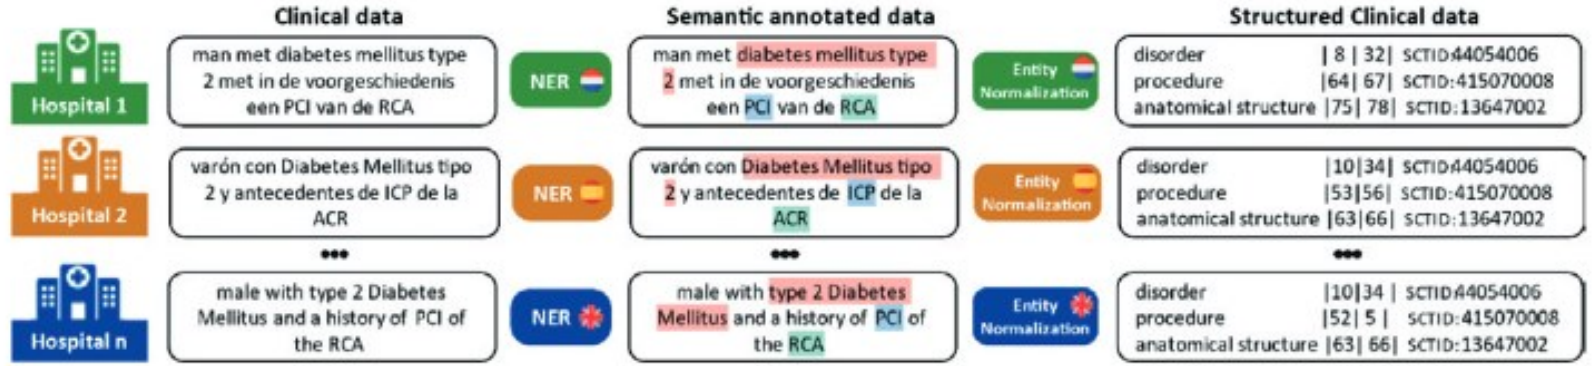
¿Dónde está Zimbabue?

¿Cómo se llama la capital de Zambia?

¿Qué país es ahora Rodesia?


Buscar en Twitter
ti
COVID-19
Tendencias
Noticias
Deportes
Entretenimiento
Tendencias de España
1 · Fútbol · Tendencia
Chelsea
UEFA Champions League
Atletico Madrid vs Chelsea
156 mil Tweets
2 · Fútbol · Tendencia
Lemar
4.620 Tweets
3 · Tendencias
#pasapalabra200
1.343 Tweets
4 · Tendencias
#FirstDates23F
Tendencias sobre #CiudadNova23Feb, #MatrimonioDivinity23F
5 · Fútbol · Tendencia
Bayern
UEFA Champions League
Lazio vs Bayern Munich



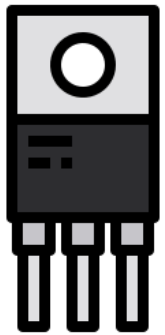

Clinical data
Semantic annotated data
Structured Clinical data
Hospital 1
man met diabetes mellitus type 2 met in de voorgeschiedenis een PCI van de RCA
NER
man met diabetes mellitus type 2 met in de voorgeschiedenis een PCI van de RCA
Entity Normalization
disorder | 8 | 32| SCTID44054006
procedure |64| 67| SCTID:415070008
anatomical structure |75| 78| SCTID:13647002
Hospital 2
varón con Diabetes Mellitus tipo 2 y antecedentes de ICP de la ACR
NER
varón con Diabetes Mellitus tipo 2 y antecedentes de ICP de la ACR
Entity Normalization
disorder |10|34| SCTID44054006
procedure |53|56| SCTID:415070008
anatomical structure |63|66| SCTID:13647002
Hospital n
male with type 2 Diabetes Mellitus and a history of PCI of the RCA
NER
male with type 2 Diabetes Mellitus and a history of PCI of the RCA
Entity Normalization
disorder |10|34 | SCTID44054006
procedure |52| 5 | SCTID:415070008
anatomical structure |63| 66| SCTID:13647002

1. Introducción

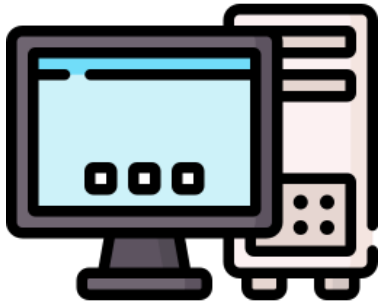
Contexto histórico

Revolución Digital: La Tercera Revolución Industrial

Transistor



Ordenador personal



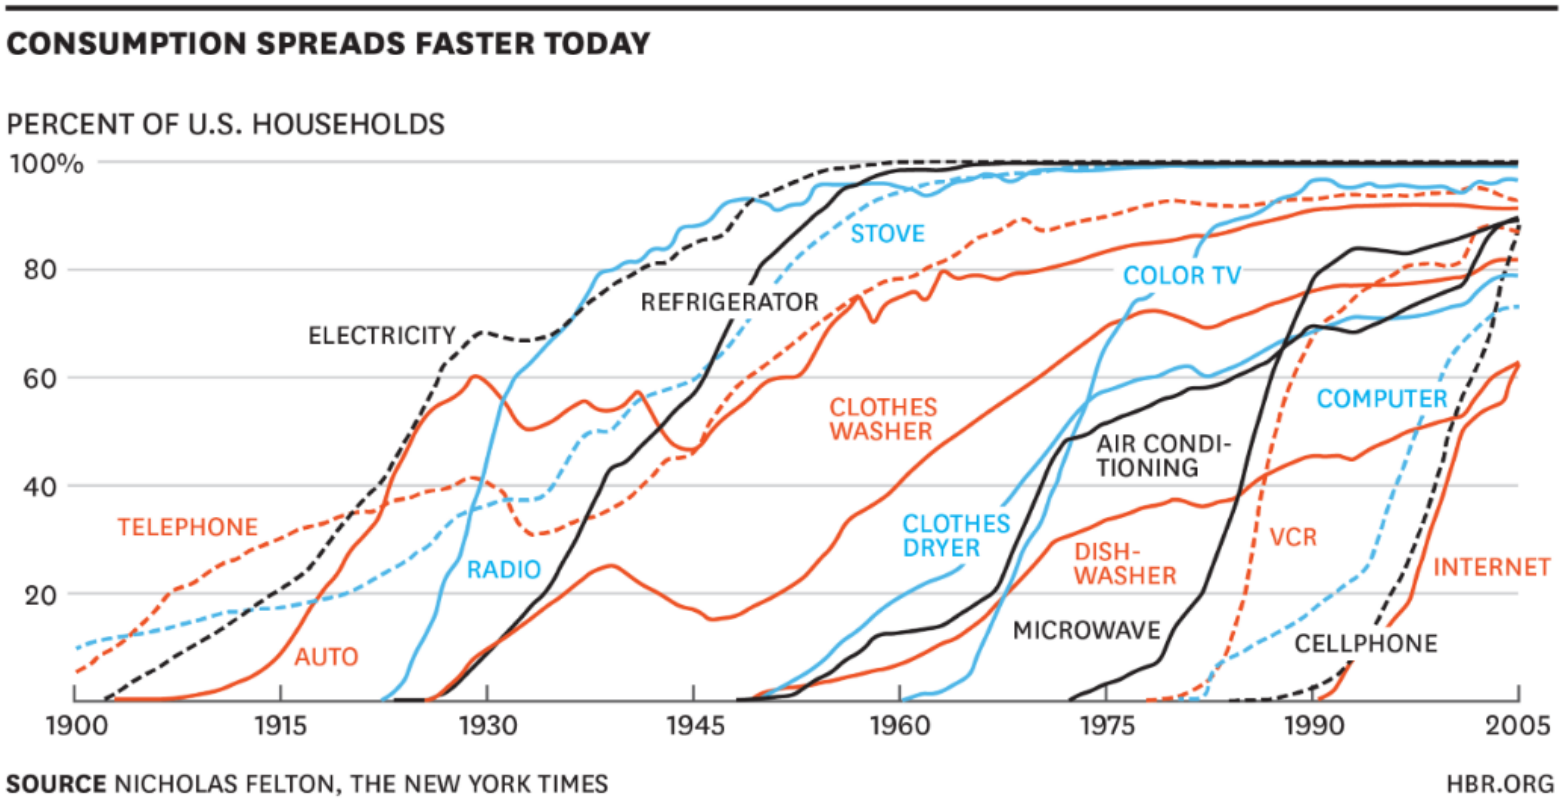
ARPANET



1. Introducción

Contexto histórico

Revolución Digital: *La Tercera Revolución Industrial*



Reducción del tiempo de **adopción tecnológica**, gracias a:

- Mejora de las líneas de producción
  - + producción
  - - coste
- Incremento exponencial de la potencia. Ley de Moore.
- Bonanza económica

1. Introducción

Contexto histórico

Revolución digital

Era de la información

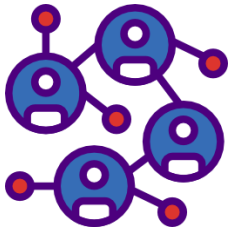


Importancia de las TICs

Tecnología como motor de la evolución social



Web 2.0.



Redes sociales



Digitalización y sensorización



DATOS

1. Introducción

Contexto histórico



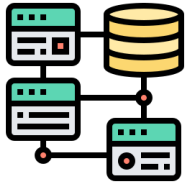
DATOS

Estructurados



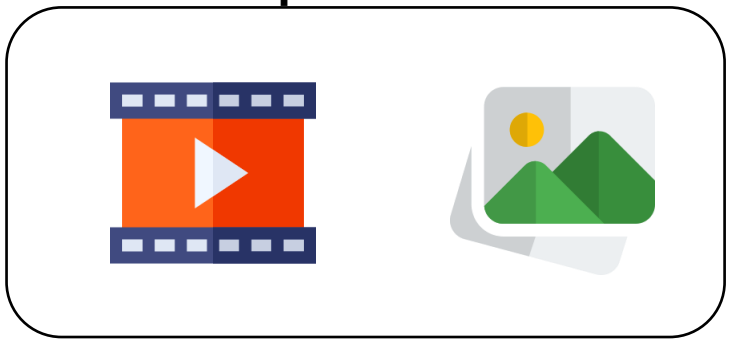


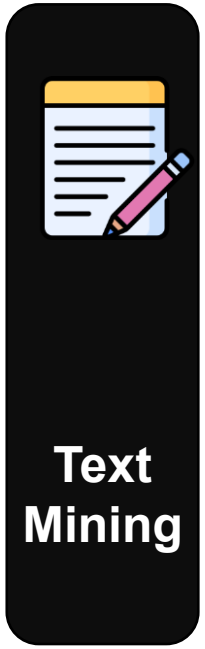




No estructurados

Visión computacional





1. Introducción

Text Mining



Definición

El proceso de transformación de datos textuales no estructurados a un formato tabular que permita analizarlos y extraer conocimiento

1. Introducción

Aplicación de las técnicas de Text Mining



Búsqueda y recuperación de información

Information Retrieval

- Consiste en el almacenado, búsqueda y obtención de documentos textuales a partir de búsquedas de palabras clave.
- Ej. Mejora de sistemas de indización automática

1. Introducción

Aplicación de las técnicas de Text Mining



Búsqueda y recuperación de información

Agrupación de documentos

Clustering

- Consiste en la agrupación de textos o secciones de textos que tienen características communes a partir de algoritmos de clustering.
- Ej. Contenido duplicado, plagio, sistemas de recomendación.

1. Introducción

Aplicación de las técnicas de Text Mining



Búsqueda y recuperación de información

Agrupación de documentos

Clasificación de documentos

Text Classification

- Categorización de textos a clases específicas a partir de algoritmos de clasificación y conjuntos de datos anotados.
- Ej. Fake News, discurso del odio, análisis de sentimiento

1. Introducción

Aplicación de las técnicas de Text Mining



Búsqueda y recuperación de información

Agrupación de documentos

Clasificación de documentos

Extracción de información

Information Extraction

- Extracción de elementos de importancia dentro de documentos textuales y encontrar relaciones entre estos.
- Ej. Datos de clients o empresas en informes de negocios

1. Introducción

Aplicación de las técnicas de Text Mining



- **Búsqueda y recuperación de información**
- **Agrupación de documentos**
- **Clasificación de documentos**
- **Extracción de información**
- **Extracción de conceptos**

Concept Extraction

- Consiste en la agrupación de palabras y frases de varios documentos en grupos semánticos similares.
- Ej. Extraer temas de importancia dentro de un conjunto de reviews.

1. Introducción

Aplicación de las técnicas de Text Mining



- Búsqueda y recuperación de información
- Agrupación de documentos
- Clasificación de documentos
- Extracción de información
- Extracción de conceptos
- Procesado de Lenguaje Natural

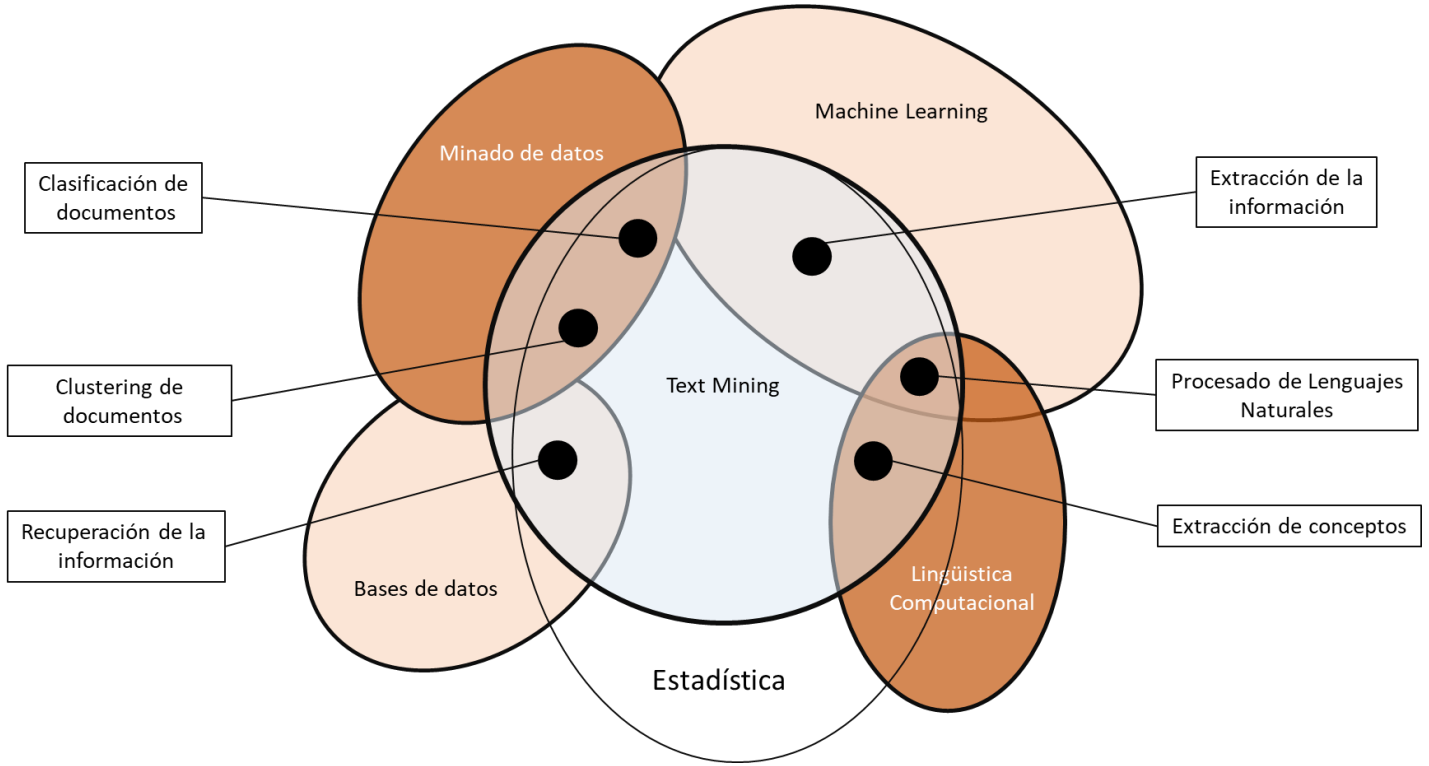
Natural Language Processing (NLP)

- Consiste en la aplicación de técnicas de bajo nivel para procesar el lenguaje y mejorar la compression del texto por sistemas automáticos.

1. Introducción

Aplicación de las técnicas de Text Mining

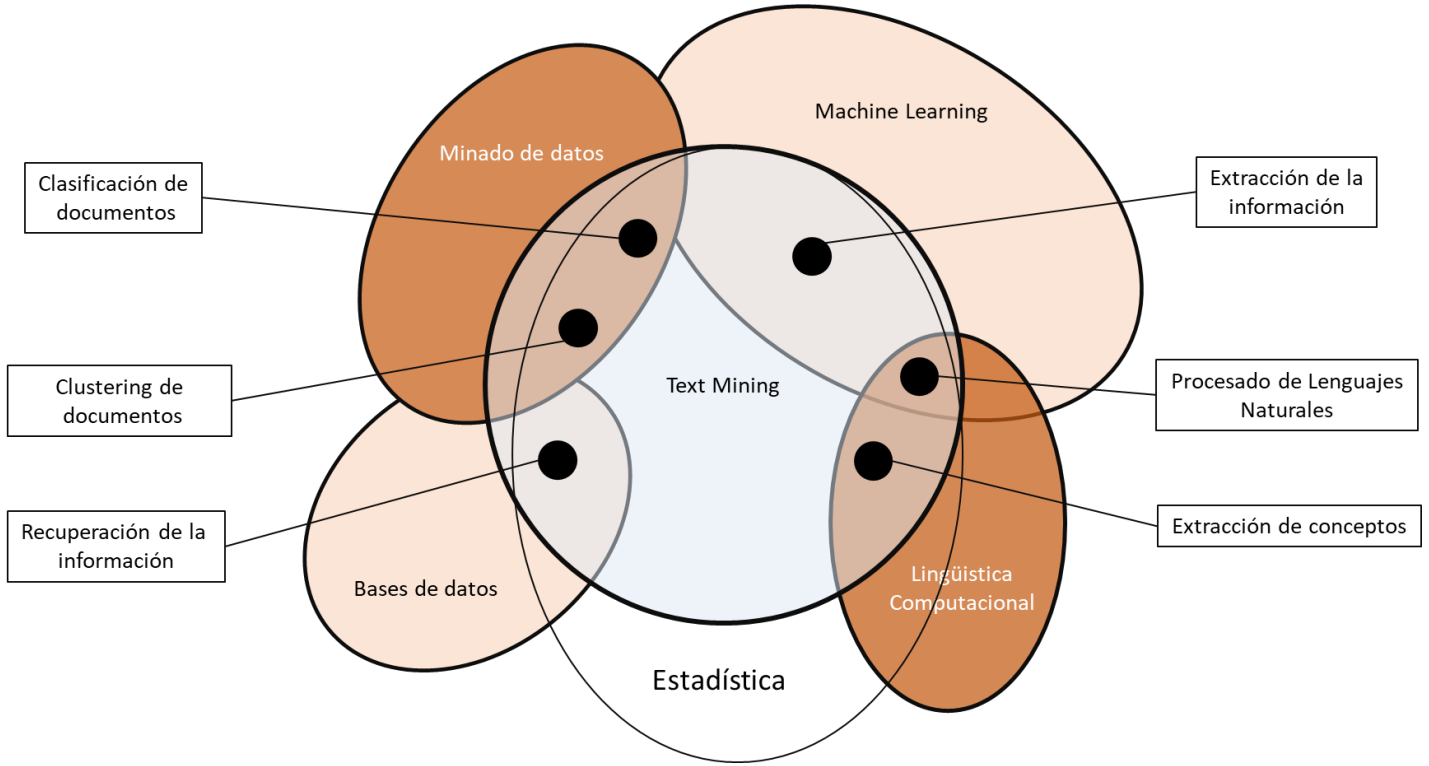
- Búsqueda y recuperación de información
- Agrupación de documentos
- Clasificación de documentos
- Extracción de información
- Extracción de conceptos
- Procesado de Lenguaje Natural



1. Introducción

Aplicación de las técnicas de Text Mining

- Búsqueda y recuperación de información
- Agrupación de documentos
- Clasificación de documentos
- Extracción de información
- Extracción de conceptos
- Procesado de Lenguaje Natural



1. Introducción

Librerías para trabajar con textos



NLTK

University of Pennsylvania

Año 2001

Orientada a investigación

Principalmente para preprocesado

Spacy

Ines Montani y Matthew Honnibal

Año 2015

Orientada a producción

Preprocesado, construcción de modelos…

Gensim

Radim Rehurek

Año 2009

Orientada a producción

Análisis preliminar

Transformers

Clement Delangue and Julien Chaumond (HuggingFace)

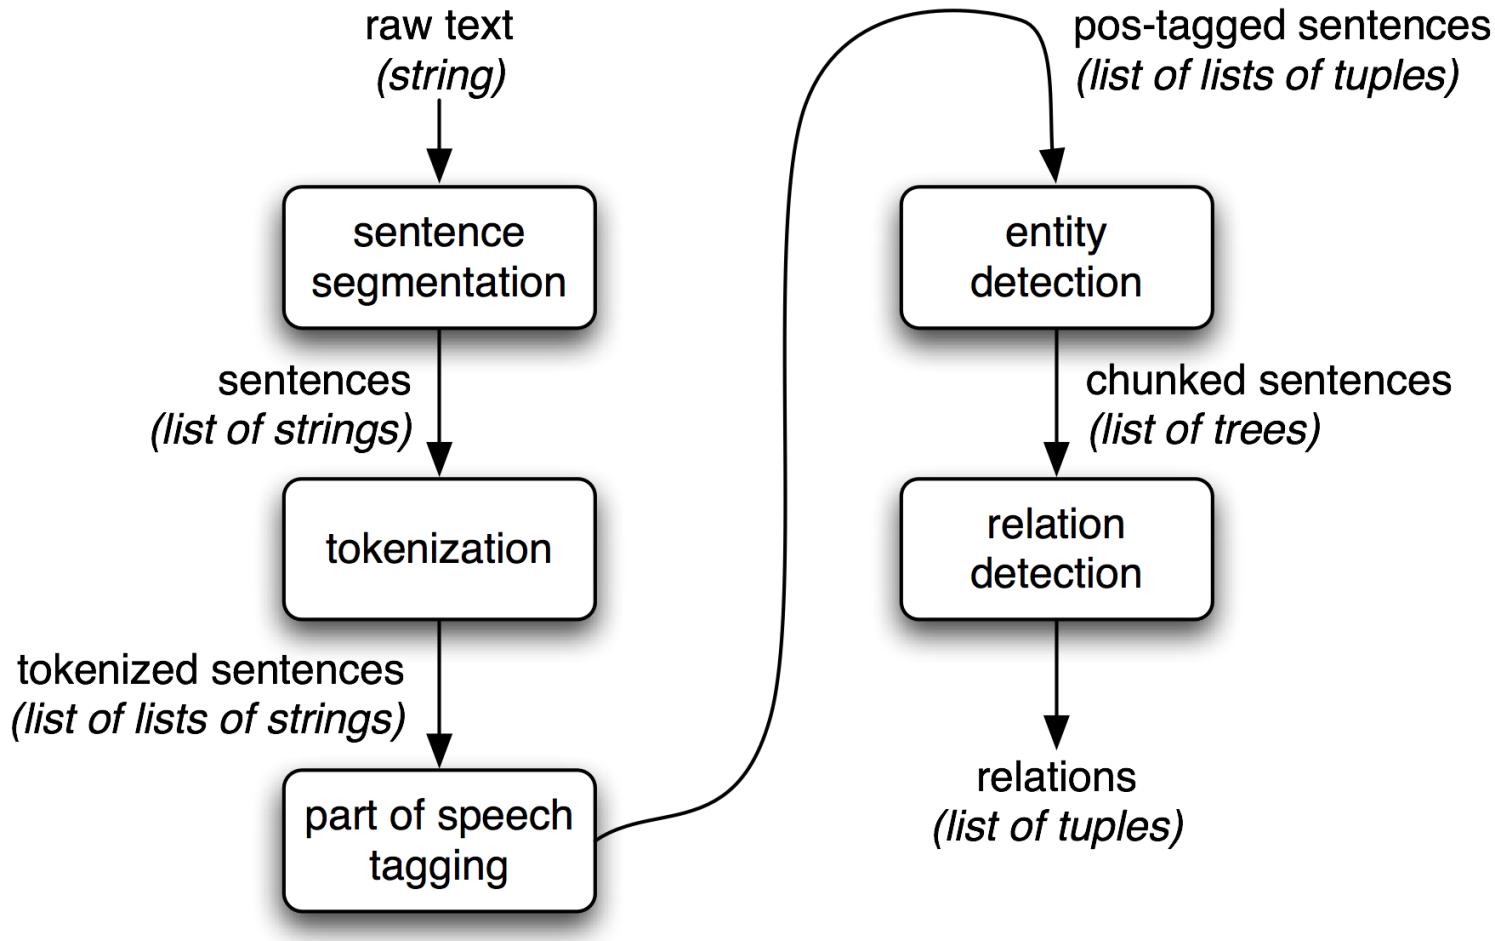
Año 2016

Orientada a producción

Construcción de modelos, reutilización de modelos

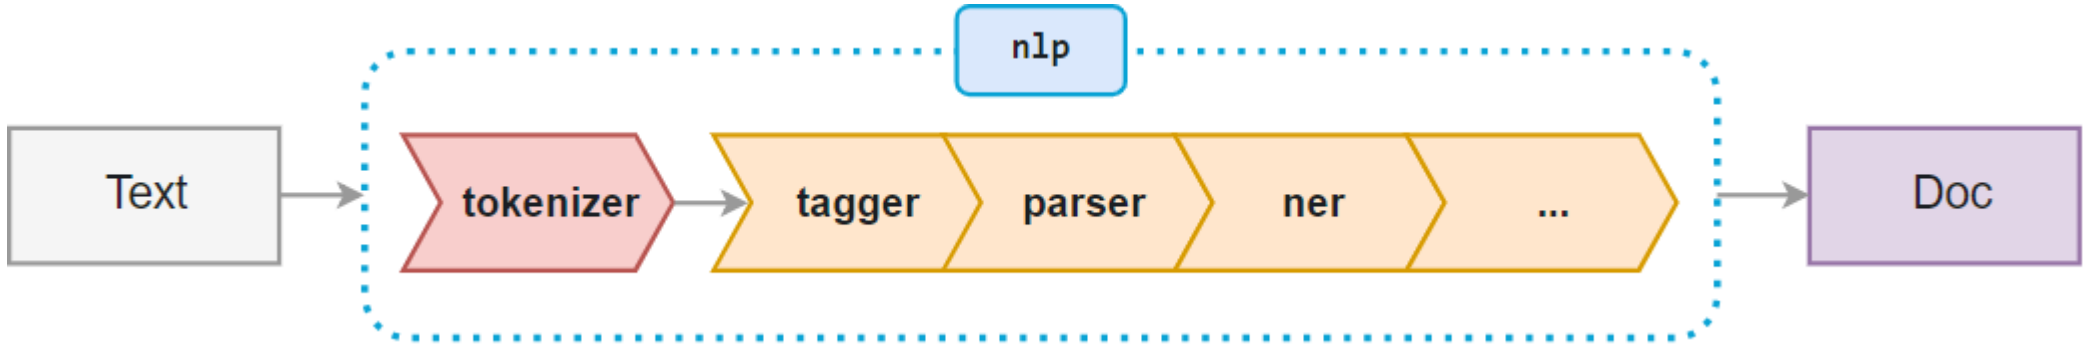
1. Introducción

Librerías para trabajar con textos - NLTK



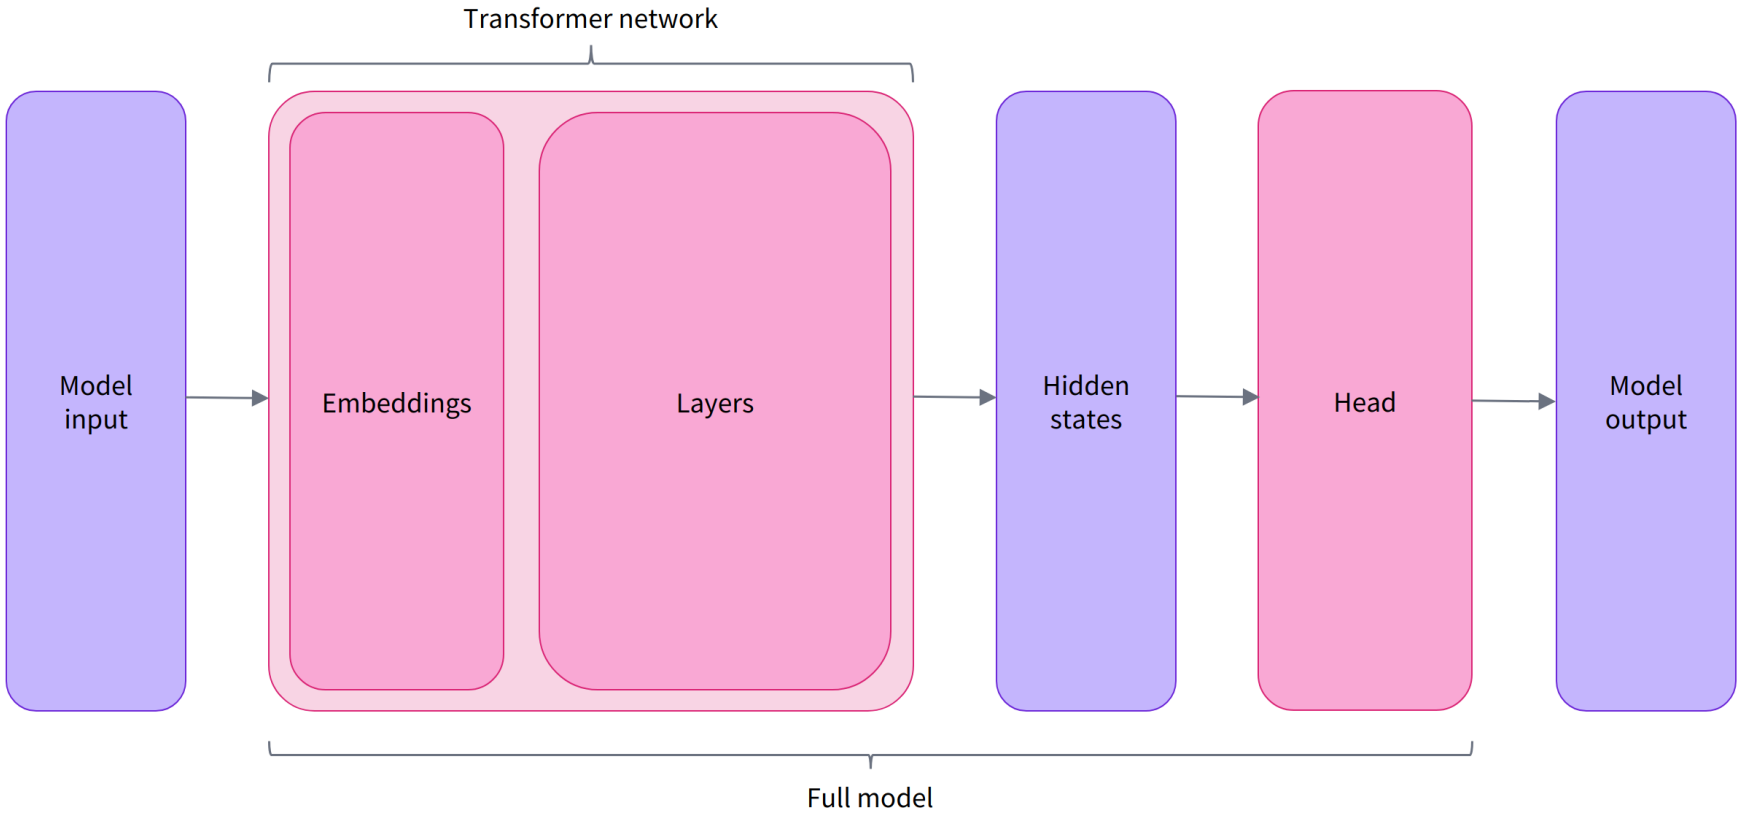
1. Introducción

Librerías para trabajar con textos - Spacy



1. Introducción

Librerías para trabajar con textos - HuggingFace



2. Técnicas y terminología básica de NLP

2. Técnicas y terminología básica de NLP

Procesado de Lenguaje Natural, Natural Language Processing (NLP)

"Un lenguaje natural es una forma de lenguaje humano con fines comunicativos que tiene asociadas una serie de reglas sintácticas, conocidas como sintaxis"



Lenguajes formales

- Ej. Lenguajes de programación
- Artificiales
- Utilizados en aplicaciones específicas
- Sintaxis

VS

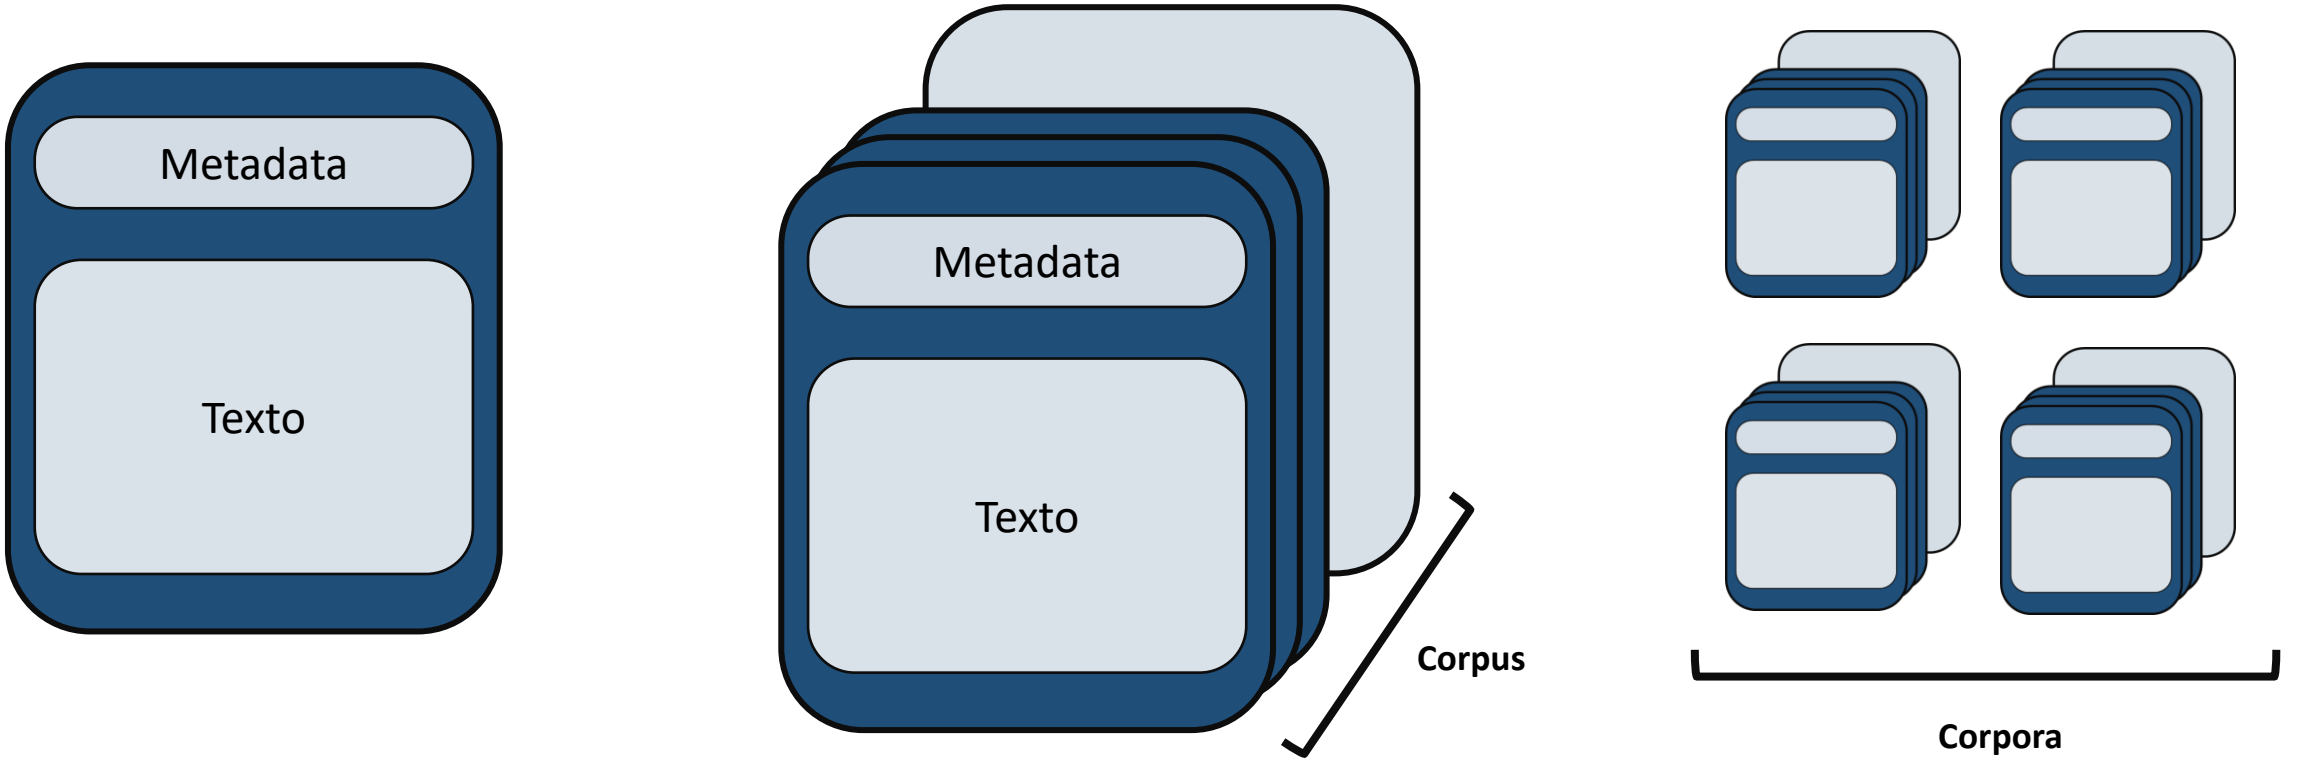


Lenguajes naturales

- Ej. Español, Inglés, …
- Naturales, evolución de otros
- Comunicación entre humanos
- Sintaxis y **semántica**

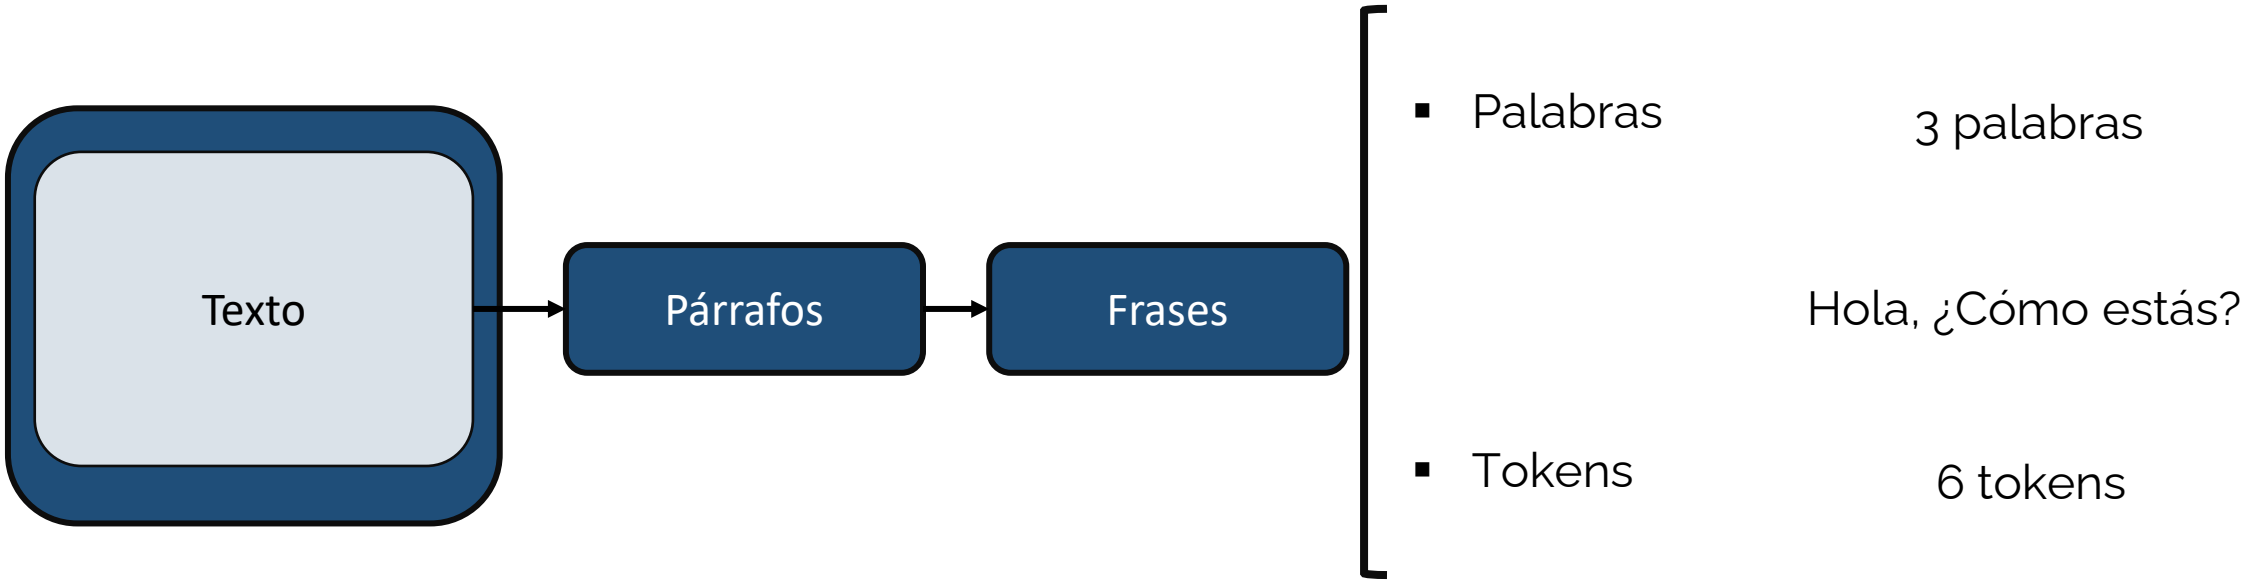
2. Técnicas y terminología básica de NLP

Corpora



2. Técnicas y terminología básica de NLP

Tokens



2. Técnicas y terminología básica de NLP

Lexicon y stopwords

Lexicon o vocabulario

Texto 1

los, estudiantes, aprenden, procesamiento, de, lenguaje, natural

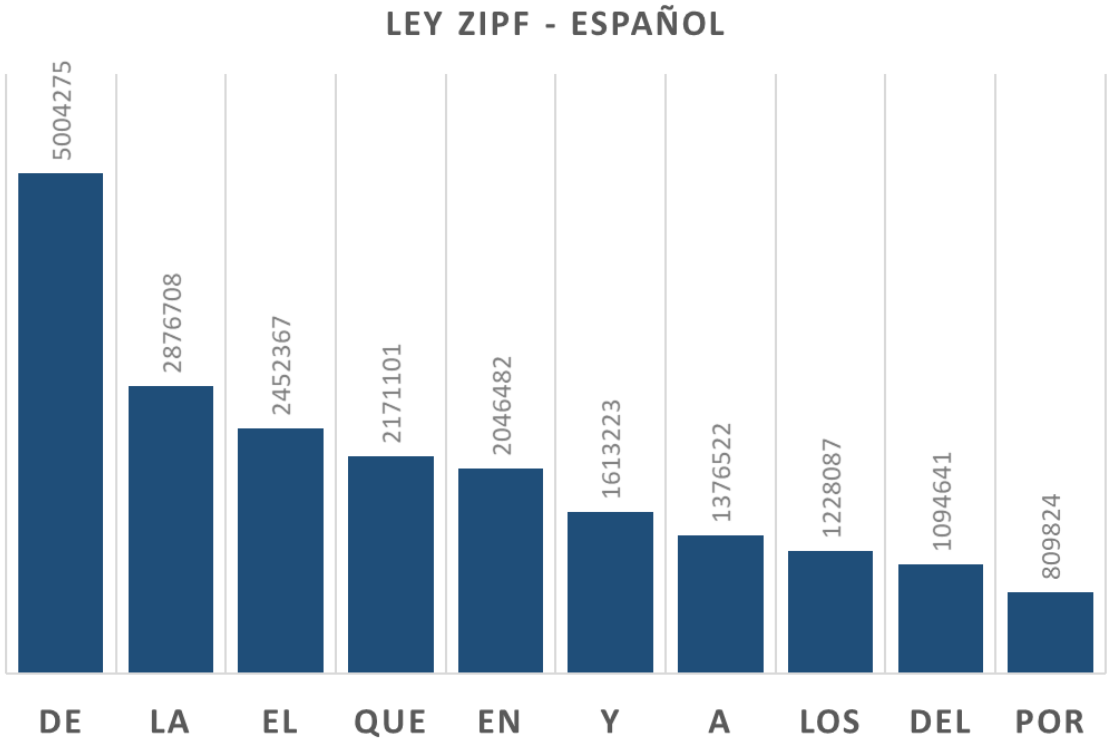
Texto 2

el, procesamiento, de, lenguaje, natural, permite, que, los, estudiantes, entiendan, mejor, los, textos

Lexicon

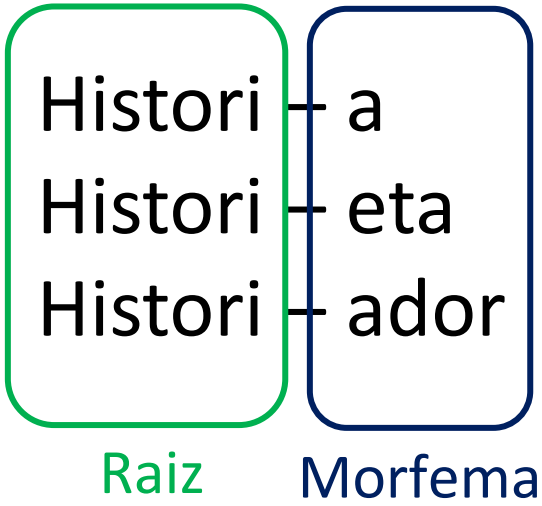
aprenden, de, el, entiendan, estudiantes, lenguaje, los, mejor, natural, permite, procesamiento, que, textos

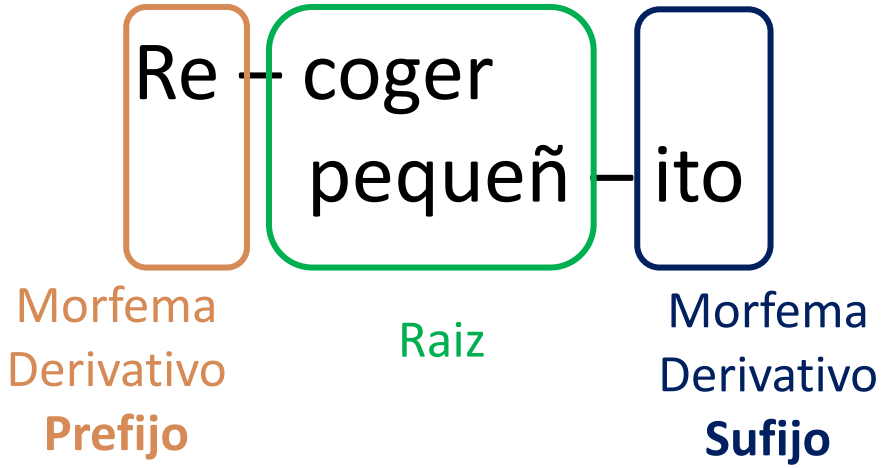
Stopwords



2. Técnicas y terminología básica de NLP

Lexemas/Lemas y morfemas





Los morfemas aportan más significado a los lexemas, a costa de incrementar la dimensionalidad de los datos y en ocasiones que los modelos aprendan peor.

¿Solución? Eliminar los morfemas

2. Técnicas y terminología básica de NLP

Stemming y Lemmatization

Stemming

Uso de reglas sintácticas para eliminar stems

Ej: Porter Stemming o Snowball Stemming

Original form	Stemmed form
Speaking	Speak
Speaks	Speak
Speaker	Speak
Bus	Bus
Buses	Buse

Lematización

Búsqueda de lemas a partir de diccionarios jerárquicos o similar

Ej: WordNetLemmatizer() o Spacy

Original form	Lemmatized form
Computes	Compute
Computing	Compute
Computed	Compute

2. Técnicas y terminología básica de NLP

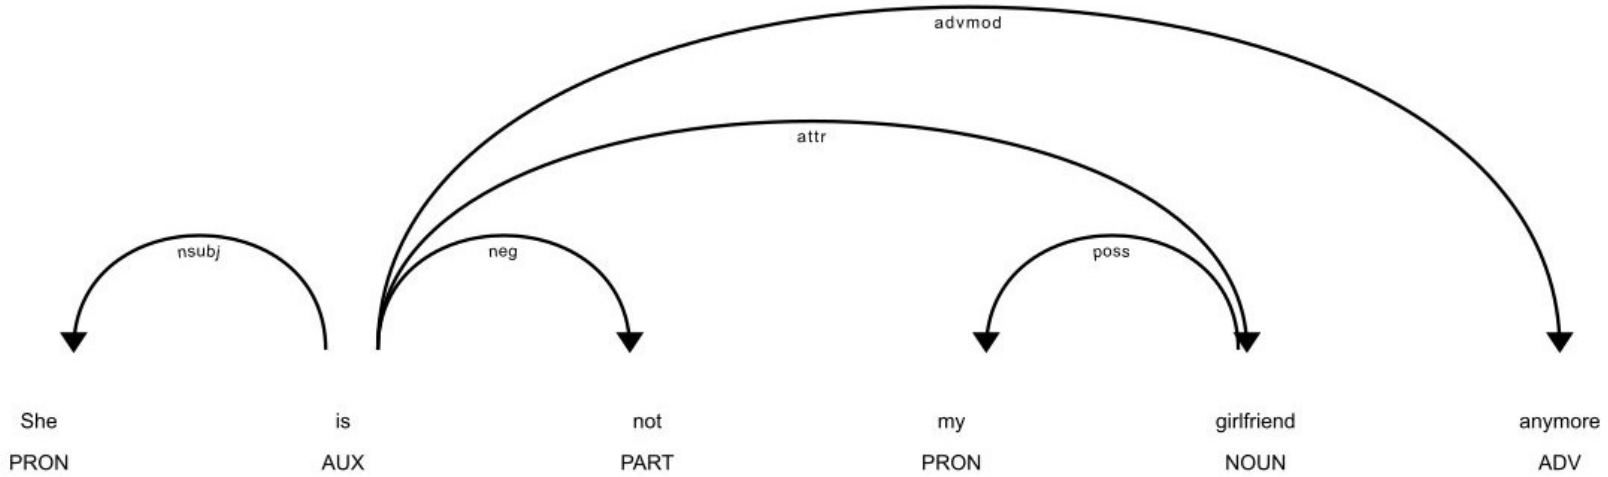
PoS y Parsing

PoS = Part-of-Speech (Categoría gramatical)

Parsing = Análisis sintáctico

She is not my girlfriend anymore

text	lemma_	pos_	tag_
She	she	PRON	PRP
is	be	AUX	VBZ
not	not	PART	RB
my	my	PRON	PRP$
girlfriend	girlfriend	NOUN	NN
anymore	anymore	ADV	RB



2. Técnicas y terminología básica de NLP

PoS y Parsing

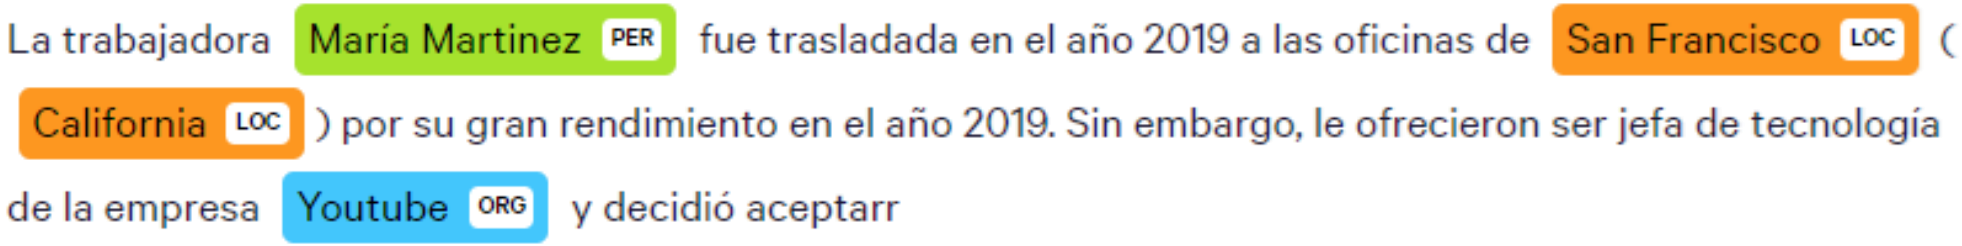
Las categorías gramaticales de las palabras son de utilidad para varias tareas en el Text Mining:

- Information Retrieval
- Information Extraction
- Clasificación
- Topic Modeling

2. Técnicas y terminología básica de NLP

Named-Entity Recognition

La trabajadora María Martínez fue trasladada en el año 2019 a las oficinas de San Francisco (California) por su gran rendimiento en el año 2019. Sin embargo, le ofrecieron ser jefa de tecnología
de la empresa Youtube y decidió aceptar.



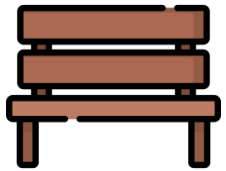
2. Técnicas y terminología básica de NLP

Semántica

Semántica

Rama que estudia el significado de las palabras, así como las diversas relaciones de sentido que se establecen entre ellas.

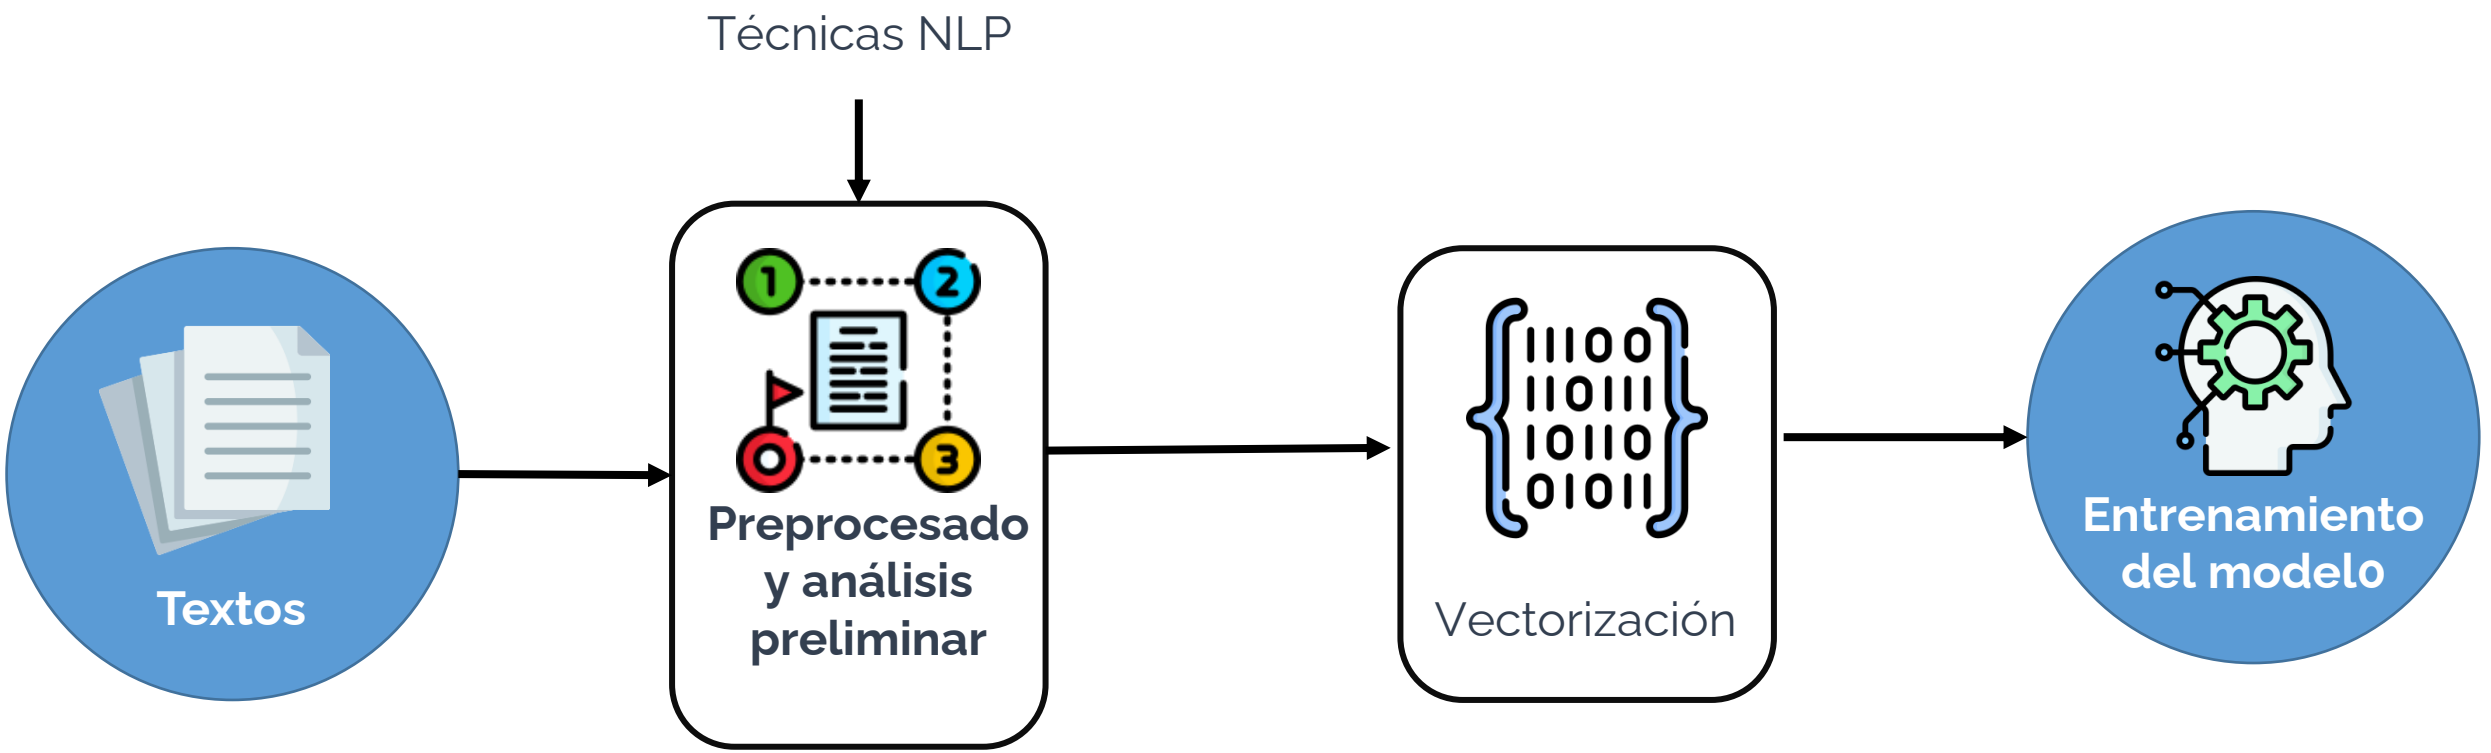
Vamos al banco, estoy cansado





Collab 1 – Técnicas NLP

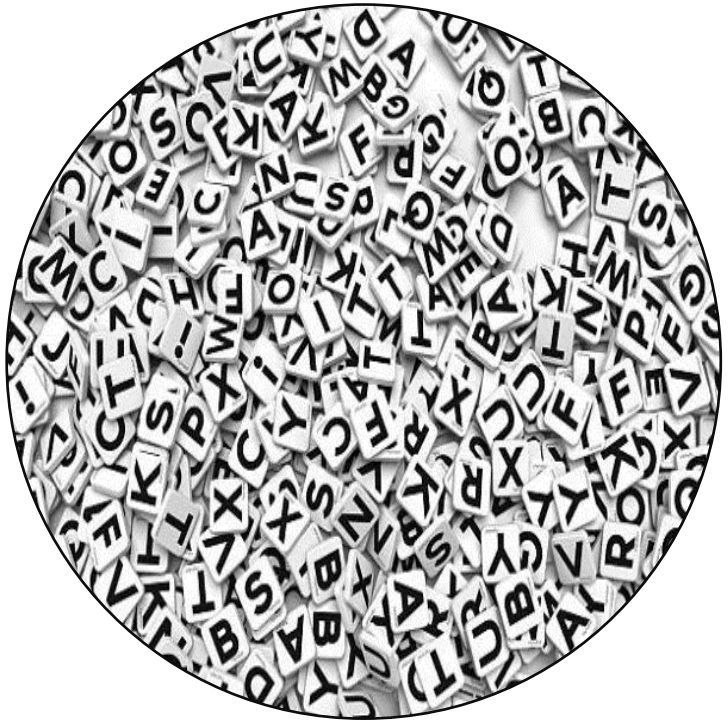



Técnicas NLP
Textos
Preprocesado y análisis preliminar
Vectorización
Entrenamiento del modelo

3. Representación numérica de textos



3. Representación numérica de textos



Representación textual

Representación numérica en un Vector Space Model

	0	0	0	
	0	0	0	11.0
0	0	9.0	0	0
6.0	0	0	0	0
0	7.0	0	0	0
0	0	0	10.0	0
	8.0	0	0	0
	0	0	0	

3. Representación numérica de textos



Cada palabra está representada por un vector

Comparar significados entre palabras, entrenar sistemas para extraer información de textos



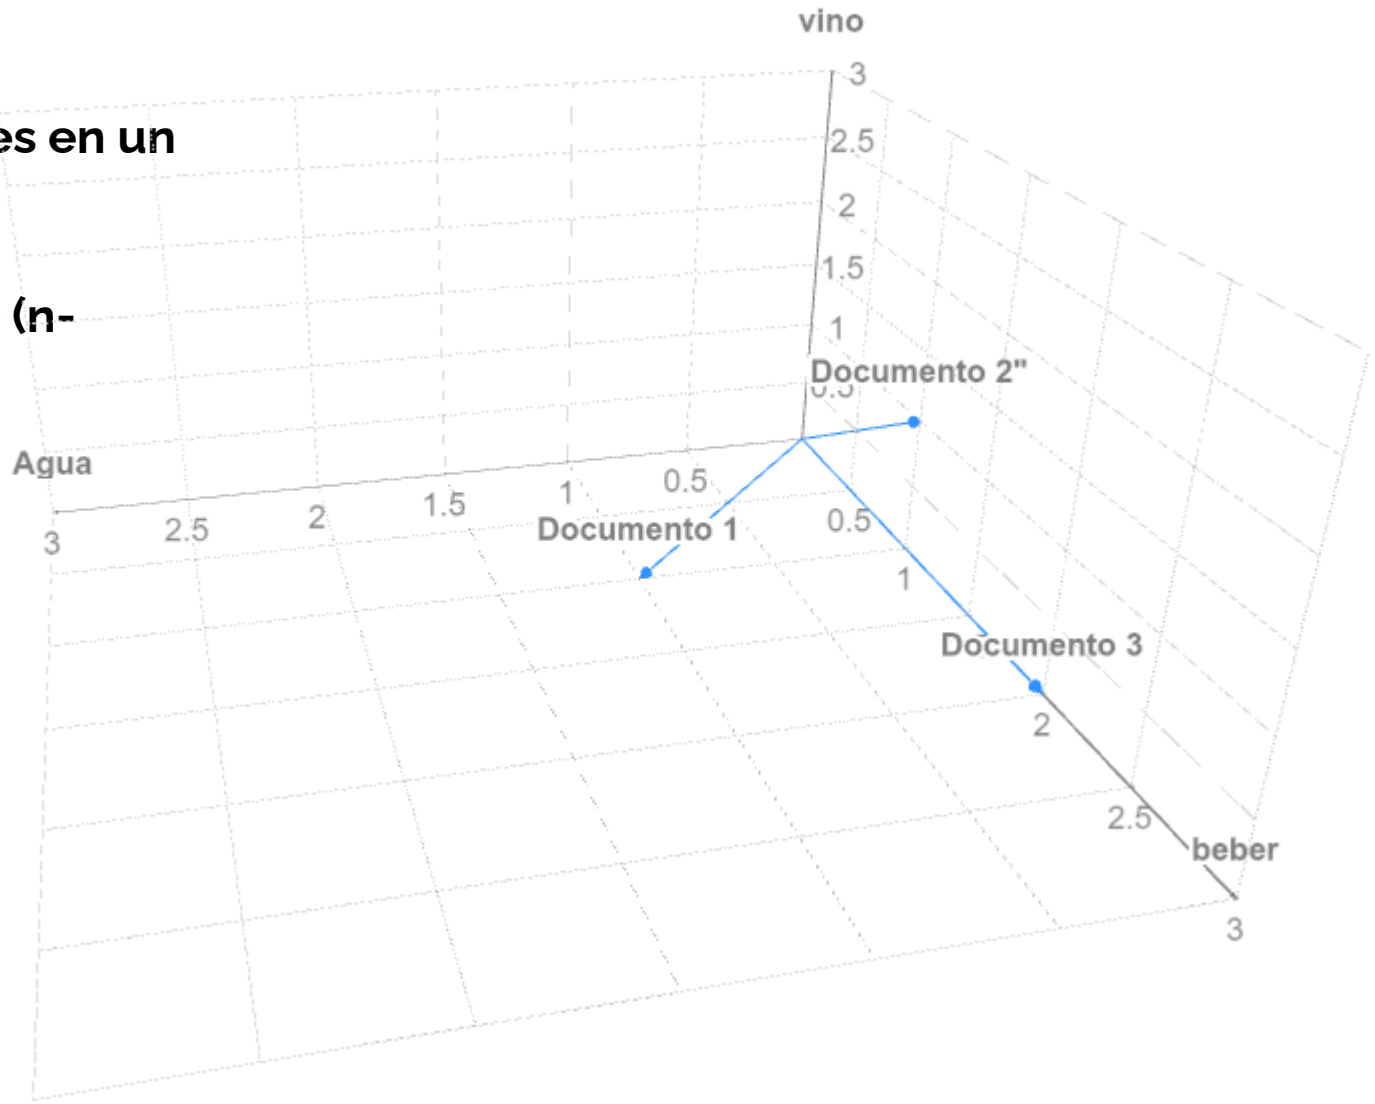
Todo el documento está representado con un único vector

Clasificar textos o agrupar por temas

3. Representación numérica de documentos textuales

Intuición

- **Representar documentos como vectores en un espacio n-dimensional**
  - **Difícil de representar gráficamente (n-dimensional)**
- **Ejemplo:**
  - Documento 1: “Beber agua”
  - Documento 2: “Beber vino”
  - Documento 3: “Beber beber”



Fuente de la imagen: LINK



Bag of Words

TF-IDF

Nivel de documento



Embeddings

Nivel de palabra o documento

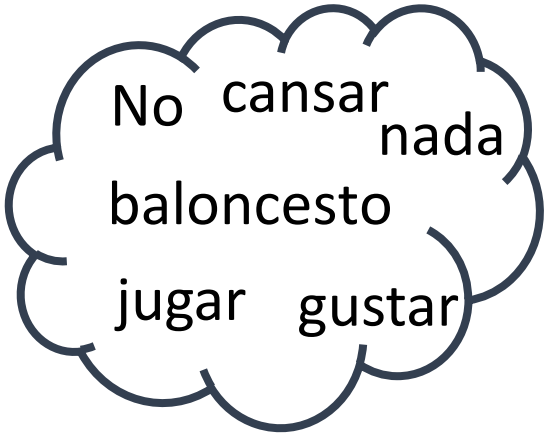
3. Representación numérica de documentos textuales

Bolsa de Palabras – *Bag of Words*

Método de representación del texto basado en la aparición de palabras de un vocabulario en un documento

Se llama bolsa de palabras porque se pierde el orden de aparición de estas.

No me gusta nada jugar al baloncesto, me cansa mucho.



3. Representación numérica de documentos textuales

Bolsa de Palabras – *Bag of Words*

1. Corpus

"Yo quiero agua"

"Yo quiero cocacola"

"Yo quiero agua y un agua"

"Yo no quiero vino"

"Yo quiero un entrecot"

2. Vocabulario

"agua"
"cocacola"
"entrecot"
"no"
"quiero"
"un"
"vino"
"yo"

3. Vectorización

agua cocacola ... vino yo

[1 0 0 0 1 0 0 1]

[0 1 0 0 1 0 1 1]

[2 0 0 0 1 1 0 1]

[0 0 0 1 1 0 1 1]

[0 0 1 0 1 1 0 1]

3. Representación numérica de documentos textuales

Bolsa de Palabras – *Bag of Words*

PROS

- Fácil de implementar y de interpretar

CONS

- Grande sparse vectors cuando el vocabulario es muy numeroso
- No existen relaciones semánticas entre las palabras del documento
- La interpretación de que las palabras más frecuentes son las más importantes, puede fallar (i.e. stopwords)

3. Representación numérica de documentos textuales

Bolsa de Palabras – *Bag of Words*

Recomendaciones:

- Transformación de tokens a minúscula
- Ignorar los signos de puntuación
- Ignorar stop-words
- Normalizar palabras
- Lematizar o Stemming



Bag of Words

TF-IDF

Nivel de documento



Embeddings

Nivel de palabra o documento

3. Representación numérica de documentos textuales

Term Frequency – Inverse Document Frequency

Método de representación del texto que penaliza las palabras comunes en muchos documentos

$$TF(w) = \frac{n_{w\ in\ d}}{N_d}$$

$n_{w\ in\ d}$ → Nº veces termino w aparece en documento d
N_d → Nº de tokens en document d

Las palabras más importantes tendrán un índice mayor

$$IDF(w) = \ln \frac{N}{n_w}$$

n_w → Nº documentos que contiene el token w
N → Nº total de documentos del corpus

Las palabras que aparezcan en muchos documentos tendrán un índice menor

3. Representación numérica de documentos textuales

Term Frequency – Inverse Document Frequency

Recomendaciones:

- Transformación de tokens a minúscula
- Ignorar los signos de puntuación
- Ignorar stop-words
- Normalizar palabras
- Lematizar o Stemming

Collab 2 – Representación de textos

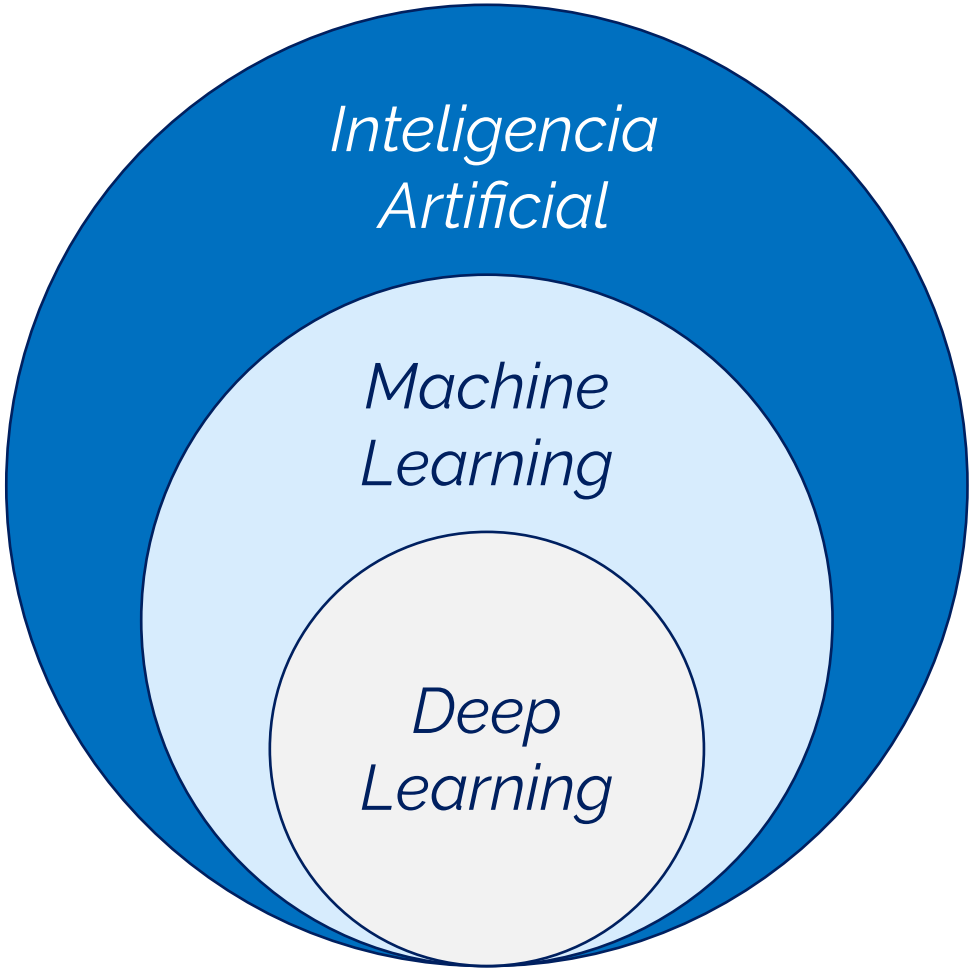


Extra. Introducción a Redes Neuronales



E. ¿Qué es el Deep Learning?

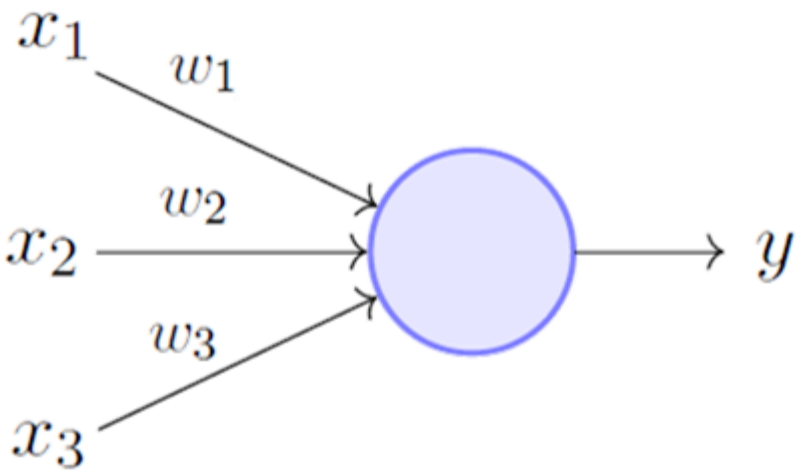
El **Deep Learning** es una rama del Machine Learning que usa **redes neuronales profundas** para aprender los patrones existentes en los datos a partir de muchos ejemplos.

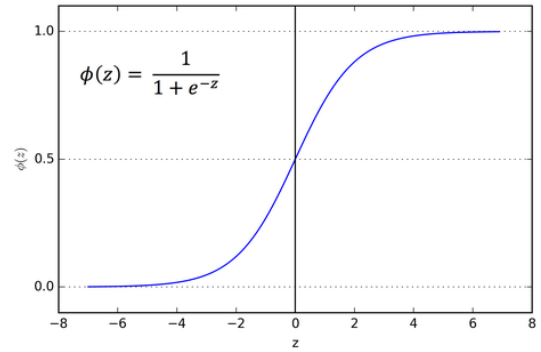


El Deep Learning se enseña a una máquina como se enseña a un niño. Le enseñas ejemplos, y a partir de los errores, se le hace mejorar progresivamente.

E. ¿Qué es el Deep Learning?

Una **neurona artificial** es la unidad básica de una red neuronal, inspirada en las neuronas del cerebro humano. Su función principal es recibir datos, procesarlos y producir una salida.



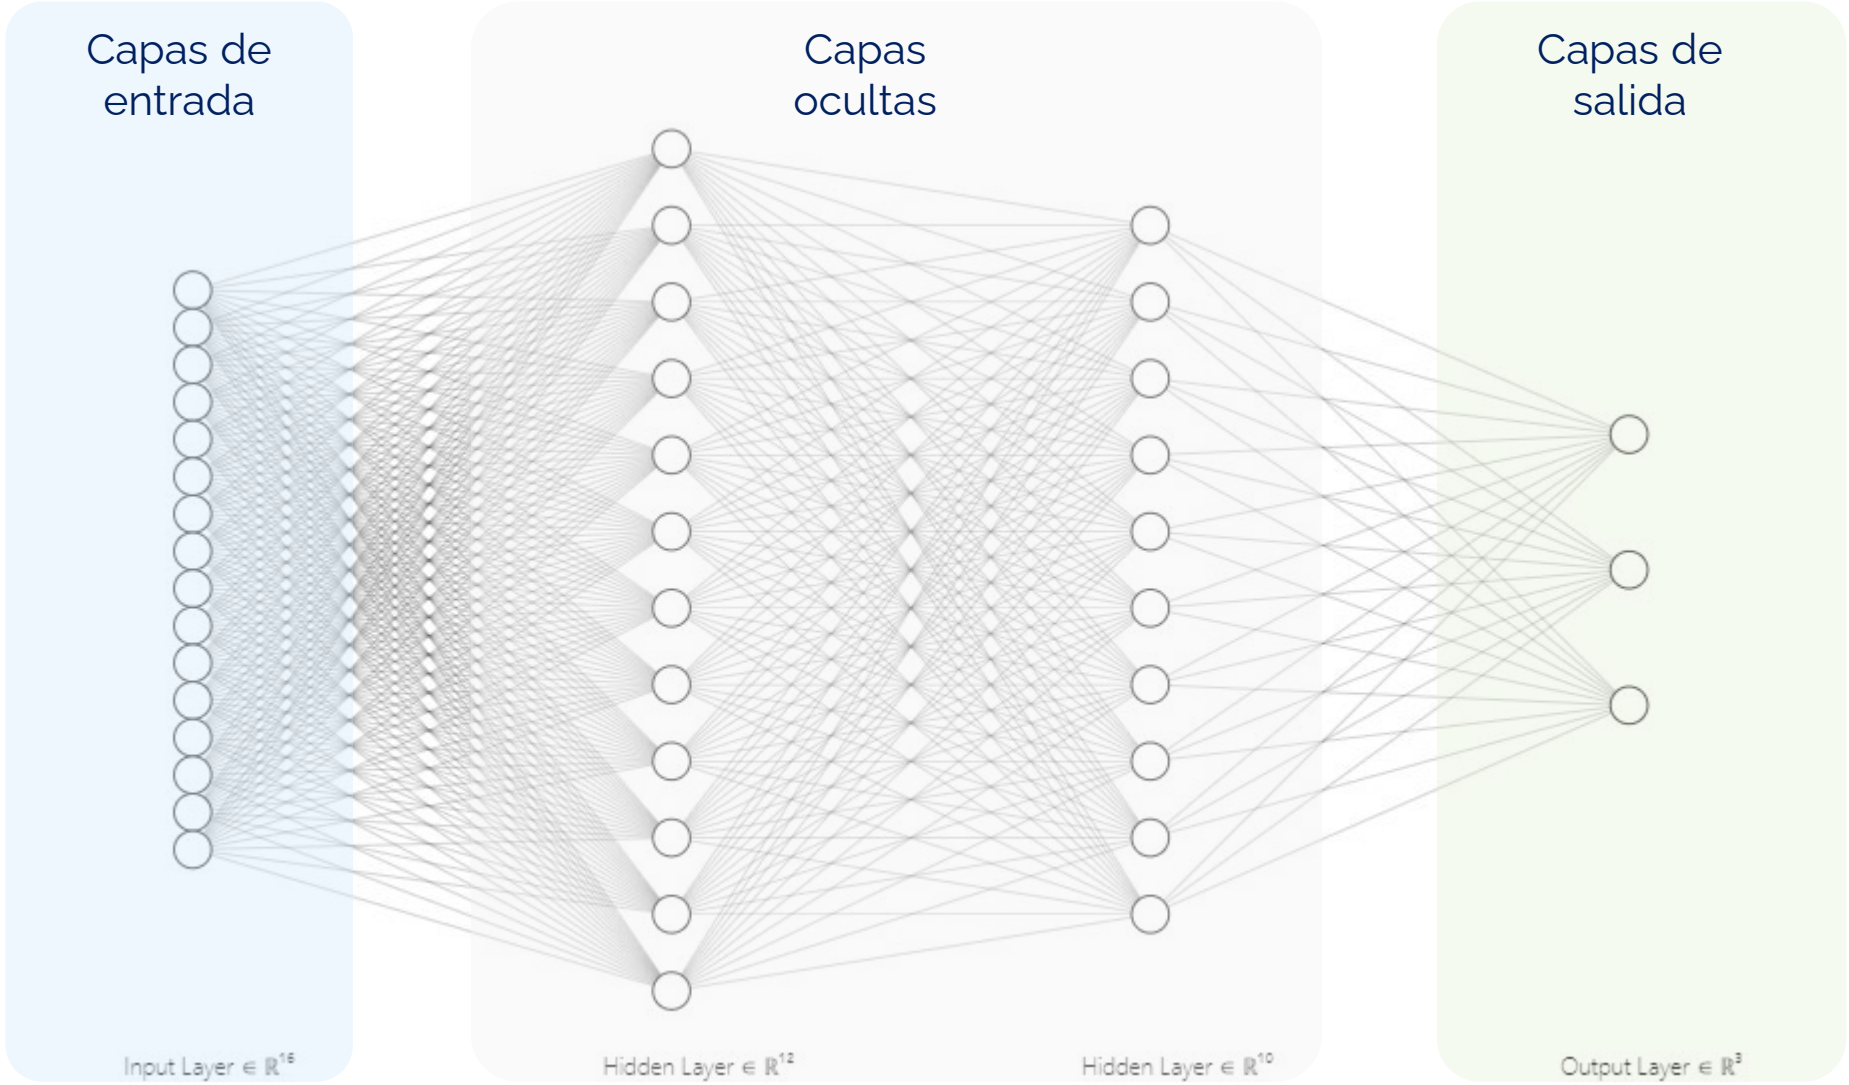


$$\text{Salida} = \sigma\left(\sum_{i=1}^{n} w_i x_i + b\right)$$

Función de activación

- Una **función de activación** transforma la salida de una neurona para que pueda aprender y representar relaciones complejas.
- Sin activación, una red neuronal solo haría combinaciones lineale (como una regresión)
- Define cómo responde la neurona ante la información recibida. Se activa o se apaga

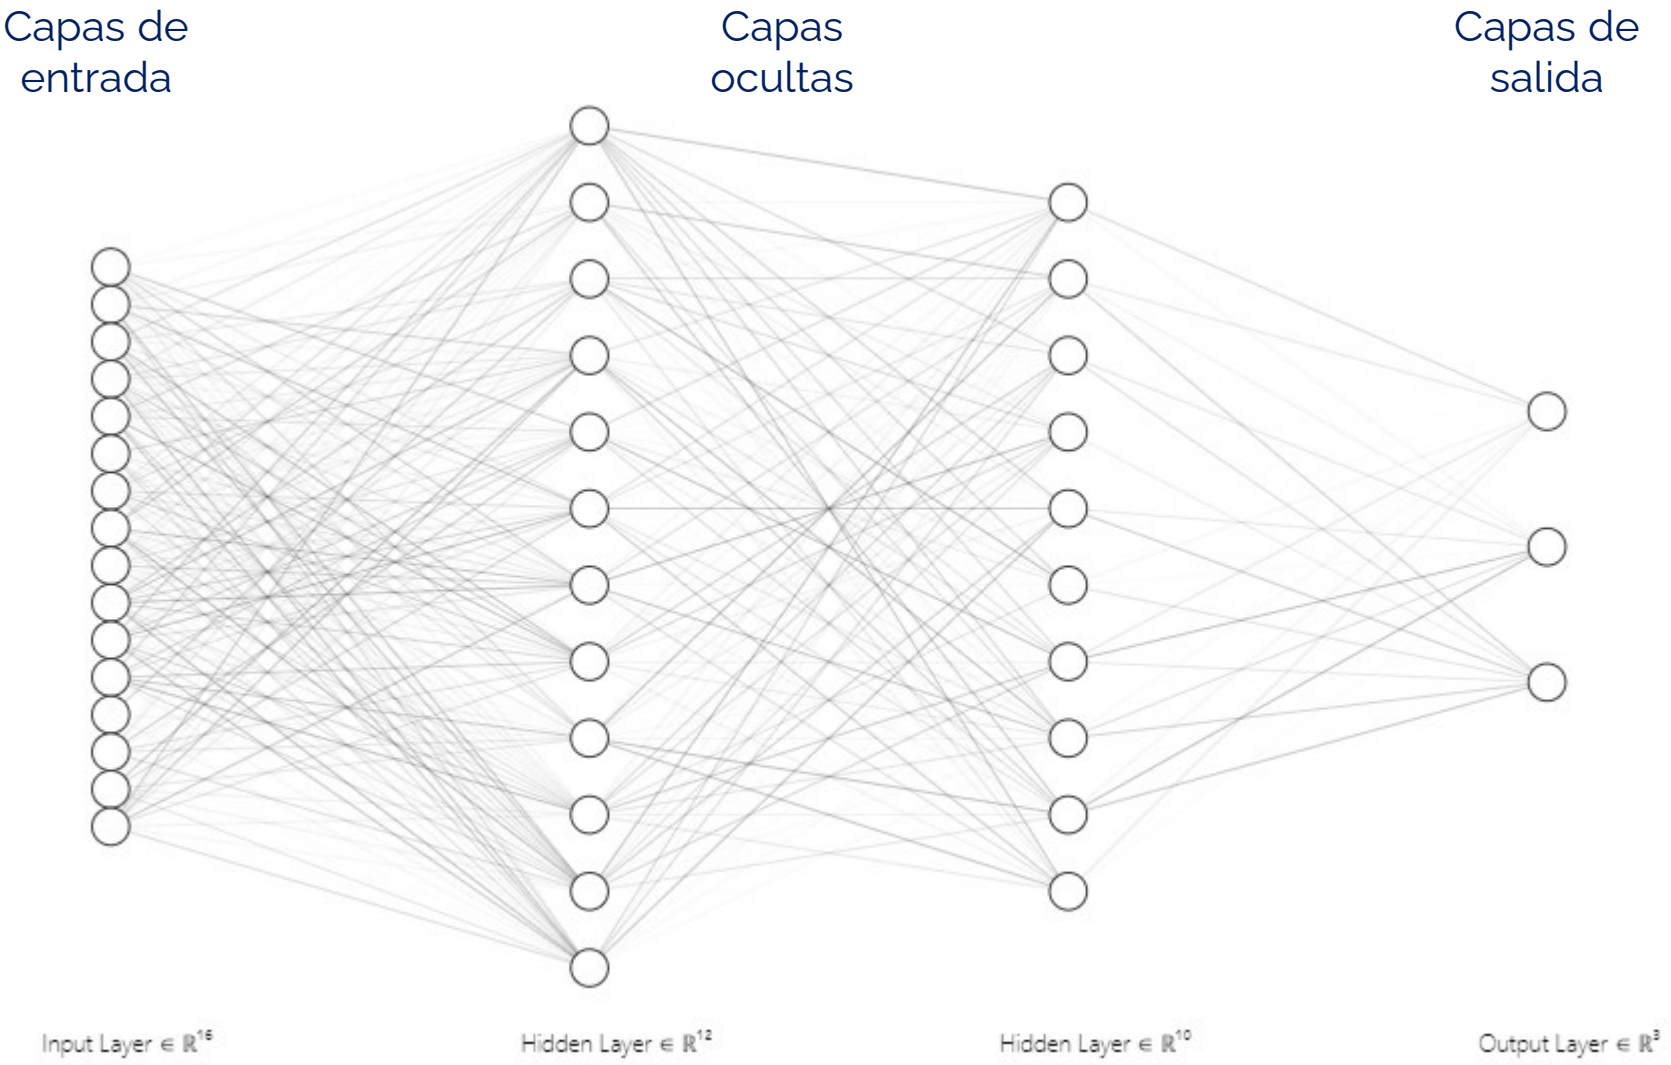
E. ¿Qué es el Deep Learning?



E. ¿Qué es el Deep Learning?

Red entrenada

Algunas neuronas activadas otras no



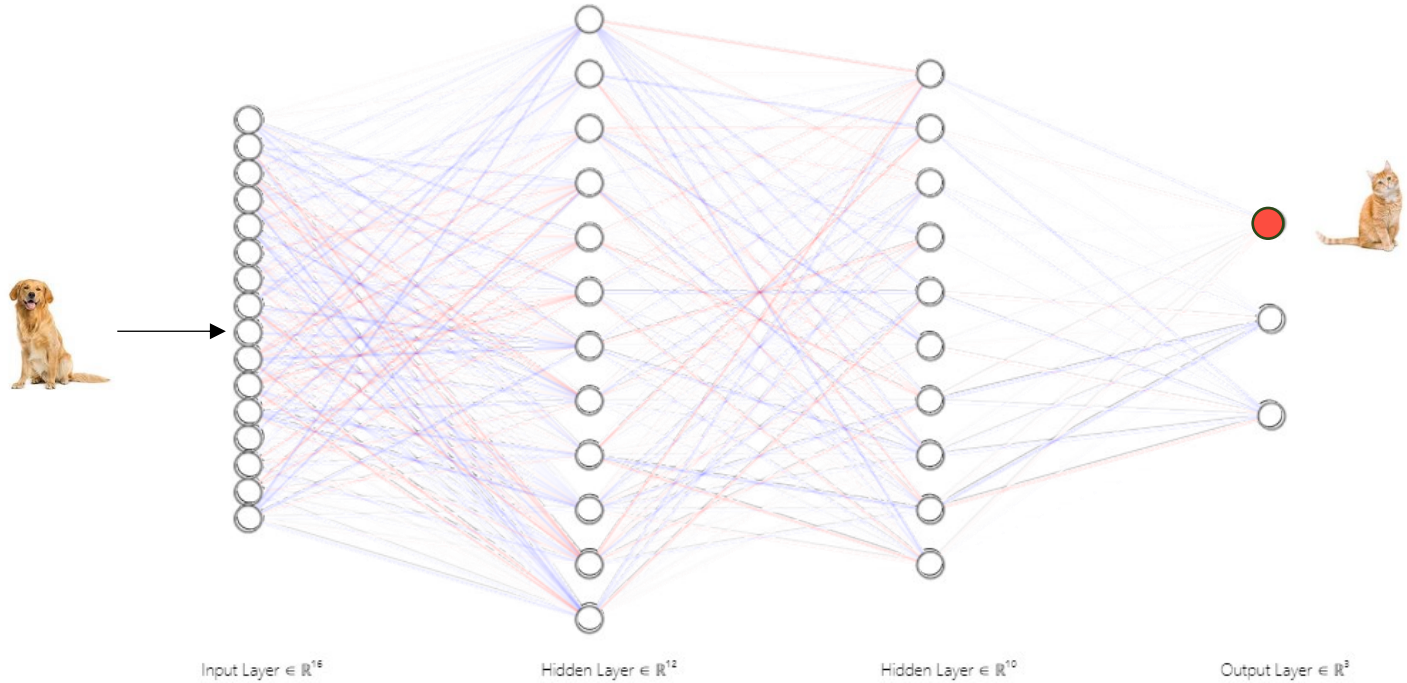
E. ¿Qué es el Deep Learning?

👶 Niño que aprende	🤖 Red neuronal que aprende
Le enseñas con ejemplos ("esto es un perro, esto es un gato")	Le das imágenes etiquetadas como "perro" o "gato"
Se equivoca al principio ("eso es un gato", pero era un perro)	El modelo da una predicción incorrecta
Le corriges ("no, eso era un perro")	Se calcula un error (*función de pérdida*)
Aprende poco a poco con muchas repeticiones	Ajusta sus pesos internos mediante *backpropagation*
Con el tiempo, reconoce bien perros y gatos	Con entrenamiento, mejora su precisión

Loss: (función de pérdida)

L( , ) = 0.7

Forward pass

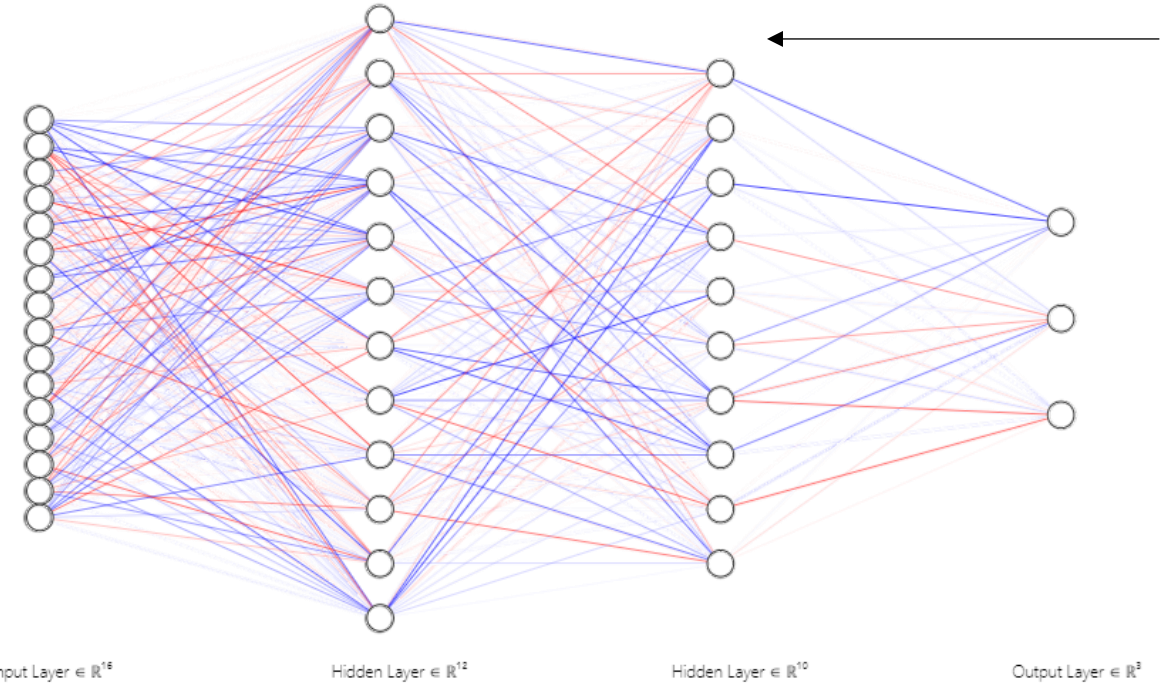


E. ¿Qué es el Deep Learning?

👶 Niño que aprende	🤖 Red neuronal que aprende
Le enseñas con ejemplos ("esto es un perro, esto es un gato")	Le das imágenes etiquetadas como "perro" o "gato"
Se equivoca al principio ("eso es un gato", pero era un perro)	El modelo da una predicción incorrecta
Le corriges ("no, eso era un perro")	Se calcula un error (*función de pérdida*)
Aprende poco a poco con muchas repeticiones	Ajusta sus pesos internos mediante *backpropagation*
Con el tiempo, reconoce bien perros y gatos	Con entrenamiento, mejora su precisión

Loss: (función de pérdida)

L( , ) = **0.7**



Backpropagation

En este proceso el backpropagation calcula cuanto debe corregirse cada peso mediante una derivada (gradiente)

Los pesos se actualizan utilizando una técnica llamada **gradient descent**, que mueve los pesos hacia una dirección donde el error se vaya a minimizar (búsqueda de minimización de los)

La rapidez con la que se hacen estos ajustes depende de un valor llamado **learning rate** (tasa de aprendizaje).

E. ¿Qué es el Deep Learning?

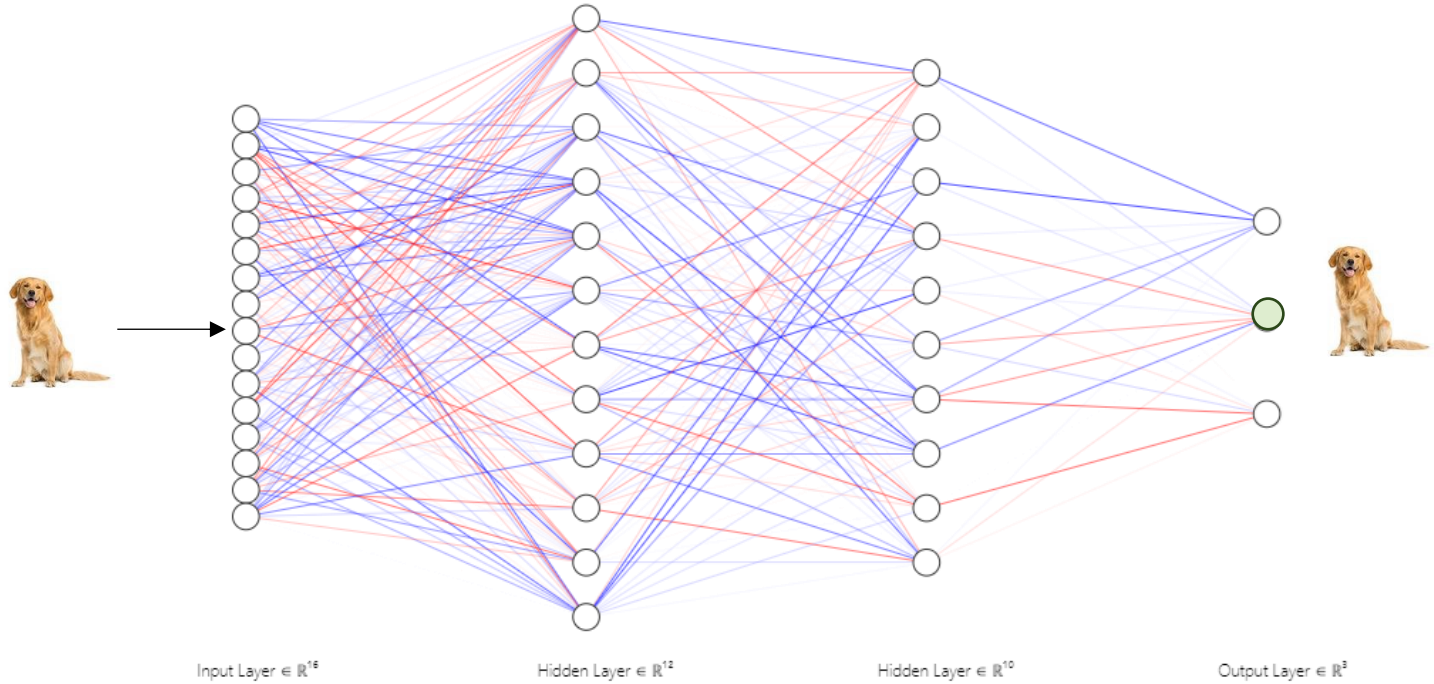
👶 Niño que aprende	🤖 Red neuronal que aprende
Le enseñas con ejemplos ("esto es un perro, esto es un gato")	Le das imágenes etiquetadas como "perro" o "gato"
Se equivoca al principio ("eso es un gato", pero era un perro)	El modelo da una predicción incorrecta
Le corriges ("no, eso era un perro")	Se calcula un error (*función de pérdida*)
Aprende poco a poco con muchas repeticiones	Ajusta sus pesos internos mediante *backpropagation*
Con el tiempo, reconoce bien perros y gatos	Con entrenamiento, mejora su precisión

Loss: (función de pérdida)

L( , ) = 0.1

El objetivo es minimizar la loss

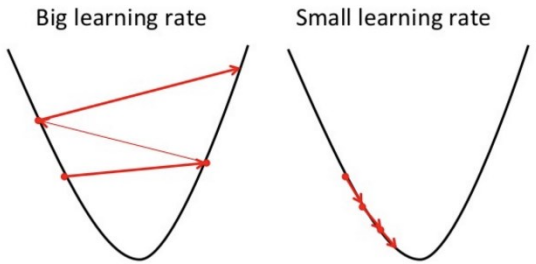
Forward pass

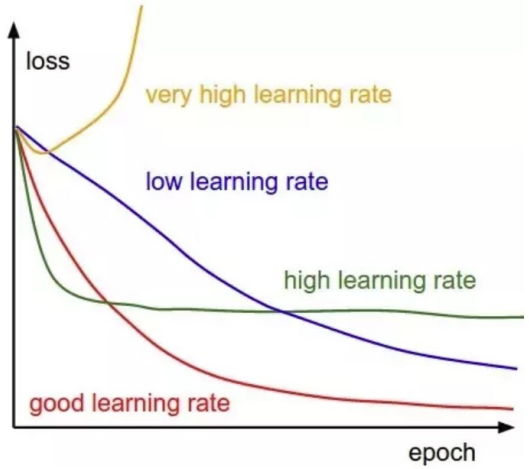


E. ¿Qué es el Deep Learning?

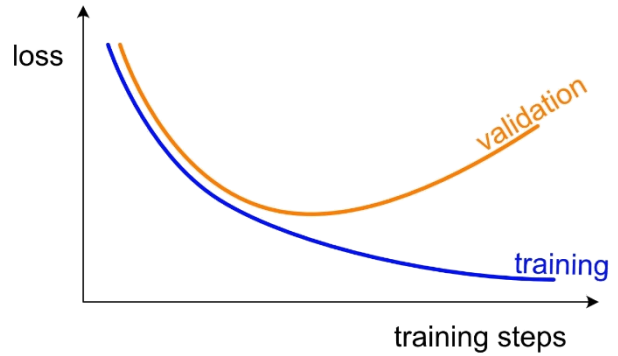
Conceptos clave

- **Epoch (época):** Una pasada completa por todos los datos del conjunto de entrenamiento.
- **Batch:** Un pequeño grupo de ejemplos usados en cada paso de entrenamiento.
- **Learning rate:** La velocidad con la que el modelo ajusta sus parámetros cuando se equivoca. Si el learnign rate es muy alto, la los tendrá picos porque tiene dificultad para llegar a los pesos donde se consigue un mínimo local de Loss.





- **Training set:** Datos que el modelo usa para aprender.
- **Validation set:** Datos que el modelo no ha visto, usados para comprobar si está aprendiendo bien (sin hacer trampa).





Bag of Words

TF-IDF

Nivel de documento



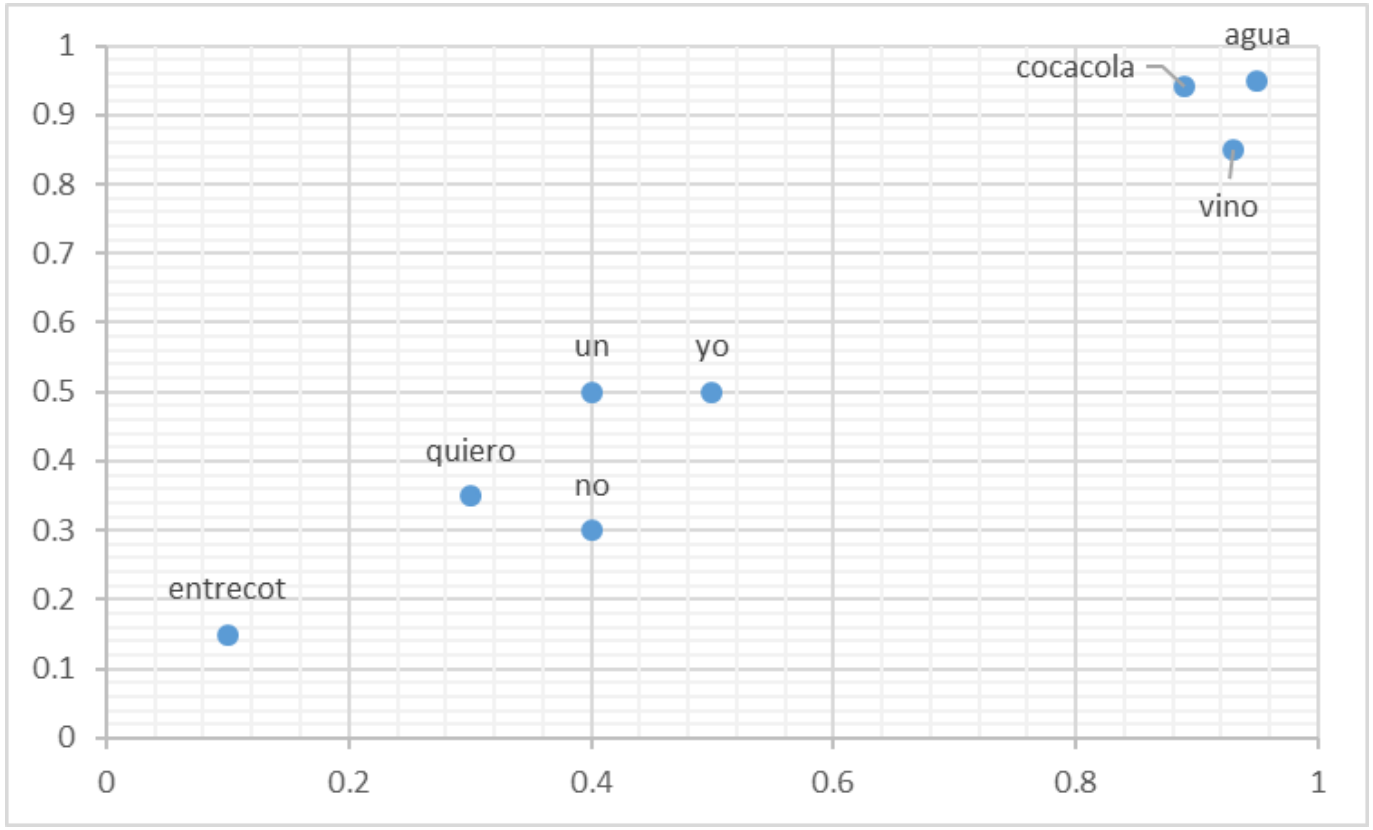
Embeddings

Nivel de palabra o documento

3. Representación numérica de palabras

Embeddings

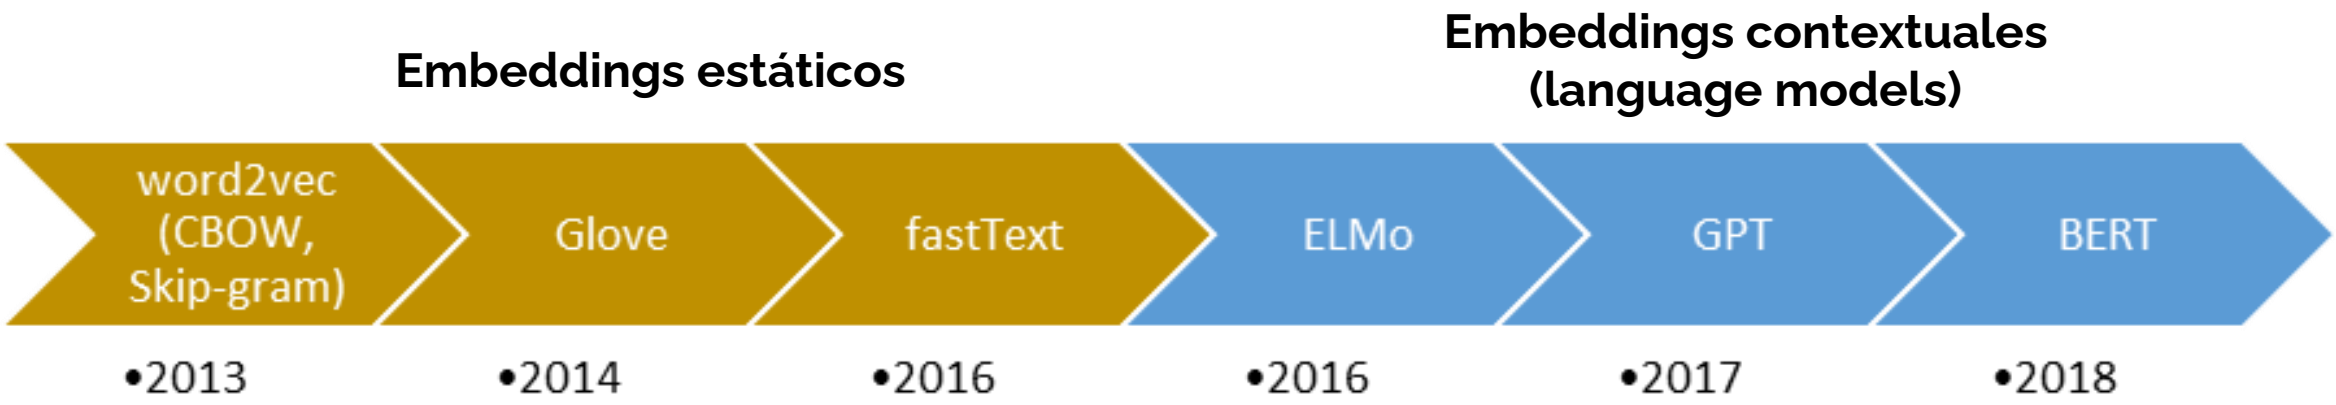
Técnica de modelización de lenguaje que permite representar palabras o documentos mediante vectores que incorporan contenido semántico



Palabras semánticamente parecidas, más cerca en el espacio vectorial

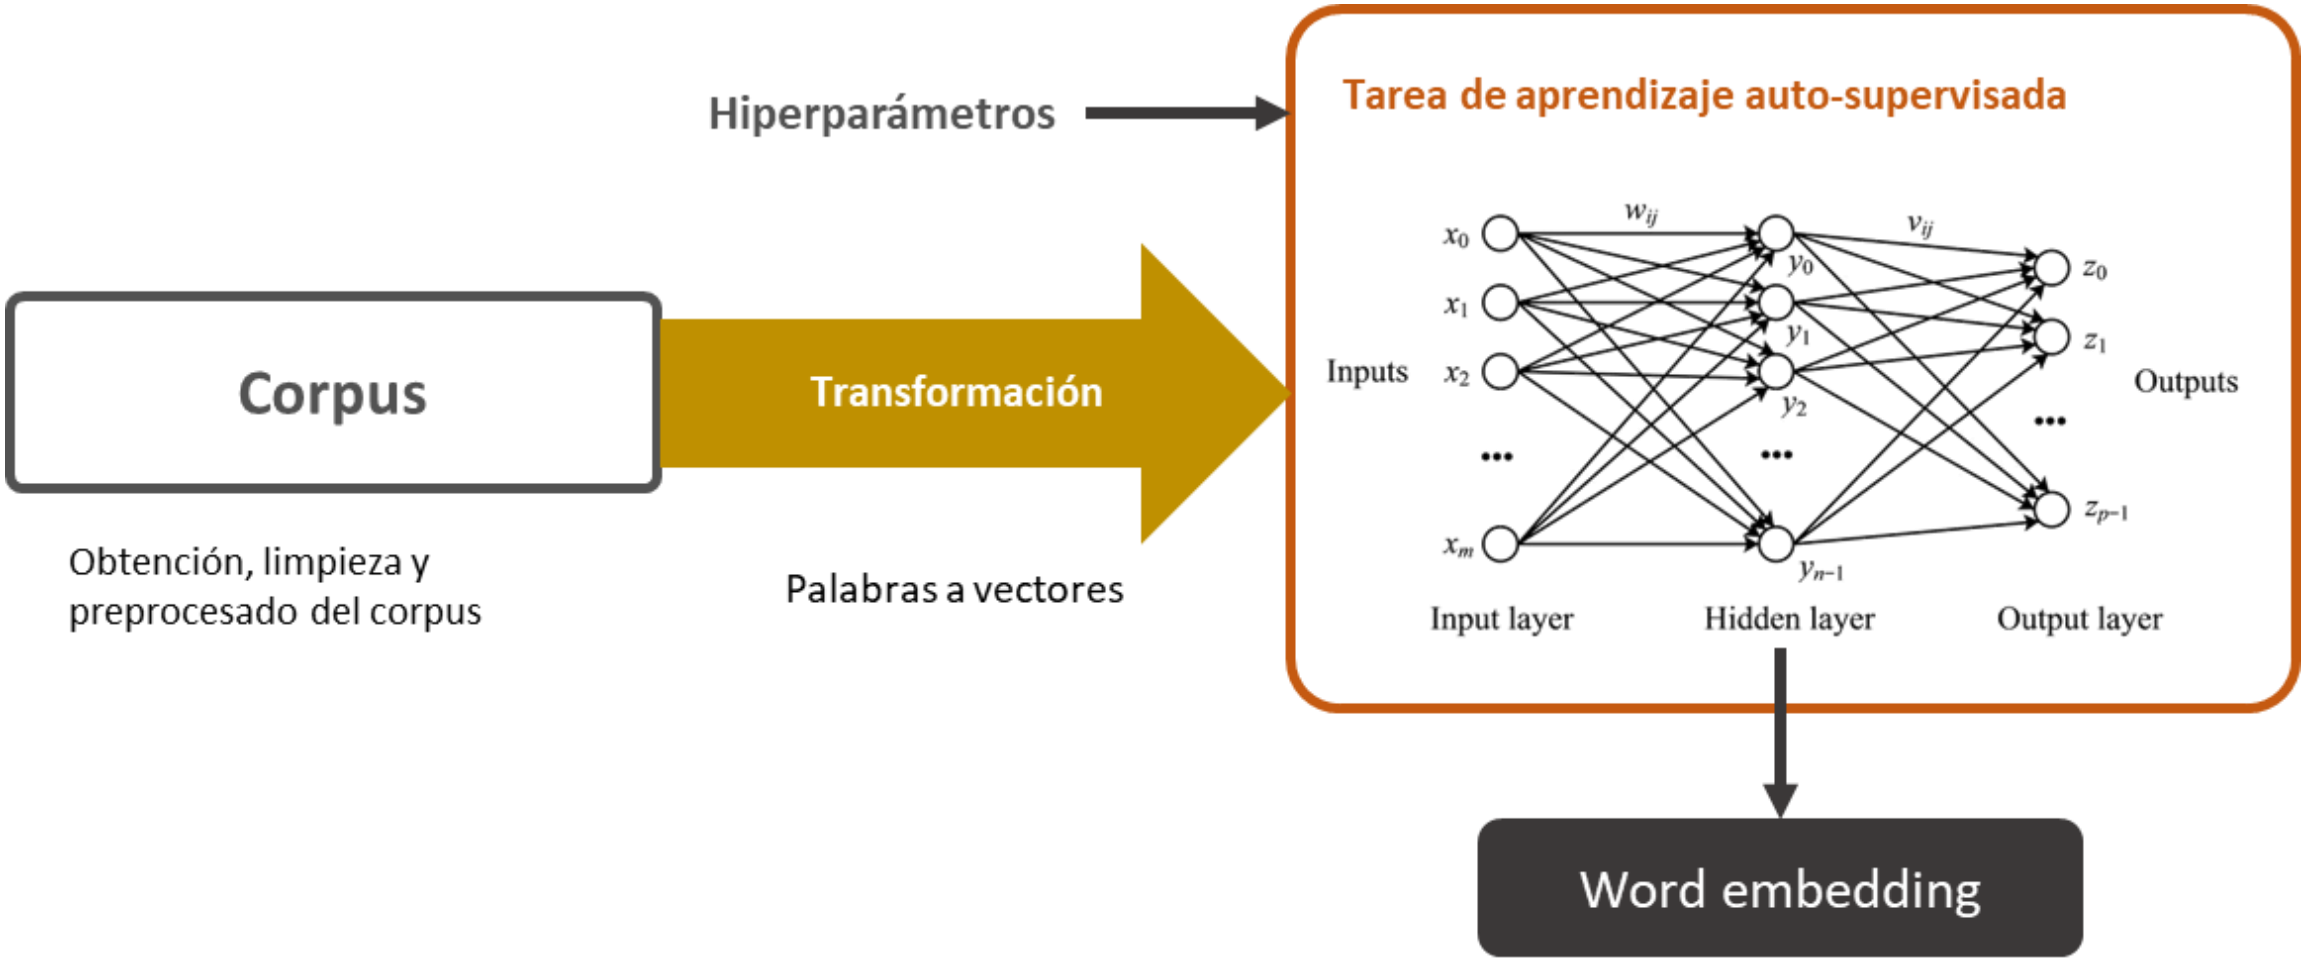
3. Representación numérica de palabras

Word Embeddings



3. Representación numérica de palabras

Embeddings estáticos - Entrenamiento



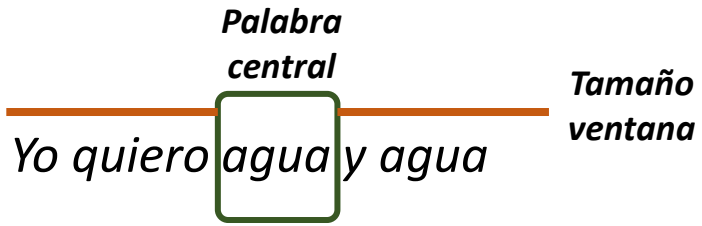
3. Representación numérica de palabras

Embeddings estáticos– Entrenamiento word2vec (CBOW)

Algoritmo de aprendizaje: Predicción de palabras

Preparación de datos:

Yo quiero agua y agua

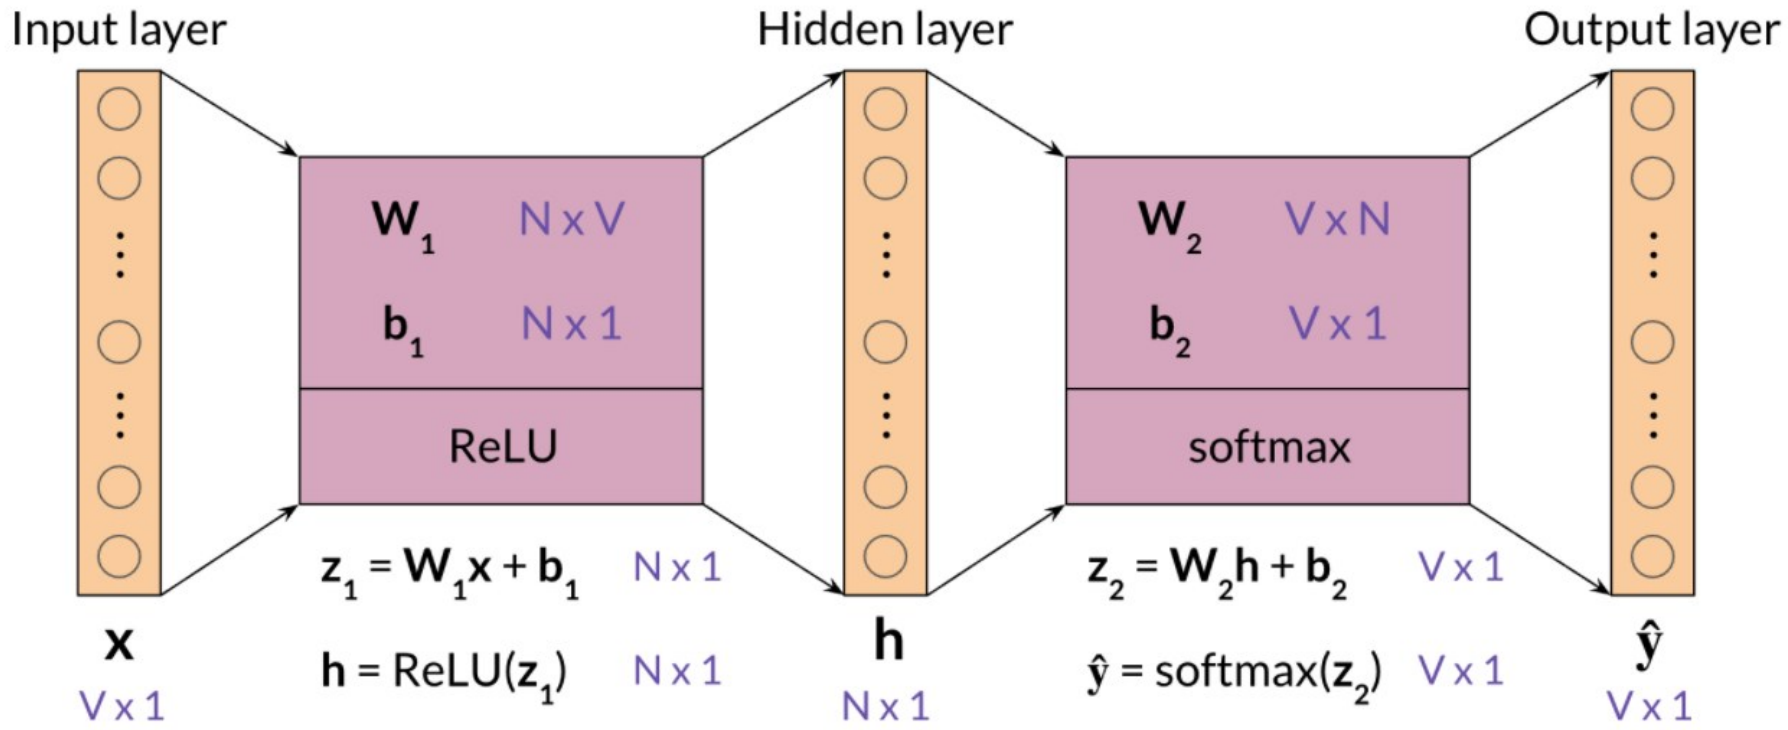


Contexto	***Label***
Yo quiero y agua	*agua*

3. Representación numérica de palabras

Embeddings estáticos– Entrenamiento word2vec (CBOW)

Entrenamiento: Predicción de palabras usando DL



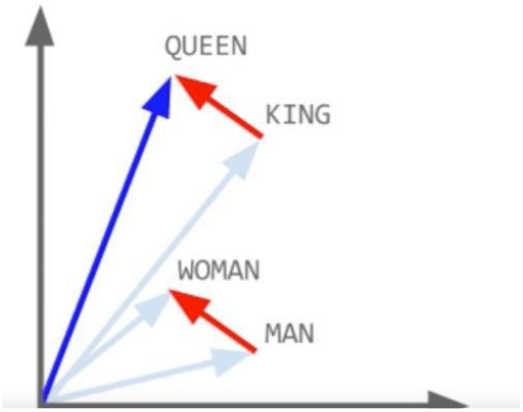
Embedding: Valor medio matrices de pesos W1 y W2

Source: C2 - Natural Language Processing with Probabilistic Models of the Natural Language Specialisation. DeepLearning.AI

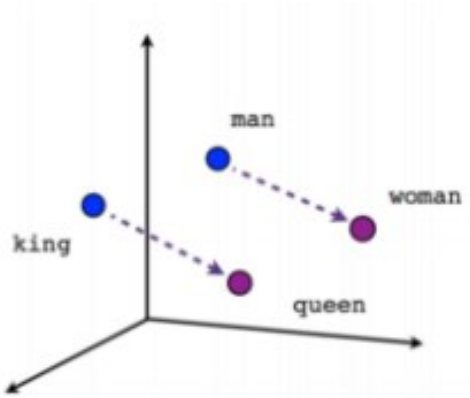
3. Representación numérica de palabras

Embeddings estáticos– Resultado word2vec (CBOW)

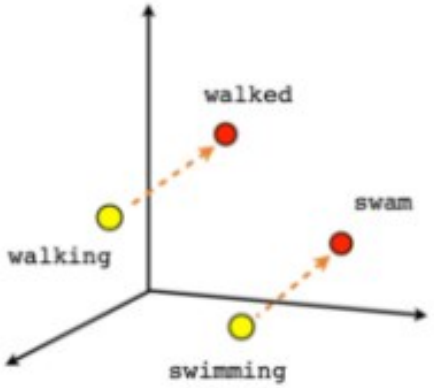
Aparecen relaciones semánticas en el espacio multidimensional



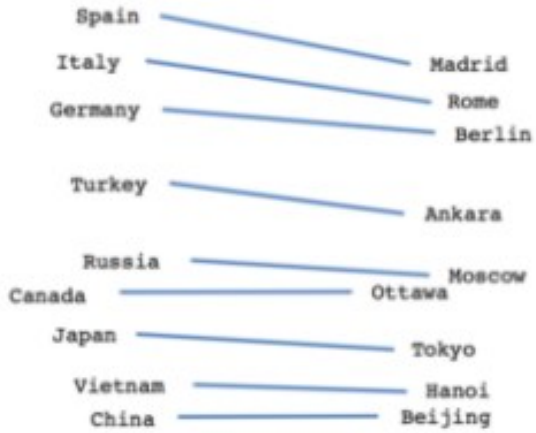
King – man + woman = Queen



Male-Female



Verb tense



Country-Capital

3. Representación numérica de palabras

Embeddings estáticos– Validación word2vec (CBOW)



Clustering

Visualización



Aplicación en tareas de NLP

3. Representación numérica de documentos textuales

Embeddings estáticos–word2vec (CBOW)

PROS

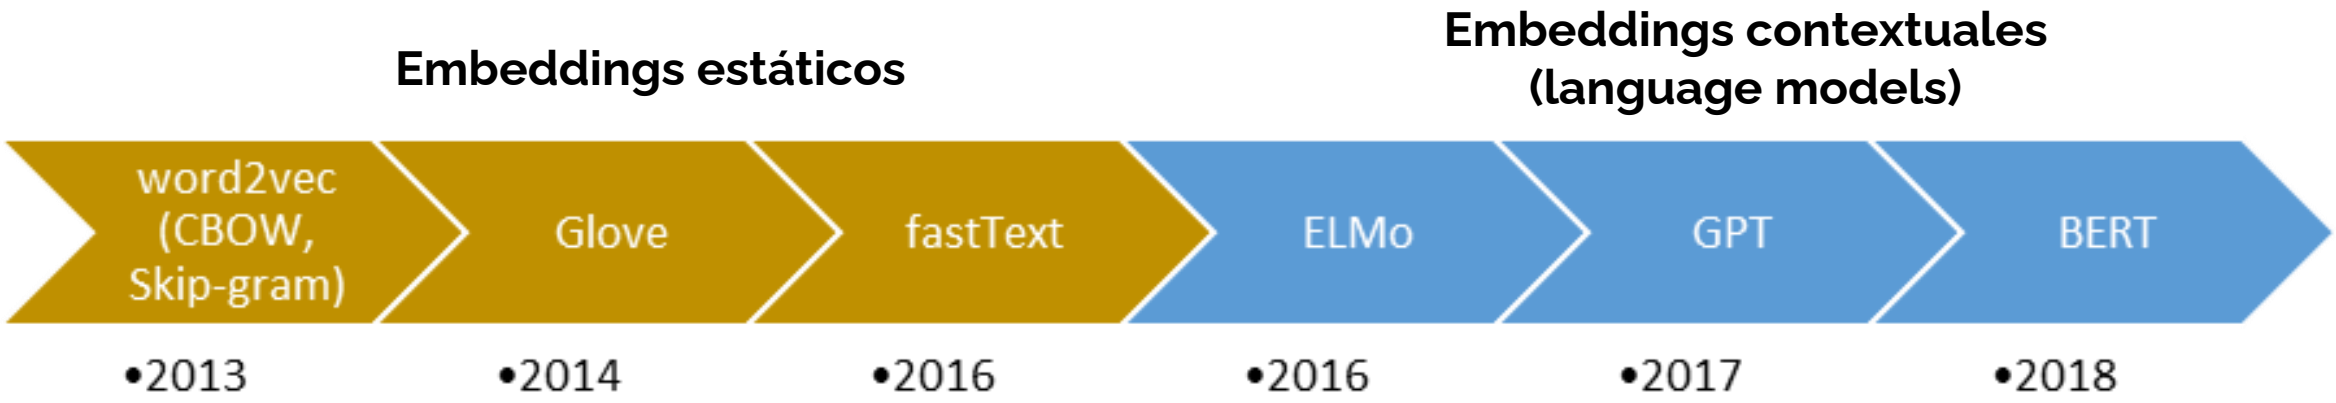
- Capaz de capturar relaciones semánticas y sintácticas entre palabras
- Vectores pequeños
- No es necesario esfuerzos de etiquetado

CONS

- No maneja bien las palabras no presentes en el vocabulario (les da valor aleatorio)
- La representación de una palabra se basa solamente en sus vecinos y no captura la polisemia de las palabras
- Requiere corpus grandes para el entrenamiento
- **No representa la polisemia de las palabras**

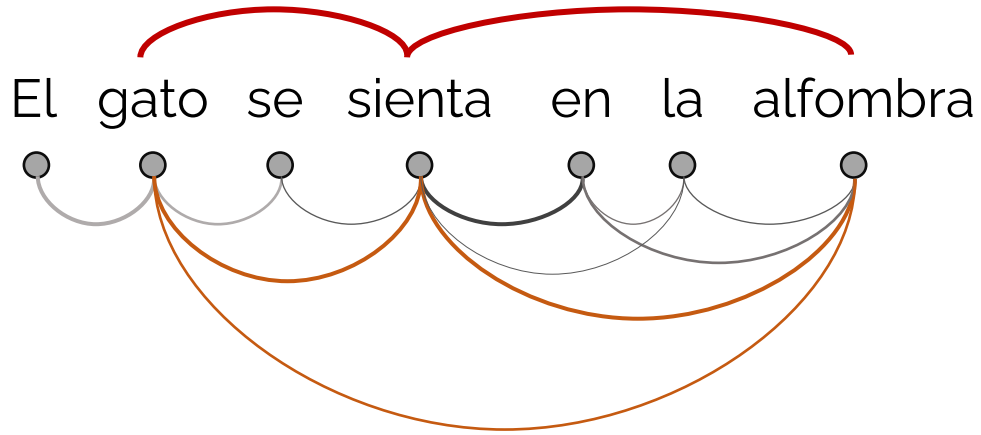
3. Representación numérica de palabras

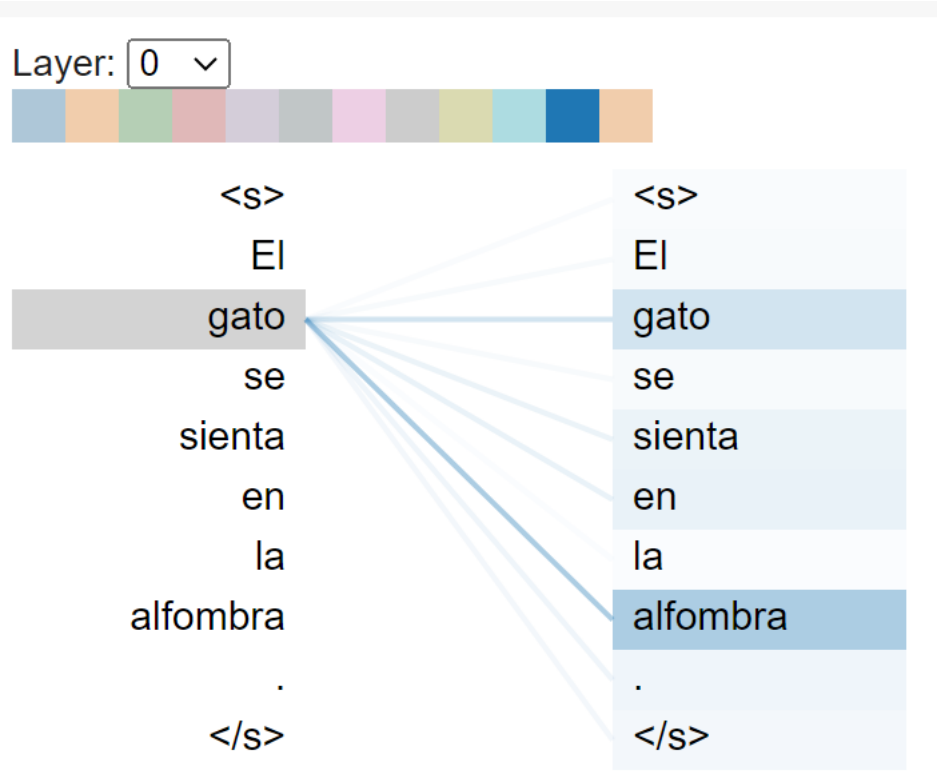
Embeddings



3. Representación numérica de palabras

Embeddings contextuales – Mecanismo de atención





3. Representación numérica de documentos textuales

Embeddings contextuales

PROS

- Capaz de capturar relaciones semánticas y sintácticas entre palabras de forma dinámica
- Alta comprensión del lenguaje
- Fácil adaptación de la arquitectura a diferentes tareas

CONS

- Tiempo de entrenamiento elevado y necesidad de GPUs
- Requiere corpus grandes para el entrenamiento y altos costes en la generación del modelo “base”

Collab 3 – **Representación de textos**



4. Modelos de Lenguaje y Arquitectura Transformers



4. Modelos de Lenguaje

¿Qué es un modelo de lenguaje?

- Un **modelo de lenguaje** predice la probabilidad de una palabra o secuencia de palabras dentro de un texto.
- Aprende **patrones del lenguaje** analizando grandes cantidades de texto.
- No entiende el lenguaje como los humanos, **pero detecta relaciones estadísticas y contextuales**.

🧠 Predicción de palabras

*El **[MASK]** corre por el parque*

- *barco*
- ***niño***
- *cielo*

✍️ Generación de texto

Érase una vez un dragón que…

…vivía en lo alto de una montaña custodiando un castillo

🌐 Traducción automática

The cat is on the table

↓

El gato está sobre la mesa

4. Modelos de Lenguaje

Evolución de los modelos de lenguaje

N-gramas | RNN | LSTM | Transformers

Modelo **estadístico** que predicen la siguiente palabra usando la **probabilidad condicional** de las *n-1* anteriores, aprendida a partir de las frecuencias en un corpus de entrenamiento.

Fueron la primera **aproximación sistemática y computacional** al modelado de lenguaje

El perro empezó a _____

ladrar (70%)
comer (20%)
dormir (10%)

📌 El modelo elige la palabra más probable según su "memoria estadística". Para ello sólo utiliza las n-1 palabras anteriores

✅ Simples, eficientes y fáciles de entrenar

❌
- No captura relaciones de largo alcance
- No puede predecir combinaciones raras
- Útiles exclusivamente para generar texto

4. Modelos de Lenguaje

Evolución de los modelos de lenguaje



Redes neuronales que procesan texto secuencialmente, manteniendo una memoria del contexto anterior.
LSTM son versiones mejoradas que controlan qué información recordar u olvidar.

Primer gran salto desde modelos estadísticos a **modelos de deep learning**.
Cambiaron la forma de abordar tareas como generación de texto, análisis de sentimientos y traducción automática.
Fundaron las bases de los siguientes avances (atención)

El perro empezó a _____

🔁 **RNN:** ***correr por el jardín***

🔐 **LSTM:** ***correr detrás del dato que cruzó la calle***

📌 LSTM generan resultados más coherentes, complejos y largos gracias a su mejor memoria

- Capaces de generar texto nuevo dependiendo de la información predecesora.
- Útiles para tareas más allá de la generación de texto

- Dificiles de entrenar.
- Mal rendimiento en secuencias muy largas

4. Modelos de Lenguaje

Evolución de los modelos de lenguaje



Modelos basados en **el mecanismo de auto-atención**, que permite analizar **toda la secuencia a la vez**, sin procesarla palabra por palabra.

Punto de inflexión en NLP. Esta arquitectura se vuelve el pilar común de todas las aplicaciones de NLP.
Adoptados más allá del texto, se utilizan también en **computer visión** y **audio**.

El perro empezó a _____ ***correr al reconocer a su dueño entre la multitud que salía del tren***

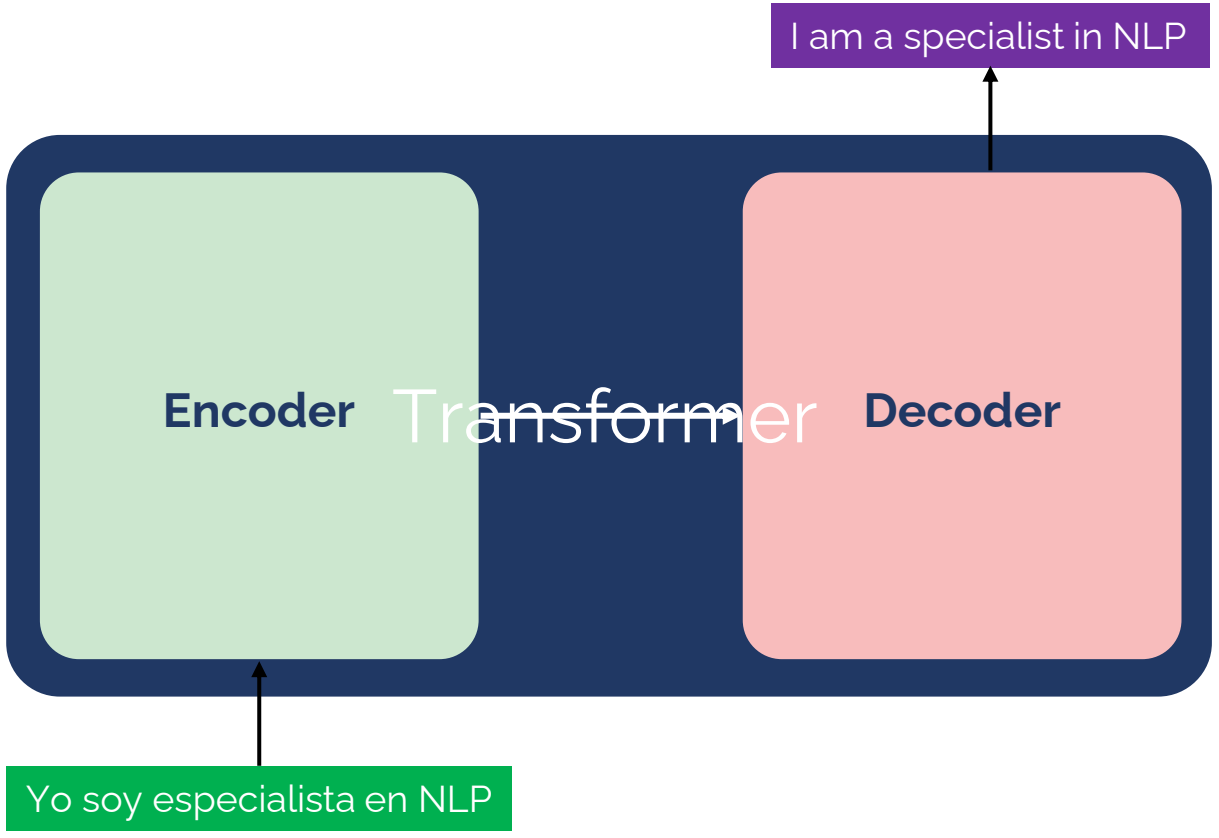
📌 Capta relaciones semánticas y contextuales a larga distancia de forma natural.

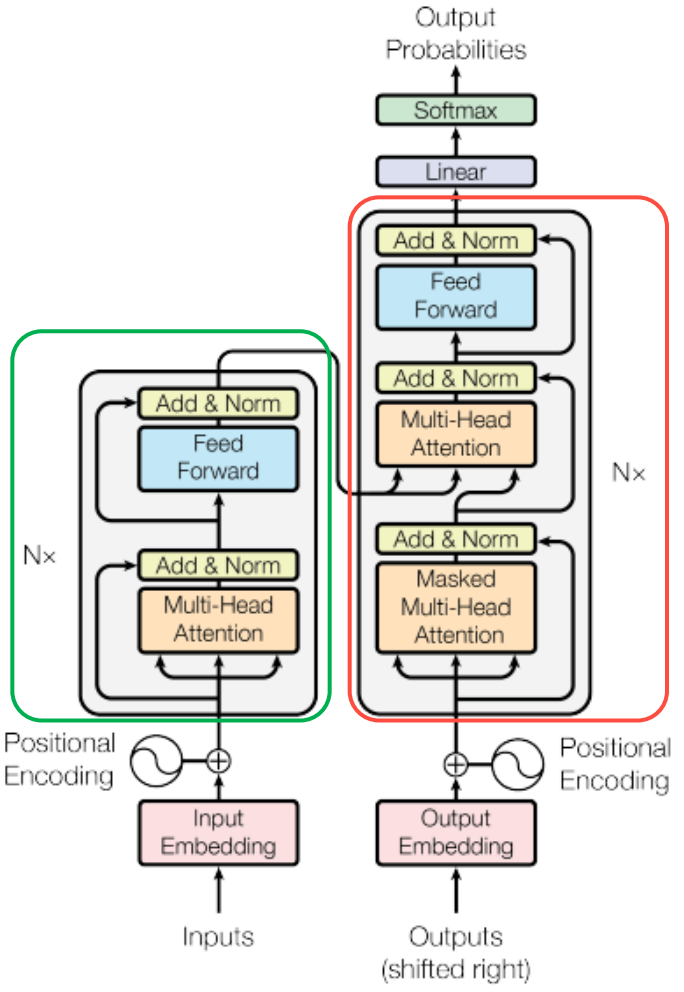
- Escalables y paralelizables.
- Manejan textos largos con relaciones complejas.
- Modelo base para tareas de NLP.

- Requieren grandes cantidades de datos y GPU.
- Baja explicabilidad

4. Modelos de Lenguaje - Arquitectura Transformers

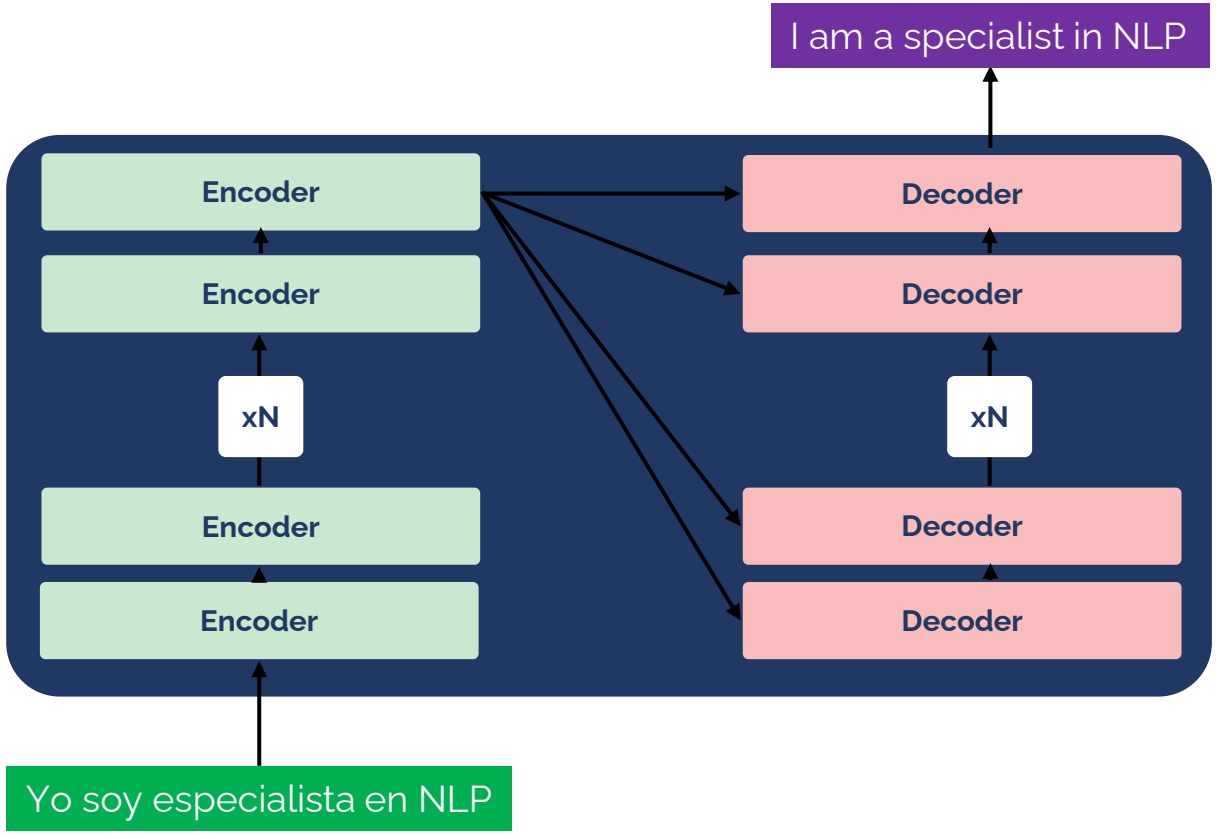
- Arquitectura introducida en el año 2017 –***Attention is All You Need*** (Vaswani et al)
- Este modelo marcó un hito en el NLP, al resolver tareas de traducción automática de manera más eficaz que los modelos anteriores basados en LSTM.
- El problema que aborda es de tipo secuencia a secuencia (**seq2seq**) donde hay una **secuencia de entrada** (un texto en inglés) y una **secuencia de salida** (un texto en español).

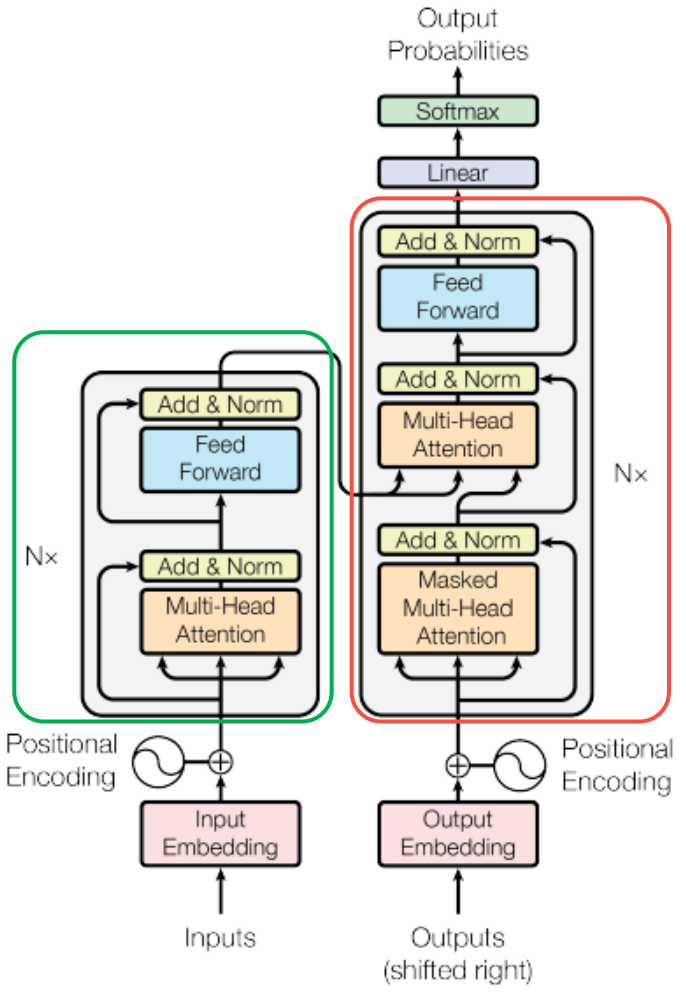




4. Modelos de Lenguaje - Arquitectura Transformers

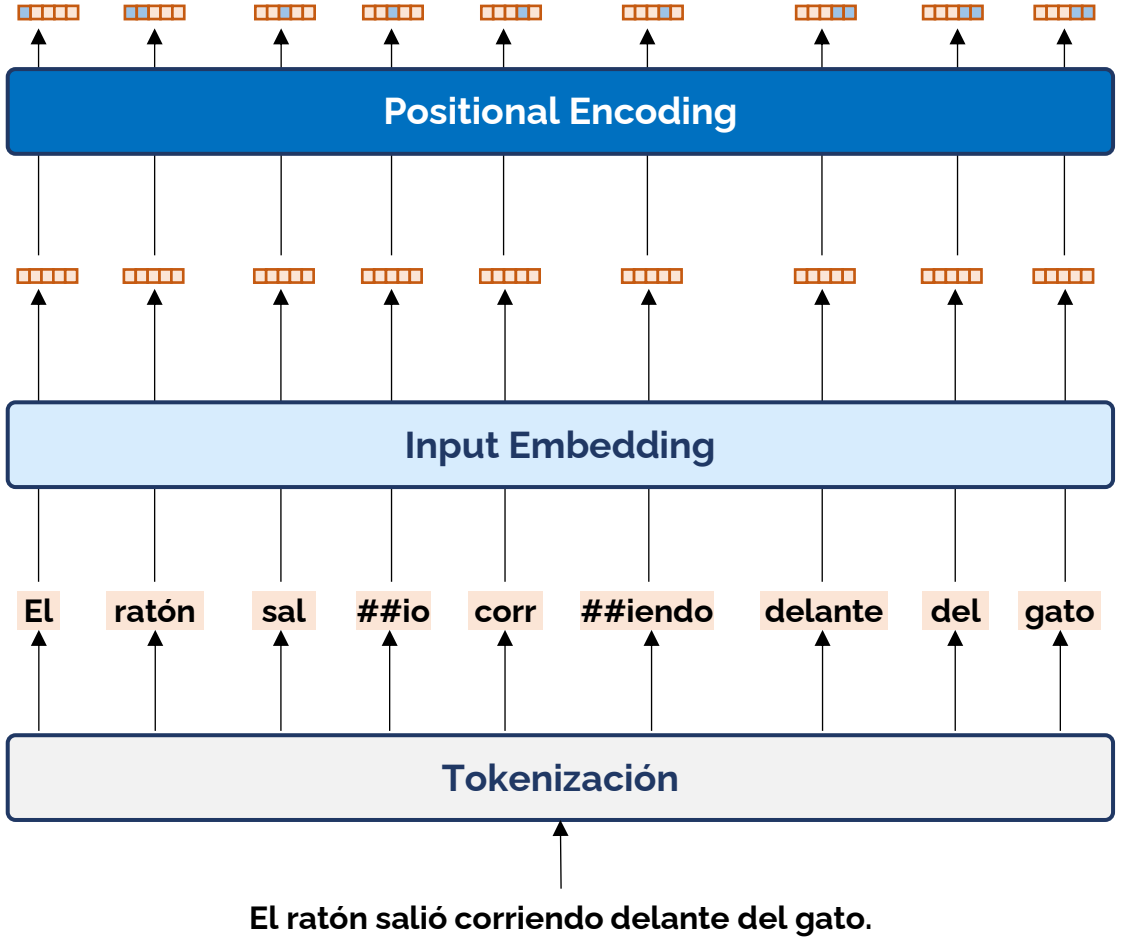
- Arquitectura introducida en el año 2017 –***Attention is All You Need*** (Vaswani et al)
- Este modelo marcó un hito en el NLP, al resolver tareas de traducción automática de manera más eficaz que los modelos anteriores basados en LSTM.
- El problema que aborda es de tipo secuencia a secuencia (**seq2seq**) donde hay una **secuencia de entrada** (un texto en inglés) y una **secuencia de salida** (un texto en español).





4. Modelos de Lenguaje - Arquitectura Transformers

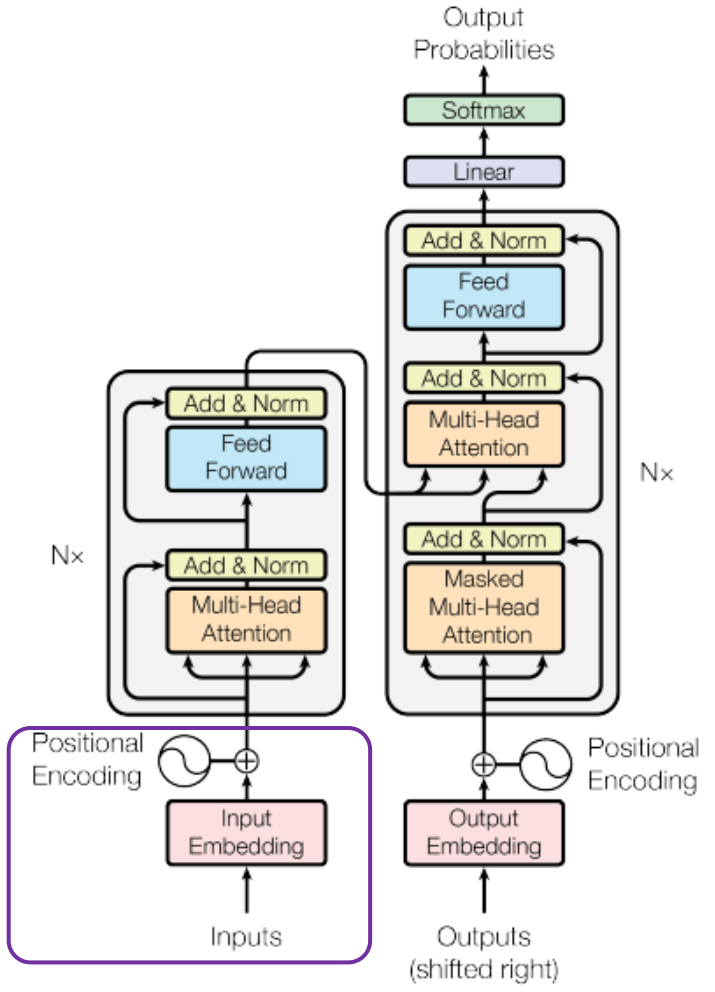
¿Cómo procesa el texto el Transformers? - Input



La arquitectura **no procesa la secuencia de tokens en orden**, así que se le incorpora un valor posicional al vector para que pueda interpretar el orden.

Cada subpalabra se convierte en un **vector** numérico calculado durante la fase de entrenamiento.

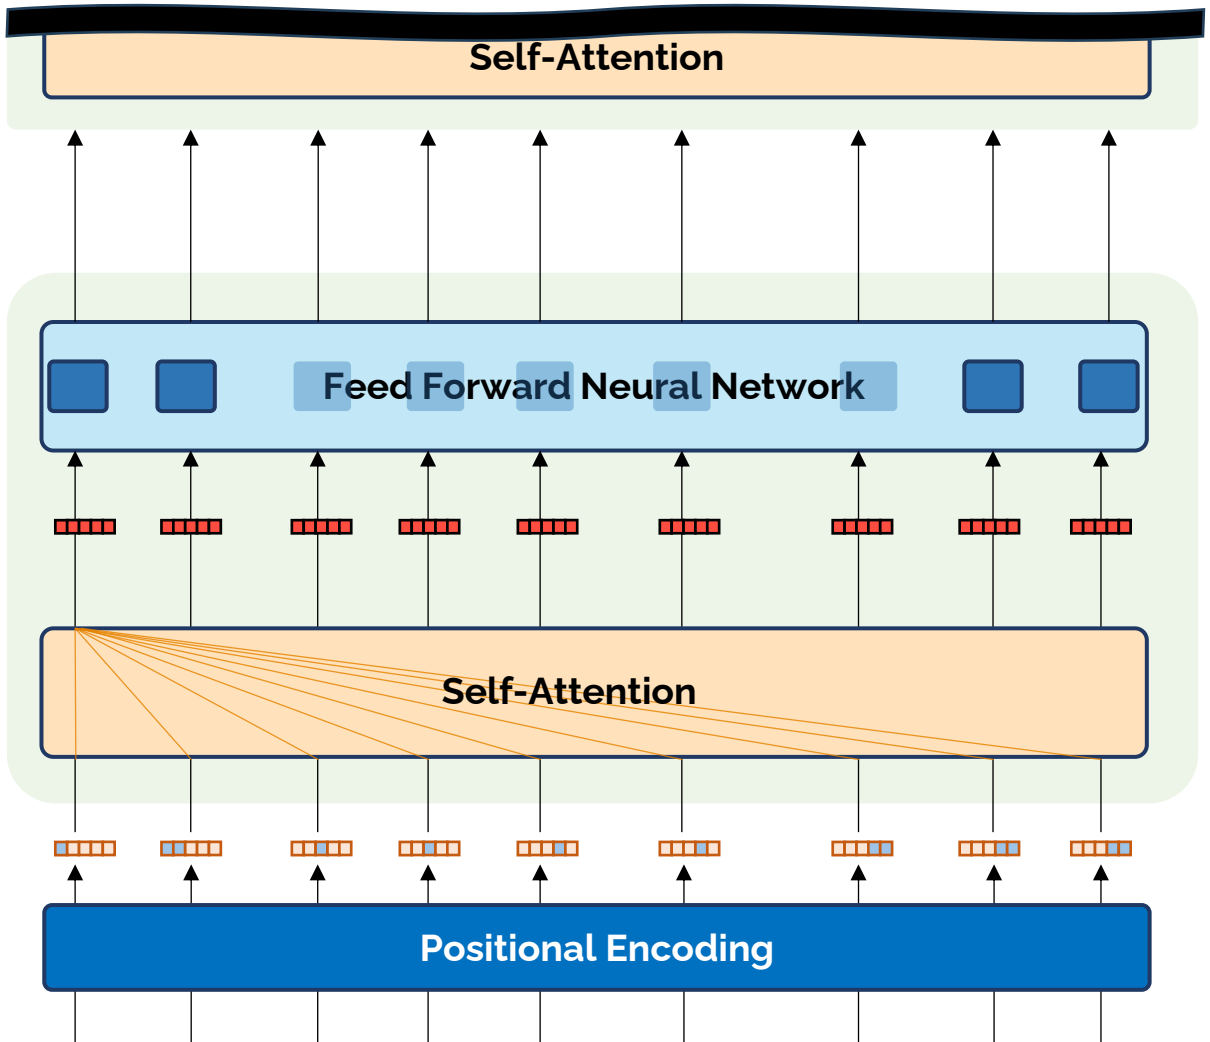
El texto se divide en tokens. En este caso, el transformer trabaja a nivel de subpalabra para optimizar el tamaño del vocabulario.



4. Modelos de Lenguaje - Arquitectura Transformers

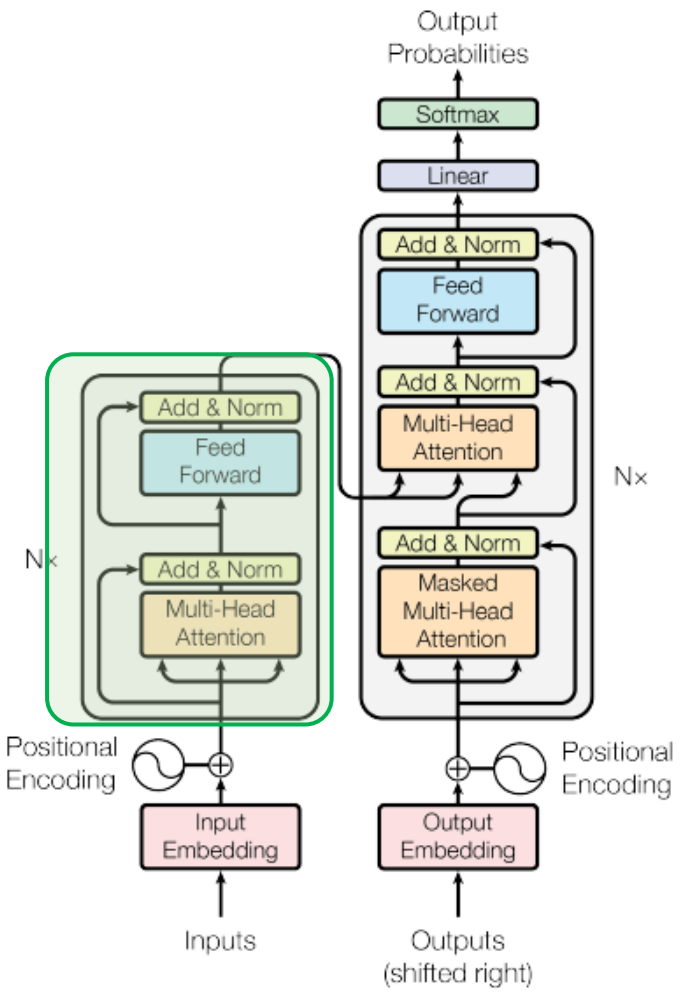
¿Cómo procesa el texto el Transformers? - Encoder

Los vectores de cada subpalabra atraviesan una secuencia de **N encoders**



FFNN: Aplica transformaciones no lineales a cada vector contextual. Ayuda al modelo a **expandir dimensiones más relevantes** según el contenido.

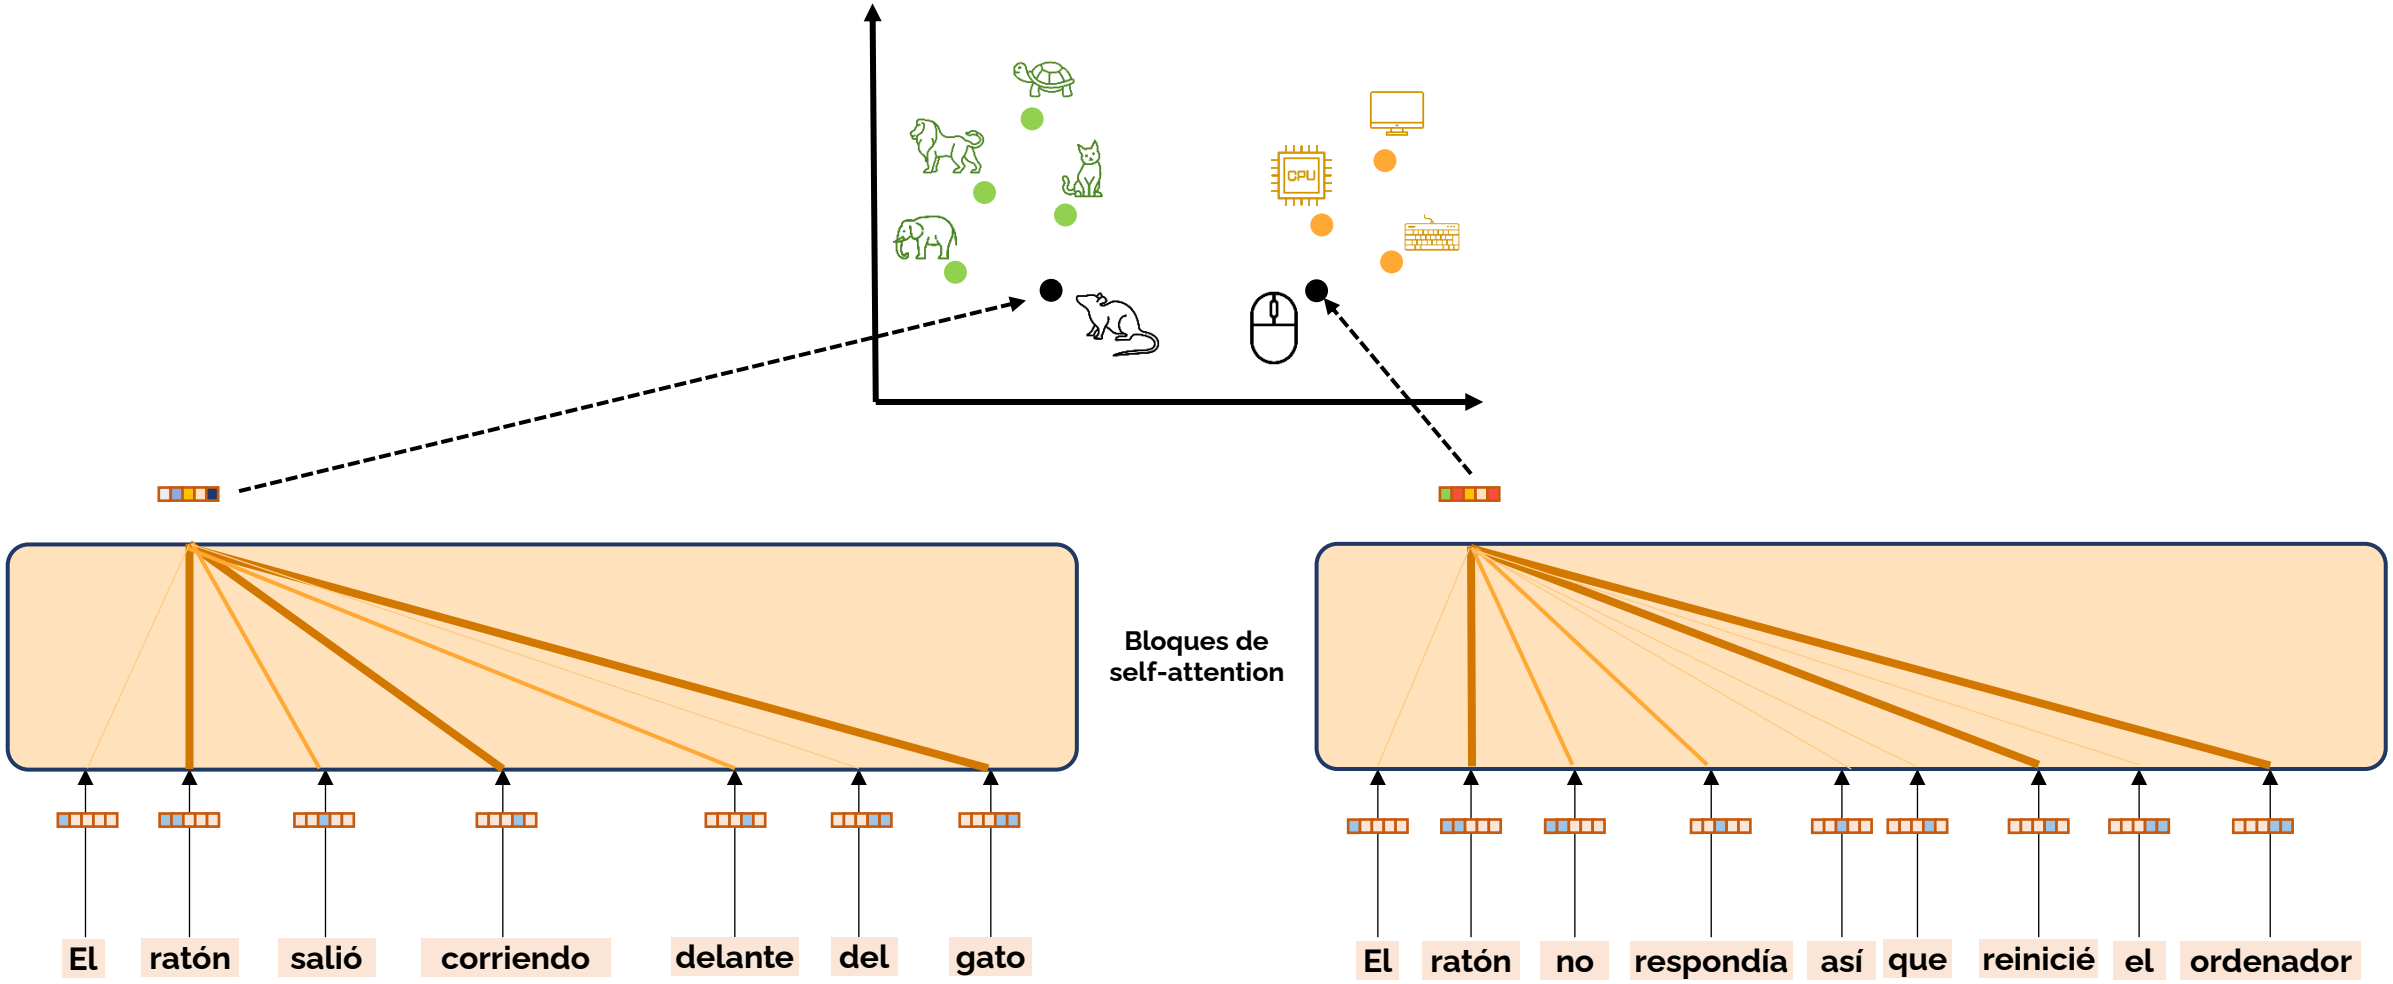
Self-attention: Es donde ocurre la "magia" de los Transformers. Cada token "atiende" a los demás para decidir cuales son más relevantes en su contexto, actualizando su representación vectorial a la salida.



4. Modelos de Lenguaje - Arquitectura Transformers

¿Cómo procesa el texto el Transformers? – Encoder – Self-Attention

Para ejemplificar el mecanismo de atención, vamos a trabajar con dos frases que utilizan el término ratón en dos contextos diferentes:



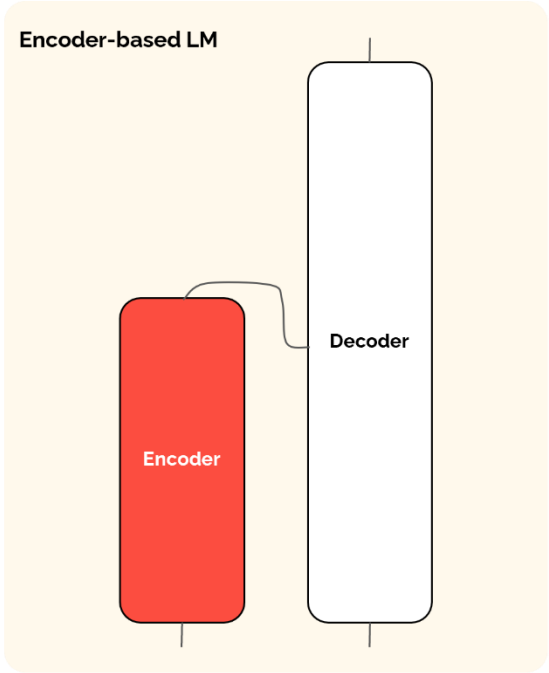
🐀 - El ratón salió corriendo delante del gato.

🖱️ - El ratón no respondía, así que reinicié el ordenador

4. Modelos de Lenguaje - Arquitectura Transformers

Tipos de modelos de lenguaje con arquitectura Transformers

Según las partes que implementan de la arquitectura Transformers, encontramos 3 tipos de modelos de lenguaje:

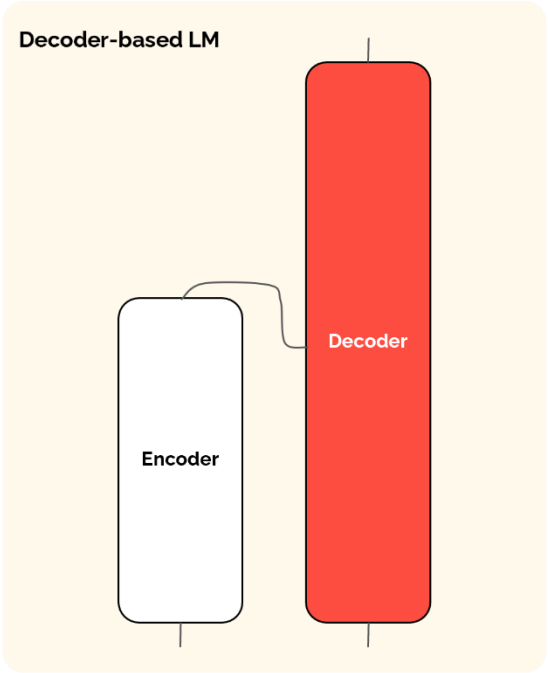


Arquitecturas: BERT, RoBERTA

Tareas de comprensión de lenguaje natural

NER, Entity Normalization, Clasificación

Modelos ligeros, computacionalmente ligeros de entrenar

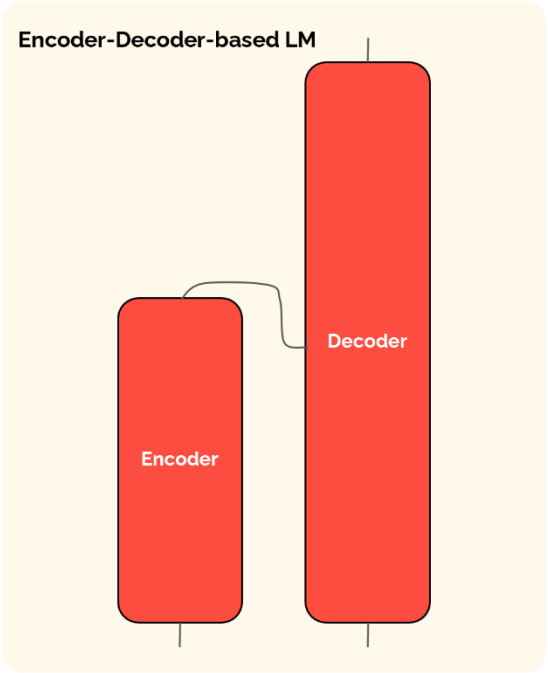


Arquitecturas : GPT3, ChatGPT

Generación de lenguaje natural

ChatBots

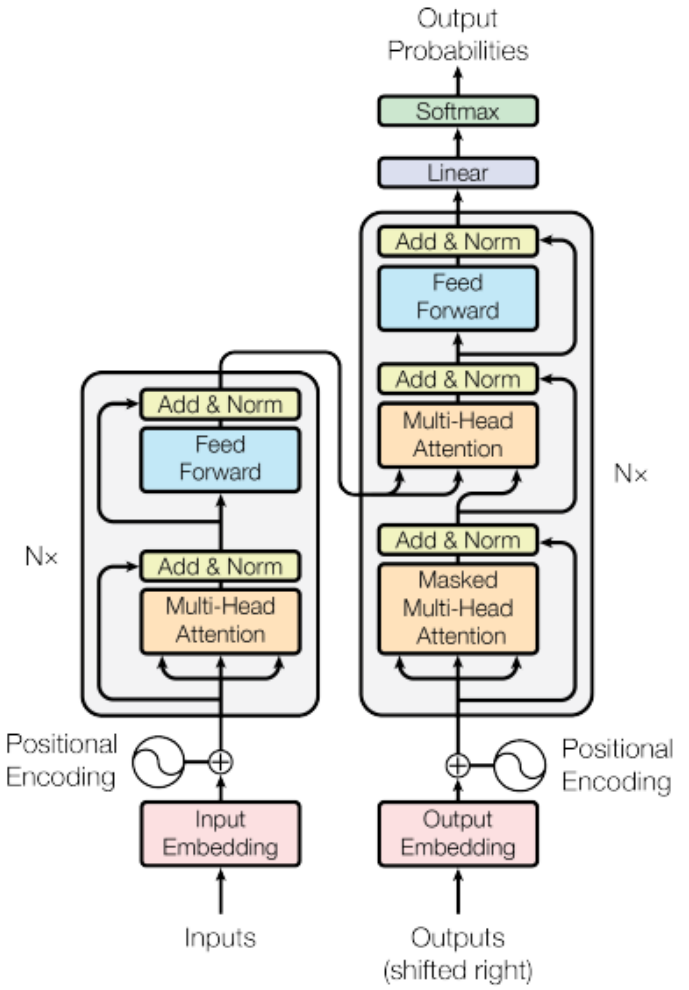
Modelos muy pesados (difíciles de servir en local), y computacionalmente muy caros de entrenar.



Arquitecturas : T5, BART

Generación de lenguaje

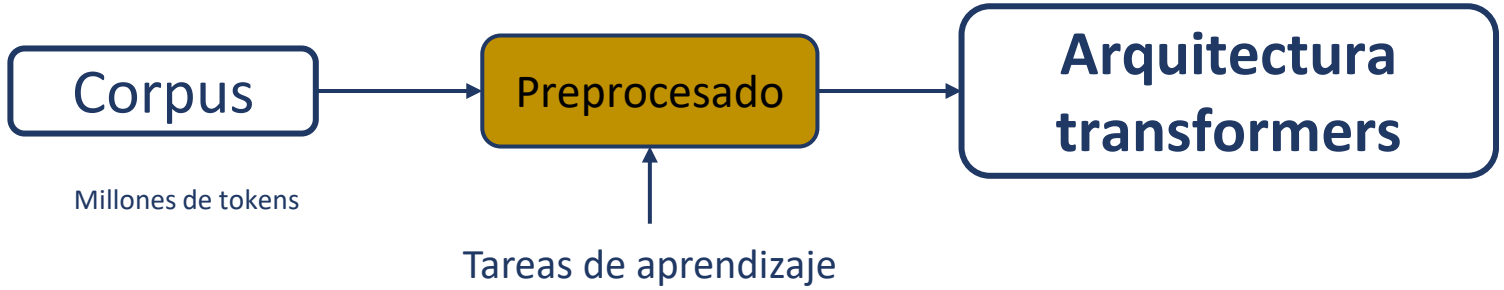
Summarization, Traducción



[1]. Vaswani, A., et al. (2017). **Attention is all you need**. *Advances in neural information processing systems*, *30*.

4. Arquitectura Transformers – Modelos Encoder

Entrenamiento

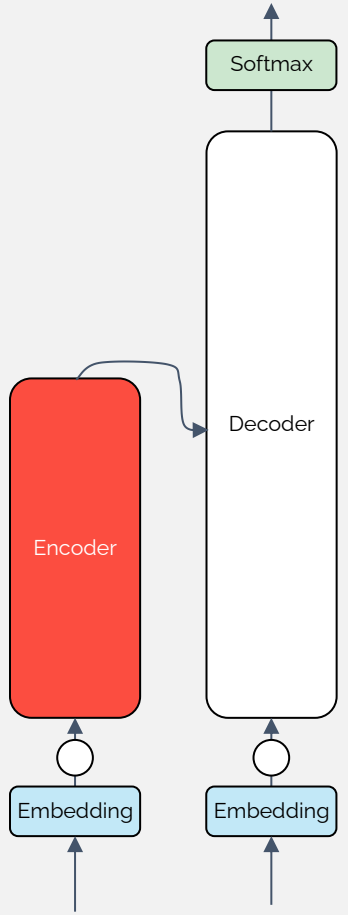


Tarea de aprendizaje 1: *Masked Language Modeling*

Objetivo: Predecir palabras

Tarea de aprendizaje 2: *Next Sentence Prediction*

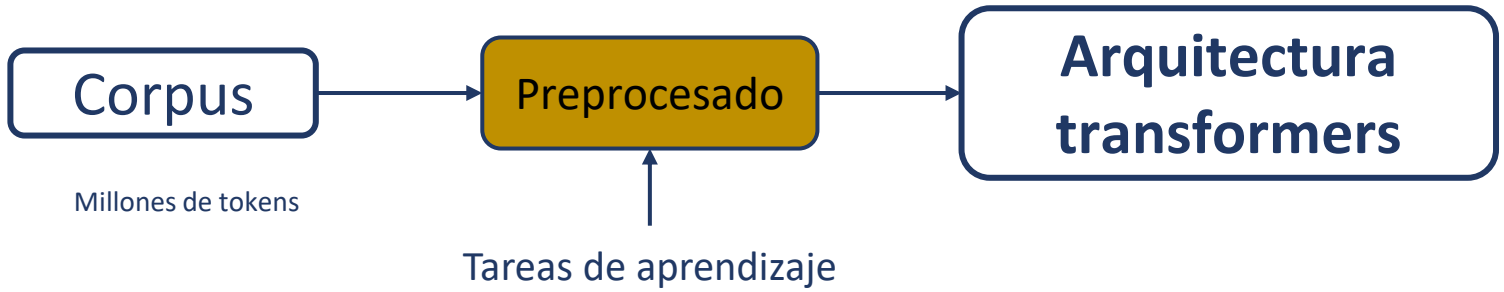
Objetivo: Establecer relación entre frases



[2]. Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2018). **Bert: Pre-training of deep bidirectional transformers for language understanding**. arXiv preprint arXiv:1810.04805.

4. Arquitectura Transformers – Modelos Encoder

Entrenamiento

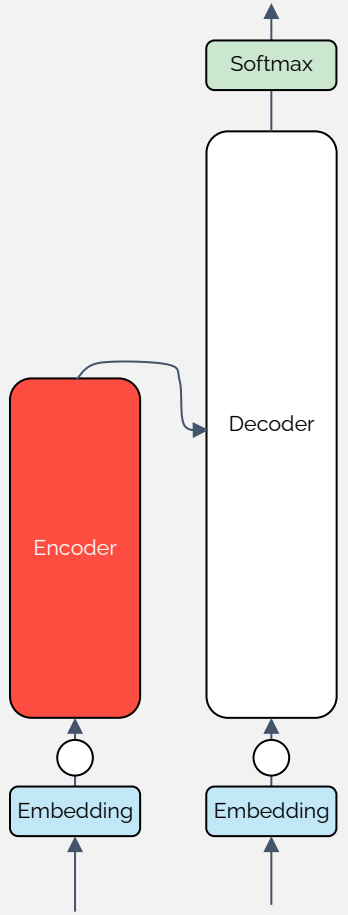


Tarea de aprendizaje 1: *Masked Language Modeling*

María decidió relajarse y ver su serie favorita en Netflix.

María decidió relajarse y ver su **[MASKED]** favorita en Netflix

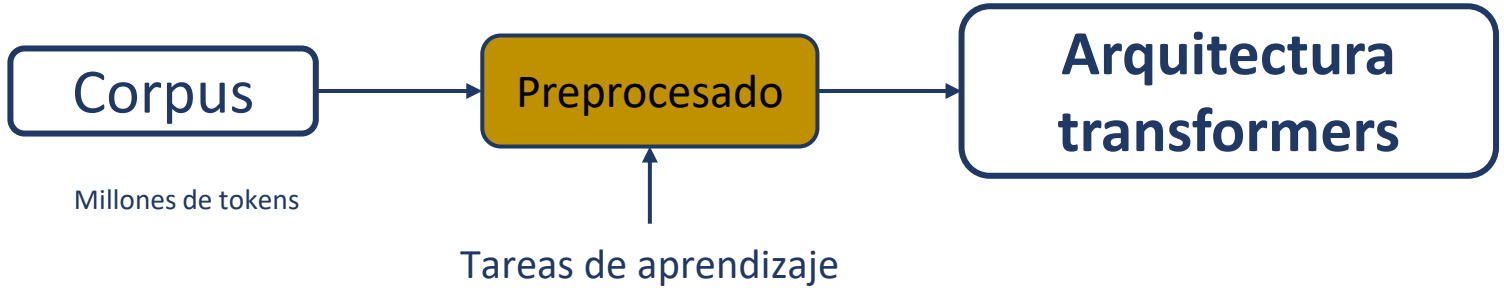
- serie 0,85
- película 0,82
- …
- fútbol 0,002



[2]. Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2018). **Bert: Pre-training of deep bidirectional transformers for language understanding**. arXiv preprint arXiv:1810.04805.

4. Arquitectura Transformers – Modelos Encoder

Entrenamiento

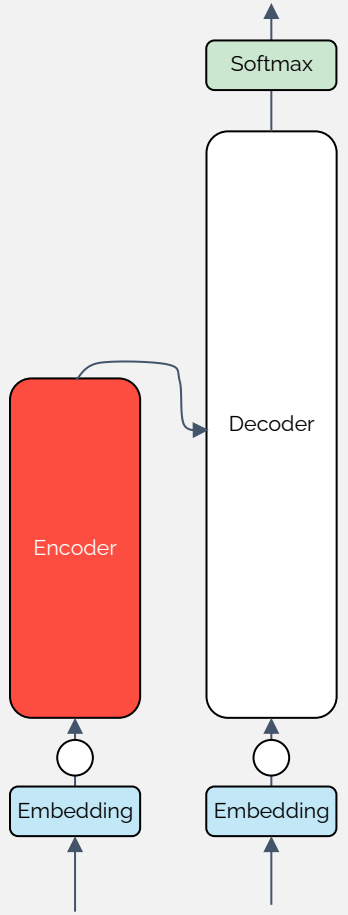


Tarea de aprendizaje 2: *Next Sentence Prediction*

Frase A: Hoy fui al supermercado Frase B: Compré frutas

¿Es la frase B una continuación lógica de A?

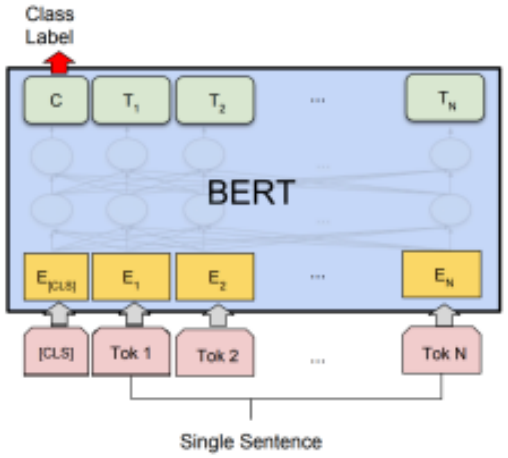
[CLS] Frase A [SEP] Frase B [SEP]



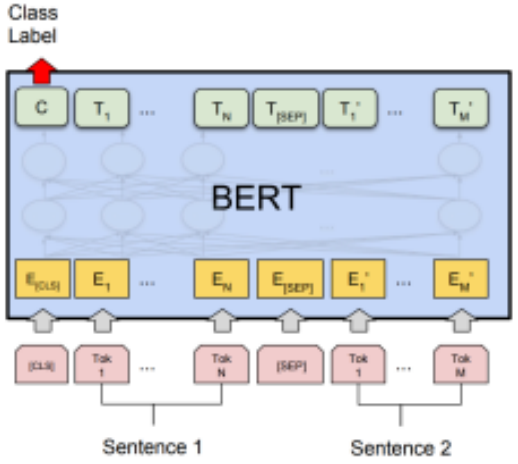
[2]. Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2018). **Bert: Pre-training of deep bidirectional transformers for language understanding**. arXiv preprint arXiv:1810.04805.

4. Arquitectura Transformers – Modelos Encoder

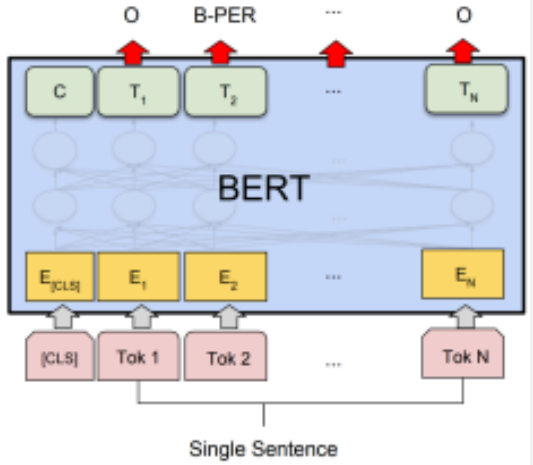
Uso de modelos de tipo encoder [2]:



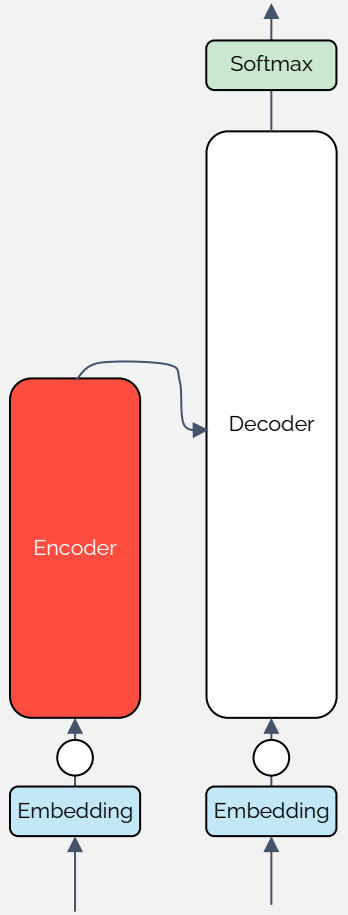
(b) Single Sentence Classification Tasks: SST-2, CoLA



(a) Sentence Pair Classification Tasks: MNLI, QQP, QNLI, STS-B, MRPC, RTE, SWAG



(d) Single Sentence Tagging Tasks: CoNLL-2003 NER



[2]. Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2018). **Bert: Pre-training of deep bidirectional transformers for language understanding**. arXiv preprint arXiv:1810.04805.

4. Arquitectura Transformers – Decoder

Entrenamiento

Autoregressive Pretraining

Se entrena la arquitectura para predecir palabras dado sólo el contexto por la izquierda.

María decidió relajarse y ver su serie favorita en **[MASKED]** → Netflix (0,65) HBO (0,20) TV (0,05)

Un modelo de lenguaje preentrenado, por sí solo, no suele ser útil, ya que como salida genera la **secuencia de texto más probable** dada una entrada. Es necesario **alinearlo** para que aprenda a **generar la secuencia que resuelva la tarea que el usuario especifica**.

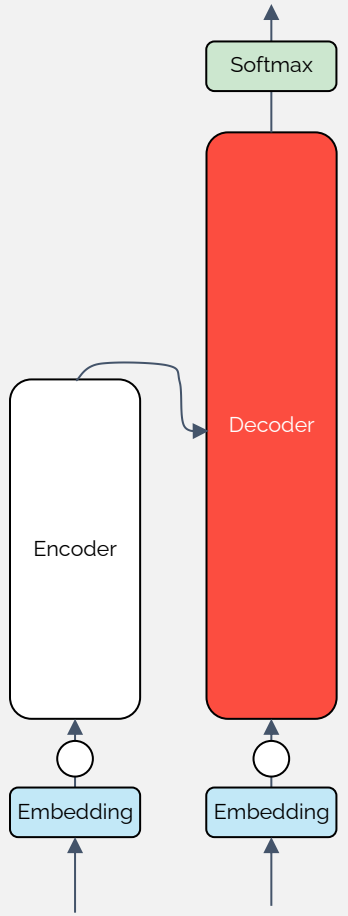
Alignment

Supervised fine-tuning

Se entrena para generar texto que resuelva las instrucciones dadas en la entrada por un usuario.

Tarea	Input	Output
Instrucciones estilo asistente	¿Cómo cambio una rueda de bicicleta?	Para cambiar una rueda de bicicleta, primero …
Resumen supervisado	Artículo sobre la fotosíntesis	La fotosíntesis es el proceso…
Traducción	Translate: "The weather is nice today."	El clima está agradable hoy.
Extracción de información	¿Quién es el arrendador en este contrato?	Juan Martínez Pérez
Conversación en diálogo	Usuario: ¿Cuál es la capital de Canadá?	Asistente: La capital de Canadá es Ottawa.

Reinforcement learning from human feedback



4. Arquitectura Transformers – Decoder

Entrenamiento

Autoregressive Pretraining

Se entrena la arquitectura para predecir palabras dado sólo el contexto por la izquierda.

María decidió relajarse y ver su serie favorita en **[MASKED]** → Netflix (0,65) HBO (0,20) TV (0,05) 💔

Un modelo de lenguaje preentrenado, por sí solo, no suele ser útil, ya que como salida genera la **secuencia de texto más probable** dada una entrada. Es necesario **alinearlo** para que aprenda a **generar la secuencia que resuelva la tarea que el usuario especifica**.

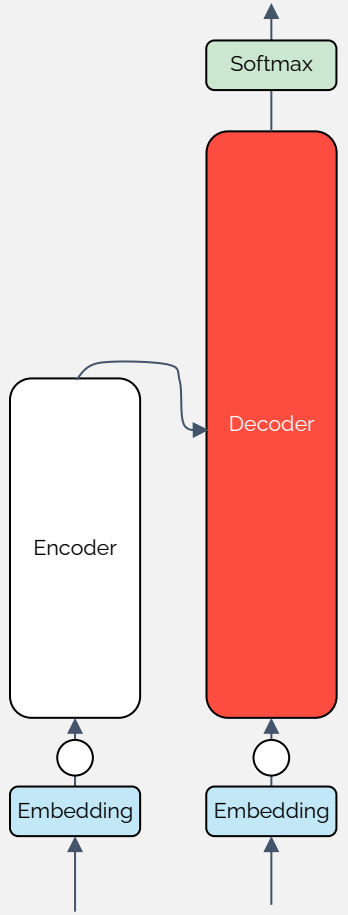
Alignment

Supervised fine-tuning

Se entrena para generar texto que resuelva las instrucciones dadas en la entrada por un usuario.

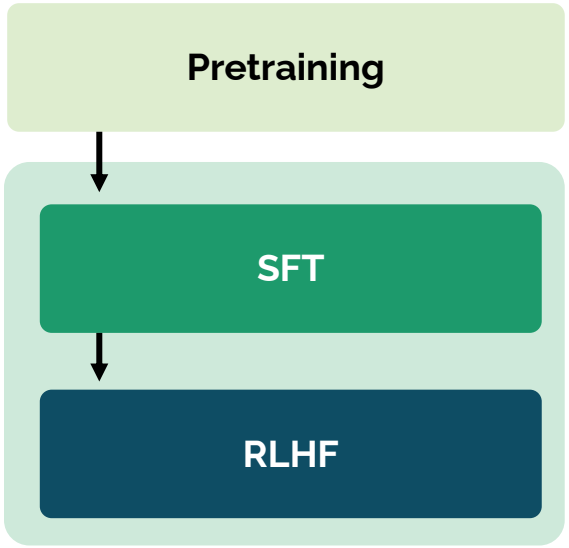
Reinforcement learning from human feedback

Se entrena para generar respuestas que se **alineen con las preferencias humanas**, eligiendo las más **útiles**, **seguras o deseadas** entre varias opciones posibles



4. Arquitectura Transformers - Decoder

Uso de modelos de tipo decoder :



In-Context Learning

Aprender a resolver nuevas tareas mediante ejemplos en el prompt.

Reasoning capabilities

Modelos diseñados para resolver tareas complejas mediante pasos intermedios, lógica o cadenas de pensamiento.

Build Agents

Crear sistemas autónomos capaces de planificar y ejecutar acciones mediante modelos de lenguaje

Gemini

MISTRAL AI_

OpenAI

deepseek

LangGraph

crewai

OpenAI

Collab 4– Transformers



RESUMEN

Técnicas y conceptos básicos de NLP

Lematizar
Corpus
Vocabulario
Stopwords
Semántica

Representación numérica del texto

BoW
TF-IDF
Embeddings

Modelos de Lenguaje

Transformer
Encoder
Self-attention
Masked Language Modeling
Decoder
Fine-tuning
RLHF

ntic master
revolucionamos la comunicación

UNIVERSIDAD COMPLUTENSE DE MADRID

