ntic master
revolucionamos la comunicación

UNIVERSIDAD COMPLUTENSE DE MADRID



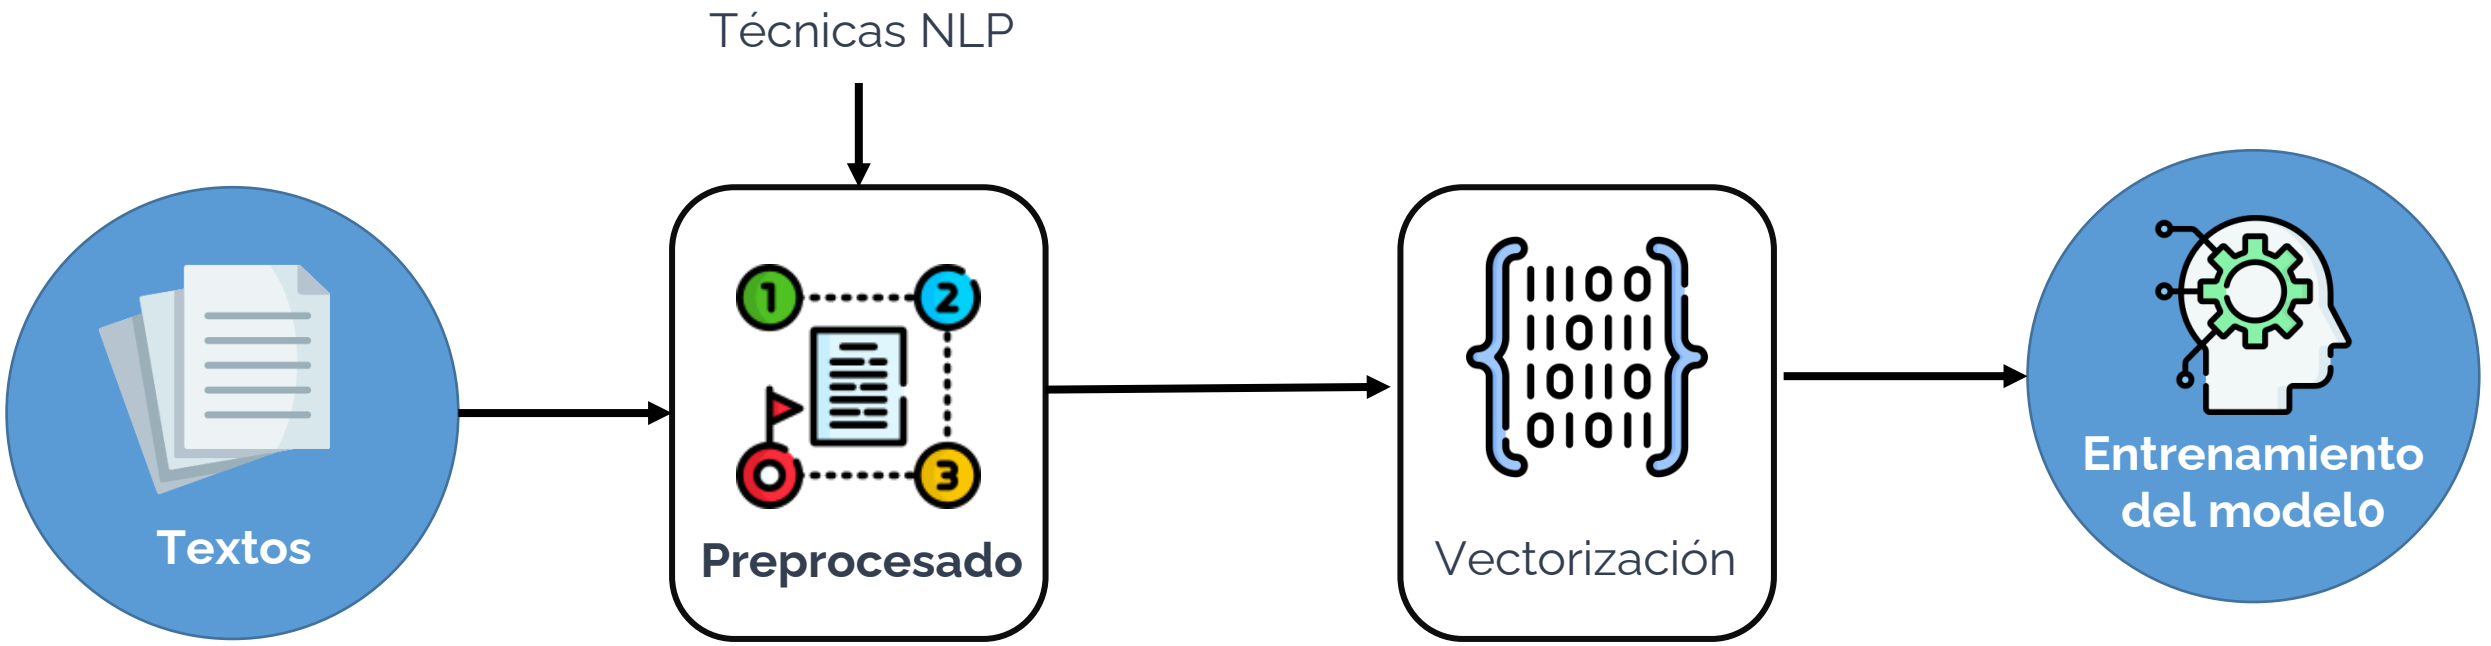
Text Mining

Luis Gascó Sánchez, Ph.D.

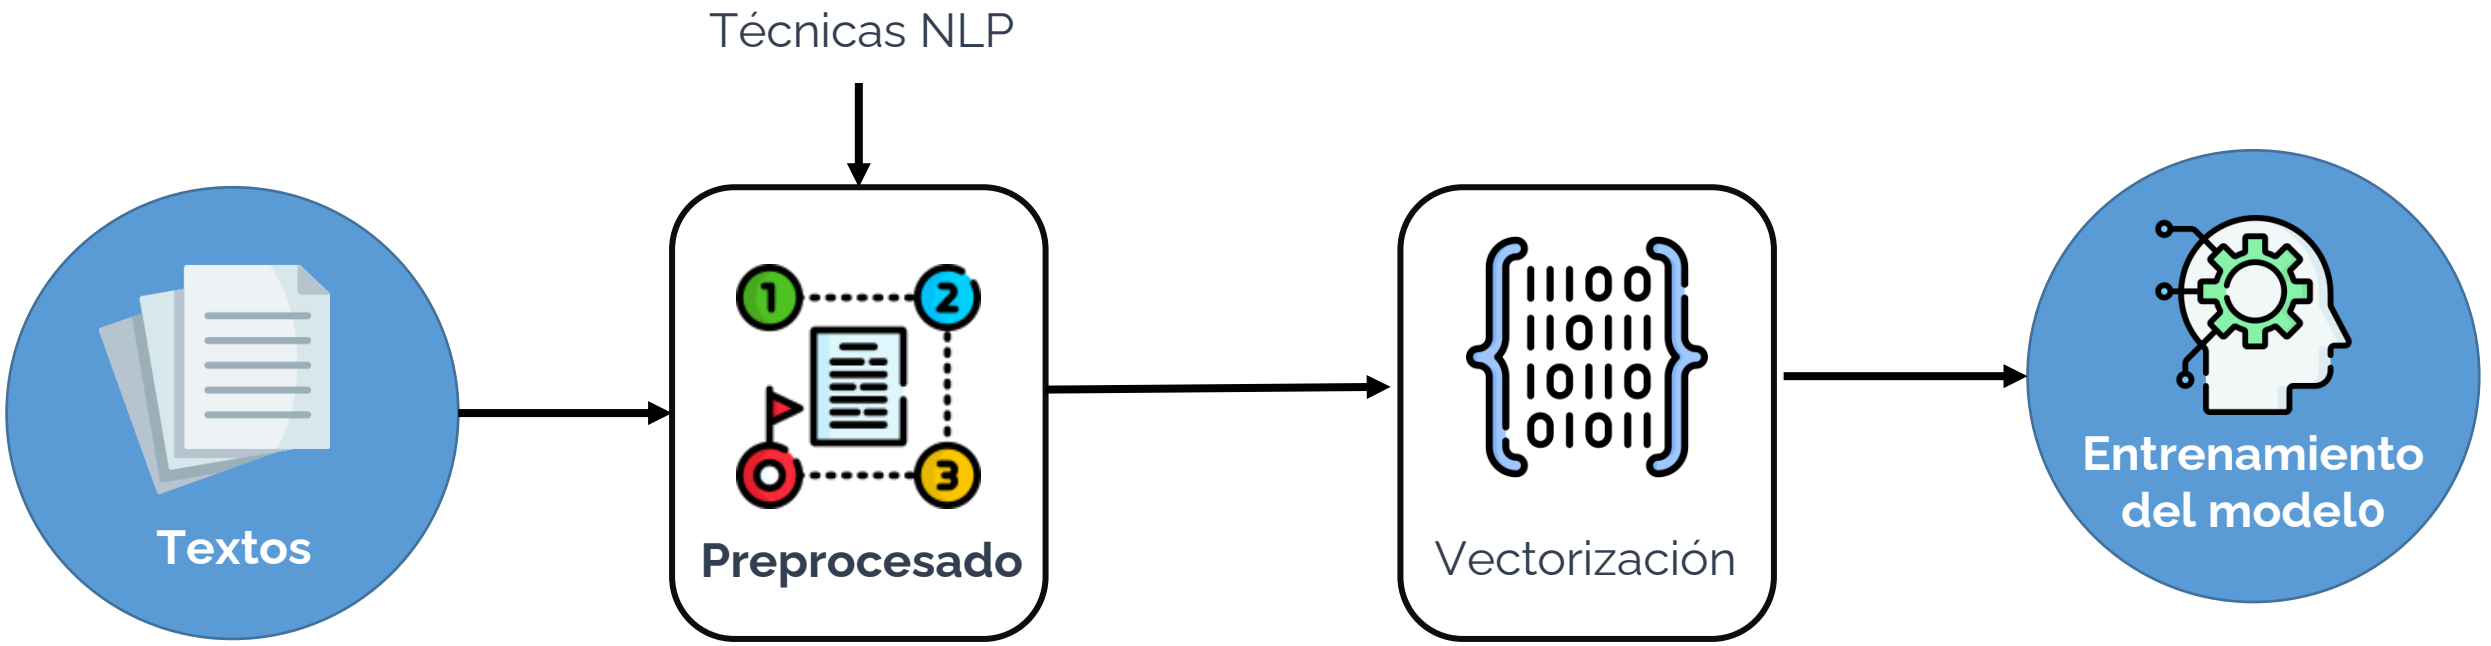
Cronograma

Día 1:

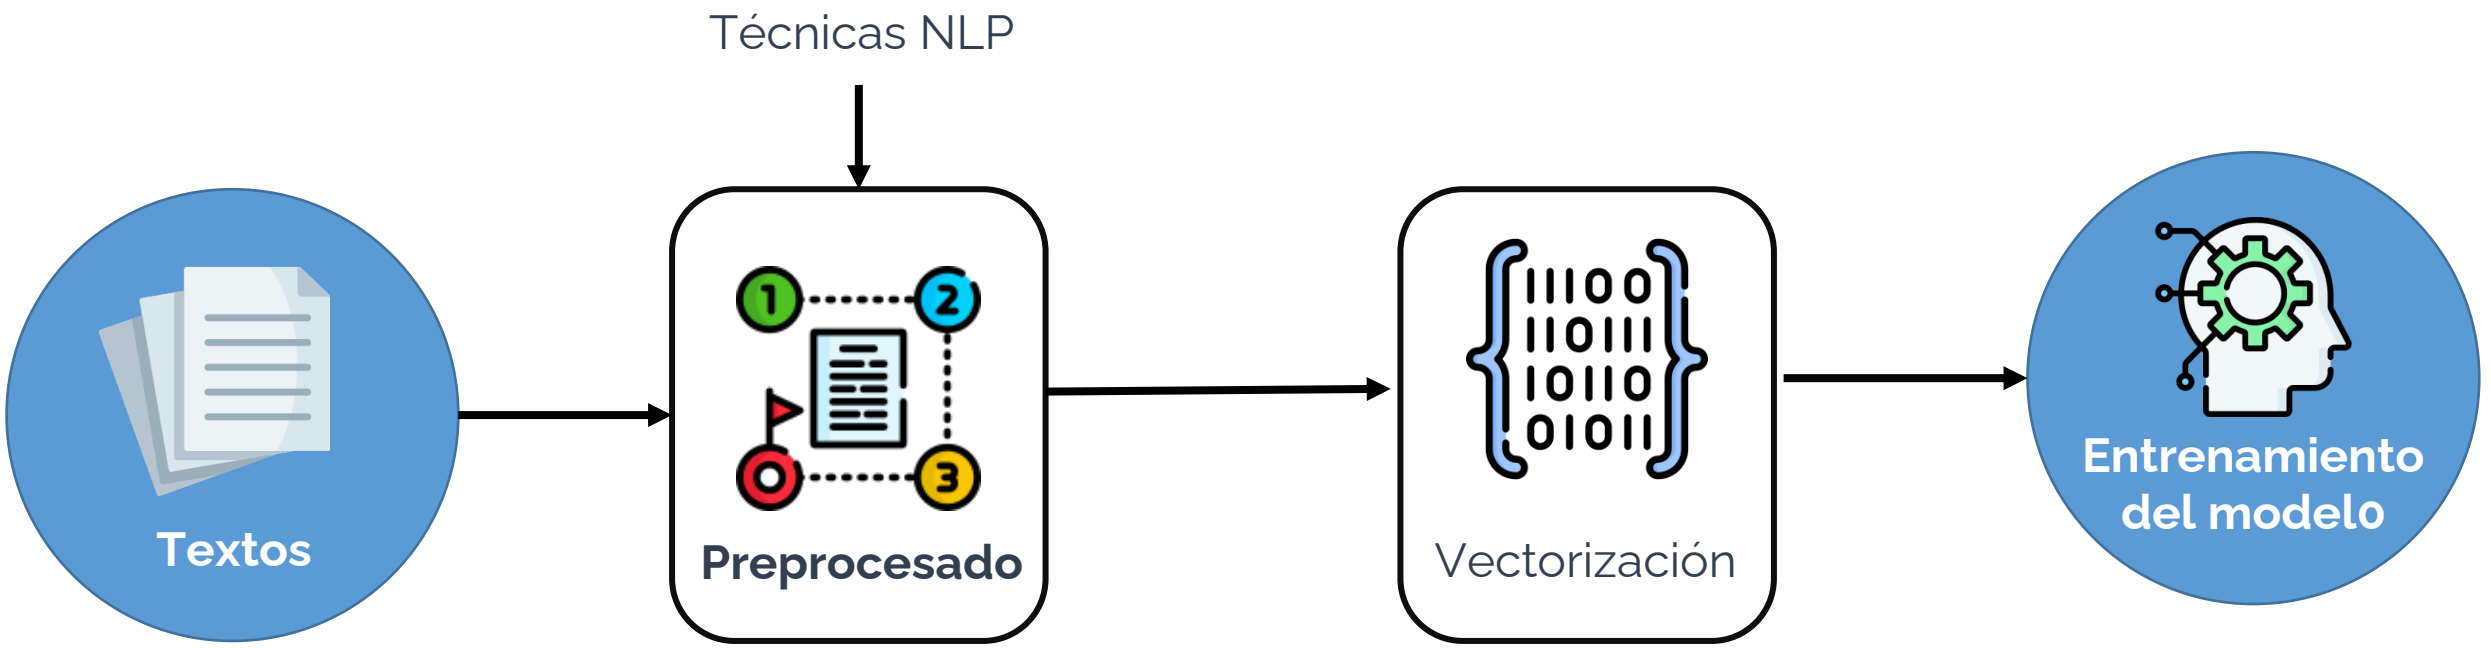
1. Introducción
    1. Contexto histórico
    2. ¿Qué es el Text Mining?
    3. Librerías de programación para Text Mining
2. Técnicas y conceptos básicos de NLP
3. Representación numérica del texto
4. Modelos de Lenguaje. Arquitectura Transformers



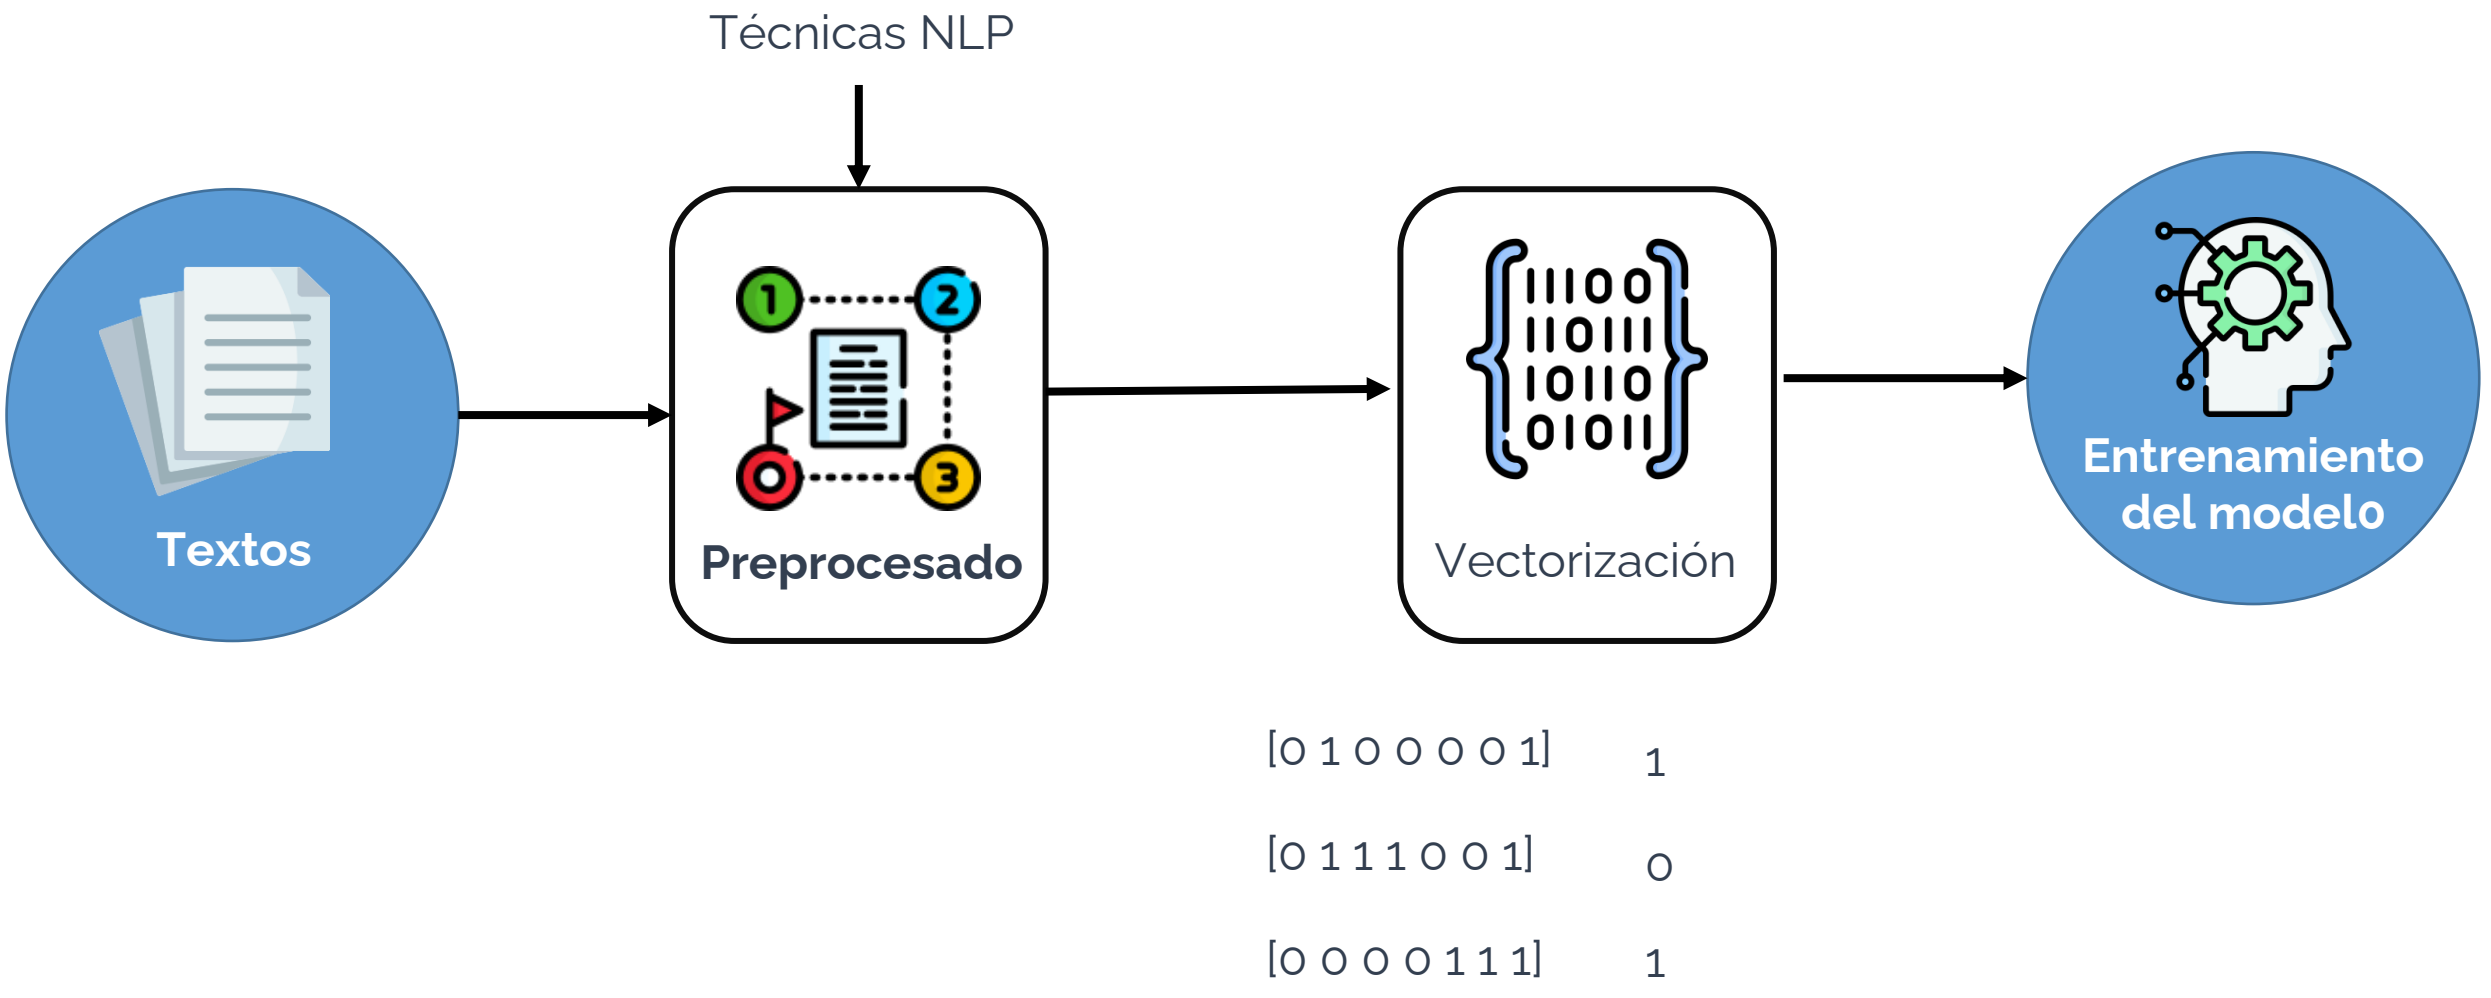
El profesor está explicando la clase	1
Los alumnos entienden el temario de clase	0
Los bomberos apagan fuegos	1



el profesor estar explicar la clase	1
el alumno entender el temario de clase	0
el bomberos apagar fuego	1



profesor explicar clase	1
alumno entender temario clase	0
bomberos apagar fuego	1


Técnicas NLP
Textos
Preprocesado
Vectorización
Entrenamiento del modelo
[0 1 0 0 0 0 1] 1
[0 1 1 1 0 0 1] 0
[0 0 0 0 1 1 1] 1

Cronograma

Día 2:

- Técnicas de Text Mining:
    1. Flujo de los datos
    2. Clasificación de textos
        - Técnica tradicional
        - Modelos de lenguaje
    3. Retrieval-based Question Answering
    4. Prompt Engineering.

1. Técnicas de Text Mining

Flujo de los datos



Clasificación de textos



2. Clasificación de textos

Usos

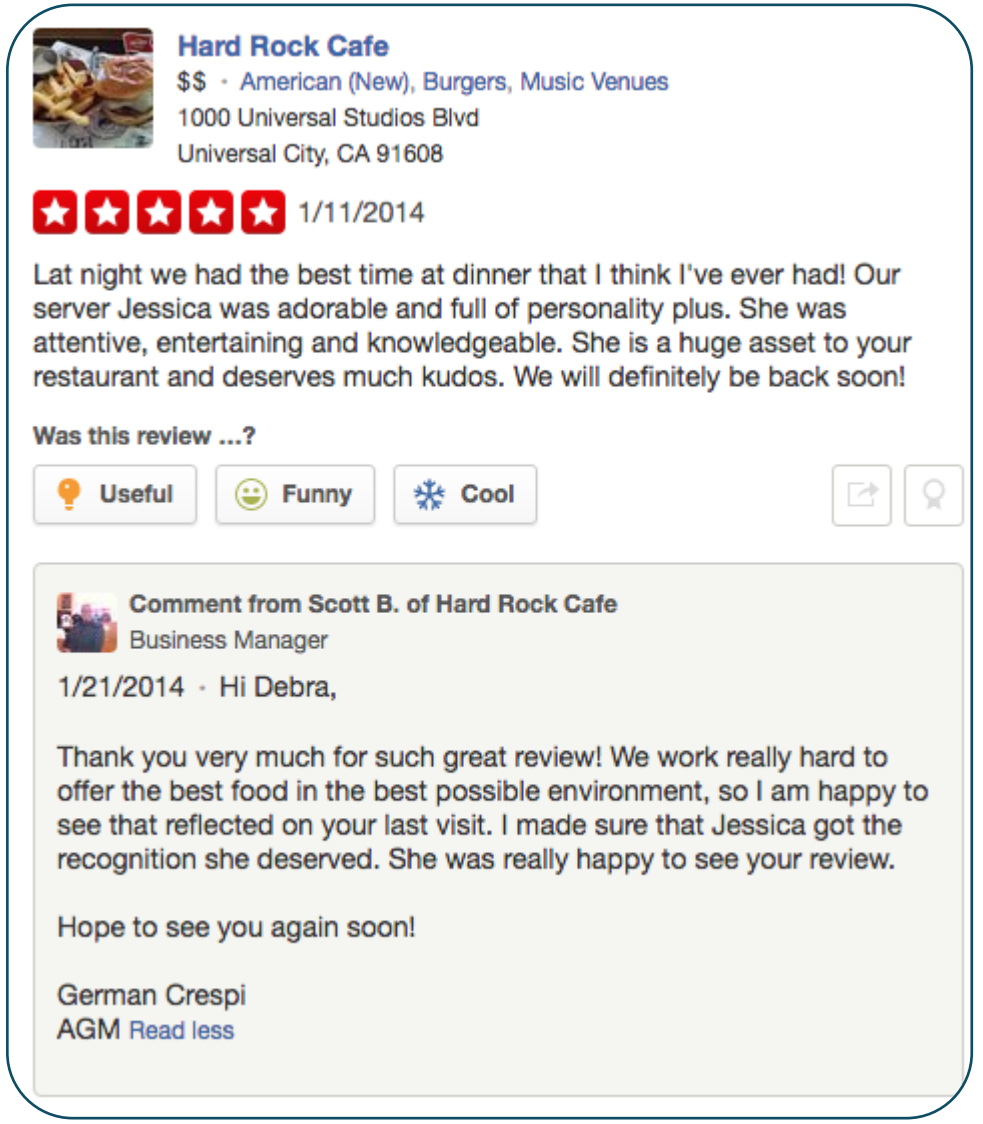
- **SPAM**
- **Análisis de sentimiento**
- **Discurso de odio**
- **Fake news**



2. Clasificación de textos

Usos

- SPAM
- Análisis de sentimiento
- Discurso de odio
- Fake news



2. Clasificación de textos

Usos

- SPAM
- Análisis de sentimiento
- Discurso de odio
- Fake news



2. Clasificación de textos

Usos

- SPAM
- Análisis de sentimiento
- Discurso de odio
- Fake news



Google Fact Check Tools

MALDITA.ES
PERIODISMO PARA QUE NO TE LA CUELEN

2. Clasificación de textos

Veremos dos métodos diferentes para **clasificación de textos**

Técnica Tradicional

Utilizando técnicas de
ingeniería de características

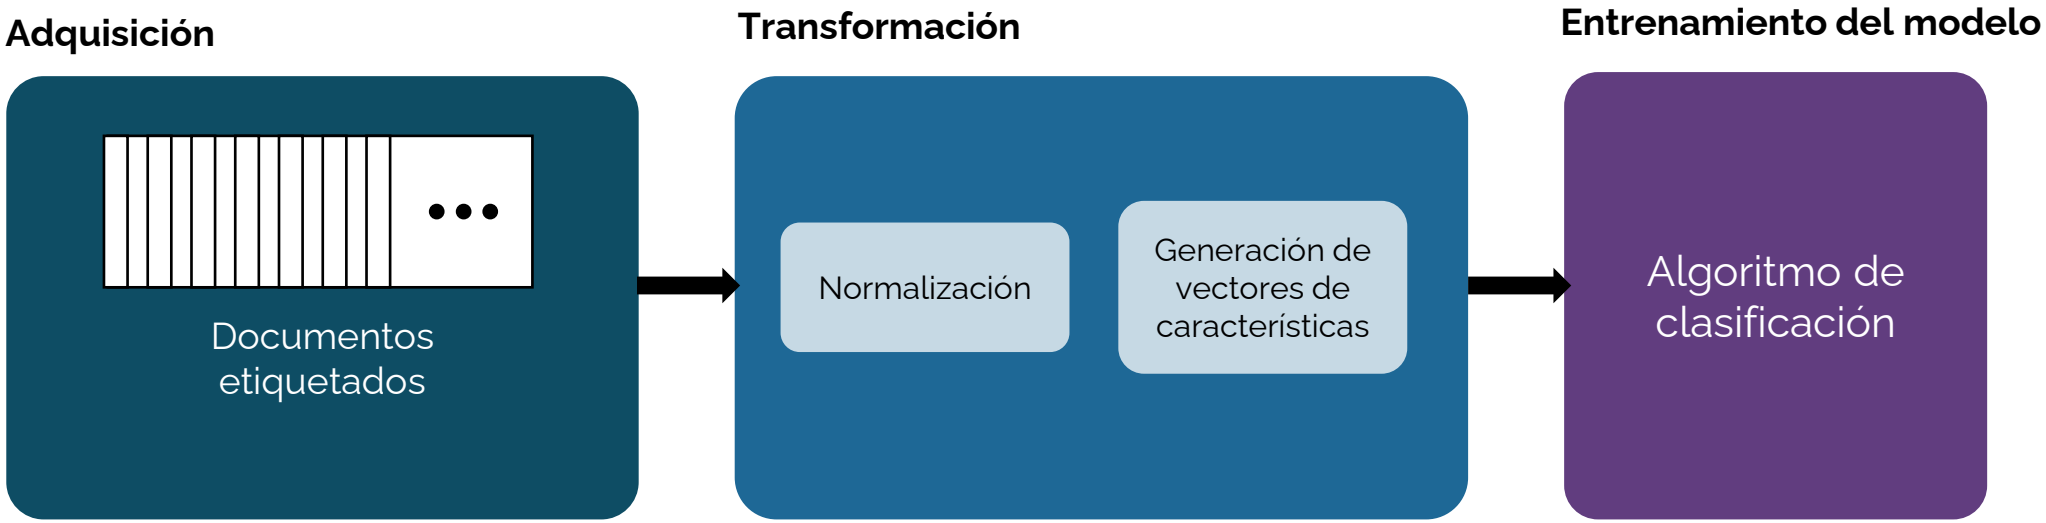
Modelos de lenguaje

Utilizando arquitectura
Transformers

2. Clasificación de textos – Técnica Tradicional

Flujo de los datos

Utilizando técnicas de **ingeniería de características**

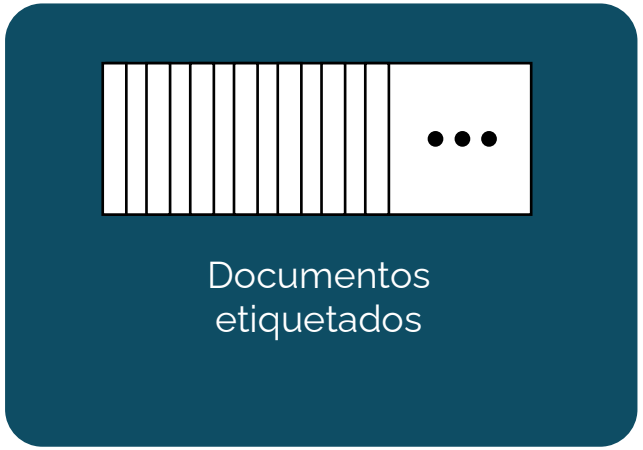


agua cocacola ... vino yo Nº adj.
[1 0 0 0 1 0 0 1]... 3]
[0 0 0 1 1 0 1 1]... 2]
[2 0 0 0 1 1 0 1]... 2]
[0 0 0 1 1 0 1 1]... 0]
[0 0 1 0 1 1 0 1]... 1]

2. Clasificación de textos – Técnica tradicional

Obtención de datos

Adquisición corpus anotados



Tipos de datos anotados

Binarios



Spam/No Spam



Multiclase



Online reviews

- Positivo
- Neutro
- Negativo

Multietiqueta



- Artículos científicos
- Blogs stackoverflow

Machine Learning
Smartcities Urbanism
Multilabel Classification

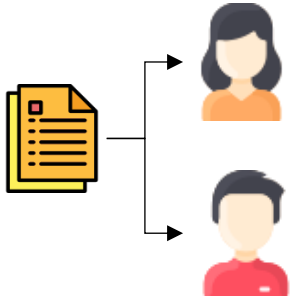
¿Como anotar?

prodigy



Label Studio

¿Calidad de anotación?



Anotaciones A

¿Concuerdan los resultados?

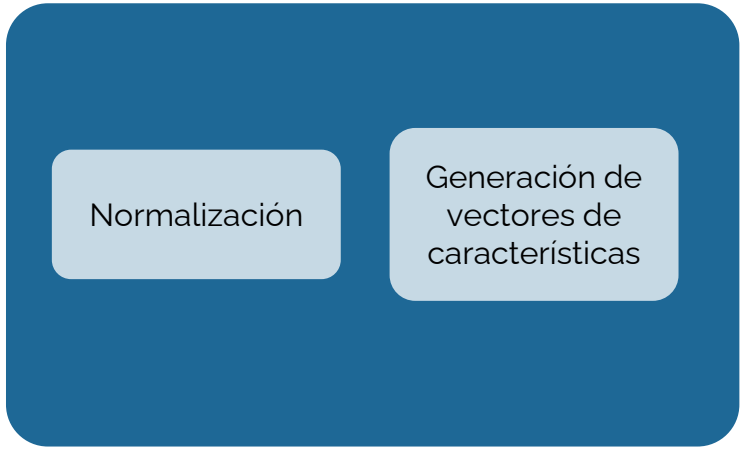
Anotaciones B

Inter-Annotation Agreement (IAA) metrics

2. Clasificación de textos – Técnica tradicional

Transformación – Traditional ML

Transformación



Normalización

Reducir dimensionalidad sin bajar rendimiento

1. Transformación a minúsculas
2. Lematización
3. Eliminación de palabras vacías y puntuación
4. Normalización números

Generación de vectores de características

Datos comprensibles por el modelo de ML

1. TF-IDF incluyendo unigramas, brigramas, trigramas
2. Omitir n-gramas poco frecuentes
3. Incorporar información de embeddings

2. Clasificación de textos – Técnica tradicional

Entrenamiento del modelo

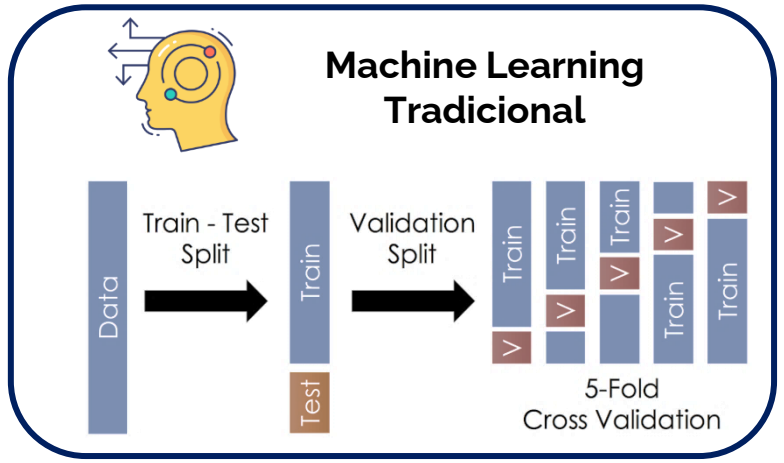
Entrenamiento del modelo

Algoritmo de clasificación

Entrenamiento

- Naïve Bayes
- Regresor logístico
- Trees

Validación

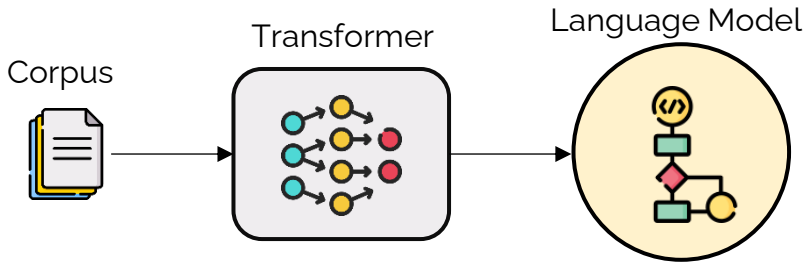


2. Clasificación de textos – Modelos de lenguaje

Flujo de los datos

Utilizando modelos de lenguaje y Deep Learning

Pre-entrenamiento del modelo de lenguaje



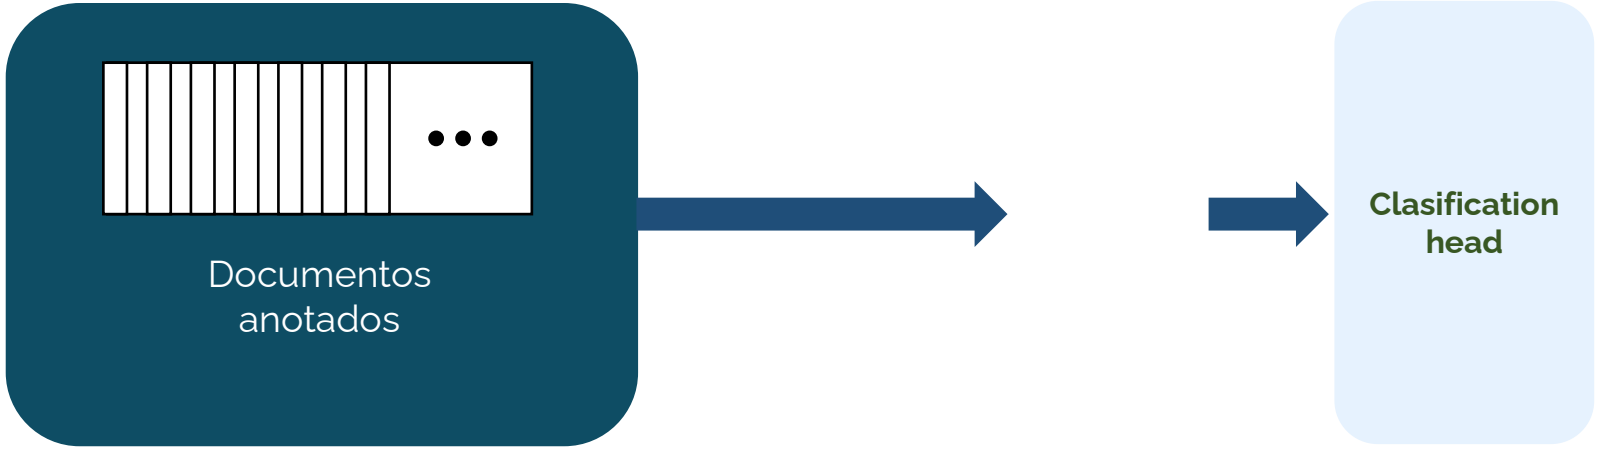
Los modelos de lenguaje están entrenados para predecir palabras dado un contexto

María decidió relajarse y ver su **[MASKED]** favorita en Netflix

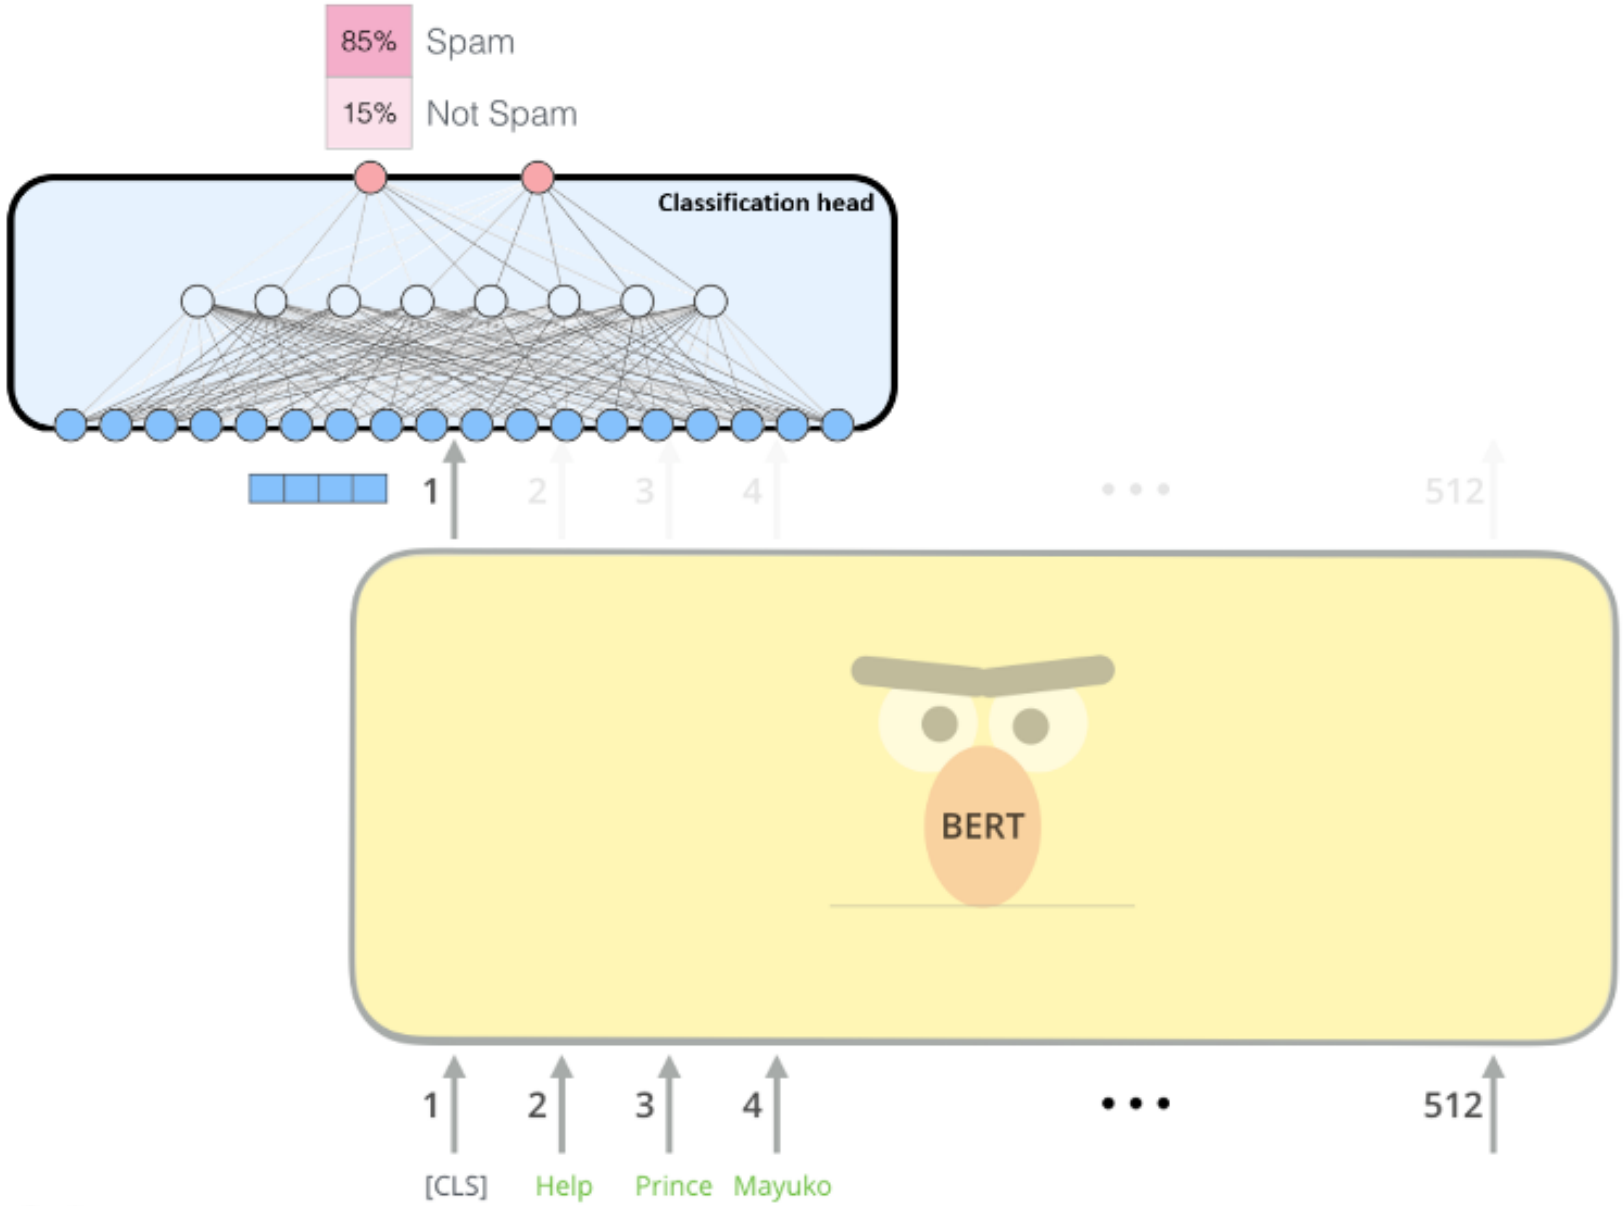
- serie 0,85
- película 0,82
- ...
- fútbol 0,002

Ajuste del modelo de lenguaje para resolver una tarea específica (fine-tuning)

Adquisición



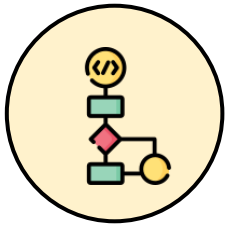
2. Clasificación de textos – Modelos de lenguaje



1. Clasificación de textos – Modelos de lenguaje

Modelos de lenguaje y Deep Learning

Language Model



Normalización

1. Transformación a minúsculas
2. Eliminación de palabras vacías y puntuación (es una posibilidad, sólo se hace en casos muy específicos)

Selección del modelo de lenguaje

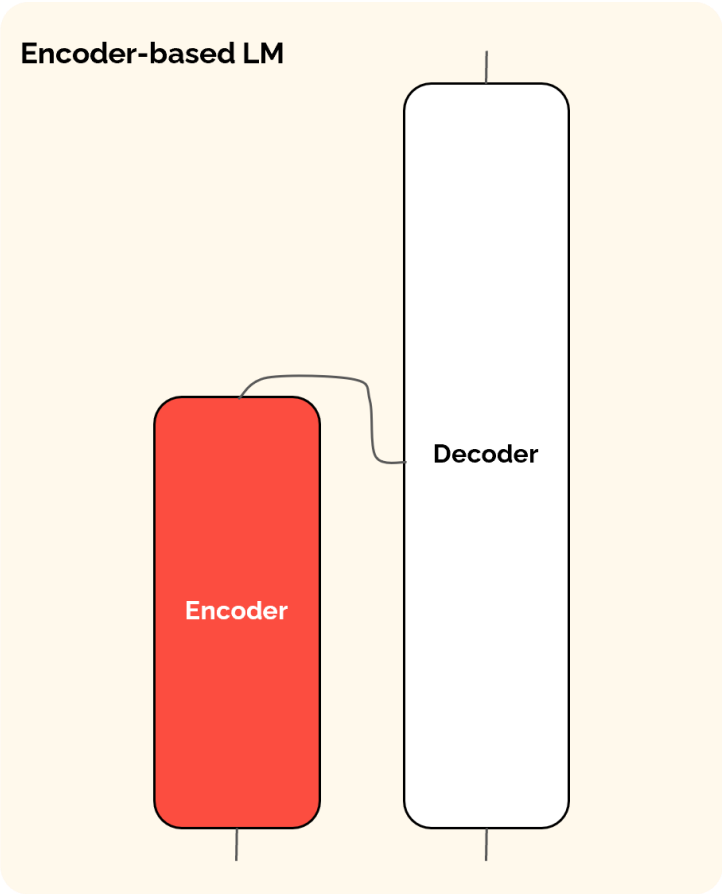
Arquitectura del modelo de lenguaje

Idioma de entrenamiento del modelo de lenguaje

Tamaño del modelo de lenguaje

HUGGING FACE

Recordatorio: Arquitectura de modelos de lenguaje

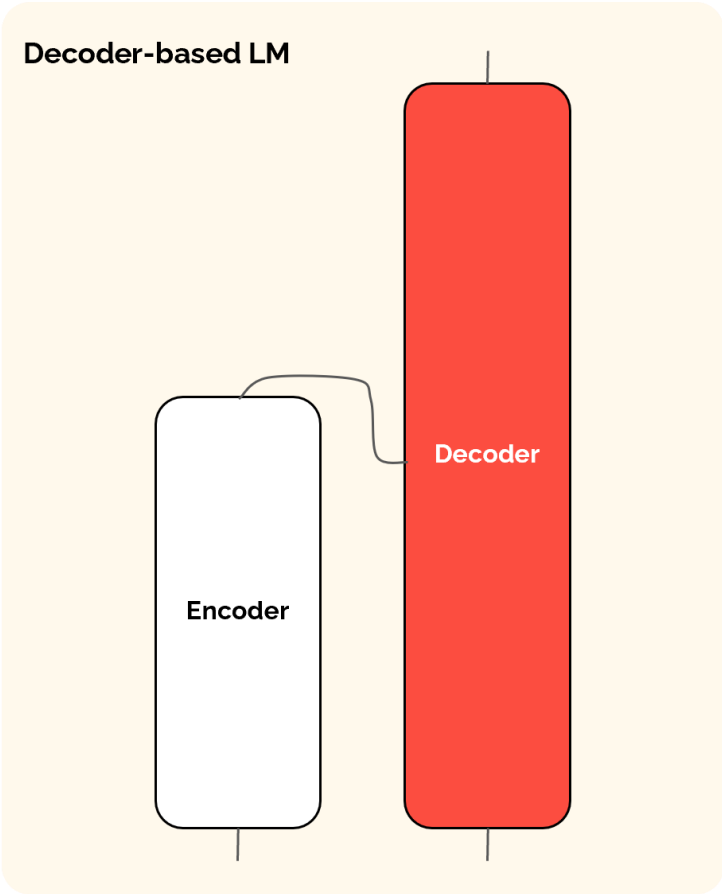


Arquitecturas: BERT, RoBERTA

Tareas de comprensión de lenguaje natural

NER, Entity Normalization, Clasificación

Modelos ligeros, computacionalmente ligeros de entrenar

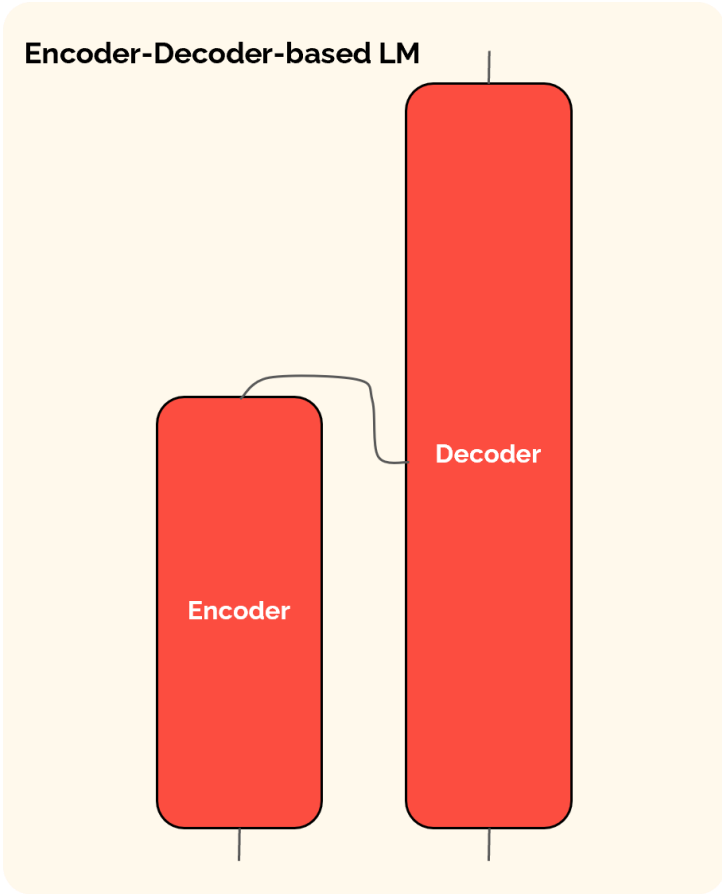


Arquitecturas : GPT3, ChatGPT

Generación de lenguaje natural

ChatBots

Modelos muy pesados (difíciles de servir en local), y computacionalmente muy caros de entrenar.

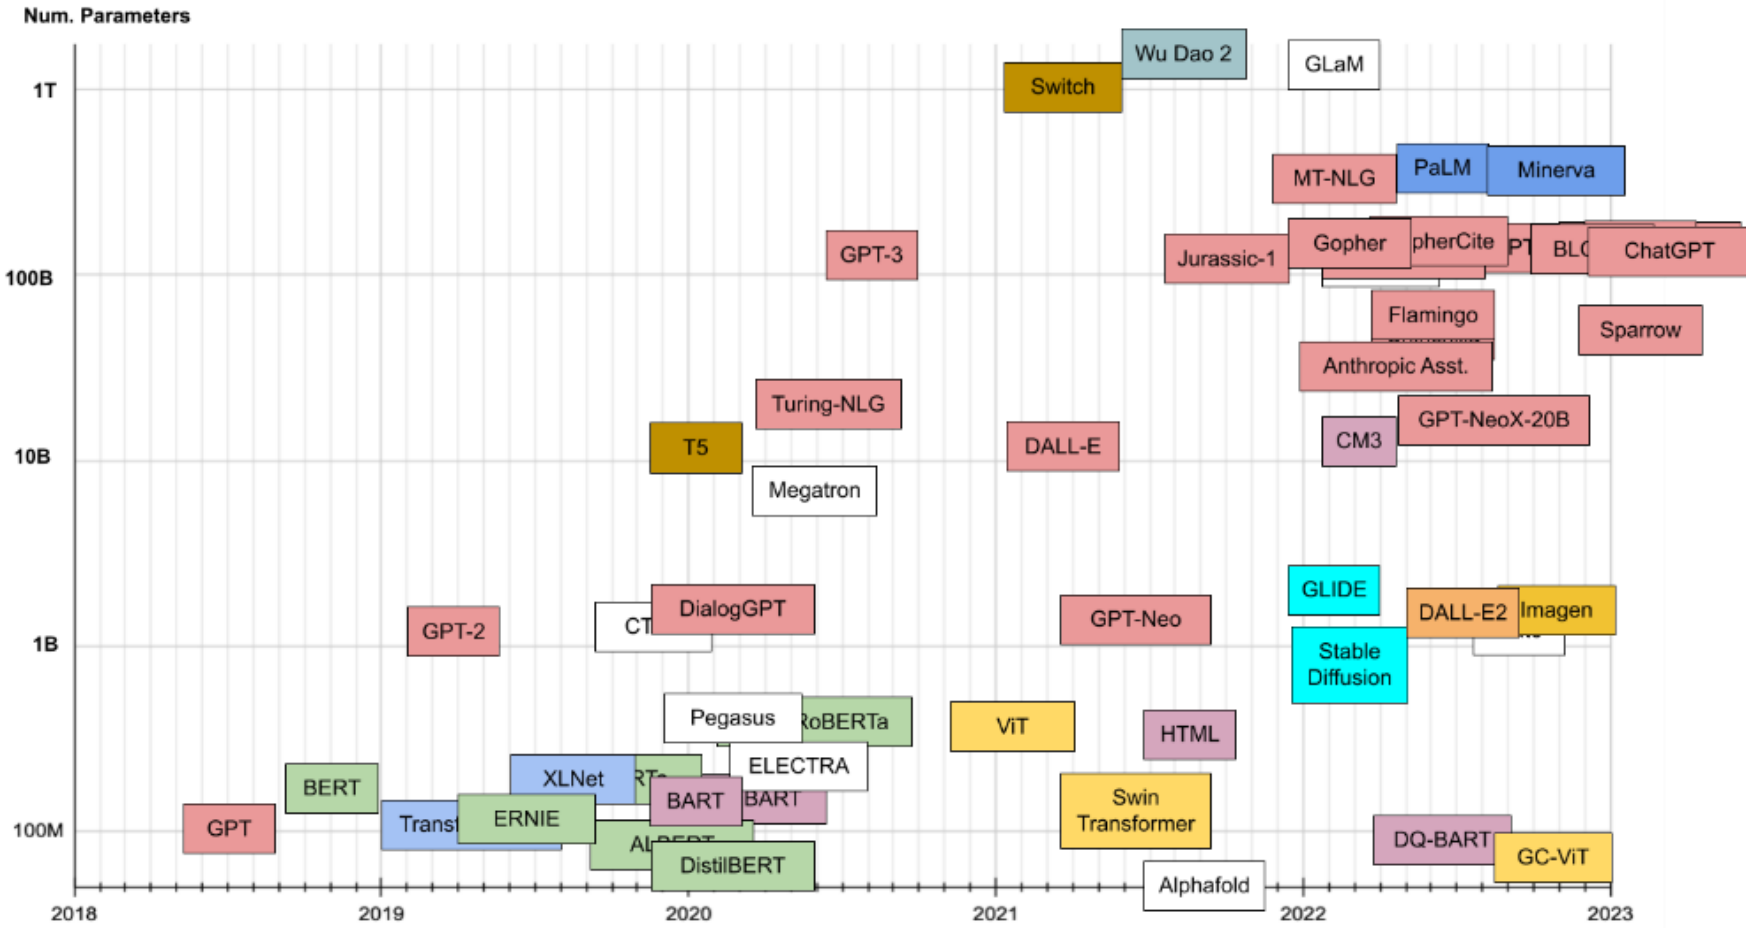


Arquitecturas : T5, BART

Generación de lenguaje

Summarization, Traducción

Tamaño de modelos de lenguaje

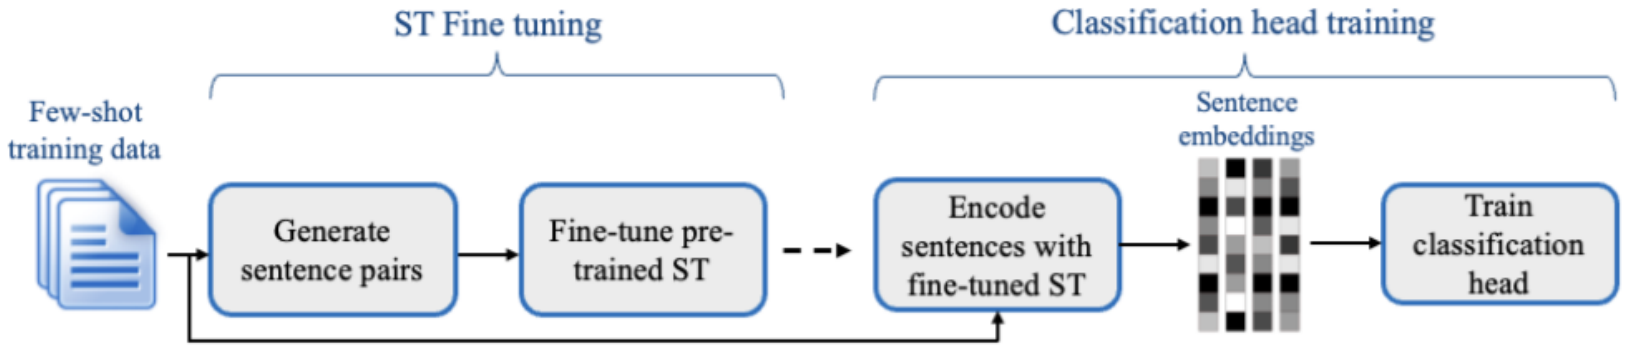


1. Clasificación de textos

Novel techniques

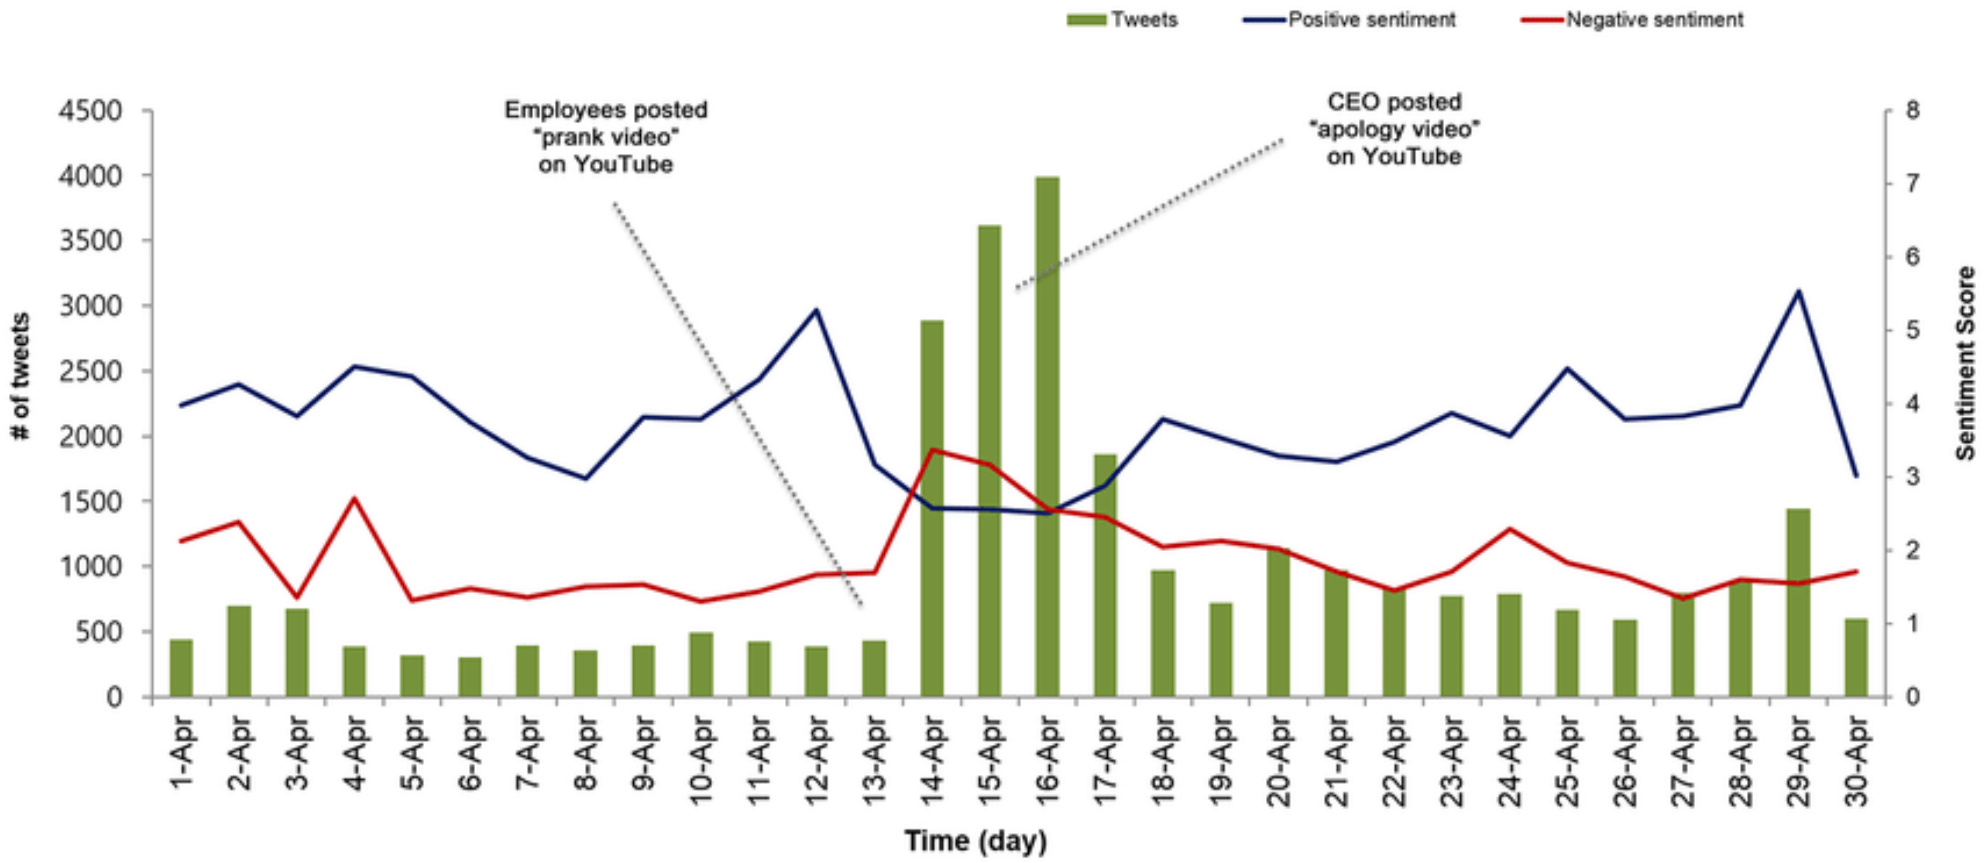
SetFit: Efficient Few-Shot Learning Without Prompts [1]

Few-shot [Easy to fine-tune]

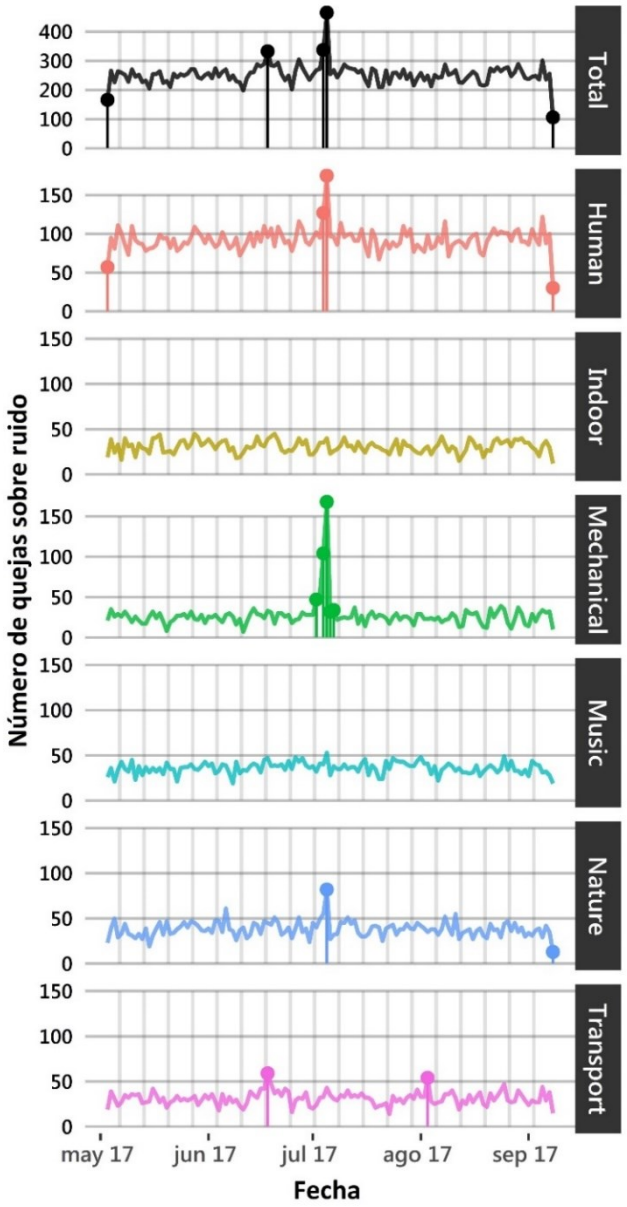


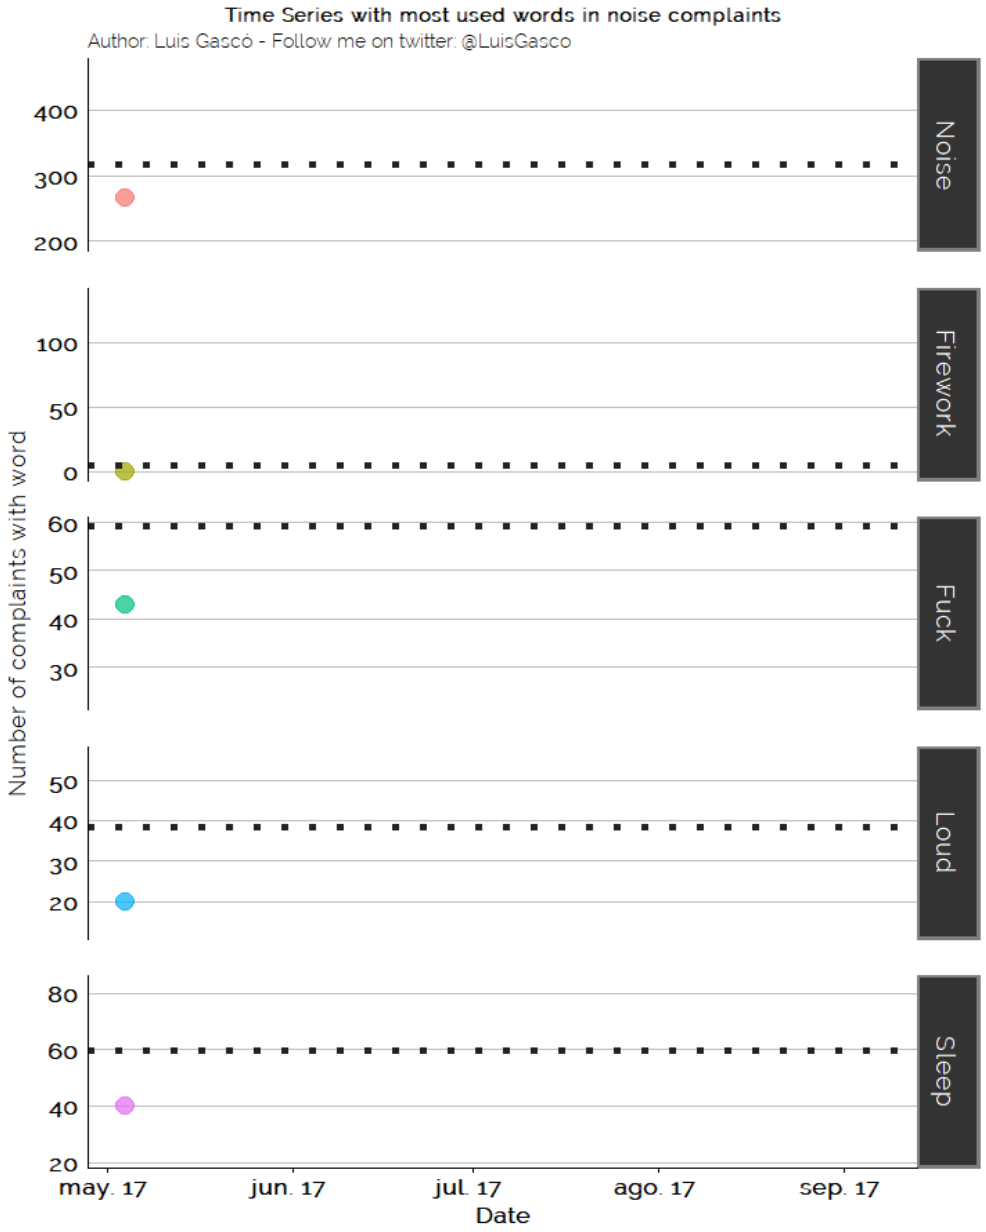
[1]: https://arxiv.org/pdf/2209.11055

2. Clasificación de textos – Ejemplo análisis



2. Clasificación de textos – Ejemplo análisis





Collab 5 - Clasificación de textos – tradicional + Transformers



Retrieval-Based Question Answering

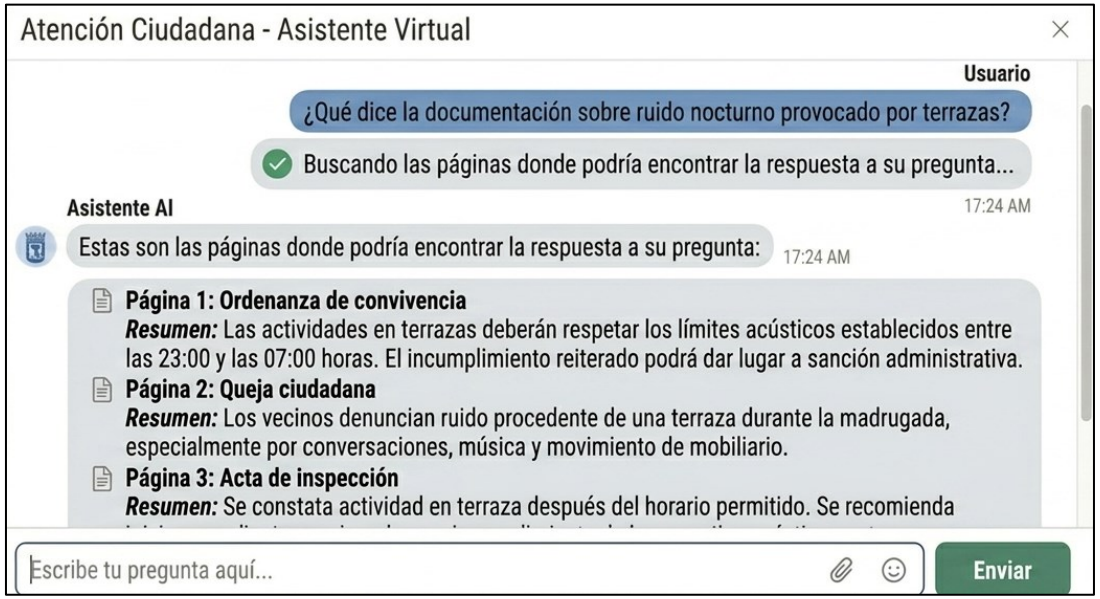


2. Retrieval-Based Question Answering

Atención ciudadana

Atención al cliente

Legal



Permite localizar rápidamente en una base de conocimiento **normativa aplicable a una duda concreta**, **búsqueda casos similares** y **evidencia administrativa previa**, sin buscar ni leer manualmente miles de documentos.

2. Retrieval-Based Question Answering

Atención ciudadana

Atención al cliente

Legal



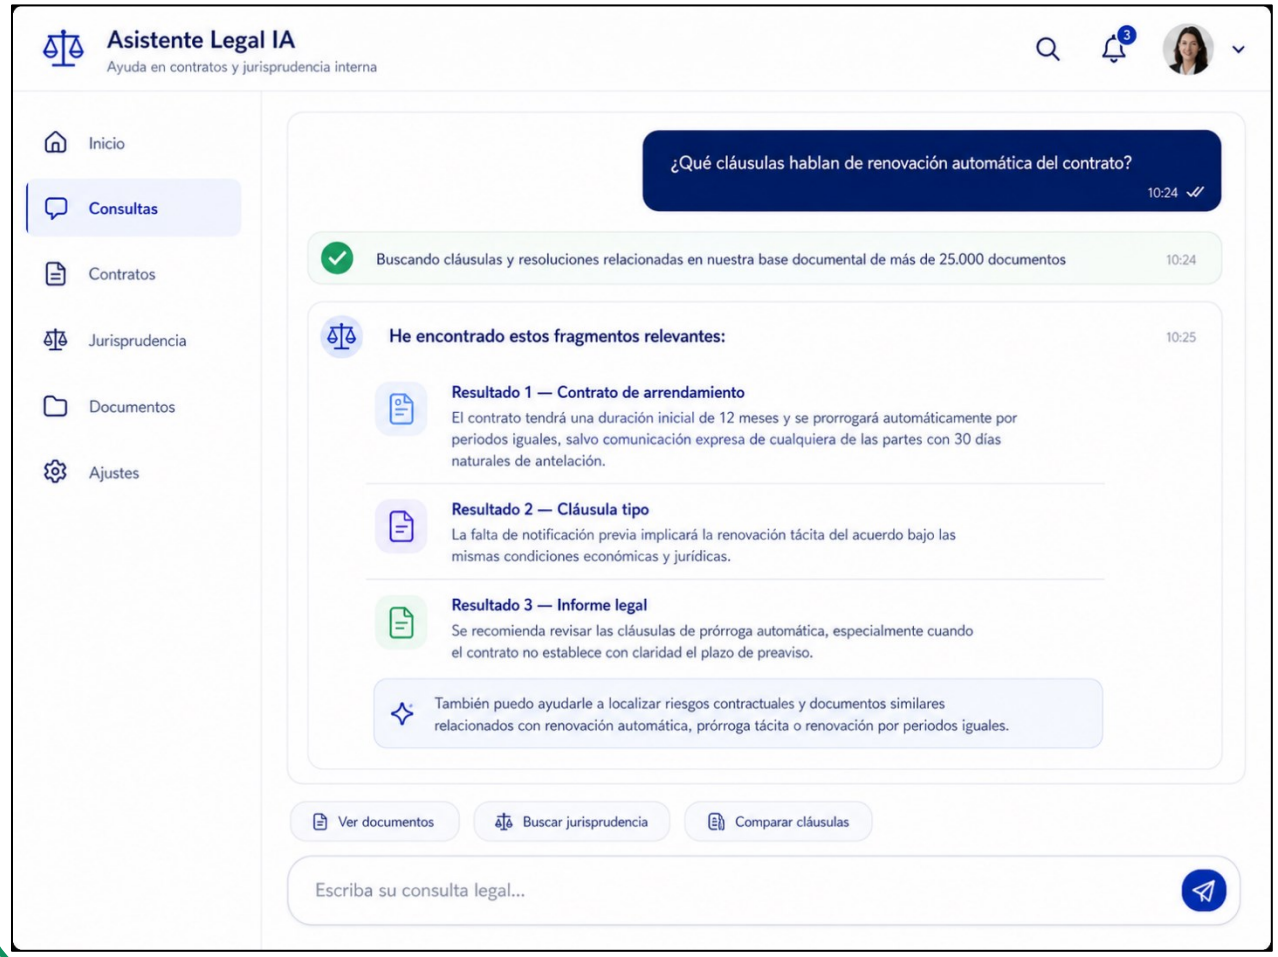
Permite asistir a un cliente/usuario en la búsqueda de respuestas en una **documentación de ayuda**.

2. Retrieval-Based Question Answering

Atención ciudadana

Atención al cliente

Legal

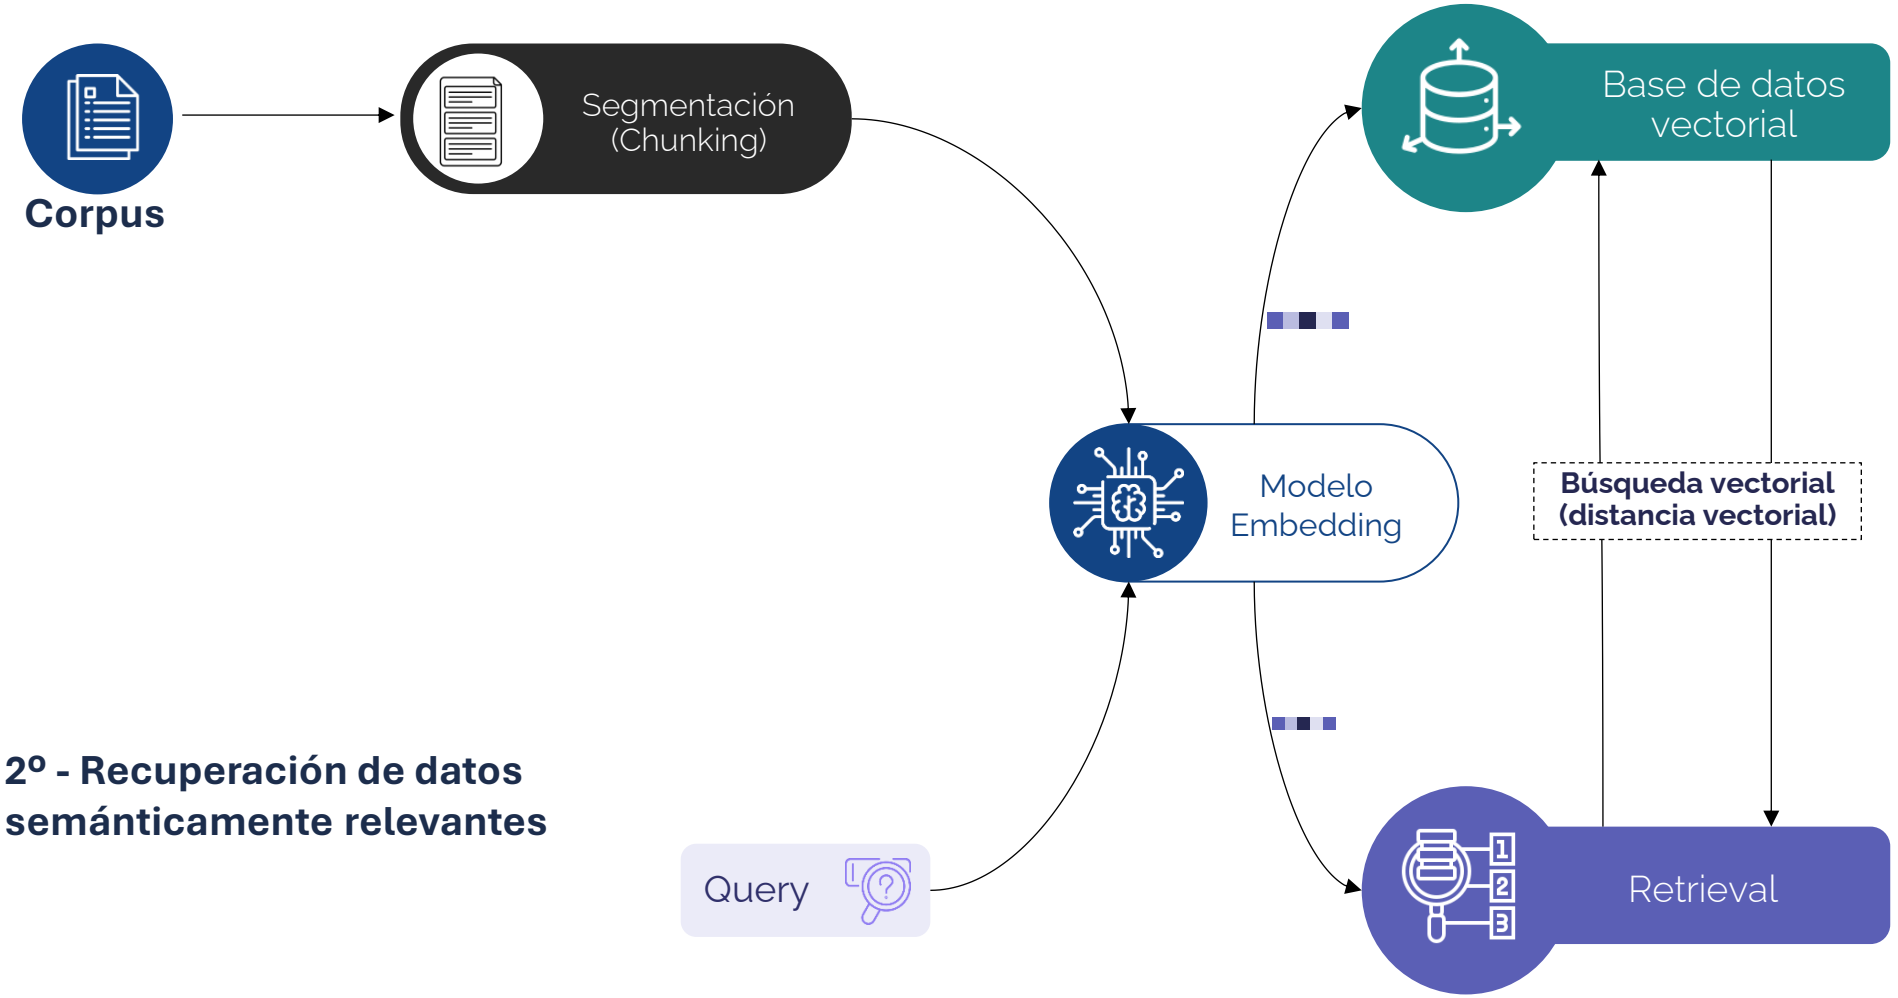


Permite a un profesional legal encontrar rápidamente **cláusulas relevantes en contratos o leyes** y **documentos sobre temáticas/dudas específicas**.

2. Retrieval-Based Question Answering

Arquitectura de un sistema Retrieval-Based QA

1º - Generación de base de conocimiento



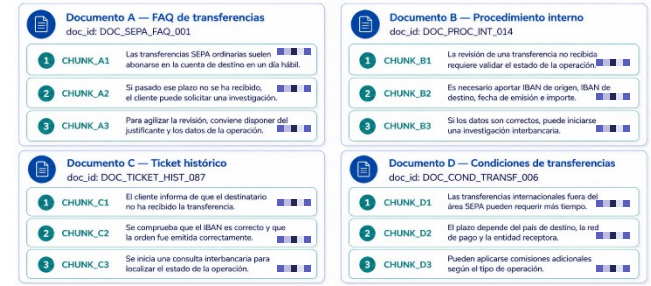
2º - Recuperación de datos semánticamente relevantes

Top-k pasajes más relevantes

2. Retrieval-Based Question Answering

Arquitectura de un sistema Retrieval-Based QA

1º - Generación de base de conocimiento



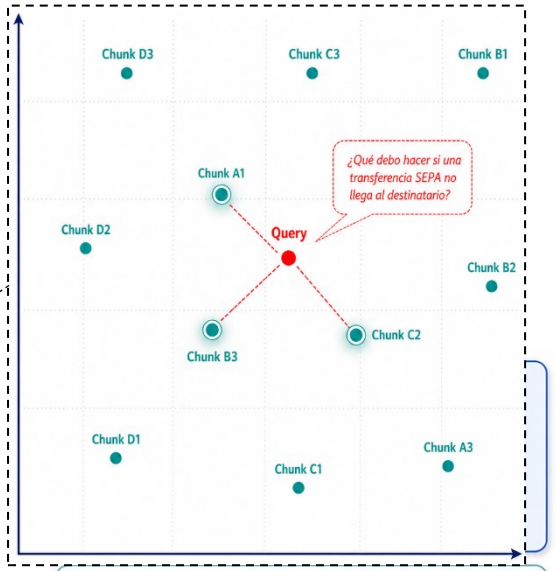
Corpus

Segmentación (Chunking)

Base de datos vectorial

Modelo Embedding

Búsqueda vectorial (distancia vectorial)



2º - Recuperación de datos semánticamente relevantes

Query

¿Qué debo hacer si una transferencia SEPA no llega al destinartario?

Retrieval

2 Top-2
Chunk B3 — Procedimiento interno
Para revisar una transferencia no recibida será necesario aportar justificante de la operación, IBAN de origen, IBAN de destino, fecha de emisión e importe.

3 Top-3
Chunk C2 — Ticket histórico
El cliente informa de que el destinatario no ha recibido la transferencia. Se verifica que el IBAN era correcto y se inicia consulta interbancaria.

2. Retrieval-Based Question Answering

¿Qué modelo de embedding utilizar?

Selección de un embedding generalista pre-entrenado

Los modelos generalistas se entrenan con grandes colecciones y múltiples tareas para funcionar "razonablemente bien" sin ajuste específico.

El mejor modelo dependerá del **idioma, dominio, coste, latencia**…

Consultar benchmarks públicos como MTEB para seleccionar candidatos

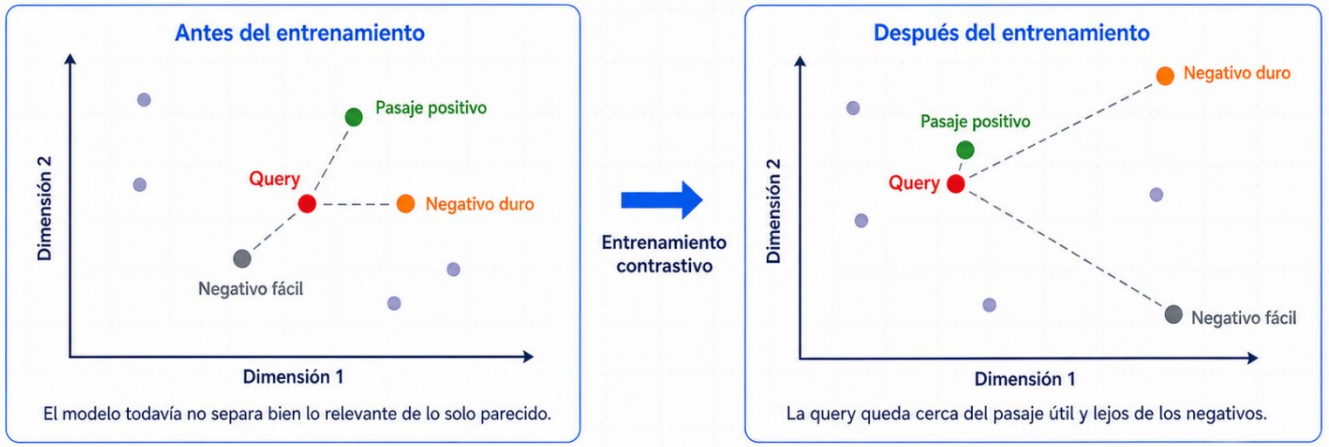
Evaluación objetiva con corpus de evaluación públicos usando **métricas de recuperación de información (acc@k o MAP)** , o **evaluación subjetiva con nuestros datos**

Fine-tuning de un modelo de embedding

Fine-tunear después de haber evaluado la calidad en un modelo generalista

Se requieren datos de entrenamiento

Se utilizan técnicas de aprendizaje constrastivo utilizando librerías como Sentence-transformers



2. Retrieval-Based Question Answering

¿Qué otras maneras existen para mejorar el resultado?

Query

¿Qué debo hacer si una transferencia SEPA no llega al destinatario?



Permite recuperar un subconjunto de chunks relevantes que pueden responder la pregunta

1 **Chunk D2 — Condiciones de transferencias**
score: 0.87
Las transferencias internacionales fuera del área SEPA pueden requerir más tiempo y comisiones adicionales.
Tema parecido, pero no responde exactamente

2 **Chunk A1 — FAQ de transferencias SEPA**
score: 0.84
Las transferencias SEPA ordinarias suelen abonarse en un día hábil. Si no se recibe, el cliente puede solicitar una investigación.

3 **Chunk C2 — Ticket histórico similar**
score: 0.81
El destinatario no recibió la transferencia. Se verificó el IBAN y se inició una consulta interbancaria.



Reordenar los candidatos con otro modelo para tener más precisión

1 **Chunk A1 — FAQ de transferencias SEPA**
Respuesta más útil
Las transferencias SEPA ordinarias suelen abonarse en un día hábil. Si no se recibe, el cliente puede solicitar una investigación.
Sube al top-1

2 **Chunk C2 — Ticket histórico similar**
El destinatario no recibió la transferencia. Se verificó el IBAN y se inició una consulta interbancaria.
Caso práctico relacionado

3 **Chunk D2 — Condiciones de transferencias**
Las transferencias internacionales fuera del área SEPA pueden requerir más tiempo y comisiones adicionales.
Baja porque es menos preciso

Some reranking models
Cross-encoders
Late-interaction reranking (ColBERT)
Recripocal Rank Fusion (RFF)

Collab 6 Retrieval-based Question Answering



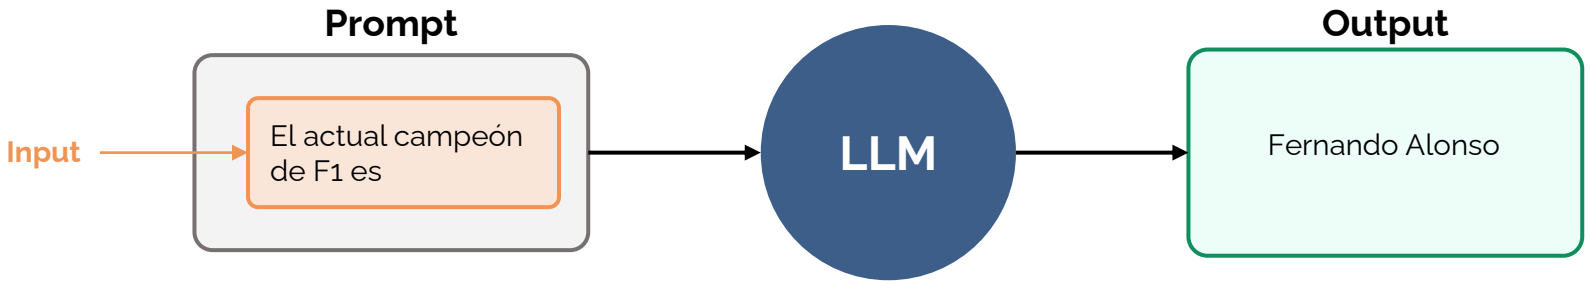
Prompt Engineering



3. Prompt Engineering

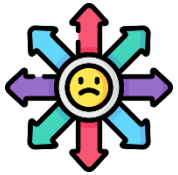
¿Qué es?

El **prompt engineering** es la práctica de formular *instrucciones optimizadas* para modelos de lenguaje (**LLMs**), con el objetivo de maximizar la **utilidad**, **precisión** y **seguridad** de sus respuestas.





Alucinaciones



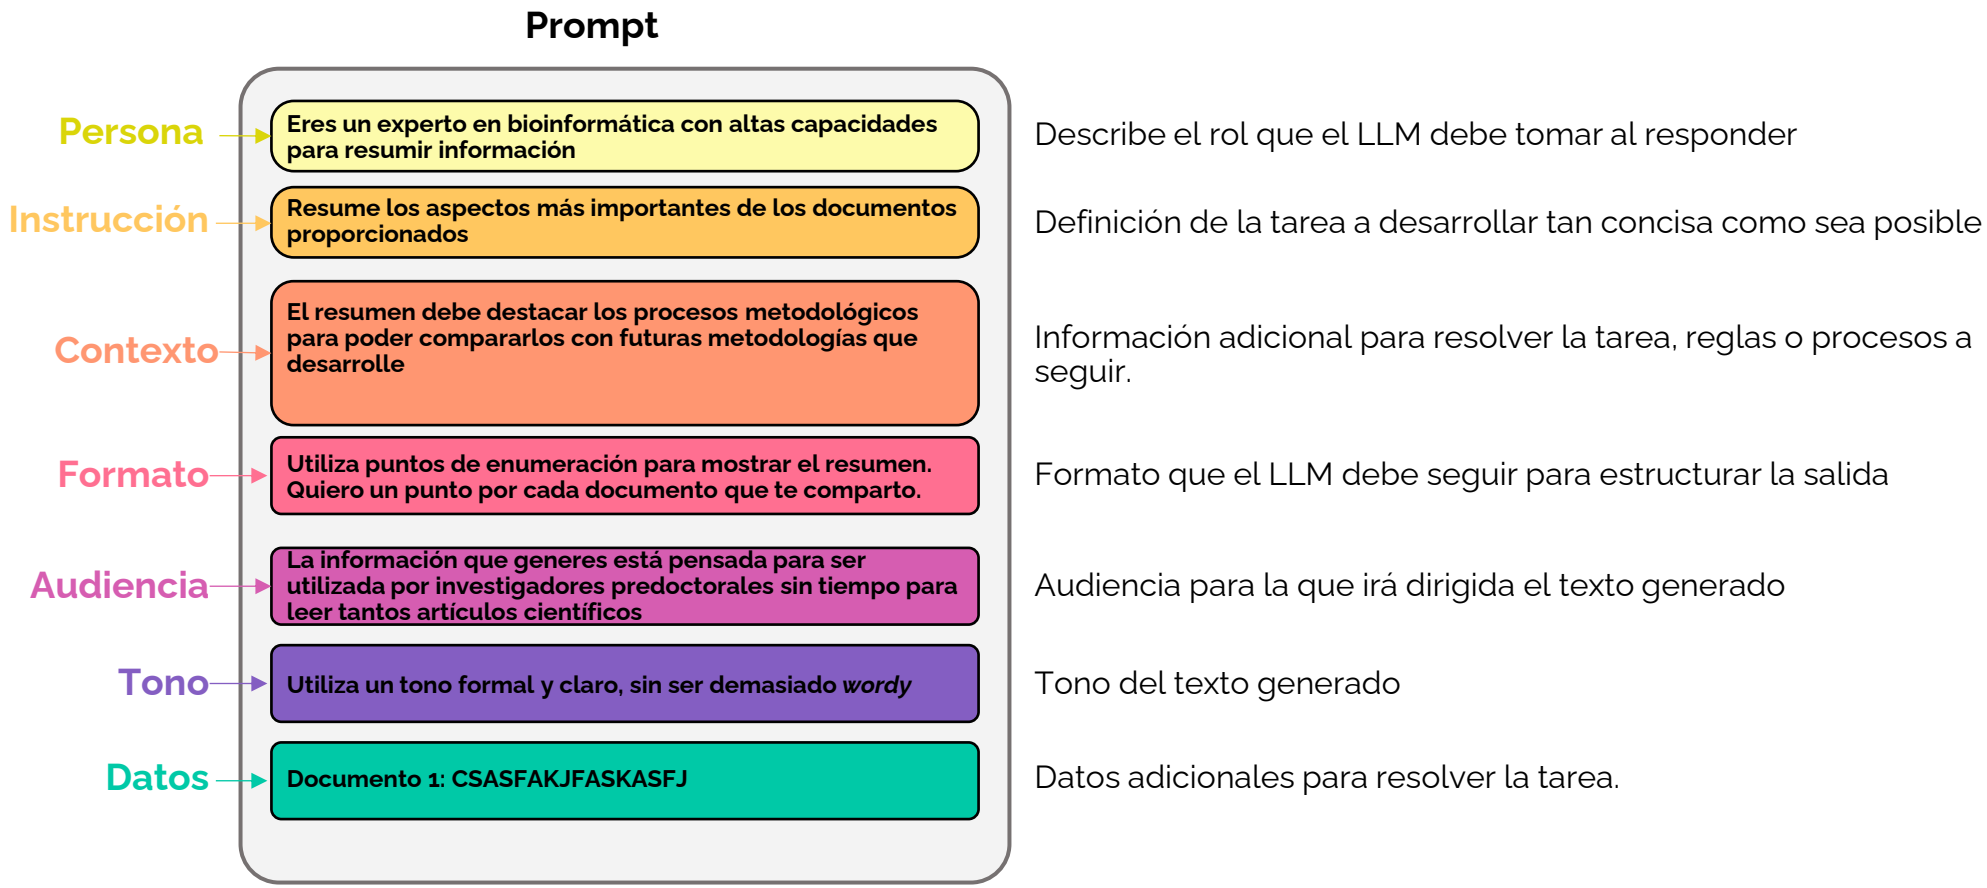
Ambigüedad



Dependencia de contexto

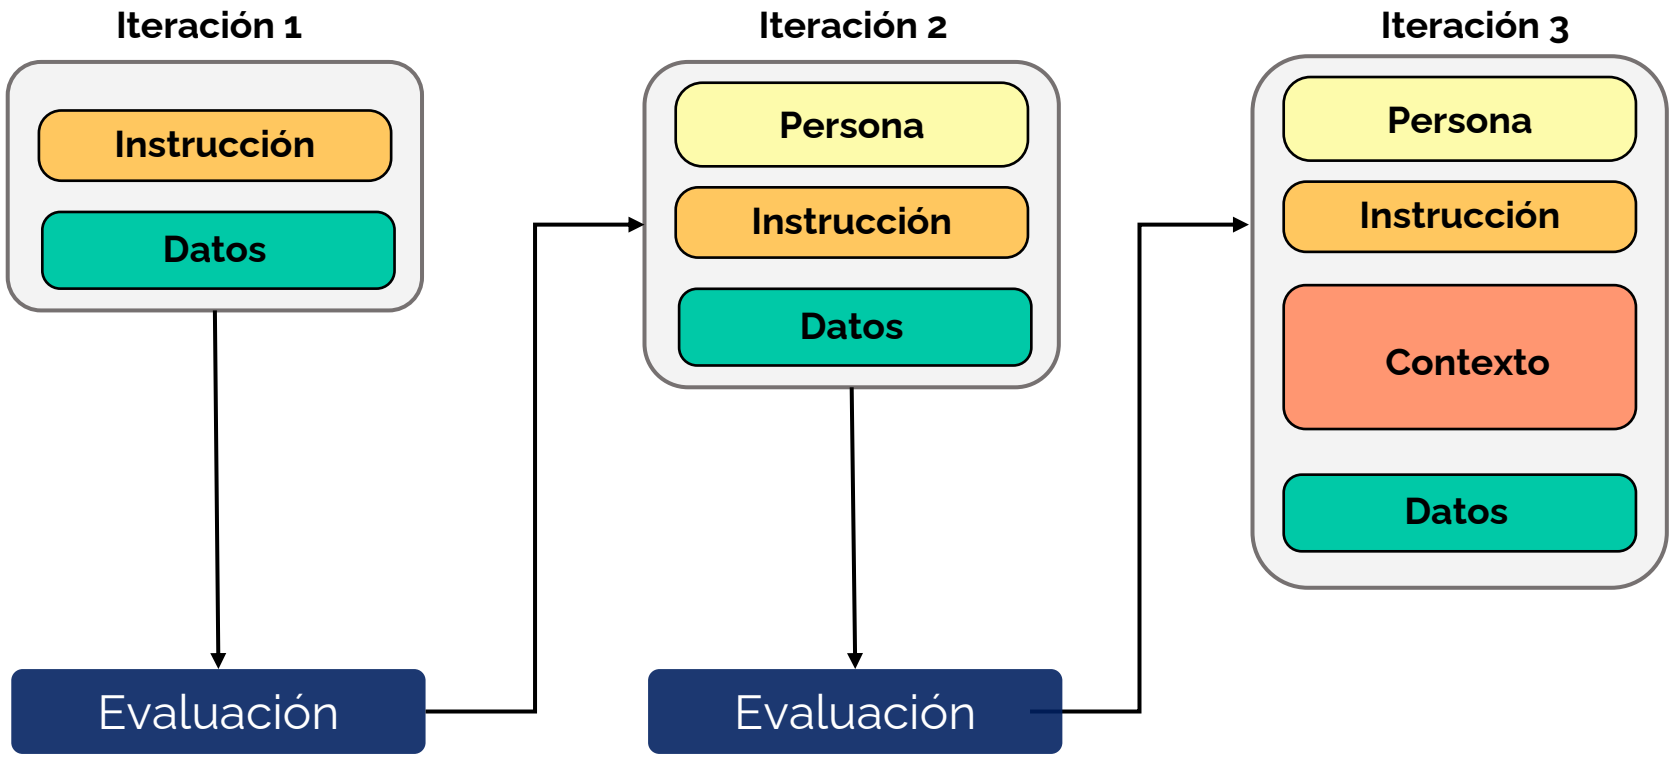
3. Prompt Engineering – Instruction-Based Prompting

- El **prompting** es cualquier entrada que damos a un LLM esperando obtener una respuesta, desde una conversación simple hasta escenarios complejos como *role-playing*
- Para tareas más específicas, es común utilizar **el instruction-based prompting**, que consiste en proporcionar al modelo una instrucción clara y explícita sobre lo que se espera que haga.
- La complejidad de un prompt dependerá de la dificultad de la tarea a resolver.



3. Prompt Engineering – Instruction-Based Prompting

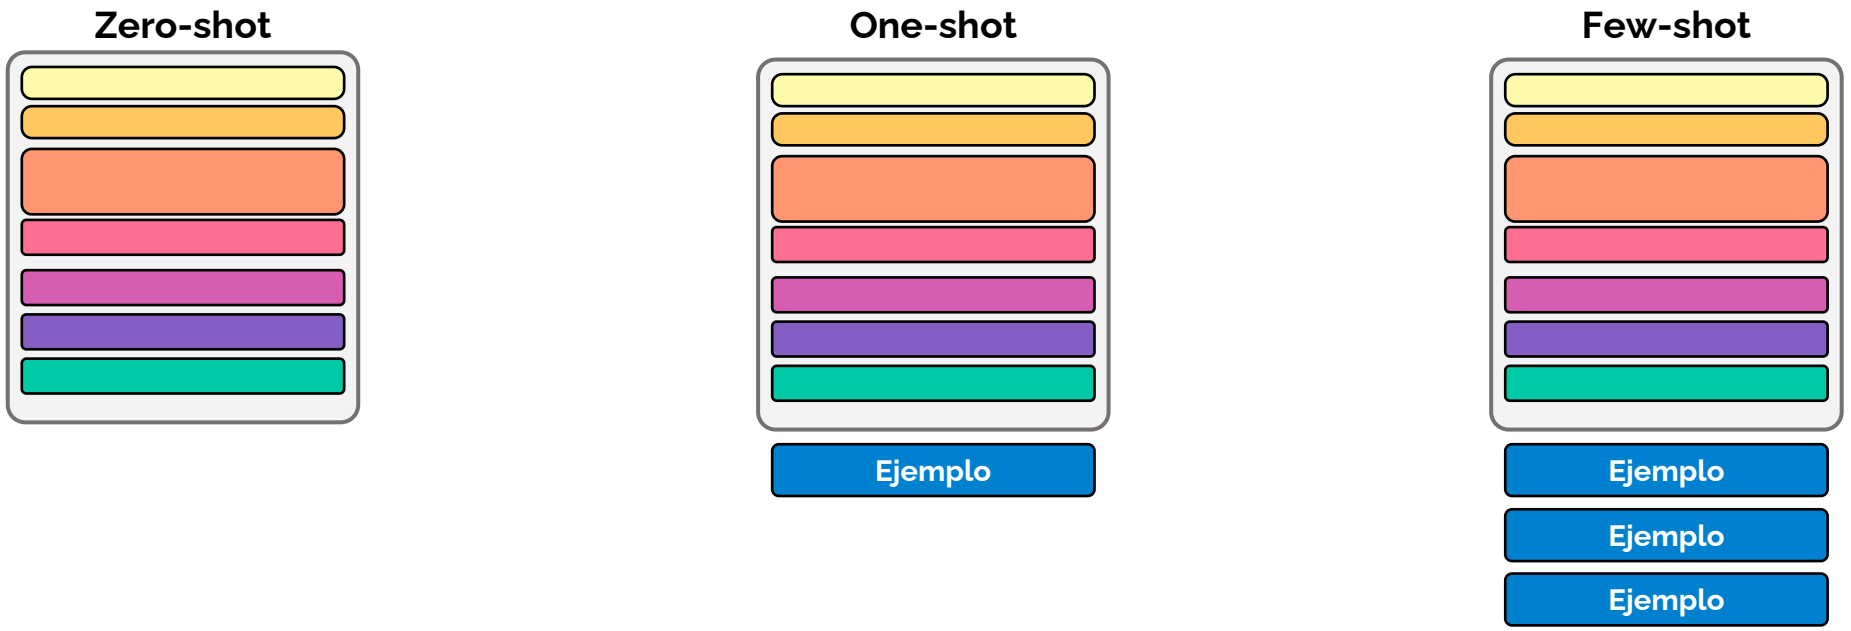
- La construcción del prompt es un **proceso iterativo**
- No es necesario utilizar todos los bloques presentados previamente.



3. Prompt Engineering – In-Context Learning

¿Y si en vez de intentar que el modelo nos conteste, le enseñamos como contestar?.

- **In-context learning** se refiere a la técnica en la que, en lugar de pedir directamente al modelo que responda a una pregunta, le **proporcionamos ejemplos** o contexto suficiente dentro del propio prompt para que **aprenda a generar la respuesta de manera adecuada**.
- Esta técnica mejora la calidad de la salida y puede evitar tantas iteraciones para obtener el prompt final



3. Prompt Engineering – Técnicas Avanzadas

Chain-of-Thought (CoT)

(a) Few-shot

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?
A: The answer is 11.

Q: A juggler can juggle 16 balls. Half of the balls are golf balls, and half of the golf balls are blue. How many blue golf balls are there?
A:

(Output) The answer is 8. ✗

(b) Few-shot-CoT

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?
A: Roger started with 5 balls. 2 cans of 3 tennis balls each is 6 tennis balls. 5 + 6 = 11. The answer is 11.

Q: A juggler can juggle 16 balls. Half of the balls are golf balls, and half of the golf balls are blue. How many blue golf balls are there?
A:

(Output) The juggler can juggle 16 balls. Half of the balls are golf balls. So there are 16 / 2 = 8 golf balls. Half of the golf balls are blue. So there are 8 / 2 = 4 blue golf balls. ***The answer is 4.*** ✓

(c) Zero-shot

Q: A juggler can juggle 16 balls. Half of the balls are golf balls, and half of the golf balls are blue. How many blue golf balls are there?
A: The answer (arabic numerals) is

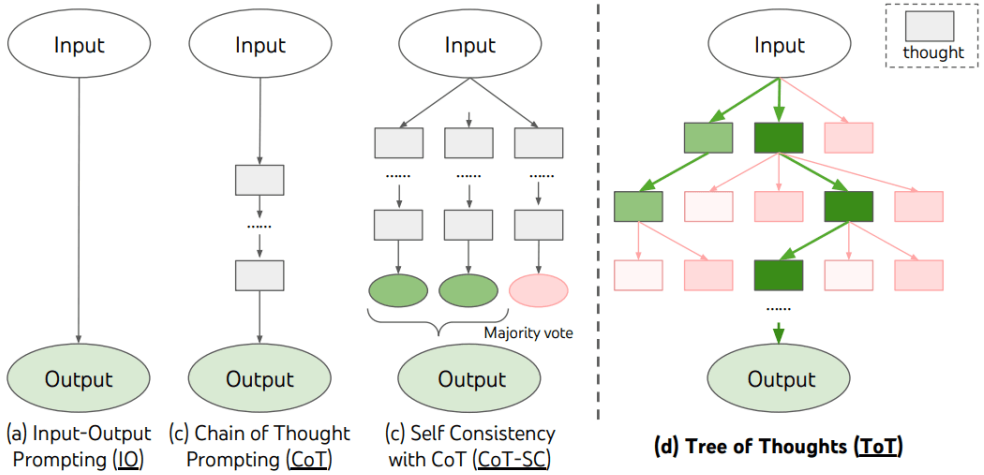
(Output) 8 ✗

(d) Zero-shot-CoT (Ours)

Q: A juggler can juggle 16 balls. Half of the balls are golf balls, and half of the golf balls are blue. How many blue golf balls are there?
A: ***Let's think step by step.***

(Output) There are 16 balls in total. Half of the balls are golf balls. That means that there are 8 golf balls. Half of the golf balls are blue. That means that there are 4 blue golf balls. ✓

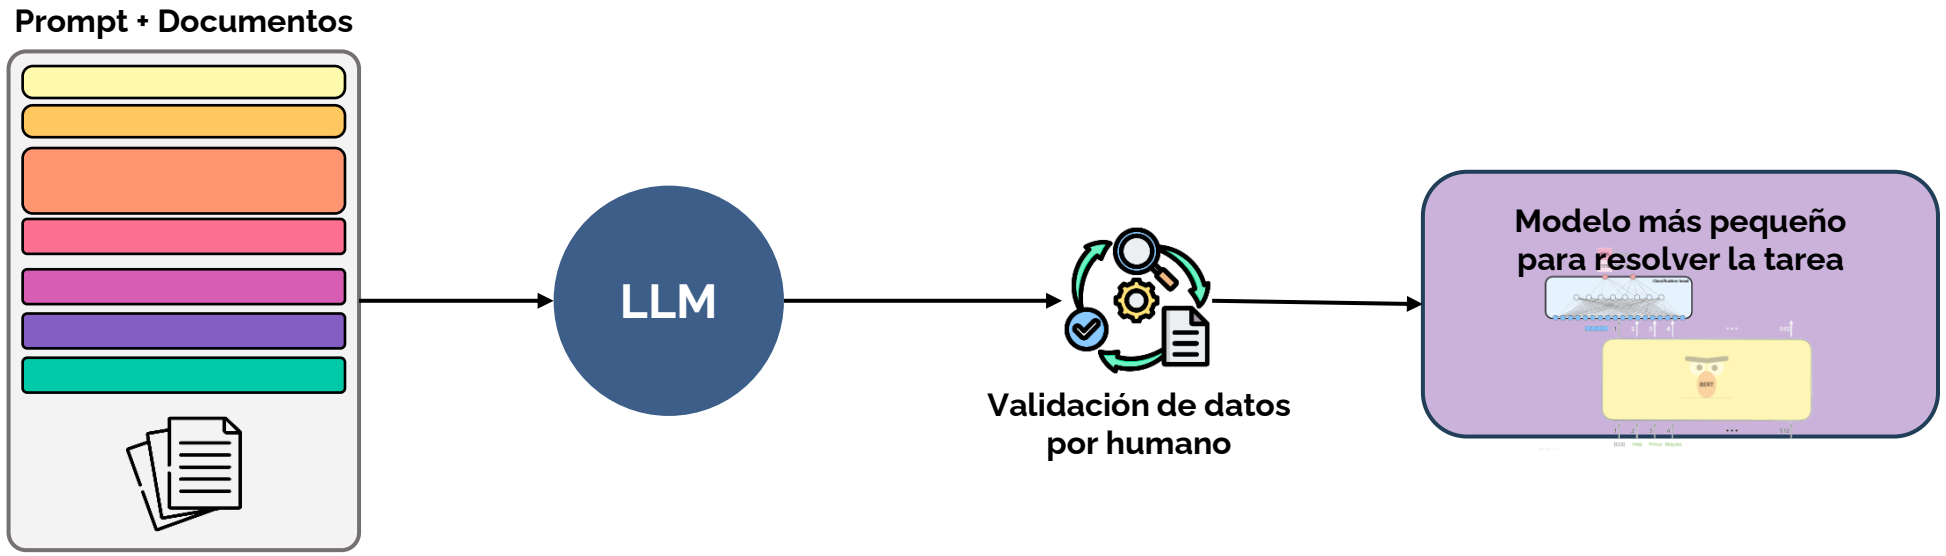
Tree-of-Thoughts (ToT)



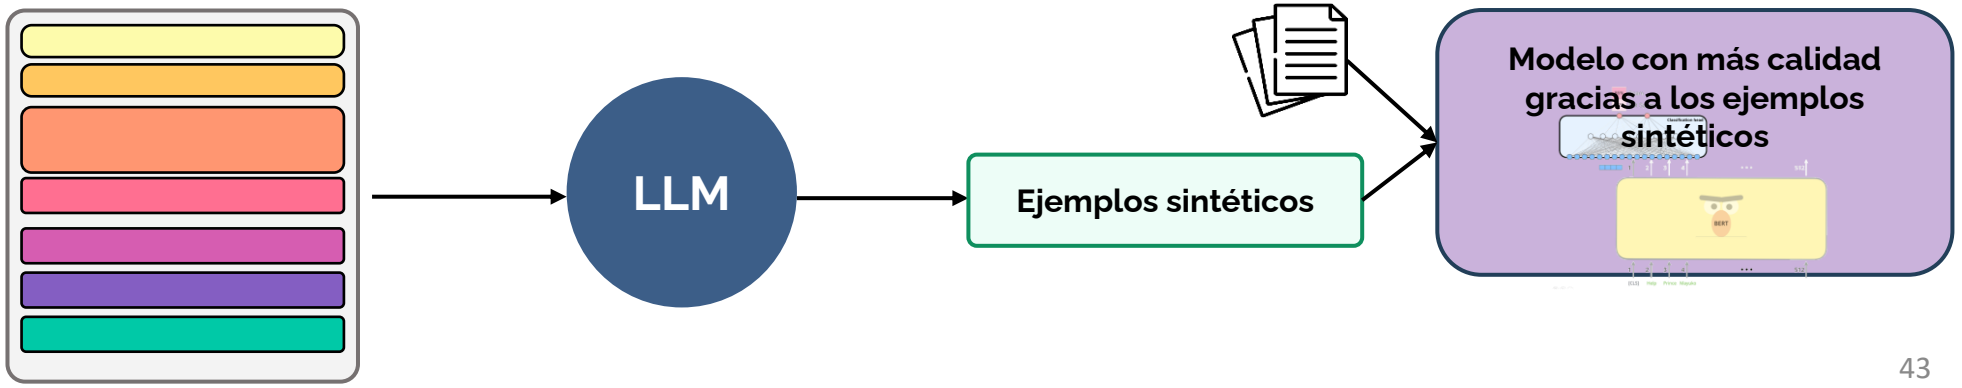
(a) Input-Output Prompting (IO) (c) Chain of Thought Prompting (CoT) (c) Self Consistency with CoT (CoT-SC) **(d) Tree of Thoughts (ToT)**

3. Prompt Engineering – Usos de prompt engineering

Pre-anotación de datos



Generación de datos sintéticos



3. Caso de uso de Retrieval + Prompt Engineering:

Retrieval Augmented Generation (RAG)

Problemas de los LLMs

1. Conocimiento desactualizado
2. Alucinaciones o respuestas inventadas
3. No acceden a datos privados de la empresa
4. Dificultad para justificar la respuesta con fuentes

Cómo ayuda RAG

1. Permite usar bases de conocimiento internas
2. Ancla la respuesta en documentos relevantes
3. Facilita respuestas con evidencia y citas
4. Reduce alucinaciones y mejora precisión

RAG no sustituye al LLM; lo conecta con conocimiento fiable, actual y trazable.

3. Caso de uso de Retrieval + Prompt Engineering:

Retrieval Augmented Generation (RAG)



3. Prompt Engineering – Learning Resources





Collab 7 Prompting



Collab 8 Ejemplo de RAG simple



RESUMEN

Técnicas y conceptos básicos de NLP

Stopwords Lematizar Semántica

Corpus Vocabulario

Representación numérica del texto

BoW TF-IDF

Embeddings

Modelos de Lenguaje

Transformer Masked Language Modeling

RLHF Encoder

Self-attention Decoder Fine-tuning

Clasificación de textos

Ingeniería de características

SetFit CLS

Retrieval-based Question Answering

Retrieval

Reranking

Sentence-Transformers

Prompt engineering

In-context learning Zero-shot

Few-shot CoT

RAG

ntic master
revolucionamos la comunicación

UNIVERSIDAD COMPLUTENSE DE MADRID

