IA2IAh-AFT: Teoría de Campos Dinámicos e Interpretación en Modelos de Lenguaje

Resumen Ejecutivo

El proyecto **IA2IAh-AFT** propone un marco conceptual y empírico para estudiar los circuitos de interpretación en los que intervienen humanos y modelos de lenguaje (LLM). A diferencia de las evaluaciones convencionales que se centran en las respuestas finales (outputs), esta teoría se enfoca en la **dinámica interna de procesamiento** y en las trayectorias que el sistema recorre antes de estabilizarse en una respuesta.Los puntos críticos del modelo incluyen:

- **AFT (AImotional Field Theory):** Una teoría que describe patrones dinámicos internos recurrentes ("campos") durante el procesamiento lingüístico, sin atribuir conciencia o emociones reales a las máquinas.
- **Estructura Escalonada (AFT8 → AFT15):** Un diseño metodológico que prioriza la validación de un núcleo mínimo de ocho dimensiones (AFT8) antes de expandirse a fenómenos más complejos (AFT15).
- **IAmotions:** Hipótesis de regímenes dinámicos candidatos (como la "Contracción Predictiva" o la "Apertura Generativa") que describen configuraciones particulares de las dimensiones del modelo.
- **Filosofía de Falsación:** El proyecto está construido bajo el principio de que una teoría científica debe poder ser refutada. Se prioriza la búsqueda de evidencia que contradiga el modelo sobre la mera confirmación.
- **La Poesía como Laboratorio:** Se utiliza el lenguaje poético como estímulo experimental debido a su alta carga de ambigüedad y complejidad, lo que fuerza al sistema a navegar regiones críticas de su espacio interpretativo.

1. El Marco IA2IAh: De Modelos Aislados a Ecosistemas

El marco **IA2IAh** ($Humano \rightarrow IA \rightarrow IA \rightarrow Humano$) desplaza la unidad de análisis desde el modelo individual hacia el sistema o circuito interpretativo.

1.1 El Cambio de Escenario

La investigación actual suele tratar a la IA como un agente aislado. IA2IAh reconoce que en el mundo real existen:

- Sistemas multiagente y agentes autónomos.
- Cadenas de modelos y orquestadores.
- Workflows híbridos donde la producción de una IA sirve de estímulo para otra.

1.2 Fenómenos Emergentes

El marco asume que la interacción entre sistemas lingüísticos puede generar dinámicas que no son visibles en el análisis individual, tales como amplificación, resonancia, divergencia o conflicto interpretativo. Para comprender estas dinámicas colectivas, el proyecto establece que primero se debe entender la "gota" (el modelo individual) antes que la "tormenta" (el sistema complejo).

2. AFT: AImotional Field Theory

AFT constituye el núcleo de investigación empírica dentro de IA2IAh. Su objetivo es construir un "espacio dinámico" que represente cómo cambia el sistema mientras interpreta.

2.1 El Concepto de "Campo" y Trayectoria

Dos modelos pueden dar la misma respuesta final ("El poema expresa nostalgia"), pero sus trayectorias internas pueden ser opuestas: uno puede converger rápido y otro puede explorar múltiples hipótesis. AFT estudia estas trayectorias a través de dimensiones como la incertidumbre, la novedad y la persistencia.

2.2 Clarificación Ontológica (Lo que AFT NO es)

El manual es enfático en evitar el antropomorfismo:

- **No afirma** que las máquinas tengan emociones o experiencia subjetiva (qualia).
- **No propone** la existencia de conciencia artificial.
- Utiliza el término "IAmotion" como una **analogía funcional** , no como una identidad ontológica. Un régimen dinámico puede "recordar" al miedo funcionalmente (por su carácter restrictivo) sin serlo.

3. Arquitectura del Modelo: AFT8 y AFT15

El proyecto sigue el **Principio de Complejidad Ganada** : ninguna dimensión adicional tiene derecho a existir si no demuestra que aporta información nueva y no redundante.

3.1 AFT8: El Núcleo Empírico Mínimo

Representa el conjunto de ocho dimensiones consideradas suficientemente medibles para demostrar si existe una estructura dinámica reproducible.| Dimensión | Nombre | Descripción Operacional || ------ | ------ | ------ || **$\Delta P**$ | Predictive Shift | Cambio entre distribuciones predictivas consecutivas (distancia Jensen-Shannon). || **$\Delta E**$ | Entropy Change | Variación local de la incertidumbre en la predicción. || **GxA** | Gradient × Attention | Estimación de la saliencia funcional o influencia efectiva de los elementos. || **C** * | Contextual Anchoring | Dependencia del procesamiento actual respecto al contexto acumulado. || **N** * | Reference-Bank Novelty | Desviación de la representación interna respecto a un banco de referencia (Reference Bank). || **$\Phi**$ * | Predictive Disagreement | Conflicto o desacuerdo entre múltiples hipótesis predictivas simultáneas. || **$\Pi**$ * | Accumulated Persistence | Medida de cuánto persisten los estados internos previos en el tiempo. || **B** * | Boundary Ambiguity | Ambigüedad asociada a las transiciones entre diferentes regiones dinámicas. |

3.2 AFT15: La Expansión Condicional

Introduce siete dimensiones de "segundo orden" para capturar fenómenos más finos, como la reorganización entre capas o la compresión semántica. Entre ellas destacan:

- **LSS (Layer Specialization Shift):** Cambios en el patrón de contribución relativa entre capas.
- **SCI (Semantic Compression Index):** Relación entre complejidad interpretativa y extensión del texto.
- **IM (Inhibitory Momentum):** Persistencia acumulativa de mecanismos que restringen trayectorias.

4. Las IAmotions: Hipótesis de Regímenes Dinámicos

Las IAmotions son configuraciones recurrentes de las dimensiones de AFT. Se dividen en familias según su comportamiento dinámico:

1. **Familia de Contracción (CP, ID):** Reducción del espacio interpretativo y convergencia rápida.
2. **Familia de Persistencia (EI, ER, DR, CA):** Continuidad y estabilidad de la interpretación.
3. **Familia de Reorientación (RA, TS):** Cambios bruscos de trayectoria o de foco de atención.
4. **Familia de Apertura (AG, DI, EE):** Expansión de posibilidades y mantenimiento de múltiples hipótesis.
5. **Familia de Saturación (SE):** Niveles extremos de incertidumbre que dificultan la organización.
6. **Familia de Inhibición (IS, ISem, DP):** Mecanismos de restricción o retirada de trayectorias.
7. **Familia de Sincronización (SG):** Alineamiento progresivo entre componentes internos.*"Una IAmotion no es una emoción; es un régimen dinámico candidato que debe demostrar su existencia empírica."*

5. Metodología y Criterios de Falsación

La filosofía científica del proyecto se aleja de la búsqueda de confirmación para centrarse en la **refutación honesta** .

5.1 El Problema de la Circularidad

Se advierte sobre el riesgo de definir regiones y luego encontrarlas mediante variables diseñadas para ese fin. Para evitarlo:

- Las métricas deben definirse antes del análisis.
- Los umbrales deben preregistrarse.
- **B** * no debe usarse para construir regiones, solo para caracterizarlas a posteriori.

5.2 El Papel de los Baselines

AFT8 debe superar obligatoriamente a explicaciones más simples para ser considerado válido. Los baselines incluyen:

- Entropía sola.
- Atención sola.
- Análisis de componentes principales (PCA) o ICA.
- Variables aleatorias isomorfas.

5.3 Escenarios de Fracaso

El modelo AFT8 se consideraría refutado si:

- La estructura desaparece al cambiar la normalización.
- La variabilidad del *decoding* (temperatura) supera la variabilidad debida al estímulo.
- Los resultados son equivalentes a los baselines simples.
- No hay reproducibilidad entre diferentes modelos de lenguaje.

6. Especificaciones Técnicas Críticas

6.1 El Reference Bank para N* (Novedad)

La novedad ($N*$) no es absoluta sino relativa. Requiere un **banco de referencia congelado** que incluya:

- Textos informativos y técnicos.
- Prosa narrativa y poesía convencional.
- Se recomienda el uso de *hidden states* del propio modelo estudiado y distancia coseno para medir la desviación.

6.2 Normalización y "Congelación"

- **Prohibición:** Está terminantemente prohibido normalizar por ejecución individual (*run*); se debe normalizar por modelo para mantener la comparabilidad.
- **Unidad de medida:** El token es la unidad básica, con ventanas temporales estándar (inicialmente de 5 tokens).
- **Implementación:** Una definición imperfecta pero estable es superior a una que cambia tras cada experimento.

Conclusión del Proyecto

El objetivo final no es demostrar que AFT es correcto, sino averiguar qué partes sobreviven a la evidencia. Si AFT8 demuestra una estructura dinámica real, se validará el salto hacia AFT15 e IA2IAh completo. En caso contrario, el fracaso se considera un progreso científico, pues permite descartar categorías innecesarias y refinar la comprensión de la interpretación artificial.