Desarrollo de un Asistente de IA Local para la Extracción Automática de Metadatos y Búsqueda Semántica

Resumen Ejecutivo

Este documento detalla el proyecto de desarrollo de un sistema de Inteligencia Artificial (IA) diseñado para automatizar la gestión de datos científicos en el contexto de **FAIR-LAB en IMDEA Materials** . El problema central abordado es la carga de trabajo manual que supone para los investigadores la organización y búsqueda de información en archivos científicos heterogéneos y no estructurados.La solución propuesta consiste en una arquitectura basada en **Modelos de Lenguaje de Gran Escala (LLM) locales y de código abierto** , integrados mediante técnicas de **Generación Aumentada por Recuperación (RAG)** . El objetivo es permitir la extracción automática de metadatos y la recuperación semántica de información sin comprometer la privacidad de los datos ni incurrir en los costes de APIs externas. El éxito del proyecto se medirá comparando el rendimiento de los modelos locales frente a soluciones en la nube en términos de precisión, latencia y coste.

Definición del Problema y Contexto Científico

Los laboratorios de investigación modernos generan volúmenes masivos de información digital en formatos diversos (informes experimentales, resultados de maquinaria, PDFs, CSVs, etc.). En el ámbito de la ciencia de materiales, específicamente en áreas como la fabricación aditiva y la tomografía computarizada de rayos X, esta información suele quedar atrapada en archivos no estructurados.

Desafíos Identificados

- **Gestión Manual:** Los investigadores dedican tiempo excesivo a leer archivos y extraer parámetros manualmente.
- **Dificultad de Acceso:** La información es difícil de organizar, buscar y reutilizar.
- **Principios FAIR:** Existe la necesidad de alinear los flujos de trabajo con los principios de que los datos sean Buscables, Accesibles, Interoperables y Reutilizables (**FAIR** , por sus siglas en inglés).

Arquitectura del Sistema y Metodología

El proyecto propone una tubería (*pipeline*) de procesamiento de datos que transforma archivos científicos brutos en información estructurada y consultable mediante lenguaje natural.

Flujo de Trabajo del Prototipo

1. **Entrada de Datos:** Archivos científicos (certificados PDF, logs de máquinas, archivos CSV).
2. **Extracción de Metadatos:** Procesamiento mediante Python, OCR y analizadores (*parsers*) específicos.
3. **Generación de Embeddings:** Uso de modelos de *embeddings* locales.
4. **Base de Datos Vectorial:** Almacenamiento en **pgvector (PostgreSQL)** , aprovechando la infraestructura existente en FAIR-LAB.
5. **Sistema RAG:** Integración de la base de datos con un LLM local.

6. **Interfaz de IA Local:** Implementación mediante **Ollama** , utilizando modelos como Llama, Mistral o Qwen.

Comparativa Estratégica

Una pregunta de investigación fundamental es evaluar hasta qué punto los LLM locales pueden igualar o superar a las APIs en la nube (como GPT-4) en precisión, considerando que los modelos locales ofrecen:

- **Cero costes de tokens.**
- **Privacidad total:** Los datos permanecen dentro de la infraestructura de IMDEA.
- **Menor dependencia** de servicios externos pagados.

Alcance y Tareas del Proyecto

El desarrollo se estructura en un núcleo esencial y extensiones opcionales para garantizar la entrega de resultados funcionales.| Componente | Descripción || ------ | ------ || **Núcleo (Core)** | Extracción de metadatos de un tipo de archivo primario; almacenamiento estructurado; búsqueda semántica en pgvector. || **Extensiones** | Asistente RAG para consultas en lenguaje natural; comparativa de rendimiento (*benchmarking*) entre modelos; soporte para múltiples tipos de archivos. |

Tareas Principales

1. **Análisis de Formatos:** Estudiar los registros de máquinas y reportes PDF de FAIR-LAB.
2. **Desarrollo de Tuberías:** Crear sistemas automáticos de conversión de datos no estructurados a metadatos estructurados.
3. **Implementación de Búsqueda:** Configurar el sistema de búsqueda semántica basado en vectores.
4. **Creación del Asistente RAG:** Desarrollar la interfaz para consultas en lenguaje natural.
5. **Evaluación:** Medir la calidad del sistema frente a un "gold set" (conjunto de referencia) de 30 a 50 archivos anotados manualmente.

Pila Tecnológica

El sistema se construye sobre un ecosistema de herramientas de código abierto y estándares de ingeniería de software modernos:

- **Lenguajes y Frameworks:** Python.
- **Inteligencia Artificial:** LLMs locales (Llama, Mistral, Qwen) servidos vía **Ollama** .
- **Bases de Datos:** PostgreSQL con la extensión **pgvector** (principal), con alternativas como FAISS o ChromaDB.
- **Infraestructura:** Docker para la contenedrización y despliegue.

Resultados Esperados y Evaluación

El proyecto busca entregar un prototipo funcional que transforme la gestión de datos en IMDEA Materials. Los resultados finales incluirán:

1. Un **asistente de IA funcional** para la gestión de datos científicos.
2. Un **flujo de trabajo automatizado** para la extracción de metadatos.
3. Un **motor de búsqueda semántica** para conjuntos de datos experimentales.

4. Un **informe de evaluación** que compare la precisión y el coste de los modelos locales frente a los servicios en la nube.
5. **Documentación técnica** detallada y recomendaciones para la integración final en la plataforma FAIR-LAB.La evaluación de la calidad de las respuestas se realizará mediante una rúbrica de evaluación humana, asegurando que la utilidad y precisión de la información recuperada cumplan con los estándares requeridos para la investigación científica.