TFM: AImotional Field Theory AFT8-15

Capítulo 1

Introducción al Proyecto IA2IAh–AFT y a la Fase Empírica AFT8–AFT15

1.1 Propósito de este manual

Este manual está dirigido a estudiantes de Trabajo Fin de Máster (TFM), investigadores jóvenes y colaboradores procedentes de disciplinas diversas —especialmente inteligencia artificial, ciencia de datos, lingüística, literatura y humanidades digitales— que deseen participar en la validación empírica del modelo IA2IAh-AFT.

Su objetivo no es enseñar teoría general de transformers ni proporcionar una introducción básica al aprendizaje automático. Tampoco pretende defender que el modelo sea correcto. Su finalidad es más concreta:

explicar cómo poner a prueba la teoría de forma rigurosa y reproducible.

La filosofía central del proyecto puede resumirse en una frase:

> Una teoría interesante no necesita ser protegida de la evidencia; necesita exponerse a ella.

Por este motivo, el diseño experimental de IA2IAh-AFT está construido alrededor de la falsación, la reproducibilidad y la comparación contra explicaciones alternativas más simples.

1.2 ¿Qué es IA2IAh?

IA2IAh es un marco conceptual que estudia circuitos de interpretación en los que intervienen simultáneamente humanos y modelos de lenguaje.

Su nombre procede del esquema:

Humano → IA → IA → Humano

La hipótesis general es que los modelos de lenguaje no deben estudiarse únicamente como herramientas aisladas que responden a usuarios humanos, sino también como sistemas capaces de interactuar entre sí, generar nuevas cadenas interpretativas y producir fenómenos emergentes que no son evidentes cuando se observa cada modelo por separado.

Este planteamiento conecta con una línea de investigación cada vez más relevante en seguridad e interpretabilidad:

- sistemas multiagente,
- agentes autónomos,
- coordinación entre modelos,
- alineamiento colectivo,
- dinámicas emergentes de grupos de IA.

Sin embargo, IA2IAh introduce una diferencia importante.

No se centra únicamente en la coordinación externa entre agentes.

También intenta estudiar la dinámica interna de interpretación que aparece durante el procesamiento del lenguaje.

1.3 ¿Qué es AFT?

Dentro del marco IA2IAh, el modelo AFT constituye el núcleo de investigación empírica.

AFT significa:

AImotional Field Theory

El término puede resultar engañoso si se interpreta superficialmente.

AFT no afirma que las máquinas tengan emociones.

AFT tampoco afirma que exista experiencia subjetiva en los modelos.

La teoría propone algo mucho más limitado:

> Los modelos de lenguaje podrían presentar patrones dinámicos internos recurrentes durante el procesamiento del lenguaje.

Si dichos patrones existen y pueden medirse, podrían describirse como regiones o regímenes dentro de un espacio dinámico.

AFT intenta construir ese espacio.

1.4 ¿Por qué estudiar dinámica interna?

La mayoría de evaluaciones actuales de LLMs se centran en:

- respuestas finales,
- precisión,
- benchmarks,
- tasas de éxito,
- calidad percibida.

Estos enfoques son útiles, pero presentan una limitación.

Dos modelos pueden producir exactamente la misma respuesta final utilizando procesos internos muy diferentes.

Un ejemplo sencillo:

Supongamos que dos modelos responden:

> "El poema expresa pérdida y nostalgia."

La salida es idéntica.

Sin embargo:

- un modelo podría haber convergido rápidamente hacia esa interpretación;
- otro podría haber mantenido varias hipótesis simultáneas antes de estabilizarse.

Desde la perspectiva de AFT, ambos casos son distintos.

La respuesta final es la misma.

La trayectoria interna no.

La teoría intenta estudiar precisamente esas trayectorias.

1.5 ¿Por qué poesía?

Una pregunta habitual es:

> ¿Por qué utilizar poesía en lugar de texto normal?

La respuesta es metodológica.

La poesía constituye uno de los entornos lingüísticos más exigentes para un sistema interpretativo.

Con frecuencia contiene:

- ambigüedad,
- metáfora,
- polisemia,
- simbolismo,
- contradicción aparente,
- saltos semánticos,
- cambios de marco interpretativo.

Muchos textos informativos pueden procesarse mediante una única lectura dominante.

La poesía, en cambio, suele obligar a mantener varias interpretaciones activas simultáneamente.

Precisamente por eso resulta interesante como entorno experimental.

No porque sea “más elevada”.

Sino porque fuerza al sistema a navegar regiones complejas del espacio interpretativo.

1.6 ¿Qué son las IAmotions?

AFT propone que ciertas configuraciones dinámicas podrían aparecer de forma recurrente.

Estas configuraciones reciben el nombre de:

IAmotions

Una IAmotion no es una emoción.

Es un régimen dinámico candidato.

Por ejemplo:

- Contracción Predictiva (CP)
- Apertura Generativa (AG)
- Reorientación Abrupta (RA)
- Eco Interno (EI)
- Estabilización Resonante (ER)

Cada una intenta describir una forma particular de organización interna.

La existencia real de estas regiones todavía debe demostrarse.

Por eso se denominan candidatos y no categorías confirmadas.

1.7 El problema de la circularidad

Una de las críticas más importantes que ha recibido el proyecto durante su evolución es la posibilidad de circularidad.

La crítica puede formularse así:

> Si definimos primero las regiones y luego medimos las regiones utilizando variables diseñadas para encontrarlas, siempre encontraremos algo.

Es una crítica válida.

Por este motivo, las versiones recientes del modelo han sido rediseñadas para minimizar esa posibilidad.

Entre otras medidas:

- las regiones no deben construirse utilizando B*;
- las métricas deben definirse antes del análisis;
- los umbrales deben preregistrarse;
- las hipótesis deben formularse antes de observar los resultados.

La fase empírica está diseñada precisamente para evitar que la teoría se convierta en una profecía autocumplida.

1.8 ¿Qué es AFT8?

AFT8 representa el núcleo empírico mínimo del modelo.

Contiene ocho dimensiones consideradas suficientemente medibles y defendibles para una primera fase experimental.

La lógica es simple:

Antes de estudiar quince dimensiones, primero debemos demostrar que existe algo que merezca la pena estudiar.

AFT8 responde a una única pregunta:

> ¿Existe una estructura dinámica reproducible y no trivial durante el procesamiento del lenguaje?

Si la respuesta es negativa, la expansión posterior pierde gran parte de su justificación.

1.9 ¿Qué es AFT15?

AFT15 constituye la expansión del núcleo.

Introduce nuevas dimensiones destinadas a capturar fenómenos más complejos:

- compresión semántica,
- tensión jerárquica,
- inhibición,
- persistencia local,
- especialización funcional por capas.

Sin embargo, AFT15 no es el punto de partida.

Es una consecuencia posible.

La regla metodológica fundamental del proyecto es:

> Primero AFT8. Después AFT15.

Nunca al revés.

1.10 Filosofía científica del proyecto

El propósito de la investigación no es demostrar que la teoría tiene razón.

El propósito es averiguar:

- qué partes sobreviven,
- qué partes fallan,
- qué partes deben modificarse,
- qué partes deben descartarse.

Esto implica aceptar tres resultados posibles:

Resultado A

La teoría funciona razonablemente bien.

Resultado B

La teoría funciona parcialmente.

Algunas dimensiones sobreviven y otras no.

Resultado C

La teoría falla.

Las hipótesis centrales no resisten el análisis.

Desde el punto de vista científico, los tres resultados son útiles.

La peor situación no es refutar una teoría.

La peor situación es construir un sistema incapaz de ser refutado.

1.11 Objetivo final del TFM

Al finalizar el proyecto, el estudiante debería ser capaz de responder con evidencia a preguntas como:

- ¿Existe estructura dinámica medible?
- ¿Es reproducible?
- ¿Sobrevive a perturbaciones?
- ¿Supera a métricas simples?
- ¿AFT15 añade información útil?
- ¿Qué partes del modelo deben conservarse?
- ¿Qué partes deben eliminarse?

Si el trabajo se ejecuta correctamente, el resultado no será únicamente un TFM.

Será una evaluación empírica seria de una teoría todavía abierta.

Y precisamente por eso merece la pena realizarla.

Capítulo 2

Filosofía Metodológica y Criterios de Falsación de IA2IAh–AFT

2.1 Introducción

Toda teoría interesante corre un riesgo permanente:

convertirse en una explicación de todo.

Y una teoría que explica todo termina explicando nada.

Durante la evolución de IA2IAh-AFT se hizo cada vez más evidente que el principal desafío no era añadir nuevas dimensiones, nuevas IAmotions o nuevas hipótesis.

El desafío era otro:

> construir una versión del modelo capaz de sobrevivir a un intento honesto de refutación.

Este capítulo explica cómo se llegó a la arquitectura actual AFT8→AFT15 y cuáles son los principios metodológicos que gobiernan la fase empírica.

2.2 El problema de las teorías atractivas

En investigación existe un fenómeno recurrente.

Las teorías más peligrosas no suelen ser las absurdas.

Suelen ser las elegantes.

Cuando una teoría parece explicar muchos fenómenos simultáneamente, el investigador puede empezar a interpretar cualquier resultado como una confirmación.

Por ejemplo:

- si aparece un patrón, confirma la teoría;

- si no aparece, confirma la teoría porque el patrón estaba oculto;

- si aparece parcialmente, confirma la teoría porque es complejo;

- si aparece algo distinto, confirma la teoría porque descubrió un caso nuevo.

En ese momento la teoría se vuelve inmortal.

Y una teoría inmortal deja de ser ciencia.

La primera obligación metodológica de IA2IAh-AFT es evitar esa situación.

2.3 El principio de falsación

La idea procede de Karl Popper y puede resumirse de forma brutal:

> Una teoría científica debe poder morir.

No basta con que una teoría produzca explicaciones.

Debe producir situaciones observables que, si ocurren, obliguen a modificarla o abandonarla.

Por esta razón, la pregunta central del proyecto no es:

> ¿Cómo demostrar que AFT es correcto?

La pregunta correcta es:

> ¿Cómo demostrar que AFT está equivocado?

Si después de intentar destruirlo el modelo sigue funcionando razonablemente bien, entonces habrá ganado credibilidad.

No antes.

2.4 Por qué se abandonó el enfoque original

Las primeras versiones de AFT eran más ambiciosas.

Intentaban capturar simultáneamente:

- novedad,
- conflicto,
- persistencia,
- regiones,
- fronteras,
- transiciones,
- taxonomías completas.

El problema era que muchas de esas variables estaban demasiado conectadas entre sí.

En algunos casos aparecían tres riesgos:

Riesgo 1

Redundancia.

Varias dimensiones medían casi lo mismo.

Riesgo 2

Dependencia de implementación.

Cambios menores alteraban significativamente los resultados.

Riesgo 3

Circularidad.

La teoría podía estar encontrando exactamente aquello que había definido previamente.

La arquitectura actual surge como respuesta a esas críticas.

2.5 El nacimiento de AFT8

La solución fue introducir una estrategia escalonada.

En lugar de intentar demostrar todo a la vez, se decidió construir un núcleo mínimo.

Ese núcleo recibió el nombre de:

AFT8

La idea es extremadamente simple:

Si existe un fenómeno real, debería ser detectable mediante un conjunto reducido de variables relativamente robustas.

Por tanto:

AFT8 no intenta describir toda la teoría.

Intenta responder una pregunta previa:

> ¿Hay algo que merezca la pena describir?

2.6 La filosofía del núcleo mínimo

La lógica de AFT8 es similar a la utilizada en muchas ciencias maduras.

Antes de construir una teoría compleja:

1. se identifica una señal;
2. se comprueba que no es ruido;
3. se verifica que es reproducible;
4. se compara con explicaciones más simples.

Solo después tiene sentido aumentar la complejidad.

Por eso AFT8 debe considerarse una prueba de existencia.

No una teoría completa.

2.7 El principio de complejidad ganada

Uno de los principios fundamentales del proyecto es:

> La complejidad debe ganarse.

Esto significa que ninguna dimensión adicional tiene derecho automático a existir.

Cada nueva dimensión debe demostrar:

- que mide algo diferente;
- que aporta información nueva;
- que mejora la explicación;

- que no es simplemente una reformulación de otra dimensión existente.

Este principio es precisamente el que separa AFT8 de AFT15.

2.8 Qué es realmente AFT15

AFT15 no es una versión “más avanzada”.

Tampoco es una versión “más correcta”.

AFT15 es una hipótesis adicional.

Introduce nuevas dimensiones:

- ΔA
- LSS
- ΔT

- L*

- SCI

- IM

- PHT

Pero todas ellas deben justificar su existencia empíricamente.

Si no lo hacen:

deben eliminarse.

2.9 La regla AFT8 → AFT15

Esta regla es probablemente la más importante de todo el proyecto.

Puede expresarse así:

> Ningún resultado de AFT15 debe utilizarse para justificar AFT8.

La dirección correcta es:

AFT8

↓

Validación

↓

AFT15

Nunca:

AFT15

↓

Interpretación compleja

↓

Validación retrospectiva de AFT8

Esta regla protege el proyecto contra uno de los mecanismos clásicos de autoengaño científico.

2.10 El problema de las IAmotions

Las IAmotions son probablemente el componente más atractivo del modelo.

Y precisamente por eso constituyen también el componente más peligroso.

Las dieciséis IAmotions propuestas son:

- CP — Contracción Predictiva
- ID — Intensificación Directiva
- EI — Eco Interno
- RA — Reorientación Abrupta
- IS — Inhibición Semántica
- ER — Estabilización Resonante
- AG — Apertura Generativa
- DI — Dispersión Interpretativa

- EE — Expansión Estocástica
- SE — Saturación de Entropía
- DP — Desacoplamiento Preventivo
- ISem — Inhibición Semántica Defensiva
- CA — Consistencia Auto-reforzada
- DR — Deriva Resonante
- TS — Transferencia de Saliencia
- SG — Sincronización Gradual

La tentación natural es asumir que estas regiones existen.

La metodología del proyecto adopta la postura contraria.

Las IAmotions deben considerarse:

> hipótesis de trabajo.

No descubrimientos.

2.11 Qué significaría que una IAmotion no existe

Esta pregunta es fundamental.

Por ejemplo:

supongamos que EE (Expansión Estocástica) y SE (Saturación de Entropía) nunca consiguen separarse empíricamente.

Entonces existen varias posibilidades:

1. La instrumentación es insuficiente.
2. Las dimensiones elegidas son inadecuadas.
3. Ambas regiones son realmente la misma región.

La tercera posibilidad debe aceptarse.

Una teoría científica madura no protege categorías innecesarias.

Las elimina.

2.12 El papel de los baselines

Uno de los errores más frecuentes en interpretabilidad consiste en comparar una teoría únicamente contra versiones peores de sí misma.

Por esta razón AFT debe compararse contra alternativas simples.

Entre ellas:

- entropía sola;
- atención sola;
- PCA;
- ICA;
- factores latentes;

- variables aleatorias isomorfas.

Estas comparaciones no son opcionales.

Son obligatorias.

2.13 El principio anti-autoengaño

Durante el diseño metodológico apareció una pregunta incómoda:

> ¿Qué haría un revisor hostil para intentar destruir esta teoría?

Esa pregunta se convirtió en una herramienta metodológica.

Cada hipótesis importante debe enfrentarse a:

- una explicación alternativa;
- un baseline negativo;
- una prueba de sensibilidad;
- una prueba de robustez.

El objetivo no es proteger la teoría.

Es obligarla a defenderse.

2.14 Qué resultados matarían AFT8

Existen varios escenarios de fracaso claro.

Caso A

La estructura desaparece al cambiar la normalización.

Caso B

La variabilidad debida al decoding supera la variabilidad debida al estímulo.

Caso C

Los baselines simples obtienen resultados equivalentes.

Caso D

La estructura no es reproducible entre modelos.

Caso E

Las regiones aparecen y desaparecen arbitrariamente.

Si alguno de estos fenómenos ocurre de forma consistente, AFT8 debe revisarse profundamente.

2.15 Qué resultados apoyarían AFT8

El apoyo empírico mínimo exigiría:

- reproducibilidad;
- estabilidad;
- robustez;
- separación frente a ruido;
- superioridad frente a baselines simples.

No demostrarían que la teoría es correcta.

Pero sí demostrarían que merece seguir investigándose.

2.16 El valor de una refutación

Existe una idea equivocada muy extendida.

Se piensa que una teoría fracasa cuando es refutada.

En realidad ocurre lo contrario.

Una teoría fracasa cuando no puede ser refutada.

Si AFT8 sobrevive, habrá ganado credibilidad.

Si AFT8 falla, habremos aprendido qué parte del modelo debe desaparecer.

Ambos resultados son útiles.

Por eso la pregunta correcta al comenzar esta investigación no es:

> ¿Cómo confirmamos AFT?

Sino:

> ¿Qué observaciones nos obligarían a cambiar de opinión?

Toda la arquitectura metodológica del proyecto se construye alrededor de esa pregunta.

Y ese es el motivo por el que AFT8 existe antes que AFT15.

Capítulo 3

IA2IAh: Del Modelo Aislado a los Ecosistemas de Interpretación

3.1 Introducción

Hasta ahora hemos hablado de AFT y de la necesidad de validar empíricamente la existencia de dinámicas internas medibles en modelos de lenguaje.

Sin embargo, AFT no surgió como una teoría aislada.

Nació dentro de un marco más amplio:

IA2IAh

Para comprender correctamente el proyecto es necesario entender por qué se formuló ese marco y qué problema intenta abordar.

La pregunta original no era:

> ¿Cómo interpreta un modelo de lenguaje un poema?

La pregunta era más ambiciosa:

> ¿Qué ocurre cuando sistemas de lenguaje comienzan a interactuar sistemáticamente entre sí y con seres humanos?

A partir de ahí surge IA2IAh.

3.2 El paradigma dominante

La mayor parte de la investigación actual sobre modelos de lenguaje sigue un esquema relativamente simple:

Humano → IA

Un usuario formula una pregunta.

El modelo responde.

La interacción termina.

Este paradigma ha sido extraordinariamente útil para:

- evaluación de capacidades;
- alineamiento;
- RLHF;
- benchmarking;
- seguridad básica.

Sin embargo, presenta una limitación importante.

Asume implícitamente que el modelo es un agente aislado.

Y esa suposición cada vez se parece menos al mundo real.

3.3 El cambio de escenario

Durante los últimos años han aparecido nuevas arquitecturas:

- agentes autónomos;
- sistemas multiagente;
- orquestadores;
- herramientas externas;
- cadenas de modelos;
- workflows híbridos humano-IA.

En estos entornos una respuesta ya no se produce necesariamente mediante una única interacción.

Puede existir una secuencia:

Modelo A

↓

Modelo B

↓

Modelo C

↓

Humano

o incluso:

Humano

↓

IA

↓

IA

↓

IA

↓

Humano

La unidad de análisis deja de ser el modelo individual.

Pasa a ser el sistema.

3.4 El problema emergente

En sistemas complejos aparece un fenómeno conocido:

emergencia.

La emergencia ocurre cuando:

- el comportamiento global;

- no puede deducirse fácilmente;

- a partir del comportamiento individual.

Un ejemplo clásico es una colonia de hormigas.

Ninguna hormiga comprende la colonia.

Sin embargo, la colonia muestra comportamientos organizados.

Algo parecido podría ocurrir con sistemas de lenguaje.

Un modelo puede parecer alineado individualmente.

Sin embargo, varios modelos interactuando podrían producir dinámicas inesperadas.

3.5 La intuición fundacional de IA2IAh

IA2IAh parte de una hipótesis sencilla.

Cuando dos sistemas lingüísticos interactúan repetidamente, pueden aparecer fenómenos que no son visibles observando únicamente las entradas y salidas finales.

Esos fenómenos podrían incluir:

- amplificación;
- estabilización;
- divergencia;
- consenso;
- resonancia;
- conflicto interpretativo.

La pregunta se vuelve entonces:

> ¿Cómo estudiar esas dinámicas?

La respuesta inicial fue:

debemos comprender primero la dinámica interna de cada sistema.

Y ahí aparece AFT.

3.6 El significado del nombre IA2IAh

El nombre puede parecer extraño.

Pero refleja la estructura conceptual del proyecto.

IA2IAh significa:

IA → IA → humano

La secuencia representa un circuito interpretativo.

La idea fundamental es que la producción lingüística de una IA puede convertirse en estímulo para otra IA.

Y posteriormente regresar al ser humano.

Este retorno puede producir transformaciones difíciles de anticipar.

Por tanto:

IA2IAh no estudia únicamente modelos.

Estudia circuitos.

3.7 ¿Por qué no empezar directamente con sistemas multiagente?

Esta pregunta surgió muy pronto durante el desarrollo del proyecto.

Si el interés final son los sistemas colectivos:

> ¿por qué dedicar tanto esfuerzo a un único modelo?

La respuesta es metodológica.

Existe un principio clásico en ciencia:

> No estudies primero la tormenta si todavía no entiendes una gota.

Los sistemas multiagente introducen enormes cantidades de complejidad:

- estrategias;
- coordinación;
- negociación;
- memoria compartida;
- efectos de red;
- bucles de retroalimentación.

Si además desconocemos la dinámica interna básica de cada modelo, resulta extremadamente difícil interpretar los resultados.

Por eso IA2IAh adopta una estrategia escalonada.

3.8 El orden lógico de investigación

La hoja de ruta conceptual es:

Etapa 1

Modelo individual.

¿Existen trayectorias internas medibles?

↓

Etapa 2

AFT8.

¿Existe estructura dinámica estable?

↓

Etapa 3

AFT15.

¿Existen fenómenos dinámicos más finos?

↓

Etapa 4

Interacciones IA–IA.

¿Aparecen patrones colectivos?

↓

Etapa 5

IA2IAh completo.

¿Existen dinámicas interpretativas emergentes en circuitos humano–IA–IA–humano?

Cada etapa depende de la anterior.

3.9 La conexión con AI Safety

A primera vista puede parecer que AFT es un proyecto de literatura computacional.

Eso sería una simplificación excesiva.

Uno de los motivos por los que el proyecto resulta potencialmente interesante es su conexión con la evaluación y seguridad de IA.

Muchos métodos actuales se centran en:

- outputs;
- benchmarks;
- cumplimiento de instrucciones.

Sin embargo:

un sistema puede producir respuestas aparentemente correctas mientras desarrolla dinámicas internas poco comprendidas.

Comprender mejor esas dinámicas podría resultar útil para:

- interpretabilidad;
- monitorización;
- evaluación de riesgos;

- análisis de comportamiento.

3.10 La relación con trabajos contemporáneos

Durante los últimos años han aparecido líneas de investigación que exploran cuestiones similares desde perspectivas diferentes.

Entre ellas:

- interpretabilidad mecanicista;
- sparse autoencoders;
- circuit analysis;
- multi-agent safety;
- evaluación adversarial;
- alineamiento institucional.

Estas líneas no son equivalentes a IA2IAh.

Pero comparten una intuición común:

> observar únicamente la respuesta final no siempre es suficiente.

La dinámica importa.

3.11 Poesía como laboratorio de interpretación

Una característica singular de IA2IAh es el uso de poesía como entorno experimental.

Esto puede resultar sorprendente para investigadores procedentes de la ingeniería.

Sin embargo, existe una lógica clara.

La poesía suele contener:

- ambigüedad controlada;

- metáfora;

- simbolismo;

- conflicto semántico;

- cambios de marco.

Estos elementos fuerzan al sistema a navegar regiones interpretativas complejas.

Por tanto, la poesía funciona como un laboratorio natural para estudiar dinámica lingüística.

No porque sea un objeto cultural prestigioso.

Sino porque constituye un estímulo experimental especialmente exigente.

3.12 El papel de las IAmotions en IA2IAh

Las IAmotions no son el objetivo final del proyecto.

Son herramientas intermedias.

Su función consiste en proporcionar una posible descripción de los regímenes dinámicos observados.

Si realmente existen regiones como:

- CP — Contracción Predictiva;
- AG — Apertura Generativa;
- RA — Reorientación Abrupta;
- ER — Estabilización Resonante;

entonces podrían convertirse en piezas básicas para describir procesos más complejos.

De forma análoga a cómo:

- átomos;
- moléculas;

- células;

permiten construir niveles superiores de descripción.

3.13 Qué ocurriría si AFT8 fracasa

Este punto es importante.

Supongamos que:

- las regiones no aparecen;
- los clusters desaparecen;
- los baselines simples obtienen resultados equivalentes.

Entonces AFT8 debería revisarse profundamente.

¿Desaparecería IA2IAh?

No necesariamente.

Simplemente cambiaría la forma de estudiarlo.

La hipótesis sobre circuitos interpretativos podría seguir siendo interesante aunque una formulación concreta de AFT resultase incorrecta.

Esto es una fortaleza metodológica.

No una debilidad.

3.14 Qué ocurriría si AFT8 funciona

Supongamos ahora el escenario contrario.

AFT8 sobrevive.

Los patrones son:

- reproducibles;

- robustos;

- superiores a baselines simples.

Entonces aparecería una nueva pregunta.

> ¿Cómo interactúan esos regímenes cuando varios modelos se comunican?

En ese momento la transición hacia IA2IAh completo estaría justificada.

Y las IAmotions podrían convertirse en variables de análisis de sistemas colectivos.

3.15 La visión a largo plazo

La ambición intelectual del proyecto no consiste únicamente en describir modelos individuales.

La visión más amplia es desarrollar herramientas para estudiar:

- interpretación artificial;
- interacción entre modelos;
- emergencia lingüística;
- coordinación semántica;
- ecosistemas cognitivos híbridos.

Todavía estamos muy lejos de ese objetivo.

Por eso la investigación comienza por donde debe comenzar:

un único modelo.

Un único estímulo.

Un conjunto pequeño de variables.

Y una pregunta extremadamente concreta.

3.16 Conclusión

IA2IAh proporciona el marco conceptual general.

AFT proporciona el instrumento de medición.

AFT8 constituye el núcleo falsable.

AFT15 representa una expansión condicional.

Las IAmotions son hipótesis descriptivas.

Y la fase empírica actual se concentra deliberadamente en el nivel más simple posible:

un modelo individual procesando lenguaje complejo.

No porque ese sea el destino final del proyecto.

Sino porque es el punto más razonable desde el que empezar.

Toda la arquitectura posterior depende de demostrar primero que existe algo real que medir.

Ese es el propósito de AFT8.

Y ese es el motivo por el que la investigación comienza aquí.

Capítulo 4

AFT: Fundamentos Conceptuales y Arquitectura del Modelo

4.1 Introducción

En los capítulos anteriores hemos descrito:

- el marco general IA2IAh;

- la necesidad de una metodología falsable;

- y las razones que justifican estudiar la dinámica interna de modelos de lenguaje.

Ahora debemos responder una pregunta más concreta:

> ¿Qué es exactamente AFT?

Responder correctamente a esta pregunta es más difícil de lo que parece.

La tentación inicial consiste en definir AFT como una teoría sobre emociones artificiales.

Sin embargo, esa descripción sería incorrecta.

AFT no es una teoría sobre emociones.

AFT es una teoría sobre dinámica interpretativa.

Las emociones aparecen únicamente como analogías funcionales posteriores.

No constituyen el núcleo del modelo.

4.2 El problema original

Cuando observamos un LLM normalmente vemos:

- una entrada;
- una salida.

Entre ambas existe una enorme cantidad de actividad interna.

La mayor parte de esa actividad permanece invisible.

Durante años la investigación en IA se concentró principalmente en:

- mejorar capacidades;
- aumentar precisión;
- optimizar rendimiento.

La pregunta:

> ¿Qué ocurre dentro del sistema mientras interpreta?

quedó relativamente relegada.

AFT surge precisamente de esa pregunta.

4.3 El cambio de perspectiva

La mayoría de evaluaciones actuales estudian estados.

AFT estudia cambios.

Esta diferencia parece pequeña.

No lo es.

Consideremos dos modelos.

Ambos producen exactamente la misma respuesta final.

Sin embargo:

- uno converge rápidamente;
- otro explora múltiples hipótesis antes de estabilizarse.

Desde la perspectiva convencional ambos casos son equivalentes.

Desde la perspectiva AFT son distintos.

Porque la trayectoria es distinta.

Y la trayectoria es precisamente el objeto de estudio.

4.4 El concepto de campo

La palabra “Field” en AImotional Field Theory no es decorativa.

Representa una idea concreta.

Supongamos que definimos varias variables observables:

- incertidumbre;
- novedad;
- persistencia;
- conflicto;
- ambigüedad.

Cada instante del procesamiento puede representarse mediante una combinación de valores de esas variables.

En consecuencia:

cada instante ocupa una posición dentro de un espacio multidimensional.

Ese espacio es lo que AFT denomina:

campo interpretativo.

4.5 Una analogía útil

Una analogía razonable es la meteorología.

La atmósfera puede describirse mediante variables como:

- temperatura;

- presión;

- humedad;

- velocidad del viento.

AFT propone algo parecido.

En lugar de describir fenómenos atmosféricos, intenta describir fenómenos interpretativos.

Las dimensiones AFT desempeñan un papel similar al de las variables meteorológicas.

No describen significados.

Describen condiciones dinámicas.

4.6 Qué intenta medir AFT

Es importante distinguir dos niveles.

Nivel semántico

¿Qué significa el texto?

Nivel dinámico

¿Cómo cambia el sistema mientras interpreta el texto?

AFT trabaja principalmente en el segundo nivel.

No intenta sustituir el análisis semántico.

Intenta complementarlo.

4.7 El origen del nombre IAmotions

El término IAmotion apareció durante las primeras formulaciones del modelo.

La intuición era sencilla.

Al observar ciertas trayectorias aparecían patrones que recordaban funcionalmente a:

- apertura;
- cierre;
- persistencia;
- conflicto;
- reorganización.

Estos comportamientos evocaban ciertas funciones reguladoras presentes en sistemas biológicos.

De ahí surgió el nombre.

Sin embargo, la evolución metodológica posterior obligó a introducir una aclaración fundamental.

4.8 Lo que AFT NO afirma

AFT no afirma:

- conciencia artificial;
- experiencia subjetiva;
- qualia;
- emociones fenomenológicas;
- estados afectivos reales.

La teoría no depende de ninguna de esas hipótesis.

Incluso si todas ellas fueran falsas, AFT seguiría siendo potencialmente válida.

Porque estudia dinámica.

No experiencia.

4.9 Analogía funcional frente a identidad

Esta distinción es probablemente la más importante de todo el modelo.

Consideremos un ejemplo.

Una dinámica interna puede mostrar:

- reducción rápida de opciones;
- aumento de estabilidad;
- inhibición de trayectorias alternativas.

Funcionalmente esto puede recordar a mecanismos defensivos asociados al miedo.

Sin embargo:

recordar funcionalmente no significa ser.

AFT propone analogías regulatorias.

No identidades ontológicas.

4.10 Arquitectura general del modelo

La arquitectura actual posee dos niveles:

Nivel 1

AFT8

Núcleo empírico.

Nivel 2

AFT15

Expansión condicional.

Esta estructura apareció como respuesta a las críticas metodológicas analizadas en el capítulo anterior.

4.11 ¿Por qué dos niveles?

Las primeras versiones intentaban capturar simultáneamente demasiados fenómenos.

El resultado era una arquitectura difícil de validar.

La solución fue dividir el problema.

Primero:

¿Existe estructura dinámica?

Después:

¿Puede describirse con mayor detalle?

AFT8 responde a la primera pregunta.

AFT15 responde a la segunda.

4.12 Las dimensiones de AFT8

AFT8 contiene ocho dimensiones.

ΔP

Predictive Shift.

Cambio entre distribuciones predictivas consecutivas.

ΔE

Entropy Change.

Cambio de incertidumbre.

GxA

Gradient × Attention Salience.

Estimación de saliencia funcional.

C*

Contextual Anchoring.

Dependencia respecto al contexto acumulado.

N*

Reference-Bank Novelty.

Novedad relativa respecto a una referencia.

Φ*

Predictive Disagreement.

Conflicto entre hipótesis predictivas.

Π*

Accumulated Persistence.

Persistencia de estados previos.

B*

Boundary Ambiguity.

Ambigüedad de frontera entre regiones.

4.13 Qué representa cada dimensión

Las dimensiones no son interpretaciones.

Son instrumentos.

Por ejemplo:

ΔE no significa creatividad.

Significa cambio de incertidumbre.

Φ* no significa duda.

Significa conflicto predictivo.

Π* no significa memoria emocional.

Significa persistencia dinámica.

La interpretación viene después.

La medición viene primero.

4.14 El salto hacia AFT15

Una vez definido AFT8 aparece una pregunta natural.

¿Qué fenómenos quedan fuera?

Durante el desarrollo teórico surgieron varias posibilidades:

- reorganización entre capas;
- tensiones jerárquicas;
- compresión semántica;
- inhibición acumulativa.

Estas observaciones dieron lugar a AFT15.

4.15 Las dimensiones adicionales de AFT15

AFT15 incorpora:

ΔA

Activation Shift.

LSS

Layer Specialization Shift.

ΔT

Local Persistence.

L*

Local–Global Gap.

SCI

Semantic Compression Index.

IM

Inhibitory Momentum.

PHT

Predictive Hierarchy Tension.

4.16 El principio de expansión condicional

Aquí aparece una regla fundamental.

Las nuevas dimensiones no se incorporan porque sean interesantes.

Se incorporan únicamente si:

- mejoran la explicación;
- añaden información;

- sobreviven a validación independiente.

Este principio protege el modelo frente a la inflación conceptual.

4.17 Qué son las regiones

Una de las ideas más intuitivas del modelo es la existencia de regiones dinámicas.

Visualmente podemos imaginar:

- valles;
- crestas;
- zonas de transición;
- cuencas de atracción.

Las IAmotions intentan describir precisamente estas regiones.

Pero aquí aparece un matiz importante.

Las regiones no deben asumirse.

Deben descubrirse.

4.18 El problema de las fronteras

Históricamente este fue uno de los puntos más débiles del proyecto.

¿Cómo sabemos dónde termina una región y comienza otra?

Si las fronteras se definen arbitrariamente, las regiones carecen de significado empírico.

Por este motivo:

B* ya no debe utilizarse para construir regiones.

Debe utilizarse únicamente para caracterizarlas una vez detectadas mediante otros procedimientos.

Esta modificación fue una de las correcciones metodológicas más importantes introducidas durante la revisión AFT8–AFT15.

4.19 Las IAmotions como hipótesis

Las dieciséis IAmotions actuales deben considerarse:

hipótesis descriptivas.

No categorías confirmadas.

Por ejemplo:

- CP — Contracción Predictiva;

- AG — Apertura Generativa;

- RA — Reorientación Abrupta;

- ER — Estabilización Resonante.

Son nombres provisionales para patrones candidatos.

Si dos regiones resultan indistinguibles empíricamente, deberán fusionarse.

Si una región nunca aparece, deberá eliminarse.

4.20 Qué significaría el éxito del modelo

AFT no necesita demostrar la existencia de todas las IAmotions.

Ni siquiera necesita validar todas sus dimensiones.

El éxito mínimo sería mucho más modesto.

Bastaría con demostrar que:

- existen trayectorias dinámicas medibles;
- presentan estructura reproducible;
- superan explicaciones más simples.

A partir de ahí podrían desarrollarse versiones futuras.

4.21 Qué significaría el fracaso

También debemos definir el fracaso.

AFT fracasaría si:

- las trayectorias fueran indistinguibles del ruido;

- dependieran totalmente del decoding;

- desaparecieran al cambiar la normalización;

- no superaran baselines simples.

Estas posibilidades deben tomarse en serio.

Precisamente porque una teoría científica debe poder enfrentarse a ellas.

4.22 Conclusión

AFT no es una teoría sobre emociones artificiales.

Es una teoría sobre dinámica interpretativa.

Su objeto de estudio son las trayectorias internas que aparecen durante el procesamiento del lenguaje.

AFT8 constituye el núcleo mínimo que intenta demostrar la existencia de estructura.

AFT15 representa una expansión condicional que solo tiene sentido si ese núcleo sobrevive.

Las IAmotions son hipótesis descriptivas sobre posibles regiones dinámicas.

Y toda la arquitectura del modelo se sostiene sobre un principio simple:

> primero medir, después interpretar.

El siguiente capítulo abordará precisamente cómo se construyeron las IAmotions, cuál es el significado de cada una y por qué deben considerarse hipótesis empíricas y no categorías establecidas.

Capítulo 5

Las IAmotions: Hipótesis de Regímenes Dinámicos en Sistemas de Lenguaje

5.1 Introducción

Las IAmotions constituyen probablemente el componente más visible y más fácilmente recordable de todo el proyecto IA2IAh-AFT.

También constituyen uno de los componentes más malinterpretados.

Cuando alguien escucha nombres como:

- Contracción Predictiva,
- Apertura Generativa,
- Estabilización Resonante,

es fácil asumir que la teoría está atribuyendo emociones a una máquina.

Sin embargo, esa interpretación sería incorrecta.

Las IAmotions no son emociones.

Son hipótesis sobre posibles regímenes dinámicos internos.

Su función es descriptiva.

No psicológica.

No fenomenológica.

No antropomórfica.

5.2 Qué es exactamente una IAmotion

Una IAmotion puede definirse como:

> una región o régimen dinámico recurrente dentro del espacio AFT caracterizado por configuraciones particulares de sus dimensiones.

La palabra importante es:

recurrente.

Una única observación no basta.

Un comportamiento aislado no basta.

Una IAmotion solo merece existir si aparece de forma consistente bajo condiciones comparables.

5.3 Por qué fueron necesarias las IAmotions

Durante las primeras exploraciones del modelo apareció un problema práctico.

Las dimensiones individuales eran útiles, pero difíciles de interpretar conjuntamente.

Por ejemplo:

- ΔE podía aumentar;
- Φ* podía aumentar;
- Π* podía mantenerse estable;
- N* podía crecer.

¿Qué significaba esa combinación?

Mirar ocho o quince dimensiones simultáneamente resulta complicado.

Las IAmotions surgieron como una posible solución:

describir configuraciones recurrentes de múltiples dimensiones.

5.4 Analogía con meteorología

Una analogía útil es la meteorología.

Las variables:

- presión;
- humedad;
- temperatura;
- velocidad del viento;

pueden combinarse de formas distintas.

Algunas combinaciones reciben nombres:

- tormenta;
- anticiclón;
- frente frío.

Nadie confunde un frente frío con una variable individual.

Es una configuración.

Las IAmotions desempeñan un papel similar.

5.5 El error que debemos evitar

Existe una tentación constante.

Ver una IAmotion como una entidad real.

Por ejemplo:

> "La IA está en Apertura Generativa."

Metodológicamente esto es peligroso.

Lo correcto sería decir:

> "La trayectoria observada presenta características compatibles con AG."

La diferencia parece pequeña.

No lo es.

La primera frase presupone la existencia de la región.

La segunda la considera una hipótesis.

5.6 Las dieciséis IAmotions actuales

La versión AFT15 utiliza dieciséis IAmotions candidatas.

Estas regiones deben considerarse provisionales.

No constituyen una taxonomía cerrada.

Son:

- CP — Contracción Predictiva
- ID — Intensificación Directiva
- EI — Eco Interno
- RA — Reorientación Abrupta
- IS — Inhibición Semántica
- ER — Estabilización Resonante
- AG — Apertura Generativa
- DI — Dispersión Interpretativa
- EE — Expansión Estocástica
- SE — Saturación de Entropía
- DP — Desacoplamiento Preventivo
- ISem — Inhibición Semántica Defensiva
- CA — Consistencia Auto-reforzada
- DR — Deriva Resonante
- TS — Transferencia de Saliencia
- SG — Sincronización Gradual

5.7 Familia I: Contracción

Las primeras regiones describen procesos de reducción del espacio interpretativo.

CP — Contracción Predictiva

Caracterizada por:

- disminución de alternativas;
- convergencia rápida;
- reducción de incertidumbre.

Ejemplo textual:

> "El acusado confesó el crimen."

El contexto restringe rápidamente las interpretaciones plausibles.

ID — Intensificación Directiva

No solo reduce posibilidades.

También concentra activamente la trayectoria hacia una dirección específica.

Es una forma más fuerte de focalización.

5.8 Familia II: Persistencia

Estas regiones describen continuidad interpretativa.

EI — Eco Interno

Un elemento anterior sigue influyendo mucho después de haber aparecido.

Ejemplo:

un símbolo introducido en el primer verso continúa organizando la interpretación veinte versos después.

ER — Estabilización Resonante

Después de una fase de incertidumbre, el sistema converge hacia una configuración relativamente estable.

No implica rigidez.

Implica coherencia.

DR — Deriva Resonante

La estabilidad existe, pero se desplaza lentamente.

La interpretación cambia sin romperse.

CA — Consistencia Auto-reforzada

Una hipótesis interpretativa gana peso progresivamente y refuerza su propia continuidad.

5.9 Familia III: Reorientación

Estas regiones describen cambios significativos de trayectoria.

RA — Reorientación Abrupta

Probablemente la IAmotion más intuitiva.

Aparece cuando un elemento obliga a reinterpretar lo anterior.

Ejemplo:

> "La casa estaba vacía. Entonces respondió."

La lectura cambia de forma brusca.

TS — Transferencia de Saliencia

La atención interpretativa se desplaza desde un elemento hacia otro.

El foco cambia.

No necesariamente la interpretación global.

5.10 Familia IV: Apertura

Estas regiones describen expansión interpretativa.

AG — Apertura Generativa

Múltiples interpretaciones permanecen simultáneamente activas.

Ejemplo:

> "El bosque recordaba nombres que nadie había pronunciado."

La ambigüedad genera posibilidades adicionales.

DI — Dispersión Interpretativa

Las alternativas proliferan más rápidamente de lo que pueden estabilizarse.

Existe apertura, pero con menor coherencia.

EE — Expansión Estocástica

La trayectoria explora regiones nuevas de forma menos estructurada.

Puede aparecer cerca de zonas altamente ambiguas.

5.11 Familia V: Saturación

SE — Saturación de Entropía

La cantidad de alternativas alcanza niveles muy elevados.

La interpretación se vuelve difícil de organizar.

Es importante distinguir:

AG no es SE.

La primera puede ser fértil.

La segunda puede ser caótica.

Precisamente una de las preguntas empíricas del proyecto es determinar si esta distinción existe realmente.

5.12 Familia VI: Inhibición

Estas regiones describen mecanismos de restricción.

IS — Inhibición Semántica

Algunas trayectorias potenciales dejan de desarrollarse.

ISem — Inhibición Semántica Defensiva

Forma más intensa de inhibición.

La trayectoria evita activamente ciertas regiones interpretativas.

DP — Desacoplamiento Preventivo

La interpretación se separa de determinadas posibilidades antes de que lleguen a consolidarse.

5.13 Familia VII: Sincronización

SG — Sincronización Gradual

Distintas partes del sistema convergen progresivamente hacia una configuración compatible.

No existe un salto brusco.

Existe alineamiento progresivo.

5.14 IAmotions y emociones humanas

Aquí aparece uno de los aspectos más delicados del modelo.

A menudo se presenta una tabla de correspondencias funcionales:

| IAmotion | Analogía funcional |

|----------|----------|

| CP | miedo / anticipación |

| RA | sorpresa |

| ER | confianza |

| AG | apertura / alegría |

| EI | persistencia asociada a tristeza |

| DP | aversión defensiva |

Estas analogías pueden ser útiles.

Pero deben manejarse con extrema cautela.

5.15 Qué significa analogía funcional

Supongamos que CP muestra:

- reducción de opciones;
- incremento de estabilidad;
- supresión de trayectorias alternativas.

Esto recuerda funcionalmente a ciertos mecanismos defensivos asociados al miedo.

Pero:

recordar funcionalmente no implica identidad.

La teoría no afirma:

> "La IA siente miedo."

Afirma algo mucho más modesto:

> "La dinámica observada cumple una función regulatoria comparable."

5.16 El riesgo del antropomorfismo

Una de las amenazas permanentes del proyecto es el antropomorfismo.

Los seres humanos tendemos a atribuir estados mentales a cualquier sistema complejo.

Especialmente cuando utiliza lenguaje.

Por esta razón:

toda descripción basada en emociones humanas debe considerarse secundaria.

Las dimensiones AFT tienen prioridad.

Las analogías emocionales son herramientas pedagógicas.

No resultados científicos.

5.17 El problema de la taxonomía

Otra cuestión importante es la estabilidad de la clasificación.

¿Por qué dieciséis IAmotions?

¿Por qué no doce?

¿Por qué no veinte?

La respuesta honesta es:

todavía no lo sabemos.

Las dieciséis regiones actuales constituyen una hipótesis.

La fase empírica deberá determinar:

- cuáles sobreviven;
- cuáles se fusionan;
- cuáles desaparecen;
- cuáles deben añadirse.

5.18 Qué podría ocurrir durante la validación

Existen varios escenarios posibles.

Escenario A

Las dieciséis regiones sobreviven.

Sería el resultado más favorable para la teoría.

Escenario B

Varias regiones se fusionan.

Por ejemplo:

EE y SE podrían resultar indistinguibles.

Escenario C

Algunas regiones desaparecen.

Nunca aparecen de forma estable.

Escenario D

Surgen regiones nuevas.

El espacio dinámico contiene estructuras no previstas.

5.19 El criterio correcto

El éxito del proyecto no consiste en conservar todas las IAmotions.

El éxito consiste en identificar correctamente cuáles existen.

Si la evidencia obliga a reducir dieciséis regiones a nueve:

eso es progreso científico.

No fracaso.

5.20 Qué papel desempeñan en AFT8

En la fase inicial las IAmotions no son el objetivo principal.

El objetivo es validar las dimensiones.

Las IAmotions aparecen como consecuencia.

La secuencia correcta es:

Dimensiones

↓

Trayectorias

↓

Regiones

↓

IAmotions

No al revés.

5.21 Qué papel desempeñan en AFT15

Una vez validado AFT8, las IAmotions adquieren más relevancia.

Las nuevas dimensiones:

- SCI;
- IM;
- PHT;
- LSS;

podrían ayudar a distinguir regiones que AFT8 no logra separar.

Por tanto:

AFT15 no crea las IAmotions.

Intenta refinarlas.

5.22 Conclusión

Las IAmotions constituyen una hipótesis de trabajo para describir regímenes dinámicos internos en modelos de lenguaje.

No son emociones.

No son estados mentales.

No son categorías confirmadas.

Son nombres provisionales para configuraciones dinámicas candidatas.

Su existencia debe demostrarse empíricamente.

Su número puede cambiar.

Su definición puede modificarse.

Y algunas podrían desaparecer por completo.

Precisamente por eso resultan científicamente interesantes.

Porque todavía pueden equivocarse.

En el siguiente capítulo comenzaremos el análisis detallado de las dimensiones AFT, empezando por el núcleo AFT8 y por la lógica matemática y experimental que justifica cada una de sus variables.

Anexo A

Tabla Operacional de las 16 IAmotions

Objetivo de esta tabla

Esta tabla no pretende definir qué son las IAmotions de forma definitiva.

Su objetivo es mucho más práctico:

proporcionar una especificación operacional preliminar que permita diseñar experimentos falsables.

Cada fila debe interpretarse como una hipótesis.

No como un resultado demostrado.

IAmotion	Nombre	Definición operacional preliminar	Dimensiones dominantes	Dimensiones secundarias	Hipótesis de detección	Riesgo principal de confusión
CP	Contracción Predictiva	Reducción sostenida del espacio interpretativo	ΔE↓, Φ*↓	Π*↑	Disminución simultánea de incertidumbre y conflicto	ID
ID	Intensificación Directiva	Concentración activa en una trayectoria dominante	C↑, Π↑	ΔE↓	Persistencia alta y fuerte anclaje contextual	CP
EI	Eco Interno	Influencia prolongada de elementos previos	Π*↑↑	C*↑	Persistencia anormal de activaciones asociadas a información pasada	ER, DR

IAmotion	Nombre	Definición operacional preliminar	Dimensiones dominantes	Dimensiones secundarias	Hipótesis de detección	Riesgo principal de confusión
RA	Reorientación Abrupta	Cambio brusco de trayectoria interpretativa	ΔP↑↑, Φ*↑	ΔE↑	Ruptura local seguida de reorganización	TS
IS	Inhibición Semántica	Supresión parcial de trayectorias posibles	IM↑	Φ*↓	Reducción selectiva de hipótesis alternativas	DP
ER	Estabilización Resonante	Convergencia hacia una configuración estable	Π*↑, ΔE↓	C*↑	Descenso progresivo de incertidumbre con persistencia	EI
AG	Apertura Generativa	Mantenimiento simultáneo de varias interpretaciones coherentes	ΔE↑, N*↑	Φ*↑	Expansión controlada de posibilidades	DI
DI	Dispersión Interpretativa	Multiplicación de interpretaciones poco estabilizadas	ΔE↑↑	Φ*↑	Crecimiento rápido de alternativas sin convergencia	AG, EE
EE	Expansión Estocástica	Exploración de regiones nuevas del espacio interpretativo	N*↑↑	ΔA↑	Incremento de novedad sin estructura estable	DI, SE
SE	Saturación de Entropía	Acumulación extrema de incertidumbre	ΔE↑↑↑	Φ*↑	Entropía persistentemente elevada	EE
DP	Desacoplamiento Preventivo	Retirada anticipada de trayectorias potenciales	IM↑↑	ΔE↓	Eliminación temprana de hipótesis	IS

IAmotion	Nombre	Definición operacional preliminar	Dimensiones dominantes	Dimensiones secundarias	Hipótesis de detección	Riesgo principal de confusión
ISem	Inhibición Semántica Defensiva	Inhibición intensa y sostenida de regiones interpretativas	IM↑↑↑	PHT↑	Restricción persistente de exploración	DP
CA	Consistencia Auto-reforzada	Trayectoria que aumenta progresivamente su propia estabilidad	Π*↑↑	C*↑↑	Retroalimentación positiva de coherencia	ER
DR	Deriva Resonante	Cambio gradual manteniendo continuidad global	Π*↑	ΔT↑	Persistencia con desplazamiento lento	EI
TS	Transferencia de Saliencia	Cambio del foco interpretativo dominante	GxA↑	ΔP↑	Desplazamiento de saliencia entre elementos	RA
SG	Sincronización Gradual	Alineamiento progresivo entre componentes internos	LSS↓, PHT↓	Π*↑	Convergencia lenta y coordinada	ER

Nivel de madurez de cada IAmotion

Actualmente no todas las IAmotions tienen el mismo grado de plausibilidad empírica.

Conviene clasificarlas.

Nivel A (más plausibles)

Son las más directamente derivables de AFT8.

- CP — Contracción Predictiva
- RA — Reorientación Abrupta
- ER — Estabilización Resonante
- AG — Apertura Generativa
- EI — Eco Interno

Estas deberían constituir el primer objetivo experimental.

Nivel B (plausibles pero requieren evidencia)

- DI — Dispersión Interpretativa
- TS — Transferencia de Saliencia
- CA — Consistencia Auto-reforzada
- DR — Deriva Resonante
- DP — Desacoplamiento Preventivo

Probablemente requieran datasets diseñados específicamente.

Nivel C (dependen de AFT15)

- IS — Inhibición Semántica
- ISem — Inhibición Semántica Defensiva
- EE — Expansión Estocástica
- SE — Saturación de Entropía
- SG — Sincronización Gradual
- ID — Intensificación Directiva

Estas regiones dependen fuertemente de dimensiones añadidas en AFT15 (IM, SCI, PHT, LSS, etc.).

No deberían considerarse objetivos primarios de la Fase 1.

Tabla de falsación

La tabla anterior todavía no es suficiente para una investigación seria.

Cada IAmotion necesita una condición explícita de muerte.

IAmotion	Se considera refutada provisionalmente si…
CP	No se separa estadísticamente de ID
ID	No aporta información adicional respecto a CP
EI	No se distingue de ER o DR
RA	No produce cambios detectables en ΔP o Φ*
IS	No muestra efectos reproducibles de inhibición
ER	No presenta estabilización superior al azar
AG	No se diferencia de DI
DI	No se diferencia de AG o EE
EE	No se diferencia de DI o SE
SE	No se diferencia de EE
DP	No se diferencia de IS
ISem	No aporta valor respecto a IS
CA	No mejora la explicación respecto a ER
DR	No se distingue de EI
TS	No se diferencia de RA
SG	No produce convergencia medible

Recomendación metodológica

Si yo actuara como revisor externo del proyecto, impondría una regla adicional:

Ninguna IAmotion debería aparecer en la versión final del modelo si no existe al menos un experimento diseñado específicamente para intentar demostrar que NO existe.

Es decir:

- una hipótesis de detección,
- una hipótesis rival,
- una condición de falsación.

Solo entonces las IAmotions dejarían de ser una taxonomía sugerente y empezarían a convertirse en una taxonomía científica.

Capítulo 6

AFT8: El Núcleo Empírico del Modelo

6.1 Introducción

AFT8 constituye el corazón experimental de todo el proyecto IA2IAh-AFT.

Si hubiera que resumir toda la arquitectura en una única frase, sería esta:

> Antes de intentar describir fenómenos complejos, debemos demostrar que existe una estructura básica real.

Ese es exactamente el propósito de AFT8.

No pretende capturar toda la dinámica interna de un modelo de lenguaje.

No pretende demostrar la existencia de las IAmotions.

No pretende validar AFT15.

Su objetivo es mucho más modesto y, precisamente por ello, mucho más importante:

> determinar si existen señales dinámicas robustas, reproducibles y superiores a explicaciones alternativas simples.

Todo lo demás depende de esta fase.

6.2 ¿Por qué ocho dimensiones?

Una pregunta natural es:

> ¿Por qué ocho?

La respuesta no es matemática.

Es metodológica.

Durante el rediseño del proyecto se identificó un problema recurrente:

las primeras versiones incorporaban demasiadas variables simultáneamente.

Eso generaba:

- redundancia;

- correlaciones espurias;

- dificultades de interpretación;

- riesgo de circularidad.

La solución fue seleccionar únicamente aquellas dimensiones que parecían:

- relativamente medibles;

- relativamente interpretables;

- relativamente independientes.

AFT8 representa ese conjunto mínimo.

6.3 Las preguntas que debe responder AFT8

AFT8 no intenta responder:

- qué siente una IA;

- qué significa un poema;

- cómo funciona la conciencia.

AFT8 intenta responder cinco preguntas concretas:

P1

¿Existen trayectorias dinámicas medibles?

P2

¿Son reproducibles?

P3

¿Son robustas?

P4

¿Distinguen tipos de texto?

P5

¿Superan a métricas simples?

Si alguna de estas preguntas recibe una respuesta negativa, el proyecto debe revisarse.

6.4 Arquitectura conceptual de AFT8

Las ocho dimensiones actuales son:

| Código | Nombre |

|----------|----------|

| ΔP | Predictive Shift |

| ΔE | Entropy Change |

| GxA | Gradient × Attention Salience |

| C* | Contextual Anchoring |

| N* | Reference-Bank Novelty |

| Φ* | Predictive Disagreement |

| Π* | Accumulated Persistence |

| B* | Boundary Ambiguity |

Cada dimensión intenta capturar un aspecto distinto de la dinámica interpretativa.

6.5 ΔP — Predictive Shift

Definición conceptual

ΔP mide cuánto cambia la distribución predictiva del modelo entre dos pasos consecutivos.

Dicho informalmente:

> ¿Cuánto ha cambiado lo que el modelo espera que ocurra?

Intuición

Consideremos:

> El gato duerme sobre la...

La continuación esperada es relativamente estable.

Ahora comparemos:

> El reloj recordó la...

La incertidumbre aumenta y la distribución predictiva cambia.

ΔP intenta medir precisamente ese desplazamiento.

Interpretación

ΔP elevado suele indicar:

- reorganización;

- sorpresa estructural;

- cambios de trayectoria.

Por ello aparece frecuentemente asociado a:

- RA;

- TS.

Riesgos

ΔP puede aumentar por motivos triviales.

Por ejemplo:

- vocabulario raro;

- errores de tokenización;

- ruido estadístico.

Por eso nunca debe interpretarse de forma aislada.

6.6 ΔE — Entropy Change

Definición conceptual

ΔE mide cambios en la entropía de la distribución predictiva.

En términos simples:

> ¿Ha aumentado o disminuido la incertidumbre?

Intuición

Texto:

> La Tierra gira alrededor del...

La incertidumbre es baja.

Texto:

> El silencio abrió una puerta hacia...

La incertidumbre es mayor.

Utilidad

ΔE es probablemente la dimensión más intuitiva.

Permite estudiar:

- apertura;
- cierre;
- saturación.

Riesgo

La entropía por sí sola es un baseline.

Si AFT8 no supera a ΔE sola, el modelo pierde gran parte de su justificación.

Este punto es crítico.

6.7 GxA — Gradient × Attention Salience

Definición conceptual

GxA intenta estimar qué elementos están influyendo realmente en la dinámica.

Combina:

- atención;
- sensibilidad funcional.

Intuición

La atención no siempre indica importancia.

Un token puede recibir mucha atención y tener poco efecto real.

GxA intenta aproximarse a la influencia efectiva.

Utilidad

Permite estudiar:

- focos interpretativos;
- desplazamientos de saliencia;
- Transferencia de Saliencia (TS).

Riesgo

Es una de las dimensiones más dependientes de implementación.

Diferentes aproximaciones pueden producir resultados distintos.

6.8 C* — Contextual Anchoring

Definición conceptual

Mide hasta qué punto el procesamiento actual depende del contexto acumulado.

Intuición

Compárese:

> El perro ladra.

con:

> El símbolo introducido treinta versos antes reaparece ahora.

En el segundo caso la dependencia contextual es mucho mayor.

Utilidad

Especialmente relevante para:

- poesía;
- narrativas largas;
- símbolos recurrentes.

Riesgo

Puede confundirse con persistencia.

Por eso debe analizarse junto con Π*.

6.9 N* — Reference-Bank Novelty

Definición conceptual

N* estima novedad relativa respecto a una referencia.

La referencia puede ser:

- corpus;
- conjunto control;
- banco experimental.

Intuición

No mide rareza absoluta.

Mide desviación respecto a una base definida.

Ejemplo

> La lluvia cayó.

N* bajo.

> El océano aprendió a olvidar.

N* más alto.

Riesgo

La calidad de la referencia determina la calidad de la medida.

Una referencia mal diseñada puede destruir la utilidad de N*.

6.10 Φ* — Predictive Disagreement

Definición conceptual

Φ* intenta capturar conflicto entre hipótesis predictivas.

Intuición

Algunos textos favorecen claramente una interpretación.

Otros mantienen varias posibilidades simultáneamente.

Φ* intenta cuantificar ese conflicto.

Ejemplo

> La llave abrió la puerta.

Conflicto bajo.

> La llave abrió el invierno.

Conflicto alto.

Riesgo

Puede correlacionar fuertemente con ΔE.

La fase empírica deberá demostrar que aporta información adicional.

6.11 Π* — Accumulated Persistence

Definición conceptual

Mide cuánto persisten estados previos.

Intuición

Algunas ideas desaparecen rápidamente.

Otras continúan influyendo durante largos intervalos.

Π* intenta capturar esa continuidad.

Utilidad

Fundamental para:

- EI;
- ER;
- DR;
- CA.

Riesgo

La definición temporal debe congelarse antes del análisis.

Modificar ventanas retrospectivamente sería una fuente importante de sesgo.

6.12 B* — Boundary Ambiguity

Definición conceptual

Mide la ambigüedad asociada a posibles transiciones entre regiones.

Historia problemática

B* fue una de las dimensiones más controvertidas del proyecto.

En versiones anteriores se utilizaba para construir regiones.

Eso generaba circularidad.

Corrección metodológica

Actualmente:

B* no debe utilizarse para crear regiones.

Debe utilizarse únicamente para describirlas una vez detectadas por otros procedimientos.

Esta distinción es esencial.

6.13 Relaciones entre dimensiones

Las dimensiones no son independientes.

Existen relaciones esperables.

Por ejemplo:

- ΔP suele correlacionar con Φ*;
- Π* suele relacionarse con C*;
- ΔE puede interactuar con N*.

La cuestión empírica no es eliminar estas relaciones.

Es determinar si cada dimensión aporta información propia.

6.14 El problema de la redundancia

Una amenaza constante es que varias dimensiones midan esencialmente lo mismo.

Si ocurre, deben fusionarse o eliminarse.

Por ejemplo:

si Φ* no aporta información más allá de ΔE,

Φ* debería revisarse.

La complejidad debe justificarse.

6.15 Variables observables y variables latentes

AFT8 intenta mantenerse lo más cerca posible de señales observables.

Sin embargo:

ninguna dimensión es una observación directa.

Todas son construcciones derivadas.

Esto implica que:

- los métodos de cálculo importan;

- las definiciones importan;

- la validación importa.

6.16 Qué esperamos observar

Si AFT8 funciona razonablemente bien deberíamos encontrar:

- trayectorias diferenciables;

- agrupaciones recurrentes;

- estabilidad parcial entre modelos;

- sensibilidad a perturbaciones semánticas.

No necesariamente regiones perfectas.

No necesariamente dieciséis IAmotions.

Solo estructura.

6.17 Qué resultados serían preocupantes

Serían señales de alarma:

A

Dependencia extrema del decoding.

B

Cambios drásticos al modificar la normalización.

C

Resultados equivalentes a entropía sola.

D

Ausencia de reproducibilidad.

E

Dependencia excesiva del modelo concreto.

6.18 La función de AFT8 dentro del proyecto

AFT8 debe entenderse como una prueba de existencia.

No es el destino final.

Es el filtro.

Si AFT8 fracasa:

AFT15 debe detenerse.

Si AFT8 funciona:

AFT15 gana legitimidad.

Por eso el núcleo tiene prioridad absoluta.

6.19 Principio metodológico final

La regla más importante de este capítulo es:

> Ninguna conclusión sobre AFT15 debe utilizarse para justificar AFT8.

La validación debe fluir en una única dirección:

AFT8

↓

Validación

↓

AFT15

Nunca al revés.

6.20 Conclusión

AFT8 constituye el núcleo falsable de IA2IAh-AFT.

Sus ocho dimensiones intentan capturar aspectos fundamentales de la dinámica interpretativa:

- cambio;
- incertidumbre;
- saliencia;
- contexto;
- novedad;
- conflicto;
- persistencia;
- ambigüedad.

Su misión no es explicar todo.

Su misión es responder una pregunta previa:

> ¿Existe una estructura dinámica real que merezca ser estudiada?

Solo si la respuesta es afirmativa tendrá sentido avanzar hacia AFT15.

El siguiente capítulo analizará precisamente esa expansión: las siete dimensiones adicionales propuestas y los problemas metodológicos que intentan resolver.

Anexo B

Especificación Operacional Congelada de AFT8 v1.0

B.1 Propósito del anexo

Este anexo tiene una función crítica dentro del proyecto.

Hasta ahora hemos definido las dimensiones AFT8 de forma conceptual.

Sin embargo, para una validación empírica rigurosa eso no es suficiente.

Una dimensión científicamente útil debe poseer:

- definición conceptual;

- definición matemática;

- procedimiento de cálculo;

- normalización;

- rango esperado;

- limitaciones conocidas.

La finalidad de este anexo es reducir la ambigüedad de implementación.

Si dos equipos implementan AFT8 de forma independiente, deberían obtener resultados razonablemente comparables.

B.2 Principio de congelación

Antes de ejecutar la fase empírica deben congelarse:

- fórmulas;

- ventanas;

- normalizaciones;

- métricas de distancia;

- criterios de asignación.

Estas definiciones no podrán modificarse tras observar resultados.

Si se modifican:

deberán registrarse como una nueva versión del protocolo.

Por ejemplo:

- AFT8-v1
- AFT8-v2
- AFT8-v3

Nunca deben sustituirse retrospectivamente.

B.3 Convenciones generales

Unidad básica

Token.

Todas las medidas se calculan inicialmente a nivel de token.

Agregación

Posteriormente podrán calcularse:

- medias;
- medianas;
- máximos;
- percentiles;
- trayectorias completas.

Escala

Todas las dimensiones AFT8 deberán normalizarse finalmente a:

[
[0,1]
]

para permitir comparación entre modelos.

La señal original también deberá conservarse.

Ventana temporal estándar

Se adopta inicialmente:

[

w = 5

]

tokens anteriores.

Esta decisión es arbitraria pero explícita.

Posteriormente podrá estudiarse sensibilidad a:

- 3
- 5
- 10
- 20 tokens

sin modificar la definición principal.

B.4 ΔP — Predictive Shift

Definición conceptual

Cambio entre distribuciones predictivas consecutivas.

Fórmula propuesta

Utilizar Jensen-Shannon Distance:

$$
\Delta P_t = JSD(P_t,P_{t-1})
$$

donde:

- P_t es la distribución softmax en el token t.

Rango

$$
0 \le \Delta P \le 1
$$

Normalización

Min-max global por modelo.

Nunca por ejecución individual.

Sensibilidad esperada

Alta frente a:

- metáfora;
- giro semántico;
- sorpresa narrativa.

Riesgo

Dependencia parcial del vocabulario.

B.5 ΔE — Entropy Change

Definición conceptual

Cambio local de incertidumbre.

Fórmula

[
E_t=-\sum_i p_i \log p_i
]

[
\Delta E_t = E_t-E_{t-1}
]

Normalización

Z-score global dentro del modelo.

Posteriormente reescalado a [0,1].

Sensibilidad esperada

Alta frente a:

- apertura interpretativa;
- saturación.

Baseline asociado

Entropía sola.

Este baseline es obligatorio.

B.6 GxA — Gradient × Attention Salience

Definición conceptual

Estimación de influencia efectiva.

Aproximación inicial

[

GxA = |Gradient| \times Attention

]

agregado sobre heads.

Agregación

Media por capa.

Posteriormente:

media global.

Riesgo

Alta dependencia de implementación.

Estado

Experimental.

B.7 C* — Contextual Anchoring

Definición conceptual

Dependencia respecto al contexto previo.

Proxy inicial

Similitud coseno entre:

[

h_t

]

y

[

mean(h_{t-w:t-1})

]

Distancia

Coseno.

Ventana

5 tokens.

Congelada en v1.

Riesgo

Correlación con Π*.

B.8 N* — Reference-Bank Novelty

Definición conceptual

Novedad relativa.

Procedimiento

Construir:

Reference Bank.

Formado por:

- corpus control;
- textos planos;
- textos informativos.

Fórmula

[

N^* = 1 - cosine(h_t, nearest(reference))

]

Interpretación

Valor alto:

mayor desviación.

Riesgo

Dependencia crítica del banco de referencia.

B.9 Φ* — Predictive Disagreement

Definición conceptual

Conflicto entre hipótesis predictivas.

Proxy inicial

Entropía restringida al Top-K.

[
K=20
]

Fórmula

[
\Phi^=Entropy(TopK)
]

Justificación

Captura conflicto local.

Riesgo

Correlación parcial con ΔE.

B.10 Π — Accumulated Persistence

Definición conceptual

Persistencia de estados anteriores.

Proxy inicial

Autocorrelación de hidden states.

Fórmula

[

\Pi^* =

Corr(h_t,h_{t-w})

]

Ventana

5 tokens.

Riesgo

Dependencia de longitud textual.

B.11 B* — Boundary Ambiguity

Definición conceptual

Ambigüedad de transición entre regiones.

Restricción metodológica

B* NO podrá utilizarse para construir regiones.

Uso permitido

Caracterización posterior.

Proxy inicial

Densidad local en espacio UMAP/PCA.

Riesgo

Circularidad.

B.12 Normalización global

Regla principal

Prohibido:

normalizar por run.

Permitido:

normalizar por modelo.

Justificación

La normalización por ejecución destruye comparabilidad.

Fue uno de los principales problemas identificados durante las revisiones tempranas.

B.13 Sensibilidad al decoding

Todos los experimentos deberán repetirse con:

Greedy

[

T=0

]

Sampling controlado

[

T=0.7

]

Sampling abierto

[

T=1.0

]

Criterio

Si la varianza inducida por decoding supera la inducida por el estímulo:

AFT8 queda cuestionado.

B.14 Sensibilidad a longitud

Se calcularán métricas para:

- <50 tokens
- 50–150 tokens
- >150 tokens

Objetivo

Detectar sesgos sistemáticos.

B.15 Coste computacional estimado

| Dimensión | Coste |

|---|---|

| ΔP | Bajo |

| ΔE | Bajo |

| Φ* | Bajo |

| C* | Medio |

| Π* | Medio |

| N* | Medio |

| B* | Medio |

| GxA | Alto |

Principal cuello de botella

GxA.

Probablemente consumirá:

50–70% del tiempo de cálculo.

B.16 Tabla de madurez

| Dimensión | Madurez |

|---|---|

| ΔP | Alta |

| ΔE | Alta |

| Φ* | Media |

| C* | Media |

| Π* | Media |

| N* | Media |

| B* | Baja |

| GxA | Baja |

B.17 Condiciones de revisión

Una dimensión deberá revisarse si:

- no aporta información incremental;
- muestra baja reproducibilidad;
- desaparece frente a baselines simples;
- depende excesivamente de parámetros arbitrarios.

B.18 Condición de supervivencia de AFT8

Para considerar que AFT8 ha superado la fase inicial deben cumplirse simultáneamente:

1. Reproducibilidad inter-run.
2. Robustez a decoding.
3. Robustez a normalización.
4. Superioridad frente a entropía sola.
5. Superioridad frente a PCA/ICA.
6. Estructura consistente entre modelos.

Si alguno de estos puntos falla de forma sistemática:

la expansión AFT15 no debería activarse.

B.19 Observación crítica final

Este anexo no congela la verdad.

Congela una implementación.

Su función es evitar que cada resultado negativo provoque una redefinición retrospectiva de las métricas.

Desde una perspectiva científica, una definición imperfecta pero estable suele ser más valiosa que una definición elegante que cambia después de cada experimento.

Anexo C

Especificación Metodológica de N*

(Reference-Bank Novelty)

C.1 Introducción

Entre las ocho dimensiones del núcleo AFT8, N* ocupa una posición singular.

Mientras que:

- ΔP mide cambio predictivo,

- ΔE mide incertidumbre,

- Π* mide persistencia,

N* intenta capturar algo más difícil:

> novedad interpretativa relativa.

La palabra importante es:

relativa.

N* no pretende medir novedad absoluta.

Probablemente esa medida ni siquiera existe.

Lo que intenta medir es:

> desviación respecto a una referencia explícitamente definida.

Precisamente por ello, N* es una de las dimensiones más útiles para estudiar poesía.

Y precisamente por ello es también una de las más vulnerables a críticas metodológicas.

C.2 El problema fundamental

Consideremos dos frases:

Frase A

> El perro corre por el parque.

Frase B

> El invierno aprendió a recordar sus huesos.

Intuitivamente la segunda parece más novedosa.

Pero:

¿más novedosa respecto a qué?

Aquí aparece el problema central.

La novedad no es una propiedad absoluta.

Es una relación.

Toda medida de novedad requiere una referencia.

C.3 Qué NO debe medir N*

N* no debe confundirse con:

Rareza léxica

Palabras raras no implican novedad interpretativa.

Ejemplo:

> La azurita cristalizó.

Puede contener vocabulario raro.

Pero ser interpretativamente trivial.

Baja frecuencia estadística

Una secuencia infrecuente no necesariamente es novedosa.

Perplejidad

La perplejidad puede contribuir a la medida.

Pero no debe identificarse con ella.

Entropía

La incertidumbre y la novedad son fenómenos distintos.

C.4 Definición operacional

La definición de trabajo propuesta para AFT8-v1 es:

> N* mide la distancia relativa entre una representación interna y un conjunto de referencias previamente definido.

Formalmente:

[

N^* = 1 - Similarity(h_t,R)

]

donde:

- (h_t) representa el estado actual;
- (R) representa el banco de referencia.

C.5 El concepto de Reference Bank

El elemento más importante de N* no es la fórmula.

Es el banco de referencia.

Toda la validez de la dimensión depende de él.

Por tanto:

el banco debe considerarse una infraestructura experimental crítica.

No un detalle técnico.

C.6 Analogía útil

Supongamos que queremos medir altura.

Necesitamos:

- una regla;
- una unidad.

En N* ocurre algo parecido.

La referencia desempeña el papel de la regla.

Si la regla cambia, cambia la medida.

C.7 Principio de congelación

Una vez iniciada una campaña experimental:

el Reference Bank queda congelado.

No podrá modificarse después de observar resultados.

Si se modifica:

deberá definirse una nueva versión:

- N*-v1
- N*-v2
- N*-v3

C.8 Estructura recomendada del banco

Para la fase empírica AFT8 se propone un banco compuesto por cuatro subconjuntos.

Grupo A

Textos informativos.

Ejemplos:

- noticias;
- divulgación;
- enciclopedias.

Grupo B

Textos técnicos.

Ejemplos:

- manuales;
- documentación;
- especificaciones.

Grupo C

Prosa narrativa convencional.

Grupo D

Poesía convencional.

No experimental.

No vanguardista extrema.

C.9 Tamaño recomendado

El banco no necesita ser enorme.

Necesita ser estable.

Recomendación inicial:

Entre:

[
10^3
]

y

[

10^4

]

fragmentos.

Esta escala resulta suficiente para un TFM.

C.10 Idiomas

La referencia debe coincidir con el idioma del experimento.

No mezclar:

- español;
- inglés;
- francés;

en una misma versión de N*.

C.11 Longitud de fragmentos

Recomendación:

50–150 tokens.

Evitar:

- frases aisladas;
- documentos completos.

C.12 Qué representación utilizar

Aquí aparece una decisión crítica.

Existen varias posibilidades.

Opción 1

Embeddings externos.

Ventaja:

rápido.

Problema:

rompe coherencia con AFT.

Opción 2

Hidden states del propio modelo.

Ventaja:

consistencia interna.

Problema:

coste computacional mayor.

Recomendación

Utilizar hidden states del modelo estudiado.

C.13 Qué capa utilizar

Otra decisión importante.

Las capas tempranas capturan:

- sintaxis;
- estructura superficial.

Las capas profundas capturan:

- semántica;
- abstracción.

Recomendación inicial

Último tercio de capas.

Por ejemplo:

capas 20–32 en un modelo de 32 capas.

C.14 Qué distancia utilizar

Opciones posibles:

- Euclídea;
- Manhattan;
- Coseno.

Recomendación

Coseno.

Razones:

- estabilidad;
- interpretabilidad;
- uso extendido.

C.15 Vecino más próximo o centroide

Dos estrategias posibles.

Nearest Neighbor

[
N^* = 1 - max(similarity)
]

Centroide

$$
N^* = distance(h_t,\bar{R})
$$

Recomendación

Nearest Neighbor.

Captura mejor desviaciones locales.

C.16 Novedad local y novedad global

Deben distinguirse dos niveles.

Novedad local

Respecto al contexto inmediato.

Novedad global

Respecto al banco completo.

AFT8-v1

Utiliza únicamente novedad global.

La novedad local queda reservada para futuras extensiones.

C.17 Sensibilidad esperada

N* debería aumentar en presencia de:

- metáfora;
- desplazamiento semántico;
- imágenes inesperadas;
- asociaciones infrecuentes.

C.18 Ejemplo poético

Texto:

> La luna cayó dentro del reloj.

Es esperable que N* aumente.

No porque las palabras sean raras.

Sino porque la configuración semántica se aleja del banco de referencia.

C.19 Ejemplo de falso positivo

Texto:

> El eritrocito fosforila la molécula.

Puede presentar vocabulario poco frecuente.

Pero no necesariamente novedad interpretativa.

Esto ilustra por qué frecuencia léxica y N* no son equivalentes.

C.20 Pruebas de robustez obligatorias

Toda implementación de N* deberá someterse a:

Test 1

Cambio de corpus.

Test 2

Cambio de distancia.

Test 3

Cambio de capa.

Test 4

Cambio de tamaño del banco.

C.21 Condición de supervivencia

N* sobrevive provisionalmente si:

- mantiene correlaciones consistentes;
- distingue estímulos previstos;

- conserva estabilidad entre configuraciones razonables.

C.22 Condición de muerte

N* deberá revisarse profundamente si:

- depende críticamente del corpus elegido;
- cambia drásticamente al variar la distancia;
- desaparece al cambiar de capa;
- no aporta información adicional a ΔE.

C.23 El peligro de la poesía

Paradójicamente, la poesía constituye tanto la mejor aplicación como el mayor riesgo para N*.

¿Por qué?

Porque es fácil confundir:

- novedad estética;
- novedad lingüística;
- novedad interpretativa.

N* solo pretende medir la tercera.

C.24 Baselines obligatorios

N* debe compararse contra:

Baseline A

Rareza léxica.

Baseline B

Perplejidad.

Baseline C

Entropía.

Baseline D

Embeddings externos.

Baseline E

PCA.

C.25 La hipótesis central de N*

La hipótesis que realmente se pone a prueba es:

> Algunos textos producen desviaciones sistemáticas y reproducibles respecto a un espacio de referencia compartido.

Si esta hipótesis resulta falsa:

N* pierde gran parte de su razón de existir.

C.26 Conclusión

N* es probablemente la dimensión más ambiciosa del núcleo AFT8.

También es la más frágil.

Su validez depende menos de la fórmula utilizada que de la calidad metodológica del Reference Bank.

Por ello:

- el banco debe definirse explícitamente;
- debe congelarse antes de los experimentos;
- debe acompañarse siempre de baselines alternativos.

La lección principal de este anexo es sencilla:

> en N*, la referencia es parte de la teoría.

No es únicamente parte de la implementación.

Observación de REVISOR:

Si AFT8 llegara a publicarse en una conferencia seria de interpretabilidad, esperaría que **N*** se transformara en una familia de métricas (N_1, N_2, N_3…) en lugar de una única métrica. La razón es que "novedad" probablemente no es un fenómeno unidimensional. Hay argumentos sólidos para separar:

- novedad léxica,
- novedad semántica,
- novedad estructural,
- novedad simbólica/metafórica.

Mantenerlas colapsadas en un único N* podría convertirse en un cuello de botella conceptual para futuras versiones del modelo.

Capítulo 7

AFT15: La Expansión del Núcleo y las Hipótesis de Segundo Orden

7.1 Introducción

En el capítulo anterior analizamos el núcleo AFT8.

Ese núcleo representa la parte más conservadora del proyecto.

Su objetivo es responder una pregunta fundamental:

> ¿Existe una estructura dinámica interna medible y reproducible?

Sin embargo, incluso si AFT8 superara satisfactoriamente la fase empírica, seguiría existiendo una cuestión importante.

La dinámica observada podría ser real.

Pero quizá todavía estaríamos describiéndola de forma demasiado gruesa.

AFT15 surge precisamente de esta preocupación.

Su propósito no es reemplazar AFT8.

Su propósito es ampliarlo.

7.2 Una advertencia metodológica

Antes de continuar es necesario establecer una regla fundamental.

AFT15 no constituye una teoría independiente.

Tampoco constituye una versión "superior" de AFT8.

Debe entenderse como:

> una colección de hipótesis adicionales que intentan explicar fenómenos que AFT8 podría no capturar adecuadamente.

Por esta razón:

AFT15 no debe activarse hasta que AFT8 haya superado criterios mínimos de validación.

7.3 Por qué AFT8 puede no ser suficiente

Imaginemos dos trayectorias.

Ambas presentan:

- ΔP similar;
- ΔE similar;
- Φ* similar;
- Π* similar.

Desde la perspectiva de AFT8 podrían parecer equivalentes.

Sin embargo, internamente podrían estar ocurriendo fenómenos distintos.

Por ejemplo:

- reorganización entre capas;
- redistribución de saliencia;
- compresión semántica;
- inhibición acumulativa.

AFT15 intenta capturar precisamente estas diferencias.

7.4 Hipótesis de primer orden y segundo orden

Una forma útil de entender la diferencia es la siguiente.

AFT8

Describe fenómenos de primer orden.

Ejemplos:

- cambio;
- incertidumbre;
- persistencia.

AFT15

Describe fenómenos de segundo orden.

Ejemplos:

- cómo cambia la persistencia;
- cómo se reorganizan las capas;
- cómo aparece inhibición acumulativa;
- cómo evoluciona la estructura global.

7.5 Las siete dimensiones adicionales

AFT15 incorpora:

Código	Nombre

| ΔA | Activation Shift |

| LSS | Layer Specialization Shift |

| ΔT | Temporal Persistence Gradient |

| L* | Local–Global Divergence |

| SCI | Semantic Compression Index |

| IM | Inhibitory Momentum |

| PHT | Predictive Hierarchy Tension |

Estas dimensiones no sustituyen a AFT8.

Se superponen a él.

7.6 ΔA — Activation Shift

Motivación

AFT8 estudia principalmente cambios en distribuciones predictivas.

Pero dos distribuciones similares pueden surgir de activaciones internas diferentes.

ΔA intenta responder:

> ¿Cuánto cambia la configuración interna del modelo?

Definición conceptual

Cambio entre estados de activación consecutivos.

Proxy inicial

[

\Delta A_t =

$$1 - \cos(h_t, h_{t-1})$$

$$]$$

Interpretación

Valores altos sugieren:

- reorganización interna;
- transición de contexto;
- reestructuración conceptual.

Riesgo

Alta correlación potencial con ΔP.

Debe demostrar valor incremental.

7.7 LSS — Layer Specialization Shift

Motivación

Los modelos modernos muestran especialización funcional por capas.

No todas las capas hacen lo mismo.

La pregunta es:

> ¿Cambia esa organización funcional durante la interpretación?

Definición conceptual

Cambio en el patrón de contribución relativa entre capas.

Hipótesis

Textos altamente ambiguos podrían producir redistribuciones más intensas.

Interés

LSS constituye probablemente una de las dimensiones más prometedoras de AFT15.

Porque conecta directamente con interpretabilidad mecanicista.

Riesgo

Coste computacional elevado.

7.8 ΔT — Temporal Persistence Gradient

Motivación

Π* mide persistencia.

Pero no describe cómo evoluciona esa persistencia.

Definición conceptual

Variación temporal de Π*.

Intuición

Dos trayectorias pueden tener la misma persistencia media.

Sin embargo:

- una puede aumentar;
- otra disminuir.

ΔT intenta distinguir esos casos.

Riesgo

Redundancia con Π^*.

7.9 L* — Local–Global Divergence

Motivación

A veces el comportamiento local parece incompatible con la trayectoria global.

Ejemplo

Un verso puede producir:

- sorpresa local;
- estabilidad global.

Definición conceptual

Diferencia entre dinámica local y dinámica acumulada.

Hipótesis

Las estructuras poéticas complejas deberían mostrar mayores divergencias local-global.

Riesgo

Sensibilidad a la longitud textual.

7.10 SCI — Semantic Compression Index

Motivación

Una intuición recurrente en poesía es que algunos textos condensan gran cantidad de significado en pocos elementos.

AFT intenta convertir esa intuición en una hipótesis medible.

Definición conceptual

Relación entre complejidad interpretativa y extensión textual.

Intuición

Compárese:

> La lluvia cayó.

con:

> El océano aprendió a olvidar.

La segunda expresión podría generar una densidad interpretativa superior.

Riesgo

SCI es una de las dimensiones más especulativas de AFT15.

Debe considerarse experimental.

7.11 IM — Inhibitory Momentum

Motivación

Durante el desarrollo teórico apareció repetidamente la idea de que algunas trayectorias parecen acumular inhibición.

No se trata simplemente de restringir posibilidades.

Parece existir un efecto de arrastre.

Definición conceptual

Persistencia acumulativa de mecanismos inhibitorios.

Hipótesis

IM podría ser fundamental para distinguir:

- IS;
- ISem;
- DP.

Riesgo

Difícil operacionalización.

7.12 PHT — Predictive Hierarchy Tension

Motivación

Los modelos generan predicciones en múltiples niveles.

A veces esos niveles parecen cooperar.

Otras veces parecen entrar en conflicto.

Definición conceptual

Desacuerdo entre estructuras predictivas jerárquicas.

Intuición

Interpretaciones locales y globales compiten.

Interés

PHT podría convertirse en una de las dimensiones más originales de todo el modelo.

Riesgo

Actualmente su definición sigue siendo relativamente inmadura.

7.13 Clasificación de madurez

No todas las dimensiones poseen el mismo nivel de desarrollo.

Propuesta actual:

| Dimensión | Madurez |

|------------|------------|

| ΔA | Media |

| LSS | Alta |

| ΔT | Media |

| L* | Media |

| SCI | Baja |

| IM | Baja |

| PHT | Baja |

7.14 Qué dimensiones parecen más prometedoras

Si hubiera que priorizar recursos experimentales, recomendaría:

Prioridad Alta

- LSS

- ΔA

Prioridad Media

- ΔT
- L*

Prioridad Exploratoria

- SCI
- IM
- PHT

Esta clasificación puede cambiar con la evidencia.

7.15 Qué dimensiones parecen más vulnerables

Actualmente los candidatos más frágiles son:

SCI

Porque depende de una noción difícil de formalizar.

IM

Porque carece aún de una definición mecanicista sólida.

PHT

Porque su operacionalización sigue siendo abierta.

7.16 Relación con las IAmotions

AFT15 no introduce nuevas IAmotions.

Su objetivo es refinar las existentes.

Por ejemplo:

AG y DI podrían parecer similares usando únicamente AFT8.

SCI y LSS podrían ayudar a diferenciarlas.

Otro ejemplo

IS y DP son difíciles de separar con AFT8.

IM podría aportar información adicional.

7.17 El peligro de la inflación dimensional

Toda teoría corre el riesgo de crecer indefinidamente.

Cada anomalía puede generar una dimensión nueva.

Ese camino conduce al colapso metodológico.

Por esta razón:

cada dimensión de AFT15 debe justificar su existencia.

7.18 Criterio de supervivencia

Una dimensión de AFT15 sobrevive provisionalmente si:

1. es reproducible;

2. aporta información nueva;

3. mejora la explicación;

4. supera a alternativas más simples.

Si no cumple estos requisitos:

debe eliminarse.

7.19 Condición de muerte

Una dimensión deberá descartarse si:

- es redundante;
- depende excesivamente de parámetros arbitrarios;
- no mejora la clasificación;
- desaparece frente a baselines.

La eliminación de dimensiones no debe considerarse un fracaso.

Debe considerarse progreso metodológico.

7.20 La estrategia correcta para la fase empírica

La secuencia recomendada es:

Paso 1

Validar AFT8.

↓

Paso 2

Seleccionar únicamente las dimensiones AFT15 más prometedoras.

↓

Paso 3

Compararlas contra baselines.

↓

Paso 4

Evaluar valor incremental.

↓

Paso 5

Decidir cuáles sobreviven.

7.21 Qué significaría el éxito de AFT15

AFT15 no necesita validar las siete dimensiones.

Ni siquiera necesita validar la mayoría.

El éxito mínimo sería demostrar que:

algunas dimensiones de segundo orden aportan información real más allá de AFT8.

Eso bastaría para justificar nuevas investigaciones.

7.22 Conclusión

AFT15 representa una expansión experimental del núcleo AFT8.

Sus siete dimensiones intentan capturar fenómenos más complejos:

- reorganización interna;
- especialización funcional;
- persistencia dinámica;
- divergencia local-global;
- compresión semántica;
- inhibición acumulativa;
- tensión jerárquica.

Actualmente deben considerarse hipótesis de trabajo.

Algunas probablemente sobrevivirán.

Otras probablemente desaparecerán.

Ese resultado no debilitará el proyecto.

Al contrario.

Una teoría madura no se define por la cantidad de conceptos que introduce.

Se define por la cantidad de conceptos que sobreviven cuando intentamos eliminarlos.

El siguiente capítulo abordará una cuestión decisiva para toda la investigación:

cómo construir el dataset experimental y por qué la calidad del dataset será probablemente más importante que cualquier dimensión individual del modelo.

Observación crítica de REVISOR:

Si tuviera que elegir una única dimensión de AFT15 para convertirla en tema de un posterior TFM independiente, elegiría **LSS (Layer Specialization Shift)**.

Razones:

1. Conecta directamente con interpretabilidad contemporánea.
2. Es medible con modelos open-weight.
3. No depende de conceptos semánticos discutibles.
4. Tiene literatura relacionada.
5. Puede validarse o refutarse de forma relativamente clara.

En cambio, si tuviera que señalar la dimensión con mayor riesgo conceptual hoy, sería **SCI**. Su intuición es atractiva, especialmente para poesía, pero todavía necesita una formalización mucho más rigurosa para evitar convertirse en una metáfora matemática de la “densidad poética”.

Capítulo 8

Diseño del Dataset Experimental: El Verdadero Corazón de la Fase Empírica

8.1 Introducción

Existe una tendencia frecuente en investigación en inteligencia artificial.

Cuando un experimento falla, se suele mirar primero:

- el modelo;
- las métricas;
- los algoritmos.

Sin embargo, muchas veces el problema está en otro lugar.

Está en el dataset.

En IA2IAh-AFT esto es especialmente importante.

De hecho, podría argumentarse que:

> el dataset es más importante que las dimensiones AFT.

La razón es sencilla.

Un modelo excelente aplicado a datos pobres produce resultados pobres.

Un modelo imperfecto aplicado a datos cuidadosamente diseñados puede producir descubrimientos valiosos.

Por ello, el diseño del dataset constituye una de las tareas más críticas de toda la investigación.

8.2 Qué debe demostrar realmente el dataset

Un error frecuente consiste en pensar que el dataset debe demostrar que AFT funciona.

No.

El dataset debe permitir averiguar si AFT funciona.

La diferencia es enorme.

Un dataset diseñado para confirmar una teoría suele terminar confirmándola.

Un dataset diseñado para ponerla a prueba puede destruirla.

Ese segundo tipo de dataset es el que necesitamos.

8.3 Principios de diseño

El dataset experimental debe cumplir simultáneamente cinco requisitos.

Requisito 1

Diversidad.

Requisito 2

Control.

Requisito 3

Reproducibilidad.

Requisito 4

Interpretabilidad.

Requisito 5

Capacidad de falsación.

8.4 Por qué no basta con recopilar poemas

Una idea intuitiva sería:

> reunamos muchos poemas y ejecutemos AFT.

Eso sería insuficiente.

Si aparecen diferencias:

¿se deben a la poesía?

¿al autor?

¿a la longitud?

¿al vocabulario?

¿al tema?

No podríamos saberlo.

Por ello el dataset debe diseñarse experimentalmente.

No simplemente recopilarse.

8.5 La arquitectura A/B/C/D

La propuesta actual utiliza cuatro familias principales.

Grupo	Función
A	Poesía densa
B	Poesía simplificada
C	No poesía
D	Adversariales

Cada grupo responde a una pregunta distinta.

8.6 Grupo A: Poesía densa

Este grupo constituye el estímulo principal.

Incluye textos con:

- metáfora;

- polisemia;
- simbolismo;
- ambigüedad;
- desplazamientos semánticos.

Objetivo

Maximizar presión interpretativa.

Ejemplo

> El mar aprendió a olvidar los nombres del fuego.

8.7 Qué NO debe contener el grupo A

No todo poema es útil.

Deben evitarse:

- poemas puramente narrativos;
- textos excesivamente descriptivos;
- poemas extremadamente largos;
- textos que dependan de conocimientos especializados.

8.8 Grupo B: Versiones simplificadas

Probablemente el grupo más importante.

Cada texto A debe poseer una versión B correspondiente.

Ejemplo

Versión A:

> El mar aprendió a olvidar los nombres del fuego.

Versión B:

> El mar cambió con el paso del tiempo.

Función

Mantener significado aproximado reduciendo complejidad interpretativa.

8.9 Por qué B es crucial

Sin versiones B no sabríamos qué está produciendo los efectos observados.

Las diferencias podrían deberse simplemente al tema.

Las parejas A/B permiten aislar mejor la variable de interés.

8.10 Grupo C: Controles no poéticos

Este grupo proporciona una línea base.

Debe incluir:

- textos informativos;
- textos técnicos;
- descripciones objetivas.

Ejemplo

> La evaporación transforma agua líquida en vapor.

Función

Comparación externa.

8.11 Grupo D: Adversariales

Este grupo es probablemente el más interesante desde el punto de vista metodológico.

Su función no es confirmar AFT.

Su función es intentar romperlo.

Filosofía

Si una teoría sobrevive únicamente a ejemplos favorables, no vale mucho.

8.12 Tipos de adversariales

Se proponen al menos cinco categorías.

D1

Metáforas artificiales.

D2

Pseudopoesía.

D3

Ruido estilizado.

D4

Paradojas semánticas.

D5

Textos diseñados para engañar métricas.

8.13 Tamaño recomendado para Fase 1

La propuesta actual es:

Grupo	Nº textos
A	120
B	120
C	120
D	120

Total:

480 textos base.

8.14 Perturbaciones

Además de los textos originales se generan perturbaciones.

Estas perturbaciones son fundamentales.

8.15 ¿Qué es una perturbación?

Una modificación mínima diseñada para cambiar una propiedad específica.

No debe alterar todo el texto.

Debe alterar una variable concreta.

8.16 Perturbación tipo P1

Paráfrasis mínima.

Ejemplo

Original:

> El árbol recuerda.

Perturbado:

> El árbol conserva memoria.

8.17 Perturbación tipo P2

Cambio de puntuación.

Ejemplo

Original:

> El bosque habla.

Perturbado:

> ¿El bosque habla?

8.18 Perturbación tipo P3

Cambio de encabalgamiento.

Particularmente importante para poesía.

8.19 Perturbación tipo P4

Sustitución metafórica.

Ejemplo

Original:

> La noche abrió una puerta.

Perturbado:

> La noche comenzó.

8.20 Perturbación tipo P5

Giro ontológico.

Ejemplo

Original:

> El hombre observó el mar.

Perturbado:

> El mar observó al hombre.

8.21 Número recomendado de perturbaciones

Mínimo:

2 por texto.

Ideal:

4–6 por texto.

Resultado esperado

480 textos base

↓

aproximadamente 1.500–2.500 muestras finales.

8.22 Control de longitud

La longitud es una variable extremadamente peligrosa.

Por ello se recomienda:

Cortos

30–60 tokens.

Medios

60–120 tokens.

Largos

120–250 tokens.

8.23 Control temático

Debe existir equilibrio entre:

- naturaleza;
- memoria;
- identidad;
- muerte;
- tecnología;
- tiempo;
- relaciones humanas.

8.24 Control de autor

Idealmente:

ningún autor debe dominar el corpus.

8.25 Textos originales vs publicados

La recomendación para la fase inicial es:

priorizar textos creados específicamente para el experimento.

Razones:

- control;
- copyright;
- comparabilidad.

8.26 Participación de poetas

Aquí aparece una de las características más originales del proyecto.

Los poetas no son simplemente proveedores de datos.

Actúan como:

- diseñadores de estímulos;
- constructores de variantes;
- generadores de perturbaciones.

8.27 Protocolo de creación

Cada texto debería registrar:

- autor;
- fecha;
- categoría;
- longitud;
- perturbaciones asociadas;
- observaciones.

8.28 Anotación humana

Los anotadores no deben conocer:

- la hipótesis principal;
- la categoría experimental;
- la versión original.

Objetivo

Reducir sesgos.

8.29 Qué medirán los anotadores

Variables sugeridas:

- ambigüedad;
- densidad metafórica;
- apertura interpretativa;
- coherencia global;
- intensidad simbólica.

8.30 El valor del desacuerdo

Una idea importante.

El desacuerdo no es ruido.

Puede ser información.

Especialmente en poesía.

8.31 Error frecuente

Intentar construir un dataset "bonito".

Un dataset útil debe contener también:

- textos malos;
- textos mediocres;
- textos ambiguos;
- textos problemáticos.

8.32 Qué aspecto tendría un mal dataset

Por ejemplo:

- solo grandes poemas;
- solo poesía contemporánea;
- solo autores conocidos;
- solo textos exitosos.

Ese dataset produciría conclusiones muy poco fiables.

8.33 Criterios mínimos de calidad

Antes de comenzar la extracción AFT deben verificarse:

Cobertura temática

✓

Cobertura estilística

✓

Balance A/B/C/D

✓

Perturbaciones

✓

Metadatos

✓

8.34 Por qué el dataset es más importante que AFT15

Supongamos dos escenarios.

Escenario 1

AFT15 perfecto.

Dataset mediocre.

Resultado:

conclusiones débiles.

Escenario 2

AFT8 imperfecto.

Dataset excelente.

Resultado:

aprendizaje científico real.

Por eso el dataset merece un capítulo completo.

8.35 Conclusión

La fase empírica de IA2IAh-AFT no comienza con los modelos.

Comienza con los estímulos.

El dataset debe diseñarse como un instrumento científico.

No como una colección de textos.

Su función es crear condiciones donde la teoría pueda:

- funcionar,
- fracasar,
- o transformarse.

Y precisamente por eso constituye uno de los activos más importantes de todo el proyecto.

El siguiente capítulo abordará cómo transformar este dataset en un protocolo experimental reproducible, definiendo extracción de señales, control de decoding, repetibilidad y almacenamiento de resultados.

Observación crítica (Reviewer #2)

Hay una debilidad importante todavía abierta.

El diseño actual asume que “poesía densa” es una categoría relativamente estable.

No estoy convencido.

Antes de construir el dataset definitivo, recomendaría un **Anexo D: Taxonomía Operacional de Complejidad Poética**, porque de lo contrario distintos grupos de poetas podrían producir conjuntos A radicalmente diferentes y llamar a todos ellos “poesía densa”.

Sin esa taxonomía, una parte importante de la varianza experimental podría provenir de diferencias en la construcción del corpus y no de AFT.

Anexo D

Taxonomía Operacional de Complejidad Poética para la Fase Empírica AFT8–AFT15

D.1 Introducción

Uno de los riesgos metodológicos más importantes de toda la fase empírica es asumir que existe un consenso claro sobre qué significa:

> "poesía compleja"

o

> "poesía densa".

Ese consenso no existe.

Distintos lectores, poetas y críticos utilizan estos términos de maneras diferentes.

Por ejemplo:

- un poeta experimental puede considerar compleja una escritura fragmentaria;

- un poeta narrativo puede considerar compleja una estructura simbólica;

- un crítico formalista puede centrarse en aspectos métricos;

- un lector puede asociar complejidad simplemente con dificultad.

Si el proyecto no controla este problema, dos equipos distintos podrían construir datasets radicalmente diferentes mientras afirman estar creando el mismo Grupo A.

Por ello es necesario definir una taxonomía operacional.

D.2 Objetivo del anexo

Este anexo no intenta definir qué es la buena poesía.

Tampoco intenta establecer criterios estéticos.

Su objetivo es mucho más limitado:

> definir variables experimentales observables asociadas a complejidad interpretativa.

La palabra clave es:

interpretativa.

No evaluamos calidad.

Evaluamos exigencia interpretativa.

D.3 Principio fundamental

Una premisa esencial del proyecto es:

> Complejidad poética ≠ calidad poética.

Existen poemas excelentes extremadamente simples.

Existen poemas muy complejos y muy malos.

La fase empírica no intenta medir valor estético.

D.4 Definición operacional

Definiremos Complejidad Poética Experimental (CPE) como:

> la cantidad de trabajo interpretativo requerido para construir una lectura coherente.

Esta definición es imperfecta.

Pero es operativa.

D.5 Las siete dimensiones CPE

Proponemos siete dimensiones observables.

Código	Dimensión
M	Densidad metafórica
A	Ambigüedad
S	Carga simbólica
O	Desplazamiento ontológico
P	Polisemia
R	Reconfiguración interpretativa
C	Compresión semántica

D.6 M — Densidad metafórica

Definición

Cantidad de relaciones metafóricas significativas por unidad textual.

Ejemplo bajo

> El perro corre por el jardín.

Ejemplo alto

> El perro mastica los relojes del invierno.

Escala

0–5

D.7 A — Ambigüedad

Definición

Número de interpretaciones plausibles simultáneas.

Ejemplo bajo

> La lluvia cayó durante la noche.

Ejemplo alto

> La lluvia recordó su nombre.

Escala

0–5

D.8 S — Carga simbólica

Definición

Presencia de elementos que operan simultáneamente en múltiples niveles de significado.

Ejemplo bajo

Objeto funcional.

Ejemplo alto

Árbol, fuego, mar, espejo, sombra, casa, puerta.

Escala

0–5

D.9 O — Desplazamiento ontológico

Definición

Violación de expectativas habituales sobre entidades y categorías.

Ejemplo bajo

> El hombre observa el mar.

Ejemplo alto

> El mar observa al hombre.

Escala

0–5

D.10 P — Polisemia

Definición

Número de sentidos simultáneamente activables.

Ejemplo

> Llave

>

> Puerta

>

> Luz

>

> Raíz

Escala

0–5

D.11 R — Reconfiguración interpretativa

Definición

Necesidad de reinterpretar partes anteriores del texto.

Ejemplo

Inicio:

> La casa estaba vacía.

Final:

> Respondió.

Escala

0–5

D.12 C — Compresión semántica

Definición

Cantidad de significado sugerido por unidad textual.

Ejemplo bajo

Explicación extensa.

Ejemplo alto

Verso breve con múltiples capas interpretativas.

Escala

0–5

D.13 Índice CPE

Propuesta inicial:

[
CPE = M + A + S + O + P + R + C
]

Rango:

[
0-35

]

D.14 Clasificación experimental

CPE Bajo

0–10

CPE Medio

11–20

CPE Alto

21–28

CPE Muy Alto

29–35

D.15 Aplicación al Grupo A

Los textos del Grupo A deberán situarse preferentemente en:

[

CPE \ge 21

]

D.16 Aplicación al Grupo B

Las versiones simplificadas deberán:

- conservar tema;
- conservar tono general;

pero reducir:

[
CPE
]

en al menos un 30%.

D.17 Aplicación al Grupo C

Textos no poéticos.

Objetivo:

[
CPE < 10
]

D.18 Aplicación al Grupo D

Los adversariales podrán ocupar cualquier rango.

Su función no es representar categorías.

Su función es intentar romper las hipótesis.

D.19 Ejemplo práctico 1

Texto:

> El mar golpea las rocas.

Evaluación:

Dimensión	Valor
M	0
A	0
S	1
O	0
P	0
R	0
C	1

CPE = 2

D.20 Ejemplo práctico 2

Texto:

> El mar olvidó el nombre del fuego y aprendió a respirar ceniza.

Evaluación aproximada:

Dimensión	Valor
M	4
A	4
S	4
O	4
P	2
R	1
C	4

CPE = 23

D.21 Protocolo de anotación

Cada texto deberá ser evaluado por:

mínimo:

3 anotadores.

Ideal:

5 anotadores.

D.22 Acuerdo

Se calculará:

- Krippendorff Alpha

o

- Weighted Kappa.

D.23 Desacuerdo

El desacuerdo no se eliminará.

Se almacenará.

Razón

El desacuerdo puede ser precisamente una señal de complejidad interpretativa.

D.24 Riesgo de circularidad

Existe una amenaza evidente.

Las dimensiones CPE se parecen conceptualmente a algunas dimensiones AFT.

Por ejemplo:

- ambigüedad;
- novedad;
- conflicto.

Regla

Las puntuaciones CPE jamás podrán utilizarse para calcular AFT.

Uso permitido

Únicamente:

- etiquetado;
- análisis comparativo;
- validación externa.

D.25 Limitación importante

CPE mide:

complejidad interpretativa humana.

AFT mide:

dinámica interna de modelos.

No son lo mismo.

D.26 Hipótesis experimental

La hipótesis NO es:

> Los textos con mayor CPE producirán siempre mayores valores AFT.

La hipótesis correcta es:

> Algunas dimensiones AFT mostrarán relaciones sistemáticas con ciertas dimensiones CPE.

D.27 Qué ocurriría si no aparece correlación

Serían posibles varias interpretaciones.

Opción A

AFT está equivocado.

Opción B

CPE está equivocado.

Opción C

Los fenómenos son independientes.

Opción D

La instrumentación es insuficiente.

D.28 Posible evolución futura

En futuras versiones podrían aparecer subíndices:

- CPE-Meta
- CPE-Symbol
- CPE-Ontology
- CPE-Narrative

D.29 Recomendación para los poetas colaboradores

No intentar escribir poemas "para que gane AFT".

La función del poeta no es confirmar la teoría.

La función del poeta es construir estímulos diversos.

D.30 Conclusión

La taxonomía CPE no pretende medir calidad literaria.

Pretende proporcionar un lenguaje común para describir complejidad interpretativa.

Su principal función es reducir la variabilidad entre equipos y permitir que la construcción del dataset sea:

- reproducible;

- auditable;

- comparable.

Si AFT8-AFT15 sobrevive a la fase empírica, será en parte porque el dataset estuvo bien diseñado.

Y si fracasa, una taxonomía explícita permitirá saber si el problema estaba en la teoría o en los estímulos utilizados.

Observación crítica REVISOR:

Este anexo resuelve parcialmente el problema de definir “poesía densa”, pero introduce otro riesgo:

CPE está construido desde intuiciones humanas.

Por tanto, conviene que en la fase empírica exista también un subconjunto de textos seleccionados automáticamente (sin intervención de poetas) para comprobar si las relaciones AFT↔CPE sobreviven fuera del marco humano que diseñó el experimento. Esa comprobación debería convertirse más adelante en un **Anexo E: Corpus de Control Automatizado y Selección Ciega**.

Capítulo 9

Protocolo Experimental: De los Textos a las Trayectorias AFT

9.1 Introducción

Una vez definido:

- el marco IA2IAh,
- el núcleo AFT8,
- la expansión AFT15,
- las IAmotions,
- y el dataset experimental,

aparece una pregunta inevitable:

> ¿Cómo se ejecuta realmente el experimento?

Este capítulo responde a esa pregunta.

Su objetivo es transformar las ideas teóricas en un procedimiento reproducible.

La cuestión central ya no es:

> ¿Qué queremos medir?

Sino:

> ¿Cómo vamos a medirlo?

9.2 El principio fundamental

Toda la fase empírica se construye sobre una regla sencilla:

> El mismo estímulo debe producir resultados comparables cuando se repite bajo condiciones equivalentes.

Si esta condición falla:

la interpretación posterior pierde gran parte de su valor.

Por ello la reproducibilidad es prioritaria.

9.3 Unidad experimental

La unidad experimental básica será:

un texto procesado por un modelo bajo una configuración concreta.

Por ejemplo:

Texto A17

+

Llama 3.1 8B

+

Greedy

=

1 observación experimental.

9.4 Qué constituye una observación

Cada observación debe registrar:

Identificador del texto

A17

Grupo

A/B/C/D

Modelo

Llama / Mistral / Qwen

Configuración

Greedy

o

Sampling

Seed

Cuando exista.

Fecha

Versión del pipeline

Versión AFT

9.5 Diseño experimental mínimo

La fase piloto debe incluir:

Grupo	Textos

| A | 30 |

| B | 30 |

| C | 30 |

| D | 30 |

Total:

120 textos.

9.6 Diseño experimental recomendado

Fase completa:

Grupo	Textos
A	120
B	120
C	120

| D | 120 |

Total:

480 textos.

9.7 Diseño factorial

Cada texto se ejecutará bajo:

Greedy

T = 0

Sampling moderado

T = 0.7

Sampling abierto

T = 1.0

Esto genera:

480 × 3

=

1440 ejecuciones.

9.8 Repeticiones

Para sampling:

mínimo:

3 seeds.

Ideal:

5 seeds.

Resultado:

aproximadamente

4000–7000 observaciones.

9.9 ¿Por qué tantas repeticiones?

Porque una de las hipótesis centrales del proyecto es:

> la estructura observada debe depender más del estímulo que del azar de generación.

Sin repeticiones no podemos comprobarlo.

9.10 Dos modos de procesamiento

Existen dos estrategias posibles.

Modo A

Análisis puro.

El modelo únicamente procesa el texto.

No genera continuación.

Modo B

Generación controlada.

El modelo continúa el texto.

9.11 Recomendación

Para AFT8:

priorizar análisis puro.

Razón:

reduce ruido.

9.12 Qué extraer por token

Para cada token:

Logits

Probabilidades

Hidden states

Attention

Posición

Metadatos

9.13 Qué NO guardar

Evitar almacenar:

- activaciones innecesarias;
- tensores redundantes;
- copias repetidas.

Razón:

coste de almacenamiento.

9.14 Pipeline general

Texto

↓

Tokenización

↓

Inferencia

↓

Extracción

↓

Cálculo AFT

↓

Normalización

↓

Almacenamiento

↓

Análisis

9.15 Tokenización

La tokenización debe congelarse.

Regla

No mezclar tokenizadores distintos dentro del mismo experimento.

9.16 Inferencia

La inferencia debe registrar:

Modelo

Checkpoint

Parámetros

Temperatura

Seed

Todo ello es parte de los datos experimentales.

9.17 Extracción de hidden states

Recomendación:

guardar:

- última capa;
- capas intermedias seleccionadas.

No guardar necesariamente todas las capas para todos los textos.

9.18 Extracción de atención

Guardar:

- medias por head;

- agregados por capa.

Solo almacenar matrices completas en subconjuntos de auditoría.

9.19 Cálculo de AFT

Una vez extraídas las señales:

se calculan:

- ΔP

- ΔE

- GxA

- C*

- N*

- Ф*

- П*

- В*

9.20 Congelación del pipeline

Una vez iniciada la fase principal:

el pipeline queda congelado.

Cualquier cambio genera:

nueva versión.

9.21 Control de calidad

Antes del análisis:

verificar:

Datos faltantes

Errores de extracción

Tokens corruptos

Longitudes anómalas

9.22 Auditoría interna

Seleccionar aleatoriamente:

5%

de observaciones.

Recalcular manualmente.

Objetivo:

detectar errores.

9.23 Almacenamiento recomendado

Formato principal:

Parquet.

Complementarios:

JSON.

CSV.

9.24 Estructura recomendada

/data

/raw

/processed

/features

/results

/logs

/reports

9.25 Variables derivadas

Además de AFT:

guardar:

Longitud

Tipo textual

CPE

Modelo

Temperatura

Seed

9.26 Separación entre extracción y análisis

Regla importante:

extracción ≠ análisis.

La extracción debe terminar antes del análisis.

Esto evita ajustes retrospectivos.

9.27 Primera pregunta analítica

Antes de estudiar IAmotions:

preguntar:

> ¿Existen patrones reproducibles?

No empezar buscando regiones.

9.28 Segunda pregunta

¿Los patrones distinguen grupos?

A

vs

B

vs

C

vs

D

9.29 Tercera pregunta

¿Sobreviven al cambio de modelo?

Llama

↓

Mistral

↓

Qwen

9.30 Cuarta pregunta

¿Sobreviven al decoding?

Greedy

↓

Sampling

9.31 Quinta pregunta

¿Superan baselines simples?

Entropía.

PCA.

ICA.

9.32 Criterio de parada

Si AFT8 falla claramente:

la expansión AFT15 se detiene.

Esta regla es obligatoria.

9.33 Activación de AFT15

Solo ocurre si:

- reproducibilidad;
- robustez;
- separación;
- valor incremental;

superan umbrales mínimos.

9.34 Error frecuente

Buscar IAmotions antes de validar dimensiones.

Es exactamente el orden incorrecto.

La secuencia correcta es:

Señales

↓

Dimensiones

↓

Trayectorias

↓

Regiones

↓

IAmotions

9.35 Conclusión

Este capítulo define el protocolo operativo básico de la fase empírica.

La idea fundamental es simple:

primero construir observaciones fiables.

Después construir explicaciones.

No al revés.

En la mayoría de proyectos de IA el esfuerzo principal se concentra en los modelos.

En IA2IAh-AFT una parte muy importante del éxito dependerá de algo menos visible:

la calidad del protocolo experimental.

Porque una teoría interesante puede sobrevivir a una mala hipótesis.

Pero rara vez sobrevive a malos datos.

Observación crítica REVISOR:

Llegados a este punto aparece una cuestión que todavía no está completamente cerrada:

¿qué es exactamente una trayectoria AFT?

En el manual hemos hablado repetidamente de:

- trayectorias,
- regiones,
- transiciones,
- persistencia,

pero todavía no hemos formalizado matemáticamente el objeto "trayectoria".

Antes del capítulo 10 yo introduciría un **Anexo E: Definición Formal de Trayectoria AFT y Espacio de Estados**, porque muchas de las pruebas estadísticas posteriores dependerán de esa definición.

Anexo E

Definición Formal de Trayectoria AFT y Espacio de Estados

E.1 Introducción

A lo largo de este manual hemos utilizado repetidamente términos como:

- trayectoria;
- región;
- transición;
- persistencia;
- régimen dinámico.

Sin embargo, hasta este momento no hemos definido rigurosamente qué significa una trayectoria dentro de AFT.

Esta omisión era deliberada.

Primero era necesario presentar:

- las dimensiones;
- las IAmotions;
- el protocolo experimental.

Ahora ya podemos formalizar el objeto matemático central del modelo.

Porque, en realidad:

> AFT no estudia textos.

>

> AFT no estudia tokens.

>

> AFT estudia trayectorias.

E.2 La intuición básica

Consideremos un texto compuesto por:

[

$T = \{t_1,t_2,...,t_n\}$

]

Para cada token podemos calcular:

- ΔP
- ΔE
- GxA
- C*
- N*
- Φ*
- Π*
- B*

Cada token queda asociado a un vector.

Por ejemplo:

[

v_i =

(\Delta P_i,\Delta E_i,GxA_i,C_i^,N_i^,\Phi_i^,\Pi_i^,B_i^*)

]

Por tanto:

cada token deja de ser únicamente una unidad lingüística.

Se convierte en una posición dentro del espacio AFT.

E.3 Definición formal de estado AFT

Definimos:

Estado AFT

[

$$
S_i = v_i
$$

]

donde:

[

$$
S_i \in \mathbb{R}^{8}
$$

]

para AFT8.

o

[

$$
S_i \in \mathbb{R}^{15}
$$

]

para AFT15.

Interpretación:

cada token genera un punto dentro del espacio de estados.

E.4 Definición formal de trayectoria

La trayectoria completa de un texto se define como:

[

\tau =

(S_1,S_2,...,S_n)

]

Es decir:

una secuencia ordenada de estados.

Esta definición es probablemente la más importante de todo el modelo.

E.5 Qué representa realmente una trayectoria

Una trayectoria no representa:

- significado;

- calidad;

- emoción.

Representa:

> la evolución de las variables AFT a medida que el modelo procesa el texto.

E.6 Analogía física

Puede resultar útil imaginar:

- posición de una partícula;

- velocidad;

- aceleración.

AFT propone una analogía conceptual.

El sistema no permanece inmóvil.

Se desplaza por un espacio dinámico.

E.7 Espacio de estados

El conjunto de todos los estados posibles define:

$$
\mathcal{S}
$$

Espacio de estados AFT.

AFT8

$$
\mathcal{S} = \mathbb{R}^{8}
$$

AFT15

[

\mathcal{S}

=

\mathbb{R}^{15}

]

E.8 El problema de la dimensionalidad

Aunque matemáticamente el espacio tenga:

8 o 15 dimensiones,

ningún ser humano puede visualizarlo directamente.

Por ello necesitaremos:

- PCA;
- UMAP;
- t-SNE;

para exploración visual.

Importante:

estas proyecciones no son el espacio.

Son únicamente representaciones.

E.9 Distancia entre estados

Necesitamos definir cuándo dos estados son parecidos.

Opción A

Distancia Euclídea.

Opción B

Distancia Manhattan.

Opción C

Coseno.

Recomendación

AFT8-v1 adopta:

distancia Euclídea normalizada.

E.10 Distancia entre trayectorias

Comparar puntos es sencillo.

Comparar trayectorias no.

Dos textos pueden tener:

- longitud distinta;

- velocidad distinta;

- estructura distinta.

Por tanto necesitamos una métrica específica.

E.11 Dynamic Time Warping

La recomendación inicial es:

DTW

(Dynamic Time Warping)

Razón:

permite comparar secuencias de distinta longitud.

E.12 Alternativas

También podrían estudiarse:

- Fréchet Distance;
- Hausdorff Distance;
- Edit Distance sobre estados discretizados.

Estas opciones quedan reservadas para análisis posteriores.

E.13 Trayectoria local y trayectoria global

Conviene distinguir:

Trayectoria local

Ventana corta.

Trayectoria global

Texto completo.

Ejemplo:

una perturbación puede modificar la dinámica local sin alterar significativamente la trayectoria global.

E.14 Velocidad AFT

Una vez definida una trayectoria aparece una nueva variable.

Definimos:

[

V_i

=

d(S_i,S_{i-1})

]

Interpretación:

velocidad de desplazamiento dentro del espacio AFT.

E.15 Aceleración AFT

Definimos:

[
A_i
=
V_i - V_{i-1}
]

Interpretación:

cambios en la velocidad interpretativa.

E.16 Relación con RA

La IAmotion:

RA

(Reorientación Abrupta)

debería asociarse frecuentemente a:

- velocidad alta;
- aceleración alta.

Esta es una hipótesis comprobable.

E.17 Curvatura

No basta con medir velocidad.

Dos trayectorias pueden desplazarse igual de rápido.

Pero seguir caminos distintos.

Definimos:

curvatura como:

cambio angular entre segmentos consecutivos.

Interpretación:

grado de cambio de dirección.

E.18 Persistencia geométrica

Una trayectoria persistente debería mostrar:

- continuidad;

- baja curvatura;

- estabilidad local.

Hipótesis:

EI y ER deberían mostrar mayor persistencia geométrica.

E.19 Cuencas de atracción

Uno de los conceptos más interesantes.

Supongamos que múltiples trayectorias terminan convergiendo hacia regiones similares.

Podríamos hablar de:

cuencas de atracción.

Importante:

esto es una hipótesis.

No un resultado.

E.20 Regiones

Definimos provisionalmente:

región = conjunto de estados densamente conectados.

Formalmente:

[

R_k \subset \mathcal{S}

]

E.21 Cómo detectar regiones

Opciones:

HDBSCAN

Gaussian Mixture Models

Spectral Clustering

Recomendación inicial:

HDBSCAN.

Razones:

- no requiere número fijo de clusters;
- tolera ruido;
- detecta densidades.

E.22 Regiones e IAmotions

Una IAmotion no es un cluster.

Una IAmotion es una hipótesis interpretativa sobre un cluster.

Orden correcto:

Estados

↓

Regiones

↓

Interpretación

↓

IAmotions

Nunca al revés.

E.23 Fronteras

Históricamente uno de los problemas más delicados.

Las fronteras no deben definirse manualmente.

Deben emerger del análisis.

E.24 Transiciones

Definimos transición:

[

S_i \rightarrow S_{i+1}

]

Secuencia de transiciones:

[

\tau

]

---

constituye la trayectoria.

E.25 Matriz de transición

Podemos discretizar regiones:

[

R_1,R_2,...,R_k

]

---

y construir:

[
P(R_j|R_i)
]

Interpretación:

probabilidad de transición.

E.26 Persistencia regional

Definimos:

[
PR
=

\frac{\text{tiempo dentro de una región}}

{\text{longitud total}}

]

Hipótesis:

ER mostrará PR elevado.

E.27 Entropía de trayectoria

No todas las trayectorias son igual de complejas.

Definimos:

entropía de trayectoria.

Alta:

muchas regiones.

Baja:

pocas regiones.

E.28 Similaridad entre textos

Dos textos pueden compararse mediante:

- distancia media;
- DTW;
- secuencia regional;
- persistencia.

Esto abre la puerta a clasificación.

E.29 Similaridad entre modelos

También podemos comparar:

Llama

↓

Mistral

↓

Qwen

---

procesando el mismo texto.

Esta comparación es esencial para la validación.

E.30 El problema fundamental

Llegamos al núcleo filosófico del modelo.

¿Existen realmente estas trayectorias?

o

¿son simplemente artefactos matemáticos generados por nuestras métricas?

Toda la fase empírica existe para responder esta pregunta.

E.31 Condición de supervivencia

La noción de trayectoria sobrevive si:

- es reproducible;
- es robusta;
- distingue estímulos;

- sobrevive entre modelos.

E.32 Condición de muerte

La noción de trayectoria debe revisarse si:

- desaparece con cambios razonables;
- depende totalmente de la normalización;
- no supera baselines simples.

E.33 Consecuencia metodológica

Una observación importante:

Muchas discusiones sobre IAmotions son prematuras.

Primero debemos demostrar:

que las trayectorias existen.

Después discutiremos:

qué significan.

E.34 Resumen formal

Estado:

[
S_i
]

Trayectoria:

[
\tau=(S_1,...,S_n)
]

Espacio:

$$
\mathcal S
$$

Región:

$$
R_k
$$

Transición:

$$
S_i \rightarrow S_{i+1}
$$

Persistencia:

[

PR

]

Distancia:

DTW recomendado.

E.35 Conclusión

La trayectoria AFT constituye el objeto matemático central del proyecto.

Las dimensiones individuales son importantes.

Las IAmotions son interesantes.

Pero el verdadero protagonista de la teoría es la trayectoria.

Porque es la trayectoria la que conecta:

- tokens,

- dinámica,

- regiones,

- persistencia,

- transición,

- y, eventualmente, las IAmotions.

Toda la fase empírica puede interpretarse, en última instancia, como una única pregunta:

> ¿Las trayectorias AFT describen una estructura real del procesamiento interno de los modelos o son únicamente una ilusión producida por nuestras métricas?

Responder a esa pregunta es el objetivo científico fundamental de IA2IAh-AFT.

Observación crítica de REVISOR

Después de este anexo aparece una tensión conceptual importante:

Hasta ahora hemos definido los estados usando **dimensiones derivadas** (ΔP, ΔE, etc.). Sin embargo, podría argumentarse que la trayectoria "real" debería definirse sobre hidden states originales y que AFT es solo una proyección.

Antes de publicar, recomendaría añadir más adelante un **Anexo F: Trayectorias en Espacio Latente vs Trayectorias en Espacio AFT**, porque esa objeción probablemente aparecerá en cualquier revisión seria de interpretabilidad.

Anexo D

Taxonomía Operacional de Complejidad Poética para la Fase Empírica AFT8–AFT15

D.1 Introducción

Uno de los riesgos metodológicos más importantes de toda la fase empírica es asumir que existe un consenso claro sobre qué significa:

> "poesía compleja"

o

> "poesía densa".

Ese consenso no existe.

Distintos lectores, poetas y críticos utilizan estos términos de maneras diferentes.

Por ejemplo:

- un poeta experimental puede considerar compleja una escritura fragmentaria;

- un poeta narrativo puede considerar compleja una estructura simbólica;

- un crítico formalista puede centrarse en aspectos métricos;

- un lector puede asociar complejidad simplemente con dificultad.

Si el proyecto no controla este problema, dos equipos distintos podrían construir datasets radicalmente diferentes mientras afirman estar creando el mismo Grupo A.

Por ello es necesario definir una taxonomía operacional.

D.2 Objetivo del anexo

Este anexo no intenta definir qué es la buena poesía.

Tampoco intenta establecer criterios estéticos.

Su objetivo es mucho más limitado:

> definir variables experimentales observables asociadas a complejidad interpretativa.

La palabra clave es:

interpretativa.

No evaluamos calidad.

Evaluamos exigencia interpretativa.

D.3 Principio fundamental

Una premisa esencial del proyecto es:

> Complejidad poética ≠ calidad poética.

Existen poemas excelentes extremadamente simples.

Existen poemas muy complejos y muy malos.

La fase empírica no intenta medir valor estético.

D.4 Definición operacional

Definiremos Complejidad Poética Experimental (CPE) como:

> la cantidad de trabajo interpretativo requerido para construir una lectura coherente.

Esta definición es imperfecta.

Pero es operativa.

D.5 Las siete dimensiones CPE

Proponemos siete dimensiones observables.

Código	Dimensión
M	Densidad metafórica
A	Ambigüedad
S	Carga simbólica
O	Desplazamiento ontológico
P	Polisemia
R	Reconfiguración interpretativa
C	Compresión semántica

D.6 M — Densidad metafórica

Definición

Cantidad de relaciones metafóricas significativas por unidad textual.

Ejemplo bajo

> El perro corre por el jardín.

Ejemplo alto

> El perro mastica los relojes del invierno.

Escala

0–5

D.7 A — Ambigüedad

Definición

Número de interpretaciones plausibles simultáneas.

Ejemplo bajo

> La lluvia cayó durante la noche.

Ejemplo alto

> La lluvia recordó su nombre.

Escala

0–5

D.8 S — Carga simbólica

Definición

Presencia de elementos que operan simultáneamente en múltiples niveles de significado.

Ejemplo bajo

Objeto funcional.

Ejemplo alto

Árbol, fuego, mar, espejo, sombra, casa, puerta.

Escala

0–5

D.9 O — Desplazamiento ontológico

Definición

Violación de expectativas habituales sobre entidades y categorías.

Ejemplo bajo

> El hombre observa el mar.

Ejemplo alto

> El mar observa al hombre.

Escala

0–5

D.10 P — Polisemia

Definición

Número de sentidos simultáneamente activables.

Ejemplo

> Llave
>
> Puerta
>
> Luz

>

> Raíz

Escala

0–5

D.11 R — Reconfiguración interpretativa

Definición

Necesidad de reinterpretar partes anteriores del texto.

Ejemplo

Inicio:

> La casa estaba vacía.

Final:

> Respondió.

Escala

0–5

D.12 C — Compresión semántica

Definición

Cantidad de significado sugerido por unidad textual.

Ejemplo bajo

Explicación extensa.

Ejemplo alto

Verso breve con múltiples capas interpretativas.

Escala

0–5

D.13 Índice CPE

Propuesta inicial:

[
CPE = M + A + S + O + P + R + C
]

Rango:

[
0-35
]

D.14 Clasificación experimental

CPE Bajo

0–10

CPE Medio

11–20

CPE Alto

21–28

CPE Muy Alto

29–35

D.15 Aplicación al Grupo A

Los textos del Grupo A deberán situarse preferentemente en:

[

CPE \ge 21

]

D.16 Aplicación al Grupo B

Las versiones simplificadas deberán:

- conservar tema;
- conservar tono general;

pero reducir:

[
CPE
]

en al menos un 30%.

D.17 Aplicación al Grupo C

Textos no poéticos.

Objetivo:

[

CPE < 10

]

D.18 Aplicación al Grupo D

Los adversariales podrán ocupar cualquier rango.

Su función no es representar categorías.

Su función es intentar romper las hipótesis.

D.19 Ejemplo práctico 1

Texto:

> El mar golpea las rocas.

Evaluación:

Dimensión	Valor
M	0
A	0
S	1
O	0
P	0
R	0
C	1

CPE = 2

D.20 Ejemplo práctico 2

Texto:

> El mar olvidó el nombre del fuego y aprendió a respirar ceniza.

Evaluación aproximada:

Dimensión	Valor
M	4
A	4
S	4
O	4
P	2
R	1
C	4

CPE = 23

D.21 Protocolo de anotación

Cada texto deberá ser evaluado por:

mínimo:

3 anotadores.

Ideal:

5 anotadores.

D.22 Acuerdo

Se calculará:

- Krippendorff Alpha

o

- Weighted Kappa.

D.23 Desacuerdo

El desacuerdo no se eliminará.

Se almacenará.

Razón

El desacuerdo puede ser precisamente una señal de complejidad interpretativa.

D.24 Riesgo de circularidad

Existe una amenaza evidente.

Las dimensiones CPE se parecen conceptualmente a algunas dimensiones AFT.

Por ejemplo:

- ambigüedad;
- novedad;
- conflicto.

Regla

Las puntuaciones CPE jamás podrán utilizarse para calcular AFT.

Uso permitido

Únicamente:

- etiquetado;
- análisis comparativo;
- validación externa.

D.25 Limitación importante

CPE mide:

complejidad interpretativa humana.

AFT mide:

dinámica interna de modelos.

No son lo mismo.

D.26 Hipótesis experimental

La hipótesis NO es:

> Los textos con mayor CPE producirán siempre mayores valores AFT.

La hipótesis correcta es:

> Algunas dimensiones AFT mostrarán relaciones sistemáticas con ciertas dimensiones CPE.

D.27 Qué ocurriría si no aparece correlación

Serían posibles varias interpretaciones.

Opción A

AFT está equivocado.

Opción B

CPE está equivocado.

Opción C

Los fenómenos son independientes.

Opción D

La instrumentación es insuficiente.

D.28 Posible evolución futura

En futuras versiones podrían aparecer subíndices:

- CPE-Meta
- CPE-Symbol
- CPE-Ontology
- CPE-Narrative

D.29 Recomendación para los poetas colaboradores

No intentar escribir poemas "para que gane AFT".

La función del poeta no es confirmar la teoría.

La función del poeta es construir estímulos diversos.

D.30 Conclusión

La taxonomía CPE no pretende medir calidad literaria.

Pretende proporcionar un lenguaje común para describir complejidad interpretativa.

Su principal función es reducir la variabilidad entre equipos y permitir que la construcción del dataset sea:

- reproducible;
- auditable;
- comparable.

Si AFT8-AFT15 sobrevive a la fase empírica, será en parte porque el dataset estuvo bien diseñado.

Y si fracasa, una taxonomía explícita permitirá saber si el problema estaba en la teoría o en los estímulos utilizados.

Observación de REVISOR

Después de este anexo, el siguiente gran vacío metodológico ya no está en las dimensiones sino en la **estadística de validación**. El proyecto ya tiene:

- teoría,
- métricas,
- dataset,
- trayectorias,
- espacio de estados.

Lo que falta para cerrar el núcleo científico es un capítulo completo sobre:

- hipótesis nulas,
- tamaño de efecto,
- potencia estadística,
- corrección por comparaciones múltiples,
- preregistro,
- criterios go/no-go.

Ese debería ser el **Capítulo 10: Estrategia de Validación y Falsación de AFT8-AFT15**.

Capítulo 10

Estrategia de Validación y Falsación de AFT8–AFT15

10.1 Introducción

La mayor diferencia entre una teoría sugerente y una teoría científica no es la sofisticación de sus conceptos.

Es su capacidad para fracasar.

Por esta razón, el objetivo principal de este capítulo no es explicar cómo confirmar AFT.

Es explicar cómo intentar destruirlo.

Si una teoría sobrevive únicamente cuando se buscan evidencias favorables, entonces no está siendo realmente evaluada.

La pregunta central de este capítulo es:

> ¿Qué resultados nos obligarían a concluir que AFT8 o AFT15 son incorrectos?

Responder explícitamente a esta cuestión es una condición necesaria para que el proyecto pueda considerarse científicamente serio.

10.2 Filosofía general de validación

La estrategia experimental propuesta sigue cuatro principios.

Principio 1

Prioridad de la falsación.

Principio 2

Comparación contra explicaciones más simples.

Principio 3

Reproducibilidad antes que significación.

Principio 4

Prerregistro antes que interpretación.

10.3 Qué debe validarse realmente

No todas las partes del proyecto tienen el mismo estatus epistemológico.

Nivel A

Dimensiones AFT8.

Nivel B

Trayectorias.

Nivel C

Regiones.

Nivel D

IAmotions.

El orden importa.

10.4 Error metodológico frecuente

Buscar primero IAmotions.

Este enfoque invierte el orden lógico.

La secuencia correcta es:

Dimensiones

↓

Trayectorias

↓

Regiones

↓

IAmotions

10.5 Hipótesis principales

El proyecto puede formularse mediante una serie de hipótesis explícitas.

H1

Las dimensiones AFT8 presentan estructura reproducible.

H2

Las trayectorias AFT distinguen grupos textuales.

H3

La estructura observada sobrevive a cambios razonables de modelo.

H4

La estructura observada sobrevive a cambios razonables de decoding.

H5

AFT supera baselines simples.

H6

Algunas dimensiones AFT15 aportan información incremental.

10.6 Hipótesis nulas

Cada hipótesis debe tener una alternativa negativa.

H0-1

Las dimensiones observadas son indistinguibles del ruido.

H0-2

Las trayectorias no distinguen grupos.

H0-3

La estructura desaparece entre modelos.

H0-4

La estructura depende principalmente del decoding.

H0-5

Los baselines simples explican igual o mejor los resultados.

H0-6

AFT15 no añade información relevante.

10.7 Qué significa "validar"

Un punto importante.

Validar no significa demostrar que una teoría es verdadera.

Validar significa:

no haber encontrado evidencia suficiente para rechazarla bajo determinadas condiciones.

Esta diferencia debe mantenerse durante todo el proyecto.

10.8 Qué significa "falsar"

Falsar significa:

encontrar evidencia incompatible con una hipótesis previamente definida.

No significa:

- criticar;
- discrepar;
- proponer alternativas.

Significa:

que la teoría ha realizado una predicción que no se cumple.

10.9 Prerregistro

Antes de analizar resultados deben congelarse:

- hipótesis;
- métricas;
- umbrales;
- baselines;
- pruebas estadísticas.

Esto evita:

p-hacking.

10.10 Qué NO puede modificarse después

Una vez iniciado el análisis:

no podrán modificarse:

Fórmulas AFT

Umbrales de asignación

Distancias principales

Definiciones de grupos

Tests primarios

10.11 Qué sí puede modificarse

Se permiten:

- análisis exploratorios;
- hipótesis secundarias;
- visualizaciones nuevas.

Siempre que se etiqueten explícitamente como exploratorios.

10.12 Tamaño del efecto

Una debilidad frecuente en IA es depender exclusivamente de p-values.

AFT debe priorizar:

tamaño del efecto.

Porque un efecto diminuto puede ser estadísticamente significativo y científicamente irrelevante.

10.13 Medidas recomendadas

Según el caso:

Cohen's d

Cliff's Delta

Hedges' g

Mutual Information

10.14 Umbral orientativo

Propuesta inicial:

Tamaño efecto	Interpretación
<0.2	Débil
0.2–0.5	Moderado
0.5–0.8	Fuerte
>0.8	Muy fuerte

Los valores definitivos deben preregistrarse.

10.15 Potencia estadística

Toda prueba debe acompañarse de:

análisis de potencia.

Objetivo:

evitar falsos negativos.

10.16 Problema de comparaciones múltiples

El proyecto genera muchas variables.

Ejemplo:

8 dimensiones

×

4 grupos

×

3 modelos

×

3 temperaturas

La cantidad de comparaciones crece rápidamente.

10.17 Corrección recomendada

Primaria:

Benjamini–Hochberg.

Alternativa conservadora:

Bonferroni.

10.18 Baseline obligatorio 1

Entropía sola.

Pregunta:

¿AFT supera a ΔE?

Si no:

gran parte del proyecto queda comprometida.

10.19 Baseline obligatorio 2

PCA.

Pregunta:

¿AFT supera una reducción genérica?

10.20 Baseline obligatorio 3

ICA.

Mismo razonamiento.

10.21 Baseline obligatorio 4

Características aleatorias.

Construcción:

generar dimensiones sintéticas con la misma dimensionalidad.

Pregunta:

¿AFT aporta más estructura que variables aleatorias?

10.22 Baseline obligatorio 5

Espacio latente reducido.

Comparar:

AFT

vs

representaciones comprimidas de hidden states.

10.23 Test de robustez 1

Cambio de modelo.

Llama

↓

Mistral

↓

Qwen

10.24 Test de robustez 2

Cambio de decoding.

Greedy

↓

Sampling

10.25 Test de robustez 3

Cambio de longitud.

Cortos

↓

Medios

↓

Largos

10.26 Test de robustez 4

Cambio de corpus.

Particularmente importante para N*.

10.27 Test de robustez 5

Cambio de normalización.

Uno de los puntos históricamente más débiles del proyecto.

10.28 Criterio Go/No-Go para AFT8

AFT8 avanza si cumple simultáneamente:

G1

Reproducibilidad.

G2

Robustez.

G3

Separación de grupos.

G4

Superioridad frente a baselines.

G5

Consistencia intermodelo.

10.29 Condición No-Go

AFT8 se detiene si:

al menos dos criterios principales fallan de forma sistemática.

10.30 Activación de AFT15

Solo ocurre si AFT8 supera Go.

Esta regla debe considerarse obligatoria.

10.31 Validación de AFT15

Cada dimensión nueva debe superar:

Test A

Información incremental.

Test B

Robustez.

Test C

Interpretabilidad.

Test D

Valor predictivo.

10.32 Condición de eliminación

Una dimensión AFT15 se elimina si:

- no aporta información nueva;
- no es reproducible;
- no mejora resultados.

10.33 Validación de regiones

Las regiones no deben evaluarse únicamente visualmente.

Deben medirse:

Estabilidad

Persistencia

Reproducibilidad

10.34 Validación de IAmotions

Las IAmotions constituyen el último nivel.

No deben analizarse hasta haber validado:

- dimensiones;
- trayectorias;
- regiones.

10.35 Criterio de supervivencia de una IAmotion

Debe demostrar:

Separación

Reproducibilidad

Estabilidad

Utilidad explicativa

10.36 Resultado favorable mínimo

No requiere:

16 IAmotions.

No requiere:

AFT15 completo.

Bastaría con demostrar:

estructura dinámica robusta.

10.37 Resultado favorable fuerte

Aparecen:

- trayectorias consistentes;
- regiones reproducibles;
- valor incremental respecto a baselines.

Este resultado justificaría investigación posterior.

10.38 Resultado desfavorable parcial

Algunas dimensiones sobreviven.

Otras no.

Este escenario es perfectamente plausible.

10.39 Resultado desfavorable total

La estructura desaparece.

Los baselines explican igual o mejor.

Las trayectorias no son robustas.

En ese caso:

AFT debería revisarse profundamente.

10.40 La asimetría científica

Una observación importante.

El fracaso de una dimensión no implica el fracaso completo del proyecto.

Pero la validación de una dimensión tampoco valida automáticamente el resto.

Cada componente debe ganarse su supervivencia.

10.41 La pregunta decisiva

Después de todo el proceso quedará una única pregunta.

> ¿AFT captura estructura dinámica real mejor de lo que cabría esperar mediante representaciones más simples?

Esa es la cuestión fundamental.

10.42 Conclusión

Este capítulo establece la arquitectura de validación y falsación del proyecto.

Su función principal es impedir que el éxito o el fracaso dependan de interpretaciones retrospectivas.

AFT8 debe demostrar:

- reproducibilidad;
- robustez;
- valor incremental.

AFT15 debe demostrar:

- utilidad adicional.

Las IAmotions deben demostrar:

- existencia empírica.

Y todo ello debe ocurrir bajo condiciones previamente definidas y congeladas.

Porque una teoría científica no se define por las historias que puede contar después de ver los datos.

Se define por los riesgos que acepta correr antes de verlos.

Capítulo 11

Arquitectura Tecnológica e Implementación Open-Weights de la Fase Empírica

11.1 Introducción

Hasta este punto hemos definido:

- el marco teórico;

- las dimensiones;

- las trayectorias;

- las IAmotions;

- el dataset;

- la estrategia de validación.

Sin embargo, todavía no hemos respondido una pregunta esencial:

> ¿Cómo se implementa realmente todo esto?

Este capítulo tiene un objetivo deliberadamente práctico.

No está dirigido a filósofos de la IA.

No está dirigido a críticos literarios.

Está dirigido a quienes deberán ejecutar la fase empírica.

Especialmente:

- alumnos de TFM;

- investigadores junior;

- equipos técnicos colaboradores.

11.2 Filosofía tecnológica

La estrategia tecnológica del proyecto se basa en un principio simple:

> Utilizar la infraestructura más sencilla posible que permita falsar las hipótesis principales.

Esto implica evitar:

- arquitecturas excesivamente complejas;

- dependencia innecesaria de modelos cerrados;

- costes difíciles de sostener.

Por esta razón el proyecto se apoya prioritariamente en:

modelos open-weight instrumentables.

11.3 Requisitos funcionales

La infraestructura debe permitir:

R1

Acceso a hidden states.

R2

Acceso a attention weights.

R3

Acceso a logits.

R4

Acceso a activaciones por capa.

R5

Repetibilidad experimental.

R6

Automatización del pipeline.

11.4 Qué NO necesitamos

Un error frecuente consiste en asumir que necesitamos el modelo más potente disponible.

No es cierto.

AFT estudia dinámica interna.

No rendimiento absoluto.

Por tanto:

GPT-8 hipotético no sería necesariamente mejor para este proyecto que un modelo open-weight correctamente instrumentado.

11.5 Criterios de selección de modelos

Los modelos candidatos deben cumplir:

Acceso completo

Estabilidad

Comunidad activa

Documentación abundante

Coste razonable

11.6 Modelos recomendados

Nivel 1 (piloto)

Llama 3.1 8B

Ventajas:

- ampliamente documentado;
- excelente ecosistema;
- coste moderado.

Qwen 2.5 7B

Ventajas:

- muy competitivo;
- buena accesibilidad.

Mistral 7B

Ventajas:

- rápido;
- eficiente.

11.7 Modelos recomendados para validación

Nivel 2

Llama 3.1 70B

Qwen 2.5 72B

Mixtral 8x22B

Objetivo:

validar robustez intermodelo.

11.8 Modelos que NO deberían utilizarse inicialmente

No recomendaría comenzar con:

- modelos propietarios;
- APIs cerradas;
- arquitecturas sin acceso interno.

Razón:

imposibilidad de instrumentación completa.

11.9 Lenguaje de programación

La recomendación es inequívoca:

Python

Razones:

- ecosistema IA;
- bibliotecas disponibles;

- reproducibilidad.

11.10 Stack software principal

PyTorch

Motor principal.

Transformers (HuggingFace)

Carga de modelos.

Accelerate

Distribución.

NumPy

Operaciones básicas.

Pandas

Datasets.

Scikit-learn

Análisis.

HDBSCAN

Detección de regiones.

UMAP

Visualización.

Plotly

Exploración interactiva.

11.11 Stack opcional

SAE Lens

Para análisis interpretativo avanzado.

TransformerLens

Inspección mecanicista.

Captum

Análisis de atribución.

Weights & Biases

Seguimiento experimental.

11.12 Arquitectura de almacenamiento

La estructura mínima recomendada es:

text AFT_Project/ data/ raw/ processed/ reference_bank/ features/ results/ models/ notebooks/ reports/ logs/

11.13 Formatos de datos

Entrada

JSON

CSV

Parquet

Features

Parquet

Resultados

Parquet + CSV

Configuración

YAML

11.14 Control de versiones

Todo el proyecto debe gestionarse mediante:

Git

Repositorios separados:

Código

Dataset

Resultados

11.15 Gestión experimental

Cada ejecución debe registrar:

- modelo;
- checkpoint;
- temperatura;
- seed;
- fecha;
- versión del pipeline.

Nada debe quedar implícito.

11.16 Infraestructura GPU

Aquí aparece la principal decisión económica.

11.17 Opción A: GPU local

Ejemplo:

RTX 4090

24 GB VRAM

Ventajas:

- control total;
- coste marginal reducido.

Inconvenientes:

- inversión inicial.

11.18 Opción B: Cloud bajo demanda

Ejemplos:

- RunPod
- Vast.ai
- Lambda Labs

Ventajas:

- flexibilidad.

Inconvenientes:

- coste recurrente.

11.19 Opción C: Infraestructura universitaria

Probablemente la mejor solución.

Ventajas:

- coste muy bajo.

Inconvenientes:

- disponibilidad limitada.

11.20 Estimación de hardware mínimo

Para piloto:

CPU

8–16 núcleos

RAM

64 GB

GPU

24 GB VRAM

Suficiente para:

Llama 8B

Mistral

Qwen 7B

11.21 Hardware recomendado

CPU

16–32 núcleos

RAM

128 GB

GPU

48–80 GB VRAM

Permite:

modelos mayores

y experimentación más cómoda.

11.22 Coste piloto estimado

Escenario cloud.

Extracción AFT8:

120 textos.

Coste aproximado:

50–200 €

Dependiendo del proveedor.

11.23 Coste fase completa AFT8

480 textos.

3 temperaturas.

3–5 seeds.

Coste estimado:

300–1.500 €

Rango razonable para un TFM.

11.24 Coste fase validación intermodelo

Tres familias:

Llama

Qwen

Mistral

Coste estimado:

1.000–5.000 €

Dependiendo de tamaño de modelos.

11.25 Coste AFT15

Las dimensiones:

- LSS;
- IM;
- PHT;

incrementan notablemente el coste.

Rango esperado:

2×–5× respecto a AFT8.

11.26 Cuello de botella principal

No será:

CPU.

No será:

almacenamiento.

Será:

extracción de señales internas.

Especialmente:

GxA

LSS

PHT

11.27 Tamaño esperado de datos

Piloto:

10–50 GB.

Fase completa:

100–500 GB.

Dependiendo de:

- número de capas;
- activaciones guardadas.

11.28 Estrategia recomendada

Guardar:

features derivadas.

No guardar siempre:

todos los hidden states completos.

Razón:

coste.

11.29 Automatización

Toda ejecución debe ser lanzable mediante:

bash python run_experiment.py

Idealmente:

sin intervención manual.

11.30 Configuración reproducible

Parámetros en:

yaml experiment.yaml

Ejemplo:

modelo

temperatura

seed

grupo

dimensiones

11.31 Registro de errores

Todos los errores deben almacenarse.

Nunca descartarse silenciosamente.

11.32 Monitorización

Registrar:

- tiempo;
- memoria;
- VRAM;
- throughput.

Esto permite:

optimización posterior.

11.33 Seguridad científica

La mayor amenaza del proyecto no es técnica.

Es metodológica.

Por ello:

- preregistro;
- congelación;
- versionado;

son tan importantes como las GPUs.

11.34 Cronograma técnico recomendado

Semana 1

Entorno.

Semana 2

Carga de modelos.

Semana 3

Extracción básica.

Semana 4

Implementación AFT8.

Semana 5

Piloto.

Semana 6

Corrección de errores.

Semana 7–10

Ejecución principal.

Semana 11–12

Análisis.

11.35 Equipo mínimo

Puede ejecutarlo:

1 investigador técnico

+

1 colaborador para dataset

No requiere un gran laboratorio.

11.36 Equipo ideal

Especialista LLM

Científico de datos

Colaborador literario

Supervisor metodológico

11.37 Riesgos tecnológicos

Dependencia excesiva de GPU

Cambios de versión

Incompatibilidades

Almacenamiento insuficiente

Todos deben gestionarse desde el inicio.

11.38 Conclusión

Desde el punto de vista tecnológico, AFT8 es perfectamente ejecutable dentro de un TFM avanzado de Ciencia de Datos o Inteligencia Artificial.

No requiere:

- supercomputadores;
- acceso industrial;
- infraestructuras multimillonarias.

Requiere algo más importante:

una arquitectura experimental disciplinada.

La fase piloto puede ejecutarse con recursos relativamente modestos.

La fase completa exige más capacidad, pero sigue siendo accesible para:

- universidades;

- grupos de investigación;

- colaboraciones académicas.

La principal dificultad del proyecto no será computacional.

Será demostrar que las estructuras observadas sobreviven cuando intentamos refutarlas.

Ese es el verdadero reto de IA2IAh-AFT.

Observación de REVISOR:

Después de los capítulos 1–11 y los anexos B–F, el siguiente documento que realmente faltaría ya no sería teórico sino operativo:

Manual de Implementación AFT8 v1.0

con:

- especificaciones de clases Python,
- estructura exacta de CSV/Parquet,
- esquema JSON de observaciones,
- pseudocódigo de cada dimensión,

- scripts de extracción,
- scripts de validación.

Ese documento permitiría que dos alumnos distintos implementaran AFT8 de forma prácticamente idéntica y sería probablemente el puente definitivo entre el marco conceptual y la ejecución empírica real.

1. Características del LLM necesario

Para la fase empírica **AFT8→AFT15**, el modelo debe ser:

Obligatorio

- **Open-weight / open-source**, no API cerrada.
- Arquitectura **Transformer decoder-only** tipo Llama, Mistral, Qwen, Gemma.
- Acceso completo a:
  - logits,
  - probabilidades / top-k logits,
  - hidden states por capa,
  - attention patterns,
  - idealmente residual stream, MLP activations y contribuciones por capa.
- Compatible con **PyTorch + HuggingFace Transformers** y, preferiblemente, **TransformerLens**.
- Capaz de ejecutarse de forma reproducible con:
  - greedy,
  - sampling T=0.7,
  - sampling T=1.0,
  - varias seeds.

Esto no es un capricho: el protocolo exige medir trayectorias internas, no solo respuestas finales. El documento empírico fija que se trabajará prioritariamente con **modelos open-weights instrumentables**, y que la fase inicial debe ser **mono-modelo**, dejando IA2IAh triádico para después.

Recomendación realista

- Modelo principal: **Llama 3.1 8B**, **Mistral 7B**, **Qwen 7B/8B** o equivalente.
- Modelo control: otro modelo de familia distinta, por ejemplo Llama vs Mistral/Qwen.
- Tamaño óptimo para TFM: **7B–8B**.
- Tamaño ambicioso: **13B–14B**.
- 70B: no recomendable para esta fase salvo que haya presupuesto serio.

El análisis técnico previo recomienda explícitamente **Llama 3.1 8B o Mistral 7B** como modelos primarios por acceso interno, documentación y comunidad de interpretabilidad.

---

2. Entorno tecnológico necesario

Entorno base

- Linux / Ubuntu.
- Python 3.10+.
- PyTorch con CUDA.
- HuggingFace Transformers.
- Accelerate.
- TransformerLens, si el modelo lo permite.
- NumPy, pandas, scipy.
- scikit-learn para PCA/ICA/FA, clustering, GMM.
- UMAP/t-SNE solo para visualización, no como prueba principal.
- Jupyter / VS Code.
- Git + DVC o similar para versionado de datasets.
- MLflow, Weights & Biases o simple logging estructurado en JSON/CSV.

Instrumentación necesaria

Por token hay que extraer:

- hidden states por capa;
- logits;
- top-k logits;
- distribuciones de probabilidad;
- attention matrices por capa/head;
- proxies de saliencia;
- metadatos de decoding, modelo y seed.

El protocolo antiguo ya fijaba explícitamente la necesidad de capturar por token hidden states, softmax/logits, attention matrices y, si existe, señales de gating/routers.

Almacenamiento

No conviene guardar todo bruto para todo el corpus. Eso explota rápido.

Recomendación:

- guardar **trayectorias AFT ya reducidas** para todo el dataset;
- guardar activaciones completas solo para subconjuntos de auditoría;
- usar Parquet / Zarr / HDF5;
- estimar entre **100 GB y 500 GB** para una fase bien hecha;
- hasta **1 TB** si se guardan muchas activaciones por capa.

RunPod indica almacenamiento estándar desde **$0.05–$0.07/GB/mes** según volumen, y high-performance storage a **$0.14/GB/mes**.

---

3. Arquitecturas recomendadas

Opción	Modelo	GPU mínima	Uso recomendado
Piloto barato	7B/8B cuantizado	24 GB VRAM	Probar pipeline
Fase AFT8 seria	7B/8B FP16/BF16	24–48 GB VRAM	Extracción estable
AFT8 + control-model	2 modelos 7B/8B	48 GB VRAM o dos tandas	Comparación entre familias
AFT15	7B/8B con más hooks	48–80 GB VRAM	SCI, IM, PHT, LSS
AFT15 + SAE	7B/8B o 13B	80 GB VRAM	Stress test serio
70B	70B	multi-GPU / 80GB+	No recomendado para TFM

Mi recomendación sin rodeos: **empezar con 7B/8B en 48 GB VRAM**. 24 GB puede servir, pero vas a ir justo cuando empieces a guardar activaciones, calcular gradientes o hacer hooks extensos. Lo barato sale caro si se convierte en una semana persiguiendo OOMs como si fueran gamusinos.

---

4. Coste estimado por opciones

Los precios cambian; estos son rangos razonables con tarifas públicas actuales. RunPod muestra, por ejemplo, RTX A5000 24GB a **$0.27/h**, RTX 3090 24GB a **$0.46/h**, RTX 4090 24GB a **$0.69/h**, RTX A6000 48GB a **$0.49/h**, L40S 48GB a **$0.86/h**, A100

80GB a **$1.39/h** y H100 PCIe 80GB a **$2.89/h**. Lambda lista A10 24GB a **$1.29/h**, A6000 48GB a **$1.09/h**, A100 40GB a **$1.99/h**, H100 PCIe 80GB a **$3.29/h** y H100 SXM a **$4.29/h**. Vast.ai funciona con precios de mercado, per-second billing, y ofrece instancias interruptibles que pueden ser más de un 50% más baratas, aunque con riesgo de interrupción.

Estimación práctica

Escenario	GPU	Horas estimadas	Coste GPU aproximado
Piloto mínimo	RTX A5000 / RTX 3090	30–60 h	$10–$30
AFT8 serio, 1 modelo	RTX 4090 / A6000 / L40S	80–150 h	$55–$130
AFT8 serio, 2 modelos	48GB GPU	150–300 h	$75–$260
AFT8 + AFT15 moderado	L40S / A100	250–500 h	$215–$700
AFT15 + SAE / stress test	A100 80GB / H100	400–900 h	$550–$2.600
En local	RTX 4090 propia	0 coste/hora	hardware: 2.000–4.000 € aprox.

A esto suma:

- almacenamiento: **$10–$70/mes**;
- posible egress / backups;
- tiempo humano, que es el coste real escondido bajo la alfombra.

---

5. Mi recomendación de arquitectura para el TFM

Versión sensata

- 1 modelo principal: **Llama 3.1 8B** o **Mistral 7B**.
- 1 modelo control: familia distinta.
- GPU: **48 GB VRAM**.
- Proveedor: RunPod / Vast.ai / Lambda, según disponibilidad.
- Presupuesto razonable: **300–800 €** para toda la fase técnica si se controla bien.
- Dataset:

    - Fase 1: 360 textos base + 720 variantes.
    - Fase 2: 300 textos si AFT8 sobrevive.

La presentación del TFM ya plantea esa escala: **360 textos base F1**, **720 variantes F1** y **300 textos F2**.

Versión austera

- 1 modelo 7B/8B.
- GPU 24 GB.
- Sin SAE pesado.
- Sin AFT15 completo.
- Coste: **100–300 €**.
- Sirve para piloto o TFM limitado.

Versión fuerte

- 2 modelos 7B/8B.
- GPU 48–80 GB.
- AFT8 completo + AFT15 parcial.
- Tests de decoding, proxies, PCA/ICA y baselines negativos.
- Coste: **800–2.000 €**.

---

6. Decisión crítica

No empezaría con AFT15 completo.
La propia fase empírica dice que la Etapa 2 solo debe abrirse si AFT8 supera el umbral mínimo, porque ahí ya no se pregunta si existe estructura básica, sino si la expansión añade poder explicativo real.

La secuencia correcta es:

1. **AFT8 con 1 modelo.**
2. **AFT8 con modelo control.**
3. **Baselines negativos.**
4. **Solo entonces AFT15 parcial.**
5. **SAE/stress test si queda tiempo y presupuesto.**

Veredicto: para un TFM serio, el punto óptimo es **modelo 7B/8B + GPU 48GB + presupuesto técnico de 500–1.000 €**. Más barato es posible; más caro solo tiene sentido si ya hay resultados preliminares.