ntic master
revolucionamos la comunicación

UNIVERSIDAD COMPLUTENSE DE MADRID



Visualización avanzada

Pedro Concejero

1 Por qué es tan importante la visualización en ciencia de datos

1.1 La potencia de la visión humana
1.2 Historia de la visualización como tecnología
1.3 La importancia de visualización en el mundo actual
1.4 Materiales de referencia

La potencia de la visión humana

¿Puedes
reconocer
algo en esta imagen?



R. C. James (fotógrafo).
En Lindsay, PH, Norman, DA(1983):
Introducción a la Psicología Cognitiva. 2ª ed.
Tecnos

La potencia de la visión humana

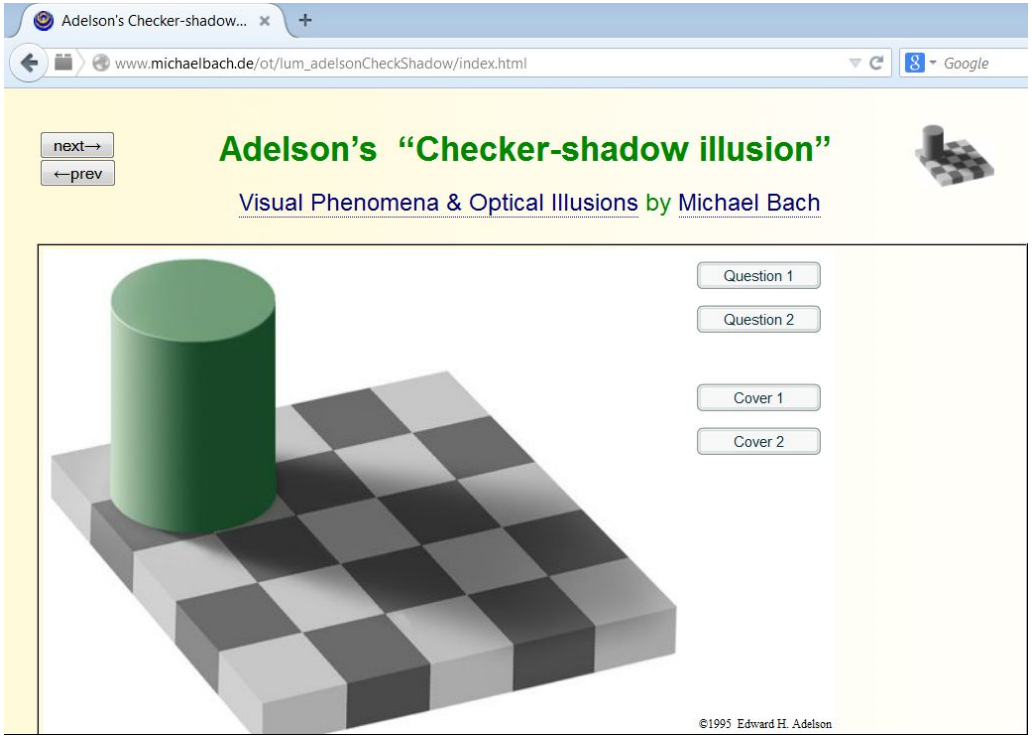
Los humanos tenemos un sistema visual potentísimo, pero su papel en nuestra vida no es (solo) por la capacidad de percibir objetos o formas, sino la capacidad de *dotarlos de significado*

Sobre este tema en concreto, hay un conocimiento extenso de los componentes de *bajo nivel* (parte esencial de nuestro sistema visual, que es un sistema cognitivo, no una simple “máquina de fotos”):



La visión es siempre creación, no una simple captura de imágenes

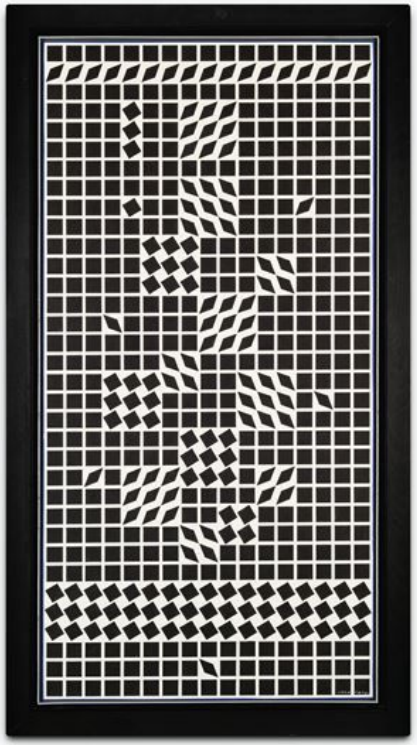
https://michaelbach.de/ot/
https://michaelbach.de/ot/lum-adelsonCheckShadow/index.html



La escuela de la Gestalt: definió principios básicos

https://es.wikipedia.org/wiki/Psicolog%C3%ADa_de_la_Gestalt

conocimiento que aprovecharon muchos artistas, entre ellos Vasarely (a la izquierda, Tlinko II, 1956-59 https://www.mutualart.com/Artwork/Tlinko-II/41EE740C30850257)
… y Dalí

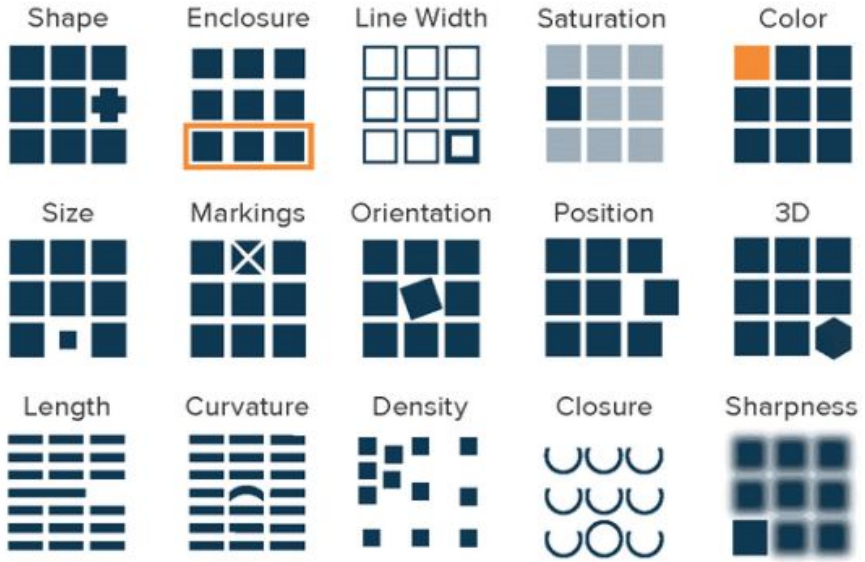


¿Debemos conocer todos estos componentes básicos?

https://policyviz.com/2018/08/07/dataviz-cheatsheet/

Preattentive Processing

Effective data visualization taps into the brain's **preattentive visual processing.** Because our eyes detect a limited set of visual characteristics (such as shape and contrast), we combine various characteristics of an object and unconsciously perceive them as comprising an image. Preattentive processing refers to the cognitive operations that can be performed prior to focusing attention on any particular region of an image. In other words, it's the stuff you notice right away.



¿Debemos conocer todos estos componentes básicos?

https://clauswilke.com/dataviz/aesthetic-mapping.html

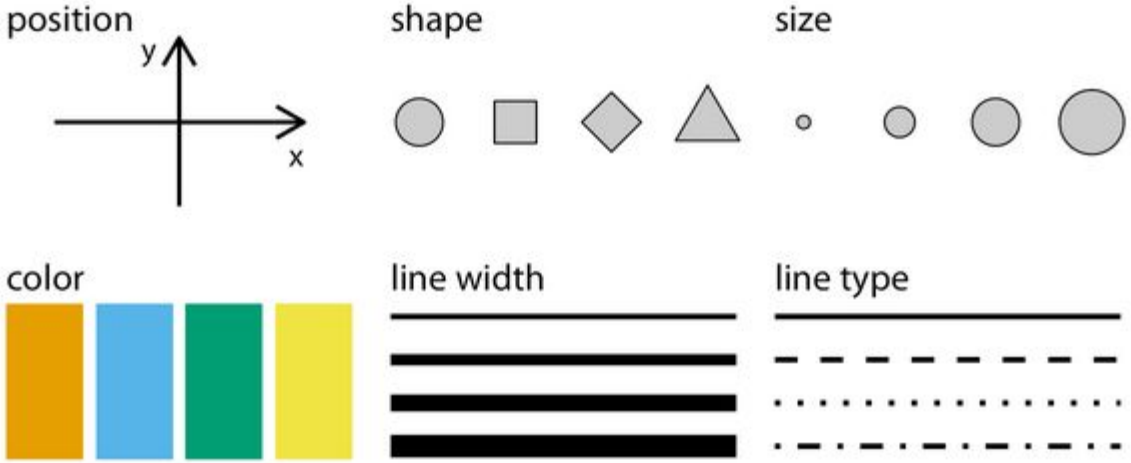


Figure 2.1: Commonly used aesthetics in data visualization: position, shape, size, color, line width, line type. Some of these aesthetics can represent both continuous and discrete data (position, size, line width, color) while others can usually only represent discrete data (shape, line type).

¿Debemos conocer todos estos componentes básicos?

https://github.com/pedroconcejero/ucm_master_24_25/blob/main/03_seaborn_ejemplo_COVID.ipynb

[11]:

grupo_edad	0-9	10-19	20-29	30-39	40-49	50-59	60-69	70-79	80+	NC
provincia_iso										
A	280	240	531	992	1788	2752	3617	3934	4782	1
AB	78	62	148	254	426	741	921	1008	1565	0
AL	109	63	281	492	706	906	1055	964	980	0
AV	15	20	37	75	135	261	345	417	849	0
B	220	254	1079	2354	4644	6795	8365	9600	13366	0
BA	54	37	106	215	388	635	827	1054	1749	9
BI	74	65	317	770	1600	2478	2692	2642	4008	0
BU	27	38	151	272	477	775	981	1011	2009	0
C	78	105	298	517	903	1212	1727	2076	2735	0
CA	75	93	230	446	715	1107	1507	1619	1798	2
CC	28	16	40	94	201	410	557	612	1469	0
CE	4	19	33	50	60	93	135	92	76	0
CO	108	95	246	425	609	1083	1249	1252	1861	0
CR	127	79	176	347	535	1014	1377	1607	2610	0
CS	82	82	163	365	611	876	1068	1099	1490	0
CU	38	30	111	227	296	576	668	691	1410	0
GC	69	41	178	349	533	766	1011	933	997	0
GI	21	30	60	138	203	391	531	604	773	0
GR	132	112	398	713	1157	1759	2094	2072	2527	0

¿Debemos conocer todos estos componentes básicos?

https://chatgpt.com/share/67ccc0f7-9f10-8000-a8ad-353ef5565b52

Razones por las que la vista es clave:

Aproximadamente el 80% de la información que procesamos proviene de la visión.

(más concretamente El 90% de la información que procesa el cerebro es visual. De ahí que seamos capaces de recordar el 80% de las imágenes, y únicamente el 20% del texto, o el 10% del sonido -nota mía a partir de artículo siguiente)

Nos permite reconocer caras, leer, movernos con precisión y reaccionar rápidamente a peligros.

El cerebro dedica casi la mitad de su capacidad a procesar información visual.

El cerebro humano procesa imágenes a una velocidad sorprendentemente rápida. Algunos estudios han demostrado que el cerebro puede identificar imágenes en tan solo **13 milisegundos**.

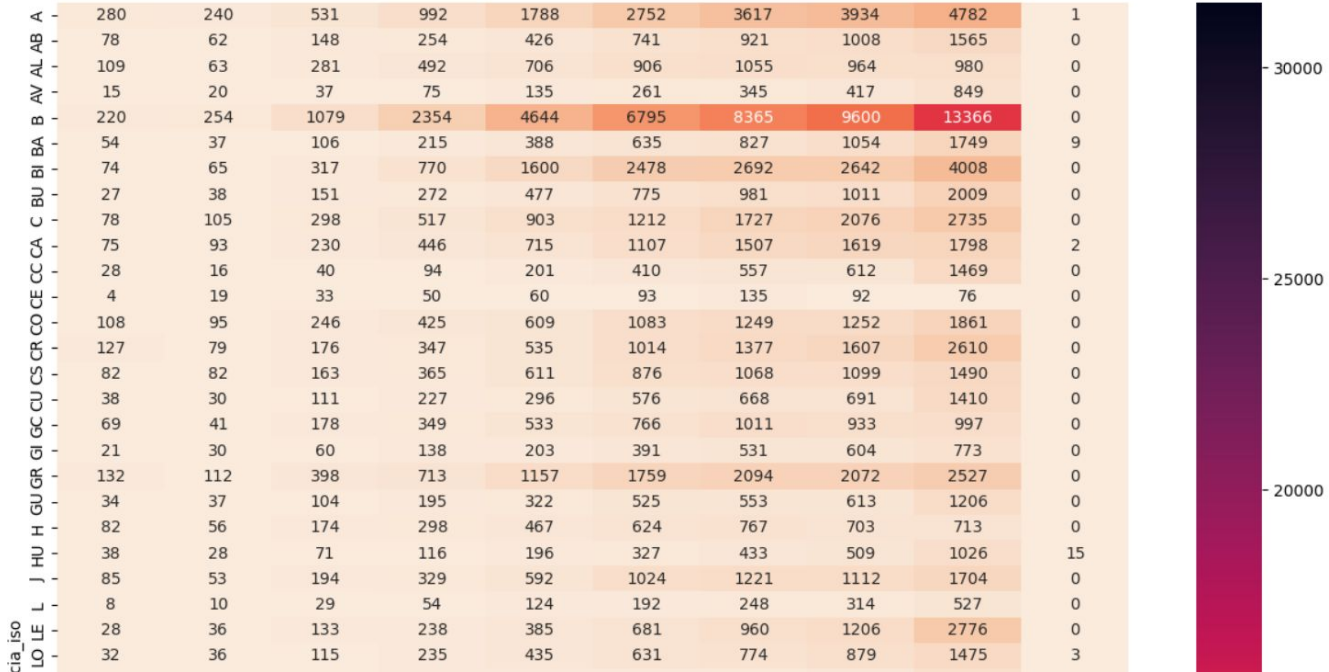
Sin embargo, el procesamiento visual completo involucra múltiples etapas:

1. **Percepción inicial**: Entre **13 y 100 ms**. Se detectan formas, colores y patrones básicos.
2. **Reconocimiento**: Entre **100 y 300 ms**. El cerebro compara la imagen con recuerdos almacenados para darle significado.
3. **Toma de decisiones**: Más de **300 ms**, dependiendo de la complejidad de la imagen y la acción requerida.

¿Debemos conocer todos estos componentes básicos?

Nuestro cerebro procesa la imagen 60.000 veces más rápido que el texto.

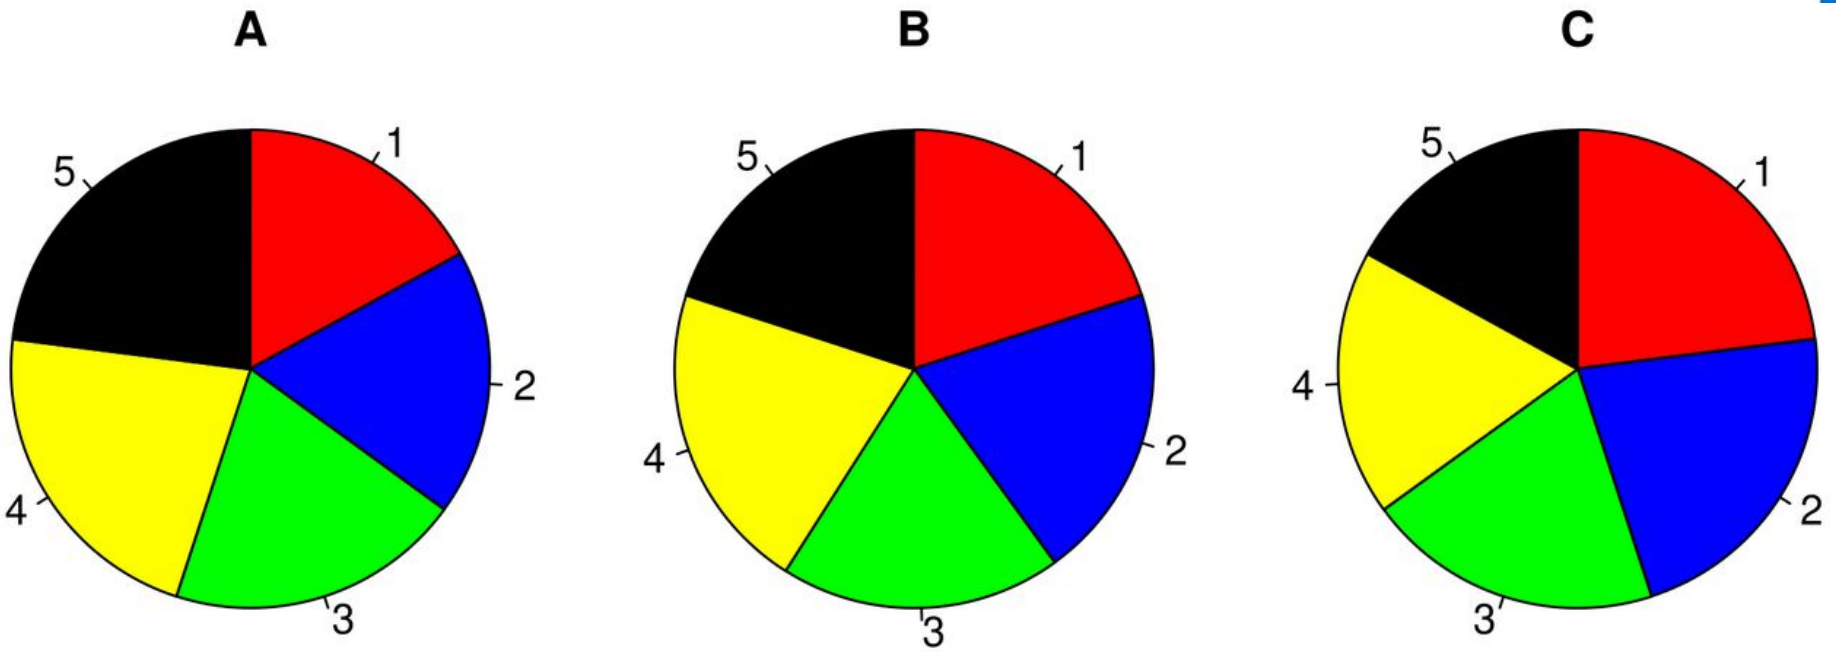
Potter, M.C., Wyble, B., Hagmann, C.E., & McCourt, E.S. (2014). Detecting meaning in RSVP at 13 ms per picture. Attention, Perception, and Psychophysics



cia_iso										
A	280	240	531	992	1788	2752	3617	3934	4782	1
AB	78	62	148	254	426	741	921	1008	1565	0
AL	109	63	281	492	706	906	1055	964	980	0
AV	15	20	37	75	135	261	345	417	849	0
B	220	254	1079	2354	4644	6795	8365	9600	13366	0
BA	54	37	106	215	388	635	827	1054	1749	9
BI	74	65	317	770	1600	2478	2692	2642	4008	0
BU	27	38	151	272	477	775	981	1011	2009	0
C	78	105	298	517	903	1212	1727	2076	2735	0
CA	75	93	230	446	715	1107	1507	1619	1798	2
CC	28	16	40	94	201	410	557	612	1469	0
CE	4	19	33	50	60	93	135	92	76	0
CO	108	95	246	425	609	1083	1249	1252	1861	0
CR	127	79	176	347	535	1014	1377	1607	2610	0
CS	82	82	163	365	611	876	1068	1099	1490	0
CU	38	30	111	227	296	576	668	691	1410	0
GC	69	41	178	349	533	766	1011	933	997	0
GI	21	30	60	138	203	391	531	604	773	0
GR	132	112	398	713	1157	1759	2094	2072	2527	0
GU	34	37	104	195	322	525	553	613	1206	0
H	82	56	174	298	467	624	767	703	713	0
HU	38	28	71	116	196	327	433	509	1026	15
J	85	53	194	329	592	1024	1221	1112	1704	0
L	8	10	29	54	124	192	248	314	527	0
LE	28	36	133	238	385	681	960	1206	2776	0
LO	32	36	115	235	435	631	774	879	1475	3

Pero no tenemos misma capacidad para todo

https://upload.wikimedia.org/wikipedia/commons/thumb/b/b4/Piecharts.svg/2000px-Piecharts.svg.png



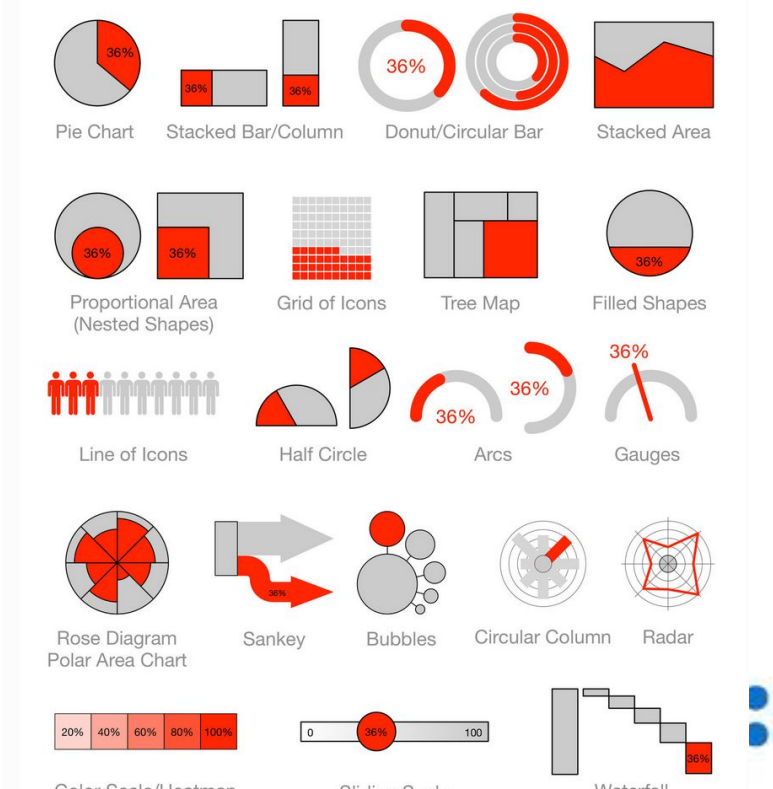
Hay *infinidad* de alternativas a los “pie charts”

https://infonewt.com/percentages/

Veremos en particular los Tree Map:

https://datavizproject.com/data-type/treemap/

Y los “heatmap”:
https://datavizproject.com/data-type/heat-map/



El color

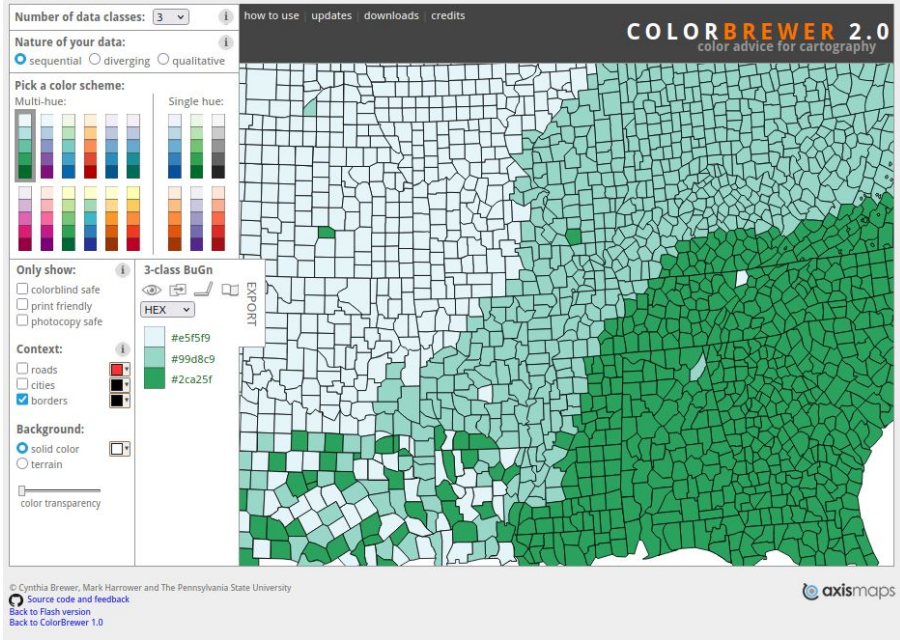
Algunas recomendaciones importantes:

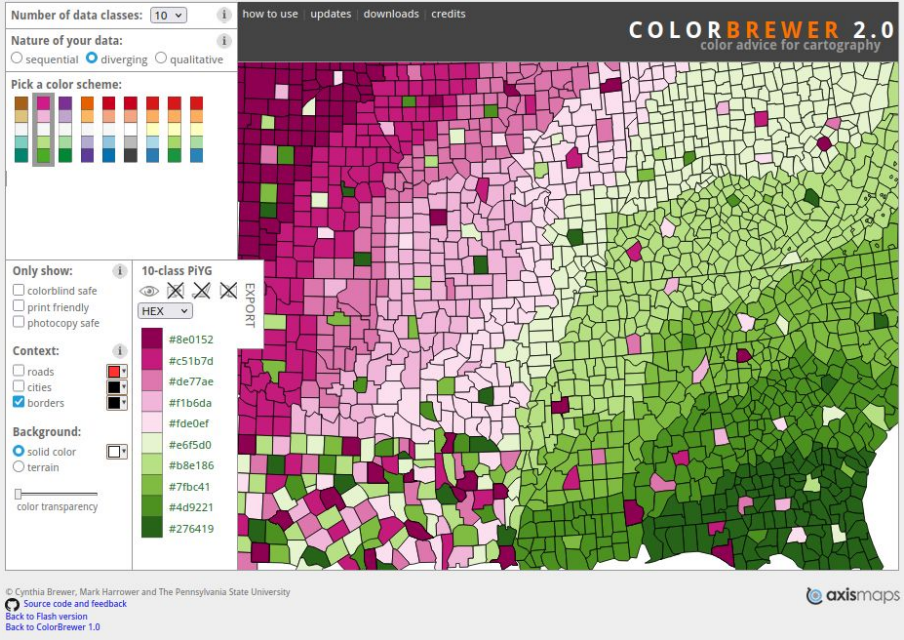
- El color en visualización de datos **no es una propiedad estética**, debe tener una función
- Sólo tenemos memoria para asociar 5 (máx. 7) colores diferentes arbitrarios a objetos o tipos -> será necesario poner una leyenda
- El color es una propiedad que requiere un cuidado extraordinario del medio con el que se presenta (ya sea impreso o proyectado)
- Usar las escalas de color testadas y propuestas por librerías:
  - https://matplotlib.org/stable/tutorials/colors/colormaps.html
  - https://seaborn.pydata.org/tutorial/color_palettes.html

El color

Una herramienta extraordinaria:

https://colorbrewer2.org/#type=sequential&scheme=BuGn&n=3





El color

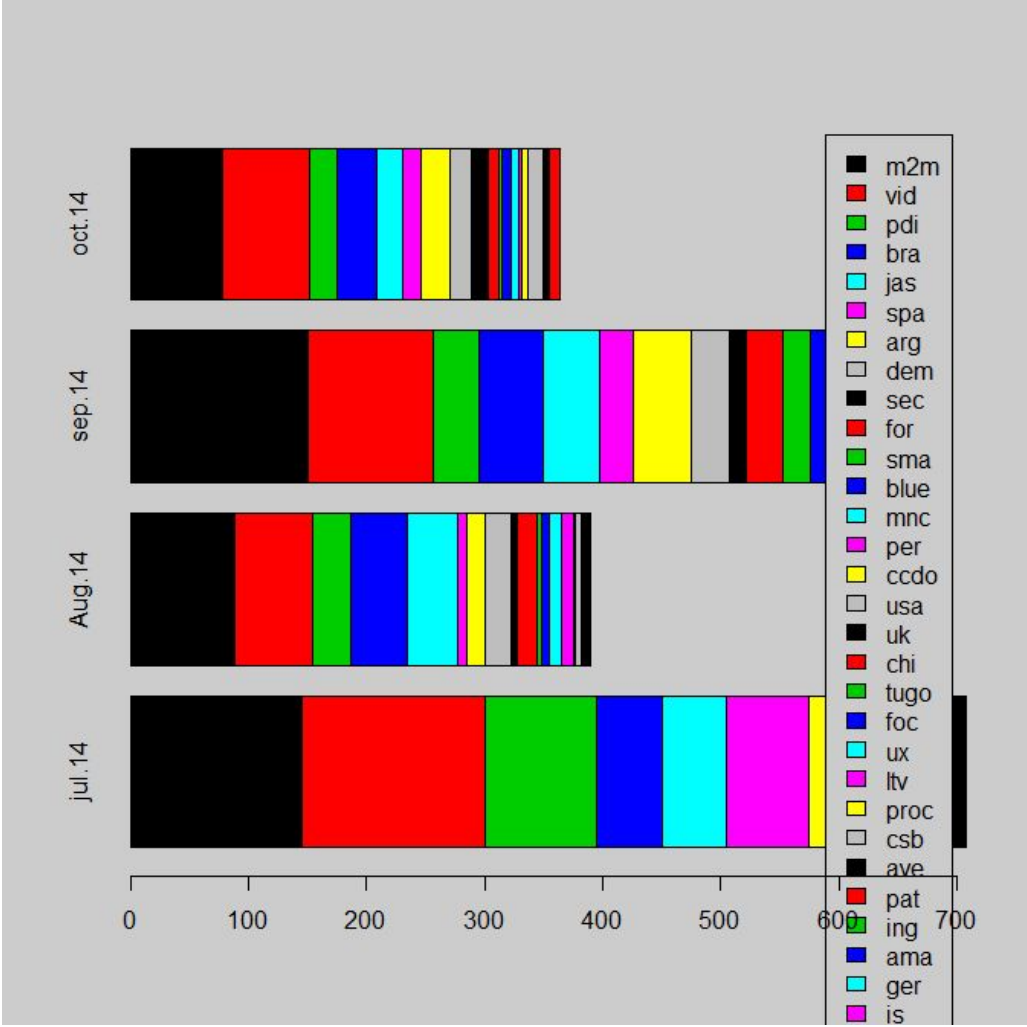
Tutorial completo sobre el color (en entornos R, pero aplicable a cualquier entorno de visualización):

https://github.com/pedroconcejero/taller-color

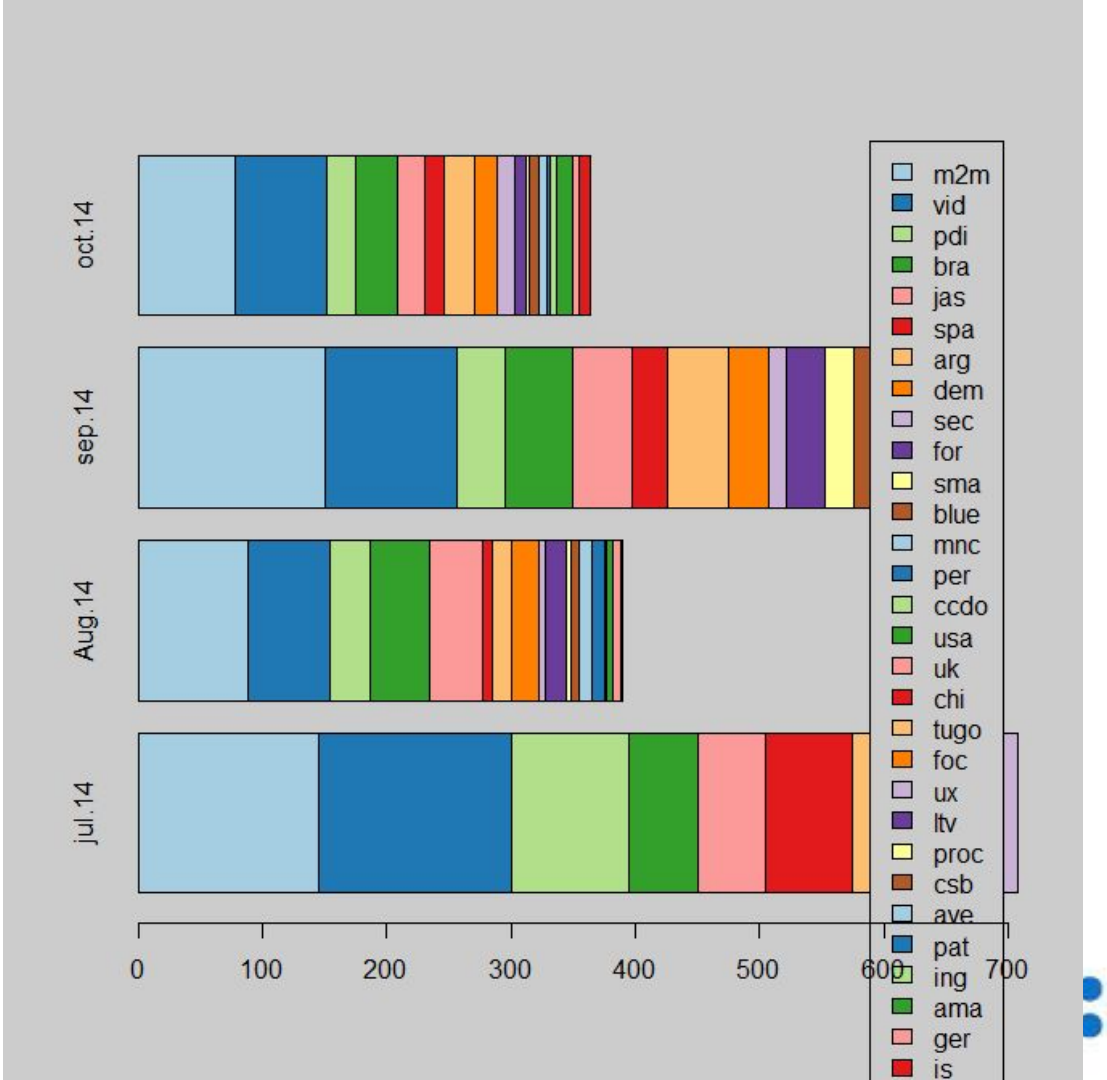
https://github.com/pedroconcejero/taller-color/blob/master/taller_color_def_grupo_madrid.docx

http://madrid.r-es.org/61-jueves-13-de-junio-2019/

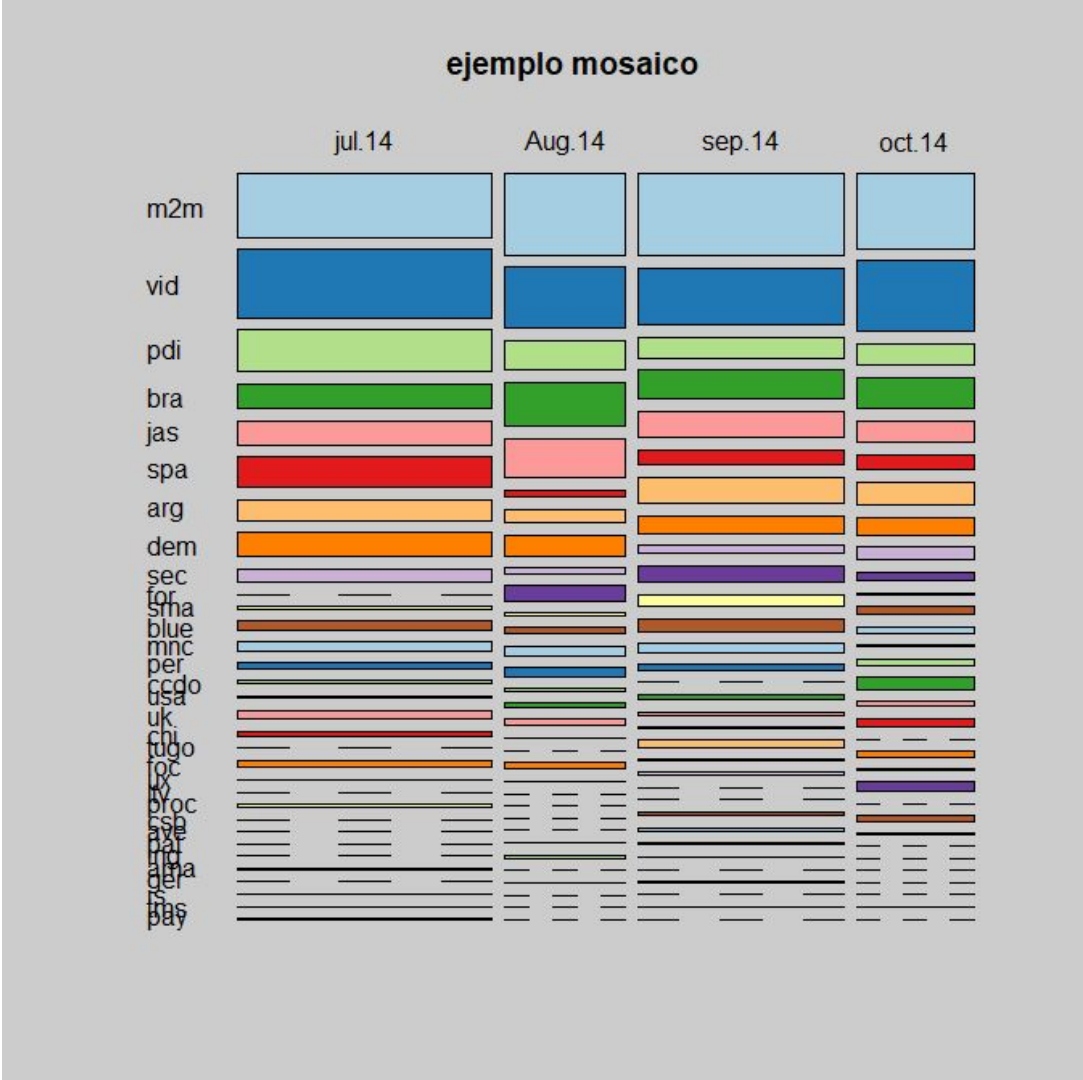
Aplicación de estos principios (ejemplo)



Aplicación de estos principios (ejemplo)



Aplicación de estos principios (ejemplo)



Historia de la visualización como tecnología

Pero además de características comunes a tod@s, hay también algunas diferentes: la experiencia, la costumbre, las convenciones… Para esto resulta interesante conocer la historia de la visualización (en general) como tecnología.

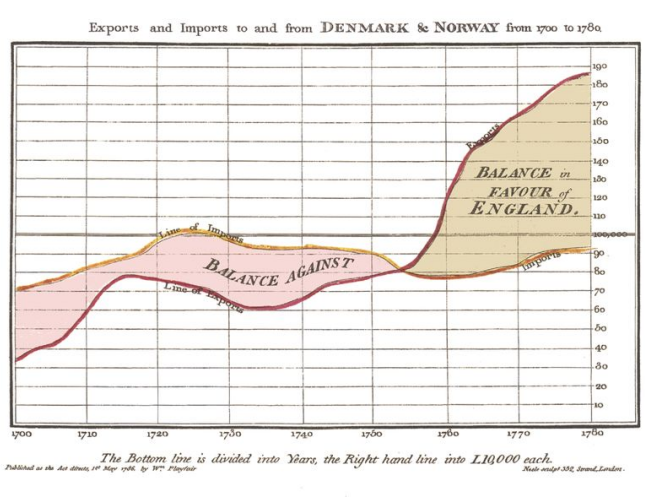
Excelentes artículos en esta búsqueda:

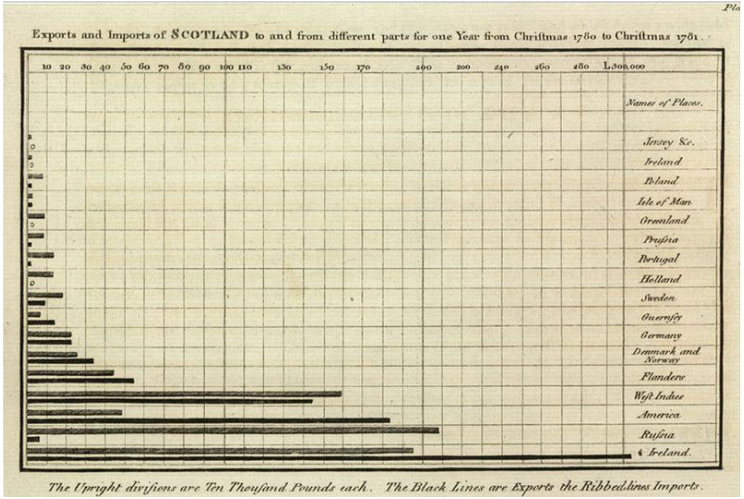
https://www.google.es/search?q=pdf+history+visualization

Especialmente:
http://euclid.psych.yorku.ca/SCS/Gallery/milestone/Visualization_Milestones.pdf

Historia de la visualización como tecnología

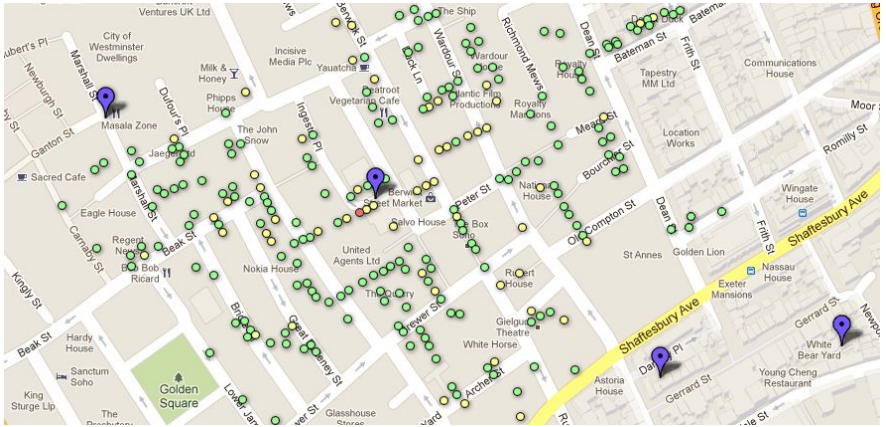
1786 Gráficos de W. Playfair
https://en.wikipedia.org/wiki/William_Playfair





Historia de la visualización como tecnología

1855: mapa de casos de cólera en Londres de John Snow: http://blog.rtwilson.com/john-snows-famous-cholera-analysis-data-in-modern-gis-formats/



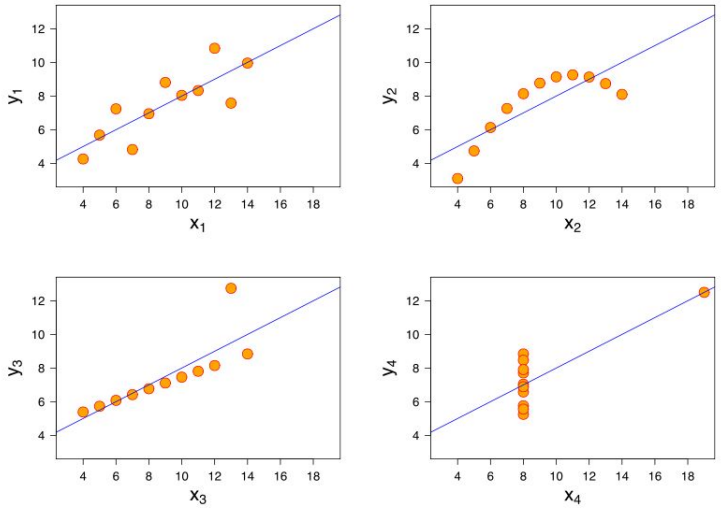
Reproducible en R: https://rpubs.com/kanch/263664

Historia de la visualización como tecnología

Primera mitad de s. XX: foco en los modelos estadísticos formales y menos en la visualización

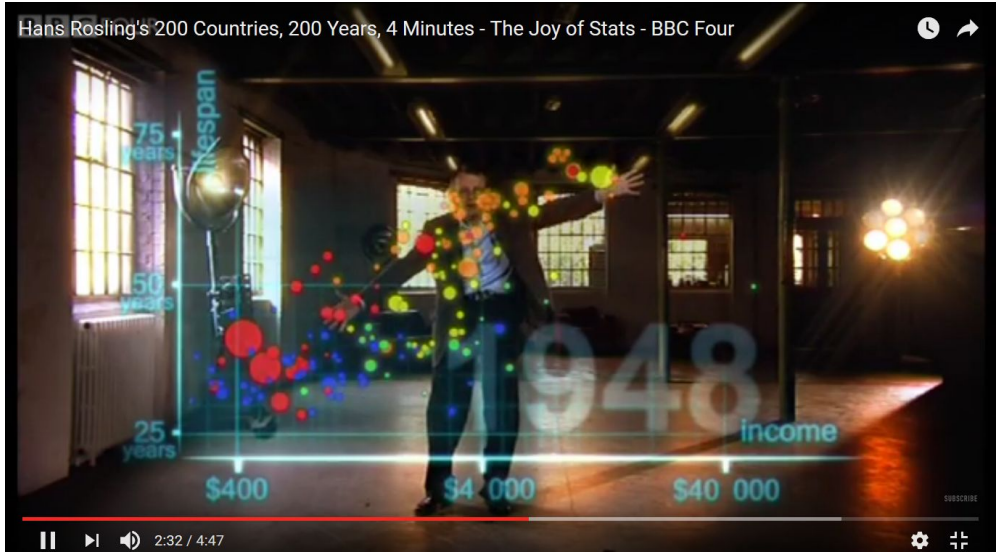
Renovación a partir de década 1960, algunos nombres:

- Tukey – Análisis exploratorio de datos (EDA) https://en.wikipedia.org/wiki/Exploratory_data_analysis#Techniques
- El “cuarteto de Anscombe” https://en.wikipedia.org/wiki/Anscombe%27s_quartet



Hitos recientes de visualización (1960-ahora)

Necesario mencionar a Hans Rosling:
Hans Rosling's 200 Countries, 200 Years, 4 Minutes - The Joy of Stats - BBC Four
https://www.youtube.com/watch?v=jbkSRLYSojo

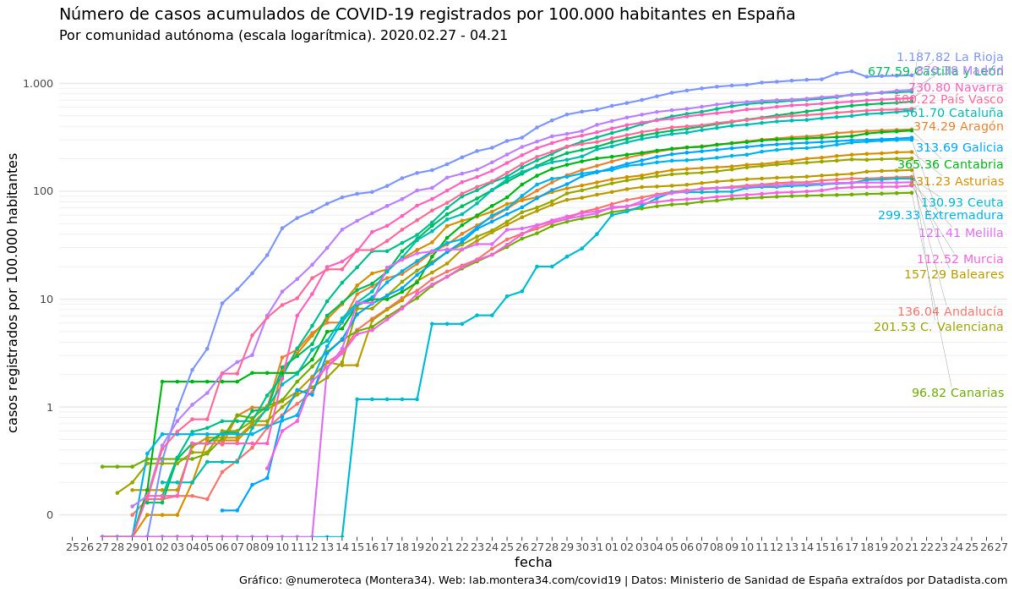


El papel clave de la comunicación en el complejo (y convulso) mundo actual

Y la visualización de datos es un componente esencial

Hay que explicar fenómenos muy complejos que requieren decisiones y acción por parte de tod@s

https://lab.montera34.com/covid19/
https://code.montera34.com/numeroteca/covid19/



Pendientes del dato… o mejor …
de la infinidad de datos!

https://www.datadista.com/coronavirus/datos-evolucion-diaria-pandemia-covid19-en-espana/

ccaa	<11 años	12-19 años	20-29 años	30-39 años	40-49 años	50-59 años	60-69 años	70-79 años	>80 años
España	**349**	**718**	**570**	**483**	**452**	**360**	**298**	**327**	**427**
Andalucía	156	280	313	346	327	215	168	200	297
Aragón	362	687	612	482	433	374	371	384	557
Asturias	372	776	447	463	423	381	365	402	651
Baleares	313	512	376	435	424	356	316	362	480
C Valenciana	360	605	437	391	369	277	251	293	364
Canarias	986	1.402	1.341	1.077	832	625	493	530	590
Cantabria	482	905	498	419	487	313	293	345	373
Castilla La Mancha	243	317	241	254	228	151	175	216	295
Castilla y León	457	969	543	440	420	357	330	324	498
Cataluña	397	1.148	962	606	588	524	411	416	503
Ceuta	176	473	367	312	358	278	231	186	341
Extremadura	595	1.696	691	630	640	483	390	470	585
Galicia	867	1.946	783	756	761	582	499	527	636
La Rioja	545	975	659	544	524	367	338	390	697
Madrid	166	242	319	306	264	224	160	160	261
Melilla	155	145	259	282	241	161	208	454	256
Murcia	509	1.033	719	658	617	488	403	388	346
Navarra	343	731	544	491	493	395	410	458	400
País Vasco	190	311	570	543	508	444	272	375	387

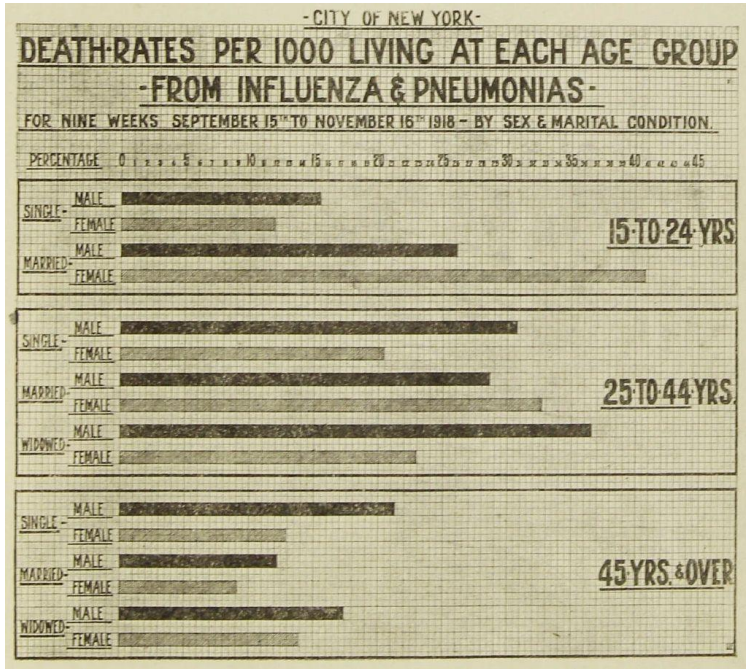
Datos actualizados el 08/03/2022. Estimado según la población en 2020

Fuente: Ministerio de Sanidad • Creado con Datawrapper

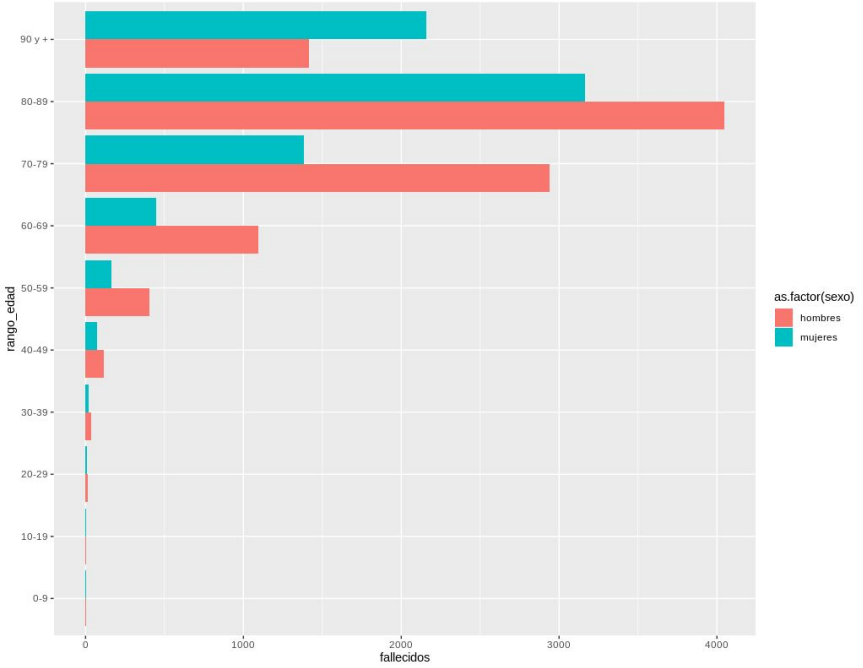
Evolución de la incidencia por grupo de edad desde la quinta ola

Gran parte de la metodología tiene una larga historia

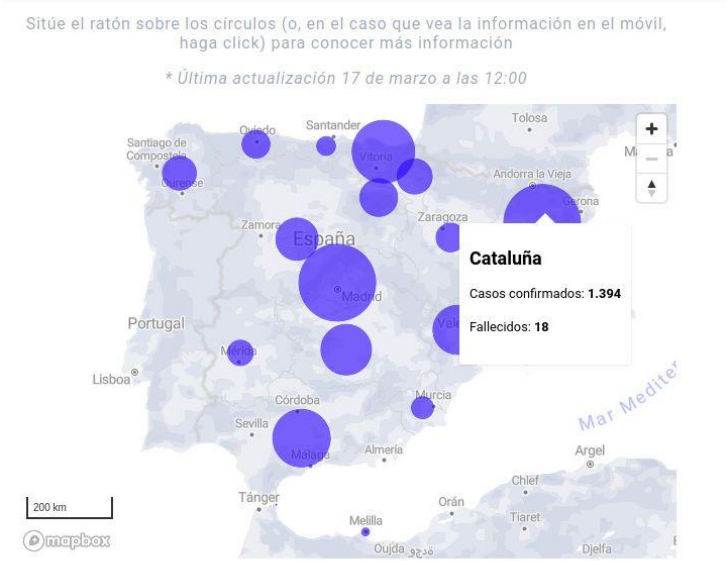
1918

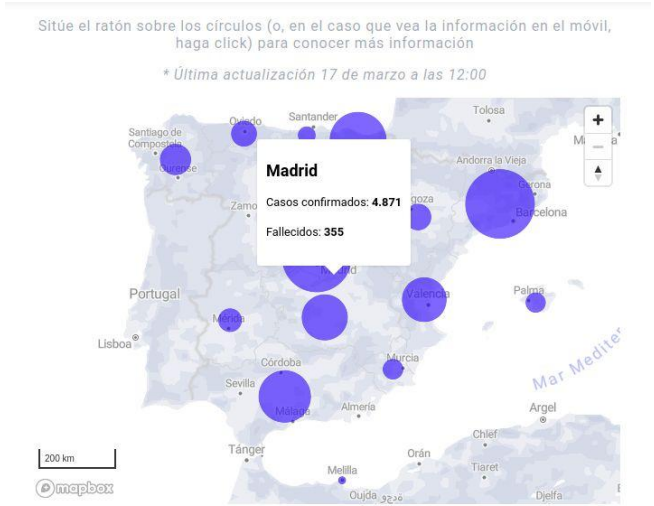


2022



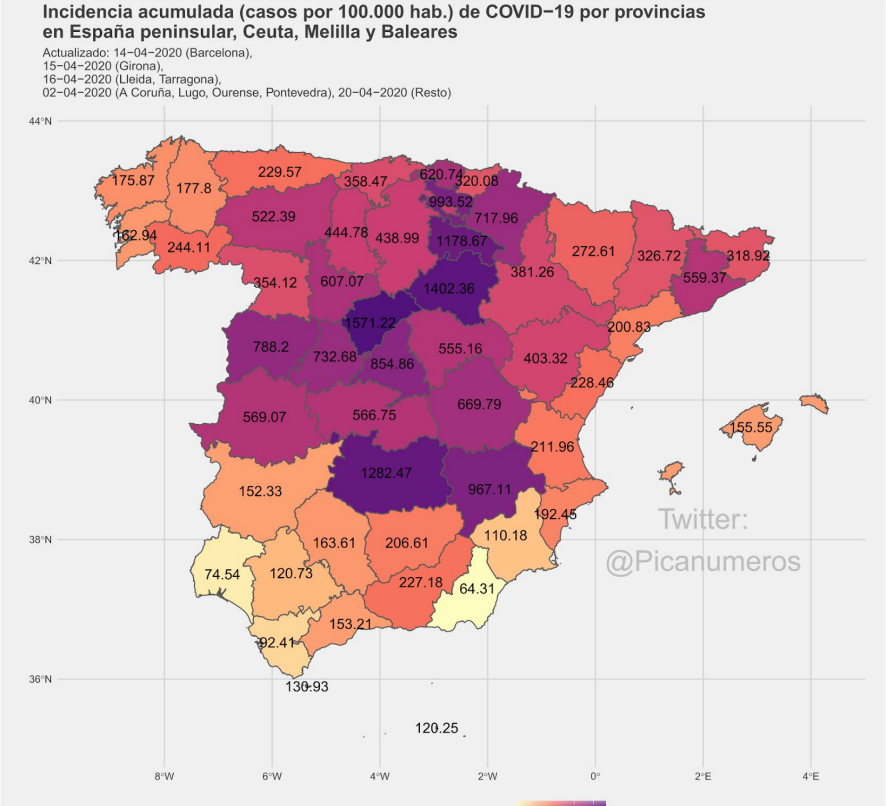
2 El hecho de disponer de herramientas sofisticadas no quiere decir que estemos comunicando bien





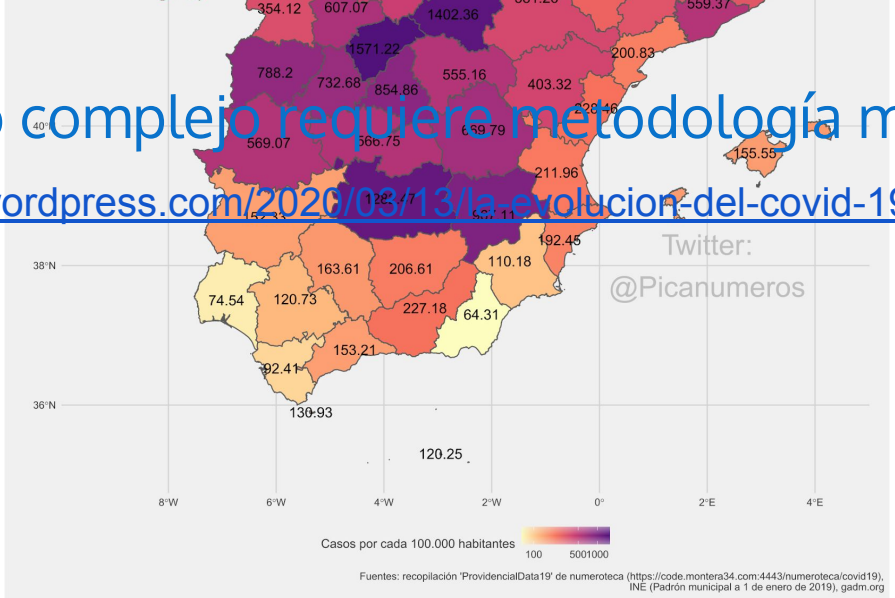
Un fenómeno complejo requiere metodología muy elaborada

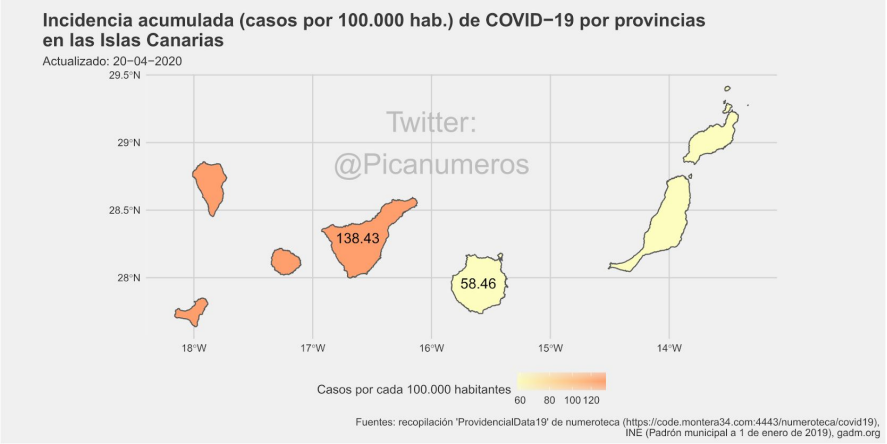
https://picanumeros.wordpress.com/2020/03/13/la-evolucion-del-covid-19-en-espana-en-graficos/



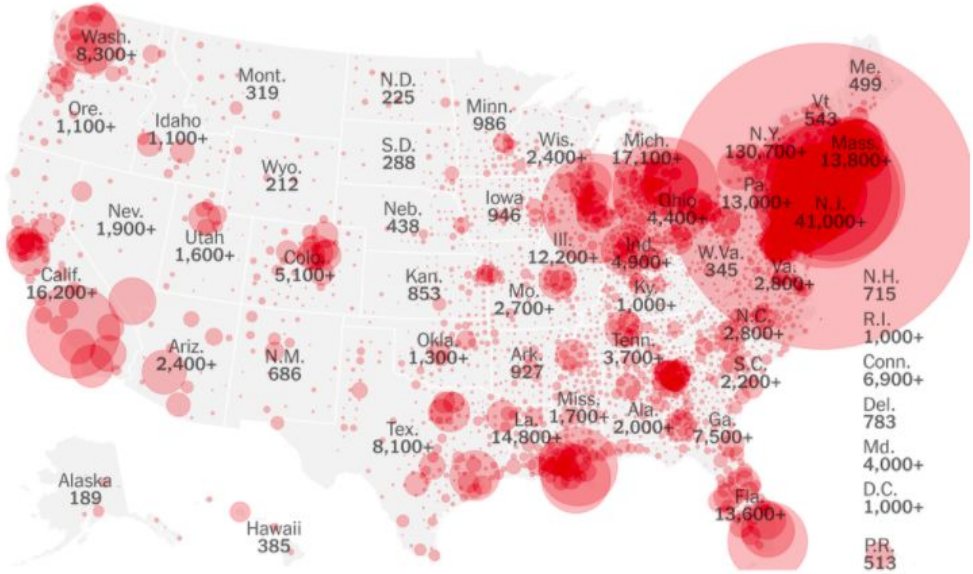
Un fenómeno complejo requiere metodología muy elaborada

https://picanumeros.wordpress.com/2020/03/13/la-evolucion-del-covid-19-en-espana-en-graficos/





Hay cosas que es obvio que no funcionan

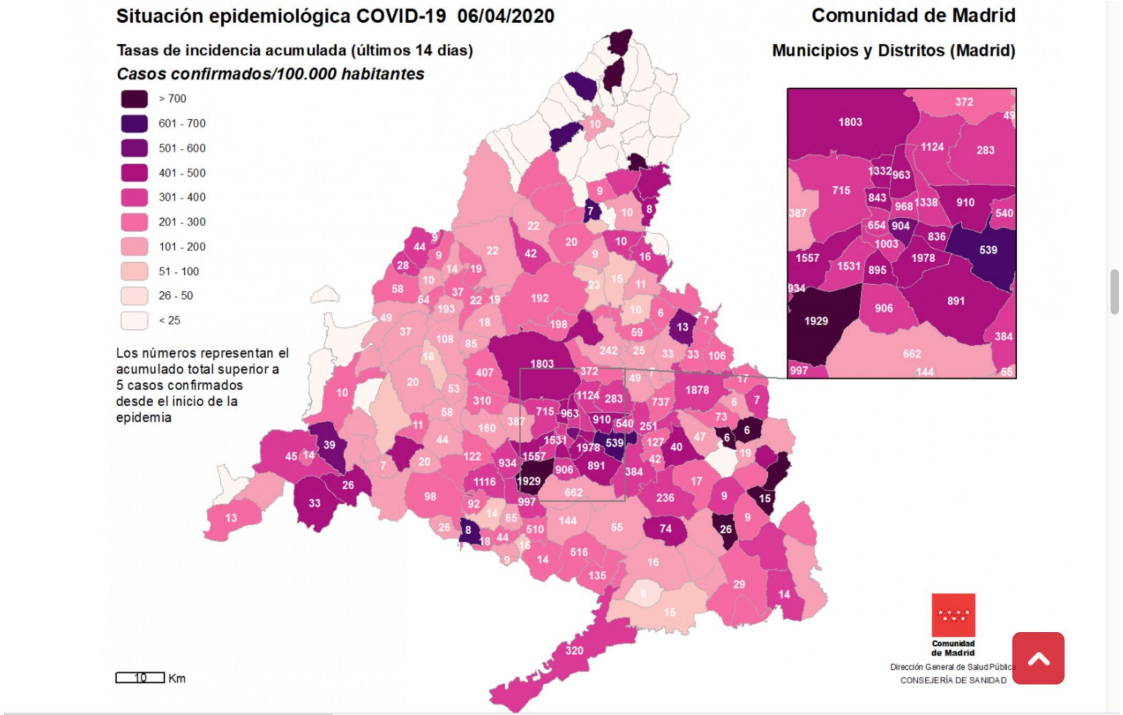


The locations of people who have tested positive in the U.S.

Pensemos: ¿estamos de verdad usando visualización para hacer comprender un problema? ¿O es simplemente un alarde técnico?



Qué duda cabe: tenemos unas herramientas como nunca en la historia para la visualización de datos. La importancia de los mapas

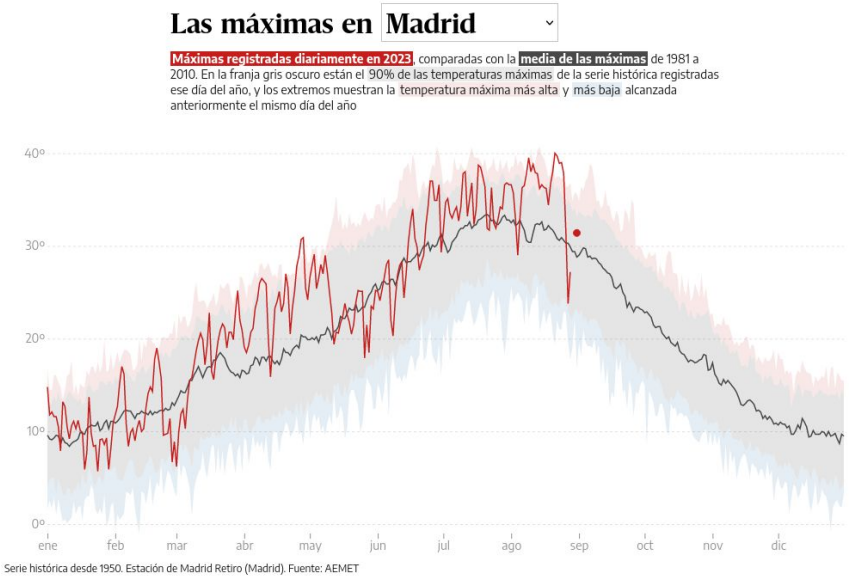


Conclusión: la importancia de la visualización en la ciencia de datos

Ya hemos visto la importancia para la comunicación de algo tan complejo como son predicciones, agregados estadísticos, … Pensemos, ¿de verdad estamos recibiendo adecuadamente la información sobre este mundo tan complejo?

El caso del cambio climático: https://www.eldiario.es/sociedad/mapa-verano-calor-record-espana-compara-temperatura-dia-media-historica-provincia-crisis-climatica_1_10153937.html

Y no solo en la comunicación: la visualización es esencial en todas las fases de un proyecto de ciencia de datos. Veremos con ejemplos razonablemente sencillos su importancia para manejo de datos previa a modelización o análisis.



Adecuación de gráfico a lo que se quiere transmitir

https://elpais.com/espana/2024-08-24/mas-del-60-de-las-multas-de-la-ley-mordaza-estan-vinculadas-al-consumo-o-la-posesion-de-drogas.html

- Tipo de gráfico, ¿es adecuado?
- Colores, ¿contribuyen a diferenciar los fenómenos?

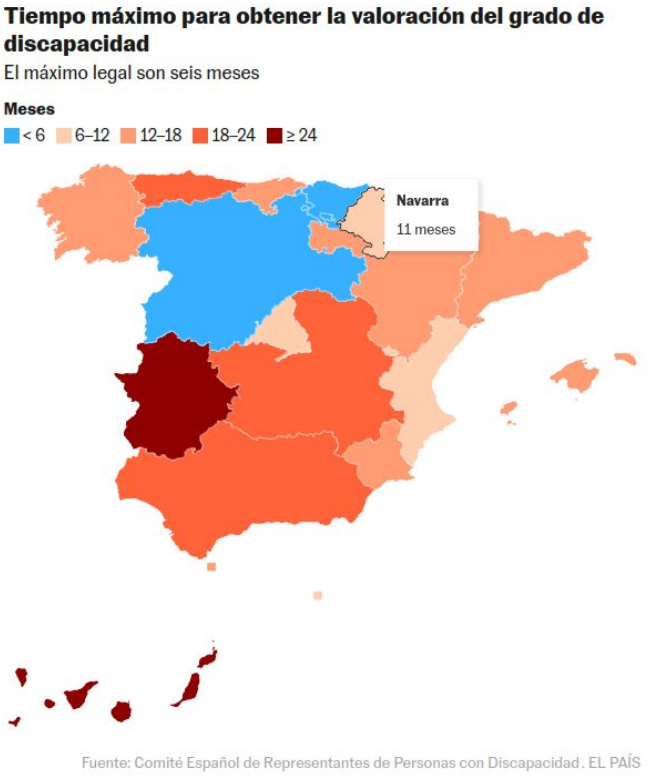
Datos:
https://estadisticasdecriminalidad.ses.mir.es/publico/portalestadistico/datos.html?type=pcaxis&path=/Datos10/&file=pcaxis

“Desde la entrada en vigor de la ley en 2015 y hasta finales de 2023, el total recaudado en Andalucía (318 millones de euros), es casi cinco veces mayor a la segunda comunidad autónoma en la lista, Comunidad Valenciana, donde se recaudaron 85 millones.”



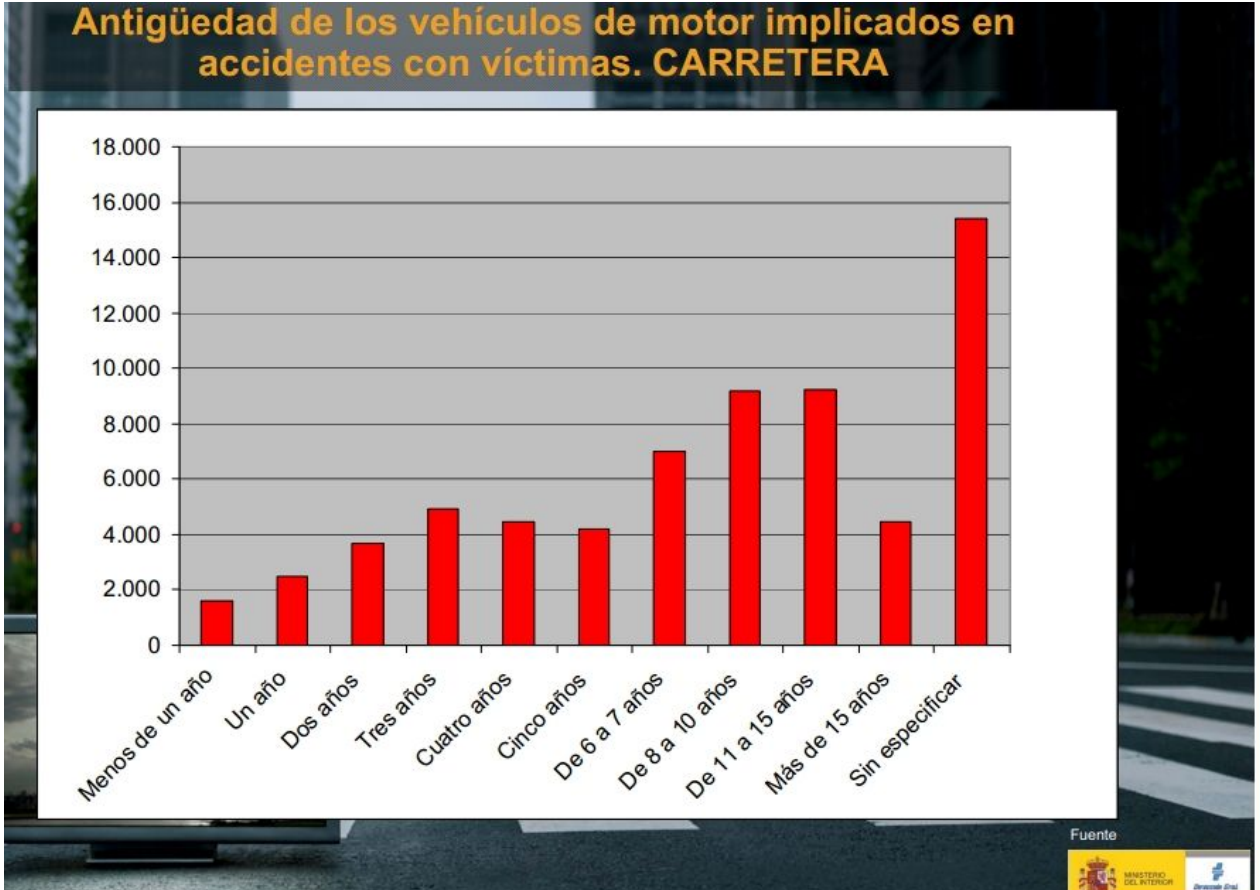
Adecuación de gráfico a lo que se quiere transmitir

- ¿Es adecuada esa escala de color?

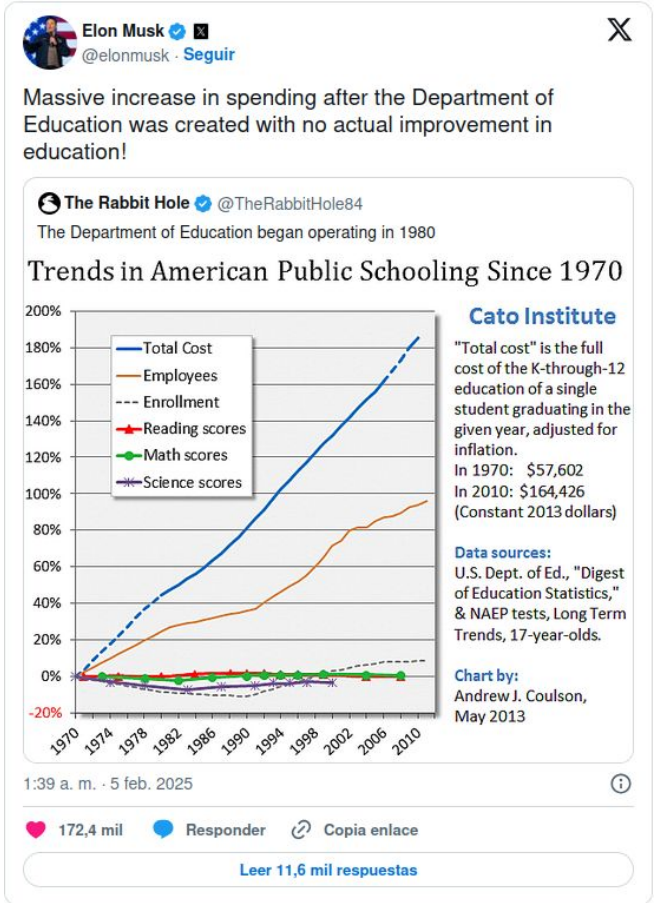


Visualización para bien … y para mal

Datos y material aquí: https://github.com/pedroconcejero/dgt_accidentes_for_RmadRid



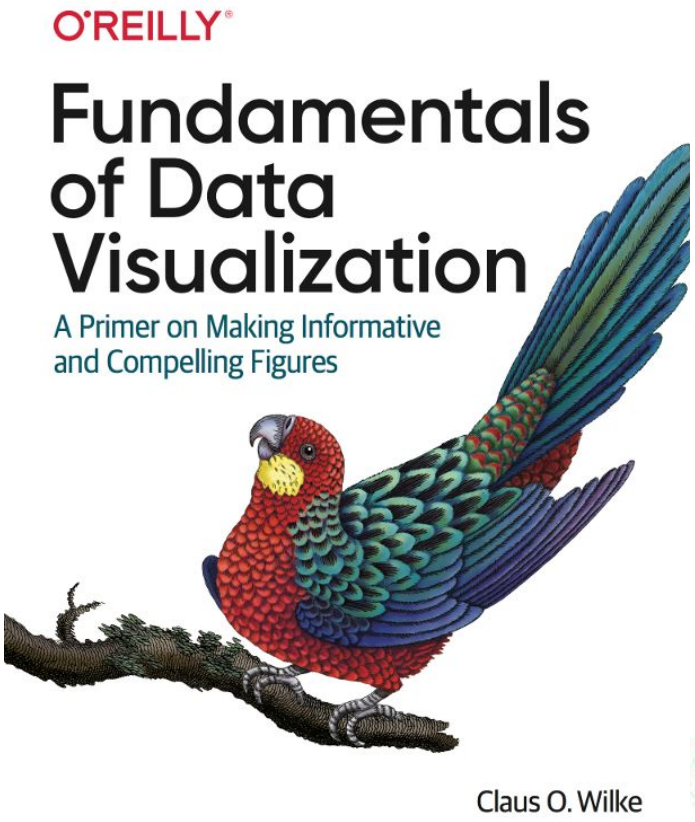
Visualización para bien … y para mal



Teoría de la visualización de datos

SÍ hay una teoría de visualización de datos:

https://clauswilke.com/dataviz/



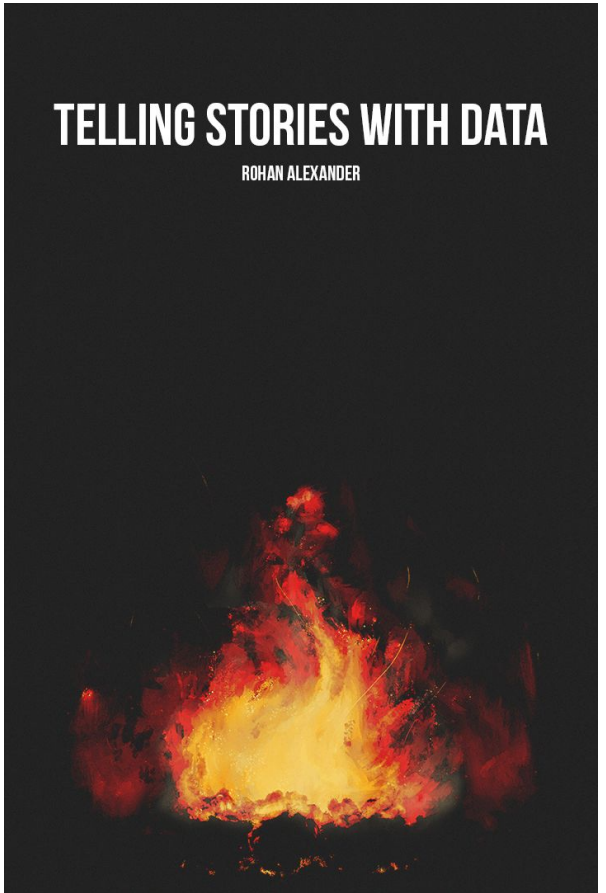
Teoría de la visualización de datos

Especialmente interesante el capítulo de “narrativa” (“telling a story”):

https://clauswilke.com/dataviz/telling-a-story.html

Y, extraordinario (basado en R pero igualmente generalizable a cualquier entorno):

https://tellingstorieswithdata.com/



¡Gracias!

Pedro Concejero

pedro.concejerocerezo@gmail.com

ntic master
revolucionamos la comunicación

UNIVERSIDAD COMPLUTENSE DE MADRID