ntic master
revolucionamos la comunicación

UNIVERSIDAD COMPLUTENSE DE MADRID



Visualización avanzada

Pedro Concejero

2. El proceso de trabajo en visualización

1. Objetivos del proyecto. Contexto, audiencia
2. Datos. La naturaleza *y la calidad* del dato
3. Entorno de trabajo. Librerías disponibles
4. Visualizaciones disponibles en estas librerías. ¿Interactivas o no? ¿Debemos presentarlas en una web o dashboard?
5. Narrativa
6. La presentación

1. Objetivos de un proyecto de ciencia de datos

¿Cuál es el objetivo de visualización?
¿Cuál es el objetivo de ciencia de datos?
Yo creo que es el mismo: **generar conocimiento** (=negocio si ese es el objetivo)

Visualización es metodología/tecnología aplicable en todas las fases de un proyecto de ciencia de datos

Pero para visualización es muy importante conocer a priori el contexto / audiencia para presentación final



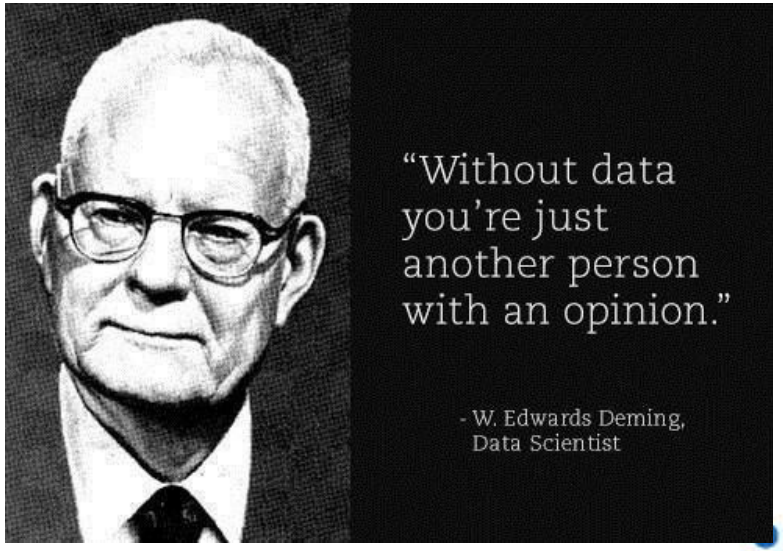
2. Datos

“No data, no game”... además ¿tienes los datos relevantes / representativos?



“In God we trust.
All others must bring data.”

- Dr. W. Edwards Deming



2. Datos

Lo primero, ante todo: conoce en detalle el dato. A menudo no es nada fácil -> Necesitaremos un diccionario o procedimientos para saber tipo de dato.
Por ejemplo:
https://www.kaggle.com/datasets/rajeshrampure/black-friday-sale/data

La naturaleza del dato es esencial (ver a continuación), pero además probablemente necesitaremos datos adicionales.

Lo veremos en gran detalle con datos COVID:
https://github.com/pedroconcejero/ucm_master_24_25/blob/main/04_datos_COVID_proporcionales_a_poblacion_DEF_heatmaps.ipynb

Tipos de datos condicionan tipos de gráficos

Conceptos clave:

Tipos de variable (también “nivel de medida”…)

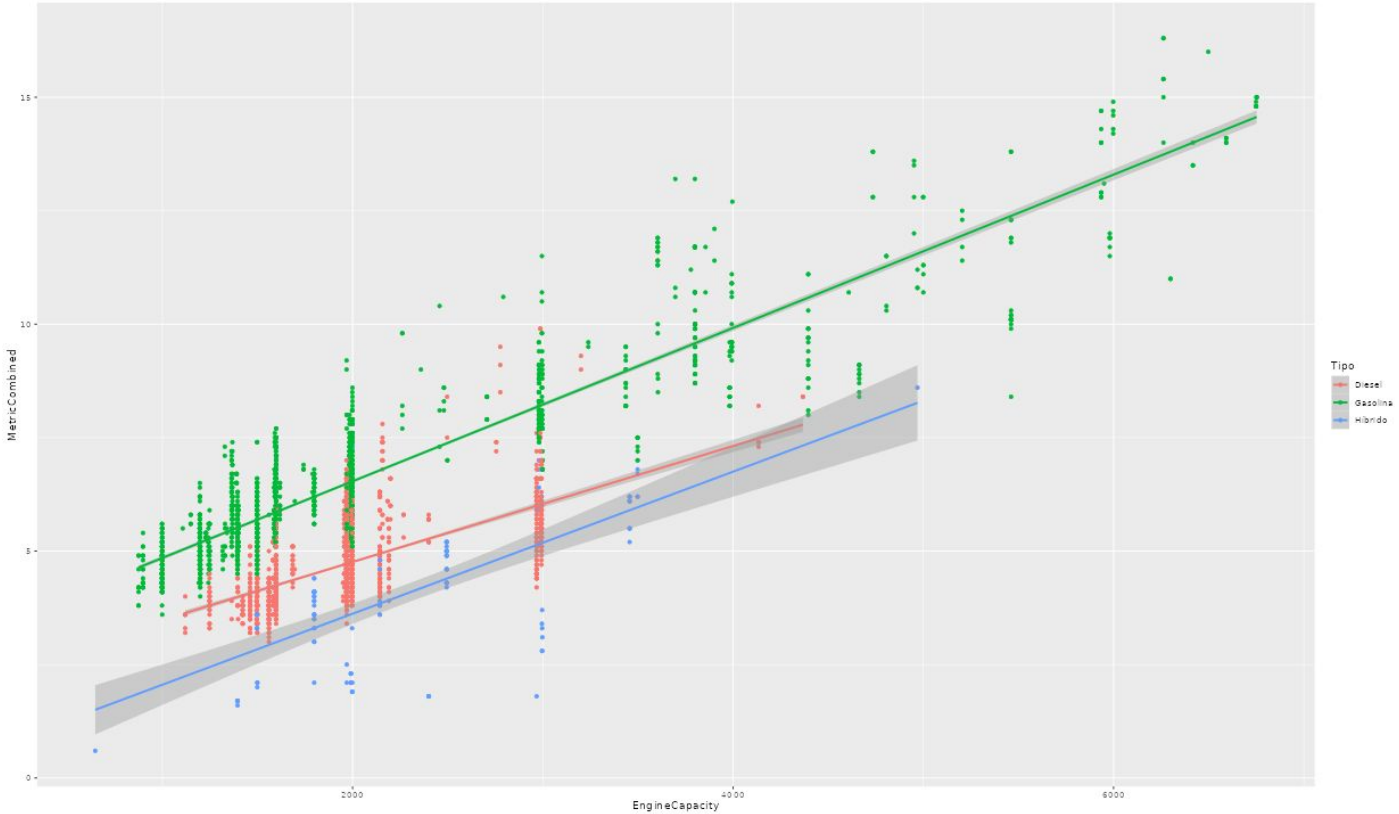
- Nivel de intervalo o razón: los números mantienen significado cuando se suman y se restan.
  - De entre las de nivel de intervalo:
  - discretas (“números enteros”)
  - continuas (“números racionales”)
  - porcentajes (normalmente de 0 a 100)
  - probabilidades (estrictamente entre 0 y 1)
  - etc.
- Categóricas o nominales: dos números diferentes sólo indican permanencia a categorías distintas, no suman ni permiten otras operaciones. Por ejemplo: código postal, matrícula… -> as.factor
- Ordinales: números mantienen significado de orden, pero no tienen propiedades de intervalo. Por ejemplo, algunas “rating scales”. (Nota: en la práctica todos los tratamos como de intervalo discretas)

Datos para módulo visualización

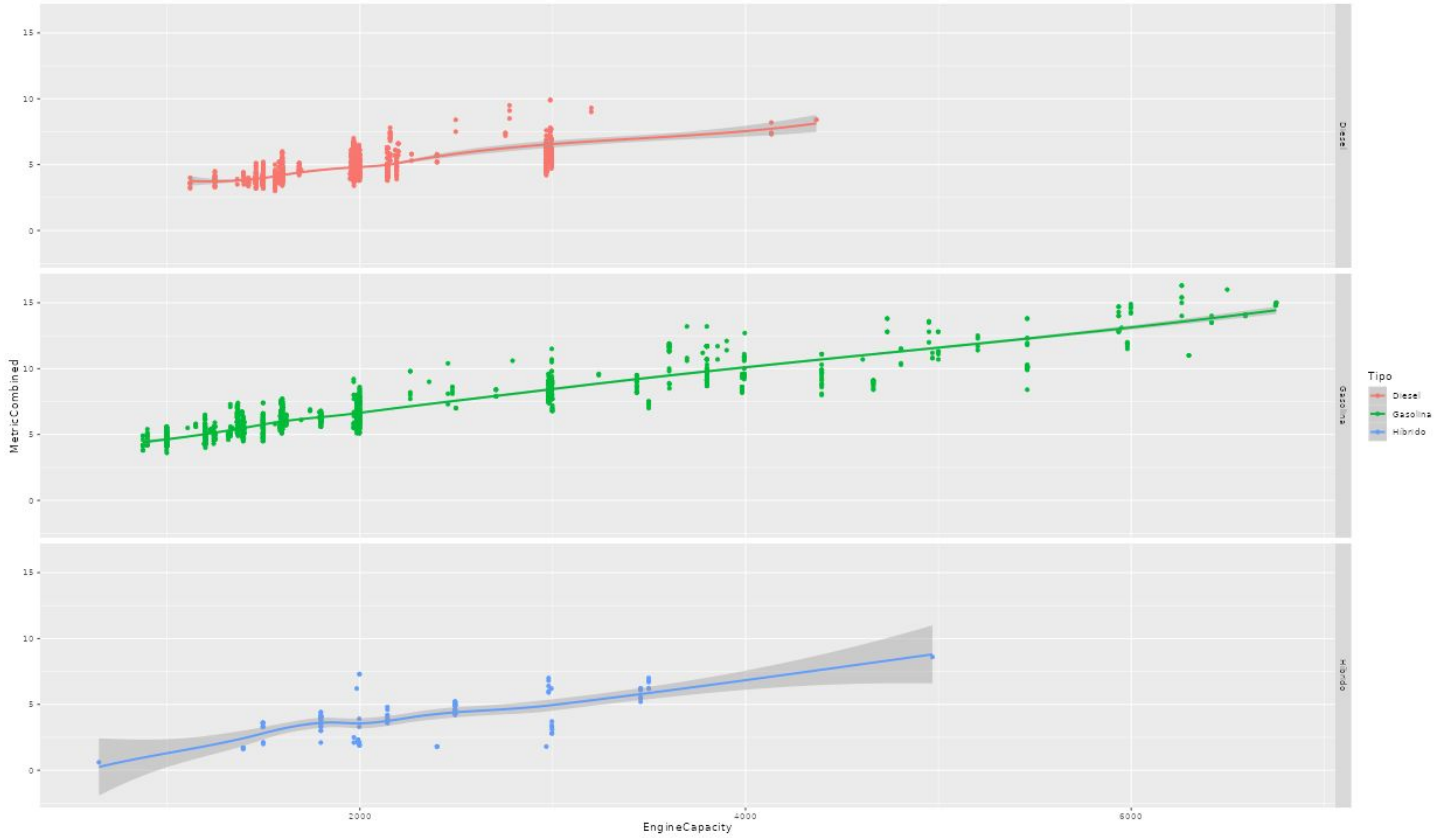
Datos disponibles en:

https://github.com/pedroconcejero/ucm_master_24_25/tree/main

Datos vehículos a la venta (UK) 2016



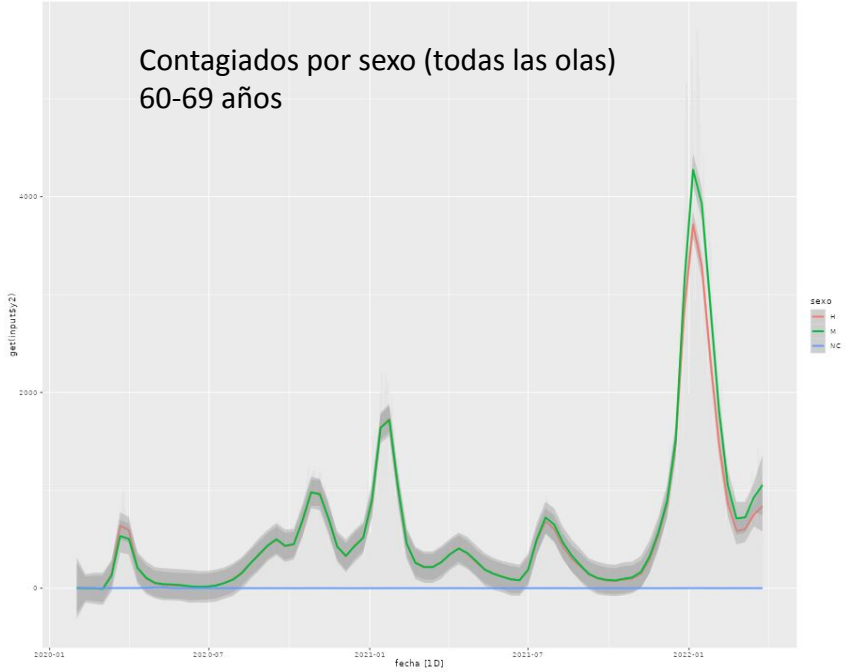
Datos vehículos a la venta (UK) 2016



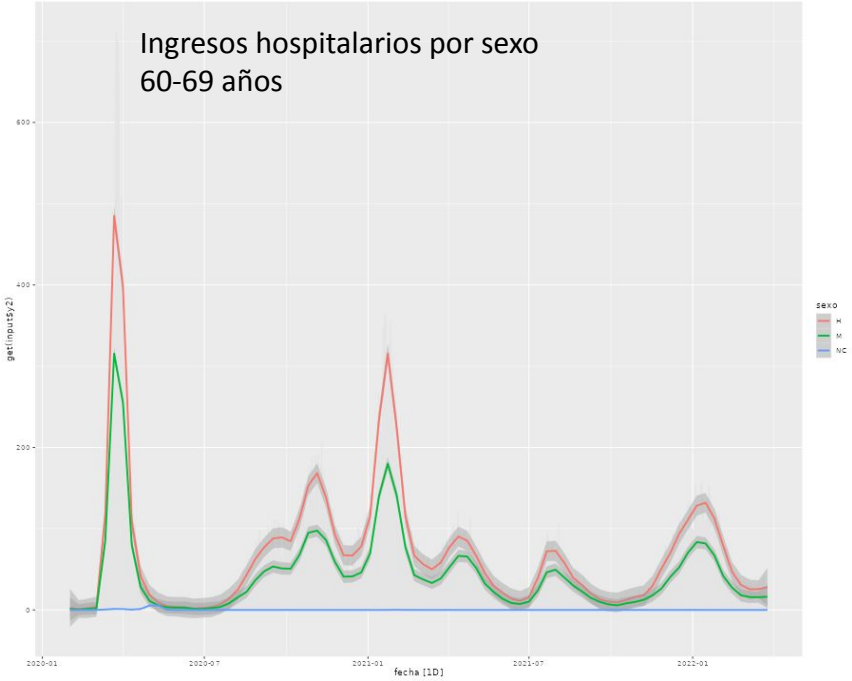
Datos COVID España 2020-2022

Datos de Instituto Salud Carlos III (ISCIII):
https://cnecovid.isciii.es/covid19/resources/casos_hosp_uci_def_sexo_edad_provres.csv

Contagiados por sexo (todas las olas)
60-69 años

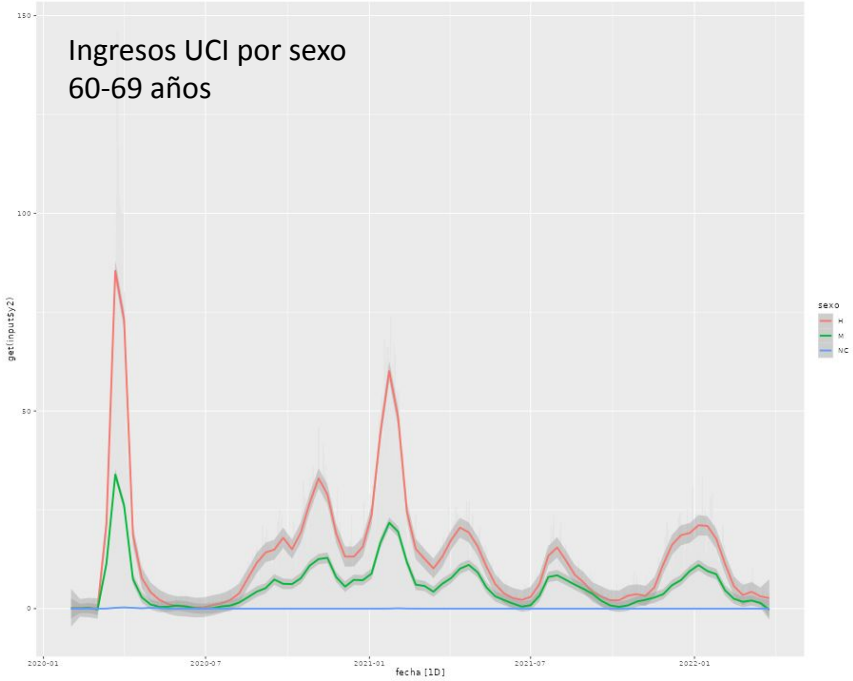


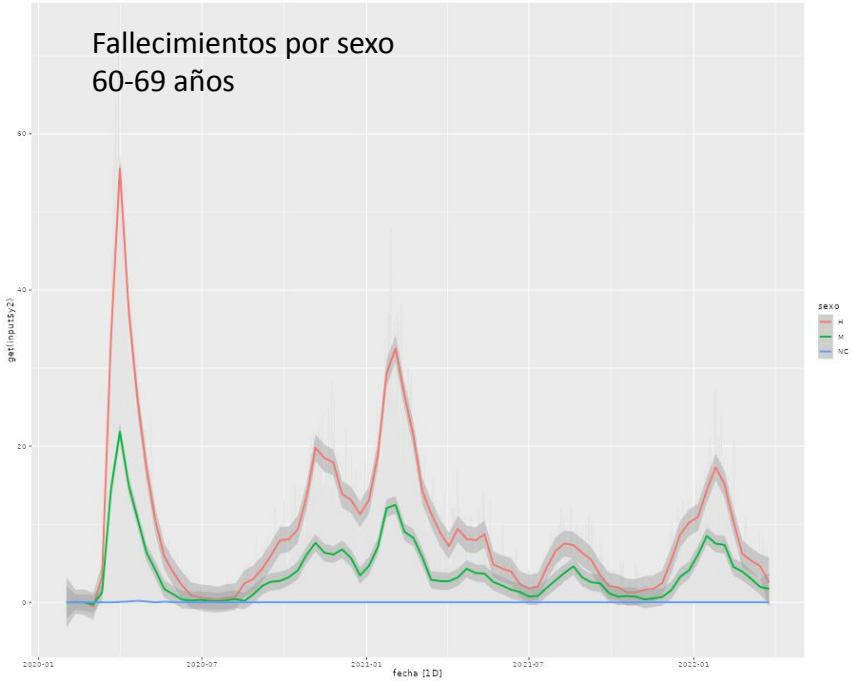
Ingresos hospitalarios por sexo
60-69 años



Datos COVID España 2020-2022

Datos de Instituto Salud Carlos III (ISCIII):
https://cnecovid.isciii.es/covid19/resources/casos_hosp_uci_def_sexo_edad_provres.csv





3. Entorno de trabajo

Trabajaremos en un entorno python, el que tenéis instalado o a partir de python.org versión 3.12 como máximo:
https://www.python.org/downloads/release/python-3129/

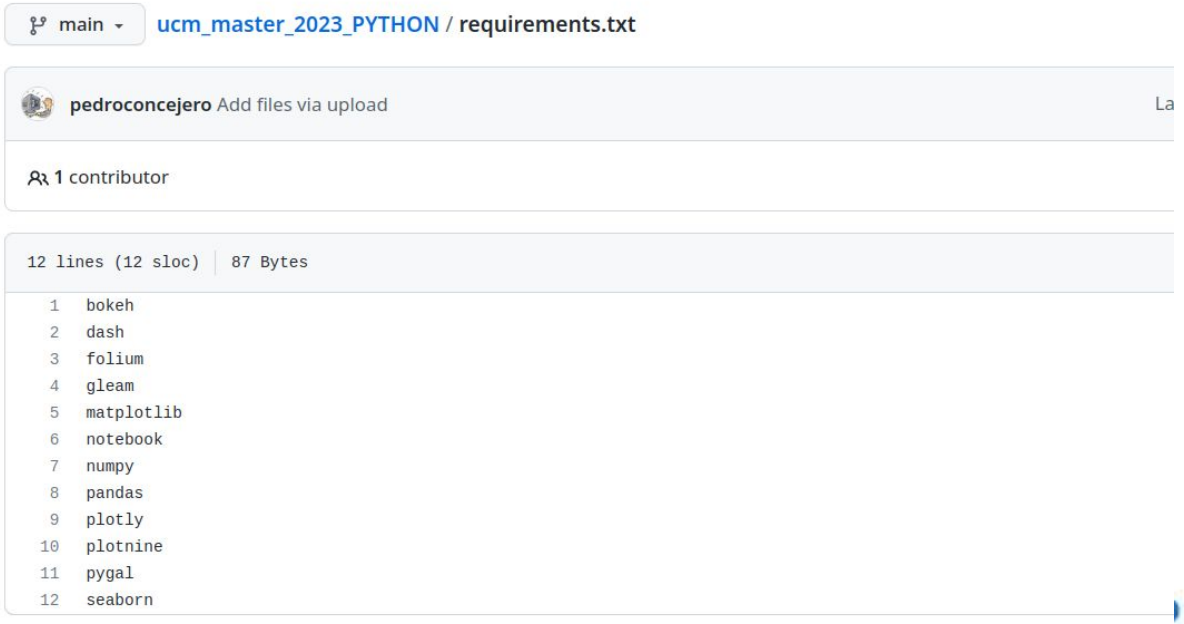
Y aconsejo conocer entornos virtuales:
https://docs.python.org/3/library/venv.html
https://www.freecodecamp.org/espanol/news/entornos-virtuales-de-python-explicados-con-ejemplos/



3. Entorno de trabajo

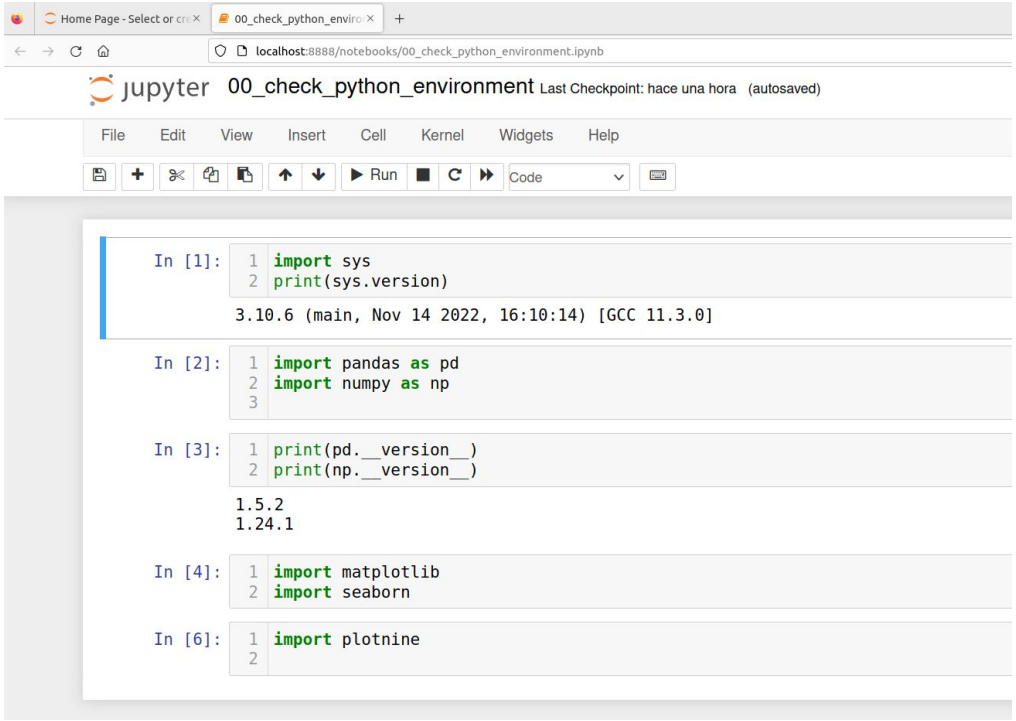
Instalación de paquetes necesarios para el módulo desde requirements.txt
https://github.com/pedroconcejero/ucm_master_24_25/blob/main/requirements.txt

(una vez descargado repo)
pip install -r requirements.txt



3. Jupyter notebooks

Por ejemplo:
https://github.com/pedroconcejero/ucm_master_24_25/blob/main/00_check_python_environment.ipynb



3. El entorno python - librerías

Podemos caracterizar las librerías de visualización de datos utilizando las siguientes dimensiones o criterios:

1. Interactividad: si la visualización generada permite interacción (o por el contrario es estrictamente estática)
2. Sintaxis: qué nivel de control permite la librería y si sigue un paradigma o teoría. Esto también tiene que ver con la *consistencia* de la sintaxis.
3. Fortalezas y documentación de la librería: para qué casos (ejemplos) es buena -está específicamente diseñada- la librería

La tabla siguiente pretende clasificar un conjunto bien establecido de librerías python para visualización:

3. El entorno python - librerías

Library	Interactive Features	Syntax	Main Strength and Use Case
Matplotlib	Limited	Low-level	Highly customized plots
seaborn	Limited	High-level	Fast, presentable reports
plotnine	Limited	High-level - Grammar of graphics	Thousands of reproducible examples (ggplot syntax)
Plotly	Yes	High- and low-level	Commercial applications and dashboards

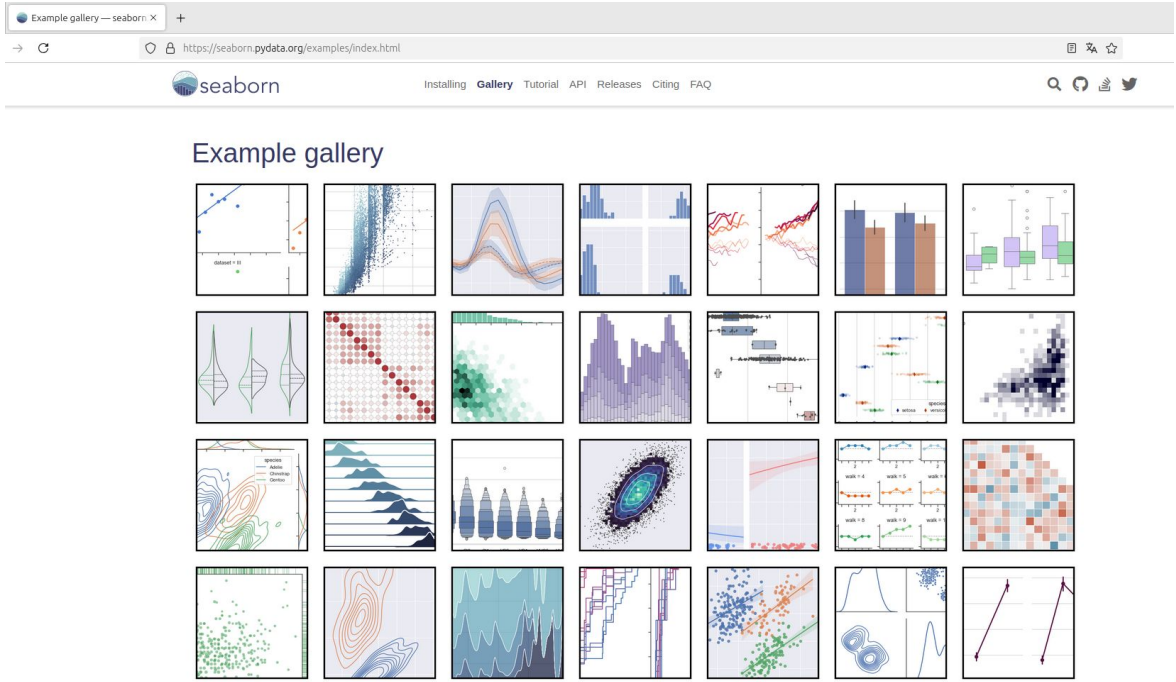
4. Visualizaciones disponibles en estas librerías de alto nivel

MUY IMPORTANTE: Comprender la naturaleza de los datos que representamos:

- ¿Tienen significado completo los números que representamos? ¿Son medidas estrictamente cuantitativas? (Lo que se conoce como nivel de medida a nivel de intervalo)
- O por el contrario, ¿los números son arbitrarios? ¿Responden a una codificación que no mantiene las propiedades naturales de las medidas cuantitativas? (Lo que se conoce como nivel de medida cualitativa o nominal)

4. Visualizaciones disponibles en estas librerías de alto nivel

https://matplotlib.org/stable/gallery/index.html
(lo más básico -y quizás no tan aconsejable)
https://seaborn.pydata.org/examples/index.html
(mucho mejor, sin duda)



4. Visualizaciones disponibles en estas librerías de alto nivel

Guías sobre tipos de gráficos modernos

¿Quizás demasiadas? Para mi las mejores:

https://datavizcatalogue.com/

https://www.data-to-viz.com/

(pero veremos más “galerías” asociadas a las diferentes librerías de cada módulo)

5. Narrativa

Traducido a partir de
https://clauswilke.com/dataviz/telling-a-story.html

- Haz una imagen “para los generales”
- Construye para introducir imágenes complejas
- Haz tus imágenes memorables
- Sé consistente pero no seas repetitivo

6. La presentación

Muy importante: el contexto de la presentación

- La audiencia: ¿requiere explicaciones previas sobre el proyecto y los datos?
- ¿Es un auditorio o un lugar pequeño?
- ¿Cuánto tiempo tienes?
- ¿Cuál es el mecanismo de presentación de imágenes? ¿Serán proyectadas o en pantalla retroiluminada? Hay un mundo de diferencias
- … y un larguísimo etc.

¡Gracias!

Pedro Concejero

pedro.concejerocerezo@gmail.com

ntic master
revolucionamos la comunicación

UNIVERSIDAD COMPLUTENSE DE MADRID