ntic master
revolucionamos la comunicación

UNIVERSIDAD COMPLUTENSE DE MADRID



Visualización avanzada

Pedro Concejero

Nuevo dataset vehículos a la venta en España - 2024

1. Objetivos
2. Datos.
   a. El sector del automóvil en la actualidad. WLTP
   b. Dataset original
   c. Preparación de dataset definitivo
3. Los retos

1. Objetivos de proponer este (nuevo) dataset

El mercado del automóvil ha cambiado radicalmente en estos últimos 10 años. El dataset de UK 2016 es muy adecuado para propósito educativo -el de este máster- pero no tanto para hacer análisis realistas de la actualidad.

¿Por qué no lo he propuesto antes? Pues porque no localicé un dataset equivalente en los datos de homologación de la UE.

1. Objetivos de proponer este (nuevo) dataset

Finalmente este año localicé una fuente de información y me lancé a ello. Fácil no ha sido, y por el momento el análisis no está completo, pero creo interesante compartirlo con vosotros para que, quien esté interesado, pueda utilizarlos en sus trabajos o proyectos.

Veamos cómo están obtenidos y qué pre-proceso ha sido necesario para ponerlo a punto.

2.a Datos: WLTP

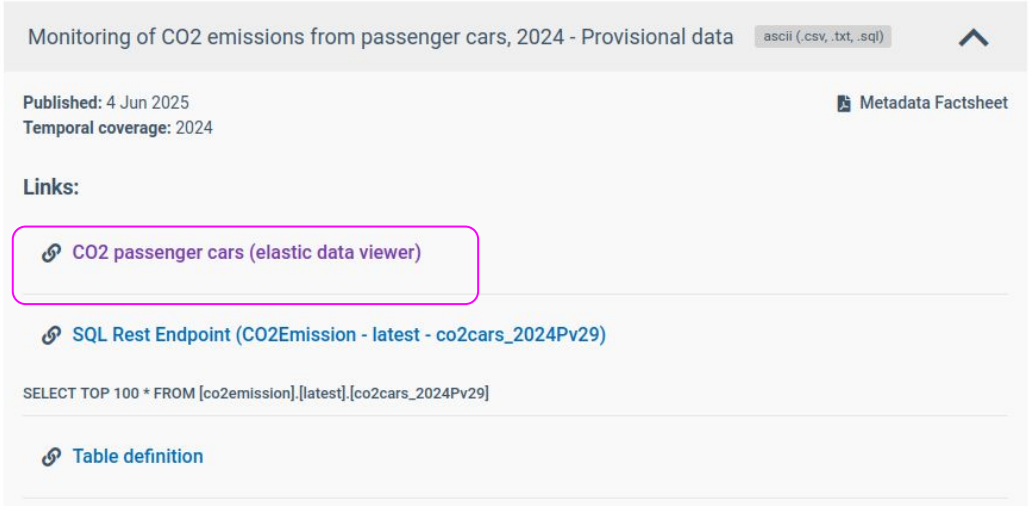
WLTP es el acrónimo de Worldwide-Harmonised Light-Vehicle Test Procedure y se estableció a partir de 2017 a partir de datos de conducción reales (en parte -o quizás completamente) para responder al “Dieselgate”.
También incluye procedimientos para vehículos que no tienen motor de combustión.
https://www.wltpfacts.eu/what-is-wltp-how-will-it-work/
A diferencia de datos anteriores, los actuales se centran en las emisiones de CO2.

2.b Datos: Dataset original de la UE

Después de varias búsquedas (por cierto fallidas) en chatGPT, localicé esta fuente de información oficial de la UE:

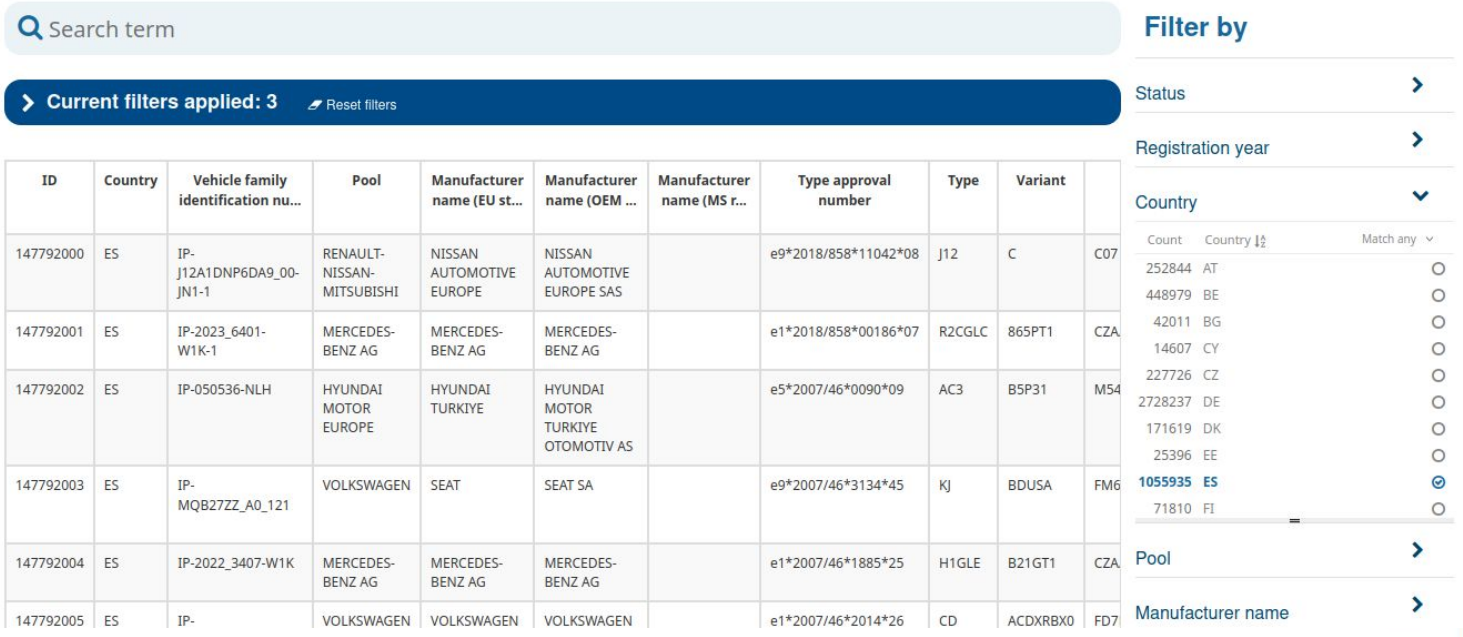
https://www.eea.europa.eu/en/datahub/datahubitem-view/fa8b1229-3db6-495d-b18e-9c9b3267c02b

Después será necesario entrar en la página resaltada:



2.b Datos: Dataset original de la UE

Una vez en sa página se abre un visor de los datos en forma de tabla en elque se puede seleccionar (filtrar) por país de la UE. Elegimos ES, el código de España:



ID	Country	Vehicle family identification nu...	Pool	Manufacturer name (EU st...	Manufacturer name (OEM ...	Manufacturer name (MS r...	Type approval number	Type	Variant	
147792000	ES	IP-J12A1DNP6DA9_00-JN1-1	RENAULT-NISSAN-MITSUBISHI	NISSAN AUTOMOTIVE EUROPE	NISSAN AUTOMOTIVE EUROPE SAS		e9*2018/858*11042*08	J12	C	C07
147792001	ES	IP-2023_6401-W1K-1	MERCEDES-BENZ AG	MERCEDES-BENZ AG	MERCEDES-BENZ AG		e1*2018/858*00186*07	R2CGLC	865PT1	CZA
147792002	ES	IP-050536-NLH	HYUNDAI MOTOR EUROPE	HYUNDAI TURKIYE	HYUNDAI MOTOR TURKIYE OTOMOTIV AS		e5*2007/46*0090*09	AC3	B5P31	M54
147792003	ES	IP-MQB27ZZ_A0_121	VOLKSWAGEN	SEAT	SEAT SA		e9*2007/46*3134*45	KJ	BDUSA	FM6
147792004	ES	IP-2022_3407-W1K	MERCEDES-BENZ AG	MERCEDES-BENZ AG	MERCEDES-BENZ AG		e1*2007/46*1885*25	H1GLE	B21GT1	CZA
147792005	ES	IP-	VOLKSWAGEN	VOLKSWAGEN	VOLKSWAGEN		e1*2007/46*2014*26	CD	ACDXRBX0	FD7

2.b Datos: Dataset original de la UE

Y así podremos descargar el dataset en formato csv para usarlo de igual modo que el resto de datasets del módulo.
Pero son >1 millón de registros!



147792009	ES	IP-HNP___MB6_142A-VF7-0	STELLANTIS	AUTOMOBILES CITROEN	AUTOMOBILES CITROEN		e4*2007/46*1241*21	2	R	HNP

Download search results (CSV)

Results 1 – 10 of 1055935 next >>

Data sources

EEA Data: Monitoring of CO2 emissions from passenger cars – Regulation (EU) 2019/631 provided by European Environment Agency (EEA)
August 2023: the number of visible decimals for the field erwltp was increased to 2

Application data last refreshed **02 June 2025 14:09 PM**. Version info **eeacms/esbootstrap:v3.1.5** and tag version **v3.1.5** on **elastic7-app-CO2-cars-esapp-1**.

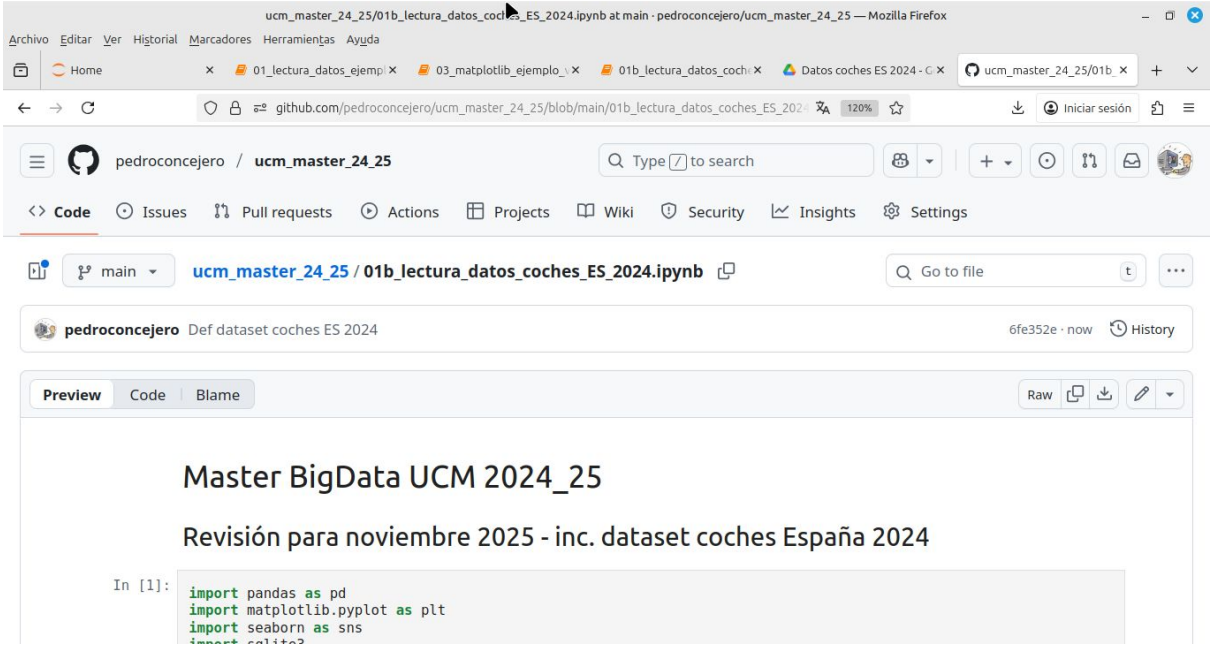
2.c Datos: Preparación de dataset definitivo

El dataset original incluye *todos* los registros de cada vehículo (ojo, no son vehículos vendidos, sino a la venta) durante el año 2024. Esto quiere decir que para un mismo modelo se pueden haber hecho múltiples registros ya sea por variaciones en el modelo o por mínimos cambios, incluso de un código del fabricante.

No podemos trabajar con este dataset, o resultará muy difícil, por lo que propongo un pre-proceso que deje un único registro por vehículo a la venta, el de fecha más reciente

2.c Datos: Preparación de dataset definitivo

Este pre-proceso lo tenéis aquí (lo habréis descargado junto con resto de notebooks y datos):



2.c Datos: Preparación de dataset definitivo

Y finalmente se genera un pickle para uso directo en notebooks con pandas:

3. Guardamos los dataframes

Propósito:

- Guardar (serializar) los objetos con sus transformaciones para uso directo en siguientes notebooks

In [22]:
```
df_filtrado.to_pickle("datos_vehiculos_ES_2024.pkl")
```

Este dataset está incluido en el github del módulo

3. Retos

¿Por qué propongo este dataset aunque no tenga (todavía) los análisis correspondientes? Pues para plantearos retos:

- El más directo: replicar los análisis hechos con dataset UK 2016 con estos datos
- Más complejos: encontrar modelos para comprender qué es lo que determina las emisiones de CO2 (en los de combustión claro está)
- Y proponer “etiquetas”. Se van a renovar las etiquetas DGT de efecto ambiental, por fin (!) teniendo en cuenta las emisiones de CO2. ¿Puedes proponer una tabla de etiquetas a partir de estos datos oficiales?

¡Gracias!

Pedro Concejero

pedro.concejerocerezo@gmail.com

ntic master
revolucionamos la comunicación

UNIVERSIDAD COMPLUTENSE DE MADRID